

資料科學導論與工具鏈建置

M0 — Introduction to Data Science & Toolchain Setup

這門課要教的東西是怎麼演變成今天這樣的、現在什麼技術重要、以及它在健康照護場域實際被拿來做什麼。

本單元大綱

01 什麼是資料科學

四個問題與技能組成

02 技術演進： 1960-2011

從統計到資料探勘（Data Mining）

03 技術演進： 2012-2026

從深度學習（Deep Learning）到 Agent

04 2026 年的技術地圖

現在什麼重要

05 應用領域巡禮

六大領域與健康照護場景

06 AI / ML / DL / GenAI

含 NLP 七十年演進

07 資料科學工作流程

六個步驟與時間的真相

08 工具鏈建置

AI Studio、Anaconda、Ollama

09 第一個端到端專案

MPG 線性迴歸（Linear Regression）實作

10 專案界定 Scoping

六步驟把範圍寫成一頁

11 選定你的貫穿主線

整學期會用三次的題目

PART 01

什麼是資料科學

What Is Data Science

這個詞被用得太浮濫，幾乎什麼都能塞進去。
先把邊界劃清楚，後面十七週才不會迷路。

資料科學的三個支柱

1

統計與數學

- ▶ 描述統計、機率分布、抽樣
- ▶ 假設檢定與信賴區間
- ▶ 迴歸與相關分析
- ▶ 線性代數（矩陣、向量、特徵值）
- ▶ 最佳化（梯度下降的直覺）
- ▶ 本課程只講到「能正確使用」的程度

2

運算與工具

- ▶ 資料存取、清理、轉換的能力
- ▶ 建模工具的操作（本課用 AI Studio）
- ▶ 結果的視覺化與呈現
- ▶ 版本管理與流程可重現性
- ▶ 程式能力有加分但非必要
- ▶ 重點是流程對，不是語法熟

3

領域知識

- ▶ 知道哪些變數在生理上說得通
- ▶ 知道哪些遺失值（Missing Data）是有意義的
- ▶ 知道模型錯了會造成什麼後果
- ▶ 知道結果要講給誰聽、怎麼講
- ▶ 這是你們相對於資工背景的優勢
- ▶ 也是最難速成、最不可取代的一塊

三者缺一都做不出有用的東西。缺統計會誤讀結果、缺工具做不出來、缺領域知識則會做出「統計上正確、實務上有害」的系統。

資料科學與相鄰名詞的差別

名詞	主要在問什麼	時間視角	典型產出
商業智慧 (Business Intelligence, BI)	發生了什麼事?	過去	儀表板、報表、 KPI 追蹤
資料分析 Data Analysis	為什麼會這樣?	過去到現在	分析報告、因素探討、 A/B 測試結論
資料科學 Data Science	接下來會怎樣? 該怎麼做?	未來	預測模型、決策建議、可部署的系統
機器學習 Machine Learning	如何從資料中自動學出規律?	方法層次	訓練好的模型與評估指標
資料工程 Data Engineering	資料怎麼可靠地流到需要的地方?	基礎設施	資料管線、資料倉儲 (Data Warehouse) 、 ETL 流程

這五者在實務上高度重疊，職稱也常混用。本課程涵蓋的是「資料分析 → 資料科學 → 機器學習」這一段。

資料分析回答的四個問題

問題	分析型態	典型產出	誰在做
發生了什麼事？	描述性分析 (Descriptive Analytics) Descriptive	儀表板、報表、 KPI 追蹤、趨勢圖	商業智慧 (Business Intelligence, BI) 資料分析
為什麼會這樣？	診斷性分析 (Diagnostic Analytics) Diagnostic	根因分析、下鑽比較、相關分析與 A/B 測試	資料分析 領域專家
接下來會發生什麼？	預測性分析 (Predictive Analytics) Predictive	風險分數、需求預測、分類與迴歸模型	資料科學 機器學習
我們該怎麼做？	指示性分析 (Prescriptive Analytics) Prescriptive	最佳化建議、決策支援系統、自動化行動	資料科學 作業研究

【原講義 ML 3.1】 p9，依 Gartner 分析成熟度模型補上「診斷性」。四者不是取代關係而是層層堆疊——沒有把「發生了什麼」看清楚，就跳到「接下來會怎樣」，多半會做出漂亮但沒用的模型。

實例：描述、預測、指示其實在同一條時間軸上



① 描述性 (深色實線)

過去 24 個月實際發生的急診人次。BI 儀
表板做的就是這段

② 預測性 (藍虛線)

未來 6 個月的推估，淺藍區塊是不確定區間。
本課 M2 做的就是這件事


③ 指示性 (紅虛線)

「超過 160 就加開門診」——把預測轉成
行動的門檻

三者疊在一起才有用

只有描述 = 知道發生什麼卻來不及；只有預
測 = 知道會發生卻不知道該做什麼

資料科學的技能組成



程式與工具

- 資料存取、清理、轉換
- 建模工具操作（本課用 AI Studio）
- 結果視覺化與呈現
- 流程可重現性

數學與統計

- 描述統計、機率分布
- 假設檢定與信賴區間
- 迴歸與相關分析
- 最佳化的基本直覺

領域專業

- 知道哪些變數生理上說得通
- 知道哪些遺失值（Missing Data）有意義
- 知道模型錯了會怎樣
- 知道結果要講給誰聽

改繪自 Drew Conway（2010）資料科學文氏圖。會寫程式又懂領域、卻缺統計，落在「危險區」：做得出東西，卻可能誤讀結果。三者交集處才是資料科學。

常見演算法地圖

機器學習

監督式 迴歸

有標籤，預測連續數值

線性迴歸

迴歸樹

隨機森林

神經網路

監督式 分類

有標籤，預測類別

決策樹

k-NN

Logistic

Naive Bayes

非監督式 分群 (Clustering)

無標籤，找出群體結構

K-Means

階層式

DBSCAN

X-Means

非監督式 降維

無標籤，壓縮維度

PCA

SVD

t-SNE


自編碼器

【原講義 ML 3.1】 p13。本課程 M2 涵蓋前兩列、M3 涵蓋後兩列，M4 加上集成方法，M5 進入深度學習（Deep Learning）。

監督式與非監督式：從「資料長什麼樣」就分得出來

監督式：有標籤（y）

客戶	月費	方案	使用時數	是否取消
C001	399	基本	12	是
C002	799	進階	45	否
C003	399	基本	3	是
C004	1299	旗艦	80	否



非監督式：沒有標籤

客戶	月費	方案	使用時數
C001	399	基本	12
C002	799	進階	45
C003	399	基本	3
C004	1299	旗艦	80

x 變數 = 特徵 = 輸入

月費、方案、使用時數——這些是餵給模型的東西，兩種學習都需要

y 變數 = 標籤 = 目標

「是否取消」只有監督式才有。它是你想預測的那個已知答案

監督式在做什麼

用歷史資料學出 $x \rightarrow y$ 的對應，再用來預測未來的新客戶


非監督式在做什麼

沒有答案可學，改問「哪些客戶彼此相似」——找結構而不是做預測


【原講義 ML 3.1】 pp35-37。換到醫療場域：x 是檢驗值與病史，y 是「三個月內是否再入院」。有沒有 y 決定了你走哪一條路。

實例：有標籤與沒標籤，長得完全不同

左・監督式 有 label



右・非監督式 沒有 label



左・監督式

每個點自帶顏色 ($y=0$ 或 1)。模型的工作是學一條線把兩色分開

右・非監督式

全部同色。沒有答案可學，只能問「哪些點自然聚在一起」

同一份 x 特徵

兩張圖的點座標完全一樣——差別只在「有沒有那一欄答案」

怎麼判斷你的題目

打開資料，看有沒有一欄是你想預測的結果。有＝監督式，沒有＝非監督式

隨堂測驗：這是監督式還是非監督式？

Q
1

估計元旦當天會有多少人上門就診

有明確的數值答案可以從歷史資料學 → 監督式（迴歸）

Q
2

找出病人回饋意見中最常被提到的幾個主題

沒有預先定義的主題清單，要讓演算法自己找 → 非監督式（主題建模）

Q
3

標記哪些病人最可能在三個月內再入院

歷史資料中有「是否再入院」的答案 → 監督式（分類）

Q
4

把病人依生活型態與共病狀況分成幾個族群

沒有預先定義的族群 → 非監督式（分群）

【原講義 ML 3.1】 pp32-33 的 Knowledge Check，改寫為健康照護情境。判斷方式只有一個：你的資料裡有沒有「答案」那一欄。

為什麼健康照護特別需要資料科學

這個領域的資料條件

- ▶ 縱貫性強：同一個人有多年的就醫、用藥、檢驗紀錄
- ▶ 多模態：結構化檢驗值、文字病歷、影像、生理訊號並存
- ▶ 標籤相對好取得：診斷碼、死亡、再入院都可當結果變數
- ▶ 介入可行：預測出高風險後，真的有事情可以做
- ▶ 價值密度高：提早發現一個個案的價值遠高於一次點擊

但也有這些困難

- ▶ 少數族群樣本稀少，正是最需要被辨識的人
- ▶ 標籤可能反映的是「誰有能力就醫」而非「誰真的生病」
- ▶ 錯誤的代價不對稱：多數情況漏診比誤報嚴重
- ▶ 可解釋性要求高，黑箱模型難以被臨床採信
- ▶ 法規與倫理限制多，資料取得與使用門檻高

本課程的所有案例都建立在這組張力之上：技術能做到的，和專業場域能接受的，往往不是同一件事。

PART 02

技術演進 上篇： 1960 - 2011

From Statistics to Data Mining

今天的每一個技術名詞，都是為了解決前一代做不到的事而出現的。
知道它在解決什麼，比記住它叫什麼有用。

四個時代，四種「資料被當成什麼」

1960s-70s

資料是「樣本」

- 統計推論、假設檢定
- 迴歸與變異數分析
- 決策支援系統 DSS
- 資料少而貴，靠抽樣
- 人提出假設，電腦驗證

1980s

資料是「紀錄」

- 關聯式模型與正規化 (Normalization)
- SQL 成為標準查詢語言
- 交易系統大量普及
- 資料第一次被大量累積
- 但只用來查，不用來推

1990s

資料是「資產」

- 資料倉儲 Data Warehouse
- OLAP 多維度分析
- KDD 知識發現 (Knowledge Discovery) 流程
- CRISP-DM 方法論成形
- 電腦開始「找」假設

2000s

資料是「原料」

- 決策樹、SVM、隨機森林 (Random Forest)
- 集成學習 (Ensemble Learning) 成為主流
- Hadoop 與大數據
- Netflix Prize 競賽
- 「資料科學家」一詞出現

真正的轉折在 1990 年代：從「人提出假設、電腦驗證」變成「電腦從資料中找出假設」。這就是 Knowledge Discovery in Databases 的核心主張。

上篇的關鍵里程碑

1958	Perceptron 感知器提出	最早的神經網路雛形。1969 年 Minsky 與 Papert 證明單層感知器無法處理非線性問題
1970	關聯式資料庫模型	Codd 提出關聯模型，資料從此可以被有結構地累積——這是後續一切的前提
1984	CART 決策樹提出	Breiman 等人。可解釋、不需正規化、對資料型態寬容——直到今天仍是醫療場域的重要選項
1986	反向傳播演算法普及	多層網路終於可以訓練。但當時算力與資料量都不足，效果有限
1996	KDD 流程正式提出	Fayyad 等人把「從資料到知識」拆成五個步驟，資料探勘（Data Mining）只是其中一步
1999	CRISP-DM 發表	業界標準流程。二十多年來幾乎沒有被取代，本課程的六步驟工作流程即由此簡化
2001	隨機森林（Random Forest）	Breiman 提出。與後來的梯度提升（XGBoost, 2016）同為表格資料上最可靠的方法
2006	Hadoop 開源	分散式儲存與運算，讓「大數據」從概念變成一般組織也做得到的事

三套方法論，今天仍在用

方法論	年份	步驟	現有的地位
KDD Process	1996	選取 → 前處理 → 轉換 → 資料探勘（Data Mining）→ 詮釋 評估 → 知識	學術界的標準描述； 「資料探勘」即其中一步
CRISP-DM	1999	業務理解 → 資料理解 → 資料準備 → 建模 → 評估 → 部署	業界最廣泛使用； 二十多年幾乎沒被取代
SEMMA	1998	Sample → Explore → Modify → Model → Assess	SAS 提出，偏工具導向； 使用率低於前兩者

共同點：建模（資料探勘）都只是其中一步。真正花時間的是前面的資料準備——這件事二十多年來沒有改變。

CRISP-DM：一個會不斷繞回去的循環



它不是直線。評估後常常要回到業務理解重新界定問題，資料準備與建模之間更是反覆來回——這才是真實專案的樣子。

PART 03

技術演進 下篇： 2012 - 2026

From Deep Learning to Agents

過去十四年發生的事比前面五十年還多。

但推動它的其實只有三個因素。

深度學習（Deep Learning）到生成式 AI

2012-2016

深度學習（Deep Learning）崛起

- AlexNet 奪下 ImageNet
- GPU 訓練成為標準
- CNN 在影像上壓倒傳統方法
- RNN / LSTM 處理序列
- AlphaGo 擊敗李世乭

2017-2019

Transformer 與預訓練

- Attention Is All You Need
- BERT 改寫 NLP 格局
- GPT-2
- 「預訓練+微調」成為範式
- 遷移學習降低資料需求

2020-2023

大型語言模型

- GPT-3 展示 few-shot 能力
- ChatGPT 引爆大眾使用
- RAG 成為企業標配
- 開源模型跟上
- 提示詞工程（Prompt Engineering）成為一項技能

2024-2026

Agent 與落地

- 工具調用與自主任務拆解
- 多代理協作與編排
- 多模態：文字+影像+語音
- 本地部署成熟（Ollama）
- 焦點從「多強」轉向「怎麼落地」

下篇的關鍵里程碑

(1 / 2) 2012-2020：深度學習到大型語言模型

2012	AlexNet 贏得 ImageNet	錯誤率一次降低十個百分點。深度學習從冷門變成主流，只花了一場競賽
2014	GAN 生成對抗網路	讓機器生成逼真影像的重要突破，為後來的生成式 AI 埋下伏筆
2017	Transformer 架構	以 Attention 取代循環結構，可平行訓練、能處理長距離依賴——今日 LLM 的共同基礎
2018	BERT 與預訓練範式	一個模型預訓練、多個任務微調。NLP 從此不必每個任務從零開始
2020	GPT-3 與 few-shot	不必微調，光靠提示就能完成新任務。「提示詞」第一次成為一種介面

下篇的關鍵里程碑

(2 / 2) 2022-2027：從人人可用到真正落地

2022	ChatGPT 公開	技術本身不算全新，但把門檻降到人人可用——這才是真正的分水嶺
2023	RAG 成為標準架構	2020 年 Lewis 等人提出、2023 年普及。緩解知識過期，並讓答案可追溯來源
2024-25	Agent 與工具調用	模型從「回答問題」走向「完成任務」。責任邊界與可控性成為主要課題
2026-27	★ 小模型與落地年	(趨勢預測) Gartner 預估 2027 年企業使用任務專用小模型的次數將達通用 LLM 的三倍

★ 最後一格是預測而非既成事實：對醫療機構而言，資料不出院、成本可控的領域小模型往往比最大的通用模型實際——這是本課程 Ollama 與本地部署章節的現實背景。

演進背後只有三個推力

1

資料變多了

- ▶ 數位化讓一切留下紀錄
- ▶ 電子病歷普及（EMR / EHR）
- ▶ 穿戴裝置持續產生生理訊號
- ▶ 網路文本成為訓練語料
- ▶ 但「多」不等於「好」
- ▶ 醫療的瓶頸多在品質不在量

2

算力變便宜了

- ▶ GPU 從繪圖轉為通用平行運算
- ▶ 雲端讓中小單位也租得起
- ▶ 訓練成本降、推論成本仍高
- ▶ 本地端小模型開始可行
- ▶ 算力決定什麼想法值得試
- ▶ 也決定誰能參與競賽


3

演算法有突破

- ▶ 反向傳播讓深層網路可訓練
- ▶ Attention 解決長距離依賴
- ▶ 預訓練讓知識可重複使用
- ▶ 自監督擺脫標註瓶頸
- ▶ 每次突破解開一個舊限制
- ▶ 但沒有一次是全面取代前代

重要觀念：新技術很少「取代」舊技術，多半只是「多了一個選項」。決策樹（Decision Tree）在 2026 年仍然是很多場域的最佳選擇。

實例：為什麼是現在（對數尺度）



兩條線都是對數軸

每一格代表 10 倍。實際成長比視覺上看到的還誇張

2012 的轉折

AlexNet 贏得 ImageNet——不是演算法突然變聰明，是 GPU 算力與 ImageNet 百萬張標註影像同時到位


2017 的轉折

Transformer。這次是演算法突破，讓算力可以平行化利用

推力只有三個

資料、算力、演算法。三者到齊之前，深度學習的想法已經存在數十年

語言模型參數量的量級變化（單位：十億參數，對數尺度）



兩個方向同時發生：前沿模型仍在變大（如 DeepSeek-V3 總參數 671B，採 MoE、每次只啟用約 37B）；同時小模型已足以勝任許多特定任務，在成本、延遲與隱私上更適合落地。數值為代表性量級。

從傳統機器學習到深度學習：典範改變了什麼

	傳統機器學習（2000s）		深度學習與生成式 AI（2012-）
誰決定特徵	人：靠領域知識手工設計特徵， 特徵工程（Feature Engineering）是最耗人力的環節	→	模型：從原始輸入自行學出表徵， 但需要大量資料才餵得飽
需要多少標註	每個任務都要重新標註， 標註成本是主要瓶頸	→	預訓練＋微調， 少量標註即可達到可用水準
如何解釋結果	係數（Coefficient）、決策路徑、特徵重要性（Feature Importance）， 可以印出來給臨床人員看	→	中間層難以直接解讀， 需要額外的解釋方法
部署形式	算出一個分數或類別， 交給人去判讀	→	直接產生語言、建議與行動， 人的角色變成審核者

最後一列是本課程 Phase C 的核心議題：當系統開始「建議行動」而不只是「給分數」，責任邊界就必須重新界定。

PART 04

2026 年的技術地圖

The Current Landscape

名詞很多，但可以整理成四層。

你不需要每一層都精通，但要知道自己站在哪一層。

資料科學的四層技術堆疊



為什麼畫成金字塔

越下面越基礎、影響範圍越廣。下層沒做好，上層再花俏都撐不住

本課程的位置

Phase A-B 在資料層與建模層； Phase C 才移到應用層

★ 治理層不是最後才補

它畫在最底下，因為它是所有層的前提—— M9 會貫穿全程回來檢查

常見的錯誤順序：先做應用層（做個 Chatbot 給人看），再回頭補資料層。結果是介面很漂亮但答案不可信——這正是多數 AI 專案失敗的樣子。

2026 年真正重要的六項技術

FOUNDATION MODEL

基礎模型

- 大規模預訓練的通用模型，可微調或提示適應各種任務
- 改變了「每個任務訓練一個模型」的做法
- 你多半是使用者而非訓練者 → W12

RAG

檢索增強生成

- 把外部文件檢索結果餵給模型再生成
- 緩解知識過期與幻覺（無法完全消除），答案可標註來源
- 已是企業導入生成式 AI 的預設架構 → W14

AI AGENT

代理與工具調用

- 模型自行決定下一步、調用外部工具
- ★ 正從試點走向正式流程
- 不可預測性與責任歸屬是主要風險 → W15

SLM

小型專用語言模型

- ★ 參數量小得多，但特定任務表現已足夠
- 更便宜、更快，且能在自己的機器上跑
- Gartner 預估 2027 年企業用量達通用 LLM 三倍 → W12

EDGE / LOCAL AI

邊緣與本地端

- 模型在本機或機構內執行，資料不出機構
- 延遲低、符合隱私要求
- 對醫療資料幾乎是必要條件 → W12

AI GOVERNANCE

治理與可解釋性

- 偏誤（Bias）檢核、公平性（Fairness）評估、可追溯性
- 歐盟 AI Act 列醫療、信用評分為高風險；台灣《人工智慧基本法》2025 年底通過
- 設計之初就要納入的限制 → M9

共同點：這六項都不是「更準的演算法」，而是「怎麼讓它真的能用、能信、能負責」。注意第 4、5 項的方向——趨勢已從「愈大愈好」轉向「夠用、可控、可負擔」，這對醫療場域特別關鍵。

從資料到決策：每一層都在流失



★ 多數 AI 專案的失敗不在「模型不準」，而在最上面兩層（拿不到可用資料）與最下面一層（做出來沒人用）。技術只佔中間三層，而那正是最容易的部分。

熱門，但你現在不需要急著學

技術	它在解決什麼	為什麼先不急
從頭預訓練大模型	建立自有的基礎模型（Foundation Model）	動輒數百萬到數億美元的算力與資料。 實務上你會是使用者與微調者
多代理編排框架	讓多個 Agent 協作完成複雜任務	單一 Agent 都還沒做穩之前談協作沒意義。 本課先把單一 Agent 做紮實
向量資料庫底層調校	提升大規模檢索效能	Dify 已封裝好。 等知識庫大到出現效能問題再學
RLHF 人類回饋強化學習	以人類回饋調整模型行為	屬模型開發端技術。 應用端用提示詞與流程約束即可達成多數目的
MLOps 工具鏈	模型的部署、監控與版本管理	重要但屬工程職能。 先做出值得部署的模型再談怎麼部署
模型蒸餾與量化	把大模型壓成小模型，降低成本與延遲	屬模型工程端。 應用端直接選現成的小模型即可
多模態模型微調	讓模型同時處理文字、影像與語音	需要成對的多模態標註資料。 先把單一模態做好再談

判斷準則：這項技術解決的問題，是不是你現在真的遇到的？不是的話，知道它存在就夠了。

PART 05

應用領域巡禮

Where It Actually Gets Used

脫離應用場景談技術沒有意義。

這一節看實際上有人在用它做什麼。

用「資料型態 × 問題型態」定位你的問題

問題型態

預測某個值或類別 × 結構化

- 檢驗值預測住院天數
- 風險分層與再入院預測
- 傳統機器學習的主場
- 本課 Phase A-B

預測某個值或類別 × 非結構化

- 影像判讀、病理切片
- 語音轉文字後分類
- 深度學習的主場
- 本課 W9、W11

生成內容或決策 × 結構化

- 依評估結果產生照護計畫
- 自動生成報表與摘要
- 規則 + LLM 混合
- 本課 W14 CMS 案例

生成內容或決策 × 非結構化

- 衛教文案、病歷摘要
- 多步驟決策支援 Agent
- 生成式 AI 的主場
- 本課 Phase C 與期末專題

資料型態 → 結構化（表格）

非結構化（文字、影像、訊號）

第一週就把你的貫穿主線題目放進這張圖，你會很快知道整學期哪幾週對你最關鍵。

六大應用領域

HEALTHCARE

醫療與臨床

- 疾病風險預測、早期篩檢、影像判讀輔助
- 再入院與併發症預測、用藥安全
- 病歷摘要、虛擬護理助理、遠距監測

LONG-TERM CARE

長照與高齡

- 失能等級評估、給付試算、資源配置
- 跌倒風險預測、ICOPE 功能評估
- 居家監測與異常通報、照顧者負荷評估

PUBLIC HEALTH

公共衛生

- 疫情趨勢預測、熱區辨識
- 族群健康分層、醫療利用率預測
- 健康行為分析與衛教設計

FINANCE

金融與保險

- 信用風險評分、詐欺交易偵測
- 保費定價與理賠風險評估
- 客戶流失預測、反洗錢監控

RETAIL

零售與行銷

- 顧客分群（Clustering，作業一屬此類）、精準行銷、推薦系統
- 購物籃分析、需求預測與庫存最佳化
- 顧客終身價值預測

MANUFACTURING

製造與運維

- 設備異常偵測（Anomaly Detection）、預測性維護
- 品質檢測與瑕疵辨識、良率預測
- 供應鏈風險預警（W7 鍋爐案例屬此類）

為什麼要看醫療以外的領域？因為方法是共通的。信用風險評分與疾病風險分層在技術上幾乎是同一件事——差別在於錯誤的代價。

應用場景 × 技術對應矩陣

應用場景	迴歸	分類	分群	集成學習	異常偵測	時間序列	深度學習	NLP	RAG / Agent
再入院風險預測		●	○	●			○		○
住院天數／費用預測	●			●		○	○		
病人分群與照護路徑			●						○
生理訊號異常監測		○			●	●	○		
醫學影像輔助判讀		○					●		
病歷文本摘要與分類		○	○				○	●	○
長照給付與決策支援		○						○	●
衛教內容生成								○	●


● 主要使用 ○ 次要／輔助使用

健康照護的五個具體場景


場景	問題型態	主要技術	本課對應
再入院風險預測	二元分類	邏輯斯迴歸（ Logistic Regression ）、決策樹、集成學習、不平衡處理、決策門檻（ Decision Threshold ）調整	W5 、 W7
病人分群與照護路徑	分群（無標籤）	K-Means 、階層式分群（ Hierarchical Clustering ）、PCA 降維、群組詮釋	W6
醫學影像輔助判讀	影像分類	CNN 、遷移學習、 Fine-tune	W9
病歷文本摘要與分類	文字分類與生成	TF-IDF 、情感分析、LLM 摘要、提示詞工程	W11 、 W12
長照給付與照護決策支援	知識檢索＋多步驟決策	RAG 知識庫、Workflow 、Agent 工具調用、人在迴路（ Human-in-the-Loop, HITL ）	W14 、 W15

實例：相關不等於因果

左・只看兩個變數 $r = 0.87$



右・依疾病嚴重度上色



左・觀察到的相關

用藥項目數與住院天數強相關。看起來「減少用藥就能縮短住院」

右・真相


兩者都被「疾病嚴重度」驅動。用藥多是因為病重，不是病重的原因

這叫混淆因子

模型抓到的是關聯，不是機制。迴歸係數不會告訴你哪個是因

實務後果

依此設計「減少用藥」的介入方案，不會縮短住院，還可能傷害病人



三個真實的失敗教訓

教訓一：整體很準，對某些人很不準

- ▶ 曾有廣泛使用的醫療資源分配演算法，以「醫療花費」作為健康需求的代理指標，導致相同病況下黑人病患被系統性低估（Obermeyer et al., Science 2019）
- ▶ 問題不在演算法，在標籤定義——花費少可能反映的是就醫障礙，而不是比較健康
- ▶ 本課 M9 會要求你把評估指標拆到子群體去看，這是標準步驟不是額外作業

教訓二：在一家醫院很準，換一家就失效

- ▶ 許多影像模型在單一機構資料上表現優異，換到不同設備、不同族群的機構就大幅退步
- ▶ 常見原因是模型學到與疾病無關的線索，如影像上的醫院標記（Zech et al., PLOS Med 2018）
- ▶ 驗證方式：一定要用「不同來源」的資料測試，而不只是同一批資料的隨機切分

教訓三：模型沒錯，但沒有人採用

- ▶ 臨床人員無法理解模型為何這樣判斷，就不會在關鍵時刻採信它
- ▶ 警示過多造成警示疲勞，真正重要的提示也被忽略（如 Epic 敗血症模型，Wong et al., JAMA IM 2021）
- ▶ 可解釋性與警示設計不是介面問題，是這個系統會不會被使用的關鍵

這三個教訓在本課程分別對應：M9 的子群體指標檢核（W10）、W5 的驗證設計（外部驗證）、以及 M9 的可解釋性與警示設計。


PART 06

AI / ML / DL / GenAI

How They Relate

這四個詞在新聞裡幾乎可以互換使用。
但它們的範圍其實是層層包含的。

由大到小的包含關係



人工智慧

讓機器展現智慧行為的所有方法，包含不需要學習的規則系統與搜尋演算法

機器學習 ML

從資料中自動學出規律，不由人明確寫死規則。迴歸、決策樹（Decision Tree）、分群都屬此類

深度學習 DL

以多層神經網路自動學出特徵表示。CNN、RNN、Transformer 都屬此類

生成式 AI

能產生新內容的深度學習模型。GPT 等 LLM、擴散模型（Diffusion Model）

常見誤解：以為生成式 AI 是「最進階所以最好」。它只是擅長不同的事——要預測住院天數，一個決策樹（Decision Tree）仍然比 LLM 適合得多。

機器學習的三種學習方式

1

監督式學習 (Supervised Learning)

- ▶ 資料有標準答案 (label)
- ▶ 目標：學出輸入到答案的對應關係
- ▶ 分類：預測類別 (會不會再入院)
- ▶ 迴歸：預測數值 (住院幾天)
- ▶ 本課 W4-W5、W8-W9
- ▶ 醫療應用最常用的一類

2

非監督式學習

- ▶ 資料沒有標準答案
- ▶ 目標：找出資料本身的結構
- ▶ 分群 (Clustering)：把相似的個案分成幾群
- ▶ 降維 (Dimensionality Reduction)：把很多欄位壓成少數幾個
- ▶ 異常偵測 (Anomaly Detection)：找出不像其他人的個案
- ▶ 本課 W6、W7

3

強化與其他學習

- ▶ 強化學習：從互動與回饋中學習策略
- ▶ 自監督：從資料本身造出標籤來學
- ▶ LLM 的預訓練就是自監督 (M7)
- ▶ 半監督：少量標註 + 大量未標註
- ▶ 生成式模型多以自監督訓練 (Phase C)
- ▶ 強化學習不在本課範圍

PART 07

資料科學工作流程

The Six-Step Workflow

這六個步驟是全課程的骨架。

第 10 週的期中發表就是要你完整走一遍並說明每一步的判斷理由。

六個步驟



這六步是 CRISP-DM 的簡化版：①＝業務理解，②－④＝資料理解與準備，⑤＝建模與評估，⑥＝部署。最常被低估的是第一步——界定錯了，後五步做得再漂亮也沒有價值。

資料科學專案的完整流程

① – ⑤ 資料準備約佔近半時間

⑦ – ⑪ 多數專案死在最後兩步



★ 切分點在這裡

評估不如預期 → 回去改特徵

監控發現飄移 → 重新收資料

① – ③ 前段

問題理解 → 資料蒐集 → 清理。去重、修正錯字這類不需估計參數的清理可以先做

④ 先切分，再動資料

補值、正規化、特徵選擇等要從資料算統計量的步驟，一律只用訓練集擬合

⑤ – ⑪ 後段

EDA 與特徵工程只看訓練集；建模 → 評估 → 調校 → 溝通 → 部署 → 監控，多數專案死在最後兩步

★ 紅色虛線


實務上一定會回頭：評估不如預期就改特徵，監控發現飄移就重收資料

每一步的產出與最常見的錯誤

步驟	應該產出什麼	最常見的錯誤
1 界定問題	一句話說清楚：為誰、預測什麼、預測出來要做什麼	做了一個沒有人會用的預測。 「準確率很高」但沒有對應的行動
2 蒐集資料	資料來源清單、時間範圍、納入排除條件	沒有問「誰不在這份資料裡」。 樣本偏誤（Bias）從這一步就注定了
3 清理資料	一份可重現的清理流程，以及清理決策的紀錄	把偽裝成 0 的遺失值（Missing Data）當成有效值。 刪掉離群值（Outlier）卻沒發現那正是目標族群
4 探索分析	分布圖、相關矩陣、初步假設清單	跳過這一步直接建模。 結果模型學到的東西你完全無法解釋
5 建立模型	模型、評估指標、與基準線的比較	只報告最好的那個結果。 沒有基準線可比，不知道到底有沒有進步
6 溝通部署	給決策者看得懂的結論、限制說明、後續行動建議	只講技術指標。 對方聽完不知道自己該做什麼

時間都花在哪裡

Anaconda State of Data Science 2020 調查 · 資料工作者自述的時間分配



資料準備（載入＋清理）合計約 45%，是單一最大宗；模型相關（選擇＋訓練＋部署）約 34%。2022 年版的數字為資料準備 37.8%、模型相關 26.4%，比例大致相同。本課程把 W2-W3 兩整週給資料工程，就是因為這一段才是決定成敗的地方。

AI 底下的三個分支



【原講義 GAI 2. NLP】 p8。資料科學家的位置：運用並詮釋這三類模型，從資料中萃取可行動的洞見。三者高度重疊——現代的 CV 與 NLP 幾乎都建立在 ML 之上。

NLP 七十年演進：四個世代

1950s-80s

規則式 Early NLP

- 文法規則、樣式比對
- 1954 喬治城 -IBM 俄英翻譯實驗
- 1966 ELIZA 第一個聊天機器人
- 研究者興奮，但成果遠低於預期
- 發現語言的複雜度被嚴重低估

1980s-2000s

統計與機器學習

- 以機率模型取代人工規則
- 1993 Penn Treebank 逾 450 萬標註詞
- 統計式機器翻譯 SMT
- 監督式與非監督式學習導入
- 算力與演算法同時到位

2010s

循環神經網路

- 深度學習 (Deep Learning) 與 NLP 結合
- RNN、LSTM 處理序列
- 詞嵌入 Word2Vec、GloVe
- 能記住較長的上下文
- 但長距離依賴仍是瓶頸


2017- 今

Transformer Modern NLP

- 2017 Attention Is All You Need
- BERT、GPT 等大型語言模型
- 可平行訓練、處理長距離依賴
- 研究爆炸性成長且仍在持續
- 效能極佳，但可解釋性極差

【原講義 GAI 2. NLP】 pp9-13。注意兩次「取代」：傳統 NLP 大致取代了規則式；Transformer 大致取代了循環式。但「取代」指的是主流地位，不是舊方法完全消失。

實例： NLP 七十年的兩次跳階



三個底色區

規則式 (1950s-80s)、統計與 ML (1980s-2000s)、深度學習與 Transformer

兩次陡升

1990 年代前後統計方法接手；2017 年 Transformer 之後再跳一階

平緩的那三十年

不是沒有人努力，是資料與算力還沒到位——與前一頁的三個推力對照

本課的位置

M6 教傳統方法（仍好用且可解釋），M7 之後進入 Transformer 世代

傳統 NLP 與現代 NLP：一個心態上的轉變

傳統 NLP 的心態

- ▶ 目標是「理解每一步在做什麼」
- ▶ 每個步驟都可以解釋：斷詞、詞性標註、句法剖析
- ▶ 特徵是人設計的，看得懂也改得動
- ▶ 資料量需求較低，小型與中型資料集就能運作
- ▶ 在資源有限或需要可解釋性時仍然是好選擇
- ▶ 本課程 M6 的文字探勘走的是這條路

現代 NLP 的心態

- ▶ 沒有辦法理解每一步在做什麼，也不強求
- ▶ 最重要的是效能——即使整體是個黑箱
- ▶ 特徵由模型自己學出，人看不懂中間表示
- ▶ 需要大量資料與算力（但可用預訓練模型繞過）
- ▶ 可解釋性差，在高風險場域是明確的限制
- ▶ 本課程 M7、M8 走的是這條路

【原講義 GAI 2. NLP】 p13。這個轉變值得記住：不是「新的比較好」，而是「兩者的目標不同」。醫療場域常常必須為了可解釋性選擇前者。

NLP 應用與對應技術

應用	類別	傳統技術	現代技術	本課
情感分析	分類	Naive Bayes、TF-IDF	BERT 等編碼器模型	M6、M7
文字分類	分類	Naive Bayes、SVM	BERT 類編碼器	M6
主題建模	分群	NMF、LDA	嵌入 + 分群	M6
文件相似度	相似度	TF-IDF + 餘弦相似度	句嵌入模型	M6
命名實體辨識	序列標註	規則式、CRF	BERT 類編碼器	M7
文本摘要	生成	抽取式（挑句子）	BART / T5 或 GPT 類 LLM	M7
文字生成	生成	（傳統做不到）	解碼器 LLM（GPT 類）	M7、M8

【原講義 GAI 2. NLP】 p14。橫著看可以發現：越往下走，傳統技術越無能為力——「生成」這一類是現代 NLP 才真正打開的。

PART 08

工具鏈建置

Toolchain Setup

五套工具，各有明確的出場時機與資料邊界。
今天先把前兩套裝起來並確認能跑。

五套工具的定位

工具	定位	用在哪幾週	為什麼是它
AI Studio (RapidMiner)	主軸工具	W1-W11 全部實作	視覺化流程，不需程式基礎，課程既有教材最完整（120+ 流程檔）。 ★ 原名 Altair AI Studio；Altair 併入 Siemens 後正式名稱為 RapidMiner AI Studio
Dify	Phase C 專屬	W13-W15 與期末專題	把模型變成可部署、可分享的實際應用； 支援多家模型供應商
Ollama	輔助	W12 起	本地端執行 LLM，資料完全不出你的機器—— 處理健康資料時這是必要條件
Anaconda / Jupyter	延伸自學	Python 延伸自學（選讀）	想深入或未來要繼續深造的同學 有配套教材可用；不列入評量
n8n	延伸自學	補充教材	把 Dify 應用接進排程與批次自動化； Dify 管知識與對話，n8n 管流程與整合

今天只需要裝好前兩項（AI Studio 必裝、Ollama 可先試裝）。Dify 在 W13 之前準備即可；Anaconda 與 n8n 屬選讀，不影響修課。

今天的安裝檢核

項目	怎麼確認裝好了	裝不起來怎麼辦
AI Studio	能開啟並在左側 Repository 面板看到課程資料夾	確認教育版授權已啟用； 課堂現場協助排除
課程 Repository	能展開「Data Sciences Course Materials」並看到各模組資料夾	用 File → Import Process 匯入， 或直接匯入整個 Repository 資料夾
Anaconda（選用）	終端機輸入 <code>conda --version</code> 有版本號回應	非必要，可跳過； 只有 Python 延伸自學才會用到
Ollama（選用）	終端機輸入 <code>ollama --version</code> 有版本號回應	W12 前裝好即可； 今天先試裝，有問題下週處理

今天的重點是 AI Studio 與課程 Repository 這兩項。其餘可以之後再補。

AI Studio 的四個核心概念

Repository 儲存庫

- ▶ 所有資料集、流程檔、模型的集中存放處，在畫面左側
- ▶ 資料集拖進編輯區會自動變成 Retrieve Operator——這是最常用的起手式
- ▶ 請養成習慣：修改既有流程時先「另存新檔」，不要覆蓋原檔

Process 與 Operator 流程與運算子

- ▶ Process 是一張流程圖，Operator 是圖上的一個節點，每個節點做一件事
- ▶ 節點之間用線連接，資料沿著線流動。連錯線不會報錯，但結果會錯
- ▶ 左下角的搜尋框可以用關鍵字找 Operator，例如輸入 normalize

Results 結果頁

- ▶ 執行後會自動切換到 Results 頁籤，左側可切換檢視不同的輸出
- ▶ 重要的檢視：Statistics（各欄位統計）、Charts（視覺化）、模型本身的內容
- ▶ 沒有輸出通常是因為最後一個節點沒有連到右側的 res 埠

PART 09

第一個端到端專案

Your First Complete Workflow

現在把六個步驟實際跑一遍。

資料是汽車油耗，很單純——重點是把流程走通，不是把模型調好。

實作 | MPG 油耗線性迴歸 (Linear Regression)

M0 實作

開啟檔案

```
範例 /ML (AI Studio)/M0. 導論與工具鏈 /  
├ 0.0 ... MPG Dataset (empty).rmp  
│   ← 課堂填空版  
├ 0.0 ... MPG Dataset.rmp  
│   ← 完成版 (對照用)  
└ 0.0 ... MPG Dataset - py.rmp  
資料 /ML (AI Studio)/M0. 導論與工具鏈 /  
└ MPG dataset.rmhdf5table  
  (... = The First Example. Linear Regression with)
```

預期結果


- ▶ RMSE 大約落在 2.5-4 之間 (依切分而異)
- ▶ squared correlation 約 0.7-0.85 (測試集上不完全等於 R^2)
- ▶ 模型係數 (Coefficient) 會列出各特徵的權重與 p 值
- ▶ 若 RMSE 明顯偏高, 先檢查 Split Data 的兩個輸出有沒有接反

操作步驟


- 1 開啟 (empty).rmp, 把 MPG dataset 從 Repository 拖進編輯區
- 2 加入 Set Role, 把 mpg 欄位設為 label (目標變數)
- 3 加入 Split Data, 設定兩個 partition: 0.8 與 0.2
- 4 加入 Linear Regression, 接在第一個輸出 (訓練集)
- 5 加入 Apply Model: model 埠接模型、unl 埠接測試集
- 6 加入 Performance (Regression), 勾選 RMSE 與 squared correlation
- 7 把最後輸出拉到右側 res 埠, 按藍色三角形執行
- 8 在 Results 檢視評估數字與模型係數 (Coefficient)

實例：你的第一個模型會長這樣

左・車重 vs 每加侖里程



右・預測 vs 實際



左・散布圖與迴歸線

車重越重、每加侖里程越低，也就是越耗油。
紅線就是本週要建的模型

R^2 與 RMSE

這兩個數字就是 Results 頁籤會給你的東西
——本週先看懂，M2 才深入

右・預測 vs 實際

理想狀態是所有點落在對角線上。偏離越遠
代表預測越不準

這張圖的用途

任何迴歸模型做完都該畫它——比單看 R^2
更能看出哪一段預測得差

這條流程對應到工作流程的哪一步

流程中的 Operator	對應的步驟	實務上這一步還會做什麼
Retrieve（拖曳資料集）	2 蒐集資料	確認資料來源、時間範圍、納入排除條件
Set Role	3 清理資料	設定目標變數與識別欄位；本例資料已清理過
（本例省略）	4 探索分析	看分布、相關矩陣、離群值（Outlier）—— W3 會補上
Split Data	5 建立模型	切分訓練與測試集； W5 會改用交叉驗證（Cross Validation）
Linear Regression + Apply Model	5 建立模型	訓練並套用到未見過的資料
Performance (Regression)	5 建立模型	評估。 W4 會討論該選 MAE 還是 RMSE
（本例省略）	6 溝通部署	把結果講成決策建議—— Task 1 會要求

今天這條流程刻意省略了第 1、4、6 步。整學期就是把這三個被省略的部分逐一補回來。

PART 10

專案界定

Scoping a Project

專案不是從資料開始的，是從一個界定清楚的範圍開始的。

這是最困難、也最常被跳過的一步——界定錯了，後面做得再好都是白費。

界定專案的六個步驟



【原講義 ML 3.1】 p27。這六步走完通常只要一到兩小時，但可以省下數週走錯方向的時間。

步驟一：站在使用者角度想

該問的三種問題

- ▶ 同理：他每天實際在煩惱什麼？哪一件事最花他時間？
- ▶ 影響：什麼指標改善了，他會覺得這件事有價值？
- ▶ 現況：現在是怎麼處理的？靠經驗、靠紙本、還是根本沒處理？
- ▶ 限制：他有多少時間看你的產出？在什麼情境下看？
- ▶ 決策：拿到結果之後，他真的有辦法採取行動嗎？

最常見的失敗

- ▶ 從「我會什麼技術」出發，而不是從「他需要什麼」出發
- ▶ 做出一個很準的模型，但預測出來的事情使用者無法採取行動
- ▶ 指標選得很技術（AUC 0.87），使用者聽不懂也不在乎
- ▶ 沒問清楚使用情境——急救現場沒時間讀三段文字
- ▶ 把使用者當成資料的來源，而不是解決方案的共同設計者

【原講義 ML 3.1】 p28。實務建議：真的去找一位第一線人員聊 30 分鐘，比你自己想三天有用得多。

步驟二與三：先想問題，再想解法

腦力激盪「問題」時

- ▶ 刻意不要想資料、不要想技術、不要想限制
- ▶ 先想大：這個場域最讓人困擾的事情是什麼？
- ▶ 例（居家照護）：為什麼個案的服務計畫常常要臨時調整？
- ▶ 例：為什麼督導總是在事情發生後才知道？
- ▶ 例：我們到底知不知道個案退出服務的原因？
- ▶ ★ 這一步的產出是「問題清單」，不是「解法清單」

腦力激盪「解法」時

- ▶ 資料科學是其中一種解法，不是唯一的
- ▶ 訪談十位個案，取得質性資料 → 可能更快更便宜
- ▶ 在退出流程加一份原因問卷 → 直接取得資料
- ▶ 調整排班或通報流程 → 根本不需要模型
- ▶ 用資料找出退出的主要預測因子 → 這才是資料科學解法
- ▶ ★ 選資料科學的理由必須是「它比其他解法更適合」

【原講義 ML 3.1】 pp29-30。資料科學的優點：有資料佐證、可能找出隱藏洞見、能做預測。缺點：耗時、需要專業資源、且不保證有結果。

步驟四：決定用什麼技術

你想做的事	技術	為什麼	本課模組
用歷史資料預測未來的數值	監督式 迴歸	有明確的數值答案可以學	M2
用歷史資料預測未來的類別	監督式 分類	有明確的類別答案可以學	M2
把對象分成幾個群體	非監督式 分群 (Clustering)	沒有預先定義的群體	M3
找出資料中的異常	非監督式 異常偵測 (Anomaly Detection)	異常的定義本身不明確	M4
理解文字內容在說什麼	NLP	輸入是非結構化文字	M6
把知識與規則組成決策支援	生成式 AI + RAG	需要語言理解與知識檢索	M7 、 M8
其實不需要模型	統計描述或流程改善	問題本身不需要預測	—

【原講義 ML 3.1】 p31。最後一列很重要：如果一張交叉分析表就能回答，就不要建模型。

步驟五：釐清資料需求的三個面向

1

結構 Structure

- ▶ 監督式：需要有標籤欄位 (y)
- ▶ 非監督式：只需要特徵欄位 (x)
- ▶ 一列代表什麼？病人？就診？月份？
- ▶ 這決定了你要不要做 Aggregate (M1)
- ▶ ★ 先把「一列 = 一個什麼」寫下來
- ▶ 很多專案是在這裡就走偏的

2

特徵 Features

- ▶ 腦力激盪：哪些欄位可能有預測力？
- ▶ 從領域知識出發，不是從資料清單出發
- ▶ 例（再入院）：年齡、共病數、住院天數、
- ▶ 出院時的活動功能、有無主要照顧者
- ▶ 先列理想清單，再看哪些拿得到
- ▶ ★ 這一步是你們最有優勢的地方

3

來源與範圍 Sources & Scope

- ▶ 每個特徵要從哪裡來？現成的還是要算的？
- ▶ 哪些取得困難？成本多高？
- ▶ 移除難以取得的，優先做拿得到的
- ▶ 時間範圍：要幾年的資料？
- ▶ ★ 資料更多不等於模型更好
- ▶ 先做出最小可行版本（MVP）再擴充

【原講義 ML 3.1】 pp34-40。最後一頁的 PRO TIP 值得記住：先做出 MVP。做太深而沒有回饋，容易走進死路或把方案過度複雜化。

步驟六：把範圍寫成一頁（範例）

問題定義

欄位	內容
使用者	長照個管師
問題	新收個案的服務需求常在三個月內大幅變動，需臨時加派
現況	靠個管師經驗判斷，無系統性預警
技術	監督式 分類
目標變數	三個月內服務時數是否增加逾 30%



資料需求

欄位	內容
分析單位	一列 = 一位新收個案
候選特徵	CMS 等級、共病數、主要照顧者有無、居住型態、初次評估的 ADL 分數
資料來源	長照系統評估紀錄、服務派案紀錄
範圍	近三年、六十五歲以上新收個案
成功定義	Recall $\geq$ 0.7 且個管師願意採用

為什麼要寫下來

寫得出來代表你想清楚了；寫不出來代表還沒。這一頁要拿去給使用者確認

成功定義最容易漏掉

不是「模型很準」，而是「達到什麼程度，這件事才算有用」

可以改

第 4 週題目確認前都能調整。但要有一個起點才知道往哪裡調

這一頁就是 M0 課後作業的格式。請以你的貫穿主線題目填一份，下週上課前上傳。

PART 11

選定你的貫穿主線

Choose Your Thread

這是今天最重要的一件事。

你現在選的題目，會在第 10 週、第 12 週、第 16 週各出現一次。

好題目的四個條件（其一至其三）

1

你真的在意

- ▶ 最好是你實務上遇過的痛點
- ▶ 或你未來想投入的領域
- ▶ 一個學期很長，不有趣會做不下去
- ▶ 臨床、長照、公衛、教育都可以
- ▶ 不必是「重要的大問題」
- ▶ 小而具體的問題往往做得更好

2

資料取得可行

- ▶ 公開資料集：UCI、Kaggle、政府開放資料
- ▶ 或你能自行建構的模擬資料
- ▶ 不得使用實習或工作場域的真實個案資料
- ▶ 先確認資料存在，再確認題目
- ▶ 找不到資料時，換一個相近的代理問題
- ▶ 第 1 週結束前請完成初步查找

3

有明確的使用者

- ▶ 誰會看到這個系統的輸出？
- ▶ 護理師、個管師、居服員、家屬、病人？
- ▶ 使用者不同，輸出的形式就完全不同
- ▶ 說得出使用者，才說得出評估指標
- ▶ 也才知道錯誤的代價是什麼
- ▶ 這一點決定了 Phase C 的設計

第四個條件：三種解法都說得通

Phase A 要能做成一個預測問題

- ▶ 有沒有一個可以預測的目標？例如：風險等級、是否再入院、需要多少照護時數
- ▶ 有沒有一組可以拿來預測的特徵？例如：年齡、檢驗值、失能項目、過往紀錄
- ▶ 如果你的題目完全沒有結構化資料，Phase A 會很難交差——請及早調整

Phase B 要能問「更複雜的模型有沒有比較好」

- ▶ 同一個預測問題換成深度學習跑一次，比較結果
- ▶ 資料量小時輸給簡單模型是正常的——把原因說清楚就是好答案
- ▶ 若你的資料涉及影像或文字，這一階段會特別有發揮空間

Phase C 要能問「算出結果之後，人該怎麼做」

- ▶ 第一線人員拿到風險分數之後，需要什麼資訊才能決定下一步？
- ▶ 有沒有可以放進知識庫的文件？法規、指引、院內規範、衛教手冊都算
- ▶ 這一階段的成果是期末專題，佔總成績 30%

四個條件不必一次滿足。第 1 週先有初步想法，第 4 週題目確認前都還可以調整。

選題示例：歷屆學長姊做過什麼

主題	使用者	Phase C 的核心設計
化療副作用照護決策支援	腫瘤科護理師	RAG 來源引用、CTCAE 分級標準納入知識庫、多重症狀平行處理
高齡運動處方生成	社區據點人員	ICOPE 結合 FITT 原則、偵測風險自動降級為坐姿、緊急停止指標前置
居服員 ISBAR 通報	居服員與督導	三位一體權責分工、人為核實後才送出、督導回饋回流優化
校園心理危機守門員	高中導師與專輔	客觀事實與專業評估分離、對家長談話劇本、法規條號標註
聽損輔具補助導航	聽力師與家屬	縣市政策動態權重、備援資料源透明標示、一鍵產出申請清單
EMT 救護處置助理	救護技術員	屬地法規強制約束、線上醫療指導授權、ePCR 草案自動生成

共同特徵：都是第一線人員每天實際遇到、目前靠經驗與紙本處理的問題。這種題目做起來最有價值。

本週作業：寫下你的問題陳述

Q
1

用一句話說清楚：我想為【誰】預測【什麼】，預測出來之後他可以【做什麼】

範例：我想為長照個案師預測【新收個案三個月內的照護需求變化】，預測出來後他可以【提前調整服務計畫，避免臨時加派】。

Q
2

這個問題目前是怎麼處理的？靠什麼判斷？花多少時間？

描述現況才能說明你的系統帶來什麼改變。若目前完全沒有處理方式，也要說明為什麼。

Q
3

你打算用什麼資料？公開資料集、政府開放資料，還是自建模擬資料？

請附上你查到的資料來源連結或名稱。查不到時說明你的替代方案。

Q
4

如果模型判斷錯了，會發生什麼事？誰承擔後果？

這一題決定了你之後要看 Precision 還是 Recall，也決定了 Phase C 需要什麼樣的安全設計。

繳交方式：一頁 A4，下週上課前上傳。這不計分，但第 4 週的 Task 1 題目確認會以此為基礎。

課後思考題

Q
1

為什麼 1990 年代會出現「知識發現（ Knowledge Discovery ）」這個詞？它跟傳統統計分析的差別在哪？

提示：想想「人提出假設、電腦驗證」與「電腦從資料中找出假設」的差別。

Q
2

最大的語言模型仍在變大，為什麼同時出現大量小型模型，而且企業越來越常用？

提示：從成本、延遲、資料隱私三個角度想。哪一個對醫療場域最關鍵？

Q
3

同樣是「風險評分」，銀行的信用評分與醫院的再入院預測，技術上幾乎一樣。差別在哪？

提示：想想錯誤的代價、可解釋性的要求、以及誰有權推翻系統的判斷。

中英術語對照 | M0

(1 / 3)

中文	English	一句話說明
資料科學	Data Science	用資料回答「接下來會怎樣、該怎麼做」
資料探勘	Data Mining	從大量資料中找出先前未知的模式
知識發現	Knowledge Discovery in Databases, KDD	資料 → 知識的完整流程（Fayyad 等人，1996）
商業智慧	Business Intelligence, BI	回答「過去發生了什麼」的報表與儀表板
描述性分析	Descriptive Analytics	發生了什麼事
預測性分析	Predictive Analytics	接下來會發生什麼
指示性分析	Prescriptive Analytics	我們該怎麼做
監督式學習	Supervised Learning	資料有標準答案（標籤），學輸入到答案的對應
非監督式學習	Unsupervised Learning	沒有答案，只找資料本身的結構

中英術語對照 | M0

(2 / 3)

中文	English	一句話說明
強化學習	Reinforcement Learning	從互動與回饋中學策略（本課程不含）
標籤	Label / Target / y	你想預測的那一欄
特徵	Feature / Input / x	餵給模型的欄位
人工智慧	Artificial Intelligence, AI	讓機器展現智慧行為的所有方法
機器學習	Machine Learning, ML	從資料自動學規律，不寫死規則
深度學習	Deep Learning, DL	以多層神經網路自動學特徵表示
生成式 AI	Generative AI, GAI	能產生新內容的深度學習模型
自然語言處理	Natural Language Processing, NLP	讓電腦處理人類語言
電腦視覺	Computer Vision, CV	讓電腦「看懂」影像

中英術語對照 | M0

(3 / 3)

中文	English	一句話說明
基礎模型	Foundation Model	大規模預訓練、可適應多種任務的通用模型
檢索增強生成	Retrieval-Augmented Generation, RAG	先檢索文件再生成，可標註來源
提示詞工程	Prompt Engineering	以指令設計引導模型行為
專案界定	Scoping	動手前先定義問題、使用者與資料需求
最小可行產品	Minimum Viable Product, MVP	先做出最小可用版本再擴充
混淆因子	Confounder	同時影響兩個變數，造成假性相關的第三者

本單元回顧

- 1 資料科學需要統計、工具、領域知識三者兼備，你們的優勢在第三項。
- 2 技術演進的推力只有三個：資料變多、算力變便宜、演算法有突破。
- 3 新技術很少取代舊技術，多半只是多了一個選項——決策樹在 2026 年仍然好用。
- 4 2026 年的重點不是更準的演算法，而是怎麼讓系統能用、能信、能負責。
- 5 時間分配：資料準備（載入＋清理）約佔四成五，是單一最大宗；建模相關約三成。
- 6 今天最重要的事：選定你的貫穿主線題目，並完成問題陳述作業。

下一步 第 2 週 M1 資料工程：資料存取、整理與合併