

資料工程：從原始資料到可建模

M1 — Data Engineering: From Raw Data to Model-Ready

這是整門課最花時間、也最決定成敗的一段。
模型選錯還可以換，資料處理錯了，後面全部都是錯的。

本單元大綱

01 為什麼這段最花時間 · 資料品質的六個維度

02 資料存取與匯入 · 來源、格式與最常見的三個坑

03 型態與角色 · AI Studio 怎麼看待每一個欄位

04 篩選、排序與聚合（Aggregation） · 把資料整理成分析單位

05 合併：Join 的四種類型 · 本模組最容易出錯的地方

06 遺失值（Missing Data） · 先問為什麼缺，再決定怎麼補

07 離群值（Outlier） · 找出來之後呢？

08 重複與不一致 · 看起來一樣但電腦覺得不一樣

09 相關與共線性 · 把重複的資訊找出來

10 正規化（Normalization）與標準化（Standardization） · 什麼時候需要、什麼時候不用

11 特徵工程（Feature Engineering） · 把領域知識變成欄位

12 資料洩漏（Data Leakage） · 做對每一步卻得到假的好成績

13 實作與練習 · Module 1-10 與完整前處理鏈

PART 01

為什麼這段最花時間

Why Data Work Dominates

資料準備與清理約佔資料工作者 38% 的時間（Anaconda 2022；2020 年版為 45%）。
這一模組處理的就是那 38%——它決定了後面所有模型的上限。

資料品質的六個維度

COMPLETENESS

完整性

- 該有的欄位與紀錄有沒有缺
- 缺失是隨機的還是有系統的？
- 醫療資料常見：檢驗未做 $\neq$ 檢驗正常

ACCURACY

正確性

- 值本身對不對、單位有沒有搞混
- 身高 175 與 1.75 同時出現在一欄
- 輸入錯誤、儀器校正、抄寫誤差

CONSISTENCY

一致性

- 同一件事在不同地方寫法一致嗎
- 「男 / M / 1」 「臺北 / 台北」並存
- 跨系統整合時最常爆發

TIMELINESS

時效性

- 資料反映的是哪個時間點的狀態
- 資料夠不夠新、需要時拿不拿得到
- 法規、給付標準會逐年更新

VALIDITY

有效性

- 值有沒有落在合理範圍內
- 血壓 0、年齡 999、BMI 0
- 生理上不可能的值幾乎都是遺失

UNIQUENESS

唯一性

- 同一筆資料有沒有重複出現
- 完全重複、鍵值重複、語意重複
- Join 之後筆數暴增通常源於此

檢查順序建議：有效性 → 完整性 → 唯一性 → 一致性 → 正確性 → 時效性。前三項用 Statistics 就能看出大半。（六維度依 DAMA UK, 2013）


一份「看起來還好」的資料，實際上有幾個問題？

原始資料

ID	性別	年齡	血壓	血糖	就診日
A001	男	45	120	98	2027/03/01
A002	M	52	0	0	2027-03-02
A003	女	999	135	110	03/03/2027
A001	男	45	120	98	2027/03/01
A004	女	38	118		2027/03/04

清理後

ID	性別	年齡	血壓	血糖	就診日
A001	1	45	120	98	2027-03-01
A002	1	52	?	?	2027-03-02
A003	0	?	135	110	2027-03-03
A004	0	38	118	?	2027-03-04



有效性

年齡 999、血壓 0、血糖 0——生理上不可能，應視為遺失而非有效值

一致性

性別欄同時有「男 / M / 女」；日期有三種格式，需統一

唯一性

A001 完全重複出現兩次，需去重

完整性

A004 的血糖為空白——與 A002 的「0」是同一件事，但長得不一樣

這張表只有五列。真實資料有數萬列時，這些問題不會自己跳出來——你必須主動去找。

三個常被低估的事實

事實	為什麼	對你的意義
資料準備佔 37.8% ，模型相關佔 26.4%	Anaconda State of Data Science 2022 的調查。 演算法已被封裝好，難的是把資料變成它吃得下的樣子	W2-W3 兩整週都給資料工程， 不是因為它簡單，而是因為它決定上限
模型的上限由資料決定	同樣的演算法，餵乾淨資料與髒資料， 結果可能差一倍以上	與其花時間調參數， 不如回頭檢查資料
資料處理的錯誤最難發現	程式不會報錯，模型照樣訓練完成， 指標甚至可能更好看	本模組每一節都會列出 「這一步做錯會怎樣」

本模組的貫穿資料：門診整合模擬資料

765 筆就診 · 300 位病人 · 教學用模擬資料，非真實病人資料

刻意埋入的問題	PART	對答案的數字
就診費用含千分位逗號被讀成文字；病歷號 P0007 的前導零	2-3	費用約 3.5% 的列 ($\geq 1,000$ 元者)；300 個病歷號
性別六種寫法（男／ M ／ 1 ／女／ F ／ 0 ）、縣市四種寫法、科別尾空白	8	清理後性別剩 2 類、縣市剩 4 類
完全重複的列	8	14 筆 (765 $\rightarrow$ 751)
收縮壓／舒張壓以 0 代表未量測，與任何欄位都無關 $\rightarrow$ MCAR	6	約 8% 的列
體重未量測：急診 39% 、其他科 2-5% ，可由科別解釋 $\rightarrow$ MAR	6	分組看遺失率就看得出來
血糖正常的人根本沒去驗，缺失取決於看不到的值 $\rightarrow$ MNAR	6	只看有驗的人，平均血糖高估 12%
身高誤填公尺（ 1.62 ）、出生年 0 ／ 999 ／ 1899 ：偽裝成有效值	6-7	身高約 5.5%、出生年約 1%
檢驗結果是一對多（ 397 筆，屬 160 位病人； 140 位無檢驗）	5	主檔 751 筆 $\rightarrow$ left join 後 1,383 筆
洩漏誘餌：出院後 30 天門診次數、結案註記	12	留著建模，Accuracy 會逼近 100%

資料：資料 / ML (AI Studio) / M1. 資料工程 / M1 醫療版模擬資料 / 流程：範例 / 同名資料夾——五支 .rmp（每支附黃色註解框說明看什麼）、Python 對照 .ipynb、README 對答案表。

PART 02

資料存取與匯入

Accessing Data

把資料讀進來聽起來很簡單。

但一半以上的下游問題，其實是在這一步就種下的。

常見資料來源與 AI Studio 的對應

來源	格式	AI Studio Operator	要注意什麼
試算表檔案	CSV、TSV、TXT	Read CSV	分隔符號、編碼、有無標題列
Excel 活頁簿	.xlsx、.xls	Read Excel	選對工作表；合併儲存格會造成空值
資料庫	MySQL、SQL Server 等	Read Database	需先設定連線；建議先在 SQL 端篩選
課程儲存庫	已轉為 .rmhdf5table	Retrieve (直接拖曳)	本課程多數範例採此方式
影像資料夾	JPG、PNG 等	Read Image Meta Data	以資料夾名稱作為標籤（W9 MNIST 會用）
網頁	HTML	Get Pages / Crawl Web	W11 文字探勘會用到

範例：RapidMiner Module 1- Accessing Data.rmp 資料：Altoona Crime Rates.rmhdf5table。★工具名稱：Altair 已併入 Siemens，本軟體現正式名稱為 RapidMiner AI Studio（最新 2026.1.1）；本課程講義一律簡稱「AI Studio」，操作與運算子名稱不變。

匯入時最常踩的三個坑

1

編碼問題

- ▶ 中文變成亂碼或問號
- ▶ 常見於 Big5 與 UTF-8 混用
- ▶ AI Studio：Read CSV 的 encoding 參數
- ▶ 台灣政府開放資料常為 Big5
- ▶ 徵兆：欄位名稱正常但內容是亂碼
- ▶ 先用純文字編輯器開檔確認

2

型態誤判

- ▶ 日期被讀成文字或數字
- ▶ 有前導零的代碼（如 007）被吃掉零
- ▶ 含逗號的數字（1,234）被讀成文字
- ▶ 身分證字號、病歷號應為文字非數字
- ▶ 在 Read 的 data set meta data 逐欄確認
- ▶ 匯入後一定接 Statistics 檢查

3

標題與空白列

- ▶ 標題不在第一列（前面有說明文字）
- ▶ 資料中夾雜小計列或空白列
- ▶ 欄位名稱有前後空白，Join 時對不上
- ▶ Excel 的合併儲存格造成大量空值
- ▶ Read Excel 可指定起始儲存格
- ▶ 匯入後看筆數對不對是最快的檢查

共同的檢查動作：匯入後立刻接一個 Statistics，看「筆數、欄位數、每欄型態、每欄的最小最大值」四件事。三十秒就能擋掉大部分問題。

PART 03

型態與角色

Types and Roles

AI Studio 用「型態」決定能做什麼運算，
用「角色」決定這個欄位在建模中扮演什麼。

AI Studio 的欄位型態

型態	中文	代表什麼	典型欄位
integer	整數	可運算的整數	年齡、住院天數、次數
real	實數	可運算的小數	血壓、BMI、檢驗值
binominal	二元類別	只有兩種值	性別、是否再入院、有無糖尿病
polynominal	多元類別	三種以上的類別	科別、教育程度、CMS 等級
date / date_time	日期時間	可做日期運算	就診日、出生日、通報時間
text	文字	不做類別處理的自由文字	主訴、護理紀錄、備註

常見錯誤：把「CMS 等級 1-8」當一般數值運算。它是有序類別：順序可保留，但間距不等——等級 8 不等於等級 4 的兩倍。

角色 Role：這個欄位在建模中做什麼

五種常用角色

- ▶ regular（預設）：一般特徵，會被拿去建模
- ▶ label：目標變數。監督式學習（Supervised Learning）一定要設一個
- ▶ id：識別欄位。不參與建模但保留以便追溯
- ▶ weight：樣本權重。處理不平衡時會用到
- ▶ cluster / prediction：由演算法產生的結果欄位
- ▶ Operator：Set Role（單一）、Set Roles（批次）

設錯角色會發生什麼

- ▶ 忘了設 label：模型無法訓練，會直接報錯
- ▶ 把 ID 留成 regular：模型可能學到病歷號的順序
- ▶ 把日期留成 regular：模型學到「就診時間越晚風險越高」
- ▶ 這兩種都是資料洩漏的常見來源
- ▶ 檢查方式：看特徵重要性（Feature Importance）排序，ID 類欄位排前面就是警訊
- ▶ 作業一任務 2 要求移除 CustomerID，就是這個道理

型態轉換：類別欄位怎麼變成數值

原始（類別）

ID	科別	滿意度
1	內科	高
2	外科	中
3	內科	低
4	急診	高



轉換後（數值）

ID	科別 = 內	科別 = 外	科別 = 急	滿意度
1	1	0	0	3
2	0	1	0	2
3	1	0	0	1
4	0	0	1	3

科別 用 One-Hot

三個類別之間沒有大小關係，展開成三個 0/1 欄位。Operator：Nominal to Numerical（dummy coding）

滿意度 用序數編碼（Ordinal Encoding）

低 < 中 < 高 有順序，可直接編成 1/2/3 保留次序資訊。Operator：Map 手動對照（unique integers 依字母編號，不保證順序）

判斷準則

問自己：這些類別之間有沒有「大小」或「先後」？有就用序數編碼，沒有就用 One-Hot

★ 與 W4 的銜接

AI Studio 的 dummy coding 預設展開成 k 欄；做線性／邏輯斯迴歸時要留一欄當參照組（k-1 欄），否則與截距共線。M2-1 會回到這一點

作業一的思考題就是這個：Genre（男 / 女）只有兩類，兩種編碼的距離意義相同；但科別若用 1/2/3，會讓模型誤以為「急診 = 內科的三倍」。

PART 04

篩選、排序與聚合（ Aggregation ）

Filter, Sort, Aggregate

把資料整理成「一列代表一個分析單位」。
在醫療資料裡，這一步通常比想像中麻煩。

三組核心 Operator

目的	Operator	說明	原課程範例
篩選列	Filter Examples	依條件保留或排除紀錄。 條件語法：欄位 運算子 值	【原課程範例】 Module 2
篩選欄	Select Attributes	保留或排除欄位。 subset / regular expression 兩種模式	【原課程範例】 Module 4
排序	Sort	依單一或多個欄位排序。 常用於檢查極值與時間序列（Time Series）	【原課程範例】 Module 2
分組聚合	Aggregate	把多列壓成一行。 這是改變「分析單位」的關鍵	【原課程範例】 Module 3
建立欄位	Generate Attributes	以運算式產生新欄位。 特徵工程（Feature Engineering）的主力	【原課程範例】 Module 4
重塑	Pivot / De-Pivot	長寬表互轉。 檢驗值紀錄常需要這一步	【原課程範例】 Module 7

Aggregate：改變分析單位

一列 = 一次就診

病歷號	就診日	科別	費用
A001	03/01	內科	800
A001	03/15	內科	650
A001	04/02	復健	1200
A002	03/08	外科	2400
A002	04/20	外科	900



一列 = 一位病人

病歷號	就診次數	總費用	平均費用	科別數
A001	3	2650	883	2
A002	2	3300	1650	1

為什麼要做

建模時「一列 = 一個病人」才對得上「這個病人會不會再入院」這種目標變數

聚合函數

count、sum、average、minimum、maximum、standard deviation、count(distinct)

實務提醒

聚合會遺失細節。建議同時保留多個統計量（總和、平均、最大、次數），讓模型自己挑

【原課程範例】 Module 3 - Merging & Grouping.rmp 。正確答案可對照同資料夾的 Module 3 - join and aggregate result.rmhdf5table

PART 05


合併：Join 的四種類型

Joining Tables

這是本模組最容易出錯、也最容易「錯得無聲無息」的地方。
筆數不對不會報錯，只會讓你後面的分析全部建在錯的資料上。

四種 Join ，保留誰

Inner Join




只保留兩邊都有的鍵值
最保守，也最容易悄悄弄丟資料
用途：確定兩邊都必須有資料時
風險：筆數大幅減少而不自知

Left Join




保留左表全部，右表補上
最常用——以主檔為準加掛資訊
用途：病人主檔 + 檢驗結果
右表沒有的地方會變成遺失值
(Missing Data)

Right Join



保留右表全部，左表補上
實務少用，通常改寫成 Left 較好讀
把兩表位置對調即等同 Left
建議統一用 Left，減少閱讀負擔

Outer Join



兩邊全部保留
用途：檢查「哪些只在單邊出現」
資料稽核時很有用
建模前通常不會直接用

AI Studio：Join Operator 的 join type 參數即為這四種。key attributes 要明確指定，不要依賴自動比對。

一對多 Join：筆數為什麼會從 3 變成 5

左表每一列可能對應右表多列——這就是筆數暴增（而且不報錯）的機制

左表 病人主檔（3 列）

A001
王○○

A002
李○○

A003
陳○○

×3
一對多

Left Join 結果（5 列）

A001 血糖 98

A001 血壓 120

A001 膽固醇 210


A002 血糖 145

A003 （無檢驗紀錄）

A001 有三筆檢驗 → 主檔那一列被複製三次。
若之後直接 count，會誤以為有 5 位病人。

正確做法：若要「一列一病人」，Join 前先對右表 Aggregate；或 Join 後再 Aggregate 回來。A003 的空值是 Left Join 保留下來的正常資訊，不要當成錯誤刪掉。

實例：Join 前後的筆數變化



Inner 少了 258 筆

鍵值對不上——可能有空白、大小寫或型態不一致

Left 多了 180 筆

一對多關係：右表同一鍵值有多筆，左表那列被複製

Outer 最多

兩邊全留，適合稽核「哪些只在單邊出現」

★ 養成習慣

每做一次 Join 就在旁邊接一個 Statistics。它不會報錯，只會安靜地給你錯的資料

Join 前後的四項檢查

檢查	怎麼做	看到什麼要警覺
1 筆數比對	Join 前後各接一個 Statistics，記下 Examples 數	Inner Join 後筆數大減 → 鍵值對不上 Left Join 後筆數變多 → 一對多關係
2 鍵值清理	Join 前先對鍵值欄位做 Trim、Generate Attributes 的 lower()	前後空白、全形半形、大小寫不一致 都會讓相同的鍵值對不起來
3 鍵值型態一致	確認兩邊的鍵值都是同一種型態	一邊是 integer、一邊是 polynomial 會完全對不上且不報錯
4 遺失值檢視	Join 後看新增欄位的遺失比例	遺失比例極高 → 可能 Join 錯欄位 預期有人沒資料卻 0% 遺失 → 可能誤用 inner

養成習慣：每做一次 Join，就在旁邊放一個 Statistics。這三十秒能省下之後好幾天的除錯。

PART 06

遺失值

Missing Data

「這欄有 30% 缺失，要刪掉還是補起來？」
這個問題沒有標準答案——要先問「為什麼會缺」。

三種遺失機制：全名與判別方式


縮寫	英文全名	中文	一句話定義	怎麼判別
MCAR	Missing Completely At Random	完全隨機遺失	缺不缺，與任何變數都無關——純粹是運氣	比較「有缺失」與「無缺失」兩組的其他欄位分布。若幾乎相同 → 傾向 MCAR
MAR	Missing At Random	隨機遺失	缺不缺，與「其他看得到的欄位」有關，但與該欄自己的值無關	以「是否缺失」為目標跑一次分類。若其他欄位預測得出來 → 傾向 MAR（無法排除 MNAR）
MNAR	Missing Not At Random	非隨機遺失	缺不缺，與「那個看不到的值本身」有關	資料本身無法證明。只能靠領域知識推斷

MAR 的英文容易誤導：Missing At Random 其實是「在控制其他變數後才隨機」，不是「完全隨機」。真正的完全隨機是 MCAR。

用同一個欄位看懂三種機制

缺失的原因

情境	骨密度檢查為什麼會缺
A	儀器當機那半天的病人都沒做
B	年輕族群依規定不需常規檢查
C	骨密度極差的人痛到做不完檢查



對應的機制

情境	機制	刪除會怎樣
A	MCAR	只損失樣本數，不偏
B	MAR	樣本偏向年長者
C	MNAR	把最嚴重的人系統性刪掉

A → MCAR

缺失原因（儀器當機）與病人的任何特質都無關

B → MAR

缺失與「年齡」有關，而年齡是你看得到的欄位 → 可用年齡建模填補

C → MNAR


缺失與「骨密度值本身」有關，而那個值正是你看不到的 → 最麻煩

為什麼 C 最危險

刪掉 C 的人，模型會以為「沒有人骨密度那麼差」，低估高風險族群

醫療資料多屬 B 與 C。實務建議：新增 is_missing 指示欄位，讓「有沒有做這項檢查」本身成為一個特徵。

拿到一個有遺失值的欄位，怎麼判斷它屬於哪一種機制



★ 重要限制：這三個檢查只能「支持」某個假設，不能「證明」。特別是 MNAR 與 MAR 在觀測資料上長得一模一樣——分辨它們靠的是領域知識，不是統計檢定。

三種遺失機制，處理方式完全不同

1

MCAR 完全隨機遺失

- ▶ 缺失與任何變數都無關
- ▶ 例：儀器隨機故障、表單掉頁
- ▶ 刪除不會造成偏誤（Bias），只損失樣本數
- ▶ 但真正的 MCAR 在實務上很罕見
- ▶ 檢查：缺失組與非缺失組的其他欄位分布相近
- ▶ 處理：缺失比例低時可直接刪除

2

MAR 隨機遺失

- ▶ 缺失與「其他已觀測欄位」有關
- ▶ 例：年輕族群較少做骨密度檢查
- ▶ 直接刪除會讓樣本偏向年長者
- ▶ 可用其他欄位建模來預測填補
- ▶ 檢查：以缺失與否為目標跑一次分類看得不得出來
- ▶ 處理：多重插補或以模型填補

3

MNAR 非隨機遺失

- ▶ 缺失與「缺失值本身」有關
- ▶ 例：病情輕的人根本不做這項檢查
- ▶ 最麻煩——資料本身無法自證
- ▶ 刪除或填補都會造成系統性偏誤（Bias）
- ▶ 「有沒有做這項檢查」本身就是特徵
- ▶ 處理：新增遺失指示欄位，並在報告中說明限制

醫療資料以 MAR 與 MNAR 居多。這也是為什麼「新增一個 is_missing 欄位」在醫療場域往往比單純填補更有價值。

醫療資料的遺失值（Missing Data）常常偽裝成 0

原始（0 = 未量測）

ID	懷孕次數	血糖	血壓	皮脂厚度	胰島素	BMI
1	6	148	72	35	0	33.6
2	1	85	66	29	0	26.6
3	8	183	64	0	0	23.3
4	1	89	66	23	94	28.1
5	0	137	40	35	168	43.1

轉為遺失值（Missing Data）後

ID	懷孕次數	血糖	血壓	皮脂厚度	胰島素	BMI
1	6	148	72	35	?	33.6
2	1	85	66	29	?	26.6
3	8	183	64	?	?	23.3
4	1	89	66	23	94	28.1
5	0	137	40	35	168	43.1

為什麼不能留著 0

懷孕次數 0 是有效值，但血糖 0、血壓 0、BMI 0 生理上不可能。留著會讓模型學到錯誤訊號

怎麼找出來


接 Statistics 看每個數值欄位的最小值，逐欄問「這個值在生理上可能嗎」

AI Studio 作法

Declare Missing Value（把 0 宣告為遺失）→ Replace Missing Values 或 Impute Missing Values 填補

這是 Pima Indians Diabetes 資料集，也是作業二（W8 發布）的指定資料。作業任務 1 要求你算出各欄位的 0 值比例並做成表格。

實例：遺失值模式圖——一眼看出「為什麼缺」



紅色＝缺失

每一列是一位病人、每一欄是一個欄位。整張圖三秒鐘看完資料品質

胰島素那欄

缺了近一半。這種欄位要先決定：整欄捨棄，還是保留並標記？

糖化血色素的規律

上半（65 歲以上）幾乎都有，下半大量缺——這是 MAR，不是隨機

為什麼重要

若直接刪除有缺失的列，剩下的資料會嚴重偏向年長者


六種處理策略與適用時機

策略	做法	適合	不適合
整列刪除	有缺失就刪掉整列	MCAR 且缺失比例 < 5%	缺失有系統性時會造成偏誤
整欄刪除	缺失比例過高的欄位整欄移除	缺失 > 50% 且該欄不關鍵	該欄是重要預測因子時
常數填補	以 0 或特定值填補	有明確語意（如「未申報 = 0」）	一般數值欄位，會扭曲分布
集中量數填補	以平均數或中位數填補	分布接近常態用平均， 偏態用中位數	缺失比例高時會低估變異（Variance）
模型填補	用其他欄位預測缺失值	MAR、缺失比例中等	可能引入循環依賴，需謹慎
新增指示欄位	保留缺失，另加 is_missing 欄	MNAR，缺失本身有意義	欄位數量會膨脹


【原課程範例】 Module 8 - Handling Missing Values.rmp 與 4. Case Studies/6. SumUp/2 Handling Missing values.rmp

實例：三種填補方式對分布的實際影響


① 刪除 $n \approx 332$



② 平均填補 填補值 104



③ 中位填補 填補值 89



三張圖的橫軸與縱軸完全相同（②③ 皆 $n=600$ ）。②③ 只有一根長條變高——那是「你替資料做的決定」，不是資料本來的樣子。

① 刪除

樣本數從 600 掉到約 330。若缺失非隨機，剩下的樣本已經偏了

② 平均數填補

中間長出一根不存在的尖峰——把大量個案灌到同一個值

③ 中位數填補

尖峰位置較貼近多數人所在的位置，偏態資料的較佳選擇

怎麼選

看 Statistics 的平均與中位數差多少。差很多 = 偏態 = 用中位數

填補時最容易犯的三個錯

錯誤一：先填補再切分資料

- ▶ 用整份資料算出的平均值去填補，等於把測試集的資訊帶進了訓練過程
- ▶ 正確作法：先切分，用訓練集的統計量填補訓練集與測試集
- ▶ AI Studio：把 Replace Missing Values 放進 Cross Validation 的訓練子流程，再以其 preprocessing model 套用到測試子流程

錯誤二：偏態分布用平均數填補

- ▶ 胰島素、醫療費用這類欄位通常右偏，少數極大值會把平均拉高
- ▶ 用平均填補會讓大量原本偏低的個案被灌成中高值
- ▶ 判斷方式：看 Statistics 的平均與中位數差多少；差很多就用中位數

錯誤三：填補後不留紀錄

- ▶ 填補是一個「你替資料做的決定」，必須可追溯
- ▶ 建議同時新增 is_missing 指示欄位，讓模型與你都知道哪些值是補的
- ▶ 報告中要寫清楚：哪些欄位補了、補多少比例、用什麼方法、為什麼

PART 07

離群值

Outliers

商業資料的預設是「找出來處理掉」。

醫療資料的預設應該是「找出來看清楚」——極端值往往正是你要找的人。


四種偵測方法

方法	判斷依據	門檻	限制
標準差法 (Z-score)	偏離平均幾個標準差	通常 $ z > 3$	假設接近常態； 離群值 (Outlier) 本身會拉高標準差
四分位距法 (IQR)	是否落在 $Q1 - 1.5 \times IQR \sim Q3 + 1.5 \times IQR$ 之外	1.5 倍 (保守用 3 倍)	對偏態分布較穩健； 盒鬚圖即依此繪製
距離法 (k 近鄰)	第 k 個最近鄰居有多遠	依 k 值與資料密度	必須先縮放 (如 Z-Score) ； 維度高時效果下降
密度法 (LOF)	周圍密度與鄰居相比稀疏多少	LOF 值明顯 > 1	資料有多個密度不同群體時較佳； 計算成本較高

【原課程範例】 Module 6 - Normalization & Detecting Outliers.rmp 。距離法與密度法在 W7 的異常偵測會深入。

實例：找離群值的三種視角


① 直方圖



② 盒鬚圖 (IQR 1.5 倍)



③ 標準差法 ($|z| > 3$)



① 直方圖

看得到右側孤立的幾個點，但看不出確切是哪幾筆

② 盒鬚圖

超過 $Q3 + 1.5 \times IQR$ 的点自動被畫出來。對偏態資料較穩健

③ 標準差法

$|z| > 3$ 標紅。注意：離群值本身會拉高標準差，讓門檻變寬

醫療場域的下一步

找到之後先問「生理上可能嗎」。血壓 138 是真實極端值，血壓 0 是遺失

找到離群值之後，四個選項

可以怎麼做

- ▶ 保留：確認是真實的極端個案，直接留下
- ▶ 標記：新增 `is_outlier` 欄位，保留但可追蹤
- ▶ 修正：確認是輸入錯誤（如身高 1.75 應為 175）後更正
- ▶ 封頂：以 99 百分位取代極端值（winsorizing）
- ▶ 移除：確認是無效資料且無法修正時才刪除
- ▶ AI Studio：Detect Outlier 系列會新增 `outlier` 欄位供你決定

醫療場域的判斷順序

- ▶ 先問：這個值在生理上可能嗎？不可能 → 視為遺失
- ▶ 再問：可能但罕見嗎？→ 這可能就是重症個案，應保留
- ▶ 移除離群值（Outlier）等於把最需要被辨識的族群從訓練資料刪掉
- ▶ 若模型的用途是「找出高風險者」，刪掉極端值會直接毀掉目標
- ▶ 建議預設：標記而非刪除，並在建模後單獨檢視這群人的預測結果
- ▶ 報告中務必說明你的處理方式與理由

W7 的異常偵測（Anomaly Detection）會回到這個主題——當「找出異常」本身就是目標時，這些極端值就是你的正樣本。

PART 08

重複與不一致

Duplicates & Inconsistency

「看起來一樣」跟「電腦覺得一樣」是兩件事。
這一節處理的就是這個落差。

文字不一致：同一件事的五種寫法

原始

ID	縣市	科別	性別
1	台北市	內科	男
2	臺北市	內科	M
3	台北市	內 科	男
4	TAIPEI	內科	1
5	新北市	外科	女



標準化後

ID	縣市	科別	性別
1	臺北市	內科	M
2	臺北市	內科	M
3	臺北市	內科	M
4	臺北市	內科	M
5	新北市	外科	F

多餘空白

「內科」與「內科」是不同的值。Operator：Trim（2026.1 起另有 Trim/Strip 可自訂字元）；「內 科」的中間空白要用 Replace

全形半形與異體字

台 / 臺、英文大小寫。Operator：Replace（正規表示式）；★ Transform Cases 屬 Text Processing 擴充、對象是文件，一般欄位請用 Generate Attributes 的 lower() / upper()

同義不同碼

男 / M / 1 需先建立對照表統一。Operator：Map 或 Replace Dictionary

為什麼重要

不統一的話，原本 1 個類別會被當成 4 個，分群（Clustering）與 One-Hot 編碼全部走樣

檢查方式：對每個類別欄位接一個 Statistics，看 unique values 的數量與清單。數量比你預期的多，就是有不一致。

三種重複，處理方式不同

型態	定義	怎麼找	怎麼處理
完全重複	所有欄位都一樣	Remove Duplicates (不指定欄位)	直接去重，通常無爭議
鍵值重複	主鍵重複但其他欄位不同	以主鍵 Aggregate 後看 count > 1	要判斷：是資料錯誤，還是本來就一對多？
語意重複	不同紀錄其實指同一個對象	姓名 + 生日 + 性別 組合比對	需要模糊比對； 醫療場域常見於跨院整合

鍵值重複最危險：它常常不是錯誤，而是你誤解了資料的粒度。先確認「一系列到底代表什麼」再決定。

PART 09

相關與共線性

Correlation & Collinearity

兩個欄位如果講的是同一件事，模型會被搞混。

這一節先學會量化「重複的資訊」，第 4 週的迴歸才知道要拿掉誰。

實例：用相關矩陣抓共線性

	年齡	身高	體重	BMI	收縮壓	舒張壓
年齡	1.00	-0.11	0.06	0.13	0.34	0.18
身高	-0.11	1.00	0.70	-0.09	-0.04	-0.02
體重	0.06	0.70	1.00	0.85	0.21	0.16
BMI	0.13	-0.09	0.85	1.00	0.26	0.20
收縮壓	0.34	-0.04	0.21	0.26	1.00	0.63
舒張壓	0.18	-0.02	0.16	0.20	0.63	1.00

|r| 深淺  <0.2  0.2  0.4  0.6  ≥0.8 警戒

看深色的格子

收縮壓 × 舒張壓、體重 × 身高—— $|r|$ 高，是共線性的候選

為什麼要抓

兩者同時放進迴歸，模型無法分辨效果歸誰，係數會不穩甚至正負翻轉

三種處理

移除其一、合成新變數（如 BMI、脈壓）、或改用 Ridge 正則化


預測 vs 解釋

只做預測時影響有限；要回答「哪個因素重要」就必須處理

相關係數 r 怎麼算：六位病人的手算

離差乘積表

病人	收縮壓 x	舒張壓 y	$x-\bar{x}$	$y-\bar{y}$	$(x-\bar{x})(y-\bar{y})$	$(x-\bar{x})^2$	$(y-\bar{y})^2$
P1	120	78	-9.83	-5.83	57.36	96.69	34.03
P2	132	85	2.17	1.17	2.53	4.69	1.36
P3	118	74	-11.83	-9.83	116.36	140.03	96.69
P4	145	94	15.17	10.17	154.19	230.03	103.36
P5	138	90	8.17	6.17	50.36	66.69	38.03
P6	126	82	-3.83	-1.83	7.03	14.69	3.36
合計	$\bar{x}=129.83$	$\bar{y}=83.83$			387.83	552.83	276.83











計算過程

步驟	計算
公式	$r = \frac{\sum(x-\bar{x})(y-\bar{y})}{\sqrt{\sum(x-\bar{x})^2 \times \sum(y-\bar{y})^2}}$
分子	387.83
分母	$\sqrt{(552.83 \times 276.83)} = \sqrt{153,043} = 391.21$
r	$387.83 \div 391.21 = 0.9914$
r	0.99 → 遠超過 0.8 的警戒線
結論	收縮壓與舒張壓高度共線，迴歸不宜同時放入

分子	x 與 y 是否一起偏離各自的平均。同方向 → r 為正
分母	把單位除掉，所以 r 無單位、落在 -1 到 +1
r	只看強度不看方向：- 0.88 與 +0.88 一樣強
AI Studio	Correlation Matrix 一次算完所有欄位，不必手算
★ 本例為教學用模擬數字，r=0.99 是為了讓手算好對。真實族群的收縮壓與舒張壓 r 約 0.6-0.75——若兩者真的接近完全共線，PART 11 的「脈壓=收縮壓-舒張壓」就不會是有用的特徵了。這是 Pearson 相關係數，只抓線性關係。	

|r| 怎麼讀：八種強度的實際長相



|r| 的意義

絕對值只看強度、不看方向。 $r = +0.89$ 與 $r = -0.89$ 的關聯一樣強

紅框 = 警戒區

$|r| \geq 0.8$ 。兩個變數提供的資訊高度重疊，同時放進迴歸會出問題

r^2 更好懂

$r = 0.8 \rightarrow r^2 = 0.64$ ，代表兩者共享 64% 的變異。 $r = 0.5$ 只共享 25%

只抓線性關係

若關係是 U 型， r 可能接近 0，但兩者其實有很強的非線性關係——所以要搭配散布圖看

|r| 的判讀標準與處理

r 範圍	強度	r^2 (共享變異)	在共線性上的意義	建議處理
0.9 - 1.0	極強	81% - 100%	幾乎是同一個變數的兩種寫法	必須移除其一
0.8 - 0.9	強	64% - 81%	共線性警戒區	移除、合成或 Ridge
0.7 - 0.8	中強	49% - 64%	需留意，視樣本數而定	可保留但檢查 VIF
0.4 - 0.7	中等	16% - 49%	一般可接受	通常不必處理
0.0 - 0.4	弱	0% - 16%	無共線性疑慮	不必處理

這些切點是慣例而非鐵律。變數少、樣本大時可放寬；要做因素解釋時應更嚴格。更嚴謹的判準是 VIF（變異數膨脹因子），一般以 $VIF > 10$ 為警戒（較嚴格用 5）；它能抓到兩兩相關看不出的多變數共線。

PART 10

正規化與標準化

Normalization & Standardization

不是每個模型都需要縮放。


但需要的時候不做，結果會完全被值域最大的欄位主導。

兩種縮放方式


比較項目	正規化 Min-Max	標準化 (Standardization) Z-Score
計算方式	$(x - \min) / (\max - \min)$	$(x - \text{平均}) / \text{標準差}$
結果範圍	固定落在 0 到 1 之間	平均為 0、標準差為 1，無固定範圍
對離群值	敏感——一個極端值會壓縮其他所有值	同樣受影響（平均與標準差會被拉動）；要穩健可改用中位數與 IQR 縮放
保留什麼	線性轉換，分布形狀不變	同樣是線性轉換；★ 不會讓分布變成常態，偏態仍是偏態
何時用	需要固定範圍時（如影像像素、神經網路輸入層）	一般情況的預設選擇；距離型演算法最常用
AI Studio	Normalize method = range transformation	Normalize method = Z-transformation

實例：不縮放時，年齡等於不存在

左・原始尺度（軸同刻度）



右・Z-Score 標準化後



左圖的点被壓成一條水平帶：年齡的差異在距離計算裡幾乎沒有貢獻。右圖兩軸展開後才等權。

左・原始尺度

兩軸畫成同一刻度後才看得清楚：年齡的變化幅度被收入完全壓扁

距離怎麼算的

歐氏距離把兩軸的差平方相加。收入差 50、年齡差 5 → 平方後收入貢獻是年齡的 100 倍

右・Z-Score 後


兩個特徵都變成「離平均幾個標準差」，等權參與距離計算

影響誰


所有用到距離的方法：k-NN、K-Means、PCA、SVM、神經網路

實例：縮放如何改變分群結果

左・真實結構



中・未縮放 (77%)



右・Z 標準化 (98%)



中圖的兩條紅色虛線是分群的切線——全部水平（只切收入）。收入的值域是年齡的十幾倍，距離完全被它主導，年齡等於沒有參與。

左・真實結構

刻意造出三群：中低收入年輕、中低收入年長、高收入中年

中・未縮放 (純度 77%)

切線全是水平的——只依收入分，年齡完全沒有作用

右・Z-Score 後 (98%)

兩個維度等權，三個真實群組被還原

★ 作業一任務 4

就是要你在 Mall Customer 資料上親手跑出這組對照

哪些演算法需要縮放

演算法	需要縮放	不需要	本課週次
k-NN 最近鄰	●		W5
K-Means 分群 (Clustering)	●		W6
PCA 主成分分析	●		W6
SVM 支援向量機	●		W5
神經網路 / 深度學習 (Deep Learning)	●		W8
線性 / 邏輯斯迴歸 (有正則化時)	●		W4-W5
決策樹 (Decision Tree)		●	W5
隨機森林 / 梯度提升		●	W5、W7
Naive Bayes		●	W5

● 適用 判準：演算法有沒有用到「距離」或「權重大小」？有就需要縮放。樹模型只比大小不比距離，所以不需要。

縮放的鐵則：參數只能從訓練集計算

為什麼

- ▶ 縮放需要平均、標準差、最大最小值——這些都是「從資料算出來的統計量」
- ▶ 若用整份資料計算，測試集的分布資訊就滲進了訓練過程，這是典型的資料洩漏（Data Leakage）
- ▶ 後果：測試集分數虛高，實際部署時表現大幅下滑

AI Studio 的正確作法

- ▶ 錯誤：Retrieve → Normalize → Split Data → 訓練與測試
- ▶ 正確：Retrieve → Split Data → 訓練集 Normalize（保留模型）→ 以同一組參數套用到測試集
- ▶ 更好：把 Normalize 整個放進 Cross Validation 的訓練子流程內，讓每一折各自計算

怎麼檢查自己有沒有犯錯

- ▶ 看流程圖：Normalize 出現在 Split Data 或 Cross Validation 之前，就是錯的
- ▶ Normalize Operator 有一個 preprocessing model 輸出——它就是給測試集用的
- ▶ 作業一與作業二都會檢查這一點

PART 11

特徵工程

Feature Engineering

這是你們最有優勢的一節。

因為好的特徵來自領域知識，不是來自演算法。

六種常見手法

ARITHMETIC

算術衍生

- 由既有欄位計算出新欄位
- BMI = 體重 / 身高²、脈壓 = 收縮壓 - 舒張壓
- Operator : Generate Attributes

BINNING

分箱

- 連續值切成區間，變成有序類別
- 年齡 → 青年 / 中年 / 長者；BMI → 過重 / 肥胖
- Operator : Discretize by Binning / by User Specification

ENCODING

類別編碼

- 類別轉數值。無序用 One-Hot、有序用序數
- 類別過多時可用頻率或目標編碼 (Target Encoding)
- Operator : Nominal to Numerical

TRANSFORM

數值轉換

- 對數轉換修正右偏 (費用、住院天數常見)
- 平方根、Box-Cox 等
- Operator : Generate Attributes 用 `log()` / `sqrt()`

DATETIME

時間特徵

- 由日期展開：星期幾、月份、是否假日
- 計算間隔：距上次就診幾天、年齡
- Operator : Date to Numerical / Generate Attributes

AGGREGATION


聚合特徵

- 由歷史紀錄統計：近一年就診次數、平均費用
- 最能帶入領域知識的一類
- Operator : Aggregate 後 Join 回主檔


【原課程範例】 Module 4 - Creating & Removing Columns.rmp ; 4. Case Studies/6. SumUp/4 與 5 (特徵工程與格式轉換)

實例：用臨床切點分箱

左・原始連續值



右・依國健署切點分箱後



切點來自臨床標準而不是資料本身。等距或等頻切出來的界線，在臨床上沒有意義。

左・連續值 + 切點

紅色虛線是國健署成人體位標準的切點，不是等距也不是等頻

為什麼不用等距

BMI 23.9 與 24.1 數值幾乎一樣，但跨越了「過重」的臨床界線

右・分箱後

六個有臨床意義的級距，可直接對應衛教建議

代價與折衷

會損失組內細節。建議原始數值與分箱欄位同時保留，讓模型自己選

分箱（Binning）：把連續值變成有臨床意義的類別

原始連續值

ID	BMI
1	17.8
2	21.5
3	25.3
4	28.9
5	32.4



分箱後

ID	BMI	體位分類	是否過重
1	17.8	過輕	0
2	21.5	正常	0
3	25.3	過重	1
4	28.9	輕度肥胖	1
5	32.4	中度肥胖	1

為什麼要分箱（Binning）

BMI 23.9 與 24.1 在數值上幾乎一樣，但在臨床判定上跨越了「過重」的界線

切點從哪來

用領域標準而不是等距或等頻。★ 依國健署：過輕 <18.5、健康 18.5-23.9、過重 24-26.9、輕度肥胖 27-29.9、中度 30-34.9、重度 ≥ 35。注意 WHO 國際標準的過重切點是 25，台灣是 24，寫報告時要標明採用哪一套

代價

會損失組內的細節資訊。建議同時保留原始數值與分箱欄位，讓模型自己選

這一頁是「領域知識轉成特徵」最典型的例子。演算法不知道 24 這個地方有一條線，但你知道。

PART 12

資料洩漏


Data Leakage

每一步都做對了，指標卻好得不合理。
八成是這個問題——而且它不會報錯。

五種常見的洩漏來源

洩漏型態	長什麼樣	怎麼發現
前處理洩漏	縮放、填補、特徵選擇（Feature Selection）在切分之前做，用到了全部資料的統計量	看流程圖：這些步驟有沒有在 Split Data 之前
時間洩漏	用了預測時間點之後才會知道的資訊	逐欄問：預測當下真的拿得到這個欄位嗎？
目標洩漏	某個特徵其實是由目標變數推導出來的	特徵重要性（Feature Importance）排序中，某一欄異常突出
重複樣本洩漏	同一個對象同時出現在訓練集與測試集	以病人 ID 檢查交集；多次就診者要以病人為單位切分
過取樣 （Oversampling）洩漏	SMOTE 等取樣在切分之前做，合成樣本進了測試集	取樣 Operator 有沒有在切分之後

實例：時間洩漏的判斷方法



紅色直線

預測發生的那一刻。這條線是你判斷每個欄位能不能用的唯一依據

綠色欄位

入院檢驗、住院用藥、出院前評估——預測當下都已經存在，可以用


紅色欄位

出院後門診次數、30 天內急診紀錄——預測時還沒發生，用了就是洩漏

怎麼檢查

把每個欄位問一次：「預測那一刻，我真的拿得到這個值嗎？」

同一件事，錯的順序與對的順序



★ 找出規律了嗎——正確的那一欄，Split Data 永遠排在第二格。所有「會用到整份資料統計量」的動作，都必須發生在切分之後。最省事的統一解法：把前處理整包放進 Cross Validation 的訓練子流程內，AI Studio 支援這種寫法，W5 會示範。

三個「好到不合理」的警訊

Accuracy 或 AUC 超過 0.98

- ▶ 在真實的醫療預測問題上，這種數字幾乎不存在
- ▶ 先假設是洩漏，逐項排查上面五種來源，而不是先高興
- ▶ 例外：問題本身很簡單（如以體溫判斷發燒），但那通常不需要機器學習

某一個特徵的重要性遠高於其他所有特徵

- ▶ 看特徵重要性（Feature Importance）排序，若第一名的權重是第二名的好幾倍，要特別警覺
- ▶ 常見情況：那一欄其實是目標的另一種寫法，或是由目標推算出來的
- ▶ 檢查方法：把那一欄拿掉重跑。若指標暴跌，代表模型完全靠它

訓練集與測試集的分數幾乎一樣好

- ▶ 正常情況下測試集會略差一些；分數異常高又完全沒有落差時才可疑
- ▶ 可能原因：測試集資料早已出現在訓練集中（重複樣本洩漏）
- ▶ 檢查方法：以個案 ID 比對兩個集合，確認沒有交集

這一頁請在每次做完模型後拿出來對一遍。Task 1 與兩份作業的評分都會檢查你有沒有處理這件事。

PART 13

實作與練習

Hands-On

第 2 週做 Module 1-5，第 3 週做 Module 6-10。
課後再把完整前處理鏈跑一次。

第 2 週實作 | 資料存取、整理與合併

【原課程範例】 Module 1-5

開啟檔案

範例 /ML (AI Studio)/M1. 資料工程 /
(檔名前綴皆為 RapidMiner)
├ Module 1- Accessing Data.rmp
├ Module 2- Filtering & Sorting.rmp
├ Module 3- Merging & Grouping.rmp
├ Module 4- Creating & Removing Columns.rmp
└ Module 5- Changing Types & Roles for Modeling.rmp

資料 /ML (AI Studio)/M1. 資料工程 /
├ Altoona Crime Rates ← 左表
├ Data Altoona Crime Rates - add on ← ★ 右表
├ Lab 1 Data Altoona Crime Rates
└ Module 3 - join and aggregate result ← 正確答案

預期結果

- ▶ Inner Join 的輸出筆數通常最少
- ▶ Left Join 遇到一對多關係時筆數會超過左表
- ▶ 鍵值有空白或大小寫不一致時，Join 會安靜地對不上
- ▶ Module 5 完成後，Statistics 中應可看到 label 與 id 的角色標示

操作步驟

- 1 Module 1：匯入後立刻接 Statistics，檢查筆數、欄位數、每欄型態與極值
- 2 Module 2：練習 Filter Examples 的條件語法，注意文字要不要加引號
- 3 Module 3：★ 本週核心。在 Join 前後各接一個 Statistics，記錄筆數
- 4 把 join type 依序改成 inner / left / right / outer，各記錄一次輸出筆數
- 5 自行列表記錄四種 join 的筆數，並回答：哪一種讓筆數變多？為什麼？
- 6 Module 4：用 Generate Attributes 建立一個衍生欄位（例如每千人犯罪率）
- 7 Module 5：把目標欄位設為 label，把識別欄位設為 id
- 8 與 Module 3 - join and aggregate result 對照，確認你的結果一致

第 3 週實作 | 資料品質、EDA 與特徵工程

【原課程範例】 Module 6-10、6. SumUp 完整前處理鏈

開啟檔案

範例 /ML (AI Studio)/M1. 資料工程 /

(檔名前綴皆為 RapidMiner)

- └ Module 6- Normalization & Detecting Outliers.rmp
- └ Module 7- Pivoting.rmp
- └ Module 8- Handling Missing Values.rmp
- └ Module 9- Macros, Sampling & Subprocess.rmp
- └ Module 10- Looping & Branching.rmp

資料 /ML (AI Studio)/M1. 資料工程 /

- └ Data Altoona Crime Rates with
missing.rmhdf5table ← 刻意含遺失值

預期結果

- ▶ 平均填補會把分布往中間擠，變異數下降
- ▶ 偏態欄位用平均與用中位數，結果差異明顯
- ▶ 標記筆數由 number of outliers 決定；改 k 只會改變「誰」被標記
- ▶ 未縮放時，值域最大的欄位會主導距離計算

操作步驟

- 1 Module 8：先接 Statistics，記下每欄的 Missing 數量與最小值
- 2 分別用「整列刪除」「平均填補」「中位數填補」跑三次，比較統計量變化
- 3 觀察：偏態欄位用平均填補後，分布形狀改變了多少？
- 4 Module 6：Normalize 試 Z-transformation 與 range transformation 各一次
- 5 同一流程加入 Detect Outlier (Distances)，固定 number of outliers，k 試 5 / 10 / 20，比較被標記的是誰
- 6 把被標記的點畫成散布圖，用顏色區分，肉眼確認是否合理
- 7 Module 7、9、10 列為自學：樞紐（Pivot）重塑、巨集與抽樣、迴圈與分支
- 8 延伸：跑一次 6. SumUp 的完整前處理鏈（1→7 共七個流程）

本模組用到的原課程教材對照

主題	原課程檔案	位置
資料存取、篩選、合併、欄位、型態角色	RapidMiner Module 1 ～ Module 5 （共 5 個 .rmp）	2. Data Science Tools/
正規化、離群值、樞紐（ Pivot ）、遺失值、巨集、迴圈	RapidMiner Module 6 ～ Module 10 （共 5 個 .rmp）	2. Data Science Tools/
練習資料（含刻意製造的遺失值與待合併的附加檔）	Altoona Crime Rates、Lab 1 Data、Data ... with missing、Data ... add on	2. Data Science Tools/
Join 與聚合（ Aggregation ）的正確答案	Module 3 - join and aggregate result.rmhdf5table	2. Data Science Tools/
完整前處理鏈（統計→遺失值→單變量→特徵工程→不平衡→存檔）	6. SumUp - A complete hand-on Practice （原資料夾拼字如此；前處理為 1 ～ 7，5 Modeling ／ 8 ／ 9 屬建模）	4. Case Studies/
資料品質檢查的實例說明	資料品質檢查.docx	4. Case Studies/4.2 Car Sales/
概念詳解（英文自學包）	ML 3.1 Data Science - Data Prep & EDA.pptx 第 60-93、109-127、138-158 頁	課程根目錄

Module 1-10 範例已複製到「範例 /ML (AI Studio)/M1. 資料工程 /」、資料在「資料 /.../M1. 資料工程 /」； 6. SumUp 與 Telco 資料未複製，請至 AI Studio Repository 原始位置開啟。

課堂範例對應：這一頁教的東西，用哪一個範例跑

教學重點（PART）	AI Studio 範例檔	資料檔	層級
2 存取 · 3 型態與角色	RapidMiner Module 1- Accessing Data RapidMiner Module 5- Changing Types & Roles	Altoona Crime Rates	示範
4 篩選、排序與聚合	RapidMiner Module 2- Filtering & Sorting RapidMiner Module 3- Merging & Grouping	Lab 1 Data Altoona Crime Rates	示範
5 Join 四種類型 ★ 本週核心	RapidMiner Module 3- Merging & Grouping join type 四種各跑一次，記錄筆數	Altoona Crime Rates（左） ★ - add on（右，必用）	示範
6 遺失值	RapidMiner Module 8- Handling Missing Values 6. SumUp / 2 Handling Missing values	Data Altoona Crime Rates with missing	示範
7 離群值 · 10 正規化	RapidMiner Module 6- Normalization & Detecting Outliers	同上	示範
9 共線性 · 11 特徵工程	6. SumUp / 3 univariate analysis 6. SumUp / 4、5 特徵工程與格式轉換	Telco Customer churn	自學
4 重塑 · 流程自動化	RapidMiner Module 7- Pivoting Module 9- Macros / Module 10- Looping & Branching	同上	挑戰
★ 全模組貫穿（新製）	M1 醫療版模擬資料 五支 .rmp 匯入 / Join / 遺失重複 / 共線性分箱 / 防洩漏	M1_ 門診主檔 M1_ 檢驗結果	示範

Module 1-10 與醫療版範例已複製到「範例 /ML (AI Studio)/M1. 資料工程 /」，資料在「資料 /ML (AI Studio)/M1. 資料工程 /」；原始位置在 AI Studio Repository ► Data Sciences Course Materials (AI Studio) ► 2. Data Science Tools 與 4. Case Studies。

課後思考題

Q
1

你的貫穿主線資料裡，有沒有「偽裝成有效值」的遺失？怎麼找出來？

提示：接 Statistics 看每個數值欄位的最小值，逐欄問這個值在你的領域裡可能嗎。

Q
2

如果一個欄位有 40% 缺失，但它是你認為最重要的預測因子，你會怎麼做？

提示：先判斷遺失機制。若是 MNAR，「有沒有這筆資料」本身可能就是一個有用的特徵。

Q
3

為什麼決策樹（Decision Tree）不需要縮放，但 k-NN 需要？

提示：想想這兩個演算法各自「怎麼比較兩筆資料」——一個比大小，一個算距離。

Q
4

你的專題如果要做「預測」，哪些欄位是預測當下其實拿不到的？

提示：把時間軸畫出來，標出預測發生的時間點，然後逐欄檢查取得時間。

PART 14

Take-Home Assignment

帶回家作業（資料工程篇）

主題：把一份髒資料整理成可建模的狀態

第 4 週上課前繳交 | 不另計分，屬隨堂 Lab（出席與課堂參與 10%）

作業規格

項目	要求
主題	選一份「有品質問題」的公開資料集，完成從原始資料到可建模狀態的完整前處理。 建議：Pima Indians Diabetes（偽裝成 0 的遺失值）、Telco Customer Churn（混合型態）、UCI Heart Disease（多種缺失），或你自己貫穿主線的資料（須為公開或模擬資料）。
工具	AI Studio（正式名稱 RapidMiner AI Studio，原 Altair AI Studio）。流程需可正常執行並繳交 .rmp 檔。
形式	個人作業。PDF 報告（含截圖）+ .rmp 流程檔，壓縮為一個檔案上傳。
篇幅	報告本文 5-8 頁（不含截圖附錄）。
期限	第 4 週上課前上傳至學校 iClass。

七個必做任務

任務	要求	對應章節
1 資料品質健檢	以 Statistics 檢視全部欄位，做出一張品質檢查表：筆數、欄位數、每欄型態、遺失比例、最小 / 最大值。標出「生理上不可能」的值。	PART 1-2
2 遺失值機制判別	至少挑三個有缺失的欄位，判斷屬於 MCAR / MAR / MNAR，並說明你的判斷依據（不是用猜的）。	PART 6
3 遺失值處理與比較	同一欄位分別做「刪除」「平均填補」「中位數填補」，比較前後的平均、標準差與分布圖，說明最終選擇的理由。	PART 6
4 離群值檢查	以直方圖、盒鬚圖、標準差法三種方式檢查至少兩個數值欄位。說明你選擇「保留／標記／修正／移除」的理由。	PART 7
5 共線性檢查	產生 Correlation Matrix，找出 $ r $ 最高的一組欄位並報告其 r 值。說明你會如何處理（或為何不處理）。	PART 9
6 特徵工程	建立三個新特徵：算術衍生、分箱（須用領域切點）、類別編碼各一。說明每個特徵的領域理由。	PART 11
7 防洩漏檢核	畫出你的流程圖，標示切分點在哪。逐項檢查五種洩漏來源，說明你如何避免。	PART 12

四個必答思考題（寫入報告）

Q
1

你的資料裡，哪些遺失是「偽裝成有效值」的？你怎麼發現它們？

提示：看 Statistics 的最小值，逐欄問「這個值在這個領域裡可能嗎」。列出你檢查過的欄位清單。

Q
2

你選擇的填補方式，會讓哪些統計量失真？失真多少？

提示：比較填補前後的平均、標準差、四分位數。用數字說明，不要只寫「影響不大」。

Q
3

如果這份資料要用來做「預測」，哪些欄位是預測當下拿不到的？

提示：把時間軸畫出來，標出預測發生的時點，逐欄檢查取得時間。

Q
4

你做的所有前處理決策中，哪一個最可能被別人質疑？你的理由是什麼？

提示：誠實面對爭議點比迴避有價值。這一題不會因為「有爭議」而扣分，只會因為「說不出理由」而扣分。

回饋規準（共 100 分，不計入學期成績）

向度	配分	評分重點
資料品質健檢的完整性	20	是否逐欄檢查；是否找出偽裝的遺失值；表格是否可讀
遺失值處理的正確性	20	機制判別有依據；填補方式與分布特性相符；有量化前後差異
離群值與共線性	15	三種偵測方式都做； r 值正確；處理決策有理由
特徵工程的領域性	15	三個新特徵；分箱用領域切點而非等距；每個都說得出臨床或業務理由
防洩漏檢核	15	流程圖標出切分點；五種洩漏逐項檢查；前處理在正確位置
報告品質	15	結構清楚；圖表可讀；.rmp 可執行；誠實說明限制與爭議點

延伸挑戰：完整跑一次 6. SumUp 的七步前處理鏈並比較與你自建流程的差異；或以 M1 學到的方法整理你貫穿主線的真實資料集。

繳交前的自我檢查

方法面

- ▶ 所有前處理是否都在「切分之後」或「交叉驗證的訓練子流程內」？
- ▶ 縮放與填補的參數，是否只從訓練集計算？
- ▶ Join 前後是否比對過筆數？

報告面

- ▶ 每一個處理決策，是否都寫了「為什麼」而不只是「做了什麼」？
- ▶ 數字是否都有單位與樣本數？圖表是否有標題與軸標籤？
- ▶ 限制與爭議點是否誠實寫出來？

檔案面

- ▶ .rmp 關閉再重新開啟一次，確認沒有斷開的連線或找不到的資料來源
- ▶ 資料若非公開資料集，是否已確認為模擬或去識別化資料？
- ▶ 檔名格式：學號_姓名_M1 作業.zip

中英術語對照 | M1

(1 / 3)

中文	English	一句話說明
資料工程	Data Engineering	讓資料可用、可信、可取得
探索性資料分析	Exploratory Data Analysis, EDA	建模前先理解資料的分布與關係
資料品質	Data Quality	完整性、正確性、一致性、時效性、有效性、唯一性
遺失值	Missing Data	該有值卻沒有；醫療資料常偽裝成 0
完全隨機遺失	Missing Completely At Random, MCAR	缺失與任何變數無關
隨機遺失	Missing At Random, MAR	缺失與其他已觀測變數有關
非隨機遺失	Missing Not At Random, MNAR	缺失與缺失值本身有關（最麻煩）
填補	Imputation	以平均、中位數或模型預測補上缺失值
離群值	Outlier	明顯偏離其他資料的觀測值

中英術語對照 | M1

(2 / 3)

中文	English	一句話說明
四分位距	Interquartile Range, IQR	Q3–Q1 ； 盒鬚圖判定離群的依據
正規化	Normalization / Min-Max Scaling	壓縮到 0–1 區間
標準化	Standardization / Z-Score	轉為平均 0 、標準差 1
特徵工程	Feature Engineering	把領域知識變成模型看得懂的欄位
分箱	Binning / Discretization	連續值切成有意義的區間
虛擬變數	Dummy Variable / One-Hot Encoding	類別展開成 0/1 欄位
序數編碼	Ordinal Encoding	有序類別編成 1/2/3 保留次序
目標編碼	Target Encoding	以各類別的陽性率取代類別（洩漏風險高）
聚合	Aggregation	把多列壓成一行，改變分析單位

中英術語對照 | M1

(3 / 3)

中文	English	一句話說明
樞紐／重塑	Pivot / Reshape	長寬表互轉
合併	Join / Merge	依鍵值把兩張表接起來
內部合併	Inner Join	只保留兩邊都有的鍵值
左合併	Left Join	保留左表全部，右表補上
外部合併	Outer Join	兩邊全部保留
一對多	One-to-Many	右表同鍵值多筆，造成 Join 後筆數增加
資料洩漏	Data Leakage	訓練時用到預測當下拿不到的資訊
共線性	Collinearity / Multicollinearity	自變數之間高度相關
變異數膨脹因子	Variance Inflation Factor, VIF	共線性的量化指標， >10 需警覺

本模組重點回顧

- 1 資料品質六個維度：有效性、完整性、唯一性最容易用 Statistics 快速檢查。
- 2 Join 前後一定要比對筆數。一對多關係會讓筆數暴增而不報錯。
- 3 遺失值先問「為什麼缺」再決定怎麼補；醫療資料的遺失常偽裝成 0。
- 4 離群值在醫療場域傾向標記而非刪除——極端值往往正是目標族群。
- 5 縮放參數只能從訓練集計算，且樹模型不需要縮放。
- 6 資料洩漏（Data Leakage）不會報錯，只會給你好看的假分數。指標好到不合理時先查它。

下一步 第 4 週 M2 監督式學習（Supervised Learning）I：迴歸