

資料工程：從原始資料到可建模

M1 — Data Engineering: From Raw Data to Model-Ready

這是整門課最花時間、也最決定成敗的一段。
模型選錯還可以換，資料處理錯了，後面全部都是錯的。

本單元大綱

01 為什麼這段最花時間

資料品質的六個維度

02 資料存取與匯入

來源、格式與最常見的三個坑

03 型態與角色

AI Studio 怎麼看待每一個欄位

04 篩選、排序與聚合 (Aggregation)

把資料整理成分析單位

05 合併：Join 的四種類型

本模組最容易出錯的地方

06 遺失值 (Missing Data)

先問為什麼缺，再決定怎麼補

07 離群值 (Outlier)

找出來之後呢？

08 重複與不一致

看起來一樣但電腦覺得不一樣

09 正規化 (Normalization) 與標準化 (Standardization)

什麼時候需要、什麼時候不用

10 特徵工程 (Feature Engineering)

把領域知識變成欄位

11 資料洩漏 (Data Leakage)

做對每一步卻得到假的好成績

12 實作與練習

Module 1–10 與完整前處理鏈

PART 01

為什麼這段最花時間

Why Data Work Dominates

資料清理、整合與驗證常是專案的主要工時。

這一模組聚焦把原始資料轉成可重現、可建模的資料。

資料品質的六個維度

COMPLETENESS

完整性

- 該有的欄位與紀錄有沒有缺
- 缺失是隨機的還是有系統的？
- 醫療資料常見：檢驗未做 $\neq$ 檢驗正常

ACCURACY

正確性

- 值本身對不對、單位有沒有搞混
- 身高 175 與 1.75 同時出現在一欄
- 輸入錯誤、儀器校正、抄寫誤差

CONSISTENCY

一致性

- 同一件事在不同地方寫法一致嗎
- 「男/M/1」「臺北/台北」並存
- 跨系統整合時最常爆發

TIMELINESS

時效性

- 資料反映的是哪個時間點的狀態
- 用未來資訊預測過去 → 資料洩漏 (Data Leakage)
- 法規、給付標準會逐年更新

VALIDITY

有效性

- 值有沒有落在合理範圍內
- 血壓 0、年齡 999、BMI 0
- 生理上不可能的值幾乎都是遺失

UNIQUENESS

唯一性

- 同一筆資料有沒有重複出現
- 完全重複、鍵值重複、語意重複
- Join 之後筆數暴增通常源於此

檢查順序建議：有效性 → 完整性 → 唯一性 → 一致性 → 正確性 → 時效性。前三項用 Statistics 就能看出大半。


一份「看起來還好」的資料，實際上有幾個問題？

原始資料

ID	性別	年齡	血壓	血糖	就診日
A001	男	45	120	98	2026/03/01
A002	M	52	0	0	2026-03-02
A003	女	999	135	110	03/03/2026
A001	男	45	120	98	2026/03/01
A004	女	38	118		2026/03/04

清理後

ID	性別	年齡	血壓	血糖	就診日
A001	1	45	120	98	2026-03-01
A002	1	52	?	?	2026-03-02
A003	0	?	135	110	2026-03-03
A004	0	38	118	?	2026-03-04



有效性

年齡 999、血壓 0、血糖 0——生理上不可能，應視為遺失而非有效值

一致性

性別欄同時有「男 / M / 女」；日期有三種格式，需統一

唯一性

A001 完全重複出現兩次，需去重

完整性

A004 是空白；A002 的「0」若代表未量測，也應轉為遺失。需先查資料字典，不能只憑數值判斷。

這張表只有五列。真實資料有數萬列時，這些問題不會自己跳出來——你必須主動去找。

三個常被低估的事實

事實	為什麼	對你的意義
建模工具通常不是主要工時	資料存取、定義、清理、整合與驗證通常更花時間；實際比例會因專案而異	W2-W3 兩整週都給資料工程，不是因為它簡單，而是因為它決定上限
模型的上限由資料決定	同樣的演算法，資料定義、標記品質與評估流程不同，結果可能大幅改變	調參前先確認資料與評估流程
資料處理的錯誤最難發現	程式不會報錯，模型照樣訓練完成，指標甚至可能更好看	本模組每一節都會列出「這一步做錯會怎樣」

PART 02

資料存取與匯入

Accessing Data

把資料讀進來聽起來很簡單。

但一半以上的下游問題，其實是在這一步就種下的。

常見資料來源與 AI Studio 的對應

來源	格式	AI Studio Operator	要注意什麼
試算表檔案	CSV、TSV、TXT	Read CSV	分隔符號、編碼、有無標題列
Excel 活頁簿	.xlsx、.xls	Read Excel	選對工作表；合併儲存格會造成空值
資料庫	MySQL、SQL Server 等	Read Database	需先設定連線；建議先在 SQL 端篩選
課程儲存庫	已轉為 .rmhdf5table	Retrieve (直接拖曳)	本課程多數範例採此方式
影像資料夾	JPG、PNG 等	Read Image Meta Data	以資料夾名稱作為標籤 (W9 MNIST 會用)
網頁	HTML	Get Pages / Crawl Web	W11 文字探勘會用到

【原課程範例】 Module 1 - Accessing Data.rmp 資料：Altoona Crime Rates.rmhdf5table

匯入時最常踩的三個坑

1

編碼問題

- ▶ 中文變成亂碼或問號
- ▶ 常見於 Big5 與 UTF-8 混用
- ▶ AI Studio : Read CSV 的 encoding 參數
- ▶ 台灣政府開放資料常為 Big5
- ▶ 徵兆：欄位名稱正常但內容是亂碼
- ▶ 先用純文字編輯器開檔確認

2

型態誤判

- ▶ 日期被讀成文字或數字
- ▶ 有前導零的代碼 (如 007) 被吃掉零
- ▶ 含逗號的數字 (1,234) 被讀成文字
- ▶ 身分證字號、病歷號應為文字非數字
- ▶ 在 Read 的 data set meta data 逐欄確認
- ▶ 匯入後一定接 Statistics 檢查

3

標題與空白列

- ▶ 標題不在第一列 (前面有說明文字)
- ▶ 資料中夾雜小計列或空白列
- ▶ 欄位名稱有前後空白，Join 時對不上
- ▶ Excel 的合併儲存格造成大量空值
- ▶ Read Excel 可指定起始儲存格
- ▶ 匯入後看筆數對不對是最快的檢查

共同的檢查動作：匯入後立刻接一個 Statistics，看「筆數、欄位數、每欄型態、每欄的最小最大值」四件事。三十秒就能擋掉大部分問題。

PART 03

型態與角色

Types and Roles

AI Studio 用「型態」決定能做什麼運算，
用「角色」決定這個欄位在建模中扮演什麼。

AI Studio 的欄位型態

型態	中文	代表什麼	典型欄位
integer	整數	可運算的整數	年齡、住院天數、次數
real	實數	可運算的小數	血壓、BMI、檢驗值
binominal	二元類別	只有兩種值	性別、是否再入院、有無糖尿病
polynominal	多元類別	三種以上的類別	科別、教育程度、CMS 等級
date / date_time	日期時間	可做日期運算	就診日、出生日、通報時間
text	文字	不做類別處理的自由文字	主訴、護理紀錄、備註

常見錯誤：把「CMS 等級 1–8」設成 integer。它是有序類別不是數值——等級 8 不等於等級 4 的兩倍。

角色 Role：這個欄位在建模中做什麼

五種常用角色

- ▶ regular (預設)：一般特徵，會被拿去建模
- ▶ label：目標變數。監督式學習 (Supervised Learning) 一定要設一個
- ▶ id：識別欄位。不參與建模但保留以便追溯
- ▶ weight：樣本權重。處理不平衡時會用到
- ▶ cluster / prediction：由演算法產生的結果欄位
- ▶ Operator：Set Role (單一)、Set Roles (批次)

設錯角色會發生什麼

- ▶ 忘了設 label：模型無法訓練
- ▶ ID 留成 regular：可能學到識別碼的偶然規律
- ▶ 日期不是自動等於洩漏；關鍵是預測時能否取得
- ▶ 預測後日期，或隨機切開時間序列 = 時間洩漏
- ▶ 檢查特徵重要性；ID 類欄位排前是警訊
- ▶ 作業一任務 2 移除 CustomerID，就是這個道理

型態轉換：類別欄位怎麼變成數值

原始（類別）

ID	科別	滿意度
1	內科	高
2	外科	中
3	內科	低
4	急診	高



轉換後（數值）

ID	科別 = 內科	科別 = 外科	科別 = 急診	滿意度
1	1	0	0	3
2	0	1	0	2
3	1	0	0	1
4	0	0	1	3

科別 用 One-Hot

三個類別之間沒有大小關係，展開成三個 0/1 欄位。Operator：Nominal to Numerical (dummy coding)

滿意度 用 Label Encoding

低 < 中 < 高有順序，可編為 1/2/3；但數字也隱含等距，需確認模型能正確解讀。Operator：Map 或 Nominal to Numerical (unique integers)

判斷準則

問自己：這些類別之間有沒有「大小」或「先後」？有就用序數編碼，沒有就用 One-Hot

作業一的思考題就是這個：Gender (男/女) 若用單一 0/1 欄位，或用 One-Hot 並去掉一欄，多數線性模型取得的資訊等價；但無序科別不能用 1/2/3 讓模型誤讀順序。

PART 04

篩選、排序與聚合 (Aggregation)

Filter, Sort, Aggregate

把資料整理成「一列代表一個分析單位」。
在醫療資料裡，這一步通常比想像中麻煩。

三組核心運算子 (Core Operators)

目的	Operator	說明	原課程範例
篩選列	Filter Examples	依條件保留或排除紀錄。 條件語法：欄位 運算子 值	【原課程範例】 Module 2
篩選欄	Select Attributes	保留或排除欄位。 subset / regular expression 兩種模式	【原課程範例】 Module 4
排序	Sort	依單一或多個欄位排序。 常用於檢查極值與時間序列 (Time Series)	【原課程範例】 Module 2
分組聚合	Aggregate	把多列壓成一行。 這是改變「分析單位」的關鍵	【原課程範例】 Module 3
建立欄位	Generate Attributes	以運算式產生新欄位。 特徵工程 (Feature Engineering) 的主力	【原課程範例】 Module 4
重塑	Pivot / De-Pivot	長寬表互轉。 檢驗值紀錄常需要這一步	【原課程範例】 Module 7

Aggregate：改變分析單位

一列 = 一次就診

病歷號	就診日	科別	費用
A001	03/01	內科	800
A001	03/15	內科	650
A001	04/02	復健	1200
A002	03/08	外科	2400
A002	04/20	外科	900



一列 = 一位病人

病歷號	就診次數	總費用	平均費用	科別數
A001	3	2650	883	2
A002	2	3300	1650	1

為什麼要做

建模時「一列 = 一個病人」才對得上「這個病人會不會再入院」這種目標變數

聚合函數

count、sum、average、minimum、maximum、standard deviation、count(distinct)

實務提醒

聚合會遺失細節。建議同時保留多個統計量（總和、平均、最大、次數），讓模型自己挑

【原課程範例】Module 3 - Merging & Grouping.rmp。正確答案可對照同資料夾的 Module 3 - join and aggregate result.rmhd5table

PART 05


合併：Join 的四種類型

Joining Tables

這是本模組最容易出錯、也最容易「錯得無聲無息」的地方。
筆數不對不會報錯，只會讓你後面的分析全部建在錯的資料上。

四種 Join，保留誰

Inner Join



左表

右表

只保留兩邊都有的鍵值
最保守，也最容易悄悄弄丟資料
用途：確定兩邊都必須有資料時
風險：筆數大幅減少而不自知

Left Join




左表

右表

保留左表全部，右表補上
最常用——以主檔為準加掛資訊
用途：病人主檔 + 檢驗結果
右表沒有的地方會變成遺失值 (Missing Data)

Right Join




左表

右表

保留右表全部，左表補上
實務少用，通常改寫成 Left 較好讀
把兩表位置對調即等同 Left
建議統一用 Left，減少閱讀負擔

Outer Join



左表

右表

兩邊全部保留
用途：檢查「哪些只在單邊出現」
資料稽核時很有用
建模前通常不會直接用

AI Studio：Join Operator 的 join type 參數即為這四種。key attributes 要明確指定，不要依賴自動比對。

一對多關係：Join 之後筆數為什麼會變多

左表：3 位病人

病歷號	姓名
A001	王○○
A002	李○○
A003	陳○○



Left Join 後：5 列

病歷號	姓名	檢驗項目	數值
A001	王○○	血糖	98
A001	王○○	血壓	120
A001	王○○	膽固醇	210
A002	李○○	血糖	145
A003	陳○○	(無)	(無)

筆數從 3 變成 5

A001 有三筆檢驗，Join 後被複製成三列。若後續直接 count，會誤以為有 5 位病人

A003 出現空值


Left Join 保留了沒有檢驗紀錄的 A003，右表欄位變成遺失值——這是正常且應保留的資訊

正確做法

若要「一列一病人」，Join 前先對右表 Aggregate；或 Join 後再 Aggregate 回來

這是醫療資料整合最常見的陷阱。病歷號在檢驗檔、用藥檔、診斷檔中幾乎都是一對多。

實例：Join 前後的筆數變化



Inner 少了 258 筆

鍵值對不上——可能有空白、大小寫或型態不一致

Left 多了 180 筆

一對多關係：右表同一鍵值有多筆，左表那列被複製

Outer 最多

兩邊全留，適合稽核「哪些只在單邊出現」

★ 養成習慣

每做一次 Join 就在旁邊接一個 Statistics
。它不會報錯，只會安靜地給你錯的資料

Join 前後的四項檢查

檢查	怎麼做	看到什麼要警覺
1 筆數比對 Row Count	Join 前後各接一個 Statistics，記下 Examples 數	Inner Join 後筆數大減 → 鍵值對不上 Left Join 後筆數變多 → 一對多關係
2 鍵值清理 Key Cleaning	Join 前先對鍵值欄位做 Trim、Transform Cases	前後空白、全形半形、大小寫不一致 都會讓相同的鍵值對不起來
3 鍵值型態一致 Key Type	確認兩邊的鍵值都是同一種型態	一邊是 integer、一邊是 polynomial 可能無法配對或直接報錯；Join 前先統一型態
4 遺失值檢視 Missingness	Join 後看新增欄位的遺失比例	遺失比例極高 → 可能 Join 錯欄位 遺失比例為 0 → 可能該有的沒對上

養成習慣：每做一次 Join，就在旁邊放一個 Statistics。這三十秒能省下之後好幾天的除錯。

PART 06

遺失值

Missing Data

「這欄有 30% 缺失，要刪掉還是補起來？」
這個問題沒有標準答案——要先問「為什麼會缺」。

三種遺失機制：全名與判別方式

縮寫	英文全名	中文	一句話定義	診斷線索（非證明）
MCAR	Missing Completely At Random	完全隨機遺失	缺不缺，與任何變數都無關——純粹是運氣	比較缺失組與非缺失組的其他欄位。有差異表示不支持 MCAR；相近仍不能證明 MCAR
MAR	Missing At Random	隨機遺失	缺不缺，與「其他看得到的欄位」有關，但與該欄自己的值無關	以「是否缺失」為目標檢查與觀測欄位的關聯。可支持 MAR 的合理性，但不能排除 MNAR
MNAR	Missing Not At Random	非隨機遺失	缺不缺，與「那個看不到的值本身」有關	觀測資料無法與 MAR 區分。需用領域知識提出假設，並做敏感度分析

MAR 的英文容易誤導：Missing At Random 其實是「在控制其他變數後才隨機」，不是「完全隨機」。真正的完全隨機是 MCAR。

用同一個欄位看懂三種機制

缺失的原因

情境	骨密度檢查為什麼會缺
A	儀器當機那半天的病人都沒做
B	年輕族群依規定不需常規檢查
C	骨密度極差的人痛到做不完檢查



對應的機制

情境	機制	刪除會怎樣
A	MCAR	樣本數減少
B	MAR	樣本偏向年長者
C	MNAR	把最嚴重的人系統性刪掉

A → MCAR

若儀器當機與病人特徵及時段無關，才與 MCAR 假設一致

B → MAR

缺失與已觀測的年齡有關，與 MAR 假設一致；但仍須檢查其他未觀測因素

C → MNAR

若未觀測的骨密度仍影響缺失，MNAR 才合理；觀測資料本身無法證明

為什麼 C 最危險

刪掉 C 的人，模型會以為「沒有人骨密度那麼差」，低估高風險族群

實務建議：新增 is_missing 指示欄位；把 MCAR / MAR / MNAR 當作待論證的假設，並說明依據、限制與敏感度分析。

三種遺失機制，處理方式完全不同

1

MCAR 完全隨機遺失

- ▶ 缺失與任何變數都無關
- ▶ 例：儀器隨機故障、表單掉頁
- ▶ 刪除不會造成偏誤 (Bias)，只損失樣本數
- ▶ 但真正的 MCAR 在實務上很罕見
- ▶ 檢查：缺失組與非缺失組的其他欄位分布相近
- ▶ 處理：缺失比例低時可直接刪除

2

MAR 隨機遺失

- ▶ 缺失與「其他已觀測欄位」有關
- ▶ 例：年輕族群較少做骨密度檢查
- ▶ 直接刪除會讓樣本偏向年長者
- ▶ 可用其他欄位建模來預測填補
- ▶ 檢查：以缺失與否為目標跑一次分類看得不得出來
- ▶ 處理：多重插補或以模型填補

3

MNAR 非隨機遺失

- ▶ 缺失與「缺失值本身」有關
- ▶ 例：病情輕的人根本不做這項檢查
- ▶ 最麻煩——資料本身無法自證
- ▶ 刪除或填補都會造成系統性偏誤 (Bias)
- ▶ 「有沒有做這項檢查」本身就是特徵
- ▶ 處理：新增遺失指示欄位，並在報告中說明限制

醫療資料以 MAR 與 MNAR 居多。這也是為什麼「新增一個 is_missing 欄位」在醫療場域往往比單純填補更有價值。

醫療資料的遺失值 (Missing Data) 常常偽裝成 0

原始 (0 = 未量測)

ID	懷孕次數	血糖	血壓	皮脂厚度	胰島素	BMI
1	6	148	72	35	0	33.6
2	1	85	66	29	0	26.6
3	8	183	64	0	0	23.3
4	1	89	66	23	94	28.1
5	0	137	40	35	168	43.1

轉為遺失值 (Missing Data) 後

ID	懷孕次數	血糖	血壓	皮脂厚度	胰島素	BMI
1	6	148	72	35	?	33.6
2	1	85	66	29	?	26.6
3	8	183	64	?	?	23.3
4	1	89	66	23	94	28.1
5	0	137	40	35	168	43.1

為什麼不能留著 0

懷孕次數 0 是有效值，但血糖 0、血壓 0、BMI 0 生理上不可能。留著會讓模型學到錯誤訊號

怎麼找出來


接 Statistics 看每個數值欄位的最小值，逐欄問「這個值在生理上可能嗎」

AI Studio 作法

Replace (把 0 換成 missing) → Replace Missing Values 或 Impute Missing Values 填補

這是 Pima Indians Diabetes 資料集，也是期末作業二的指定資料。作業任務 1 要求你算出各欄位的 0 值比例並做成表格。

實例：遺失值模式圖——一眼看出「為什麼缺」



紅色 = 缺失

每一列是一位病人、每一欄是一個欄位。
整張圖三秒鐘看完資料品質

胰島素那欄

缺了近一半。這種欄位要先決定：整欄捨棄，還是保留並標記？

糖化血色素的規律

上半（65 歲以上）幾乎都有，下半大量缺——缺失與已觀測年齡有關，與 MAR 假設一致，但不是證明

為什麼重要


若直接刪除有缺失的列，剩下的資料會嚴重偏向年長者

六種處理策略與適用時機

策略	做法	適合	不適合
整列刪除 Listwise Deletion	有缺失就刪掉整列	MCAR 且缺失比例 < 5%	缺失有系統性時會造成偏誤
整欄刪除 Column Deletion	缺失比例過高的欄位整欄移除	缺失 > 50% 且該欄不關鍵	該欄是重要預測因子時
常數填補 Constant Imputation	以 0 或特定值填補	有明確語意 (如「未申報 = 0」)	一般數值欄位，會扭曲分布
平均 / 中位數填補 Mean/Median Imputation	以平均數或中位數填補	分布接近常態用平均， 偏態用中位數	缺失比例高時會低估變異 (Variance)
模型填補 Model-based Imputation	用其他欄位預測缺失值	MAR、缺失比例中等	可能引入循環依賴，需謹慎
遺失指示欄位 Missingness Indicator	保留缺失，另加 is_missing 欄	MNAR，缺失本身有意義	欄位數量會膨脹

【原課程範例】 Module 8 - Handling Missing Values.rmp 與 4. Case Studies/6. SumUp/2 Handling Missing values.rmp

實例：三種填補方式對分布的實際影響



① 刪除

樣本數從 600 掉到約 330。若缺失非隨機，剩下的樣本已經偏了

② 平均數填補

中間長出一根不存在的尖峰——把大量個案灌到同一個值

③ 中位數填補

尖峰位置較貼近多數人所在的位置，偏態資料的較佳選擇

怎麼選

先看分布、平均與中位數差異，再比較模型敏感度。中位數是偏態資料常見基準，但不是自動最佳答案

填補 (Imputation) 時最容易犯的三個錯

錯誤一：先填補再切分資料

- ▶ 用整份資料算出的平均值去填補，等於把測試集的資訊帶進了訓練過程
- ▶ 正確作法：先切分，用訓練集的統計量填補訓練集與測試集
- ▶ AI Studio：把 Replace Missing Values 放進 Cross Validation 的訓練子流程內

錯誤二：偏態分布用平均數填補

- ▶ 胰島素、醫療費用這類欄位通常右偏，少數極大值會把平均拉高
- ▶ 用平均填補會讓大量原本偏低的個案被灌成中高值
- ▶ 判斷方式：看 Statistics 的平均與中位數差多少；差很多就用中位數

錯誤三：填補後不留紀錄

- ▶ 填補是一個「你替資料做的決定」，必須可追溯
- ▶ 建議同時新增 is_missing 指示欄位，讓模型與你都知道哪些值是補的
- ▶ 報告中要寫清楚：哪些欄位補了、補多少比例、用什麼方法、為什麼

PART 07

離群值

Outliers

商業資料的預設是「找出來處理掉」。


醫療資料的預設應該是「找出來看清楚」——極端值往往正是你要找的人。

四種離群值偵測方法 (Outlier Detection)

方法	判斷依據	門檻	限制
標準分數法 Z-Score	偏離平均幾個標準差	通常 $ z > 3$	假設接近常態； 離群值 (Outlier) 本身會拉高標準差
四分位距法 (IQR)	是否落在 $Q1 - 1.5 \times IQR \sim Q3 + 1.5 \times IQR$ 之外	1.5 倍 (保守用 3 倍)	對偏態分布較穩健； 盒鬚圖即依此繪製
距離法 k-NN (k-Nearest Neighbors)	第 k 個最近鄰居有多遠	依 k 值與資料密度	必須先正規化 (Normalization) ； 維度高時效果下降
密度法 LOF (Local Outlier Factor)	周圍密度與鄰居相比稀疏多少	LOF 值明顯 > 1	資料有多個密度不同群體時較佳； 計算成本較高

【原課程範例】 Module 6 - Normalization & Detecting Outliers.rmp 。距離法與密度法在 W7 的異常偵測會深入。

實例：找離群值的三種視角



① 直方圖

看得到右側孤立的幾個點，但看不出確切是哪幾筆

② 盒鬚圖

超過 $Q3 + 1.5 \times IQR$ 的點自動被畫出來。對偏態資料較穩健

③ 標準差法

$|z| > 3$ 標紅。注意：離群值 (Outlier) 本身會拉高標準差，讓門檻變寬

醫療場域的下一步

找到之後先問「生理上可能嗎」。血壓 138 是真實極端值，血壓 0 是遺失

找到離群值之後，四個選項

可以怎麼做

- ▶ 保留：確認是真實的極端個案，直接留下
- ▶ 標記：新增 `is_outlier` 欄位，保留但可追蹤
- ▶ 修正：確認是輸入錯誤（如身高 1.75 應為 175）後更正
- ▶ 封頂：以 99 百分位取代極端值（winsorizing）
- ▶ 移除：確認是無效資料且無法修正時才刪除
- ▶ AI Studio：Detect Outlier 系列會新增 outlier 欄位供你決定

醫療場域的判斷順序

- ▶ 先問：這個值在生理上可能嗎？不可能 → 視為遺失
- ▶ 再問：可能但罕見嗎？→ 這可能就是重症個案，應保留
- ▶ 移除離群值（Outlier）等於把最需要被辨識的族群從訓練資料刪掉
- ▶ 若模型的用途是「找出高風險者」，刪掉極端值會直接毀掉目標
- ▶ 建議預設：標記而非刪除，並在建模後單獨檢視這群人的預測結果
- ▶ 報告中務必說明你的處理方式與理由

W7 的異常偵測（Anomaly Detection）會回到這個主題——當「找出異常」本身就是目標時，這些極端值就是你的正樣本。

PART 08

重複與不一致

Duplicates & Inconsistency

「看起來一樣」跟「電腦覺得一樣」是兩件事。
這一節處理的就是這個落差。

文字不一致 (Text Inconsistency) 的五種寫法

原始

ID	縣市	科別	性別
1	台北市	內科	男
2	臺北市	內科	M
3	台北市	內 科	男
4	TAIPEI	內科	1
5	新北市	外科	女



標準化後

ID	縣市	科別	性別
1	臺北市	內科	M
2	臺北市	內科	M
3	臺北市	內科	M
4	臺北市	內科	M
5	新北市	外科	F

前後空白

「內科」與「內科」是不同的值。Operator : Trim

全形半形與異體字

台/臺、英文大小寫。Operator : Replace (可用正規表示式) 、Transform Cases

同義不同碼


男/M/1 需先建立對照表統一。Operator : Map 或 Replace Dictionary

為什麼重要

不統一的話，原本 1 個類別會被當成 4 個，分群 (Clustering) 與 One-Hot 編碼全部走樣

檢查方式：對每個類別欄位接一個 Statistics，看 unique values 的數量與清單。數量比你預期的多，就是有不一致。

相關矩陣 (Correlation Matrix) 抓共線性



看粗體的格子

收縮壓×舒張壓、體重×身高—— $|r| > 0.8$ ，是共線性 (Collinearity) 的候選

為什麼要抓

兩者同時放進迴歸，模型無法分辨效果歸誰，係數 (Coefficient) 會不穩甚至正負翻轉

三種處理

移除其一、合成新變數 (如 BMI、脈壓)、或改用 Ridge 正則化 (Regularization)

預測 vs 解釋

只做預測時共線性 (Collinearity) 影響有限；要回答「哪個因素重要」就必須處理

相關係數 r (Correlation Coefficient) 怎麼算

離差乘積表

病人	收縮壓 x	舒張壓 y	$x-\bar{x}$	$y-\bar{y}$	$(x-\bar{x})(y-\bar{y})$	$(x-\bar{x})^2$	$(y-\bar{y})^2$
P1	120	78	-9.83	-5.83	57.36	96.69	34.03
P2	132	85	2.17	1.17	2.53	4.69	1.36
P3	118	74	-11.83	-9.83	116.36	140.03	96.69
P4	145	94	15.17	10.17	154.19	230.03	103.36
P5	138	90	8.17	6.17	50.36	66.69	38.03
P6	126	82	-3.83	-1.83	7.03	14.69	3.36
合計	$\bar{x}=129.83$	$\bar{y}=83.83$			387.83	552.83	276.83



計算過程

步	計算
公式	$r = \frac{\sum(x-\bar{x})(y-\bar{y})}{\sqrt{(\sum(x-\bar{x})^2 \times \sum(y-\bar{y})^2)}}$
分	387.83
分母	$\sqrt{(552.83 \times 276.83)} = \sqrt{153,043} = 391.21$
r	$387.83 \div 391.21 = 0.9914$
r	0.99 → 遠超過 0.8 的警戒線
結論	收縮壓與舒張壓高度共線，迴歸不宜同時放入

分子在說什麼

x 與 y 是否「一起偏離各自的平均」。同方向偏離 → 正值累積 → r 為正

分母在做什麼

把單位標準化掉。所以 r 沒有單位，永遠落在 -1 到 +1 之間

|r| 是絕對值

去掉正負號只看「強度」。r=-0.88 與 r=+0.88 的關聯強度相同，只是方向相反


AI Studio

Correlation Matrix Operator 一次算出所有欄位兩兩的 r，不必手算

這是 Pearson 相關係數 (Pearson Correlation Coefficient)，衡量的是「線性」關係。彎曲的關係即使很強，r 也可能接近 0。

$|r|$ 怎麼讀：八種強度的實際長相

相關係數 r 長什麼樣：紅框 = $|r| \geq 0.8$ (共線性警戒區)



$|r|$ 的意義

絕對值只看強度、不看方向。 $r = +0.89$ 與 $r = -0.89$ 的關聯一樣強

紅框 = 警戒區

$|r| \geq 0.8$ 。兩個變數提供的資訊高度重疊，同時放進迴歸會出問題

r^2 更好懂

只在單一預測變數的線性迴歸裡， r^2 可解讀為 R^2 ；它不是因果，也不是所有模型的通則

只抓線性關係

若關係是 U 型， r 可能接近 0，但兩者其實高度相關——所以要搭配散布圖看

|r| 的判讀標準與處理

r 範圍	強度	r^2 (共享變異)	在共線性上的意義	建議處理
0.9 – 1.0	極強	81% – 100%	幾乎是同一個變數的兩種寫法	先查資料定義與 VIF，再決定移除、合成或正則化
0.8 – 0.9	強	64% – 81%	共線性警戒區	移除、合成或 Ridge
0.7 – 0.8	中強	49% – 64%	需留意，視樣本數而定	可保留但檢查 VIF
0.4 – 0.7	中等	16% – 49%	一般可接受	通常不必處理
0.0 – 0.4	弱	0% – 16%	無共線性疑慮	不必處理

兩兩相關只是初篩，無法看出三個以上變數的線性依賴。VIF > 4 值得調查、> 10 通常視為嚴重；門檻仍須依樣本、任務與可解釋性判斷。

三種重複，處理方式不同

型態	定義	怎麼找	怎麼處理
完全重複 (Exact Duplicate)	所有欄位都一樣	Remove Duplicates (不指定欄位)	直接去重，通常無爭議
鍵值重複 (Key Duplicate)	主鍵重複但其他欄位不同	以主鍵 Aggregate 後看 count > 1	要判斷：是資料錯誤，還是本來就一對多？
語意重複 (Semantic Duplicate)	不同紀錄其實指同一個對象	姓名+生日+性別 組合比對	需要模糊比對； 醫療場域常見於跨院整合

鍵值重複最危險：它常常不是錯誤，而是你誤解了資料的粒度。先確認「一系列到底代表什麼」再決定。

正規化與標準化 (Standardization)

Scaling


不是每個模型都需要縮放。

但需要的時候不做，結果會完全被值域最大的欄位主導。

兩種縮放方式

比較項目	正規化 Min-Max	標準化 (Standardization) Z-Score
計算方式	$(x - \min) / (\max - \min)$	$(x - \text{平均}) / \text{標準差}$
結果範圍	固定落在 0 到 1 之間	平均為 0、標準差為 1，無固定範圍
對離群值	敏感——一個極端值會壓縮其他所有值	較穩健，但仍受影響
保留什麼	保留原始分布的形狀	平均為 0、標準差為 1； 不會把偏態分布變成常態
何時用	需要固定範圍時（如影像像素、 神經網路輸入層）	一般情況的預設選擇； 距離型演算法最常用
AI Studio	Normalize method = range transformation	Normalize method = Z-transformation

實例：不正規化時，年齡等於不存在



左・原始尺度

把兩軸畫成同一刻度後才看得清楚：年齡的變化幅度被收入完全壓扁

距離怎麼算的

歐氏距離把兩軸的差平方相加。收入差 50、年齡差 5 → 收入貢獻是年齡的 100 倍


右・Z-Score 後

兩個特徵都變成「離平均幾個標準差」，等權參與距離計算

影響誰

k-NN、K-Means、PCA、SVM 受尺度影響；神經網路與含正則化的線性模型通常也受益於縮放

實例：正規化如何改變分群結果



左・真實結構

刻意造出三群：中低收入年輕、中低收入年長、高收入中年

中・未正規化 (純度 77%)

切線全是垂直的——只依收入分，年齡完全沒有作用

右・Z-Score 後 (98%)

兩個維度等權，三個真實群組被還原

★ 作業一任務 4

就是要你在 Mall Customer 資料上親手跑出這組對照

哪些演算法需要縮放

應用場景	需要縮放	不需要	本課週次
k-NN (k-Nearest Neighbors)	●		W5
K-Means (K-Means Clustering)	●		W6
PCA (Principal Component Analysis)	●		W6
SVM (Support Vector Machine)	●		W5
神經網路 / 深度學習 (NN / DL)	●		W8
線性 / 邏輯迴歸 (Linear / Logistic)	●		W4
Decision Tree (決策樹)		●	W5
隨機森林 / 梯度提升 (RF / GB)		●	W7
Naive Bayes (樸素貝氏)		●	W5

- 適用 判準：演算法有沒有用到「距離」或「權重大小」？有就需要縮放。樹模型只比大小不比距離，所以不需要。

縮放的鐵則：參數只能從訓練集計算

為什麼

- ▶ 縮放需要平均、標準差、最大最小值——這些都是「從資料算出來的統計量」
- ▶ 若用整份資料計算，測試集的分布資訊就滲進了訓練過程，這是典型的資料洩漏 (Data Leakage)
- ▶ 後果：測試集分數虛高，實際部署時表現大幅下滑

AI Studio 的正確作法

- ▶ 錯誤：Retrieve → Normalize → Split Data → 訓練與測試
- ▶ 正確：Retrieve → Split Data → 訓練集 Normalize (保留模型) → 以同一組參數套用到測試集
- ▶ 更好：把 Normalize 整個放進 Cross Validation 的訓練子流程內，讓每一折各自計算

怎麼檢查自己有沒有犯錯

- ▶ 看流程圖：Normalize 出現在 Split Data 或 Cross Validation 之前，就是錯的
- ▶ Normalize Operator 有一個 preprocessing model 輸出——它就是給測試集用的
- ▶ 作業一與作業二都會檢查這一點

PART 10

特徵工程

Feature Engineering

這是你們最有優勢的一節。

因為好的特徵來自領域知識，不是來自演算法。

六種常見手法

ARITHMETIC

算術衍生

- 由既有欄位計算出新欄位
- BMI = 體重 / 身高²、脈壓 = 收縮壓 - 舒張壓
- Operator : Generate Attributes

BINNING

分箱

- 連續值切成區間，變成有序類別
- 年齡 → 青年/中年/長者；BMI → 過重/肥胖
- Operator : Discretize by Bins / by User Specification

ENCODING

類別編碼

- 無序類別用 One-Hot；有序類別可用序數編碼，但要留意等距假設
- 高基數可用頻率或目標編碼；目標編碼需在訓練折內估計，避免洩漏
- Operator : Nominal to Numerical

TRANSFORM

數值轉換

- 對數轉換修正右偏（費用、住院天數常見）
- 平方根、Box-Cox 等
- Operator : Generate Attributes 用 log() / sqrt()

DATETIME

時間特徵

- 由日期展開：星期幾、月份、是否假日
- 計算間隔：距上次就診幾天、年齡
- Operator : Date to Numerical / Generate Attributes


AGGREGATION

聚合特徵

- 由歷史紀錄統計：近一年就診次數、平均費用
- 最能帶入領域知識的一類
- Operator : Aggregate 後 Join 回主檔

【原課程範例】 Module 4 - Creating & Removing Columns.rmp ; 4. Case Studies/6. SumUp/4 與 5 (特徵工程與格式轉換)

實例：用臨床切點分箱



左・連續值 + 切點

紅色虛線是國健署成人體位標準的切點，不是等距也不是等頻

為什麼不用等距

BMI 23.9 與 24.1 數值幾乎一樣，但跨越了「過重」的臨床界線

右・分箱後

五個有臨床意義的級距，可直接對應衛教建議

代價與折衷

會損失組內細節。建議原始數值與分箱 (Binning) 欄位同時保留，讓模型自己選

分箱（Binning）：把連續值變成有臨床意義的類別

原始連續值

ID	BMI
1	17.8
2	21.5
3	25.3
4	28.9
5	32.4



分箱後

ID	BMI	體位分類	是否過重
1	17.8	過輕	0
2	21.5	正常	0
3	25.3	過重	1
4	28.9	輕度肥胖	1
5	32.4	中度肥胖	1

為什麼要分箱（Binning）

BMI 23.9 與 24.1 在數值上幾乎一樣，但在臺灣成人體位標準下跨越了「過重」界線

切點從哪來

用領域標準而不是等距或等頻。本例依國健署成人體位標準（教材：成人健康體位手冊.pdf）

代價

會損失組內的細節資訊。建議同時保留原始數值與分箱欄位，讓模型自己選

這一頁是「領域知識轉成特徵」最典型的例子。演算法不知道 24 與 25 之間有一條線，但你知道。

PART 11

資料洩漏

Data Leakage

每一步都做對了，指標卻好得不合理。

先檢查資料洩漏——它不會報錯，卻會讓驗證分數過度樂觀。

五種常見的洩漏來源

洩漏型態	長什麼樣	怎麼發現
前處理洩漏 Preprocessing Leakage	縮放、填補、特徵選擇 (Feature Selection) 在切分之前做，用到了全部資料的統計量	看流程圖：這些步驟有沒有在 Split Data 之前
時間洩漏 Temporal Leakage	用了預測時間點之後才會知道的資訊	逐欄問：預測當下真的拿得到這個欄位嗎？
目標洩漏 Target Leakage	某個特徵其實是由目標變數推導出來的	特徵重要性 (Feature Importance) 排序中，某一欄異常突出
重複樣本洩漏 Duplicate Leakage	同一個對象同時出現在訓練集與測試集	以病人 ID 檢查兩集合有無交集
過取樣洩漏 Oversampling Leakage	SMOTE 等取樣在切分之前做，合成樣本進了測試集	取樣 Operator 有沒有在切分之後

實例：時間洩漏的判斷方法

時間洩漏：逐欄問「預測那一刻，這個欄位拿得到嗎」

預測發生的時點
(出院當天)



✓ 可以用：預測當下已經存在

☒ 不能用：預測時還不存在
= 時間洩漏

紅色直線

預測發生的那一刻。這條線是你判斷每個欄位能不能用的唯一依據

綠色欄位

入院檢驗、住院用藥、出院前評估——預測當下都已經存在，可以用

紅色欄位

出院後門診次數、30 天內急診紀錄——預測時還沒發生，用了就是洩漏

怎麼檢查

把每個欄位問一次：「預測那一刻，我真的拿得到這個值嗎？」

同一件事，錯的順序與對的順序

	錯誤 (會產生虛高的分數)		正確
前處理 Preprocessing	Retrieve → Normalize → Impute → Split Data → 建模	→	Retrieve → Split Data → 訓練集 Normalize / Impute → 以同組參數套用測試集
不平衡處理 Class Imbalance	Retrieve → SMOTE 過取樣 (Oversampling) → Split Data → 建模	→	Retrieve → Split Data → 僅對訓練集 SMOTE → 測試集維持原始分布
特徵選擇 Feature Selection	以全部資料算相關係數 (Coefficient) 挑欄位 → Split Data → 建模	→	Split Data → 僅用訓練集 挑選欄位 → 同一組欄位 套用到測試集
時間序列 Time Series	隨機 shuffle 切分 (等於用未來預測過去)	→	依時間切分： 前段訓練、後段測試 或用 Forward Chaining

最省事的統一解法：把所有前處理步驟包進 Cross Validation 的訓練子流程內。AI Studio 支援這種寫法，W5 會示範。

三個「好到不合理」的警訊

分數遠高於合理基準或既有研究

- ▶ 沒有通用的 0.98 警戒線；門檻取決於任務、盛行率、資料與評估設計
- ▶ 當結果遠超過基準或外部研究，先稽核五種洩漏來源
- ▶ 容易的任務確實可能高分；重點是驗證資料是否獨立且符合部署情境

某一個特徵的重要性遠高於其他所有特徵

- ▶ 單一特徵主導可能合理，也可能是目標替身或時間洩漏
- ▶ 先檢查欄位語意、取得時點與計算來源，再做跨折的重要性比較
- ▶ 拿掉重跑是敏感度檢查；指標下降本身不能證明洩漏

訓練集與測試集的分數幾乎一樣好

- ▶ 訓練與測試分數接近不一定有問題；大樣本或簡單模型也可能如此
- ▶ 應檢查個案與時間是否重疊、是否有重複樣本，以及切分是否符合部署情境
- ▶ 同時看多折變異與外部驗證，比只看一次切分更可靠

這一頁請在每次做完模型後拿出來對一遍。Task 1 與兩份作業的評分都會檢查你有沒有處理這件事。

PART 12

實作與練習

Hands-On

第 2 週做 Module 1–5，第 3 週做 Module 6–10。
課後再把完整前處理鏈跑一次。

第 2 週實作 | 資料存取、整理與合併

【原課程範例】 Module 1-5

開啟檔案

範例/ML (AI Studio)/M1. 資料工程/

- | Module 1- Accessing Data.rmp
- | Module 2- Filtering & Sorting.rmp
- | Module 3- Merging & Grouping.rmp
- | Module 4- Creating & Removing Columns.rmp
- | Module 5- Changing Types & Roles.rmp

資料/ML (AI Studio)/M1. 資料工程/

- | Altoona Crime Rates.rmhdf5table
- | Lab 1 Data Altoona Crime Rates.rmhdf5table
- | Module 3 - join and aggregate
result.rmhdf5table ← 正確答案

預期結果

- ▶ Inner Join 的輸出筆數通常最少
- ▶ Left Join 遇到一對多關係時筆數會超過左表
- ▶ 鍵值有空白或大小寫不一致時，Join 會安靜地對不上
- ▶ Module 5 完成後，Statistics 中應可看到 label 與 id 的角色標示

操作步驟

- 1 Module 1：匯入後立刻接 Statistics，檢查筆數、欄位數、每欄型態與極值
- 2 Module 2：練習 Filter Examples 的條件語法，注意文字要不要加引號
- 3 Module 3：★ 本週核心。在 Join 前後各接一個 Statistics，記錄筆數
- 4 把 join type 依序改成 inner / left / right / outer，各記錄一次輸出筆數
- 5 填寫講義附的 Join 比較表，並回答：哪一種讓筆數變多？為什麼？
- 6 Module 4：用 Generate Attributes 建立一個衍生欄位（例如每千人犯罪率）
- 7 Module 5：把目標欄位設為 label，把識別欄位設為 id
- 8 與 Module 3 - join and aggregate result 對照，確認你的結果一致

第 3 週實作 | 品質、EDA 與特徵工程 (Feature Engineering)

【原課程範例】 Module 6-10、6. SumUp 完整前處理鏈

開啟檔案

範例/ML (AI Studio)/M1. 資料工程/

- └ Module 6- Normalization & Outliers.rmp
- └ Module 7- Pivoting.rmp
- └ Module 8- Handling Missing Values.rmp
- └ Module 9- Macros, Sampling & Subprocess.rmp
- └ Module 10- Looping & Branching.rmp

資料/ML (AI Studio)/M1. 資料工程/

- └ Data Altoona Crime Rates with
missing.rmhd5table ← 刻意含遺失值

預期結果

- ▶ 平均填補會把分布往中間擠，變異數下降
- ▶ 偏態欄位用平均與中位數，結果差異明顯
- ▶ 改變 k 會改變離群排序；實際標記筆數由 number of outliers (n) 決定
- ▶ 未正規化時，值域最大的欄位會主導距離計算

操作步驟

- 1 Module 8：先接 Statistics，記下每欄的 Missing 數量與最小值
- 2 分別用「整列刪除」「平均填補」「中位數填補」跑三次，比較統計量變化
- 3 觀察：偏態欄位用平均填補後，分布形狀改變了多少？
- 4 Module 6：Normalize 試 Z-transformation 與 range transformation 各一次
- 5 同一流程加入 Detect Outlier (Distances)，k 值試 5 / 10 / 20 記錄標記筆數
- 6 把被標記的點畫成散布圖，用顏色區分，肉眼確認是否合理
- 7 Module 7、9、10 列為自學：樞紐 (Pivot) 重塑、巨集與抽樣、迴圈與分支
- 8 延伸：跑一次 6. SumUp 的完整前處理鏈 (1→7 共七個流程)

本模組用到的原課程教材對照

主題	原課程檔案	位置
資料存取、篩選、合併、欄位、型態角色	RapidMiner Module 1 ~ Module 5 (共 5 個 .rmp)	2. Data Science Tools/
正規化、離群值、樞紐 (Pivot)、遺失值、巨集、迴圈	RapidMiner Module 6 ~ Module 10 (共 5 個 .rmp)	2. Data Science Tools/
練習資料 (含刻意製造的遺失值與待合併的附加檔)	Altoona Crime Rates、Lab 1 Data、Data ... with missing、Data ... add on	2. Data Science Tools/
Join 與聚合 (Aggregation) 的正確答案	Module 3 - join and aggregate result.rm hdf5table	2. Data Science Tools/
完整前處理鏈 (統計→遺失值→單變量→特徵工程→不平衡→存檔)	6. SumUp - A complete hands-on Practice 流程 1 ~ 7 (共 7 個 .rmp)	4. Case Studies/
資料品質檢查的實例說明	資料品質檢查.docx	4. Case Studies/4.2 Car Sales/
概念詳解 (英文自學包)	ML 3.1 Data Science - Data Prep & EDA.pptx 第 60–93、109–127、138–158 頁	課程根目錄

範例檔已複製到「範例/ML (AI Studio)/M1. 資料工程/」，資料檔在「資料/ML (AI Studio)/M1. 資料工程/」，可直接使用；AI Studio Repository 內的原始位置保留不動。

課後思考題

Q
1

你的貫穿主線資料裡，有沒有「偽裝成有效值」的遺失？怎麼找出來？

提示：接 Statistics 看每個數值欄位的最小值，逐欄問這個值在你的領域裡可能嗎。

Q
2

如果一個欄位有 40% 缺失，但它是你認為最重要的預測因子，你會怎麼做？

提示：先判斷遺失機制。若是 MNAR，「有沒有這筆資料」本身可能就是一個有用的特徵。

Q
3

為什麼決策樹 (Decision Tree) 不需要正規化，但 k-NN 需要？

提示：想想這兩個演算法各自「怎麼比較兩筆資料」——一個比大小，一個算距離。

Q
4

你的專題如果要做「預測」，哪些欄位是預測當下其實拿不到的？

提示：把時間軸畫出來，標出預測發生的時間點，然後逐欄檢查取得時間。

PART 13

Take-Home Assignment

帶回家作業 (資料工程篇)

主題：把一份髒資料整理成可建模的狀態

第 4 週上課前繳交 | 佔學期成績 10% (併入 Task 2)

作業規格

項目	要求
主題	選一份「有品質問題」的公開資料集，完成從原始資料到可建模狀態的完整前處理。 建議：Pima Indians Diabetes（偽裝成 0 的遺失值）、Telco Customer Churn（混合型態）、UCI Heart Disease（多種缺失），或你自己貫穿主線的資料（須為公開或模擬資料）。
工具	Altair AI Studio。流程需可正常執行並繳交 .rmp 檔。
形式	個人作業。PDF 報告（含截圖）+ .rmp 流程檔，壓縮為一個檔案上傳。
篇幅	報告本文 5–8 頁（不含截圖附錄）。
期限	第 4 週上課前上傳至學校 iClass。逾期一週內以八折計分。

七個必做任務

任務	要求	對應章節
1 資料品質健檢 Data Quality Audit	以 Statistics 檢視全部欄位，做出一張品質檢查表： 筆數、欄位數、每欄型態、遺失比例、最小/最大值。 標出「生理上不可能」的值。	PART 1–2
2 遺失值機制判別 Missingness Assessment	至少挑三個有缺失的欄位，提出 MCAR / MAR / MNAR 的合理假設， 列出觀測線索、領域依據與無法驗證之處；不得把分類寫成已被資料證明。	PART 6
3 遺失值處理與比較 Missing Data Treatment	同一欄位分別做「刪除」「平均填補」「中位數填補」， 比較前後的平均、標準差與分布圖，說明最終選擇的理由。	PART 6
4 離群值檢查 Outlier Detection	以直方圖、盒鬚圖、標準差法三種方式檢查至少兩個數值欄位。 說明你選擇「保留 / 標記 / 修正 / 移除」的理由。	PART 7
5 共線性檢查 Multicollinearity Check	產生 Correlation Matrix，找出 $ r $ 最高的一組欄位並報告其 r 值。 說明你會如何處理（或為何不處理）。	PART 9
6 特徵工程 Feature Engineering	建立三個新特徵：算術衍生、分箱（須用領域切點）、類別編碼各一。 說明每個特徵的領域理由。	PART 10
7 防洩漏檢核 Leakage Audit	畫出你的流程圖，標示切分點在哪。 逐項檢查五種洩漏來源，說明你如何避免。	PART 11

四個必答思考題（寫入報告）

Q
1

你的資料裡，哪些遺失是「偽裝成有效值」的？你怎麼發現它們？

提示：看 Statistics 的最小值，逐欄問「這個值在這個領域裡可能嗎」。列出你檢查過的欄位清單。

Q
2

你選擇的填補方式，會讓哪些統計量失真？失真多少？

提示：比較填補前後的平均、標準差、四分位數。用數字說明，不要只寫「影響不大」。

Q
3

如果這份資料要用來做「預測」，哪些欄位是預測當下拿不到的？

提示：把時間軸畫出來，標出預測發生的時點，逐欄檢查取得時間。

Q
4

你做的所有前處理決策中，哪一個最可能被別人質疑？你的理由是什麼？

提示：誠實面對爭議點比迴避有價值。這一題不會因為「有爭議」而扣分，只會因為「說不出理由」而扣分。

評分標準（共 100 分）

向度	配分	評分重點
資料品質健檢的完整性	20	是否逐欄檢查；是否找出偽裝的遺失值；表格是否可讀
遺失值處理的正確性	20	機制判別有依據；填補方式與分布特性相符；有量化前後差異
離群值與共線性	15	三種偵測方式都做；r 值正確；處理決策有理由
特徵工程的領域性	15	三個新特徵；分箱用領域切點而非等距；每個都說得出臨床或業務理由
防洩漏檢核	15	流程圖標出切分點；五種洩漏逐項檢查；前處理在正確位置
報告品質	15	結構清楚；圖表可讀；.rmp 可執行；誠實說明限制與爭議點

加分項（至多 +10）：完整跑一次 6. SumUp 的七步前處理鏈並比較與你自建流程的差異；或以 M1 學到的方法整理你貫穿主線的真實資料集。

繳交前的自我檢查

方法面

- ▶ 會從資料估計參數的前處理，是否都在切分後或交叉驗證的訓練子流程內？
- ▶ 縮放與填補的參數，是否只從訓練集計算？
- ▶ Join 前後是否比對過筆數？

報告面

- ▶ 每一個處理決策，是否都寫了「為什麼」而不只是「做了什麼」？
- ▶ 數字是否都有單位與樣本數？圖表是否有標題與軸標籤？
- ▶ 限制與爭議點是否誠實寫出來？

檔案面

- ▶ .rmp 關閉再重新開啟一次，確認沒有斷開的連線或找不到的資料來源
- ▶ 資料若非公開資料集，是否已確認為模擬或去識別化資料？
- ▶ 檔名格式：學號_姓名_M1作業.zip

中英術語對照 | M1

(1 / 3)

中文	English	一句話說明
資料工程	Data Engineering	讓資料可用、可信、可取得
探索性資料分析	Exploratory Data Analysis, EDA	建模前先理解資料的分布與關係
資料品質	Data Quality	完整性、正確性、一致性、時效性、有效性、唯一性
遺失值	Missing Data	該有值卻沒有；醫療資料常偽裝成 0
完全隨機遺失	Missing Completely At Random, MCAR	缺失與任何變數無關
隨機遺失	Missing At Random, MAR	缺失與其他已觀測變數有關
非隨機遺失	Missing Not At Random, MNAR	缺失與缺失值本身有關 (最麻煩)
填補	Imputation	以平均、中位數或模型預測補上缺失值
離群值	Outlier	明顯偏離其他資料的觀測值

中英術語對照 | M1

(2 / 3)

中文	English	一句話說明
四分位距	Interquartile Range, IQR	Q3–Q1；盒鬚圖判定離群的依據
正規化	Normalization / Min-Max Scaling	壓縮到 0–1 區間
標準化	Standardization / Z-Score	轉為平均 0、標準差 1
特徵工程	Feature Engineering	把領域知識變成模型看得懂的欄位
分箱	Binning / Discretization	連續值切成有意義的區間
虛擬變數	Dummy Variable / One-Hot Encoding	類別展開成 0/1 欄位
序數編碼	Ordinal Encoding	有序類別編成 1/2/3 保留次序
目標編碼	Target Encoding	以各類別的陽性率取代類別（洩漏風險高）
聚合	Aggregation	把多列壓成一列，改變分析單位

中英術語對照 | M1

(3 / 3)

中文	English	一句話說明
樞紐 / 重塑	Pivot / Reshape	長寬表互轉
合併	Join / Merge	依鍵值把兩張表接起來
內部合併	Inner Join	只保留兩邊都有的鍵值
左合併	Left Join	保留左表全部，右表補上
外部合併	Outer Join	兩邊全部保留
一對多	One-to-Many	右表同鍵值多筆，造成 Join 後筆數增加
資料洩漏	Data Leakage	訓練時用到預測當下拿不到的資訊
共線性	Collinearity / Multicollinearity	自變數之間高度相關
變異數膨脹因子	Variance Inflation Factor, VIF	共線性的量化指標；>4 值得調查，>10 通常視為嚴重

本模組重點回顧

- 1 資料品質六個維度：有效性、完整性、唯一性最容易用 Statistics 快速檢查。
- 2 Join 前後一定要比對筆數。一對多關係會讓筆數暴增而不報錯。
- 3 遺失值先問「為什麼缺」再決定怎麼補；醫療資料的遺失常偽裝成 0。
- 4 離群值在醫療場域傾向標記而非刪除——極端值往往正是目標族群。
- 5 縮放參數只能從訓練集計算，且樹模型不需要縮放。
- 6 資料洩漏（Data Leakage）不會報錯，只會給你好看的假分數。指標好到不合理時先查它。

下一步 第 4 週 M2 監督式學習（Supervised Learning）I：迴歸