

迴歸：預測連續數值

M2-1 — Regression: Predicting Continuous Values

從一條直線開始，到你知道什麼時候該懷疑這條直線。
本講義以原課程 ML 3.2 (196 頁) 為本改寫，融入健康照護實例。

本講義大綱

01 迴歸 101 · 目標、類型、工作流程

02 迴歸的 EDA · 看目標、看特徵、看關係

03 簡單線性迴歸 (Linear Regression) · 最小平方法 (Ordinary Least Squares, OLS) 手算一次

04 讀懂模型輸出 · R^2 、F 檢定、t 檢定、p 值

05 殘差圖 · 模型的健康檢查

06 多元迴歸 (Multiple Regression) · 係數 (Coefficient) 意義改變了

07 共線性 (Collinearity) · 係數 (Coefficient) 為什麼會翻正負

08 評估指標 · MAE、MSE、RMSE、MAPE

09 五個假設 · 違反的症狀與處理

10 切分、過擬合與偏誤-變異 · 分數可不可信

11 特徵工程 (Feature Engineering) · 多項式、交互作用 (Interaction)、分箱

12 正則化 (Regularization) 迴歸 · Ridge、Lasso、Elastic Net

13 AI Studio 實作 · 三案例漸進改良

14 Take-Home Assignment · 迴歸建模完整演練

PART 01

迴歸 101

Regression Basics


迴歸做一件事：用一些已知的欄位，預測一個連續的數值。
住院天數、醫療費用、血糖值——都是它的守備範圍。

迴歸的三種目標

目標	在問什麼	例子	重點
預測 Prediction	新個案的數值會是多少？	這位病人預計住院幾天？	只在乎準不準， 不深究為什麼
解釋 Inference	哪些因素影響結果？影響多大？	年齡每多一歲， 住院天數增加多少？	在乎係數的意義與 統計顯著性
情境模擬 What-if	若改變某因素，結果會怎麼變？	若提早介入復健， 可縮短幾天？	需要因果推論， 迴歸只能提供線索

【原講義 ML 3.2】p13。同一個模型可以同時做前兩件事，但第三件（因果）需要額外的研究設計——迴歸係數本身不代表因果。

實例：同一條迴歸線的三種用途



① 預測

給定新病人的年齡，讀出線上對應的位置。
。只在乎「準不準」

② 解釋

看斜率本身。每 10 歲增加約 1.1 天——這個數字才是重點

③ 情境模擬

如果提早介入，整條線會往下平移多少？
需要額外的研究設計才能回答

同一個模型，不同要求

做預測可以用黑箱；做解釋必須檢查假設
；做因果需要實驗或準實驗設計

迴歸家族

迴歸

線性迴歸 (Linear Regression)

一條直線 / 平面

簡單線性

多元線性

非線性形式

彎曲的關係

多項式

對數轉換

樣條

正則化 (Regularization)

抑制過擬合 (Overfitting)

Ridge

Lasso

Elastic Net

樹與集成

非參數方法

迴歸樹

隨機森林 (Random Forest)

梯度提升

【原講義 ML 3.2】 p14。本週主講前三列；樹與集成的迴歸版本在 M4 集成學習 (Ensemble Learning) 一併處理。

迴歸建模工作流程



【原講義 ML 3.2】 p16。注意「檢查假設」是正式的一步，不是可有可無——這是迴歸與其他方法最大的差別。

PART 02

迴歸的 EDA

EDA for Regression

建模前先看三樣東西：

目標的分布、特徵的分布、以及兩者之間的關係。

三個必看

看目標變數的分布

- 直方圖 (Histogram) : 對稱、右偏、雙峰? 醫療費用與住院天數常右偏
- 嚴重右偏 → 先取對數再建模, 預測後指數還原
- 雙峰是警訊: 可能混了兩個母體 (如兩種嚴重度) , 考慮分開建模

看特徵與目標的散布圖 (Scatter Plot)


- 關係是直線、曲線, 還是單變量線性訊號很弱? Scatter Matrix 可一次檢視
- 彎的 → 記下來, 特徵工程時加多項式或取對數
- 沒關係的 → 也記下來, 變數選擇時優先剔除

看特徵之間的相關性

- Correlation Matrix : $|r| > 0.8$ 的特徵對要標記
- 它們是共線性的候選——本講義第 7 節會處理
- 同時看目標與各特徵的相關係數, 作為變數重要性的初步線索

【原講義 ML 3.2】pp20–33。EDA 的產出不是圖本身, 而是一張「待辦清單」: 哪些要轉換、哪些要剔除、哪些要小心。

實例：EDA 三張必看的圖



① 目標的分布

平均 (紅) 明顯右於中位數 (綠) = 右偏
• 考慮取對數再建模

② 有訊號的特徵

嚴重度與住院天數呈明顯正向關係， r 高
→ 強候選

③ 沒訊號的特徵

雲團狀、看不出方向， r 接近 0 → 變數選擇時優先剔除

EDA 的產出

不是這三張圖本身，而是一張待辦清單：
哪些要轉換、哪些要剔除、哪些要小心

PART 03

簡單線性迴歸


Simple Linear Regression

用五筆資料把最小平方法 (Ordinary Least Squares, OLS) 親手算一次。
公式看過就忘，算過一遍會記得為什麼。

手算：以年齡預測住院天數

離差乘積表

病人	年齡 x	天數 y	$x - \bar{x}$	$y - \bar{y}$	$(x - \bar{x})(y - \bar{y})$	$(x - \bar{x})^2$
P1	45	3	-14.8	-2.8	41.4	219.0
P2	52	4	-7.8	-1.8	14.0	60.8
P3	61	6	1.2	0.2	0.2	1.4
P4	68	7	8.2	1.2	9.8	67.2
P5	73	9	13.2	3.2	42.2	174.2
合計	$\bar{x}=59.8$	$\bar{y}=5.8$			108	523



係數計算

步驟	計算	結果
斜率 b	$108 \div 523$	0.2062
截距 (Intercept) a	$5.8 - 0.2062 \times 59.8$	-6.53
迴歸式	$\hat{y} = -6.53 + 0.2062x$	
預測 P3	$-6.53 + 0.2062 \times 61$	6.05
殘差 (Residual) P3	$6 - 6.05$	-0.05

斜率的直覺

x 與 y 一起偏離平均的程度 (分子)，除以 x 自己偏離的程度 (分母)

解讀

在 45–73 歲樣本範圍內，年齡每增加 1 歲，預測住院天數平均增加約 0.21 天；10 歲約 2.1 天

截距 (Intercept)


年齡 0 歲時的預測值 -6.53 天。沒有現實意義——它只是數學上的必要項

外插警告

資料範圍是 45–73 歲。拿去預測 20 歲或 90 歲的病人，模型不負責任何後果

【原講義 ML 3.2】pp37–48。最小平方法：找一條線讓「殘差平方和」最小。取平方是為了不讓正負抵消，且可微分有唯一解。

看見最小平方法：五位病人的擬合



紅色虛線

每位病人的殘差 (Residual) —— 實際與預測的落差。演算法要讓這些線段的平方和最小

為什麼平方

正負不抵消，且大誤差被加重懲罰。P4 病人差 -0.49 ，貢獻的懲罰是 P3 (-0.05) 的近百倍

跟手算對照

這張圖就是前一頁離差乘積表的視覺版—— $b=0.206$ 的那條藍線


外插警告

線可以無限延伸，但資料只到 45–73 歲。範圍外的預測不可信

R² 的計算與意義

逐筆計算

病人	實際 y	預測 $\hat{y}$	殘差 (Residual)	殘差 ²	$(y-\hat{y})^2$
P1	3	2.75	+0.25	0.063	7.84
P2	4	4.19	-0.19	0.036	3.24
P3	6	6.05	-0.05	0.003	0.04
P4	7	7.49	-0.49	0.240	1.44
P5	9	8.52	+0.48	0.230	10.24
合計				0.572	22.80



彙整

量	意義	數值
SS _{tot}	不用模型、只用平均值猜的總誤差	22.80
SS _{res}	用了模型之後剩下的誤差	0.572
R ²	$1 - 0.572/22.80$	0.975
解讀	住院天數的變異 (Variance) 中 97.5% 被年齡解釋	

R² 的本質

「跟直接用平均值猜相比，模型好多少」——它內建了與基準線的比較

本例為何極高

只有五筆且刻意造得線性。真實醫療資料的 R² 常在 0.2–0.6 之間

R² 低就沒用嗎


不一定。R²=0.3 的模型仍可能比沒有模型好很多——看場域需求

R² 高就可信嗎


不一定。先看殘差、未見資料表現與資料洩漏 (Data Leakage)，再判斷能否泛化

【原講義 ML 3.2】pp49–50

實例：R² 的幾何意義



用了模型： $\hat{y} = -6.53 + 0.206x$
 SS_{res} = 各點到迴歸線距離的平方和 = 0.572



左・不用模型

只用平均值猜。紅色方塊是每筆的誤差平方，總面積 = $SS_{tot} = 22.8$

右・用了模型

改用迴歸線猜。綠色方塊小得多，總面積 = $SS_{res} = 0.572$

R² 在算什麼

紅色面積被縮掉了多少比例： $1 - 0.572/22.8 = 0.975$

為什麼 R² 內建基準線


它的比較對象「平均值模型」就是最陽春的基準線

模型輸出的統計檢定怎麼讀

項目	在檢定什麼	怎麼讀	常見誤讀
F 檢定 (整體)	整個模型是否比 「只用平均值」好	$p < 0.05$: 模型整體有解釋力	F 顯著不代表 每個變數都有用
t 檢定 (個別係數)	這個係數是否 顯著不為 0	$p < 0.05$: 該變數有 統計上的貢獻	不顯著 $\neq$ 沒關係， 可能只是樣本不夠
係數的信賴區間	係數的可能範圍	區間不含 0 即顯著； 區間寬代表估得不準	只報點估計 不報區間
p 值本身	在「真的沒關係」的前提下， 看到這種資料的機率	越小越不像巧合	p 值不是 「效果大小」

【原講義 ML 3.2】pp52–55。醫學研究的提醒：統計顯著 ($p < 0.05$) 與臨床重要 (效果夠大) 是兩回事。樣本夠大時，微不足道的效果也會顯著。

實例：讀係數表的正確方式



看區間不看點估計

每條橫線是 95% 信賴區間。點是估計值，線是「可能落在哪」

跨過紅色 0 線 = 不顯著

男性、BMI 的區間都含 0，代表「可能根本沒效果」

區間寬 = 估得不準

男性的區間最寬，因為樣本或變異的關係，這個估計不可靠

顯著 $\neq$ 重要

BMI 若樣本夠大也會顯著，但係數 0.04 在臨床上可能毫無意義

PART 04

殘差圖：模型的健康檢查

Residual Plots

R^2 告訴你模型擬合得多緊，
殘差圖告訴你模型「哪裡出了錯」。





四種殘差圖形狀的診斷

形狀	診斷	病因	處方
隨機散布在 0 附近	健康	—	繼續前進
U 型或倒 U 型彎曲	模型形式錯誤	真實關係是曲線， 你用直線去配	加入 x^2 項， 或對 x 取對數
喇叭狀（越右越寬）	異質變異	數值越大的個案 變異越大（醫療費用典型）	對 y 取對數； 或加權最小平方
週期性起伏	誤差不獨立	有時間結構或 分群（Clustering）結構沒處理	加入時間特徵； 或改用適當模型

【原講義 ML 3.2】pp56–57。看圖順序：先殘差圖（形式對不對）→ 再 R^2 （解釋力夠不夠）。順序反了會被高 R^2 誤導。

實例：四種殘差圖，四種診斷

殘差圖四種型態：先看形狀，再看 R^2



左上・健康

隨機散布、無形狀——模型形式正確，可以繼續

右上・彎曲

倒 U 形 = 關係非線性。處方：加 x^2 或取對數

左下・喇叭

越往右越散 = 異質變異 (Variance)。醫療費用的典型長相。處方：對 y 取對數

右下・週期

規律起伏 = 誤差不獨立，通常有時間結構沒被放進模型

實例：直線硬配曲線關係

劑量-反應資料

劑量 x	反應 y	線性預測	線性殘差
1	2.1	3.6	-1.5
2	3.9	3.9	0.0
4	5.9	4.6	+1.3
5	6.1	4.9	+1.2
7	5.2	5.6	-0.4
8	4.1	5.9	-1.8



兩種模型比較

模型	形式	R ²
線性	$y = a + bx$	0.235
二次	$y = a + bx + cx^2$	0.998
差異	殘差呈倒 U 型 → 加入 x^2 項	

殘差的樣子

線性模型的殘差：先負、後正、再負——標準的倒 U 型

為什麼

劑量-反應常有「先升後降」的生理現象，直線根本配不上

處方

Generate Attributes 加一個 x^2 欄位，R² 從 0.235 跳到 0.998

提醒

不是所有低 R² 都該加多項式——先看殘差圖有沒有形狀，沒形狀就是真的沒關係

數字為刻意設計的教學範例，已實際驗算。醫療上的劑量-反應、年齡-風險常見這種非線性。

PART 05

多元迴歸

Multiple Regression

加入更多變數，係數的意義就變了。

這是從「相關」走向「控制其他因素後」的關鍵一步。

三件意義改變的事

係數：從「總效果」變成「淨效果」

- ▶ 簡單迴歸的 0.21 是未調整關聯；多元迴歸 (Multiple Regression) 是「給定其他納入變數」的條件關聯
- ▶ 加入共病數後年齡係數可能變小，表示兩者共享部分可預測資訊
- ▶ 這正是多元迴歸的價值：把混在一起的效果拆開

R^2 ：只會上升，改看調整後 R^2


- ▶ 加入任何變數，訓練資料上的 R^2 都不會下降——數學上的必然
- ▶ Adjusted R^2 對變數個數施加懲罰，加入無用變數時可能下降
- ▶ 變數個數不同的模型互比，優先看未見資料或交叉驗證 (Cross-Validation)

變數選擇：三種策略

- ▶ 前向 Forward：從零開始逐一加入；後向 Backward：全放再逐一剔除
- ▶ AI Studio：Forward Selection / Backward Elimination 包住模型即可
- ▶ 自動選擇是探索工具，最終清單仍應以領域知識覆核

【原講義 ML 3.2】pp62–67

實例：為什麼加入共病數後，年齡係數變小



左・簡單迴歸

年齡係數包含了「年齡帶動共病、共病拉長住院」這條間接路徑

右・多元迴歸

依嚴重度分層後，在每一層內看年齡的效果——三條線都變平了

這就是「淨效果」

多元迴歸的係數 = 在其他變數維持不變的條件下，該變數的獨立貢獻

實務意義

若你想回答「年齡本身有多大影響」，就必須控制共病——否則會高估

變數選擇的四種策略

策略	做法	優點	風險
全部放入	把所有候選變數一次放進模型	不遺漏；係數是「控制全部其他變數」後的淨效果	變數多時過擬合；共線性嚴重
前向選擇 Forward	從空模型開始，每次加入最能改善的一個	計算快；適合變數很多時	早期選錯就回不去； 忽略變數間的組合效果
後向淘汰 Backward	全部放入，每次剔除貢獻最小的一個	考慮了變數間的相互調整	變數數 > 樣本數時無法起步
領域先驗	由臨床或業務知識決定必納入的變數，其餘再用統計方法篩	★ 醫學研究的標準做法；結果可解釋、可辯護	需要領域專家投入時間

【原講義 ML 3.2】p66。重要提醒：逐步迴歸（stepwise）的 p 值在多次篩選後已經失真，不宜當成正式的統計推論。醫學期刊近年對純逐步法的接受度下降。

共線性：係數翻正負的實例

同一份資料的三個模型

模型	納入變數	身高係數	體重係數	R ²
A	僅身高	+0.42	—	0.31
B	僅體重	—	+0.55	0.38
C	身高 + 體重	-0.18	+0.71	0.39



診斷工具

檢查	工具	判準
相關矩陣	Correlation Matrix	$ r > 0.8$ 僅為篩檢線索
VIF	變異數膨脹因子	VIF > 10 警戒
係數穩定性處理	單獨 vs 同時納入 三選一	翻正負 = 紅色警報 刪一個 / 合成 BMI / Ridge

發生了什麼

身高與體重 $r=0.82$ 。兩者同時放入時，模型無法分辨效果歸誰，給出不穩定的解

R² 沒有變差

預測力幾乎不受影響 (0.38→0.39)。受害的是「解釋」——係數不能信了

什麼時候要處理


目的是解釋因素影響 → 必須處理；目的只是預測 → 可以容忍

醫療常見組合

收縮壓×舒張壓、BMI×體重、多個發炎指標——都是慣犯

【原講義 ML 3.2】pp83–84

實例：共線性讓係數失去意義



左・問題來源

身高與體重 $r \approx 0.9$ ，兩者提供的資訊高度重疊

中・重抽 40 次

每次重抽樣本重估一次係數，結果散得到處都是、跨越 0 兩側

右・盒鬚圖

係數的估計在正負之間劇烈擺盪 → 無法回答「哪個比較重要」

關鍵區分

預測力幾乎不受影響。受害的是「解釋」——這是醫學研究最在意的部分

PART 06

評估指標

Error Metrics

兩個模型的 MAE 完全一樣，
但其中一個明顯比另一個危險。

同樣的 MAE，不同的 RMSE

兩組預測

實際值	模型A 預測	A 誤差	模型B 預測	B 誤差
3	3.5	-0.5	3.0	0.0
4	4.5	-0.5	4.0	0.0
6	5.5	+0.5	6.0	0.0
7	7.5	-0.5	7.0	0.0
9	8.5	+0.5	6.5	+2.5



指標對照

指標	模型A	模型B	誰好
MAE	0.50	0.50	平手
MSE	0.25	1.25	A
RMSE	0.50	1.12	A
最大誤差	0.5	2.5	A

模型 A

每筆都差 0.5——誤差平均分散

模型 B

四筆全對，一筆差 2.5——誤差集中爆發

MAE 看不出來

絕對值平均都是 0.5。MAE 對大誤差不敏感

RMSE 抓得到

平方放大了 2.5 那筆，RMSE 從 0.50 升到 1.12

【原講義 ML 3.2】 pp68–69。原講義的結論：兩者無法互相取代。你的場域怕不怕「單次大誤差」，決定該看哪個。

四個指標速查

指標	單位	對大誤差	何時用	報告時注意
MAE	與 y 同	較不敏感	離群值 (Outlier) 少 ; 需要好解釋 (平均差 3.2 天)	一定要附 y 的平均 與標準差當參照
MSE	y 的平方	很敏感	作為最佳化目標 ; 很少直接報告	單位是平方 , 不好向人解釋
RMSE	與 y 同	敏感	大誤差代價不成比例時 ; 醫療常用	與 MAE 一起報 , 兩者差距大 = 有大誤差
MAPE	百分比	中等	跨尺度比較 (不同科別、不同單位)	y 有 0 或接近 0 會爆炸 , 先檢查

鐵則：報告任何誤差指標都要附「基準線」——一律預測平均值的那個模型的同一指標。沒有比較對象的 RMSE 是沒有意義的數字。

PART 07

線性迴歸（ Linear Regression ）的五個假設

The Five Assumptions


違反假設不會報錯，模型照樣給你數字。
只是那些 p 值、信賴區間、預測區間，都不能信了。

五個假設完整版

假設	檢查方法	違反的後果	處理
線性 Linearity	殘差圖有無彎曲	系統性高估/低估某些區間	x^2 、 $\log(x)$ 、樣條
誤差獨立 Independence	殘差 (Residual) 有無週期； Durbin-Watson 檢定	標準誤低估， p 值過度樂觀	納入時間/群組結構； 混合效應模型
誤差常態 Normality	殘差 (Residual) 直方圖、Q-Q 圖	小樣本時 p 值不可信 (大樣本影響小)	對 y 取對數； 穩健標準誤
等變異 Equal Variance	殘差圖有無喇叭狀	預測區間在高值區失準	對 y 取對數； 加權最小平方
無完美共線性 No Multicollinearity	相關矩陣、VIF	係數 (Coefficient) 不穩、正負翻轉， 無法解釋因素	刪變數、合成變數、 Ridge

【原講義 ML 3.2】pp74–91。醫療資料最常違反：等變異（費用、天數右偏）與共線性（生理指標成群相關）。

實例：右偏資料取對數



左・原始費用

長尾拉到很遠——少數天價個案。直接建模，那幾筆會綁架整個模型

右・取對數後

接近常態。等變異 (Variance) 假設較可能成立，模型也更穩

係數 (Coefficient) 解讀改變


$\ln(y)$ 模型的係數 (Coefficient) 要用「百分比」解讀 (見前頁)

預測記得還原

$y = e^{(\text{預測值})}$ ，且誤差要回到原尺度評估

實例：Q-Q 圖判斷殘差常態性

Q-Q 圖：點貼著對角線 = 殘差接近常態



怎麼看

把殘差排序後，與理論常態分位數比對。
貼著對角線 = 接近常態

中・右偏

點呈向上彎的弧形。醫療費用、住院天數常見。處方：對 y 取對數

右・厚尾

兩端明顯偏離對角線 = 極端值比常態多。
先檢查是不是資料錯誤


大樣本時放寬

樣本夠大時（幾百筆以上），常態假設對 p 值的影響會變小


實例：一個點就能扭轉整條線

一個點就能扭轉整條線：槓桿值 (Leverage) 與影響力 (Cook's D)

不含極端點：斜率 = 0.117



含右下角那一點：斜率 = 0.033



高槓桿 Leverage

該點的 x 值遠離其他資料 (本例 95 歲) → 對迴歸線有很大的拉力

高影響 Influence

它同時也偏離趨勢 → 加入後斜率明顯改變

Cook's Distance

量化「拿掉這一點，模型變多少」。> 4/n 值得檢查

怎麼處理

先查是不是輸入錯誤；確認是真實個案時，分別跑含與不含的版本並報告差異

對 y 取對數之後，係數 (Coefficient) 怎麼解讀

轉換前後的模型

- ▶ 轉換前： $y = a + bx \rightarrow x$ 每增 1 單位， y 增加 b (絕對量)
- ▶ 轉換後： $\ln(y) = a + bx \rightarrow x$ 每增 1 單位， y 變為原來的 e^b 倍 (相對量)
- ▶ b 很小時的速算： $e^b \approx 1 + b$ ，所以 $b = 0.05 \approx y$ 增加約 5%

醫療費用的例子

- ▶ $\ln(\text{費用})$ 對共病數的係數 = 0.18 $\rightarrow$ 每多一項共病，條件比值為 $e^{0.18}$ ，約增加 19.7%
- ▶ 這種「百分比」解讀往往比絕對金額更符合實務直覺
- ▶ 預測時記得指數還原：費用 = $e^{(\text{預測值})}$ ，且還原後的誤差要在原尺度上重新評估

【原講義 ML 3.2】p82 (PRO TIP: Interpreting Transformed Targets)。這是原講義特別標註的專業技巧，實務中很常用卻很常被算錯。

切分、過擬合與偏誤 (Bias) - 變異 (Variance)


Splitting, Overfitting & the Tradeoff

訓練集上的分數是「它記住了多少」，
測試集上的分數才是「它學會了多少」。

過擬合 (Overfitting) 長什麼樣子

多項式次數實驗

模型	複雜度	訓練	測試
直線	1 次	2.10	2.15
二次曲線	2 次	1.42	1.38
五次多項式	5 次	0.71	1.94
九次多項式	9 次	0.02	6.30



三種狀態

診斷	訓練	測試	判定
欠擬合 (Underfitting)	高	高 (接近)	模型太簡單
剛好	中	中 (接近)	★ 目標
過擬合 (Overfitting)	低	高 (差距大)	模型太複雜
嚴重過擬合	≈0	爆炸	記住了雜訊

九次多項式

訓練 RMSE 幾乎 0——它穿過了每一個訓練點，包括雜訊

代價

測試 RMSE 爆炸到 6.30。它記住的雜訊在新資料上全是錯的

最佳點

二次曲線：訓練與測試接近且都不高——這就是偏誤 (Bias) 與變異 (Variance) 的平衡點




怎麼找

同時追蹤訓練與測試誤差，找測試誤差的最低點

【原講義 ML 3.2】 pp100–103。偏誤-變異取舍：太簡單=高偏誤 (學不會)，太複雜=高變異 (學過頭)。所有機器學習都繞著這個取舍轉。

實例：同一份資料，三種複雜度

同一份資料，三種複雜度：過擬合把雜訊也背下來了



左・欠擬合 (Underfitting)

直線抓不到彎曲的趨勢——訓練與測試誤差都高

中・剛好

二次曲線貼合趨勢又不追逐個別點——這是目標


右・過擬合 (Overfitting)

九次多項式穿過每個點，包括雜訊。訓練誤差 ≈ 0 ，新資料上會爆炸

怎麼分辨

單看訓練資料無法分辨中與右——一定要留測試集

實例：找出模型複雜度的甜蜜點



訓練誤差 (灰)

隨複雜度單調下降——模型越複雜，越能記住訓練資料

測試誤差 (藍)

先降後升。上升的那一段就是開始記憶雜訊

甜蜜點

測試誤差的最低點。本例是 2 次多項式

這條曲線到處都是

k-NN 的 k、樹的深度、正則化的 λ ——換個參數名，同一個故事

訓練集、驗證集、測試集：為什麼要三份

三分割：為什麼需要三份而不是兩份



模型「看得到」的資料
用來學參數 (係數、權重、樹的切點)

選超參數、比較模型
看很多次，分數會樂觀

只在最後看一次
動過就作廢

★ 鐵則：縮放、填補、取樣、特徵選擇的「參數」一律只從訓練集計算，再套用到驗證與測試集

訓練集 Training set

模型「看得到」的資料，用來學參數 (迴歸係數、樹的切點、網路權重)

驗證集 Validation set

用來選超參數、比較模型。因為看很多次，它的分數會逐漸樂觀

測試集 Test set

只在最後看一次。一旦用它做過任何決策，它就失去公正性了

★ 鐵則

縮放、填補、取樣、特徵選擇的參數，一律只從訓練集計算

三份資料的分工

	訓練集 Train	驗證集 Validation	測試集 Test
典型比例	60%	20%	20%
用途	學習模型參數	選超參數、比較模型	估計最終表現
模型看幾次	很多次 (每個 epoch)	很多次 (每組參數一次)	★ 只有一次
分數的性質	樂觀 (記憶力)	略為樂觀 (選過很多次)	最接近真實部署表現
能不能重複用	可以	可以	★ 不可以
資料少時的替代	—	以交叉驗證取代	仍應保留獨立測試集

常見誤解：以為「有做交叉驗證就不用測試集」。交叉驗證取代的是驗證集，不是測試集——你仍需要一份從頭到尾沒被碰過的資料。

三層資料的正確用法

1

訓練集 Train

- ▶ 60–80% 的資料
- ▶ 用來擬合模型參數
- ▶ 模型「看過」的資料
- ▶ 訓練分數只代表記憶力
- ▶ 所有前處理的統計量從這裡算
- ▶ 縮放、填補的參數來源

2

驗證集 Validation

- ▶ 10–20% 的資料
- ▶ 用來選超參數、比較模型
- ▶ 「用很多次」的考卷
- ▶ 選來選去之後，分數也會虛高
- ▶ 交叉驗證 (Cross Validation) 是它的替代方案
- ▶ 小資料集建議直接用 CV

3

測試集 Test

- ▶ 10–20% 的資料
- ▶ 只在最後用一次
- ▶ 動過任何決策就作廢
- ▶ 它是你對外報告的那個數字
- ▶ AI Studio : Split Data 先切走，剩下的再進 Cross Validation
- ▶ 碰過兩次的測試集不叫測試集

【原講義 ML 3.2】 pp94–114。k-fold 交叉驗證 (Cross Validation)：資料切 k 份輪流當驗證集，分數取平均並看標準差——小資料集的標準做法。

為什麼需要交叉驗證

問題：單次切分的分數不穩定

- ▶ 同一份資料、同一個模型，換一個隨機種子切分，AUC 可能從 0.78 變成 0.85
- ▶ 你回報哪一個？兩個都是真的，但都不可靠——這只是運氣
- ▶ 樣本數越少，這個問題越嚴重。醫療資料常常只有幾百到幾千筆

解法：讓每一筆都當過一次測試資料

- ▶ 把資料切成 k 份，輪流用其中一份當測試集、其餘訓練，跑 k 次
- ▶ 回報 k 次分數的平均——這比任何單一次的分數都可靠
- ▶ 同時回報標準差：它告訴你「這個模型有多穩」

怎麼寫進報告

- ▶ 正確寫法：「5-fold stratified CV : AUC 0.81 ± 0.03 」
- ▶ 只寫 0.81 的話，讀者無從判斷這個數字有多可信
- ▶ 標準差大（如 ± 0.09 ）代表模型對切分很敏感，部署後的表現可能落在很寬的範圍


資料洩漏最常見的形式：順序反了

資料洩漏最常見的形式：前處理與切分的順序反了

❌ 錯誤：先前處理再切分 → 測試集的資訊滲入訓練



✓ 正確：先切分，前處理的參數只從訓練集算



X 上排

先對「全部資料」做縮放與填補，再切分。
。測試集的分布資訊已滲入訓練

✓ 下排

先切分。用訓練集算出縮放與填補的參數，
再套用到測試集

後果

上排的測試分數會虛高，部署後表現大幅
下滑——而且不會有任何錯誤訊息

統一解法

把所有前處理放進 Cross Validation 的訓
練子流程內，讓每折各自計算

PART 09

迴歸的特徵工程

Feature Engineering

模型只能學到你給它的形狀。



關係是彎的就給它彎的項，有交互作用（Interaction）就給它乘積項。

四種手法

手法	做什麼	什麼時候用	AI Studio
多項式項 Polynomial	加入 x^2 、 x^3 欄位	殘差圖呈彎曲； 劑量-反應、年齡-風險	Generate Attributes $x*x$
交互作用 Interaction	加入 $x_1 \times x_2$ 欄位	一個變數的效果 依另一個變數而不同	Generate Attributes $x1*x2$
虛擬變數 (Dummy Variable) Dummy	類別展開成 0/1 欄位	科別、縣市等無序類別 進迴歸模型的唯一方式	Nominal to Numerical (dummy coding)
分箱 Binning	連續值切成有序區間	關係呈階梯狀； 或需要對齊臨床分級	Discretize by User Specification

【原講義 ML 3.2】pp117–134

實例：多項式項與交互作用



左・多項式

劑量-反應常見「先升後降」。直線（灰虛線）根本配不上，加 x^2 後貼合

右・交互作用

三個年齡層的斜率不同——復健時數的效果隨年齡遞減

沒放交互作用會怎樣

模型被迫用一條共同斜率去代表三群人，對誰都不準

怎麼發現

依某個變數分組畫散布圖，若各組斜率明顯不同，就該加交互作用項

交互作用（Interaction）：一個健康照護的例子

情境

- ▶ 復健時數對功能恢復的效果，可能依年齡而不同：年輕人多做多恢復，高齡者效果趨緩
- ▶ 只放「復健時數」與「年齡」兩個主效果，模型假設復健效果對所有年齡都一樣——這假設可能是錯的

做法

- ▶ 加入乘積項：恢復分數 = $a + b_1 \text{時數} + b_2 \text{年齡} + b_3 (\text{時數} \times \text{年齡})$
- ▶ b_3 顯著為負 $\rightarrow$ 年齡越大，每小時復健的邊際效果越小
- ▶ 解讀時數的效果必須連 b_3 一起看： $dY/d\text{時數} = b_1 + b_3 \times \text{年齡}$

兩個提醒

- ▶ 放了交互作用項，對應的主效果必須保留（階層原則）
- ▶ 交互作用項與主效果天生相關，會推高 VIF——先把變數中心化（減去平均）可緩解

【原講義 ML 3.2】p124。虛擬變數（Dummy Variable）陷阱順帶提醒：k 類展開 k-1 欄，留一類當基準。全展開會造成完美共線性（Collinearity）。

PART 10

正則化 (Regularization) 迴歸

Regularized Regression


當變數很多、樣本不多、又彼此相關時，
給係數「加一條韁繩」反而讓模型更穩。

三種正則化

方法	懲罰項	效果	什麼時候選
Ridge (L2)	係數平方和	把係數「壓小」但不歸零。 對共線性 (Collinearity) 特別有效	變數都可能有貢獻； 主要問題是共線性
Lasso (L1)	係數絕對值和	把不重要的係數「壓到 0」 = 自動變數選擇	懷疑多數變數沒用； 想要精簡模型
Elastic Net	兩者混合	介於中間， 混合比例可調	變數成群相關 且想做選擇時

【原講義 ML 3.2】pp140–159。兩個操作重點：一、正則化前必須標準化 (Standardization) (否則懲罰對大尺度變數不公平) ；二、懲罰強度 λ 用交叉驗證選。

實例：Ridge 的係數路徑



每條線 = 一個變數

橫軸是懲罰強度 λ (對數軸)，縱軸是該變數的係數估計

λ 很小 (左端)

等同普通最小平方。共線的 x_1 、 x_2 一正一負大幅擺盪 = 不穩定

λ 增大

所有係數被穩定地壓向 0，擺盪消失。這就是「加韁繩」的視覺意義

λ 太大 (右端)

全被壓扁，模型退化成只剩截距 $\rightarrow$ 欠擬合。所以要用交叉驗證選 λ

λ (懲罰強度) 的直覺

$\lambda = 0$

- ▶ 沒有懲罰，就是普通最小平方法 (Ordinary Least Squares, OLS)
- ▶ 係數自由發揮，共線性問題原樣呈現

λ 適中

- ▶ 係數被適度收縮，變異下降
- ▶ 犧牲一點訓練誤差，換取測試誤差下降——這正是偏誤-變異取舍的實際應用


λ 太大

- ▶ 所有係數被壓向 0，模型退化成「只剩截距 (Intercept) 」
- ▶ 欠擬合 (Underfitting)：訓練與測試誤差都變高

怎麼選

- ▶ 掃一排 λ ，每個都跑交叉驗證，選平均驗證誤差最低者
- ▶ 最終測試集不參與選 λ ；AI Studio 可用 Optimize Parameters 包住驗證流程

實例：信賴區間 vs 預測區間



藍色窄帶・信賴區間

「這個年齡的病人，平均住院天數」的不確定範圍。樣本越多越窄

橘色寬帶・預測區間

「下一位這個年齡的病人」的不確定範圍。
永遠比信賴區間寬得多

為什麼寬那麼多

預測區間還要加上個體之間的隨機變異，
那部分不會因為樣本變多而消失

★ 常見錯誤

拿信賴區間去跟病人溝通個人預後。要用的是預測區間

線性迴歸 vs 迴歸樹：什麼時候換工具

線性迴歸的優勢

- ▶ 係數可直接解讀，且能給信賴區間與 p 值
- ▶ 外插時仍能給出 (雖不保證正確的) 預測
- ▶ 需要的樣本數較少
- ▶ 醫學文獻的通用語言
- ▶ 適合：關係大致線性、需要解釋、樣本不多

迴歸樹 / 集成的優勢

- ▶ 自動抓非線性與交互作用，不需你手動指定
- ▶ 不需要正規化，對特徵尺度與型態寬容
- ▶ 對離群值較不敏感
- ▶ 但無法外插——樹的預測永遠落在訓練資料的範圍內
- ▶ 適合：關係複雜、變數多、預測準確度優先

實務建議：先跑線性迴歸建立可解釋的基準線，再跑迴歸樹或隨機森林看能不能大幅超越。差距很大 = 關係高度非線性，值得回頭做特徵工程。M4 會實作。

迴歸結果的標準報告格式

段落	必含內容
1 問題與資料	目標變數的定義與單位、樣本數、納入排除條件、遺失處理方式
2 描述統計	目標與主要變數的平均、標準差、範圍；目標的分布圖
3 模型設定	納入哪些變數與為什麼；是否轉換（取對數、分箱）；如何處理共線性
4 模型結果	每個變數的係數、標準誤、95% 信賴區間、p 值； R^2 與調整後 R^2
5 假設檢查	殘差圖、Q-Q 圖、共線性檢查的結果；違反時如何處理
6 預測表現	測試集或交叉驗證的 MAE / RMSE；與基準線的比較
7 限制	外插範圍、未納入的干擾因子、因果解讀的限制、資料代表性

第 7 段最能看出專業程度。「本模型之係數為關聯性估計，不宜作為介入成效之因果推論依據」這句話是加分不是示弱。

迴歸建模的八個常見錯誤

#	錯誤	後果
1	只看 R^2 不看殘差圖	模型形式根本錯了卻不知道
2	變數數不同的模型比 R^2	永遠選到最複雜的那個
3	對外插的預測有信心	資料只到 73 歲，卻拿去預測 90 歲
4	把係數當因果	「減少用藥可縮短住院」——但兩者都被嚴重度驅動
5	共線性下解讀個別係數	係數正負可能只是抽樣的偶然
6	忽略異質變異	高值區的預測區間嚴重低估
7	取對數後忘記還原	報告的誤差單位是 $\ln(\text{元})$ 而不是元
8	用信賴區間跟病人溝通	應該用預測區間——一個人的不確定性大得多

建模前的五個提問

Q
1

我的目標變數需要轉換嗎？

看分布圖。右偏（醫療費用、住院天數）通常先取對數；記得預測後要還原。

Q
2

我打算解釋係數，還是只要預測？

要解釋 → 必須檢查共線性與假設；只要預測 → 可以容忍共線性，改看測試誤差。

Q
3

我的預測會用在什麼範圍？

把訓練資料的 x 範圍寫下來。超出範圍的預測要在報告中明確標示為外插。

Q
4

誰會看這個結果？他需要哪種區間？

族群層級的決策 → 信賴區間；個別病人的溝通 → 預測區間。

Q
5

如果有人問「這代表因果嗎」，我怎麼回答？

先想好答案。多數觀察性資料的迴歸只能說關聯，這一句要寫進報告。

PART 11

AI Studio 實作

Hands-on Labs

三個案例是刻意設計的難度階梯。

記錄每一步的指標變化，比最後的數字更重要。

實作 1 | University Admission：基準與檢定

【AI Studio 範例】 4. Case Studies / 4.1

開啟檔案

範例/ML (AI Studio)/M2. 監督式學習/
└ 4.1 University Admission/
 └ Case Study 4 University
 └ admission - regression .rmp
 └ ML university admission.pptx

資料/ML (AI Studio)/M2. 監督式學習/
└ university_admission.csv

難度：入門

預期結果

- ▶ 移除不顯著變數後 R^2 微降、調整後 R^2 (Adjusted R^2) 可能升
- ▶ 殘差應大致隨機——這份資料相對乾淨
- ▶ 說不出係數意義的，回去看本講義 P3

操作步驟

- 1 執行流程，記錄 R^2 與 RMSE 作為基準
- 2 檢視 LinearRegression 輸出：每個特徵的 Coefficient、t 值、p 值
- 3 找出 $p > 0.05$ 的特徵，用 Select Attributes 移除後重跑
- 4 比較移除前後：Adjusted R^2 、交叉驗證 RMSE 與係數穩定性各怎麼變？
- 5 畫殘差圖（預測值 vs 殘差的 Scatter），檢查四種形狀
- 6 把係數用一句話解讀給非技術人員聽（寫下來）

實作 2 | Car Sales：漸進改良（本週核心）

【AI Studio 範例】 4. Case Studies / 4.2

開啟檔案

範例/ML (AI Studio)/M2. 監督式學習/
└ 4.2 Car Sales/
 └ Car_sales.rmp
 └ 資料品質檢查.docx ← 先讀
 └ Used car price prediction.pptx

資料/ML (AI Studio)/M2. 監督式學習/
└ car_sales_data.csv

難度：中

預期結果

- 取對數那一輪通常改善最明顯
- 某一輪變差是正常的——寫下原因與證據
- 這張五輪表就是 Task 1 的方法論骨架

操作步驟

- 1 讀「資料品質檢查.docx」，列出資料問題清單
- 2 第 0 輪：不做任何處理直接跑，記錄 R^2 、RMSE
- 3 第 1 輪：處理遺失值（Missing Data），重跑記錄
- 4 第 2 輪：處理離群值（Outlier），重跑記錄
- 5 第 3 輪：對右偏的價格取對數，重跑記錄（注意還原）
- 6 第 4 輪：加入你認為合理的多項式或交互作用項
- 7 五輪結果填入 Take-Home Assignment 的表格

實作 3 | Car Purchasing：特徵選擇（Feature Selection）與交叉驗證

【AI Studio 範例】 4. Case Studies / 4.3.1

開啟檔案

範例/ML (AI Studio)/M2. 監督式學習/

└ 4.3.1 Car Purchasing/

└ Case Study - Car Purchasing price
prediction - FeatureSelection
and CV.rmp

同資料夾另有：

Car_Purchasing_Data_ANNs.rmp (M5 預告)

Car_Purchasing_Data_Ensemble.rmp (M4 預告)

難度：進階

預期結果

- ▶ 選擇後的模型變數更少、CV 分數通常持平或略升
- ▶ fold 數少 → 每折測試集大、分數變異通常較小
- ▶ 入選變數若無法解釋，懷疑是巧合相關

操作步驟

- 1 執行流程，理解 Forward Selection 如何包住迴歸模型
- 2 記錄它最終選了哪些變數、依什麼順序加入
- 3 比較「全變數」與「選擇後」的交叉驗證 RMSE
- 4 把 Cross Validation 的 fold 數從 10 改成 5，看分數與標準差變化
- 5 檢查：標準差大代表什麼？（模型對切分方式敏感）
- 6 選擇後的變數清單，用領域知識覆核一遍——有沒有莫名其妙的入選者

PART 12

Take-Home Assignment

帶回家作業（迴歸篇）

主題：健康照護數值預測的完整建模演練

第 5 週上課前繳交 | 與分類篇作業合併計分

作業任務（迴歸篇）

任務	要求	對應章節
1 EDA 與轉換決策	檢視目標分布，判斷是否需要取對數。附直方圖與你的決策理由。	P2
2 基準線	分別報告常數基準：MAE 用中位數；RMSE 用平均值，作為後續比較標竿。	P6
3 漸進改良五輪表	以 Car Sales 或自選資料完成五輪改良（原始→遺失值→離群值→對數→特徵工程），每輪記錄 MAE、RMSE、 R^2 、調整後 R^2 。	P11 實作 2
4 係數與檢定解讀	對最終模型：解讀三個係數（含一個不顯著的）、說明 F 檢定結果、若有取對數需以百分比方式解讀。	P3、P7
5 假設檢查	附殘差圖並診斷四種形狀；附相關矩陣並報告最高的 $ r $ 與處理方式。	P4、P5
6 交叉驗證	以 5-fold CV 報告最終模型的 RMSE 平均與標準差，並與單次切分的結果比較。	P8

必答思考題（寫入報告）

Q
1

你的模型贏過「指標相配的常數基準」多少？這個差距值得部署嗎？

從使用者的角度回答：預測誤差縮小的那幾天/那些錢，對誰有什麼實際意義？

Q
2

如果只能保留三個變數，你留哪三個？依據是什麼？

p 值、係數大小、領域知識三者可能指向不同答案——說明你如何取捨。

Q
3

你的資料違反了哪些假設？你處理了嗎？沒處理的話，報告中該怎麼誠實聲明？

「本模型之預測區間在高值區可能失準」這類聲明是專業，不是示弱。

中英術語對照 | M2-1 迴歸

(1 / 4)

中文	English	一句話說明
迴歸	Regression	預測連續數值
簡單線性迴歸	Simple Linear Regression	一個自變數的直線模型
多元迴歸	Multiple Regression	多個自變數的線性模型
最小平方法	Ordinary Least Squares, OLS	讓殘差平方和最小的擬合方法
係數	Coefficient / Slope	自變數每增一單位，目標變動多少
截距	Intercept	所有自變數為 0 時的預測值
殘差	Residual	實際值 – 預測值
決定係數	R-squared, R^2	目標變異被模型解釋的比例
調整後決定係數	Adjusted R^2	對變數個數施加懲罰後的 R^2

中英術語對照 | M2-1 迴歸

(2 / 4)

中文	English	一句話說明
平均絕對誤差	Mean Absolute Error, MAE	誤差絕對值的平均；對大誤差不敏感
均方誤差	Mean Squared Error, MSE	誤差平方的平均
均方根誤差	Root Mean Squared Error, RMSE	MSE 開根號；與目標同單位
平均絕對百分比誤差	Mean Absolute Percentage Error, MAPE	百分比誤差，便於跨尺度比較
基準線	Baseline	一律預測平均值的模型；比較的起點
線性	Linearity	X 與 Y 的關係是直線
誤差獨立	Independence of Errors	一筆的誤差不影響下一筆
常態性	Normality of Errors	殘差分布接近常態
等變異	Homoscedasticity	殘差的散布程度處處相同

中英術語對照 | M2-1 迴歸

(3 / 4)

中文	English	一句話說明
異質變異	Heteroscedasticity	殘差呈喇叭狀，變異隨數值改變
過擬合	Overfitting	記住訓練資料的雜訊，新資料表現差
欠擬合	Underfitting	模型太簡單，訓練集就學不好
偏誤-變異取捨	Bias-Variance Tradeoff	太簡單 = 高偏誤，太複雜 = 高變異
交叉驗證	Cross Validation, CV	切成 k 份輪流當測試集，取平均
多項式項	Polynomial Term	加入 x^2 、 x^3 以捕捉曲線關係
交互作用	Interaction Term	一個變數的效果依另一個變數而不同
正則化	Regularization	對係數施加懲罰以抑制過擬合
脊迴歸	Ridge Regression, L2	壓小係數但不歸零；對共線性有效

中英術語對照 | M2-1 迴歸

(4 / 4)

中文	English	一句話說明
套索迴歸	Lasso Regression, L1	把不重要的係數壓到 0 = 自動選變數
彈性網	Elastic Net	Ridge 與 Lasso 的混合

迴歸篇重點回顧

- 1 迴歸的三種目標：預測、解釋、模擬——係數不代表因果。
- 2 先看殘差圖（形式對不對），再看 R^2 （解釋力夠不夠）。
- 3 MAE 與 RMSE 併報；差距大常提示重尾或少數大誤差，需回查個案。
- 4 多元迴歸（Multiple Regression）的係數是「其他不變下的淨效果」；共線性會讓它不可信。
- 5 訓練/測試差距大 = 過擬合。正則化是給係數加韁繩的解法。
- 6 任何指標都要跟基準線比。沒有比較的 RMSE 是沒有意義的數字。

下一步 第 5 週 M2-2 分類：從 k-NN 到集成方法