MODULE 2-2

# 分類：從 k-NN 到集成方法

## M2-2 — Classification: From k-NN to Ensembles

本課程份量最重的單元。以原課程 ML 3.3 （235 頁）為本改寫：
五種演算法、完整評估體系、不平衡處理、集成方法——醫療預測的核心工具箱。

資料科學　2027 Spring　·　第 5 週　·　Phase A　｜　謝楠楨

# 本講義大綱


01 分類 101 · 目標、類型、工作流程

02 定義目標變數 · 最容易被輕忽的一步

03 特徵工程（Feature Engineering）與切分 · 分類版的準備工作

04 k-NN · 距離手算＋ k 值選擇

05 Logistic 迴歸 · Sigmoid、勝算比（Odds Ratio, OR）、正則化（Regularization）

06 Naive Bayes · 貝氏定理的快速分類器

07 混淆矩陣（Confusion Matrix）家族 · 六個指標與盛行率陷阱

08 ROC、PR 與門檻 · 評估的完整體系

09 類別不平衡（Imbalanced Data） · 五種處理與三個鐵則

10 交叉驗證（Cross Validation） · 三份切分、巢狀 CV 與學習曲線

11 決策樹（Decision Tree） · Gini 手算＋剪枝（Pruning）

12 集成方法 · Voting、隨機森林、梯度提升

13 模型比較總表 · 怎麼選、怎麼報告

14 AI Studio 實作 · Loan Risk 六步＋ HR Churn

15 Take-Home Assignment · 分類完整演練

# 貫穿本講義的案例：出院準備服務的風險分層

## 情境

- 你是醫院品管中心的資料分析師。院方要推「出院準備服務加強方案」，但個管師人力只夠追蹤兩成的出院病人
- 任務：建立 30 天非計畫性再入院的風險模型，讓有限人力花在最需要的人身上

## 你手上的資料

- 近三年出院病人 12,000 筆：人口學、診斷、住院天數、檢驗值、過往就醫紀錄、出院去向
- 30 天內非計畫性再入院率約 6%—— 標準的不平衡問題

## 成功的定義（先寫好，再動手）

- 個管師追蹤的前 20% 高風險名單，要涵蓋至少六成的實際再入院者（Lift 觀點）
- 名單要附「為什麼是他」的理由——個管師不接受無法解釋的黑箱名單
- 本講義每一節的技術，最後都會回到這個案例

【原講義 ML 3.3】 pp5–8 的 National Bank 案例結構，改寫為健康照護場景。原講義的做法值得學：先講清楚情境與成功定義，才開始講技術。

PART 01

# 分類 101

## Classification Basics

分類預測的是「屬於哪一類」。

但好的分類器給你的不只是類別——還有機率。

# 分類的三種類型

| 類型 | 目標變數 | 例子 | 注意 |
|---|---|---|---|
| **二元分類**<br>**Binary** | 兩種值 | 會不會再入院；<br>是否為垃圾郵件 | 本週的主軸；<br>醫療風險預測多屬此類 |
| **多元分類**<br>**Multi-class** | 三種以上，互斥 | CMS 等級 1–8；<br>檢傷分級 1–5 | 每筆只屬一類；<br>注意類別是否有序 |
| **多標籤**<br>**Multi-label** | 可同時多個 | 一位病人同時有<br>多項共病診斷 | 每個標籤各自是<br>一個二元問題 |

【原講義 ML 3.3】 p14。有序的多元類別（如檢傷分級）介於分類與迴歸之間——把「差一級」和「差四級」當成一樣的錯，是常見的浪費。

# Hard 分類與 Soft 分類

## Hard：直接給類別

- 輸出：「會再入院」或「不會」
- 簡單直接，但丟失信心資訊
- 「51% 會」和「99% 會」被當成同一件事
- 無法調整決策門檻（Decision Threshold）
- k-NN 多數決（Majority Vote）、決策樹（Decision Tree）的預設輸出屬此類

## Soft：先給機率，再決定

- 輸出：「再入院機率 0.73」
- 保留完整的信心資訊
- 可依場域的代價比（Cost Ratio）自訂門檻
- 可以排序：先處理機率最高的個案
- ★ 醫療場域幾乎都應該用 Soft
- Logistic、Naive Bayes 天生輸出機率

【原講義 ML 3.3】 pp77–79、136–139。原講義特別提醒：模型輸出的「機率」是相對排序的分數，未必等於真實的事件發生率（需要校準才能當機率讀）。

# 分類建模工作流程




【原講義 ML 3.3】 p15。與迴歸最大的差異在第一步與最後一步：目標定義與門檻調整——這兩步都是「決策」而不是「計算」。

PART 02

# 定義目標變數

## Defining the Target

「預測再入院」聽起來很明確。

實際動手時你會發現至少要做四個決定。

# 「預測再入院」的四個隱藏決定

| 決定 | 選項 | 影響 |
| --- | --- | --- |
| **時間窗** | 出院後 14 天？ 30 天？ 90 天？ | 窗越短事件越少（更不平衡）；<br>窗越長「與此次住院的關聯」越弱 |
| **哪種再入院算** | 全部？同科別？非計畫性？ | 計畫性化療回診算不算「再入院」？<br>定義不同，模型學的東西完全不同 |
| **分母是誰** | 所有出院病人？排除死亡？排除轉院？ | 排除條件會改變盛行率（Prevalence），<br>也改變模型的適用對象 |
| **預測時點** | 出院當天？入院 48 小時內？ | 決定了哪些特徵「當時拿得到」——<br>用了之後才有的資料就是時間洩漏 |

【原講義 ML 3.3】 pp20–21。原講義的例子是「顧客流失」的定義；醫療場域的對應就是這張表。目標定義寫不清楚的專案，做出來的模型無法被任何人使用。

# 同一份資料，兩種目標定義

**原始就醫紀錄**

| 病人 | 出院日 | 下次入院 | 間隔天數 |
|---|---|---|---|
| P1 | 3/01 | 3/12 | 11 |
| P2 | 3/03 | 4/20 | 48 |
| P3 | 3/05 | — | — |
| P4 | 3/08 | 3/29 | 21 |
| P5 | 3/10 | 6/15 | 97 |



**兩種標籤**

| 病人 | 30 天定義 | 90 天定義 |
|---|---|---|
| P1 | 1 | 1 |
| P2 | **0** | **1** |
| P3 | 0 | 0 |
| P4 | 1 | 1 |
| P5 | 0 | 0 |

**P2 的標籤翻轉** — 30 天定義是陰性、90 天定義是陽性——同一個人，兩個答案

**盛行率也變了** — 30 天：2/5 = 40%；90 天：3/5 = 60%。所有指標的基準都不同

**沒有對錯** — 選哪個取決於介入方案：出院衛教管 30 天，慢性病管理管 90 天

**報告要求** — 目標定義必須完整寫進報告第一節，包括排除條件

這就是為什麼 Take-Home Assignment 的任務 1 是「寫清楚目標定義」而不是直接建模。

# 分類的 EDA：三張必看的圖

| 看什麼 | 怎麼看 | 要找什麼 |
| --- | --- | --- |
| **目標的類別比例** | 長條圖或一個百分比 | 不平衡程度。6% 與 40% 的問題是兩種完全不同的仗 |
| **數值特徵 × 類別** | 按類別分組的盒鬚圖（再入院者 vs 未再入院者的年齡分布） | 兩組分布有沒有分開？分得越開，該特徵越有預測力 |
| **類別特徵 × 類別** | 交叉表 + 各組陽性率（各出院去向的再入院率） | 哪些類別的陽性率特別高？樣本太少的類別要先合併 |

【原講義 ML 3.3】 pp19–23。AI Studio：Statistics 看比例；Charts 的 Box Plot 選 group by label；Aggregate 算分組陽性率。

# 分組陽性率：一眼看出誰是強特徵

### 各出院去向的再入院率

| 出院去向 | 人數 | 再入院數 | 再入院率 |
|---|---|---|---|
| 回家（自理） | 6,000 | 180 | 3.0% |
| 回家（家人照顧） | 3,600 | 252 | 7.0% |
| 護理之家 | 1,800 | 216 | **12.0%** |
| 呼吸照護病房 | 600 | 72 | **12.0%** |
| 整體 | 12,000 | 720 | 6.0% |



### 判讀

| 特徵 | 判讀 |
|---|---|
| 出院去向 | 3% → 12%，四倍差距<br>＝強特徵 |
| 樣本量檢查 | 呼吸照護僅 600 筆，<br>12% 的估計較不穩 |
| 行動 | 可考慮把兩個 12% 的<br>類別合併 |
| 下一步 | 把這類表格對每個<br>類別特徵都做一遍 |

**為什麼有效**

陽性率在組間差異越大，該特徵切下去的資訊增益（Information Gain）越高——決策樹（Decision Tree）自己也是這樣挑的

**陷阱**

小樣本類別的比率不可靠。600 筆的 12% ± 誤差可能蓋過與 7% 的差距

**這張表的另一個用途**

它就是「單特徵基準線」：只用出院去向分四級，已經是一個可用的粗模型

數字為教學設計。實務上這張表做完，你對「模型大概能做到多好」已經有底了。

PART 03

# 特徵工程與資料切分

## Features & Splitting

大部分與迴歸相同（M1、M2-1 已 covered），
這裡只講分類特有的三件事。

# 分類特有的三件事

## 分層切分（Stratified Split）

- 隨機切分在不平衡資料上，某一份可能幾乎沒有陽性樣本
- 分層切分（Stratified Split）維持每份的類別比例一致。 AI Studio： sampling type = stratified
- ★ 本課程所有分類作業的預設要求

## 類別編碼的目標視角

- One-Hot 在高基數類別（High Cardinality）會產生大量稀疏欄位
- 替代：頻率編碼（用出現次數）或分組（依臨床意義合併成大類）
- 目標編碼（Target Encoding）會學到標籤資訊，必須只在每個 CV 訓練折內估計

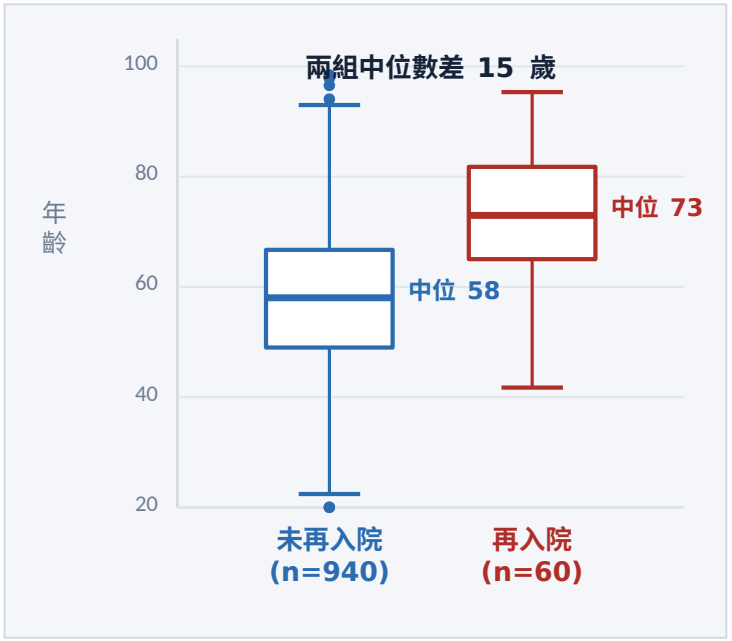
## 縮放：看你用哪個演算法

- k-NN、 SVM、含正則化的 Logistic、神經網路：通常需要縮放
- 決策樹、隨機森林（Random Forest）、梯度提升（Gradient Boosting）、 Naive Bayes： 不需要
- 縮放參數一律從訓練集算（M1 的鐵則，此處再次適用）

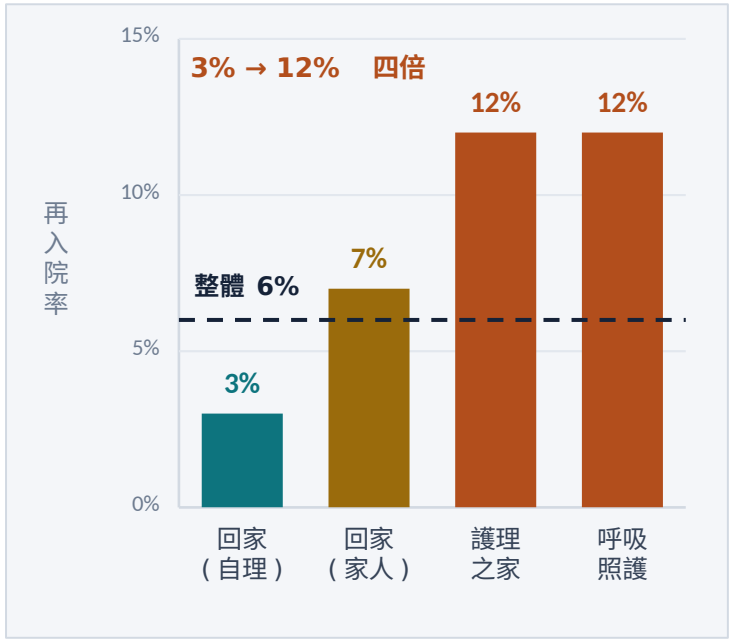
【原講義 ML 3.3】 pp30–45

# 實例：分類 EDA 的兩張關鍵圖

左・年齡 × 是否再入院




右・各出院去向的再入院率




左圖看「連續特徵分不分得開」，右圖看「類別特徵的陽性率差多少」。兩張圖都畫完，你大致就知道模型能學到什麼了。

### 左・分組盒鬚圖

再入院組的年齡分布整體高一截——分得越開，特徵越有預測力

### 右・分組陽性率

出院去向從 3% 到 12%，四倍差距＝強特徵。這就是前頁表格的圖形版

### 先看圖再建模

這兩張圖看完，你已經知道模型大概會抓什麼、能做到多好

### AI Studio

Charts → Box Plot （group by label）；Aggregate 算分組比率後畫 Bar

圖：課程自製（對應本講義案例數據） ★ 原生圖形，可直接在 PowerPoint 編輯

# 類別太多時：頻率編碼（Frequency Encoding）與分組

## 480 個診斷碼的困境

| 主診斷碼 | 出現次數 | One-Hot 的問題 |
|---|---|---|
| I50 心衰竭 | 1,850 | 480 個診斷碼 |
| J18 肺炎 | 1,320 | = 480 個新欄位 |
| N39 泌尿道感染 | 990 | 多數欄位幾乎全 0 |
| E11 第 2 型糖尿病 | 870 | 模型難以學習 |
| ……其餘 476 碼 | 6,970 | 且極易過擬合 |

## 四種出路

| 策略 | 做法 | 結果 |
|---|---|---|
| 頻率編碼（Frequency Encoding） | 以出現次數取代類別 | 1 個數值欄位 |
| 臨床分組 | 按器官系統合併<br>（心血管 / 呼吸 / 泌尿…） | 10–15 個類別 |
| 保留 Top-k | 前 20 碼各自一欄，<br>其餘併入「其他」 | 21 個欄位 |
| 目標編碼（Target Encoding） | 以各碼的再入院率取代 | 威力大，但必須<br>在 CV 內做（洩漏） |

**臨床分組通常最好** — 它注入了領域知識，且每組樣本量足夠、可解釋

**目標編碼（Target Encoding）的警告** — 用整份資料的陽性率＝把答案偷渡進特徵。目標編碼（Target Encoding）必須只在每個 CV 訓練折內估計，必要時做平滑

**檢查** — 編碼後檢查未見資料表現與特徵重要性（Feature Importance）；單一欄位異常突出時，回查時間點、ID 與標籤洩漏

【原講義 ML 3.3】 pp36–41 的 dummy variables 與 binning，延伸到醫療高基數類別的實務處理。

PART 04

# k-NN：最直覺的分類器

k-Nearest Neighbors

它甚至不算「學習」——它只是把訓練資料背起來，
新個案來的時候，看最像的 k 個鄰居怎麼樣。

# 手算： P6 會不會再入院？（k=3）

### 距離計算（Min-Max 正規化後）

| 病人 | 年齡 | 住院天數 | 再入院 | 正規化（年齡，天數） | 距 P6 |
|---|---|---|---|---|---|
| P1 | 55 | 3 | 否 | (0.00, 0.00) | 0.905 |
| P2 | 78 | 9 | 是 | (0.88, 0.75) | 0.262 |
| P3 | 62 | 5 | 否 | (0.27, 0.25) | 0.537 |
| P4 | 81 | 11 | 是 | (1.00, 1.00) | 0.510 |
| P5 | 70 | 7 | 是 | (0.58, 0.50) | **0.147** |
| P6 | 72 | 8 | ? | (0.65, 0.63) | — |

### 不同 k 的判定

| k | 最近鄰 | 票數 | 判定 |
|---|---|---|---|
| 1 | P5 | 是 1:0 | 是 |
| 3 | P5, P2, P4 | 是 3:0 | 是 |
| 5 | 全部 | 是 3:2 | 是 |
| 機率輸出 | k=5 時 | 3/5 | 0.60 |

**步驟** ① 正規化 → ② 算歐氏距離 → ③ 取最近 k 個 → ④ 多數決（Majority Vote）（或算比例當機率）

**為什麼要正規化（Normalization）** 年齡值域 26、天數值域 8。不正規化時年齡獨大，天數形同虛設

**k 的效果** k 小 → 邊界複雜、對雜訊敏感（過擬合）；k 大 → 邊界平滑、可能欠擬合（Underfitting）

**k 怎麼選** 二元硬投票可先試奇數以減少平手；在合理範圍掃描 k，依交叉驗證（Cross-Validation）與業務指標選擇

【原講義 ML 3.3】 pp49–71。距離已實際驗算。 AI Studio： k-NN Operator，記得前面接 Normalize。

# k-NN 工作流程

1

**正規化（Normalization）**

Min-Max 或 Z-Score
訓練集參數

2

**算距離**

新個案對全部
訓練樣本

3

**取 k 個**

距離最近的
k 個鄰居

4

**投票**

多數決（Majority Vote）＝類別
比例＝機率

5

**調 k**

掃一排 k 值
交叉驗證（Cross Validation）選

【原講義 ML 3.3】 p62。第一步忘了做，整個模型等於只看值域最大的那個特徵——這是 k-NN 最常見的死法。

# k 值的過擬合（Overfitting）曲線

**k 從 1 掃到 101**

| k | 訓練 Accuracy | CV 驗證 Accuracy | 診斷 |
|---|---|---|---|
| 1 | **1.000** | 0.71 | 嚴重過擬合 |
| 5 | 0.89 | 0.78 | 仍偏複雜 |
| 15 | 0.84 | **0.82** | ★ 甜蜜點附近 |
| 31 | 0.82 | 0.81 | 開始欠擬合（Underfitting） |
| 101 | 0.76 | 0.74 | 太平滑 |

**判讀**

| 現象 | 原因 |
|---|---|
| k=1 訓練必為 1.0 | 每個點最近的鄰居是它自己 |
| k 增大訓練分數降 | 邊界越來越平滑，記不住雜訊 |
| 測試分數先升後降 | 偏誤（Bias）- 變異（Variance）取捨的標準形狀 |
| 選 k 的方法 | 測試（CV）分數最高點 |

**k=1 的教訓** 訓練分數 100% 毫無意義——它只是記憶，不是學習

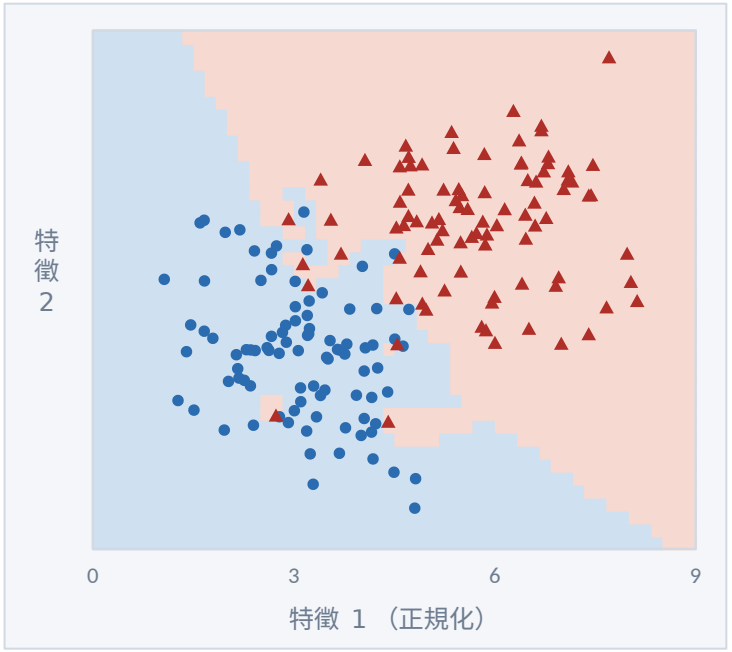
**與多項式次數同構** M2-1 的九次多項式、這裡的 k=1，都是同一個過擬合故事

**AI Studio** Optimize Parameters (Grid) 包住 CV，掃 k 的範圍

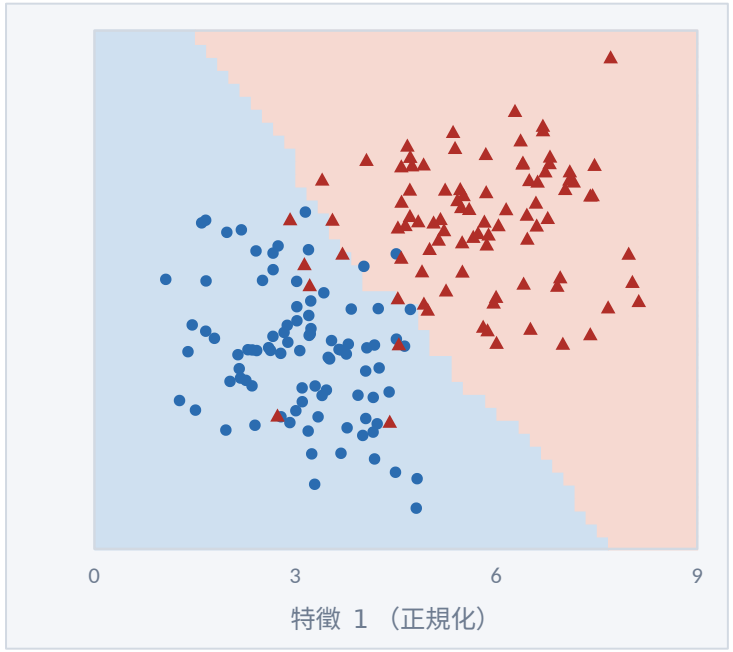
【原講義 ML 3.3】 pp70–74

# 實例： k 值如何改變 k-NN 的邊界

左・k = 1　邊界破碎（記住每一筆）




右・k = 15　邊界平滑（學到型態）




● 未再入院　　▲ 再入院　　底色＝模型判定的類別區域

兩張圖的資料點完全相同，只有 k 換了。左圖為了遷就幾個落在對方陣營的點，在邊界上挖出一個個小島——那些小島就是過擬合的長相。

圖：課程自製（模擬二維資料， 180 筆）　★ 原生圖形，可直接在 PowerPoint 編輯

**左・k=1**

邊界破碎、圍著單一樣本畫小圈圈——訓練分數 100%，但那是記憶不是學習

**右・k=15**

邊界平滑，個別雜訊點被多數鄰居稀釋——泛化能力較好

**對應前頁的表**

k 掃描表的 0.71 → 0.82，就是從左圖走到右圖的過程

**紅三角＝再入院**

注意兩群交界處：那裡的個案本來就難分，任何模型都一樣

# 距離的三種算法

| 距離 | 公式概念 | 特性 | 適用 |
| --- | --- | --- | --- |
| **歐氏**<br>**Euclidean** | 直線距離<br>$\sqrt{\Sigma(\text{差})^2}$ | 最直覺的預設；<br>大差異被平方放大 | 一般數值特徵<br>（正規化後） |
| **曼哈頓**<br>**Manhattan** | 沿座標軸走<br>$\Sigma\lvert\text{差}\rvert$ | 對單一特徵的極端差<br>較不敏感 | 含離群值（Outlier）、<br>高維度時較穩 |
| **餘弦**<br>**Cosine** | 夾角相似度 | 只看方向不看長度 | 文字向量（M6）、<br>就醫「型態」比較 |

AI Studio： k-NN 的 measure types 參數。醫療上的例子：比較兩位病人的「用藥組合型態」用餘弦；比較「檢驗值」用歐氏。

# k-NN 的優缺點

## 優點

- 概念最直覺，向任何人都解釋得通
- 不假設資料形狀——彎的邊界也抓得到
- 天生支援多元分類
- 沒有訓練時間（直接背資料）
- 新資料加入即刻生效，不需重訓

## 缺點

- 預測慢：每次都要算與全部訓練資料的距離
- 資料量大時記憶體與速度都是問題
- 維度高時距離失去意義（維度詛咒）
- 對不相關特徵敏感——垃圾欄位會污染距離
- 可解釋性弱：只能說「跟這幾個人像」，說不出為什麼

【原講義 ML 3.3】 p80。定位： k-NN 是很好的「第二意見」與基準線，但很少作為醫療場域的最終部署模型。

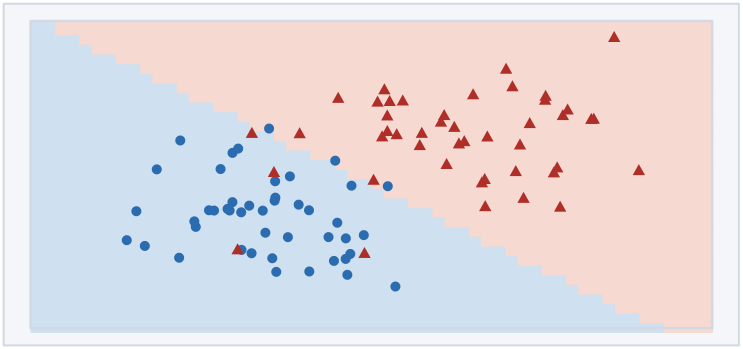
# 五種模型的決策邊界（Decision Boundary）長相

| 模型 | 邊界形狀 | 代表什麼 | 抓得到彎的關係嗎 |
|---|---|---|---|
| **Logistic** | 一條直線（超平面） | 特徵的線性加權 | 不行（除非手動加多項式） |
| **k-NN** | 不規則、貼著資料 | 局部多數決（Majority Vote） | 可以，但邊界破碎 |
| **Naive Bayes** | 平滑曲線 | 各類別的機率分布交界 | 部分（依分布假設） |
| **決策樹（Decision Tree）** | 軸平行的階梯 | 一連串單變數切分 | 可以，但斜線要切很多刀 |
| **隨機森林（Random Forest）** | 平滑化的階梯 | 數百棵樹的平均 | 可以，且較平滑 |

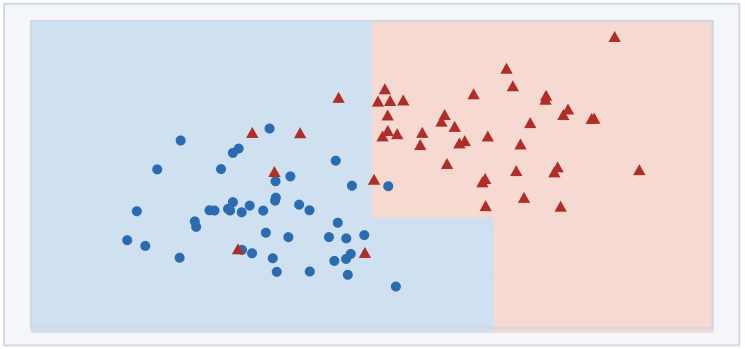
【原講義 ML 3.3】各演算法章節的邊界圖總結。直覺：資料的真實邊界長什麼樣，決定哪個模型天生佔優——這就是「沒有免費午餐」定理的日常版。

# 實例：四種模型，四種邊界

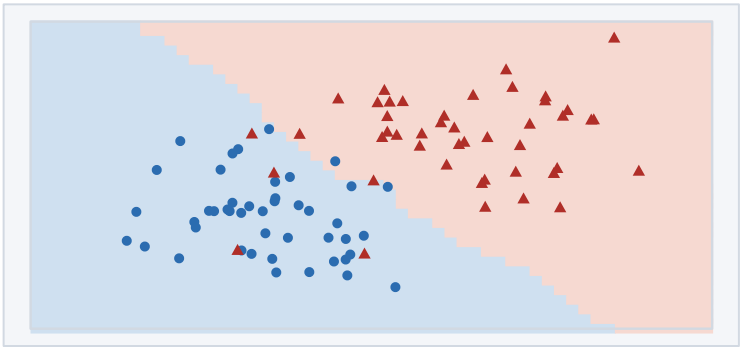
① Logistic：一條直線



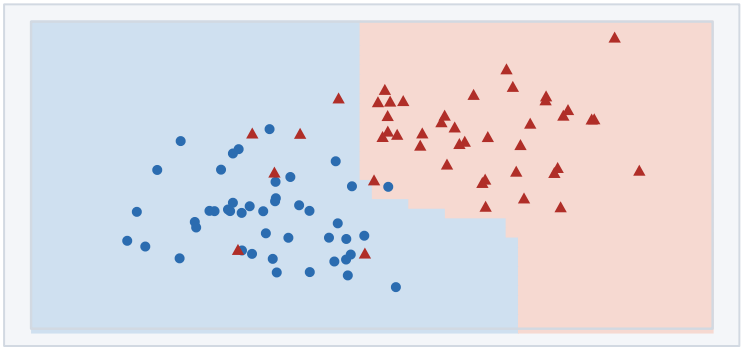
② 決策樹：軸平行的階梯



③ k-NN (k=15)：貼著資料的曲線



④ 隨機森林：平滑化的階梯



● 未再入院　▲ 再入院　底色＝該模型判定的類別區域（同一份資料、同一組座標）

**Logistic**

一條直線。簡潔、可解釋，但斜的彎的都只能用這一條直線近似

**決策樹（Decision Tree）**

軸平行的階梯——每一刀都只問一個特徵

**k-NN**

貼著資料的曲線邊界，交界處最忠實也最容易受雜訊影響

**隨機森林（Random Forest）**

把樹的階梯平均成較平滑的邊界——這就是集成的效果

圖：課程自製（同一份模擬資料）　★ 原生圖形，可直接在 PowerPoint 編輯

PART 05

# Logistic 迴歸

## Logistic Regression

醫學文獻出現頻率最高的模型。

優勢不只在效能，更在係數（Coefficient）可轉成勝算比（Odds Ratio, OR），便於溝通條件關聯。

# Sigmoid：把任意數字壓成機率

### Sigmoid 數值表

| 線性組合 z | $p = 1/(1+e^{-z})$ | 判定（門檻 0.5） |
|---|---|---|
| −4 | 0.018 | 陰性 |
| −2 | 0.119 | 陰性 |
| −1 | 0.269 | 陰性 |
| 0 | 0.500 | 邊界 |
| +1 | 0.731 | 陽性 |
| +2 | 0.881 | 陽性 |
| +4 | 0.982 | 陽性 |

### 四個性質

| 性質 | 意義 |
|---|---|
| S 型曲線 | 中段陡、兩端平 |
| z=0 對應 p=0.5 | 線性組合的 0 就是決策邊界（Decision Boundary） |
| 中段最敏感 | 邊界附近的個案，特徵的微小變動（Small Changes）影響較大 |
| 兩端飽和 | z 很大之後再增加，機率幾乎不動 |
| 對稱 | $p(z) = 1 - p(-z)$ |

**整個模型** $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots$，然後 $p = \text{sigmoid}(z)$

**訓練目標** 最大概似（Maximum Likelihood）：找一組 β 讓「實際發生的事」機率最大（原講義 pp97–103 的數學，此處只需直覺）

**決策邊界（Decision Boundary）** $p=0.5 \Leftrightarrow z=0 \Leftrightarrow$ 一條直線（超平面）。所以 Logistic 的邊界是直的

**邊界是直的** 代表它抓不到彎的關係——需要彎的邊界時考慮樹或 k-NN

【原講義 ML 3.3】 pp84–96。數值已驗算。原講義用 14 頁推導概似函數（pp90–103），本課程略過推導、直接用結論。

# 係數（Coefficient）→ 勝算比（Odds Ratio, OR）：醫學文獻的通用語言

**模型輸出**

| 變數 | 係數 β | p 值 |
|---|---|---|
| 年齡（每 1 歲） | +0.045 | <0.001 |
| 糖尿病（有 =1） | +0.693 | <0.001 |
| 性別（女 =1） | −0.105 | **0.460** |

**勝算比**

| 變數 | OR = e^β | 解讀 |
|---|---|---|
| 年齡 +1 歲 | 1.046 | 勝算（Odds） +4.6% |
| 年齡 +10 歲 | 1.568 | 勝算（Odds） +56.8% |
| 糖尿病 | 2.000 | 勝算為 2 倍 |
| 性別（女） | 0.900 | p=0.46 不顯著，不應解讀 |

**勝算 odds**

p/(1−p)。機率 0.5 = 勝算 1；機率 0.75 = 勝算 3

**為什麼是 e^β**

Logistic 對「勝算的對數」做線性迴歸（Linear Regression），所以 β 取指數＝勝算比

**連續變數換算**

每 k 單位：OR = e^(k×β)。年齡 10 歲 = e^0.45 = 1.568

**OR ≠ RR**

事件常見時 OR 會誇大相對風險——醫學文獻解讀的常見誤區

【原講義 ML 3.3】 pp110–111

# Logistic 迴歸工作流程

1

**編碼與縮放**

類別→虛擬變數（Dummy Variable）
數值標準化（Standardization）

2

**擬合**

最大概似（Maximum Likelihood）估計
得到係數（Coefficient） β

3

**檢定**

看 p 值與信賴區間

4

**轉勝算比（Odds Ratio, OR）**

e^β
寫進報告

5

**調門檻**

依代價比（Cost Ratio）
定操作點

【原講義 ML 3.3】 p107

# 正則化（Regularization）強度的選擇（Logistic + Ridge）

### λ 的掃描結果

| λ（懲罰） | 訓練 AUC | CV AUC | 係數（Coefficient）的樣子 |
|---|---|---|---|
| 0（無） | 0.87 | 0.79 | 幾個係數極大，共線性（Collinearity）原形畢露 |
| 0.01 | 0.86 | 0.81 | 略收縮 |
| 0.1 | 0.84 | **0.83** | ★ CV 最高 |
| 1.0 | 0.80 | 0.80 | 明顯壓扁 |
| 10 | 0.72 | 0.71 | 全被壓向 0，欠擬合（Underfitting） |

### 四個原則

| 原則 | 說明 |
|---|---|
| 先標準化（Standardization） | 懲罰才公平 |
| 掃 λ + CV | 選 CV 分數最高 |
| 訓練分數必降 | 這是正常的、刻意的犧牲 |
| 醫學報告注意 | 正則化（Regularization）後的係數不宜直接當 OR 解讀 |

**最後一點很重要**

正則化把係數往 0 拉，OR 因此被系統性低估。要報告 OR 就用未正則化的版本

**兩個模型並用**

解釋用無正則化的 Logistic；預測用正則化調到最好的版本——目的不同，模型可以不同

【原講義 ML 3.3】 pp114–120

# 正則化（Regularization）與多元分類

## Logistic 也需要正則化（Regularization）

- 變數多、樣本少或近乎完美可分時，係數可能不穩，正則化可抑制極端值
- L2 （Ridge）收縮係數； L1 （Lasso）可讓部分係數為 0
- 強度 C 或 λ 用交叉驗證（Cross Validation）選；正則化前必須標準化（與迴歸篇相同）

## 多元分類的兩種策略

- One-vs-Rest： k 類拆成 k 個「這類 vs 其他」的二元問題，取機率最高者
- Softmax （多項 Logistic）： 直接輸出 k 類機率，總和為 1
- AI Studio 的 Logistic Regression 遇到多元標籤時自動處理，但你要知道它在做什麼

## 優缺點小結

- 優點：可輸出機率、係數可轉 OR 、訓練快
- 缺點：決策邊界是直的；特徵工程（Feature Engineering）的品質決定它的上限
- 定位：★ 幾乎永遠應該是你的第一個正式模型——它就是分類問題的基準線

【原講義 ML 3.3】 pp114–124

# Logistic 也有假設：logit 的線性

## 假設內容

- Logistic 假設「勝算的對數」與每個連續特徵呈線性關係
- 年齡 40→50 與 70→80 對 log-odds 的影響被假設一樣大——臨床上未必

## 怎麼檢查

- 把連續特徵分箱（如年齡每 10 歲一組），各組跑出的係數（Coefficient）畫起來看是否近似直線
- 若呈 U 型或閾值型（過了某點才有影響），線性假設就不成立

## 怎麼處理

- 加多項式項（年齡$^2$）、分箱後當類別、或用受限三次樣條
- 或者換模型：樹系天生不需要這個假設
- 報告中處理過要說明——這是 OR 解讀是否可信的前提

【原講義 ML 3.3】 pp112–113 的 feature engineering for logistic。與 M2-1 的迴歸假設一脈相承。

# 多元分類：檢傷分級的例子（3 類示意）

### Softmax 輸出

| 個案 | P(1 級) | P(2 級) | P(3 級) | 判定 |
|---|---|---|---|---|
| A | 0.72 | 0.20 | 0.08 | 1 級 |
| B | 0.15 | 0.55 | 0.30 | 2 級 |
| C | 0.05 | 0.42 | 0.53 | 3 級 |
| D | **0.33** | **0.35** | **0.32** | 2 級（勉強） |

### 多元策略

| 策略 | 做法 |
|---|---|
| One-vs-Rest | k 類拆 k 個二元模型，取機率最高 |
| Softmax | 直接輸出 k 類機率，總和為 1 |
| 有序類別 | 檢傷 1<2<3 有順序：差兩級比差一級嚴重 |
| 有序的做法 | 累積 Logit 模型，或至少在評估時計權重 |

**個案 D 的警訊**　三類機率 0.33/0.35/0.32—— 模型其實不知道。這種個案應轉人工判斷

**Hard 分類會隱藏這件事**　只輸出「2 級」的話，你永遠不知道它有多沒把握

**實務設計**　訂一個「最高機率須超過門檻」的規則，不到門檻就進人工佇列

【原講義 ML 3.3】 pp121–123、145–152

PART 06

# Naive Bayes

單純貝氏

它做了一個明知是錯的假設——特徵彼此獨立。
但這個錯的假設，讓它快得離譜，而且常常夠用。

# 手算：症狀組合的機率判定

### 訓練資料的條件機率

| | 發燒 | 咳嗽 | 流感（10 人） | 非流感（90 人） |
|---|---|---|---|---|
| 有發燒 | — | — | 8/10 | 18/90 |
| 有咳嗽 | — | — | 7/10 | 27/90 |
| 先驗機率 | — | — | 10/100 | 90/100 |

### 新病人（發燒＋咳嗽）

| 步驟 | 流感 | 非流感 |
|---|---|---|
| 先驗 | 0.10 | 0.90 |
| ×P( 發燒 \| 類 ) | ×0.80 | ×0.20 |
| ×P( 咳嗽 \| 類 ) | ×0.70 | ×0.30 |
| 分數 | **0.056** | 0.054 |
| 歸一化 | **0.509** | 0.491 |

**Naive 在哪** — 假設「發燒」與「咳嗽」在給定類別下彼此獨立——實際上顯然相關

**為什麼還能用** — 即使機率估不準，「哪一類分數較高」的排序常常還是對的

**流感只贏一點點** — 0.509 vs 0.491—— 先驗 0.10 的劣勢幾乎吃掉了症狀的證據力

**平滑** — 訓練集沒出現過的組合會得到機率 0，需拉普拉斯平滑避免一票否決

數字為教學設計、已驗算。 AI Studio： Naive Bayes Operator 。它常是快速基準，但分布假設、平滑與機率校準仍需驗證。

# Naive Bayes 的定位

## 強項

- 訓練與預測都極快，資料再大也不怕
- 高維資料表現意外地好（文字分類的傳統霸主）
- 小樣本也能運作——不容易過擬合（Overfitting）
- 可輸出機率分數並支援多元分類
- M6 文字探勘會再遇到它

## 弱項

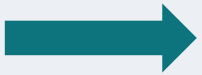
- 獨立假設在特徵高度相關時失真（醫療生理指標常見）
- 輸出的機率值本身不可靠（排序可以，數值別當真）
- 連續特徵需假設分布（通常假設常態）
- 類別組合沒看過就會出問題（需平滑）
- 可解釋性中等：能看各特徵的貢獻，但沒有 OR 那麼直白

【原講義 ML 3.3】。定位：快速基準線與文字類問題的首選之一；在特徵高度相關的結構化醫療資料上通常不是最終選擇。

# Naive Bayes 的主場：文字分類預告（M6）

### 詞的條件機率

| 詞 | 垃圾郵件中出現率 | 正常郵件中出現率 |
|---|---|---|
| 「免費」 | 0.62 | 0.04 |
| 「中獎」 | 0.45 | 0.01 |
| 「會議」 | 0.03 | 0.38 |
| 「附件」 | 0.18 | 0.22 |

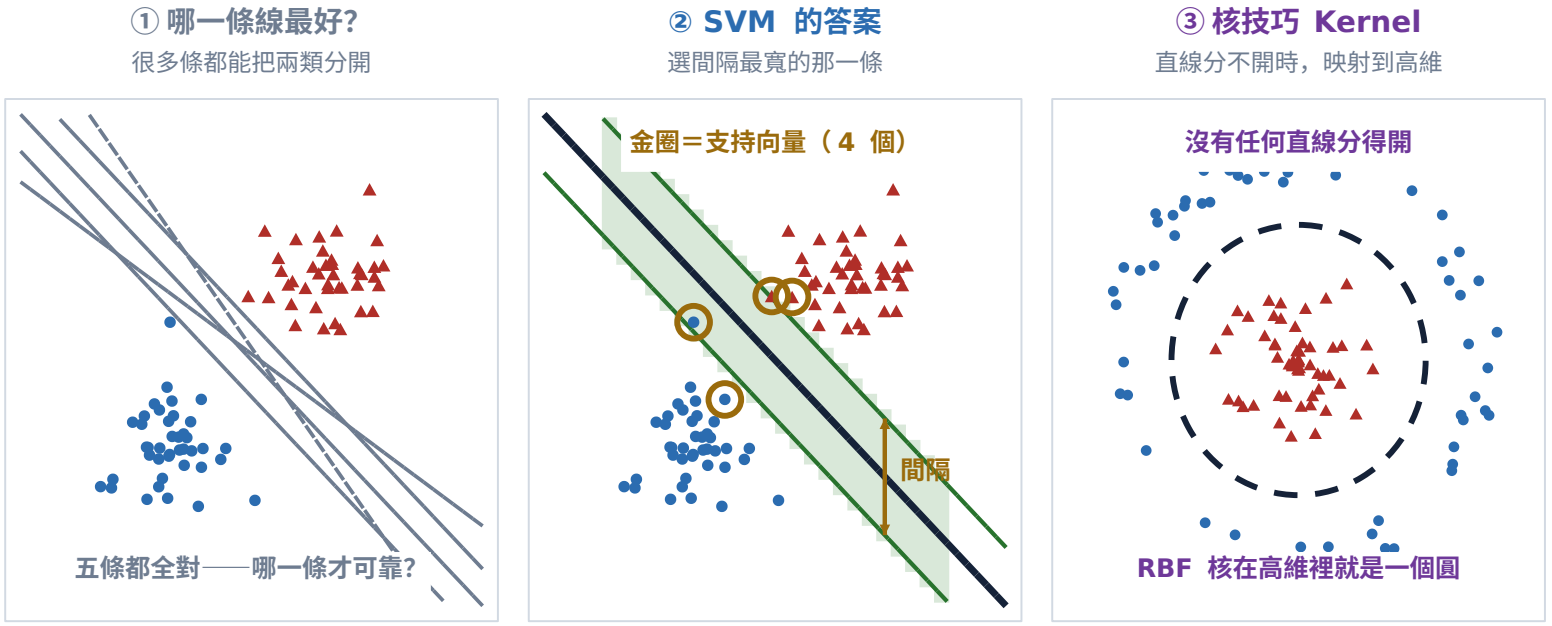


### 高維文字與 NB 的緣分

| 為什麼文字適合 NB | 說明 |
|---|---|
| 維度極高 | 每個詞一個特徵，數萬維很正常 |
| NB 不怕高維 | 逐特徵獨立相乘，維度高也算得快 |
| 獨立假設較無害 | 詞與詞的相關性傷害相對小 |
| M6 見 | Spam 分類實作（Project 6） |

【AI Studio 範例】 4. Case Studies/7. Email Spam classification 將在 M6 使用。這裡先埋個伏筆：本週覺得 NB 平庸，到文字問題它會翻身。

# 支援向量機 SVM：找間隔最寬的那條線




把中間那張圖裡沒被金圈圈起來的 76 個點全部刪掉，重跑 SVM，會得到一模一樣的線——這就是「支持向量」這個名字的來源，也是它在高維小樣本仍站得住的原因。

### ① 問題

能把兩類分開的直線有無限多條。哪一條在新資料上最可靠?

### ② SVM 的答案

選「離最近的點最遠」的那條——間隔（Margin）最寬

### 支持向量

只有金圈那幾個點決定了這條線。其餘的點刪掉也不影響結果

### ③ 核技巧

資料不是直線可分時，映射到高維空間再找超平面。常用 RBF 核

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# SVM 的參數與定位

## 兩個關鍵參數

- C （懲罰強度）：容忍多少樣本落在間隔內或分錯
- C 大 → 硬邊界、追求全對、容易過擬合
- C 小 → 軟邊界、容忍少數錯誤、泛化較好
- kernel （核函數）： linear / polynomial / RBF （radial basis function）
- 線性關係用 linear；不確定時 RBF 是安全的預設
- gamma （RBF 專用）：控制單一樣本的影響範圍，大則邊界複雜

## 什麼時候用 SVM

- 特徵數多、樣本數中等（幾百到幾千）時表現很好
- 高維資料（如文字向量）的傳統強項
- 必須正規化——它靠距離運作
- 缺點：樣本量大時訓練慢；機率輸出需額外校準
- 缺點：可解釋性差，說不出「為什麼是這個病人」
- 醫療定位：效能候選之一，但通常不是最終部署的模型

AI Studio： Support Vector Machine Operator （另有 SVM (LibSVM) 版本支援多種核）。前面務必接 Normalize。

# 判別分析 LDA / QDA：醫學統計的老朋友

## 線性判別分析 LDA

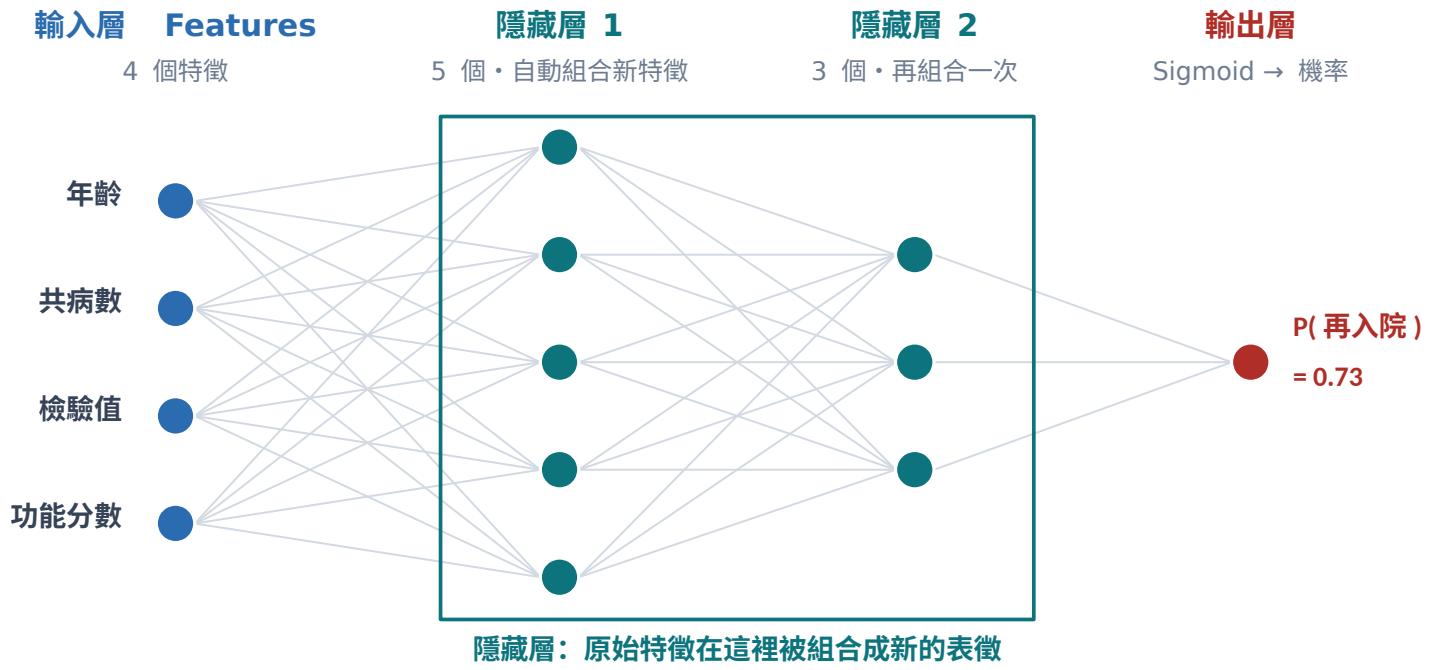
- 假設各類別近似常態且共用共變異數矩陣
- 在此假設下，決策邊界是一條直線（與 Logistic 類似但推導不同）
- 優點：樣本少時比 Logistic 穩定；可同時做降維
- 醫學文獻中歷史悠久，常見於診斷分類研究
- AI Studio： Linear Discriminant Analysis Operator

## 二次判別分析 QDA

- 放寬假設：允許各類別有不同的共變異數矩陣
- 決策邊界變成曲線（二次曲面）
- 更彈性，但需要更多樣本才估得準
- 類別間變異差異大時（如健康組與重症組）較合適
- AI Studio： Quadratic Discriminant Analysis Operator

與 Logistic 的分工： LDA 假設較強（常態、等共變異），成立時效率較高； Logistic 假設較弱、較穩健，且能直接給勝算比——這是它在現代醫學文獻勝出的主因。

# 神經網路 MLP：分類器的一種




每一條灰線都是一個權重。本圖共 4×5 + 5×3 + 3×1 = 38 條權重線（另有 9 個偏權值 bias）。

訓練就是反覆調整這 38 個數字，讓預測與實際的差距最小（反向傳播）。問題也在這裡：這 38 個數字沒有一個能被翻譯成「勝算比 2.1 倍」那樣的臨床語言。

### 結構

輸入層（Features）→ 一到多個隱藏層 → 輸出層；二元常用 Sigmoid，多元互斥分類常用 Softmax

### 隱藏層在做什麼

自動把原始特徵組合成新的表徵——這是它與其他方法最大的差別

### 訓練

找出全部權重，讓預測與實際的差距最小（反向傳播）

### 與 M5 的關係

本週把它當成「另一個分類器」；M5 深度學習會深入層數、Dropout、過擬合

圖：課程自製 ★ 原生圖形，可直接在 PowerPoint 編輯

# 神經網路作為分類器：現實的評估

| 面向 | 狀況 | 對你的意義 |
| --- | --- | --- |
| **表格資料上的表現** | 在許多中小型結構化資料上，樹提升或隨機森林常很有競爭力；仍須以同一切分比較 | 不要因為它「聽起來厲害」就選它 |
| **需要的資料量** | 參數多，需要較多樣本才餵得飽 | 768 筆的 Pima 資料上，它常輸給 Logistic |
| **調參成本** | 層數、每層神經元、學習率、 Epoch 、正則化都要調 | 同樣的時間拿去做特徵工程，報酬通常更高 |
| **可解釋性** | 中間層學到什麼難以解讀 | 醫療高風險場域的明確限制 |
| **真正的優勢** | 影像、語音、文字這類非結構化資料 | M5 的 CNN 與 M6/M7 的 NLP 才是它的主場 |

AI Studio： Neural Net Operator （淺層 MLP ）。作業二（ M5 ）會在同一驗證設計下比較 Logistic 、梯度提升樹與 H2O 深度學習；結論以實際資料為準。

# 其他值得知道的分類演算法

| 演算法 | 核心想法 | 何時考慮 | 本課程 |
| --- | --- | --- | --- |
| **XGBoost / LightGBM / CatBoost** | 梯度提升的高效實作，加上正則化與缺失值處理 | 表格資料競賽的常勝軍；<br>資料量大且追求效能時 | M4 提及；<br>AI Studio 有 GBT |
| **Extra Trees（極端隨機樹）** | 比隨機森林更隨機：切點也隨機選 | 想要更快、變異更低時；<br>常與森林一起比較 | 自學 |
| **Ridge / Lasso Logistic** | 加上 L2 / L1 懲罰的邏輯斯迴歸 | 變數多、共線性嚴重、<br>想自動篩變數時 | 本講義 P5 已含 |
| **規則式模型（RIPPER 等）** | 直接產出 if-then 規則清單 | 需要可直接寫進 SOP 的規則時 | 自學 |
| **最近質心 Nearest Centroid** | 算每類的中心，看新樣本靠近誰 | 極簡基準線；<br>高維小樣本時意外好用 | 自學 |

判斷原則：先用本講義的七個模型建立完整基準線，確認瓶頸在「模型不夠強」而非「特徵不夠好」，再考慮引入更複雜的演算法。

# 隨堂檢核 1 ｜演算法

Q 1

**k-NN 忘了正規化（Normalization），會發生什麼事?**

距離被值域最大的特徵獨占——其他特徵形同虛設。

Q 2

**Logistic 係數 β=1.1 （p<0.001），勝算比（Odds Ratio, OR）是多少? 怎麼用一句話解讀?**

e^1.1 ≈ 3.0 。該因素存在時，事件勝算是不存在時的 3 倍。

Q 3

**Naive Bayes 明知假設是錯的，為什麼還能用?**

它需要的只是「哪類分數高」的排序正確；機率數值本身不必準。

Q 4

**三個模型的訓練 Accuracy 都是 0.95，就能說它們一樣好嗎?**

訓練分數只是記憶力。要比就比交叉驗證（Cross Validation）分數，且附標準差。

PART 07

# 混淆矩陣家族

## The Confusion Matrix Family

整個單元最重要的一節。

六個指標全部來自同一張 2×2 表，但回答的是完全不同的問題。

# 實例：再入院預測（1000 位病人）

### 混淆矩陣（Confusion Matrix）

| | 模型：會 | 模型：不會 | 小計 |
|---|---|---|---|
| 實際：會 | TP = 45 | FN = 15 | 60 |
| 實際：不會 | FP = 60 | TN = 880 | 940 |
| 小計 | 105 | 895 | 1000 |

### 六個指標

| 指標 | 計算 | 值 |
|---|---|---|
| Accuracy | (45+880)/1000 | 0.925 |
| Precision (PPV) | 45/105 | 0.429 |
| Recall（敏感度（Sensitivity）） | 45/60 | 0.750 |
| 特異度（Specificity） | 880/940 | 0.936 |
| NPV | 880/895 | 0.983 |
| F1 | 2PR/(P+R) | 0.545 |

**★ 關鍵** 全判「不會」的 Accuracy = 940/1000 = 0.940 > 模型的 0.925

**這代表什麼** 以 Accuracy 論，模型輸給「什麼都不做」。但它抓到了 45/60 個真陽性

**該看什麼** Recall 0.750（抓到七成五）、Precision 0.429（喊「會」的人四成三是真的）

**成本問題** 攔到 45 個真的，代價是多追蹤 60 個假的。值不值得？——這是臨床決定，不是統計決定

【原講義 ML 3.3】 pp67–69、129–135。這一頁請學生親手算一遍。

# 機器學習 × 醫學用語對照

| ML 用語 | 醫學用語 | 公式 | 回答的問題 |
|---|---|---|---|
| **Recall / TPR** | 敏感度 Sensitivity | TP/(TP+FN) | 真的有病的，抓到幾成? |
| **—** | 特異度 Specificity | TN/(TN+FP) | 沒病的，正確排除幾成? |
| **Precision** | 陽性預測值 PPV | TP/(TP+FP) | 說有病的，幾成真的有? |
| **—** | 陰性預測值 NPV | TN/(TN+FN) | 說沒病的，幾成真的沒有? |
| **FPR** | 1 − 特異度（Specificity） | FP/(FP+TN) | 沒病卻被誤判的比例 |
| **F1** | — | 2PR/(P+R) | P 與 R 的調和平均 |

關鍵區分：敏感度（Sensitivity）與特異度是「模型的性質」，不受盛行率影響（但病人組成不同時仍會變）； PPV 與 NPV 是「部署結果」，隨盛行率（Prevalence）大幅變動——下一頁就是這件事。

# 盛行率（Prevalence）陷阱：同一個模型，兩種結論

**同一模型（敏感度 0.90　特異度 0.95）**

| 部署場域 | 盛行率 | TP | FP | PPV |
|---|---|---|---|---|
| 高風險科別 | 10% | 900 | 450 | 0.667 |
| 社區篩檢 | 1% | 90 | 495 | 0.154 |

**數字拆解**

| | 高風險科別 | 社區篩檢 |
|---|---|---|
| 每萬人患者數 | 1000 | 100 |
| 敏感度 90% 抓到 | 900 | 90 |
| 特異度 95% 誤判 | 450 | 495 |
| PPV | 66.7% | **15.4%** |
| 意義 | 可作初篩 | 誤報是真陽性的 5 倍 |

**模型沒變**　敏感度、特異度完全相同。變的只有部署場域的盛行率

**PPV 為何崩**　盛行率 1% 時健康人是病人的 99 倍；就算只誤判 5%，絕對數量仍碾壓真陽性

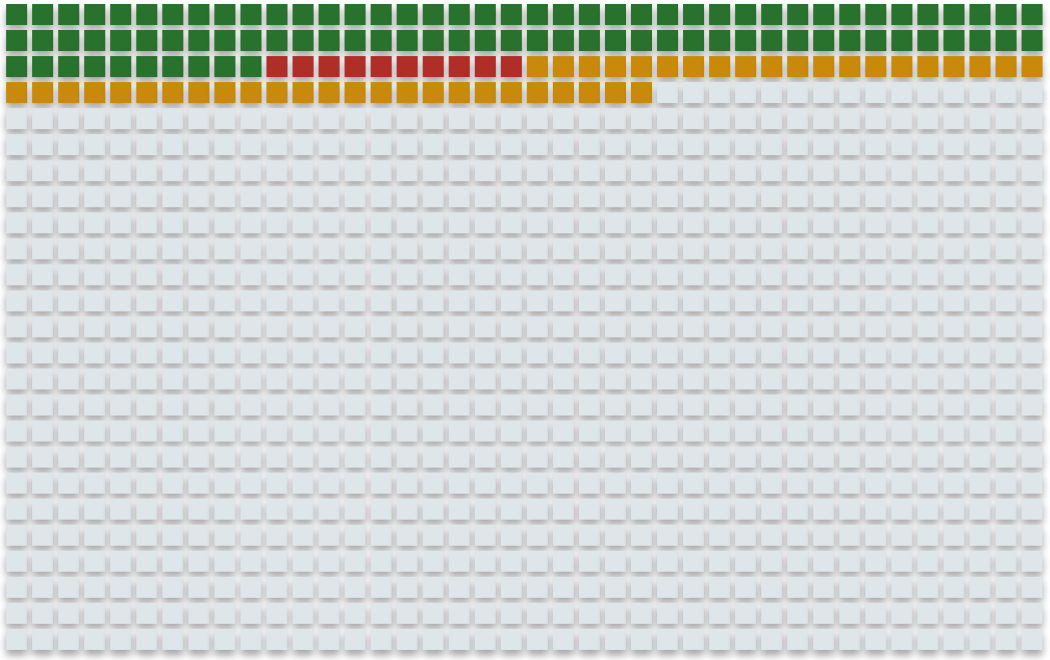
**教訓**　醫院驗證良好的模型直接推到社區，會製造大量無謂的複檢與焦慮

**該做什麼**　依部署場域重估 PPV；提高門檻；或兩階段篩檢

這是醫療 AI 落地最常見的失敗模式。專題涉及篩檢者，必須在報告中說明目標場域的盛行率。

# 實例：每 1,000 人裡，誰被喊陽性?

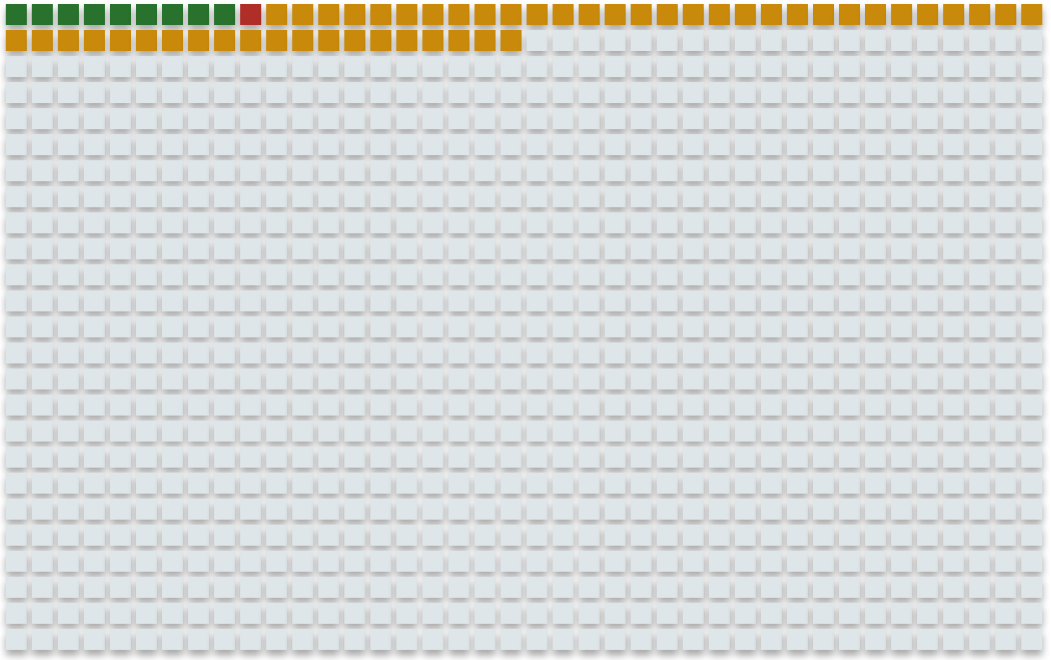
**高風險科別　盛行率 10%**



**真陽性 90　漏掉 10　誤報 45　PPV = 90/(90+45) = 66.7%**

被喊陽性的人裡，三個有兩個真的有事

**社區篩檢　盛行率 1%**



**真陽性 9　漏掉 1　誤報 50　PPV = 9/(9+50) = 15.4%**

被喊陽性的 59 人裡，只有 9 個真的有事——誤報是真陽性的 5.6 倍

同一個模型（敏感度 0.90、特異度 0.95），只換部署場域。每一格是一個人，綠＝真陽性、紅＝漏掉、黃＝誤報、灰＝真陰性。專題若涉及篩檢，報告必須寫出目標場域的盛行率。

# F1：什麼時候調和平均有意義

### 三個模型的比較

| 模型 | Precision | Recall | 算術平均 | F1 |
|---|---|---|---|---|
| A | 0.50 | 0.50 | 0.50 | 0.500 |
| B | 0.90 | 0.10 | **0.50** | **0.180** |
| C | 0.70 | 0.30 | 0.50 | 0.420 |

### F1 的性質

| 性質 | 說明 |
|---|---|
| 調和平均懲罰失衡 | B 的算術平均也是 0.5，但 F1 只有 0.18 |
| 兩者都要好 | F1 高 ⇔ P 與 R 同時高 |
| 何時用 F1 | 兩種錯誤代價相近時 |
| 何時不用 | 代價比（Cost Ratio）懸殊時——直接用加權成本更誠實 |

**B 的故事**

高 Precision、低 Recall—— 只喊最有把握的，漏掉九成。算術平均看不出這有多糟

**醫療場域提醒**

漏診與誤報的代價通常不相等， F1 的「平等對待」未必合適——它是方便的單一數字，不是萬用的

【原講義 ML 3.3】 p135

# 多元分類的混淆矩陣（Confusion Matrix）（3×3）

### 檢傷三級的混淆矩陣（Confusion Matrix）

| 實際 \ 預測 | 1 級 | 2 級 | 3 級 | Recall |
|---|---|---|---|---|
| 1 級（60） | 48 | 10 | **2** | 0.80 |
| 2 級（100） | 12 | 76 | 12 | 0.76 |
| 3 級（40） | 2 | 10 | 28 | 0.70 |
| Precision | 0.77 | 0.79 | 0.67 | |

### Micro vs Macro

| 彙整方式 | 計算 | 值 |
|---|---|---|
| Micro-F1 | 全部 TP/( 全部 ) | 0.76 |
| Macro-F1 | 三類 F1 取平均 | 0.75 |
| 差異 | Micro 被大類主導；<br>Macro 每類平權 | |
| 有序性 | 1 級被判 3 級（2 例）<br>比判 2 級嚴重——<br>必要時用加權懲罰 | |

**對角線是對的**

48+76+28=152/200=0.76 整體正確率

**小類別優先看 Macro**

若 3 級是最危險的病人，它的 Recall 0.70 才是重點，別讓大類的好成績蓋過去

**報告要求**

多元分類一律附完整混淆矩陣，不能只給一個數字

【原講義 ML 3.3】 pp145–153。數字已驗算（行列合計一致）。

PART 08

# ROC、PR 曲線與門檻

ROC, PR & Thresholds

模型輸出的是機率，門檻才決定判成哪類。
一條曲線，就是把所有可能的門檻一次看完。

# 兩條曲線怎麼選

## ROC 曲線（FPR vs TPR）

- 掃過所有門檻，畫偽陽性率（FPR）對真陽性率（TPR）
- ROC-AUC 可解讀為隨機一正一負時，正例分數較高的機率
- 0.5 隨機；0.7–0.8 尚可；0.8–0.9 良好；>0.95 先查洩漏
- 與門檻無關 → 適合「比較模型」
- 極度不平衡時過度樂觀（TN 太多把 FPR 壓低）

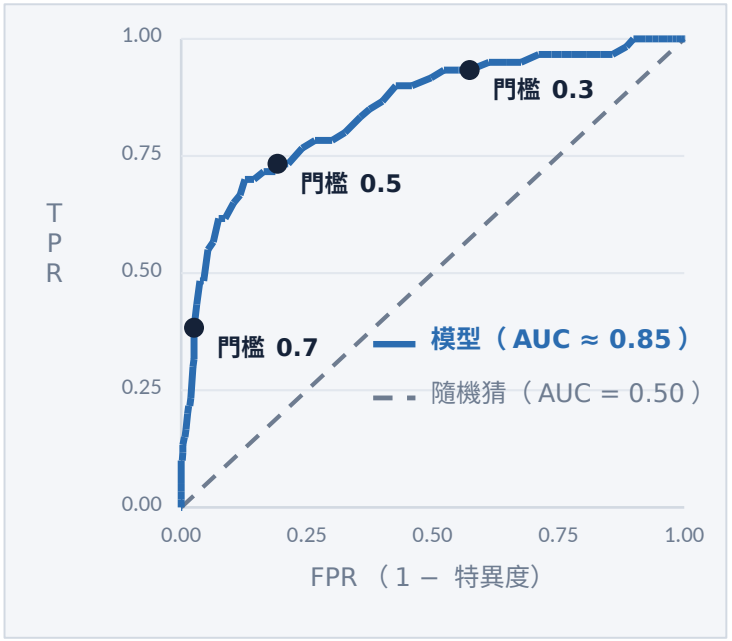
## PR 曲線（Recall vs Precision）

- 同樣掃門檻，但完全不看 TN
- 不被龐大負類稀釋 → 極度不平衡時更誠實
- 基準線是「正類比例」不是 0.5
- 適合「決定門檻」：在曲線上選操作點
- 盛行率 <5% 的問題，優先看 PR

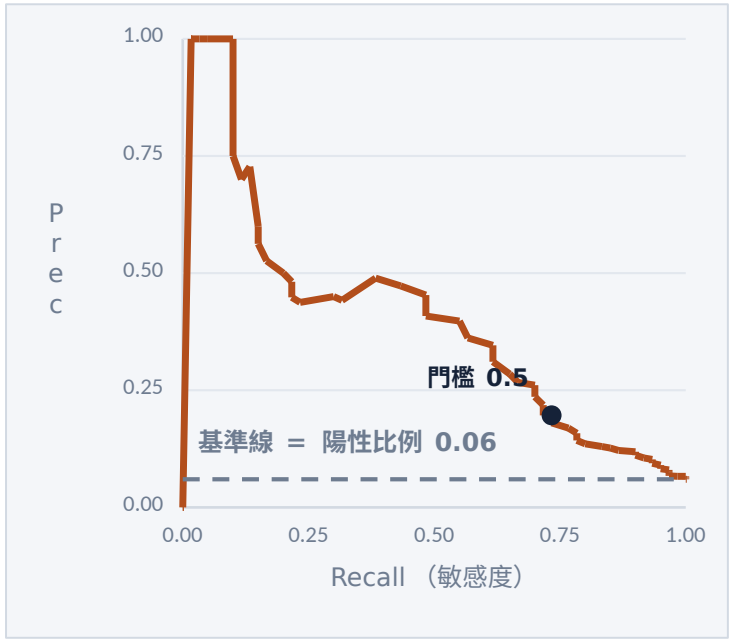
【原講義 ML 3.3】 pp140–144。實務：兩條都畫。ROC 選模型，PR 定門檻。AI Studio： Compare ROCs 可多模型疊圖。

# 實例： ROC 與 PR 曲線（6% 陽性的資料）

左・ ROC　每個門檻是曲線上一點




右・ PR　不平衡資料更誠實




同一個模型、同一批分數，只是換了兩個軸。 ROC 的基準是 0.50， PR 的基準只有 0.06—— 在 6% 陽性的資料裡，「喊中的比例」有多難拉高，只有右圖看得出來。

**左・ ROC**

三個黑點＝三個門檻。整條曲線就是把所有門檻掃一遍

**AUC≈0.85**

隨機抽一正一負，模型給正例較高分的機率

**右・ PR**

同一個模型。注意基準線是 0.06 不是 0.5 —— 不平衡資料的誠實視角

**兩張一起看**

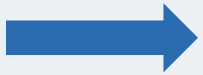
ROC 選模型、 PR 定門檻。只看 ROC 會高估不平衡場景的實用性

圖：課程自製（60 陽性 / 940 陰性）　★ 原生圖形，可直接在 PowerPoint 編輯

# ROC 曲線是怎麼畫出來的

### 門檻掃描 → 座標點

| 門檻 | TP | FP | TPR (y 軸) | FPR (x 軸) |
|---|---|---|---|---|
| 0.9 | 10 | 2 | 0.17 | 0.002 |
| 0.7 | 28 | 18 | 0.47 | 0.019 |
| 0.5 | 45 | 60 | 0.75 | 0.064 |
| 0.3 | 54 | 165 | 0.90 | 0.176 |
| 0.1 | 59 | 470 | 0.98 | 0.500 |



### 曲線的讀法

| 讀法 | 說明 |
|---|---|
| 每個門檻＝一個點 | 門檻從 1 掃到 0 |
| 左下 → 右上 | 門檻越低越往右上走 |
| 對角線 | 隨機猜的軌跡 |
| AUC | 曲線下面積；本例約 0.85 |
| 越靠左上越好 | 同樣 TPR 用更少 FPR 換到 |

**一條曲線＝全部門檻**　這就是「AUC 與門檻無關」的原因——它把所有門檻一次算完

**部署時只取一點**　曲線上你只會活在一個點上。 AUC 高但你選的那點差，一樣沒用

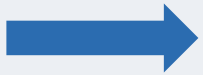
**與 P8 門檻表的關係**　那張表就是這條曲線的其中四個點

【原講義 ML 3.3】 pp142–144

# 門檻調整的實際效果（同一模型）

四個門檻的混淆矩陣（Confusion Matrix）

| 門檻 | TP | FN | FP | TN |
|---|---|---|---|---|
| 0.7 | 28 | 32 | 18 | 922 |
| 0.5 | 45 | 15 | 60 | 880 |
| 0.3 | 54 | 6 | 165 | 775 |
| 0.2 | 58 | 2 | 310 | 630 |



對應的取捨

| 門檻 | Recall | Precision | 適用情境 |
|---|---|---|---|
| 0.7 | 0.467 | 0.609 | 資源極少，只追最確定的 |
| 0.5 | 0.750 | 0.429 | 預設值（沒有理由的預設） |
| 0.3 | 0.900 | 0.247 | 漏掉的代價高 |
| 0.2 | 0.967 | 0.158 | 幾乎不能漏（如敗血症警示） |

**規律** — 門檻降 → Recall 升、Precision 降。你在用誤報買回漏網之魚

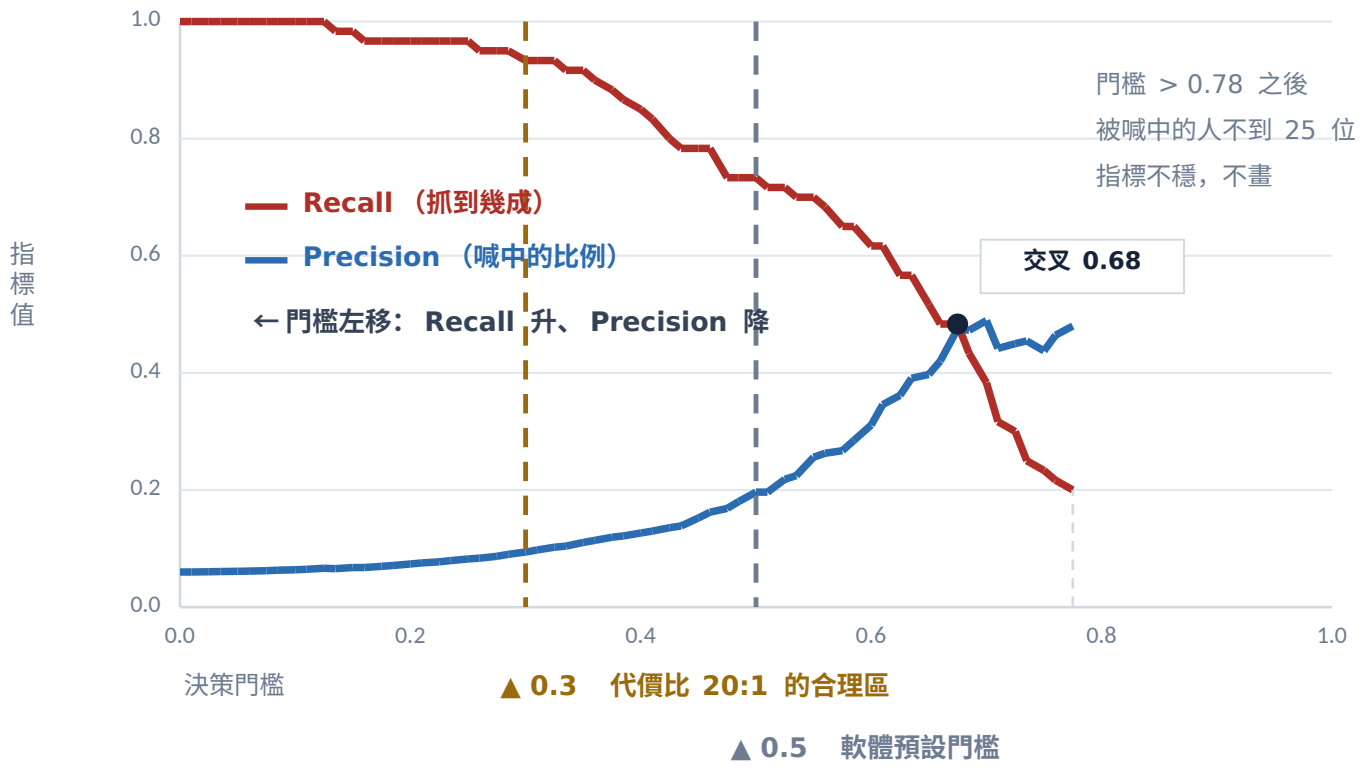
**怎麼決定** — 先估代價比（Cost Ratio）：漏一個真陽性 = 幾個偽陽性的成本？代價比（Cost Ratio） 10:1 就往低門檻走

**誰決定** — 代價比是臨床 / 管理判斷，不是資料科學家自己決定的

**AI Studio** — Find Threshold + Apply Threshold；門檻最佳化應放在驗證／CV 內，選定後才在最終測試集評估

【原講義 ML 3.3】 pp157–161。0.5 只是軟體預設，不是自然法則——這是本單元最重要的一句話。

# 實例：門檻左移，用 Precision 買 Recall




從 0.5 移到 0.3： Recall 由 0.73 升到 0.93 （多抓到 12 位）， Precision 由 0.20 掉到 0.09。這筆交易划不划算，由代價比決定，不是由軟體決定。

### 兩條線的交叉

門檻往左：紅線（ Recall ）升、藍線（ Precision ）降——沒有免費的午餐

### 灰色虛線 0.5

軟體預設。它不知道你的場域漏一個要付什麼代價

### 金色虛線 0.3

代價比（ Cost Ratio ） 20:1 時的合理區——對應後頁期望成本表的計算

### 報告要求

選定門檻時，把這張圖與代價比（ Cost Ratio ）假設一起放進報告

圖：課程自製（同 ROC 頁模型） ★ 原生圖形，可直接在 PowerPoint 編輯

# 用期望成本直接選門檻

## 各門檻的期望成本（代價比 10:1）

| 門檻 | FN 數 | FP 數 | FN 成本 ×10 | FP 成本 ×1 | 總成本 |
|---|---|---|---|---|---|
| 0.7 | 32 | 18 | 320 | 18 | 338 |
| 0.5 | 15 | 60 | 150 | 60 | **210** |
| 0.3 | 6 | 165 | 60 | 165 | 225 |
| 0.2 | 2 | 310 | 20 | 310 | 330 |

## 設定與結論

| 設定 | 說明 |
|---|---|
| 代價比 10:1 | 漏一個再入院的代價 = 10 次無效追蹤 |
| 最低成本 | 門檻 0.5 附近（本例恰巧） |
| 代價比改 20:1 | 最佳門檻會往 0.3 移 |
| 重點 | 門檻跟著代價比走，不是跟著 Accuracy 走 |

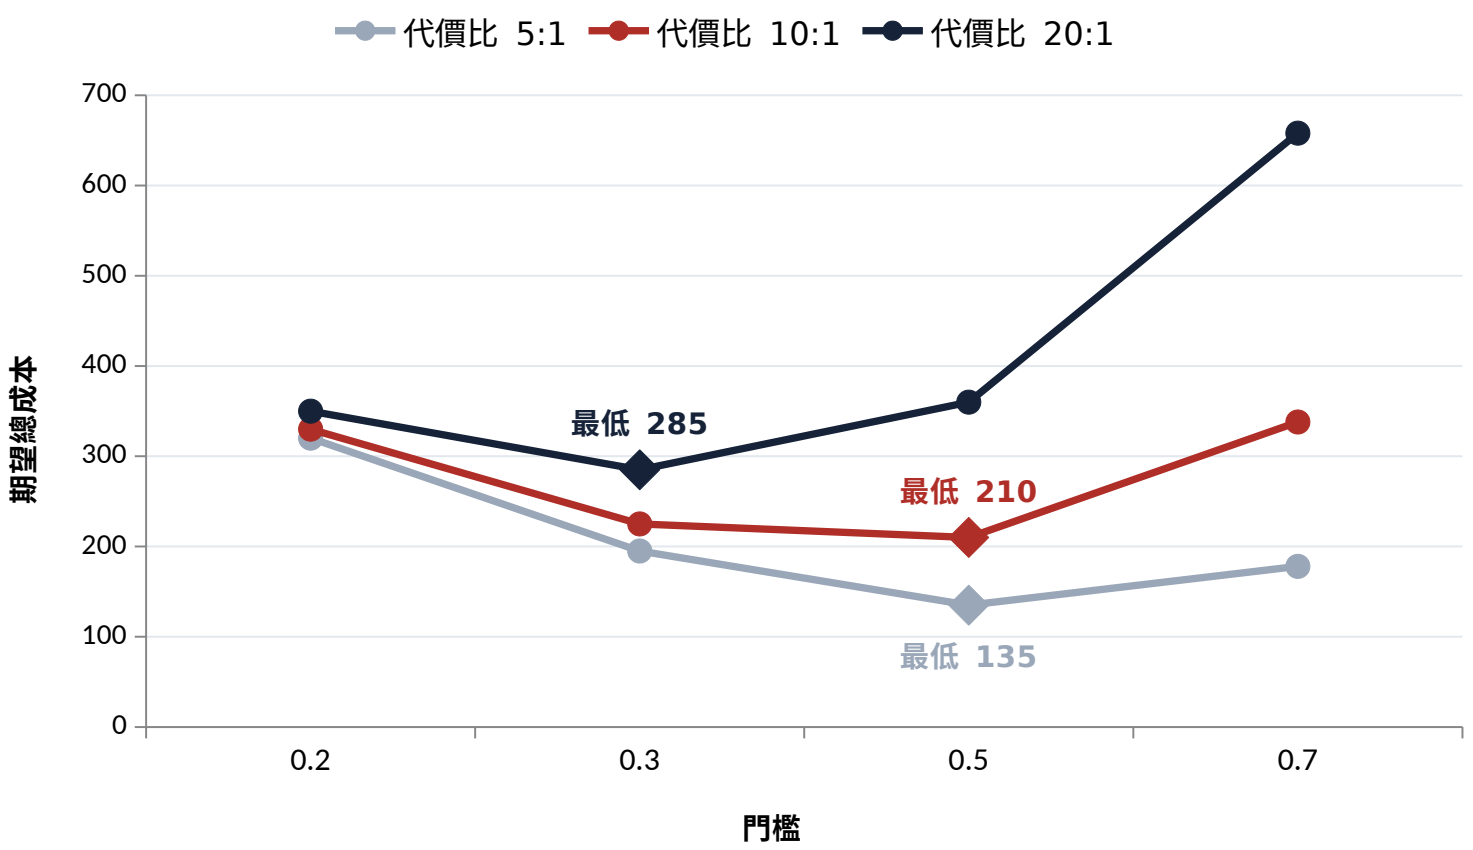
**計算** — 總成本 = FN×10 + FP×1。把 P8 門檻表的數字直接乘上代價

**敏感度（Sensitivity）分析** — 把代價比從 5:1 掃到 20:1，看最佳門檻怎麼移——報告裡放這張表最有說服力

**誰給代價比** — 臨床與管理者。資料科學家的工作是把「選門檻」翻譯成「選代價比」這個他們答得出的問題

AI Studio： Performance (Costs) 可直接輸入成本矩陣。若機率已校準，理論最佳門檻 = 1/(1+ 代價比）（10:1 → 0.09）；表中結果不同，代表機率需要校準（下頁）。

# 實例：代價比一變，最佳門檻就跟著移




**代價比 5:1**

最佳門檻 0.5，總成本 135

**代價比 10:1（前頁）**

最佳門檻 0.5，總成本 210

**代價比 20:1**

最佳門檻移到 0.3，總成本 285——漏一個的代價越高，越該用誤報換回漏網之魚

使用前頁門檻表的 FN、FP 數，只改代價比重算：總成本 = FN × 代價比 + FP。這就是前頁說「報告裡放這張表最有說服力」的敏感度分析——代價比由臨床與管理者決定，門檻跟著它走。

# 機率校準：模型說 70%，就真的是 70% 嗎

## 問題

- 模型輸出 0.7，但同分數群體可能只有 45% 發生事件：排序可用，數值失真
- 樹與集成模型的「機率」尤其常失真； Logistic 相對誠實
- 如果只拿來排序（先追蹤誰），失真無妨；要拿數值溝通（「您的風險是 70%」），就必須校準

## 怎麼檢查

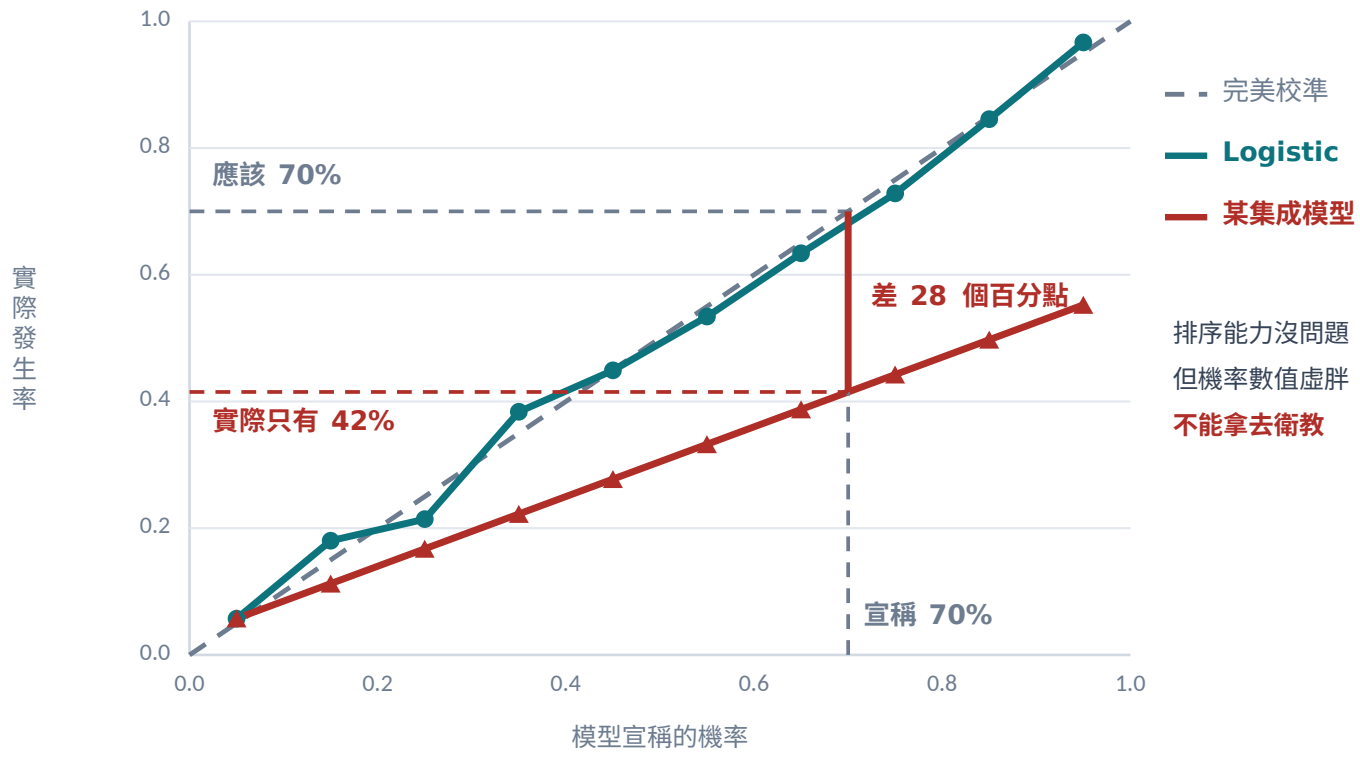
- 校準圖：把預測機率分十組，畫「預測平均 vs 實際發生率」。貼近對角線＝校準（Calibration）良好
- AI Studio 沒有內建校準圖，可用 Discretize + Aggregate 自行做出這張表

## 怎麼修

- Platt scaling： 模型分數再套一層 Logistic （AI Studio： Rescale Confidences (Logistic)）；或等張回歸
- 務必在獨立的驗證資料上做，不能用訓練集
- 醫療溝通場景（衛教、共享決策）強烈建議校準（Calibration）後再引用機率數字

【原講義 ML 3.3】 p79 （probability vs event rate）。這是原講義輕描淡寫、但醫療應用不能跳過的一頁。

# 實例：校準圖——模型說 70%，是真的嗎




AUC 只看「排得對不對」，校準看「數字準不準」。要跟病人說「你有七成機會」之前，先確認這條線真的貼著對角線。

**對角線**

完美校準：說 70% 就真的 70% 發生

**青色線**

Logistic 通常貼近對角線——它的機率相對誠實

**紅色線**

某集成模型：說 70% 實際只有 42%。排序沒問題，數值虛胖

**何時必須校準（Calibration）**

要把機率「講給病人聽」（衛教、共享決策）之前

圖：課程自製（示意型態）　★ 原生圖形，可直接在 PowerPoint 編輯

# Brier 分數與淨效益：兩個臨床預測模型的標準指標

## 區辨力 vs 校準：兩者要一起看

| 模型 | AUC | Brier 分數 | 校準斜率 |
|---|---|---|---|
| A Logistic | 0.78 | 0.051 | 0.98 |
| B 梯度提升 | 0.81 | **0.062** | 0.62 |
| 一律預測 6% | 0.50 | 0.056 | — |

## 決策曲線分析：各門檻下的淨效益

| 門檻機率 | 模型 A 淨效益 | 全篩淨效益 | 全不篩 |
|---|---|---|---|
| 5% | 0.041 | 0.011 | 0 |
| 10% | 0.032 | −0.044 | 0 |
| 20% | 0.018 | −0.175 | 0 |
| 40% | **−0.004** | −0.567 | 0 |

**★ 看穿一個陷阱**

模型 B 的 AUC 較高，Brier 卻較差——它排序更好，但機率過度極端、高風險端高估（校準斜率 0.62，理想為 1）

**Brier 分數是什麼**

預測機率與實際結果差距的平方平均。越小越好，同時反映區辨力與校準

**為什麼要有基準**

「一律預測 6%」的 Brier 為 0.056：模型 B 還不如它，模型 A 也只小贏——低盛行率時 Brier 差距天生很小，必須和基準比

**淨效益怎麼讀**

在該門檻下，模型相對於「全篩」與「全不篩」多帶來多少真陽性。數值 > 0 且高於兩條基準線才有臨床價值

★ 這一頁對應臨床預測模型論文的標準要求：只報 AUC 會被審稿人退。 40% 門檻時模型 A 的淨效益已為負——代表在那個決策情境下，用這個模型還不如不用。數值為教學設計。

# 內部驗證與外部驗證：換一家醫院還準嗎

## 內部驗證　Internal Validation

- 用同一份資料做交叉驗證或 bootstrap—— 這是本課程作業要求的最低標準
- 回答的是「這個模型在同一群人身上穩不穩」，不是「換一群人還準不準」
- ★ 內部驗證的分數天生樂觀，因為變數選擇與調參都用過同一批資料

## 外部驗證　External Validation

- 拿另一個時間、另一個院區、另一個族群的資料重跑——分數幾乎一定會掉
- 掉多少才可接受，取決於用途；重點是「你有沒有誠實測過並報告」
- 常見的掉分原因：盛行率不同、量測方式不同、族群結構不同（年齡、共病）

## 報告規範：TRIPOD+AI （2024）

- 臨床預測模型的國際報告準則（2024 版涵蓋機器學習），期刊投稿幾乎必用；本課程專題不強制，但建議照它的架構寫
- ★ 核心要求與本模組完全一致：講清楚資料來源、模型設定、區辨力、校準、以及驗證的類型

給修課同學的實話：你的專題大概率只做得到內部驗證——這完全可以接受。不可接受的是在報告裡把內部驗證的分數，說成模型「在真實世界的表現」。

# 實例： Epic 敗血症模型——外部驗證的 AUC 只剩 0.63

## 發生了什麼

- Epic 電子病歷內建的敗血症警示（懲罰化 Logistic 迴歸），全美數百家醫院在用
- 密西根大學做外部驗證： 27,697 位病人、 38,455 次住院，敗血症發生 2,552 次（盛行率 7%）
- AUC 0.63 （95% CI 0.62–0.64），遠低於原廠文件的 0.76–0.83；校準也不佳

## 在建議門檻（6 分）下，用 PART 07 的指標來讀

- 敏感度 33%、特異度 83%、 PPV 12%、 NPV 95%—— 漏掉 67% 的敗血症病人
- 卻對 18% 的住院病人發出警示：每 8 個警示約只有 1 個是真的，造成警示疲勞（盛行率陷阱）
- 臨床醫師沒及時處置、而模型有抓到的只有 183 人（敗血症病人的 7%）——比現行做法多幫的人很少

## 教訓：內部分數不能當成真實世界的表現

- 換醫院就換了盛行率、記錄習慣與病人組成——正是上一頁列的三個掉分原因
- 原廠效能文件未經同儕審查，外部無從驗證；不透明本身就是風險，上線前要先在本院做驗證

資料： Wong et al., JAMA Intern Med 2021;181:1065–70； Habib et al. 同期社論。互動站 M2-2 可用這組數字重建混淆矩陣，並改變盛行率看 PPV 怎麼變。

PART 09

# 類別不平衡

## Imbalanced Data

醫療的重要事件幾乎都是少數類。

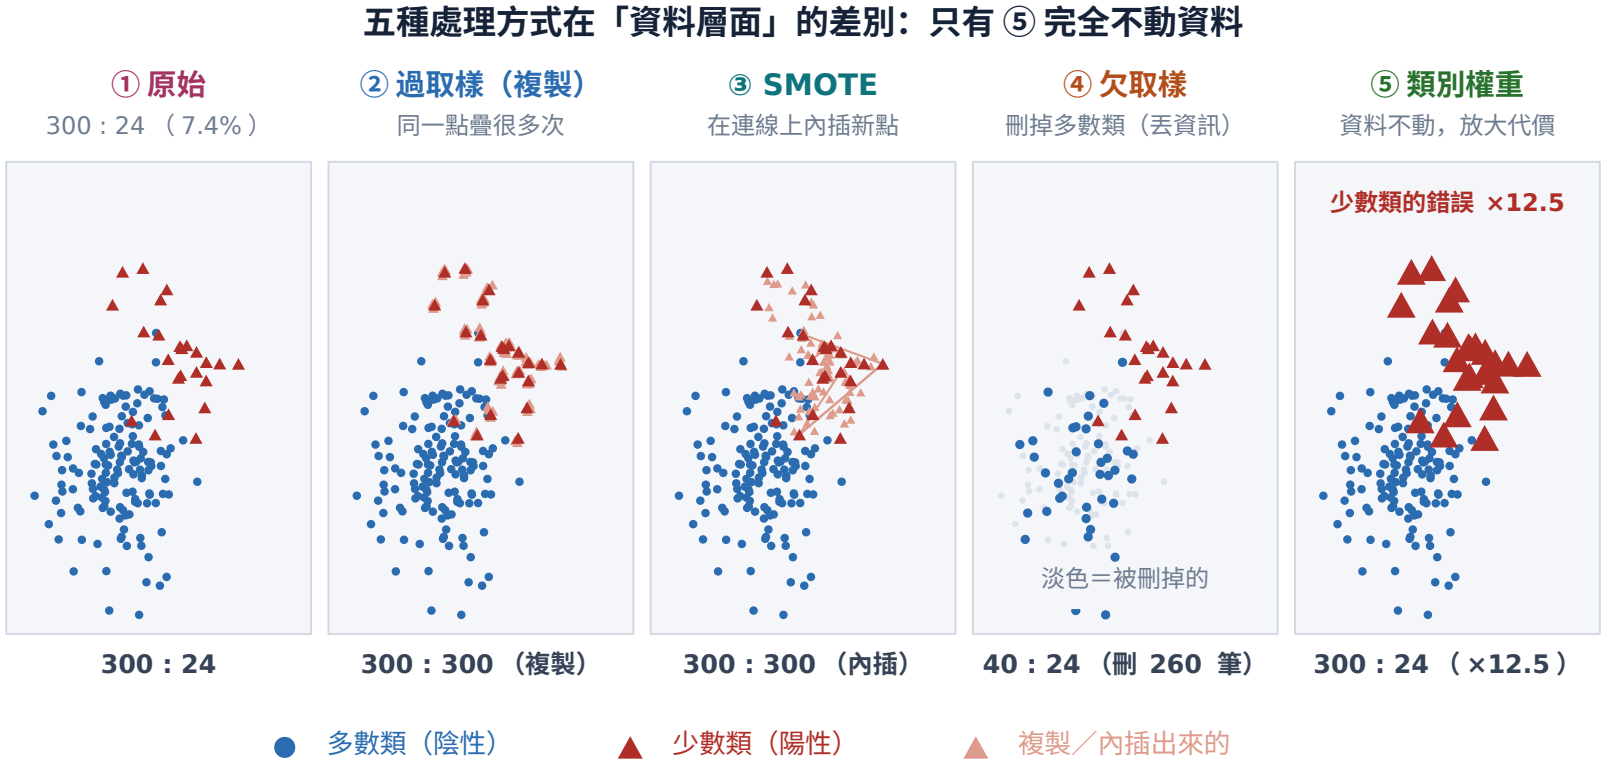
你要找的人，正好是資料裡最稀少的人。

# 五種處理方式

| 方式 | 做法 | 優點 | 風險 |
| --- | --- | --- | --- |
| **調整門檻** | 不動資料不重訓，改判定切點 | 最簡單透明；<br>★ 永遠先試這個 | 需要機率輸出 |
| **類別權重（Class Weight）** | 訓練時加重少數類的損失 | 不改資料、不丟資訊；<br>★ 次選 | 並非所有 Operator 支援 |
| **過取樣（Oversampling）** | 複製少數類至平衡 | 不丟資訊 | 複製樣本易被過擬合（Overfitting） |
| **SMOTE** | 少數類樣本間內插合成新樣本 | 比複製多樣 | 「合成病人」——<br>醫療報告需說明 |
| **欠取樣（Undersampling）** | 刪多數類樣本 | 訓練快 | 丟資訊；小資料不可行 |

【原講義 ML 3.3】 pp157–171

# 實例：五種不平衡處理在資料上的差別




① ～ ④ 都動到了你手上的資料集，所以只能在訓練折內做，否則會把資訊洩漏到驗證折；⑤ 一筆資料都沒動，改的是損失函數裡少數類的代價——這是它最安全的地方。

### ① 原始

300 : 24 。多數類（藍圓）淹沒少數類（紅三角）

### ② 過取樣

少數類被複製多份疊在同一位置——模型容易死背這幾個點

### ③ SMOTE

在少數類樣本的連線上內插出新點，比複製多樣

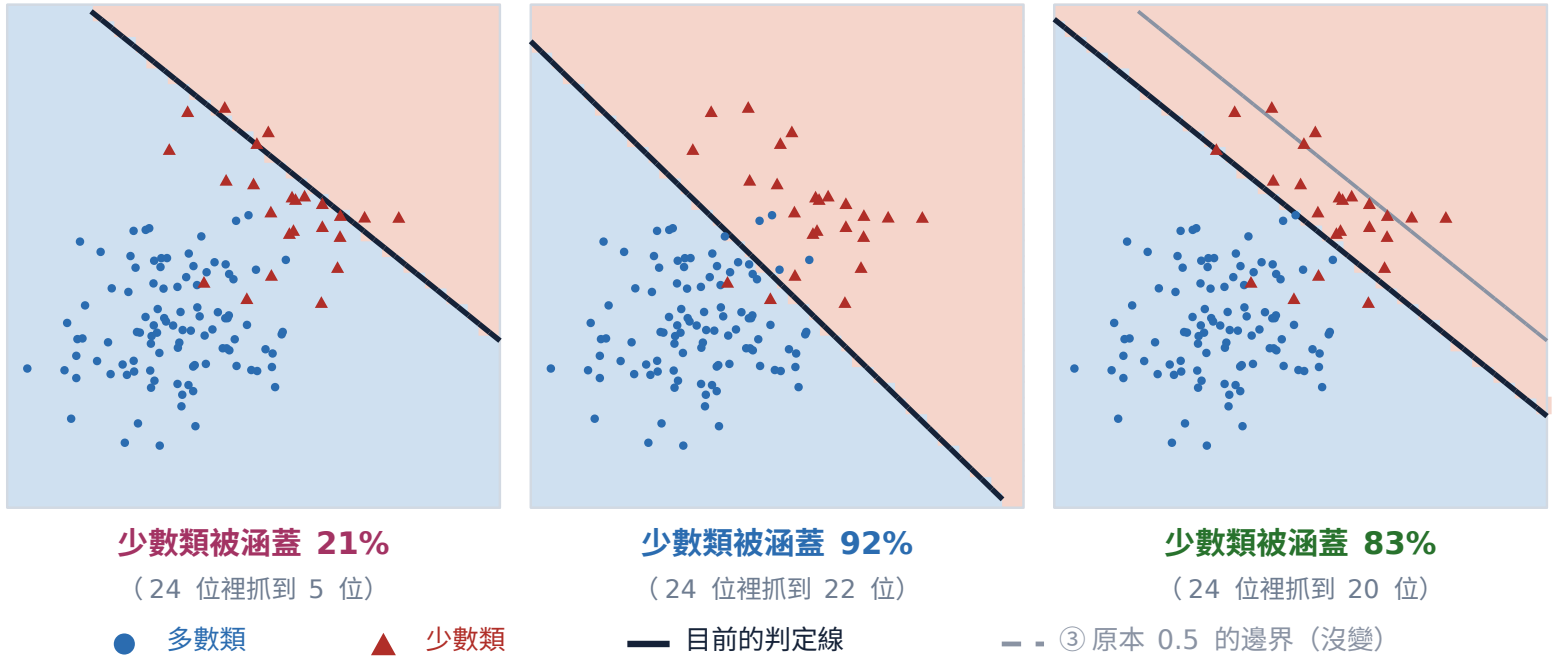
### ④ 欠取樣 vs ⑤ 類別權重

④ 刪掉大量多數類（丟資訊）；⑤ 資料完全不動，只把少數類的錯誤代價放大

圖：課程自製（模擬資料 324 筆） ★ 原生圖形，可直接在 PowerPoint 編輯

# 實例：三種做法對決策邊界的實際影響

**同一份 300：24 的資料，三種做法各自畫出來的判定區域**




② 的黑線位置變了——那是重新訓練出來的另一個模型；③ 的黑線只是從灰線平移過去，模型的係數一個字都沒改。兩者可以並用：先加權訓練，再調門檻。

### ① 不處理

邊界被多數類推到少數類那一側，紅色三角大量落在藍區＝被判為陰性

### ② 類別權重

把少數類的錯誤代價放大 12.5 倍，邊界被拉回中間，涵蓋率明顯上升

### ③ 只調門檻

模型與邊界完全沒變，只是把判定線從 0.5 移到 0.15

### ② 與 ③ 的差別

權重改變「訓練出來的模型」，門檻只改變「怎麼用這個模型」。可以並用

圖：課程自製（涵蓋率為實際計算值）　★ 原生圖形，可直接在 PowerPoint 編輯

# 三個鐵則（作業必查）

### 取樣只能在訓練集做

- 切分前取樣 → 同一筆的複本同時進訓練與測試 → 分數虛高且不可信
- AI Studio 正確作法：取樣 Operator 放進 Cross Validation 的訓練子流程

### 測試集維持原始分布

- 平衡過的測試集 ＝ 假設盛行率 50% ＝ 所有 Precision 都是幻覺
- 評估必須反映真實世界的類別比例

### 不平衡時不用 Accuracy 當主指標

- 本講義 P7 已示範： 0.925 輸給全判陰性的 0.940
- 改用 Recall 、 Precision 、 PR-AUC ，且報告一定附上類別比例

# SMOTE 在做什麼：內插出合成樣本

## 兩個真實樣本 → 兩個合成樣本

| 樣本 | 年齡 | 天數 | 類別 |
|---|---|---|---|
| 真實 A | 78 | 9 | 再入院 |
| 真實 B | 70 | 7 | 再入院 |
| **合成 S1** | 74.8 | 8.2 | 再入院 |
| **合成 S2** | 71.6 | 7.4 | 再入院 |



## 性質與風險

| 性質 | 說明 |
|---|---|
| 做法 | 在少數類樣本連線上<br>隨機取點 |
| S1 = A + 0.4×(B−A) | 逐特徵線性內插 |
| 優點 | 比複製多樣，<br>不易死背特定樣本 |
| 風險 | 類別邊界附近亂內插<br>會製造「不可能的病人」 |

**醫療的特殊顧慮**

合成的「74.8 歲、 8.2 天」病人不存在。報告若用 SMOTE ，必須聲明並說明比例

**類別特徵怎麼辦**

SMOTE 原版只吃數值；類別特徵要用 SMOTE-NC 變體或先編碼

**永遠只在訓練集做**

合成樣本進了測試集＝考卷裡混了你自己出的題

【原講義 ML 3.3】 pp165–166

# 類別權重（Class Weight）：把少數類的錯「放大」給模型看

## 同一資料、不同權重

| 設定 | FN 的損失 | FP 的損失 | 模型行為 |
|---|---|---|---|
| 無權重 | 1 | 1 | 偏向多數類，Recall 低 |
| 權重 5:1 | 5 | 1 | 開始重視陽性 |
| 權重 15:1 | 15 | 1 | Recall 大增、Precision 降 |
| 權重 = 類別比 | ≈15.7 | 1 | 常見候選起點（940/60），不是通用最佳值 |

## 定位

| 與其他方法比 | 說明 |
|---|---|
| vs 過取樣（Oversampling） | 效果類似，但不複製資料 |
| vs 門檻調整 | 權重改變「訓練」，門檻改變「判定」 |
| 可以並用 | 權重訓練＋門檻微調 |
| AI Studio | 部分模型支援 weight 欄位（Set Role 設 weight 角色） |

**直覺**　權重 15:1 ＝告訴模型「漏掉一個陽性等於錯十五個陰性」——跟代價比（Cost Ratio）是同一種語言

**起點**　權重設成類別比例的倒數，再依驗證結果微調

**報告**　用了權重要寫明數值與理由，它跟門檻一樣是「決策」不是「計算」

【原講義 ML 3.3】 pp169–170

# 不平衡場景的其他指標

| 指標 | 公式概念 | 特性 | 何時用 |
| --- | --- | --- | --- |
| **Balanced Accuracy** | ( 敏感度（ Sensitivity ） ＋特異度（ Specificity ） )/2 | 兩類平權的準確率；全判多數類只得 0.5 | 想要單一數字且兩類都重要 |
| **MCC** | 四格全入的相關係數（ Coefficient ） | −1~+1 ； 對四格都敏感，公認最難被騙 | 極度不平衡的嚴謹比較 |
| **PR-AUC** | PR 曲線下面積 | 不看 TN ；基準＝陽性比例 | 盛行率（ Prevalence ） <5% 的模型比較 |
| **G-mean** | √( 敏感度（ Sensitivity ） × 特異度（ Specificity ） ) | 任一邊爛就整體爛 | 篩檢兩端都不能放 |

本例模型： Balanced Acc = (0.75+0.936)/2 = 0.843—— 比 Accuracy 0.925 更誠實地反映「陽性那邊還有進步空間」。

PART 10

# 交叉驗證

## Cross Validation

單次切分的分數，換一次隨機種子就變了。

交叉驗證（Cross Validation）給你平均值——還附贈標準差。

# 訓練集、驗證集、測試集：為什麼要三份




| | 訓練集 60% | 驗證集 20% | 測試集 20% |
|---|---|---|---|
| 模型看幾次 | 很多次（每個 epoch） | 很多次（每組參數一次） | ★ 只有一次 |
| 分數的性質 | 樂觀（記憶力） | 略為樂觀（選過很多次） | 最接近真實部署表現 |
| 能不能重複用 | 可以 | 可以 | ★ 不可以 |

**★ 鐵則：縮放、填補、取樣、特徵選擇的參數，一律只從綠色那一段計算**

用到驗證集或測試集的統計量 → 分數虛高、部署後大幅下滑，而且不會有任何錯誤訊息。
資料少的時候，驗證集可以用交叉驗證取代——但測試集仍要獨立保留。

### 訓練集 Training set

模型「看得到」的資料，用來學參數（迴歸係數、樹的切點、網路權重）

### 驗證集 Validation set

用來選超參數、比較模型。因為看很多次，它的分數會逐漸樂觀

### 測試集 Test set

只在最後看一次。一旦用它做過任何決策，它就失去公正性了

### ★ 鐵則

縮放、填補、取樣、特徵選擇的參數，一律只從訓練集計算

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# 為什麼需要交叉驗證

## 問題：單次切分的分數不穩定

- 同一份資料、同一個模型，換一個隨機種子切分， AUC 可能從 0.78 變成 0.85
- 你回報哪一個？兩個都是真的，但都不可靠——這只是運氣
- 樣本數越少，這個問題越嚴重。醫療資料常常只有幾百到幾千筆

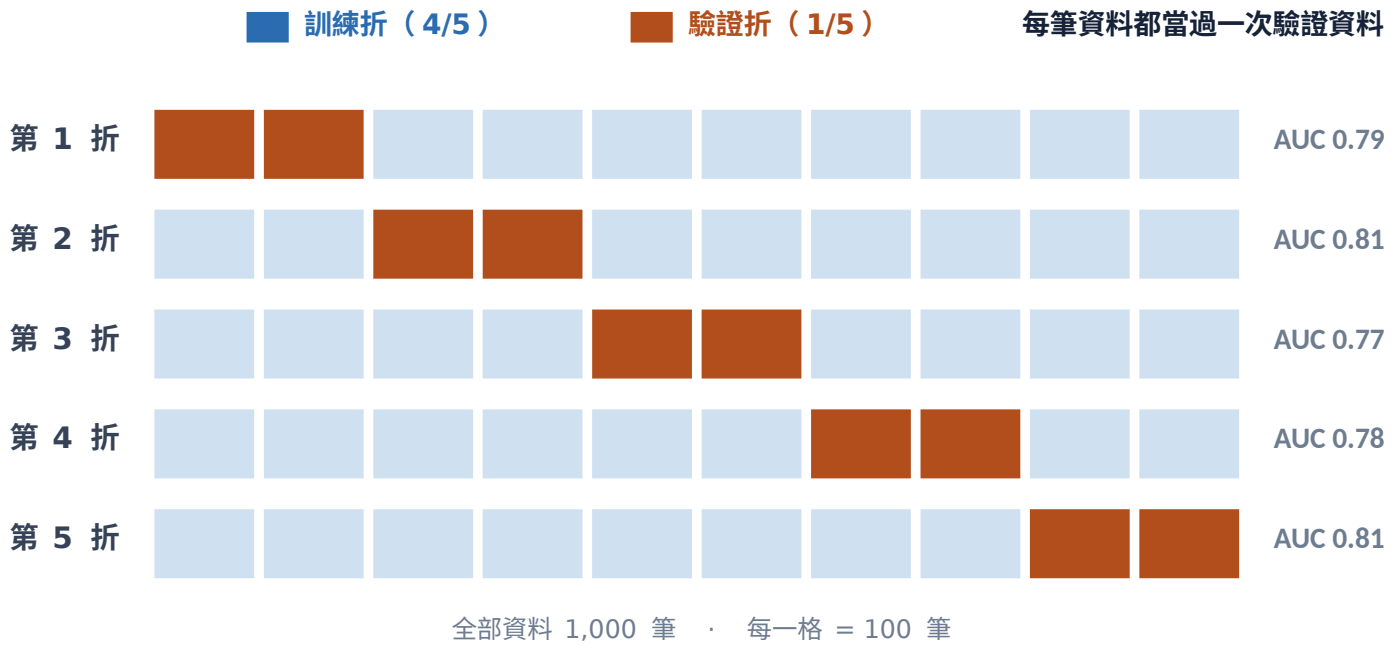
## 解法：讓每一筆都當過一次驗證資料

- 把資料切成 k 份，輪流用其中一份當驗證折、其餘訓練，跑 k 次
- 回報 k 次分數的平均——這比任何單一次的分數都可靠
- 同時回報標準差：它告訴你「這個模型有多穩」

## 怎麼寫進報告

- 正確寫法：「5-fold stratified CV： AUC 0.81 ± 0.03」
- 只寫 0.81 的話，讀者無從判斷這個數字有多可信
- 標準差大（如 ±0.09）代表模型對切分很敏感，部署後的表現可能落在很寬的範圍

# 實例： 5-fold 交叉驗證怎麼跑




**最終回報：五折分數的平均 ± 標準差 → AUC 0.79 ± 0.02**

**分層 Stratified：每一折的陽性比例都必須一致**




若不分層，某一折可能
**一個陽性樣本都沒有**
→ 那一折的 AUC 算不出來

### 橘色 = 測試

每一折把不同的 1/5 當驗證折，其餘 4/5 訓練

### 每筆都在折外評估一次

這是它比「單次切分」可信的原因——沒有運氣好壞的問題

### 回報兩個數字

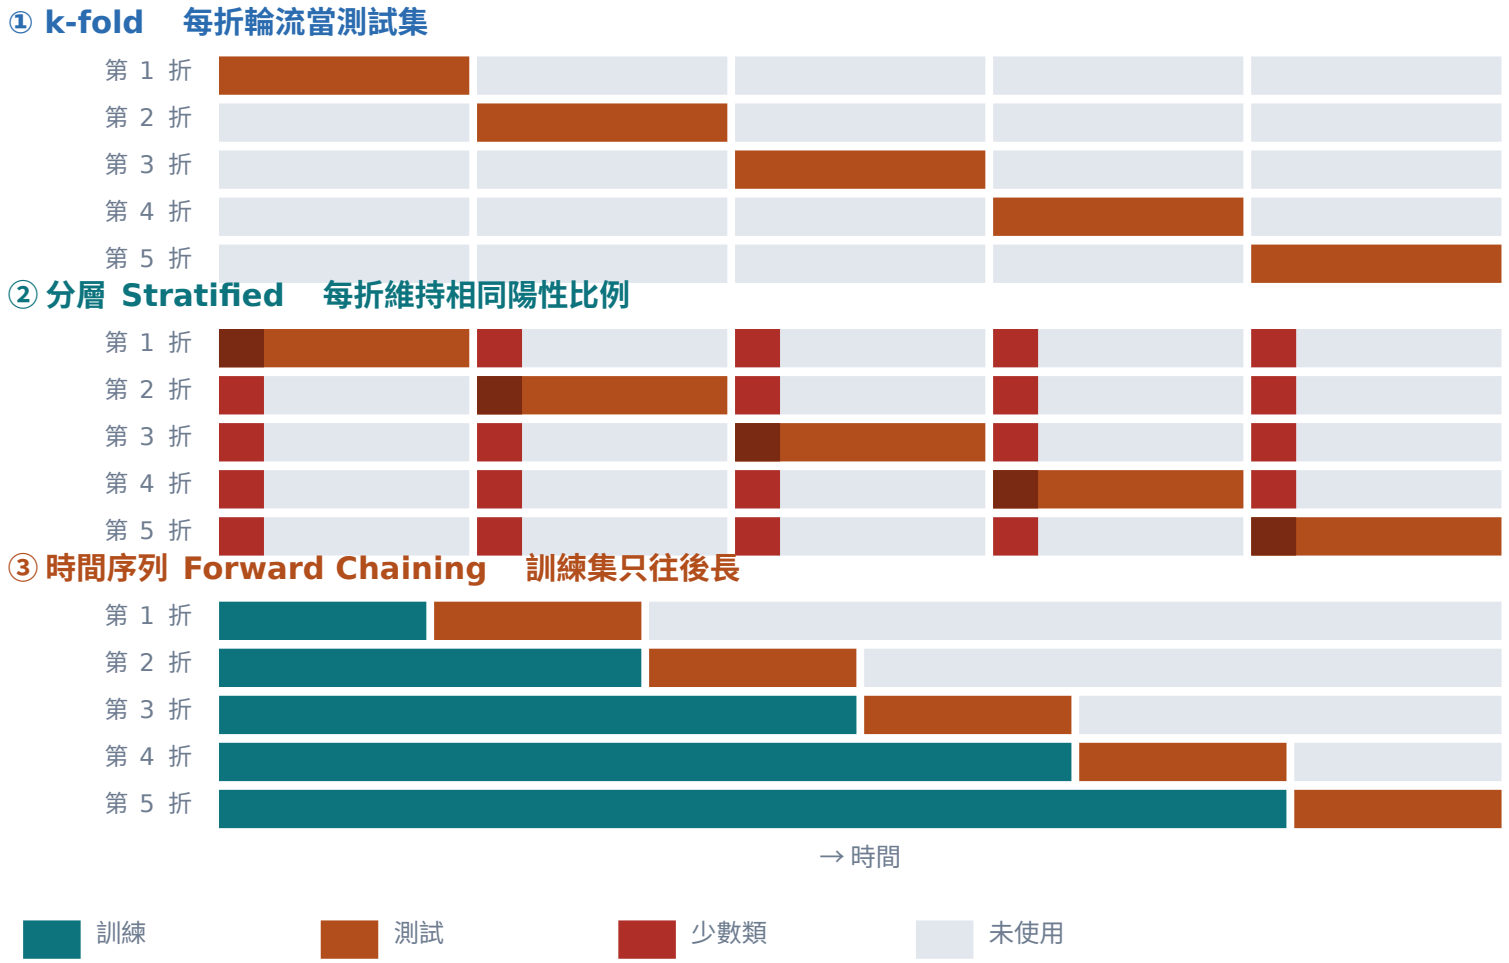
五折分數的平均 ± 標準差。標準差大代表模型對切分很敏感

### 分層 Stratified

不平衡資料要額外要求每折的類別比例一致，否則某折可能沒有陽性樣本

圖：課程自製 ★ 原生圖形，可直接在 PowerPoint 編輯

# 三種交叉驗證的資料分配




### ① k-fold

最基本的形式。每折輪流當測試集，每筆資料都被測過一次

### ② 分層 Stratified

每折維持與整體相同的類別比例。★ 不平衡資料必用

### ③ 時間序列 Forward Chaining

只能用過去預測未來。訓練集逐步往後擴大，絕不 shuffle

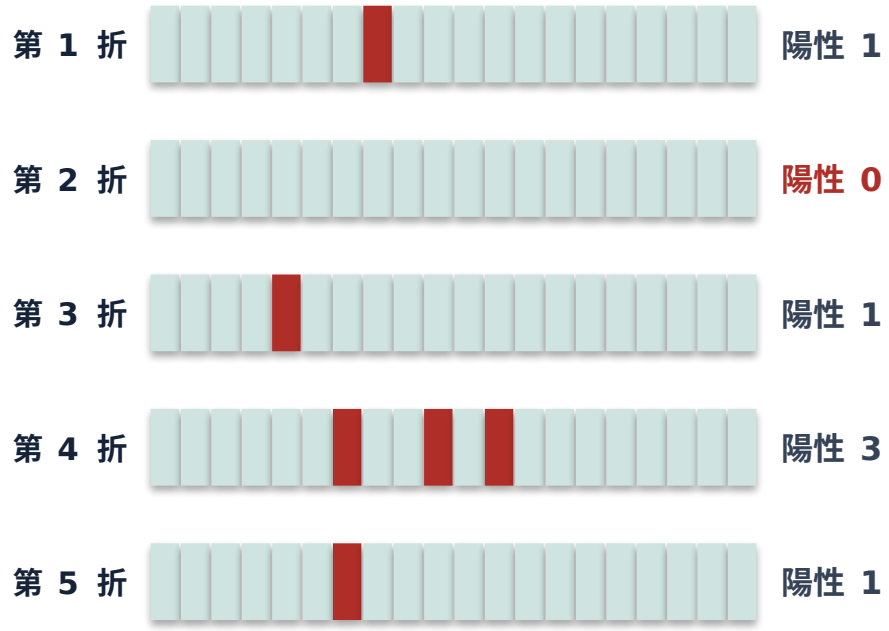
### AI Studio

Cross Validation 的 sampling type 設 stratified 即為②；③ 要改用 Forecast Validation 等時序驗證運算子

圖：課程自製 ★ 原生圖形，可直接在 PowerPoint 編輯

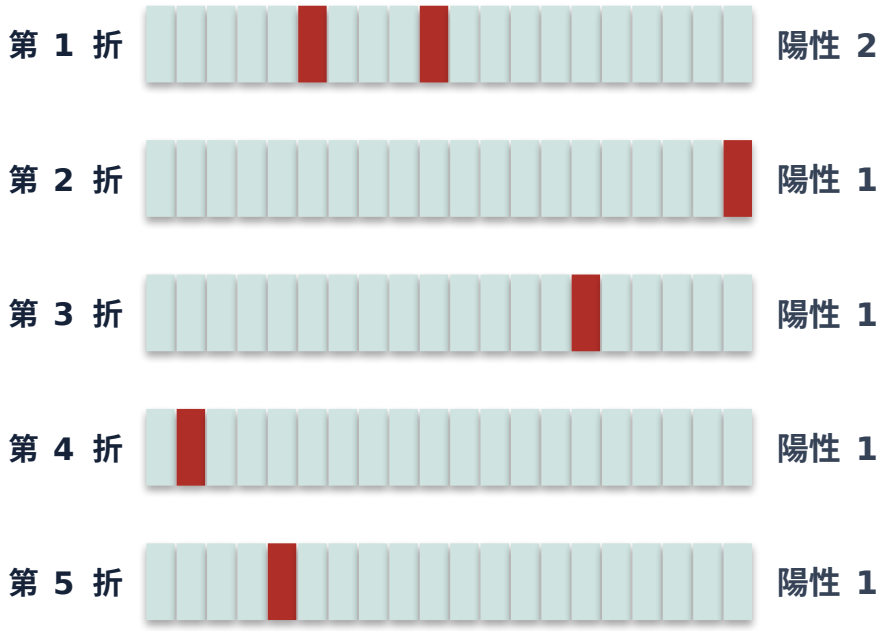
# 實例：不分層時，某一折可能一個陽性都沒有

### 隨機切 5 折




這一次有 1 折一個陽性都沒有，那一折的 Recall 、 AUC 算不出來；另一折卻有 3 個。

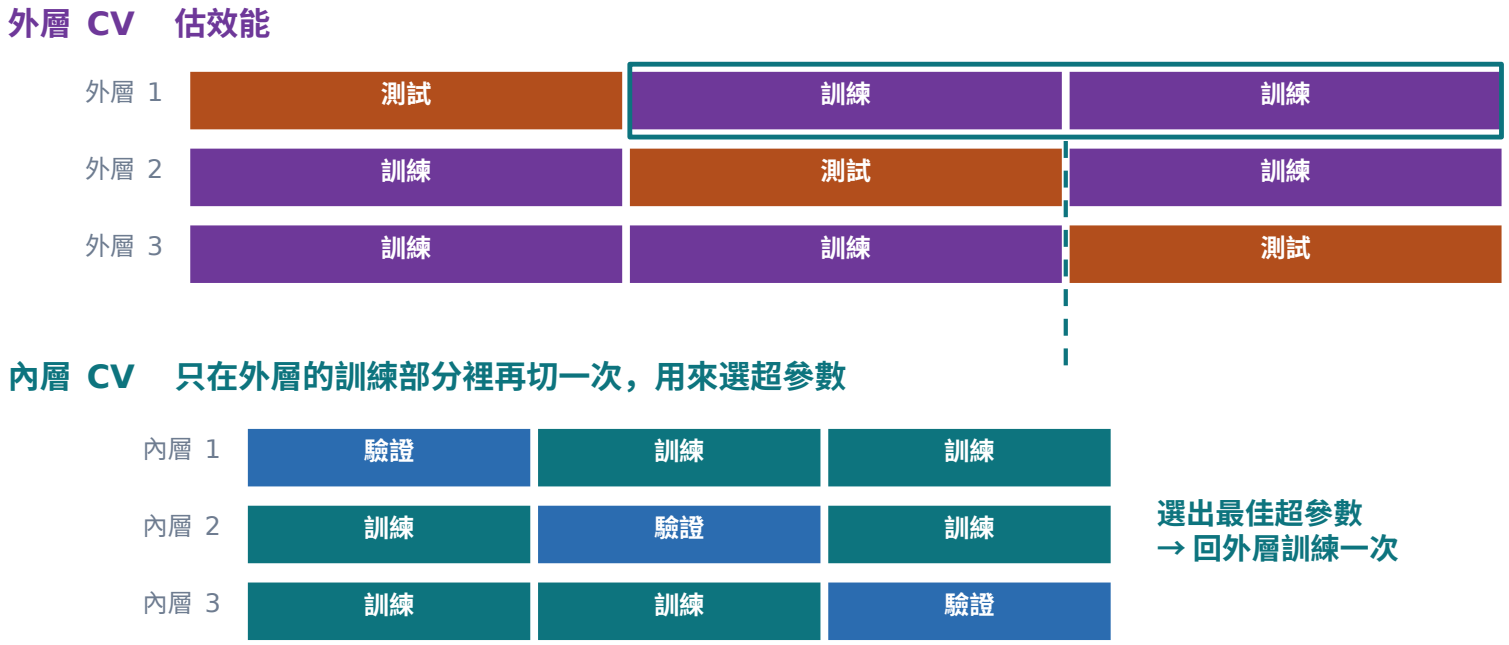
### 分層 Stratified 切 5 折




每折都有 1–2 個陽性，比例與整體一致，各折分數才能比較。

100 筆、 6 個陽性（紅色）。每一格是一筆資料。 AI Studio： Cross Validation 的 sampling type 設為 stratified sampling—— 本課程分類作業預設要求。

# 巢狀交叉驗證：選參數與估效能要分開




橘色的測試部分從頭到尾沒有參與選參數——這就是巢狀的意義。單層 CV 同時做兩件事，報出來的分數會系統性偏高。

### 問題在哪

如果用同一份資料「選超參數」又「報成績」，分數會系統性偏高

### 外層 CV

負責估計最終模型的表現。每一折的測試部分完全不參與選參數

### 內層 CV

在外層的訓練部分裡再切一次，用來選超參數

### 何時需要

要對外報告效能、或比較多個調參過的模型時。 AI Studio： 兩層 CV 巢狀擺放

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# 切分與驗證的五個檢查

Q 1

### 我的前處理是在切分之前還是之後做的?

縮放、填補、 SMOTE 、特徵選擇——全部都要在切分之後、且只用訓練集的統計量。

Q 2

### 不平衡資料，我的切分有沒有用 stratified ?

沒有的話，某一折可能完全沒有陽性樣本，那一折的指標會是無意義的。

Q 3

### 我的測試集被看過幾次?

超過一次就等於變成第二個驗證集。最終數字會偏高。

Q 4

### 我報告的是平均還是單次分數? 有沒有附標準差?

「 AUC 0.81 ± 0.03 」與「 AUC 0.81 」傳達的資訊量差很多。

Q 5

### 同一個病人有多筆紀錄嗎?

有的話要以「病人」為單位切分（ group split ），不能以「紀錄」為單位——否則同一人會同時出現在訓練與測試集。

# 三種交叉驗證（Cross Validation）

## 1 k-fold

- 資料切 k 份輪流當驗證折
- 每筆都在折外評估一次
- 常用 k=5 或 10
- 報告平均 ± 標準差
- 標準差大 = 模型不穩
- 小資料集的標準做法

## 2 Stratified k-fold

- 每折維持類別比例
- 不平衡資料必用
- 否則某折可能沒有正樣本
- AI Studio： sampling type = stratified
- ★ 本課程分類作業預設
- 作業會檢查這個設定

## 3 前處理放進 CV 內

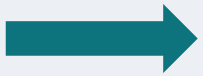
- 縮放、填補、取樣、特徵選擇（Feature Selection）
- 全部放進訓練子流程
- 每折各自計算參數
- 這是防洩漏的統一解法
- AI Studio 的 CV 是容器型 Operator，天生支援
- Ref 5.5 / 5.6 的做法

【原講義 ML 3.3】 pp75–76。報告範例寫法：「5-fold stratified CV： AUC 0.81 ± 0.03」——平均與標準差一起給，讀者才知道穩不穩。

# 學習曲線（Learning Curve）：資料夠了嗎?

### 逐步增加訓練樣本

| 訓練樣本數 | 訓練 AUC | CV AUC | 差距 |
|---|---|---|---|
| 500 | 0.95 | 0.68 | 0.27 |
| 2,000 | 0.90 | 0.75 | 0.15 |
| 5,000 | 0.87 | 0.80 | 0.07 |
| 12,000 | 0.86 | 0.83 | 0.03 |



### 三種形態的處方

| 形態 | 解讀 | 行動 |
|---|---|---|
| 兩線仍在靠攏 | 更多資料仍有幫助 | 繼續收資料 |
| 兩線已收斂但都低 | 資料夠了、特徵不夠 | 做特徵工程（Feature Engineering） |
| 差距持續巨大 | 嚴重過擬合 | 簡化模型 / 正則化（Regularization） |
| 本例 | 接近收斂 | CV 仍微升但增幅遞減 |

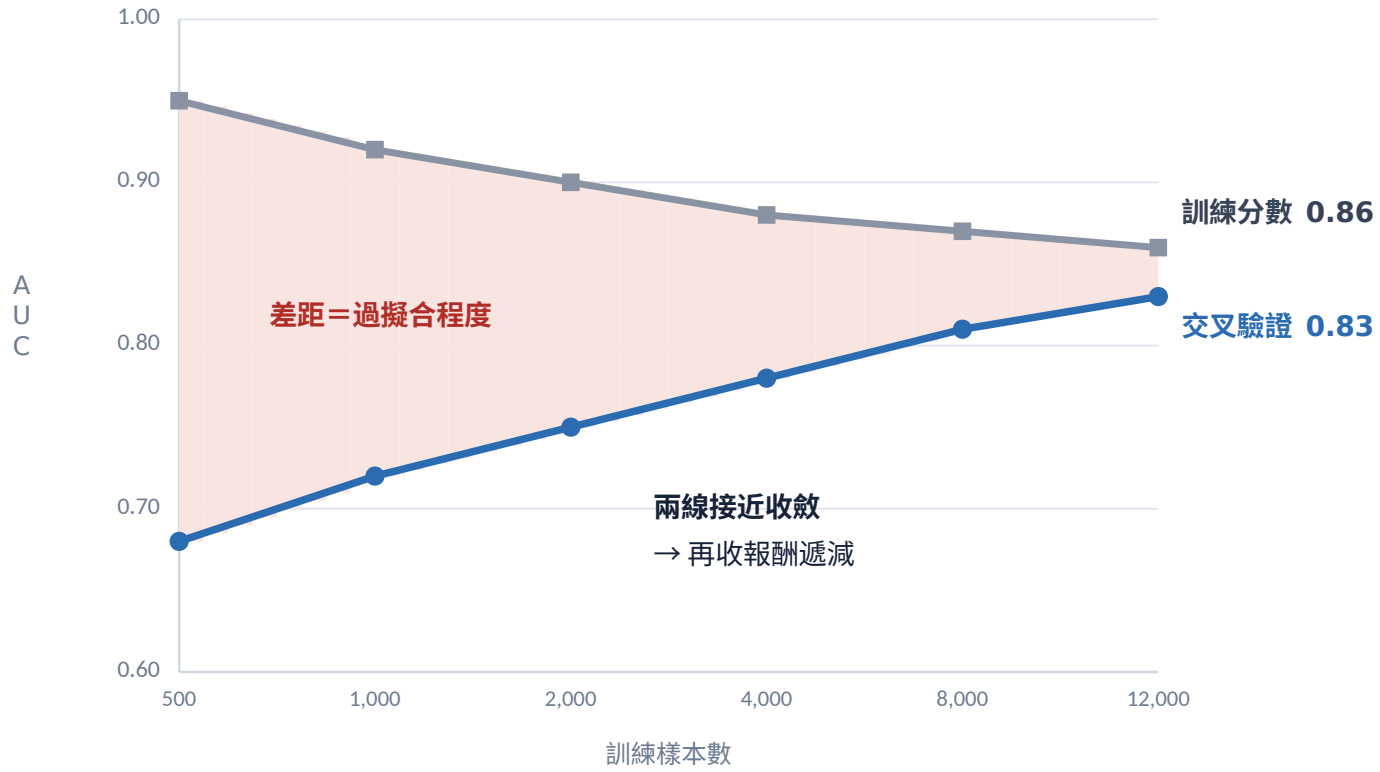
**回答一個常見問題** 「再多收一年資料值得嗎?」——學習曲線（Learning Curve）給出量化答案

**怎麼做** 固定測試集，訓練集從小到大逐步餵，各記錄兩個分數

**AI Studio** Loop + Sample Operator 組合可做出這張表

這是說服管理層「該投資資料收集」或「該止損」的最佳圖表。

# 實例：學習曲線




差距從 0.27 收斂到 0.03， CV 雖仍微升，但 5,000→12,000 筆只多 0.03，再收資料的報酬已遞減。
若兩條線早就平行且貼近，再收一年資料也不會變好，該去做特徵工程。

**紅色陰影**

訓練與 CV 分數的差距＝過擬合（Overfitting）的程度

**兩線靠攏中**

到 12,000 筆 CV 仍微升，但增幅已遞減——再收資料報酬有限

**若兩線已平行**

資料夠了，瓶頸在特徵——該做特徵工程（Feature Engineering）而不是收資料

**管理決策工具**

「要不要再收一年資料」用這張圖回答

圖：課程自製（示意型態）　★ 原生圖形，可直接在 PowerPoint 編輯

# 隨堂檢核 2 ｜評估

**Q 1** **敏感度（Sensitivity） 0.9、特異度（Specificity） 0.95 的模型，在盛行率 2% 的場域，PPV 大約多少?**

每萬人：真陽 180、偽陽 490 → PPV ≈ 0.27。自己算一遍。

**Q 2** **為什麼「測試集也做了 SMOTE」會讓 Precision 虛高?**

測試集陽性比例被人工拉高，喊「陽性」猜中的機率自然上升——但真實世界沒有被拉高。

**Q 3** **5-fold CV 得到 AUC 0.82 ± 0.09，這個 ±0.09 在告訴你什麼?**

模型對資料切分很敏感＝不穩定。部署後的表現可能落在很寬的範圍。

**Q 4** **什麼情況下 F1 是錯誤的指標選擇?**

漏診代價遠高於誤報（或反之）時—— F1 假設兩者等價。

PART 11

# 決策樹

## Decision Trees

一連串『是／否』問題把資料逐層切開。

它是醫療場域最受歡迎的模型——因為可以整棵印出來。

# Gini 不純度（Impurity）：手算一次分裂

依「年齡≥ 65」分裂

| 節點 | 人數 | 再入院 | 比例 |
|---|---|---|---|
| 母節點 | 100 | 30 | 30% |
| 左：年齡 <65 | 50 | 8 | 16% |
| 右：年齡≥ 65 | 50 | 22 | 44% |



不純度（Impurity）計算

| 節點 | 計算 | Gini |
|---|---|---|
| 母 | $1-(0.3^2+0.7^2)$ | 0.4200 |
| 左 | $1-(0.16^2+0.84^2)$ | 0.2688 |
| 右 | $1-(0.44^2+0.56^2)$ | 0.4928 |
| 加權 | $0.5\times0.2688+0.5\times0.4928$ | 0.3808 |
| 增益 | $0.4200-0.3808$ | **0.0392** |

**Gini 的意義**

隨機抽兩筆、類別不同的機率。 0= 全純， 0.5= 最亂（二元）

**演算法**

對每個特徵 × 每個切點都算增益，挑最大的切下去，然後遞迴

**Entropy 版本**

同一母節點的 Entropy=0.881 （log 底 2）。與 Gini 選的切點通常一致

**何時停**

增益太小、葉節點（Leaf Node）人數太少、或達到深度上限——這就是預剪枝（Pruning）

【原講義 ML 3.3】 pp176–189。 AI Studio： Decision Tree 的 criterion 參數可選 gain_ratio / information_gain / gini_index。

# Entropy 與 Gini：兩把很像的尺

| 準則 | 公式 | 30/70 節點的值 | 特性 |
|---|---|---|---|
| **Gini** | $1 - \Sigma p_i^2$ | 0.420 | 計算快（無對數）；<br>CART 的預設 |
| **Entropy** | $-\Sigma p_i \log_2 p_i$ | 0.881 | 資訊理論出身；<br>ID3/C4.5 使用 |
| **Gain Ratio** | 資訊增益（Information Gain）<br>÷ 分裂資訊 | — | 懲罰「切太碎」的特徵<br>（如 ID 欄位）； C4.5 |
| **實務結論** | 三者選的切點<br>多數時候一致 | — | AI Studio 預設 gain_ratio<br>即可，不必糾結 |

兩個數值已驗算。 Gain Ratio 的價值：純資訊增益偏好類別數多的特徵——極端例子是病歷號，每人一類、增益最大、毫無用處。

# 兩個候選切點，選哪個?

母節點 Gini = 0.42 （30/100 再入院）

| 候選 | 左節點 | 右節點 | 加權 Gini | 增益 |
|---|---|---|---|---|
| 年齡≥ 65 | 8/50 | 22/50 | 0.3808 | 0.0392 |
| 糖尿病 = 有 | 12/60 | 18/40 | 0.3900 | 0.0300 |

計算過程

| 步驟 | 年齡≥ 65 | 糖尿病 |
|---|---|---|
| 左 Gini | 0.2688 | 0.320 |
| 右 Gini | 0.4928 | 0.495 |
| 權重 | 0.5 / 0.5 | 0.6 / 0.4 |
| 加權 | 0.3808 | 0.390 |
| 勝出 | ★ | |

**演算法就是這樣選的** 每個特徵、每個切點都算一次，年齡的增益 0.0392 > 糖尿病的 0.0300 ，第一刀切年齡

**但差距不大** 0.0092 的差距換一批資料可能翻盤——這就是單棵樹不穩定的根源

**臨床覆核** 第一刀切年齡合理嗎？若第一刀切的是「病歷號 >5000 」，你該做什麼？（答：查洩漏）

糖尿病組的數字為教學設計，已驗算。

# 決策樹（Decision Tree）的關鍵參數（AI Studio）

| 參數 | 作用 | 調大會 | 調小會 | 起手建議 |
|---|---|---|---|---|
| **maximal depth** | 樹的最大深度 | 過擬合（Overfitting）風險升 | 欠擬合風險升 | 4–6（醫療小資料） |
| **minimal leaf size** | 葉節點（Leaf Node）最少樣本數 | 樹更保守 | 為個案開分支 | ≥ 20 |
| **minimal gain** | 低於此增益就不分裂 | 樹更小 | 樹更茂密 | 0.01–0.05 |
| **pruning** | 事後剪枝 | — | — | 開啟 |
| **criterion** | 分裂準則 | — | — | gini ／ gain ratio 均可列入候選 |

【原講義 ML 3.3】 pp193–196。用 Optimize Parameters 包住 CV 掃 depth × leaf size，是 Ref 5.4 的標準做法。

# 決策樹（Decision Tree）的優缺點

## 為什麼醫療場域愛它

- 整棵樹可以印出來，判斷路徑一目了然
- 可直接轉成臨床決策流程圖
- 不需要縮放、能吃類別特徵、對遺失值（Missing Data）寬容
- 特徵重要性（Feature Importance）排序附送
- 非線性關係與交互作用（Interaction）自動抓到

## 它的致命傷

- 不穩定：資料換一批，樹可能長得完全不同
- 貪婪演算法：每步選當下最好，不保證整體最優
- 容易過擬合（Overfitting）（需靠剪枝與參數節制）
- 軸平行邊界：斜的關係要切很多刀才逼近
- → 這些正是集成方法要解決的問題

【原講義 ML 3.3】 pp197–198。單棵樹的價值在解釋；預測力要靠下一節的「一群樹」。

# 決策樹（Decision Tree）的深度掃描：又是那條過擬合（Overfitting）曲線

**depth 從 2 掃到無限制**

| maximal depth | 訓練 AUC | CV AUC | 診斷 |
|---|---|---|---|
| 2 | 0.71 | 0.70 | 欠擬合（Underfitting） |
| 4 | 0.79 | 0.77 | 接近甜蜜點 |
| 6 | 0.85 | **0.78** | ★ CV 最高 |
| 10 | 0.93 | 0.75 | 過擬合（Overfitting） |
| 無限制 | **0.99** | **0.70** | 背答案 |

**第四次見到這條曲線**

| 對照 | 相同的故事 |
|---|---|
| M2-1 多項式次數 | 1→9 次 |
| k-NN 的 k | 101→1 |
| Logistic 的 λ | 大→ 0 |
| 樹的 depth | 2→∞ |
| 共同教訓 | 複雜度旋鈕轉到底<br>＝記憶不是學習 |

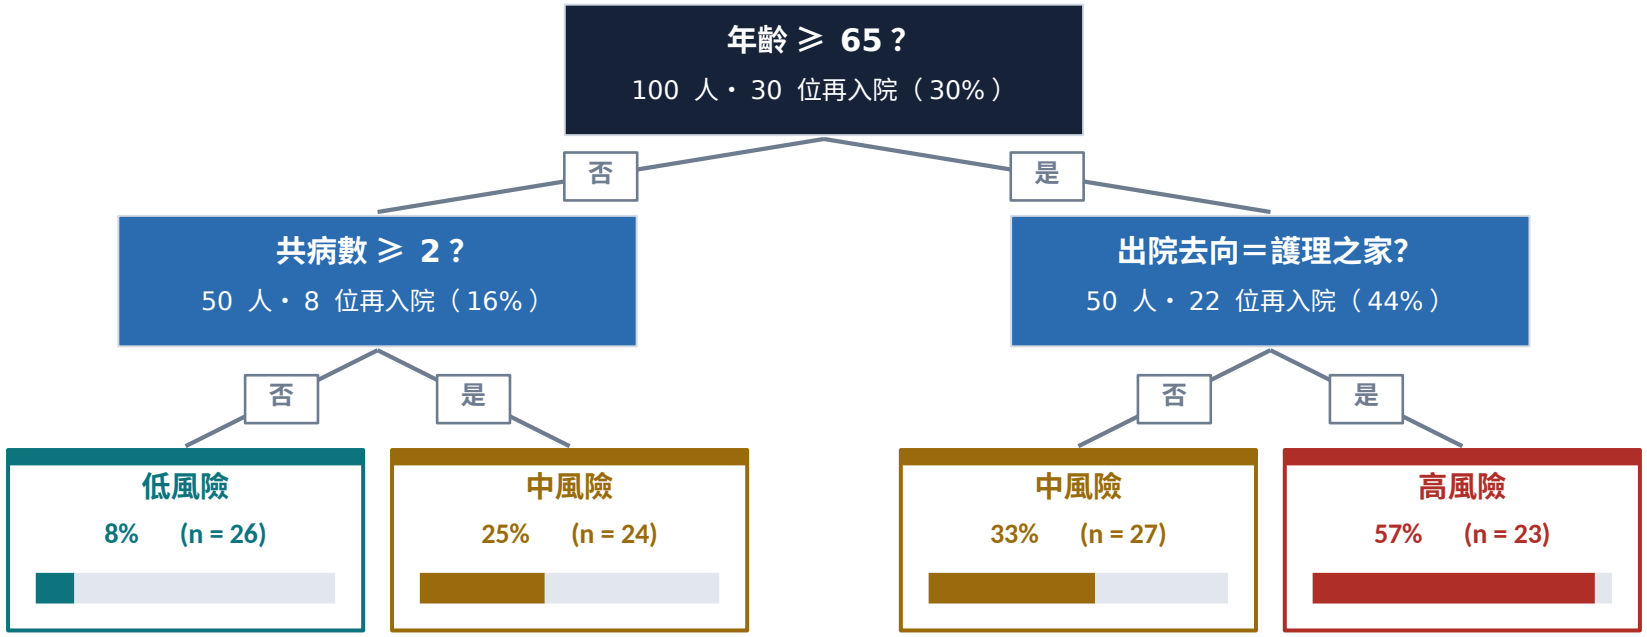
**每個模型都有一顆複雜度旋鈕** 多項式次數、 k 、 λ 、 depth—— 名字不同，物理相同

**找法永遠一樣** 掃參數 → 交叉驗證（Cross Validation） → 取 CV 最高點

**這就是 Optimize Parameters 的工作** Ref 5.4 / 5.5 的流程自動做這件事

【原講義 ML 3.3】 pp193–196

# 實例：一棵印得出來的樹




風險條：滿格 ＝ 60%　（同一把尺，四個葉節點可以直接比）

每個葉節點都要同時看「比率」與「人數」—— n=23 的 57% 其 95% 信賴區間約 37%–74%，遠比數字看起來不確定。整棵樹只有兩層、四條規則，個管師拿到就能用，不需要任何軟體。

### 根節點（Root Node）

第一刀切年齡 ≥ 65—— 就是前頁 Gini 手算選出的那一刀

### 四個葉節點（Leaf Node）

風險 8% 到 57%，直接構成風險分層

### 紅色葉的警訊

57% 聽起來很高，但 n=23—— 樣本小，不確定性大

### 交給個管師

這張圖可以直接印成判讀卡。這就是決策樹（Decision Tree）在醫療場域的價值

圖：課程自製（對應本講義案例）　★ 原生圖形，可直接在 PowerPoint 編輯

# 讀一棵印出來的樹：三條路徑

**路徑一：年齡≥ 65 → 出院去向 = 護理之家 → 【高風險 57%】**

- 讀法： 65 歲以上且出院到護理之家的病人，再入院率 57% （該葉節點 23 人中 13 人）
- 個管師看得懂、能行動：這群人優先排入追蹤名單

**路徑二：年齡 <65 → 共病數 <2 → 【低風險 8%】**

- 年輕且共病少： 26 人中 2 人再入院——追蹤資源可優先給其他組
- 但 26 人的 8%，區間約 2%–24%；真實專案的葉節點要數百人才可信

**路徑三：年齡≥ 65 → 出院去向≠護理之家 → 【中風險 33%】（葉節點僅 27 人）**

- 27 人中 9 人，區間約 19%–52%；葉節點太小，比率不穩
- 可調大 minimal leaf size，或報告區間與證據有限
- ★ 每個葉節點都要同時看「比率」與「人數」——只看比率會被小樣本騙

【原講義 ML 3.3】 pp190–192。這一頁的技能（帶人數讀樹）是把模型交給臨床人員時最重要的溝通能力。

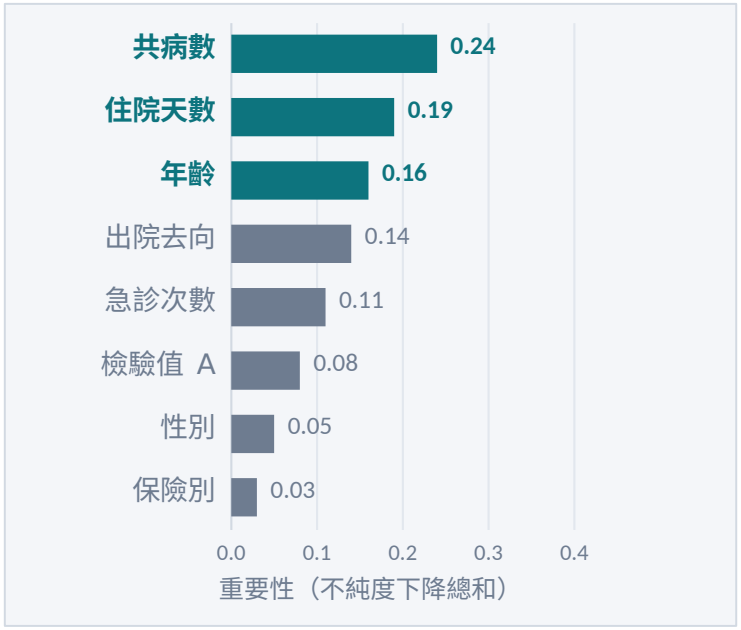
# 特徵重要性（Feature Importance）：怎麼算、怎麼讀、怎麼被騙

| 面向 | 內容 |
| --- | --- |
| **怎麼算** | 每個特徵在所有分裂中貢獻的不純度（Impurity）下降總和（加權），歸一化成 0–1 |
| **怎麼讀** | 排序看相對大小；前幾名應該通過臨床直覺的檢驗 |
| **陷阱一** | 偏好高基數特徵：可切的點多，天生佔便宜（病歷號、流水號會浮上來＝洩漏警訊） |
| **陷阱二** | 共線特徵互相攤薄：收縮壓與舒張壓都重要時，兩者的重要性都被壓低 |
| **陷阱三** | 重要 ≠ 因果：住院天數重要，不代表縮短住院就能降低再入院 |
| **更穩的替代** | Permutation Importance：只在未見資料打亂欄位看分數下降；相關特徵仍可能互相替代。個案級解釋可用 SHAP（M9） |

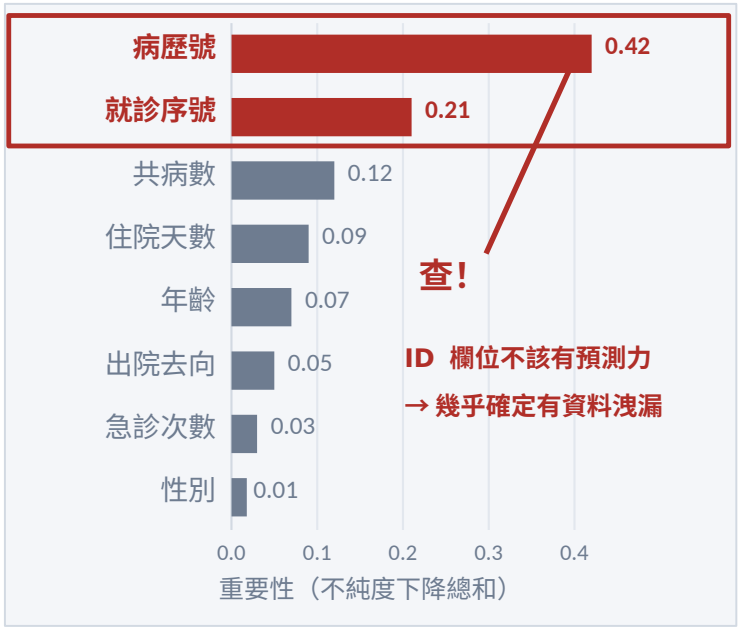
【原講義 ML 3.3】 pp192、207。特徵重要性是「模型視角的重要」，把它當成「臨床上的重要」是常見的過度解讀。

# 實例：特徵重要性怎麼看、怎麼被騙

**左・正常的排序：臨床上說得通**




**右・紅色警訊： ID 類欄位排最前面**




兩張圖用的是同一份病人資料，只差在右邊多留了病歷號與就診序號兩個欄位。病歷號隱含時間順序（越晚就診號碼越大），模型抓到的是「什麼時候來的」而不是「病人多重」。

**左・正常**

前幾名（共病數、住院天數、年齡）在臨床上說得通

**右・警訊**

病歷號與就診序號排在最前面—— ID 類欄位不該有預測力

**為什麼會這樣**

病歷號可能隱含時間順序（越晚就診號碼越大）＝時間洩漏

**怎麼處理**

刪掉這些欄位重跑。若重要性排序因此大變，代表你原本的模型是假的

圖：課程自製（示意數值） ★ 原生圖形，可直接在 PowerPoint 編輯

PART 12

# 集成方法

## Ensemble Methods

一群各自不完美、但錯得不一樣的模型，
投票的結果會比任何單一成員更可靠。

# 為什麼投票有效：機率的魔法

### 多數決的正確率（獨立假設）

| 單一模型正確率 | 5 個獨立投票 | 提升 |
|---|---|---|
| 0.60 | 0.683 | +0.083 |
| 0.70 | 0.837 | +0.137 |
| 0.80 | 0.942 | +0.142 |
| 0.90 | 0.991 | +0.091 |

### 兩個前提

| 前提 | 說明 |
|---|---|
| 各自夠好 | 單模型至少要比亂猜好 |
| 彼此獨立 | 錯的地方不能都一樣 |
| 獨立性是關鍵 | 五個一模一樣的模型<br>投票毫無意義 |
| 實務手段 | 隨機抽資料、隨機抽特徵<br>→ 逼出多樣性 |

**已驗算** 單模 0.70 → 五模獨立多數決（Majority Vote） 0.837。公式： P( 至少 3 個對 ) 的二項式加總

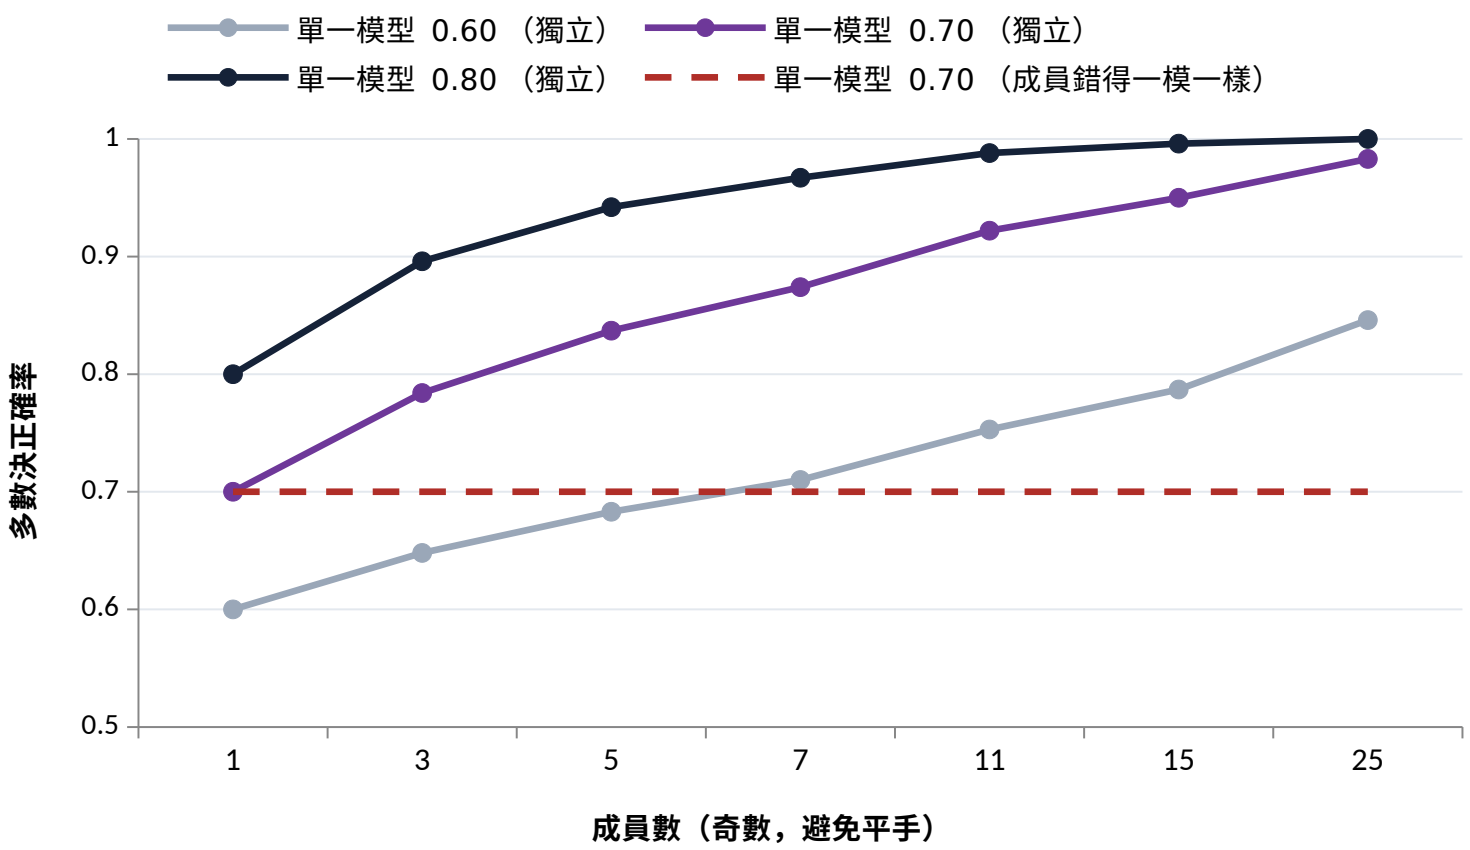
**整個集成學的核心** 怎麼製造「夠好又夠不一樣」的成員

**Bagging 的答案** 給每個成員不同的訓練資料（自助抽樣）

**隨機森林（Random Forest）再加碼** 每次分裂只准看隨機一部分特徵——樹與樹更不像

【原講義 ML 3.3】 pp201–204

# 實例：成員越多，多數決越準——前提是彼此獨立




**0.70 的模型**

5 個獨立投票 0.837，11 個 0.922，25 個 0.983。

**錯得一模一樣**

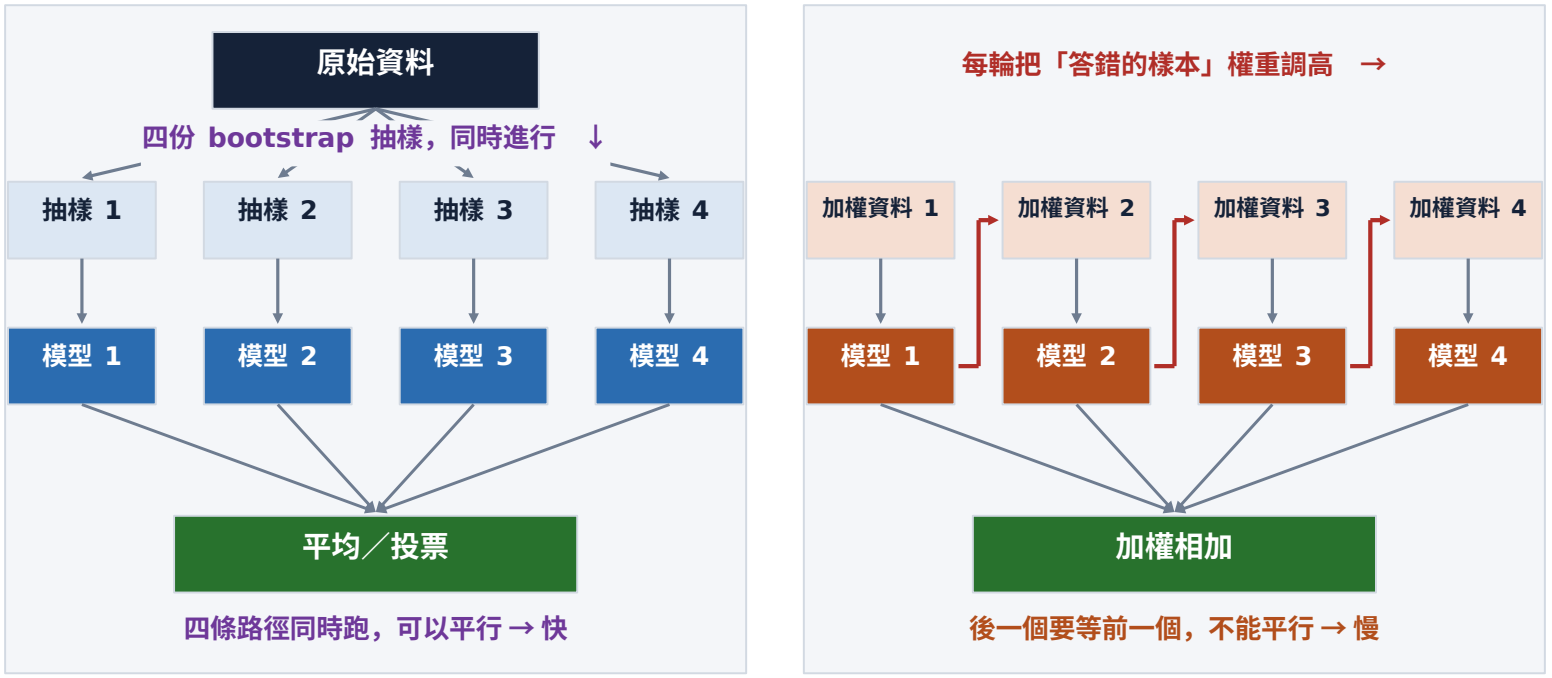
成員再多，正確率仍是 0.70。獨立性是關鍵——不夠多樣的森林只是同一棵樹。

**真實情況介於兩者之間**

樹與樹總有相關，提升會比獨立假設少。
Bagging 抽資料、隨機森林抽特徵，就是在逼成員錯得不一樣。

公式： P( 過半數答對 ) 的二項式加總，與前頁表格同一算法（前頁 5 個成員的數字即本圖 n = 5 那一欄）。前提：每個成員都比亂猜好（> 0.5）；若低於 0.5，投票反而越投越差。

# 實例： Bagging 與 Boosting 的流程差異




| | | | |
|---|---|---|---|
| 可否平行 | Bagging 可以（快） | · | Boosting 不行（慢），因為後一個要等前一個 |
| 治什麼病 | Bagging 治「不穩」（高變異） | · | Boosting 治「學不夠」（高偏誤） |

### 左・Bagging

四份抽樣同時進行、四個模型互不知道彼此，最後平均或投票

### 右・Boosting

一個接一個。紅色箭頭代表「把上一輪答錯的樣本加重」再訓練下一個

### 可否平行

Bagging 可以（快）；Boosting 不行（慢），因為後一個要等前一個

### 治什麼病

Bagging 治「不穩」（高變異）；
Boosting 治「學不夠」（高偏誤）

圖：課程自製 ★ 原生圖形，可直接在 PowerPoint 編輯

# 三種集成策略

| 策略 | 怎麼製造多樣性 | 代表 | 特性 |
|---|---|---|---|
| **Voting**<br>**投票** | 用「不同種類」的演算法<br>（樹＋ kNN ＋ NB ＋ Logistic ） | Vote Operator | 最簡單；成員少；<br>適合結合既有模型 |
| **Bagging**<br>**裝袋** | 同一演算法、不同的<br>自助抽樣（ Bootstrap ）資料集 | 隨機森林<br>Random Forest | 平行訓練；降低變異（ Variance ）；<br>附贈 OOB 驗證與特徵重要性（ Feature Importance ） |
| **Boosting**<br>**提升** | 序列訓練，每個新成員<br>專攻前面錯的樣本 | Gradient Boosting<br>AdaBoost / XGBoost | 降低偏誤（ Bias ）；威力最強；<br>對雜訊與離群值（ Outlier ）較敏感 |

【原講義 ML 3.3】 pp201–220 。 Bagging 治「不穩」（高變異）， Boosting 治「學不夠」（高偏誤）——先診斷再選藥， M4 會深入。

# 隨機森林（Random Forest） vs 梯度提升（Gradient Boosting）

## 隨機森林

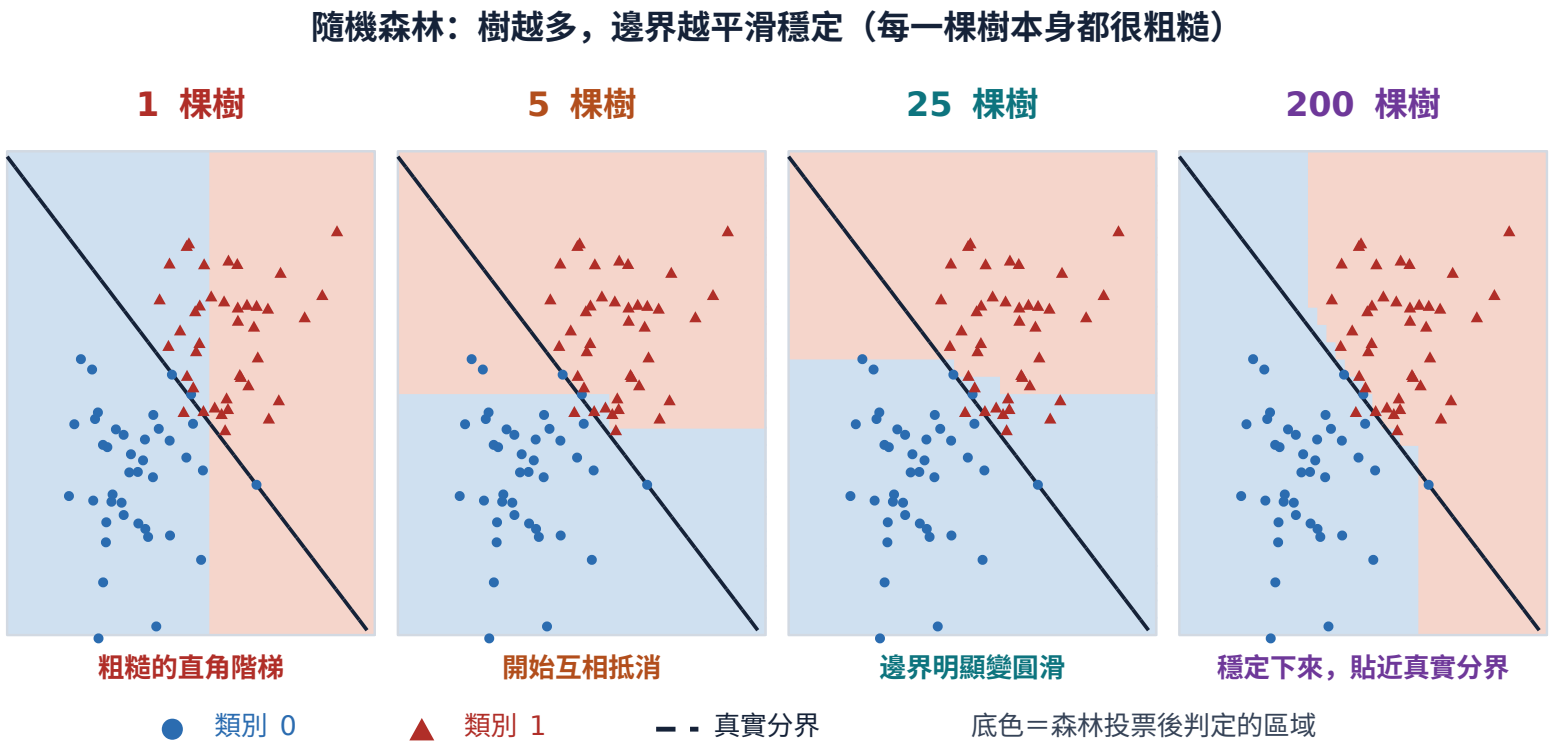
- 數百棵樹平行訓練，各看部分資料與特徵
- 分類可硬投票或平均機率
- 幾乎不需調參就有好表現（棵數夠多即可）
- 不易過擬合；訓練可平行、速度快
- 結構化資料的重要候選
- 參數： number of trees 、每次分裂的特徵數

## 梯度提升（Gradient Boosting）

- 樹一棵接一棵，每棵修正前面的殘差（Residual）
- 表格資料的強力候選，不保證是效能天花板
- 學習率、深度、棵數與正則化要聯合調整
- 學習率低＋棵數多＝穩定但慢
- 對雜訊敏感，資料髒時反而輸隨機森林
- AI Studio： Gradient Boosted Trees Operator

【原講義 ML 3.3】 pp205–220 。兩者的特徵重要性都可輸出；個案級解釋可用 SHAP 值（原講義 pp221–224），本課程在 M9 可解釋性再展開。

# 實例：森林越大，邊界越平滑




四張圖用的是同一份資料、同一組隨機種子——右邊的森林就是把左邊那棵樹再多長 199 棵。單棵樹的階梯歪得很誇張，但每棵歪的方向不一樣，投票之後就磨平了。

**1 棵樹**

一刀切下去，邊界是粗糙的直角階梯——這就是單棵樹不穩定的樣子

**5 棵 → 25 棵**

不同的抽樣讓每棵樹切在不同位置，投票之後邊界開始變圓滑

**200 棵**

邊界穩定下來，接近真實的分界。再加更多樹，變化已經很小

**關鍵**

每棵樹本身都很粗糙，但它們「錯的地方不一樣」，平均之後就抵消了

圖：課程自製（每棵為單層決策樹）　★ 原生圖形，可直接在 PowerPoint 編輯

# OOB：隨機森林（Random Forest）附贈的免費驗證集

## 原理

- 每棵樹自助抽樣，平均約 36.8% 樣本未被該樹抽中（Out-of-Bag）
- 對每筆資料，用「沒看過它的那些樹」投票預測它——這就是一次誠實的驗證
- 全部資料的 OOB 預測彙整起來＝一個近似交叉驗證（Cross Validation）的分數，不用另外切資料

## 實務用途

- 小資料集捨不得切測試集時， OOB 是可接受的替代
- OOB 分數與 CV 分數通常相近；差很多時檢查資料獨立性（同一病人多筆？）
- 注意：調參調到 OOB 上，它就失去「沒看過」的純潔性——最終仍需獨立測試集

【原講義 ML 3.3】 p206。「同一病人多筆紀錄」是醫療資料的獨立性殺手：切分時應以病人為單位（group split），不是以紀錄為單位。

# 隨機森林的參數（AI Studio: Random Forest）

| 參數 | 作用 | 建議起點 | 調整方向 |
|---|---|---|---|
| **number of trees** | 樹的數量 | 100 | 越多越穩，200 之後報酬遞減；<br>不會因太多而過擬合 |
| **subset ratio / features per split** | 每次分裂可看的特徵數 | AI Studio 預設 log(p) +1； sklearn 為 $\sqrt{p}$ | 調小→樹更不像、變異（Variance）更低；<br>調大→單樹更強、彼此更像 |
| **maximal depth** | 單樹深度 | 可放寬（森林自帶保險） | 過深仍會拖慢速度 |
| **voting strategy** | 投票方式 | confidence vote | 用機率平均比硬投票<br>保留更多資訊 |

【原講義 ML 3.3】 pp208–209。森林的預設值通常已經很好——它是「不太需要調參」的模型，這正是它作為主力的理由之一。

# 梯度提升（Gradient Boosting）：學習率與棵數的交易

## 四組設定

| 學習率 | 棵數 | 訓練 AUC | CV AUC |
|---|---|---|---|
| 0.3 | 50 | 0.93 | 0.84 |
| 0.1 | 150 | 0.91 | 0.86 |
| 0.03 | 500 | 0.90 | **0.87** |
| 0.01 | 2000 | 0.90 | **0.87** |

## 調參原則

| 原則 | 說明 |
|---|---|
| 低學習率＋多棵 | 幾乎總是更穩 |
| 代價 | 訓練時間線性增加 |
| 搭配 | early stopping：CV 分數不再升就停 |
| 深度 | 3–6 的淺樹即可，Boosting 靠疊加不靠深 |

**讀表**

0.03×500 與 0.01×2000 的 CV 相同——後者只是多花四倍時間

**與森林的分工**

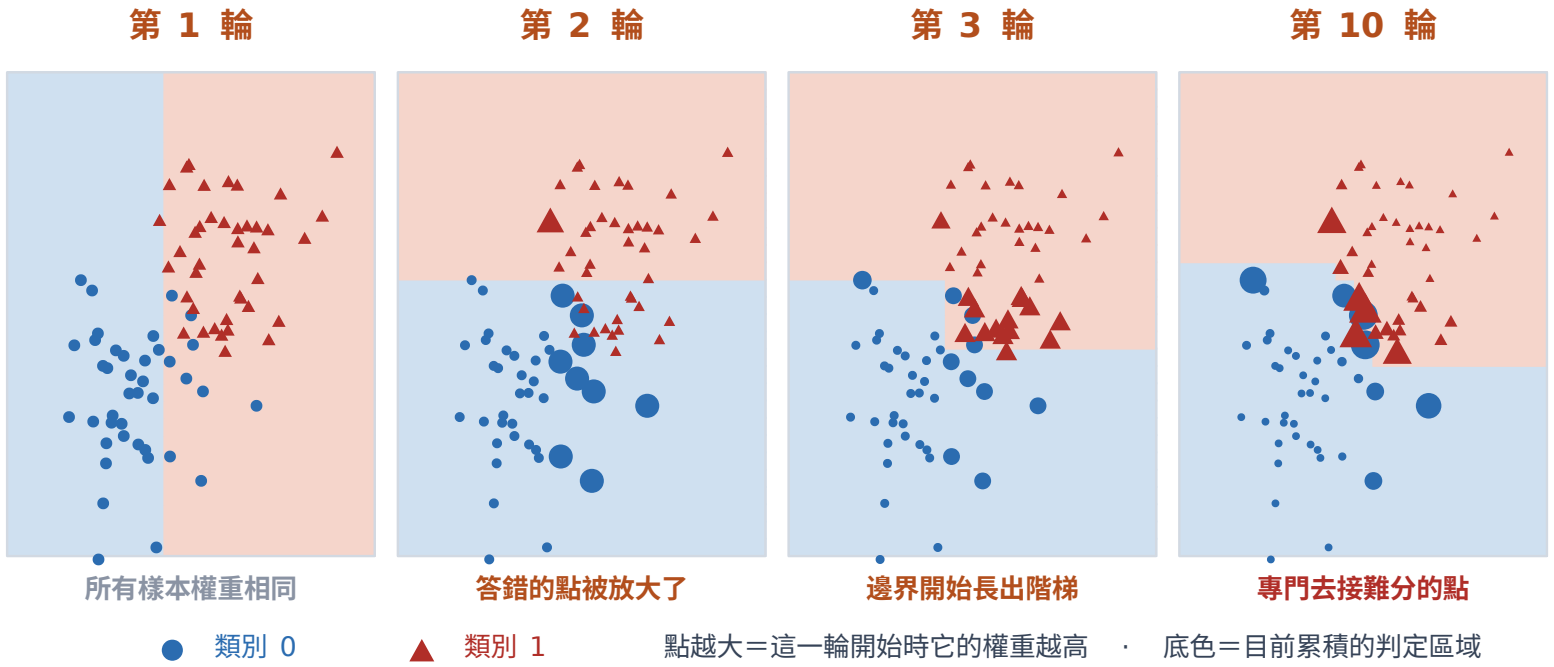
先跑森林拿穩定基準；時間允許再調提升去衝上限

**過擬合監控**

訓練與 CV 的差距（0.90 vs 0.87）持續擴大就該停

【原講義 ML 3.3】 pp215–220。數字為典型型態的教學示意。

# 實例： AdaBoost 每一輪在做什麼




第 1 輪每個點一樣大（權重都是 1/80）；到第 10 輪，只剩交界處那幾個點是大的——模型已經把全部注意力放在它們身上。它們若是標錯的雜訊，這就是災難。

**點的大小 ＝ 樣本權重**

一開始所有樣本權重相同（大小一致）

**第 1→2 輪**

被分錯的點變大了。下一個模型會被迫優先處理它們

**第 3→10 輪**

邊界逐漸長出階梯，專門去接那些難分的點

**風險**

若那些「難分的點」其實是標錯的雜訊，Boosting 會越陷越深——這是它的弱點

圖：課程自製（實際執行 AdaBoost 演算法） ★ 原生圖形，可直接在 PowerPoint 編輯

# AdaBoost 與 Stacking（認識即可，M4 深入）

## AdaBoost：加權重訓

- 每輪提高前一輪錯分樣本的權重
- 下一個弱模型更關注難例
- 最後依成員表現加權投票
- Boosting 的代表作（Freund & Schapire, 1997）
- 對離群值（Outlier）敏感——錯的離群值（Outlier）會被瘋狂加權
- AI Studio： AdaBoost Operator

## Stacking：用模型組合模型

- 第一層：多個異質模型產生預測
- 第二層： meta model 學習組合
- 第一層訓練預測必須是 out-of-fold，否則洩漏
- 威力最大、也最容易過擬合、最難解釋
- 競賽常勝軍；醫療部署少見
- AI Studio： Stacking Operator

M4 進階監督式學習會實作四種集成的完整比較（Ensemble - bagging vote stacking Adaboost.rmp）。

PART 13

# 模型比較總表

## The Big Comparison

九類模型放在同一張桌上。

沒有永遠的冠軍——只有適不適合你的場域。

# 九類模型全比較

| 模型 | 機率輸出 | 可解釋性 | 需縮放 | 過擬合傾向 | 定位 |
|---|---|---|---|---|---|
| **Logistic** | ★ 天生 | ★★★ OR 語言 | 要 | 低 | 第一個正式模型；醫學研究標準 |
| **LDA / QDA** | ★ | ★★ 判別函數 | 要 | 低 | 樣本少時的穩健選擇 |
| **k-NN** | 比例近似 | ★ 弱 | 必要 | k 小時高 | 直覺基準；少作最終部署 |
| **Naive Bayes** | 有（需校準檢查） | ★★ 中 | 不用 | 低 | 快速基準；文字問題強 |
| **SVM** | 需校準 | ★ 弱 | 必要 | C 大時高 | 高維中樣本的效能候選 |
| **神經網路 MLP** | ★ | ☆ 極弱 | 要 | 高 | 非結構化資料才是主場（M5） |
| **決策樹** | 比例近似 | ★★★ 可印出 | 不用 | 高（需剪枝） | 解釋用；轉臨床決策流程圖 |
| **隨機森林** | ★ 投票比例 | ★★ 特徵重要性 | 不用 | 低 | 結構化資料主力 |
| **梯度提升** | ★ | ★★ 特徵重要性 | 不用 | 中（參數敏感） | 強力候選；需仔細調參 |

實務流程不變： Logistic 建基準 → 樹看結構 → 森林／提升拚效能 → 依可解釋性需求決定最終部署。 SVM 與 MLP 屬「值得一試但通常不是答案」的候選。

# 演算法選擇速查：你的情況適合誰

| 應用場景 | Logistic | LDA | k-NN | NB | SVM | MLP | 決策樹 | 隨機森林 | 梯度提升 |
|---|---|---|---|---|---|---|---|---|---|
| 需要向臨床人員解釋每個判斷 | ● | ○ | | | | | ● | | |
| 需要報告勝算比 OR | ● | | | | | | | | |
| 樣本數很少（< 200） | ● | ● | | ● | | | ○ | | |
| 特徵數 > 樣本數 | ○ | | | ● | ● | | | | |
| 特徵高度非線性 | | | ● | | ● | ● | ● | ● | ● |
| 類別型特徵很多 | ○ | | | ● | | | ● | ● | ● |
| 追求最高預測效能 | | | | | ○ | ○ | | ● | ● |
| 要轉成紙本決策流程 | | | | | | | ● | | |
| 資料量大、需快速預測 | ● | ● | | ● | | ○ | ● | ● | ○ |

● 建議　○ 可用但非首選。實務作法：挑 3–4 個跑 Compare ROCs 一次比完，不要只用一個。

PART 14

# AI Studio 實作

## Hands-on Labs

Loan Risk 六步是本課程最完整的評估流程示範。
每步只加一件事，讓你看清楚各自的貢獻。

# 實作 1 ｜ Loan Risk 六步序列

【AI Studio 範例】 4. Case Studies / 4.3.3

### 開啟檔案

```
範例 /ML (AI Studio)/M2. 監督式學習 /
└ 4.3.3 Loan Risk/ (檔名為縮寫)
    ├ Ref 5.1 split data.rmp
    ├ Ref 5.2 imbalanced data.rmp
    ├ Ref 5.3 Compare Models - ROCs.rmp
    ├ Ref 5.4 decision tree tuning.rmp
    ├ Ref 5.5 CV + Optimized Params.rmp
    ├ Ref 5.6 Optimized Threshold.rmp
    └ ML in Finance.pdf

資料 /.../loan_train.rmhdf5table
```

### 預期結果

- 5.2 後 Recall 與 Precision 如何取捨，要看實際結果
- 5.5 的 CV 分數通常略低——這才是誠實的估計
- 5.6 的最佳門檻不一定是 0.5
- 「哪步提升最多」的答案因資料而異——這就是要你記錄的原因

### 操作步驟

1. 依序執行 5.1–5.6，每步記錄 Accuracy、Precision、Recall、AUC
2. 5.1 基準：注意 Split Data 是否為 stratified
3. 5.2 不平衡處理：Recall 升了多少？Precision 掉了多少？
4. 5.3 ROC 疊圖：四個演算法哪個 AUC 最高？差多少？
5. 5.4 決策樹調參：depth 與 leaf size 的最佳組合是？
6. 5.5 CV ＋參數最佳化：分數與單次切分差多少？
7. 5.6 門檻最佳化：最佳門檻是多少？隱含什麼代價比（Cost Ratio）？
8. 六步表格填入 Take-Home Assignment

# Loan Risk 六步紀錄表（隨堂填寫）

| 步驟 | Accuracy | Precision | Recall | AUC | Recall 變化 | 這一步加了什麼／觀察 |
|---|---|---|---|---|---|---|
| **Ref 5.1　切分基準（stratified？）** | | | | | — | |
| **Ref 5.2　不平衡處理** | | | | | | |
| **Ref 5.3　Compare ROCs** | | | | | | |
| **Ref 5.4　決策樹調參** | | | | | | |
| **Ref 5.5　CV ＋參數最佳化** | | | | | | |
| **Ref 5.6　門檻最佳化** | | | | | | |

Recall 變化＝本步 − 上一步。每步只加一件事，才看得出是哪個改動造成差異。

> 5.5 的 CV 分數通常略低——這才是誠實的估計； 5.6 的最佳門檻不一定是 0.5 。這張表就是作業任務 3 、 5 的骨架；網站版可直接填寫並下載 CSV 。

# 實作 2 ｜ HR Churn：特徵選擇（Feature Selection）與 Lift Chart

【AI Studio 範例】　4. Case Studies / 4.3.2

### 開啟檔案

```
範例 /ML (AI Studio)/M2. 監督式學習 /
└ 4.3.2 HR Churn/ (檔名為縮寫)
    ├ Case Study 1 - churn prediction
    │   (various feature selection).rmp
    ├ Case Study 1.1 Selection Criterion.rmp
    ├ Case Study 1.3 Compare ROCs and
    │   Lift Chart.rmp
    └ 1.3 Human Resources Dataset &
  模型選擇 .docx  ← 先讀

資料 /.../Human_Resources Churn dataset
     .rmhdf5table
```

### 預期結果

- 不同特徵選擇方法的結果不完全一致
- Lift Chart 直接回答「資源有限時先找誰」
- 說不出入選理由的變數，懷疑是巧合相關

### 操作步驟

1. 先讀說明文件，理解資料背景與欄位
2. 執行 Case Study 1，比較不同特徵選擇（Feature Selection）方法選出的欄位
3. 檢查特徵重要性排序—— ID 類欄位排前面＝洩漏警訊
4. 執行 1.3，檢視 ROC 疊圖與 Lift Chart
5. Lift 解讀：只介入前 10% 高風險者，能涵蓋幾成實際流失者?
6. 把「介入涵蓋率」翻譯成你專題場域的語言
7. 選定最終模型並寫下三行理由（效能＋解釋＋部署）

# 分類建模全流程總複習

1

**定義**

目標四要素
成功定義

2

**EDA**

類別比例
分組陽性率

3

**準備**

編碼、縮放
stratified 切分

4

**建模**

六模型＋ CV
前處理在 CV 內

5

**評估**

混淆家族
ROC/PR/Lift

6

**決策**

代價比→門檻
解釋與部署

貼在牆上的版本。每一步的細節都在本講義對應的 PART 裡。

# 多標籤：一個病人同時多個結果

### 多標籤資料的樣子

| 病人 | 再入院 | 跌倒 | 感染 |
|---|---|---|---|
| P1 | 1 | 0 | 1 |
| P2 | 0 | 0 | 0 |
| P3 | 1 | 1 | 0 |
| P4 | 0 | 1 | 0 |



### 三種策略

| 策略 | 做法 | 注意 |
|---|---|---|
| Binary Relevance | 每個標籤獨立訓練<br>一個二元模型 | 忽略標籤間相關 |
| Classifier Chains | 前一個標籤的預測<br>餵給下一個 | 順序影響結果 |
| 評估 | 每標籤各自報告<br>＋整體 Hamming loss | 別只報平均 |

【原講義 ML 3.3】 p14 的 multi-label。實務上「同時預測多種不良事件」就是這個問題——最簡單的 Binary Relevance 通常是合理起點。

# 從模型到部署： AI Studio 的模型物件工作流

| 步驟 | Operator | 說明 |
| --- | --- | --- |
| **1 訓練並存出模型** | Store | 把訓練好的模型存進 Repository |
| **2 新資料進來** | Retrieve + Read | 下個月的新出院病人 |
| **3 讀回模型套用** | Retrieve(model) + Apply Model | 不重訓，直接預測 |
| **4 前處理必須一致** | 存出 preprocessing model 一併套用 | 新資料要用「當初訓練集的」縮放參數 |
| **5 定期重訓與監控** | 排程重跑訓練流程 | 盛行率（Prevalence）或特徵分布飄移時警示 |

【AI Studio 範例】 Export-Import and Automatic model selection/01–04 就是這個流程的完整示範（匯入資料→建樹→套用→測試）。

# 實作 3 ｜ 自動模型選擇八步曲

【AI Studio 範例】 Export-Import and Automatic model selection / 01–08

### 開啟檔案

```
範例/ML (AI Studio)/M2. 監督式學習/
└ Export-Import 系列（原始位置:
    Export-Import and Automatic
    model selection/）
  01-import customer data.rmp
  02-build decision tree.rmp
  03-apply the model.rmp
  04-testing the model.rmp
  05-cross-validation.rmp
  06-model selection.rmp
  07-parameter optimization.rmp
  08-Automatic Model Selection and
     Optimization.rmp
```

### 預期結果

- 08 的結果通常略優於手動，但未必值得解釋成本
- 自動化取代的是「試錯的勞力」，不是「該優化什麼」的判斷
- AutoML 時代，這個界線更重要

### 操作步驟

1. 01–04：走一遍「訓練→存出→套用→測試」的部署流程
2. 05：把單次切分升級成交叉驗證，比較分數變化
3. 06： Select Sub-process 一次比較多個模型
4. 07： Optimize Parameters 自動掃參數格
5. 08：全自動版——模型選擇＋參數最佳化一次完成
6. 記錄 08 選出的最終模型與參數，和你在實作 1 手動調的結果比較
7. 思考：自動選出的模型，你能向個管師解釋它嗎?

# 案例收尾：出院風險分層的最終設計

## 模型組合

- 隨機森林（Random Forest）產生風險分數與前 20% 名單（Lift 3.3，涵蓋 65% 達標）
- Logistic（未正則化）提供 OR 表給醫學會議；決策樹（Decision Tree）前三層印成個管師的判讀卡
- 同一系統、三個模型、各司其職——這是實務常態，不是取巧

## 決策設定

- 門檻依代價比（Cost Ratio） 20:1 設在 0.30；每月重跑，監控盛行率與特徵分布飄移
- 名單附「主要風險因子」欄（樹路徑），個管師可覆核可推翻
- 小葉節點（Leaf Node）（<30 人）的個案標註「證據有限」

## 誠實的限制聲明

- 模型以本院資料訓練，他院或社區使用前需重新驗證（盛行率陷阱）
- 特徵重要性與樹路徑是預測性關聯，不是介入因果
- 同一病人多次住院需 group split；仍應報告殘餘限制

這是 Take-Home Assignment 報告最後一節的教學模板；其中數字與規則都必須換成你的資料、驗證結果與場域決策。

PART 15

# Take-Home Assignment

帶回家作業（分類篇）

主題：健康照護風險分類的完整演練

第 6 週上課前繳交 ｜ 與迴歸篇合併為一份報告，不另計分（隨堂 Lab）

# 作業任務（分類篇）

| 任務 | 要求 | 對應 |
| --- | --- | --- |
| **1　目標定義** | 比照本講義 P2 的四個決定，完整寫出你的目標變數定義（時間窗、事件定義、分母、預測時點）。 | P2 |
| **2　基準線** | 報告類別比例與「全判多數類」的 Accuracy。 | P7 |
| **3　六模型比較** | 以 stratified 5-fold CV 跑六個模型（Logistic、kNN、NB、樹、森林、梯度提升），報告四指標的平均 ± 標準差，附 Compare ROCs 疊圖。 | P4–P6, P11–P12 |
| **4　混淆矩陣（Confusion Matrix）六指標** | 對最佳模型手算六個指標（Accuracy、Precision、Recall、特異度、NPV、F1）。 | P7 |
| **5　不平衡與門檻** | 至少比較兩種不平衡處理；所有取樣只在訓練折。門檻在驗證資料依代價比（Cost Ratio）與容量選定。 | P8–P9 |
| **6　勝算比（Odds Ratio, OR）與樹的解讀** | Logistic：三個變數的 OR 與臨床解讀。決策樹：印出樹、描述前兩層的分裂邏輯是否符合臨床直覺。 | P5, P11 |
| **7　盛行率（Prevalence）敏感度（Sensitivity）** | 估算模型部署到「盛行率（Prevalence）減半」場域時的 PPV 變化。 | P7 |

# 回饋規準（迴歸＋分類合併，共 100 分，不計入學期成績）

| 向度 | 配分 | 評分重點 |
| --- | --- | --- |
| **目標與資料界定** | 15 | 目標定義四要素完整；資料檢查含偽裝遺失值（ Missing Data ） |
| **方法正確性** | 25 | stratified CV ；前處理在訓練子流程內；無取樣洩漏 |
| **評估完整性** | 25 | 指標計算正確；基準線與 ROC/PR 齊備；門檻有代價比依據 |
| **解讀與臨床意義** | 20 | OR 連同 95% 信賴區間、樹路徑解讀合理；盛行率情境分析有據；誠實面對不確定結果 |
| **報告品質** | 15 | 結構清楚；圖表可讀； .rmp 可執行；限制聲明專業 |

延伸挑戰： Lift Chart 的介入優先順序分析；或依性別 / 年齡層拆分指標的公平性初探（ M9 預習）。

# 本講義 Operator 總對照

| 用途 | Operator | 出現在 |
|---|---|---|
| **模型** | k-NN、 Logistic、 Naive Bayes、 Decision Tree、 Random Forest、 Gradient Boosted Trees | P4–P6, P11–12 |
| **評估** | Performance (Binominal)、 Compare ROCs、 Create Lift Chart、 Performance (Costs) | P7–P8 |
| **切分與驗證** | Split Data、 Cross Validation （stratified） | P10 |
| **不平衡** | SMOTE Upsampling、 Sample、 Set Role (weight) | P9 |
| **調參** | Optimize Parameters (Grid)、 Loop | P11–12 |
| **門檻** | Find Threshold、 Apply Threshold | P8 |
| **部署** | Store、 Retrieve、 Apply Model、 Group Models | P14 |
| **特徵** | Nominal to Numerical、 Normalize、 Forward Selection、 Weight by … | P3 |

找不到 Operator 時：左下搜尋框輸入英文關鍵字。名稱與版本可能隨 AI Studio 更新微調。

# 與你的貫穿主線的連結

## 本週你該對自己的題目做的三件事

- 把目標定義四要素（時間窗 / 事件 / 分母 / 預測時點）套進你的題目寫一遍
- 估計你的類別比例——它決定了你之後要用哪套指標與處理
- 列出你的代價比：漏一個的代價是誤報幾個？問你場域的專業人員

## Task 1 的伏筆

- 第 10 週期中發表的主體就是本週＋ M2-1 的完整流程
- 漸進改良表、六模型比較表、門檻決策——三張表構成你的方法論
- 現在開始邊學邊填，發表前一週才動手一定來不及

## 往後看

- M3：沒有標籤時怎麼辦（分群）； M4：集成的完整展開＋不平衡的進階
- M5：深度學習（Deep Learning）——你會發現 768 筆的資料上它常輸給今天的 Logistic
- M9：今天的特徵重要性（Feature Importance）與可解釋性議題，會以公平性的角度重新出現

# 公式總表（考前速查）

| 指標 | 公式 | 本講義例值 |
| --- | --- | --- |
| **Accuracy** | (TP+TN)/ 總數 | 0.925 |
| **Precision / PPV** | TP/(TP+FP) | 0.429 |
| **Recall / 敏感度** | TP/(TP+FN) | 0.750 |
| **特異度** | TN/(TN+FP) | 0.936 |
| **NPV** | TN/(TN+FN) | 0.983 |
| **F1** | 2PR/(P+R) | 0.545 |
| **Balanced Acc** | (Sens+Spec)/2 | 0.843 |
| **Odds** | $p/(1-p)$ | $p=0.75 \to 3$ |
| **OR** | $e^{\beta}$ | $\beta=0.693 \to 2.0$ |
| **Gini** | $1-\Sigma p_i^2$ | 30/70→0.42 |
| **Entropy** | $-\Sigma p_i \log_2 p_i$ | 30/70→0.881 |
| **Lift@k** | 命中率 @k ÷ 整體陽性率 | 前 20%→3.3 |

# 本講義術語速查（上）

| 術語 | 一句話 |
| --- | --- |
| **Hard / Soft 分類** | 直接給類別 vs 先給機率再切門檻 |
| **決策邊界（Decision Boundary）** | 模型把空間切成各類別區域的那條線 / 面 |
| **最大概似（Maximum Likelihood）** | 挑一組參數讓「實際觀察到的資料」機率最大 |
| **勝算 Odds** | $p/(1-p)$；機率 0.75 = 勝算 3 |
| **勝算比 OR** | 兩組勝算（Odds）之比；$e^{\beta}$ |
| **拉普拉斯平滑** | 避免沒見過的組合得到機率 0 |
| **分層抽樣（Stratified Sampling）** | 切分時維持類別比例 |
| **維度詛咒（Curse of Dimensionality）** | 維度高時距離失去鑑別力（k-NN 的天敵） |

# 本講義術語速查（下）

| 術語 | 一句話 |
| --- | --- |
| **Gini 不純度（Impurity）** | 隨機抽兩筆類別不同的機率 |
| **資訊增益** | 分裂前後不純度的下降量 |
| **剪枝 Pruning** | 限制或修剪樹的生長以抗過擬合 |
| **自助抽樣 Bootstrap** | 可放回抽樣出與原資料同大小的子集 |
| **OOB** | Out-of-Bag：沒被抽到的樣本，免費的驗證集 |
| **Lift** | 前 x% 高風險名單的命中率是隨機的幾倍 |
| **校準 Calibration** | 模型說 70% 時，實際是不是 70% |
| **代價比** | 一個 FN 抵幾個 FP 的成本——門檻的依據 |

# 必答思考題（寫入報告）

Q 1

**AUC 0.85 的模型和 AUC 0.83 但 Recall 高很多的模型，你部署哪個?**

AUC 是全門檻的平均表現；你部署時只活在一個門檻上。

Q 2

**你的決策樹第一刀切在哪個變數？臨床上說得通嗎？如果說不通，下一步是什麼?**

說不通的第一刀通常指向資料洩漏（Data Leakage）或編碼錯誤，而不是「有趣的發現」。

Q 3

**隨機森林比單棵樹準，卻更難解釋。你的場域裡，這個交換值得嗎?**

想想誰要為判斷負責、誰需要推翻模型的能力。

Q 4

**把你的模型從醫院推到社區（盛行率降為 1/5），哪些指標會變、哪些不變?**

敏感度 / 特異度（Specificity） vs PPV/NPV 的差別——這題就是 P7 的核心。

# 總檢核｜出門前四題

Q 1

**用一句話說明：為什麼本講義的模型 Accuracy 0.925 卻「輸給什麼都不做」？**

全判陰性得 0.940。不平衡資料上 Accuracy 會獎勵懶惰。

Q 2

**若只是純盛行率改變、且條件效能固定，敏感度、特異度、 PPV 、 NPV 哪兩個一定要重算?**

PPV 與 NPV。它們是盛行率的函數。

Q 3

**你的隨機森林 AUC 0.86 、 Logistic 0.83。什麼情況下你仍該部署 Logistic ?**

需要 OR 語言溝通、需要個案級解釋、或 0.03 的差距在你的門檻附近根本不影響名單。

Q 4

**Take-Home 的第一步是什麼? （提示：不是打開 AI Studio ）**

把目標定義四要素寫下來。定義錯了，後面全白做。

# 中英術語對照｜ M2-2 分類

（1 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **分類** | Classification | 預測類別 |
| **二元分類** | Binary Classification | 兩種類別 |
| **多元分類** | Multi-class Classification | 三種以上、互斥 |
| **多標籤** | Multi-label | 一筆可同時屬於多個標籤 |
| **硬分類／軟分類** | Hard / Soft Classification | 直接給類別 vs 先給機率 |
| **決策邊界** | Decision Boundary | 模型把空間切成各類別區域的界線 |
| **k 最近鄰** | k-Nearest Neighbors, k-NN | 看最近的 k 個鄰居投票 |
| **維度詛咒** | Curse of Dimensionality | 高維時距離失去鑑別力 |
| **邏輯斯迴歸** | Logistic Regression | 以 Sigmoid 輸出機率的線性模型 |

# 中英術語對照｜ M2-2 分類

（2 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **最大概似** | Maximum Likelihood Estimation, MLE | 讓觀察到的資料機率最大的參數 |
| **勝算** | Odds | p / (1−p) |
| **勝算比** | Odds Ratio, OR | 兩組勝算之比； e^β |
| **風險比** | Risk Ratio, RR | 兩組風險之比；事件常見時與 OR 差距大 |
| **單純貝氏** | Naive Bayes | 假設特徵獨立的機率分類器 |
| **拉普拉斯平滑** | Laplace Smoothing | 避免未見過的組合機率為 0 |
| **混淆矩陣** | Confusion Matrix | TP / FN / FP / TN 的 2×2 表 |
| **準確率** | Accuracy | (TP+TN)/ 總數；不平衡時會誤導 |
| **精確率／陽性預測值** | Precision / Positive Predictive Value, PPV | 說有病的人裡真的有病的比例 |

# 中英術語對照｜ M2-2 分類

（3 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **召回率／敏感度** | Recall / Sensitivity / TPR | 真的有病的人裡被抓到的比例 |
| **特異度** | Specificity / TNR | 沒病的人裡被正確排除的比例 |
| **陰性預測值** | Negative Predictive Value, NPV | 說沒病的人裡真的沒病的比例 |
| **F1 分數** | F1 Score | Precision 與 Recall 的調和平均 |
| **平衡準確率** | Balanced Accuracy | ( 敏感度＋特異度 )/2 |
| **馬修斯相關係數** | Matthews Correlation Coefficient, MCC | 四格全入的相關係數，最難被騙 |
| **盛行率** | Prevalence | 母體中陽性的比例； PPV 隨它大幅變動 |
| **ROC 曲線** | Receiver Operating Characteristic Curve | 掃過所有門檻的 FPR–TPR 軌跡 |
| **曲線下面積** | Area Under the Curve, AUC | ROC 下的面積；與門檻無關 |

# 中英術語對照｜ M2-2 分類

（4 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **PR 曲線** | Precision-Recall Curve | 不看 TN，極度不平衡時更誠實 |
| **決策門檻** | Decision Threshold | 把機率切成類別的那個值（預設 0.5） |
| **代價比** | Cost Ratio | 一個偽陰性抵幾個偽陽性；門檻的依據 |
| **校準** | Calibration | 模型說 70% 時實際是不是 70% |
| **類別不平衡** | Imbalanced Data | 某一類遠少於另一類 |
| **過取樣** | Oversampling | 複製少數類至平衡 |
| **合成少數類過取樣** | Synthetic Minority Over-sampling Technique, SMOTE | 在少數類樣本間內插造出新樣本 |
| **欠取樣** | Undersampling | 刪除部分多數類樣本 |
| **類別權重** | Class Weight | 訓練時加重少數類的損失 |

# 中英術語對照｜ M2-2 分類

（5 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **分層抽樣** | Stratified Sampling | 切分時維持類別比例一致 |
| **決策樹** | Decision Tree | 一連串是 / 否問題逐層切分資料 |
| **不純度** | Impurity | 節點內類別混雜的程度 |
| **吉尼不純度** | Gini Impurity | 隨機抽兩筆類別不同的機率 |
| **熵** | Entropy | 資訊理論的不確定性度量 |
| **資訊增益** | Information Gain | 分裂前後不純度的下降量 |
| **增益率** | Gain Ratio | 懲罰高基數特徵的增益指標 |
| **剪枝** | Pruning | 限制或修剪樹的生長以抗過擬合 |
| **葉節點** | Leaf Node | 樹的末端；最終判定所在 |

# 中英術語對照｜ M2-2 分類

（6 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **集成學習** | Ensemble Learning | 組合多個模型以提升穩定與效能 |
| **投票法** | Voting | 結合不同種類模型的預測 |
| **裝袋法** | Bagging / Bootstrap Aggregating | 不同抽樣子集訓練同種模型後平均 |
| **自助抽樣** | Bootstrap | 可放回抽樣出同大小的子集 |
| **袋外樣本** | Out-of-Bag, OOB | 未被抽中的樣本；免費的驗證集 |
| **隨機森林** | Random Forest | Bagging ＋ 分裂時隨機選特徵 |
| **提升法** | Boosting | 序列訓練，每個新模型修正前者的錯 |
| **梯度提升** | Gradient Boosting | 以殘差為目標序列疊加弱模型 |
| **堆疊法** | Stacking | 以 meta 模型學習如何組合第一層預測 |

# 中英術語對照｜ M2-2 分類

（7 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **特徵重要性** | Feature Importance | 各特徵對模型貢獻的相對大小 |
| **排列重要性** | Permutation Importance | 打亂該欄後分數掉多少 |
| **提升度** | Lift | 前 x% 名單的命中率是隨機的幾倍 |
| **累積增益** | Cumulative Gain | 前 x% 名單涵蓋多少實際陽性 |
| **學習曲線** | Learning Curve | 分數隨訓練樣本數的變化 |
| **支援向量機** | Support Vector Machine, SVM | 找間隔最寬的分隔超平面 |
| **間隔** | Margin | 決策邊界到最近樣本的距離 |
| **支持向量** | Support Vector | 決定邊界位置的那少數幾個樣本 |
| **核技巧** | Kernel Trick | 映射到高維空間以處理非線性可分 |

# 中英術語對照｜ M2-2 分類

（8 / 8）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **線性判別分析** | Linear Discriminant Analysis, LDA | 假設常態且等共變異的判別方法 |
| **二次判別分析** | Quadratic Discriminant Analysis, QDA | 允許各類別共變異不同的判別方法 |
| **多層感知器** | Multilayer Perceptron, MLP | 最基本的前饋神經網路 |
| **反向傳播** | Backpropagation | 神經網路更新權重的演算法 |
| **極端隨機樹** | Extremely Randomized Trees | 切點也隨機選的森林變體 |

# 分類篇重點回顧

1. 目標定義有四個隱藏決定：時間窗、事件、分母、預測時點——先寫清楚再建模。
2. Accuracy 在不平衡資料會輸給「什麼都不做」；醫療場域看 Recall 與 Precision。
3. 敏感度 / 特異度不受盛行率影響， PPV/NPV 隨盛行率變——換場域必須重新評估。
4. 0.5 只是軟體預設。門檻由代價比決定，而代價比是臨床判斷。
5. 取樣只在訓練集做；分層 CV 是分類作業的預設要求。
6. Logistic 、樹、森林與提升各有角色；最終部署要共同考量驗證效能、校準、可解釋性與場域限制。

**下一步　第 6 週　M3 非監督式學習：分群（Clustering）與降維　＋　作業一發布**

# 課後複習：本單元的互動學習站

掃描 QR code 或輸入網址；手機、平板、電腦都能用

**掃我開啟 M2-2 互動版**

手機相機對準即可開啟

網址

**nchsieh.github.io/assets/courses/001/interactive/m2-2/**

### 14 節，順序對應講義各 PART

看完一個 PART 就做對應的那一節，不必一次做完

### 改參數、立刻看結果

圖表可以拖拉調整，看懂「為什麼」，而不只是背結論

### 隨堂練習＋即時回饋

答錯會說明原因；作答進度只存在你自己的瀏覽器

全部單元入口： nchsieh.github.io/assets/courses/001/interactive/ · 網站內容為教學示例與模擬資料，不需登入