

分類：從 k-NN 到集成方法

M2-2 — Classification: From k-NN to Ensembles

本課程份量最重的單元。以原課程 ML 3.3（235 頁）為本改寫：
五種演算法、完整評估體系、不平衡處理、集成方法——醫療預測的核心工具箱。

本講義大綱

01 分類 101 · 目標、類型、工作流程

02 定義目標變數 · 最容易被輕忽的一步

03 特徵工程（Feature Engineering）與切分 · 分類版的準備工作

04 k-NN · 距離手算 + k 值選擇

05 Logistic 迴歸 · Sigmoid、勝算比（Odds Ratio, OR）、正則化（Regularization）

06 Naive Bayes · 貝氏定理的快速分類器

07 混淆矩陣（Confusion Matrix）家族 · 六個指標與盛行率陷阱

08 ROC、PR 與門檻 · 評估的完整體系

09 類別不平衡（Imbalanced Data） · 五種處理與三個鐵則

10 交叉驗證（Cross Validation） · 三份切分、巢狀 CV 與學習曲線

11 決策樹（Decision Tree） · Gini 手算 + 剪枝（Pruning）

12 集成方法 · Voting、隨機森林、梯度提升

13 模型比較總表 · 怎麼選、怎麼報告

14 AI Studio 實作 · Loan Risk 六步 + HR Churn

15 Take-Home Assignment · 分類完整演練

貫穿本講義的案例：出院準備服務的風險分層

情境

- ▶ 你是醫院品管中心的資料分析師。院方要推「出院準備服務加強方案」，但個管師人力只夠追蹤兩成的出院病人
- ▶ 任務：建立 30 天非計畫性再入院的風險模型，讓有限人力花在最需要的人身上

你手上的資料

- ▶ 近三年出院病人 12,000 筆：人口學、診斷、住院天數、檢驗值、過往就醫紀錄、出院去向
- ▶ 30 天內非計畫性再入院率約 6%——標準的不平衡問題

成功的定義（先寫好，再動手）

- ▶ 個管師追蹤的前 20% 高風險名單，要涵蓋至少六成的實際再入院者（Lift 觀點）
- ▶ 名單要附「為什麼是他」的理由——個管師不接受無法解釋的黑箱名單
- ▶ 本講義每一節的技術，最後都會回到這個案例

【原講義 ML 3.3】 pp5-8 的 National Bank 案例結構，改寫為健康照護場景。原講義的做法值得學：先講清楚情境與成功定義，才開始講技術。

PART 01

分類 101

Classification Basics

分類預測的是「屬於哪一類」。

但好的分類器給你的不只是類別——還有機率。

分類的三種類型

類型	目標變數	例子	注意
二元分類 Binary	兩種值	會不會再入院； 是否為垃圾郵件	本週的主軸； 醫療風險預測多屬此類
多元分類 Multi-class	三種以上，互斥	CMS 等級 1-8 ； 檢傷分級 1-5	每筆只屬一類； 注意類別是否有序
多標籤 Multi-label	可同時多個	一位病人同時有 多項共病診斷	每個標籤各自是 一個二元問題

【原講義 ML 3.3】 p14 。有序的多元類別（如檢傷分級）介於分類與迴歸之間——把「差一級」和「差四級」當成一樣的錯，是常見的浪費。

Hard 分類與 Soft 分類

Hard：直接給類別

- ▶ 輸出：「會再入院」或「不會」
- ▶ 簡單直接，但丟失信心資訊
- ▶ 「51% 會」和「99% 會」被當成同一件事
- ▶ 無法調整決策門檻（Decision Threshold）
- ▶ k-NN 多數決（Majority Vote）、決策樹（Decision Tree）的預設輸出屬此類

Soft：先給機率，再決定

- ▶ 輸出：「再入院機率 0.73」
- ▶ 保留完整的信心資訊
- ▶ 可依場域的代價比（Cost Ratio）自訂門檻
- ▶ 可以排序：先處理機率最高的個案
- ▶ ★ 醫療場域幾乎都應該用 Soft
- ▶ Logistic、Naive Bayes 天生輸出機率

【原講義 ML 3.3】 pp77-79、136-139。原講義特別提醒：模型輸出的「機率」是相對排序的分數，未必等於真實的事件發生率（需要校準才能當機率讀）。

分類建模工作流程



【原講義 ML 3.3】 p15。與迴歸最大的差異在第一步與最後一步：目標定義與門檻調整——這兩步都是「決策」而不是「計算」。

PART 02

定義目標變數

Defining the Target

「預測再入院」聽起來很明確。
實際動手時你會發現至少要做四個決定。

「預測再入院」的四個隱藏決定

決定	選項	影響
時間窗	出院後 14 天？ 30 天？ 90 天？	窗越短事件越少（更不平衡）； 窗越長「與此次住院的關聯」越弱
哪種再入院算	全部？ 同科別？ 非計畫性？	計畫性化療回診算不算「再入院」？ 定義不同，模型學的東西完全不同
分母是誰	所有出院病人？ 排除死亡？ 排除轉院？	排除條件會改變盛行率（Prevalence）， 也改變模型的適用對象
預測時點	出院當天？ 入院 48 小時內？	決定了哪些特徵「當時拿得到」—— 用了之後才有的資料就是時間洩漏

【原講義 ML 3.3】 pp20-21。原講義的例子是「顧客流失」的定義；醫療場域的對應就是這張表。目標定義寫不清楚的專案，做出來的模型無法被任何人使用。

同一份資料，兩種目標定義

原始就醫紀錄

病人	出院日	下次入院	間隔天數
P1	3/01	3/12	11
P2	3/03	4/20	48
P3	3/05	—	—
P4	3/08	3/29	21
P5	3/10	6/15	97



兩種標籤

病人	30 天定義	90 天定義
P1	1	1
P2	0	1
P3	0	0
P4	1	1
P5	0	0

P2 的標籤翻轉

30 天定義是陰性、90 天定義是陽性——同一個人，兩個答案

盛行率也變了

30 天： $2/5 = 40\%$ ； 90 天： $3/5 = 60\%$ 。所有指標的基準都不同

沒有對錯

選哪個取決於介入方案：出院衛教管 30 天，慢性病管理管 90 天

報告要求

目標定義必須完整寫進報告第一節，包括排除條件

這就是為什麼 Take-Home Assignment 的任務 1 是「寫清楚目標定義」而不是直接建模。

分類的 EDA：三張必看的圖

看什麼	怎麼看	要找什麼
目標的類別比例	長條圖或一個百分比	不平衡程度。6% 與 40% 的問題是兩種完全不同的仗
數值特徵 × 類別	按類別分組的盒鬚圖 (再入院者 vs 未再入院者的年齡分布)	兩組分布有沒有分開？ 分得越開，該特徵越有預測力
類別特徵 × 類別	交叉表 + 各組陽性率 (各出院去向的再入院率)	哪些類別的陽性率特別高？ 樣本太少的類別要先合併

【原講義 ML 3.3】 pp19-23。AI Studio：Statistics 看比例；Charts 的 Box Plot 選 group by label；Aggregate 算分組陽性率。

分組陽性率：一眼看出誰是強特徵

各出院去向的再入院率

出院去向	人數	再入院數	再入院率
回家（自理）	6,000	180	3.0%
回家（家人照顧）	3,600	252	7.0%
護理之家	1,800	216	12.0%
呼吸照護病房	600	72	12.0%
整體	12,000	720	6.0%



判讀

特徵	判讀
出院去向	3% → 12%，四倍差距 = 強特徵
樣本量檢查	呼吸照護僅 600 筆， 12% 的估計較不穩
行動	可考慮把兩個 12% 的 類別合併
下一步	把這類表格對每個 類別特徵都做一遍

為什麼有效

陽性率在組間差異越大，該特徵切下去的資訊增益（Information Gain）越高——決策樹（Decision Tree）自己也是這樣挑的

陷阱

小樣本類別的比率不可靠。600 筆的 12% ± 誤差可能蓋過與 7% 的差距

這張表的另一個用途

它就是「單特徵基準線」：只用出院去向分四級，已經是一個可用的粗模型

數字為教學設計。實務上這張表做完，你對「模型大概能做到多好」已經有底了。

PART 03

特徵工程與資料切分

Features & Splitting

大部分與迴歸相同（M1、M2-1 已 covered），
這裡只講分類特有的三件事。

分類特有的三件事

分層切分（Stratified Split）

- ▶ 隨機切分在不平衡資料上，某一份可能幾乎沒有陽性樣本
- ▶ 分層切分（Stratified Split）維持每份的類別比例一致。AI Studio：sampling type = stratified
- ▶ ★ 本課程所有分類作業的預設要求

類別編碼的目標視角

- ▶ One-Hot 在高基數類別（High Cardinality）會產生大量稀疏欄位
- ▶ 替代：頻率編碼（用出現次數）或分組（依臨床意義合併成大類）
- ▶ 目標編碼（Target Encoding）會學到標籤資訊，必須只在每個 CV 訓練折內估計


縮放：看你用哪個演算法

- ▶ k-NN、SVM、含正則化的 Logistic、神經網路：通常需要縮放
- ▶ 決策樹、隨機森林（Random Forest）、梯度提升（Gradient Boosting）、Naive Bayes：不需要
- ▶ 縮放參數一律從訓練集算（M1 的鐵則，此處再次適用）


【原講義 ML 3.3】 pp30-45

實例：分類 EDA 的兩張關鍵圖

左・年齡 × 是否再入院



右・各出院去向的再入院率



左圖看「連續特徵分不分得開」，右圖看「類別特徵的陽性率差多少」。兩張圖都畫完，你大致就知道模型能學到什麼了。

左・分組盒鬚圖

再入院組的年齡分布整體高一截——分得越開，特徵越有預測力

右・分組陽性率

出院去向從 3% 到 12%，四倍差距＝強特徵。這就是前頁表格的圖形版

先看圖再建模

這兩張圖看完，你已經知道模型大概會抓什麼、能做到多好

AI Studio

Charts → Box Plot (group by label) ; Aggregate 算分組比率後畫 Bar

類別太多時：頻率編碼（Frequency Encoding）與分組

480 個診斷碼的困境

主診斷碼	出現次數	One-Hot 的問題
I50 心衰竭	1,850	480 個診斷碼
J18 肺炎	1,320	= 480 個新欄位
N39 泌尿道感染	990	多數欄位幾乎全 0
E11 第 2 型糖尿病	870	模型難以學習
……其餘 476 碼	6,970	且極易過擬合



四種出路

策略	做法	結果
頻率編碼（Frequency Encoding）	以出現次數取代類別	1 個數值欄位
臨床分組	按器官系統合併 (心血管 / 呼吸 / 泌尿...)	10-15 個類別
保留 Top-k	前 20 碼各自一欄， 其餘併入「其他」	21 個欄位
目標編碼（Target Encoding）	以各碼的再入院率取代	威力大，但必須 在 CV 內做（洩漏）

臨床分組通常最好

它注入了領域知識，且每組樣本量足夠、可解釋

目標編碼（Target Encoding）的警告

用整份資料的陽性率＝把答案偷渡進特徵。目標編碼（Target Encoding）必須只在每個 CV 訓練折內估計，必要時做平滑

檢查

編碼後檢查未見資料表現與特徵重要性（Feature Importance）；單一欄位異常突出時，回查時間點、ID 與標籤洩漏

【原講義 ML 3.3】 pp36-41 的 dummy variables 與 binning，延伸到醫療高基數類別的實務處理。

k-NN：最直覺的分類器


k-Nearest Neighbors

它甚至不算「學習」——它只是把訓練資料背起來，
新個案來的時候，看最像的 k 個鄰居怎麼樣。

手算： P6 會不會再入院？（ k=3 ）

距離計算（ Min-Max 正規化後）

病人	年齡	住院天數	再入院	正規化（年齡，天數）	距 P6
P1	55	3	否	(0.00, 0.00)	0.905
P2	78	9	是	(0.88, 0.75)	0.262
P3	62	5	否	(0.27, 0.25)	0.537
P4	81	11	是	(1.00, 1.00)	0.510
P5	70	7	是	(0.58, 0.50)	0.147
P6	72	8	？	(0.65, 0.63)	—



不同 k 的判定

k	最近鄰	票數	判定
1	P5	是 1:0	是
3	P5, P2, P4	是 3:0	是
5	全部	是 3:2	是
機率輸出	k=5 時	3/5	0.60

步驟

① 正規化 → ② 算歐氏距離 → ③ 取最近 k 個 → ④ 多數決（ Majority Vote ）（或算比例當機率）

為什麼要正規化（ Normalization ）

年齡值域 26、天數值域 8。不正規化時年齡獨大，天數形同虛設

k 的效果

k 小 → 邊界複雜、對雜訊敏感（過擬合）； k 大 → 邊界平滑、可能欠擬合（ Underfitting ）

k 怎麼選

二元硬投票可先試奇數以減少平手；在合理範圍掃描 k，依交叉驗證（ Cross-Validation ）與業務指標選擇

【原講義 ML 3.3】 pp49-71。距離已實際驗算。 AI Studio： k-NN Operator，記得前面接 Normalize。

k-NN 工作流程




【原講義 ML 3.3】 p62。第一步忘了做，整個模型等於只看值域最大的那個特徵——這是 k-NN 最常見的死法。

k 值的過擬合（Overfitting）曲線

k 從 1 掃到 101

k	訓練 Accuracy	CV 驗證 Accuracy	診斷
1	1.000	0.71	嚴重過擬合
5	0.89	0.78	仍偏複雜
15	0.84	0.82	★ 甜蜜點附近
31	0.82	0.81	開始欠擬合（Underfitting）
101	0.76	0.74	太平滑



判讀

現象	原因
k=1 訓練必為 1.0	每個點最近的鄰居是它自己
k 增大訓練分數降	邊界越來越平滑，記不住雜訊
測試分數先升後降	偏誤（Bias）- 變異（Variance）取舍的標準形狀
選 k 的方法	測試（CV）分數最高點

k=1 的教訓

訓練分數 100% 毫無意義——它只是記憶，不是學習

與多項式次數同構

M2-1 的九次多項式、這裡的 k=1，都是同一個過擬合故事


AI Studio

Optimize Parameters (Grid) 包住 CV，掃 k 的範圍


【原講義 ML 3.3】 pp70-74

實例：k 值如何改變 k-NN 的邊界

左 · $k = 1$ 邊界破碎（記住每一筆）



右 · $k = 15$ 邊界平滑（學到型態）



● 未再入院

▲ 再入院

底色 = 模型判定的類別區域

兩張圖的資料點完全相同，只有 k 換了。左圖為了遷就幾個落在對方陣營的點，在邊界上挖出一個個小島——那些小島就是過擬合的長相。

左 · $k=1$

邊界破碎、圍著單一樣本畫小圈圈——訓練分數 100%，但那是記憶不是學習

右 · $k=15$

邊界平滑，個別雜訊點被多數鄰居稀釋——泛化能力較好

對應前頁的表

k 掃描表的 $0.71 \rightarrow 0.82$ ，就是從左圖走到右圖的過程

紅三角 = 再入院

注意兩群交界處：那裡的個案本來就難分，任何模型都一樣

距離的三種算法

距離	公式概念	特性	適用
歐氏 Euclidean	直線距離 $\sqrt{\sum (\text{差})^2}$	最直覺的預設； 大差異被平方放大	一般數值特徵 (正規化後)
曼哈頓 Manhattan	沿座標軸走 $\sum \text{差} $	對單一特徵的極端差 較不敏感	含離群值 (Outlier)、 高維度時較穩
餘弦 Cosine	夾角相似度	只看方向不看長度	文字向量 (M6)、 就醫「型態」比較

AI Studio：k-NN 的 measure types 參數。醫療上的例子：比較兩位病人的「用藥組合型態」用餘弦；比較「檢驗值」用歐氏。

k-NN 的優缺點

優點

- ▶ 概念最直覺，向任何人都解釋得通
- ▶ 不假設資料形狀——彎的邊界也抓得到
- ▶ 天生支援多元分類
- ▶ 沒有訓練時間（直接背資料）
- ▶ 新資料加入即刻生效，不需重訓

缺點

- ▶ 預測慢：每次都要算與全部訓練資料的距離
- ▶ 資料量大時記憶體與速度都是問題
- ▶ 維度高時距離失去意義（維度詛咒）
- ▶ 對不相關特徵敏感——垃圾欄位會污染距離
- ▶ 可解釋性弱：只能說「跟這幾個人像」，說不出為什麼

【原講義 ML 3.3】 p80。定位：k-NN 是很好的「第二意見」與基準線，但很少作為醫療場域的最終部署模型。


五種模型的決策邊界（Decision Boundary）長相

模型	邊界形狀	代表什麼	抓得到彎的關係嗎
Logistic	一條直線（超平面）	特徵的線性加權	不行（除非手動加多項式）
k-NN	不規則、貼著資料	局部多數決（ Majority Vote ）	可以，但邊界破碎
Naive Bayes	平滑曲線	各類別的機率分布交界	部分（依分布假設）
決策樹（ Decision Tree ）	軸平行的階梯	一連串單變數切分	可以，但斜線要切很多刀
隨機森林（ Random Forest ）	平滑化的階梯	數百棵樹的平均	可以，且較平滑


【原講義 ML 3.3】各演算法章節的邊界圖總結。直覺：資料的真實邊界長什麼樣，決定哪個模型天生佔優——這就是「沒有免費午餐」定理的日常版。

實例：四種模型，四種邊界


① Logistic：一條直線




② 決策樹：軸平行的階梯



③ k-NN (k=15)：貼著資料的曲線



④ 隨機森林：平滑化的階梯



● 未再入院

▲ 再入院

底色＝該模型判定的類別區域（同一份資料、同一組座標）

Logistic

一條直線。簡潔、可解釋，但斜的彎的都只能用這一條直線近似

決策樹（Decision Tree）

軸平行的階梯——每一刀都只問一個特徵

k-NN

貼著資料的曲線邊界，交界處最忠實也最容易受雜訊影響

隨機森林（Random Forest）

把樹的階梯平均成較平滑的邊界——這就是集成的效果

PART 05

Logistic 迴歸

Logistic Regression

醫學文獻出現頻率最高的模型。

優勢不只在效能，更在係數（Coefficient）可轉成勝算比（Odds Ratio, OR），便於溝通條件關聯。

Sigmoid：把任意數字壓成機率

Sigmoid 數值表

線性組合 z	$p = 1/(1+e^{-z})$	判定 (門檻 0.5)
-4	0.018	陰性
-2	0.119	陰性
-1	0.269	陰性
0	0.500	邊界
+1	0.731	陽性
+2	0.881	陽性
+4	0.982	陽性



四個性質

性質	意義
S 型曲線	中段陡、兩端平
$z=0$ 對應 $p=0.5$	線性組合的 0 就是決策邊界 (Decision Boundary)
中段最敏感	邊界附近的個案，特徵的微小變動 (Small Changes) 影響較大
兩端飽和	z 很大之後再增加，機率幾乎不動
對稱	$p(z) = 1 - p(-z)$

整個模型

$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots$ ，然後 $p = \text{sigmoid}(z)$

訓練目標

最大概似 (Maximum Likelihood)：找一組 β 讓「實際發生的事」機率最大 (原講義 pp97-103 的數學，此處只需直覺)

決策邊界 (Decision Boundary)

$p=0.5 \Leftrightarrow z=0 \Leftrightarrow$ 一條直線 (超平面)。所以 Logistic 的邊界是直的

邊界是直的

代表它抓不到彎的關係——需要彎的邊界時考慮樹或 k-NN

【原講義 ML 3.3】 pp84-96。數值已驗算。原講義用 14 頁推導概似函數 (pp90-103)，本課程略過推導、直接用結論。

係數（Coefficient）→ 勝算比（Odds Ratio, OR）：醫學文獻的通用語言

模型輸出

變數	係數 β	p 值
年齡（每 1 歲）	+0.045	<0.001
糖尿病（有 =1）	+0.693	<0.001
性別（女 =1）	-0.105	0.460



勝算比

變數	OR = e^{β}	解讀
年齡 +1 歲	1.046	勝算（Odds）+4.6%
年齡 +10 歲	1.568	勝算（Odds）+56.8%
糖尿病	2.000	勝算為 2 倍
性別（女）	0.900	p=0.46 不顯著，不應解讀

勝算 odds

$p/(1-p)$ 。機率 0.5 = 勝算 1；機率 0.75 = 勝算 3

為什麼是 e^{β}

Logistic 對「勝算的對數」做線性迴歸（Linear Regression），所以 β 取指數=勝算比

連續變數換算

每 k 單位：OR = $e^{(k \times \beta)}$ 。年齡 10 歲 = $e^{0.45} = 1.568$

OR $\neq$ RR

事件常見時 OR 會誇大相對風險——醫學文獻解讀的常見誤區

【原講義 ML 3.3】 pp110-111

Logistic 迴歸工作流程



正則化（Regularization）強度的選擇（Logistic + Ridge）

λ 的掃描結果

λ（懲罰）	訓練 AUC	CV AUC	係數（Coefficient）的樣子
0（無）	0.87	0.79	幾個係數極大，共線性（Collinearity）原形畢露
0.01	0.86	0.81	略收縮
0.1	0.84	0.83	★ CV 最高
1.0	0.80	0.80	明顯壓扁
10	0.72	0.71	全被壓向 0，欠擬合（Underfitting）



四個原則

原則	說明
先標準化（Standardization）	懲罰才公平
掃 λ + CV	選 CV 分數最高
訓練分數必降	這是正常的、刻意的犧牲
醫學報告注意	正則化（Regularization）後的係數不宜直接當 OR 解讀

最後一點很重要

正則化把係數往 0 拉，OR 因此被系統性低估。要報告 OR 就用未正則化的版本

兩個模型並用

解釋用無正則化的 Logistic；預測用正則化調到最好的版本——目的不同，模型可以不同

【原講義 ML 3.3】 pp114-120

正則化（Regularization）與多元分類

Logistic 也需要正則化（Regularization）

- ▶ 變數多、樣本少或近乎完美可分時，係數可能不穩，正則化可抑制極端值
- ▶ L2（Ridge）收縮係數；L1（Lasso）可讓部分係數為 0
- ▶ 強度 C 或 λ 用交叉驗證（Cross Validation）選；正則化前必須標準化（與迴歸篇相同）

多元分類的兩種策略

- ▶ One-vs-Rest：k 類拆成 k 個「這類 vs 其他」的二元問題，取機率最高者
- ▶ Softmax（多項 Logistic）：直接輸出 k 類機率，總和為 1
- ▶ AI Studio 的 Logistic Regression 遇到多元標籤時自動處理，但你要知道它在做什麼

優缺點小結

- ▶ 優點：可輸出機率、係數可轉 OR、訓練快
- ▶ 缺點：決策邊界是直的；特徵工程（Feature Engineering）的品質決定它的上限
- ▶ 定位：★ 幾乎永遠應該是你的第一個正式模型——它就是分類問題的基準線

【原講義 ML 3.3】 pp114-124

Logistic 也有假設：logit 的線性

假設內容

- ▶ Logistic 假設「勝算的對數」與每個連續特徵呈線性關係
- ▶ 年齡 40→50 與 70→80 對 log-odds 的影響被假設一樣大——臨床上未必

怎麼檢查

- ▶ 把連續特徵分箱（如年齡每 10 歲一組），各組跑出的係數（Coefficient）畫起來看是否近似直線
- ▶ 若呈 U 型或閾值型（過了某點才有影響），線性假設就不成立

怎麼處理

- ▶ 加多項式項（年齡²）、分箱後當類別、或用受限三次樣條
- ▶ 或者換模型：樹系天生不需要這個假設
- ▶ 報告中處理過要說明——這是 OR 解讀是否可信的前提

【原講義 ML 3.3】 pp112-113 的 feature engineering for logistic 。與 M2-1 的迴歸假設一脈相承。

多元分類：檢傷分級的例子（3 類示意）

Softmax 輸出

個案	P(1 級)	P(2 級)	P(3 級)	判定
A	0.72	0.20	0.08	1 級
B	0.15	0.55	0.30	2 級
C	0.05	0.42	0.53	3 級
D	0.33	0.35	0.32	2 級 (勉強)



多元策略

策略	做法
One-vs-Rest	k 類拆 k 個二元模型，取機率最高
Softmax	直接輸出 k 類機率，總和為 1
有序類別	檢傷 1<2<3 有順序：差兩級比差一級嚴重
有序的做法	累積 Logit 模型，或至少在評估時計權重

個案 D 的警訊

三類機率 0.33/0.35/0.32—— 模型其實不知道。這種個案應轉人工判斷

Hard 分類會隱藏這件事

只輸出「2 級」的話，你永遠不知道它有多沒把握

實務設計

訂一個「最高機率須超過門檻」的規則，不到門檻就進人工佇列

【原講義 ML 3.3】 pp121-123、145-152

PART 06

Naive Bayes


單純貝氏

它做了一個明知是錯的假設——特徵彼此獨立。
但這個錯的假設，讓它快得離譜，而且常常夠用。

手算：症狀組合的機率判定

訓練資料的條件機率

	發燒	咳嗽	流感（10 人）	非流感（90 人）
有發燒	—	—	8/10	18/90
有咳嗽	—	—	7/10	27/90
先驗機率	—	—	10/100	90/100



新病人（發燒＋咳嗽）

步驟	流感	非流感
先驗	0.10	0.90
×P(發燒 類)	×0.80	×0.20
×P(咳嗽 類)	×0.70	×0.30
分數	0.056	0.054
歸一化	0.509	0.491

Naive 在哪

假設「發燒」與「咳嗽」在給定類別下彼此獨立——實際上顯然相關

為什麼還能用

即使機率估不準，「哪一類分數較高」的排序常常還是對的

流感只贏一點點

0.509 vs 0.491——先驗 0.10 的劣勢幾乎吃掉了症狀的證據力

平滑

訓練集沒出現過的組合會得到機率 0，需拉普拉斯平滑避免一票否決

數字為教學設計、已驗算。AI Studio：Naive Bayes Operator。它常是快速基準，但分布假設、平滑與機率校準仍需驗證。

Naive Bayes 的定位

強項

- ▶ 訓練與預測都極快，資料再大也不怕
- ▶ 高維資料表現意外地好（文字分類的傳統霸主）
- ▶ 小樣本也能運作——不容易過擬合（Overfitting）
- ▶ 可輸出機率分數並支援多元分類
- ▶ M6 文字探勘會再遇到它

弱項


- ▶ 獨立假設在特徵高度相關時失真（醫療生理指標常見）
- ▶ 輸出的機率值本身不可靠（排序可以，數值別當真）
- ▶ 連續特徵需假設分布（通常假設常態）
- ▶ 類別組合沒看過就會出問題（需平滑）
- ▶ 可解釋性中等：能看各特徵的貢獻，但沒有 OR 那麼直白

【原講義 ML 3.3】。定位：快速基準線與文字類問題的首選之一；在特徵高度相關的結構化醫療資料上通常不是最終選擇。

Naive Bayes 的主場：文字分類預告（M6）

詞的條件機率

詞	垃圾郵件中出現率	正常郵件中出現率
「免費」	0.62	0.04
「中獎」	0.45	0.01
「會議」	0.03	0.38
「附件」	0.18	0.22



高維文字與 NB 的緣分


為什麼文字適合 NB	說明
維度極高	每個詞一個特徵，數萬維很正常
NB 不怕高維	逐特徵獨立相乘，維度高也算得快
獨立假設較無害	詞與詞的相關性傷害相對小
M6 見	Spam 分類實作（Project 6）

【AI Studio 範例】 4. Case Studies/7. Email Spam classification 將在 M6 使用。這裡先埋個伏筆：本週覺得 NB 平庸，到文字問題它會翻身。

支援向量機 SVM：找間隔最寬的那條線


① 哪一條線最好？

很多條都能把兩類分開




② SVM 的答案

選間隔最寬的那一條



③ 核技巧 Kernel

直線分不開時，映射到高維



● 類別 0 ▲ 類別 1 — 決策超平面 - - 間隔邊界

把中間那張圖裡沒被金圈圈起來的 76 個點全部刪掉，重跑 SVM，會得到一模一樣的線——這就是「支持向量」這個名字的來源，也是它在高維小樣本仍站得住的原因。

① 問題

能把兩類分開的直線有無限多條。哪一條在新資料上最可靠？

② SVM 的答案

選「離最近的點最遠」的那條——間隔（Margin）最寬

支持向量

只有金圈那幾個點決定了這條線。其餘的點刪掉也不影響結果

③ 核技巧

資料不是直線可分時，映射到高維空間再找超平面。常用 RBF 核

SVM 的參數與定位

兩個關鍵參數

- ▶ C（懲罰強度）：容忍多少樣本落在間隔內或分錯
- ▶ C 大 → 硬邊界、追求全對、容易過擬合
- ▶ C 小 → 軟邊界、容忍少數錯誤、泛化較好
- ▶ kernel（核函數）：linear / polynomial / RBF（radial basis function）
- ▶ 線性關係用 linear；不確定時 RBF 是安全的預設
- ▶ gamma（RBF 專用）：控制單一樣本的影響範圍，大則邊界複雜

什麼時候用 SVM

- ▶ 特徵數多、樣本數中等（幾百到幾千）時表現很好
- ▶ 高維資料（如文字向量）的傳統強項
- ▶ 必須正規化——它靠距離運作
- ▶ 缺點：樣本量大時訓練慢；機率輸出需額外校準
- ▶ 缺點：可解釋性差，說不出「為什麼是這個病人」
- ▶ 醫療定位：效能候選之一，但通常不是最終部署的模型

AI Studio：Support Vector Machine Operator（另有 SVM (LibSVM) 版本支援多種核）。前面務必接 Normalize。

判別分析 LDA / QDA：醫學統計的老朋友

線性判別分析 LDA


- ▶ 假設各類別近似常態且共用共變異數矩陣
- ▶ 在此假設下，決策邊界是一條直線（與 Logistic 類似但推導不同）
- ▶ 優點：樣本少時比 Logistic 穩定；可同時做降維
- ▶ 醫學文獻中歷史悠久，常見於診斷分類研究
- ▶ AI Studio：Linear Discriminant Analysis Operator

二次判別分析 QDA

- ▶ 放寬假設：允許各類別有不同的共變異數矩陣
- ▶ 決策邊界變成曲線（二次曲面）
- ▶ 更彈性，但需要更多樣本才估得準
- ▶ 類別間變異差異大時（如健康組與重症組）較合適
- ▶ AI Studio：Quadratic Discriminant Analysis Operator

與 Logistic 的分工：LDA 假設較強（常態、等共變異），成立時效率較高；Logistic 假設較弱、較穩健，且能直接給勝算比——這是它在現代醫學文獻勝出的主因。

神經網路 MLP：分類器的一種



每一條灰線都是一個權重。本圖共 $4 \times 5 + 5 \times 3 + 3 \times 1 = 38$ 條權重線（另有 9 個偏權值 bias）。

訓練就是反覆調整這 38 個數字，讓預測與實際的差距最小（反向傳播）。問題也在這裡：這 38 個數字沒有一個能被翻譯成「勝算比 2.1 倍」那樣的臨床語言。

結構

輸入層（Features）→ 一到多個隱藏層 → 輸出層；二元常用 Sigmoid，多元互斥分類常用 Softmax

隱藏層在做什麼

自動把原始特徵組合成新的表徵——這是它與其他方法最大的差別

訓練

找出全部權重，讓預測與實際的差距最小（反向傳播）

與 M5 的關係

本週把它當成「另一個分類器」；M5 深度學習會深入層數、Dropout、過擬合

神經網路作為分類器：現實的評估

面向	狀況	對你的意義
表格資料上的表現	在許多中小型結構化資料上，樹提升或隨機森林常很有競爭力；仍須以同一切分比較	不要因為它「聽起來厲害」就選它
需要的資料量	參數多，需要較多樣本才餵得飽	768 筆的 Pima 資料上，它常輸給 Logistic
調參成本	層數、每層神經元、學習率、Epoch、正則化都要調	同樣的時間拿去做特徵工程，報酬通常更高
可解釋性	中間層學到什麼難以解讀	醫療高風險場域的明確限制
真正的優勢	影像、語音、文字這類非結構化資料	M5 的 CNN 與 M6/M7 的 NLP 才是它的主場

AI Studio：Neural Net Operator（淺層 MLP）。作業二（M5）會在同一驗證設計下比較 Logistic、梯度提升樹與 H2O 深度學習；結論以實際資料為準。

其他值得知道的分類演算法

演算法	核心想法	何時考慮	本課程
XGBoost / LightGBM / CatBoost	梯度提升的高效實作，加上正則化與缺失值處理	表格資料競賽的常勝軍； 資料量大且追求效能時	M4 提及； AI Studio 有 GBT
Extra Trees (極端隨機樹)	比隨機森林更隨機：切點也隨機選	想要更快、變異更低時； 常與森林一起比較	自學
Ridge / Lasso Logistic	加上 L2 / L1 懲罰的邏輯斯迴歸	變數多、共線性嚴重、 想自動篩變數時	本講義 P5 已含
規則式模型 (RIPPER 等)	直接產出 if-then 規則清單	需要可直接寫進 SOP 的規則時	自學
最近質心 Nearest Centroid	算每類的中心，看新樣本靠近誰	極簡基準線； 高維小樣本時意外好用	自學

判斷原則：先用本講義的七個模型建立完整基準線，確認瓶頸在「模型不夠強」而非「特徵不夠好」，再考慮引入更複雜的演算法。

隨堂檢核 1 | 演算法

Q
1

k-NN 忘了正規化（**Normalization**），會發生什麼事？

距離被值域最大的特徵獨占——其他特徵形同虛設。

Q
2

Logistic 係數 $\beta=1.1$ （ $p<0.001$ ），勝算比（**Odds Ratio, OR**）是多少？怎麼用一句話解讀？

$e^{1.1} \approx 3.0$ 。該因素存在時，事件勝算是不存在時的 3 倍。

Q
3

Naive Bayes 明知假設是錯的，為什麼還能用？

它需要的只是「哪類分數高」的排序正確；機率數值本身不必準。

Q
4

三個模型的訓練 **Accuracy** 都是 **0.95**，就能說它們一樣好嗎？

訓練分數只是記憶力。要比就比交叉驗證（**Cross Validation**）分數，且附標準差。

PART 07

混淆矩陣家族

The Confusion Matrix Family

整個單元最重要的一節。

六個指標全部來自同一張 2×2 表，但回答的是完全不同的問題。

實例：再入院預測（1000 位病人）

混淆矩陣（Confusion Matrix）

	模型：會	模型：不會	小計
實際：會	TP = 45	FN = 15	60
實際：不會	FP = 60	TN = 880	940
小計	105	895	1000



六個指標

指標	計算	值
Accuracy	$(45+880)/1000$	0.925
Precision (PPV)	$45/105$	0.429
Recall (敏感度 (Sensitivity))	$45/60$	0.750
特異度 (Specificity)	$880/940$	0.936
NPV	$880/895$	0.983
F1	$2PR/(P+R)$	0.545

★ 關鍵

全判「不會」的 Accuracy = $940/1000 = 0.940 >$ 模型的 0.925

這代表什麼

以 Accuracy 論，模型輸給「什麼都不做」。但它抓到了 45/60 個真陽性

該看什麼

Recall 0.750（抓到七成五）、Precision 0.429（喊「會」的人四成三是真的）

成本問題

攔到 45 個真的，代價是多追蹤 60 個假的。值不值得？——這是臨床決定，不是統計決定

【原講義 ML 3.3】 pp67-69、129-135。這一頁請學生親手算一遍。

機器學習 × 醫學用語對照

ML 用語	醫學用語	公式	回答的問題
Recall / TPR	敏感度 Sensitivity	$TP/(TP+FN)$	真的有病的，抓到幾成？
—	特異度 Specificity	$TN/(TN+FP)$	沒病的，正確排除幾成？
Precision	陽性預測值 PPV	$TP/(TP+FP)$	說有病的，幾成真的有？
—	陰性預測值 NPV	$TN/(TN+FN)$	說沒病的，幾成真的沒有？
FPR	1 – 特異度（Specificity）	$FP/(FP+TN)$	沒病卻被誤判的比例
F1	—	$2PR/(P+R)$	P 與 R 的調和平均

關鍵區分：敏感度（Sensitivity）與特異度是「模型的性質」，不受盛行率影響（但病人組成不同時仍會變）；PPV 與 NPV 是「部署結果」，隨盛行率（Prevalence）大幅變動——下一頁就是這件事。

盛行率（Prevalence）陷阱：同一個模型，兩種結論

同一模型（敏感度 0.90 特異度 0.95）

部署場域	盛行率	TP	FP	PPV
高風險科別	10%	900	450	0.667
社區篩檢	1%	90	495	0.154



數字拆解

	高風險科別	社區篩檢
每萬人患者數	1000	100
敏感度 90% 抓到	900	90
特異度 95% 誤判	450	495
PPV	66.7%	15.4%
意義	可作初篩	誤報是真陽性的 5 倍

模型沒變

敏感度、特異度完全相同。變的只有部署場域的盛行率

PPV 為何崩

盛行率 1% 時健康人是病人的 99 倍；就算只誤判 5%，絕對數量仍碾壓真陽性

教訓

醫院驗證良好的模型直接推到社區，會製造大量無謂的複檢與焦慮

該做什麼

依部署場域重估 PPV；提高門檻；或兩階段篩檢

這是醫療 AI 落地最常見的失敗模式。專題涉及篩檢者，必須在報告中說明目標場域的盛行率。

F1：什麼時候調和平均有意義

三個模型的比較

模型	Precision	Recall	算術平均	F1
A	0.50	0.50	0.50	0.500
B	0.90	0.10	0.50	0.180
C	0.70	0.30	0.50	0.420



F1 的性質

性質	說明
調和平均懲罰失衡	B 的算術平均也是 0.5，但 F1 只有 0.18
兩者都要好	F1 高 $\Leftrightarrow$ P 與 R 同時高
何時用 F1	兩種錯誤代價相近時
何時不用	代價比（Cost Ratio）懸殊時——直接用加權成本更誠實

B 的故事

高 Precision、低 Recall——只喊最有把握的，漏掉九成。算術平均看不出這有多糟

醫療場域提醒

漏診與誤報的代價通常不相等，F1 的「平等對待」未必合適——它是方便的單一數字，不是萬用的

【原講義 ML 3.3】 p135

多元分類的混淆矩陣（Confusion Matrix）（3×3）

檢傷三級的混淆矩陣（Confusion Matrix）

實際 \ 預測	1 級	2 級	3 級	Recall
1 級（60）	48	10	2	0.80
2 級（100）	12	76	12	0.76
3 級（40）	2	10	28	0.70
Precision	0.77	0.79	0.67	



Micro vs Macro

彙整方式	計算	值
Micro-F1	全部 TP/(全部)	0.76
Macro-F1	三類 F1 取平均	0.75
差異	Micro 被大類主導； Macro 每類平權	
有序性	1 級被判 3 級（2 例） 比判 2 級嚴重—— 必要時用加權懲罰	

對角線是對的

$48+76+28=152/200=0.76$ 整體正確率

小類別優先看 Macro

若 3 級是最危險的病人，它的 Recall 0.70 才是重點，別讓大類的好成績蓋過去

報告要求

多元分類一律附完整混淆矩陣，不能只給一個數字

【原講義 ML 3.3】 pp145-153。數字已驗算（行列合計一致）。

PART 08

ROC、PR 曲線與門檻

ROC, PR & Thresholds

模型輸出的是機率，門檻才決定判成哪類。
一條曲線，就是把所有可能的門檻一次看完。

兩條曲線怎麼選

ROC 曲線 (FPR vs TPR)

- ▶ 掃過所有門檻，畫偽陽性率 (FPR) 對真陽性率 (TPR)
- ▶ ROC-AUC 可解讀為隨機一正一負時，正例分數較高的機率
- ▶ 0.5 隨機；0.7-0.8 尚可；0.8-0.9 良好；>0.95 先查洩漏
- ▶ 與門檻無關 → 適合「比較模型」
- ▶ 極度不平衡時過度樂觀 (TN 太多把 FPR 壓低)


PR 曲線 (Recall vs Precision)

- ▶ 同樣掃門檻，但完全不看 TN
- ▶ 不被龐大負類稀釋 → 極度不平衡時更誠實
- ▶ 基準線是「正類比例」不是 0.5
- ▶ 適合「決定門檻」：在曲線上選操作點
- ▶ 盛行率 <5% 的問題，優先看 PR


【原講義 ML 3.3】 pp140-144。實務：兩條都畫。ROC 選模型，PR 定門檻。AI Studio：Compare ROCs 可多模型疊圖。

實例：ROC 與 PR 曲線（6% 陽性的資料）

左・ROC 每個門檻是曲線上一點



右・PR 不平衡資料更誠實



同一個模型、同一批分數，只是換了兩個軸。ROC 的基準是 0.50，PR 的基準只有 0.06——在 6% 陽性的資料裡，「喊中的比例」有多難拉高，只有右圖看得出來。

左・ROC

三個黑點＝三個門檻。整條曲線就是把所有門檻掃一遍

AUC≈0.85

隨機抽一正一負，模型給正例較高分的機率

右・PR

同一個模型。注意基準線是 0.06 不是 0.5
——不平衡資料的誠實視角


兩張一起看

ROC 選模型、PR 定門檻。只看 ROC 會高估不平衡場景的實用性

ROC 曲線是怎麼畫出來的

門檻掃描 → 座標點

門檻	TP	FP	TPR (y 軸)	FPR (x 軸)
0.9	10	2	0.17	0.002
0.7	28	18	0.47	0.019
0.5	45	60	0.75	0.064
0.3	54	165	0.90	0.176
0.1	59	470	0.98	0.500



曲線的讀法

讀法	說明
每個門檻=一個點	門檻從 1 掃到 0
左下 → 右上	門檻越低越往右上走
對角線	隨機猜的軌跡
AUC	曲線下面積; 本例約 0.85
越靠左上越好	同樣 TPR 用更少 FPR 換到

一條曲線=全部門檻

這就是「AUC 與門檻無關」的原因——它把所有門檻一次算完

部署時只取一點

曲線上你只會活在一個點上。AUC 高但你選的那點差，一樣沒用

與 P8 門檻表的關係


那張表就是這條曲線的其中四個點

【原講義 ML 3.3】 pp142-144

門檻調整的實際效果（同一模型）

四個門檻的混淆矩陣（Confusion Matrix）

門檻	TP	FN	FP	TN
0.7	28	32	18	922
0.5	45	15	60	880
0.3	54	6	165	775
0.2	58	2	310	630



對應的取捨

門檻	Recall	Precision	適用情境
0.7	0.467	0.609	資源極少，只追最確定的
0.5	0.750	0.429	預設值（沒有理由的預設）
0.3	0.900	0.247	漏掉的代價高
0.2	0.967	0.158	幾乎不能漏（如敗血症警示）

規律

門檻降 → Recall 升、Precision 降。你在用誤報買回漏網之魚

怎麼決定

先估代價比（Cost Ratio）：漏一個真陽性 = 幾個偽陽性的成本？代價比（Cost Ratio） 10:1 就往低門檻走

誰決定


代價比是臨床 / 管理判斷，不是資料科學家自己決定的

AI Studio

Find Threshold + Apply Threshold；門檻最佳化應放在驗證 / CV 內，選定後才在最終測試集評估

【原講義 ML 3.3】 pp157-161。0.5 只是軟體預設，不是自然法則——這是本單元最重要的一句話。

實例：門檻左移，用 Precision 買 Recall



從 0.5 移到 0.3：Recall 由 0.73 升到 0.93（多抓到 12 位），Precision 由 0.20 掉到 0.09。
這筆交易划不划算，由代價比決定，不是由軟體決定。

兩條線的交叉

門檻往左：紅線（Recall）升、藍線（Precision）降——沒有免費的午餐

灰色虛線 0.5

軟體預設。它不知道你的場域漏一個要付什麼代價

金色虛線 0.3

代價比（Cost Ratio）20:1 時的合理區——對應後頁期望成本表的計算

報告要求

選定門檻時，把這張圖與代價比（Cost Ratio）假設一起放進報告

用期望成本直接選門檻

各門檻的期望成本（代價比 10:1）

門檻	FN 數	FP 數	FN 成本 ×10	FP 成本 ×1	總成本
0.7	32	18	320	18	338
0.5	15	60	150	60	210
0.3	6	165	60	165	225
0.2	2	310	20	310	330



設定與結論

設定	說明
代價比 10:1	漏一個再入院的代價 = 10 次無效追蹤
最低成本	門檻 0.5 附近 (本例恰巧)
代價比改 20:1	最佳門檻會往 0.3 移
重點	門檻跟著代價比走， 不是跟著 Accuracy 走

計算

總成本 = FN×10 + FP×1 。把 P8 門檻表的數字直接乘上代價

敏感度（Sensitivity）分析

把代價比從 5:1 掃到 20:1 ，看最佳門檻怎麼移——報告裡放這張表最有說服力

誰給代價比

臨床與管理者。資料科學家的工作是把「選門檻」翻譯成「選代價比」這個他們答得出的問題

AI Studio：Performance (Costs) 可直接輸入成本矩陣。若機率已校準，理論最佳門檻 = 1/(1+ 代價比)（10:1 → 0.09）；表中結果不同，代表機率需要校準（下頁）。

機率校準：模型說 70%，就真的是 70% 嗎

問題

- ▶ 模型輸出 0.7，但同分數群體可能只有 45% 發生事件：排序可用，數值失真
- ▶ 樹與集成模型的「機率」尤其常失真；Logistic 相對誠實
- ▶ 如果只拿來排序（先追蹤誰），失真無妨；要拿數值溝通（「您的風險是 70%」），就必須校準

怎麼檢查


- ▶ 校準圖：把預測機率分十組，畫「預測平均 vs 實際發生率」。貼近對角線＝校準（Calibration）良好
- ▶ AI Studio 沒有內建校準圖，可用 Discretize + Aggregate 自行做出這張表

怎麼修

- ▶ Platt scaling：模型分數再套一層 Logistic（AI Studio：Rescale Confidences (Logistic)）；或等張回歸
- ▶ 務必在獨立的驗證資料上做，不能用訓練集
- ▶ 醫療溝通場景（衛教、共享決策）強烈建議校準（Calibration）後再引用機率數字

【原講義 ML 3.3】 p79 （probability vs event rate）。這是原講義輕描淡寫、但醫療應用不能跳過的一頁。

實例：校準圖——模型說 70%，是真的嗎



AUC 只看「排得對不對」，校準看「數字準不準」。要跟病人說「你有七成機會」之前，先確認這條線真的貼著對角線。

對角線

完美校準：說 70% 就真的 70% 發生

青色線

Logistic 通常貼近對角線——它的機率相對誠實

紅色線

某集成模型：說 70% 實際只有 42%。排序沒問題，數值虛胖

何時必須校準 (Calibration)

要把機率「講給病人聽」（衛教、共享決策）之前

Brier 分數與淨效益：兩個臨床預測模型的標準指標

區辨力 vs 校準：兩者要一起看

模型	AUC	Brier 分數	校準斜率
A Logistic	0.78	0.051	0.98
B 梯度提升	0.81	0.062	0.62
一律預測 6%	0.50	0.056	—



決策曲線分析：各門檻下的淨效益

門檻機率	模型 A 淨效益	全篩淨效益	全不篩
5%	0.041	0.011	0
10%	0.032	-0.044	0
20%	0.018	-0.175	0
40%	-0.004	-0.567	0

★ 看穿一個陷阱

模型 B 的 AUC 較高，Brier 卻較差——它排序更好，但機率過度極端、高風險端高估（校準斜率 0.62，理想為 1）

Brier 分數是什麼

預測機率與實際結果差距的平方平均。越小越好，同時反映區辨力與校準

為什麼要有基準

「一律預測 6%」的 Brier 為 0.056：模型 B 還不如它，模型 A 也只小贏——低盛行率時 Brier 差距天生很小，必須和基準比

淨效益怎麼讀

在該門檻下，模型相對於「全篩」與「全不篩」多帶來多少真陽性。數值 > 0 且高於兩條基準線才有臨床價值

★ 這一頁對應臨床預測模型論文的標準要求：只報 AUC 會被審稿人退。40% 門檻時模型 A 的淨效益已為負——代表在那個決策情境下，用這個模型還不如不用。數值為教學設計。

內部驗證與外部驗證：換一家醫院還準嗎

內部驗證 Internal Validation

- ▶ 用同一份資料做交叉驗證或 bootstrap——這是本課程作業要求的最低標準
- ▶ 回答的是「這個模型在同一群人身上穩不穩」，不是「換一群人還準不準」
- ▶ ★ 內部驗證的分數天生樂觀，因為變數選擇與調參都用過同一批資料

外部驗證 External Validation

- ▶ 拿另一個時間、另一個院區、另一個族群的資料重跑——分數幾乎一定會掉
- ▶ 掉多少才可接受，取決於用途；重點是「你有沒有誠實測過並報告」
- ▶ 常見的掉分原因：盛行率不同、量測方式不同、族群結構不同（年齡、共病）

報告規範：TRIPOD+AI（2024）

- ▶ 臨床預測模型的國際報告準則（2024 版涵蓋機器學習），期刊投稿幾乎必用；本課程專題不強制，但建議照它的架構寫
- ▶ ★ 核心要求與本模組完全一致：講清楚資料來源、模型設定、區辨力、校準、以及驗證的類型

給修課同學的實話：你的專題大概率只做到內部驗證——這完全可以接受。不可接受的是在報告裡把內部驗證的分數，說成模型「在真實世界的表現」。

PART 09

類別不平衡

Imbalanced Data

醫療的重要事件幾乎都是少數類。
你要找的人，正好是資料裡最稀少的人。


五種處理方式

方式	做法	優點	風險
調整門檻	不動資料不重訓，改判定切點	最簡單透明； ★ 永遠先試這個	需要機率輸出
類別權重（Class Weight）	訓練時加重少數類的損失	不改資料、不丟資訊； ★ 次選	並非所有 Operator 支援
過取樣（Oversampling）	複製少數類至平衡	不丟資訊	複製樣本易被過擬合（Overfitting）
SMOTE	少數類樣本間內插合成新樣本	比複製多樣	「合成病人」—— 醫療報告需說明
欠取樣（Undersampling）	刪多數類樣本	訓練快	丟資訊；小資料不可行

【原講義 ML 3.3】 pp157-171

實例：五種不平衡處理在資料上的差別

五種處理方式在「資料層面」的差別：只有 ⑤ 完全不動資料



① ~ ④ 都動到了你手上的資料集, 所以只能在訓練折內做, 否則會把資訊洩漏到驗證折; ⑤ 一筆資料都沒動, 改的是損失函數裡少數類的代價——這是它最安全的地方。

① 原始

300 : 24。多數類 (藍圓) 淹沒少數類 (紅三角)

② 過取樣

少數類被複製多份疊在同一位置——模型容易死背這幾個點

③ SMOTE


在少數類樣本的連線上內插出新點, 比複製多樣

④ 欠取樣 vs ⑤ 類別權重

④ 刪掉大量多數類 (丟資訊); ⑤ 資料完全不動, 只把少數類的錯誤代價放大

實例：三種做法對決策邊界的實際影響

同一份 300 : 24 的資料，三種做法各自畫出來的判定區域



② 的黑線位置變了——那是重新訓練出來的另一個模型；③ 的黑線只是從灰線平移過去，模型的係數一個字都沒改。兩者可以並用：先加權訓練，再調門檻。

① 不處理

邊界被多數類推到少數類那一側，紅色三角大量落在藍區＝被判為陰性

② 類別權重

把少數類的錯誤代價放大 12.5 倍，邊界被拉回中間，涵蓋率明顯上升

③ 只調門檻

模型與邊界完全沒變，只是把判定線從 0.5 移到 0.15

② 與 ③ 的差別

權重改變「訓練出來的模型」，門檻只改變「怎麼用這個模型」。可以並用

三個鐵則（作業必查）

取樣只能在訓練集做

- ▶ 切分前取樣 → 同一筆的複本同時進訓練與測試 → 分數虛高且不可信
- ▶ AI Studio 正確作法：取樣 Operator 放進 Cross Validation 的訓練子流程

測試集維持原始分布

- ▶ 平衡過的測試集 = 假設盛行率 50% = 所有 Precision 都是幻覺
- ▶ 評估必須反映真實世界的類別比例

不平衡時不用 Accuracy 當主指標

- ▶ 本講義 P7 已示範：0.925 輸給全判陰性的 0.940
- ▶ 改用 Recall、Precision、PR-AUC，且報告一定附上類別比例

SMOTE 在做什麼：內插出合成樣本

兩個真實樣本 → 兩個合成樣本

樣本	年齡	天數	類別
真實 A	78	9	再入院
真實 B	70	7	再入院
合成 S1	74.8	8.2	再入院
合成 S2	71.6	7.4	再入院



性質與風險

性質	說明
做法	在少數類樣本連線上隨機取點
$S1 = A + 0.4 \times (B - A)$	逐特徵線性內插
優點	比複製多樣，不易死背特定樣本
風險	類別邊界附近亂內插會製造「不可能的病人」

醫療的特殊顧慮

合成的「74.8 歲、8.2 天」病人不存在。報告若用 SMOTE，必須聲明並說明比例

類別特徵怎麼辦

SMOTE 原版只吃數值；類別特徵要用 SMOTE-NC 變體或先編碼

永遠只在訓練集做


合成樣本進了測試集＝考卷裡混了你自己出的題

【原講義 ML 3.3】 pp165-166

類別權重（Class Weight）：把少數類的錯「放大」給模型看

同一資料、不同權重

設定	FN 的損失	FP 的損失	模型行為
無權重	1	1	偏向多數類，Recall 低
權重 5:1	5	1	開始重視陽性
權重 15:1	15	1	Recall 大增、Precision 降
權重 = 類別比	≈15.7	1	常見候選起點（940/60），不是通用最佳值



定位

與其他方法比	說明
vs 過取樣（Oversampling）	效果類似，但不複製資料
vs 門檻調整	權重改變「訓練」， 門檻改變「判定」
可以並用	權重訓練＋門檻微調
AI Studio	部分模型支援 weight 欄位（Set Role 設 weight 角色）

直覺

權重 15:1 = 告訴模型「漏掉一個陽性等於錯十五個陰性」——跟代價比（Cost Ratio）是同一種語言

起點

權重設成類別比例的倒數，再依驗證結果微調

報告

用了權重要寫明數值與理由，它跟門檻一樣是「決策」不是「計算」

【原講義 ML 3.3】 pp169-170

不平衡場景的其他指標

指標	公式概念	特性	何時用
Balanced Accuracy	(敏感度 (Sensitivity) + 特異度 (Specificity))/2	兩類平權的準確率； 全判多數類只得 0.5	想要單一數字 且兩類都重要
MCC	四格全入的相關係數 (Coefficient)	-1~+1 ； 對四格都敏感， 公認最難被騙	極度不平衡的 嚴謹比較
PR-AUC	PR 曲線下面積	不看 TN ； 基準 = 陽性比例	盛行率 (Prevalence) <5% 的 模型比較
G-mean	$\sqrt{(\text{敏感度 (Sensitivity) } \times \text{特異度 (Specificity) })}$	任一邊爛就整體爛	篩檢兩端 都不能放

本例模型：Balanced Acc = $(0.75+0.936)/2 = 0.843$ —— 比 Accuracy 0.925 更誠實地反映「陽性那邊還有進步空間」。

PART 10

交叉驗證

Cross Validation

單次切分的分數，換一次隨機種子就變了。

交叉驗證（Cross Validation）給你平均值——還附贈標準差。

訓練集、驗證集、測試集：為什麼要三份

全部資料 100%



模型看幾次	很多次（每個 epoch）	很多次（每組參數一次）	★ 只有一次
分數的性質	樂觀（記憶力）	略為樂觀（選過很多次）	最接近真實部署表現
能不能重複用	可以	可以	★ 不可以

★ 鐵則：縮放、填補、取樣、特徵選擇的參數，一律只從綠色那一段計算

用到驗證集或測試集的統計量 → 分數虛高、部署後大幅下滑，而且不會有任何錯誤訊息。
資料少的時候，驗證集可以用交叉驗證取代——但測試集仍要獨立保留。

訓練集 Training set

模型「看得到」的資料，用來學參數（迴歸係數、樹的切點、網路權重）

驗證集 Validation set

用來選超參數、比較模型。因為看很多次，它的分數會逐漸樂觀

測試集 Test set

只在最後看一次。一旦用它做過任何決策，它就失去公正性了

★ 鐵則

縮放、填補、取樣、特徵選擇的參數，一律只從訓練集計算

為什麼需要交叉驗證

問題：單次切分的分數不穩定

- ▶ 同一份資料、同一個模型，換一個隨機種子切分，AUC 可能從 0.78 變成 0.85
- ▶ 你回報哪一個？兩個都是真的，但都不可靠——這只是運氣
- ▶ 樣本數越少，這個問題越嚴重。醫療資料常常只有幾百到幾千筆


解法：讓每一筆都當過一次驗證資料

- ▶ 把資料切成 k 份，輪流用其中一份當驗證折、其餘訓練，跑 k 次
- ▶ 回報 k 次分數的平均——這比任何單一次的分數都可靠
- ▶ 同時回報標準差：它告訴你「這個模型有多穩」

怎麼寫進報告

- ▶ 正確寫法：「5-fold stratified CV：AUC 0.81 ± 0.03 」
- ▶ 只寫 0.81 的話，讀者無從判斷這個數字有多可信
- ▶ 標準差大（如 ± 0.09 ）代表模型對切分很敏感，部署後的表現可能落在很寬的範圍


實例： 5-fold 交叉驗證怎麼跑



全部資料 1,000 筆 · 每一格 = 100 筆

最終回報：五折分數的平均 $\pm$ 標準差 $\rightarrow$ **AUC 0.79 $\pm$ 0.02**

分層 **Stratified**：每一折的陽性比例都必須一致



橘色 = 測試

每一折把不同的 1/5 當驗證折，其餘 4/5 訓練

每筆都在折外評估一次

這是它比「單次切分」可信的原因——沒有運氣好壞的問題

回報兩個數字


五折分數的平均 $\pm$ 標準差。標準差大代表模型對切分很敏感

分層 **Stratified**


不平衡資料要額外要求每折的類別比例一致，否則某折可能沒有陽性樣本

三種交叉驗證的資料分配


① k-fold 每折輪流當測試集



② 分層 Stratified 每折維持相同陽性比例



③ 時間序列 Forward Chaining 訓練集只往後長



■ 訓練 ■ 測試 ■ 少數類 ■ 未使用

① k-fold

最基本的形式。每折輪流當測試集，每筆資料都被測過一次

② 分層 Stratified

每折維持與整體相同的類別比例。★ 不平衡資料必用

③ 時間序列 Forward Chaining

只能用過去預測未來。訓練集逐步往後擴大，絕不 shuffle

AI Studio

Cross Validation 的 sampling type 設 stratified 即為②；③ 要改用 Forecast Validation 等時序驗證運算子

巢狀交叉驗證：選參數與估效能要分開

外層 CV 估效能



內層 CV 只在外層的訓練部分裡再切一次，用來選超參數



選出最佳超參數
→ 回外層訓練一次

橘色的測試部分從頭到尾沒有參與選參數——這就是巢狀的意義。單層 CV 同時做兩件事，報出來的分數會系統性偏高。

問題在哪

如果用同一份資料「選超參數」又「報成績」，分數會系統性偏高

外層 CV

負責估計最終模型的表現。每一折的測試部分完全不參與選參數

內層 CV

在外層的訓練部分裡再切一次，用來選超參數

何時需要

要對外報告效能、或比較多個調參過的模型時。AI Studio：兩層 CV 巢狀擺放

切分與驗證的五個檢查

Q
1

我的前處理是在切分之前還是之後做的？

縮放、填補、SMOTE、特徵選擇——全部都要在切分之後、且只用訓練集的統計量。

Q
2

不平衡資料，我的切分有沒有用 **stratified ？**

沒有的話，某一折可能完全沒有陽性樣本，那一折的指標會是無意義的。

Q
3

我的測試集被看過幾次？

超過一次就等於變成第二個驗證集。最終數字會偏高。

Q
4

我報告的是平均還是單次分數？有沒有附標準差？

「AUC 0.81 ± 0.03」與「AUC 0.81」傳達的資訊量差很多。

Q
5

同一個病人有多筆紀錄嗎？

有的話要以「病人」為單位切分（group split），不能以「紀錄」為單位——否則同一人會同時出現在訓練與測試集。

三種交叉驗證（Cross Validation）

1

k-fold

- ▶ 資料切 k 份輪流當驗證折
- ▶ 每筆都在折外評估一次
- ▶ 常用 k=5 或 10
- ▶ 報告平均 $\pm$ 標準差
- ▶ 標準差大 = 模型不穩
- ▶ 小資料集的標準做法

2

Stratified k-fold

- ▶ 每折維持類別比例
- ▶ 不平衡資料必用
- ▶ 否則某折可能沒有正樣本
- ▶ AI Studio：sampling type = stratified
- ▶ ★ 本課程分類作業預設
- ▶ 作業會檢查這個設定

3

前處理放進 CV 內


- ▶ 縮放、填補、取樣、特徵選擇（Feature Selection）
- ▶ 全部放進訓練子流程
- ▶ 每折各自計算參數
- ▶ 這是防洩漏的統一解法
- ▶ AI Studio 的 CV 是容器型 Operator，天生支援
- ▶ Ref 5.5 / 5.6 的做法

【原講義 ML 3.3】 pp75-76。報告範例寫法：「5-fold stratified CV：AUC 0.81 $\pm$ 0.03」——平均與標準差一起給，讀者才知道穩不穩。

學習曲線（ Learning Curve ）：資料夠了嗎？

逐步增加訓練樣本

訓練樣本數	訓練 AUC	CV AUC	差距
500	0.95	0.68	0.27
2,000	0.90	0.75	0.15
5,000	0.87	0.80	0.07
12,000	0.86	0.83	0.03



三種形態的處方

形態	解讀	行動
兩線仍在靠攏	更多資料仍有幫助	繼續收資料
兩線已收斂但都低	資料夠了、特徵不夠	做特徵工程（ Feature Engineering ）
差距持續巨大	嚴重過擬合	簡化模型 / 正則化（ Regularization ）
本例	接近收斂	CV 仍微升但增幅遞減

回答一個常見問題

「再多收一年資料值得嗎？」——學習曲線（ Learning Curve ） 給出量化答案

怎麼做


固定測試集，訓練集從小到大逐步餵，各記錄兩個分數

AI Studio

Loop + Sample Operator 組合可做出這張表

這是說服管理層「該投資資料收集」或「該止損」的最佳圖表。

實例：學習曲線



差距從 0.27 收斂到 0.03，CV 雖仍微升，但 5,000→12,000 筆只多 0.03，再收資料的報酬已遞減。若兩條線早就平行且貼近，再收一年資料也不會變好，該去做特徵工程。

紅色陰影

訓練與 CV 分數的差距＝過擬合（Overfitting）的程度

兩線靠攏中

到 12,000 筆 CV 仍微升，但增幅已遞減——再收資料報酬有限

若兩線已平行

資料夠了，瓶頸在特徵——該做特徵工程（Feature Engineering）而不是收資料

管理決策工具

「要不要再收一年資料」用這張圖回答

隨堂檢核 2 | 評估

Q
1

敏感度（Sensitivity）0.9、特異度（Specificity）0.95 的模型，在盛行率 2% 的場域，PPV 大約多少？

每萬人：真陽 180、偽陽 490 → PPV ≈ 0.27 。自己算一遍。

Q
2

為什麼「測試集也做了 SMOTE」會讓 Precision 虛高？

測試集陽性比例被人工拉高，喊「陽性」猜中的機率自然上升——但真實世界沒有被拉高。

Q
3

5-fold CV 得到 AUC 0.82 ± 0.09 ，這個 ± 0.09 在告訴你什麼？

模型對資料切分很敏感＝不穩定。部署後的表現可能落在很寬的範圍。

Q
4

什麼情況下 F1 是錯誤的指標選擇？

漏診代價遠高於誤報（或反之）時——F1 假設兩者等價。

PART 11

決策樹

Decision Trees

一連串『是／否』問題把資料逐層切開。

它是醫療場域最受歡迎的模型——因為可以整棵印出來。

Gini 不純度（Impurity）：手算一次分裂

依「年齡 ≥ 65 」分裂

節點	人數	再入院	比例
母節點	100	30	30%
左：年齡 < 65	50	8	16%
右：年齡 ≥ 65	50	22	44%



不純度（Impurity）計算

節點	計算	Gini
母	$1 - (0.3^2 + 0.7^2)$	0.4200
左	$1 - (0.16^2 + 0.84^2)$	0.2688
右	$1 - (0.44^2 + 0.56^2)$	0.4928
加權	$0.5 \times 0.2688 + 0.5 \times 0.4928$	0.3808
增益	$0.4200 - 0.3808$	0.0392

Gini 的意義

隨機抽兩筆、類別不同的機率。0 = 全純，0.5 = 最亂（二元）

演算法

對每個特徵 $\times$ 每個切點都算增益，挑最大的切下去，然後遞迴

Entropy 版本

同一母節點的 Entropy = 0.881（log 底 2）。與 Gini 選的切點通常一致

何時停

增益太小、葉節點（Leaf Node）人數太少、或達到深度上限——這就是預剪枝（Pruning）

【原講義 ML 3.3】 pp176-189。AI Studio：Decision Tree 的 criterion 參數可選 gain_ratio / information_gain / gini_index。

Entropy 與 Gini：兩把很像的尺

準則	公式	30/70 節點的值	特性
Gini	$1 - \sum p_i^2$	0.420	計算快（無對數）； CART 的預設
Entropy	$-\sum p_i \log_2 p_i$	0.881	資訊理論出身； ID3/C4.5 使用
Gain Ratio	資訊增益（Information Gain） ÷ 分裂資訊	—	懲罰「切太碎」的特徵 （如 ID 欄位）； C4.5
實務結論	三者選的切點 多數時候一致	—	AI Studio 預設 gain_ratio 即可，不必糾結

兩個數值已驗算。Gain Ratio 的價值：純資訊增益偏好類別數多的特徵——極端例子是病歷號，每人一類、增益最大、毫無用處。

兩個候選切點，選哪個？

母節點 Gini = 0.42 （ 30/100 再入院）

候選	左節點	右節點	加權 Gini	增益
年齡 ≥ 65	8/50	22/50	0.3808	0.0392
糖尿病 = 有	12/60	18/40	0.3900	0.0300



計算過程

步驟	年齡 ≥ 65	糖尿病
左 Gini	0.2688	0.320
右 Gini	0.4928	0.495
權重	0.5 / 0.5	0.6 / 0.4
加權	0.3808	0.390
勝出	★	

演算法就是這樣選的

每個特徵、每個切點都算一次，年齡的增益 0.0392 > 糖尿病的 0.0300 ，第一刀切年齡

但差距不大

0.0092 的差距換一批資料可能翻盤——這就是單棵樹不穩定的根源

臨床覆核

第一刀切年齡合理嗎？若第一刀切的是「病歷號 > 5000 」，你該做什麼？（答：查洩漏）

糖尿病組的數字為教學設計，已驗算。

決策樹（Decision Tree）的關鍵參數（AI Studio）

參數	作用	調大會	調小會	起手建議
maximal depth	樹的最大深度	過擬合（Overfitting）風險升	欠擬合風險升	4-6（醫療小資料）
minimal leaf size	葉節點（Leaf Node）最少樣本數	樹更保守	為個案開分支	≥ 20
minimal gain	低於此增益就不分裂	樹更小	樹更茂密	0.01-0.05
pruning	事後剪枝	—	—	開啟
criterion	分裂準則	—	—	gini / gain ratio 均可列入候選

【原講義 ML 3.3】 pp193-196。用 Optimize Parameters 包住 CV 掃 depth × leaf size，是 Ref 5.4 的標準做法。

決策樹（Decision Tree）的優缺點

為什麼醫療場域愛它

- ▶ 整棵樹可以印出來，判斷路徑一目了然
- ▶ 可直接轉成臨床決策流程圖
- ▶ 不需要縮放、能吃類別特徵、對遺失值（Missing Data）寬容
- ▶ 特徵重要性（Feature Importance）排序附送
- ▶ 非線性關係與交互作用（Interaction）自動抓到

它的致命傷

- ▶ 不穩定：資料換一批，樹可能長得完全不同
- ▶ 貪婪演算法：每步選當下最好，不保證整體最優
- ▶ 容易過擬合（Overfitting）（需靠剪枝與參數節制）
- ▶ 軸平行邊界：斜的關係要切很多刀才逼近
- ▶ → 這些正是集成方法要解決的問題

【原講義 ML 3.3】 pp197-198。單棵樹的價值在解釋；預測力要靠下一節的「一群樹」。

決策樹（Decision Tree）的深度掃描：又是那條過擬合（Overfitting）曲線

depth 從 2 掃到無限制

maximal depth	訓練 AUC	CV AUC	診斷
2	0.71	0.70	欠擬合（Underfitting）
4	0.79	0.77	接近甜蜜點
6	0.85	0.78	★ CV 最高
10	0.93	0.75	過擬合（Overfitting）
無限制	0.99	0.70	背答案



第四次見到這條曲線

對照	相同的故事
M2-1 多項式次數	1→9 次
k-NN 的 k	101→1
Logistic 的 λ	大→0
樹的 depth	2→ ∞
共同教訓	複雜度旋鈕轉到底 ＝記憶不是學習

每個模型都有一顆複雜度旋鈕

多項式次數、k、 λ 、depth—— 名字不同，物理相同

找法永遠一樣


掃參數 → 交叉驗證（Cross Validation） → 取 CV 最高點

這就是 Optimize Parameters 的工作

Ref 5.4 / 5.5 的流程自動做這件事

【原講義 ML 3.3】 pp193-196

實例：一棵印得出來的樹



風險條：滿格 = 60% (同一把尺，四個葉節點可以直接比)

每個葉節點都要同時看「比率」與「人數」—— $n=23$ 的 57% 其 95% 信賴區間約 37%–74%，遠比數字看起來不確定。整棵樹只有兩層、四條規則，個管師拿到就能用，不需要任何軟體。

根節點 (Root Node)

第一刀切年齡 ≥ 65 ——就是前頁 Gini 手算選出的那一刀

四個葉節點 (Leaf Node)

風險 8% 到 57%，直接構成風險分層

紅色葉的警訊

57% 聽起來很高，但 $n=23$ ——樣本小，不確定性大

交給個管師

這張圖可以直接印成判讀卡。這就是決策樹 (Decision Tree) 在醫療場域的價值

讀一棵印出來的樹：三條路徑

路徑一：年齡 ≥ 65 $\rightarrow$ 出院去向 = 護理之家 $\rightarrow$ 【高風險 57%】

- ▶ 讀法：65 歲以上且出院到護理之家的病人，再入院率 57%（該葉節點 23 人中 13 人）
- ▶ 個管師看得懂、能行動：這群人優先排入追蹤名單

路徑二：年齡 < 65 $\rightarrow$ 共病數 < 2 $\rightarrow$ 【低風險 8%】

- ▶ 年輕且共病少：26 人中 2 人再入院——追蹤資源可優先給其他組
- ▶ 但 26 人的 8%，區間約 2%-24%；真實專案的葉節點要數百人才可信

路徑三：年齡 ≥ 65 $\rightarrow$ 出院去向 $\neq$ 護理之家 $\rightarrow$ 【中風險 33%】（葉節點僅 27 人）

- ▶ 27 人中 9 人，區間約 19%-52%；葉節點太小，比率不穩
- ▶ 可調大 minimal leaf size，或報告區間與證據有限
- ▶ ★ 每個葉節點都要同時看「比率」與「人數」——只看比率會被小樣本騙

【原講義 ML 3.3】 pp190-192。這一頁的技能（帶人數讀樹）是把模型交給臨床人員時最重要的溝通能力。


特徵重要性（Feature Importance）：怎麼算、怎麼讀、怎麼被騙

面向	內容
怎麼算	每個特徵在所有分裂中貢獻的不純度（Impurity）下降總和（加權），歸一化成 0-1
怎麼讀	排序看相對大小；前幾名應該通過臨床直覺的檢驗
陷阱一	偏好高基數特徵：可切的點多，天生佔便宜（病歷號、流水號會浮上來＝洩漏警訊）
陷阱二	共線特徵互相攤薄：收縮壓與舒張壓都重要時，兩者的重要性都被壓低
陷阱三	重要 $\neq$ 因果：住院天數重要，不代表縮短住院就能降低再入院
更穩的替代	Permutation Importance：只在未見資料打亂欄位看分數下降；相關特徵仍可能互相替代。個案級解釋可用 SHAP（M9）


【原講義 ML 3.3】 pp192、207。特徵重要性是「模型視角的重要」，把它當成「臨床上的重要」是常見的過度解讀。

實例：特徵重要性怎麼看、怎麼被騙

左・正常的排序：臨床上說得通



右・紅色警訊：ID 類欄位排最前面



兩張圖用的是同一份病人資料，只差在右邊多留了病歷號與就診序號兩個欄位。病歷號隱含時間順序（越晚就診號碼越大），模型抓到的是「什麼時候來的」而不是「病人多重」。

左・正常

前幾名（共病數、住院天數、年齡）在臨床上說得通

右・警訊

病歷號與就診序號排在最前面——ID 類欄位不該有預測力

為什麼會這樣

病歷號可能隱含時間順序（越晚就診號碼越大）＝時間洩漏

怎麼處理

刪掉這些欄位重跑。若重要性排序因此大變，代表你原本的模型是假的

PART 12

集成方法

Ensemble Methods

一群各自不完美、但錯得不一樣的模型，
投票的結果會比任何單一成員更可靠。

為什麼投票有效：機率的魔法

多數決的正確率（獨立假設）

單一模型正確率	5 個獨立投票	提升
0.60	0.683	+0.083
0.70	0.837	+0.137
0.80	0.942	+0.142
0.90	0.991	+0.091



兩個前提

前提	說明
各自夠好	單模型至少要比亂猜好
彼此獨立	錯的地方不能都一樣
獨立性是關鍵	五個一模一樣的模型 投票毫無意義
實務手段	隨機抽資料、隨機抽特徵 → 逼出多樣性

已驗算

單模 0.70 → 五模獨立多數決（ Majority Vote ） 0.837 。公式： P(至少 3 個對) 的二項式加總

整個集成學的核心

怎麼製造「夠好又夠不一樣」的成員

Bagging 的答案

給每個成員不同的訓練資料（自助抽樣）


隨機森林（ Random Forest ）再加碼

每次分裂只准看隨機一部分特徵——樹與樹更不像


【原講義 ML 3.3 】 pp201-204

實例：Bagging 與 Boosting 的流程差異

左・Bagging：平行、獨立 → 降低變異



右・Boosting：序列、相依 → 降低偏誤



左・Bagging

四份抽樣同時進行、四個模型互不知道彼此，最後平均或投票

右・Boosting

一個接一個。紅色箭頭代表「把上一輪答錯的樣本加重」再訓練下一個

可否平行

Bagging 可以（快）；Boosting 不行（慢），因為後一個要等前一個

治什麼病

Bagging 治「不穩」（高變異）；
Boosting 治「學不夠」（高偏誤）

可否平行 Bagging 可以（快） · Boosting 不行（慢），因為後一個要等前一個
治什麼病 Bagging 治「不穩」（高變異） · Boosting 治「學不夠」（高偏誤）

三種集成策略

策略	怎麼製造多樣性	代表	特性
Voting 投票	用「不同種類」的演算法 (樹 + kNN + NB + Logistic)	Vote Operator	最簡單；成員少； 適合結合既有模型
Bagging 裝袋	同一演算法、不同的 自助抽樣 (Bootstrap) 資料集	隨機森林 Random Forest	平行訓練；降低變異 (Variance) ； 附贈 OOB 驗證與特徵重要性 (Feature Importance)
Boosting 提升	序列訓練，每個新成員 專攻前面錯的樣本	Gradient Boosting AdaBoost / XGBoost	降低偏誤 (Bias) ；威力最強； 對雜訊與離群值 (Outlier) 較敏感

【原講義 ML 3.3】 pp201-220 。 Bagging 治「不穩」 (高變異)， Boosting 治「學不夠」 (高偏誤) ——先診斷再選藥， M4 會深入。

隨機森林（Random Forest） vs 梯度提升（Gradient Boosting）

隨機森林

- ▶ 數百棵樹平行訓練，各看部分資料與特徵
- ▶ 分類可硬投票或平均機率
- ▶ 幾乎不需調參就有好表現（棵數夠多即可）
- ▶ 不易過擬合；訓練可平行、速度快
- ▶ 結構化資料的重要候選
- ▶ 參數： number of trees、每次分裂的特徵數


梯度提升（Gradient Boosting）

- ▶ 樹一棵接一棵，每棵修正前面的殘差（Residual）
- ▶ 表格資料的強力候選，不保證是效能天花板
- ▶ 學習率、深度、棵數與正則化要聯合調整
- ▶ 學習率低 + 棵數多 = 穩定但慢
- ▶ 對雜訊敏感，資料髒時反而輸隨機森林
- ▶ AI Studio： Gradient Boosted Trees Operator

【原講義 ML 3.3】 pp205-220。兩者的特徵重要性都可輸出；個案級解釋可用 SHAP 值（原講義 pp221-224），本課程在 M9 可解釋性再展開。

實例：森林越大，邊界越平滑

隨機森林：樹越多，邊界越平滑穩定（每一棵樹本身都很粗糙）



四張圖用的是同一份資料、同一組隨機種子——右邊的森林就是把左邊那棵樹再多長 199 棵。單棵樹的階梯歪得很誇張，但每棵歪的方向不一樣，投票之後就磨平了。

1 棵樹

一刀切下去，邊界是粗糙的直角階梯——這就是單棵樹不穩定的樣子

5 棵 → 25 棵

不同的抽樣讓每棵樹切在不同位置，投票之後邊界開始變圓滑

200 棵

邊界穩定下來，接近真實的分界。再加更多樹，變化已經很小

關鍵

每棵樹本身都很粗糙，但它們「錯的地方不一樣」，平均之後就抵消了

OOB：隨機森林（Random Forest）附贈的免費驗證集

原理

- ▶ 每棵樹自助抽樣，平均約 36.8% 樣本未被該樹抽中（Out-of-Bag）
- ▶ 對每筆資料，用「沒看過它的那些樹」投票預測它——這就是一次誠實的驗證
- ▶ 全部資料的 OOB 預測彙整起來＝一個近似交叉驗證（Cross Validation）的分數，不用另外切資料

實務用途

- ▶ 小資料集捨不得切測試集時，OOB 是可接受的替代
- ▶ OOB 分數與 CV 分數通常相近；差很多時檢查資料獨立性（同一病人多筆？）
- ▶ 注意：調參調到 OOB 上，它就失去「沒看過」的純潔性——最終仍需獨立測試集

【原講義 ML 3.3】 p206。「同一病人多筆紀錄」是醫療資料的獨立性殺手：切分時應以病人為單位（group split），不是以紀錄為單位。

隨機森林的參數（AI Studio: Random Forest）

參數	作用	建議起點	調整方向
number of trees	樹的數量	100	越多越穩，200 之後報酬遞減； 不會因太多而過擬合
subset ratio / features per split	每次分裂可看的特徵數	AI Studio 預設 $\log(p)+1$ ；sklearn 為 $\sqrt{p}$	調小→樹更不像、變異（Variance）更低； 調大→單樹更強、彼此更像
maximal depth	單樹深度	可放寬（森林自帶保險）	過深仍會拖慢速度
voting strategy	投票方式	confidence vote	用機率平均比硬投票 保留更多資訊

【原講義 ML 3.3】 pp208-209。森林的預設值通常已經很好——它是「不太需要調參」的模型，這正是它作為主力的理由之一。

梯度提升（Gradient Boosting）：學習率與棵數的交易

四組設定

學習率	棵數	訓練 AUC	CV AUC
0.3	50	0.93	0.84
0.1	150	0.91	0.86
0.03	500	0.90	0.87
0.01	2000	0.90	0.87



調參原則

原則	說明
低學習率+多棵	幾乎總是更穩
代價	訓練時間線性增加
搭配	early stopping：CV 分數 不再升就停
深度	3-6 的淺樹即可， Boosting 靠疊加不靠深

讀表

0.03×500 與 0.01×2000 的 CV 相同——後者只是多花四倍時間

與森林的分工

先跑森林拿穩定基準；時間允許再調提升去衝上限


過擬合監控

訓練與 CV 的差距（0.90 vs 0.87）持續擴大就該停

【原講義 ML 3.3】 pp215-220 。數字為典型型態的教學示意。

實例： AdaBoost 每一輪在做什麼

AdaBoost：點的大小 = 樣本權重。答錯的點被放大，下一輪專攻它們



第 1 輪每個點一樣大（權重都是 $1/80$ ）；到第 10 輪，只剩交界處那幾個點是大的——模型已經把全部注意力放在它們身上。它們若是標錯的雜訊，這就是災難。

點的大小 = 樣本權重

一開始所有樣本權重相同（大小一致）

第 1→2 輪

被分錯的點變大了。下一個模型會被迫優先處理它們

第 3→10 輪

邊界逐漸長出階梯，專門去接那些難分的點

風險

若那些「難分的點」其實是標錯的雜訊，Boosting 會越陷越深——這是它的弱點

AdaBoost 與 Stacking（認識即可，M4 深入）

AdaBoost：加權重訓

- ▶ 每輪提高前一輪錯分樣本的權重
- ▶ 下一個弱模型更關注難例
- ▶ 最後依成員表現加權投票
- ▶ Boosting 的代表作（Freund & Schapire, 1997）
- ▶ 對離群值（Outlier）敏感——錯的離群值（Outlier）會被瘋狂加權
- ▶ AI Studio：AdaBoost Operator

Stacking：用模型組合模型

- ▶ 第一層：多個異質模型產生預測
- ▶ 第二層：meta model 學習組合
- ▶ 第一層訓練預測必須是 out-of-fold，否則洩漏
- ▶ 威力最大、也最容易過擬合、最難解釋
- ▶ 競賽常勝軍；醫療部署少見
- ▶ AI Studio：Stacking Operator

M4 進階監督式學習會實作四種集成的完整比較（Ensemble - bagging vote stacking Adaboost.rmp）。

PART 13

模型比較總表

The Big Comparison

九類模型放在同一張桌上。

沒有永遠的冠軍——只有適不適合你的場域。

九類模型全比較

模型	機率輸出	可解釋性	需縮放	過擬合傾向	定位
Logistic	★ 天生	★★★ OR 語言	要	低	第一個正式模型；醫學研究標準
LDA / QDA	★	★★ 判別函數	要	低	樣本少時的穩健選擇
k-NN	比例近似	★ 弱	必要	k 小時高	直覺基準；少作最終部署
Naive Bayes	有（需校準檢查）	★★ 中	不用	低	快速基準；文字問題強
SVM	需校準	★ 弱	必要	C 大時高	高維中樣本的效能候選
神經網路 MLP	★	☆ 極弱	要	高	非結構化資料才是主場（M5）
決策樹	比例近似	★★★ 可印出	不用	高（需剪枝）	解釋用；轉臨床決策流程圖
隨機森林	★ 投票比例	★★ 特徵重要性	不用	低	結構化資料主力
梯度提升	★	★★ 特徵重要性	不用	中（參數敏感）	強力候選；需仔細調參

實務流程不變：Logistic 建基準 → 樹看結構 → 森林／提升拚效能 → 依可解釋性需求決定最終部署。SVM 與 MLP 屬「值得一試但通常不是答案」的候選。

演算法選擇速查：你的情況適合誰

應用場景	Logistic	LDA	k-NN	NB	SVM	MLP	決策樹	隨機森林	梯度提升
需要向臨床人員解釋每個判斷	●	○					●		
需要報告勝算比 OR	●								
樣本數很少（ < 200 ）	●	●		●			○		
特徵數 > 樣本數	○			●	●				
特徵高度非線性			●		●	●	●	●	●
類別型特徵很多	○			●			●	●	●
追求最高預測效能					○	○		●	●
要轉成紙本決策流程							●		
資料量大、需快速預測	●	●		●		○	●	●	○

● 建議 ○ 可用但非首選。實務作法：挑 3-4 個跑 Compare ROCs 一次比完，不要只用一個。

PART 14

AI Studio 實作

Hands-on Labs

Loan Risk 六步是本課程最完整的評估流程示範。
每步只加一件事，讓你看清楚各自的貢獻。

實作 1 | Loan Risk 六步序列

【AI Studio 範例】 4. Case Studies / 4.3.3

開啟檔案

範例 / ML (AI Studio) / M2. 監督式學習 /

└ 4.3.3 Loan Risk/ (檔名為縮寫)

└ Ref 5.1 split data.rmp

└ Ref 5.2 imbalanced data.rmp

└ Ref 5.3 Compare Models - ROCs.rmp

└ Ref 5.4 decision tree tuning.rmp

└ Ref 5.5 CV + Optimized Params.rmp

└ Ref 5.6 Optimized Threshold.rmp

└ ML in Finance.pdf

資料 / ... / loan_train.rmhdf5table

預期結果

- ▶ 5.2 後 Recall 與 Precision 如何取捨，要看實際結果
- ▶ 5.5 的 CV 分數通常略低——這才是誠實的估計
- ▶ 5.6 的最佳門檻不一定是 0.5
- ▶ 「哪步提升最多」的答案因資料而異——這就是要你記錄的原因

操作步驟

- 1 依序執行 5.1–5.6，每步記錄 Accuracy、Precision、Recall、AUC
- 2 5.1 基準：注意 Split Data 是否為 stratified
- 3 5.2 不平衡處理：Recall 升了多少？Precision 掉了多少？
- 4 5.3 ROC 疊圖：四個演算法哪個 AUC 最高？差多少？
- 5 5.4 決策樹調參：depth 與 leaf size 的最佳組合是？
- 6 5.5 CV + 參數最佳化：分數與單次切分差多少？
- 7 5.6 門檻最佳化：最佳門檻是多少？隱含什麼代價比（Cost Ratio）？
- 8 六步表格填入 Take-Home Assignment

實作 2 | HR Churn：特徵選擇（Feature Selection）與 Lift Chart

【AI Studio 範例】 4. Case Studies / 4.3.2

開啟檔案

```
範例 /ML (AI Studio)/M2. 監督式學習 /  
└─ 4.3.2 HR Churn/ (檔名為縮寫)  
    │ Case Study 1 - churn prediction  
    │ (various feature selection).rmp  
    │ Case Study 1.1 Selection Criterion.rmp  
    │ Case Study 1.3 Compare ROCs and  
    │ Lift Chart.rmp  
    └─ 1.3 Human Resources Dataset &  
       模型選擇 .docx ← 先讀  
  
資料 /.../Human_Resources Churn dataset  
      .rmhdf5table
```

預期結果

- ▶ 不同特徵選擇方法的結果不完全一致
- ▶ Lift Chart 直接回答「資源有限時先找誰」
- ▶ 說不出入選理由的變數，懷疑是巧合相關

操作步驟

- 1 先讀說明文件，理解資料背景與欄位
- 2 執行 Case Study 1，比較不同特徵選擇（Feature Selection）方法選出的欄位
- 3 檢查特徵重要性排序——ID 類欄位排前面＝洩漏警訊
- 4 執行 1.3，檢視 ROC 疊圖與 Lift Chart
- 5 Lift 解讀：只介入前 10% 高風險者，能涵蓋幾成實際流失者？
- 6 把「介入涵蓋率」翻譯成你專題場域的語言
- 7 選定最終模型並寫下三行理由（效能＋解釋＋部署）

分類建模全流程總複習



貼在牆上的版本。每一步的細節都在本講義對應的 PART 裡。

多標籤：一個病人同時多個結果

多標籤資料的樣子

病人	再入院	跌倒	感染
P1	1	0	1
P2	0	0	0
P3	1	1	0
P4	0	1	0



三種策略

策略	做法	注意
Binary Relevance	每個標籤獨立訓練一個二元模型	忽略標籤間相關
Classifier Chains	前一個標籤的預測餵給下一個	順序影響結果
評估	每標籤各自報告 + 整體 Hamming loss	別只報平均

【原講義 ML 3.3】 p14 的 multi-label。實務上「同時預測多種不良事件」就是這個問題——最簡單的 Binary Relevance 通常是合理起點。

從模型到部署： AI Studio 的模型物件 workflow

步驟	Operator	說明
1 訓練並存出模型	Store	把訓練好的模型存進 Repository
2 新資料進來	Retrieve + Read	下個月的新出院病人
3 讀回模型套用	Retrieve(model) + Apply Model	不重訓，直接預測
4 前處理必須一致	存出 preprocessing model 一併套用	新資料要用「當初訓練集的」縮放參數
5 定期重訓與監控	排程重跑訓練流程	盛行率（ Prevalence ）或特徵分布飄移時警示

【 AI Studio 範例】 Export-Import and Automatic model selection/01-04 就是這個流程的完整示範（匯入資料→建樹→套用→測試）。

實作 3 | 自動模型選擇八步曲

【AI Studio 範例】 Export-Import and Automatic model selection / 01-08

開啟檔案

範例 /ML (AI Studio)/M2. 監督式學習 /

└ Export-Import 系列 (原始位置:
Export-Import and Automatic
model selection/)
01-import customer data.rmp
02-build decision tree.rmp
03-apply the model.rmp
04-testing the model.rmp
05-cross-validation.rmp
06-model selection.rmp
07-parameter optimization.rmp
08-Automatic Model Selection and
Optimization.rmp

預期結果

- ▶ 08 的結果通常略優於手動，但未必值得解釋成本
- ▶ 自動化取代的是「試錯的勞力」，不是「該優化什麼」的判斷
- ▶ AutoML 時代，這個界線更重要

操作步驟

- 1 01-04：走一遍「訓練→存出→套用→測試」的部署流程
- 2 05：把單次切分升級成交叉驗證，比較分數變化
- 3 06：Select Sub-process 一次比較多個模型
- 4 07：Optimize Parameters 自動掃參數格
- 5 08：全自動版——模型選擇+參數最佳化一次完成
- 6 記錄 08 選出的最終模型與參數，和你在實作 1 手動調的結果比較
- 7 思考：自動選出的模型，你能向個管師解釋它嗎？

案例收尾：出院風險分層的最終設計

模型組合

- ▶ 隨機森林（Random Forest）產生風險分數與前 20% 名單（Lift 3.3，涵蓋 65% 達標）
- ▶ Logistic（未正則化）提供 OR 表給醫學會議；決策樹（Decision Tree）前三層印成個管師的判讀卡
- ▶ 同一系統、三個模型、各司其職——這是實務常態，不是取巧

決策設定

- ▶ 門檻依代價比（Cost Ratio）20:1 設在 0.30；每月重跑，監控盛行率與特徵分布飄移
- ▶ 名單附「主要風險因子」欄（樹路徑），個管師可覆核可推翻
- ▶ 小葉節點（Leaf Node）（<30 人）的個案標註「證據有限」

誠實的限制聲明

- ▶ 模型以本院資料訓練，他院或社區使用前需重新驗證（盛行率陷阱）
- ▶ 特徵重要性與樹路徑是預測性關聯，不是介入因果
- ▶ 同一病人多次住院需 group split；仍應報告殘餘限制

這是 Take-Home Assignment 報告最後一節的教學模板；其中數字與規則都必須換成你的資料、驗證結果與場域決策。

PART 15

Take-Home Assignment

帶回家作業（分類篇）

主題：健康照護風險分類的完整演練

第 6 週上課前繳交 | 與迴歸篇合併為一份報告，不另計分（隨堂 Lab）

作業任務（分類篇）

任務	要求	對應
1 目標定義	比照本講義 P2 的四個決定，完整寫出你的目標變數定義（時間窗、事件定義、分母、預測時點）。	P2
2 基準線	報告類別比例與「全判多數類」的 Accuracy。	P7
3 六模型比較	以 stratified 5-fold CV 跑六個模型（Logistic、kNN、NB、樹、森林、梯度提升），報告四指標的平均 ± 標準差，附 Compare ROCs 疊圖。	P4-P6, P11-P12
4 混淆矩陣（Confusion Matrix）六指標	對最佳模型手算六個指標（Accuracy、Precision、Recall、特異度、NPV、F1）。	P7
5 不平衡與門檻	至少比較兩種不平衡處理；所有取樣只在訓練折。門檻在驗證資料依代價比（Cost Ratio）與容量選定。	P8-P9
6 勝算比（Odds Ratio, OR）與樹的解讀	Logistic：三個變數的 OR 與臨床解讀。決策樹：印出樹、描述前兩層的分裂邏輯是否符合臨床直覺。	P5, P11
7 盛行率（Prevalence）敏感度（Sensitivity）	估算模型部署到「盛行率（Prevalence）減半」場域時的 PPV 變化。	P7

回饋規準（迴歸＋分類合併，共 100 分，不計入學期成績）

向度	配分	評分重點
目標與資料界定	15	目標定義四要素完整；資料檢查含偽裝遺失值（Missing Data）
方法正確性	25	stratified CV；前處理在訓練子流程內；無取樣洩漏
評估完整性	25	指標計算正確；基準線與 ROC/PR 齊備；門檻有代價比依據
解讀與臨床意義	20	OR 連同 95% 信賴區間、樹路徑解讀合理；盛行率情境分析有據；誠實面對不確定結果
報告品質	15	結構清楚；圖表可讀；.rmp 可執行；限制聲明專業

延伸挑戰：Lift Chart 的介入優先順序分析；或依性別 / 年齡層拆分指標的公平性初探（M9 預習）。

本講義 Operator 總對照

用途	Operator	出現在
模型	k-NN、Logistic、Naive Bayes、Decision Tree、Random Forest、Gradient Boosted Trees	P4-P6, P11-12
評估	Performance (Binominal)、Compare ROCs、Create Lift Chart、Performance (Costs)	P7-P8
切分與驗證	Split Data、Cross Validation (stratified)	P10
不平衡	SMOTE Upsampling、Sample、Set Role (weight)	P9
調參	Optimize Parameters (Grid)、Loop	P11-12
門檻	Find Threshold、Apply Threshold	P8
部署	Store、Retrieve、Apply Model、Group Models	P14
特徵	Nominal to Numerical、Normalize、Forward Selection、Weight by ...	P3

找不到 Operator 時：左下搜尋框輸入英文關鍵字。名稱與版本可能隨 AI Studio 更新微調。

與你的貫穿主線的連結

本週你該對自己的題目做的三件事

- ▶ 把目標定義四要素（時間窗 / 事件 / 分母 / 預測時點）套進你的題目寫一遍
- ▶ 估計你的類別比例——它決定了你之後要用哪套指標與處理
- ▶ 列出你的代價比：漏一個的代價是誤報幾個？問你場域的專業人員

Task 1 的伏筆

- ▶ 第 10 週期中發表的主體就是本週 + M2-1 的完整流程
- ▶ 漸進改良表、六模型比較表、門檻決策——三張表構成你的方法論
- ▶ 現在開始邊學邊填，發表前一週才動手一定來不及

往後看

- ▶ M3：沒有標籤時怎麼辦（分群）； M4：集成的完整展開 + 不平衡的進階
- ▶ M5：深度學習（Deep Learning）——你會發現 768 筆的資料上它常輸給今天的 Logistic
- ▶ M9：今天的特徵重要性（Feature Importance）與可解釋性議題，會以公平性的角度重新出現

公式總表（考前速查）

指標	公式	本講義例值
Accuracy	$(TP+TN)/\text{總數}$	0.925
Precision / PPV	$TP/(TP+FP)$	0.429
Recall / 敏感度	$TP/(TP+FN)$	0.750
特異度	$TN/(TN+FP)$	0.936
NPV	$TN/(TN+FN)$	0.983
F1	$2PR/(P+R)$	0.545
Balanced Acc	$(\text{Sens}+\text{Spec})/2$	0.843
Odds	$p/(1-p)$	$p=0.75 \rightarrow 3$
OR	e^{β}	$\beta=0.693 \rightarrow 2.0$
Gini	$1-\sum p_i^2$	$30/70 \rightarrow 0.42$
Entropy	$-\sum p_i \log_2 p_i$	$30/70 \rightarrow 0.881$
Lift@k	命中率 @k ÷ 整體陽性率	前 20% $\rightarrow 3.3$

本講義術語速查（上）

術語	一句話
Hard / Soft 分類	直接給類別 vs 先給機率再切門檻
決策邊界（Decision Boundary）	模型把空間切成各類別區域的那條線 / 面
最大概似（Maximum Likelihood）	挑一組參數讓「實際觀察到的資料」機率最大
勝算 Odds	$p/(1-p)$ ；機率 0.75 = 勝算 3
勝算比 OR	兩組勝算（Odds）之比； e^{β}
拉普拉斯平滑	避免沒見過的組合得到機率 0
分層抽樣（Stratified Sampling）	切分時維持類別比例
維度詛咒（Curse of Dimensionality）	維度高時距離失去鑑別力（k-NN 的天敵）

本講義術語速查（下）

術語	一句話
Gini 不純度 (Impurity)	隨機抽兩筆類別不同的機率
資訊增益	分裂前後不純度的下降量
剪枝 Pruning	限制或修剪樹的生長以抗過擬合
自助抽樣 Bootstrap	可放回抽樣出與原資料同大小的子集
OOB	Out-of-Bag：沒被抽到的樣本，免費的驗證集
Lift	前 x% 高風險名單的命中率是隨機的幾倍
校準 Calibration	模型說 70% 時，實際是不是 70%
代價比	一個 FN 抵幾個 FP 的成本——門檻的依據

必答思考題（寫入報告）

Q
1

AUC 0.85 的模型和 AUC 0.83 但 Recall 高很多的模型，你部署哪個？

AUC 是全門檻的平均表現；你部署時只活在一個門檻上。

Q
2

你的決策樹第一刀切在哪個變數？臨床上說得通嗎？如果說不通，下一步是什麼？

說不通的第一刀通常指向資料洩漏（Data Leakage）或編碼錯誤，而不是「有趣的發現」。

Q
3

隨機森林比單棵樹準，卻更難解釋。你的場域裡，這個交換值得嗎？

想想誰要為判斷負責、誰需要推翻模型的能力。

Q
4

把你的模型從醫院推到社區（盛行率降為 1/5），哪些指標會變、哪些不變？

敏感度 / 特異度（Specificity） vs PPV/NPV 的差別——這題就是 P7 的核心。

總檢核 | 出門前四題

Q
1

用一句話說明：為什麼本講義的模型 **Accuracy 0.925** 卻「輸給什麼都不做」？

全判陰性得 0.940。不平衡資料上 Accuracy 會獎勵懶惰。

Q
2

若只是純盛行率改變、且條件效能固定，敏感度、特異度、**PPV**、**NPV** 哪兩個一定要重算？

PPV 與 NPV。它們是盛行率的函數。

Q
3

你的隨機森林 **AUC 0.86**、**Logistic 0.83**。什麼情況下你仍該部署 **Logistic**？

需要 OR 語言溝通、需要個案級解釋、或 0.03 的差距在你的門檻附近根本不影響名單。

Q
4

Take-Home 的第一步是什麼？（提示：不是打開 **AI Studio**）

把目標定義四要素寫下來。定義錯了，後面全白做。

中英術語對照 | M2-2 分類

(1 / 8)

中文	English	一句話說明
分類	Classification	預測類別
二元分類	Binary Classification	兩種類別
多元分類	Multi-class Classification	三種以上、互斥
多標籤	Multi-label	一筆可同時屬於多個標籤
硬分類／軟分類	Hard / Soft Classification	直接給類別 vs 先給機率
決策邊界	Decision Boundary	模型把空間切成各類別區域的界線
k 最近鄰	k-Nearest Neighbors, k-NN	看最近的 k 個鄰居投票
維度詛咒	Curse of Dimensionality	高維時距離失去鑑別力
邏輯斯迴歸	Logistic Regression	以 Sigmoid 輸出機率的線性模型

中英術語對照 | M2-2 分類

(2 / 8)

中文	English	一句話說明
最大概似	Maximum Likelihood Estimation, MLE	讓觀察到的資料機率最大的參數
勝算	Odds	$p / (1-p)$
勝算比	Odds Ratio, OR	兩組勝算之比； e^{β}
風險比	Risk Ratio, RR	兩組風險之比；事件常見時與 OR 差距大
單純貝氏	Naive Bayes	假設特徵獨立的機率分類器
拉普拉斯平滑	Laplace Smoothing	避免未見過的組合機率為 0
混淆矩陣	Confusion Matrix	TP / FN / FP / TN 的 2×2 表
準確率	Accuracy	$(TP+TN)/$ 總數；不平衡時會誤導
精確率／陽性預測值	Precision / Positive Predictive Value, PPV	說有病的人裡真的有病的比例

中英術語對照 | M2-2 分類

(3 / 8)

中文	English	一句話說明
召回率／敏感度	Recall / Sensitivity / TPR	真的有病的人裡被抓到的比例
特異度	Specificity / TNR	沒病的人裡被正確排除的比例
陰性預測值	Negative Predictive Value, NPV	說沒病的人裡真的沒病的比例
F1 分數	F1 Score	Precision 與 Recall 的調和平均
平衡準確率	Balanced Accuracy	(敏感度 + 特異度) / 2
馬修斯相關係數	Matthews Correlation Coefficient, MCC	四格全入的相關係數，最難被騙
盛行率	Prevalence	母體中陽性的比例； PPV 隨它大幅變動
ROC 曲線	Receiver Operating Characteristic Curve	掃過所有門檻的 FPR-TPR 軌跡
曲線下面積	Area Under the Curve, AUC	ROC 下的面積；與門檻無關

中英術語對照 | M2-2 分類

(4 / 8)

中文	English	一句話說明
PR 曲線	Precision-Recall Curve	不看 TN，極度不平衡時更誠實
決策門檻	Decision Threshold	把機率切成類別的那個值（預設 0.5）
代價比	Cost Ratio	一個偽陰性抵幾個偽陽性；門檻的依據
校準	Calibration	模型說 70% 時實際是不是 70%
類別不平衡	Imbalanced Data	某一類遠少於另一類
過取樣	Oversampling	複製少數類至平衡
合成少數類過取樣	Synthetic Minority Over-sampling Technique, SMOTE	在少數類樣本間內插造出新樣本
欠取樣	Undersampling	刪除部分多數類樣本
類別權重	Class Weight	訓練時加重少數類的損失

中英術語對照 | M2-2 分類

(5 / 8)

中文	English	一句話說明
分層抽樣	Stratified Sampling	切分時維持類別比例一致
決策樹	Decision Tree	一連串是 / 否問題逐層切分資料
不純度	Impurity	節點內類別混雜的程度
吉尼不純度	Gini Impurity	隨機抽兩筆類別不同的機率
熵	Entropy	資訊理論的不確定性度量
資訊增益	Information Gain	分裂前後不純度的下降量
增益率	Gain Ratio	懲罰高基數特徵的增益指標
剪枝	Pruning	限制或修剪樹的生長以抗過擬合
葉節點	Leaf Node	樹的末端；最終判定所在

中英術語對照 | M2-2 分類

(6 / 8)

中文	English	一句話說明
集成學習	Ensemble Learning	組合多個模型以提升穩定與效能
投票法	Voting	結合不同種類模型的預測
裝袋法	Bagging / Bootstrap Aggregating	不同抽樣子集訓練同種模型後平均
自助抽樣	Bootstrap	可放回抽樣出同大小的子集
袋外樣本	Out-of-Bag, OOB	未被抽中的樣本；免費的驗證集
隨機森林	Random Forest	Bagging + 分裂時隨機選特徵
提升法	Boosting	序列訓練，每個新模型修正前者的錯
梯度提升	Gradient Boosting	以殘差為目標序列疊加弱模型
堆疊法	Stacking	以 meta 模型學習如何組合第一層預測

中英術語對照 | M2-2 分類

(7 / 8)

中文	English	一句話說明
特徵重要性	Feature Importance	各特徵對模型貢獻的相對大小
排列重要性	Permutation Importance	打亂該欄後分數掉多少
提升度	Lift	前 x% 名單的命中率是隨機的幾倍
累積增益	Cumulative Gain	前 x% 名單涵蓋多少實際陽性
學習曲線	Learning Curve	分數隨訓練樣本數的變化
支援向量機	Support Vector Machine, SVM	找間隔最寬的分隔超平面
間隔	Margin	決策邊界到最近樣本的距離
支持向量	Support Vector	決定邊界位置的那少數幾個樣本
核技巧	Kernel Trick	映射到高維空間以處理非線性可分

中英術語對照 | M2-2 分類

(8 / 8)

中文	English	一句話說明
線性判別分析	Linear Discriminant Analysis, LDA	假設常態且等共變異的判別方法
二次判別分析	Quadratic Discriminant Analysis, QDA	允許各類別共變異不同的判別方法
多層感知器	Multilayer Perceptron, MLP	最基本的前饋神經網路
反向傳播	Backpropagation	神經網路更新權重的演算法
極端隨機樹	Extremely Randomized Trees	切點也隨機選的森林變體

分類篇重點回顧

- 1 目標定義有四個隱藏決定：時間窗、事件、分母、預測時點——先寫清楚再建模。
- 2 Accuracy 在不平衡資料會輸給「什麼都不做」；醫療場域看 Recall 與 Precision。
- 3 敏感度 / 特異度不受盛行率影響，PPV/NPV 隨盛行率變——換場域必須重新評估。
- 4 0.5 只是軟體預設。門檻由代價比決定，而代價比是臨床判斷。
- 5 取樣只在訓練集做；分層 CV 是分類作業的預設要求。
- 6 Logistic、樹、森林與提升各有角色；最終部署要共同考量驗證效能、校準、可解釋性與場域限制。

下一步 第 6 週 M3 非監督式學習：分群（Clustering）與降維 + 作業一發布