

非監督式學習：分群與降維

M3 — Unsupervised Learning: Clustering & Dimensionality Reduction

沒有標準答案的學習。以原課程 ML 3.4 (326 頁) 為本改寫：
分群、異常偵測、降維——問的不是「會怎樣」，而是「這裡面有什麼結構」。

本講義大綱

01 非監督式學習 101 · 沒有標籤的世界

02 完整流程回顧 · 從問題理解到部署

03 前處理：為什麼縮放是必要的 · 距離型演算法的前提

04 K-Means · 手算兩輪 + 逐步圖解

05 怎麼決定 K · 手肘法與 Silhouette

06 階層式分群 · 樹狀圖與連結方式

07 DBSCAN · 密度式分群與雜訊

08 三種演算法的形狀能力 · 同一資料三種結果

09 分群結果怎麼解讀 · 群組剖析與命名

10 異常偵測 · 三種取徑與 Isolation Forest

11 降維與 PCA · 幾何意義與解釋變異

12 t-SNE 與降維 + 分群 · 看見高維資料

13 AI Studio 實作 · Customer Credit Risk

14 Take-Home Assignment · 作業一：顧客分群分析

PART 01

非監督式學習 101

Unsupervised Learning Basics


監督式問「這一筆會怎樣」，非監督式問「這一堆裡面有什麼結構」。
沒有答案可以對，所以評估方式完全不同。

監督式 vs 非監督式

比較項目	監督式 Supervised	非監督式 Unsupervised
資料長相	每筆有標籤 y (會不會再入院)	只有特徵 x , 沒有 y
在學什麼	輸入到答案的對應關係	資料本身的結構與關係
怎麼知道對不對	跟正確答案比對 (Accuracy 、 AUC)	沒有正確答案 ; 看指標 + 業務可解釋性
典型任務	分類、迴歸	分群、降維、異常偵測、關聯規則
結果的性質	可驗證：預測對或錯	可討論：這樣分有沒有道理
本課程	M2 (W4-W5)	M3 (W6) 、M4 的異常偵測與關聯規則

【原講義 ML 3.4】pp8-15。非監督式沒有單一標準答案，因此必須結合內部指標 (Internal Metrics) 、穩定性 (Stability) 與領域判斷；專業判斷是必要條件，不代表結果自動有效。

實例：分群沒有標準答案



左・你拿到的資料

全部同色。沒有人告訴你有幾群、誰屬於哪一群

中・K=2

硬把資料切成兩塊。演算法照做，不會抱怨

右・K=3

看起來比較貼近資料的自然結構

哪一個對

演算法本身無法回答。要靠指標 (Silhouette) + 你的領域判斷

非監督式學習的四大應用

應用	在做什麼	健康照護的例子	本課程
分群 Clustering	把相似的個案分成幾群	病人分型、照護路徑設計、 社區族群分層	M3 主軸
降維 Dimensionality Reduction	把很多欄位壓成少數幾個	問卷量表降維、 高維檢驗值視覺化	M3 主軸
異常偵測 Anomaly Detection	找出「不像其他人」的個案	生理訊號異常、 異常申報偵測	M3 概念 + M4 實作
關聯規則 Association Rules	找出「常一起出現」的組合	共病組合、 用藥組合分析	M4

【原講義 ML 3.4】p14。原講義另含推薦系統 (pp293–318)，本課程不列入正式範圍——有興趣可參考 4. Case Studies/Product Recommendation/。

PART 02

完整流程回顧


The Full Workflow

在進入分群之前，先把整個資料科學流程完整看過一次。
這張圖適用於本課程所有模組——包含監督式與非監督式。

資料科學專案的完整流程

資料科學專案的完整流程

調校後回頭：重做特徵工程，甚至重新界定問題



這不是一條直線：紅色虛線代表實務上一定會發生的回頭與迭代

① – ⑤ 前段

問題理解 → 資料蒐集 → 清理 → EDA → 特徵工程。前段常耗費大量時間；實際占比取決於資料品質、任務與組織流程

⑥ 切分與建模

橘色虛線框內是關鍵：所有前處理的統計量只能從訓練集算

⑦ – ⑪ 後段

評估 → 調校 → 溝通 → 部署 → 監控。最後兩步決定分析能否持續產生價值

★ 紅色虛線

實務上一定會回頭。評估不如預期就回去改特徵，監控發現飄移就回去收資料

非監督式的流程差在哪

與監督式相同的部分

- ▶ 問題理解：一樣要先問「誰要用、拿來做什麼」
- ▶ 資料蒐集與清理：遺失值、離群值、一致性照樣要處理
- ▶ EDA：分布與相關性照樣要看
- ▶ 特徵工程：衍生、編碼、分箱照樣要做
- ▶ 溝通與部署：一樣要能講給使用者聽

非監督式獨有的差異

- ▶ 沒有標籤 → 沒有傳統 Accuracy
- ▶ 若會套用新資料，保留 Holdout / Future Data
- ▶ 距離型方法要縮放；非距離型方法未必需要
- ▶ 評估看 Silhouette、Davies–Bouldin、穩定性 + 業務判斷
- ▶ 調校 K、距離、特徵時記錄敏感度


【原講義 ML 3.4】pp16–17。原講義的提醒：非監督式的最終判準是「這些群組能不能幫你解決問題」，而不是任何單一數字。

前處理：距離型方法先處理尺度

Scaling for Distance-Based Methods

K-Means、DBSCAN、階層式與 k-NN 直接使用距離；尺度不同時，大數值欄位會主導。對不靠距離的方法，縮放未必必要。

實例：不正規化時，年齡等於不存在



左・原始尺度

兩軸畫成同刻度後才看得清楚：年齡的變化幅度被收入完全壓扁

距離怎麼算

歐氏距離把兩軸的差平方相加。收入差 50、年齡差 5 → 收入貢獻是年齡的 100 倍


右・Z-Score 後

兩個特徵都變成「離平均幾個標準差」，等權參與距離計算

影響誰

K-Means、階層式、DBSCAN、k-NN
PCA：視各欄尺度是否應等權

實例：縮放如何改變分群結果



左・真實結構

刻意造出三群：中低收入年輕、中低收入年長、高收入中年

中・未正規化（純度 77%）

切線全是垂直的——只依收入分，年齡完全沒有作用

右・Z-Score 後（98%）

兩個維度等權，三個真實群組被還原

★ 作業一任務 4

就是要你在 Mall Customer 資料上親手跑出這組對照

分群前的三個前處理決策

① 哪些欄位要納入

- 純列識別碼 (Row ID) 通常移除；若代碼本身承載業務資訊，不能一律刪除
- 與分群目的無關的欄位應移除；放越多不代表分得越好
- 高度相關欄位會重複加權； $|r| > 0.8$ 只能當篩查提示，仍要看目的與共線資訊

② 類別欄位怎麼處理

- K-Means 需要數值輸入；名目類別不要直接用任意整數順序
- 二元類別可用 0/1；多類別常用 One-Hot Encoding，但會提高維度
- 混合型資料可考慮 k-Prototypes 或 Gower Distance (需額外工具)

③ 用哪一種縮放

- Z-Score (StandardScaler)：常見預設，但對離群值敏感
- Min-Max Scaling：需要固定範圍時使用，也會受極端值影響
- RobustScaler：以中位數與 IQR 縮放，較能抵抗離群值
- 先檢查分布與距離意義，再做敏感度比較

【原講義 ML 3.4】 pp45–49 + scikit-learn StandardScaler / RobustScaler 官方文件 (2026/07 查證)。

K-Means 分群

K-Means Clustering

最常用的分群演算法。

它只反覆做兩件事，而且兩件都很簡單。

K-Means 的演算法




【原講義 ML 3.4】 pp56–65。K-Means 保證會收斂，但不保證收斂到全域最優——起始中心不同，結果可能不同。這是為什麼要多跑幾次取最好的。

手算：六位病人、K=2、跑到收斂

第 1 輪的距離計算

點	x	y	到 C1 距離	到 C2 距離	歸屬
A	2.0	2.0	0.00	1.41	群1
B	3.0	3.0	1.41	0.00	群2
C	2.5	2.0	0.50	1.12	群1
D	8.0	8.0	8.49	7.07	群2
E	9.0	7.0	8.60	7.21	群2
F	8.5	9.0	9.55	8.14	群2



中心的移動軌跡

輪次	C1	C2
起始	(2.0, 2.0)	(3.0, 3.0)
第 1 輪後	(2.25, 2.0)	(7.12, 6.75)
第 2 輪後	(2.5, 2.33)	(8.5, 8.0)
第 3 輪後	(2.5, 2.33)	(8.5, 8.0)
結果	A B C	D E F

起始中心刻意選得很差

兩個中心都在左下角，第 1 輪的分群是錯的 (B 被分到群2)

第 2 輪就修正了

中心移動後，B 回到群1，D E F 正確聚成群2

第 3 輪中心不動


這個例子只花三輪；實務迭代數取決於資料、初始化與收斂容忍度 (Tolerance)

距離公式

歐氏距離 = $\sqrt{(x_1-x_2)^2 + (y_1-y_2)^2}$ 。所有數字都已驗算

【原講義 ML 3.4】 pp57-65

實例：K-Means 逐步收斂的過程



紅色 X = 中心

看它每一輪往哪裡移動——移向該群所有點的平均位置

第 1 輪

起始中心都在左下，分群明顯不合理

第 2 輪

中心大幅移動後，分群已經正確

第 3 輪

中心不再變動 → 收斂。這就是演算法停止的條件

K-Means 的優缺點與參數

面向	內容
優點	速度快、可擴展到大資料；概念直觀；結果（中心點）容易解讀成「典型個案」
缺點 1	必須事先指定 K——但你通常不知道有幾群
缺點 2	只擅長球狀、大小相近的群。彎月形、同心圓會完全失敗（本講義後面有實例）
缺點 3	對離群值敏感——一個極端點會把中心整個拉走
缺點 4	結果依起始中心而變。務必跑多次（AI Studio 的 max runs 參數）
AI Studio 參數	k（群數）、max runs（重跑次數）、measure types（距離定義）、max optimization steps（最大迭代）

【AI Studio 範例】5. Clustering/CLUSTERING - Customer Credit Risk 2026/ 的 1、2、6 號流程。

PART 05

怎麼決定 K

Choosing K

這是分群最常被問的問題，而且沒有唯一正確答案。
但有三個可以依循的判準。

Inertia (組內平方和) 怎麼算

逐點計算

群	成員	中心	各點到中心距離 ²
群1	A(2,2)	(2.5, 2.33)	0.36
	B(3,3)		0.69
	C(2.5,2)		0.11
群2	D(8,8)	(8.5, 8.0)	0.25
	E(9,7)		1.25
	F(8.5,9)		1.00



彙整

量	值
群1 組內平方和	1.167
群2 組內平方和	2.500
Inertia 總和	3.667
別名	WCSS (Within-Cluster Sum of Squares)
性質	K 越大一定越小 (K = n 時為 0)

Inertia 在量什麼

每個點離自己群中心有多遠。越小代表群內越緊密

為什麼不能直接選最小的

K 越大 Inertia 一定越小。K = 樣本數時每點自成一群，Inertia = 0，但毫無意義

所以要看「轉折」

下降速度突然趨緩的那個 K，就是手肘法要找的點



AI Studio

Cluster Distance Performance Operator 會輸出 Avg. within centroid distance

【原講義 ML 3.4】 pp76–79

實例：手肘法與 Silhouette

兩個指標一起看：手肘看趨勢、Silhouette 看品質



左・手肘法 Elbow

Inertia 隨 K 單調下降。找「下降突然變慢」的轉折點

手肘的問題

有時候彎得不明顯，三個人看會有三種答案——這是它的弱點

右・Silhouette

可重複計算的內部指標 (Internal Metric)；但結果仍受距離、尺度與群形狀假設影響

兩個都看

兩者同方向時證據較強；不一致時再檢查穩定性、群形狀與業務用途

Silhouette 係數：手算一個點

點 A 的兩個距離

點	所屬群	a = 同群平均距離	b = 最近他群平均距離
A	群1	0.957	8.880



係數計算

步驟	計算	值
公式	$s = (b - a) / \max(a, b)$	
代入	$(8.880 - 0.957) / 8.880$	
s(A)		0.892
判讀	接近 +1 → 分得很好	

a 在量什麼

這個點與「自己群其他成員」的平均距離。越小越好

b 在量什麼

這個點與「最近的另一群」全部成員的平均距離。越大越好

整體 Silhouette


把每個點的 s 算出來取平均，就是整個分群的分數

範圍與判讀

-1 到 +1；接近 1 表示群內緊密、群間分離，接近 0 表示重疊。0.5 / 0.25 只宜當常見經驗值 (Rule of Thumb)，沒有通用門檻。

【原講義 ML 3.4】pp171-173

實例：Silhouette 的三種情況



左 · $s \approx +0.9$

星號點離自己群很近、離另一群很遠 → 分得很好

中 · $s \approx +0.1$

在兩群邊界上， a 與 b 差不多 → 這個點分到哪群都可以

右 · $s \approx -0.4$

離另一群反而更近 → 很可能被分錯了

實務用途

把 s 很低的個案挑出來單獨檢視——它們常是最有洞見的邊界案例

三個判準，缺一不可

判準	怎麼看	優點	限制
① 手肘法 Elbow	Inertia 對 K 作圖，找轉折	直觀、計算快	轉折常不明顯，主觀
② Silhouette / Davies-Bouldin	Silhouette 取最大； Davies-Bouldin 取最小	有明確極值，較客觀	仍假設「群是緊密且分離的」
③ 業務可解釋性	每一群說得出「這是誰」嗎？ 能對應到不同行動嗎？	★ 最終判準	需要領域知識

【原講義 ML 3.4】pp80–83。原講義的 PRO TIP：有時候精確的群組歸屬沒那麼重要，重要的是你能依此提出什麼可行動的建議。

分群驗證：三層證據一起看

1

內部品質 Internal Validation

- ▶ Silhouette、Davies–Bouldin
- ▶ 只回答群內緊密與群間分離
- ▶ 必須在同一特徵空間、距離下比較
- ▶ 高分不等於真實族群

2

穩定性 Stability

- ▶ 換起始種子重跑
- ▶ 抽樣 80% 後重新分群
- ▶ 用 ARI (Adjusted Rand Index) 比較標籤
- ▶ 群組剖析若大幅漂移，結論不穩

3

外部效度與用途 External & Usefulness

- ▶ 有外部結果時，只在建模後驗證
- ▶ 請領域專家檢視代表個案
- ▶ 每群是否對應不同決策？
- ▶ 同時檢查公平性與資料期間

三層都要留證據：內部指標、重抽樣穩定性、外部 / 業務效度。來源：scikit-learn Clustering Metrics、K-Means Stability (2026/07)。

PART 06


階層式分群

Hierarchical Clustering

不必事先決定群數。

它把所有可能的群數一次算完，讓你事後再切。

實例：樹狀圖怎麼讀



左・五個點

P1 與 P2 很近、P3 與 P4 很近、P5 孤零零在右下

右・樹狀圖

由下往上：先合併最近的一對 (P3-P4，距離 0.54)，再來 P1-P2 (0.71)

縱軸的意義

合併時兩群之間的距離。跳很高代表「硬把兩個不像的群併在一起」


怎麼決定群數

橫切一刀。切在距離 3.0 處會得到 3 群：
{P1,P2}、{P3,P4}、{P5}

合併順序：從距離矩陣看

兩兩距離

配對	距離
P3-P4	0.539
P1-P2	0.707
P2-P3	4.950
P4-P5	5.467
P1-P3	5.657
P1-P5	8.000



凝聚式合併順序

步驟	合併誰	距離
1	P3 + P4	0.539
2	P1 + P2	0.707
3	{P1,P2} + {P3,P4}	約 5.55
4	全部 + P5	約 6.60
觀察	第 3、4 步距離跳很大 → 切在這之前較合理	

凝聚式 Agglomerative

由下而上：每個點自成一群，反覆合併最近的兩群。這是最常用的

分裂式 Divisive

由上而下：全部一群，反覆切開。計算量大，較少用

距離跳躍是線索

第 2 步 (0.707) 到第 3 步 (5.55) 跳了 8 倍——這裡就是自然的切點

距離已驗算


所有數值為實際計算的歐氏距離

【原講義 ML 3.4】 pp85-91


實例：三種連結方式

兩群之間的「距離」怎麼算？三種連結方式會長出不同的樹


單一連結 Single
取最短距離



完全連結 Complete
取最長距離



平均連結 Average
取所有配對的平均



單一連結 Single

取兩群之間「最短」的那一對距離。容易產生鏈狀的長條群

完全連結 Complete

取「最長」的那一對。傾向產生大小相近的緊密群

平均連結 Average

兼顧最近與最遠配對；是否合適仍要用資料與穩定性驗證

還有 Ward 法

Ward's Method 以合併後組內平方和增加最少為準；常搭配歐氏距離，偏好緊密群，並非所有資料都最佳

階層式分群的優缺點

優點

- ▶ 不必事先指定群數——樹狀圖一次呈現不同切法
- ▶ 樹狀圖適合溝通，也能看出群中子群
- ▶ 無隨機初始化；但仍受縮放、距離、Linkage 與離群值影響
- ▶ 適合可承受成對距離矩陣、且想探索巢狀結構的資料

缺點

- ▶ 計算量大：距離矩陣是 $n \times n$ ，樣本上萬時吃不消
- ▶ 合併之後不能反悔——早期的錯誤會一路帶下去
- ▶ 對離群值敏感（單一連結尤其）
- ▶ 仍需要你決定「切在哪」
- ▶ AI Studio : Agglomerative Clustering Operator


DBSCAN 密度式分群

Density-Based Clustering

前兩種都假設「群是一團一團的」。

DBSCAN 改問：哪裡的點特別密集？

實例：DBSCAN 的三種點



核心點 Core

以 eps 為半徑畫圓，圓內至少有 min_samples 個點

邊界點 Border

自己不夠密，但落在某個核心點的半徑內
→ 併入該群

雜訊點 Noise

★ DBSCAN 的原生能力：直接輸出 Noise Label (-1) ；但雜訊不等於真實異常

兩個參數

eps (半徑) 與 min_samples (最少點數) 共同決定結果，必須做敏感度分析 (Sensitivity Analysis)

DBSCAN 的兩個參數怎麼調

參數	意義	調大會	調小會	起手建議
eps (半徑)	多近算「鄰居」	群變少變大； 最後可能全部併成一群	群變多變碎； 雜訊點暴增	先縮放；令 $k = \text{min_samples}$ ，畫 k-Distance Plot 找膝點。沒有通用的 1–5% 比例
min_samples (最少點數)	多密才算核心	雜訊點變多； 只保留最密的核心	幾乎沒有雜訊； 容易把稀疏區也算成群	值越大代表要求更高密度；依維度、噪音容忍度試一段範圍，並報告敏感度

【原講義 ML 3.4】pp111–168。DBSCAN 適合密度相近的群；高維時距離辨識力下降。密度差異大可比較 HDBSCAN / OPTICS。來源：scikit-learn DBSCAN、HDBSCAN (2026/07)。

DBSCAN 的三個強項與邊界

① 不必事先指定群數

- 群數由資料的密度結構自己決定，這是它相對於 K-Means 最大的優勢
- 但代價是你改成要調 `eps` 與 `min_samples`——難度不見得比較低

② 能找出任意形狀的群

- 能沿密集區擴張，處理非凸形 (Non-convex) 結構
- 彎月形、環狀常比 K-Means 合適；但不同密度的群可能無法用同一 `eps` 同時找出

③ 自動標出雜訊

- 不強迫每點歸群，稀疏點標為雜訊 (`-1`)
- Noise Label 可作異常候選，但不應直接等同錯誤或高風險個案
- 仍需以領域規則、時間資料或人工複核驗證


PART 08

三種演算法的形狀能力

Same Data, Different Results

同一份資料餵給三種演算法，結果可能天差地遠。
這一頁決定你該選哪一個。

實例：三種演算法 × 三種資料形狀



第一列・球狀

三者在這組參數下都能形成合理分群；若品質與穩定性相近，可選較簡單的 K-Means

第二列・彎月形

K-Means 的凸形假設不合；經調校的 DBSCAN 能沿相近密度的兩彎擴張

第三列・同心圓

K-Means 切成左右兩半（完全錯）；DBSCAN 正確分出內外環

結論

形狀、密度、尺度與噪音共同影響選擇。散布圖只是一個線索，還要比較指標與穩定性

三種演算法全比較

面向	K-Means	階層式	DBSCAN
需要指定群數	★ 要	不用 (事後切)	不用
能抓的形狀	偏好凸形、尺度相近	看連結方式，較彈性	非凸形、密度相近
雜訊處理	強制每點歸群	強制每點歸群	★ 自動標為雜訊
對離群值	敏感 (拉走中心)	敏感 (尤其單一連結)	可隔離噪音；仍敏感參數
計算量	低，可處理大資料	高 ($n \times n$ 距離矩陣)	依資料與 ϵ ；最壞 $O(n^2)$
結果穩定性	依起始中心而變	無隨機起始；敏感尺度與 Linkage	依參數而變
群大小差異大時	表現差 (傾向切成等大)	視 Linkage 與距離而定	密度差大時易漏群
高維表現	需降噪並驗證	距離辨識力會下降	距離與密度更難分辨
AI Studio	k-Means / X-Means	Agglomerative Clustering	DBSCAN

【原講義 ML 3.4】 pp175–176。先依目標、距離、形狀、密度與尺度選候選法；再用內部指標、穩定性與群組用途比較，不以單張 2D 圖拍板。

PART 09


分群結果怎麼解讀

Interpreting Clusters

跑出群組只是一半的工作。

說不出「每一群是誰」，這個分析就沒有價值。

實例：群組剖析圖



怎麼做

把每一群在各特徵上的平均，與「整體平均」相比，畫成長條圖

怎麼讀

往上 = 該群在這個特徵上高於平均；往下 = 低於平均

怎麼命名

看哪幾根特別突出。群3 在就診次數與共病數都很高 → 高需求族群

★ 命名是分析的一部分

說不出每群是誰，就等於什麼都沒做出來

分群結果的解讀四步驟

步驟	做什麼	產出
① 看群大小	每群各多少人？佔比多少？	極小群要判斷是真實次族群還是雜訊；<5% 可作警示，不是通用門檻
② 做群組剖析	算每群在各特徵的平均，與整體平均比較	剖析圖或表格（本頁的圖）
③ 為每群命名	用 2–6 個字描述這群的特徵	例：「高齡低支出型」「年輕高就診型」
④ 對應到行動	每一群該有什麼不同的處置？	★ 若兩群的處置一樣，那分成兩群就沒有意義

【原講義 ML 3.4】pp70–71、82–83。第 ④ 步是檢驗分群是否有價值的最終標準——這也是作業一任務 6 的要求。

隨堂檢核 1 | 分群

Q
1

K-Means 跑兩次得到不同結果，是程式有問題嗎？

不是。起始中心隨機，結果本來就可能不同。解法：提高 max runs，或固定 random seed。

Q
2

Silhouette 最高的 K 是 6，但你只能設計 3 種照護方案。怎麼辦？

選 3。業務可解釋性是最終判準——分成 6 群卻只有 3 種處置，多出來的區分沒有意義。

Q
3

DBSCAN 跑出來 80% 的點都是雜訊，哪裡出錯了？

eps 太小或 min_samples 太大。先畫 k-距離圖找合適的 eps。

Q
4

為什麼距離型分群通常要縮放，但決策樹不用？

K-Means、DBSCAN 等方法直接算距離，會被大尺度欄位主導；決策樹只比較切分，不計算特徵間距離。

PART 10

異常偵測


Anomaly Detection

換一個問法：不是「這些點怎麼分群」，
而是「哪些點不像其他人」。


實例：三種異常偵測取徑

異常偵測三種取徑：紅色 × 為被標記的異常點


① 統計法 ($|z| > 3$ 附近)
簡單，但假設接近常態



② 距離法 (第 k 個鄰居很遠)
需正規化，維度高時失效



③ Isolation Forest
隨機切幾刀就能孤立 = 異常



① 統計法

Z-Score：偏離平均數個標準差，需注意分布假設；IQR / MAD 是較穩健替代

② 距離法

第 k 個最近鄰居特別遠；需要縮放，且高維時距離辨識力會下降

③ Isolation Forest



以較短的平均切分路徑判異常；不需分布假設，常比距離法更能擴展到高維，但仍要驗證

沒有標準答案

完整標籤通常缺少；可用少量已知事件、時間切分、人工複核與 Top-k 命中率共同驗證

實例：Isolation Forest 的核心直覺

Isolation Forest 的核心直覺：異常點「容易被孤立」



左・正常點

位於密集區。要隨機切很多刀，才能把它單獨隔離出來

右・異常點

位於稀疏區。切兩三刀就孤立了

演算法

建很多棵隨機切分樹，記錄每個點平均被幾刀孤立

為什麼好用

不依賴成對距離，常比 k -NN / LOF 更能擴展；但特徵太多或無關特徵很多時，仍可能退化

四種異常偵測方法比較

方法	判斷依據	優點	限制
統計法 (Z-score / IQR)	偏離平均幾個標準差； 或落在四分位距外	極簡單、可解釋	Z-Score 有分布假設； 單欄方法看不到交互異常
距離法 (k-NN 距離)	第 k 個最近鄰居有多遠	直覺；可處理多維	需縮放；高維時 距離辨識力下降
密度法 (LOF / DBSCAN)	周圍密度比鄰居稀疏多少	LOF 比較局部密度； DBSCAN 同時分群與標噪音	參數敏感；DBSCAN 難同時處理不同密度
Isolation Forest	隨機切幾刀能孤立	不需分布假設； 常快速且可擴展	門檻可用 auto 或 contamination； 仍需做時間與人工驗證

【原講義 ML 3.4】 pp183–208 + scikit-learn IsolationForest / LOF 官方文件 (2026/07 查證) 。M4 第 7 週會實作感測器異常偵測。

醫療場域的三個提醒

異常 ≠ 錯誤

- ▶ 被標記為異常的個案，可能是資料輸入錯誤，也可能是真正的重症病人
- ▶ 先問「生理上可能嗎」：血壓 0 是錯誤，血壓 210 是真實的高危個案
- ▶ M1 講過的原則在這裡再次適用：標記而非直接刪除

污染比例要自己設

- ▶ 部分方法以 contamination 設定分數門檻，也有 auto 模式
- ▶ 設 5% 通常會把約 5% 樣本標成異常，這是閾值假設，不是資料真相
- ▶ 應用領域先定可接受的警報量，再做敏感度比較

驗證需要領域專家

- ▶ 專家複核很重要，但不是唯一證據：可結合少量已知事件、時間切分與合成異常
- ▶ 報告 Precision@k、Alert Yield、漏報案例與群體差異
- ▶ 追蹤新資料上的警報率，確認規則沒有漂移

降維與主成分分析

Dimensionality Reduction & PCA

降維可幫助視覺化、減少計算並緩解距離退化；但也會丟失資訊，是否值得必須看下游任務。

為什麼要降維

1

看得見

- ▶ 人類最容易檢視 2–3 維圖
- ▶ 高維資料需投影後才方便視覺化
- ▶ 2D 圖是診斷視窗，不是資料真相
- ▶ ★ 常見用途：溝通與探索
- ▶ 分群標籤可投影上色
- ▶ 仍要回到原建模空間驗證

2

算得動

- ▶ 降低特徵數可減少距離與模型計算
- ▶ 效益取決於樣本量、演算法與降維成本
- ▶ 不保證一定更快或更準
- ▶ 對大量高維資料較有感
- ▶ 先量測再決定
- ▶ 保留可重現的轉換流程

3



避開維度詛咒

- ▶ 維度升高時，距離常變得較難區分
- ▶ → 距離型方法可能退化
- ▶ → 需要特徵選擇、PCA 或更合適的度量
- ▶ 降維只能緩解，不能保證消除
- ▶ ★ 以穩定性與下游表現驗證
- ▶ 無關特徵常比維度數本身更傷


【原講義 ML 3.4】pp214–218。降維與「特徵選擇」的差別：特徵選擇是「挑出原始欄位」（保留可解釋性）；降維是「造出新的組合欄位」（效果好但難解釋）。

實例：PCA 的三個步驟

PCA 三步驟：置中 → 找最大變異方向 → 投影降維



③ 投影到 PC1 (1 維)
保留了 95.9% 的變異



① 原始資料

兩個特徵高度相關，資料呈斜向分布

② 找主成分方向

PC1 = 變異最大的方向 (紅) ; PC2 與它垂直 (綠) 且變異次大

③ 投影降維

把所有點投影到 PC1 上，二維變一維，仍保留 95.9% 的變異


關鍵

PCA 不是「刪掉欄位」，而是「換一組座標軸」，再丟掉變異小的那些軸

PCA 手算：從共變異數矩陣到解釋變異

計算流程

步驟	計算內容
① 置中	每個特徵減去自己的平均
② 共變異數矩陣	[[0.688, 0.651], [0.651, 0.731]]
③ 求特徵值	$\lambda_1 = 1.361$ $\lambda_2 = 0.058$
④ 求特徵向量	PC1 = (0.696, 0.719) PC2 = (-0.719, 0.696)
⑤ 投影	原始資料 × PC1 方向 = PC1 分數



解釋變異比例

量	值	意義
λ_1	1.361	PC1 抓到的變異量
λ_2	0.058	PC2 抓到的變異量
PC1 解釋比例	95.9%	$1.361 \div (1.361+0.058)$
PC2 解釋比例	4.1%	
結論	4.1% → PC1	丟掉 4.1% 的資訊，維度減半

特徵值 λ 是什麼

該主成分方向上的變異量。越大代表這個方向承載越多資訊

特徵向量是什麼

主成分的方向。它是原始特徵的線性組合——這就是難以解釋的原因

解釋變異比例



$\lambda_i \div \sum \lambda$ 。第一主成分永遠最大，之後遞減

數值已驗算

以 8 筆二維資料實際計算，可用 AI Studio 的 PCA Operator 對照

【原講義 ML 3.4】 pp219–252

實例：要保留幾個主成分



左・陡坡圖 Scree Plot

每個主成分的解釋變異比例。找「陡降後趨平」的轉折點

右・累積解釋變異

80% / 90% 是常見教學門檻，不是標準答案；還要檢查重建誤差與下游任務表現

本例的答案

4 個主成分即達 86%，原本 10 個欄位減為 4 個

怎麼選

兩張圖一起看，再加上「後續要拿來做什麼」——只是要畫圖的話取 2 個就好



PCA 的三個限制與前提

限制	說明	怎麼辦
主成分難以解釋	PC1 是「 $0.7 \times \text{身高} + 0.72 \times \text{體重}$ 」，不是任何一個現實概念	要解釋時改用特徵選擇； 或看各特徵在 PC 上的載荷量
只抓線性關係	彎曲的結構 PCA 抓不到	改用 t-SNE、UMAP 等非線性方法
是否標準化取決於尺度	PCA 找的是「變異最大」的方向， 沒標準化時大尺度欄位會主導	不同單位或不希望大變異欄位主導時先 Standardize ；若原始變異大小有意義，可保留尺度。scikit-learn PCA 會置中但不自動縮放。

【AI Studio 範例】4. Case Studies/4.3.2 HR Churn/A2–A3 + scikit-learn PCA 官方文件 (2026/07 查證) 。

實例：PCA 與 t-SNE 的差別

同一份 3 維資料降到 2 維：兩種方法、兩種目的
PCA：線性投影
保留整體變異與距離結構
t-SNE：非線性
強調鄰近關係，群更分明



PCA

線性投影，最大化保留變異；計算快、結果穩定，但不保證所有全域距離都被保留

t-SNE

非線性嵌入，強調局部鄰近關係；視覺上常較分明，但不等於真的存在離散群

★ t-SNE 的三個陷阱



群間距離、大小與形狀通常不可直接解讀；perplexity 與初始化會改變圖，固定 random seed 才可重現

怎麼用

t-SNE 主要用於視覺化；不直接判定 K，不解讀 2D 全域距離。比較多組 perplexity / seed。

降維 + 分群：建模空間與顯示空間分開

實務常見組合：降維用來「看見」，分群用來「切開」
先 PCA 降到 2 維
(此時還沒有分群)
再對降維後的資料分群
並用同一張圖檢視結果



步驟一

先完成前處理；若要降噪或減少計算，可在訓練流程內用 PCA 建立「建模空間」

步驟二

在選定的建模空間分群；以內部指標、重抽樣穩定性與群組用途選 K

步驟三

另用 PCA / t-SNE 投影到 2D，沿用同一組群標籤上色，作為視覺診斷與溝通

注意

指標與穩定性應在建模空間計算；2D 投影可能扭曲距離，不能只靠圖判斷品質

PART 12

AI Studio 實作

Hands-on Labs

Customer Credit Risk 的六個流程涵蓋本模組全部技術。
請用 2026 版資料夾。

實作 1 | Customer Credit Risk 分群

【AI Studio 範例】 5. Clustering / 2026 版

開啟檔案

範例/ML (AI Studio)/M3. 非監督式與降維/

```
L CLUSTERING - Customer Credit Risk 2026/  
  | 6. Iris Clustering K-means.rmp ← 先跑這個  
  | 1 ... data preparation.rmp  
  | 2 ... view clusters.rmp  
  | 3 ... X-means .rmp  
  | 4 ... K-Means with PSO.rmp  
  L Segmentation_Clustering_CraftBeer  
    Consumers_FullProcess.rmp
```

資料/ML (AI Studio)/M3. 非監督式與降維/

CustomerCreditRiskData / Marketing_data

預期結果

- ▶ 未正規化時，分群幾乎由值域最大的欄位決定
- ▶ 手肘圖的轉折點常不明顯——這是正常的，要搭配其他判準
- ▶ X-Means 選出的 K 未必等於你選的，兩者都要能說出理由

操作步驟

- 1 先跑 6. Iris Clustering：資料小、結構清楚，建立直覺
- 2 開 1 data preparation：確認 Normalize 有沒有啟用，記下有哪些欄位被排除
- 3 ★ 停用 Normalize 跑一次、啟用再跑一次，比較兩組 centroid 表
- 4 開 2 view clusters：檢視散布圖與各群中心，試著為每一群命名
- 5 接 Cluster Distance Performance，把 k=2 到 6 各跑一次記錄指標
- 6 畫出手肘圖與 Davies-Bouldin 折線，決定你的 K
- 7 開 3 X-means：它會自動決定 K。與你手動選的一致嗎？不一致時誰有道理？
- 8 開 4 PSO 版本觀摩（進階，理解即可）

實作 2 | 降維與 PCA

【AI Studio 範例】 4.3.2 HR Churn / Challenge

開啟檔案

範例/ML (AI Studio)/M3. 非監督式與降維/

└ HR Churn 降維系列/

└ A2. SVD PCA and covariance for
dimensional reduction.rmp

└ A3. Weights by PCA for
dimensional reduction.rmp

└ A4. SVD and Grouping models.rmp

挑戰題 (進階) :

Challenge/5. Dimension Reduction/
Dimension Reduction Challenge.pdf
abalone-challenge.csv / Solution.docx

預期結果

- ▶ 解釋變異取決於資料；先看累積曲線
- ▶ Weights by PCA 保留欄名，通常較易解釋
- ▶ 降維後分群未必更好；比較指標與穩定性

操作步驟

- 1 開 A2，找到 PCA Operator，檢視它輸出的 Eigenvalues 與解釋變異比例
- 2 把「保留的主成分數」從 2 調到 5，觀察累積解釋變異的變化
- 3 畫出陡坡圖（把各主成分的變異比例做成表再繪圖）
- 4 門檻只是起點：比較 80% / 90%、Scree Plot 轉折與下游分群表現
- 5 開 A3：Weights by PCA 是「特徵選擇」而非「特徵萃取」——比較兩者差異
- 6 ★ 思考：哪一種在你的專題裡比較適合？（可解釋 vs 效果）
- 7 進階：對降維後的資料再跑一次 K-Means，與原始高維的分群結果比較

PART 13

Take-Home Assignment

作業一：顧客分群分析

本模組對應學期的正式作業一

第 9 週上課前繳交 | 佔學期成績 15%

作業規格

項目	要求
資料集	Mall Customer Segmentation Dataset (Kaggle · 200 筆) 。 亦可改用你貫穿主線的資料，但須為公開或模擬資料，且欄位數 ≥ 4 。
工具	Altair AI Studio 。流程需可正常執行並繳交 .rmp 檔。
形式	個人作業。PDF 報告 (含截圖) + .rmp 流程檔，壓縮為一個檔案上傳。
篇幅	報告本文 6–10 頁 (不含截圖附錄) 。
期限	第 9 週上課前上傳至學校 iClass 。逾期一週內以八折計分。

七個必做任務

任務	要求	對應章節
1 資料探索 EDA	以 Statistics 檢視型態、極值、缺失。繪製各數值欄位的分布圖，判斷是否有偏態或多峰（多峰是判斷群數的直觀線索）。	PART 2–3
2 前處理與類別編碼	移除 ID 欄位並說明理由。將類別欄位編碼並截圖前後型態。 ★ 思考題：Label Encoding 與 One-Hot 的距離意義有何不同？	PART 3
3 相關性檢查	產生 Correlation Matrix，找出 $ r $ 最高的一組並報告數值。說明是否移除及理由。	M1 PART 9
4 正規化對照實驗	★ 核心任務。實驗 A（未正規化）與實驗 B（Z-Score）各跑 K-Means（ $K=3$ ），記錄兩組的各群平均值與散布圖，說明為什麼正規化是必要的。	PART 3
5 決定最佳 K	以正規化後的資料， $K = 2$ 到 6 各跑一次，記錄 Davies-Bouldin 與 Silhouette。做成表格與折線圖，說明選定 K 的理由（量化指標 + 業務可解釋性）。	PART 5
6 視覺化與群組命名	繪製散布圖並以群組上色。計算每群在各特徵的平均，為每群命名（如「高收入低消費型」）並提出對應的行銷或照護策略。	PART 9
7 演算法比較	另跑一次階層式分群或 DBSCAN，與 K-Means 的結果比較。說明哪一個較適合這份資料，依據是什麼。	PART 6–8

四個必答思考題（寫入報告）

Q
1

為什麼正規化對距離型演算法是必要的？請用你實驗 A 與 B 的實際數字說明。

不要只寫「因為尺度不同」。要指出未正規化時是哪一個欄位主導了分群，以及群平均差了多少。

Q
2

你選定的 K 值，三個判準（手肘、Silhouette、業務）各指向什麼？不一致時你怎麼取捨？

三者指向不同是常態。重點是說明你為什麼相信其中一個。

Q
3

你為每一群取的名字，能對應到不同的行動嗎？如果兩群的行動一樣，代表什麼？

代表這兩群其實不需要分開——這是檢驗分群價值的最終標準。

Q
4

若這份資料多了 20 個欄位，你的流程要改哪些地方？

是否需要降維、先做特徵選擇或改用其他距離；要用穩定性與下游表現驗證

評分標準（共 100 分）

向度	配分	評分重點
EDA 與前處理	20	逐欄檢查完整；ID 欄位有移除並說明；編碼方式正確
正規化對照實驗	25	★ 兩組實驗都有做；有量化比較（群平均表）；結論說得出所以然
K 值決定	20	兩個指標都有算；有折線圖；選擇理由兼顧量化與業務
群組解讀與命名	20	每群都有名字；命名依據明確；有提出對應行動
演算法比較與報告品質	15	有跑第二種演算法；.rmp 可執行；結構清楚、誠實說明限制

加分（至多 +10）：以 PCA 降至 2D 後視覺化並比較；或用 X-Means 自動選 K 與手動結果對照；或對分群結果做穩定性檢驗（換 seed / 換子樣本）。

中英術語對照 | M3

(1 / 4)

中文	English	一句話說明
非監督式學習	Unsupervised Learning	沒有標籤，找資料本身的結構
分群	Clustering	把相似的個案分成幾群
降維	Dimensionality Reduction	把很多欄位壓成少數幾個
異常偵測	Anomaly / Outlier Detection	找出不像其他人的個案
K-Means 分群	K-Means Clustering	以中心點與距離反覆指派的分群法
中心點	Centroid	一群的平均位置，代表該群的「典型」
組內平方和	Inertia / Within-Cluster Sum of Squares, WCSS	各點到自己群中心距離平方的總和
手肘法	Elbow Method	以 Inertia 對 K 作圖，找下降趨緩的轉折
輪廓係數	Silhouette Coefficient	$(b-a)/\max(a,b)$ ，-1 到 +1，越大越好

中英術語對照 | M3

(2 / 4)

中文	English	一句話說明
Davies-Bouldin 指數	Davies-Bouldin Index	群內緊密度與群間分離度的比值，越小越好
X-Means	X-Means	自動嘗試不同 K 並選出最佳的 K-Means 變體
階層式分群	Hierarchical Clustering	逐步合併或分裂，產生巢狀結構
凝聚式	Agglomerative	由下而上，每點自成一群後反覆合併
分裂式	Divisive	由上而下，全部一群後反覆切開
樹狀圖	Dendrogram	呈現合併順序與距離的樹狀圖
單一連結	Single Linkage	以兩群間最短距離作為群距離
完全連結	Complete Linkage	以兩群間最長距離作為群距離
平均連結	Average Linkage	以所有配對距離的平均作為群距離

中英術語對照 | M3

(3 / 4)

中文	English	一句話說明
Ward 法	Ward's Method	以合併後組內變異增加最少為準則
DBSCAN	Density-Based Spatial Clustering (DBSCAN)	以密度定義群，可標出雜訊
核心點	Core Point	半徑內鄰居數達門檻的點
邊界點	Border Point	自身不夠密但落在核心點半徑內
雜訊點	Noise Point	不屬於任何群的點
局部離群因子	Local Outlier Factor, LOF	與鄰居相比的密度稀疏程度
孤立森林	Isolation Forest	以隨機切分的深度判斷異常
污染比例	Contamination	預期資料中異常所佔的比例
主成分分析	Principal Component Analysis, PCA	找變異最大的線性方向並投影降維

中英術語對照 | M3

(4 / 4)

中文	English	一句話說明
主成分	Principal Component	原始特徵的線性組合，彼此正交
特徵值	Eigenvalue	該主成分方向上的變異量
特徵向量	Eigenvector	主成分的方向
解釋變異比例	Explained Variance Ratio	各主成分佔總變異的比例
陡坡圖	Scree Plot	各主成分解釋變異的長條 / 折線圖
奇異值分解	Singular Value Decomposition, SVD	矩陣分解技術，PCA 的計算基礎之一
t-SNE	t-Distributed Stochastic Neighbor Embedding	強調局部鄰近關係的非線性嵌入，主要用於視覺化
維度詛咒	Curse of Dimensionality	維度高時距離常變得較難區分，距離型方法可能退化
群組剖析	Cluster Profiling	比較各群在各特徵上與整體平均的差異

本模組重點回顧

- 1 非監督式沒有標準答案——最終判準是「這些群組能不能幫你做決定」。
- 2 距離型方法通常需要處理尺度；StandardScaler 對離群值敏感，必要時比較 RobustScaler。
- 3 K-Means 是凸形、尺度相近群的基準；DBSCAN 適合密度相近的非凸形；階層式可看 Linkage 結構。
- 4 決定 K 要看手肘、Silhouette / DB、重抽樣穩定性與業務用途，並記錄取捨。
- 5 分群跑完只是一半——說不出每群是誰、該做什麼，就等於沒做。
- 6 PCA 保留主要變異但尺度選擇重要；t-SNE 主要用於視覺化，不能用 2D 距離直接下結論。

下一步 第 7 週 M4 進階監督式學習：集成、異常偵測與關聯規則