MODULE 3

# 非監督式學習：分群與降維

## M3 — Unsupervised Learning: Clustering & Dimensionality Reduction

沒有標準答案的學習。以原課程 ML 3.4 （326 頁）為本改寫：
分群、異常偵測、降維——問的不是「會怎樣」，而是「這裡面有什麼結構」。

資料科學　2027 Spring　·　第 6 週　·　Phase A　｜　謝楠楨

# 本講義大綱


01 非監督式學習 101 · 沒有標籤的世界

02 完整流程回顧 · 從問題理解到部署

03 前處理：為什麼縮放是必要的 · 距離型演算法的前提

04 K-Means · 手算兩輪＋逐步圖解

05 怎麼決定 K · 手肘法與 Silhouette

06 階層式分群 · 樹狀圖與連結方式

07 DBSCAN · 密度式分群與雜訊

08 三種演算法的形狀能力 · 同一資料三種結果

09 分群結果怎麼解讀 · 群組剖析與命名

10 異常偵測 · 三種取徑與 Isolation Forest

11 降維與 PCA · 幾何意義與解釋變異

12 t-SNE 與降維＋分群 · 看見高維資料

13 AI Studio 實作 · Customer Credit Risk

14 Take-Home Assignment · 作業一：顧客分群分析

# 學完這個單元，你要能做到

1. **說明為什麼分群前一定要縮放，並用自己的實驗數字佐證**
   對應： PART 03 · 縮放對照（第 12 頁） · 作業任務 4、思考題 1

2. **手算 K-Means，並用手肘、 Silhouette、業務三個判準決定 K**
   對應： PART 04–05 · 三個判準（第 24 頁） · 隨堂檢核 Q2、作業任務 5

3. **依資料形狀選 K-Means、階層式或 DBSCAN，並調 eps 與 min_samples**
   對應： PART 06–08 · 三種演算法全比較（第 37 頁） · 隨堂檢核 Q3

4. **為每一群命名並對應不同行動；兩群行動相同就該合併**
   對應： PART 09 · 解讀四步驟（第 40 頁） · 思考題 3

5. **用 Isolation Forest 找離群個案；用 PCA 降維並說明它的限制**
   對應： PART 10–11 · 異常偵測比較（第 47 頁）、 PCA 限制（第 55 頁） · 思考題 4

需要先會： M1 的縮放（第 57–62 頁）、 M0 的資料科學專案完整流程（第 58 頁）。

PART 01

# 非監督式學習 101

## Unsupervised Learning Basics

監督式問「這一筆會怎樣」，非監督式問「這一堆裡面有什麼結構」。
沒有答案可以對，所以評估方式完全不同。

# 監督式 vs 非監督式

| 比較項目 | 監督式 Supervised | 非監督式 Unsupervised |
| --- | --- | --- |
| **資料長相** | 每筆有標籤 y （會不會再入院） | 只有特徵 x，沒有 y |
| **在學什麼** | 輸入到答案的對應關係 | 資料本身的結構與關係 |
| **怎麼知道對不對** | 跟正確答案比對（Accuracy、AUC） | 沒有正確答案；<br>看指標＋業務可解釋性 |
| **典型任務** | 分類、迴歸 | 分群、降維、異常偵測、關聯規則 |
| **結果的性質** | 可驗證：預測對或錯 | 可討論：這樣分有沒有道理 |
| **本課程** | M2 （W4–W5） | M3 （W6）、M4 的異常偵測與關聯規則 |

【原講義 ML 3.4】 pp8–15。關鍵差異：非監督式沒有「標準答案」，所以最終判準一定包含人的專業判斷——這在醫療場域反而是優勢。

# 實例：分群沒有標準答案

左・你拿到的資料



同一份資料，180 筆

中・K = 2



切成 2 群

右・K = 3



切成 3 群

× 紅色 × = 各群中心（Centroid）

三張圖的資料完全相同。K=2 與 K=3 都是演算法「正確」的輸出——選哪一個是你的判斷。

**左・你拿到的資料**

全部同色。沒有人告訴你有幾群、誰屬於哪一群

**中・K=2**

硬把資料切成兩塊。演算法照做，不會抱怨

**右・K=3**

看起來比較貼近資料的自然結構

**哪一個對**

演算法本身無法回答。要靠指標（Silhouette）＋你的領域判斷

圖：課程自製（模擬資料，180 筆）　★ 原生圖形，可直接在 PowerPoint 編輯

# 非監督式學習的四大應用

| 應用 | 在做什麼 | 健康照護的例子 | 本課程 |
|---|---|---|---|
| **分群 Clustering** | 把相似的個案分成幾群 | 病人分型、照護路徑設計、社區族群分層 | M3 主軸 |
| **降維 Dimensionality Reduction** | 把很多欄位壓成少數幾個 | 問卷量表降維、高維檢驗值視覺化 | M3 主軸 |
| **異常偵測 Anomaly Detection** | 找出「不像其他人」的個案 | 生理訊號異常、異常申報偵測 | M3 概念＋ M4 實作 |
| **關聯規則 Association Rules** | 找出「常一起出現」的組合 | 共病組合、用藥組合分析 | M4 |

【原講義 ML 3.4】 p14。原講義另含推薦系統（pp293–318），本課程不列入正式範圍——有興趣可參考 4. Case Studies/Product Recommendation/。

PART 02

# 完整流程回顧

## The Full Workflow

在進入分群之前，先把整個資料科學流程完整看過一次。
這張圖適用於本課程所有模組——包含監督式與非監督式。

# 複習：資料科學專案的完整流程（詳見 M0 第 58 頁）

## 切分點在哪

- ①–③ 問題理解、資料蒐集、清理可以先做
- ④ 先切分，再動資料：補值、縮放、特徵選擇只用訓練集擬合
- EDA 與特徵工程只看訓練集

## 後段與部署

- 建模 → 評估 → 調校 → 溝通 → 部署 → 監控
- 多數專案死在最後兩步
- 非監督式的差別見下一頁

## 實務上一定會回頭

- 評估不如預期，回去改特徵
- 監控發現飄移，回去收資料
- 流程是迴圈，不是一條直線

# 非監督式的流程差在哪

## 與監督式相同的部分

- 問題理解：一樣要先問「誰要用、拿來做什麼」
- 資料蒐集與清理：遺失值、離群值、一致性照樣要處理
- EDA：分布與相關性照樣要看
- 特徵工程：衍生、編碼、分箱照樣要做
- 溝通與部署：一樣要能講給使用者聽

## 非監督式獨有的差異

- 沒有標籤 → 沒有「訓練 / 測試」的必要切分
- 但仍需檢驗穩定性：換隨機種子、換子樣本，群組會不會大變?
- 縮放從「可選」變成「必要」——距離是核心運算
- 評估沒有 Accuracy，改用 Silhouette、Davies-Bouldin ＋ 業務判斷
- 「調校」調的是 K 值、距離定義、要納入哪些特徵

【原講義 ML 3.4】 pp16–17。原講義的提醒：非監督式的最終判準是「這些群組能不能幫你解決問題」，而不是任何單一數字。

PART 03

# 前處理：縮放是必要的

## Scaling Is Not Optional

監督式學習中，縮放是「看演算法而定」。

非監督式學習中，多數技術靠距離運作——不縮放等於白做。

# 複習：縮放對分群的影響（詳見 M1 第 59–60 頁）

## 不縮放會怎樣

- 收入差 50、年齡差 5，收入對距離的貢獻是年齡的 100 倍
- 兩軸畫成同刻度，年齡的變化幅度被壓扁

## 分群結果差多少

- 同一份三群資料，未縮放純度 77%，切線全是垂直的，只依收入分
- Z-Score 後純度 98%，三個真實群組被還原

## 對你的作業

- 作業一任務 4：在 Mall Customer 資料上親手跑出這組對照
- 受影響的演算法： K-Means、階層式、 DBSCAN、 PCA、 k-NN

# 分群前的三個前處理決策

## ① 哪些欄位要納入

- ID 類欄位一律移除——它只會引入雜訊（作業一任務 2 的 CustomerID）
- 與分群目的無關的欄位也應移除。放越多不代表分得越好
- 高度相關的欄位（|r|>0.8）會讓同一資訊被重複加權，考慮擇一或先做 PCA

## ② 類別欄位怎麼處理

- K-Means 只吃數值。類別必須先編碼（M1 學過的 Nominal to Numerical）
- 二元類別（性別）用 0/1 即可；多類別用 One-Hot，但會拉高維度
- 混合型態可設 measure types = MixedMeasures； k-Modes、 Gower 需外掛或 Python

## ③ 用哪一種縮放

- Z-Score （標準化）：一般情況的預設；平均與標準差同樣會被離群值拉動
- Min-Max （正規化）：需要固定 0–1 範圍時，但離群值會壓縮其他所有點
- 有極端離群值時，先處理離群值再縮放——否則縮放本身就被扭曲了

【原講義 ML 3.4】 pp45–49 ＋【AI Studio 範例】 Module 6- Normalization & Detecting Outliers.rmp

PART 04

# K-Means 分群

## K-Means Clustering

最常用的分群演算法。

它只反覆做兩件事，而且兩件都很簡單。

# K-Means 的演算法

1

**選 K 個起始中心**

隨機挑 K 個點
或用 K-Means++

2

**指派**

每點歸給
最近的中心

3

**更新**

中心移到
該群的平均位置

4

**重複**

直到中心
不再移動

5

**收斂**

得到最終分群
與 K 個中心

【原講義 ML 3.4】 pp56–65 。 K-Means 保證會收斂，但不保證收斂到全域最優——起始中心不同，結果可能不同。這是為什麼要多跑幾次取最好的。

# 手算：六位病人、 K=2 、跑到收斂

### 第 1 輪的距離計算

| 點 | x | y | 到 C1 距離 | 到 C2 距離 | 歸屬 |
|---|---|---|---|---|---|
| A | 2.0 | 2.0 | 0.00 | 1.41 | 群 1 |
| B | 3.0 | 3.0 | 1.41 | 0.00 | 群 2 |
| C | 2.5 | 2.0 | 0.50 | 1.12 | 群 1 |
| D | 8.0 | 8.0 | 8.49 | 7.07 | 群 2 |
| E | 9.0 | 7.0 | 8.60 | 7.21 | 群 2 |
| F | 8.5 | 9.0 | 9.55 | 8.14 | 群 2 |

### 中心的移動軌跡

| 輪次 | C1 | C2 |
|---|---|---|
| 起始 | (2.0, 2.0) | (3.0, 3.0) |
| 第 1 輪後 | (2.25, 2.0) | (7.12, 6.75) |
| 第 2 輪後 | (2.5, 2.33) | (8.5, 8.0) |
| 第 3 輪後 | **(2.5, 2.33)** | **(8.5, 8.0)** |
| 結果 | A B C | D E F |

**起始中心刻意選得很差** — 兩個中心都在左下角，第 1 輪的分群是錯的（B 被分到群 2）

**第 2 輪就修正了** — 中心移動後， B 回到群 1 ， D E F 正確聚成群 2

**第 3 輪中心不動** — 收斂。這個例子只花三輪，實務上通常十幾輪

**距離公式** — 歐氏距離 $= \sqrt{(x_1-x_2)^2 + (y_1-y_2)^2}$ 。所有數字都已驗算

【原講義 ML 3.4】 pp57–65

# 實例： K-Means 逐步收斂的過程




第 1 輪把 B 分錯了；中心移動後第 2 輪就修正，第 3 輪不再變動 → 收斂。

**紅色 X = 中心**

看它每一輪往哪裡移動——移向該群所有點的平均位置

**第 1 輪**

起始中心都在左下，分群明顯不合理

**第 2 輪**

中心大幅移動後，分群已經正確

**第 3 輪**

中心不再變動 → 收斂。這就是演算法停止的條件

圖：課程自製（數據同前頁手算例）　★ 原生圖形，可直接在 PowerPoint 編輯

# K-Means 的優缺點與參數

| 面向 | 內容 |
| --- | --- |
| **優點** | 速度快、可擴展到大資料；概念直觀；結果（中心點）容易解讀成「典型個案」 |
| **缺點 1** | 必須事先指定 K—— 但你通常不知道有幾群 |
| **缺點 2** | 只擅長球狀、大小相近的群。彎月形、同心圓會完全失敗（本講義後面有實例） |
| **缺點 3** | 對離群值敏感——一個極端點會把中心整個拉走 |
| **缺點 4** | 結果依起始中心而變。務必跑多次（AI Studio 的 max runs 參數） |
| **AI Studio 參數** | k （群數）、 max runs （重跑次數）、 measure types （距離定義）、<br>max optimization steps （最大迭代） |

【AI Studio 範例】 5. Clustering/CLUSTERING - Customer Credit Risk 2026/ 的 1、 2、 6 號流程。

PART 05

# 怎麼決定 K

## Choosing K

這是分群最常被問的問題，而且沒有唯一正確答案。

但有三個可以依循的判準。

# Inertia （組內平方和）怎麼算

### 逐點計算

| 群 | 成員 | 中心 | 各點到中心距離² |
|---|---|---|---|
| 群 1 | A(2,2) | (2.5, 2.33) | 0.36 |
| | B(3,3) | | 0.69 |
| | C(2.5,2) | | 0.11 |
| 群 2 | D(8,8) | (8.5, 8.0) | 0.25 |
| | E(9,7) | | 1.25 |
| | F(8.5,9) | | 1.00 |

### 彙整

| 量 | 值 |
|---|---|
| 群 1 組內平方和 | 1.167 |
| 群 2 組內平方和 | 2.500 |
| Inertia 總和 | 3.667 |
| 別名 | WCSS<br>(Within-Cluster Sum of Squares) |
| 性質 | **K 越大一定越小<br>（K = n 時為 0）** |

**Inertia 在量什麼**

每個點離自己群中心有多遠。越小代表群內越緊密

**為什麼不能直接選最小的**

K 越大 Inertia 一定越小。K = 樣本數時每點自成一群，Inertia = 0，但毫無意義

**所以要看「轉折」**

下降速度突然趨緩的那個 K，就是手肘法要找的點

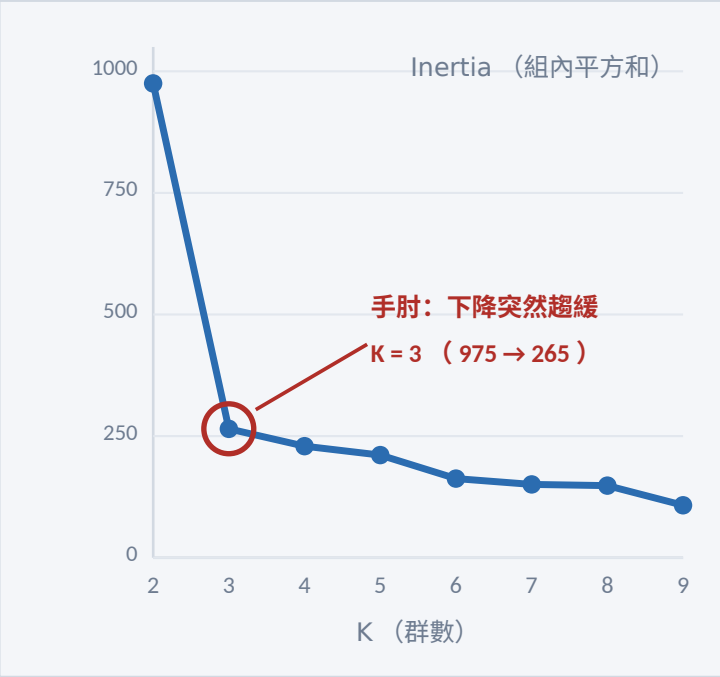
**AI Studio**

Cluster Distance Performance 輸出 Avg. within centroid distance （平均距離，非平方和；看趨勢可，數值不等於 Inertia ）

【原講義 ML 3.4】 pp76–79

# 實例：手肘法與 Silhouette

左・手肘法 Elbow Method




右・平均 Silhouette 係數




Inertia 越小越好，但 K 越大一定越小； Silhouette 越大越好，有明確極值。兩者都指向 K = 3 。

**左・手肘法 Elbow**

Inertia 隨 K 單調下降。找「下降突然變慢」的轉折點

**手肘的問題**

有時候彎得不明顯，三個人看會有三種答案——這是它的弱點

**右・ Silhouette**

有明確的最高點，判讀比手肘法客觀

**兩個都看**

兩者指向同一個 K 時最有信心；不一致時以業務可解釋性拍板

圖：課程自製（模擬資料，實際計算值） ★ 原生圖形，可直接在 PowerPoint 編輯

# Silhouette 係數：手算一個點

### 點 A 的兩個距離

| 點 | 所屬群 | a = 同群平均距離 | b = 最近他群平均距離 |
|---|---|---|---|
| A | 群 1 | 0.957 | 8.880 |

### 係數計算

| 步驟 | 計算 | 值 |
|---|---|---|
| 公式 | s = (b − a) / max(a, b) | |
| 代入 | (8.880 − 0.957) / 8.880 | |
| s(A) | | 0.892 |
| 判讀 | 接近 +1 → 分得很好 | |

**a 在量什麼**

這個點與「自己群其他成員」的平均距離。越小越好

**b 在量什麼**

這個點與「最近的另一群」全部成員的平均距離。越大越好

**整體 Silhouette**

把每個點的 s 算出來取平均，就是整個分群的分數

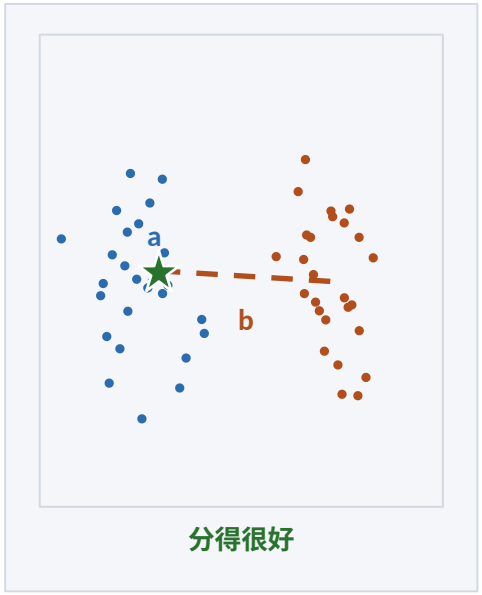
**範圍與判讀**

−1 到 +1。>0.7 強、0.5–0.7 合理、≤ 0.25 無明顯結構（Kaufman & Rousseeuw, 1990）

【原講義 ML 3.4】 pp171–173。AI Studio 內建指標沒有 Silhouette，可用 Execute Python （sklearn 的 silhouette_score）計算

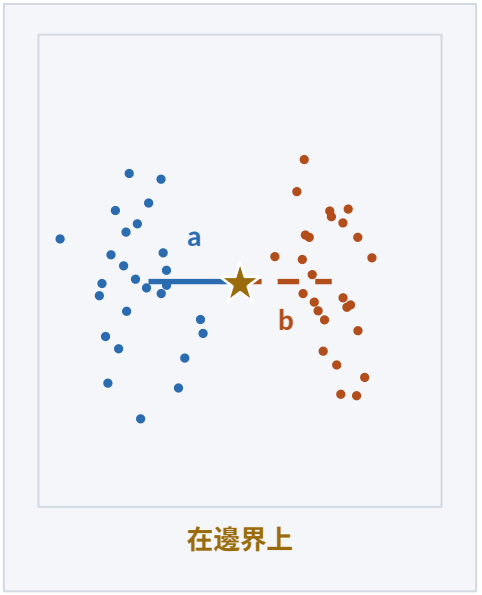
# 實例： Silhouette 的三種情況

左 · s ≈ +0.9



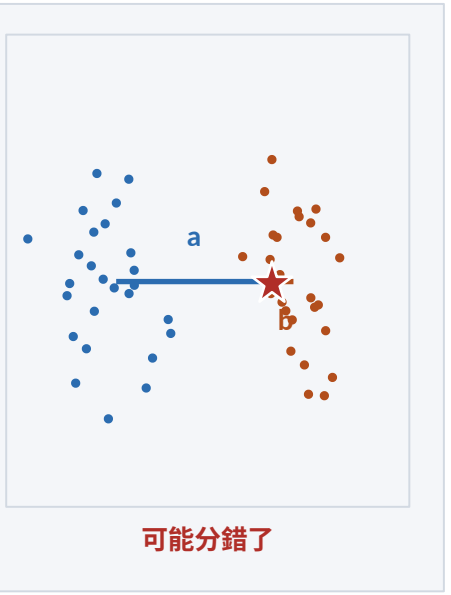

分得很好

中 · s ≈ +0.1




在邊界上

右 · s ≈ −0.4




可能分錯了

a ＝到自己群的平均距離

b ＝到最近他群的平均距離

$s = (b - a) / \max(a, b)$

s 的範圍是 −1 到 +1：越接近 +1 分得越好，接近 0 在邊界上，小於 0 很可能分錯群。

### 左 · s ≈ +0.9

星號點離自己群很近、離另一群很遠 → 分得很好

### 中 · s ≈ +0.1

在兩群邊界上， a 與 b 差不多 → 這個點分到哪群都可以

### 右 · s ≈ −0.4

離另一群反而更近 → 很可能被分錯了

### 實務用途

把 s 很低的個案挑出來單獨檢視——它們常是最有洞見的邊界案例

圖：課程自製 ★原生圖形，可直接在 PowerPoint 編輯

# 三個判準，缺一不可

| 判準 | 怎麼看 | 優點 | 限制 |
| --- | --- | --- | --- |
| **① 手肘法 Elbow** | Inertia 對 K 作圖，找轉折 | 直觀、計算快 | 轉折常不明顯，主觀 |
| **② Silhouette / Davies-Bouldin** | Silhouette 取最大；<br>Davies-Bouldin 取最小 | 有明確極值，較客觀 | 仍假設「群是緊密且分離的」 |
| **③ 業務可解釋性** | 每一群說得出「這是誰」嗎?<br>能對應到不同行動嗎? | ★ 最終判準 | 需要領域知識 |

【原講義 ML 3.4】 pp80–83。原講義的 PRO TIP：有時候精確的群組歸屬沒那麼重要，重要的是你能依此提出什麼可行動的建議。

PART 06

# 階層式分群

## Hierarchical Clustering

不必事先決定群數。

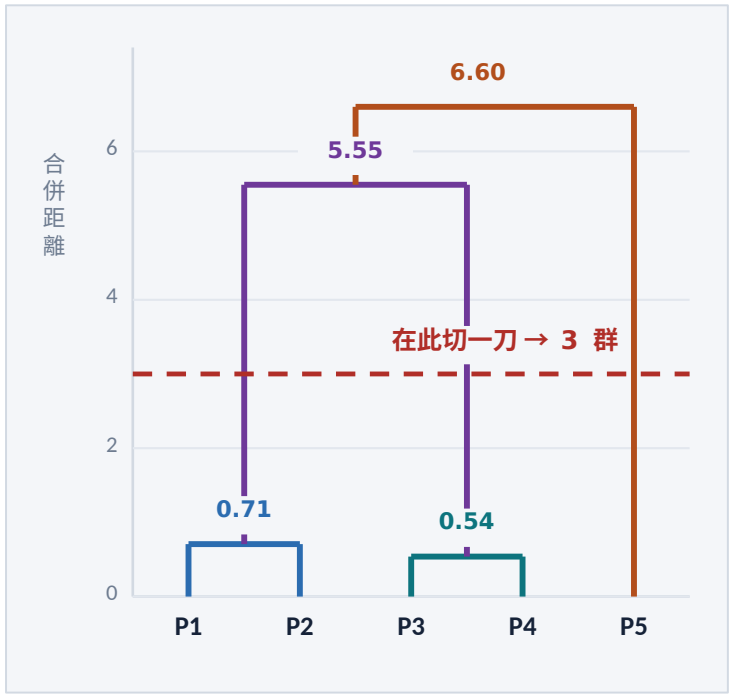
它把所有可能的群數一次算完，讓你事後再切。

# 實例：樹狀圖怎麼讀

左・五個資料點




右・樹狀圖 Dendrogram




第 2 步（0.71）到第 3 步（5.55）距離跳了 8 倍——那裡就是最自然的切點。

**左・五個點**

P1 與 P2 很近、P3 與 P4 很近、P5 孤零零在右下

**右・樹狀圖**

由下往上：先合併最近的一對（P3-P4，距離 0.54），再來 P1-P2 （0.71）

**縱軸的意義**

合併時兩群之間的距離。跳很高代表「硬把兩個不像的群併在一起」

**怎麼決定群數**

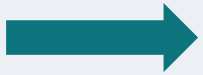
橫切一刀。切在距離 3.0 處會得到 3 群：{P1,P2}、{P3,P4}、{P5}

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# 合併順序：從距離矩陣看（平均連結）

**兩兩距離**

| 配對 | 距離 |
|---|---|
| P3–P4 | **0.539** |
| P1–P2 | **0.707** |
| P2–P3 | 4.950 |
| P4–P5 | 5.467 |
| P1–P3 | 5.657 |
| P1–P5 | 8.000 |



**凝聚式合併順序**

| 步驟 | 合併誰 | 距離 |
|---|---|---|
| 1 | P3 + P4 | 0.539 |
| 2 | P1 + P2 | 0.707 |
| 3 | {P1,P2} + {P3,P4} | 約 5.55 |
| 4 | 全部 + P5 | 約 6.60 |
| 觀察 | 第 3、4 步距離跳很大<br>→ 切在這之前較合理 | |

**凝聚式 Agglomerative** 由下而上：每個點自成一群，反覆合併最近的兩群。這是最常用的

**分裂式 Divisive** 由上而下：全部一群，反覆切開。計算量大，較少用

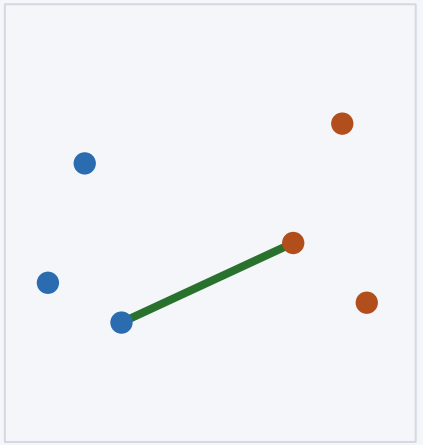
**距離跳躍是線索** 第 2 步（0.707）到第 3 步（5.55）跳了 8 倍——這裡就是自然的切點

**距離已驗算** 歐氏距離；群間距離採平均連結（若用單一連結，第 3 步為 4.95）

【原講義 ML 3.4】 pp85–91

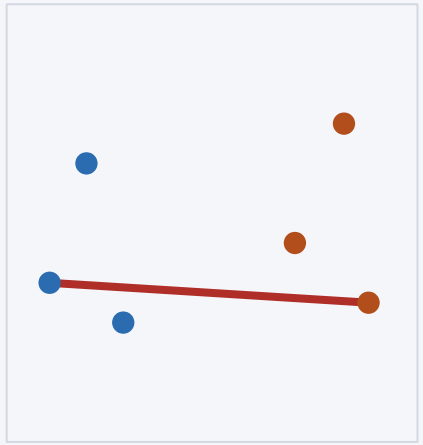
# 實例：三種連結方式

左・單一連結 Single



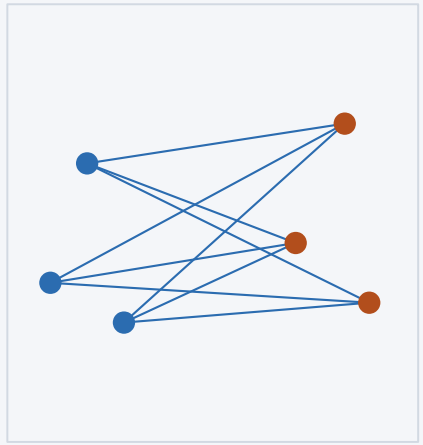
最短的一對　d = 2.83

中・完全連結 Complete



最長的一對　d = 5.20

右・平均連結 Average



九對的平均　d = 4.10

● 群 A（3 點）　● 群 B（3 點）　同一組點，三種「群間距離」的定義

連結方式決定「兩群有多遠」，換一種定義就會長出完全不同的樹。

## 單一連結 Single

取兩群之間「最短」的那一對距離。容易產生鏈狀的長條群

## 完全連結 Complete

取「最長」的那一對。傾向產生大小相近的緊密群

## 平均連結 Average

取所有配對的平均。★ 最常用的折衷選擇

## 還有 Ward 法

以「合併後組內變異增加最少」為準則，實務上效果常最好（AI Studio 無此選項，需 Python）

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# 階層式分群的優缺點

## 優點

- 不必事先指定群數——樹狀圖把所有可能一次呈現
- 樹狀圖本身就是很好的溝通工具，非技術人員看得懂
- 可以看出「群中還有子群」的巢狀結構
- 結果穩定：不像 K-Means 依賴隨機起始
- 適合：樣本數不大（幾百到幾千）、想探索結構時

## 缺點

- 計算量大：距離矩陣是 n×n，樣本上萬時吃不消
- 合併之後不能反悔——早期的錯誤會一路帶下去
- 對離群值敏感（單一連結尤其）
- 仍需要你決定「切在哪」
- AI Studio： Agglomerative Clustering （single ／ complete ／ average 三種連結）

PART 07

# DBSCAN 密度式分群

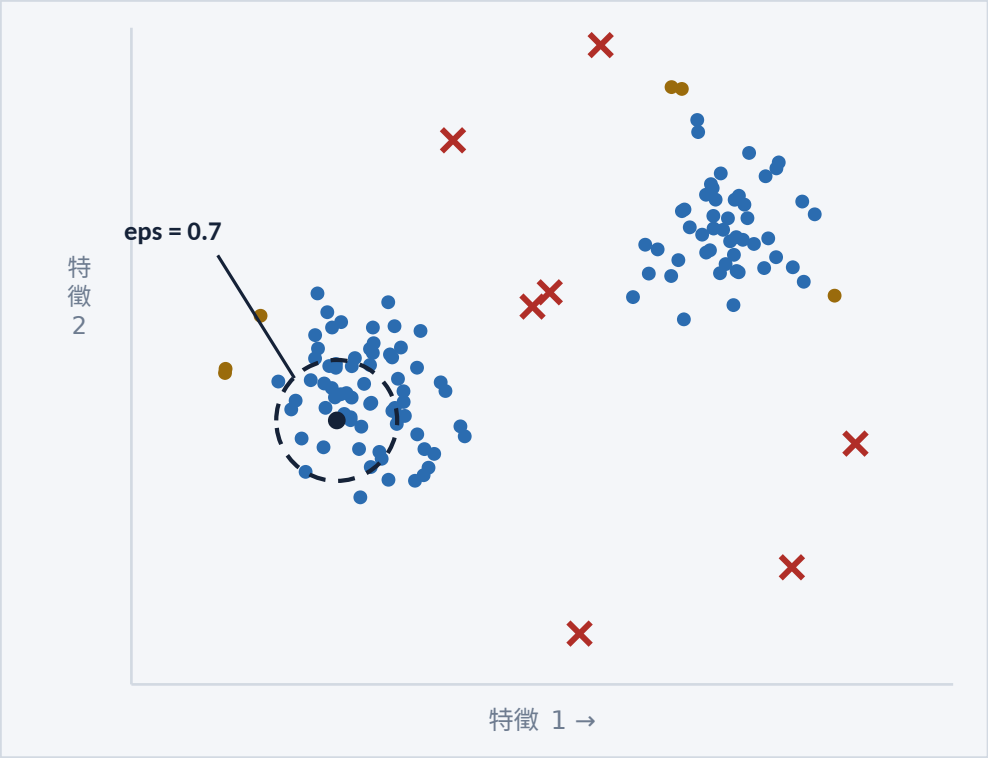
Density-Based Clustering

前兩種都假設「群是一團一團的」。

DBSCAN 改問：哪裡的點特別密集？

# 實例： DBSCAN 的三種點

**eps 半徑內的點夠多，就是核心點**




**● 核心點 Core**
半徑內 ⩾ 5 個點
本圖 119 點

**● 邊界點 Border**
落在核心點的半徑內
本圖 6 點

**✕ 雜訊點 Noise**
兩者皆非，不屬任何群
本圖 7 點

min_samples = 5

不必事先指定群數：密度夠的地方自己長成群，密度不夠的點被標成雜訊。

### 核心點 Core

以 eps 為半徑畫圓，圓內至少有 min_samples 個點

### 邊界點 Border

自己不夠密，但落在某個核心點的半徑內 → 併入該群

### 雜訊點 Noise

兩者皆非 → 不屬於任何群。★ 這是 DBSCAN 獨有的能力

### 兩個參數

eps （半徑）與 min_samples （最少點數）。這兩個決定一切

圖：課程自製 ★ 原生圖形，可直接在 PowerPoint 編輯

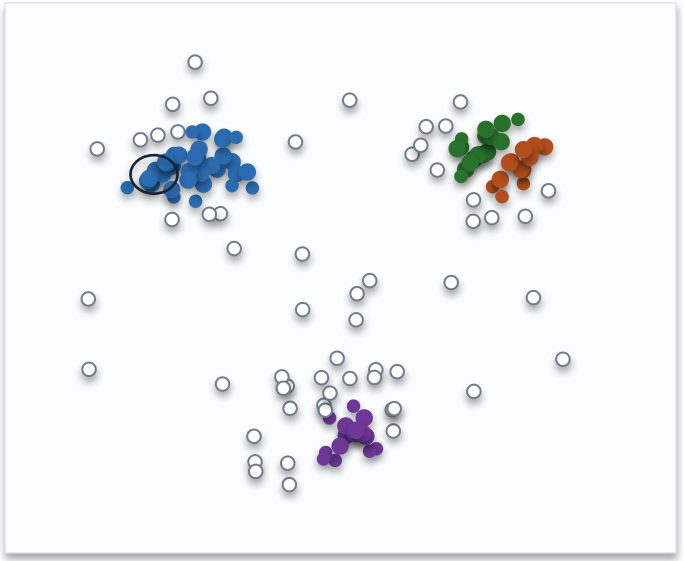
# DBSCAN 的兩個參數怎麼調

| 參數 | 意義 | 調大會 | 調小會 | 起手建議 |
|---|---|---|---|---|
| **epsilon（半徑）** | 多近算「鄰居」 | 群變少變大；<br>最後可能全部併成一群 | 群變多變碎；<br>雜訊點暴增 | 畫 k- 距離圖找轉折；<br>或從資料尺度的 1–5% 試 |
| **min points（最少點數）** | 多密才算核心 | 雜訊點變多；<br>只保留最密的核心 | 幾乎沒有雜訊；<br>容易把稀疏區也算成群 | 經驗值：維度數 × 2（Sander et al., 1998）；<br>二維資料常用 4–6 |

【原講義 ML 3.4】 pp111–168。實務提醒： DBSCAN 對參數很敏感，且高維時「密度」的概念會失效（維度詛咒）——超過十幾維時效果通常不好。

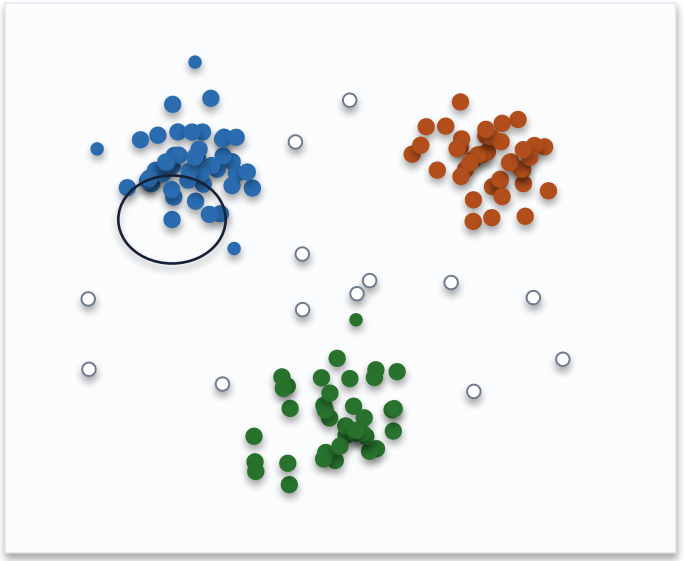
# 實例：同一份資料，eps 一變，群就變

**eps = 0.35**　（太小）



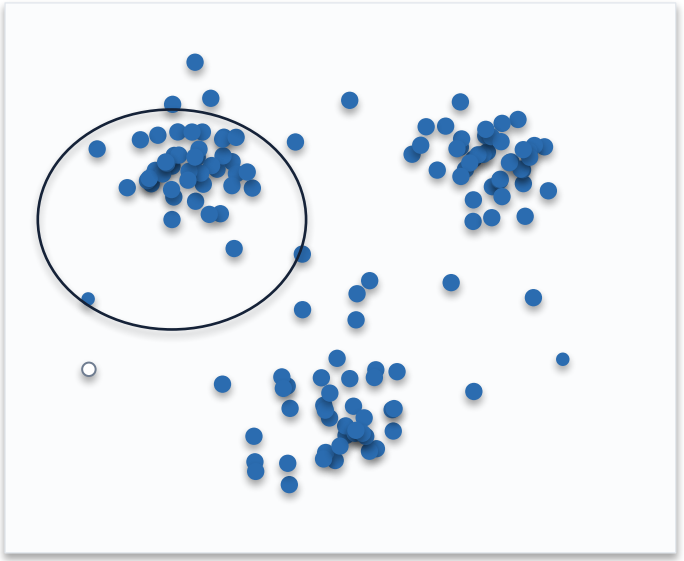
4 群、 57 個雜訊點——大部分點找不到夠多鄰居，被當成雜訊

**eps = 0.8**　（剛好）



3 群、 13 個雜訊點——三團被找出來，散落的點標為雜訊

**eps = 2.0**　（太大）



1 群、 1 個雜訊點——鄰居範圍太大，三團被併在一起

min_samples 固定為 5，只改 eps （虛線圓＝某個核心點的鄰居範圍）。起手方式：畫「每點到第 min_samples 個鄰居的距離」排序圖， eps 設在曲線急速上升的轉折處。（模擬資料 137 筆：三團＋ 12 個散點）

# DBSCAN 的三個獨特能力

### ① 不必事先指定群數

- 群數由資料的密度結構自己決定，這是它相對於 K-Means 最大的優勢
- 但代價是你改成要調 epsilon 與 min points—— 難度不見得比較低

### ② 能找出任意形狀的群

- K-Means 只會畫圓（球狀）， DBSCAN 可以順著密集區的形狀延伸
- 彎月形、環狀、不規則形狀都抓得到——下一頁有實例對照

### ③ 自動標出雜訊

- 不強迫每個點都歸屬某一群。稀疏區的點被標為雜訊（AI Studio 歸為 cluster_0，別誤讀成第一群； Python 為 −1）
- 這讓 DBSCAN 同時可以當作異常偵測工具使用（原講義 pp204–208）
- 對醫療資料特別有用：那些「不像任何一群」的個案往往最值得看

PART 08

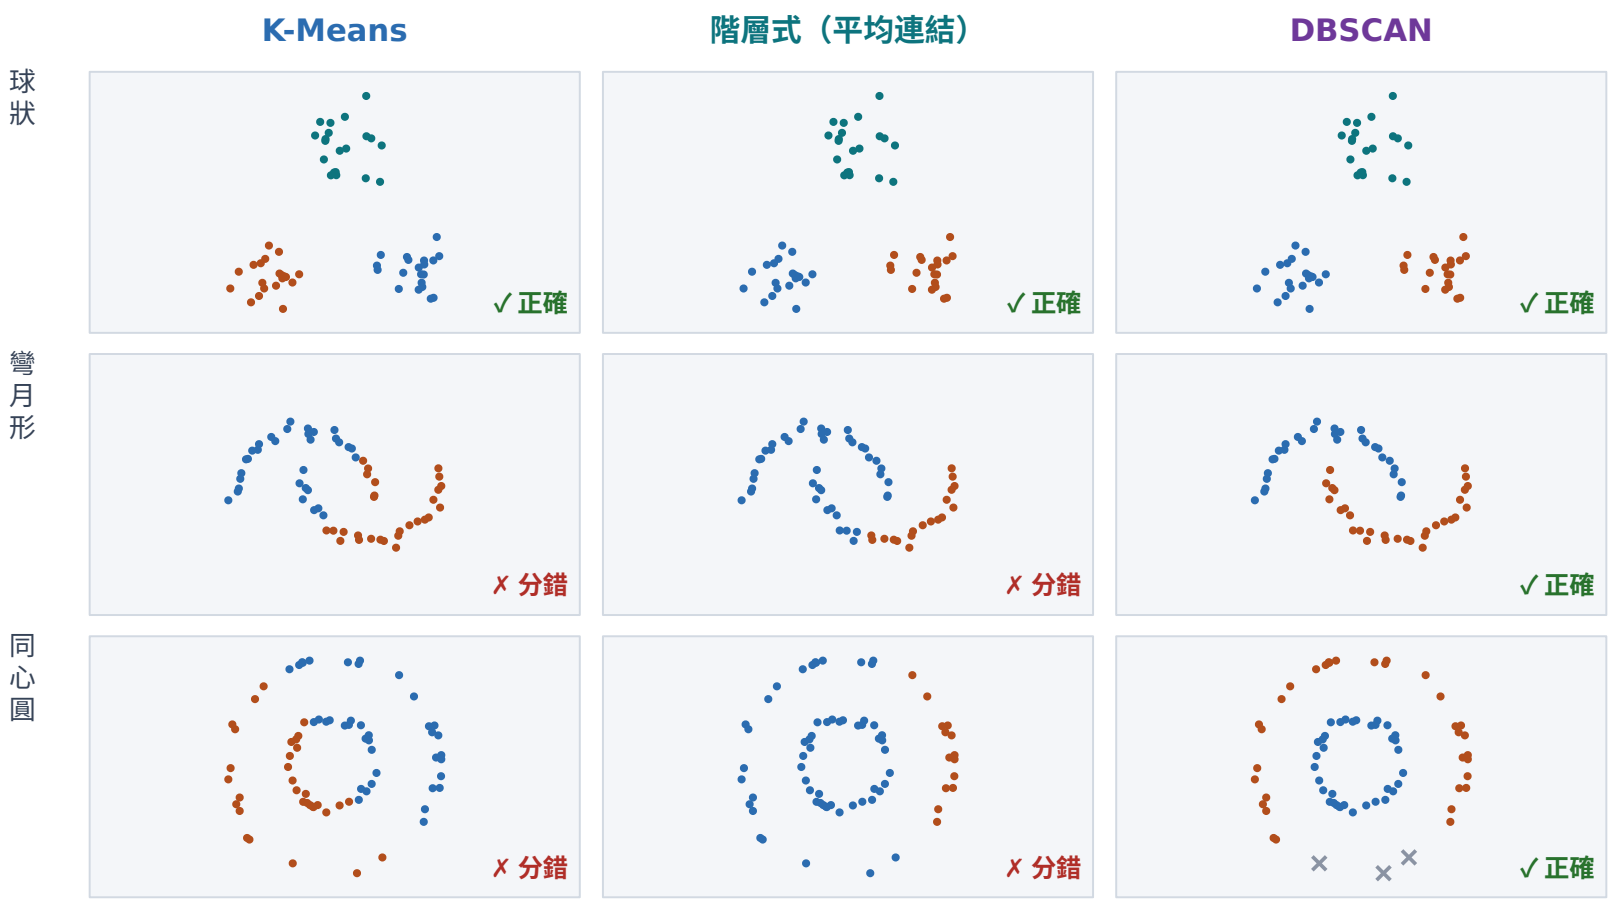
# 三種演算法的形狀能力

## Same Data, Different Results

同一份資料餵給三種演算法，結果可能天差地遠。

這一頁決定你該選哪一個。

# 實例：三種演算法 × 三種資料形狀




**第一列・球狀**

三者都做對了。這種情況下選最快的 K-Means 即可

**第二列・彎月形**

K-Means 與階層式從中間垂直切開（錯）；DBSCAN 正確分出兩彎

**第三列・同心圓**

K-Means 切成左右兩半（完全錯）；DBSCAN 正確分出內外環

**結論**

形狀決定演算法。先畫散布圖看資料長什麼樣，再決定用誰

圖：課程自製（DBSCAN 的 eps 已依各資料集調校）　★ 原生圖形，可直接在 PowerPoint 編輯

# 三種演算法全比較

| 面向 | K-Means | 階層式 | DBSCAN |
|---|---|---|---|
| **需要指定群數** | ★ 要 | 不用（事後切） | 不用 |
| **能抓的形狀** | 只有球狀 | 看連結方式，較彈性 | 任意形狀 |
| **雜訊處理** | 強制每點歸群 | 強制每點歸群 | ★ 自動標為雜訊 |
| **對離群值** | 敏感（拉走中心） | 敏感（尤其單一連結） | 穩健 |
| **計算量** | 低，可處理大資料 | 高（ n×n 距離矩陣） | 中等 |
| **結果穩定性** | 依起始中心而變 | 穩定 | 依參數而變 |
| **群大小差異大時** | 表現差（傾向切成等大） | 可以處理 | 可以處理 |
| **高維表現** | 尚可 | 尚可 | 差（密度失效） |
| **AI Studio** | k-Means / X-Means | Agglomerative Clustering | DBSCAN |

【原講義 ML 3.4】 pp175–176。實務建議：先跑 K-Means 建立基準（快），畫散布圖檢視結果；若形狀明顯不是球狀，再換 DBSCAN 或階層式。

PART 09

# 分群結果怎麼解讀

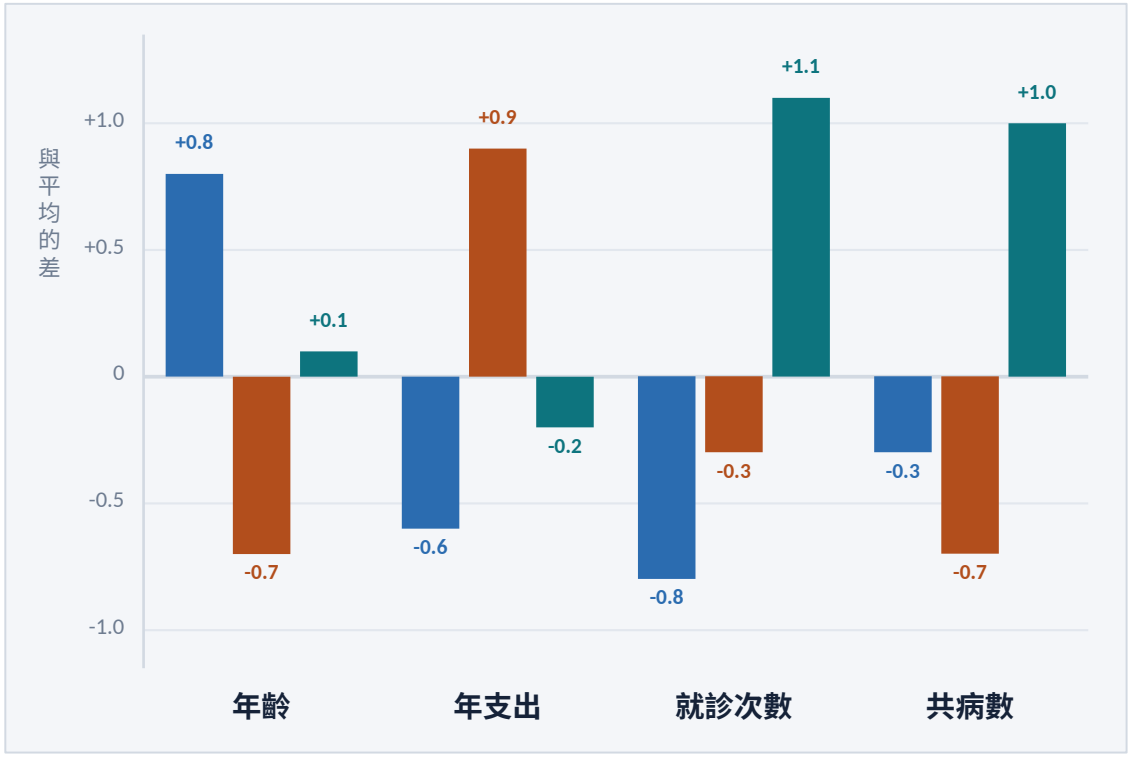
## Interpreting Clusters

跑出群組只是一半的工作。

說不出「每一群是誰」，這個分析就沒有價值。

# 實例：群組剖析圖

**各群在四個特徵上與整體平均的差（標準化後）**




**群 1（n = 57）**
年長、低支出

**群 2（n = 61）**
年輕、高支出

**群 3（n = 62）**
高就診、高共病

**命名 = 看哪幾根特別突出**

零線之上＝這一群在該特徵高於整體平均，之下＝低於平均。命名就是讀這張圖。

### 怎麼做

把每一群在各特徵上的平均，與「整體平均」相比，畫成長條圖

### 怎麼讀

往上＝該群在這個特徵上高於平均；往下＝低於平均

### 怎麼命名

看哪幾根特別突出。群 3 在就診次數與共病數都很高 → 高需求族群

### ★ 命名是分析的一部分

說不出每群是誰，就等於什麼都沒做出來

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# 分群結果的解讀四步驟

| 步驟 | 做什麼 | 產出 |
|---|---|---|
| ① **看群大小** | 每群各多少人？佔比多少？ | 極小的群（ <5% ）要判斷是真的次族群還是雜訊 |
| ② **做群組剖析** | 算每群在各特徵的平均，與整體平均比較 | 剖析圖或表格（本頁的圖） |
| ③ **為每群命名** | 用 2–6 個字描述這群的特徵 | 例：「高齡低支出型」「年輕高就診型」 |
| ④ **對應到行動** | 每一群該有什麼不同的處置？ | ★ 若兩群的處置一樣，那分成兩群就沒有意義 |

【原講義 ML 3.4】 pp70–71 、 82–83 。第 ④ 步是檢驗分群是否有價值的最終標準——這也是作業一任務 6 的要求。

# 實例：糖尿病其實有五型？——一個真實的 K-Means 研究

## 研究怎麼做（Ahlqvist et al., Lancet Diabetes Endocrinol 2018）

- 瑞典 ANDIS 世代 8,980 位新診斷的成人糖尿病人；只用 6 個常規變數：GAD 抗體、診斷年齡、BMI、HbA1c、β 細胞功能（HOMA2-B）、胰島素阻抗（HOMA2-IR）
- GAD 抗體陽性者自成一群，其餘的人以另外 5 個變數縮放後跑 K-Means；並在另外三個世代重跑，得到相似的群
- 五群：SAID 自體免疫 577 人、SIDD 胰島素不足 1,575、SIRD 胰島素阻抗 1,373、MOD 輕度肥胖 1,942、MARD 輕度年齡相關 3,513（最大群，約 39%）

## 命名之後，群才有臨床意義

- 同樣叫第 2 型：SIRD 的腎臟病變風險最高、SIDD 的視網膜病變風險最高——追蹤重點不同
- 名字是研究者看完群剖析（本 PART 的四步驟）後取的，演算法只給編號 0–4
- 在獨立世代重跑仍得到相似的群，這一步就是分群的「外部驗證」

## 後續的爭論：分群不等於發現了新疾病

- 後續分析發現，直接用診斷年齡、BMI 等連續變數預測，效果不輸甚至優於分群（Dennis et al., 同刊 2019）
- 群與群之間多是連續漸層而非斷點—— K-Means 一定給你 K 群，不管資料裡是否真的有
- 要改變治療指引，還得證明「依群治療」比現行做法好——分群是假設的起點，不是結論

# 實例：敗血症其實有四型？——分群改寫試驗判讀

## 研究｜Seymour et al., JAMA 2019（匹茲堡大學，NIH 支持）

- 12 家醫院、20,189 位符合 Sepsis-3 的病人；就診 6 小時內的 29 個變項；用 consensus k-means 分群
- 在第二組 43,086 人、前瞻世代與三個隨機試驗的資料中，看到相似的型態
- 四型：α 33%、β 27%、γ 27%、δ 13%

## 結果｜四型的長相與預後不同

- α：器官功能最好、升壓劑最少；β：年長、慢性病與腎功能不佳；γ：發炎與肺功能障礙；δ：肝功能不佳與休克
- 28 天死亡率（衍生世代）：α 5%、β 13%、γ 24%、δ 40%
- 和第 41 頁的糖尿病五型一樣：群由演算法切出，名字由人取

## 為什麼重要，與保留｜分群會改變試驗的解讀

- 模擬：同一種治療，只改變試驗中四型的比例，結果可從「超過 33% 機率有益」變成「超過 60% 機率有害」
- 作者結論保守：這是回顧性分析，分型能否指導治療，要靠前瞻研究
- 回到本課：分群好不好（第 20–24 頁）、怎麼解讀（第 39–40 頁）、能否重現，缺一不可

對本課的意義：分群的價值在於能不能改變決策；重現性與解讀，才是它從統計走進臨床的門檻。（資料：Seymour et al., JAMA 2019;321:2003–2017；HealthDay 2019/5/21；查核 2026/11）　連結：[1]

# 隨堂檢核 1 ｜分群

Q 1

### K-Means 跑兩次得到不同結果，是程式有問題嗎?

不是。起始中心隨機，結果本來就可能不同。解法：提高 max runs ，或固定 random seed 。

Q 2

### Silhouette 最高的 K 是 6，但你只能設計 3 種照護方案。怎麼辦?

選 3 。業務可解釋性是最終判準——分成 6 群卻只有 3 種處置，多出來的區分沒有意義。

Q 3

### DBSCAN 跑出來 80% 的點都是雜訊，哪裡出錯了?

eps 太小或 min_samples 太大。先畫 k- 距離圖找合適的 eps 。

Q 4

### 為什麼分群前一定要縮放，但決策樹不用?

分群靠「距離」，距離會被大尺度特徵主導；決策樹只比大小、不算距離。

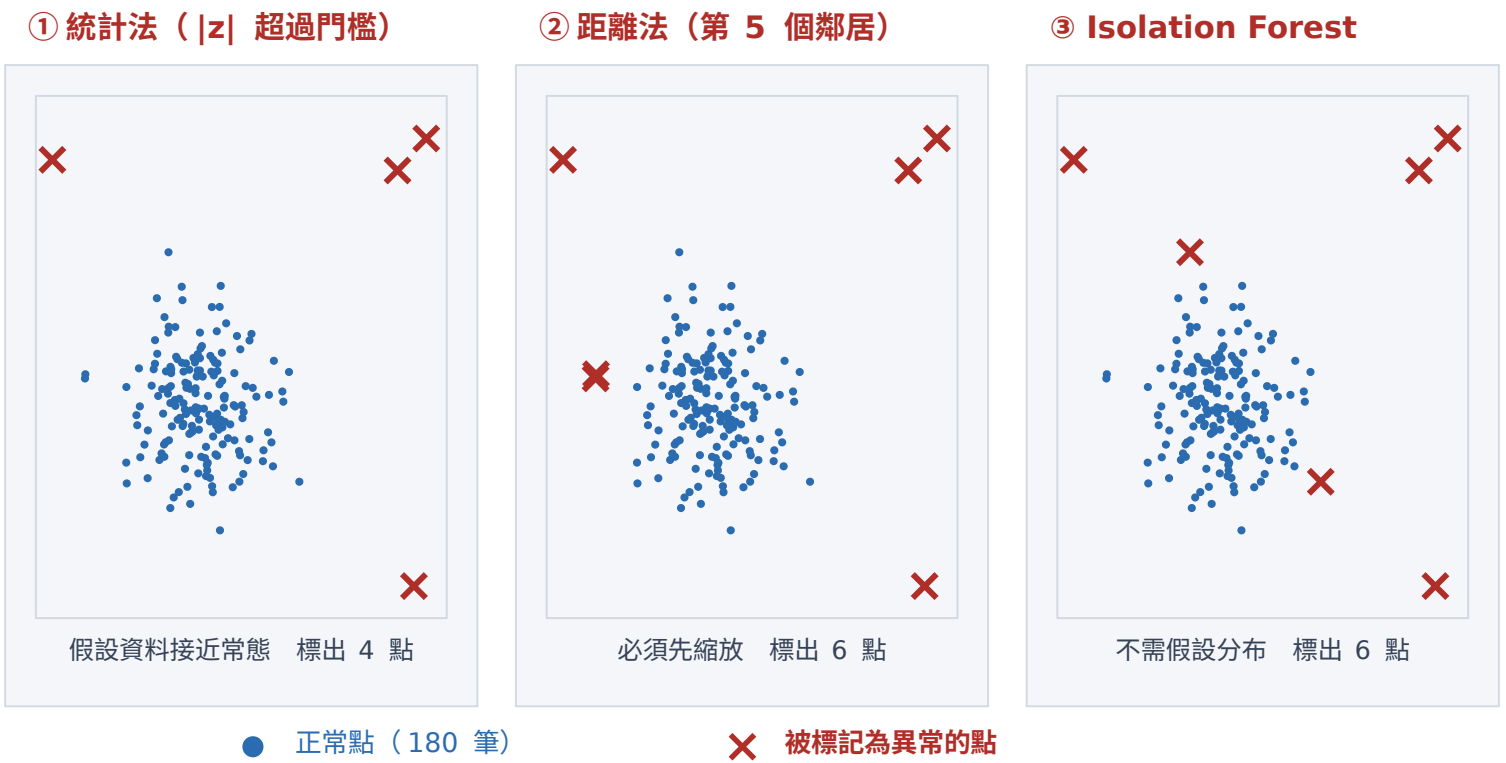
PART 10

# 異常偵測

## Anomaly Detection

換一個問法：不是「這些點怎麼分群」，
而是「哪些點不像其他人」。

# 實例：三種異常偵測取徑




四個真正的離群點三種方法都抓到了；邊緣地帶的點就各有各的看法——沒有標準答案。

### ① 統計法

偏離平均超過 3 個標準差。最簡單，但假設接近常態

### ② 距離法

第 k 個最近鄰居特別遠。需要先縮放，維度高時失效

### ③ Isolation Forest

隨機切幾刀就能孤立的點＝異常。不需假設分布，高維也能用

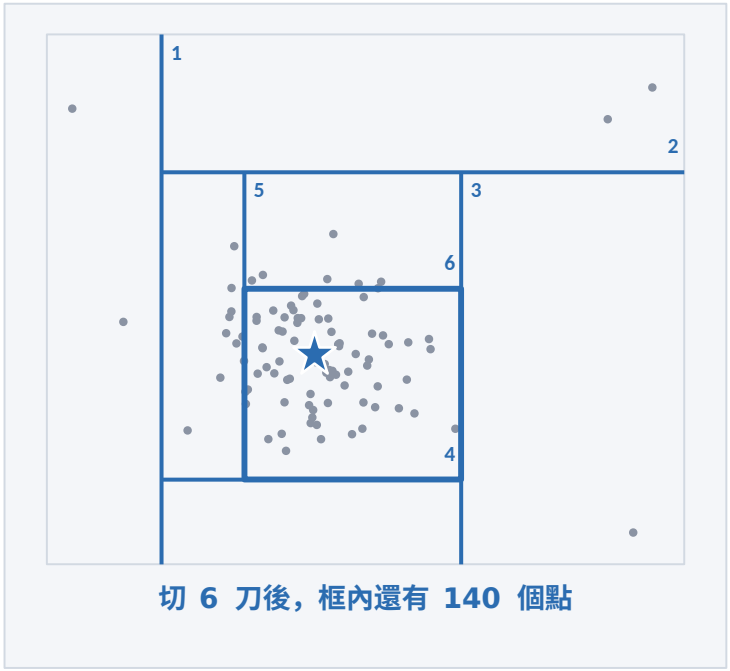
### 沒有標準答案

異常偵測沒有標籤可對。三種方法標出的點會部分重疊但不完全一致

圖：課程自製（模擬資料 184 筆）　★ 原生圖形，可直接在 PowerPoint 編輯

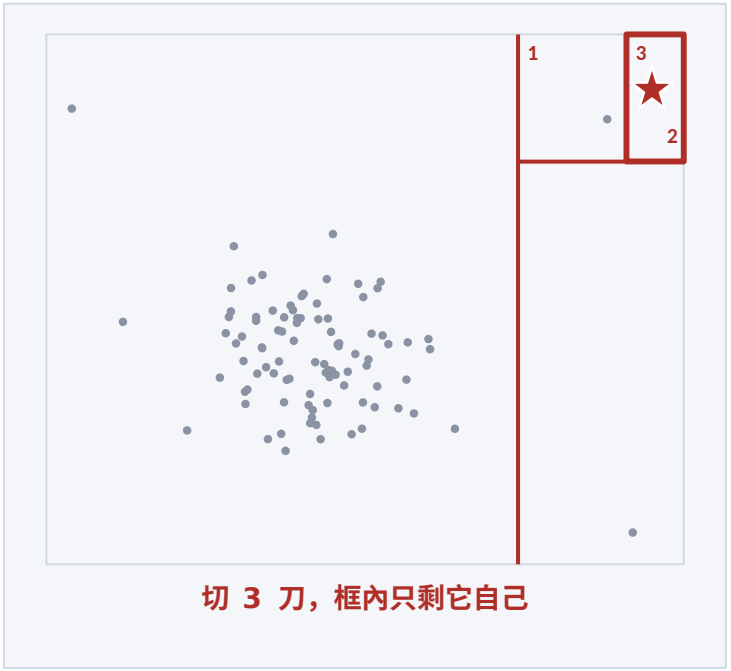
# 實例： Isolation Forest 的核心直覺

左・正常點：密集區




切 6 刀後，框內還有 140 個點

右・異常點：稀疏區




切 3 刀，框內只剩它自己

● 其他資料點　★ 被追蹤的點

細線＝隨機切的一刀，粗框＝目前還沒被切開的區域

平均要切幾刀才孤立得了——這個數字就是異常分數。刀數越少，越可能是異常。

**左・正常點**

位於密集區。要隨機切很多刀，才能把它單獨隔離出來

**右・異常點**

位於稀疏區。切兩三刀就孤立了

**演算法**

建很多棵隨機切分樹，記錄每個點平均被幾刀孤立

**為什麼好用**

不需要算距離、不需要假設分布，高維時仍有效——這是它勝過前兩種的地方

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

# 四種異常偵測方法比較

| 方法 | 判斷依據 | 優點 | 限制 |
| --- | --- | --- | --- |
| **統計法（Z-score / IQR）** | 偏離平均幾個標準差；<br>或落在四分位距外 | 極簡單、可解釋 | 假設近常態；<br>只看單一欄位 |
| **距離法（k-NN 距離）** | 第 k 個最近鄰居有多遠 | 直覺；可處理多維 | 必須先縮放；<br>維度高時失效 |
| **密度法（LOF / DBSCAN）** | 周圍密度比鄰居稀疏多少 | 能處理密度不均的資料 | 計算成本高；<br>參數敏感 |
| **Isolation Forest** | 隨機切幾刀能孤立 | 不需假設分布；<br>高維仍有效；速度快 | 結果依隨機性略有變動；<br>需設定污染比例 |

【原講義 ML 3.4】 pp183–208 ＋【AI Studio 範例】 3. Outlier and Ensemble/Anomaly Detection .rmp。 M4 第 7 週會實作鍋爐感測器異常偵測。

# 醫療場域的三個提醒

## 異常 ≠ 錯誤

- 被標記為異常的個案，可能是資料輸入錯誤，也可能是真正的重症病人
- 先問「生理上可能嗎」：血壓 0 是錯誤，血壓 210 是真實的高危個案
- M1 講過的原則在這裡再次適用：標記而非直接刪除

## 污染比例要自己設

- 多數演算法要你指定「預期有多少比例是異常」（contamination）
- 設 5% 就會標出 5% 的點，不管資料裡實際有幾個異常
- 所以這個數字要從領域知識來，不是隨便填

## 驗證需要領域專家

- 沒有標籤可以算 Accuracy。唯一的驗證是把標出的個案給專業人員看
- 實務做法：標出前 20 名最異常的個案，請臨床人員判斷有幾個是真的
- 這個「命中率」就是你能報告的最實在的指標

PART 11

# 降維與主成分分析

## Dimensionality Reduction & PCA

欄位太多會有三個問題：算得慢、畫不出來、而且距離會失去意義。
降維同時解決這三件事。

# 為什麼要降維

## 1 看得見

- 人類只能看懂 2–3 維的圖
- 50 個欄位的資料無法直接視覺化
- 降到 2 維才畫得出散布圖
- ★ 這是最常見的用途
- 配合分群使用效果最好
- 本講義後面有實例

## 2 算得動

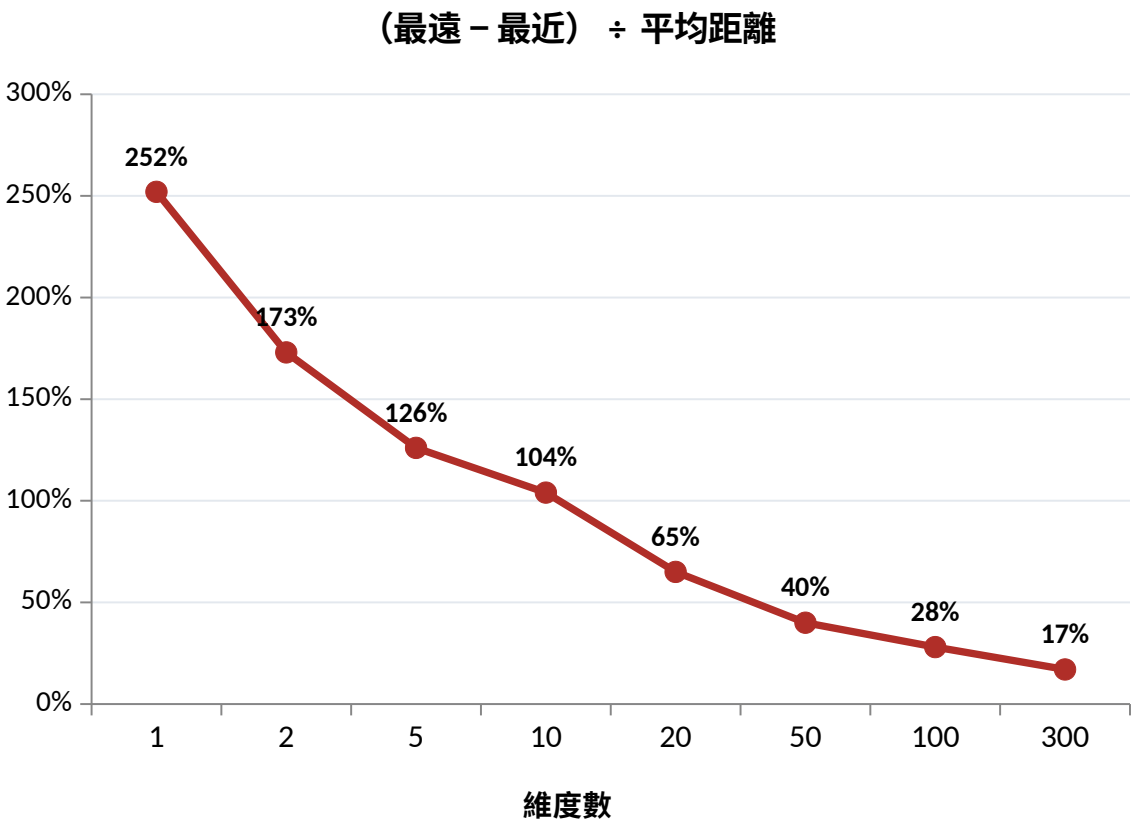
- 維度高時計算量急遽上升
- 距離計算、模型訓練都變慢
- 降維後速度可以快好幾倍
- 儲存空間也變小
- 對大資料特別有感
- 但現代硬體下這點沒以前重要

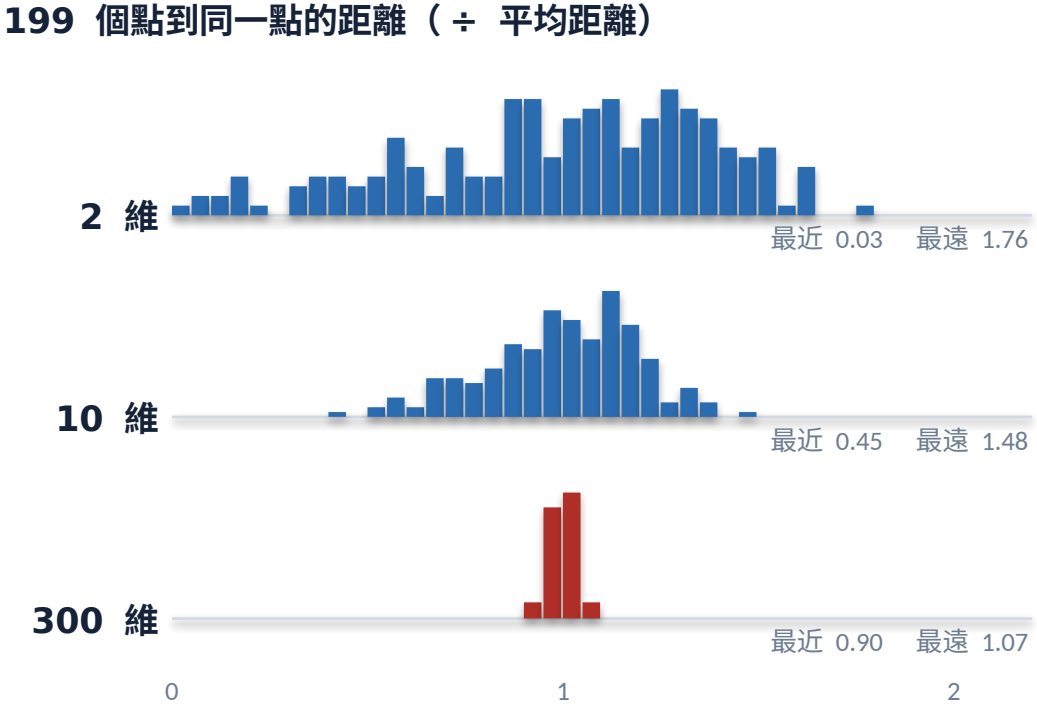
## 3 避開維度詛咒

- 維度越高，所有點的距離越接近
- → 距離失去鑑別力
- → k-NN 、分群、 DBSCAN 全失效
- 也會加重過擬合
- ★ 這是最根本的理由
- 特別影響本模組的所有技術

【原講義 ML 3.4】 pp214–218。降維與「特徵選擇」的差別：特徵選擇是「挑出原始欄位」（保留可解釋性）；降維是「造出新的組合欄位」（效果好但難解釋）。

# 實例：維度詛咒——維度越高，點和點越來越一樣遠



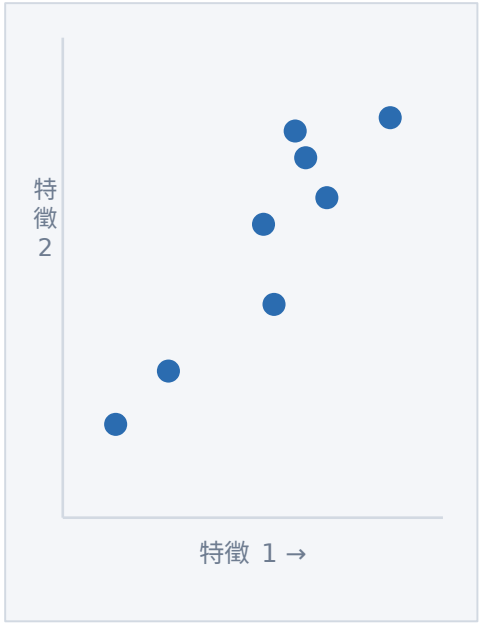




300 維時，所有距離都擠在平均值附近——「最近的鄰居」和「最遠的點」幾乎一樣遠。

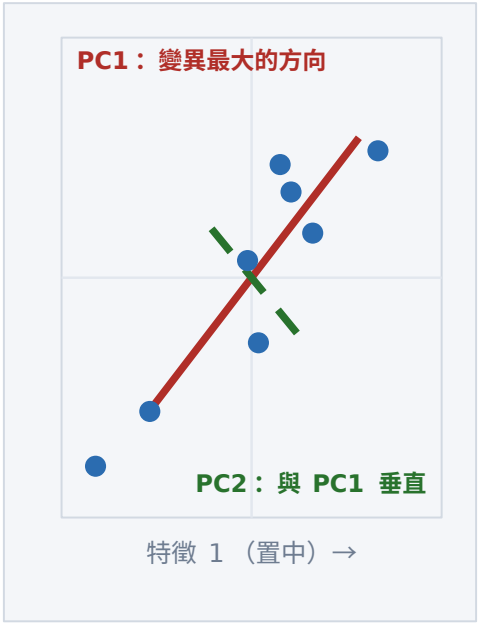
200 個均勻亂數點。維度從 2 升到 300，最遠與最近的差距從平均距離的 173% 掉到 17%。K-Means、k-NN、DBSCAN 都靠距離運作，欄位一多就失靈——所以要先降維或做特徵選擇（作業一思考題 Q4）。

# 實例： PCA 的三個步驟

① 原始資料（2 維）




② 置中後找主成分方向




③ 投影到 PC1 （1 維）




**$\lambda_1 = 1.361$　$\lambda_2 = 0.058$　→　PC1 解釋 95.9% 的變異，PC2 只剩 4.1%**

三步驟：置中 → 找最大變異方向 → 投影。座標軸換了，資訊幾乎沒有損失。

### ① 原始資料

兩個特徵高度相關，資料呈斜向分布

### ② 找主成分方向

PC1 = 變異最大的方向（紅）； PC2 與它垂直（綠）且變異次大

### ③ 投影降維

把所有點投影到 PC1 上，二維變一維，仍保留 95.9% 的變異

### 關鍵

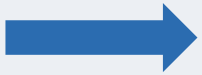
PCA 不是「刪掉欄位」，而是「換一組座標軸」，再丟掉變異小的那些軸

圖：課程自製（8 筆資料，數值為實際計算）　★ 原生圖形，可直接在 PowerPoint 編輯

# PCA 手算：從共變異數矩陣到解釋變異

## 計算流程

| 步驟 | 計算內容 |
|---|---|
| ① 置中 | 每個特徵減去自己的平均 |
| ② 共變異數矩陣 | [[0.688, 0.651], [0.651, 0.731]] |
| ③ 求特徵值 | $\lambda_1 = 1.361$　$\lambda_2 = 0.058$ |
| ④ 求特徵向量 | PC1 = (0.696, 0.719) |
| | PC2 = (−0.719, 0.696) |
| ⑤ 投影 | 原始資料 × PC1 方向 = PC1 分數 |



## 解釋變異比例

| 量 | 值 | 意義 |
|---|---|---|
| $\lambda_1$ | 1.361 | PC1 抓到的變異量 |
| $\lambda_2$ | 0.058 | PC2 抓到的變異量 |
| PC1 解釋比例 | **95.9%** | 1.361 ÷ (1.361+0.058) |
| PC2 解釋比例 | 4.1% | |
| 結論 | 保留 PC1 即可 | 丟掉 4.1% 的資訊，維度減半 |

**特徵值 λ 是什麼**　該主成分方向上的變異量。越大代表這個方向承載越多資訊

**特徵向量是什麼**　主成分的方向。它是原始特徵的線性組合——這就是難以解釋的原因

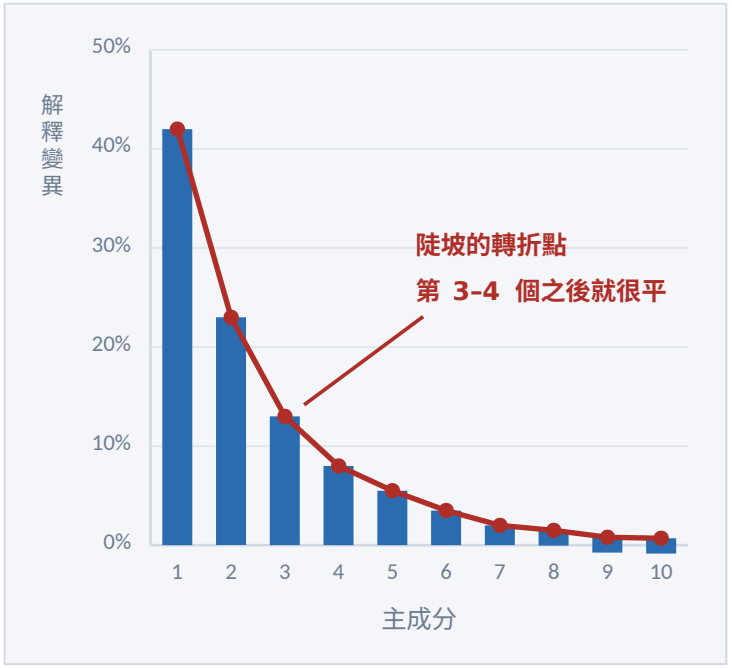
**解釋變異比例**　$\lambda_i \div \Sigma\lambda$。第一主成分永遠最大，之後遞減

**數值已驗算**　以 8 筆二維資料實際計算，可用 AI Studio 的 PCA Operator 對照

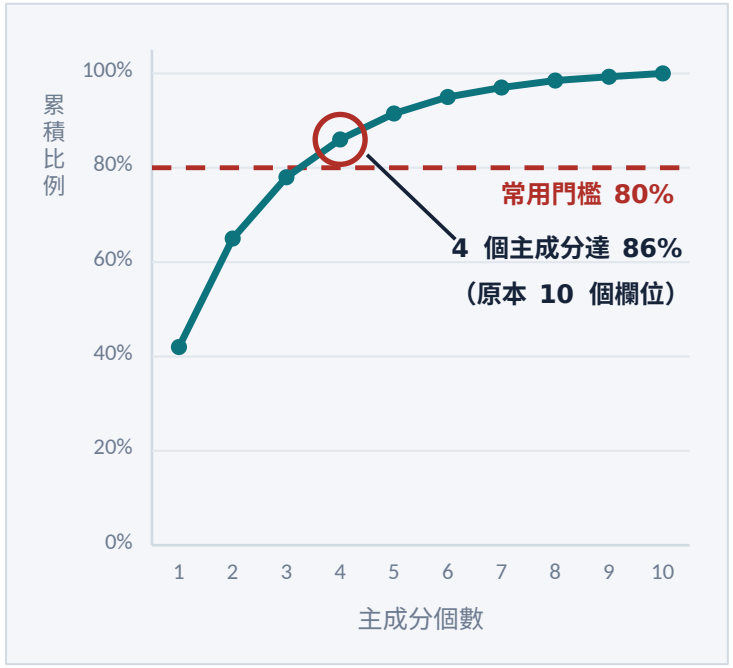
【原講義 ML 3.4】 pp219–252

# 實例：要保留幾個主成分

左・陡坡圖 Scree Plot




右・累積解釋變異




陡坡圖看「哪裡開始變平」，累積圖看「到幾個才夠」——兩張一起看才有把握。

### 左・陡坡圖 Scree Plot

每個主成分的解釋變異比例。找「陡降後趨平」的轉折點

### 右・累積解釋變異

常用門檻 80%（有些領域用 90%）

### 本例的答案

4 個主成分即達 86%，原本 10 個欄位減為 4 個

### 怎麼選

兩張圖一起看，再加上「後續要拿來做什麼」——只是要畫圖的話取 2 個就好

圖：課程自製（示意數值）　★ 原生圖形，可直接在 PowerPoint 編輯

# PCA 的三個限制

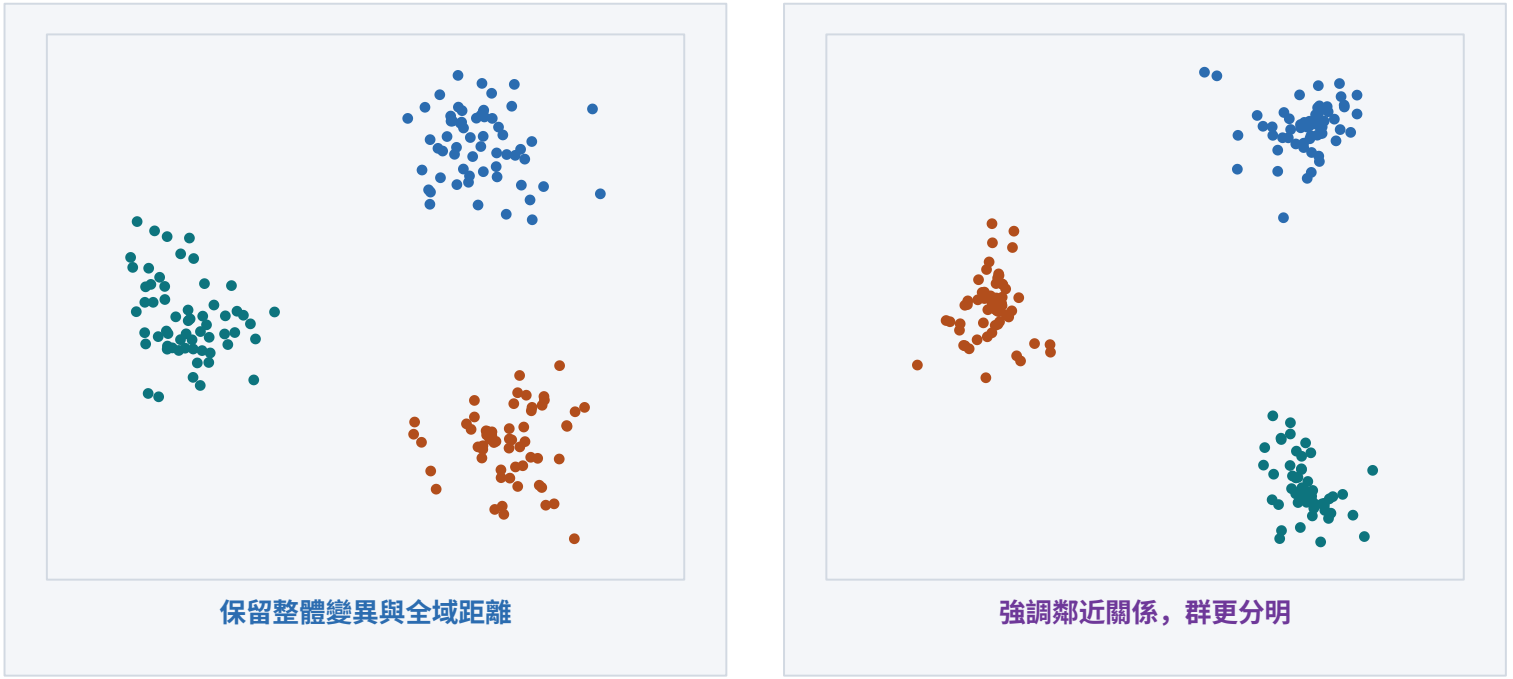
| 限制 | 說明 | 怎麼辦 |
| --- | --- | --- |
| **主成分難以解釋** | PC1 是「0.7× 身高 + 0.72× 體重」，不是任何一個現實概念 | 要解釋時改用特徵選擇；<br>或看各特徵在 PC 上的載荷量 |
| **只抓線性關係** | 彎曲的結構 PCA 抓不到 | 改用 t-SNE 、 UMAP 等非線性方法 |
| **必須先標準化** | PCA 找的是「變異最大」的方向，<br>沒標準化時大尺度欄位會主導 | ★ 一律先做 Z-Score 標準化 |

【AI Studio 範例】 4. Case Studies/4.3.2 HR Churn/A2. SVD PCA and covariance for dimensional reduction.rmp 與 A3. Weights by PCA

# 實例： PCA 與 t-SNE 的差別

左・ PCA： 線性投影

右・ t-SNE： 非線性




同一份 3 維資料降到 2 維： PCA 看得到群的相對位置， t-SNE 把每一群擠得更開。

## PCA

線性投影。保留整體變異與全域距離結構，計算快、結果穩定

## t-SNE

非線性。強調「鄰近關係」，群看起來更分明

## ★ t-SNE 的三個陷阱

群之間的距離、群的大小都沒有意義，且每次跑結果不同（ Wattenberg et al., 2016 ）

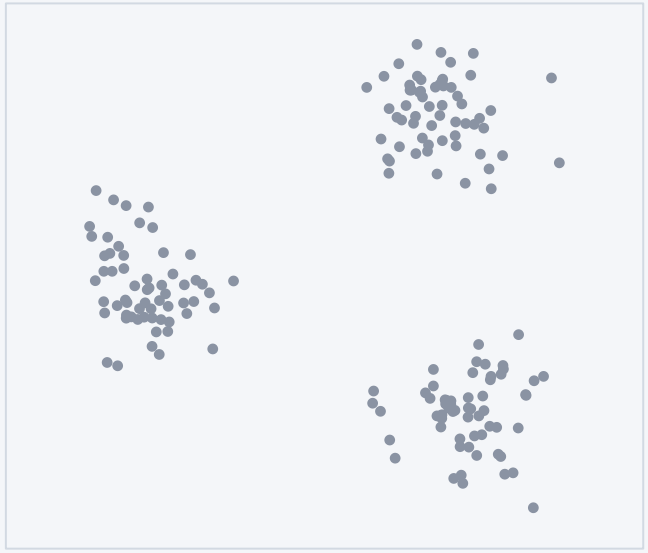
## 怎麼用

t-SNE 只適合「視覺化探索」，不要拿它的座標去做後續建模

圖：課程自製（同一份三維資料） ★ 原生圖形，可直接在 PowerPoint 編輯

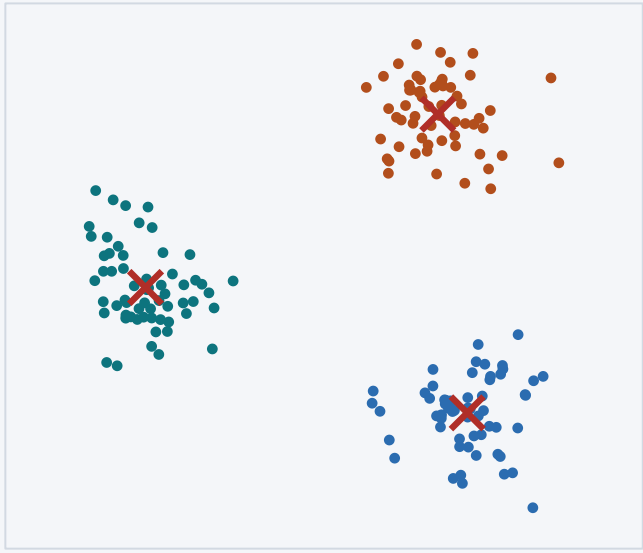
# 實例：降維 ＋ 分群的實務組合

左・先 PCA 降到 2 維（還沒分群）



先「看見」：肉眼判斷大概三群

右・在原始空間分群，用同一張圖上色



再「切開」： K-Means K = 3　× 為群中心

**同一張圖、同一批點：左邊只是換座標，右邊才是分群的結果**

降維是為了「看見」，分群才是「切開」——兩件事分開想，順序才不會搞混。

**步驟一**

先用 PCA 或 t-SNE 把高維資料降到 2 維，畫出來看

**步驟二**

肉眼判斷大概有幾群 → 作為選 K 的第三個線索

**步驟三**

跑分群，把結果用同一張降維圖上色檢視

**注意**

分群本身可在原始高維空間做（資訊較完整），降維只是為了「看見」

圖：課程自製　★ 原生圖形，可直接在 PowerPoint 編輯

PART 12

# AI Studio 實作

## Hands-on Labs

Customer Credit Risk 的六個流程涵蓋本模組全部技術。
請用 2026 版資料夾。

# 實作 1 ｜ Customer Credit Risk 分群

【AI Studio 範例】 5. Clustering / 2026 版

### 開啟檔案

```
範例 /ML (AI Studio)/M3. 非監督式與降維 /
└ CLUSTERING - Customer Credit Risk 2026/
  ├ 6. Iris Clustering K-means.rmp  ← 先跑這個
  ├ 1 ... data preparation.rmp
  ├ 2 ... view clusters.rmp
  ├ 3 ... X-means .rmp
  ├ 4 ... K-Means with PSO.rmp
  └ Segmentation_Clustering_CraftBeer
        Consumers_FullProcess.rmp

資料 /ML (AI Studio)/M3. 非監督式與降維 /
  CustomerCreditRiskData / Marketing_data
```

### 預期結果

- 未縮放時，分群幾乎由值域最大的欄位決定
- 手肘圖的轉折點常不明顯——這是正常的，要搭配其他判準
- X-Means 選出的 K 未必等於你選的，兩者都要能說出理由

### 操作步驟

1. 先跑 6. Iris Clustering： 資料小、結構清楚，建立直覺
2. 開 1 data preparation： 確認 Normalize 有沒有啟用，記下有哪些欄位被排除
3. ★ 停用 Normalize 跑一次、啟用再跑一次，比較兩組 centroid 表
4. 開 2 view clusters： 檢視散布圖與各群中心，試著為每一群命名
5. 接 Cluster Distance Performance，把 k=2 到 6 各跑一次記錄指標
6. 畫出手肘圖與 Davies-Bouldin 折線，決定你的 K
7. 開 3 X-means： 它會自動決定 K。與你手動選的一致嗎？不一致時誰有道理?
8. 開 4 PSO 版本觀摩（進階，理解即可）

# 實作 2 ｜降維與 PCA

【AI Studio 範例】 4.3.2 HR Churn ／ Challenge

**開啟檔案**

```
範例 /ML (AI Studio)/M3. 非監督式與降維 /
└ HR Churn 降維系列 /
  ├ A2. SVD PCA and covariance for
  │     dimensional reduction.rmp
  ├ A3. Weights by PCA for
  │     dimensional reduction.rmp
  └ A4. SVD and Grouping models.rmp

挑戰題（進階）：
Challenge 降維挑戰 /（同一資料夾）
  Dimension Reduction Challenge.pdf
  abalone-challenge.csv ／ Solution.docx
```

**預期結果**

- 前 2–3 個主成分通常就能解釋大部分變異
- Weights by PCA 保留原始欄位名稱，可解釋性高得多
- 降維後分群的結果未必更好——要實測才知道

**操作步驟**

1. 開 A2，找到 PCA Operator，檢視它輸出的 Eigenvalues 與解釋變異比例
2. 把「保留的主成分數」從 2 調到 5，觀察累積解釋變異的變化
3. 畫出陡坡圖（把各主成分的變異比例做成表再繪圖）
4. 決定你要保留幾個主成分，並寫下理由（門檻 80% 還是看轉折？）
5. 開 A3： Weights by PCA 是「特徵選擇」而非「特徵萃取」——比較兩者差異
6. ★ 思考：哪一種在你的專題裡比較適合？（可解釋 vs 效果）
7. 進階：對降維後的資料再跑一次 K-Means，與原始高維的分群結果比較

PART 13

# Take-Home Assignment

作業一：顧客分群分析

本模組對應學期的正式作業一

第 9 週上課前繳交 ｜ 佔學期成績 15%

# 作業規格

| 項目 | 要求 |
| --- | --- |
| **資料集** | Mall Customer Segmentation Dataset （Kaggle， 200 筆）。<br>亦可改用你貫穿主線的資料，但須為公開或模擬資料，且欄位數 ≥ 4 。 |
| **工具** | AI Studio （正式名稱 RapidMiner AI Studio，原 Altair AI Studio ）。流程需可正常執行並繳交 .rmp 檔。 |
| **形式** | 個人作業。 PDF 報告（含截圖） ＋ .rmp 流程檔，壓縮為一個檔案上傳。 |
| **篇幅** | 報告本文 6–10 頁（不含截圖附錄）。 |
| **期限** | 第 9 週上課前上傳至學校 iClass 。逾期一週內以八折計分。 |

# 七個必做任務

| 任務 | 要求 | 對應章節 |
|---|---|---|
| **1 資料探索 EDA** | 以 Statistics 檢視型態、極值、缺失。繪製各數值欄位的分布圖，<br>判斷是否有偏態或多峰（多峰是判斷群數的直觀線索）。 | PART 2–3 |
| **2 前處理與類別編碼** | 移除 ID 欄位並說明理由。將類別欄位編碼並截圖前後型態。<br>★ 思考題： Label Encoding 與 One-Hot 的距離意義有何不同? | PART 3 |
| **3 相關性檢查** | 產生 Correlation Matrix，找出 \|r\| 最高的一組並報告數值。<br>說明是否移除及理由。 | M1 PART 9 |
| **4 縮放對照實驗** | ★ 核心任務。實驗 A （未縮放）與實驗 B （ Z-Score ）各跑 K-Means （ K=3 ），<br>記錄兩組的各群平均值與散布圖，說明為什麼縮放是必要的。 | PART 3 |
| **5 決定最佳 K** | 以標準化後的資料， K = 2 到 6 各跑一次，記錄 Davies-Bouldin （必做）與 Silhouette （選做，用 Execute Python 計算）。<br>做成表格與折線圖，說明選定 K 的理由（量化指標＋業務可解釋性）。 | PART 5 |
| **6 視覺化與群組命名** | 繪製散布圖並以群組上色。計算每群在各特徵的平均，<br>為每群命名（如「高收入低消費型」）並提出對應的行銷或照護策略。 | PART 9 |
| **7 演算法比較** | 另跑一次階層式分群或 DBSCAN，與 K-Means 的結果比較。<br>說明哪一個較適合這份資料，依據是什麼。 | PART 6–8 |

# 作業一任務 5：決定 K 紀錄表

| K | Davies-Bouldin （越小越好） | Silhouette （越大越好） | Inertia | 這個 K 的群能命名成不同行動嗎? |
|---|---|---|---|---|
| K = 2 | | | | |
| K = 3 | | | | |
| K = 4 | | | | |
| K = 5 | | | | |
| K = 6 | | | | |

填完後各畫一條折線，標出 Davies-Bouldin 最低與 Silhouette 最高的 K。兩個指標不一致是常態——報告中說明你最後相信哪一個、為什麼。
Davies-Bouldin： Cluster Distance Performance 輸出； Silhouette： Execute Python （from sklearn.metrics import silhouette_score ）。

最終判準還要加上業務可解釋性：這幾群能不能各自對應到不同的策略。網站版可直接填寫，會自動畫折線、標出建議 K，並可下載 CSV。

# 四個必答思考題（寫入報告）

Q 1

**為什麼縮放對距離型演算法是必要的？請用你實驗 A 與 B 的實際數字說明。**

不要只寫「因為尺度不同」。要指出未縮放時是哪一個欄位主導了分群，以及群平均差了多少。

Q 2

**你選定的 K 值，三個判準（手肘、 Silhouette 、業務）各指向什麼？不一致時你怎麼取捨？**

三者指向不同是常態。重點是說明你為什麼相信其中一個。

Q 3

**你為每一群取的名字，能對應到不同的行動嗎？如果兩群的行動一樣，代表什麼？**

代表這兩群其實不需要分開——這是檢驗分群價值的最終標準。

Q 4

**若這份資料多了 20 個欄位，你的流程要改哪些地方？**

提示：維度詛咒、降維的必要性、以及演算法的選擇會不會改變。

# 評分標準（共 100 分）

| 向度 | 配分 | 評分重點 |
| --- | --- | --- |
| **EDA 與前處理** | 20 | 逐欄檢查完整； ID 欄位有移除並說明；編碼方式正確 |
| **縮放對照實驗** | 25 | ★ 兩組實驗都有做；有量化比較（群平均表）；結論說得出所以然 |
| **K 值決定** | 20 | Davies-Bouldin 有算（ Silhouette 選做）；有折線圖；選擇理由兼顧量化與業務 |
| **群組解讀與命名** | 20 | 每群都有名字；命名依據明確；有提出對應行動 |
| **演算法比較與報告品質** | 15 | 有跑第二種演算法； .rmp 可執行；結構清楚、誠實說明限制 |

加分（至多 +10 ）：以 PCA 降至 2D 後視覺化並比較；或用 X-Means 自動選 K 與手動結果對照；或對分群結果做穩定性檢驗（換 seed ／換子樣本）。

# 中英術語對照｜ M3

（1 / 4）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **非監督式學習** | Unsupervised Learning | 沒有標籤，找資料本身的結構 |
| **分群** | Clustering | 把相似的個案分成幾群 |
| **降維** | Dimensionality Reduction | 把很多欄位壓成少數幾個 |
| **異常偵測** | Anomaly / Outlier Detection | 找出不像其他人的個案 |
| **K-Means 分群** | K-Means Clustering | 以中心點與距離反覆指派的分群法 |
| **中心點** | Centroid | 一群的平均位置，代表該群的「典型」 |
| **組內平方和** | Inertia / Within-Cluster Sum of Squares, WCSS | 各點到自己群中心距離平方的總和 |
| **手肘法** | Elbow Method | 以 Inertia 對 K 作圖，找下降趨緩的轉折 |
| **輪廓係數** | Silhouette Coefficient | (b−a)/max(a,b)，−1 到 +1，越大越好 |

# 中英術語對照｜ M3

（2 / 4）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **Davies-Bouldin 指數** | Davies-Bouldin Index | 群內緊密度與群間分離度的比值，越小越好 |
| **X-Means** | X-Means | 自動嘗試不同 K 並選出最佳的 K-Means 變體 |
| **階層式分群** | Hierarchical Clustering | 逐步合併或分裂，產生巢狀結構 |
| **凝聚式** | Agglomerative | 由下而上，每點自成一群後反覆合併 |
| **分裂式** | Divisive | 由上而下，全部一群後反覆切開 |
| **樹狀圖** | Dendrogram | 呈現合併順序與距離的樹狀圖 |
| **單一連結** | Single Linkage | 以兩群間最短距離作為群距離 |
| **完全連結** | Complete Linkage | 以兩群間最長距離作為群距離 |
| **平均連結** | Average Linkage | 以所有配對距離的平均作為群距離 |

# 中英術語對照｜ M3

（3 / 4）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **Ward 法** | Ward's Method | 以合併後組內變異增加最少為準則 |
| **DBSCAN** | Density-Based Spatial Clustering (DBSCAN) | 以密度定義群，可標出雜訊 |
| **核心點** | Core Point | 半徑內鄰居數達門檻的點 |
| **邊界點** | Border Point | 自身不夠密但落在核心點半徑內 |
| **雜訊點** | Noise Point | 不屬於任何群的點 |
| **局部離群因子** | Local Outlier Factor, LOF | 與鄰居相比的密度稀疏程度 |
| **孤立森林** | Isolation Forest | 以隨機切分的深度判斷異常 |
| **污染比例** | Contamination | 預期資料中異常所佔的比例 |
| **主成分分析** | Principal Component Analysis, PCA | 找變異最大的線性方向並投影降維 |

# 中英術語對照｜ M3

（4 / 4）

| 中文 | English | 一句話說明 |
| --- | --- | --- |
| **主成分** | Principal Component | 原始特徵的線性組合，彼此正交 |
| **特徵值** | Eigenvalue | 該主成分方向上的變異量 |
| **特徵向量** | Eigenvector | 主成分的方向 |
| **解釋變異比例** | Explained Variance Ratio | 各主成分佔總變異的比例 |
| **陡坡圖** | Scree Plot | 各主成分解釋變異的長條／折線圖 |
| **奇異值分解** | Singular Value Decomposition, SVD | 矩陣分解技術， PCA 的計算基礎之一 |
| **t-SNE** | t-Distributed Stochastic Neighbor Embedding | 強調鄰近關係的非線性降維，僅供視覺化 |
| **維度詛咒** | Curse of Dimensionality | 維度高時距離失去鑑別力 |
| **群組剖析** | Cluster Profiling | 比較各群在各特徵上與整體平均的差異 |

# 本模組回顧：逐條自評

1. ☐ 說明為什麼分群前一定要縮放，並用自己的實驗數字佐證
2. ☐ 手算 K-Means，並用手肘、 Silhouette 、業務三個判準決定 K
3. ☐ 依資料形狀選 K-Means 、階層式或 DBSCAN，並調 eps 與 min_samples
4. ☐ 為每一群命名並對應不同行動；兩群行動相同就該合併
5. ☐ 用 Isolation Forest 找離群個案；用 PCA 降維並說明它的限制

★ 背景：非監督式沒有標準答案，最終判準是「這些群組能不能幫你做決定」

**下一步　第 7 週　M4 進階監督式學習：集成、異常偵測與關聯規則**

# 本單元實例參考資料（點連結可開啟）

[1] Seymour et al.： Derivation, Validation, and Potential Treatment Implications of Novel Clinical Phenotypes for Sepsis （ JAMA 2019 ） （原始論文 PDF （匹茲堡大學））
https://www.dbmi.pitt.edu/wp-content/uploads/2022/09/Derivation-Validation-and-Potential-Treatment-Implications-of-Novel-Clinical-Phenotypes-for-Sepsis.pdf

查核日 2026/11/13 。「原始」指論文或機構本身發布的頁面；「報導／摘要」為第三方整理，數字請以原始來源為準。 未列入： HealthDay 報導與 PMC 論文頁無法穩定開啟，故未放連結。

# 課後複習：本單元的互動學習站

掃描 QR code 或輸入網址；手機、平板、電腦都能用

**掃我開啟 M3 互動版**

手機相機對準即可開啟

網址

**nchsieh.github.io/assets/courses/001/interactive/m3/**

### 14 節，順序對應講義各 PART

看完一個 PART 就做對應的那一節，不必一次做完

### 改參數、立刻看結果

圖表可以拖拉調整，看懂「為什麼」，而不只是背結論

### 隨堂練習＋即時回饋

答錯會說明原因；作答進度只存在你自己的瀏覽器

全部單元入口： nchsieh.github.io/assets/courses/001/interactive/ · 網站內容為教學示例與模擬資料，不需登入