

非監督式學習：分群與降維

M3 — Unsupervised Learning: Clustering & Dimensionality Reduction

沒有標準答案的學習。以原課程 ML 3.4 （326 頁）為本改寫：

分群、異常偵測、降維——問的不是「會怎樣」，而是「這裡面有什麼結構」。

本講義大綱

01 非監督式學習 101 · 沒有標籤的世界

02 完整流程回顧 · 從問題理解到部署

03 前處理：為什麼縮放是必要的 · 距離型演算法的前提

04 K-Means · 手算兩輪+逐步圖解

05 怎麼決定 K · 手肘法與 Silhouette

06 階層式分群 · 樹狀圖與連結方式

07 DBSCAN · 密度式分群與雜訊

08 三種演算法的形狀能力 · 同一資料三種結果

09 分群結果怎麼解讀 · 群組剖析與命名

10 異常偵測 · 三種取徑與 Isolation Forest

11 降維與 PCA · 幾何意義與解釋變異

12 t-SNE 與降維+分群 · 看見高維資料

13 AI Studio 實作 · Customer Credit Risk

14 Take-Home Assignment · 作業一：顧客分群分析

PART 01

非監督式學習 101

Unsupervised Learning Basics

監督式問「這一筆會怎樣」，非監督式問「這一堆裡面有什麼結構」。
沒有答案可以對，所以評估方式完全不同。

監督式 vs 非監督式

比較項目	監督式 Supervised	非監督式 Unsupervised
資料長相	每筆有標籤 y （會不會再入院）	只有特徵 x ，沒有 y
在學什麼	輸入到答案的對應關係	資料本身的結構與關係
怎麼知道對不對	跟正確答案比對（Accuracy、AUC）	沒有正確答案； 看指標+業務可解釋性
典型任務	分類、迴歸	分群、降維、異常偵測、關聯規則
結果的性質	可驗證：預測對或錯	可討論：這樣分有沒有道理
本課程	M2（W4-W5）	M3（W6）、M4 的異常偵測與關聯規則

【原講義 ML 3.4】 pp8-15。關鍵差異：非監督式沒有「標準答案」，所以最終判準一定包含人的專業判斷——這在醫療場域反而是優勢。

實例：分群沒有標準答案

左・你拿到的資料



中・K = 2



右・K = 3



✕ 紅色 ✕ = 各群中心 (Centroid)

三張圖的資料完全相同。K=2 與 K=3 都是演算法「正確」的輸出——選哪一個是你的判斷。

左・你拿到的資料

全部同色。沒有人告訴你有幾群、誰屬於哪一群

中・K=2

硬把資料切成兩塊。演算法照做，不會抱怨

右・K=3

看起來比較貼近資料的自然結構

哪一個對

演算法本身無法回答。要靠指標 (Silhouette) + 你的領域判斷

非監督式學習的四大應用

應用	在做什麼	健康照護的例子	本課程
分群 Clustering	把相似的個案分成幾群	病人分型、照護路徑設計、社區族群分層	M3 主軸
降維 Dimensionality Reduction	把很多欄位壓成少數幾個	問卷量表降維、高維檢驗值視覺化	M3 主軸
異常偵測 Anomaly Detection	找出「不像其他人」的個案	生理訊號異常、異常申報偵測	M3 概念+ M4 實作
關聯規則 Association Rules	找出「常一起出現」的組合	共病組合、用藥組合分析	M4

【原講義 ML 3.4】 p14。原講義另含推薦系統（pp293-318），本課程不列入正式範圍——有興趣可參考 4. Case Studies/Product Recommendation/。

PART 02

完整流程回顧

The Full Workflow

在進入分群之前，先把整個資料科學流程完整看過一次。
這張圖適用於本課程所有模組——包含監督式與非監督式。

資料科學專案的完整流程

① – ⑤ 資料準備約佔近半時間

⑦ – ⑪ 多數專案死在最後兩步



① – ③ 前段

問題理解 → 資料蒐集 → 清理。去重、修正錯字這類不需估計參數的清理可以先做

④ 先切分，再動資料

補值、縮放、特徵選擇等要從資料算統計量的步驟，一律只用訓練集擬合

⑤ – ⑪ 後段

EDA 與特徵工程只看訓練集；建模 → 評估 → 調校 → 溝通 → 部署 → 監控，多數專案死在最後兩步

★ 紅色虛線

實務上一定會回頭。評估不如預期就回去改特徵，監控發現飄移就回去收資料

非監督式的流程差在哪

與監督式相同的部分

- ▶ 問題理解：一樣要先問「誰要用、拿來做什麼」
- ▶ 資料蒐集與清理：遺失值、離群值、一致性照樣要處理
- ▶ EDA：分布與相關性照樣要看
- ▶ 特徵工程：衍生、編碼、分箱照樣要做
- ▶ 溝通與部署：一樣要能講給使用者聽

非監督式獨有的差異

- ▶ 沒有標籤 → 沒有「訓練 / 測試」的必要切分
- ▶ 但仍需檢驗穩定性：換隨機種子、換子樣本，群組會不會大變？
- ▶ 縮放從「可選」變成「必要」——距離是核心運算
- ▶ 評估沒有 Accuracy，改用 Silhouette、Davies-Bouldin + 業務判斷
- ▶ 「調校」調的是 K 值、距離定義、要納入哪些特徵

【原講義 ML 3.4】 pp16-17。原講義的提醒：非監督式的最終判準是「這些群組能不能幫你解決問題」，而不是任何單一數字。

PART 03

前處理：縮放是必要的


Scaling Is Not Optional

監督式學習中，縮放是「看演算法而定」。


非監督式學習中，多數技術靠距離運作——不縮放等於白做。

實例：不正規化時，年齡等於不存在

左・原始尺度（兩軸同刻度）



右・Z-Score 標準化後



左圖的點被壓成一條水平帶：年齡的差異在距離計算裡幾乎沒有貢獻。右圖兩軸展開後才等權。

左・原始尺度

兩軸畫成同刻度後才看得清楚：年齡的變化幅度被收入完全壓扁

距離怎麼算

歐氏距離把兩軸的差平方相加。收入差 50、年齡差 5 → 收入貢獻是年齡的 100 倍

右・Z-Score 後


兩個特徵都變成「離平均幾個標準差」，等權參與距離計算

影響誰


K-Means、階層式、DBSCAN、PCA、k-NN——本模組幾乎全部

實例：縮放如何改變分群結果


左・真實結構



中・未正規化 (純度 77%)



右・Z-Score 後 (98%)



—— 紅色虛線 = 未正規化時的分群切線 (全部垂直, 只切收入)

收入的值域是年齡的十幾倍, 距離完全被它主導——中圖的年齡等於沒有參與計算。

左・真實結構

刻意造出三群：中低收入年輕、中低收入年長、高收入中年

中・未正規化 (純度 77%)

切線全是垂直的——只依收入分, 年齡完全沒有作用

右・Z-Score 後 (98%)

兩個維度等權, 三個真實群組被還原

★ 作業一任務 4

就是要你在 Mall Customer 資料上親手跑出這組對照

分群前的三個前處理決策

① 哪些欄位要納入

- ▶ ID 類欄位一律移除——它只會引入雜訊（作業一任務 2 的 CustomerID）
- ▶ 與分群目的無關的欄位也應移除。放越多不代表分得越好
- ▶ 高度相關的欄位（ $|r| > 0.8$ ）會讓同一資訊被重複加權，考慮擇一或先做 PCA

② 類別欄位怎麼處理

- ▶ K-Means 只吃數值。類別必須先編碼（M1 學過的 Nominal to Numerical）
- ▶ 二元類別（性別）用 0/1 即可；多類別用 One-Hot，但會拉高維度
- ▶ 混合型態可設 `measure types = MixedMeasures`；k-Modes、Gower 需外掛或 Python

③ 用哪一種縮放

- ▶ Z-Score（標準化）：一般情況的預設；平均與標準差同樣會被離群值拉動
- ▶ Min-Max（正規化）：需要固定 0-1 範圍時，但離群值會壓縮其他所有點
- ▶ 有極端離群值時，先處理離群值再縮放——否則縮放本身就被扭曲了

【原講義 ML 3.4】 pp45-49 + 【AI Studio 範例】 Module 6- Normalization & Detecting Outliers.rmp

PART 04

K-Means 分群

K-Means Clustering

最常用的分群演算法。

它只反覆做兩件事，而且兩件都很簡單。

K-Means 的演算法




【原講義 ML 3.4】 pp56-65。K-Means 保證會收斂，但不保證收斂到全域最優——起始中心不同，結果可能不同。這是為什麼要多跑幾次取最好的。

手算：六位病人、K=2、跑到收斂

第 1 輪的距離計算

點	x	y	到 C1 距離	到 C2 距離	歸屬
A	2.0	2.0	0.00	1.41	群 1
B	3.0	3.0	1.41	0.00	群 2
C	2.5	2.0	0.50	1.12	群 1
D	8.0	8.0	8.49	7.07	群 2
E	9.0	7.0	8.60	7.21	群 2
F	8.5	9.0	9.55	8.14	群 2



中心的移動軌跡

輪次	C1	C2
起始	(2.0, 2.0)	(3.0, 3.0)
第 1 輪後	(2.25, 2.0)	(7.12, 6.75)
第 2 輪後	(2.5, 2.33)	(8.5, 8.0)
第 3 輪後	(2.5, 2.33)	(8.5, 8.0)
結果	A B C	D E F

起始中心刻意選得很差

兩個中心都在左下角，第 1 輪的分群是錯的（B 被分到群 2）

第 2 輪就修正了

中心移動後，B 回到群 1，D E F 正確聚成群 2

第 3 輪中心不動

收斂。這個例子只花三輪，實務上通常十幾輪

距離公式

歐氏距離 = $\sqrt{(x_1-x_2)^2 + (y_1-y_2)^2}$ 。所有數字都已驗算

【原講義 ML 3.4】 pp57-65

實例：K-Means 逐步收斂的過程

紅色 X = 中心

看它每一輪往哪裡移動——移向該群所有點的平均位置

第 1 輪

起始中心都在左下，分群明顯不合理

第 2 輪

中心大幅移動後，分群已經正確


第 3 輪

中心不再變動 → 收斂。這就是演算法停止的條件


起始：中心都在左下角




第 1 輪：更新中心後



第 2 輪：分群已改變



第 3 輪：中心不動了



× = 群中心

● 群 1

● 群 2

每輪只做兩件事：指派 → 更新中心

第 1 輪把 B 分錯了；中心移動後第 2 輪就修正，第 3 輪不再變動 → 收斂。

K-Means 的優缺點與參數

面向	內容
優點	速度快、可擴展到大資料；概念直觀；結果（中心點）容易解讀成「典型個案」
缺點 1	必須事先指定 K—— 但你通常不知道有幾群
缺點 2	只擅長球狀、大小相近的群。彎月形、同心圓會完全失敗（本講義後面有實例）
缺點 3	對離群值敏感——一個極端點會把中心整個拉走
缺點 4	結果依起始中心而變。務必跑多次（AI Studio 的 max runs 參數）
AI Studio 參數	k（群數）、max runs（重跑次數）、measure types（距離定義）、max optimization steps（最大迭代）

【AI Studio 範例】 5. Clustering/CLUSTERING - Customer Credit Risk 2026/ 的 1、2、6 號流程。

PART 05

怎麼決定 K


Choosing K

這是分群最常被問的問題，而且沒有唯一正確答案。
但有三個可以依循的判準。

Inertia (組內平方和) 怎麼算

逐點計算

群	成員	中心	各點到中心距離 ²
群 1	A(2,2)	(2.5, 2.33)	0.36
	B(3,3)		0.69
	C(2.5,2)		0.11
群 2	D(8,8)	(8.5, 8.0)	0.25
	E(9,7)		1.25
	F(8.5,9)		1.00



彙整

量	值
群 1 組內平方和	1.167
群 2 組內平方和	2.500
Inertia 總和	3.667
別名	WCSS (Within-Cluster Sum of Squares)
性質	K 越大一定越小 (K = n 時為 0)

Inertia 在量什麼

每個點離自己群中心有多遠。越小代表群內越緊密

為什麼不能直接選最小的

K 越大 Inertia 一定越小。K = 樣本數時每點自成一群，Inertia = 0，但毫無意義

所以要看「轉折」

下降速度突然趨緩的那個 K，就是手肘法要找的點

AI Studio

Cluster Distance Performance 輸出 Avg. within centroid distance (平均距離，非平方和；看趨勢可，數值不等於 Inertia)

【原講義 ML 3.4】 pp76-79

實例：手肘法與 Silhouette

左・手肘法 Elbow Method



右・平均 Silhouette 係數



Inertia 越小越好，但 K 越大一定越小；Silhouette 越大越好，有明確極值。兩者都指向 K = 3。

左・手肘法 Elbow

Inertia 隨 K 單調下降。找「下降突然變慢」的轉折點

手肘的問題

有時候彎得不明顯，三個人看會有三種答案——這是它的弱點

右・Silhouette

有明確的最高點，判讀比手肘法客觀

兩個都看

兩者指向同一個 K 時最有信心；不一致時以業務可解釋性拍板

Silhouette 係數：手算一個點

點 A 的兩個距離

點	所屬群	a = 同群平均距離	b = 最近他群平均距離
A	群 1	0.957	8.880



係數計算

步驟	計算	值
公式	$s = (b - a) / \max(a, b)$	
代入	$(8.880 - 0.957) / 8.880$	
s(A)		0.892
判讀	接近 +1 → 分得很好	

a 在量什麼

這個點與「自己群其他成員」的平均距離。越小越好

b 在量什麼

這個點與「最近的另一群」全部成員的平均距離。越大越好

整體 Silhouette

把每個點的 s 算出來取平均，就是整個分群的分數


範圍與判讀

-1 到 +1。 >0.7 強、0.5-0.7 合理、≤ 0.25 無明顯結構（Kaufman & Rousseeuw, 1990）


【原講義 ML 3.4】 pp171-173。AI Studio 內建指標沒有 Silhouette，可用 Execute Python（sklearn 的 silhouette_score）計算

實例：Silhouette 的三種情況


左 · $s \approx +0.9$



中 · $s \approx +0.1$



右 · $s \approx -0.4$



— a = 到自己群的平均距離

- - b = 到最近他群的平均距離

$$s = (b - a) / \max(a, b)$$

s 的範圍是 -1 到 +1：越接近 +1 分得越好，接近 0 在邊界上，小於 0 很可能分錯群。

左 · $s \approx +0.9$

星號點離自己群很近、離另一群很遠 → 分得很好

中 · $s \approx +0.1$

在兩群邊界上，a 與 b 差不多 → 這個點分到哪群都可以

右 · $s \approx -0.4$

離另一群反而更近 → 很可能被分錯了

實務用途

把 s 很低的個案挑出來單獨檢視——它們常是最有洞見的邊界案例

三個判準，缺一不可

判準	怎麼看	優點	限制
① 手肘法 Elbow	Inertia 對 K 作圖，找轉折	直觀、計算快	轉折常不明顯，主觀
② Silhouette / Davies-Bouldin	Silhouette 取最大； Davies-Bouldin 取最小	有明確極值，較客觀	仍假設「群是緊密且分離的」
③ 業務可解釋性	每一群說得出「這是誰」嗎？ 能對應到不同行動嗎？	★ 最終判準	需要領域知識

【原講義 ML 3.4】 pp80-83。原講義的 PRO TIP：有時候精確的群組歸屬沒那麼重要，重要的是你能依此提出什麼可行動的建議。

PART 06

階層式分群


Hierarchical Clustering

不必事先決定群數。


它把所有可能的群數一次算完，讓你事後再切。

實例：樹狀圖怎麼讀

左・五個資料點



右・樹狀圖 Dendrogram



第 2 步 (0.71) 到第 3 步 (5.55) 距離跳了 8 倍——那裡就是最自然的切點。

左・五個點

P1 與 P2 很近、P3 與 P4 很近、P5 孤零零在右下

右・樹狀圖

由下往上：先合併最近的一對 (P3-P4，距離 0.54)，再來 P1-P2 (0.71)

縱軸的意義

合併時兩群之間的距離。跳很高代表「硬把兩個不像的群併在一起」


怎麼決定群數

橫切一刀。切在距離 3.0 處會得到 3 群：
{P1,P2}、{P3,P4}、{P5}

合併順序：從距離矩陣看（平均連結）

兩兩距離

配對	距離
P3-P4	0.539
P1-P2	0.707
P2-P3	4.950
P4-P5	5.467
P1-P3	5.657
P1-P5	8.000



凝聚式合併順序

步驟	合併誰	距離
1	P3 + P4	0.539
2	P1 + P2	0.707
3	{P1,P2} + {P3,P4}	約 5.55
4	全部 + P5	約 6.60
觀察	第 3、4 步距離跳很大 → 切在這之前較合理	

凝聚式 Agglomerative

由下而上：每個點自成一群，反覆合併最近的兩群。這是最常用的

分裂式 Divisive

由上而下：全部一群，反覆切開。計算量大，較少用

距離跳躍是線索

第 2 步（0.707）到第 3 步（5.55）跳了 8 倍——這裡就是自然的切點


距離已驗算

歐氏距離；群間距離採平均連結（若用單一連結，第 3 步為 4.95）


【原講義 ML 3.4】 pp85-91

實例：三種連結方式


左・單一連結 Single



中・完全連結 Complete



右・平均連結 Average



● 群 A (3 點)

● 群 B (3 點)

同一組點，三種「群間距離」的定義

連結方式決定「兩群有多遠」，換一種定義就會長出完全不同的樹。

單一連結 Single

取兩群之間「最短」的那一對距離。容易產生鏈狀的長條群

完全連結 Complete

取「最長」的那一對。傾向產生大小相近的緊密群

平均連結 Average

取所有配對的平均。★ 最常用的折衷選擇

還有 Ward 法

以「合併後組內變異增加最少」為準則，實務上效果常最好（AI Studio 無此選項，需 Python）

階層式分群的優缺點

優點

- ▶ 不必事先指定群數——樹狀圖把所有可能一次呈現
- ▶ 樹狀圖本身就是很好的溝通工具，非技術人員看得懂
- ▶ 可以看出「群中還有子群」的巢狀結構
- ▶ 結果穩定：不像 K-Means 依賴隨機起始
- ▶ 適合：樣本數不大（幾百到幾千）、想探索結構時

缺點

- ▶ 計算量大：距離矩陣是 $n \times n$ ，樣本上萬時吃不消
- ▶ 合併之後不能反悔——早期的錯誤會一路帶下去
- ▶ 對離群值敏感（單一連結尤其）
- ▶ 仍需要你決定「切在哪」
- ▶ AI Studio：Agglomerative Clustering（single / complete / average 三種連結）

DBSCAN 密度式分群


Density-Based Clustering

前兩種都假設「群是一團一團的」。

DBSCAN 改問：哪裡的點特別密集？

實例：DBSCAN 的三種點

eps 半徑內的點夠多，就是核心點



不必事先指定群數：密度夠的地方自己長成群，密度不夠的點被標成雜訊。

● 核心點 Core

半徑內 ≥ 5 個點
本圖 119 點

● 邊界點 Border

落在核心點的半徑內
本圖 6 點

✕ 雜訊點 Noise

兩者皆非，不屬任何群
本圖 7 點

min_samples = 5

核心點 Core

以 eps 為半徑畫圓，圓內至少有 min_samples 個點

邊界點 Border

自己不夠密，但落在某個核心點的半徑內 → 併入該群

雜訊點 Noise

兩者皆非 → 不屬於任何群。★ 這是 DBSCAN 獨有的能力

兩個參數

eps（半徑）與 min_samples（最少點數）。這兩個決定一切

DBSCAN 的兩個參數怎麼調

參數	意義	調大會	調小會	起手建議
epsilon (半徑)	多近算「鄰居」	群變少變大； 最後可能全部併成一群	群變多變碎； 雜訊點暴增	畫 k- 距離圖找轉折； 或從資料尺度的 1-5% 試
min points (最少點數)	多密才算核心	雜訊點變多； 只保留最密的核心	幾乎沒有雜訊； 容易把稀疏區也算成群	經驗值：維度數 $\times 2$ (Sander et al., 1998) ； 二維資料常用 4-6

【原講義 ML 3.4】 pp111-168。實務提醒：DBSCAN 對參數很敏感，且高維時「密度」的概念會失效（維度詛咒）——超過十幾維時效果通常不好。

DBSCAN 的三個獨特能力

① 不必事先指定群數

- ▶ 群數由資料的密度結構自己決定，這是它相對於 K-Means 最大的優勢
- ▶ 但代價是你改成要調 epsilon 與 min points——難度不見得比較低

② 能找出任意形狀的群

- ▶ K-Means 只會畫圓（球狀），DBSCAN 可以順著密集區的形狀延伸
- ▶ 彎月形、環狀、不規則形狀都抓得到——下一頁有實例對照

③ 自動標出雜訊

- ▶ 不強迫每個點都歸屬某一群。稀疏區的點被標為雜訊（AI Studio 歸為 cluster_0，別誤讀成第一群；Python 為 -1）
- ▶ 這讓 DBSCAN 同時可以當作異常偵測工具使用（原講義 pp204-208）
- ▶ 對醫療資料特別有用：那些「不像任何一群」的個案往往最值得看

PART 08

三種演算法的形狀能力

Same Data, Different Results

同一份資料餵給三種演算法，結果可能天差地遠。
這一頁決定你該選哪一個。

實例：三種演算法 × 三種資料形狀

球狀

K-Means



階層式 (平均連結)




DBSCAN



彎月形



同心圓



灰色 × = DBSCAN 標出的雜訊點。先畫散布圖看形狀，再決定用哪個演算法。

第一列・球狀

三者都做對了。這種情況下選最快的 K-Means 即可

第二列・彎月形

K-Means 與階層式從中間垂直切開（錯）；
DBSCAN 正確分出兩彎

第三列・同心圓

K-Means 切成左右兩半（完全錯）；
DBSCAN 正確分出內外環

結論

形狀決定演算法。先畫散布圖看資料長什麼樣，再決定用誰

三種演算法全比較

面向	K-Means	階層式	DBSCAN
需要指定群數	★ 要	不用（事後切）	不用
能抓的形狀	只有球狀	看連結方式，較彈性	任意形狀
雜訊處理	強制每點歸群	強制每點歸群	★ 自動標為雜訊
對離群值	敏感（拉走中心）	敏感（尤其單一連結）	穩健
計算量	低，可處理大資料	高（ $n \times n$ 距離矩陣）	中等
結果穩定性	依起始中心而變	穩定	依參數而變
群大小差異大時	表現差（傾向切成等大）	可以處理	可以處理
高維表現	尚可	尚可	差（密度失效）
AI Studio	k-Means / X-Means	Agglomerative Clustering	DBSCAN

【原講義 ML 3.4】 pp175-176。實務建議：先跑 K-Means 建立基準（快），畫散布圖檢視結果；若形狀明顯不是球狀，再換 DBSCAN 或階層式。

PART 09

分群結果怎麼解讀


Interpreting Clusters

跑出群組只是一半的工作。

說不出「每一群是誰」，這個分析就沒有價值。

實例：群組剖析圖

各群在四個特徵上與整體平均的差（標準化後）



零線之上＝這一群在該特徵高於整體平均，之下＝低於平均。命名就是讀這張圖。

群 1 (n = 57)

年長、低支出

群 2 (n = 61)

年輕、高支出

群 3 (n = 62)

高就診、高共病

命名 = 看哪幾根特別突出

怎麼做

把每一群在各特徵上的平均，與「整體平均」相比，畫成長條圖

怎麼讀

往上＝該群在這個特徵上高於平均；往下＝低於平均

怎麼命名

看哪幾根特別突出。群 3 在就診次數與共病數都很高 → 高需求族群

★ 命名是分析的一部分

說不出每群是誰，就等於什麼都沒做出來

分群結果的解讀四步驟

步驟	做什麼	產出
① 看群大小	每群各多少人？佔比多少？	極小的群（<5%）要判斷是真的次族群還是雜訊
② 做群組剖析	算每群在各特徵的平均，與整體平均比較	剖析圖或表格（本頁的圖）
③ 為每群命名	用 2-6 個字描述這群的特徵	例：「高齡低支出型」「年輕高就診型」
④ 對應到行動	每一群該有什麼不同的處置？	★ 若兩群的處置一樣，那分成兩群就沒有意義

【原講義 ML 3.4】 pp70-71、82-83。第④步是檢驗分群是否有價值的最終標準——這也是作業一任務 6 的要求。

隨堂檢核 1 | 分群

Q
1

K-Means 跑兩次得到不同結果，是程式有問題嗎？

不是。起始中心隨機，結果本來就可能不同。解法：提高 max runs，或固定 random seed。

Q
2

Silhouette 最高的 K 是 6，但你只能設計 3 種照護方案。怎麼辦？

選 3。業務可解釋性是最終判準——分成 6 群卻只有 3 種處置，多出來的區分沒有意義。

Q
3

DBSCAN 跑出來 80% 的點都是雜訊，哪裡出錯了？

eps 太小或 min_samples 太大。先畫 k-距離圖找合適的 eps。

Q
4

為什麼分群前一定要縮放，但決策樹不用？

分群靠「距離」，距離會被大尺度特徵主導；決策樹只比大小、不算距離。

PART 10


異常偵測

Anomaly Detection


換一個問法：不是「這些點怎麼分群」，
而是「哪些點不像其他人」。

實例：三種異常偵測取徑


① 統計法 ($|z|$ 超過門檻)



② 距離法 (第 5 個鄰居)



③ Isolation Forest



● 正常點 (180 筆)

✗ 被標記為異常的點

四個真正的離群點三種方法都抓到了；邊緣地帶的點就各有各的看法——沒有標準答案。

① 統計法

偏離平均超過 3 個標準差。最簡單，但假設接近常態

② 距離法

第 k 個最近鄰居特別遠。需要正規化，維度高時失效

③ Isolation Forest


隨機切幾刀就能孤立的點 = 異常。不需假設分布，高維也能用

沒有標準答案

異常偵測沒有標籤可對。三種方法標出的點會部分重疊但不完全一致

實例： Isolation Forest 的核心直覺


左・正常點：密集區



● 其他資料點

★ 被追蹤的點

右・異常點：稀疏區



細線＝隨機切的一刀，粗框＝目前還沒被切開的區域

平均要切幾刀才孤立得了——這個數字就是異常分數。刀數越少，越可能是異常。

左・正常點

位於密集區。要隨機切很多刀，才能把它單獨隔離出來

右・異常點

位於稀疏區。切兩三刀就孤立了

演算法

建很多棵隨機切分樹，記錄每個點平均被幾刀孤立

為什麼好用

不需要算距離、不需要假設分布，高維時仍有效——這是它勝過前兩種的地方

四種異常偵測方法比較

方法	判斷依據	優點	限制
統計法（Z-score / IQR）	偏離平均幾個標準差； 或落在四分位距外	極簡單、可解釋	假設近常態； 只看單一欄位
距離法（k-NN 距離）	第 k 個最近鄰居有多遠	直覺；可處理多維	必須正規化； 維度高時失效
密度法（LOF / DBSCAN）	周圍密度比鄰居稀疏多少	能處理密度不均的資料	計算成本高； 參數敏感
Isolation Forest	隨機切幾刀能孤立	不需假設分布； 高維仍有效；速度快	結果依隨機性略有變動； 需設定污染比例

【原講義 ML 3.4】 pp183-208 + 【AI Studio 範例】 3. Outlier and Ensemble/Anomaly Detection .rmp。M4 第 7 週會實作鍋爐感測器異常偵測。

醫療場域的三個提醒

異常 ≠ 錯誤

- ▶ 被標記為異常的個案，可能是資料輸入錯誤，也可能是真正的重症病人
- ▶ 先問「生理上可能嗎」：血壓 0 是錯誤，血壓 210 是真實的高危個案
- ▶ M1 講過的原則在這裡再次適用：標記而非直接刪除

污染比例要自己設

- ▶ 多數演算法要你指定「預期有多少比例是異常」（contamination）
- ▶ 設 5% 就會標出 5% 的點，不管資料裡實際有幾個異常
- ▶ 所以這個數字要從領域知識來，不是隨便填

驗證需要領域專家

- ▶ 沒有標籤可以算 Accuracy。唯一的驗證是把標出的個案給專業人員看
- ▶ 實務做法：標出前 20 名最異常的個案，請臨床人員判斷有幾個是真的
- ▶ 這個「命中率」就是你能報告的最實在的指標

PART 11

降維與主成分分析

Dimensionality Reduction & PCA

欄位太多會有三個問題：算得慢、畫不出來、而且距離會失去意義。
降維同時解決這三件事。

為什麼要降維

1

看得見

- ▶ 人類只能看懂 2-3 維的圖
- ▶ 50 個欄位的資料無法直接視覺化
- ▶ 降到 2 維才畫得出散布圖
- ▶ ★ 這是最常見的用途
- ▶ 配合分群使用效果最好
- ▶ 本講義後面有實例

2

算得動

- ▶ 維度高時計算量急遽上升
- ▶ 距離計算、模型訓練都變慢
- ▶ 降維後速度可以快好幾倍
- ▶ 儲存空間也變小
- ▶ 對大資料特別有感
- ▶ 但現代硬體下這點沒以前重要

3


避開維度詛咒

- ▶ 維度越高，所有點的距離越接近
- ▶ → 距離失去鑑別力
- ▶ → k-NN、分群、DBSCAN 全失效
- ▶ 也會加重過擬合
- ▶ ★ 這是最根本的理由
- ▶ 特別影響本模組的所有技術


【原講義 ML 3.4】 pp214-218。降維與「特徵選擇」的差別：特徵選擇是「挑出原始欄位」（保留可解釋性）；降維是「造出新的組合欄位」（效果好但難解釋）。

實例：PCA 的三個步驟


① 原始資料（2 維）



② 置中後找主成分方向



③ 投影到 PC1（1 維）



$\lambda_1 = 1.361$ $\lambda_2 = 0.058$ → PC1 解釋 95.9% 的變異，PC2 只剩 4.1%

三步驟：置中 → 找最大變異方向 → 投影。座標軸換了，資訊幾乎沒有損失。

① 原始資料

兩個特徵高度相關，資料呈斜向分布

② 找主成分方向

PC1 = 變異最大的方向（紅）；PC2 與它垂直（綠）且變異次大

③ 投影降維

把所有點投影到 PC1 上，二維變一維，仍保留 95.9% 的變異


關鍵

PCA 不是「刪掉欄位」，而是「換一組座標軸」，再丟掉變異小的那些軸

PCA 手算：從共變異數矩陣到解釋變異

計算流程

步驟	計算內容
① 置中	每個特徵減去自己的平均
② 共變異數矩陣	[[0.688, 0.651], [0.651, 0.731]]
③ 求特徵值	$\lambda_1 = 1.361$ $\lambda_2 = 0.058$
④ 求特徵向量	PC1 = (0.696, 0.719) PC2 = (-0.719, 0.696)
⑤ 投影	原始資料 × PC1 方向 = PC1 分數



解釋變異比例

量	值	意義
λ_1	1.361	PC1 抓到的變異量
λ_2	0.058	PC2 抓到的變異量
PC1 解釋比例	95.9%	$1.361 \div (1.361+0.058)$
PC2 解釋比例	4.1%	
結論	保留 PC1 即可	丟掉 4.1% 的資訊，維度減半

特徵值 λ 是什麼

該主成分方向上的變異量。越大代表這個方向承載越多資訊

特徵向量是什麼

主成分的方向。它是原始特徵的線性組合——這就是難以解釋的原因

解釋變異比例

$\lambda_i \div \sum \lambda$ 。第一主成分永遠最大，之後遞減


數值已驗算

以 8 筆二維資料實際計算，可用 AI Studio 的 PCA Operator 對照


【原講義 ML 3.4】 pp219-252

實例：要保留幾個主成分

左・陡坡圖 Scree Plot



右・累積解釋變異



陡坡圖看「哪裡開始變平」，累積圖看「到幾個才夠」——兩張一起看才有把握。

左・陡坡圖 Scree Plot

每個主成分的解釋變異比例。找「陡降後趨平」的轉折點

右・累積解釋變異

常用門檻 80% (有些領域用 90%)

本例的答案

4 個主成分即達 86%，原本 10 個欄位減為 4 個

怎麼選

兩張圖一起看，再加上「後續要拿來做什麼」——只是要畫圖的話取 2 個就好


PCA 的三個限制

限制	說明	怎麼辦
主成分難以解釋	PC1 是「 $0.7 \times \text{身高} + 0.72 \times \text{體重}$ 」，不是任何一個現實概念	要解釋時改用特徵選擇； 或看各特徵在 PC 上的載荷量
只抓線性關係	彎曲的結構 PCA 抓不到	改用 t-SNE、UMAP 等非線性方法
必須先標準化	PCA 找的是「變異最大」的方向， 沒標準化時大尺度欄位會主導	★ 一律先做 Z-Score 標準化


【AI Studio 範例】 4. Case Studies/4.3.2 HR Churn/A2. SVD PCA and covariance for dimensional reduction.rmp 與 A3. Weights by PCA

實例：PCA 與 t-SNE 的差別

左・PCA：線性投影



右・t-SNE：非線性



● 第 1 群 ● 第 2 群 ● 第 3 群

同一份 3 維資料降到 2 維：PCA 看得到群的相對位置，t-SNE 把每一群擠得更開。

PCA

線性投影。保留整體變異與全域距離結構，計算快、結果穩定

t-SNE

非線性。強調「鄰近關係」，群看起來更分明

★ t-SNE 的三個陷阱


群之間的距離、群的大小都沒有意義，且每次跑結果不同（Wattenberg et al., 2016）

怎麼用


t-SNE 只適合「視覺化探索」，不要拿它的座標去做後續建模

實例：降維 + 分群的實務組合

左・先 PCA 降到 2 維（還沒分群）



右・在原始空間分群，用同一張圖上色



同一張圖、同一批點：左邊只是換座標，右邊才是分群的結果

降維是為了「看見」，分群才是「切開」——兩件事分開想，順序才不會搞混。

步驟一

先用 PCA 或 t-SNE 把高維資料降到 2 維，畫出來看

步驟二

肉眼判斷大概有幾群 → 作為選 K 的第三個線索

步驟三

跑分群，把結果用同一張降維圖上色檢視

注意

分群本身可在原始高維空間做（資訊較完整），降維只是為了「看見」

PART 12

AI Studio 實作

Hands-on Labs

Customer Credit Risk 的六個流程涵蓋本模組全部技術。
請用 2026 版資料夾。

實作 1 | Customer Credit Risk 分群

【AI Studio 範例】 5. Clustering / 2026 版

開啟檔案

```
範例 /ML (AI Studio)/M3. 非監督式與降維 /  
└ CLUSTERING - Customer Credit Risk 2026/  
  └ 6. Iris Clustering K-means.rmp ← 先跑這個  
  └ 1 ... data preparation.rmp  
  └ 2 ... view clusters.rmp  
  └ 3 ... X-means .rmp  
  └ 4 ... K-Means with PSO.rmp  
    └ Segmentation_Clustering_CraftBeer  
      Consumers_FullProcess.rmp
```

```
資料 /ML (AI Studio)/M3. 非監督式與降維 /  
CustomerCreditRiskData / Marketing_data
```

預期結果

- ▶ 未正規化時，分群幾乎由值域最大的欄位決定
- ▶ 手肘圖的轉折點常不明顯——這是正常的，要搭配其他判斷
- ▶ X-Means 選出的 K 未必等於你選的，兩者都要能說出理由

操作步驟

- 1 先跑 6. Iris Clustering：資料小、結構清楚，建立直覺
- 2 開 1 data preparation：確認 Normalize 有沒有啟用，記下有哪些欄位被排除
- 3 ★ 停用 Normalize 跑一次、啟用再跑一次，比較兩組 centroid 表
- 4 開 2 view clusters：檢視散布圖與各群中心，試著為每一群命名
- 5 接 Cluster Distance Performance，把 k=2 到 6 各跑一次記錄指標
- 6 畫出手肘圖與 Davies-Bouldin 折線，決定你的 K
- 7 開 3 X-means：它會自動決定 K。與你手動選的一致嗎？不一致時誰有道理？
- 8 開 4 PSO 版本觀摩（進階，理解即可）

實作 2 | 降維與 PCA

【AI Studio 範例】 4.3.2 HR Churn / Challenge

開啟檔案

範例 / ML (AI Studio) / M3. 非監督式與降維 /

└ HR Churn 降維系列 /

└ A2. SVD PCA and covariance for
dimensional reduction.rmp

└ A3. Weights by PCA for
dimensional reduction.rmp

└ A4. SVD and Grouping models.rmp

挑戰題（進階）：

Challenge 降維挑戰 / （同一資料夾）

Dimension Reduction Challenge.pdf

abalone-challenge.csv / Solution.docx

預期結果

- ▶ 前 2-3 個主成分通常就能解釋大部分變異
- ▶ Weights by PCA 保留原始欄位名稱，可解釋性高得多
- ▶ 降維後分群的結果未必更好——要實測才知道

操作步驟

- 1 開 A2，找到 PCA Operator，檢視它輸出的 Eigenvalues 與解釋變異比例
- 2 把「保留的主成分數」從 2 調到 5，觀察累積解釋變異的變化
- 3 畫出陡坡圖（把各主成分的變異比例做成表再繪圖）
- 4 決定你要保留幾個主成分，並寫下理由（門檻 80% 還是看轉折？）
- 5 開 A3：Weights by PCA 是「特徵選擇」而非「特徵萃取」——比較兩者差異
- 6 ★ 思考：哪一種在你的專題裡比較適合？（可解釋 vs 效果）
- 7 進階：對降維後的資料再跑一次 K-Means，與原始高維的分群結果比較

PART 13

Take-Home Assignment

作業一：顧客分群分析

本模組對應學期的正式作業一

第 9 週上課前繳交 | 佔學期成績 15%

作業規格

項目	要求
資料集	Mall Customer Segmentation Dataset （Kaggle ， 200 筆）。亦可改用你貫穿主線的資料，但須為公開或模擬資料，且欄位數 ≥ 4 。
工具	AI Studio （正式名稱 RapidMiner AI Studio ， 原 Altair AI Studio ）。流程需可正常執行並繳交 .rmp 檔。
形式	個人作業。PDF 報告（含截圖）+ .rmp 流程檔，壓縮為一個檔案上傳。
篇幅	報告本文 6-10 頁（不含截圖附錄）。
期限	第 9 週上課前上傳至學校 iClass 。逾期一週內以八折計分。

七個必做任務

任務	要求	對應章節
1 資料探索 EDA	以 Statistics 檢視型態、極值、缺失。繪製各數值欄位的分布圖，判斷是否有偏態或多峰（多峰是判斷群數的直觀線索）。	PART 2-3
2 前處理與類別編碼	移除 ID 欄位並說明理由。將類別欄位編碼並截圖前後型態。 ★ 思考題：Label Encoding 與 One-Hot 的距離意義有何不同？	PART 3
3 相關性檢查	產生 Correlation Matrix，找出 $ r $ 最高的一組並報告數值。說明是否移除及理由。	M1 PART 9
4 正規化對照實驗	★ 核心任務。實驗 A（未正規化）與實驗 B（Z-Score）各跑 K-Means（ $K=3$ ），記錄兩組的各群平均值與散布圖，說明為什麼正規化是必要的。	PART 3
5 決定最佳 K	以正規化後的資料， $K = 2$ 到 6 各跑一次，記錄 Davies-Bouldin（必做）與 Silhouette（選做，用 Execute Python 計算）。做成表格與折線圖，說明選定 K 的理由（量化指標＋業務可解釋性）。	PART 5
6 視覺化與群組命名	繪製散布圖並以群組上色。計算每群在各特徵的平均，為每群命名（如「高收入低消費型」）並提出對應的行銷或照護策略。	PART 9
7 演算法比較	另跑一次階層式分群或 DBSCAN，與 K-Means 的結果比較。說明哪一個較適合這份資料，依據是什麼。	PART 6-8

四個必答思考題（寫入報告）

Q
1

為什麼正規化對距離型演算法是必要的？請用你實驗 **A** 與 **B** 的實際數字說明。

不要只寫「因為尺度不同」。要指出未正規化時是哪一個欄位主導了分群，以及群平均差了多少。

Q
2

你選定的 **K** 值，三個判準（手肘、**Silhouette**、業務）各指向什麼？不一致時你怎麼取捨？

三者指向不同是常態。重點是說明你為什麼相信其中一個。

Q
3

你為每一群取的名字，能對應到不同的行動嗎？如果兩群的行動一樣，代表什麼？

代表這兩群其實不需要分開——這是檢驗分群價值的最終標準。

Q
4

若這份資料多了 **20** 個欄位，你的流程要改哪些地方？

提示：維度詛咒、降維的必要性、以及演算法的選擇會不會改變。

評分標準（共 100 分）

向度	配分	評分重點
EDA 與前處理	20	逐欄檢查完整；ID 欄位有移除並說明；編碼方式正確
正規化對照實驗	25	★ 兩組實驗都有做；有量化比較（群平均表）；結論說得出所以然
K 值決定	20	Davies-Bouldin 有算（Silhouette 選做）；有折線圖；選擇理由兼顧量化與業務
群組解讀與命名	20	每群都有名字；命名依據明確；有提出對應行動
演算法比較與報告品質	15	有跑第二種演算法；.rmp 可執行；結構清楚、誠實說明限制

加分（至多 +10）：以 PCA 降至 2D 後視覺化並比較；或用 X-Means 自動選 K 與手動結果對照；或對分群結果做穩定性檢驗（換 seed / 換子樣本）。

中英術語對照 | M3

(1 / 4)

中文	English	一句話說明
非監督式學習	Unsupervised Learning	沒有標籤，找資料本身的結構
分群	Clustering	把相似的個案分成幾群
降維	Dimensionality Reduction	把很多欄位壓成少數幾個
異常偵測	Anomaly / Outlier Detection	找出不像其他人的個案
K-Means 分群	K-Means Clustering	以中心點與距離反覆指派的分群法
中心點	Centroid	一群的平均位置，代表該群的「典型」
組內平方和	Inertia / Within-Cluster Sum of Squares, WCSS	各點到自己群中心距離平方的總和
手肘法	Elbow Method	以 Inertia 對 K 作圖，找下降趨緩的轉折
輪廓係數	Silhouette Coefficient	$(b-a)/\max(a,b)$ ，-1 到 +1，越大越好

中英術語對照 | M3

(2 / 4)

中文	English	一句話說明
Davies-Bouldin 指數	Davies-Bouldin Index	群內緊密度與群間分離度的比值，越小越好
X-Means	X-Means	自動嘗試不同 K 並選出最佳的 K-Means 變體
階層式分群	Hierarchical Clustering	逐步合併或分裂，產生巢狀結構
凝聚式	Agglomerative	由下而上，每點自成一群後反覆合併
分裂式	Divisive	由上而下，全部一群後反覆切開
樹狀圖	Dendrogram	呈現合併順序與距離的樹狀圖
單一連結	Single Linkage	以兩群間最短距離作為群距離
完全連結	Complete Linkage	以兩群間最長距離作為群距離
平均連結	Average Linkage	以所有配對距離的平均作為群距離

中英術語對照 | M3

(3 / 4)

中文	English	一句話說明
Ward 法	Ward's Method	以合併後組內變異增加最少為準則
DBSCAN	Density-Based Spatial Clustering (DBSCAN)	以密度定義群，可標出雜訊
核心點	Core Point	半徑內鄰居數達門檻的點
邊界點	Border Point	自身不夠密但落在核心點半徑內
雜訊點	Noise Point	不屬於任何群的點
局部離群因子	Local Outlier Factor, LOF	與鄰居相比的密度稀疏程度
孤立森林	Isolation Forest	以隨機切分的深度判斷異常
污染比例	Contamination	預期資料中異常所佔的比例
主成分分析	Principal Component Analysis, PCA	找變異最大的線性方向並投影降維

中英術語對照 | M3

(4 / 4)

中文	English	一句話說明
主成分	Principal Component	原始特徵的線性組合，彼此正交
特徵值	Eigenvalue	該主成分方向上的變異量
特徵向量	Eigenvector	主成分的方向
解釋變異比例	Explained Variance Ratio	各主成分佔總變異的比例
陡坡圖	Scree Plot	各主成分解釋變異的長條／折線圖
奇異值分解	Singular Value Decomposition, SVD	矩陣分解技術，PCA 的計算基礎之一
t-SNE	t-Distributed Stochastic Neighbor Embedding	強調鄰近關係的非線性降維，僅供視覺化
維度詛咒	Curse of Dimensionality	維度高時距離失去鑑別力
群組剖析	Cluster Profiling	比較各群在各特徵上與整體平均的差異

本模組重點回顧

- 1 非監督式沒有標準答案——最終判準是「這些群組能不能幫你做決定」。
- 2 縮放在非監督式從「可選」變成「必要」：距離是所有技術的核心。
- 3 K-Means 只擅長球狀群；形狀不規則時用 DBSCAN，想看結構用階層式。
- 4 決定 K 要三個判準：手肘看趨勢、Silhouette 看品質、業務可解釋性拍板。
- 5 分群跑完只是一半——說不出每群是誰、該做什麼，就等於沒做。
- 6 PCA 保留變異但主成分難解釋；要解釋時改用特徵選擇。

下一步 第 7 週 M4 進階監督式學習：集成、異常偵測與關聯規則