MODULE 4

進階監督式學習：集成、異常、關聯與時間序列

M4 — Ensembles, Anomalies, Association Rules & Time Series

M2 教你把單一模型做好。這一週處理四件單一模型做不到的事：
把模型組起來、找出沒有標籤的異常、挖出隱藏的關聯、處理有時間的資料。

資料科學 2027 Spring • 第 7 週 • Phase B | 謝楠楨

本講義大綱

01 為什麼需要這一週 • 單一模型的四個天花板

02 偏誤—變異分解 • 為什麼集成有效

03 集成方法完整分類 • 平行・序列・異質

04 多樣性原理 • 成員必須「錯得不一樣」

05 Bagging 家族 • 隨機森林與 Extra Trees

06 Boosting 家族 • AdaBoost 手算三輪

07 GBDT 三大實作 • XGBoost・LightGBM・CatBoost

08 Stacking • 用模型組合模型

09 集成的代價 • 什麼時候不該用

10 異常有三種型態 • 點・情境・集體

11 異常偵測方法分類 • 統計・密度・模型・監督式

12 LOF 與 Isolation Forest • 兩個主力演算法

13 無標籤怎麼評估 • 異常偵測最大的難題

14 關聯規則三指標 • 以及 lift 陷阱

15 Apriori 與 FP-Growth • 兩種頻繁項目集演算法

16 醫療應用：共病與處方 • 購物籃分析的延伸

17 時間序列基礎 • 切分、滯後特徵、分解

18 機率校準 • 模型說 70% 真的是 70% 嗎

19 代價敏感學習 • 錯在哪一邊代價不同

20 AI Studio 實作 • 四個主題各一個範例

為什麼要有這一週：單一模型的四個天花板（上）

① 再怎麼調參，單一模型就是有極限

- 決策樹調到最好，仍然不穩定：換一批資料，樹就長得完全不同
- 邏輯斯迴歸再怎麼加特徵，也畫不出複雜的非線性邊界
- ★ 這時要換的不是「更強的模型」，而是「用一群模型」

② 有些問題根本沒有標籤

- 異常事件、設備故障、詐欺通常只有少量、延遲或不完整的異常標籤
- 標註夠多時，就改用監督式分類（ M2-2 ）
- ★ 標註稀少時， M2 那套監督式方法很難直接套用

這兩點對應本模組的 PART 1–3： 集成與異常偵測。

為什麼要有這一週：單一模型的四個天花板（下）

③ 有些問題不是在「預測」，而是在「發現」

- 「哪些藥常常一起開？」「哪些診斷常常同時出現？」
- 沒有 Y 可以預測，你要的是資料裡的結構
- 這類問題屬於關聯規則的範疇

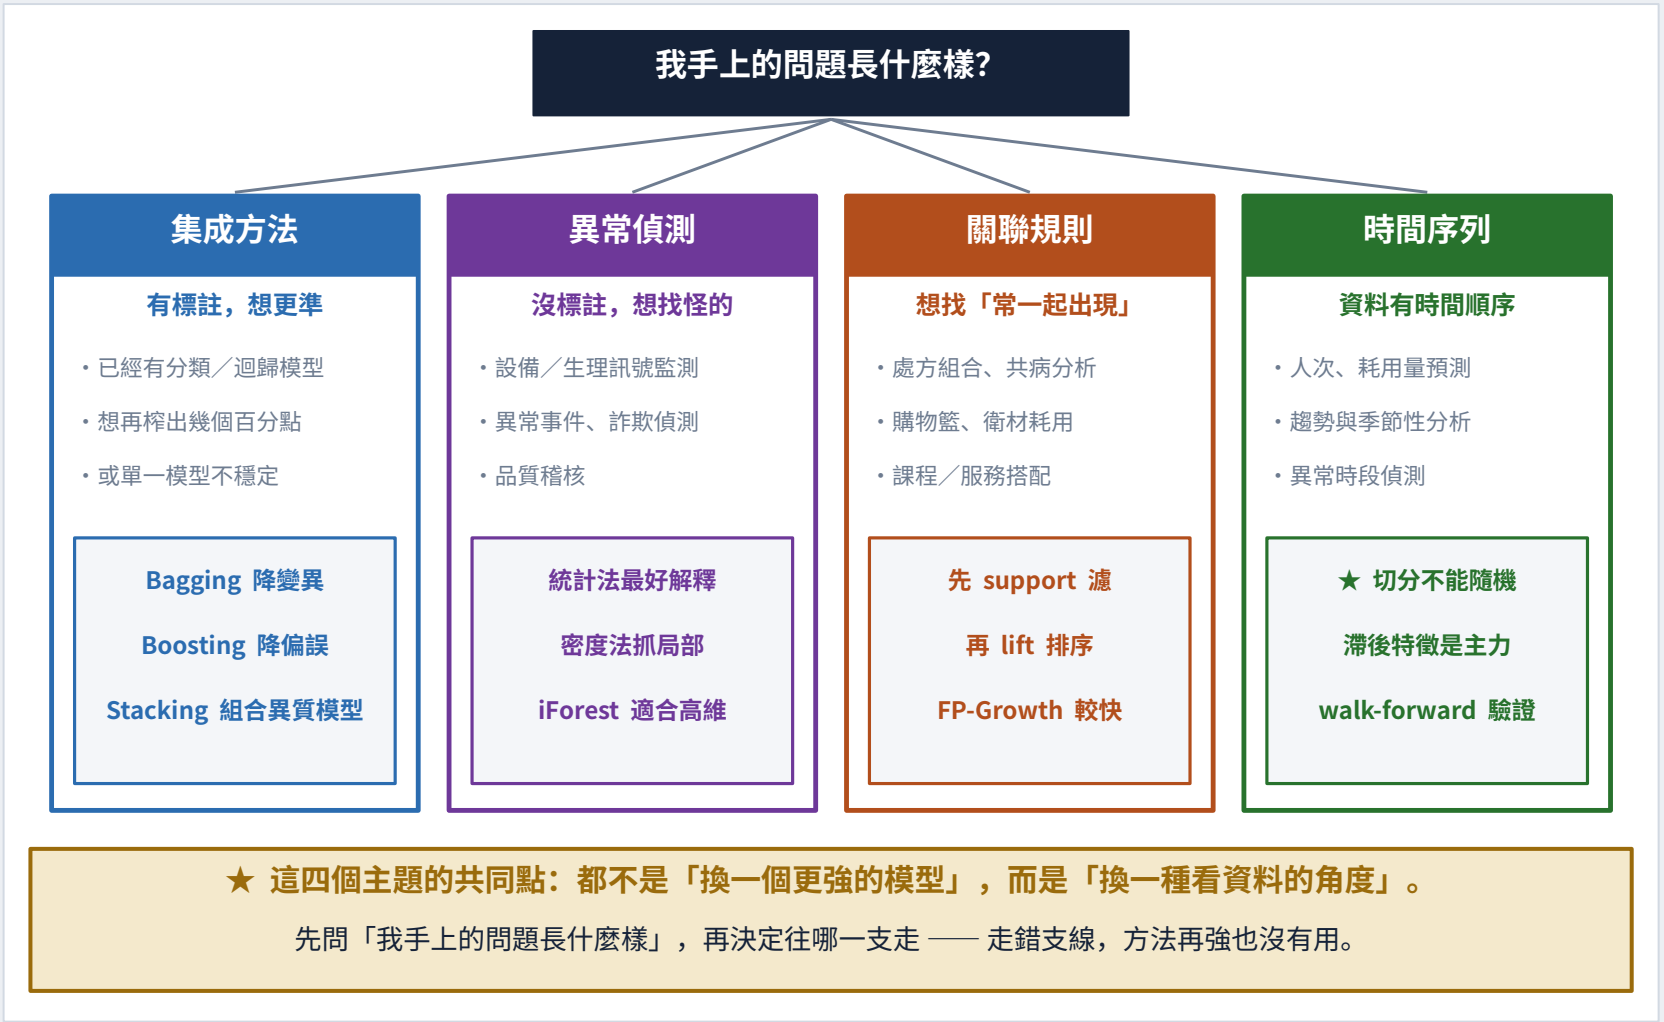
④ 有些資料有時間順序，不能亂切

- ★ 用未來的資料預測過去，是資料科學最常見也最嚴重的錯誤之一
- M2 用的 Split Data 隨機（shuffled）切分，在這裡是災難
- 時間序列需要完全不同的切分與驗證方式

這兩點對應 PART 4–5：關聯規則與時間序列。四者的共同點是「換一種看資料的角度」。

四大主題的選用地圖

這張圖建議印出來貼著；本模組所有內容都掛在這四支上



★ 這四個主題的共同點：都不是「換一個更強的模型」，而是「換一種看資料的角度」。

先問「我手上的問題長什麼樣」，再決定往哪一支走 —— 走錯支線，方法再強也沒有用。

有標註、想更準

集成方法。已經有模型了，想再榨出幾個百分點。

沒標註、想找怪的

異常偵測。設備監測、異常事件、品質稽核。

想找「常一起出現」

關聯規則。處方組合、共病分析、衛材耗用。

資料有時間順序

時間序列。★ 切分方式與前三者完全不同。

★ 原生圖形，可直接在 PowerPoint 編輯

PART 01

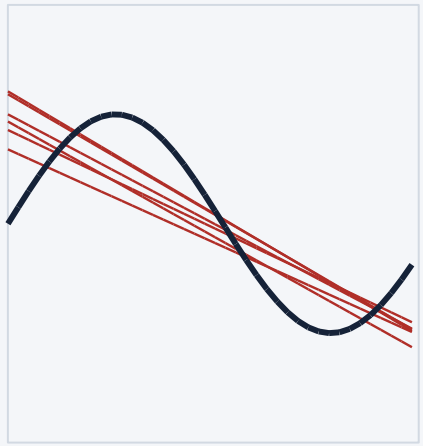
集成為什麼有效

Why Ensembles Work

在學怎麼用之前，先弄懂它在解什麼問題。
這一節的觀念決定你之後會不會用錯。

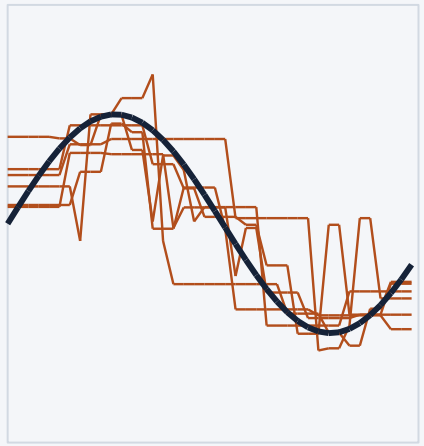
偏誤—變異分解：集成到底降低了什麼

高偏誤・低變異
模型太簡單（單一淺樹）



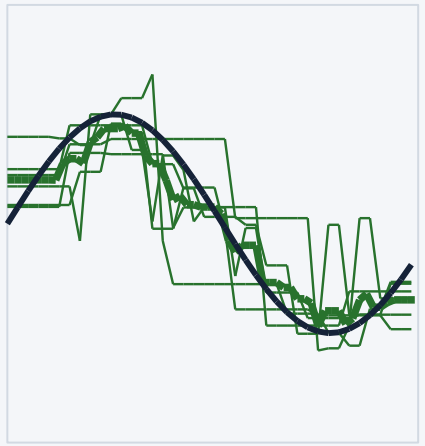
欠擬合：怎麼抽樣都畫成同一條直線，離真相很遠

低偏誤・高變異
模型太複雜（單一深樹）



過擬合：每次抽樣結果差很多，抓到的是雜訊

低偏誤・低變異
集成（多棵樹平均）



★ 集成的目標：保留彈性，但把抖動平均掉

真實關係　六次不同抽樣訓練出的模型（細線）　**六個模型的平均（集成）**

三張圖的真實關係（深色粗線）完全相同，差別只在模型的複雜度。左邊怎麼抽樣都畫成同一條直線＝偏誤大；中間每次抽樣差很多＝變異大；右邊把中間那六條平均起來，抖動互相抵消，就回到真實關係附近。

偏誤 Bias

模型太簡單，系統性地偏離真相。
表現：訓練與測試都不好（欠擬合）。

變異 Variance

模型太複雜，對訓練資料的抖動過度敏感。
表現：訓練很好、測試很差（過擬合）。

★ 一句話記住

Bagging 常藉平均降低變異； Boosting 常先改善偏誤，但正則化、樹深與資料雜訊也會影響兩者。

怎麼用這句話

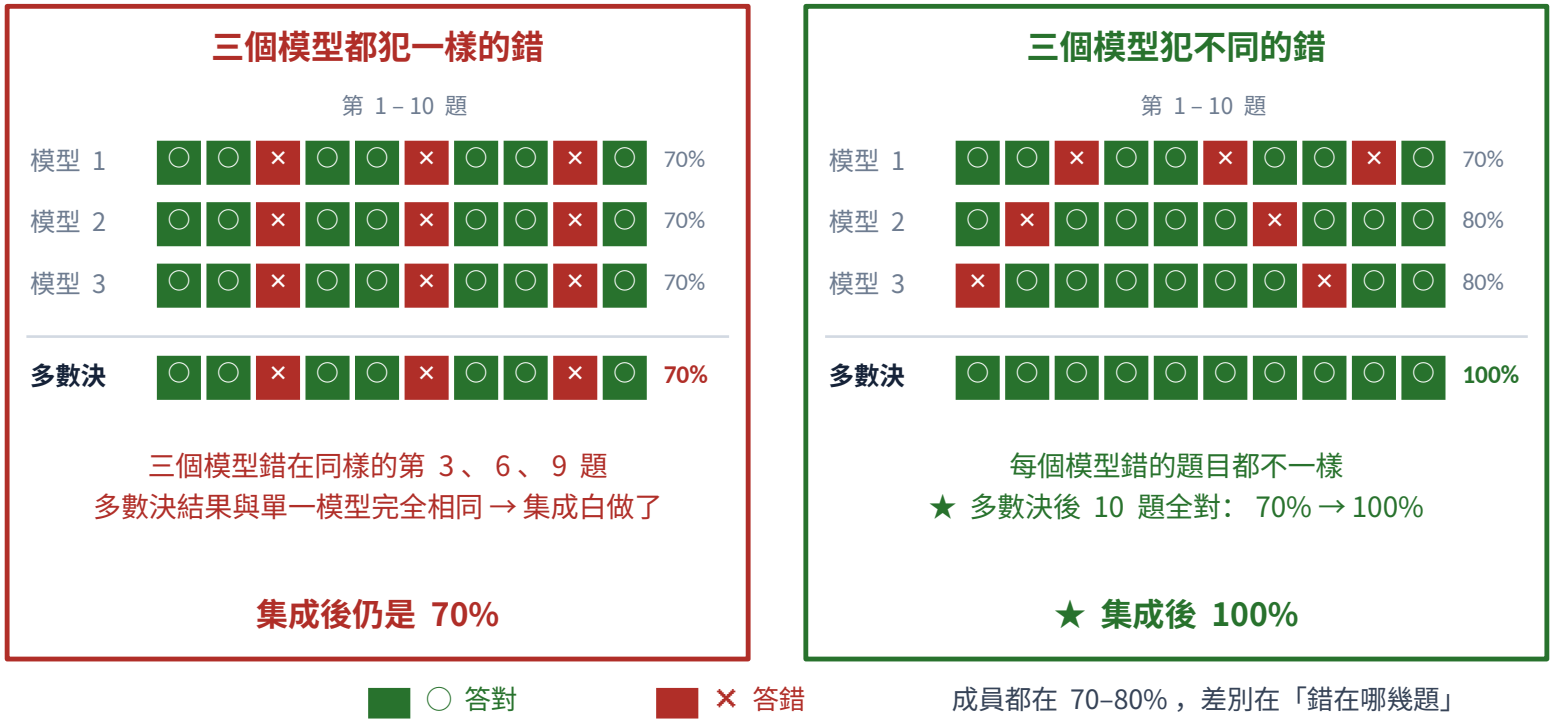
模型不穩定（換資料結果差很多）→ 用 Bagging。
模型太弱（怎麼調都不準）→ 用 Boosting。

先診斷再開藥：三種症狀對應三種處方

症狀	訓練分數	測試分數	診斷	處方
兩邊都差	0.68	0.66	高偏誤（欠擬合）	★ 換更強的模型、加特徵、用 Boosting
訓練好測試差	0.99	0.71	高變異（過擬合）	★ 減少複雜度、加正則化、用 Bagging／隨機森林
兩邊都好但不穩	0.91	0.88 （ ±0.09 ）	變異偏高	集成可降低波動；同時檢查資料量是否太少
兩邊都好且穩定	0.91	0.89 （ ±0.02 ）	健康	不需要集成。★ 別為了用而用

★ 「測試分數 ± 」是交叉驗證各折的標準差。只看平均值看不出穩不穩定——這是最常被忽略的一欄。

集成的前提：成員必須「錯得不一樣」



★ 集成能不能變強，取決於成員「錯得不一樣」——這叫多樣性（ Diversity ）。

三種手段：抽不同的樣本（ Bagging ）、抽不同的特徵（ Random Forest ）、用不同演算法（ Voting ／ Stacking ）。

左邊：三個模型犯一樣的錯

多數決之後準確率完全沒變。集成白做了。

右邊：三個模型犯不同的錯

多數決之後 70% → 100% 。

★ 這叫多樣性 Diversity

集成能不能變強，取決於成員錯得夠不夠不一樣。

製造多樣性的三種手段

抽不同樣本（ Bagging ）、抽不同特徵（ Random Forest ）、
用不同演算法（ Voting ／ Stacking ）。

★ 原生圖形，可直接在 PowerPoint 編輯

多樣性與準確度的取捨：集成的核心張力

成員要夠準，但也要夠不一樣

- 全部都很準但完全一樣 → 集成沒有增益（左圖的情況）
- 全部都很不一樣但都很爛 → 多數決也是爛的
- ★ 理想：每個成員都「比隨機猜好一點」，且彼此錯得不一樣

為什麼弱學習器（ weak learner ）反而好用

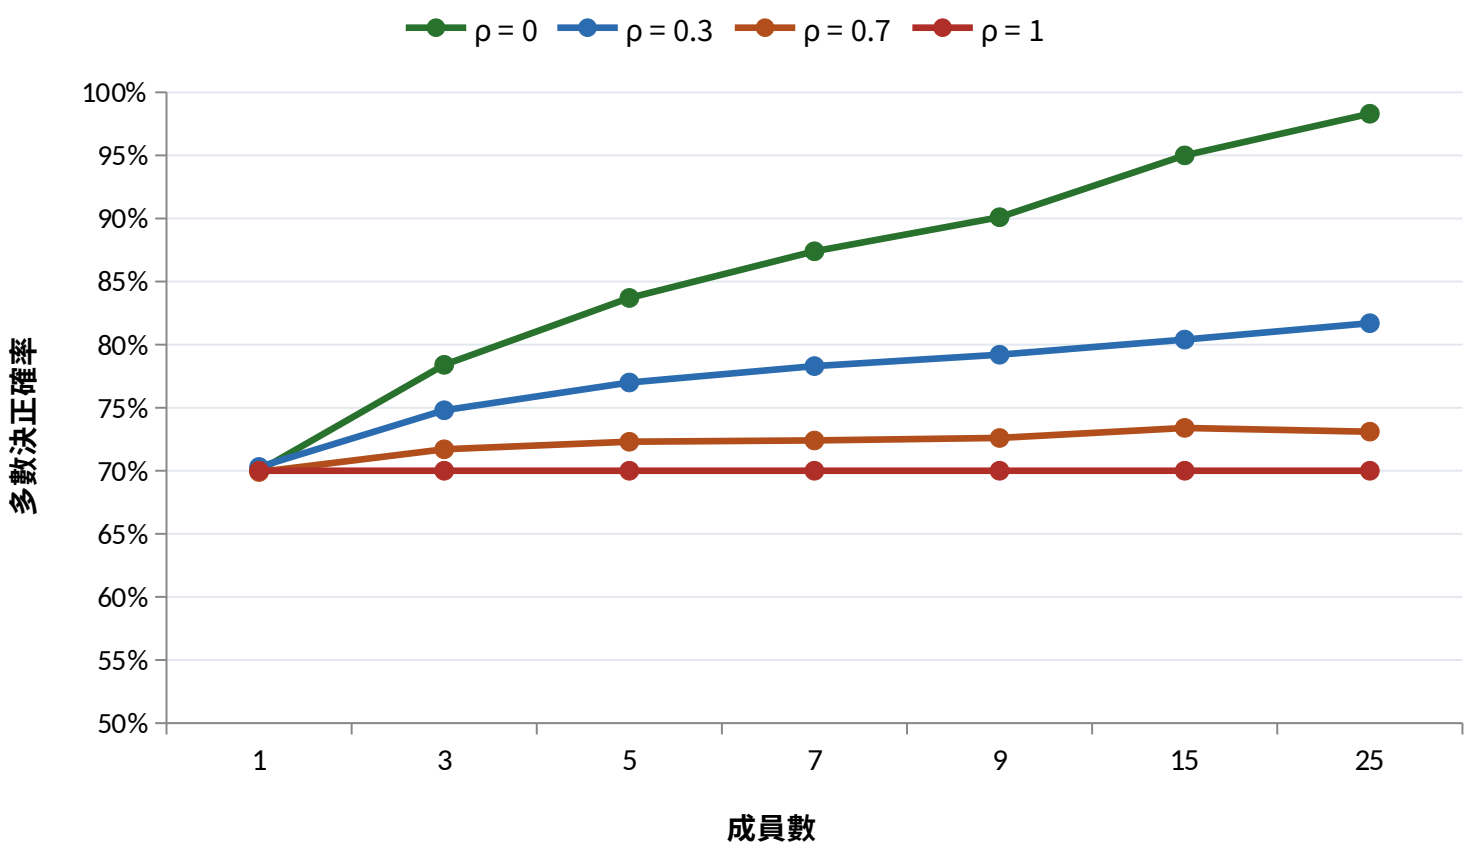
▶ Boosting 刻意用很淺的樹（甚至只有一層，叫決策樁 Decision Stump ）

- 淺樹很弱，但每棵專注在不同的錯誤上 → 多樣性天然就高
- ★ 這解釋了一個反直覺的現象：多個較弱但互補的模型，可以組成表現很強的模型

怎麼檢查你的集成有沒有多樣性

- 看成員之間的預測相關性：相關係數接近 1 就表示白做工
- 看各成員的錯誤是不是集中在同一批樣本上
- 實務簡易法：拿掉任一成員，整體分數幾乎不變 → 那個成員是多餘的

實例：成員數與錯誤相關性——集成能好到哪裡



錯誤彼此獨立（ρ = 0）

每個成員只有 70%， 25 個投票就到 98%。

中度相關（ρ = 0.3）

25 個只到 82%—— 增益很快飽和。真實的樹與樹大多在這一帶。

錯得一模一樣（ρ = 1）

成員再多都是 70%。所以 Bagging 抽資料、隨機森林抽特徵，目的都是降低 ρ。

模擬：每個成員單獨正確率 70%，成員之間的錯誤相關為 ρ（ρ = 0 與 1 為精確值，其餘為 4 萬次模擬）。多樣性才是集成的燃料：與其多加幾個相似的成員，不如換一個原理不同的成員。

PART 02

集成方法的完整分類

Taxonomy of Ensemble Methods

三大家族、十幾種方法，但分辨它們只需要問一個問題。

集成方法完整分類圖



★ 分辨三者最快的方法：問「第 N 個模型訓練時，需不需要知道前 N−1 個的結果？」

不需要 → 平行（Bagging 家族） ｜ 需要 → 序列（Boosting 家族） ｜ 需要，但只用它們的「預測值」→ Stacking

平行 Parallel

各成員獨立訓練，互不知道彼此 → 降低變異。

Bagging 、隨機森林、 Extra Trees 。

序列 Sequential

後者專門修正前者的錯 → 降低偏誤。
AdaBoost 、 Gradient Boosting 、 XGBoost 家族。

異質 Heterogeneous

組合不同型態的模型。
Voting 、 Stacking 。

★ 一句話分辨

問「第 N 個模型訓練時，需不需要知道前 N−1 個的結果？」
不需要＝平行；需要＝序列；只用它們的預測值＝ Stacking 。

原講義： Ensemble Learning.pdf ★ 原生圖形，可直接在 PowerPoint 編輯

Bagging 家族：三種方法的差別

方法	抽樣本	抽特徵	分裂點選擇	特點
Bagging	★ 有放回抽樣（Bootstrap）	全部使用	找最佳分裂點	最基本的形式；可搭配任何模型
隨機森林 Random Forest	★ 有放回抽樣	★ 每次分裂隨機抽部分特徵（sklearn $\sqrt{p}$； AI Studio 預設 log(p)+1）	在抽到的特徵中找最佳	多樣性更高；分類問題的預設起點
Extra Trees	通常用全部資料	每次分裂隨機抽	★ 分裂點也隨機取，不找最佳	更快、變異更低，但偏誤略高

★ 注意隨機森林的兩層隨機：抽樣本 ＋ 抽特徵。第二層才是它比單純 Bagging 強的原因——它強迫每棵樹用不同的特徵，多樣性大增。

Bootstrap 抽樣：那 36.8% 是怎麼來的

有放回抽樣的數學

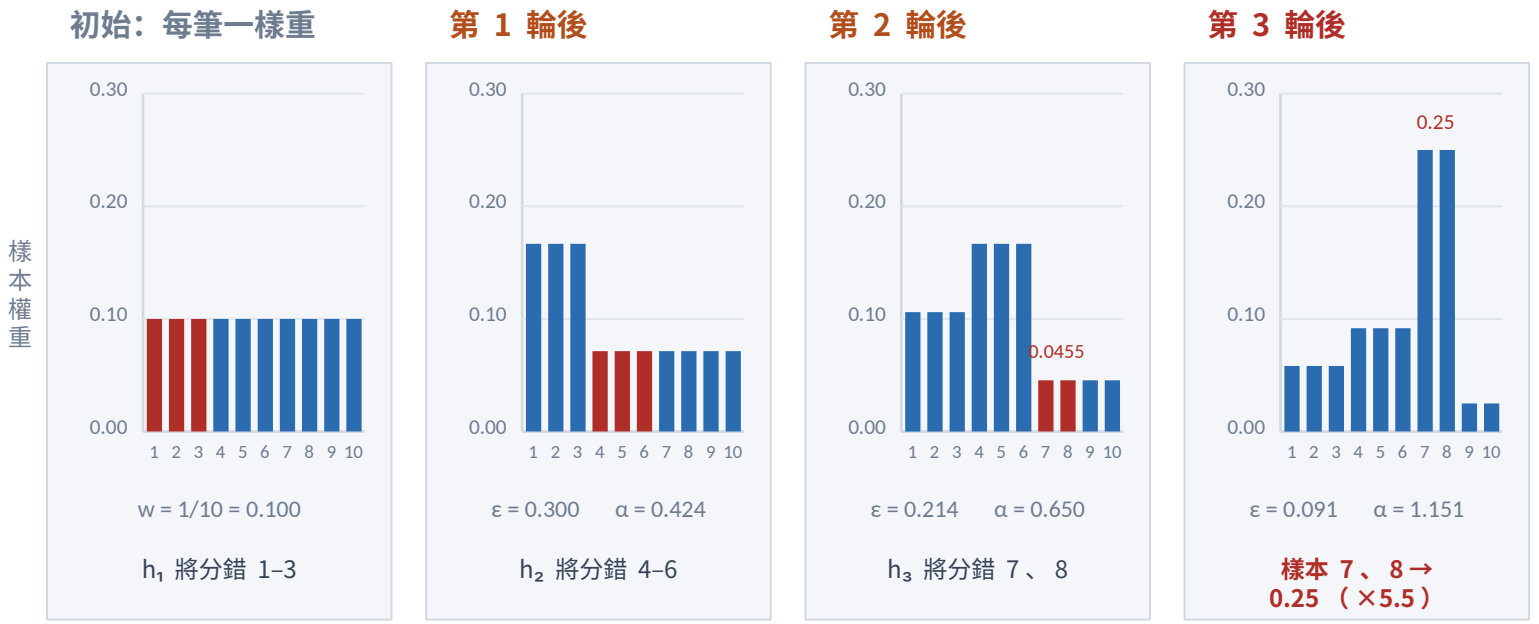
- n 筆資料中抽 n 次（有放回），某一筆從沒被抽到的機率：
- $(1 - 1/n)^n \rightarrow$ 當 n 夠大時趨近 $1/e \approx 0.368$
- ★ 所以平均約有 36.8% 的資料從未進入某棵樹的訓練集
- 這批資料就叫「袋外樣本」（Out-of-Bag, OOB）

OOB 的實用價值

- ★ 免費的驗證集：不用切出 validation set 就能評估
- 每棵樹用「它沒看過的那 36.8%」評估，再平均
- 資料量少的時候特別有用——不必犧牲資料去做驗證
- AI Studio 的 Random Forest 運算子可直接輸出 OOB 誤差

※ 驗算：n=100 時 $(1-0.01)^{100} = 0.366$；n=1000 時 $= 0.3677$；$n \to \infty$ 時 $= 1/e = 0.3679$。

AdaBoost 實際跑三輪：權重怎麼變



ε 逐輪下降（0.300 → 0.214 → 0.091），α 逐輪上升（0.424 → 0.650 → 1.151）——越準的分類器票數越重。
但被反覆放大的那兩筆若其實是標錯的資料，AdaBoost 就會越陷越深。

每一輪做兩件事

① 訓練一個弱分類器　② 把它分錯的樣本權重調高

分類器權重 α

$\alpha = 0.5 \times \ln((1-\varepsilon)/\varepsilon)$。錯誤率越低，α 越大，
最終投票的話語權越重。

★ 看第 3 輪

樣本 7、8 的權重從 0.0455 放大到 0.25（5.5 倍）。
下一個分類器會被迫專心對付它們。

為什麼降低偏誤

每一輪都在補前面的不足，整體逐步逼近真相。
代價是對雜訊與離群值敏感。

原講義： Ensemble Learning.pdf　★ 原生圖形，可直接在 PowerPoint 編輯

AdaBoost 手算：完整三輪（數值已驗算）

10 筆樣本，每輪一個弱分類器

手算（已用 Python 驗算）

【初始】每筆樣本權重 $w = 1/10 = 0.100$

【第 1 輪】弱分類器 h_1 分錯樣本 {1, 2, 3}
加權錯誤率 $\varepsilon_1 = 0.1 + 0.1 + 0.1 = 0.300$
分類器權重 $\alpha_1 = 0.5 \times \ln((1-0.300)/0.300) = 0.5 \times \ln(2.333) = 0.4236$
更新權重：分錯者 $\times e^{\alpha_1}$、分對者 $\times e^{-\alpha_1}$，再正規化
→ 分錯的三筆：0.100 → 0.1667（放大 1.67 倍）
→ 分對的七筆：0.100 → 0.0714

【第 2 輪】h_2 分錯樣本 {4, 5, 6}
$\varepsilon_2 = 0.0714 \times 3 = 0.2143$ （用「更新後」的權重算）
$\alpha_2 = 0.5 \times \ln((1-0.2143)/0.2143) = 0.6496$
→ 分錯的三筆：0.0714 → 0.1667（放大 2.33 倍）

【第 3 輪】h_3 分錯樣本 {7, 8}
$\varepsilon_3 = 0.0455 \times 2 = 0.0909$
$\alpha_3 = 0.5 \times \ln((1-0.0909)/0.0909) = 1.1513$
→ 分錯的兩筆：0.0455 → 0.2500（放大 5.50 倍）

【最終預測】$H(x) = \text{sign}(0.4236 \cdot h_1(x) + 0.6496 \cdot h_2(x) + 1.1513 \cdot h_3(x))$

★ 觀察三件事：
① ε 逐輪下降是本例刻意設計；實務上題目越來越難，ε 常回升——整體好壞要看 H(x) 的誤差
② α 逐輪上升（0.424 → 0.650 → 1.151）—— 越準的分類器票數越重
③ 但若資料中有標錯的樣本，它會被一路放大 → 這是 AdaBoost 的弱點

Boosting 家族的演進：每一代解決了什麼

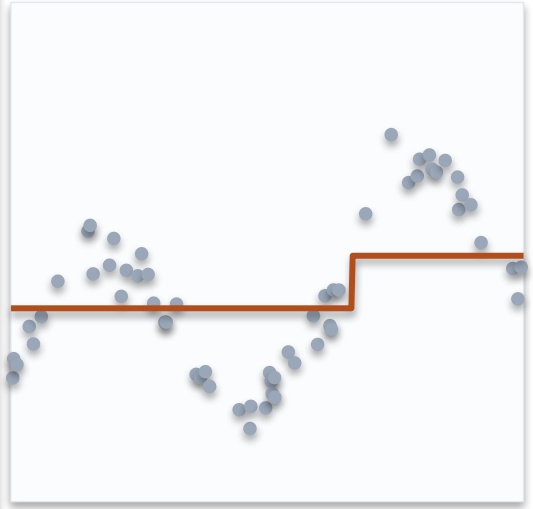
方法	核心作法	解決了什麼	留下什麼問題
AdaBoost 1997	調整「樣本權重」，讓後續分類器專注在錯誤上	讓「弱可組成強」（Schapire 1990 的理論）變得實用	★ 對雜訊與標錯的資料極敏感
Gradient Boosting 2001	改成擬合「殘差」（前面模型的誤差）	可用於任意可微損失函數；迴歸分類皆適用	訓練慢，且容易過擬合
XGBoost 2014	加入正則化項、二階導數、平行化	★ 速度與精度大幅提升，成為競賽主流	記憶體用量大
LightGBM 2017	逐葉生長、直方圖分箱、 GOSS 抽樣	★ 大資料快很多倍	小資料容易過擬合
CatBoost 2018	Ordered Boosting 、原生處理類別特徵	★ 類別型特徵不用自己做編碼，且避免目標洩漏	訓練較慢

★ 醫療資料常有大量類別型特徵（科別、診斷碼、藥品碼）， CatBoost 往往是很好的預設選擇。 AI Studio 內建 Gradient Boosted Trees ；LightGBM 、 CatBoost 需透過 Python 。

實例：梯度提升一棵一棵擬合殘差

1 棵決策樁

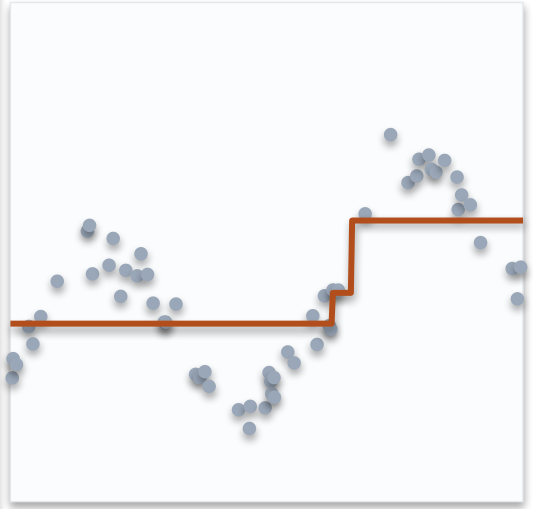
訓練 RMSE = 1.86



第一棵只能切一刀：全部資料被分成左右兩個平均。

3 棵決策樁

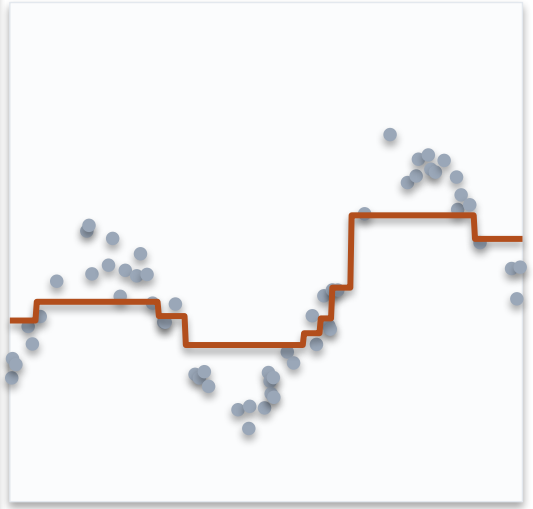
訓練 RMSE = 1.56



每一棵都去擬合「前面還沒解釋的殘差」，線開始彎。

10 棵決策樁

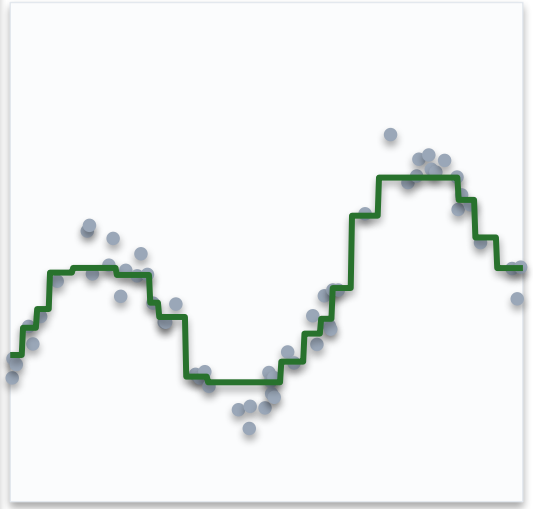
訓練 RMSE = 1.18



十棵後已抓到大致的波形，殘差越來越小。

50 棵決策樁

訓練 RMSE = 0.50

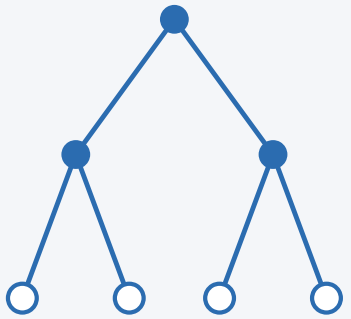


五十棵後幾乎貼著資料——再加下去就開始記雜訊。

每一棵決策樁（深度 1 的樹）都很弱，但每次只修正前面剩下的誤差，學習率 0.4 控制每一步修多少。學習率越小，需要的棵數越多，但比較不會過擬合（見第 20 張）。（模擬資料 60 筆）

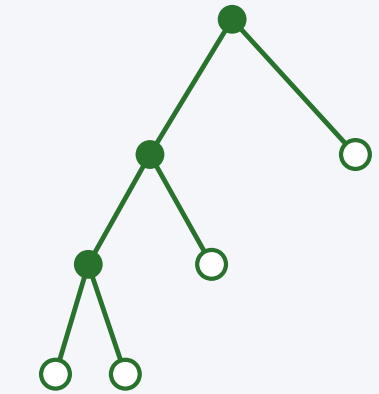
GBDT 三大實作的分裂策略

XGBoost
逐層生長 Level-wise



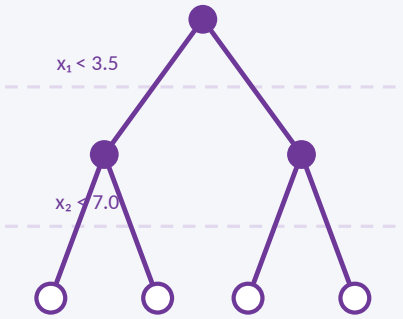
整層一起長，樹形對稱
穩定、不易過擬合，但會長出沒用的分支

LightGBM
逐葉生長 Leaf-wise



一路往這邊深長
★ 每次挑「增益最大」的葉子往下長
同樣葉數下更準更快，小資料易過擬合

CatBoost
對稱樹 Symmetric



同一層用同一個切分條件
預測極快，對類別型特徵處理最好

● 實心＝分裂節點　● 空心圈＝葉節點　三棵樹的葉數相同，長法不同

同樣是梯度提升，差別只在「下一刀切哪裡」。逐層生長把整層補滿（對稱但浪費）；逐葉生長只挑增益最大的那片葉子（不對稱但有效率）；對稱樹整層共用一個條件（預測最快）。

XGBoost 逐層生長

整層一起長，樹形對稱。穩定、不易過擬合，

但會長出沒用的分支。

★ LightGBM 逐葉生長

每次挑「增益最大」的葉子長。同樣葉數下更準更快，
但小資料容易過擬合（要限制 max_depth ）。

CatBoost 對稱樹

同一層用同一個切分條件。預測極快，
且對類別型特徵處理最好。

選用建議

資料大又趕時間 → LightGBM ； 類別特徵多 → CatBoost ；
要穩定、文件齊全 → XGBoost 。

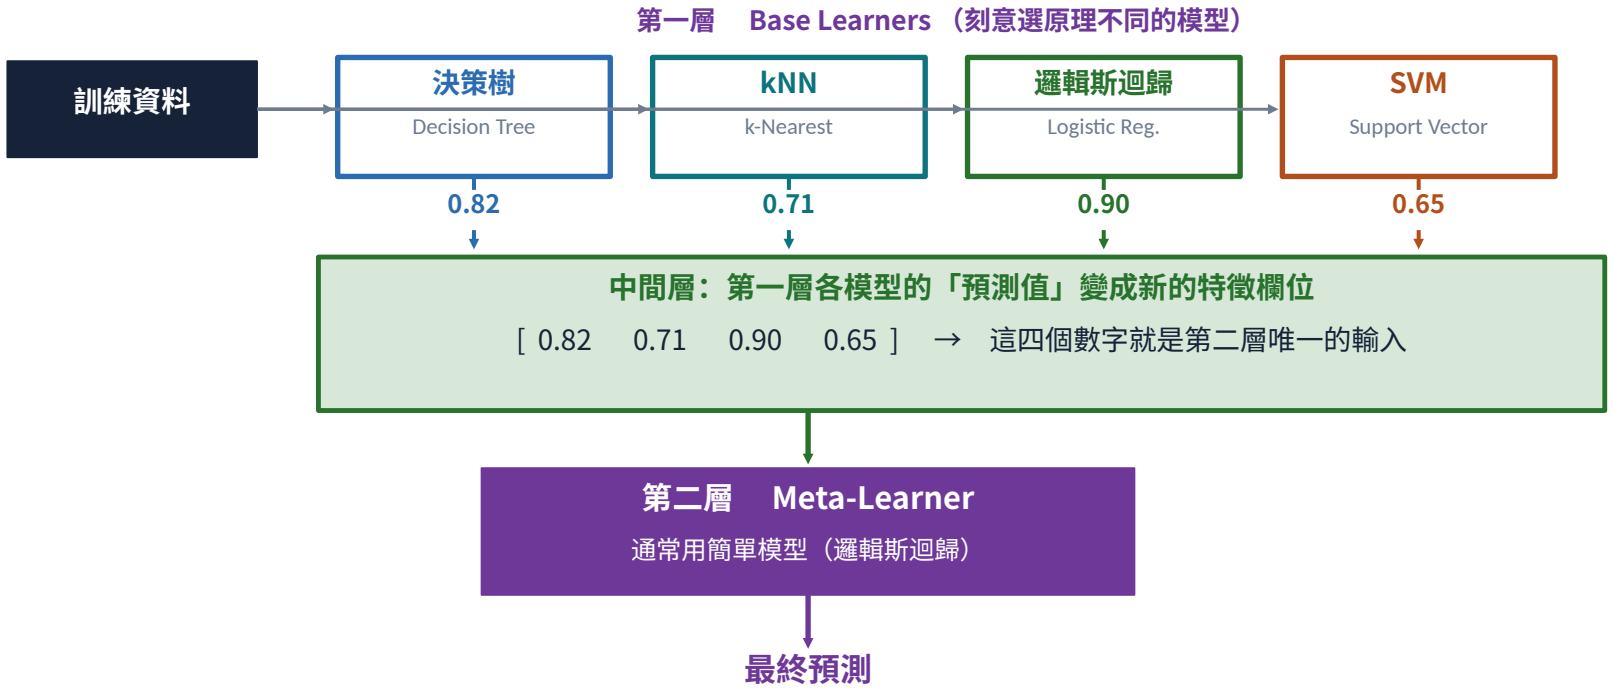
★ 原生圖形，可直接在 PowerPoint 編輯

Boosting 的關鍵參數：學習率與棵數的交易

參數	作用	調小會怎樣	調大會怎樣	建議起點
learning_rate **學習率**	每棵樹的貢獻比例	更穩、更準，但需要更多棵樹	訓練快，但容易錯過最佳解	0.05 – 0.1
n_estimators **樹的數量**	總共長幾棵	欠擬合	過擬合（但有早停就還好）	★ 設大一點 + 早停
max_depth **樹深**	單棵樹的複雜度	欠擬合	過擬合、訓練慢	3 – 6 （比隨機森林淺）
subsample **樣本抽樣比例**	每棵樹用多少資料	多樣性高但可能欠擬合	接近 1 就失去隨機性	0.8
early_stopping **早停**	驗證分數不再進步就停	—	—	★ 一定要開，這是最有效的防過擬合手段

★ 學習率與棵數是一組交易：學習率減半，棵數大致要加倍。實務做法是固定一個小學習率（ 0.05 ），然後用早停決定棵數。

Stacking： 用一個模型來組合其他模型



★ 最關鍵的一件事

第一層的預測值必須用「交叉驗證的 out-of-fold 預測」產生，不能用它訓練過的資料。

否則第二層學到的是「第一層記住答案」這件事 → 嚴重資料洩漏，驗證分數虛高、上線就崩。

這也是 Stacking 最容易做錯的一步：流程對了才有價值，做錯比不用還糟。

第一層

數個不同型態的模型各自預測。
刻意選「原理不同」的模型以製造多樣性。

中間層

把第一層的預測值當成新的特徵欄位。

第二層 Meta-Learner

通常用簡單模型（邏輯斯迴歸）學「怎麼組合」。

★ 最關鍵的一件事

第一層的預測值必須用交叉驗證的 out-of-fold 預測產生。
用它訓練過的資料 → 嚴重資料洩漏，上線就崩。

原講義： Ensemble Learning.pdf ★ 原生圖形，可直接在 PowerPoint 編輯

三種異質集成的比較

方法	怎麼組合	需要調什麼	什麼時候用
硬投票 **Hard Voting**	看誰的票多（多數決）	成員的選擇	成員表現接近、都輸出類別時
軟投票 **Soft Voting**	把各成員的機率平均	成員的選擇 ＋ 權重	若機率可比較，常比硬投票更有效，因為保留信心程度
Stacking	訓練一個模型來學「怎麼組合」	成員 ＋ meta 模型 ＋ CV 折數	組合潛力高，但不保證最佳；複雜度與洩漏風險最高

★ 實務順序：先試軟投票（簡單、不易出錯）。只有在軟投票明顯不夠、且你有時間仔細處理 out-of-fold 時，才上 Stacking。

軟投票 vs 硬投票：一個會改變結論的差別

三個模型對同一位病人「30 天內再入院」的預測

模型	預測機率 P(再入院) 0——1	硬投票的票	信心程度
決策樹	0.55	是	勉強過半
kNN	0.52	是	勉強過半
邏輯斯迴歸	0.10	否	非常確定

判定門檻 0.5

硬投票 Hard Voting

票數：是 2 票、否 1 票

→ 判定：是（會再入院）

★ 兩張「勉強過半」的票，蓋過了一張「非常確定」的票

支持比例 2/3

軟投票 Soft Voting

平均機率 = (0.55 + 0.52 + 0.10) / 3 = 0.39

→ 判定：否（不會再入院）

★ 保留了「有多確定」的資訊，結論完全相反

平均機率 0.39

★ 同一組模型、同一位病人，兩種投票法給出相反的答案。

實務建議：只要成員模型能輸出機率，優先用軟投票（前提是機率可比較）。硬投票丟掉的「信心程度」往往正是關鍵資訊。

硬投票

票數 2:1 → 判定「會再入院」。
★ 兩張「勉強過半」的票蓋過一張「非常確定」的票。

軟投票

平均機率 0.39 → 判定「不會」。結論完全相反。

★ 實務建議

只要成員能輸出機率，優先用軟投票。
硬投票丟掉的「信心程度」往往正是關鍵資訊。

但有前提

各成員的機率必須是「可比較的」——
這就帶到下一個主題：機率校準。

★ 原生圖形，可直接在 PowerPoint 編輯

集成的代價：什麼時候不該用（上）

① 可解釋性大幅下降

- 單棵決策樹可以印出來給臨床看； 100 棵樹不行
- ★ 醫療場域若需要逐案解釋判斷依據，集成會是障礙
- 折衷：用 SHAP 等事後解釋工具（ M9 會談），但那是另一層近似

② 訓練與預測成本上升

- 訓練時間乘上成員數；預測時每一筆都要跑過所有成員
- 即時性要求高的場景（如床邊監測）要先確認延遲可接受

這兩點是「用了會付出什麼」。

集成的代價：什麼時候不該用（下）

③ 單一模型已經夠好的時候

- ★ 如果邏輯斯迴歸 AUC 0.88 、集成 0.89 ，那 0.01 值得嗎?
- 多花的維運成本、失去的可解釋性，通常不值得
- 先問「這 0.01 會改變任何臨床決策嗎」

④ 資料本身有問題的時候

- 集成放大不了不存在的訊號。資料髒、標註爛、特徵沒訊息量——
- ★ 換再厲害的集成也救不回來。回去修資料，那才是投報率最高的事

★ 這兩點是「根本不該用」的情況。集成是工具不是目標，會用也要會判斷什麼時候不用。

實作 1 ｜ Titanic 集成模型比較

【AI Studio 範例】 Ensemble - bagging vote stacking Adaboost.rmp

開啟檔案

```
Repository ▸ 3. Outlier and Ensemble/
  Ensemble - bagging vote
    stacking Adaboost.rmp
  Titanic.rmhdf5table
  WineData.rmhdf5table
```

★ 此範例一次示範四種集成，
是本模組最重要的檔案

預期結果

- Bagging 的標準差明顯小於單一決策樹
- AdaBoost 常能提升平均，但對雜訊敏感
- 軟投票通常略優於硬投票
- 哪種最好因資料而異； Stacking 訓練時間最長

操作步驟

1. 先跑單一決策樹，記錄準確率與各折標準差（基準線）
2. 跑 Bagging （10 個成員），比較準確率「與標準差」的變化
3. ★ 重點看標準差： Bagging 主要降的是變異，不一定拉高平均
4. 跑 AdaBoost，觀察它在哪些樣本上反覆調權重
5. 跑 Vote （決策樹＋ kNN ＋邏輯斯迴歸），比較硬投票與軟投票
6. 跑 Stacking，注意 meta-learner 的設定
7. 把五種結果做成一張表：準確率、標準差、訓練時間

PART 03

異常偵測

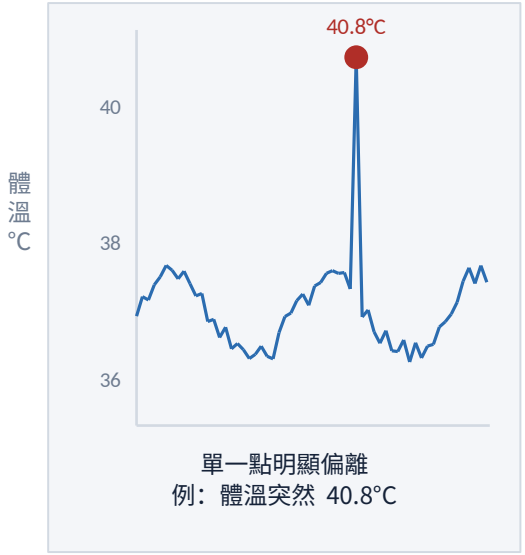
Anomaly Detection

當你沒有標籤，卻要找出「不對勁」的東西。
這是醫療與設備監測領域最實用的一類方法。

異常有三種型態，偵測方法完全不同

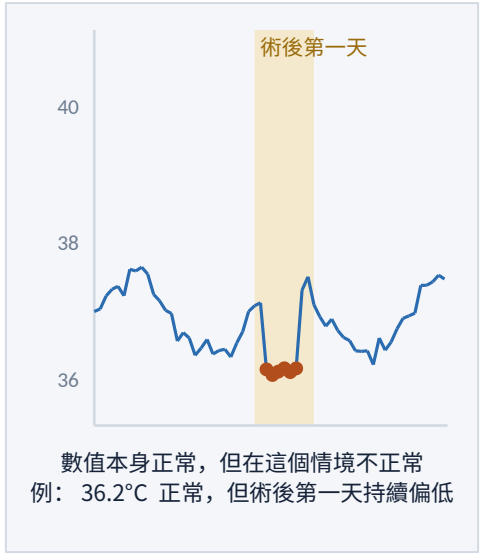
以體溫監測為例

① 點異常　Point



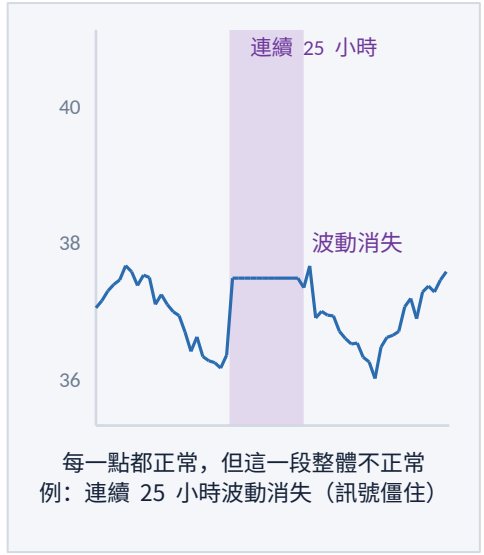
單一點明顯偏離
例：體溫突然 40.8°C

② 情境異常　Contextual



數值本身正常，但在這個情境不正常
例： 36.2°C 正常，但術後第一天持續偏低

③ 集體異常　Collective



每一點都正常，但這一段整體不正常
例：連續 25 小時波動消失（訊號僵住）

三張圖的橫軸都是「連續 120 小時」，縱軸都是體溫（°C）

★ 先分辨你要抓的是哪一種。多數人只想到①，但臨床上②③往往更重要，也更難抓。

① 只要看單點數值；②必須先建立「情境」（術後第幾天、哪個班別）；③必須看一整段區間的統計特性。

① 點異常

單一點明顯偏離。例：體溫突然 40.8°C 。
最容易抓，統計法就夠。

② 情境異常

數值本身正常，但在這個情境不正常。
例： 36.2°C 正常，但術後第一天持續偏低。

③ 集體異常

每一點都正常，但這一段整體不正常。
例：連續 25 小時波動消失（訊號僵住）。

★ 先分辨你要抓的是哪一種

多數人只想到①，但臨床上②③往往更重要，
也更難抓。

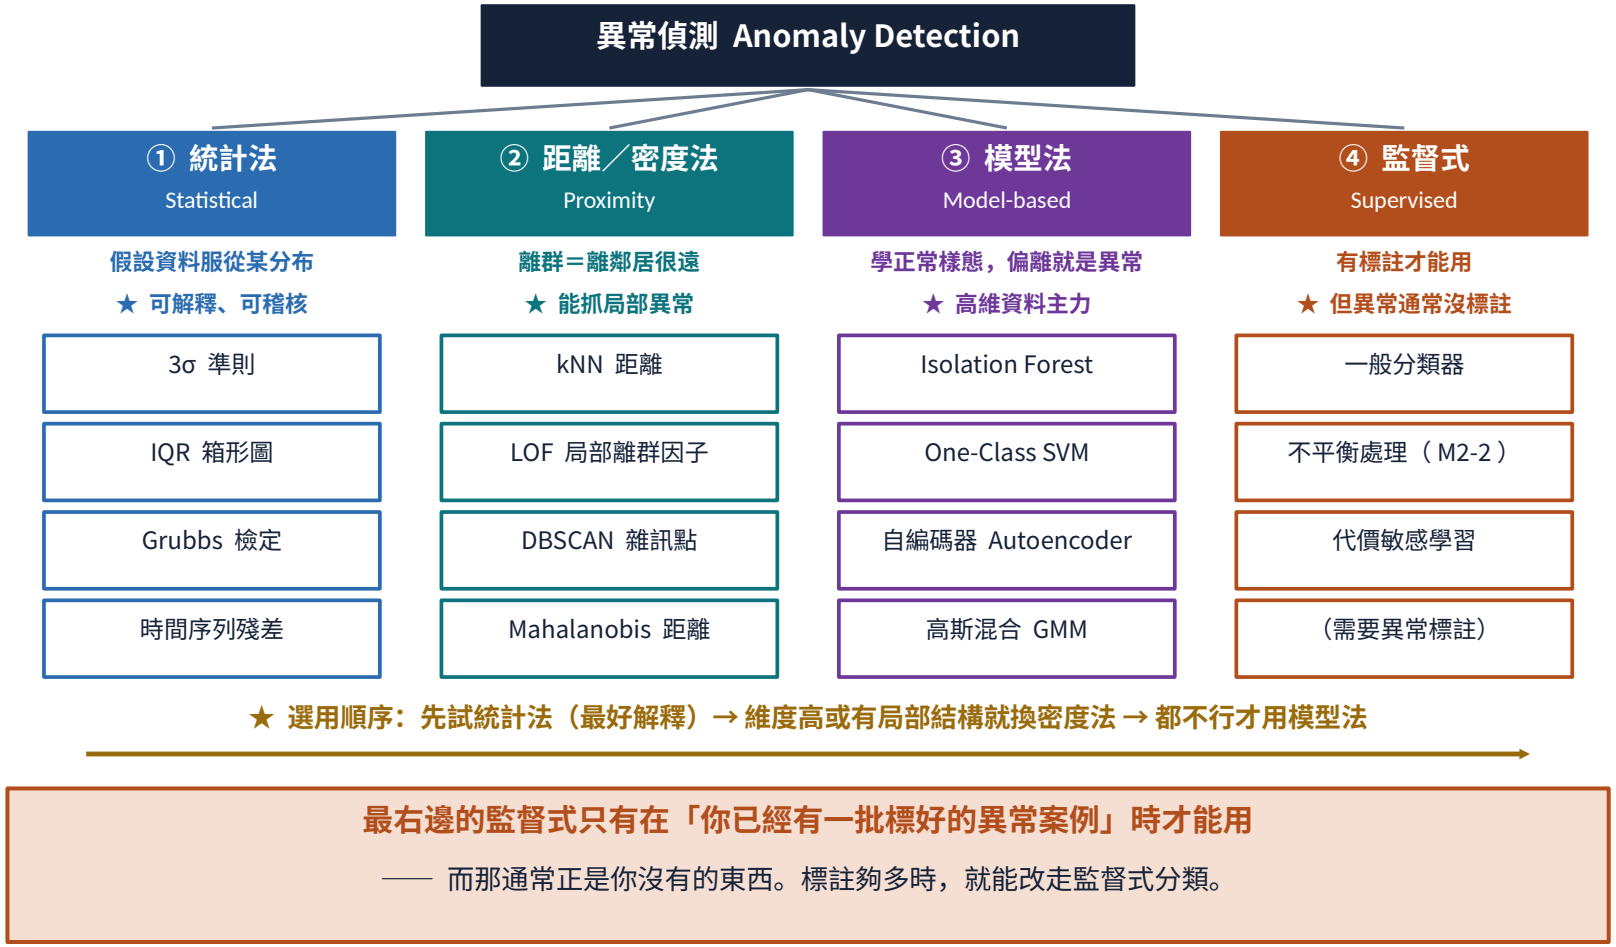
★ 原生圖形，可直接在 PowerPoint 編輯

三種異常型態的偵測策略

型態	怎麼抓	需要什麼	醫護場域的例子
點異常	統計門檻（3σ、IQR）、距離法	單一時間點的數值	檢驗值超出參考範圍、給藥劑量異常
情境異常	★ 先分群或建立情境模型，再在情境內比較	情境變數（時段、術後天數、年齡層）	夜班的活動量、術後第 N 天的引流量
集體異常	看一段區間的統計特性（變異數、自相關）	★ 序列資料，不是單點	監測訊號僵住、連續數小時無紀錄

★ 第二列是實務上最有價值也最常被做錯的：把所有病人的數值混在一起算門檻，情境異常就完全抓不到。

異常偵測方法的完整分類



統計法

3σ 、 IQR 、 Grubbs 檢定。假設資料服從某分布。
★ 可解釋、可稽核——醫療場域的首選起點。

距離／密度法

kNN 距離、 LOF 、 DBSCAN 雜訊點。
★ 能抓局部異常。

模型法

Isolation Forest 、 One-Class SVM 、自編碼器。
★ 高維資料的主力。

★ 選用順序

先試統計法 → 維度高或有局部結構就換密度法 →
都不行才用模型法。

★ 原生圖形，可直接在 PowerPoint 編輯

統計法：三種門檻的實際計算與適用時機

看起來簡單，但選錯方法會漏掉一大半

統計法（數值為示範用）

【資料】某病房 30 天的日均給藥次數
平均 μ = 48.2　標準差 σ = 6.4　中位數 = 47.0　Q1 = 43.5　Q3 = 52.0

【方法一】 3σ 準則
上界 = μ + 3σ = 48.2 + 19.2 = 67.4
下界 = μ − 3σ = 48.2 − 19.2 = 29.0
✔️ 適用：資料接近常態分布
✖ 陷阱：★ μ 與 σ 本身會被離群值拉走 —— 一筆極端值就能讓門檻失效

【方法二】 IQR 箱形圖法（穩健，推薦預設）
IQR = Q3 − Q1 = 52.0 − 43.5 = 8.5
上界 = Q3 + 1.5×IQR = 52.0 + 12.75 = 64.75
下界 = Q1 − 1.5×IQR = 43.5 − 12.75 = 30.75
✔️ 適用：★ 不假設特定分布，且較不受極端值影響（中位數與四分位數都穩健，但不是完全免疫）
✔️ 這就是 M1 箱形圖上那兩條鬚

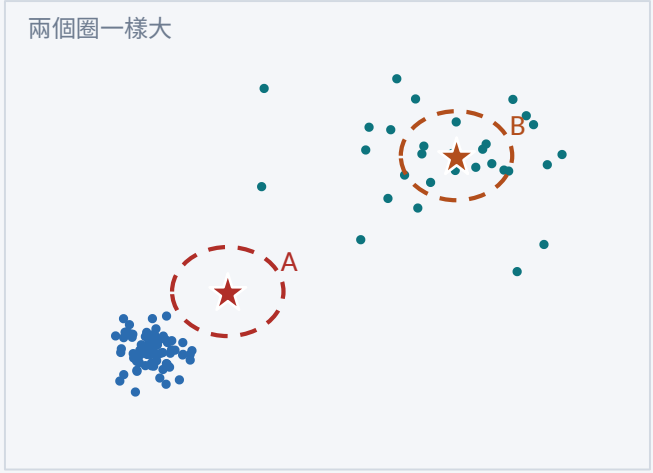
【方法三】穩健 Z 分數（MAD）
MAD = median(|x_i − median|) = 4.5
修正 Z = 0.6745 × (x − median) / MAD　　（0.6745 為常態一致化常數）
門檻通常取 |修正 Z| > 3.5
✔️ 適用：★ 樣本數少、或分布明顯偏斜時最可靠

【怎麼選】
資料近常態且乾淨　→ 3σ
不確定分布　→★ IQR（最安全的預設）
樣本少或嚴重偏斜　→ MAD

LOF：為什麼「局部」兩個字這麼重要

左・用「全域距離」判斷

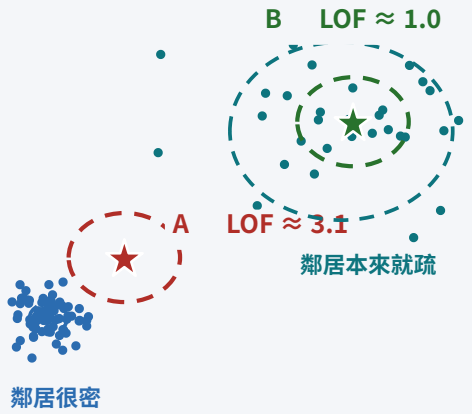
A 與 B 到最近鄰的距離差不多



→ 兩者被視為同樣異常，或同樣正常。錯了。

右・LOF：跟「鄰居的密度」比

A 週遭很密它卻疏 → 異常



→ A 異常、B 正常。同樣的距離，結論完全相反。

● 密集群（80 點）　● 稀疏群（30 點）　★ 待判定的點 A、B　虛線圈＝鄰域半徑

LOF ≈ 1 表示與鄰居密度相當（正常）；明顯 > 1 表示比鄰居稀疏（異常）。注意：LOF 的「局部」是跟特徵空間裡的鄰居比；臨床上「跟病人自己平常比」是個人基線，概念相近但不相同。

全域距離的問題

A 與 B 到最近鄰的距離差不多 → 被視為同樣異常。錯了。

LOF 的作法

拿自己的密度和「鄰居的密度」比。
A 週遭很密它卻疏 → 異常；B 週遭本來就疏 → 正常。

怎麼讀數值

LOF ≈ 1 表示與鄰居密度相當（正常）；
明顯 > 1 表示比鄰居稀疏（異常）。

★ 醫療上的意義

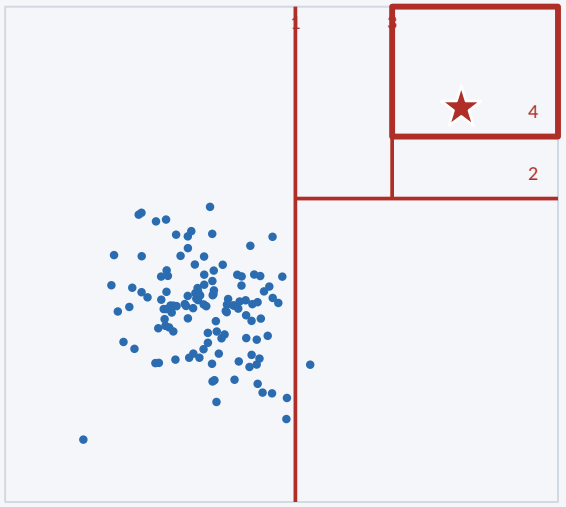
同一位病人的生理數值要跟「他自己平常」比，

不是跟全院平均比——這就是局部的概念。

★ 原生圖形，可直接在 PowerPoint 編輯

Isolation Forest：用「切幾刀能孤立它」衡量異常

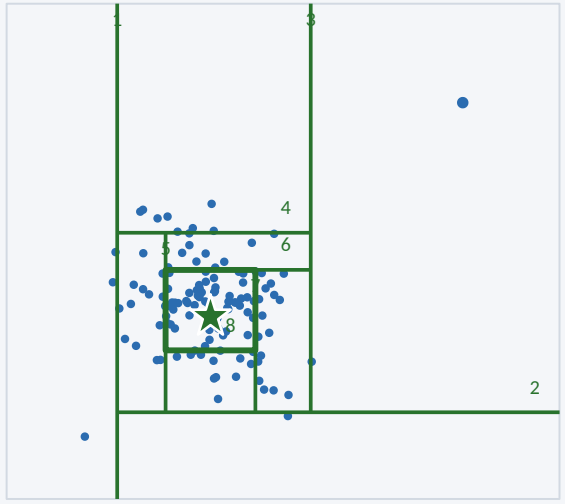
左・異常點：切 4 刀就被孤立



切 4 刀後，粗框內只剩它自己

路徑短 → 異常分數高

右・正常點：切 8 刀還在人群裡



切 8 刀後，粗框內還有 53 個點

路徑長 → 異常分數低

● 其他資料點　★ 被追蹤的那個點　細線＝一刀（依序編號），粗框＝未切開區

建很多棵這樣的隨機切分樹，記錄每個點「平均要切幾刀才孤立得了」——這個刀數就是異常分數。不需要算距離、不需要假設分布，高維時仍然有效。

原理

隨機挑特徵、隨機挑切點，反覆切。
異常點很快就被單獨切出來，正常點要切很多刀。

★ 反直覺但高明的地方

它不去定義「什麼是正常」，
而是直接找「容易被孤立的點」。

為什麼適合高維

不需要算距離 → 較不受維度詛咒影響，速度快；無關特徵多時仍會變差。

關鍵參數

contamination （預期異常比例）——
★ 這個值你其實不知道，設定時要保守並搭配人工覆核（AI Studio 需 Anomaly Detection 擴充或 Python ／ PyOD ）。

★ 原生圖形，可直接在 PowerPoint 編輯

四種主流異常偵測演算法的對照

演算法	原理	維度	可解釋性	什麼時候用
IQR ／ 3σ	統計門檻	單變量	★ 極高	單一指標監測；一定要先試這個
LOF	局部密度比較	中低維	中	★ 資料有明顯的密度差異（不同群體混在一起）
Isolation Forest	隨機切分路徑長度	★ 高維	低	特徵較多、資料量大時的候選起點
One-Class SVM	學一個包住正常資料的邊界	中維	低	正常樣態很集中、且資料量不大時

※ 自編碼器（Autoencoder）屬深度學習取徑， M5 會談：訓練它重建正常資料，重建誤差大的就是異常。

異常偵測怎麼評估：沒有標準答案的時候

異常偵測最大的困難不是演算法，是「你怎麼知道抓對了」

- 沒有標準答案：如果你已經知道哪些是異常，就不需要異常偵測了
- 準確率算不出來：分母（真正的異常總數）你不知道

★ **這是它與分類問題最根本的差別 —— M2-2 那套評估指標在這裡多半用不上**

① 人工覆核前 N 名

把模型分數最高的 50 筆交給專家看

算出「精確率 @50」

這是最務實的做法

② 注入已知異常

把已知的異常案例混進資料，看抓不抓得到

算出「召回率」

但只對這類異常有效

★ ③ 穩定性檢查

換參數、換時段跑，看抓到的是不是同一批

每次結果都不同

→ 代表模型不可信

★ 實務建議：把異常偵測定位成「幫人縮小檢視範圍的工具」，而不是「自動判定異常的系統」。

從 10 萬筆縮到 200 筆讓專家看，價值就已經很大了 —— 不必追求它能取代人。

★ 最大的困難不是演算法

是「你怎麼知道抓對了」。
如果你已經知道哪些是異常，就不需要異常偵測了。

① 人工覆核前 N 名

把分數最高的 50 筆交給專家看，算「精確率 @50」。
這是最務實的做法。

② 注入已知異常

把已知案例混進資料看抓不抓得到。可算召回率，
但只對這類異常有效。

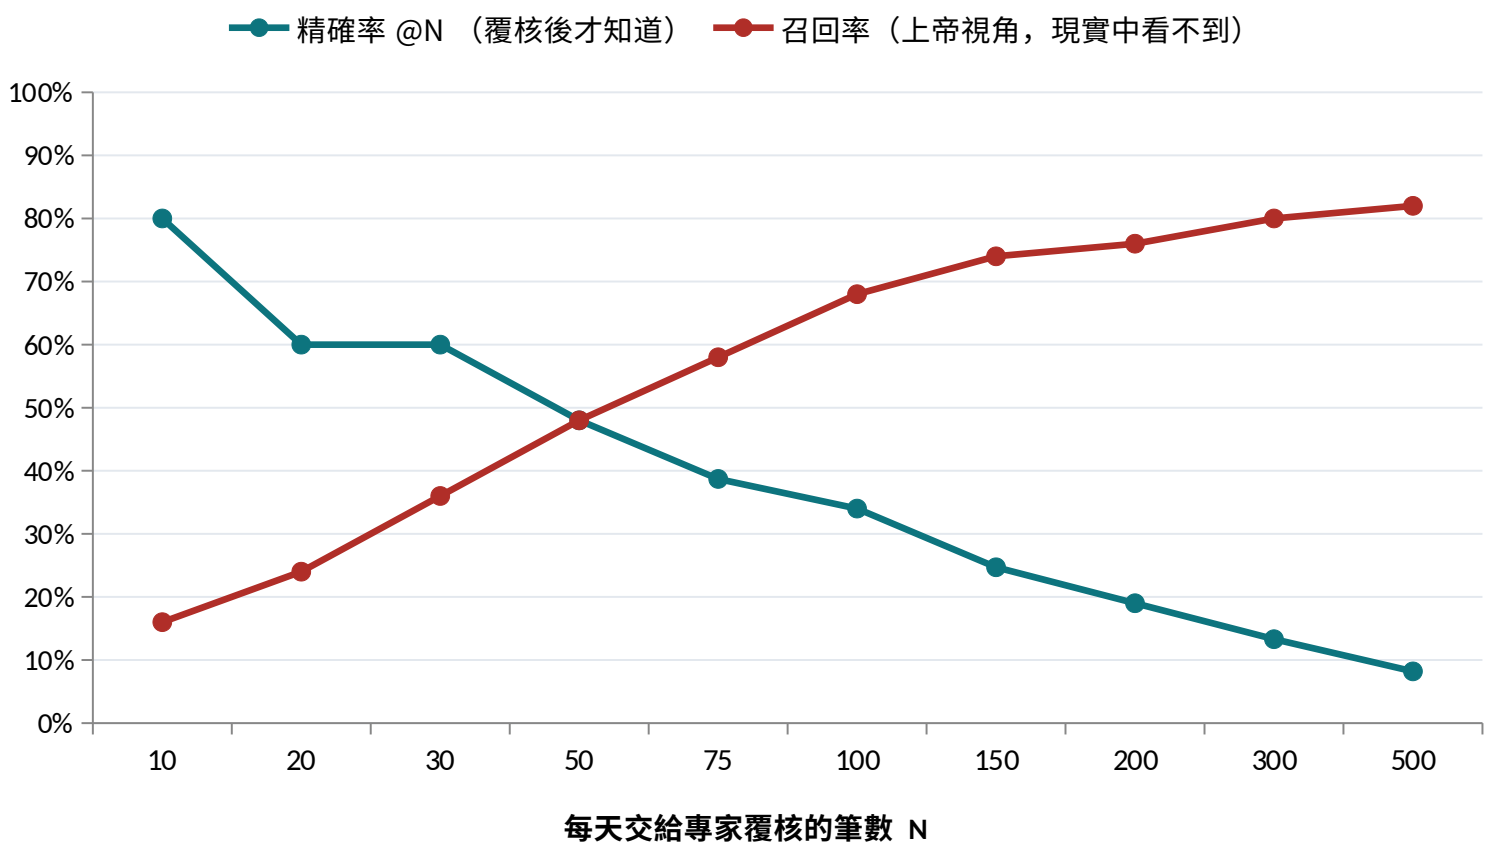
★ ③ 穩定性檢查

換參數、換時段跑，看抓到的是不是同一批。

每次結果都不同 → 模型不可信。

★ 原生圖形，可直接在 PowerPoint 編輯

實例：門檻由人力決定——每天能覆核幾筆?



每天看 50 筆

其中 24 筆是真的（精確率 48%）。這是唯一算得出來的指標。

分母未知

這一天其實有 50 筆真異常；每天看 50 筆只抓到 48%，看 200 筆抓到 76%—— 但現實中你不知道總共有幾筆。

門檻怎麼定

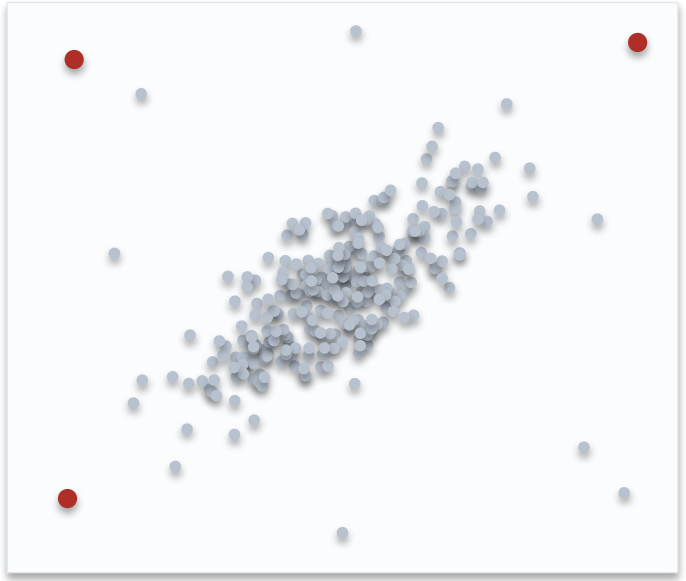
先問專家每天能看幾筆，再把門檻設在那個名次。太嚴漏掉問題，太鬆沒人看、系統形同虛設。

模擬：每天 1 萬筆、其中 50 筆真異常，依異常分數由高到低交給專家。異常偵測多半沒有標準答案，「覆核前 N 名的精確率」是最務實的評估方式；覆核結果記得回寫成標註，累積後就能改走監督式分類。

實例：穩定性檢查—— contamination 由你決定

contamination = 0.01

標出 3 筆

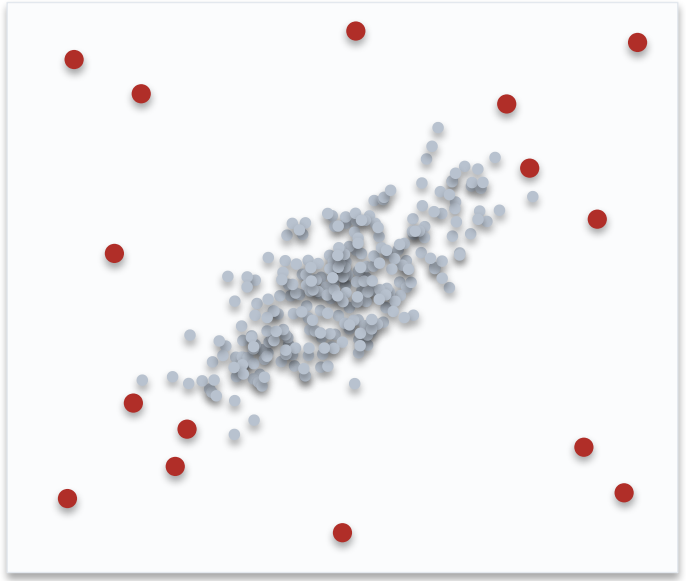


包含 0.01 那批的 3 / 3 筆

換隨機種子重跑，重疊 50%

contamination = 0.05

標出 15 筆

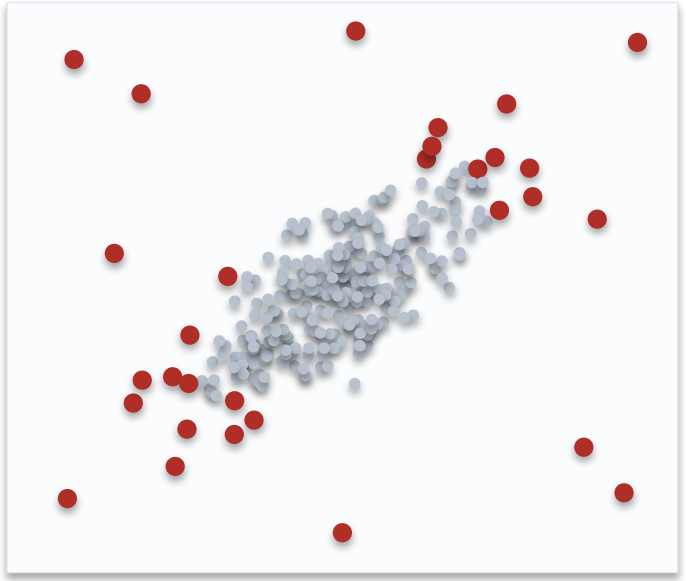


包含 0.01 那批的 3 / 3 筆

換隨機種子重跑，重疊 88%

contamination = 0.1

標出 30 筆



包含 0.01 那批的 3 / 3 筆

換隨機種子重跑，重疊 94%

最明顯的異常在三種設定裡都會出現；越往邊緣，換種子重跑的結果越不一致。報告中要說明 contamination 怎麼定的；多種設定或多種方法的交集，通常才是最可信的異常。（模擬資料 300 筆， Isolation Forest ）

異常偵測的三個實務原則

① 定位成「縮小範圍的工具」，不是「自動判定系統」

- 從 10 萬筆縮到 200 筆讓專家看，價值就已經很大了
- ★ 不必追求它能取代人——那既做不到，責任上也不該這樣設計
- 在醫療場域這個定位還能大幅降低法規與責任風險

② 門檻由「人力可負荷量」決定，不是由統計決定

- ★ 專家一天能看 50 筆，那門檻就設在每天產出約 50 筆的位置
- 設得太嚴 → 漏掉真正的問題；設得太鬆 → 沒人看，系統形同虛設
- 這是統計課本不會教、但實務上最重要的一件事

③ 一定要留回饋迴路

- 專家覆核的結果要能回寫成標註
- 累積一段時間後，你就有了監督式學習的訓練資料
- ★ 這是從「異常偵測」演進到「分類模型」的正確路徑

實作 2 ｜鍋爐感測器異常偵測

【AI Studio 範例】 Anomaly Detection .rmp 、 Boiler Sensor 資料集

開啟檔案

```
Repository ▸ 3. Outlier and Ensemble/
  Anomaly Detection .rmp
  Anomaly - outlier detection.rmp
  Boiler Sensor.rmhdf5table
```

★ 感測器資料的結構與
醫療監測訊號高度類似，
方法可直接移轉

預期結果

- ▸ IQR 只抓得到單點極端值
- ▸ LOF 能抓到「數值不極端但脈絡奇怪」的點
- ▸ contamination 設定直接決定抓幾筆——它不是自動的
- ▸ 三種方法的交集通常才是最可信的異常

操作步驟

1. 先畫時序圖，用肉眼找出你認為的異常段落（這只是初步候選，不等於客觀真值）
2. 跑 IQR 門檻，看抓到哪些——通常只抓到「點異常」
3. 跑 LOF，比較它抓到的與 IQR 有什麼不同
4. 跑 Isolation Forest，把 contamination 分別設 0.01 / 0.05 / 0.10
5. ★ 比較三個設定抓到的是不是同一批（穩定性檢查）
6. 把三種方法的結果做成一張表：各抓幾筆、重疊多少
7. 回頭對照你第一步的標註，算出「相對於你標註」的精確率

PART 04

關聯規則

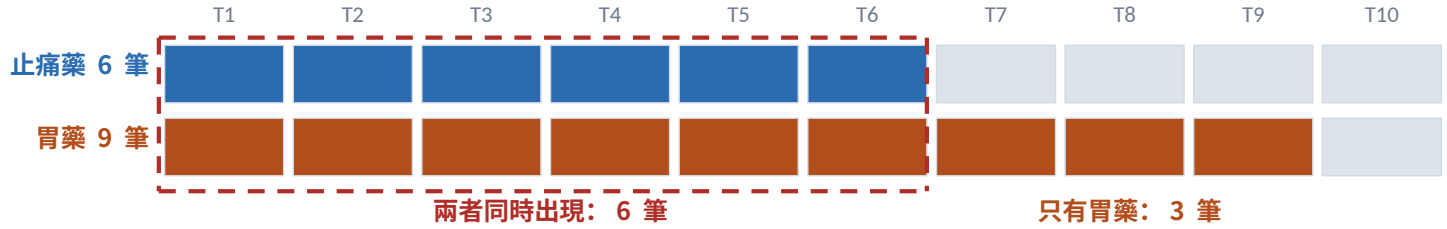
Association Rule Mining

沒有 Y 可以預測，你想知道的是「什麼跟什麼常常一起出現」。
購物籃分析出身，但在醫療領域用途更廣。

三個指標：為什麼信賴度會騙人

規則：｛止痛藥｝→｛胃藥｝， 10 筆處方交易

10 筆處方交易的實際內容（■ 表示這筆交易裡有這個藥）



支持度 Support	這條規則涵蓋多少比例的交易	**6 / 10 = 0.60**	太低表示組合太罕見，不值得管
信賴度 Confidence	買了止痛藥的人，有多少也買胃藥	**6 / 6 = 1.00**	看起來完美，但先別下結論
提升度 Lift	比「隨機碰巧一起出現」強多少倍	**1.00 / 0.90 = 1.11**	★ 只比隨機好 11%，沒什麼特別

為什麼 lift 才是關鍵

胃藥本來就出現在 9/10 的交易裡。
隨便挑一個藥，它的「信賴度」都會很高，
因為胃藥幾乎人人都開。

lift = 1 → **兩者獨立，沒有關聯**
lift > 1 → **正相關（越大越值得注意）**
lift < 1 → **負相關（互斥）**

支持度 Support

這條規則涵蓋多少比例的交易。
太低表示組合太罕見，不值得管。

信賴度 Confidence

買了 A 的人有多少也買 B。
本例 6/6 = 1.00，看起來完美。

★ 提升度 Lift

比「隨機碰巧一起出現」強多少倍。
本例僅 1.11—— 只比隨機好 11%。

為什麼

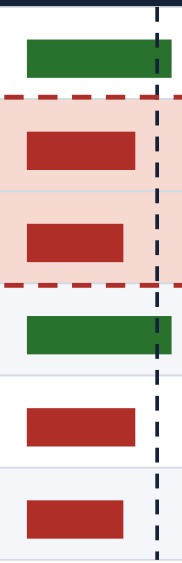
胃藥本來就出現在 9/10 的交易裡。
隨便挑一個藥，信賴度都會很高。

★ 原生圖形，可直接在 PowerPoint 編輯

lift 陷阱：信賴度排行榜為什麼會誤導你

同一份資料跑出來的六條規則，依信賴度由高到低排序

規則（依 confidence 排序）	support	confidence	lift （虛線＝ 1.0 ）	判讀
止痛藥 → 胃藥	0.60	1.000	1.111	信賴度 100%，但 lift 僅 1.11
降血壓藥 → 胃藥	0.30	0.750	0.833	★ 陷阱：信賴度高，lift 卻 < 1
維他命 → 胃藥	0.20	0.667	0.741	★ 同上，實際是負相關
胃藥 → 止痛藥	0.60	0.667	1.111	與第一條同一組關聯，方向不同
胃藥 → 降血壓藥	0.30	0.333	0.833	低信賴度也低 lift
胃藥 → 維他命	0.20	0.222	0.741	同上



★ 只用信賴度排序，你會把虛線框裡那兩條當成重要發現 —— 但它們的 lift 都在 1.0 的左邊。

★ 這兩條規則實際上是「負相關」：開了降血壓藥的人，反而比較少同時開胃藥。

正確做法：先用 support 濾掉太罕見的，再用 lift 排序，最後才看 confidence 判斷實用性。

看第 2、3 條

信賴度 0.75 與 0.67 排名很前，但 lift 都小於 1。

★ lift < 1 是負相關

這兩條規則實際上是「開了降血壓藥的人，反而比較少同時開胃藥」——與你想的相反。

正確做法

先用 support 濾掉太罕見的 → 再用 lift 排序 →
最後才看 confidence 判斷實用性。

三個指標的分工

support 管「值不值得看」、lift 管「是不是真的有關」、
confidence 管「實際上多可靠」。

★ 原生圖形，可直接在 PowerPoint 編輯

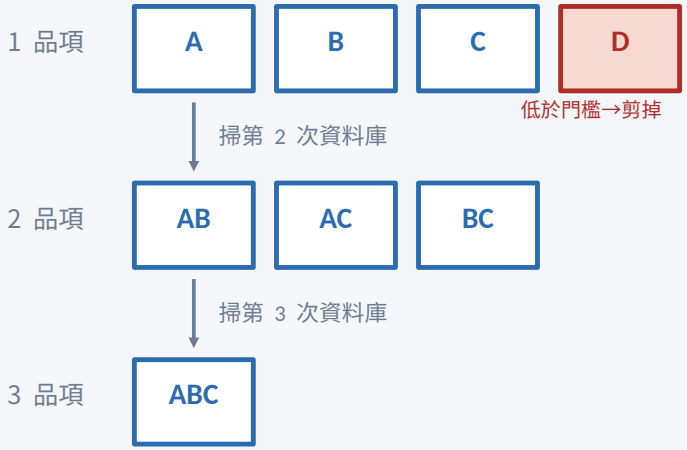
五個評估指標的完整定義（含手算範例）

指標	公式	本例數值	怎麼讀
支持度 Support	$P(A \cap B)$	0.60	10 筆中有 6 筆同時出現
信賴度 Confidence	$P(B\|A) = P(A \cap B)/P(A)$	1.000	開止痛藥的 6 筆，全部都開了胃藥
提升度 Lift	$P(B\|A)/P(B)$	1.111	★ 只比隨機好 11%，實際關聯很弱
槓桿度 Leverage	$P(A \cap B) - P(A)P(B)$	0.060	實際共現與獨立假設的差距
確信度 Conviction	$(1-P(B))/(1-P(B\|A))$	∞	信賴度為 1 時無定義；一般越大越強

★ 實務只看前三個就夠。後兩個在論文與需要更細緻判斷時才用得上。

兩種頻繁項目集演算法

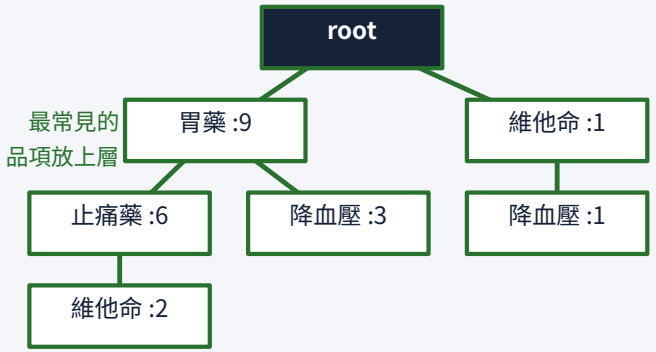
左・ Apriori： 逐層產生候選並剪枝



★ 核心定理： {A,B} 不頻繁 → {A,B,C} 一定也不頻繁，可直接剪掉

代價：每一層都要重掃一次資料庫（本例 3 次），資料量大時很慢

右・ FP-Growth： 建一棵前綴樹，只掃兩次



★ 把交易壓縮成一棵前綴樹：共用的前綴只存一次

第 1 次掃：算各品項次數並排序
第 2 次掃：把每筆交易掛上樹
之後頻繁項目集都在樹上挖，不必再碰原始資料

總共只掃資料庫 2 次 → 資料量大時快非常多

★ 實務結論：品項少（＜100）用哪個都行；品項多或交易量大，一律用 FP-Growth。

AI Studio 內建的 FP-Growth 運算子就是這個演算法；差別只在「要掃幾次資料庫」。

Apriori

逐層產生候選並剪枝。核心定理：
如果 {A,B} 不頻繁， {A,B,C} 一定也不頻繁。

Apriori 的代價

要掃描資料庫 N 次（每一層掃一次）。
資料量大時很慢。

★ FP-Growth

把交易壓縮成一棵前綴樹，共用的前綴只存一次。
只掃資料庫 2 次。

實務結論

品項少（＜100）用哪個都行；
品項多或交易量大，一律用 FP-Growth。 AI Studio 內建的就是它。

★ 原生圖形，可直接在 PowerPoint 編輯

關聯規則在醫護場域的六個應用

應用	把什麼當成「一筆交易」	把什麼當成「品項」	能發現什麼
處方組合分析	一次就診／一張處方	開立的藥品	常見的用藥組合；★ 潛在交互作用風險
共病分析	一位病人	診斷碼（ICD）	哪些疾病常同時出現 → 照護模式設計
檢驗開單模式	一次就診	檢驗項目	★ 是否有不必要的重複開單
衛材耗用	一台手術	使用的衛材	備料組合最佳化
症狀組合	一次諮詢	主訴症狀	哪些症狀常一起出現 → 分診規則參考
照護活動	一個班別	執行的護理活動	工作流程的實際樣態

★ 注意共病分析的「一筆交易」是「一位病人」而非「一次就診」——單位定義錯了，整個分析就沒有意義。

關聯規則的三個常見誤用

① 把關聯當成因果

- 「開止痛藥 → 開胃藥」不代表止痛藥造成胃藥的需求
- ★ 很可能是醫師的習慣性搭配，或兩者都由第三個原因造成
- 關聯規則只告訴你「同時出現」，因果要靠實驗或臨床知識判斷

② 支持度門檻設得太低

- 設 0.001 會跑出幾萬條規則，其中絕大多數是雜訊
- ★ 實務起點： support ≥ 0.01 （1% 的交易）、 lift ≥ 1.2
- 規則數量控制在人看得完的範圍（幾十條）才有意義

③ 忽略了「品項粒度」的選擇

- 用藥品「品項名」還是「成分」還是「ATC 分類」？結果完全不同
- 粒度太細 → 每個組合都很罕見，跑不出規則
- ★ 粒度太粗 → 規則太籠統，沒有行動價值。這一步要跟臨床討論

實作 3 ｜ Golf 與購物籃分析

【AI Studio 範例】 Repository ▸ 6. Association Rules/1 、 2

開啟檔案

```
Repository ▸ 6. Association Rules/
  1. GOLF - FPGrowth
    association rules.rmp
  2. Market Basket Analysis.rmp
  Golf.rmhdf5table
  Transactions.rmhdf5table

★ Golf 資料極小，適合
  逐條驗算指標
```

預期結果

- ▸ support 門檻對規則數量的影響是指數級的
- ‣ 兩種排序的前十名會有明顯差異
- ▸ ★ confidence 排名前段的規則， lift 常常很普通
- ‣ 真正有價值的規則通常只有個位數條

操作步驟

1. 先跑 Golf 範例，資料只有 14 筆——★ 手算驗證一條規則的三個指標
2. 把 min support 從 0.1 調到 0.5 ，觀察規則數量如何驟減
3. 改跑 Market Basket ，先用預設參數看跑出幾條規則
4. ★ 把結果依 confidence 排序，再依 lift 排序，比較前十名有何不同
5. 在 confidence 前 10 名中找出 lift 最低的一條（ lift 陷阱）
6. 改變 min lift 門檻為 1.2 ，看剩下幾條
7. 挑三條你認為最有行動價值的規則，說明理由

PART 05

時間序列基礎

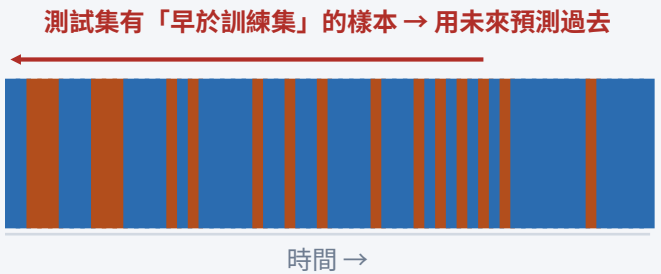
Time Series Fundamentals

當資料有時間順序，前面學過的規則有一半要改寫。
這一節不求完整，但求你不要犯致命錯誤。

時間序列最容易犯的錯：切分方式

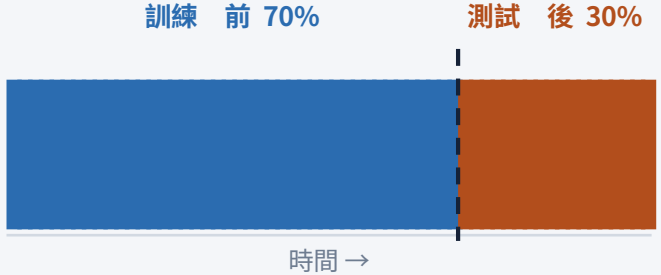
同一份資料的 60 個樣本，由左到右依時間先後排列

左・一般監督式：隨機切分



訓練與測試完全交錯在一起

右・時間序列：依時間切分



只用過去預測未來，才是真實情境

訓練樣本　測試樣本

兩張圖的樣本數與比例完全相同

★ 資料有時間順序 → M2 用的 Split Data 隨機切分一律不能用。

交叉驗證也要改成 walk-forward （滾動視窗）：每一折的測試集都必須在該折訓練集之後。

左圖的驗證分數會漂亮得離譜——因為模型早就在訓練時看過「未來」了。上線之後才會發現全是假的。

★ 隨機切分是災難

訓練集裡有未來的資料，測試集裡有過去的資料。
這叫資料洩漏，驗證分數會虛高得離譜。

正確做法

依時間切：前面 70% 訓練、後面 30% 測試。
只用過去預測未來，才是真實情境。

交叉驗證也要改

不能用一般 K-Fold 。要用 walk-forward （滾動視窗）：
每一折的測試集都在訓練集之後。

★ 一句話

資料有時間順序 → 隨機（ shuffled ）切分一律不能用。

★ 原生圖形，可直接在 PowerPoint 編輯

實例： Walk-forward 滾動驗證——測試永遠在訓練之後

擴張視窗 Expanding

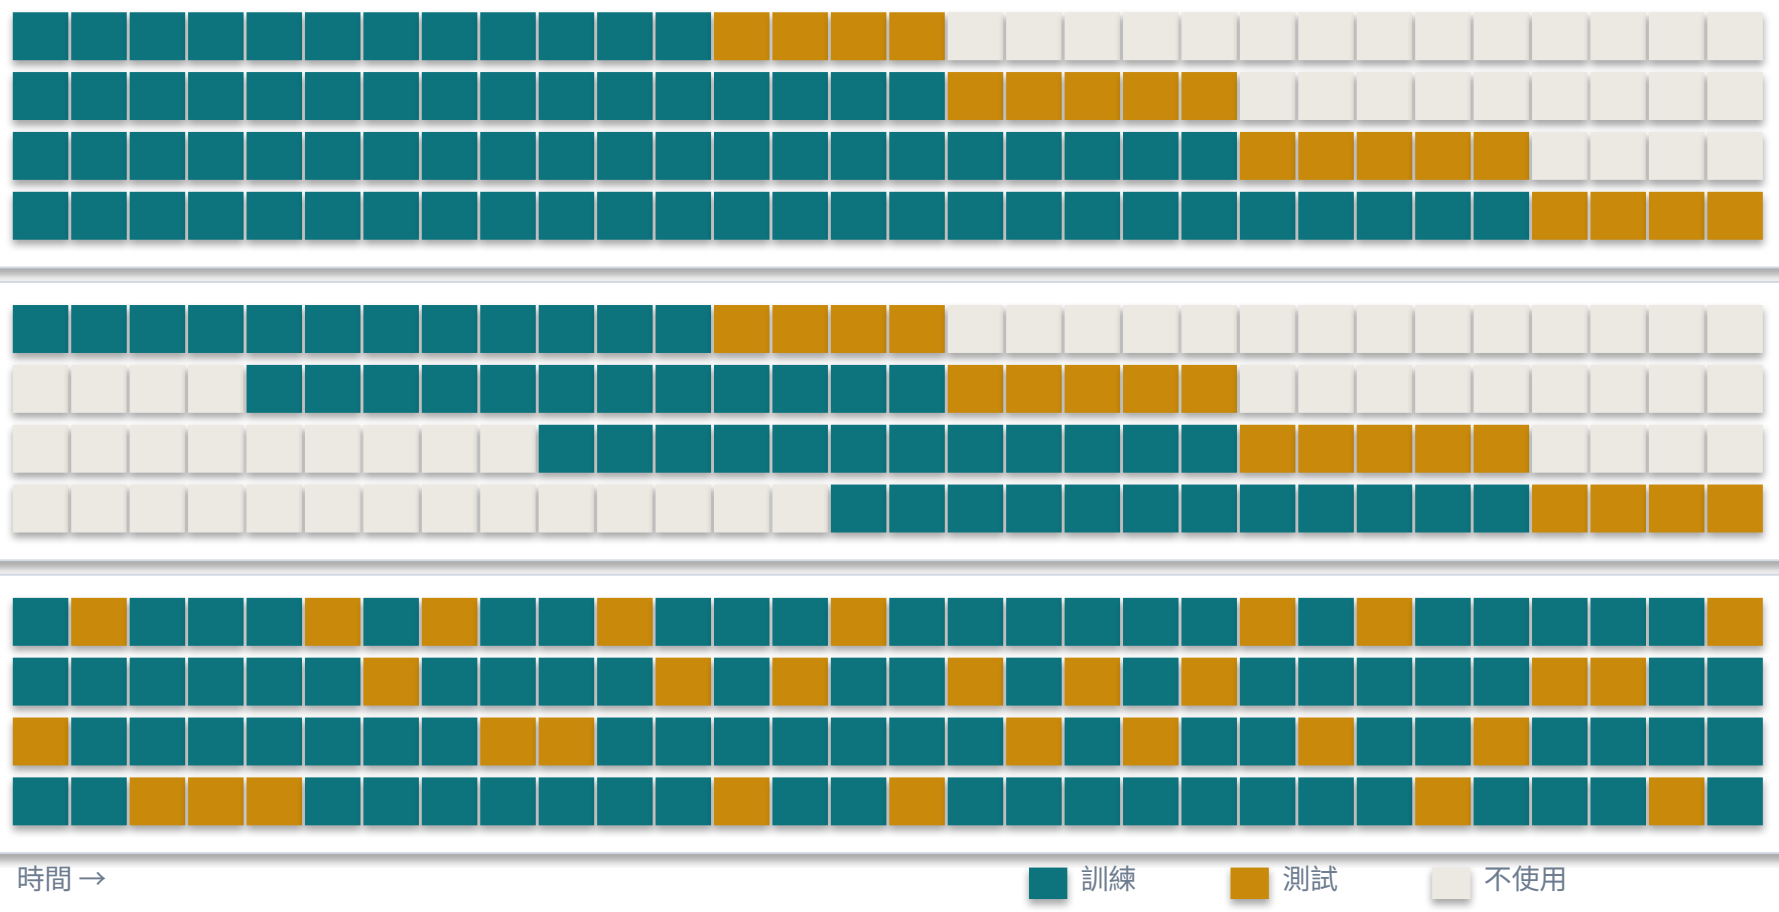
每一折用「到那時為止」的全部資料訓練。最常用

滑動視窗 Sliding

訓練長度固定。資料型態會隨時間改變（舊資料不再代表現在）時用

✕ 一般 K-Fold

測試折散在整條時間軸上——大部分折都在用未來預測過去，時間序列不能用



每一列是一折，每一格是一個時間點。前一張的隨機切分讓測試點左右都有訓練點，等於偷看了未來。 AI Studio： Sliding Window Validation ；Python： sklearn TimeSeriesSplit 。

時間序列與一般監督式學習的五個差異

面向	一般監督式（M2）	時間序列	做錯的後果
切分方式	隨機切分	★ 依時間切	驗證分數虛高，上線就崩
交叉驗證	K-Fold	★ Walk-forward 滾動視窗	同上
樣本獨立性	假設各筆獨立	★ 前後高度相關（自相關）	標準誤估計錯誤
特徵來源	現有欄位	★ 大多要自己造（滯後、移動平均）	沒有特徵可用
評估重點	整體準確率	★ 還要看「預測多遠」仍準確	把短期預測當成長期能力

★ 第四列是實務重點：時間序列的特徵工程比模型選擇重要得多。

滯後特徵：把時間序列變成監督式問題

做完這一步， M2 學過的所有模型就都能用了

特徵工程（時間序列的主戰場）

【原始資料】某急診每日就診人次

```
日期    人次
 2027-03-01   142
 2027-03-02   138
 2027-03-03   155
 2027-03-04   149
 2027-03-05   163
```

【建立滯後特徵】目標：用過去 3 天預測今天

```
日期    lag_1  lag_2  lag_3  ma_3    dow  is_holiday   y（今日）
 2027-03-04   155    138    142   145.0    4       0          149
 2027-03-05   149    155    138   147.3    5       0          163

 lag_n       = n 天前的人次      （最基本、也最重要的特徵）
 ma_3        = 前 3 天的移動平均    （平滑短期波動）
 dow         = 星期幾（1–7）            ⋆ 醫療需求有強烈的週週期
 is_holiday  = 是否連假       ★ 台灣的連假效應非常明顯
```

【做完之後】這就是一張普通的表格資料 → 隨機森林、 XGBoost 都能直接用

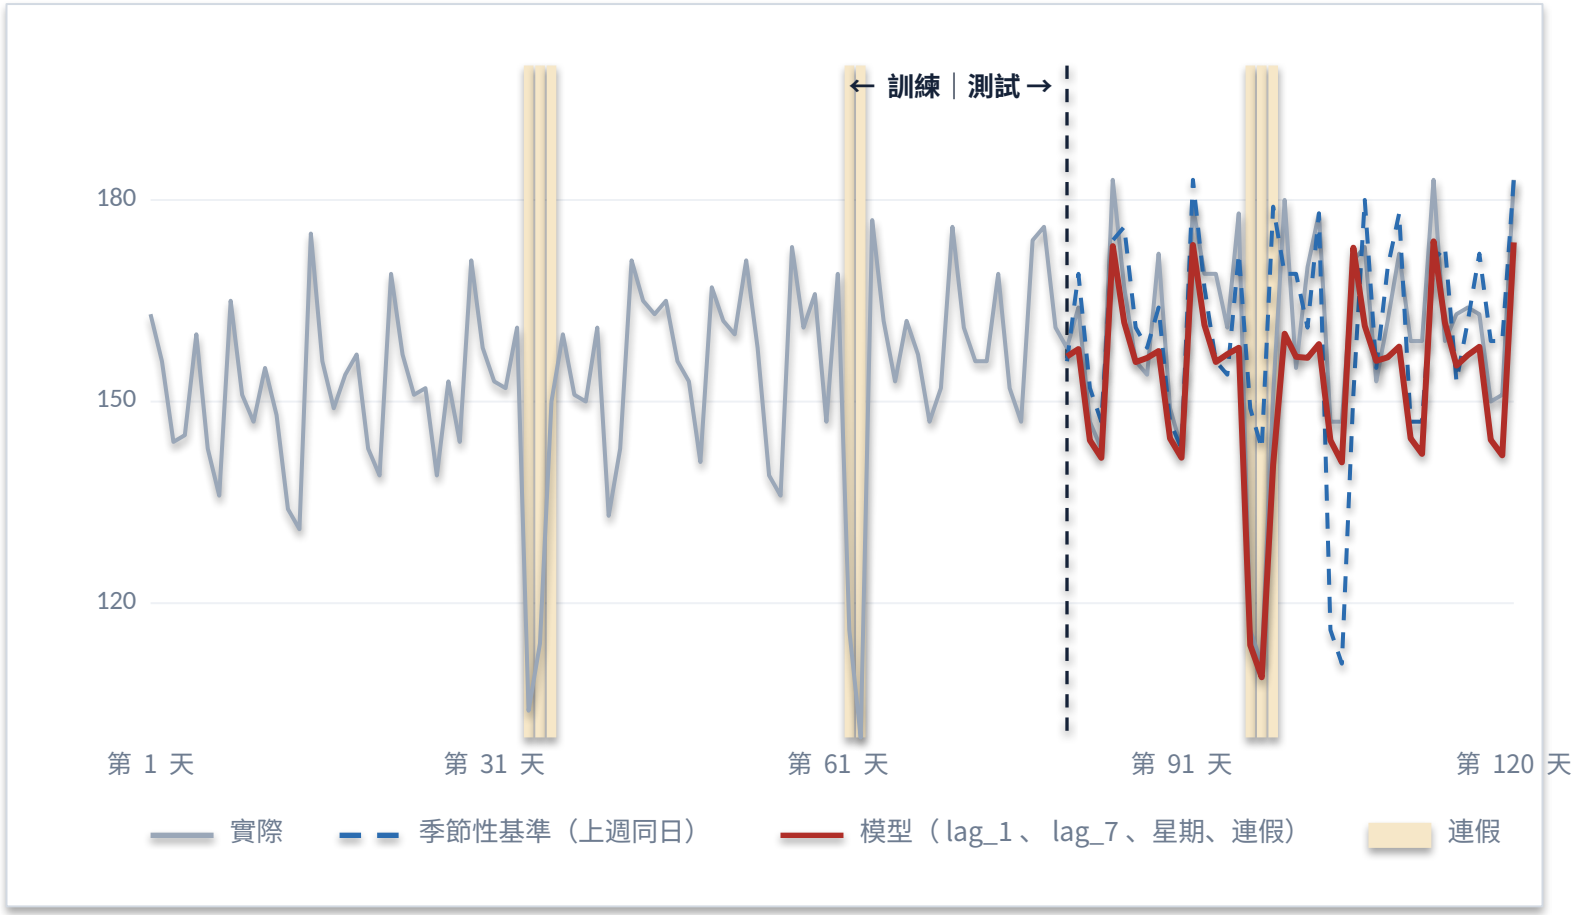
★ 三個一定要注意的地方：

① 建完滯後特徵，最前面幾列會有空值（沒有前 3 天）→ 必須刪掉

② 絕對不能用「當天或未來」的資訊當特徵 —— 那是最典型的洩漏
例：用「當日住院人數」預測「當日急診人次」→ 上線時你拿不到

③ 切分時間點之後，特徵計算不能跨越那個點（滾動視窗要重算）

實例：急診每日人次——模型要先贏過基準線



天真基準：明天＝今天

MAE 15.2 人次

季節性基準：上週同日

MAE 10.2 人次

模型

MAE 7.5 人次——贏過兩個基準，主力是星期幾與連假

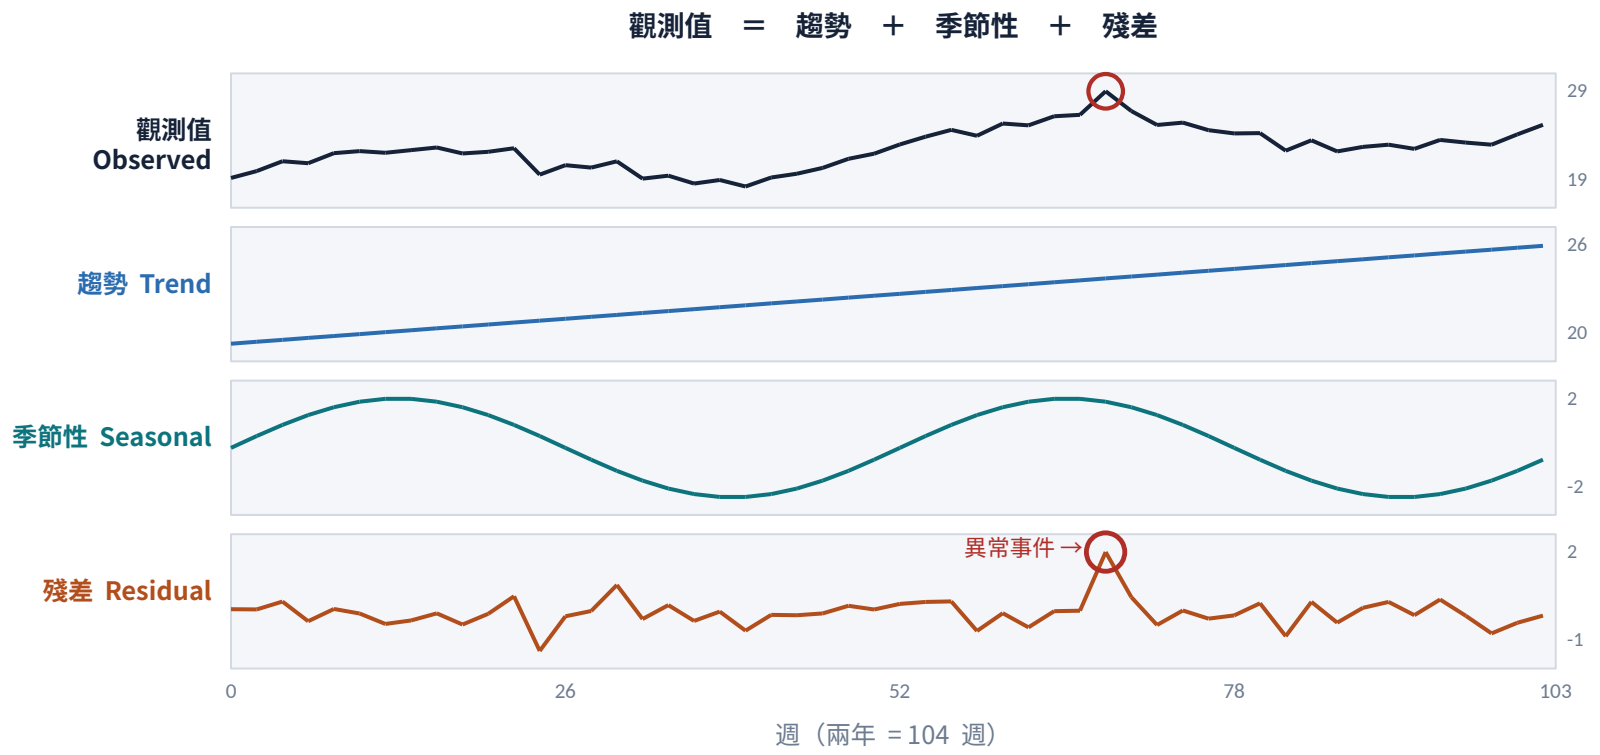
⚠ 加入「當日住院人數」

MAE 降到 1.6，好得不像話——那要到當天結束才知道，是洩漏

測試期 40 天的平均絕對誤差（越小越好）。模型沒贏過「上週同日」就不必上線——這很常發生。醫療需求有強烈的週週期，台灣的連假效應也非常明顯。（模擬資料 120 天）

時間序列分解：把一條線拆成可解釋的成分

範例：急診人次，兩年週資料



★ 趨勢告訴你長期方向、季節性告訴你何時該加派人力、殘差裡的大波動就是異常事件。

第 68 週的殘差突然衝高——單一週是「點異常」，若連續數週偏高才是「集體異常」；分解圖直接把它挑出來了。

趨勢 Trend

長期方向。告訴你「整體是在增加還是減少」。

季節性 Seasonal

規律重複的波動。★ 告訴你何時該加派人力。

殘差 Residual

扣掉前兩者剩下的。★ 裡面的大波動就是異常事件——
這裡與 PART 3 的異常偵測接上了。

★ 分解本身就有價值

不一定要做到預測。光是把這三張圖給管理者看，
往往就足以支撐排班與資源配置的決策。

★ 原生圖形，可直接在 PowerPoint 編輯

時間序列的三個實務提醒

① 先問「真的需要預測嗎」

- 很多時候管理者要的是「解釋過去」而不是「預測未來」
- ★ 分解圖 + 同期比較，往往比一個預測值更有用
- 預測誤差 ±15% 的模型，在排班決策上可能根本用不上

② 基準線一定要建立

- 最簡單的基準：「明天＝今天」（naive forecast）
- 季節性基準：「這週三＝上週三」
- ★ 你的複雜模型如果贏不過這兩個，那就別用了——這很常發生

③ 外部事件要當成特徵

- 連假、流感季、疫情、大型活動、天氣
- ★ 台灣的連假效應極強，不放進去模型一定抓不準
- 這些資訊通常要自己整理成對照表，是很花時間但必要的工作

※ 時間序列的完整方法（ARIMA、Prophet、LSTM）超出本課程範圍；本節目標是讓你不犯致命錯誤，並知道往哪裡進修。

實作 4 ｜芝加哥犯罪率時間序列預測

【AI Studio 範例】 Predict Crime Rate.rmp

開啟檔案

```
Repository ▸ 4. Case Studies/
  5. Time Series - Predict
    Crime Rate in Chicago/
  Predict Crime Rate.rmp
  Chicago_Crimes_2001-2017.csv
```

★ 資料橫跨 17 年，
趨勢與季節性都很明顯

預期結果

- 季節性與 naive 基準孰佳因資料而異
- ★ 加了滯後特徵的模型不一定贏過季節性基準
- 若沒贏，表示這份資料的可預測性主要來自季節性
- 這是很正常也很重要的發現，不是失敗

操作步驟

1. 先把資料彙總成「每月犯罪件數」，畫出時序圖
2. 做時間序列分解，觀察趨勢與季節性
3. ★ 建立基準線：用「上個月的值」當預測，記錄誤差（MAE）
4. ★ 再建一個季節性基準：用「去年同月的值」，記錄誤差
5. 建立滯後特徵（lag_1、lag_12、月份），跑隨機森林
6. 依時間切分（前 80% 訓練、後 20% 測試），不要隨機切
7. 比較三者的 MAE —— 模型有沒有真的贏過基準線?

PART 06

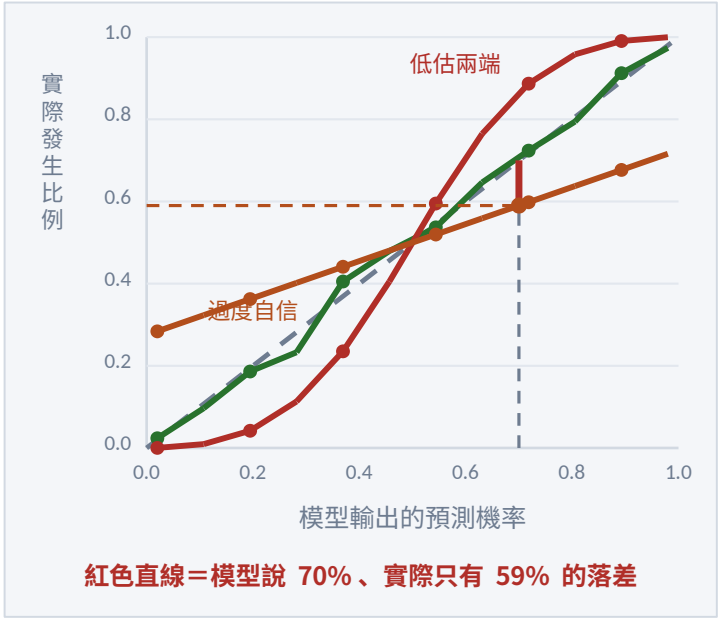
機率校準與代價敏感

Calibration & Cost-Sensitive Learning

兩個在醫療場域極重要、但在一般課程常被跳過的主題。
它們決定了你的模型能不能真的被拿來用。

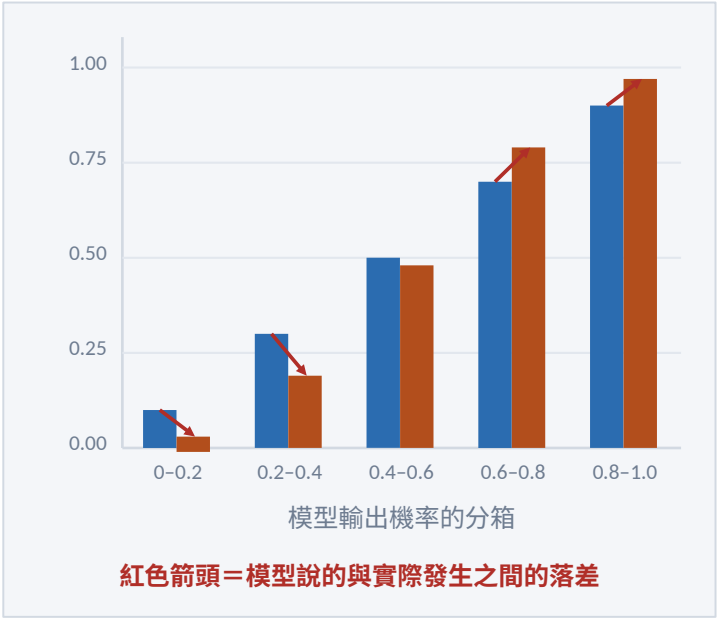
機率校準：模型說「70%」的時候，真的有 70% 嗎

左・校準曲線 Calibration Curve



紅色直線＝模型說 70%、實際只有 59% 的落差

右・未校準模型：兩端偏差最大



紅色箭頭＝模型說的與實際發生之間的落差

- - 完美校準（對角線）　**校準良好**　低估兩端（未調整的隨機森林）　過度自信（如 Naive Bayes）

★ 為什麼醫療場域特別重要：風險分數要拿來跟臨床決策門檻比對（如「超過 20% 就啟動介入」）。沒校準的機率只能拿來「排序」，不能拿來「當成真實機率解讀」—— 這是最常被誤用的地方。

校準曲線怎麼看

橫軸是模型說的機率、縱軸是實際發生比例。

完美校準應該落在對角線上。

常見的偏差

隨機森林、 SVM 、 AdaBoost 的分數常擠向中間；
Naive Bayes 與過擬合模型常過度自信（ Niculescu-Mizil & Caruana, 2005 ）。

★ 為什麼醫療特別重要

風險分數要拿來跟臨床門檻比對（如「超過 20% 就啟動介入」）。

★ 最常見的誤用

沒校準的機率只能拿來「排序」，不能當成真實機率解讀。

★ 原生圖形，可直接在 PowerPoint 編輯

兩種校準方法

方法	作法	適合	注意
Platt Scaling	用邏輯斯迴歸把原始分數映射到機率	★ 樣本少（< 1000 ）、偏差呈 S 形	假設偏差形狀固定，較不彈性
Isotonic Regression 保序迴歸	學一個單調遞增的映射函數	★ 樣本多（ > 1000 ）、偏差形狀不規則	樣本少時容易過擬合

★ 兩者都必須在「獨立的校準集」上訓練 —— 用訓練集校準等於沒校準。實務做法：切三份（訓練／校準／測試）。

什麼時候你必須做校準

① 要把機率當成「風險值」解讀時

- 「這位病人再入院風險 35%」——這句話要成立，機率就必須校準
- ★ 若只是要排序挑出前 100 名高風險，不校準也可以
- 先問：這個數字會被誰、怎麼使用?

② 要做軟投票或 Stacking 時

- 各成員的機率若尺度不一致，平均起來就沒有意義
- ★ 一個過度自信的成員會主導整個集成的結果

③ 要設定決策門檻時

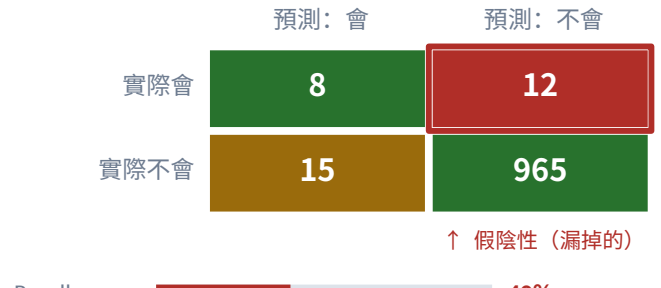
- 「超過 20% 啟動介入」——這個 20% 必須對應真實的 20%
- 沒校準的話，你設 20% 實際上可能是 8% 或 45%

★ 反過來說：只需要排名、或門檻由驗證資料調出來時，可以不做校準。但畫一張校準曲線來看看仍然值得——它會告訴你這個模型的「性格」。

代價敏感學習：把「錯的代價不對稱」放進模型

情境：敗血症早期預警。 1000 位病人中實際發生 20 位。

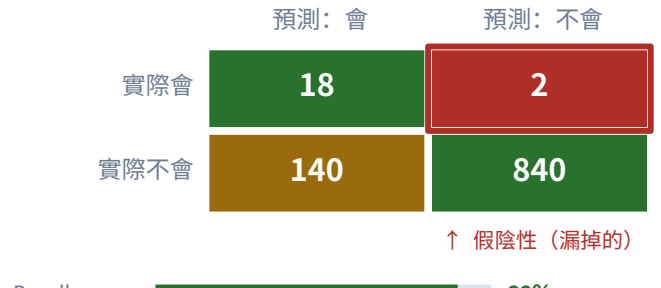
① 一般訓練（追求準確率）



準確率 97.3%　　Recall 40%

★ 漏掉 12 位敗血症病人

② 代價敏感訓練



準確率 85.8%　　Recall 90%

★ 只漏 2 位，代價是 140 次誤報

把「代價」量化，決策就變得清楚

假設：漏掉一位敗血症的代價 ≈ 200 單位（延誤治療）；一次誤報的代價 ≈ 3 單位（多做一次評估）

① 總代價 = 12×200 + 15×3 = 2,445　⟶　② 總代價 = 2×200 + 140×3 = 820

★ 準確率低的那個模型，總代價只有三分之一。這就是為什麼醫療場域不能只看準確率。

問題

一般訓練追求準確率 → 97.3% 很漂亮，
但漏掉 12 位敗血症病人（Recall 僅 40%）。

代價敏感訓練

準確率降到 85.8%，但 Recall 提升到 90%，
只漏 2 位。

★ 把代價量化就清楚了

總代價 2,445 vs 820。準確率低的那個模型，

總代價只有三分之一。

★ 這是醫療 AI 的核心觀念

不能只看準確率。要問「錯在哪一邊、
各自的代價是多少」。

★ 原生圖形，可直接在 PowerPoint 編輯

三種實作代價敏感的方式

方式	怎麼做	優點	限制
調整類別權重 **class_weight**	少數類的樣本在損失函數中權重加大	★ 最簡單，多數演算法內建支援	權重比例要自己試
調整決策門檻	訓練照常，預測時把門檻從 0.5 改成 0.2	★ 不用重訓；可依情境動態調整	套臨床既定機率門檻時需先校準
重抽樣 **Resampling**	過採樣少數類或欠採樣多數類（ M2-2 已談）	直觀、與演算法無關	過採樣可能過擬合；欠採樣丟資料
代價矩陣 **Cost Matrix**	直接把不同錯誤的代價寫進訓練目標	★ 最貼近實際決策； AI Studio： MetaCost	代價數值要跟臨床討論才有意義

★ 最實用的組合： class_weight 訓練 + 校準 + 依代價選門檻。三步都做，模型才真的能用在臨床決策上。

怎麼把「代價」問出來：跟臨床討論的四個問題

這一步不是技術問題，但沒做好整個模型就白建了

需求訪談（這是資料科學家最該練的一項軟技能）

【問題一】漏掉一個（假陰性）會發生什麼事?
✗ 不要問：「Recall 要多少？」——臨床人員不知道你在說什麼
✔ 要問：「如果系統沒示警，但病人真的惡化了，後果是什麼？」
→ 得到：延誤治療的時數、可能的併發症、法律責任

【問題二】誤報一次（假陽性）會發生什麼事?
✔ 要問：「如果系統示警但其實沒事，誰要去做什麼？花多久？」
→ 得到：一次額外評估約 15 分鐘、需要一位護理師
★ 同時要問：「一天最多能承受幾次誤報？」——這決定你的門檻

【問題三】警報疲勞的臨界點在哪?
✔ 要問：「如果十次示警有九次是假的，你們還會理它嗎？」
→ 幾乎所有臨床人員的答案都是「不會」
★ 這比任何統計指標都重要：沒人理的系統，Recall 再高也等於零

【問題四】現在沒有系統的時候，是怎麼做的?
✔ 要問：「目前靠什麼發現？漏掉的比例大概多少？」
→ 得到「人的基準線」—— 你的模型要贏過的是這個，不是 0

★ 把答案換算成代價比例（例：漏報：誤報 = 200:3），
就能直接算出最佳門檻，而不是憑感覺設 0.5。

AI Studio 範例總覽（皆在 Repository，未複製）

主題	範例檔	資料集	對應章節
集成	Ensemble - bagging vote stacking Adaboost.rmp	Titanic、 WineData	PART 1–2
集成	Building Model - processes.rmp	—	PART 2
異常偵測	Anomaly Detection .rmp、 Anomaly - outlier detection.rmp	Boiler Sensor	PART 3
關聯規則	1. GOLF - FPGrowth association rules.rmp	Golf	PART 4
關聯規則	2. Market Basket Analysis.rmp	Transactions	PART 4
時間序列	Predict Crime Rate.rmp	Chicago Crimes 2001–2017	PART 5

Take-Home Assignment ｜ M4 進階監督式學習

W8 上課前繳交 • 不另計分（隨堂 Lab）

作業說明

【任務一】集成方法比較 （40%）
資料：Titanic（或自選有標籤的公開資料）
1. 建立基準線：單一決策樹，記錄 10-fold CV 的平均準確率「與標準差」
2. 分別跑 Bagging、AdaBoost、Vote（軟投票）、Stacking
3. 做成一張表：方法 / 平均準確率 / 標準差 / 訓練時間
4. 寫 200 字回答：
・哪一種方法主要改善了「平均」？哪一種主要改善了「標準差」？
・這個結果符合偏誤—變異的理論預期嗎?

【任務二】異常偵測與門檻設定 （30%）
資料：Boiler Sensor（或自選公開的感測器／生理訊號資料）
1. 先用肉眼標出你認為異常的區段（這是你的對照組）
2. 跑 IQR、LOF、Isolation Forest 三種方法
3. ★ Isolation Forest 的 contamination 分別設 0.01 / 0.05 / 0.10
4. 做成一張表：各方法抓到幾筆、彼此重疊多少、與你的標註吻合多少
5. 寫 150 字：如果每天只有 30 分鐘人力可以覆核，你會怎麼設門檻?

【任務三】關聯規則與 lift 陷阱 （30%）
資料：Transactions（或自選公開的交易／處方資料）
1. 跑 FP-Growth，min support = 0.01
2. 依 confidence 排序取前 10 條；再依 lift 排序取前 10 條
3. ★ 在 confidence 前 10 名中找出 lift 最低的一條規則
4. 寫 150 字：說明這條規則為什麼會誤導人，以及正確的判讀方式

【繳交】PDF 一份，含流程截圖與結果表。檔名：M4_學號_姓名.pdf

任務一紀錄表：五種方法的平均與標準差

方法	10-fold 平均準確率	標準差	訓練時間（秒）	與基準相比：平均／標準差
單一決策樹（基準）				—
Bagging				
AdaBoost				
Vote （軟投票）				
Stacking				

理論預期： Bagging 主要降標準差（變異）， AdaBoost 主要拉高平均（偏誤）。你的結果符合嗎？不符合也是發現——寫進那 200 字。

把 AI Studio 10-fold CV 的平均與標準差填進來（準確率用 0–1 或百分比皆可，但要一致）。網站版可直接填寫，會畫出「平均 ± 標準差」對照圖並可下載 CSV。

本模組重點回顧

1. 四大主題的共同點：不是「換更強的模型」，而是「換一種看資料的角度」
2. ★ Bagging 常降變異； Boosting 常先改善偏誤，但都要靠驗證確認 —— 先診斷症狀再開藥
3. 集成的前提是多樣性：成員必須「錯得不一樣」，否則白做
4. Stacking 的第一層必須用 out-of-fold 預測，否則嚴重洩漏
5. ★ 集成的代價是可解釋性；醫療場域要先問「這 0.01 值得嗎」
6. 異常有三種型態，多數人只想到「點異常」，但情境與集體異常更重要

M4 名詞速查表　集成・異常・關聯・時間序列

（1/6）

中文	English	一句話說明
集成學習	Ensemble Learning	組合多個模型的預測以提升表現與穩定性
偏誤	Bias	模型系統性偏離真實關係的程度；高偏誤＝欠擬合
變異	Variance	模型對訓練資料抖動的敏感程度；高變異＝過擬合
多樣性	Diversity	集成成員之間「錯得不一樣」的程度；集成有效的前提
拔靴抽樣	Bootstrap Sampling	有放回的隨機抽樣，每次抽 n 筆
袋外樣本	Out-of-Bag, OOB	未被某次拔靴抽中的樣本，約佔 36.8%，可當免費驗證集
Bagging	Bootstrap Aggregating	平行訓練多個模型再平均；主要降低變異
隨機森林	Random Forest	Bagging ＋ 每次分裂隨機抽特徵的決策樹集成
Extra Trees	Extremely Randomized Trees	分裂點也隨機取的森林；更快、變異更低

M4 名詞速查表　集成・異常・關聯・時間序列

（2 / 6）

中文	English	一句話說明
Boosting	Boosting	序列訓練，後者修正前者的錯；主要降低偏誤
弱學習器	Weak Learner	僅略優於隨機猜測的模型； Boosting 的基本成員
決策樁	Decision Stump	只有一層的決策樹，常用作 AdaBoost 的弱學習器
AdaBoost	Adaptive Boosting	調整樣本權重讓後續分類器專注於錯誤樣本
梯度提升	Gradient Boosting	以擬合殘差的方式逐步改善；可用於任意可微損失
學習率	Learning Rate / Shrinkage	每棵樹的貢獻比例；與樹的數量成交易關係
早停	Early Stopping	驗證分數不再進步即停止訓練，防止過擬合
逐層生長	Level-wise Growth	整層一起分裂（XGBoost）；樹形對稱、較穩定
逐葉生長	Leaf-wise Growth	每次挑增益最大的葉分裂（LightGBM）；更準更快但易過擬合

M4 名詞速查表　集成・異常・關聯・時間序列

（3 / 6）

中文	English	一句話說明
投票法	Voting	硬投票取多數決；軟投票平均各成員的機率
堆疊法	Stacking	以第二層模型學習如何組合第一層各模型的預測
元學習器	Meta-Learner	Stacking 的第二層模型，通常用簡單模型
折外預測	Out-of-Fold Prediction	以交叉驗證產生的預測值； Stacking 避免洩漏的關鍵
異常偵測	Anomaly Detection	找出與多數樣態明顯不同的資料點
點異常	Point Anomaly	單一資料點明顯偏離
情境異常	Contextual Anomaly	數值本身正常，但在該情境下不正常
集體異常	Collective Anomaly	單點皆正常，但一整段序列不正常
三倍標準差準則	3-Sigma Rule	以 $\mu \pm 3\sigma$ 為界；假設常態分布且易受離群值影響

M4 名詞速查表　集成・異常・關聯・時間序列

（4 / 6）

中文	English	一句話說明
四分位距	Interquartile Range, IQR	Q3−Q1；以 Q1−1.5IQR 、 Q3+1.5IQR 為界，穩健
中位數絕對離差	Median Absolute Deviation, MAD	以中位數為基礎的穩健離散度量
局部離群因子	Local Outlier Factor, LOF	比較自身與鄰居的密度； ≈ 1 正常、 >1 異常
孤立森林	Isolation Forest	以隨機切分所需路徑長度衡量異常；適合高維
單類別支援向量機	One-Class SVM	學習包住正常資料的邊界
汙染率	Contamination	預期的異常比例；直接決定會標出幾筆
精確率 @N	Precision@N	分數最高的 N 筆中真正異常的比例；無標籤時的務實指標
關聯規則	Association Rule	形如 A→B 的共現關係
支持度	Support	規則涵蓋的交易比例

M4 名詞速查表　集成・異常・關聯・時間序列

（5 / 6）

中文	English	一句話說明
信賴度	Confidence	P(B|A)；在 A 出現的條件下 B 出現的比例
提升度	Lift	P(B|A)/P(B)； >1 正相關、 =1 獨立、 <1 負相關
槓桿度	Leverage	P(A∩B)−P(A)P(B)；與獨立假設的差距
確信度	Conviction	(1−P(B))/(1−P(B|A))；越大關聯越強
頻繁項目集	Frequent Itemset	支持度高於門檻的品項組合
Apriori	Apriori Algorithm	逐層產生候選並剪枝；需多次掃描資料庫
FP-Growth	Frequent Pattern Growth	以前綴樹壓縮交易，只需掃描兩次
購物籃分析	Market Basket Analysis	關聯規則在零售交易上的典型應用
時間序列	Time Series	依時間先後排列的觀測值序列

M4 名詞速查表　集成・異常・關聯・時間序列

（6 / 6）

中文	English	一句話說明
滯後特徵	Lag Feature	以 n 期前的值作為特徵
移動平均	Moving Average	以滑動視窗計算的平均值，用於平滑波動
時間序列分解	Time Series Decomposition	拆解為趨勢、季節性與殘差三成分
自相關	Autocorrelation	序列與自身滯後版本的相關性
滾動驗證	Walk-forward Validation	測試集恆在訓練集之後的時間序列交叉驗證
天真預測	Naive Forecast	以前一期的值作為預測；最基本的基準線