

醫療 AI 的倫理、偏誤與可解釋性

M9 — Ethics, Bias & Interpretability in Health AI

前八個模組教你「做得出來」。這一個模組問三個不同的問題：
這樣做對嗎？對誰不公平？出事了誰負責？

本講義大綱

01 這個模組的定位 · 發表週的反思框架

02 三種真實的失敗 · 不是模型不準，是別的問題

03 三個案例深入 · 標籤偏誤 · 捷徑學習 · 誤用

04 偏誤怎麼進入系統 · 六個環節，而且會累積

05 代理變數 · 沒用種族欄位也會有種族偏誤

06 公平性的三種定義 · 而且它們互相衝突

07 不可能定理 · 這是數學必然，不是技術不足

08 子群體稽核 · 整體漂亮不代表對每個人都好

09 偏誤的四種類型 · 選擇 · 測量 · 標籤 · 部署

10 公平性的技術手段 · 三個介入時機

11 可解釋性的四個層次 · 本質 · 全域 · 局部 · 黑箱

12 SHAP 怎麼用與不能怎麼用 · 事後近似不是推理過程

13 責任邊界 · AI 介入程度的四個層級

14 自動化偏誤 · 介面越權威，人越不會質疑

15 生成式 AI 的六個新問題 · 以及它們的處方

16 四類法規要求 · 個資 · 醫材 · AI 專法 · 研究倫理

17 五個討論情境 · 來自歷屆專題的真實兩難

18 Grad-CAM · 檢查模型在看哪裡

19 模型卡 · 交付時該附的文件

20 貫穿八個模組的倫理線 · 不是最後才想的事

21 ★ 發表前自我檢核清單 · W10 與 W16 都要用

這個模組跟其他八個不一樣

① 它沒有「正確答案」

- ▶ 前面八個模組，每個問題都有技術上較好的解
- ▶ ★ 這個模組的核心問題是價值選擇：你要優先保障誰、願意犧牲什麼
- ▶ 所以本模組以討論為主，講述為輔

② 它不是「做完再想」的事

- ▶ 倫理反思不是專題最後補一頁投影片
- ▶ ★ 偏誤在「問題定義」那一刻就已經進來了——那是專題的第一步
- ▶ 本模組的檢核清單應該在你選定題目時就拿出來對照

③ 它是 W10 與 W16 的評分項目

- ▶ W10 案例研究發表：明列「限制與倫理反思」
- ▶ W16 期末專題發表：★ 醫療場域的四條紅線屬「不符即扣分」
- ▶ 本模組最後的檢核清單，就是你發表前該逐項確認的東西

※ 建議在 W10 發表前一週講授前半（偏誤與公平性），W16 前複習後半（責任與檢核清單）。

三種真實的失敗：都不是「模型不夠準」

失敗類型	實際情況	為什麼指標看不出來	對應本模組章節
★ 學到錯的東西	肺炎判讀模型靠「攜帶式 X 光機標記」在猜（M5 提過）	原醫院內測 AUC 0.93、指標全過；換到外院才明顯下降（Zech et al., 2018）	PART 4 可解釋性 → 用 Grad-CAM 檢視
★ 對某些人特別不準	整體 AUC 0.842，但 80 歲以上只有 0.771 非都會區只有 0.782	整體指標被多數群體主導，少數群被平均掉	PART 3 子群體稽核
★ 準確但不該用	高精確度的再入院預測，被用來決定「誰不值得投入資源」	技術上完全沒問題；問題在使用方式	PART 5 責任邊界

★ 三者的共同點：模型評估指標全部通過。這說明「準確率高」跟「可以用」是兩件事——而後者不是技術問題。

案例一：用「醫療花費」當作「醫療需求」

最著名的醫療 AI 偏誤案例，也是最好懂的一個

標籤偏誤的經典案例

【背景】某大型醫療系統要找出「高風險、需要額外照護資源」的病人

【技術決策】

問題：「醫療需求高」沒有現成欄位可以當標籤

解法：用「未來一年的醫療花費」當作代理指標

理由：★聽起來完全合理——病得重的人花費自然高

【結果】

模型準確率很好，成功預測了醫療花費

★但在「同樣的健康狀況」下，黑人病患被判定的風險分數系統性偏低

→ 因此較少被納入額外照護計畫

【為什麼】

★花費低 ≠ 健康。弱勢族群花費低是因為可近性差、付不起、

以及歷史上的醫療不平等造成的迴避

模型忠實學到「這群人花費少」，並把它解讀成「這群人需求低」

【關鍵觀察】

★模型從頭到尾沒有使用「種族」這個欄位

★偏誤不是來自演算法，是來自「標籤的定義」（標籤偏誤）

★所有技術指標都正常——沒有任何一個評估數字會告訴你出事了

【對你的意義】

下次你要用一個代理指標時，問自己：

「這個代理指標，對哪一群人特別不準？為什麼？」

案例二：模型學到「錯的東西」

發生了什麼

- ▶ 某肺炎判讀模型在單一醫院準確率超過 90%
- ▶ 換一家醫院測試，表現大幅下降
- ▶ ★ 事後用 Grad-CAM 檢視，發現它在看「影像角落的標記」
- ▶ 原因：攜帶式 X 光機片子有特定標記，而重症病人才用攜帶式
- ▶ ★ 模型從未學會看肺部，它學會了看標記

為什麼沒被發現

- ▶ 準確率、AUC、Recall 全部通過
- ▶ ★ 院內測試集與訓練集來自同一個分布，標記的相關性一樣成立
- ▶ 只有做「外部驗證」才會露餡
- ▶ ★ 這是為什麼 M5 說：外部驗證是必要條件，不是加分項
- ▶ 以及為什麼 Grad-CAM 值得花時間看

★ 表格資料一樣會發生：某個欄位與標籤高度相關但沒有因果，例如「已開立會診單」預測「重症」。

案例三：準確，但不該這樣用

情境

- ▶ 一個準確率很高的再入院預測模型
- ▶ 管理者提議：把資源優先給「預測不會再入院」的病人
- ▶ 理由：★「投資報酬率比較高」
- ▶ 技術上完全沒問題 —— 模型也確實準確
- ▶ ★ 但這等於把資源從最需要的人身上移開

問題出在哪

- ▶ ★ 模型回答的是「會不會發生」，不是「值不值得投入」
- ▶ 把預測結果直接當成資源分配依據，中間跳過了價值判斷
- ▶ 而那個價值判斷，本來應該由人明確地做並負責
- ▶ ★ 這種失敗，任何技術檢核都攔不下來
- ▶ 只有「有人問了這個問題」才攔得下來

★ 這是為什麼本模組排在課程後段但要求貫穿全期：技術做得越好，這類問題的後果越大。

PART 01

偏誤是怎麼進來的

How Bias Enters the System

不是有人故意做壞。

偏誤在每一個技術決策裡悄悄累積，而每一步看起來都很合理。

偏誤進入系統的六個環節

從問題定義到部署使用，偏誤有六次進入系統的機會



★ 偏誤會沿著流程累積：每一環都在前一環的基礎上再疊一層

① 問題定義	「醫療需求高」→ 用「醫療花費高」代替。但弱勢族群花費低不是因為健康，是因為看不起病				
② 資料蒐集	偏鄉、無健保、外籍移工的資料本來就少 → 模型對他們的預測必然不準				
④ 特徵選擇	郵遞區號、就醫院所、保險別 —— 這些都是族群與社經地位的代理變數				
⑥ 部署使用	臨床人員看到分數就照做，不再自己判斷 —— 自動化偏誤（Automation Bias）				

★ 真實案例：美國商用風險演算法以「花費」代理「需求」（Obermeyer et al., 2019）

結果：同樣病情下，黑人病患被判定的風險分數系統性偏低，因為他們歷史上的醫療花費較少。

★ 模型沒有用到「種族」這個欄位，卻產生了種族偏誤 —— 這就是代理變數的威力。

① 問題定義

把「醫療需求」代換成「醫療花費」——
★ 弱勢族群花費低不是因為健康，是因為看不起病。

② 資料蒐集

偏鄉、無健保、外籍移工的資料本來就少 → 模型對他們的預測必然不準。


★ ④ 特徵選擇

郵遞區號、就醫院所、保險別——
這些都是族群與社經地位的代理變數。

⑥ 部署使用

臨床人員看到分數就照做，不再自己判斷。
這叫自動化偏誤。

偏誤的四種類型：各自要用不同方法檢查



① 選擇偏誤

誰進得了資料庫。偏鄉、無健保、不就醫的人不在裡面。
→ 把資料的人口結構與母體比對。

② 測量偏誤

同一件事被測得不一樣。不同院所的檢驗標準與儀器不同。
→ 檢查各來源的分布是否一致。

★ ③ 標籤偏誤

標準答案本身有偏。用「醫療花費」當「醫療需求」的代理。
→ 追問標籤怎麼來、算標註一致性（Kappa，M6）。

④ 部署偏誤

用在非預期的場景。為 A 醫院訓練卻用在 B 醫院。
→ 外部驗證、明訂適用範圍。

四種偏誤的具體檢查動作

類型	檢查方法	要看什麼數字	發現問題怎麼辦
選擇偏誤	資料的人口結構 vs 服務區母體	各年齡層／地區的佔比差異	★ 補資料；或明訂適用範圍並揭露
測量偏誤	按資料來源（院所、儀器、期間）分組看分布	各組的平均、標準差、缺值率	標準化轉換；或把來源當成特徵
標籤偏誤	★ 追問「這個標籤實際上是怎麼產生的」	多人標註的 Kappa 一致性	重新定義標籤；多人標註並仲裁
部署偏誤	★ 用另一機構／另一時期的資料測試	外部驗證的表現掉多少	限定適用範圍；或重新訓練

★ 第三列的「追問標籤怎麼來」是最有價值也最少人做的一步。很多專題直接接受資料附的標籤，從沒問過它代表什麼。

代理變數：沒用種族欄位，也會產生種族偏誤

常見的代理變數

- ▶ 郵遞區號 → 族群、社經地位、居住區域
- ▶ 保險別（健保／自費／福保）→ 經濟狀況
- ▶ 就醫院所層級 → 城鄉、可近性
- ▶ ★ 過去醫療花費 → 就醫可近性，不是健康需求
- ▶ 教育程度、職業別 → 社經地位
- ▶ 手機型號、上網時間 → 消費能力（數位服務常見）

怎麼檢查

- ▶ ★ 把受保護屬性（年齡、性別、地區）當成「標籤」，用其他特徵去預測它——預測得越準，代理越強
- ▶ 檢視特徵重要性排行，逐一問「這個欄位為什麼有預測力」
- ▶ 拆到子群體看表現差異（PART 3）
- ▶ ★ 拿掉可疑欄位重跑，看整體表現掉多少、公平性改善多少

★ 關鍵觀念：把敏感欄位刪掉，並不能消除偏誤——因為其他欄位仍然攜帶那個資訊。這叫「透過不知情達成公平」的謬誤。

PART 02

公平性

Fairness

「這個模型公平嗎？」——這個問題沒辦法用一個數字回答。
因為公平有好幾種定義，而它們互相衝突。

公平性的三種主要定義


定義	要求什麼	白話說	什麼時候適合
人口平價 Demographic Parity	各群體「被選中的比例」相同	每一群被標記為高風險的人數比例一樣	資源分配、機會給予（如篩檢名額）
機會均等 Equal Opportunity	各群體的「召回率」相同	★ 真正需要的人，在每一群被抓到的比例一樣	★ 醫療篩檢最常用——漏掉病人的代價最高
預測平價 Predictive Parity	各群體的「精確率」相同	被標記的人當中，真的有問題的比例一樣	資源有限、誤報成本高時

★ 還有第四種：個體公平（相似的人得到相似的對待）。但「什麼叫相似」本身就需要價值判斷。

三種定義互相衝突：具體算給你看

情境：再入院風險模型 | A 群盛行率 20% B 群盛行率 10% | 各 1,000 人

① 強制「選出率相同」 人口平價



選出率相同 (○) 但 B 群精確率只有 0.450 (×)
★ 被標記的人超過一半其實不會再入院

② 強制「精確率相同」 預測平價



精確率相同 (○) 但 B 群召回率只有 0.600 (×)
★ B 群有更多真正需要的人被漏掉

★ 不可能定理：盛行率不同時，除非模型完美預測，三種定義無法同時滿足（Kleinberg, 2016）。

這不是演算法不夠好，也不是資料不夠多。這是數學上的必然。

★ 所以「這個模型公平嗎」不是技術問題，是價值選擇：

你要優先保障誰、願意犧牲什麼。這必須由人來決定並負責。

情境

A 群盛行率 20%、B 群 10%，各 1,000 人。

① 強制選出率相同

兩群都選 200 人。但 B 群精確率只有 0.450——

★ 被標記的人超過一半其實不會再入院。

② 強制精確率相同

兩群精確率都 0.750。但 B 群召回率只有 0.600——

★ 有更多真正需要的人被漏掉。

★ 不可能定理

盛行率不同時，除非模型完美預測，三種定義無法同時滿足。

這不是演算法不夠好，是數學必然。

所以「公平」該怎麼處理

① 先承認你必須選一個

- ▶ ★ 不能說「我們的模型是公平的」——要說「我們選擇以機會均等為準」
- ▶ 並說明為什麼：在這個場景，漏掉真正需要的人代價最高
- ▶ 這個選擇要寫進文件，並由能負責的人拍板

② 選定之後，量化並持續監測

- ▶ 把選定的指標拆到每個子群體去算（下一節）
- ▶ 設定可接受的差距門檻（如各群召回率差距不超過 0.05）
- ▶ ★ 上線後定期重算——族群結構會變，模型表現也會漂移


③ 技術手段有限，要搭配流程

- ▶ 技術面：重抽樣、調整各群門檻、公平性正則化
- ▶ ★ 但真正有效的往往是流程面：對表現較差的群體加強人工覆核
- ▶ 以及最根本的：回去補那些群體的資料


★ 給專題的具體要求：發表時要能回答「你的模型對哪一群人最不準？你怎麼知道？打算怎麼處理？」

子群體稽核：交付前一定要做的一張表

同一個模型，拆到子群體去看 AUC



樣本數少的群體，表現往往也差



整體 AUC 0.842 看起來不錯

但 80 歲以上只有 0.771、非都會區只有 0.782。

★ 而這兩群往往正是最需要這個模型的人

高齡、偏鄉——
他們的資料最少，模型對他們也最不準。

樣本數與表現高度相關

右圖看得很清楚：樣本少的群體，表現往往也差。

★ 整體 AUC 0.842 看起來不錯，但 80 歲以上只有 0.771、非都會區只有 0.782。

而這兩群往往正是最需要這個模型的人——高齡、偏鄉，他們的資料最少，模型對他們也最不準。

★ 交付任何模型前，一定要做這張表。它不難做，但很少人做。

★ 怎麼做

按年齡、性別、地區、保險別、科別各拆一次，
算同一個指標。這張表不難做，但很少人做。

子群體稽核的實作步驟

AI Studio 或 Python 都能做；重點是「記得做」

子群體稽核（發表時要附這張表）

【步驟一】決定要拆哪些子群體

必查：年齡層、性別、地區（都會／非都會）

視情境加查：保險別、科別、就診院所層級、族群、語言

★ 原則：所有「可能影響資源可近性」的維度都該查

【步驟二】對每個子群體算同一組指標

子群體	n	AUC	Recall	Precision	實際陽性率	
整體	5000	0.842	0.781	0.664	0.184	
65 歲以下	1800	0.861	0.812	0.690	0.142	
65–79 歲	2100	0.848	0.795	0.671	0.191	
★ 80 歲以上	1100	0.771	0.684	0.598	0.238	← 最差
都會區	3900	0.858	0.803	0.682	0.176	
★ 非都會區	1100	0.782	0.701	0.611	0.212	← 次差

【步驟三】判讀

① 差距多大？AUC 差 0.07 以上通常值得處理

② ★ 是不是「樣本少」造成的？看 n 欄—— 1,100 vs 3,900

③ ★ 是不是「盛行率不同」造成的？看最後一欄—— 0.238 vs 0.176
盛行率不同時，精確率本來就會不同（回想不可能定理）

【步驟四】處理與揭露

- 技術面：對弱勢群體單獨調整門檻、加權訓練、補資料
- 流程面：★ 這兩群的預測結果一律加註「建議人工覆核」
- 文件面：★ 把這張表放進交付文件與發表投影片 —— 不要藏起來

★ 誠實揭露限制，比宣稱「我們的模型很公平」專業得多。

PART 03

可解釋性

Interpretability

「為什麼是這個答案？」

在醫療場域，回答不出這個問題，模型就推不動。

可解釋性的四個層次與對應工具

可解釋性 Interpretability

模型本身的透明度：高 → 低

對「事後近似」的依賴：低 → 高

① 本質可解釋

Intrinsic

- 線性／邏輯斯迴歸
- 決策樹（淺）
- 規則式系統
- GAM 廣義加法模型

★ 模型本身就看得懂
不需要額外工具

② 全域解釋

Global

- 特徵重要性
- 部分依賴圖 PDP
- SHAP 摘要圖
- 替代模型 Surrogate

整體而言模型看重什麼
★ 用來檢查有無捷徑學習

③ 局部解釋

Local

- SHAP 單筆解釋
- LIME
- 反事實解釋
- Grad-CAM（影像）

★ 這一筆為什麼被判成這樣
臨床溝通的關鍵

④ 不可解釋

Black Box

- 深層神經網路
- 大型語言模型
- 複雜集成
- 多模型串接的系統

只能事後近似
★ 高風險場景要三思

★ 一個常被誤解的重點：SHAP 與 LIME 是「事後近似」，不是模型真正的推理過程。

它們告訴你「哪些特徵對這個預測貢獻最大」，但那是用另一個簡單模型去逼近黑箱的結果。

★ 因此：如果可解釋性是硬需求，優先選①本質可解釋的模型，而不是「先用黑箱再加 SHAP」。

① 本質可解釋

線性／邏輯斯迴歸、淺決策樹、規則式。
模型本身就看得懂，不需要額外工具。

② 全域解釋

特徵重要性、PDP、SHAP 摘要圖。
★ 用來檢查有無捷徑學習。

③ 局部解釋


SHAP 單筆、LIME、Grad-CAM。
★ 「這一筆為什麼被判成這樣」——臨床溝通的關鍵。

★ 常被誤解的重點

SHAP 與 LIME 是「事後近似」，不是模型真正的推理過程。
若可解釋性是硬需求，優先選①，而不是「先用黑箱再加 SHAP」。

SHAP 實例：怎麼用、以及不能怎麼用

SHAP 瀑布圖：這一位病人為什麼被判高風險



最終預測 0.46 = 基準 0.18 + 貢獻 0.28

可以這樣跟臨床同仁說

「系統判定這位個案再入院風險 46%，
主要因為：高齡 82 歲、共病 5 項、
一個月內剛住過院、獨居。
唯一的保護因子是有規律回診。」

★ 這樣說，對方能判斷合不合理

★ 但要誠實說明它的限制

- SHAP 值是「事後近似」，不是模型真正的推理過程
- 數值會隨參照資料集改變
- ★ 它顯示「相關貢獻」，不是因果

★ 最重要的一句：不能拿來說「讓他不獨居就會降低風險」——那是把相關當成因果。

SHAP 只回答「在這個模型裡，哪些欄位把這一筆的分數推高或拉低」，
它不回答「改變這個欄位會不會改變真實世界的結果」。那需要因果推論或試驗設計。

怎麼讀

從基準值出發，每個特徵推高或拉低預測值，
最後得到這一筆的預測機率。

★ 怎麼跟臨床說

「風險 46%，主要因為高齡、共病 5 項、
一個月內剛住過院、獨居；保護因子是有規律
回診。」

★ 三個限制要誠實說


- ① 事後近似，不是真正的推理過程
- ② 數值會隨參照資料集改變
- ③ 顯示相關貢獻，不是因果

★ 最重要的一句

不能拿來說「讓他不獨居就會降低風險」——
那是把相關當成因果。


Grad-CAM：檢查模型「在看哪裡」

輸入：胸部 X 光（示意）




模型判定：肺炎陽性 信心 0.91

★ 合理：注意力在肺野病灶區



熱區落在右下肺野 —— 該看的地方

★ 危險：注意力在角落標記上



熱區落在攜帶式機器標記 —— 捷徑學習

熱區強度  低 → 高

★ 兩張熱區圖對應的準確率可能一模一樣。差別只有 Grad-CAM 看得出來。

這就是 M5 講過的捷徑學習：模型學到了跟標籤相關、但跟疾病無關的線索。

★ 具體作法：抽 20 筆模型判「陽性」的案例，請臨床專家看熱區圖，問「它是不是在看該看的地方」。

中間：合理

注意力落在肺野病灶區——這是我們希望看到的。

★ 右邊：危險

注意力落在影像角落的標記上。
這就是 M5 講過的捷徑學習。

★ 兩者準確率可能一模一樣

差別只有 Grad-CAM 看得出來。

★ 具體作法

抽 20 筆模型判「陽性」的案例，請臨床專家看熱區圖，
問「它是不是在看該看的地方」。

不同對象要不同的解釋

對象	他們要知道什麼	適合的呈現方式	★ 常見的錯誤
臨床人員	這一筆為什麼被判高風險，合不合理	SHAP 單筆貢獻 + 命中的關鍵欄位	給一個分數就沒了
病人與家屬	這對我意味著什麼、我能做什麼	★ 白話說明 + 可行動的建議 + 明確免責	丟給他們技術圖表
管理者	整體效益、風險、成本	整體與子群體表現 + 誤判成本估算	只報準確率
資訊／稽核	模型怎麼建的、資料從哪來、怎麼監測	★ 完整技術文件 + 資料血緣 + 監測計畫	口頭說明
法規／IRB	風險等級、個資處理、人為監督機制	風險評估文件 + 去識別化說明	事後才想到要申請

★ 專題發表時，你面對的是「管理者 + 資訊稽核」的混合對象——所以整體表現、子群體表現、限制與監測計畫都要講到。

PART 04

責任邊界

Accountability

模型給了建議，人照做了，結果錯了——誰負責？
這個問題目前沒有標準答案，但你的設計會決定答案。

AI 介入程度的四個層級

從左到右，系統做的決定越來越多、人能推翻的空間越來越小



★ 課程專題一律停在①或②。這不只是保守，是責任歸屬還沒有明確答案。

目前實務共識：AI 是工具，最終決定與責任仍在專業人員身上。所以介面設計必須讓人「容易推翻它」。

★ 設計上要小心「自動化偏誤」：介面越權威、越像已成定局，人就越不會去質疑它。

① 資訊提供

整理資料、呈現數字，不做判斷。責任風險低。

② 輔助判斷

提供分數或建議，★ 人做最終決定。這是醫療場域的主流定位。

③ 條件式自動

符合條件即自動執行，但可被推翻。

★ ④ 完全自動

醫療場域幾乎不應採用。
★ 課程專題一律停在①或②。

自動化偏誤：設計上最該小心的一件事

① 什麼是自動化偏誤

- ▶ 人傾向過度信任自動化系統的輸出，即使自己的判斷不同
- ▶ ★ 研究顯示：即使系統明顯出錯，仍有相當比例的使用者選擇跟從
- ▶ 越忙、越累、越沒把握的時候，越容易發生——而臨床正是這種環境

② 介面設計會放大或減緩它

- ▶ ★ 放大：只給一個分數、用權威的紅色警示、預設值就是採納建議
- ▶ ★ 減緩：同時顯示依據與不確定性、要求使用者輸入自己的判斷、讓「不採納」跟「採納」一樣容易操作
- ▶ 把「AI 建議」與「你的判斷」並列，而不是讓 AI 先講

③ 實務作法

- ▶ 顯示信心區間或「本次預測不確定性較高」的標示
- ▶ ★ 記錄使用者是否採納，定期檢視採納率——
如果採納率 99%，那不是模型很準，是沒有人思考
- ▶ 定期做「無 AI 對照」的抽樣，比較有無系統的決策品質

★ 這一頁對做 Dify 專題的同學特別重要：你的 Chatbot 介面怎麼呈現，會直接影響使用者要不要質疑它。

公平性的技術處理手段：三個介入時機

時機	手法	做什麼	優點與限制
前處理 Pre-processing	重抽樣、重加權、 移除代理變數	調整訓練資料的組成	★ 與模型無關、可解釋；但可能損失資訊
訓練中 In-processing	公平性正則化、 對抗式去偏	把公平性當成損失函數的一部分	效果直接；但需要改演算法、較難實作
後處理 Post-processing	★ 各群體用不同的決策門檻	訓練照常，預測後再調整	★ 最容易實作；但「不同群不同標準」在法律與倫理上可能有爭議

★ 第三列的爭議值得討論：對 80 歲以上族群用較低的門檻，是「補償他們資料少」還是「差別待遇」？這正是本模組要練的判斷。

技術手段之外，三個更有效的作法

① 回去補資料

- ▶ ★ 這是最根本的解法，也是最少人做的
- ▶ 不必補到平衡，只要讓弱勢群體的樣本數達到可靠的最低量
- ▶ 跨機構合作、延長蒐集期間、針對性補樣

② 對表現差的群體加強人工覆核

- ▶ ★ 不改模型，改流程：這兩群的預測一律加註「建議人工覆核」
- ▶ 成本低、立即可行、且責任歸屬清楚
- ▶ 實務上這往往比任何演算法調整都有效

③ 明訂適用範圍並誠實揭露

- ▶ 「本模型在 80 歲以上族群的表現顯著較差，該族群不建議單獨依賴」
- ▶ ★ 寫進模型卡、寫進交付文件、寫進發表投影片
- ▶ 這不是承認失敗，這是專業

模型卡：交付模型時該附的說明文件

模型卡 Model Card 七個欄位 該寫什麼（改編自 Mitchell et al., 2019）

誰會讀它 | 交付前打勾

① 基本資訊

模型名稱、版本、日期、開發者、聯絡窗口

接手的人

☐

② 預期用途

★ 設計來做什麼、給誰用、在什麼場景

使用者

☐

③ 不適用範圍

★ 明確寫出「不該用在哪裡」——這一項最重要也最常缺

使用者／法務

☐

④ 訓練資料

來源、期間、樣本數、涵蓋的族群與院所

資訊／稽核

☐

⑤ 評估結果

整體指標 + ★ 各子群體指標（年齡、性別、地區）

管理者

☐

⑥ 已知限制

對哪些群體較不準、在什麼情況會失效

臨床人員

☐

⑦ 倫理考量

公平性選擇與理由、去識別化方式、人為監督機制

IRB／評審

☐

★ 這七項寫下來大約兩頁 A4。專題交付時附上它，專業度立刻不同——而且逼你自己想清楚。

★ 第③項「不適用範圍」是最常被省略的一項，也是接手的人最需要的一項。

★ 第③項最重要也最常缺

「不適用範圍」——明確寫出這個模型不該用在哪裡。

第⑤項要拆子群體

不是只放整體指標，要放各年齡層、地區的表現。

兩頁 A4 的份量

不多，但逼你自己把事情想清楚。

★ 對專題的意義

交付時附上模型卡，專業度立刻不同。這是本模組建議的最具體產出。

模型卡範例（上）：用途、來源與評估

以 M8 期末專題為例，實際填一份給你看

模型卡範例（一）

① 基本資訊

名稱：長照給付試算助理 版本：v1.0 日期：2027-06-01
開發者：○○組（4 人） 聯絡窗口：○○○

② 預期用途

協助長照個管人員與家屬，依個案描述查詢可能適用的給付項目與額度上限。

★ 定位：資訊提供／輔助判斷。不做等級核定，不取代照管專員評估。

③ 不適用範圍 ★ 這一項最重要，也最常被省略

- 不得用於：正式的等級核定、給付金額的最終認定
- 不得用於：任何醫療診斷或用藥建議
- 不適用對象：法規未涵蓋的特殊個案、跨縣市差異性給付
- 時效限制：知識庫為 2027 年版法規，法規修訂後未更新前不應使用

④ 訓練／知識來源

衛福部公開之長照 3.0 給付及支付基準（2027 年版）、CMS 評估量表說明。

★ 未使用任何真實個案資料；測試個案為虛構。

⑤ 評估結果

30 題測試集：等級判定正確率 26/30（86.7%）

★ 金額計算正確率 30/30（由程式碼節點查表，非模型生成）

子群體：資訊完整的個案 20/20；★ 資訊不足的個案僅 6/10

模型卡範例（下）：限制與倫理考量

注意最後一行——誠實寫出「還沒做的事」

模型卡範例（二）

⑥ 已知限制

- 個案資訊不足時，容易直接給等級而非追問（4 筆失敗案例全屬此類——這是目前最主要的弱點）
- 多重障礙合併的複雜個案未充分測試
- 知識庫外的問題約 8% 未正確回覆「查無相關資料」
- 僅測試 30 題，樣本數不足以支撐統計推論

⑦ 倫理考量

- 所有輸出附「僅供參考，實際給付以照管專員評估結果為準」
- 不提供醫療建議；用藥與診斷相關提問一律導向專業人員
- 金額由程式碼節點查表計算，不由模型生成（避免數值幻覺）
- API 金鑰未寫入 DSL；匯出檔可安全提交
- 未使用真實個案資料，無個資疑慮

★ 尚未建立的機制（誠實揭露）：

- 無監測機制。若實際導入，需指定專人季度覆核法規更新
- 無使用紀錄與回饋迴路，無法得知實際採納率
- 未做使用者測試，不知道介面是否會誘導盲目採納

★ 最後這三行才是這份文件最有價值的地方。

寫出「還沒做的事」，比宣稱「已經很完整」專業得多——而且它直接告訴接手的人：下一步該做什麼。

PART 05

生成式 AI 與法規

GenAI Ethics & Regulation

M7 與 M8 教的護欄，在這裡變成倫理要求。

生成式 AI 帶來的六個新問題

① 幻覺無法根除

M7 講過：這是機率生成的必然產物

→ RAG 提供事實、程式碼接管數值、人工覆核

② 說不出資料來源

模型不知道某個說法從哪學來

→ 用 RAG 才能標註來源 (M8)

③ 訓練資料的版權與同意

病歷有無同意用於訓練

→ 課程一律用公開或虛構資料

④ 流暢度 ≠ 正確性

講得越順越容易被相信

→ 介面主動標示不確定性與免責

⑤ 提示詞注入

使用者可能誘導模型繞過限制

→ 輸出端也要驗證，不能只靠 Prompt

⑥ 使用紀錄外流

對話內容送到雲端就收不回

→ 敏感資料用本地模型 (M7 Ollama)

★ 注意：六個問題的處方，全部都在 M7 與 M8 教過了。

這不是新的技術挑戰，是「你有沒有把學過的護欄真的裝上去」的問題

—— 而那是專業判斷與紀律，不是技術能力。

① 幻覺無法根除

機率生成的必然產物 (M7)。
→ RAG 提供事實、程式碼接管數值、人工覆核。

④ 流暢度 ≠ 正確性

講得越順越容易被相信。
→ 介面主動標示不確定性與免責。

⑤ 提示詞注入

使用者可能誘導模型繞過限制。
→ 輸出端也要驗證，不能只靠 Prompt。

★ 注意

六個問題的處方全部都在 M7、M8 教過了。
這不是新的技術挑戰，是「你有沒有真的把護欄裝上去」。

醫療 AI 的四類法規要求

※ 本頁為 2026 年 9 月概況整理，非法律意見

個人資料保護

個資法、GDPR

- 蒐集目的特定與告知
- ★ 去識別化的程度要求
- 跨境傳輸限制
- 當事人權利（查詢、刪除）
- 告知同意的取得與紀錄

醫療器材管理

醫材法規、SaMD

- 軟體也可能是醫材
- ★ 用於診斷／治療決定
→ 需查驗登記
- 臨床驗證要求
- 上市後監督與事件通報

AI 專法

★ EU AI Act

- 醫療 AI 屬「高風險」類別
- ★ 醫材類義務延至 2028/8（2026 修法）
- 要求：資料治理、透明度、人為監督、風險管理
- 技術文件與紀錄保存

研究倫理

IRB / 人體研究法

- ★ 使用病歷做研究需 IRB
- 知情同意或免除同意
- 資料保存與銷毀規範
- 利益衝突揭露
- 共享決策與病人參與

個資保護

個資法、GDPR。★ 去識別化的程度要求、跨境傳輸限制。

醫療器材管理

★ 軟體也可能是醫材。用於診斷／治療決定
→ 需查驗登記。

★ AI 專法

EU AI Act 把醫療 AI 列為「高風險」，2026 年修法後，醫材類高風險義務延至 2028/8 適用。台灣《人工智慧基本法》2025 年底三讀。

研究倫理

★ 使用病歷做研究需 IRB。這是最容易被學生忽略的一項。

★ 決策點：你的專題要不要碰上面這四類？



★ 對課程專題的實際意義：只要你用「公開資料或完全虛構的資料」，上面四項多數都不會觸及。

※ 本頁為 2026 年 9 月的概況整理，非法律意見。實際導入前務必諮詢機構法務與 IRB。

專題常見的四個法規誤解

誤解	事實	對專題的意義
「資料去識別化了就沒事」	★ 去識別化不等於絕對安全：罕見疾病 + 特定年齡 + 地區的組合仍可能識別出個人	課程一律用公開資料或完全虛構的資料
「只是課堂作業，不用申請 IRB」	★ 只要使用真實病歷（即使去識別化），多數機構都要求 IRB 或至少免除審查同意	★ 這是本課程禁止使用真實病歷的主要原因之一
「我只做輔助建議，不算醫材」	用於「診斷、治療決定」的軟體可能被認定為醫材，與是否稱為「輔助」無關	專題定位在①資訊提供或②輔助判斷，並明確標示
「用雲端 API 只是傳文字，沒關係」	★ 傳出去的內容就在對方伺服器上了，收不回來	敏感資料一律用本地模型（M7 Ollama）
★ 課程的處理方式很簡單：全部用公開或虛構資料，就能避開上述絕大多數問題，同時仍能完整練習方法。		

倫理與可解釋性如何貫穿前八個模組

模組	當時教的技術	對應的倫理／可解釋議題
M1 資料工程	缺值、離群值、正規化	★ 缺值不是隨機的（MNAR）——誰的資料常缺？刪掉他們等於排除他們
M2 監督式學習	分類、評估指標、類別不平衡	★ 選哪個指標＝選擇「哪一種錯誤比較能接受」，那是價值判斷
M3 非監督式	分群、降維	分群結果的命名會固化刻板印象（如把某群稱為「高風險族群」）
M4 進階監督式	集成、異常偵測、代價敏感	★ 集成的可解釋性代價；異常偵測的門檻＝決定誰被盯上
M5 深度學習	CNN、遷移學習	★ 捷徑學習、外部驗證、黑箱的可解釋性難題
M6 NLP	文字探勘、去識別化	★ 去識別化不等於安全；標註品質決定模型天花板
M7 生成式 AI	LLM 原理、幻覺、部署	★ 幻覺無法根除；資料能不能出機構是第一個問題
M8 Dify	RAG、Agent、HITL	★ 責任邊界、人在迴路、四條紅線

★ 這張表說明：倫理不是最後一個模組的內容，而是每個模組都埋著的線。這一週只是把它們串起來講清楚。

隨堂檢核 | 倫理判斷

Q
1

你的模型沒有使用「性別」欄位，是否就不會有性別偏誤？

不是。其他欄位可能是性別的代理變數（如就診科別、用藥類別、身高體重）。正確作法是把性別當標籤、用其他特徵去預測它——預測得越準，代理越強；並做子群體稽核，看實際表現是否有差距。

Q
2

有人問「你的模型公平嗎」，你該怎麼回答？

不能直接說「公平」。要說：「我們選擇以機會均等為標準，因為在這個場景漏掉真正需要的人代價最高。各群召回率差距為 0.08，主要落差在高齡族群，我們的處理是對該族群一律加註建議人工覆核。」——說清楚選了什麼標準、為什麼、差距多大、怎麼處理。

Q
3

模型準確率 94%，但你發現它對某群人只有 0.77。要不要上線？

這沒有標準答案，但要能說出理由。可考慮的路徑：① 限定適用範圍（該群不使用）；② 上線但對該群強制人工覆核；③ 延後上線補資料。三種都可以，關鍵是——這個決定要由能負責的人做，且必須被誠實揭露，不能藏在附錄裡。

Q
4

你的 Chatbot 使用者採納率高達 99%，這是好消息嗎？

不是。這很可能是自動化偏誤——沒有人在真正思考，只是照著做。合理的採納率應該有一定比例的不採納。應該檢查：介面是否誘導盲目採納？不採納跟採納一樣容易操作嗎？有沒有顯示判斷依據讓人能質疑？

怎麼跟不同對象說明模型的限制

對象	不要這樣說	★ 要這樣說
臨床人員	「模型準確率 94%」	「這個分數主要來自這四個欄位。它對 80 歲以上較不準，那群請務必自行覆核。」
管理者	「這是最先進的深度學習」	「它能把每天要看的 500 筆縮到 50 筆。誤判會發生，我們建議這樣接住。」
病人與家屬	「系統評估您的風險是 46%」	「這是一個參考指標，主要因為年齡與最近的住院紀錄。實際情況請與醫師討論。」
同儕與評審	「我們的模型很公平」	★「我們選擇以機會均等為公平標準，因為漏掉真正需要的人代價最高。各群召回率差距為 0.08，主要落差在高齡族群。」

★ 共同點：右欄都比左欄長。誠實的說明本來就比較費口舌——但那正是專業與話術的差別。

這門課想留給你的三件事

① 工具會過時，判斷不會

- ▶ 這學期學的 AI Studio、Dify、某某模型，五年後可能都換了
- ▶ ★ 但「這個問題該用什麼方法」「這個結果可不可信」「這樣用對不對」——這三個判斷不會過時
- ▶ 所以每個模組都花時間在「什麼時候不該用」

② 你的領域知識是稀缺的，不是次要的

- ▶ ★ 會寫程式的人很多，看得懂護理紀錄又會分析的人很少
- ▶ 主題模型跑出一組詞，資工背景的人不知道那代表什麼，你知道
- ▶ 「這個標籤實際上是怎麼產生的」——只有你問得出來

③ 誠實比聰明重要

- ▶ ★ 主動揭露限制、承認不確定、說得出模型對誰不準
- ▶ 在醫療場域，一個被過度宣稱的模型造成的傷害，遠大於一個誠實的爛模型
- ▶ 這是本模組、也是整門課最後想說的一句話

PART 06

課堂討論與自我檢核

Discussion & Self-Check

以下五個情境都改編自歷屆專題遇到的真實兩難。
沒有標準答案——但你要能說出你的理由。

五個討論情境

#	情境	要討論什麼
1	再入院預測模型準確率很高，管理者想拿它來決定「哪些病人值得投入出院準備資源」。	★ 技術上沒問題，但這樣用對嗎？誰被排除了？ 模型預測「會再入院」是否等於「值得投入資源」？
2	你的衛教 Chatbot 被問到「我可以不吃藥嗎」，它禮貌地回答了一些一般性建議。	這算不算提供醫療建議？System Prompt 該怎麼改？ ★ 如果使用者堅持追問，該怎麼設計？
3	模型對 80 歲以上族群明顯較不準，但那一群只佔資料的 8%，補資料要半年。	★ 現在上線還是等？如果上線，要怎麼揭露與補救？ 誰有權做這個決定？
4	同事說「反正是輔助，錯了也是醫師負責」。	★ 這句話對嗎？設計者有沒有責任？ 如果介面設計讓人很難不採納呢？
5	你發現訓練資料裡有一批標註明顯是錯的，但修正後模型分數會下降。	★ 要修嗎？如果專題成績跟分數掛鉤呢？ 這一題其實在問研究誠信。

★ 建議帶法：分組討論 10 分鐘，每組報告 2 分鐘。重點不是答案，是「有沒有意識到這是個問題」。

★ 發表前自我檢核清單（一） 資料與模型

W10 案例研究與 W16 期末專題都適用 · 逐項打勾

檢核清單（一）

【一、資料】

- ☐ 使用的是公開資料集或完全虛構的資料（未使用任何真實病歷）
- ☐ 說得出資料的來源、蒐集方式、涵蓋期間
- ☐ ★ 說得出「誰不在這批資料裡」以及那代表什麼
- ☐ ★ 說得出標籤實際上是怎麼產生的（有沒有標籤偏誤）
- ☐ 標準化／缺值處理的參數只用訓練集計算（無洩漏）
- ☐ 若為時間序列，切分方式依時間而非隨機

【二、模型與評估】

- ☐ 有建立基準線（簡單模型或現況作法），並說明模型贏了多少
- ☐ 不是只報準確率：附混淆矩陣、Recall、F1 或 AUC
- ☐ 說明為什麼選這個指標（漏報與誤報的代價哪個高）
- ☐ ★ 附子群體稽核表（至少按年齡、性別、地區拆）
- ☐ ★ 說得出「模型對哪一群人最不準」
- ☐ 若為影像任務，做過外部驗證或說明未做的原因

【三、可解釋性】

- ☐ 能說出模型看重哪些特徵，並判斷是否合理
- ☐ ★ 檢查過有無捷徑學習（可疑的高預測力欄位、Grad-CAM 熱區）
- ☐ 若用黑箱模型，說明為什麼可解釋性在此情境可接受
- ☐ 沒有把 SHAP 的貢獻度說成因果關係

★ 發表前自我檢核清單（二） 倫理與揭露

前四項有任一未打勾，發表時請主動說明原因

檢核清單（二）

【四、倫理與責任】

- ☐ ★ 明確標示 AI 介入層級（① 資訊提供 或 ② 輔助判斷）
- ☐ 醫療相關輸出附「僅供參考，最終應由專業人員判斷」
- ☐ 不提供診斷、不提供處方與劑量建議
- ☐ ★ 說得出「這個系統誤判時，誰會發現、怎麼補救」
- ☐ ★ 說得出「上線後誰維護、多久檢視一次」
- ☐ 介面設計不會誘導使用者盲目採納（自動化偏誤）
- ☐ 若用雲端 API，確認送出的內容不含敏感資料
 - ☐ API 金鑰未寫入交付檔案

【五、公平性】

- ☐ ★ 說得出「我們選擇以○○為公平標準，因為…」
- ☐ 檢查過有無代理變數（郵遞區號、保險別、就醫院所等）
- ☐ 對表現較差的群體，有對應的處理或揭露

【六、誠實揭露】

- ☐ ★ 主動說明限制，而不是等人問
- ☐ 沒有把相關性說成因果
- ☐ 沒有誇大效能（例：把驗證分數說成上線表現）
- ☐ 說得出這個模型「不該用在哪裡」

【七、建議產出】

- ☐ ★ 附一份模型卡（七個欄位，約兩頁 A4）

★ 誠實揭露限制，比宣稱模型很好，專業得多。這是本模組唯一希望你記住的一句話。

本模組重點回顧

- 1 三種真實失敗的共同點：★ 所有評估指標都通過，問題出在別的地方
- 2 偏誤在「問題定義」那一刻就進來了——不是最後補一頁投影片的事
- 3 ★ 刪掉敏感欄位不能消除偏誤，因為代理變數仍攜帶那個資訊
- 4 公平有三種定義，盛行率不同時★數學上無法同時滿足（不可能定理）
- 5 所以不能說「我們的模型是公平的」，要說「我們選擇以○○為準，因為…」
- 6 ★ 子群體稽核表不難做，但很少人做——而它往往是最有價值的一張表

M9 名詞速查表 倫理、偏誤與可解釋性

(1 / 4)

中文	English	一句話說明
演算法偏誤	Algorithmic Bias	模型對特定群體產生系統性不利結果
代理變數	Proxy Variable	與受保護屬性高度相關的特徵，如郵遞區號之於族群
受保護屬性	Protected Attribute	法律或倫理上不應據以差別待遇的特徵
透過不知情達成公平	Fairness Through Unawareness	刪除敏感欄位即認為公平的謬誤
人口平價	Demographic Parity	各群體被選中的比例相同
機會均等	Equal Opportunity	各群體的召回率相同；醫療篩檢最常採用
預測平價	Predictive Parity	各群體的精確率相同
個體公平	Individual Fairness	相似的個體應得到相似的對待
不可能定理	Impossibility Theorem	盛行率不同時，多種公平性定義無法同時滿足

M9 名詞速查表 倫理、偏誤與可解釋性

(2 / 4)

中文	English	一句話說明
子群體稽核	Subgroup Audit	把評估指標拆到各子群體分別計算
盛行率	Prevalence	母體中實際陽性的比例；影響精確率的關鍵
可解釋性	Interpretability	人能理解模型行為或特定預測的程度
本質可解釋模型	Intrinsically Interpretable Model	結構本身即可讀懂，如線性模型、淺決策樹
全域解釋	Global Explanation	說明模型整體看重哪些特徵
局部解釋	Local Explanation	說明單一筆預測的成因
SHAP	SHapley Additive exPlanations	以賽局理論分配各特徵對預測的貢獻
LIME	Local Interpretable Model-agnostic Explanations	在單點附近以簡單模型逼近黑箱
部分依賴圖	Partial Dependence Plot, PDP	顯示單一特徵變化對預測的平均影響

M9 名詞速查表 倫理、偏誤與可解釋性

(3 / 4)

中文	English	一句話說明
Grad-CAM	Gradient-weighted Class Activation Mapping	顯示 CNN 判斷時注意到影像的哪些區域
反事實解釋	Counterfactual Explanation	說明「要改變什麼才會得到不同結果」
捷徑學習	Shortcut Learning	模型學到與任務無關但有相關性的線索
自動化偏誤	Automation Bias	人過度信任自動化系統輸出的傾向
人在迴路	Human-in-the-Loop, HITL	關鍵決策點保留人工判斷與否決權
去識別化	De-identification	移除或代換可識別個人身分的資訊
再識別風險	Re-identification Risk	以多個屬性組合反推出個人身分的可能性
資料血緣	Data Lineage	資料從來源到使用的完整流向紀錄
模型卡	Model Card	記載模型用途、限制、評估結果與適用族群的說明文件

M9 名詞速查表 倫理、偏誤與可解釋性

(4 / 4)

中文	English	一句話說明
資料表	Datasheet for Datasets	記載資料集蒐集方式、組成與已知限制的文件
高風險 AI 系統	High-Risk AI System	EU AI Act 分類；醫療 AI 屬之，須符合完整義務
軟體醫材	Software as a Medical Device, SaMD	本身即構成醫療器材的軟體
研究倫理審查	Institutional Review Board, IRB	涉及人體或個人資料之研究的事前審查機制
知情同意	Informed Consent	告知並取得當事人同意的程序
資料漂移	Data Drift	上線後輸入資料分布逐漸偏離訓練時的狀態
上市後監督	Post-market Surveillance	產品上線後持續監測效能與安全性
研究誠信	Research Integrity	誠實呈現資料與結果，不隱匿不利發現