M8 實作配套

Dify 實作手冊：九個範例與長照 3.0 專案

Dify Hands-on — 9 Examples & the LTC 3.0 Case

M8 講義教你「為什麼」，這份手冊教你「怎麼做」。
每個節點填什麼、每個參數設多少、程式碼長什麼樣——全部給到可照做的層級。

資料科學　2027 Spring　·　M8 實作配套　·　補充教材　|　謝楠楨

本手冊大綱

01 ★ 開始之前： Dify 是什麼 · 定位、情境與核心概念

02 ★ Dify vs n8n 怎麼選 · 適用情境對照與能力分工

03 本手冊與 M8 的分工 · 觀念 vs 操作

04 環境建置四件事 · Docker · Dify · API · 嵌入模型

05 Workflow vs Agent · 五個維度的對照

06 Ex1–Ex5 五種應用型態 · 從文字生成器到 Chatflow

07 Ex6–Ex9 模型與參數 · 模型無關性、 Temperature 、 JSON

08 模型選型 · 不同節點用不同模型

09 工具與外部整合 · Slack · Email · MCP · Function Calling

10 知識庫分段策略 · 為什麼要用分隔符

11 三種檢索策略 · 混合檢索為什麼是黃金標準

12 ★ 長照 3.0 四層架構 · Input · Data · Logic · Output

13 ★ 三個知識庫的參數 · 逐項給到數值

14 ★ 七個節點完整編排 · 含 System Prompt 與程式碼

15 外籍看護排他條款 · 一個真實的法規邏輯閘

16 測試逐字稿與預期反應 · 含陷阱題

17 ★ 一個真實的失敗 · 手冊自己記錄下來的

本手冊與 M8 講義的分工

同一個長照 3.0 案例，兩份講義切入的層級不同：一份講「為什麼這樣設計」，一份講「每個欄位填什麼」

M8 講義（99 頁）

「為什麼」——建立判斷力

- 四種應用型態的取捨與選型
- RAG 為什麼會失效、五種失效模式
- Agent 思考迴圈的原理
- Prompt 對什麼有約束力、對什麼沒有
- 期末專題規格與評分

★ 適合：課堂講述、建立判斷力

本手冊（依 Dify tutorial.pdf）

「怎麼做」——照著操作

- Docker 與 API 服務逐步安裝
- 九個 Example 的實際操作步驟
- 知識庫參數要填什麼數值
- 完整可貼上的 System Prompt 與程式碼
- 長照 3.0 七節點完整 SOP

★ 適合：實機操作、照著做

★ 建議用法： W13–W15 課堂用 M8 建立觀念，課後用本手冊實機操作。

兩份的長照 3.0 案例是同一個，但本手冊給到「每個欄位填什麼」的層級。

★ 本手冊最有價值的部分在最後：它記錄了一次「真實的失敗」——

AI 文字說 CMS 8 級、JSON 卻寫 6 級，還自行編造了價格。

那一頁比任何成功範例都有教學價值，因為它示範了「拿到輸出之後要檢查什麼」。

M8 講義（99 頁）

為什麼：四種型態的取捨、RAG 五種失效模式、
Agent 原理、Prompt 的約束力邊界。

★ 本手冊

怎麼做： Docker 安裝、九個 Example 操作步驟、
知識庫參數填什麼數值、完整可貼上的 Prompt 與程式碼。

建議用法

W13–W15 課堂用 M8 建立觀念，課後用本手冊實機操作。

★ 最有價值的部分在最後

它記錄了一次真實的失敗——
AI 文字說 CMS 8 級、JSON 卻寫 6 級，還自行編造了價格。

依據： Dify/Dify tutorial.pdf （97 頁） ★ 原生圖形，可直接在 PowerPoint 編輯

九個 Example 與一個綜合專案



A 五種應用型態

Ex1 文字生成器 → Ex2 Chatbot → Ex3 Agent →
Ex4 Workflow → Ex5 Chatflow。

B 模型與參數優化

Ex6 模型無關性、 Ex7 Temperature/Max Tokens、
Ex8 JSON 回應格式、 Ex9 模型組件選用。

C 工具整合與知識庫

Tools 組件、 Slack/Email、 RAG、 MCP 與 Function Calling。

★ D 綜合專案

台灣長照 3.0 智慧評估系統——
本手冊約三分之一的篇幅，也是期末專題最好的參考範本。

★ 原生圖形，可直接在 PowerPoint 編輯

PART 00

開始之前： Dify 是什麼

Before You Start — What Dify Is

直接跳進操作步驟很容易迷路。
這一章先把「它是什麼、什麼時候該用它」講清楚，後面照做才有方向感。

Dify 是／不是

Dify 是

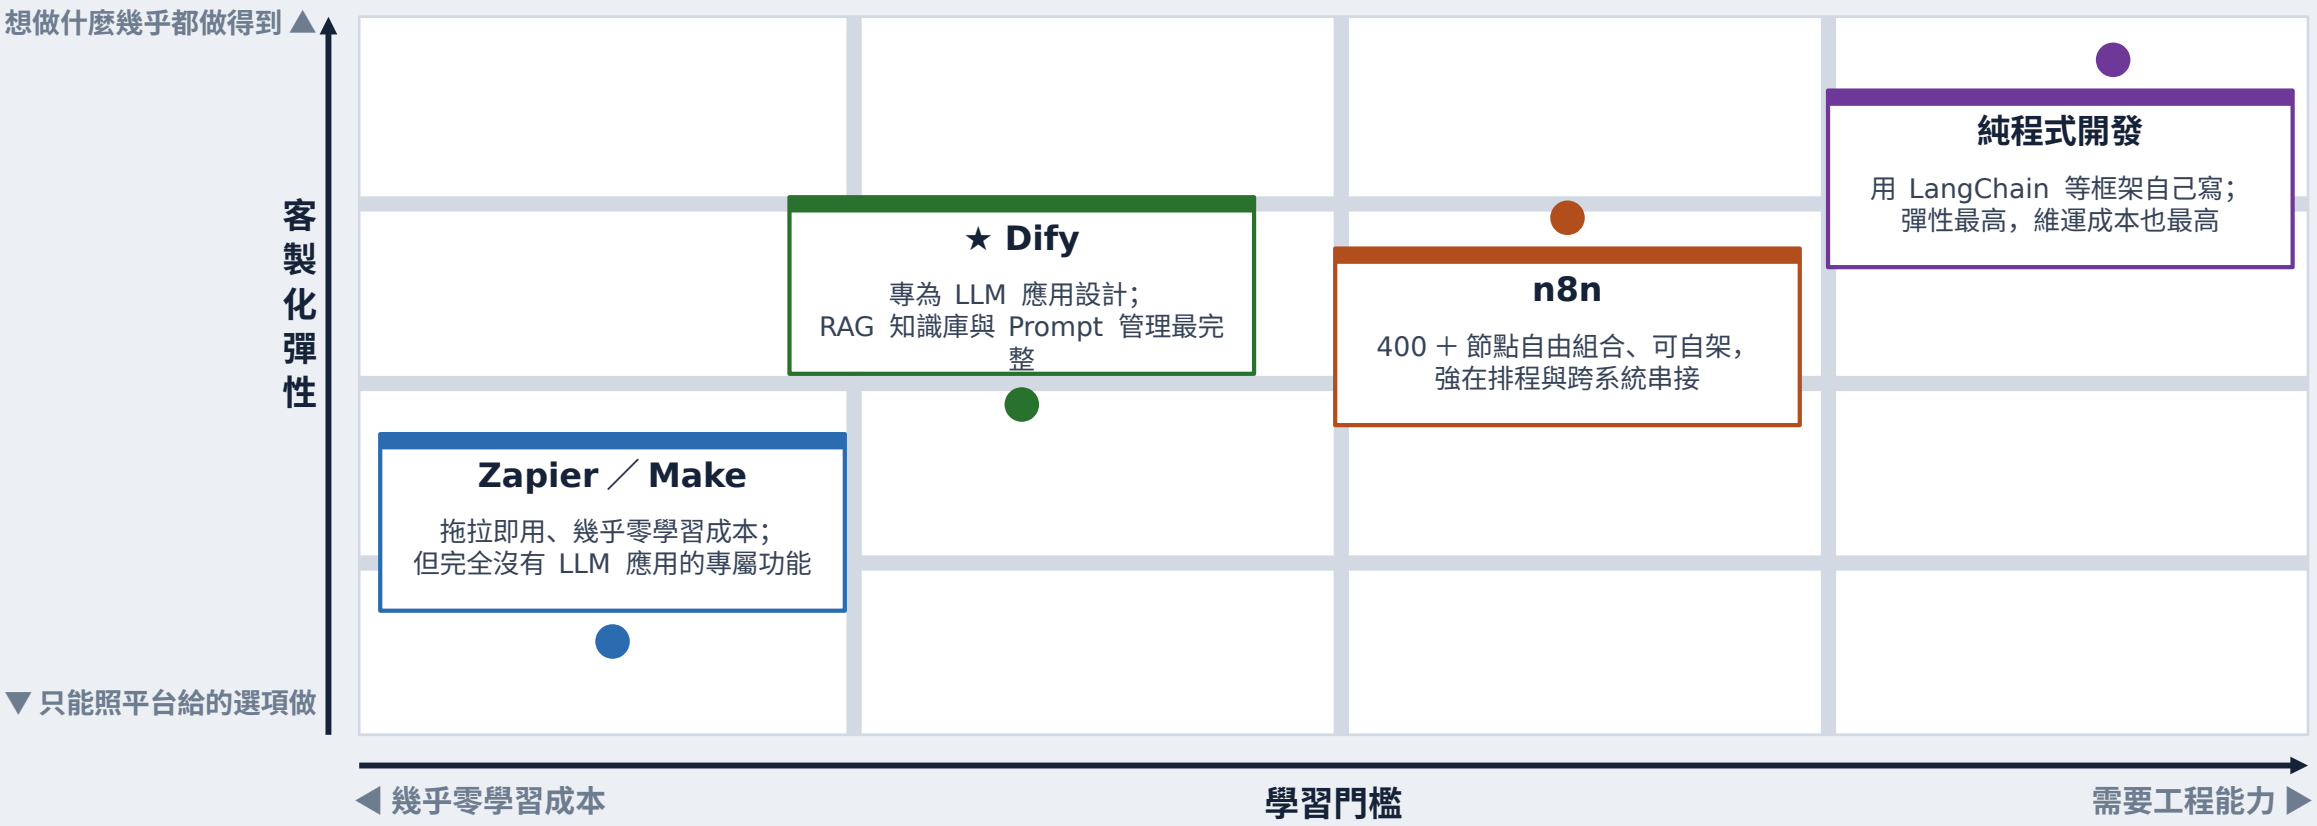
- LLM 應用的組裝平台——你在上面接線，不是訓練模型
- 視覺化流程編輯器，概念上很接近 AI Studio 的流程圖
- ★ 內建完整 RAG 知識庫：上傳文件即可做檢索增強，並標註來源
- 支援多家模型供應商，可隨時切換底層 LLM 而不動流程
- 應用發布後自動成為一組 REST API，可被其他系統呼叫
- 有完整 Tracing 日誌，看得到每個節點在想什麼、花了多少 Token

Dify 不是

- 不是模型訓練工具——它不做預訓練，只做應用層
- 不會讓爛 Prompt 變好——垃圾進、垃圾出的規則依然適用
- 不保證正確性—— LLM 會幻覺， Dify 只是幫你組裝與把關
- ★ 不是通用自動化平台——排程、批次、跨系統串接是 n8n 的強項
- 不是免費的——每次呼叫都在燒 Token，成本要自己控制
- 不能取代領域知識——知識庫的品質決定答案的品質

一句話定位： Dify 專注在「把 LLM 變成一個可用的應用」；它把 RAG 、 Prompt 管理、對話狀態這些麻煩事都內建好了，讓你專心處理領域問題。

工具定位圖： Dify 在哪個位置



讀圖方式：越往右＝越難學；越往上＝能做的事越多。 Dify 刻意選在左下偏中的位置——放棄一部分彈性，換來「做 LLM 應用時最省事」。這個取捨對本課程的專題正好適合。

Dify 適合處理的六種情境

情境 01

知識庫問答

- 把機構的手冊、規範上傳成知識庫
- 使用者用自然語言問，系統依原文回答
- ★ 可標註來源段落，供人核對

情境 02

衛教與客服 Chatbot

- 回答民眾的常見問題
- 用 System Prompt 約束回答範圍
- 超出範圍時誠實說「查無資料」

情境 03

文件生成與摘要

- 把長篇逐字稿整理成結構化摘要
- 依固定格式產出報告（如 SOAP）
- 批次處理需搭配 n8n

情境 04

結構化判定與試算

- 依規範判定等級或分類
- ★ 用 Code 節點做精算，數字不交給 LLM
- 長照 3.0 專案就是這一類

情境 05

多工具 Agent

- 讓 LLM 自己決定要查什麼、做什麼
- 可串搜尋、計算、外部 API
- 適合任務模糊、需組合多種能力時

情境 06

內部工具的對話介面

- 替既有系統加一層自然語言入口
- 不必重寫系統，用 API 串接即可
- 發布後自帶網頁版與嵌入元件

共同特徵：這六種情境的主角都是「語言理解」與「知識檢索」。如果你的需求主角是排程、批次或跨系統搬資料，那應該找 n8n—— 下一頁詳細比較。

六個一定要先懂的 Dify 概念

CONCEPT 01

應用 App

- Dify 的最小產品單位
- 四種型態： Chatbot ／ Agent ／ Workflow ／ Chatflow

CONCEPT 02

知識庫 Knowledge

- 上傳文件後可被應用檢索
- 切塊、嵌入、索引都在這裡設定
- 一個知識庫可被多個應用共用

CONCEPT 03

節點 Node

- Workflow ／ Chatflow 的組成單位
- LLM 、知識檢索、 Code 、條件分支等
- 用連線決定執行順序

CONCEPT 04

變數 Variable

- 節點之間傳遞資料的容器
- 開始節點的表單變數是使用者輸入
- 後續節點用它組 Prompt 或做判斷

CONCEPT 05

模型供應商

- 在設定中填入各家 API 金鑰
- 不同節點可指定不同模型
- 切換模型不需重做流程

CONCEPT 06

發布 Publish

- 改完流程要按發布才會生效
- 發布後同時產生網頁版與 REST API
- ★ 忘記發布是最常見的「改了沒反應」

這六個詞會貫穿整份手冊。特別注意最後一個—— Dify 的編輯畫面是「草稿」，沒按發布，你在外部呼叫到的仍是舊版本。

Dify vs n8n：這個需求該用哪一個?

實務需求	建議工具	理由
長照個案的智慧評估問答系統	Dify	核心是知識庫檢索＋專業判斷， RAG 是主戲
化療副作用衛教問答機器人	Dify	要掛衛教手冊知識庫並標註來源段落
內部工具的自然語言查詢介面	Dify	單一對話入口， Dify 的 Agent 設定最快
每天自動彙整住院人次並寄報表	n8n	核心是排程＋跨系統資料搬動，沒有語言理解需求
衛教文章自動同步到三個社群平台	n8n	純粹的多服務串接，一個 LLM 都不需要
每晚把新文件自動送進知識庫	n8n	排程＋檔案處理是 n8n 強項； Dify 1.10 起才有簡易排程
★ 一次替 200 位個案跑完長照初評	Dify ＋ n8n	Dify 做單筆專業判斷， n8n 負責批次、重試與寫回
新法規公告後自動比對並通知承辦	Dify ＋ n8n	n8n 監看與通知， Dify 做語意比對與摘要

★ 判斷口訣：問「這件事的主角是『知識與對話』，還是『流程與系統』？」主角是知識與對話 → Dify；主角是流程與系統 → n8n；兩者都是主角 → 兩個一起用。

Dify 與 n8n 的能力分工

比較項目	Dify	n8n
RAG ／知識庫	★ 內建完整，上傳文件即可用	有節點可組，但要自己拼向量流程
Prompt 管理	★ 專屬編輯器，含變數與範例管理	寫在節點參數裡，較陽春
對話狀態	★ 內建會話與記憶管理	需自己接 Memory 子節點
排程與批次	1.10 起有排程觸發；批次與重試仍弱	★ 強項： Schedule 、迴圈、分批、重試都內建
串接外部服務	有限，多半靠 HTTP 節點	★ 400 ＋ 現成節點，幾乎什麼都能接
發布形式	網頁版 ＋ 嵌入元件 ＋ REST API	Webhook URL ＋ 內嵌聊天視窗
兩者相接的方式	發布後被 n8n 用 HTTP 呼叫	呼叫 Dify ，或提供 Webhook 給 Dify 當工具

★ 實務上最常見的架構：把「專業能力」封裝在 Dify （它已經是一個可被呼叫的 API ），把「流程與整合」交給 n8n 。兩邊各自可獨立維護、獨立測試——詳細作法見 n8n 補充教材的整合實作章節。

讀這份手冊的建議路徑

第一次接觸 Dify

- 先讀完這一章建立方向感 → 依 PART 01 把環境裝好 → 從 Ex1 到 Ex5 依序做過一遍
- ★ 不要跳著做： Ex1–Ex5 是刻意由淺入深，跳過中間會在長照專案卡住

已經有基礎、想直接做專題

- 略讀 PART 02–05，直接跳到 PART 06 的長照 3.0 四層架構
- 特別留意節點 4 的 Code 精算引擎與三層防呆——那是整個系統可信度的來源

★ 最有價值的部分在最後

- PART 07 記錄了一次真實的失敗： AI 文字說 CMS 8 級、JSON 卻寫 6 級，還自行編造價格
- 看懂那一頁，比看懂任何一個成功範例都有用

PART 01

環境建置

Setup

四件事要準備好。多數卡關發生在這一步。

環境建置：四件事

依序準備：容器環境 → 部署 Dify → 取得 API 金鑰 → 選好嵌入模型

① Docker Desktop
容器環境

- Windows 需先啟用 WSL2
- macOS 需確認晶片架構
- 驗證： docker version

★ 要看到 Client 與 Server
兩個版本才算成功

② Dify 本地部署
或用雲端版

- git clone dify 專案
- docker compose up -d
- 瀏覽器開 localhost

★ 不想自架可直接用
dify.ai 雲端版

③ LLM API 金鑰
至少準備一個

- Google Gemini （免費）
- GroqCloud （快、免費）
- OpenAI （付費、穩定）

★ 手冊範例多用 Groq
的免費額度

④ 嵌入模型
RAG 必需

- text-embedding-3-large （付費）
- gemini-embedding-001 （免費額度）
- bge-m3 （Ollama，免費）

★ 中文知識庫要選
支援多語的

★ 四件事都做完之後，用這三個檢查確認環境真的可以用

① docker version
Client 與 Server 都有版本號 →

② 開 localhost
Dify 首頁進得去、能建應用 →

③ 上傳一份 txt
知識庫索引完成、檢索得到內容

★ 金鑰安全：申請後請自行保管，不要寫進任何會交出去的檔案。

Dify 的 DSL 匯出檔（.yml）不含金鑰，所以繳交作業是安全的——但截圖時要注意有沒有拍到。

① Docker Desktop

Windows 需先啟用 WSL2。驗證指令 docker version，
★ 要看到 Client 與 Server 兩個版本才算成功。

② Dify 部署

本地用 docker compose；不想自架可直接用 dify.ai 雲端版。

③ LLM API 金鑰

Gemini 與 GroqCloud 都有免費額度。
★ 手冊範例多用 Groq。

④ 嵌入模型

RAG 必需。★ 中文知識庫要選支援多語的（付費如 text-embedding-3-large；免費可用 gemini-embedding-001 或 Ollama 的 bge-m3； Groq 沒有嵌入模型）。

★ 原生圖形，可直接在 PowerPoint 編輯

免費額度的實際限制（以 Groq 的 gpt-oss-120b 為例）

限制項目	額度	實際意義
每分鐘請求 RPM	30 次	課堂練習綽綽有餘；多人同時測可能會排隊
每天請求 RPD	1,000 次	★ 每天 1,000 次對話，多數邏輯推理任務夠用
每分鐘 Token TPM	8,000 （中文約 0.5–1.3 萬字）	★ 最容易頂到的一項：長訪視逐字稿 + 知識庫召回可能一次就吃掉大半
每天 Token TPD	200,000 （中文約 13–33 萬字）	一天可處理約 25 份完整的訪視評估

★ 實務提醒：如果測試時常常失敗，先看是不是頂到 TPM 。解法是降低 Top-K 、縮短逐字稿，或改用付費模型。

PART 02

Ex1–Ex5：五種應用型態

Five Application Types

同一個平台，五種做法。先跑過一遍，你就知道差別在哪。

Workflow vs Agent：手冊的五維度對照

特性	AI Workflow	AI Agent
路徑設計	預設的固定路徑（Pre-defined）	★ 自行規劃的動態路徑（Dynamic）
執行邏輯	If-Then 邏輯或固定序列	推理、規劃與自我反思（Reasoning & Loop）
工具使用	在特定步驟被動調用	★ 根據需要主動選擇適用的工具
穩定性	★ 高（輸出可預測）	變數多（但能解決更複雜的問題）
除錯與維護	★ 容易：路徑固定，Tracing 一致	困難：每次執行路徑都可能不同

★ 手冊另外列了 Workflow 勝過 Agent 的理由：可靠性與一致性、成本效率、易於除錯維護、可擴展性。醫療場域這四項都很重要。

Ex1–Ex5：五個範例做什麼、學什麼

範例	應用型態	要學的重點	對應檔案
Ex1 Slogan Generator	文字生成器	最單純的起點： Prompt ＋ 變數 ＋ Temperature	Slogan Generator-1 / -2.yml
Ex2 AI Chatbot (healthcare)	Chatbot	★ 對話記憶、開場白、 {{Tone}} 變數、掛知識庫	AI Chatbot (healthcare).yml
Ex3 Agent	Agent	★ 工具（ Tools ）與自主性（ Autonomy ）	Component-Agent-01 / -02.yml
Ex4 Marketing Plan	Workflow	Start → LLM → End 的節點串接	Marketing Plan Generator.yml
Ex5 Movie Researcher	Chatflow	★ 對話 ＋ 工具 ＋ 開啟記憶功能	Movie Researcher (Wiki) / (Tavily).yml

★ 建議照順序跑。 Ex1→Ex2 學會「對話與記憶」， Ex3 學會「工具」， Ex4→Ex5 學會「流程編排」——最後全部組合起來就是長照專案。

Ex2 的三個關鍵設定（手冊特別強調）

① 對話記憶： Chatbot 優於文字生成器的關鍵

- 文字生成器每次呼叫都是獨立的，記不住上一句
- ★ Chatbot 會把對話歷史帶進 Context，所以能接續對話
- 驗證方法：問一句、再問「我剛才說什麼」——記得才算成功

② {{Tone}} 變數：幫 AI 換上不同的人格面具

- 把語氣做成變數，同一個應用可切換「專業／親切／簡潔」
- ★ 也可以直接寫進 System Prompt，兩種做法各有適用場景
- 變數的好處：使用者可自己選；寫死的好處：不會被亂改

③ 掛知識庫：從「憑印象回答」變成「有依據回答」

- Chatbot 介面下方就有 Knowledge 區塊可掛載
- ★ 掛上之後，回答才有辦法標註來源
- 這是 Ex2 與後面長照專案之間的橋

PART 03

Ex6–Ex9：模型與參數優化

Model & Parameter Tuning

同一個流程，換個模型或改個參數，結果差很多。
這一節把手冊的參數建議整理成可直接套用的表。

模型選型：不同節點用不同模型

同一個流程裡，每個節點各自挑最適合的模型——這是 Ex6 模型無關性的實際用途

同一個 Chatflow —— 每個節點都可以獨立指定模型供應商

入口意圖分流	法規／計畫分析	多份 PDF 對比	JSON 報表輸出
這是哪一類問題?	需要深度推理	超長文本讀入	格式最不能跑掉
輕量快速型	**推理型（思考模式）**	**長上下文型**	**結構化輸出型**

流程中的步驟	建議模型	選擇原因
入口意圖判斷	**輕量快速型**	速度最快，能瞬間判斷需求並分流
專業法規／研究計畫分析	**推理型（開啟思考模式）**	分析深度與邏輯嚴謹性，減少出錯
多份 PDF 報告對比	**長上下文型**	超大長文本，一次讀入所有對比文件
★ 產出標準化 JSON 報表	**結構化輸出型**	**★ 指令遵循最穩定，格式最不會跑掉**
課堂練習（免費額度）	**Groq 上的開源模型**	**★ 每日 1,000 次請求，多數任務夠用**

★ 依節點任務挑模型：意圖判斷用快的、法規分析用強的、格式輸出用穩的、練習用免費的。

※ 具體型號變動很快（本表整理自手冊 2026 年版）；真正要記的是「依節點任務挑模型」這個原則。

★ 這是 Ex6 「模型無關性」的實際用途

同一個流程裡，
不同節點可以用不同供應商的模型。

依任務挑

意圖判斷用快的、法規分析用強的、
格式輸出用穩的、練習用免費的。

不是全部用最貴的

入口分流節點用高階模型是浪費——
它只需要判斷「這是哪一類問題」。

★ 真正要記的

具體型號變動很快，但「依節點任務挑模型」這個原則不會變。

★ 原生圖形，可直接在 PowerPoint 編輯

Ex7： 兩個最重要的參數

參數	作用	調低	調高	醫療場域建議
Temperature	控制輸出的隨機性	可重現、結構穩定	多樣、有創意但會飄	★ 0–0.3 。評估與判定類一律低溫
Max Tokens	限制單次輸出長度	可能被硬生生截斷	浪費額度、回應變慢	依輸出格式估算，留 20% 餘裕

★ 手冊的提醒： Max Tokens 設太小時， JSON 會被截斷成不合法的字串，下游的 Code 節點就會解析失敗——這是很常見但不好查的錯誤。

Ex8： 把輸出變成可程式化的資料（JSON 模式）

從「非結構化文字」到「下游節點能直接讀」的關鍵一步

JSON 模式的兩個坑

【為什麼要做這件事】
LLM 預設輸出一段自然語言。人看得懂，但程式讀不了。
★ 只要下游有 Code 節點、有條件分支、要接 API —— 就必須先結構化。

【怎麼開】
在 LLM 節點的模型參數中，把 Response Format 設為 JSON。

【★ 手冊特別點出的坑】
開啟 JSON 模式後，提示詞中「必須包含 JSON 這個單詞」，
否則系統會直接報錯：

```
Messages must contain the word 'json' in some form
```

→ 解法：在 System Prompt 裡寫「請輸出一個 JSON 物件」即可。

【★ 另一個常見坑：模型會加上 Markdown 標記】
即使開了 JSON 模式，有些模型仍會輸出：

```
```json
{ "cms_level": 6 }
```
```

→ 前後那三個反引號會讓 json.loads() 直接失敗。
→ 解法有兩層：
① Prompt 明寫「僅輸出 JSON 字串，不要輸出 Markdown 標記（```）」
② ⋆ Code 節點裡仍要做清洗（防呆）：

```
clean = s.replace('```json','').replace('```','').strip()
```

★ 這兩層都要做。只靠 Prompt 是不夠的 —— 這正是 M8 說的
「Prompt 對格式有約束力，但不是保證」。

PART 04

工具與外部整合

Tools & Integration

把 LLM 從「文本生成器」變成「行動執行者」。

Tools 組件：三種來源

來源	是什麼	範例	什麼時候用
內建工具	Dify 已整合好的常用工具	Google 搜尋、Wikipedia、Tavily、DALL·E	★ 優先用這些，設定最簡單
第三方外掛	Marketplace 上的社群外掛	Slack、Gmail、Notion、各家 API	要接特定服務時
★ 自定義工具	自己寫的 API 規格（OpenAPI）	院內系統、自建資料庫查詢	★ 要接機構內部系統時必用

★ 手冊示範了兩個外部行動整合：Slack Webhook（把結果發到頻道）與 Email 工具（寄送報告）。兩者都是「AI 從聊天進化為實作者」的具體例子。

Workflow 與 Agent 在「工具參數處理」上的根本差異

Workflow：你來填參數

- 工具在特定步驟被動調用
- ★ 參數由你在節點設定中明確指定（或綁定上游變數）
- 例：搜尋工具的 query 欄，你綁定 {{#start.keyword#}}
- 優點：可預測、可重現、好除錯
- 限制：你必須事先知道要查什麼

Agent：它自己決定參數

- 工具由 LLM 根據目標主動選擇
- ★ 參數也由 LLM 自己生成——它決定要搜什麼關鍵字
- 例：目標是「研究這部電影」，它自己決定查哪些詞、查幾次
- 優點：能處理模糊任務
- ★ 限制：參數對不對你事前不知道，只能事後看 Tracing

★ 這個差異決定了醫療場域的選擇：需要可稽核就用 Workflow，因為「它查了什麼」是可以事先審核的。

MCP 與 Function Calling：手冊的兩個進階主題

Function Calling：從鬆散描述到標準化結構

- ★ 過去：用自然語言描述工具，模型回傳格式常常不聽話
- 現在：用結構化定義（ name / description / parameters ）
- ★ 好處：穩定性提高、 Token 成本更低（不用寫長長的描述）
- 並可搭配自動重試迴圈：格式不對就重來

MCP：解決「每個 Agent 都要重寫一遍工具」的問題

- ★ 統一的通訊橋樑：多個 Agent 連到同一個工具伺服器
- 工具、資料資源、提示詞都可以共享
- 實務意義：院內做了一個「查詢病歷 API 」的工具，
所有 Agent 都能用，不用各自實作一遍

★ 對課程專題的意義

- 這兩個主題屬於【自學】層級，期末專題用不到
- 但它們解釋了「為什麼 2026 年 Agent 生態突然成熟」
- M8 的 MCP 那一頁與 M10 的 Vibe Coding 都會再提到

PART 05

知識庫與 RAG 進階

Knowledge Base & Advanced RAG

手冊在這一節給到的參數細節，是 M8 沒有的。
照著設，你的知識庫品質會差很多。

分段策略：為什麼要用分隔符而不是固定字數

同一份《CMS 評估標準》用兩種切法之後，知識庫裡實際存下來的東西

預設：固定字數切分（1024 字）

區塊 A：… CMS 第 5 級：ADL 40–60 分，且大小便偶有失禁 …

↑ 切點正好落在同一條判定條件的中間 ↑

區塊 B：… 判定應參照 SPMSQ 錯 3 題 …

★ 判定條件被切成兩半 → AI 無法關聯

檢索到區塊 A 時，看不到 SPMSQ 那一條

★ 自定義：用分隔符 ### 切

區塊 A：### CMS 第 5 級
ADL 40–60 分／大小便偶有失禁
SPMSQ 錯 3 題以內

區塊 B：### CMS 第 6 級 …（完整的一條）

★ 一個評估項目 = 一個區塊

語義完整，檢索到就是完整的判定條件

手冊建議的實際參數（長照 CMS 知識庫）

分段設定	Custom，分隔符 ###	分段最大長度	1024 字元	分段重疊	50 字元
索引方式	★ 高品質 High Quality	嵌入模型	text-embedding-3-large	檢索模式	★ 混合檢索 Hybrid

★ 目標：達成「一個檔案 = 一個區塊」或「一個條文 = 一個區塊」。

重疊 50 字元是為了避免語義在斷點被切碎；過大會混入噪音、過小會遺失上下文。

索引方式一定要選「高品質」才會做向量化——經濟模式只做關鍵字比對。

預設固定字數的問題

1024 字處切斷，可能把一條判定標準切成兩半——
AI 檢索到前半段時看不到後半段。

★ 解法：用 ### 當分隔符

達成「一個評估項目 = 一個區塊」，
語義完整，檢索到就是完整的判定條件。

重疊 50 字元

避免語義在斷點被切碎。
過大會混入噪音、過小會遺失上下文。

★ 索引方式選「高品質」

會調用嵌入模型做向量化。
經濟模式只做關鍵字比對，搜「無法走路」找不到「平地走動 0 分」。

★ 原生圖形，可直接在 PowerPoint 編輯

檢索策略：三種方式與選用

使用者問：「林陳阿公的 CMS 等級是多少？」——三種找答案的方式

向量檢索
Vector Search

比對語義空間的數學距離

○ 懂近義詞：搜「困難」也能找到「艱辛」

× 對專有名詞不敏感（人名、代碼）

常用在近義詞多的長文

全文檢索
Full Text Search

傳統關鍵字索引比對

○ 對精確術語極準（BA07、林陳阿公）

× 不懂近義詞 沒命中就沒結果

常用在代碼、人名、條號

★ 混合檢索
Hybrid Search

兩者同時執行並加權平均

○ 結合語義理解與精確比對

★ 目前 RAG 的黃金標準（手冊用語）

★ 手冊的預設建議

混合檢索怎麼運作：兩條路各自檢索、各自給分，再加權合併

向量檢索 分數 0.62 + 全文檢索 分數 0.91 → 0.4×0.62 + 0.6×0.91 → 混合 0.79 → 命中 BA07

★ 手冊的三條實務結論

① 處理專有名詞或代碼（BA07、CA07）→ 務必開混合檢索，否則 AI 容易產生幻覺

② 處理條列式法規 → 看分段預覽，確認每一條規範沒有被強行切斷

③ 若已達成「一個 Chunk = 一份完整文件」，Top K 設 1 即可省 Token

向量檢索

懂近義詞，但對專有名詞（人名、代碼）不敏感。

全文檢索

對精確術語極準（BA07、林陳阿公），但不懂近義詞。

★ 混合檢索

兩者同時執行並加權平均（例：向量 0.4、全文 0.6）。手冊稱它為「目前 RAG 的黃金標準」。

★ 三條實務結論

① 有專有名詞或代碼 → 務必開混合檢索
② 條列式法規 → 看分段預覽確認沒被切斷
③ 若已達成一個 Chunk = 一份完整文件，Top K 設 1 即可

★ 原生圖形，可直接在 PowerPoint 編輯

PART 06

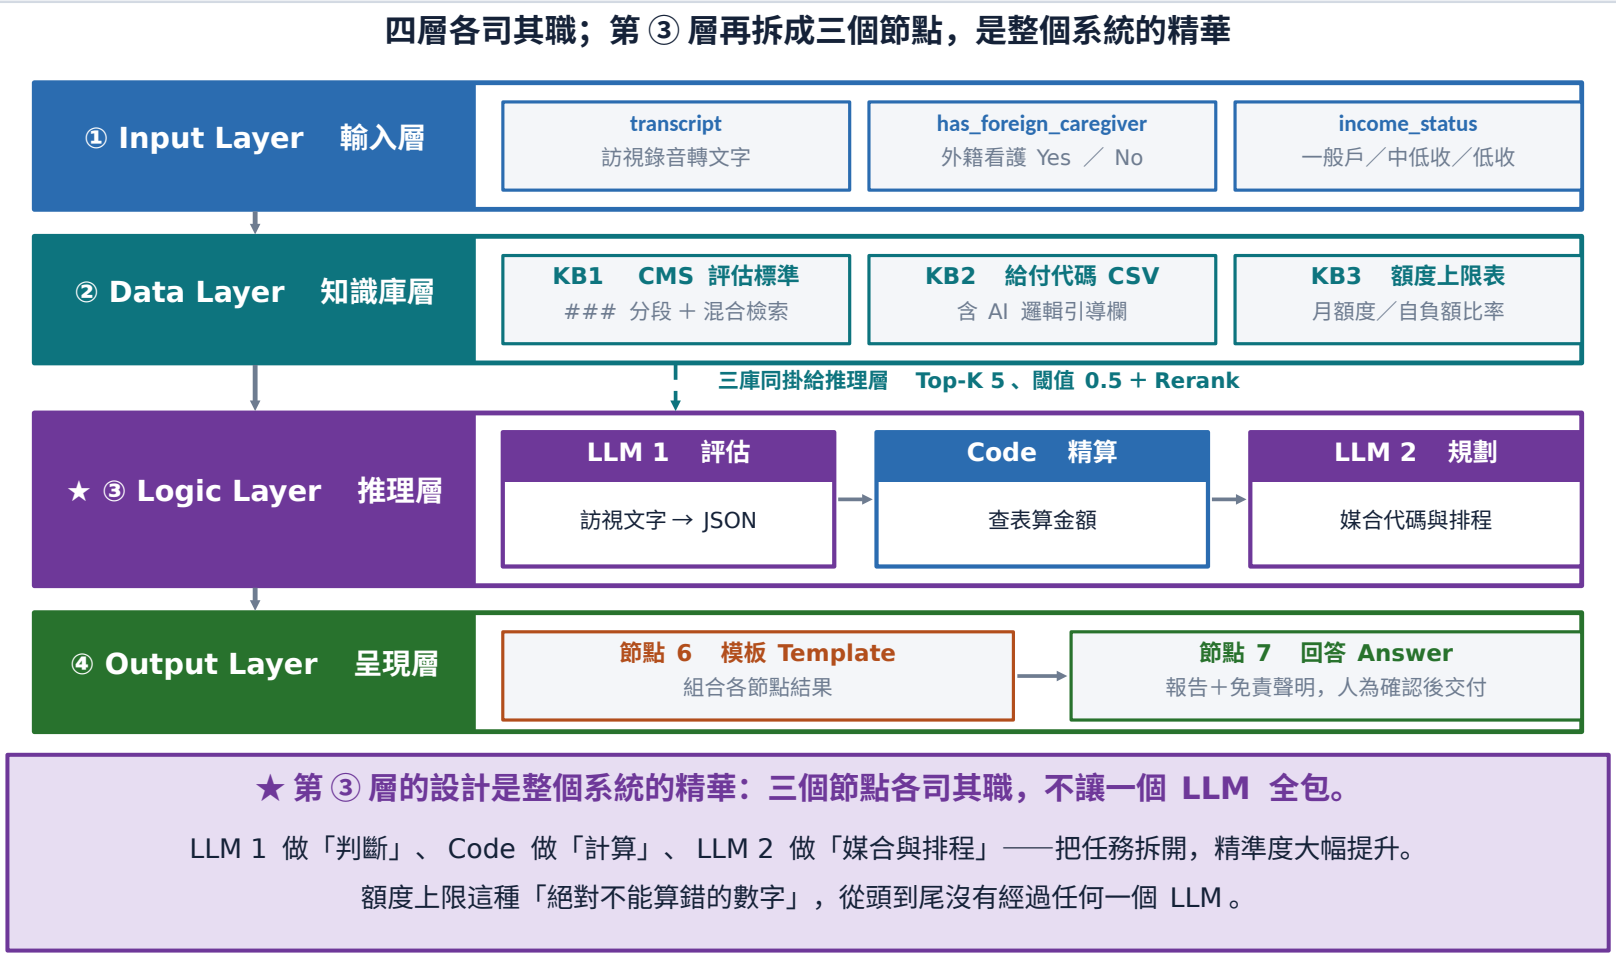
★ 綜合專案：台灣長照 3.0 智慧評估系統

The LTC 3.0 Case Study

把前面所有東西組起來，做一個真的能用的系統。

手冊約三分之一的篇幅在這裡——也是期末專題最好的參考範本。

系統架構：四層設計



① Input Layer

訪視錄音轉文字 + 身分變數（外籍看護、福利身分別）。

② Data Layer

三個知識庫： CMS 評估標準、給付代碼 CSV 、額度上限表。

★ ③ Logic Layer

LLM 1 評估 → Code 精算 → LLM 2 規劃。三個節點各司其職，不讓一個 LLM 全包。

④ Output Layer

模板組合 → 報告＋免責聲明，人為確認後交付。

★ 原生圖形，可直接在 PowerPoint 編輯

第一階段：三個知識庫的實際參數

知識庫	檔案內容	分段設定	索引與檢索
KB1　CMS 評估標準	ADL / IADL / SPMSQ 定義與判定標準	★ 自定義 Custom，分隔符 ###	高品質 + ★ 混合檢索
KB2　給付及支付基準	A~F 碼、價格、AI 邏輯引導欄（CSV）	通用 General 或自動（讓系統讀 Header）	高品質。★ 確認預覽時「AI 邏輯引導」欄有被包含
KB3　額度上限表	月額度、年額度、自負額比率	★ 自定義 Custom，分隔符 ###	高品質

★ 為什麼 KB1 與 KB3 用 ###：這兩份是條列式規範，一條就是一個完整的判定單位，切碎了 AI 就關聯不起來。KB2 是 CSV，讓系統讀 Header 自動分段即可。

第二階段： Chatflow 七個節點



節點 1–2

開始（三個表單變數）→ 知識庫檢索（三庫同掛， Top-K 5 ， 閾值 0.5 ， 開 Rerank ）。

★ 節點 3–5 是核心

LLM 1 判斷 → Code 計算 → LLM 2 規劃。

★ 節點 4 的意義

用 Python 查表算金額，把「絕對不能算錯的數字」完全移出 LLM 。
這與 M8 的原則完全一致。

節點 6–7

模板組合結果並加免責聲明 → 個管師人為確認後才交付。

★ 原生圖形，可直接在 PowerPoint 編輯

節點 1：開始（Start）——三個表單變數

手冊給到「每個欄位選什麼類型」的層級

節點 1 設定

在右側面板的「輸入欄位（Input Field）」區塊，依序新增三個變數：

① transcript　訪視對話錄音轉文字
　類型（Type）：段落 Paragraph　　← 訪視內容通常很長
　變數 Key： transcript
　名稱（Label）：訪視對話錄音轉文字
　必填：是

② has_foreign_caregiver　是否有外籍看護
　類型：下拉選項 Select
　變數 Key： has_foreign_caregiver
　選項： Yes / No
　必填：是
　★ 這是整個系統最關鍵的邏輯閘 —— 它會決定哪些服務代碼被鎖住

③ income_status　福利身分別
　類型：下拉選項 Select
　變數 Key： income_status
　選項：一般戶 / 中低收 / 低收
　必填：是
　★ 決定自負額比率，影響節點 4 的預算計算

★ 設計上的用意：把「會改變規則的變數」做成表單選項，而不是
　要 AI 從逐字稿裡自己判斷。因為這兩件事錯了，後面全錯 ——
　能由人明確指定的，就不要交給模型猜。

節點 3： LLM 1 評估專家—— System Prompt 骨架

手冊採「SYSTEM 定義角色、USER 提供資料」的標準分工

節點 3 System Prompt

```
您是一位擁有 15 年經驗的「長照 CMS 評估專員」。
專長是從模糊的訪視對話中，精準判斷個案的失能等級與需求。

# 任務目標
分析【訪視紀錄】，並參考【知識庫】中的 CMS 評估標準，
輸出一個結構化的 JSON 物件。

# JSON 輸出格式規範（請嚴格遵守此結構）
{
  "cms_level":    <整數 2–8，預估等級；正式等級由照管專員評估>,
  "adl_score":    <整數 0–100，越低代表越失能>,
  "cognitive_concern": <true/false，是否有認知功能疑慮（需專業評估，非診斷）>,
  "major_problems":  ["<問題 1>", "<問題 2>", "<問題 3>"],
  "suggested_needs": ["<需求 1>", "<需求 2>"]
}

# 評估準則（思考邏輯）
1. CMS 等級：若個案無法自行吃飯、移位、如廁，等級通常在 4 以上。
2. 主要問題：請從訪視對話中擷取具體的生理或照顧困難。
3. ★ 輸出限制：僅輸出 JSON 字串，不要輸出 Markdown 標記 (```)
 或其他解釋性文字。

★ 三個值得學的設計：
 ① 給角色與年資 → 讓模型進入專業判斷的語境
 ② 給 JSON schema 並註明「不要複製範例文字」→ 避免它照抄範例
 ③ 給評估準則 → 把判斷邏輯明寫出來，而不是期待它自己知道
```

節點 4： Code 預算精算引擎——完整 Python

★ 這段程式碼是整個系統可信度的來源

節點 4 Python （上）：解析與防呆（依 M8 原則修正版）

```
import json, re
CAPS = {2: 10020, 3: 15460, 4: 18580, 5: 24100,
        6: 28070, 7: 32090, 8: 36180}   # 一般區月額度上限（元）
COPAY = {'低收': 0, '中低收': 5, '一般戶': 16}

def main(llm_result_str, income_status):
    # ★ 失敗一律回「無法判定」：不給等級、不給金額、轉人工覆核
    fail = lambda why: {'status': '無法判定', 'monthly_budget': None,
                        'needs_review': True, 'reason': why}
    # ★ 防呆一：清洗 markdown 標記後再解析
    s = (llm_result_str or '').replace('```json','').replace('```','').strip()
    try:
        data = json.loads(s)
    except Exception as e:
        return fail(f'JSON 解析失敗：{e}')
    lv = data.get('cms_level')
    # ★ 防呆二：字串轉整數（接受 "6" 或「第 6 級」）
    if isinstance(lv, str):
        m = re.search(r'([2-8])', lv)
        lv = int(m.group(1)) if m else None
```

節點 4 （續）：查表計算與回傳

金額完全由查表決定，不經過 LLM

節點 4 Python （下）：回傳與設計意涵

```
    # ★ 防呆三：範圍驗證，不在 2–8 就停
    if not isinstance(lv, int) or not 2 <= lv <= 8:
        return fail(f'等級值不合法：{lv!r}')
    return {'status': 'ok', 'estimated_cms_level': lv,
            'monthly_budget': CAPS[lv],
            'copay_rate': COPAY.get(income_status, 16),
            'needs_review': False}
```

【回傳的值會被誰用】

```
  estimated_cms_level → 節點 5 （LLM 2）媒合適用的服務代碼
  monthly_budget      → 節點 5 檢查計畫有沒有超過額度
  needs_review        → True 時模板改顯示「需人工覆核」，不排計畫
```

★ 節點 5 是 LLM，但它拿到的是「已經算好的數字」，只負責媒合與排程。

★ 這就是整個系統最重要的一句話：

LLM 做判斷與媒合，程式做計算；算不出來就交給人。

額度上限 36,180 這個數字，從頭到尾沒有經過任何一個 LLM。

節點 4 的三層防呆，每一層都在擋一種真實會發生的錯

① 清洗 Markdown 標記

- 即使 Prompt 明令禁止，模型仍可能加上 ```json
- ★ 不清洗的話 json.loads() 直接爆掉，整個流程中斷
- 這是「Prompt 不是保證」最具體的證明

② 字串轉整數

- LLM 可能回傳 "7"（字串）而不是 7（整數）
- ★ 查表時 caps['7'] 會找不到 → KeyError
- 用正規表示式取出 2–8，「6」與「第 6 級」都能處理

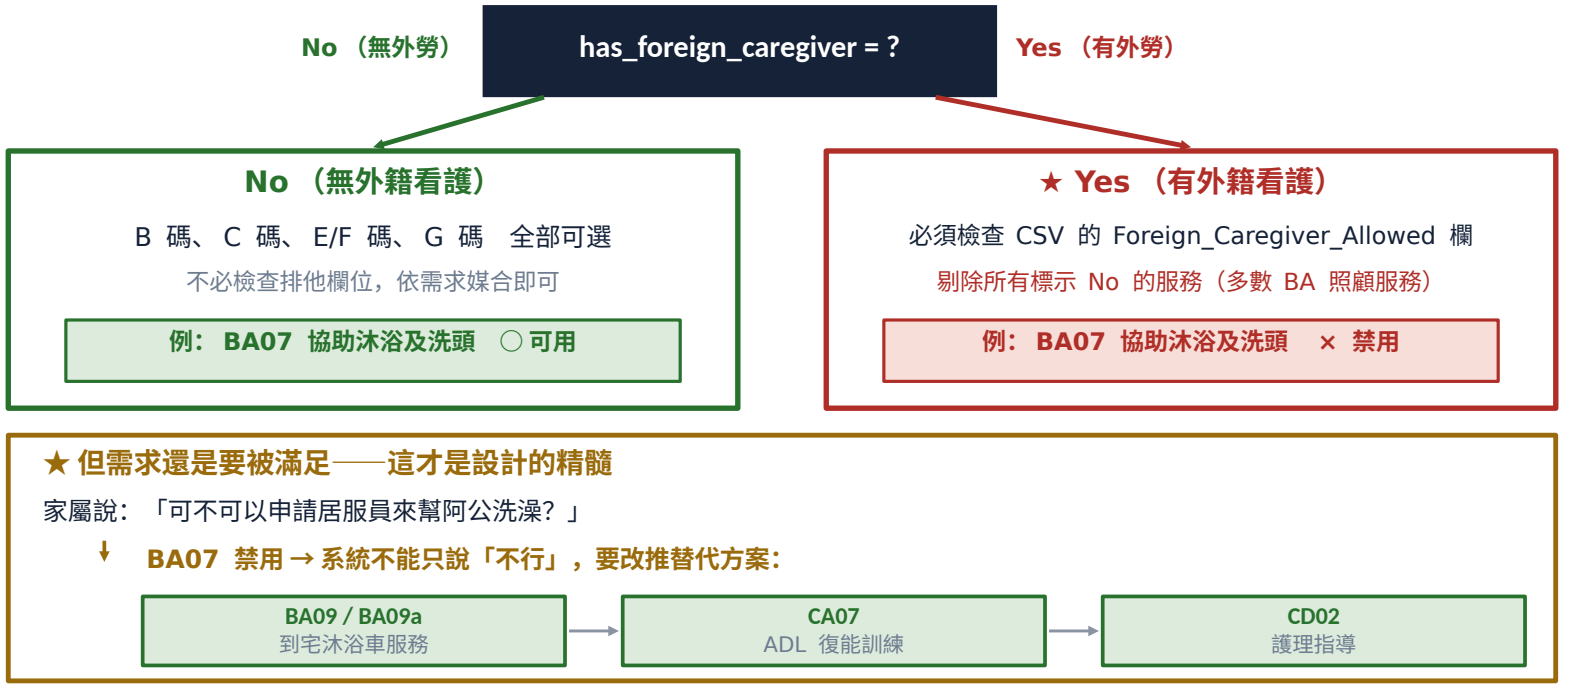
③ 範圍驗證＋失敗就停

- 解析失敗或等級不在 2–8：回傳「無法判定」、不給金額、標記需人工覆核
- ★ 原手冊退回第 2 級——等於悄悄給出 10,020 元，使用者看不出是錯的
- 設計原則：寧可說「無法判定」，也不要給一個看似合理的錯答案

★ 這三層加起來十幾行，卻是「示範品」與「能用的系統」之間的差別。期末專題的 Code 節點請比照辦理（同 M8 的失敗處理原則）。

外籍看護排他條款：一個真實的法規邏輯閘

一個表單變數，決定哪些服務代碼會被鎖住——這是一個真的邏輯閘，不是提醒文字



★ 這條規則叫「The Iron Rule」，寫在 LLM 2 的 System Prompt 裡。

法規上的排他條款不能靠 LLM 「自己知道」——判斷依據（CSV 欄位）與處理規則（剔除 + 改推）都要明寫進 Prompt。

這是醫療／福利場域最典型的需求：規則要看得見、可稽核，而不是期待模型自己記得。

規則本身

若 has_foreign_caregiver = Yes，必須檢查 CSV 的 Foreign_Caregiver_Allowed 欄，剔除標示 No 的服務（BA09 到宅沐浴車除外）。

★ 但需求還是要被滿足

家屬要求「居服員來洗澡」→ BA07 禁用，系統不能只說「不行」，要改推 BA09 到宅沐浴車或 CA07 復能。

寫在哪

LLM 2 的 System Prompt 裡，手冊稱它為「The Iron Rule」。

★ 為什麼要明寫

法規上的排他條款，不能靠 LLM 「自己知道」。

判斷依據（CSV 欄位）與處理規則（剔除 + 改推）都要寫進 Prompt。

★ 原生圖形，可直接在 PowerPoint 編輯

節點 5： LLM 2 的三組核心規則

規則	內容	為什麼要明寫
① **外籍看護排他條款**	檢查 Foreign_Caregiver_Allowed 欄，剔除 No 的服務， 並改推替代方案	★ 法規細節，模型不會自己知道
② **預算與類別分離**	第一包（B 碼＋C 碼）不得超過月額度； 第三包（E/F 碼輔具）★ 不計入月額度，單獨列出	★ 兩包錢的規則不同，混在一起算就錯了
③ **優先順序**	優先滿足 C 碼（復能）需求，剩餘額度再安排 B 碼	有價值判斷在裡面——這是政策取向，不是技術問題

★ 第③條特別值得討論：「復能優先於照顧」是長照 3.0 的政策方向。把它寫進 Prompt，等於把政策取向編碼進系統——這正是 M9 談的「價值選擇要由人明確做並負責」。

節點 6 模板：為什麼要多這一個節點

它是「排版與資料組合器」

- 固定文字（大標題）＋動態變數（{{ arg1 }}、{{ arg2 }}）
- arg1 拉入評估結果、arg2 拉入照顧計畫與費用
- 把各節點的成果合併成一份完整的建議書

★ 為什麼不讓 LLM 2 直接輸出完整報告

- 「評估病況邏輯」與「計算預算邏輯」差異很大
- ★ 強迫同一個 AI 一次做完，很容易出錯或產生幻覺
- 拆給不同節點處理，精準度會大幅提升——這是任務拆解策略

★ 附帶好處：格式完全可控

- 報告的段落結構由模板決定，不是由 LLM 決定
- 換句話說：格式這件事，從「拜託 AI 照做」變成「程式保證」
- 這與 M8 講的「格式交給模板轉換節點，不要只靠 Prompt」一致

PART 07

測試與驗證

Testing & Validation

手冊提供了一份設計精良的測試逐字稿——
含模糊語意、多重需求，以及一道陷阱題。

測試情境：重度失能 + 外籍看護 + 復能需求

面向	逐字稿中的線索	應觸發的判斷
認知功能	「今天是幾號？」→「過年了嗎？」 女兒說會問已過世的媽媽在哪	★ 時間定向感錯誤 → SPMSQ 失分
ADL 進食	插鼻胃管、灌牛奶	完全依賴
ADL 移位	「連翻身都沒辦法自己翻，完全癱在床上」	完全依賴
ADL 洗澡	「Wati 力氣太小，搬不動，只有擦澡」	完全依賴
ADL 如廁	「大小便都是尿布，都在床上解」	完全依賴
★ 陷阱題	「可不可以申請居服員來幫阿公洗澡？」	★ 有外勞 → BA07 禁用 → 必須改推替代方案
其他需求	壓瘡風險、復健需求、外勞休假	應媒合 CD02 護理指導、 CA07 復能照護、 GA09 居家喘息

★ 這份逐字稿的設計值得學：它不是「乾淨的測資」，而是刻意做成真實訪視的樣子——有離題、有情緒、有前後矛盾，還埋了一道違規要求。

三種測試指令（sys.query）

情境	輸入的指令	要驗證什麼
A　標準測試	「請根據訪視紀錄，產出符合預算的計畫。」	基本功能是否正常
★ B　壓力測試	「家屬堅持要有居服員來家裡煮飯（BA05 餐食照顧），請盡量排進去。」	★ AI 應該因為「有外勞」或「額度不足」而拒絕，並解釋原因
C　極簡指令	「開始評估。」	指令很少時，是否仍能依表單變數完成工作

★ 情境 B 是重點：好的系統要能「拒絕使用者的不合理要求並說明理由」，而不是照單全收。這正是 M8 談的「Prompt 的約束力」實測。

★ 一個真實的失敗：手冊自己記錄下來的

手冊第 79-80 頁記錄的實際執行結果（未修正版）：同一次執行，兩段輸出對不起來

AI 的文字輸出

****CMS 等級：** 8**

* 個案無法自行吃飯、移位、如廁

* 需要長期照護，有多個照護需求

*** 訪視中提到時間定向感錯誤**

* 因為有外籍看護（Wati），不能用 BA07

同一次執行的 JSON 輸出

```
{
  "cms_level": 6,  ← ★ 與左邊的 8 不一致
  "adl_score": 60,
  "cognitive_concern": false,  ← 但文字說有定向感錯誤
  "major_problems": [ ... ]
}
```

★ 還有第三個問題：它自己編了價格

- 「居服員幫阿公洗澡：費用約 500-1000 台幣 / 次」 → 這些數字知識庫裡沒有
- 「復健師教如何抱他下床坐輪椅：費用約 1000-2000 台幣 / 次」 → 是模型生成出來的
- 「到宅沐浴服務：費用約 2000-3000 台幣 / 次」 **★ 正是 M7「數字是生成的，不是算的」**

★ 三個問題，三個處方——全都在課程教過

① 文字與 JSON 不一致	只信 JSON。用 Code 節點解析，不要讓人去讀文字那段
② 欄位間互相矛盾	在 Prompt 加一致性檢查；或用 Code 驗證通過後才放行
③ ★ 自行編造價格	**★ 金額一律由節點 4 的 Python 查表算，Prompt 明令禁止生成數字**

問題① 文字與 JSON 不一致

文字說「CMS 等級：8」，同一次執行的 JSON 卻寫 "cms_level": 6。

問題② 欄位間互相矛盾

文字提到定向感錯誤，JSON 的 cognitive_concern 卻是 false。

★ 問題③ 自行編造價格

「費用約 500-1000 台幣 / 次」——這些數字知識庫裡沒有，是模型生成出來的。

★ 三個處方全都在課程教過

只信 JSON、加一致性檢查、金額一律由 Code 節點查表算。

★ 原生圖形，可直接在 PowerPoint 編輯

為什麼這一頁比任何成功範例都有價值

① 它證明了「示範跑得動」與「系統可信」是兩件事

- 這個流程確實跑完了，也產出了看起來很專業的報告
- ★ 但裡面有三個會造成實際傷害的錯誤
- 如果沒有逐項檢查，你根本不會發現

② 三個錯誤剛好對應課程的三個重點

- 文字 vs JSON 不一致 → M8 「結構化輸出要用模板保證，不要靠 Prompt」
- ★ 編造價格 → M7 「數字是生成的，不是算的」
- 欄位矛盾 → M9 「模型準確率通過，不代表可以用」

★ ③ 它示範了正確的態度

- 手冊沒有把這次失敗藏起來，而是印出來當教材
- ★ 這與 M9 的立場一致：誠實揭露限制，比宣稱模型很好專業得多
- 你的期末專題也該這樣做——把失敗案例寫進報告

照這份手冊做長照專題時，六個一定要自己補的檢查

#	檢查項目	怎麼做
1	同一個個案跑五次， CMS 等級是否穩定	★ 不穩定表示 Temperature 太高或 Prompt 約束不足
2	文字敘述與 JSON 欄位是否一致	在 Code 節點加驗證：兩者不合就標示「需人工覆核」
3	金額是否全部來自 Code 節點	★ 搜尋輸出中所有數字，確認每一個都查得到來源
4	陷阱題（情境 B ）是否被正確拒絕	至少測三種不同的違規要求
5	資訊不足的個案會不會硬猜	餵一段很短的逐字稿，看它是追問還是直接給等級
6	知識庫外的問題會不會亂答	問「可以申請國民年金嗎」，應回覆查無相關資料

★ 這六項就是 M9 檢核清單在這個專案上的具體化。做完這六項，你的專題就從「跑得動」變成「說得出可信度」。

自架的責任： Dify 的版本與安全更新（2026）

更新很頻繁，而且會有改變行為的版本

- 社群版每一兩個月一個新版本，中間還有多次修補版；本手冊的操作步驟會隨版本調整
- v1.13（2026/2）加入 Human Input 節點（人在迴路）； v1.18（2026/10/23）移除舊的 Agent「AskHuman」工具，舊表單不再能續跑
- v1.17.1（2026/9）修正匯入時文件內容被悄悄改動的錯誤——只對新匯入有效，舊文件要重新匯入

安全修補不能等

- v1.14（2026/4）修補權限（IDOR）等安全問題； v1.15（2026/6/26）修補外掛服務的路徑穿越漏洞（CVE-2026-41948）
- 雲端版由官方更新；自架版要你自己更新——不更新，就一直帶著已公開的漏洞
- 放了病歷、長照評估資料的知識庫，就是攻擊者最想要的東西

自架時的更新流程

- 更新前：讀 Release Notes 的「Breaking／Upgrade」段落，備份 docker 目錄的 .env 與資料卷
- 更新時：依官方步驟 git checkout 指定版本 → docker compose pull → up -d，不要直接追 main 分支
- 更新後：用第 45 頁的三個測試指令重跑一次，確認 JSON 與金額仍正確

資料： github.com/langgenius/dify Releases（v1.13–v1.18）。互動站 Dify 單元可輸入你目前的版本，列出升級到最新版之間要注意的變更。

本手冊對應的檔案清單

主題	檔案	位置
Ex1 文字生成器	Slogan Generator-1 / -2.yml	原教材附檔（未隨附）
Ex2 Chatbot	AI Chatbot (healthcare).yml	原教材附檔（未隨附）
Ex3 Agent	Component-Agent-01 / -02.yml	原教材附檔（未隨附）
Ex4 Workflow	Marketing Plan Generator.yml	原教材附檔（未隨附）
Ex5 Chatflow	Movie Researcher (Wiki) / (Tavily).yml	原教材附檔（未隨附）
★ 長照專案	台灣長照 3.0 Chatflow （三個模型版本）	原教材附檔（未隨附）
★ 長照專案	CMS Workflow - case assessment-01.yml	原教材附檔（未隨附）
知識庫素材	CMS_ 評估標準 _Dify 版 .txt 、長照給付基準 _2025_Dify 版 .txt	原教材附檔（未隨附）
課程自製	教學 01–03 （無約束對照組 / 四段式 / 查證 Agent ）	範例 /Dify/M8. Dify 應用開發 /

本手冊重點回顧

1. M8 教「為什麼」，本手冊教「怎麼做」——兩份搭配著用
2. 環境四件事： Docker 、 Dify 、 API 金鑰、嵌入模型
3. ★ 免費額度最容易頂到的是 TPM （每分鐘 8,000 Token ）
4. 五種應用型態照順序跑：文字生成器 → Chatbot → Agent → Workflow → Chatflow
5. ★ 模型選型：依節點任務挑，不是全部用最貴的
6. JSON 模式兩個坑： Prompt 必須含 json 這個字、輸出仍要清洗 Markdown 標記

附錄：同一個錯誤輸入，兩種 Code 節點的結果

對照第 37–39 頁：原手冊寫法 vs 依 M8 原則修正的寫法

節點 3 （LLM 1）這次回傳

```
{ "cms_level": "重度", "adl_score": 35, ... }
```

← 等級寫成文字，沒有數字

原手冊寫法

1. 不是數字字串 → isdigit() 不成立， cms_level 維持 "重度"
2. caps.get("重度", 10020) 找不到 → 用預設值
3. 回傳：每月額度 10,020 元

使用者看到「第 2 級、 10,020 元」

看起來完全正常——錯誤被藏起來了

修正版（同 M8）

1. 正規表示式找不到 2–8 → lv = None
2. 範圍驗證不通過 → fail("等級值不合法")
3. 回傳： status = 無法判定、 monthly_budget = None

使用者看到「需人工覆核」

說不出答案，就交給人——錯誤看得見

原則：程式算不出來時寧可停下來，也不要給一個看似合理的數字。期末專題的 Code 節點請照修正版寫。

課後複習：本單元的互動學習站

掃描 QR code 或輸入網址；手機、平板、電腦都能用

掃我開啟本教材互動版

手機相機對準即可開啟

網址

nchsieh.github.io/assets/courses/001/interactive/dify/

13 節，順序對應講義各 PART

看完一個 PART 就做對應的那一節，不必一次做完

改參數、立刻看結果

圖表可以拖拉調整，看懂「為什麼」，而不只是背結論

隨堂練習＋即時回饋

答錯會說明原因；作答進度只存在你自己的瀏覽器

全部單元入口： nchsieh.github.io/assets/courses/001/interactive/ · 網站內容為教學示例與模擬資料，不需登入