

量性研究方法 · 完整研究專案

單元 2

變數測量

Measuring Your Variables — Reliability & Validity

如果變數測不準，再好的設計也白費：操作型定義、信度三型、效度、四種測量方法與問卷設計實務

有效測量的兩大支柱

信

信度 Reliability

= 穩定一致性

測量結果是否「穩定、一致、可重複」。同一對象量兩次應得到相近結果。

例：體重計每次都顯示 60.0 kg → 很穩定（信度高）

效

效度 Validity

= 測得對不對

測量是否「真正反映」要測的概念。準不準，比穩不穩更根本。

例：但真實體重是 57 kg → 穩定地多 3 kg（效度低）

本單元結束後，你能……

- 能為一個抽象概念寫出可操作、可測量的操作型定義。
- 能判別變數屬名目、次序、等距或比率尺度，並據以選擇統計方法。
- 能規劃信度驗證：從三型中選出適用者，並說明可接受門檻。
- 能規劃效度證據：說明內容、效標關聯與構念效度各需要什麼證據。
- 驗收方式 ① 對應作業 A3、B1；② 對應 B5；③ 對應 A2、B2；④ 對應 A4、B3。

本單元怎麼走 先決定『測什麼』，再確認『測得穩、測得準』，最後才是『用什麼方法、什麼格式』



從變數到測量：操作型定義

承上 信度、效度是目標（第 2 張） → 本頁 第一步：先把抽象概念變成可測的『操作型定義』

操作型定義（Operational Definition）＝為了這個研究的目的，把抽象概念變成「可實際測量」的具體做法。

抽象概念	可能的操作型定義
健康 Health	主觀評分、生理指標（如腫瘤大小）、體能表現
表現 Performance	速度、品質，或兩者兼具？
公司規模 Company size	營收、員工人數、顧客數
創業者 Entrepreneur	擁有事業（全職／兼職）、每週投入 ≥ 30 小時經營

同一個概念往往有多種操作型定義——選擇會直接影響你測到什麼。

操作型定義的原則：找到一個「行得通」的

承上 一個概念有很多種測法 → 本頁 怎麼選？找到一個『行得通』的就好

- 別在這一步過度糾結——通常有很多操作型定義都可行
- 你只需要找到「一個行得通」的定義即可
- 「行得通」＝ ① 可以被測量 ② 對你關心的變數而言是合理的
- 把定義寫清楚、可重複——別人照著也能測出同一件事
- 例：『睡眠品質』可用 PSQI 量表總分，也可用手環記錄的睡眠時數——兩者都行得通，選一個並寫清楚

提醒：操作型定義是「這份研究的測量約定」，不是「概念的唯一真理」——在方法章寫明你選了哪個、為什麼。

操作化實例：把「工作壓力」變成可測量

承上 選定義的原則 → 本頁 實例：把『工作壓力』一步步變成可測量


步驟	內容
概念定義	工作壓力 = 工作要求超過個人可負荷時的緊張感受
子構面	① 工作負荷 ② 時間壓力 ③ 情緒耗竭
操作型定義（選定）	以自陳量表測量：每構面 2-3 題、7 點量表
題項範例	「我常覺得工作量超過我能負荷。」（工作負荷）
替代做法	生理：唾液皮質醇；行為：加班時數——可交叉驗證

教學重點 別過度糾結『唯一真理』；把選定的定義寫清楚、可重複，並在方法章說明為何這樣測。

信效度四象限：靶心比喻


承上 測量方式定了 → 本頁 接著問：測得穩不穩（信度）、準不準（效度）——用靶心看四種組合

信度高．效度高




彈著集中又在靶心

信度高．效度低




集中但系統性偏離（如體重計每次都多 3 公斤）
分散但平均在靶心（多測取平均可補救）

信度低．效度高



信度低．效度低



又散又偏

教學重點 信度是效度的必要非充分條件：不穩定的工具不可能有效；但很穩定也可能穩定地測錯東西。效度比信度更根本——『穩定地測錯』比隨機誤差更難發現，也更危險。註：兩種「效度」不同層次——靶心圖的「效度高」指無系統性偏誤（平均不偏），故「信度低．效度高」可以成立；心理計量意義的效度則會被低信度衰減（見衰減圖）。

信度的三種檢驗

承上 信度 = 穩不穩 → **本頁** 信度有三種檢驗：跨時間、跨題項、跨觀察者

再測信度

Test-retest

同一測量在不同時間點多次施測，結果是否一致。例：每次站上體重計都顯示同一數字。

內部一致性

Internal consistency

同一份工具的多個子題是否測到同一件事。例：數學題 1、3、4 得分一致。以 Cronbach's α 評估。

評分者間信度

Inter-observer

不同觀察者對同一對象是否得到相同結論。例：觀察者 1 與 2 都判定某人具攻擊性。

三種信度回答不同問題：跨時間、跨題項、跨觀察者是否一致。

提高信度的訣竅：多測幾次、取平均

承上 知道怎麼檢驗 → 本頁 怎麼提高信度：多測幾次、多用幾題、取平均

核心訣竅：多次測量後取平均——隨機誤差會互相抵銷，測量結果更接近真值。

三種做法

- 多測幾次取平均：例如量體重量好幾次再平均，抵銷單次波動
- 多用幾個題項：問卷用數道題測同一構念，取平均（信度以內部一致性 α 評估）
- 改良工具與標準化施測程序：減少隨機波動（信度 $\uparrow$ ），也減少系統性偏差（效度 $\uparrow$ ）
- 例：單次量體重誤差約 ± 1 kg；量 4 次取平均，誤差約縮小一半（ $\div \sqrt{4}$ ，原理見 2.5）

信度三型實例：同一份「工作壓力量表」怎麼驗

承上 三種信度的概念 → 本頁 同一份量表 三種信度實際怎麼驗 關鍵多小

信度類型	怎麼做	範例結果	可接受門檻
再測 Test-retest	同一群人隔 2 週再填一次，算 ICC 或 r	ICC = .85	ICC ≥ .70
內部一致性	算量表題項的 Cronbach's α	$\alpha = .88$	$\alpha \geq .70$
評分者間 Inter-rater	兩位主管各評同一批員工壓力行為	$\kappa = .82$	$\kappa > .60$ (>.80 幾近完美)

κ 算法示例（另一例：兩位督導各判 100 份交班紀錄）

	B 判達標	B 判未達標	A 小計
A 判達標	40 一致	10	50
A 判未達標	10	40 一致	50
B 小計	50	50	100

再測信度 ICC

MS 受試者間 13.33
MS 誤差 1.08
 $(13.33 - 1.08) \div (13.33 + 1.08)$
= **12.25 ÷ 14.41 ≈ .85**

內部一致性 α

k = 10 題；題目變異和 3.8
總分變異 18
 $10/9 \times (1 - 3.8/18)$
= **1.11 × .789 ≈ .88**

評分者間 Cohen's κ

Po = $(40 + 40) \div 100 = .80$
Pe = $.5 \times .5 + .5 \times .5 = .50$
 $(.80 - .50) \div (1 - .50)$
= **.30 ÷ .50 = .60**

教學重點 三型回答不同問題（跨時間／跨題項／跨評分者）；量表研究最常報告 Cronbach's α ，觀察法必報 inter-rater。

三種信度：各檢驗一種「一致」

承上 三種信度的數字 → 本頁 用圖再看一次：各自檢驗哪一種『一致』



重測信度 **Test-retest**：跨「時間」穩不穩



評分者間信度 **Inter-rater**：跨「評分者」一不一致 (κ)



內部一致性 **Internal consistency**：題目之間一不一致 (α)

教學重點 選哪一種取決於你的威脅：怕狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→ α 。

三個信度係數怎麼算？

承上 三種係數的名字 → 本頁 r 、 α 、 κ 各自怎麼算、直覺是什麼

r · 再測信度

做法：同一群人隔一段

時間（如 2 週）再測一次。

算法：兩次分數的 Pearson

相關係數 r 。

直覺：兩次是否『同起同落』。

例：10 人重測， $r = .85$

進階： r 看不出「第二次全體都偏高」，ICC 會扣分，故改報 ICC。

α · 內部一致性

做法：一次施測，看各題

是否測同一件事。

算法： $\alpha = (k / (k - 1)) \times$
 $(1 - \Sigma \sigma^2_{\text{題}} \div \sigma^2_{\text{總}})$

直覺：題目越一致， α 越高。

例：5 題， $\alpha = .88$

κ · 評分者間

做法：兩位評分者評同

一批對象。

算法： $\kappa = (P_o - P_e) \div$
 $(1 - P_e)$

直覺：扣掉『運氣一致』

後的真實一致。例：見下方

教學重點 κ 為什麼要扣運氣：兩位主管各把 50 位員工分成『高壓力／否』。都判高 20、都判否 20 → 實際一致 $P_o = (20 + 20) / 50 = 0.80$ ； P_e 為「兩人各自判高的比例相乘 + 各自判否的比例相乘」（本例兩人皆 25/50 判高）→ $P_e = 0.5 \times 0.5 + 0.5 \times 0.5 = 0.50$ 。故 $\kappa = (0.80 - 0.50) / (1 - 0.50) = 0.60$ （Landis-Koch：.41-.60 中等，未達 $> .60$ 門檻；.61-.80 高度、 $> .80$ 幾近完美）。

動手算：Cronbach's α 逐步計算

承上 α 的公式 → 本頁 動手算一次：5 人 $\times$ 3 題，算到 α

受試者	題 1	題 2	題 3	總分
P1	4	5	4	13
P2	2	3	2	7
P3	5	4	5	14
P4	3	3	4	10
P5	1	2	2	5
變異數 σ^2	2.00	1.04	1.44	11.76

步驟

- ① 每題的變異數： $\sigma^2_1=2.00$ 、 $\sigma^2_2=1.04$ 、 $\sigma^2_3=1.44$
- ② 加總題項變異數： $\Sigma\sigma^2 \text{ 題} = 4.48$
- ③ 總分的變異數： $\sigma^2 \text{ 總} = 11.76$
- ④ 代入公式 ($k=3$):

$$\alpha = (3/2)(1 - 4.48/11.76) = 0.93$$

教學重點 讀懂： $\alpha=0.93$ 遠高於 .70 → 這 3 題內部一致性很好，像在測同一個構念。直覺：題項彼此越相關， $\Sigma\sigma^2 \text{ 題}$ 相對 $\sigma^2 \text{ 總}$ 越小、（1－比值）越大 → α 越高。（此處變異數除以 n ；軟體除以 $n-1$ 時各變異數同比例放大、比值不變， α 仍為 0.93。）

為什麼信度會影響統計顯著性？

承上 會算信度了 → 本頁 為什麼要在乎：信度會影響你的 p 值

信度高

- 測量誤差低
- 統計檢定力（power）高
- 較易偵測顯著差異
- p 值較小
- 例：真實相關 .40、兩量表信度 .9 → 看到約 .36

信度低

- 測量誤差大
- 效果被雜訊稀釋
- 檢定力下降
- p 值較大（可能藏住真實關係）
- 例：同樣真實相關 .40、信度只有 .6 → 只看到約 .24（下一張）

顯著水準 α （如 0.05；與 Cronbach's α 不同）是事前設定的門檻，不因信度改變；但信度低時應增加樣本數或改良工具來補償。


信度低 → 效果被低估 → 檢定力下降

承上 信度低 → p 變大 → 本頁 用圖看『衰減』：信度越低，看到的效果越小

低信度的連鎖後果



衰減 Attenuation：信度越低，效果越被低估



教學重點 提高信度（多題、多次測量取平均）等於免費提升檢定力——比事後加樣本便宜得多。（圖示假設 X 、 Y 兩變項信度相同）

隨堂 60 秒：信度怎麼選、怎麼算

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 的「交班紀錄完整性是否達標」由兩位觀察員各自判定。要檢驗這項測量的一致性，該算哪一個係數？
- ② 為什麼這裡不能用 Pearson r？請用一句話說明。
- ③ 若兩位觀察員的一致率 $P_o = 0.80$ 、運氣一致 $P_e = 0.50$ ， κ 是多少？屬於哪一級？

參考解答

- ① Cohen's κ ：兩位觀察員判定二元／類別結果，要看的是評分者間一致性
- ② 「是否達標」是類別（名義）變數；Pearson r 只適用連續（等距／等比）變數
- ③ $\kappa = (P_o - P_e) \div (1 - P_e) = (0.80 - 0.50) \div (1 - 0.50) = 0.30 \div 0.50 = \mathbf{0.60} \rightarrow$ 中等一致（Landis-Koch .41-.60）

講評重點 選係數看的是「變數型態」與「威脅來源」，不是看手邊有什麼數字。

效度的全景：三大類、五種常見檢驗

承上 信度講完（穩不穩） → 本頁 換效度（準不準）：三大類、五種檢驗的全景

效度類別	問的問題	常用指標	案例 Q 的做法
內容效度 Content	題目涵蓋構念的全部面向了嗎？	CVI（專家評定）	紀錄完整性評分表由長照專家審涵蓋面
效標關聯・同時	與同時測到的標準一致嗎？	與效標的相關	系統記錄的準備時間 vs 觀察員現場計時
效標關聯・預測	能預測未來的結果嗎？	與後續結果的相關	導入前認知負荷能否預測後續使用流失
構念效度・聚斂	與「應該相關」的變數相關嗎？	r、AVE	認知負荷 vs 二次確認詢問次數 → 應正相關
構念效度・區辨	與「不該相關」的變數不相關嗎？	r 接近 0	認知負荷 vs 年資 → 應接近 0

教學重點 效度不是單一數字，而是一組證據；同一份工具用在不同目的上，需要的效度證據不同（AERA / APA / NCME 《Standards》（2014）以「效度證據來源」統稱）。信度是效度的必要非充分條件——見第 7 張靶心圖。

效度的兩種：聚斂與區辨

承上 效度全景 → **本頁** 最常用的構念效度：聚斂與區辨，用體適能舉例

聚斂效度 Convergent

測量與「應該相關」的變數確實相關。

- 例：體重計顯示數字，隨堆疊物品增加而增加 → 合理
- 體適能 vs 跑步速度 → 正相關 ✓

區辨效度 Discriminant

測量與「不該相關」的變數不相關。

- 例：體重計上的數字不應受「室溫」影響
- 體適能 vs 身高 → 接近 0、不顯著 ✓

好的測量：該相關的相關、不該相關的不相關——兩者一起看才完整。

效度實例：用相關矩陣看聚斂與區辨

承上 聚斂與區辨的概念 → 本頁 實例：新工作壓力量表與四個變數的相關

與哪個變數比	預期	觀察 r	判讀
職業倦怠	應正相關（聚斂）	.62	聚斂效度 ✓
睡眠品質	應負相關（聚斂）	-.48	聚斂效度 ✓
每週工時	弱正相關（合理）	.30	合理
身高	不該相關（區辨）	.04	區辨效度 ✓

教學重點 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算測到『壓力』而非別的東西。

核心原則為：「同構念要高、跨構念要低」

聚斂與區辨：用相關矩陣看

承上 看了四個相關 → 本頁 換成相關矩陣：同構念要高、跨構念要低

具體問卷題目設計

構念 A：工作壓力（測量個人感受到的工作負荷與緊繃感）

壓力 1：「我經常覺得交辦的工作量過大，難以在時間內完成。」

壓力 2：「面對繁重的工作任務，我常常感到焦慮或緊繃。」

壓力 3：「下班回到家後，我常常覺得身心俱疲、無法好好放鬆。」

構念 B：主管 / 同事支持（測量在職場能獲得的人際資源與實質幫助）

支持 1：「當我在工作上遇到難題時，主管會提供具體指引與協助。」

支持 2：「同事之間會互相補位、分擔突發的工作負荷。」

支持 3：「在單位裡，我能感受到團隊成員的關心與心理支持。」

壓力 1	1.00	0.72	0.68	-0.18	-0.12	-0.15
壓力 2	0.72	1.00	0.75	-0.14	-0.16	-0.11
壓力 3	0.68	0.75	1.00	-0.12	-0.10	-0.13
支持 1	-0.18	-0.14	-0.12	1.00	0.70	0.74
支持 2	-0.12	-0.16	-0.10	0.70	1.00	0.69
支持 3	-0.15	-0.11	-0.13	0.74	0.69	1.00
	壓力 1	壓力 2	壓力 3	支持 1	支持 2	支持 3

怎麼讀這張相關矩陣

綠框：同一構念的題目

應該「高」（此例 .68~.75）→ 聚斂效度成立

橘框：不同構念之間

應該「低」（此例 -.10~-0.18）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是一件事，要合併、重新定義，或改題。

教學重點 跨構念相關若逼近同構念相關，先回頭看題目問法是不是太像——改題比事後在討論章辯解容易得多。

四種測量方法總覽

承上 工具要信、要效 → 本頁 接著選『用什麼方法測』：四種測量方法總覽

自陳法 Self-report

直接問當事人（訪談、問卷、調查）——最常用，但可能有社會期許偏誤。

例：PSS 知覺壓力量表

表現測量 Performance

以任務測能力（IQ、體能、反應時間）——難造假，但易受狀態干擾。

例：6 分鐘步行距離

觀察行為 Observed behavior

觀察人們「實際怎麼做」（購買選擇、臉部表情）——外部效度高，但難設置。

例：觀察員計時交班時間（案例 Q）

生理測量 Physical

心率、皮膚電導（流汗）、荷爾蒙（皮質醇）、腦活動——難造假，但需設備、難解讀。

例：穿戴裝置測心率

沒有最好的方法，只有「最適合這個研究情境」的方法。

自陳法 Self-report：開放式 vs 封閉式

承上 最常用的是自陳法 → 本頁 自陳法的兩種題型：開放式 vs 封閉式

開放式（偏質性）

- 不引導受訪者往任何方向回答
- 多用「你做了什麼？為什麼這樣做？」
- 避免「是不是因為 X？喜不喜歡 X？」這種誘導

封閉式（偏量化）

- 評定量表（5 = 非常同意… 1 = 非常不同意）→ 數值變量
- 勾選題（性別：男／女／其他）→ 類別變量
- 易統計，但受選項侷限

留意：社會期許偏誤 敏感題（是否欺騙伴侶、智商多高）易得美化答案；測量潛在構念時，用「多個題項」較穩。
尺度層級 單題 **Likert** 為次序尺度，多題加總後方近似等距——見下一節「四種測量尺度」。

常見自陳偏誤與對策

承上 封閉式題目易統計 → 本頁 但自陳有四種常見偏誤，各有對策

偏誤	症狀	對策
社會期許 Social desirability	敏感題給美化的答案	匿名作答、中立措辭、間接問法
默許傾向 Acquiescence	不管內容都傾向『同意』	加入反向題、平衡正反向題
集中趨勢 Central tendency	什麼都選中間值	調整量尺點數、必要時強制選擇
月暈效應 Halo	一個印象影響所有題	打散題序、清楚定義各構面

教學重點 測潛在構念時『用多個題項』最穩；反向題與注意力檢查題能同時抓默許與敷衍作答。

常見自陳偏誤 · 各舉一例

承上 四種偏誤與對策 → 本頁 放進真實情境，各舉一例

偏誤	具體範例
社會期許	問護理師『你會不會對病人不耐煩？』→即使會，也答『從不』以維持良好形象。
默許傾向	受訪者每題都勾『同意』，連反向題也勾同意→前後矛盾露餡。
集中趨勢	每題都選『普通／中立』，避免表態→分數擠在中間、拉不開差異。
月暈效應	覺得某主管『人很好』，就把他所有領導面向都評高分。

教學重點 對策速記：社會期許→匿名／間接問法；默許→加反向題；集中趨勢→偶數點量尺或強制選擇；月暈→打散題序、清楚定義各面向。（問卷寫作詳見 4.3 問卷設計實務）

表現、行為、生理測量：優缺點對照

承上 自陳法的優缺點 → 本頁 另外三種方法：表現、行為、生理，優缺點對照

方法	例子	優點	缺點
表現 Performance	IQ、體能、反應時間	難造假	易受狀態干擾（如沒睡好）
觀察行為 Observed	購買選擇、臉部表情	外部效度高（看實際行為）	常較難設置
生理 Physical	心率、皮膚電導、皮質醇	難造假	需設備、有時難解讀

表現測量常需在「不受干擾、條件相似」下進行，結果才可比較。

如何選擇測量方法

承上 四種方法各有優缺 → 本頁 怎麼選：回到信度與效度兩把尺

- 永遠先想「信度」與「效度」——這兩把尺決定方法好壞
- 例①：自陳法若因社會期許而失真 → 改換問法，或用不同方法測量
- 例②：反應時間波動大 → 多測幾次、取平均
- 例③：心率可能反映興奮，也可能只是喝了咖啡 → 若各法都有問題，就用多種方法交叉比對

每種測量方法都可能是好選擇——取決於研究情境；若都不理想，考慮同時使用多種方法。

測量的類型：數值 vs 類別

承上 方法選好了 → 本頁 測出來是數值還是類別？這決定信度指標與統計

數值變量 Numerical

- 有大小、可測差距（例：壓力分數、睡眠時數）
- 靈敏度高，能捕捉細微變化
- 可用 ICC 或相關係數評估信度

類別變量 Categorical

- 以類別區分（例：有無失眠、性別、國籍）
- 名目類別無大小；次序類別（輕／中／重）有先後、無等距，可用加權 κ
- 信度改用一致性指標評估：Cohen's κ 或百分比一致度，不可用相關係數（例：兩位觀察員判定「交班紀錄完整性是否達標」，須先驗 κ ）

四種測量尺度：決定你能用哪些統計

承上 數值 vs 類別 → 本頁 再細分成四種尺度：決定能不能算平均、能用哪些檢定

尺度	可分類	可排序	間距相等	絕對零點	案例 Q 變數 (值域)	集中量數	典型檢定
名目 Nominal	✓	✗	✗	✗	職類、機構 (A / B)、班別	眾數	卡方
次序 Ordinal	✓	✓	✗	✗	認知負荷量表單題 (1-7)	中位數	無母數 (Wilcoxon)
等距 Interval (準)	✓	✓	✓	✗	認知負荷加總分 (19-48)、紀錄完整性分數 (6.9-20.0)	平均數、SD	t 檢定、ANOVA
比率 Ratio	✓	✓	✓	✓	交班準備時間 (2.0-36.4 分)、詢問次數 (0-7)、照顧住民數 (4-22)	平均數	t 檢定、相關、迴歸

單題 Likert 嚴格說是次序尺度；多題加總後方視為近似等距，才能用平均數與 t 檢定。凡「零」代表「完全沒有」的量，才是比率尺度。

隨堂 60 秒：判斷測量尺度

先自己作答，再看解答 · 預估 1 分鐘

- ① 下列四個案例 Q 變數各屬哪一種測量尺度？ 職類／認知負荷單題（1-7）／認知負荷加總分／交班準備時間（分）
- ② 其中哪些可以算平均數？哪些只能看眾數或中位數？
- ③ 「準備時間 20 分鐘是 10 分鐘的兩倍」這句話成立嗎？為什麼？

參考解答（先自己想，再對照）

- ① 職類＝名目；認知負荷單題＝次序；認知負荷加總分＝等距（近似）；準備時間＝比率。
- ② 可算平均：加總分、準備時間。單題看中位數（或眾數）；職類只能看眾數。
- ③ 成立。時間有絕對零點（0 分鐘＝完全沒花時間），比率尺度才能說『兩倍』；溫度 20°C 就不是 10°C 的兩倍。

講評重點 尺度決定集中量數與檢定；判斷順序是「可分類 → 可排序 → 間距相等 → 有絕對零點」。

測不準怎麼辦？調整研究問題

承上 尺度與方法都有了 → 本頁 如果概念就是測不準？換指標，或調整研究問題

- 有些概念難以直接、準確測量（例：犯罪行為、真實態度）
- 策略一：尋找可靠的替代指標 / 操作型定義
- 策略二：微調研究問題，使其可被測量
- 自陳式（self-report）測量要留意「社會期許偏誤」
- 健康例：自陳『有按時吃藥』常被高估 → 改用藥盒開啟紀錄或回診時剩藥計數

例：直接問「你是否有犯罪行為」難以取得可靠答案 → 可改測「與犯罪相關的可觀察行為」或使用官方紀錄等替代指標。

問卷設計的具體做法

承上 前面所有原則 → 本頁 串成問卷設計的四個具體步驟

① 題項與概念對應

為每個構念（construct）建立清楚定義，據此設計題項。例：服務品質可依 SERVQUAL 五構面設計。

② 專家效度檢核

邀專家審查題項是否涵蓋構念內容範圍；以 CVI（內容效度指數）評估各題與構念的相關性。

③ 預試與修正

小樣本預試，檢查題目是否模糊或誘導；以項目分析刪除區分度低的題項。

④ 構念效度檢驗

以探索性因素分析（EFA）或驗證性因素分析（CFA）確認題項結構符合理論預期。

本單元重點回顧

- **【目標①】** 先把抽象概念變成「操作型定義」——找到一個可測且合理的即可。
- **【目標③】** **【目標④】** 信度＝穩定一致（再測、內部一致性、評分者間）；效度＝內容＋效標關聯（同時／預測）＋構念（聚斂／區辨）。
- **【目標③】** 多題項／多次測量取平均，是提高信度最實用的訣竅。
- 四種測量方法：自陳、表現、觀察行為、生理——各有優缺，依情境選、必要時併用。
- **【目標③】** 信度低會稀釋效果、降低檢定力、放大 p 值，可能藏住真實關係。
- 問卷設計四步：概念對應 → 專家效度 → 預試修正 → 構念效度。
- **【目標②】** 測量尺度（名目／次序／等距／比率）是 2.4 選圖、2.5 選檢定的共同判準。

下一站 2.3 資料蒐集：測量工具定下來了，接著決定跟誰收、收多少、怎麼避開偏誤。



延伸

量表發展與驗證

Scale Development & Validation

把前面的『信度・效度』升級成一套完整的量表製作流程：
從產生題項、內容效度，到 EFA 探索因素、CFA 驗證結構。

為什麼需要『量表發展』這一節？

承上 前半講信度、效度的觀念 → **本頁** 延伸：為什麼要學一整套『量表發展』流程

隨便湊題目的下場

- 題目測到的不是你想測的概念（效度差）
 - 不同題目各測各的、內部不一致（信度差）
 - 幾個構面混在一起、分不開（維度不清）
 - 审稿人一句『量表未經驗證』就退稿
- 資料再多也是雜訊

這一節給你的能力

- 用系統流程把抽象概念變成可信量表
 - EFA：找出題目背後有幾個構面
 - CFA：驗證你的構面結構站不站得住
 - 用 AVE/CR、適配度指標客觀評估
- 依 COSMIN 報告，讓量表可被引用

重點 量表發展＝把「信度＝一致、效度＝測得準」做出來並證明給別人看的工程；健康科技尤其常需自製量表。
與 4.3 的分工 題目怎麼寫、量尺怎麼設計見 4.3 問卷設計實務；本節專講「寫完之後」的統計驗證。

量表發展的生命週期：六個階段


承上 知道為什麼要做 → 本頁 全流程六個階段，一條龍走完

- 1 界定建構＋維度** 講清楚概念定義與理論上有幾個構面 (dimension)
- 2 產生題項 Item pool** 依定義＋文獻＋專家，寫出比需要更多的候選題
- 3 內容效度 CVI** 專家評每題相關性，算 I-CVI / S-CVI 篩題
- 4 前測＋項目分析** 小樣本試測，看題目鑑別度、刪爛題
- 5 EFA 探索因素** 用一半樣本找出實際的構面結構
- 6 CFA＋信效度＋報告** 另一半樣本驗證，算 AVE/CR、依 COSMIN 報告

重點 關鍵紀律：EFA 與 CFA 要用『不同的樣本』（或把資料切兩半）。用同一批資料先探索再驗證，等於自己出題自己改考卷——結構一定過，但沒有意義。本節實例：自製『數位健康識能量表 DHLS』（教學用虛構數據）。（次頁把這六個階段展開為八個關卡）

量表發展八關卡：一張圖看完

承上 六個階段 → 本頁 細拆成八個關卡；任何一關不過就回頭



任何一關不過 → 回頭修題再走一次

⑥ EFA 與 ⑦ CFA 必須用「不同樣本」——用同一批資料先探索再驗證，等於自己驗證自己。

健康測量工具的品質報告可對照 COSMIN 標準。

教學重點 切樣本前先確認兩半的年資與職類分佈相近；否則 CFA 不通過可能只是抽樣造成，不是結構有問題。

先修 · 因素分析在做什麼？（白話）

承上 關卡⑥⑦要用因素分析 → 本頁 先修：因素分析在做什麼（白話）

核心直覺

- 因素分析 = 看『哪些題彼此高度相關，像在測同一件事』。
- 把這些題歸成一個『因素／構面』（例如：焦慮、工作壓力）。
- 例：5 題若彼此相關都很高
→ 可能都在測『工作壓力』這一個構面。

三個關鍵名詞

- 因素負荷 loading：一題與某因素的相關（ $-1 \sim 1$ ）； > 0.5 = 這題『忠於』該因素。
- 特徵值／陡坡圖／平行分析：決定『抽幾個因素』的方法。
- KMO／Bartlett：資料『適不適合』做因素分析的體檢（ $KMO > 0.6$ 才值得做）。

重點 一句話：EFA（探索性因素分析）就是『讓資料告訴你——這一堆題背後其實有幾個構面、每題屬於哪一個』。把它想成『幫題目分組』；後面的 KMO、負荷、因素數，都是為了把這件事做得可靠。

先修 · 驗證與信效度指標（白話速查）

承上 因素分析的直覺 → 本頁 先修：後面會出現的指標縮寫，各回答一個問題

名詞	白話：它在問什麼	好的門檻
CVI（內容效度）	專家覺得這題『切不切題』的比例	$I-CVI \geq .78$ 、 $S-CVI \geq .90$
題總相關	這一題和量表總分有沒有關係	$\geq .30$
CFA 適配度 (CFI/RMSEA...)	你畫的構面圖和真實資料合不合	$CFI/TLI \geq .95$ ； $RMSEA/SRMR \leq .06/.08$
AVE	一個構面的題目『共同解釋的變異』夠不夠	$\geq .50$
CR / Cronbach α / ω	內部一致性（同構面的題夠不夠一致）	$\geq .70$

重點 看懂速查：每個指標都對應一個問句——切題嗎 (CVI)、這題有用嗎（題總相關）、結構對嗎 (CFA)、構面實在嗎 (AVE)、夠一致嗎 (CR/ α / ω)。之後本節總覽表，就是把這些門檻收在一起。

產生題項＋內容效度 CVI：先讓專家把關

承上 先修完畢 → 本頁 關卡②③：寫題項的原則＋用專家評分算內容效度 CVI

產生題項的原則

- 一題一概念，避免雙重內涵 (double-barreled)
- 語意清楚、避免引導與否定套否定
- 涵蓋建構的每個面向（內容代表性）
- 寧可多寫（如每構面 8-10 題），後面再刪
- 量尺一致（如 Likert 1-5）

內容效度指標 CVI

專家小組（常 5-10 人）逐題評『相關性』 1-4 分

$I-CVI$ = 某題評 3-4 分的專家比例

建議 $I-CVI \geq 0.78$ 保留（6 位以上專家；3-5 位須 1.00）

$S-CVI/Ave$ = 全量表平均，建議 ≥ 0.90

→ 據此刪修題目，並記錄過程

重點 CVI 是『量化的專家共識』：它把『這題到底測不測得到概念』交給領域專家評分，而不是研究者自己說了算。健康量表尤其重要——臨床專家能抓出病人真正在意、你卻漏掉的面向。

動手算：內容效度 CVI 逐步計算

承上 CVI 的規則 → 本頁 動手算：6 位專家評 4 題，算 I-CVI 與 S-CVI

題目	評 3-4 分的專家數 (N=6)	I-CVI	判斷
Q1	6	1.00	保留
Q2	5	0.83	保留
Q3	6	1.00	保留
Q4	4	0.67	< 0.78 → 修 / 刪

重點 步驟：① $I-CVI = \text{該題評『相關（3-4分）』的專家數} \div \text{總專家數}(6)$ 。② $S-CVI/Ave = \text{各題 } I-CVI \text{ 平均}$
 $= (1.00 + 0.83 + 1.00 + 0.67) \div 4 = 0.875$ 。判讀：I-CVI 應 ≥ 0.78 （6 位以上專家）→ Q4 只有 0.67，須修改或刪除；整體
 0.875 略低於 0.90 → 修好 Q4 再重評即達標。

前測與項目分析：淘汰『沒有鑑別力』的題

承上 專家把關過 → 本頁 關卡④⑤：前測＋項目分析，刪掉沒有鑑別力的題


檢查	看什麼	判準（參考）
題總相關	該題與量表總分的相關	$r < 0.3 \rightarrow$ 考慮刪除
刪題後 α	刪掉這題，Cronbach α 會不會反而升高	升高 $\rightarrow$ 這題可能是雜訊
決斷值 critical ratio	高分組 vs 低分組在該題差異（t 檢定）	不顯著 $\rightarrow$ 鑑別力差
分佈 / 天花板	是否幾乎所有人都選同一格	嚴重偏斜 $\rightarrow$ 資訊量低

重點 直覺：一個好題目應該讓『概念高的人』和『概念低的人』答得不一樣。如果人人都答一樣、或它跟總分沒關係，這題就沒在測東西——先在前測用項目分析刪掉，別把爛題帶進 EFA。

EFA vs CFA：先探索、後驗證

承上 題目刪乾淨了 → 本頁 關卡⑥⑦的分工：EFA 先探索、CFA 後驗證


EFA 探索性：不預設哪題屬哪因素



所有題目對所有因素都有負荷 → 由資料告訴你結構

用途：量表初期，還不確定有幾個構面

CFA 驗證性：事先指定結構再檢驗



事先規定 1-3 屬 F1、4-6 屬 F2 → 檢驗這個假設合不合

用途：用「新樣本」驗證 EFA 找到的結構

教學重點 EFA 用途在量表開發早期、發現構面，結果是因素數與負荷矩陣；CFA 用於已有理論結構、拿新樣本驗證。量表初期不確定幾個構面 → EFA；順序不能反。

EFA 步驟①：先確認資料『適不適合』做因素分析

承上 要跑 EFA 了 → 本頁 EFA 第一步：資料適不適合做因素分析（KMO、Bartlett）

兩個把關指標

KMO 取樣適切性：0-1，越高越好

> 0.6 尚可、> 0.8 良好

Bartlett 球形檢定： $p < 0.05$ 才通過

（檢定相關矩陣是否 $\neq$ 單位矩陣）

樣本量：常建議每題 5-10 人、且 ≥ 200

為什麼要先做

若題目彼此幾乎不相關 → 抽不出共同因素

KMO 太低 (< 0.5) → 別硬做 EFA

Bartlett 不顯著 → 沒有結構可找

→ 先過這關，再談抽幾個因素

DHLS 實例：KMO=0.89、Bartlett $p < 0.001$ ✓

重點 直覺：因素分析是『從很多題的共同變異裡，萃取出背後的少數構面』。如果題目之間根本沒共同變異（低 KMO、Bartlett 不顯著），就沒有『共同的東西』可萃取——硬做只會得到一堆無意義的因素。

EFA 步驟②：到底該抽『幾個』因素？

承上 資料適合 → 本頁 EFA 第二步：該抽幾個因素

方法	規則	評價
特徵值 > 1 (Kaiser)	保留 eigenvalue > 1 的因素	最常見，但常『高估』因素數，別單用
陡坡圖 Scree plot	看曲線『手肘』轉折前的因素	主觀，需搭配其他方法
平行分析 Parallel	與隨機資料的特徵值比較	目前最推薦、較準確
可解釋性	抽出的因素能不能合理命名	理論與統計要並重

重點 別只信『特徵值 > 1』：這條 Kaiser 規則簡單但常抽出太多因素。實務上以『平行分析』為主、陡坡圖與可解釋性為輔，三者交叉判斷。因素數不是純統計題——最終要能對每個因素講出一個有意義的構面名字。

EFA 步驟③：轉軸與負荷量判讀

承上 因素數決定了 → 本頁 EFA 第三步：轉軸，讀負荷量決定每題歸誰

轉軸 Rotation

目的：讓每題盡量只在『一個』因素高載入

正交 (Varimax)：假設因素間不相關

斜交 (Promax/Oblimin)：允許因素相關

→ 社會 / 健康構面常相關，多用斜交

轉軸不改變適配，只改變『可讀性』

負荷量 Loading 判讀

負荷量 = 題目與因素的關聯（正交轉軸時即相關）

一般保留 $|\text{loading}| \geq 0.40$ （嚴格 0.50）

交叉負荷（兩因素都 $>0.3 \sim 0.4$ ）→ 考慮刪

共同性 communality 太低 (<0.2) → 該題弱

據此刪題、重跑，直到結構乾淨

重點 判讀口訣：好題目『只忠於一個因素』——在自己構面上高載入 (>0.5)、在別的構面低載入 (<0.3)。腳踏兩條船的交叉負荷題會讓構面糊在一起，通常刪掉。刪題是正常且必要的，記得記錄每次決定。

EFA 實例：數位健康識能量表（DHLS）

承上 EFA 三步驟 → 本頁 實例：DHLS 24 題跑出三個構面

因素（命名）	高載入題（示例）	載入量範圍
F1 取得資訊 Access	我能找到可信的健康網站 /App	0.72 - 0.84
F2 理解資訊 Understand	我看得懂檢驗報告與衛教內容	0.68 - 0.81
F3 應用決策 Apply	我能用查到的資訊做健康決定	0.70 - 0.79
（已刪）交叉負荷題 ×3	同時載入 F1 與 F3	刪除

重點 解讀：24 題經 EFA（斜交轉軸）後，浮現三個因素、共解釋約 62% 變異，各題乾淨載入到單一構面；刪掉 3 題交叉負荷題後剩 21 題。這三個構面（取得／理解／應用）符合健康識能理論——統計與理論對得上，才算好結構。

CFA：把 EFA 找到的結構，拿到新樣本『驗證』

承上 EFA 找到三構面 → 本頁 關卡⑦：拿新樣本用 CFA 驗證這個結構

CFA 在做什麼

事先畫好模型：F1、F2、F3 各含哪些題

用『另一半樣本』檢定模型與資料的適配

每題只允許載入自己的構面（不像 EFA）

輸出：適配度指標＋標準化負荷＋AVE/CR

模型不好 → 依理論修正（勿盲目改）

為什麼要換樣本

同一批資料先探索再驗證＝作弊（必過）

CFA 需獨立樣本（或先切一半留給 CFA）

跨樣本仍站得住 → 結構才可信

健康量表常再做跨族群 / 跨語言恆等性

→ 這是可發表量表的基本要求

重點 EFA 與 CFA 的分工：EFA 像『田野探勘』畫出草圖，CFA 像『工程驗收』檢查這張圖在新地基上蓋不蓋得起來。只有草圖沒驗收，量表不算完成；用同一塊地既探勘又驗收，驗收一定過但毫無保證。

CFA 適配度指標：模型和資料合不合？

承上 CFA 跑完 → 本頁 看一組適配度指標：模型和資料合不合

指標	門檻（可接受 / 良好）	說明
χ^2/df	< 3 （嚴格 < 2）	卡方受樣本數影響，看比值
CFI / TLI	≥ 0.90 / ≥ 0.95	比較適配指標，越接近 1 越好
RMSEA	≤ 0.08 / ≤ 0.06	近似誤差，越小越好（附 90% CI）
SRMR	≤ 0.08	標準化殘差均方根

重點 報告慣例：CFI/TLI、RMSEA、SRMR 都要報、一起判讀（Hu & Bentler, 1999），別只挑漂亮的講。DHLS 實例： $\chi^2/df=2.1$ 、CFI=0.96、TLI=0.95、RMSEA=0.05、SRMR=0.04 → 模型適配良好，三構面結構獲驗證。

收斂與區辨效度：用 AVE、CR、 $\sqrt{AVE}$ 客觀判斷

承上 結構通過 → 本頁 關卡⑧：構面內要抱團（收斂）、構面間要分開（區辨）

收斂效度 Convergent

同構面的題要『測到同一件事』

平均變異抽取 $AVE \geq 0.50$

組合信度 $CR \geq 0.70$

標準化因素負荷 ≥ 0.50 （佳 0.70）

→ DHLS：各構面 AVE 0.55-0.63 ✓

區辨效度 Discriminant

不同構面要『分得開』、不重疊

Fornell-Larcker： $\sqrt{AVE} >$ 與其他構面的相關

HTMT < 0.85 （寬鬆 0.90）

→ 若兩構面相關過高，可能該合併

→ DHLS： $\sqrt{AVE}$ 均大於構面間相關 ✓

重點 兩個效度一起看：收斂 = 『同構面的題彼此夠像』（AVE 夠高）；區辨 = 『不同構面夠不一樣』（ $\sqrt{AVE}$ 大於它與別人的相關）。前者確保構面『實』，後者確保構面『各自獨立』——健康量表若『理解』和『應用』分不開，就得考慮合併或重新界定。

動手算：AVE 與 CR 逐步計算

承上 AVE、CR 的門檻 → 本頁 動手算：4 題負荷算 AVE 與 CR

① 收斂效度 AVE

因素負荷 λ ：.72、.81、.68、.77

$AVE = \Sigma \lambda^2 \div \text{題數}$

$\lambda^2 = .52、.66、.46、.59$ ； $\Sigma = 2.23$

$AVE = 2.23 \div 4 = 0.56$ ($\geq .50$ ✓)

→ 構面平均能解釋各題 56% 的變異

② 組合信度 CR

$CR = (\Sigma \lambda)^2 \div [(\Sigma \lambda)^2 + \Sigma(1 - \lambda^2)]$

$\Sigma \lambda = 2.98 \rightarrow (\Sigma \lambda)^2 = 8.88$

$\Sigma(1 - \lambda^2) = 1.77$

$CR = 8.88 \div (8.88 + 1.77) = 0.83$

($\geq .70$ ✓)

重點 讀懂：AVE=0.56 → 這個構面平均能解釋各題 56% 的變異（收斂效度足夠）；CR=0.83 是用因素負荷加權的信度，比 Cronbach α 更貼近 CFA。兩者都過門檻 → 這個構面『實在且一致』。（ $\sqrt{AVE}$ 再拿去和其他構面的相關比，即區辨效度。）

信度再進階： α 不是唯一，也不是萬能

承上 CR 也是一種信度 → 本頁 信度再進階： α 、CR、 ω 怎麼選

指標	特點	建議
Cronbach's α	最常見；假設各題貢獻相等 (tau-equivalent)	≥ 0.70 ；題數多時會虛高
組合信度 CR	用因素負荷加權，較貼近 CFA	≥ 0.70 ；SEM/CFA 常報這個
McDonald's ω	放寬 α 的等價假設，較穩健	≥ 0.70 ；越來越被推薦

重點 別再只報 α ： α 假設每題同等貢獻，題數一多就會『看起來很高』而誤導。在 CFA/SEM 脈絡下，組合信度 CR 與 McDonald's ω 更貼近真實內部一致性。報告時可同時附上，讓審稿人安心。 α 高也不代表單一維度——維度要靠因素分析判斷。

COSMIN：健康測量工具的『品質共識標準』

承上 八關都走完 → 本頁 COSMIN：怎麼把整套證據報告給別人看

COSMIN 是什麼

健康測量工具的方法學共識標準

把測量性質分成三大類：

- 信度（內部一致性、信度、測量誤差）
- 效度（內容、結構、假設檢驗、跨文化、效標）
- 反應性（responsiveness 偵測變化）

你能拿它做什麼

- 開發量表：對照它逐項確認做齊了
 - 選現成量表：系統性評比工具品質
 - 寫系統性回顧：評測量性質的證據
 - 投稿：用它證明你的驗證流程完整
- 健康科技自製量表的黃金對照表

重點 為什麼健康領域特別看重 COSMIN：臨床與健康科技常需自製或改編量表（症狀、生活品質、數位識能），COSMIN 提供一致的語言與標準，讓不同量表的品質可被公平比較——這也是量表能被引用、被納入指引的關鍵。

本節總覽：一頁看完量表怎麼『做出來又證明給人看』

承上 所有關卡與指標 → 本頁 本節總覽：一頁收齊流程與門檻

階段	關鍵動作	判準速查
內容效度	專家評分	$I-CVI \geq 0.78$ 、 $S-CVI \geq 0.90$
項目分析	刪爛題	題總相關 ≥ 0.3
EFA	找構面	$KMO > 0.6$ 、負荷 ≥ 0.4 、平行分析定因素數
CFA	驗結構	$CFI/TLI \geq .95$ 、 $RMSEA/SRMR \leq .06/.08$
信效度	算指標	$AVE \geq .5$ 、 $CR/\omega \geq .7$ 、 $\sqrt{AVE} >$ 構面相關

重點 帶走一句話：量表發展 = 『把抽象概念，用可重現、可驗證的流程，變成一把量得準、分得開、別人也能信的尺』。EFA 找結構、CFA 驗結構、AVE/CR/ω 給證據、COSMIN 定標準——這正是這一節加給你的能力。

小試身手：讀懂一份量表驗證結果

(參考答案見下一頁)

某團隊自製『長者用藥遵從 App 易用性量表』，報告如下，請判讀：

- Q1 EFA：KMO=0.55、Bartlett $p=0.21$ 。這份資料適合做因素分析嗎？為什麼？
- Q2 他們用『特徵值 >1 』抽出 5 個因素，但有 2 個因素各只有 1 題、且無法命名。你會怎麼建議？
- Q3 CFA 報告：CFI=0.91、RMSEA=0.11、SRMR=0.06。模型適配可接受嗎？哪個指標有問題？
- Q4 某構面 AVE=0.38、CR=0.82。收斂效度 OK 嗎？該怎麼解讀與處理？

重點 提示：Q1 想 KMO/Bartlett 門檻；Q2 想 Kaiser 高估因素數+可解釋性；Q3 想 RMSEA 超標；Q4 想 AVE <0.5 的判讀（Fornell-Larcker 的但書）。

參考答案

判讀重點；四個錯誤如何逐關修正，見第 72-98 張附錄

題	參考要點
Q1	不適合。KMO=0.55 偏低 (<0.6)、Bartlett $p=0.21$ 不顯著，代表題目間缺乏足夠共同相關，抽不出有意義的共同因素。應先檢討題目或增樣本，別硬跑 EFA。
Q2	『特徵值 >1 』常高估因素數。單題因素、無法命名=不可解釋。建議改用平行分析+陡坡圖重定因素數，刪除或合併那些單題 / 無法命名的因素，並兼顧理論可解釋性。
Q3	不理想。CFI=0.91 未達 .95；關鍵是 RMSEA=0.11 遠超 0.08，近似誤差過大、適配不佳。不能只挑 SRMR=0.06 好看的講，應依理論修正模型或重檢構面。
Q4	收斂效度不足：AVE=0.38 <0.50 ，構面內題目共同解釋的變異偏低。雖 CR=0.82 高，仍應檢查並刪修低負荷題或重新界定構面（Fornell-Larcker：CR >0.6 時可勉強接受但需說明）。

參考文獻與延伸閱讀

- Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159-174. → κ 分級 (第 10-12 張)
- Koo, T. K., & Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. *J Chiropractic Medicine*, 15(2), 155-163. → ICC
- AERA, APA, & NCME. (2014). Standards for educational and psychological testing. AERA. → 效度證據來源 (第 17 張)
- Polit, D. F., & Beck, C. T. (2006). The content validity index: Are you sure you know what's being reported? *Research in Nursing & Health*, 29(5), 489-497. → CVI
- Boateng, G. O., et al. (2018). Best practices for developing and validating scales for health, social, and behavioral research: A primer. *Frontiers in Public Health*, 6, 149. → 量表發展流程
- Hu, L., & Bentler, P. M. (1999). Cutoff criteria for fit indexes in covariance structure analysis. *Structural Equation Modeling*, 6(1), 1-55. → CFA 適配度
- Fornell, C., & Larcker, D. F. (1981). Evaluating structural equation models with unobservable variables and measurement error. *J Marketing Research*, 18(1), 39-50. → AVE / CR
- Henseler, J., Ringle, C. M., & Sarstedt, M. (2015). A new criterion for assessing discriminant validity in variance-based SEM. *J Academy of Marketing Science*, 43(1), 115-135. → HTMT
- McNeish, D. (2018). Thanks coefficient alpha, we'll take it from here. *Psychological Methods*, 23(3), 412-433. → α 與 ω
- Mokkink, L. B., et al. (2010). The COSMIN study reached international consensus on taxonomy, terminology, and definitions of measurement properties. *J Clin Epidemiol*, 63(7), 737-745. → COSMIN



作業

Take-home Assignment

Measure it right, or the design is wasted.

涵蓋單元 2：操作型定義、信度三型、效度（聚斂／區辨）、四種測量方法、問卷設計。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題檢驗你「測不測得準」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

針對一個構念，產出一份『可信又有效』的測量方案（操作型定義＋量表＋信效度規劃）。

繳交方式

一份 PDF：Part A 文字作答＋Part B 量表與信效度規劃，建議 3-5 頁。

建議時間

約 2-3 小時；先做 Part A 暖身，再進入 Part B 設計。

工具與誠信

可用 AI 協助發想與潤飾，但須附『AI 使用聲明』；引用需標註，禁止代寫與杜撰。

Part A | 觀念題：熟悉變數測量（1/2）

- A1** 用一句話區分信度與效度；為什麼說『效度比信度更根本』？用靶心比喻說明其中一種組合。
- A2** 信度三種檢驗（再測／內部一致性／評分者間）各回答什麼問題？各舉一個檢驗情境。
- A3** 什麼是操作型定義？同一概念可有多個，選擇的準則是什麼？
- A4** 聚斂效度與區辨效度的差異為何？各需要什麼證據？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2-4 句即可，不必長篇。

Part A | 觀念題：熟悉變數測量（2/2）

- A5** 四種測量方法（自陳／表現／觀察／生理）各寫一個優點與一個缺點；什麼情況該併用？
- A6** 為什麼信度低會降低統計檢定力、放大 p 值？低信度時可以怎麼補償？
- A7** 自陳法常見偏誤至少三種，並各寫出一個對策。
- A8** 問卷設計四步驟是什麼？每步用一句話說明『產出什麼』。

Part B | 實作題：設計一份可信可效的測量（1/2）

指示：選一個構念（工作壓力／學習動機／服務品質，或你自己的變數），完成下列各題。

- B1** 寫出該構念的操作型定義；設計一份 5-8 題量表（附量尺），標明每題對應的子構面。
- B2** 規劃如何驗證信度：三型中至少兩型，寫出做法與可接受門檻。
- B3** 規劃如何驗證聚斂與區辨效度：列出『應相關』與『不該相關』的變數各至少一個，並預期相關方向／大小。

教學重點 量表題項必須對得回你的構念定義與子構面——這是內容效度的基礎。

Part B | 實作題：設計一份可信可效的測量（2/2）

- B4** 指出你的測量可能的偏誤（社會期許等）與你的對策。
- B5** 說明你會用數值或類別測量、為什麼；若構念難測，你的替代指標或研究問題微調策略。
- B6** 附一段方法章『測量』小節（150 字內）+ AI 使用聲明。

繳交格式 Part B 建議用『量表題目表+信效度規劃表』呈現，一眼看得出每題測什麼、怎麼驗。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能用靶心／門檻說明
B1 操作化+量表	15%	操作型定義清楚、題項對應子構面、附量尺
B2 信度規劃	15%	至少兩型、做法具體、門檻正確
B3 效度規劃	15%	聚斂與區辨都有、預期方向合理
B4-B6 偏誤+方法+誠信	15%	偏誤與對策對應、方法段可重做、附 AI 聲明

常見扣分 信效度混用、只報 α 就當作『效度良好』、題項與子構面對不上、忘了反向題與匿名。

案例應用：把三個結果變數變成可以測量的東西

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

- ① 本單元教了什麼** 操作型定義、測量尺度，以及信度與效度各自需要什麼證據。
- ② 案例怎麼用**
 - 主要結果定義為：自取得前一班紀錄至開始口頭交班之分鐘數。
 - 以第三方觀察計時，兩位觀察者校準 30 次交班， $ICC = .91$ 。
 - 紀錄完整性以 0 至 20 分評分表測量，兩位評分者獨立評分， $ICC = .84$ 。
 - 認知負荷屬潛在構念，須自編量表並驗證（題目撰寫見 4.3，統計驗證見本單元量表發展節），不可用單題自陳。
- ③ 產出什麼證據** 變數操作型定義表（次頁），納入計畫書第 3.4 節「研究工具」。
- ④ 承接關係** 上游：承自 2.1 之研究設計決策表 | 下游：交棒 2.3，據此建立資料字典。

教學重點 操作型定義的檢驗標準只有一個：換一個人來測，會不會得到同一個數字。寫不到這個程度，就不是操作型定義，只是換句話說。

示範產物：變數操作型定義表

六個變數逐一交代定義、尺度、來源與品質證據；缺任一欄即為審查意見來源

變數	角色	操作型定義	尺度	資料來源與品質證據
交班準備時間	主要依變量	自取得前一班紀錄至開始口頭交班之分鐘數	比率	第三方觀察計時；ICC = .91（設定值）
紀錄完整性	次要依變量	8 項必載事項之評分加總，滿分 20 分	等距	兩位評分者獨立評分；ICC = .84（設定值）
二次確認詢問次數	探索性依變量	交班結束後 30 分鐘內接班者回頭詢問之次數	比率	現場計數
自評認知負荷	解釋變項	自編 8 題量表加總，8 至 56 分	等距	$\alpha = .87$ ；重測 ICC = .78（設定值）
導入與否	自變量	該次交班是否發生於該機構導入日之後	名目	系統上線紀錄
職類、年資	控制變項	護理師／資深照服員／單位主管；到職年數	名目／比率	人事資料

教學重點 「二次確認詢問次數」原本不在計畫中，是預試時觀察到才補測的（未列入預先註冊之分析，故屬探索性，見 7.2）——這一欄後來成了本研究最有價值的發現。測量計畫留一點餘裕，比全部鎖死更好。

附

附錄


量表發展全程實例

Worked Example: Building a Usability Scale Step by Step

以第 54 張的『長者用藥遵從 App 易用性量表』為例，從零走完八個關卡；
每一關都交代：要做什麼、實際怎麼做、得到什麼數字、下了什麼決定。
(教學用虛構數據，以固定亂數種子模擬產生，數字前後一致、可自行驗算。)

全程地圖：八個關卡、兩批樣本、題數 30 → 15

先看全貌；後面每一張的眉標都標出它在哪一關



①-④ 不跑統計：焦點團體 26 人
專家 6 位、認知訪談 10 人

⑤⑥ 樣本 A：260 人
項目分析+ EFA

⑦⑧ 樣本 B：240 人
CFA + 信效度（60 人再測）

任何一關不過 → 回頭修題再走一次

①-④ 不跑統計；⑤⑥ 只用樣本 A；⑦⑧ 只用樣本 B——EFA 與 CFA 用的是兩批不同的人。

題數 30 → 25 → 26 → 20 → 15；第 74 張先對照第 54 張的四個錯誤，各出在哪一關。

教學重點 題數一路刪減是正常的：30 題最後只留一半。每刪一題都要留下理由（數字+題意），審查者最常問的就是『為什麼刪這題』。

第一版的四個錯誤：各出在哪一關？

第 54 張的報告，就是這個團隊的第一版——錯誤會一關傳一關

第 54 張	第一版做了什麼	錯在哪一關	正確做法（見第幾張）
Q1 KMO .55 Bartlett p = .21	前測只收 45 人，就拿 26 題直接跑 EFA （每題不到 2 人）	⑥ 的前提：樣本數	另收樣本 A 260 人 → KMO .91 （第 81、85 張）
Q2 特徵值 > 1 抽出 5 個因素	只看 Kaiser 規則；其中 2 個因素各只有 1 題、無法命名	⑥ 決定因素數	改用平行分析 → 3 個因素（第 86 張）
Q3 CFI .91 RMSEA .11	把含單題因素的 5 因素模型直接拿去 CFA	⑦（被 ⑥ 的錯拖累）	3 因素模型+新樣本 B → RMSEA .050 （第 90 張）
Q4 AVE .38 CR .82	8 題全留，其中 3 題負荷量不到 .50	⑤ 項目分析被跳過	先淘汰弱題 → AVE .55-.65 （第 83、84、91 張）

重點 四個錯其實是同一個病：急著跑統計、跳過前面的關卡。樣本不夠（Q1）→ 因素數抓錯（Q2）→ CFA 不合（Q3）；弱題沒先刪（Q4）→ AVE 被拉低。

關卡①：先確認『要自己編』，再把概念寫清楚

自編量表之前，要先證明現成的不夠用

第一步：先找現成量表

- 找到通用的系統易用性量表 SUS（10 題）
- 但 SUS 沒問長者最在意的兩件事：
字看不看得清楚、提醒有沒有幫到吃藥
- 決定：自編新量表
- SUS 不丟：留到關卡⑧ 當比較對象，
檢驗新量表的聚斂效度

第二步：寫出操作型定義

- 誰：65 歲以上、每天吃慢性病藥的長者
- 在哪：在家，自己用手機 App
- 做什麼：三項核心任務——設定吃藥提醒、
提醒響時確認服藥、查看服藥紀錄
- 測什麼：做這三件事時主觀感受到的
『看得清楚、操作容易、提醒有用』程度

重點 定義要寫到『換一個人來讀，也知道測誰、在什麼情境、測什麼』。範圍越清楚，題目越好寫、專家越好評。

關卡①：三個構面從哪裡來？理論＋長者原話

焦點團體 3 場（長者 20 人）＋照顧者 1 場（6 人），逐字稿編碼後與理論對照

構面	定義	理論依據	焦點團體原話（例）
看得清楚	畫面上的字、顏色、圖示與藥品照片，長者能否看清、認得出來	ISO 9241-11 效能； 老化帶來的視力退化	「字太小，都要叫孫子唸給我聽」
操作容易	設定與修改的步驟是否少、好記，按錯時能不能回頭	ISO 9241-11 效率； TAM 知覺易用性	「按錯一次，就不知道跑去哪裡了」
提醒有用	提醒是否真的幫助按時吃藥，並留下服藥紀錄	TAM 知覺有用性； 用藥遵從文獻	「有響才記得吃，但要告訴我吃哪一顆」

重點 構面不是研究者想像出來的：理論說『應該有什麼』，長者原話說『實際在意什麼』，對得上才定案。這三個構面就是 EFA 要驗證的理論預期。

關卡②：每個構面寫 10 題，共 30 題題庫

目標最終 15 題；題庫至少寫到最終長度的 2 倍（Boateng 等，2018）

寫題原則	好題目（採用）	壞題目（避免）與原因
一題只問一件事	修改吃藥的時間很容易	App 好用又好看（兩件事，無從作答）
寫具體行為，不寫抽象評價	我一眼就能找到今天要吃的藥	App 的資訊架構清楚（術語、太抽象）
對準易用性，不測別的	吃完藥按「已服用」很方便	App 對我的健康有幫助（測到效益）
用長者自己的話	按錯的時候，我知道怎麼回到上一步	錯誤復原機制完善（長者看不懂）
時間框架一致	指導語統一：想想過去一週的使用經驗	各題時間不一（「最近」「平常」混用）

重點 量尺用 5 點（1 非常不同意～5 非常同意），每一點都印上文字、字級放大——長者的作答負擔優先（點數取捨見 4.3）。

關卡③： 6 位專家兩輪評分， 30 題 → 25 題

專家：老年醫學科醫師 1、社區藥師 2、老人護理 1、人因設計 1、資訊工程 1

題目（例）	評 3-4 分人數	I-CVI	處理
我一眼就能找到今天要吃的藥	6 / 6	1.00	保留
新增一種藥的步驟不多，我做得到	5 / 6	.83	保留 (≥ .78)
提醒功能很好用	4 / 6	.67	太籠統 → 改寫為「提醒響起時，我知道要做什麼」 第二輪 6 / 6 → 保留
App 功能齊全	4 / 6	.67	改寫後第二輪仍 4 / 6 → 刪（功能多不等於好用）
App 下載很快	3 / 6	.50	刪（測到的是網路速度，不是 App 本身）
我喜歡這個 App 的設計風格	2 / 6	.33	刪（測到的是個人喜好）

重點 整體：第一輪 21 題直接過、5 題改寫、4 題刪除；第二輪只重評改寫的 5 題，4 題過、1 題刪——共留 25 題。

關卡③： I-CVI 與 S-CVI 怎麼算（本例）

每位專家逐題評 1-4 分：1 不相關、2 需大改、3 小改即可、4 非常相關

逐題：I-CVI

- 評 3 或 4 分 = 「相關」
- $I-CVI = \text{評相關的人數} \div \text{專家數}$
- 6 位以上專家門檻 .78（Lynn，1986）
→ 至少 5 人評相關（ $5 \div 6 = .83$ ）才過
- 本研究規則：4 人（.67）改寫後重評；
3 人以下（ $\leq .50$ ）直接刪除

全量表：S-CVI/Ave

- 最後 25 題的 I-CVI：
16 題為 1.00、9 題為 .83（5/6）
- $S-CVI/Ave = \text{各題 I-CVI 的平均}$
 $= (16 \times 1 + 9 \times 5/6) \div 25$
 $= (16 + 7.5) \div 25 = .94$
- 門檻 $\geq .90$ （Polit 等，2007）→ 通過 ✓

重點 與第 40 張同一套算法。6 位以上專家用 .78；只有 3-5 位時每題都要全員同意（1.00）——專家越少，門檻越嚴。

關卡④：請 10 位長者邊想邊說，25 → 26 題

一對一：先作答，再追問「這題你是怎麼想的？」；刻意找 75 歲以上、戴老花眼鏡者

發現的問題	卡住人數	修正做法
「介面」這個詞看不懂	4 / 10	全部改成「畫面」
「推播通知」不知道是什麼	6 / 10	改成「手機跳出來的提醒訊息」
「字夠大、顏色也清楚」一題問兩件事	3 / 10	拆成「字夠大」與「顏色對比清楚」兩題 → 25 → 26 題
反向題「我常常不知道下一步要按哪裡」答反	3 / 10	改成正向：「我知道下一步要按哪裡」
中間選項「普通」被當成「不知道」	5 / 10	每一點都印文字；另設「沒用過這個功能」（不計分）

重點 本量表不用反向題：長者看到否定句易答反，誤差比默許傾向更大（與第 67 張一般建議不同，依族群調整並寫進研究限制）。

兩批不同的長者：樣本 A 探索、樣本 B 驗證

這一頁就是 Q1 的解方：樣本要夠大，而且 EFA 與 CFA 不能用同一批人

樣本 A (n = 260) → 關卡⑤⑥

- 用途：項目分析 + EFA
- 人數：26 題 × 每題 10 人 = 260
(第 43 張：每題 5-10 人、且 ≥ 200)
- 來源：3 個社區關懷據點
+ 1 家醫院藥局

樣本 B (n = 240) → 關卡⑦⑧

- 用途：CFA + 信度 + 效度
- 人數：CFA 常建議 ≥ 200 ，本例收 240
- 來源：另外 4 個據點、晚兩個月收案，
與樣本 A 沒有重複的人
- 其中 60 人兩週後再填一次（再測；
COSMIN：50-99 人屬「足夠」）

重點 共同條件：65 歲以上、每天吃慢性病藥、已用該 App 至少 2 週；排除中度以上認知障礙。兩批都由訪員唸題、長者作答。

關卡⑤：用四把尺檢查每一題（樣本 A）

規則：兩把以上不合格 → 刪除；只有一把不合格 → 標記「觀察」，交給 EFA 再判

尺	怎麼算	不合格的標準
① 校正題總相關	該題與「同構面其他題加總」的相關（不含自己）	$< .30$
② 刪題後 α	把這題拿掉，構面的 Cronbach's α 變成多少	比原本高（這題在拖後腿）
③ 決斷值（t 檢定）	總分前 27% 與後 27% 兩組，比較該題平均	差異不顯著（ $p \geq .05$ ）
④ 天花板／地板	選最高分（或最低分）那一格的人數比例	超過 50%

重點 ①② 看『這題跟同構面其他題是不是一夥的』，③ 看『能不能分出高低』，④ 看『是不是大家都答一樣』。原理見第 41 張。

關卡⑤結果：刪 6 題、標記 2 題，26 → 20 題

只列出有問題的 8 題（ $\times$ = 不合格）；其餘 18 題四把尺全部通過

題目	① 題總相關	② 刪題後 α (原 α)	③ 決斷值	④ 最高／最低格	不合格	決定
V7 App 的配色讓我看了舒服	.20 $\times$	.864 (.842) $\times$	顯著	—	2	刪
V9 畫面不會超出手機螢幕	.297 $\times$	.848 (.842) $\times$	顯著	5 分 87% $\times$	3	刪
O8 我會自己更新 App 版本	.25 $\times$	.843 (.834) $\times$	顯著	1 分 58% $\times$	3	刪
O9 我會打開這個 App	.21 $\times$	.844 (.834) $\times$	顯著	5 分 93% $\times$	3	刪
R7 提醒的鈴聲好聽	.06 $\times$	.837 (.796) $\times$	$p = .077 \times$	—	3	刪
R8 我會把 App 推薦給朋友	.20 $\times$	.816 (.796) $\times$	顯著	—	2	刪
V6 晚上光線暗也看得清楚	.37	.845 (.842) $\times$	顯著	—	1	觀察
O7 不需家人幫忙就會用	.33	.843 (.834) $\times$	顯著	—	1	觀察

重點 刪完 6 題，各構面 α 不降反升：看得清楚 .84 → .87、操作容易 .83 → .86、提醒有用 .80 → .87。

回頭看 Q4：為什麼 CR 有 .82，AVE 卻只有 .38？

第一版『操作容易』8 題全留（跳過項目分析）——拿它的負荷量實際算一次

第一版：8 題全留

$$\lambda: .82 .78 .74 .70 .52 .44 .40 .35$$

$$AVE = \Sigma \lambda^2 \div 8 = 3.06 \div 8 = .38 \times$$

$$\Sigma \lambda = 4.75 \rightarrow (\Sigma \lambda)^2 = 22.56$$

$$\Sigma(1-\lambda^2) = 8 - 3.06 = 4.94$$

$$CR = 22.56 \div (22.56 + 4.94) = .82 \checkmark$$

刪掉 $\lambda < .50$ 的 3 題：剩 5 題

$$\lambda: .82 .78 .74 .70 .52$$

$$AVE = \Sigma \lambda^2 \div 5 = 2.59 \div 5 = .52 \checkmark$$

$$\Sigma \lambda = 3.56 \rightarrow (\Sigma \lambda)^2 = 12.67$$

$$\Sigma(1-\lambda^2) = 5 - 2.59 = 2.41$$

$$CR = 12.67 \div (12.67 + 2.41) = .84 \checkmark$$

重點 CR 會隨題數變大，題一多就『看起來很一致』；AVE 是平均，弱題會把它拉下來。CR 高只能讓 AVE 偏低『勉強接受』（第 55 張），根本解法是刪弱題。

關卡⑥ -1：這批資料適合做因素分析嗎？

方法：主軸因素法抽取 + oblimin 斜交轉軸（三個構面預期彼此相關）

本例：樣本 A、20 題

- $KMO = .91$ ($> .80$ 良好) ✓
 - Bartlett: $\chi^2(190) = 2,796.2$, $p < .001$ ✓
 - 每題人數: $260 \div 20 = 13$ 人 ✓
- 可以做 EFA


對照第一版 (Q1)：45 人、26 題

- 每題不到 2 人 ($45 \div 26 = 1.7$)
 - $KMO = .55$ 、Bartlett $p = .21$ ✗
 - 人太少時相關係數充滿隨機雜訊，
看不出題目間真正的共同變異
- 該做的是多收人，不是硬跑

重點 Bartlett 的自由度 = 題數 $\times$ (題數 - 1) $\div 2 = 20 \times 19 \div 2 = 190$ 。體檢通過只代表『可以做』，接著還要決定抽幾個因素。

關卡⑥-2：抽幾個因素？看平行分析

實際資料的特徵值（藍）高於隨機資料（橘，500 次模擬的 95 百分位）才保留



讀圖三步

① 第 1-3 個：7.66、2.65、1.77 都高於隨機的 1.62、1.49、1.41 → 保留

② 第 4 個：0.91 低於隨機的 1.35 → 停

③ 陡坡圖的手肘也在第 3 個之後

結論：3 個因素，和關卡① 的理論一致

為什麼第一版抽出 5 個？(Q2)

45 人、26 題的『純隨機』資料，平均就有 11 個特徵值 > 1——人少時 Kaiser 規則必然高估。

重點 平行分析的邏輯：連亂數都做得出來的特徵值，不算真的因素。本例 Kaiser 也剛好給 3 個，是運氣——人少或題多時它常多抓好幾個。

關卡⑥ -3：第一輪負荷量，找出要刪的 5 題

20 題抽 3 個因素：15 題乾淨地只落在自己的構面，下列 5 題有問題（pattern 負荷量）

題目	看得清楚	操作容易	提醒有用	共同性 h^2	問題	決定
V6 晚上光線暗也看得清楚	.44	-.07	-.04	.17	共同性 < .20（⑤已標記觀察）	刪
V8 小圖示的意思我看得懂	.34	.33	.09	.39	交叉負荷：兩個構面都約 .3	刪
O3 按鈕夠大，我點得到	.50	.29	.05	.52	寫給操作，卻落在看清： 同時問『看得到』與『點得到』	刪
O7 不需家人幫忙就會用	.11	.35	-.14	.14	主負荷 < .40、共同性 < .20	刪
R5 提醒畫面寫清楚吃哪顆藥	.38	.02	.44	.46	交叉負荷：看清 .38、提醒 .44	刪

重點 保留規則：主負荷 $\geq .40$ 、次負荷 < .30、共同性 $\geq .20$ ，且歸屬要符合題意。一次只刪一題、刪完重跑，再看下一題。

關卡⑥結果： 15 題、 3 個乾淨的構面


刪完重跑：KMO = .89、Bartlett $\chi^2(105) = 2,253.0$ ， $p < .001$ ；平行分析仍為 3 個因素

構面	保留的 5 題 (題意)	主負荷量	最大交叉負荷
看得清楚	V1 字夠大、V2 顏色對比、V3 找到今天的藥、 V4 認得藥品照片、V5 看懂服藥紀錄	.74-.84	.17
操作容易	O1 新增藥步驟少、O2 知道下一步、O4 按錯能回頭、 O5 用過就記得、O6 改時間容易	.52-.86	.17
提醒有用	R1 依習慣設提醒、R2 響了知道做什麼、R3 比較不會忘、 R4 依作息調整、R6 按已服用很方便	.68-.81	.16

重點 3 個因素共解釋 61.2% 的變異，因素間相關 .29-.50（所以用斜交轉軸）。EFA 找到的正是關卡①的三個構面——對上了，才進 CFA。

關卡⑦：CFA 模型——拿到樣本 B 驗證

事先規定每題只屬於一個構面（不像 EFA）；線旁數字為標準化負荷量 λ



看得清楚 與 提醒有用 的相關 $r = .50$ （兩者不相鄰，未畫線）。
圖中 15 題＝關卡⑥ 留下的題目；每題只畫一條線到自己的構面。

重點 估計法：最大概似法（ML），5 點題視為連續；分布嚴重偏斜時改用 WLSMV。R1 與 R4 下方的括號是『誤差相關』，理由見下一張。

關卡⑦：適配度——初始模型 vs 修正一次

門檻同第 48 張（可接受／良好）；最右欄為第一版的 5 因素模型（Q3），作為對照

指標	門檻（可接受／良好）	初始模型	修正後（+ R1-R4 誤差相關）	第一版（Q3）
χ^2 / df	< 3（嚴格 < 2）	196.8 / 87 = 2.26	136.9 / 86 = 1.59	—
CFI	$\geq .90 / \geq .95$	.950	.977	.91
TLI	$\geq .90 / \geq .95$	.940	.972	—
RMSEA [90% CI]	$\leq .08 / \leq .06$	.073 [.059, .086]	.050 [.033, .065]	.11 x
SRMR	$\leq .08$	.053	.046	.06

重點 修正指標最大的是 R1、R4：兩題都在問『設定提醒時間』，誤差相關有題意依據才加（ χ^2 降 59.8）；次大的 O5-O6 只降 14.9 且無題意理由，不加。

關卡⑧ -1：信度與收斂效度（樣本 B）

AVE 與 CR 用頁面上四捨五入後的 λ 計算，可自行驗算； α 由原始資料算出

構面	標準化負荷量 λ	AVE ($\geq .50$)	CR ($\geq .70$)	α ($\geq .70$)	判讀
看得清楚	.87 .82 .79 .76 .77	.64	.90	.90	收斂 ✓ 信度 ✓
操作容易	.84 .86 .83 .72 .77	.65	.90	.90	收斂 ✓ 信度 ✓
提醒有用	.65 .85 .81 .60 .78	.55	.86	.87	收斂 ✓ 信度 ✓ R1、R4 較低：兩題共享誤差
全量表 15 題	—	—	—	.91	總分可用

重點 驗算『看得清楚』： $AVE = (.87^2 + .82^2 + .79^2 + .76^2 + .77^2) \div 5 = 3.22 \div 5 = .64$ ； $CR = 4.01^2 \div (4.01^2 + 1.78) = .90$ 。算法同第 50 張。

關卡⑧ -2：區辨效度——三個構面分得開嗎？

Fornell-Larcker：對角線 $\sqrt{\text{AVE}}$ 要大於同列、同欄的構面相關；HTMT 要 $< .85$

構面	看得清楚	操作容易	提醒有用	HTMT
看得清楚	$\sqrt{\text{AVE}} .80$			—
操作容易	.55	$\sqrt{\text{AVE}} .81$		與看得清楚 .54
提醒有用	.50	.52	$\sqrt{\text{AVE}} .74$	與看得清楚 .49、與操作容易 .51

重點 判讀：.80、.81、.74 都大於所在列與欄的相關（最大 .55）；HTMT 最大 .54，遠低於 .85。三個構面相關但不重疊。

關卡⑧ -3：事先寫好的 4 個預測成立嗎？

構念效度的『假設檢驗』：預測寫在研究計畫裡，資料出來後才對答案（樣本 B）

事先寫好的預測	為什麼這樣預期	結果	成立
H1 與 SUS 總分正相關， $r \geq .50$	兩者都在測易用性（聚斂）	$r = .70$	✓
H2 與三項任務完成時間負相關， $r \leq -.30$	越好用、做得越快（訪員現場計時）	$r = -.39$	✓
H3 與每天吃幾顆藥幾乎無關， $ r < .20$	易用性不該隨藥量改變（區辨）	$r = -.02$	✓
H4 每天用智慧型手機者分數較高， $d \geq .50$	熟悉手機的人較容易上手 （已知群體：111 人 vs 129 人）	M 3.59 vs 2.95 $t(238) = 7.22$ ， $p < .001$ ， $d = .93$	✓

重點 4 個預測全部成立（COSMIN 建議至少 75% 成立）。關鍵在『事先』：看了資料才編預測，一定全中也毫無意義。

關卡⑧ -4：再測信度與測量誤差

樣本 B 中 60 人，隔 2 週（期間 App 未改版）再填一次

再測信度：ICC

- 模式：ICC(2,1)，絕對一致性
- $ICC = .87$ ，95% CI [.79, .92]
- 門檻 $\geq .70$ ✓（同第 68 張）
- 兩次平均 3.27 $\rightarrow$ 3.31，幾乎沒變

測量誤差：SEM 與 SDC

- $SEM = SD \times \sqrt{1 - ICC}$
 $= 0.79 \times \sqrt{0.13} = 0.79 \times 0.361 = 0.285$
- 最小可偵測變化 SDC
 $= 1.96 \times \sqrt{2} \times SEM = 2.77 \times 0.285 = 0.79$
- 1-5 分量尺上，個人前後差 ≥ 0.8 分
才算真的改變（團體平均可偵測更小差異）

重點 ICC 高代表『整群人的排序穩定』；SEM / SDC 則說『個人分數有多少雜訊』：看某位長者有沒有變好，差距要 ≥ 0.8 分才算數。

成品：長者用藥遵從 App 易用性量表

指導語：請想想過去一週使用這個 App 的經驗，圈選最符合的答案（1 非常不同意～5 非常同意）

構面	題目	題目（續）
看得清楚	1 畫面上的字夠大，我看得清楚 2 畫面的顏色對比清楚，字不會和背景混在一起 3 我一眼就能找到今天要吃的藥	4 藥品的照片，讓我認得出是哪一顆藥 5 服藥紀錄的畫面，我看得懂自己有沒有漏吃
操作容易	6 新增一種藥的步驟不多，我做得到 7 我知道下一步要按哪裡 8 按錯的時候，我知道怎麼回到上一步	9 用過一兩次後，我就記得怎麼操作 10 修改吃藥的時間很容易
提醒有用	11 我可以把提醒設定在習慣吃藥的時間 12 提醒響起時，我知道要做什麼 13 有了提醒，我比較不會忘記吃藥	14 提醒的時間可以依我的作息調整 15 吃完藥按「已服用」很方便

重點 計分：各構面取 5 題平均（1-5 分），總分取 15 題平均，越高越好用；「沒用過這個功能」不計分，某構面缺 2 題以上則該構面不計分。

對照 COSMIN：做了什麼、還缺什麼

COSMIN 的測量性質逐項核對（第 52 張）；「待補」要寫進研究限制

測量性質	本例的證據	狀態
內容效度	焦點團體 26 人+專家 6 位（S-CVI/Ave .94）+認知訪談 10 人	✓
結構效度	EFA（樣本 A）→ CFA（樣本 B）：CFI .977、RMSEA .050	✓
內部一致性	α .87-.90、CR .86-.90	✓
信度（再測）	ICC .87（60 人，間隔 2 週）	✓
測量誤差	SEM 0.285、SDC 0.79 分	✓
假設檢驗	4 個事先預測全部成立	✓
跨文化／測量恆等性	未檢驗（例：65-74 歲與 75 歲以上是否為同一結構）	待補
效標效度	易用性沒有公認的黃金標準	不適用
反應性	需要 App 改版前後的追蹤資料	待補

重點 完成的量表不是『全部打勾』，而是『清楚交代做了哪些、還缺哪些』。缺的兩項是下一篇研究的題目，也是審查者一定會問的地方。

寫成論文方法段：一段話交代全流程

照關卡順序寫，每一步都附人數與數字——讀者照著做，要能做出同一份量表

【題項與內容效度】量表依 Boateng 等（2018）之流程發展。依文獻與焦點團體（長者 20 人、照顧者 6 人）界定三個構面並撰寫 30 題，經 6 位專家兩輪內容效度評定，保留 $I-CVI \geq .78$ 者 25 題（ $S-CVI/Ave = .94$ ），再經 10 位長者認知訪談修訂為 26 題。

【項目分析與 EFA】樣本 A（ $n = 260$ ）先進行項目分析，刪除 6 題；再以主軸因素法與 oblimin 斜交轉軸進行探索性因素分析，依平行分析保留 3 個因素，刪除 5 題後得 15 題（ $KMO = .89$ ，解釋變異 61.2%）。

【CFA 與信效度】樣本 B（ $n = 240$ ）以最大概似法進行驗證性因素分析，依題意加入一組誤差相關後， $\chi^2(86) = 136.9$ 、 $CFI = .977$ 、 $TLI = .972$ 、 $RMSEA = .050$ （90% CI [.033, .065]）、 $SRMR = .046$ ；各構面 AVE .55-.65、CR .86-.90、Cronbach's α .87-.90；再測 $ICC(2,1) = .87$ （ $n = 60$ ，間隔 2 週）。

重點 寫法口訣：每一關寫『做了什麼＋多少人＋得到什麼數字＋刪幾題』。刪題理由放附錄表格（如第 83、87 張），正文只寫結果。

附錄參考文獻

- Brooke, J. (1996). SUS: A "quick and dirty" usability scale. In P. W. Jordan et al. (Eds.), Usability evaluation in industry (pp. 189–194). Taylor & Francis. → SUS (第 75、93 張)
- Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. MIS Quarterly, 13(3), 319–340. → TAM (第 76 張)
- ISO. (2018). ISO 9241-11:2018 Ergonomics of human-system interaction — Usability: Definitions and concepts. ISO. → 易用性定義 (第 76 張)
- Lynn, M. R. (1986). Determination and quantification of content validity. Nursing Research, 35(6), 382–385. → I-CVI 門檻 (第 79 張)
- Polit, D. F., Beck, C. T., & Owen, S. V. (2007). Is the CVI an acceptable indicator of content validity? Appraisal and recommendations. Research in Nursing & Health, 30(4), 459–467. → S-CVI/Ave (第 79 張)
- Willis, G. B. (2005). Cognitive interviewing: A tool for improving questionnaire design. Sage. → 認知訪談 (第 80 張)
- Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. Psychometrika, 30(2), 179–185. → 平行分析 (第 86 張)
- Costello, A. B., & Osborne, J. W. (2005). Best practices in exploratory factor analysis. Practical Assessment, Research, and Evaluation, 10, Article 7. → EFA 刪題 (第 87 張)
- Brown, T. A. (2015). Confirmatory factor analysis for applied research (2nd ed.). Guilford Press. → 誤差相關的修正原則 (第 90 張)
- de Vet, H. C. W., Terwee, C. B., Mokkink, L. B., & Knol, D. L. (2011). Measurement in medicine: A practical guide. Cambridge University Press. → SEM / SDC (第 94 張)
- Mokkink, L. B., et al. (2018). COSMIN Risk of Bias checklist for systematic reviews of patient-reported outcome measures. Quality of Life Research, 27(5), 1171–1179. → 再測樣本數 (第 81 張)
- Prinsen, C. A. C., et al. (2018). COSMIN guideline for systematic reviews of patient-reported outcome measures. Quality of Life Research, 27(5), 1147–1157. → 假設檢驗 75% 準則 (第 93 張)
- 其餘 (Boateng et al., 2018 ; Hu & Bentler, 1999 ; Fornell & Larcker, 1981 ; Henseler et al., 2015) 見第 56 張。