

量性研究方法 · 完整研究專案

單元 2

變數測量

Measuring Your Variables — Reliability & Validity

如果變數測不準，再好的設計也白費：操作型定義、信度三型、效度、四種測量方法與問卷設計實務

有效測量的兩大支柱



信度 Reliability

= 穩定一致性

測量結果是否「穩定、一致、可重複」。同一對象量兩次應得到相近結果。



效度 Validity

= 測得對不對

測量是否「真正反映」要測的概念。準不準，比穩不穩更根本。

本單元結束後，你能.....

- 能為一個抽象概念寫出可操作、可測量的操作型定義。
- 能判別變數屬名目、次序、等距或比率尺度，並據以選擇統計方法。
- 能規劃信度驗證：從三型中選出適用者，並說明可接受門檻。
- 能規劃效度證據：說明內容、效標關聯與構念效度各需要什麼證據。
- 驗收方式 ① 對應作業 A3、B1；② 對應 B5；③ 對應 A2、B2；④ 對應 A4、B3。

從變數到測量：操作型定義

操作型定義 (Operational Definition) = 為了這個研究的目的，把抽象概念變成「可實際測量」的具體做法。

抽象概念	可能的操作型定義
健康 Health	主觀評分、生理指標 (如腫瘤大小) 、體能表現
表現 Performance	速度、品質，或兩者兼具？
公司規模 Company size	營收、員工人數、顧客數
創業者 Entrepreneur	擁有事業 (全職 / 兼職) 、每週投入 ≥ 30 小時經營

同一個概念往往有多種操作型定義——選擇會直接影響你測到什麼。

操作型定義的原則：找到一個「行得通」的

- 別在這一步過度糾結——通常有很多操作型定義都可行
- 你只需要找到「一個行得通」的定義即可
- 「行得通」= ① 可以被測量 ② 對你關心的變數而言是合理的
- 把定義寫清楚、可重複——別人照著也能測出同一件事

提醒：操作型定義是「這份研究的測量約定」，不是「概念的唯一真理」——在方法章寫明你選了哪個、為什麼。

操作化實例：把「工作壓力」變成可測量

同一概念可有多種操作型定義——選一個可測且合理的即可


步驟	內容
概念定義	工作壓力 = 工作要求超過個人可負荷時的緊張感受
子構面	① 工作負荷 ② 時間壓力 ③ 情緒耗竭
操作型定義（選定）	以自陳量表測量：每構面 2-3 題、7 點量表
題項範例	「我常覺得工作量超過我能負荷。」（工作負荷）
替代做法	生理：唾液皮質醇；行為：加班時數——可交叉驗證

教學重點 別過度糾結『唯一真理』；把選定的定義寫清楚、可重複，並在方法章說明為何這樣測。

信效度四象限：靶心比喻


信度 = 集不集中；效度 = 有沒有打在靶心

信度高 · 效度高




彈著集中又在靶心

信度高 · 效度低




集中但系統性偏離 (如體重計每次都多3公斤)
分散但平均在靶心 (多測取平均可補救)

信度低 · 效度高



信度低 · 效度低



又散又偏

教學重點 信度是效度的必要非充分條件：不穩定的工具不可能有效；但很穩定也可能穩定地測錯東西。效度比信度更根本——『穩定地測錯』比隨機誤差更難發現，也更危險。註：兩種「效度」不同層次——靶心圖的「效度高」指無系統性偏誤（平均不偏），故「信度低·效度高」可以成立；心理計量意義的效度則會被低信度衰減（見衰減圖）。

信度的三種檢驗

再測信度

Test-retest

同一測量在不同時間點多次施測，結果是否一致。例：每次站上體重計都顯示同一數字。

內部一致性

Internal consistency

同一份工具的多個子題是否測到同一件事。例：數學題 1、3、4 得分一致。以 Cronbach's α 評估。

評分者間信度

Inter-observer

不同觀察者對同一對象是否得到相同結論。例：觀察者 1 與 2 都判定某人具攻擊性。

三種信度回答不同問題：跨時間、跨題項、跨觀察者是否一致。

提高信度的訣竅：多測幾次、取平均

核心訣竅：多次測量後取平均——隨機誤差會互相抵銷，測量結果更接近真值。

三種做法

- 多測幾次取平均：例如量體重量好幾次再平均，抵銷單次波動
- 多用幾個題項：問卷用數道題測同一構念，取平均（＝內部一致性）
- 改良工具與標準化程序：降低系統誤差，提升效度也連帶提高信度

信度三型實例：同一份「工作壓力量表」怎麼驗

信度類型	怎麼做	範例結果	可接受門檻
再測 Test-retest	同一群人隔 2 週再填一次，算兩次相關	$r = .85$	$r \geq .70$
內部一致性	算量表題項的 Cronbach's α	$\alpha = .88$	$\alpha \geq .70$
評分者間 Inter-rater	兩位主管各評同一批員工壓力行為	$\kappa = .82$	$\kappa \geq .60$ (佳 $\geq .80$)

教學重點 三型回答不同問題（跨時間 / 跨題項 / 跨評分者）；量表研究最常報告 Cronbach's α ，觀察法必報 inter-rater。

三種信度：各檢驗一種「一致」

跨時間 / 跨評分者 / 題目之間



重測信度 Test-retest：跨「時間」穩不穩



評分者間信度 Inter-rater：跨「評分者」一不一致 (κ)



內部一致性 Internal consistency：題目之間一不一致 (α)

教學重點 選哪一種取決於你的威脅：怕狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→ α 。

三個信度係數怎麼算？

接上頁： r （再測）、 α （內部一致）、 κ （評分者間）各自的算法

r · 再測信度

做法：同一群人隔一段

時間（如 2 週）再測一次。

算法：兩次分數的 Pearson

相關係數 r 。

直覺：兩次是否『同起同落』。

例：10 人重測， $r = .85$

α · 內部一致性

做法：一次施測，看各題

是否測同一件事。

算法： $\alpha = (k / (k - 1)) \times$
 $(1 - \Sigma \sigma^2_{\text{題}} \div \sigma^2_{\text{總}})$

直覺：題目越一致， α 越高。

例：5 題， $\alpha = .88$

κ · 評分者間

做法：兩位評分者評同

一批對象。

算法： $\kappa = (P_o - P_e) \div$
 $(1 - P_e)$

直覺：扣掉『運氣一致』

後的真實一致。例：見下方

教學重點 κ 為什麼要扣運氣：兩位主管各把 50 位員工分成『高壓力 / 否』。都判高 20、都判否 20 → 實際一致 $P_o = (20 + 20) / 50 = 0.80$ ； P_e 為「兩人各自判高的比例相乘 + 各自判否的比例相乘」（本例兩人皆 25/50 判高）→ $P_e = 0.5 \times 0.5 + 0.5 \times 0.5 = 0.50$ 。故 $\kappa = (0.80 - 0.50) / (1 - 0.50) = 0.60$ （Landis-Koch 屬「中等」.41-.60;.61-.80 佳、>.80 極佳）。

動手算：Cronbach's α 逐步計算

5 位受試者、3 題的迷你量表，一步步算到 α

受試者	題1	題2	題3	總分
P1	4	5	4	13
P2	2	3	2	7
P3	5	4	5	14
P4	3	3	4	10
P5	1	2	2	5
變異數 σ^2	2.00	1.04	1.44	11.76

步驟

- ① 每題的變異數： $\sigma^2_1=2.00$ 、 $\sigma^2_2=1.04$ 、 $\sigma^2_3=1.44$
- ② 加總題項變異數： $\Sigma\sigma^2_{\text{題}} = 4.48$
- ③ 總分的變異數： $\sigma^2_{\text{總}} = 11.76$
- ④ 代入公式($k=3$):
$$\alpha = (3/2)(1 - 4.48/11.76) = 0.93$$

教學重點 讀懂： $\alpha=0.93$ 遠高於 .70 $\rightarrow$ 這 3 題內部一致性很好，像在測同一個構念。直覺：題項彼此越相關， $\Sigma\sigma^2_{\text{題}}$ 相對 $\sigma^2_{\text{總}}$ 越小、(1-比值) 越大 $\rightarrow \alpha$ 越高。(此處用母體變異數/ n ；統計軟體多用樣本變異數，數值會略不同。)

為什麼信度會影響統計顯著性？

信度高

- 測量誤差低
- 統計檢定力 (power) 高
- 較易偵測顯著差異
- p 值較小

信度低

- 測量誤差大
- 效果被雜訊稀釋
- 檢定力下降
- p 值較大 (可能藏住真實關係)

顯著水準 α (如 0.05 ; 與 Cronbach's α 不同) 是事前設定的門檻，不因信度改變；但信度低時應增加樣本數或改良工具來補償。

信度 → 誤差 → 檢定力


信度低 → 效果被低估 → 檢定力下降

衰減 Attenuation 的連鎖後果

低信度的連鎖後果



衰減 Attenuation：信度越低，效果越被低估



教學重點 提高信度（多題、多次測量取平均）等於免費提升檢定力——比事後加樣本便宜得多。（圖示假設 X、Y 兩變項信度相同）

隨堂 60 秒：信度怎麼選、怎麼算

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 的「交班紀錄完整性是否達標」由兩位觀察員各自判定。要檢驗這項測量的一致性，該算哪一個係數？
- ② 為什麼這裡不能用 Pearson r ？請用一句話說明。
- ③ 若兩位觀察員的一致率 $P_o = 0.80$ 、運氣一致 $P_e = 0.50$ ， κ 是多少？屬於哪一級？

講評重點 選係數看的是「變數型態」與「威脅來源」，不是看手邊有什麼數字。

效度的全景：三大類、五種證據

效度類別	問的問題	常用指標	案例 Q 的做法
內容效度 Content	題目涵蓋構念的全部面向了嗎？	CVI (專家評定)	紀錄完整性評分表由長照專家審涵蓋面
效標關聯・同時	與同時測到的標準一致嗎？	與效標的相關	系統記錄的準備時間 vs 觀察員現場計時
效標關聯・預測	能預測未來的結果嗎？	與後續結果的相關	導入前認知負荷能否預測後續使用流失
構念效度・聚斂	與「應該相關」的變數相關嗎？	r、AVE	認知負荷 vs 二次確認詢問次數 → 應正相關
構念效度・區辨	與「不該相關」的變數不相關嗎？	r 接近 0	認知負荷 vs 年資 → 應接近 0

教學重點 效度不是單一數字，而是一組證據；同一份工具用在不同目的上，需要的效度證據不同。信度是效度的必要非充分條件——見 p.7 靶心圖。

效度的兩種：聚斂與區辨

聚斂效度 Convergent

測量與「應該相關」的變數確實相關。

- 例：體重計顯示數字，隨堆疊物品增加而增加 → 合理
- 體適能 vs 跑步速度 → 正相關 ✓

區辨效度 Discriminant

測量與「不該相關」的變數不相關。

- 例：體重計上的數字不應受「室溫」影響
- 體適能 vs 身高 → 接近 0、不顯著 ✓

好的測量：該相關的相關、不該相關的不相關——兩者一起看才完整。

效度實例：用相關矩陣看聚斂與區辨

新『工作壓力量表』——該相關的相關、不該相關的不相關

與哪個變數比	預期	觀察 r	判讀
職業倦怠	應正相關（聚斂）	.62	聚斂效度 ✓
睡眠品質	應負相關（聚斂）	-.48	聚斂效度 ✓
每週工時	弱正相關（合理）	.30	合理
身高	不該相關（區辨）	.04	區辨效度 ✓

教學重點 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算測到『壓力』而非別的東西。

聚斂與區辨：用相關矩陣看

同構念要高、跨構念要低

壓力1	1.00	0.72	0.68	-0.18	-0.12	-0.15
壓力2	0.72	1.00	0.75	-0.14	-0.16	-0.11
壓力3	0.68	0.75	1.00	-0.12	-0.10	-0.13
支持1	-0.18	-0.14	-0.12	1.00	0.70	0.74
支持2	-0.12	-0.16	-0.10	0.70	1.00	0.69
支持3	-0.15	-0.11	-0.13	0.74	0.69	1.00
壓力1	壓力2	壓力3	支持1	支持2	支持3	

怎麼讀這張相關矩陣

 綠框：同一構念的題目

應該「高」（此例 .68-.75）→ 聚斂效度成立

 橘框：不同構念之間

應該「低」（此例 -.10~-0.18）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事，要合併、重新定義，或改題。

教學重點 若跨構念相關也很高，代表兩個構念可能其實是同一件事——要合併、重新定義或改題。

四種測量方法總覽

自陳法 Self-report

直接問當事人（訪談、問卷、調查）——最常用，但可能有社會期許偏誤。

表現測量 Performance

以任務測能力（IQ、體能、反應時間）——難造假，但易受狀態干擾。

觀察行為 Observed behavior

觀察人們「實際怎麼做」（購買選擇、臉部表情）——外部效度高，但難設置。

生理測量 Physical

心率、皮膚電導（流汗）、荷爾蒙（皮質醇）、腦活動——難造假，但需設備、難解讀。

沒有最好的方法，只有「最適合這個研究情境」的方法。

自陳法 Self-report：開放式 vs 封閉式

開放式（偏質性）

- 不引導受訪者往任何方向回答
- 多用「你做了什麼？為什麼這樣做？」
- 避免「是不是因為 X？喜不喜歡 X？」這種誘導

封閉式（偏量化）

- 評定量表（5 = 非常同意...1 = 非常不同意）→ 數值變量
- 勾選題（性別：男 / 女 / 其他）→ 類別變量
- 易統計，但受選項侷限

留意：社會期許偏誤 敏感題（是否欺騙伴侶、智商多高）易得美化答案；測量潛在構念時，用「多個題項」較穩。

尺度層級 單題 Likert 為次序尺度，多題加總後方近似等距——見下一節「四種測量尺度」。

常見自陳偏誤與對策

問卷測得準不準，一半看題目怎麼寫

偏誤	症狀	對策
社會期許 Social desirability	敏感題給美化的答案	匿名作答、中立措辭、間接問法
默許傾向 Acquiescence	不管內容都傾向『同意』	加入反向題、平衡正反向題
集中趨勢 Central tendency	什麼都選中間值	調整量尺點數、必要時強制選擇
月暈效應 Halo	一個印象影響所有題	打散題序、清楚定義各構面

教學重點 測潛在構念時『用多個題項』最穩；反向題與注意力檢查題能同時抓默許與敷衍作答。

常見自陳偏誤・各舉一例

把上頁四種偏誤，放進真實情境看

偏誤	具體範例
社會期許	問護理師『你會不會對病人不耐煩？』→即使會，也答『從不』以維持良好形象。
默許傾向	受訪者每題都勾『同意』，連反向題也勾同意→前後矛盾露餡。
集中趨勢	每題都選『普通 / 中立』，避免表態→分數擠在中間、拉不開差異。
月暈效應	覺得某主管『人很好』，就把他所有領導面向都評高分。

教學重點 對策速記：社會期許→匿名 / 間接問法；默許→加反向題；集中趨勢→偶數點量尺或強制選擇；月暈→打散題序、清楚定義各面向。（問卷寫作詳見 4.3 問卷設計實務）

表現、行為、生理測量：優缺點對照

方法	例子	優點	缺點
表現 Performance	IQ、體能、反應時間	難造假	易受狀態干擾（如沒睡好）
觀察行為 Observed	購買選擇、臉部表情	外部效度高（看實際行為）	常較難設置
生理 Physical	心率、皮膚電導、皮質醇	難造假	需設備、有時難解讀

表現測量常需在「不受干擾、條件相似」下進行，結果才可比較。

如何選擇測量方法

- 永遠先想「信度」與「效度」——這兩把尺決定方法好壞
- 例①：自陳法若因社會期許而失真 → 改換問法，或用不同方法測量
- 例②：反應時間波動大 → 多測幾次、取平均
- 例③：心率可能反映興奮，也可能只是喝了咖啡 → 若各法都有問題，就用多種方法交叉比對

每種測量方法都可能是好選擇——取決於研究情境；若都不理想，考慮同時使用多種方法。

測量的類型：數值 vs 類別

數值變量 Numerical

- 有大小、可測差距（例：壓力分數、睡眠時數）
- 靈敏度高，能捕捉細微變化
- 可用相關係數評估信度

類別變量 Categorical

- 以類別區分（例：有無失眠、性別、國籍）
- 無大小之分，不適合用相關係數評估信度
- 信度改用一致性指標評估：Cohen's κ 或百分比一致度，不可用相關係數（例：兩位觀察員判定「交班紀錄完整性是否達標」，須先驗 κ ）

四種測量尺度：決定你能用哪些統計

尺度	可分類	可排序	間距相等				
名目 Nominal	✓	✗	✗				
次序 Ordinal	✓	✓	✗				
等距 Interval (準)	✓	✓	✓				
比率 Ratio	✓	✓	✓				

單題 *Likert* 嚴格說是次序尺度；多題加總後方視為近似等距，才能用平均數與 *t* 檢定。凡「零」代表「完全沒有」的量，才是比率尺度。

隨堂 60 秒：判斷測量尺度

先自己作答，再看解答 · 預估 1 分鐘

- ① 下列四個案例 Q 變數各屬哪一種測量尺度？ 職類 / 認知負荷單題 (1-7) / 認知負荷加總分 / 交班準備時間 (分)
- ② 其中哪些可以算平均數？哪些只能看眾數或中位數？
- ③ 「準備時間 20 分鐘是 10 分鐘的兩倍」這句話成立嗎？為什麼？

講評重點 尺度決定集中量數與檢定；判斷順序是「可分類 → 可排序 → 間距相等 → 有絕對零點」。

測不準怎麼辦？調整研究問題

- 有些概念難以直接、準確測量（例：犯罪行為、真實態度）
- 策略一：尋找可靠的替代指標 / 操作型定義
- 策略二：微調研究問題，使其可被測量
- 自陳式（self-report）測量要留意「社會期許偏誤」

例：直接問「你是否有犯罪行為」難以取得可靠答案 → 可改測「與犯罪相關的可觀察行為」或使用官方紀錄等替代指標。

問卷設計的具體做法

① 題項與概念對應

為每個構念 (construct) 建立清楚定義，據此設計題項。例：服務品質可依 SERVQUAL 五構面設計。

② 專家效度檢核

邀專家審查題項是否涵蓋構念內容範圍；以 CVI (內容效度指數) 評估重要性與相關性。

③ 預試與修正

小樣本預試，檢查題目是否模糊或誘導；以項目分析刪除區分度低的題項。

④ 建構效度檢驗

以探索性因素分析 (EFA) 或驗證性因素分析 (CFA) 確認題項結構符合理論預期。

本單元重點回顧

- 【目標①】先把抽象概念變成「操作型定義」——找到一個可測且合理的即可。
- 【目標③】【目標④】信度 = 穩定一致（再測、內部一致性、評分者間）；效度 = 內容 + 效標關聯（同時 / 預測） + 構念（聚斂 / 區辨）。
- 【目標③】多題項 / 多次測量取平均，是提高信度最實用的訣竅。
- 四種測量方法：自陳、表現、觀察行為、生理——各有優缺，依情境選、必要時併用。
- 【目標③】信度低會稀釋效果、降低檢定力、放大 p 值，可能藏住真實關係。
- 問卷設計四步：概念對應 → 專家效度 → 預試修正 → 建構效度。
- 【目標②】測量尺度（名目 / 次序 / 等距 / 比率）是 2.4 選圖、2.5 選檢定的共同判準。

下一站 2.3 資料蒐集：測量工具定下來了，接著決定跟誰收、收多少、怎麼避開偏誤。



延伸

量表發展與驗證

Scale Development & Validation

把前面的『信度・效度』升級成一套完整的量表製作流程：
從產生題項、內容效度，到 EFA 探索因素、CFA 驗證結構。

為什麼需要『量表發展』這一節？

好量表不是湊幾題問卷，而是一套可驗證的建構過程

隨便湊題目的下場

- 題目測到的不是你想測的概念（效度差）
 - 不同題目各測各的、內部不一致（信度差）
 - 幾個構面混在一起、分不開（維度不清）
 - 审稿人一句『量表未經驗證』就退稿
- 資料再多也是雜訊

這一節給你的能力

- 用系統流程把抽象概念變成可信量表
 - EFA：找出題目背後有幾個構面
 - CFA：驗證你的構面結構站不站得住
 - 用 AVE/CR、適配度指標客觀評估
- 依 COSMIN 報告，讓量表可被引用

重點 承接本單元：信度＝一致、效度＝測得準。量表發展就是把這兩件事『做出來並證明給別人看』的工程——特別在健康科技，你常要自製量表（如數位健康識能、App 使用者體驗），這套流程是研究可信度的根本。

與 4.3 的分工 題目怎麼寫、量尺怎麼設計、版面與前測，見 4.3 問卷設計實務；本節專講「寫完之後」的統計驗證：

EFA、CFA 與信效度指標。

量表發展的生命週期：六個階段

一條龍走完，才是一份『經驗證』的量表

- 1 **界定建構 + 維度** 講清楚概念定義與理論上有幾個構面(dimension)
- 2 **產生題項 Item pool** 依定義 + 文獻 + 專家，寫出比需要更多的候選題
- 3 **內容效度 CVI** 專家評每題相關性，算 I-CVI / S-CVI 篩題
- 4 **前測 + 項目分析** 小樣本試測，看題目鑑別度、刪爛題
- 5 **EFA 探索因素** 用一半樣本找出實際的構面結構
- 6 **CFA + 信效度 + 報告** 另一半樣本驗證，算 AVE/CR、依 COSMIN 報告

重點 關鍵紀律：EFA 與 CFA 要用『不同的樣本』（或把資料切兩半）。用同一批資料先探索再驗證，等於自己出題自己改考卷——結構一定過，但沒有意義。本節實例：自製『數位健康識能量表 DHLS』（次頁把這六個階段展開為八個關卡）

量表發展八關卡：一張圖看完

從概念界定到信效度總結



任何一關不過 → 回頭修題再走一次

⑥ EFA 與 ⑦ CFA 必須用「不同樣本」——用同一批資料先探索再驗證，等於自己驗證自己。

健康測量工具的品質報告可對照 COSMIN 標準。

教學重點 EFA 與 CFA 必須用「不同樣本」；用同一批資料先探索再驗證，等於自己驗證自己。

先修 · 因素分析在做什麼？（白話）

量表發展會用到的統計，先用白話 + 小例子建立直覺

核心直覺

- 因素分析 = 看『哪些題彼此高度相關，像在測同一件事』。
- 把這些題歸成一個『因素 / 構面』（例如：焦慮、工作壓力）。
- 例：5 題若彼此相關都很高
→ 可能都在測『工作壓力』這一個構面。

三個關鍵名詞

- 因素負荷 loading：一題與某因素的相關 ($-1 \sim 1$); > 0.5 = 這題『忠於』該因素。
- 特徵值 / 陡坡圖 / 平行分析：決定『抽幾個因素』的方法。
- KMO / Bartlett：資料『適不適合』做因素分析的體檢 (KMO > 0.6 才值得做)。

重點 一句話：EFA (探索性因素分析) 就是『讓資料告訴你——這一堆題背後其實有幾個構面、每題屬於哪一個』。把它想成『幫題目分組』；後面的 KMO、負荷、因素數，都是為了把這件事做得可靠。

先修・驗證與信效度指標（白話速查）

這些縮寫看起來嚇人，其實各回答一個簡單問題

名詞	白話：它在問什麼	好的門檻
CVI (內容效度)	專家覺得這題『切不切題』的比例	I-CVI $\geq$.78、S-CVI $\geq$.90
題總相關	這一題和量表總分有沒有關係	$\geq$.30
CFA 適配度(CFI/RMSEA...)	你畫的構面圖和真實資料合不合	CFI/TLI $\geq$.95;RMSEA/SRMR $\leq$.06/.08
AVE	一個構面的題目『共同解釋的變異』夠不夠	$\geq$.50
CR / Cronbach α / ω	內部一致性 (同構面的題夠不夠一致)	$\geq$.70

重點 看懂速查：每個指標都對應一個問句——切題嗎(CVI)、這題有用嗎 (題總相關)、結構對嗎(CFA)、構面實在嗎(AVE)、夠一致嗎(CR/ α / ω)。之後本節總覽表，就是把這些門檻收在一起。

產生題項 + 內容效度 CVI：先讓專家把關

題目對不對題，先問懂的人

產生題項的原則

- 一題一概念，避免雙重內涵(double-barreled)
- 語意清楚、避免引導與否定套否定
- 涵蓋建構的每個面向（內容代表性）
- 寧可多寫（如每構面 8–10 題），後面再刪
- 量尺一致（如 Likert 1–5）

內容效度指標 CVI

專家小組（常 5–10 人）逐題評『相關性』1–4 分

$I-CVI = \text{某題評 3–4 分的專家比例}$

建議 $I-CVI \geq 0.78$ 保留

$S-CVI/Ave = \text{全量表平均}$ ，建議 ≥ 0.90

→ 據此刪修題目，並記錄過程

重點 CVI 是『量化的專家共識』：它把『這題到底測不測得到概念』交給領域專家評分，而不是研究者自己說了算。健康量表尤其重要——臨床專家能抓出病人真正在意、你卻漏掉的面向。

動手算：內容效度 CVI 逐步計算

6 位專家評 4 題的相關性，算 I-CVI 與 S-CVI

題目	評 3–4 分的專家數(N=6)	I-CVI	判斷
Q1	6	1.00	保留
Q2	5	0.83	保留
Q3	6	1.00	保留
Q4	4	0.67	< 0.78 → 修/刪

重點 步驟：① I-CVI = 該題評『相關 (3–4 分)』的專家數 ÷ 總專家數(6)。② S-CVI/Ave = 各題 I-CVI 平均 = $(1.00 + 0.83 + 1.00 + 0.67) \div 4 = 0.875$ 。判讀：I-CVI 應 ≥ 0.78 (6 位以上專家) → Q4 只有 0.67，須修改或刪除；整體 0.875 略低於 0.90 → 修好 Q4 再重評即達標。

前測與項目分析：淘汰『沒有鑑別力』的題

好題目要能把高分群和低分群分開


檢查	看什麼	判準 (參考)
題總相關	該題與量表總分的相關	$r < 0.3 \rightarrow$ 考慮刪除
刪題後 α	刪掉這題，Cronbach α 會不會反而升高	升高 $\rightarrow$ 這題可能是雜訊
決斷值 CR	高分組 vs 低分組在該題差異 (t 檢定)	不顯著 $\rightarrow$ 鑑別力差
分佈/天花板	是否幾乎所有人都選同一格	嚴重偏斜 $\rightarrow$ 資訊量低

重點 直覺：一個好題目應該讓『概念高的人』和『概念低的人』答得不一樣。如果人人都答一樣、或它跟總分沒關係，這題就沒在測東西——先在前測用項目分析刪掉，別把爛題帶進 EFA。

EFA vs CFA：先探索、後驗證


一個讓資料說話，一個檢驗你的假設

EFA 探索性：不預設哪題屬哪因素



所有題目對所有因素都有負荷 → 由資料告訴你結構
用途：量表初期，還不確定有幾個構面

CFA 驗證性：事先指定結構再檢驗



事先規定 1-3 屬 F1、4-6 屬 F2 → 檢驗這個假設合不合
用途：用「新樣本」驗證 EFA 找到的結構

教學重點 EFA 用途在量表開發早期、發現構面，結果是因素數與負荷矩陣；CFA 用於已有理論結構、拿新樣本驗證。量表初期不確定幾個構面 → EFA；順序不能反。

EFA 步驟①：先確認資料『適不適合』做因素分析

題目之間要有足夠的相關，才值得抽因素

兩個把關指標

KMO 取樣適切性：0–1，越高越好

> 0.6 尚可、> 0.8 良好

Bartlett 球形檢定： $p < 0.05$ 才通過

(檢定相關矩陣是否 $\neq$ 單位矩陣)

樣本量：常建議每題 5–10 人、且 ≥ 200

為什麼要先做

若題目彼此幾乎不相關 → 抽不出共同因素

KMO 太低(<0.5) → 別硬做 EFA

Bartlett 不顯著 → 沒有結構可找

→ 先過這關，再談抽幾個因素

DHLS 實例：KMO=0.89、Bartlett $p < 0.001$ ✓

重點 直覺：因素分析是『從很多題的共同變異裡，萃取出背後的少數構面』。如果題目之間根本沒共同變異（低 KMO、Bartlett 不顯著），就沒有『共同的东西』可萃取——硬做只會得到一堆無意義的因素。

EFA 步驟②：到底該抽『幾個』因素？

這是 EFA 最關鍵、也最常做錯的一步

方法	規則	評價
特徵值 > 1 (Kaiser)	保留 eigenvalue > 1 的因素	最常見，但常『高估』因素數，別單用
陡坡圖 Scree plot	看曲線『手肘』轉折前的因素	主觀，需搭配其他方法
平行分析 Parallel	與隨機資料的特徵值比較	目前最推薦、較準確
可解釋性	抽出的因素能不能合理命名	理論與統計要並重

重點 別只信『特徵值>1』：這條 Kaiser 規則簡單但常抽出太多因素。實務上以『平行分析』為主、陡坡圖與可解釋性為輔，三者交叉判斷。因素數不是純統計題——最終要能對每個因素講出一個有意義的構面名字。

EFA 步驟③：轉軸與負荷量判讀

轉軸讓因素結構『看得懂』；負荷量告訴你題目歸誰

轉軸 Rotation

目的：讓每題盡量只在『一個』因素高載入

正交(Varimax)：假設因素間不相關

斜交(Promax/Oblimin)：允許因素相關

→ 社會/健康構面常相關，多用斜交

轉軸不改變適配，只改變『可讀性』

負荷量 Loading 判讀

負荷量 = 題目與因素的相關(-1~1)

一般保留 $|\text{loading}| \geq 0.40$ (嚴格 0.50)

交叉負荷 (兩因素都 $>0.3 \sim 0.4$) → 考慮刪

共同性 communality 太低(<0.2) → 該題弱

據此刪題、重跑，直到結構乾淨

重點 判讀口訣：好題目『只忠於一個因素』——在自己構面上高載入(>0.5)、在別的構面低載入(<0.3)。腳踏兩條船的交叉負荷題會讓構面糊在一起，通常刪掉。刪題是正常且必要的，記得記錄每次決定。

EFA 實例：數位健康識能量表 (DHLS)

24 題跑 EFA，浮現三個乾淨的構面

因素 (命名)	高載入題 (示例)	載入量範圍
F1 取得資訊 Access	我能找到可信的健康網站/App	0.72 – 0.84
F2 理解資訊 Understand	我看得懂檢驗報告與衛教內容	0.68 – 0.81
F3 應用決策 Apply	我能用查到的資訊做健康決定	0.70 – 0.79
(已刪) 交叉負荷題×3	同時載入 F1 與 F3	刪除

重點 解讀：24 題經 EFA (斜交轉軸) 後，浮現三個因素、共解釋約 62% 變異，各題乾淨載入到單一構面；刪掉 3 題交叉負荷題後剩 21 題。這三個構面 (取得 / 理解 / 應用) 符合健康識能理論——統計與理論對得上，才算好結構。

CFA：把 EFA 找到的結構，拿到新樣本『驗證』

從『資料告訴我』升級為『我假設，並檢定』

CFA 在做什麼

事先畫好模型：F1、F2、F3 各含哪些題
用『另一半樣本』檢定模型與資料的適配
每題只允許載入自己的構面（不像 EFA）
輸出：適配度指標 + 標準化負荷 + AVE/CR
模型不好 → 依理論修正（勿盲目改）

為什麼要換樣本

同一批資料先探索再驗證 = 作弊（必過）
CFA 需獨立樣本（或先切一半留給 CFA）
跨樣本仍站得住 → 結構才可信
健康量表常再做跨族群/跨語言恆等性
→ 這是可發表量表的基本要求

重點 EFA 與 CFA 的分工：EFA 像『田野探勘』畫出草圖，CFA 像『工程驗收』檢查這張圖在新地基上蓋不蓋得起來。只有草圖沒驗收，量表不算完成；用同一塊地既探勘又驗收，驗收一定過但毫無保證。

CFA 適配度指標：模型和資料合不合？

看一組指標，不要只看單一個

指標	門檻 (可接受 / 良好)	說明
χ^2/df	< 3 (嚴格 < 2)	卡方受樣本數影響，看比值
CFI / TLI	≥ 0.90 / ≥ 0.95	比較適配指標，越接近 1 越好
RMSEA	≤ 0.08 / ≤ 0.06	近似誤差，越小越好 (附 90% CI)
SRMR	≤ 0.08	標準化殘差均方根

重點 報告慣例(Hu & Bentler 1999)：至少報 CFI/TLI、RMSEA、SRMR 各一，並要同時達標，不要挑一個漂亮的講。DHLS 實例： $\chi^2/df=2.1$ 、CFI=0.96、TLI=0.95、RMSEA=0.05、SRMR=0.04 → 模型適配良好，三構面結構獲驗證。

收斂與區辨效度：用 AVE、CR、 $\sqrt{\text{AVE}}$ 客觀判斷

構面內要抱團、構面間要分得開

收斂效度 Convergent

同構面的題要『測到同一件事』

平均變異抽取 $\text{AVE} \geq 0.50$

組合信度 $\text{CR} \geq 0.70$

標準化因素負荷 ≥ 0.50 (佳 0.70)

→ DHLS：各構面 AVE 0.55–0.63 ✓

區辨效度 Discriminant

不同構面要『分得開』、不重疊

Fornell-Larcker： $\sqrt{\text{AVE}}$ > 與其他構面的相關

HTMT < 0.85 (嚴格 0.90)

→ 若兩構面相關過高，可能該合併

→ DHLS： $\sqrt{\text{AVE}}$ 均大於構面間相關 ✓

重點 兩個效度一起看：收斂 = 『同構面的題彼此夠像』 (AVE 夠高)；區辨 = 『不同構面夠不一樣』 ($\sqrt{\text{AVE}}$ 大於它與別人的相關)。前者確保構面『實』，後者確保構面『各自獨立』——健康量表若『理解』和『應用』分不開，就得考慮合併或重新界定。

動手算：AVE 與 CR 逐步計算

從 4 題的因素負荷，算收斂效度 AVE 與組合信度 CR

① 收斂效度 AVE

因素負荷 λ : .72、.81、.68、.77

$AVE = \Sigma \lambda^2 \div \text{題數}$

$\lambda^2 = .52、.66、.46、.59; \Sigma = 2.23$

$AVE = 2.23 \div 4 = 0.56 \quad (\geq .50 \checkmark)$

→ 構面平均能解釋各題 56% 的變異

② 組合信度 CR

$CR = (\Sigma \lambda)^2 \div [(\Sigma \lambda)^2 + \Sigma (1 - \lambda^2)]$

$\Sigma \lambda = 2.98 \rightarrow (\Sigma \lambda)^2 = 8.88$

$\Sigma (1 - \lambda^2) = 1.77$

$CR = 8.88 \div (8.88 + 1.77) = 0.83$

$(\geq .70 \checkmark)$

重點 讀懂：AVE=0.56 → 這個構面平均能解釋各題 56% 的變異（收斂效度足夠）；CR=0.83 是用因素負荷加權的信度，比 Cronbach α 更貼近 CFA。兩者都過門檻 → 這個構面『實在且一致』。（ $\sqrt{AVE}$ 再拿去和其他構面的相關比，即區辨效度。）

信度再進階： α 不是唯一，也不是萬能

Cronbach α 、組合信度 CR、McDonald ω

指標	特點	建議
Cronbach's α	最常見；假設各題貢獻相等(tau-equivalent)	≥ 0.70 ；題數多時會虛高
組合信度 CR	用因素負荷加權，較貼近 CFA	≥ 0.70 ；SEM/CFA 常報這個
McDonald's ω	放寬 α 的等價假設，較穩健	≥ 0.70 ；越來越被推薦

重點 別再只報 α ： α 假設每題同等貢獻，題數一多就會『看起來很高』而誤導。在 CFA/SEM 脈絡下，組合信度 CR 與 McDonald's ω 更貼近真實內部一致性。報告時可同時附上，讓審稿人安心。 α 高也不代表單一維度——維度要靠因素分析判斷。

COSMIN：健康測量工具的『品質共識標準』

做量表、選量表、評量表，都用得上

COSMIN 是什麼

健康測量工具的方法學共識標準

把測量性質分成三大類：

- 信度 (reliability、測量誤差)
- 效度 (內容、結構、效標、跨文化)
- 反應性 (responsiveness 偵測變化)

你能拿它做什麼

- 開發量表：對照它逐項確認做齊了
 - 選現成量表：系統性評比工具品質
 - 寫系統性回顧：評測量性質的證據
 - 投稿：用它證明你的驗證流程完整
- 健康科技自製量表的黃金對照表

重點 為什麼健康領域特別看重 COSMIN：臨床與健康科技常需自製或改編量表 (症狀、生活品質、數位識能)，COSMIN 提供一致的語言與標準，讓不同量表的品質可被公平比較——這也是量表能被引用、被納入指引的關鍵。

本節總覽：一頁看完量表怎麼『做出來又證明給人看』

把流程與判準速查表收在一起

階段	關鍵動作	判準速查
內容效度	專家評分	$I-CVI \geq 0.78$ 、 $S-CVI \geq 0.90$
項目分析	刪爛題	題總相關 ≥ 0.3
EFA	找構面	$KMO > 0.6$ 、負荷 ≥ 0.4 、平行分析定因素數
CFA	驗結構	$CFI/TLI \geq .95$ 、 $RMSEA/SRMR \leq .06/.08$
信效度	算指標	$AVE \geq .5$ 、 $CR/\omega \geq .7$ 、 $\sqrt{AVE} >$ 構面相關

重點 帶走一句話：量表發展 = 『把抽象概念，用可重現、可驗證的流程，變成一把量得準、分得開、別人也能信的尺』。EFA 找結構、CFA 驗結構、AVE/CR/ ω 給證據、COSMIN 定標準——這正是這一節加給你的能力。

小試身手：讀懂一份量表驗證結果

(參考答案見下一頁)

某團隊自製『長者用藥遵從 App 易用性量表』，報告如下，請判讀：

- Q1 EFA：KMO=0.55、Bartlett $p=0.21$ 。這份資料適合做因素分析嗎？為什麼？
- Q2 他們用『特徵值 >1 』抽出 5 個因素，但有 2 個因素各只有 1 題、且無法命名。你會怎麼建議？
- Q3 CFA 報告：CFI=0.91、RMSEA=0.11、SRMR=0.06。模型適配可接受嗎？哪個指標有問題？
- Q4 某構面 AVE=0.38、CR=0.82。收斂效度 OK 嗎？該怎麼解讀與處理？

重點 提示：Q1 想 KMO/Bartlett 門檻；Q2 想 Kaiser 高估因素數 + 可解釋性；Q3 想 RMSEA 超標；Q4 想 AVE <0.5 的判讀 (Fornell-Larcker 的但書)。

參考答案

判讀重點，實際作答請展開說明

題	參考要點
Q1	不適合。KMO=0.55 偏低(<0.6)、Bartlett $p=0.21$ 不顯著，代表題目間缺乏足夠共同相關，抽不出有意義的共同因素。應先檢討題目或增樣本，別硬跑 EFA。
Q2	『特徵值>1』常高估因素數。單題因素、無法命名 = 不可解釋。建議改用平行分析 + 陡坡圖重定因素數，刪除或合併那些單題/無法命名的因素，並兼顧理論可解釋性。
Q3	不理想。CFI=0.91 未達 .95；關鍵是 RMSEA=0.11 遠超 0.08，近似誤差過大、適配不佳。不能只挑 SRMR=0.06 好看的講，應依理論修正模型或重檢構面。
Q4	收斂效度不足：AVE=0.38<0.50，構面內題目共同解釋的變異偏低。雖 CR=0.82 高，仍應檢查並刪修低負荷題或重新界定構面（Fornell-Larcker：CR>0.6 時可勉強接受但需說明）。



作業

Take-home Assignment

Measure it right, or the design is wasted.

涵蓋單元 2：操作型定義、信度三型、效度（聚斂 / 區辨）、四種測量方法、問卷設計。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題檢驗你「測不測得準」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

針對一個構念，產出一份『可信又有效』的測量方案（操作型定義 + 量表 + 信效度規劃）。

繳交方式

一份 PDF：Part A 文字作答 + Part B 量表與信效度規劃，建議 3–5 頁。

建議時間

約 2–3 小時；先做 Part A 暖身，再進入 Part B 設計。

工具與誠信

可用 AI 協助發想與潤飾，但須附『AI 使用聲明』；引用需標註，禁止代寫與杜撰。

Part A | 觀念題：熟悉變數測量 (1/2)

- A1 用一句話區分信度與效度；為什麼說『效度比信度更根本』？用靶心比喻說明其中一種組合。
- A2 信度三種檢驗（再測 / 內部一致性 / 評分者間）各回答什麼問題？各舉一個檢驗情境。
- A3 什麼是操作型定義？同一概念可有多個，選擇的準則是什麼？
- A4 聚斂效度與區辨效度的差異為何？各需要什麼證據？

作答提示 觀念題重『說得清楚 + 舉得出例』；每題 2–4 句即可，不必長篇。

Part A | 觀念題：熟悉變數測量 (2/2)

- A5 四種測量方法 (自陳 / 表現 / 觀察 / 生理) 各寫一個優點與一個缺點；什麼情況該併用？
- A6 為什麼信度低會降低統計檢定力、放大 p 值？低信度時可以怎麼補償？
- A7 自陳法常見偏誤至少三種，並各寫出一個對策。
- A8 問卷設計四步驟是什麼？每步用一句話說明『產出什麼』。

Part B | 實作題：設計一份可信可效的測量（1/2）

指示：選一個構念（工作壓力 / 學習動機 / 服務品質，或你自己的變數），完成下列各題。

- B1** 寫出該構念的操作型定義；設計一份 5–8 題量表（附量尺），標明每題對應的子構面。
- B2** 規劃如何驗證信度：三型中至少兩型，寫出做法與可接受門檻。
- B3** 規劃如何驗證聚斂與區辨效度：列出『應相關』與『不該相關』的變數各至少一個，並預期相關方向 / 大小。

教學重點 量表題項必須對得回你的構念定義與子構面——這是內容效度的基礎。

Part B | 實作題：設計一份可信可效的測量 (2/2)

- B4** 指出你的測量可能的偏誤 (社會期許等) 與你的對策。
- B5** 說明你會用數值或類別測量、為什麼；若構念難測，你的替代指標或研究問題微調策略。
- B6** 附一段方法章『測量』小節 (150 字內) + AI 使用聲明。

繳交格式 Part B 建議用『量表題目表 + 信效度規劃表』呈現，一眼看得出每題測什麼、怎麼驗。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能用靶心 / 門檻說明
B1 操作化 + 量表	15%	操作型定義清楚、題項對應子構面、附量尺
B2 信度規劃	15%	至少兩型、做法具體、門檻正確
B3 效度規劃	15%	聚斂與區辨都有、預期方向合理
B4–B6 偏誤 + 方法 + 誠信	15%	偏誤與對策對應、方法段可重做、附 AI 聲明

常見扣分 信效度混用、只報 α 就當作『效度良好』、題項與子構面對不上、忘了反向題與匿名。

案例應用：把三個結果變數變成可以測量的東西

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

本單元教了什麼

操作型定義、測量尺度，以及信度與效度各自需要什麼證據。

②

案例怎麼用

- 主要結果定義為：自取得前一班紀錄至開始口頭交班之分鐘數。
- 以第三方觀察計時，兩位觀察者校準 30 次交班， $ICC = .91$ 。
- 紀錄完整性以 0 至 20 分評分表測量，兩位評分者獨立評分， $ICC = .84$ 。
- 認知負荷屬潛在構念，須自編量表並驗證（題目撰寫見 4.3，統計驗證見本單元量表發展節），不可用單題自陳。
- 四個變數之測量尺度不同，直接決定單元 2.5 可用之檢定方法。

③

產出什麼證據

變數操作型定義表（次頁），納入計畫書第 3.4 節「研究工具」。

④

承接關係

上游：承自 2.1 之研究設計決策表 | 下游：交棒 2.3，據此建立資料字典。

教學重點

操作型定義的檢驗標準只有一個：換一個人來測，會不會得到同一個數字。寫不到這個程度，就不是操作型定義，只是換句話說。

示範產物：變數操作型定義表

六個變數逐一交代定義、尺度、來源與品質證據；缺任一欄即為審查意見來源

變數	角色	操作型定義	尺度	資料來源與品質證據
交班準備時間	主要依變項	自取得前一班紀錄至開始口頭交班之分鐘數	比率	第三方觀察計時；觀察者間 ICC = .91
紀錄完整性	次要依變項	8 項必載事項之加總評分，每項 0 至 2.5 分	等距	兩位評分者獨立評分；評分者間 ICC = .84
二次確認詢問次數	次要依變項	交班結束後 30 分鐘內接班者回頭詢問之次數	比率	現場計數
自評認知負荷	解釋變項	自編 8 題量表加總，8 至 56 分	等距	Cronbach α = .87；重測 ICC = .78
導入與否	自變項	該次交班是否發生於該機構導入日之後	名目	系統上線紀錄
職類、年資	控制變項	護理師 / 資深照服員 / 單位主管；到職年數	名目 / 比率	人事資料

教學重點 「二次確認詢問次數」原本不在計畫中，是預試時觀察到才補上的——這一欄後來成了本研究最有價值的發現。測量計畫留一點餘裕，比全部鎖死更好。