量性研究方法 · 完整研究專案

單元 2

變數測量

Measuring Your Variables — Reliability & Validity

如果變數測不準，再好的設計也白費：操作型定義、信度三型、效度、四種測量方法與問卷設計實務

Reliability × Validity

有效測量的兩大支柱

信 信度 Reliability

＝ 穩定一致性

測量結果是否「穩定、一致、可重複」。同一對象量兩次應得到相近結果。

例：體重計每次都顯示 60.0 kg → 很穩定（信度高）

效 效度 Validity

＝ 測得對不對

測量是否「真正反映」要測的概念。準不準，比穩不穩更根本。

例：但真實體重是 57 kg → 穩定地多 3 kg （效度低）

Learning Objectives

本單元結束後，你能……

- 能為一個抽象概念寫出可操作、可測量的操作型定義。
- 能判別變數屬名目、次序、等距或比率尺度，並據以選擇統計方法。
- 能規劃信度驗證：從三型中選出適用者，並說明可接受門檻。
- 能規劃效度證據：說明內容、效標關聯與構念效度各需要什麼證據。
- 驗收方式　① 對應作業 A3、B1；② 對應 B5；③ 對應 A2、B2；④ 對應 A4、B3。

本單元怎麼走　先決定『測什麼』，再確認『測得穩、測得準』，最後才是『用什麼方法、什麼格式』



從變數到測量：操作型定義

承上 信度、效度是目標（第 2 張） → **本頁** 第一步：先把抽象概念變成可測的『操作型定義』

操作型定義 為了這個研究的目的，把抽象概念變成『可實際測量』的具體做法。

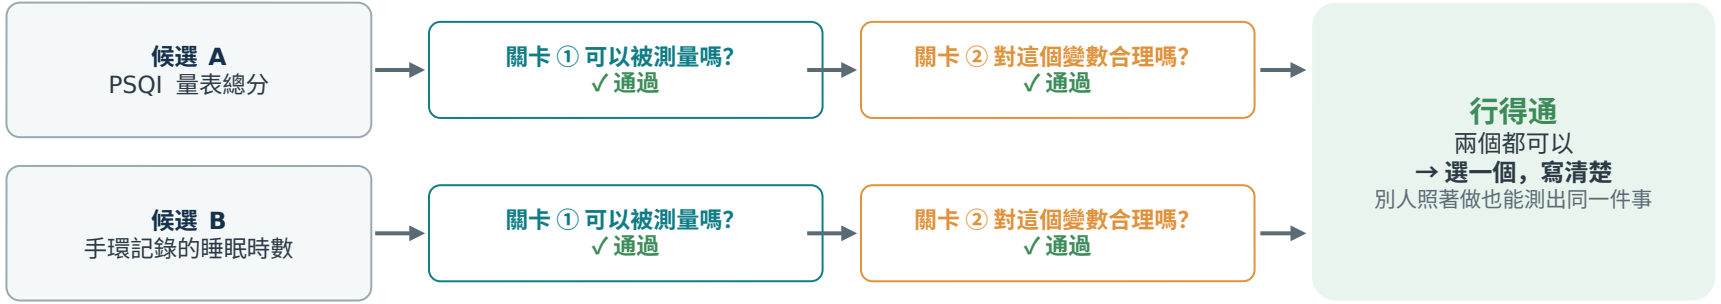
健康 Health	表現 Performance	公司規模	創業者
自評健康（1–5 分）	速度：每小時完成件數	營收	擁有事業（全職／兼職）
生理指標：血壓、腫瘤大小	品質：錯誤率	員工人數	每週投入 ≥ 30 小時經營
體能： 6 分鐘步行距離	兩者兼具：加權分數	顧客數	自我認定

同一個概念往往有多種操作型定義——選擇會直接影響你測到什麼。

操作型定義的原則：找到一個「行得通」的

承上 一個概念有很多種測法 → **本頁** 怎麼選？找到一個『行得通』的就好

例：『睡眠品質』要怎麼測？



提醒 操作型定義是『這份研究的測量約定』，不是『概念的唯一真理』。別在這一步過度糾結：找到一個行得通的，在方法章寫明選了哪個、為什麼。

操作化實例：把「工作壓力」變成可測量

承上 選定義的原則 → **本頁** 實例：把『工作壓力』一步步變成可測量

抽象

具體

概念定義 工作壓力＝工作要求超過個人可負荷時的緊張感受

子構面 ① 工作負荷 ② 時間壓力 ③ 情緒耗竭

操作型定義（選定） 自陳量表：每構面 2–3 題、7 點量表

題項範例 「我常覺得工作量超過我能負荷。」（工作負荷）

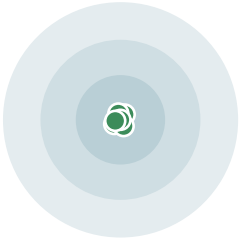
替代做法 生理：唾液皮質醇；行為：加班時數——可以和量表交叉驗證

教學重點 別過度糾結『唯一真理』；把選定的定義寫清楚、可重複，並在方法章說明為何這樣測。

信效度四象限：靶心比喻

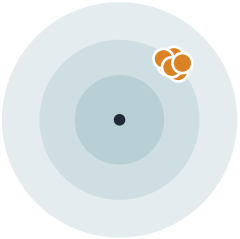
承上 測量方式定了 → **本頁** 接著問：測得穩不穩（信度）、準不準（效度）——用靶心看四種組合

信度高．效度高



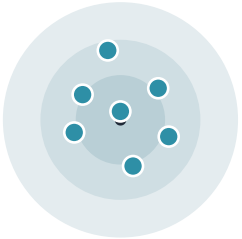
彈著集中又在靶心

信度高．效度低



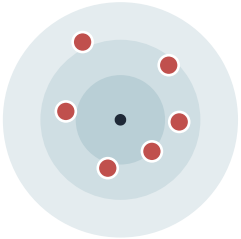
集中但系統性偏離（如體重計每次都多 3 公斤）

信度低．效度高



分散但平均在靶心（多測取平均可補救）

信度低．效度低



又散又偏

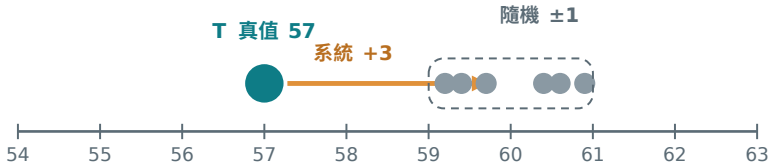
教學重點 信度是效度的必要非充分條件：不穩定的工具不可能有效；但很穩定也可能穩定地測錯東西。效度比信度更根本——『穩定地測錯』比隨機誤差更難發現，也更危險。註：兩種「效度」不同層次——靶心圖的「效度高」指無系統性偏誤（平均不偏），故「信度低．效度高」可以成立；心理計量意義的效度則會被低信度衰減（見衰減圖）。

測量誤差從哪來：觀察分數＝真分數＋誤差

承上 靶心：穩不穩、準不準 → **本頁** 兩種誤差各傷哪一個：隨機傷信度、系統傷效度

X 觀察分數 = T 真分數 + E 系統 + E 隨機

例：真實體重 57 kg，秤沒歸零（每次多 3 kg），每次站法不同（±1 kg）



隨機誤差 → 傷信度
忽上忽下、平均會抵銷；多測幾次取平均就能壓低（第 10 張）

系統誤差 → 傷效度
每次往同一邊偏，取平均也消不掉；要靠校正與好的設計

信度的定義：真分數變異 ÷ 觀察分數變異，例 80 ÷ 100 = .80—— 觀察到的差異有 80% 是真的、 20% 是雜訊（示意）

誤差的四個來源

來源	例子	多半造成	對策
受測者	疲倦、情緒、想給好印象	隨機＋系統	固定時段、匿名
工具	題意模糊、秤沒校正	隨機＋系統	預試、定期校正
施測情境	吵雜、趕時間、訪員語氣	隨機	標準化程序與指導語
評分者	標準不一、月暈效應	系統	評分訓練、算 κ／ICC

驗信度＝量『隨機』那一塊；驗效度＝找『系統』那一塊（第 19 張起）

教學重點 信度在問『隨機誤差占多少』，效度在問『有沒有系統性偏掉』；先想清楚誤差從哪來，才知道該驗哪一種信度、該怎麼改工具。

Three Types of Reliability

信度的三種檢驗

承上 信度＝穩不穩 → **本頁** 信度有三種檢驗：跨時間、跨題項、跨觀察者

再測信度

Test-retest

同一測量在不同時間點多次施測，結果是否一致。例：每次站上體重計都顯示同一數字。

內部一致性

Internal consistency

同一份工具的多個子題是否測到同一件事。例：數學題 1、3、4 得分一致。以 Cronbach's α 評估。

評分者間信度

Inter-observer

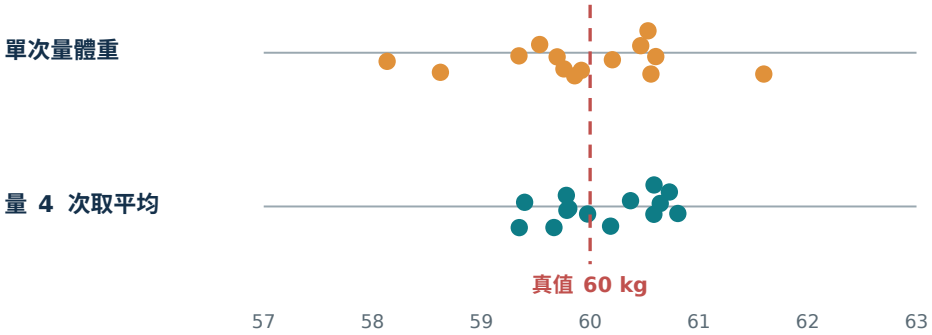
不同觀察者對同一對象是否得到相同結論。例：觀察者 1 與 2 都判定某人具攻擊性。

三種信度回答不同問題：跨時間、跨題項、跨觀察者是否一致。

提高信度的訣竅：多測幾次、取平均

承上 知道怎麼檢驗 → **本頁** 怎麼提高信度：多測幾次、多用幾題、取平均

核心訣竅 多次測量後取平均：隨機誤差會互相抵銷，結果更接近真值。



誤差約 ±1 kg → 取 4 次平均約 ±0.5 kg（÷√4，原理見 2.5）；點為示意

三種做法

多測幾次 量體重量好幾次再平均，抵銷單次波動
多用幾題 問卷用數道題測同一構念再平均（用 α 評估）
改良工具 標準化施測程序：減少隨機波動（信度↑），也減少系統性偏差（效度↑）

信度三型實例：同一份「工作壓力量表」怎麼驗

承上 三種信度的概念 → **本頁** 同一份量表，三種信度實際怎麼驗、門檻多少

信度類型	怎麼做	範例結果	可接受門檻
再測 Test-retest	同一群人隔 2 週再填一次，算 ICC 或 r	ICC = .85	ICC ≥ .70
內部一致性	算量表題項的 Cronbach's α	α = .88	α ≥ .70
評分者間 Inter-rater	兩位主管各評同一批員工壓力行為	κ = .82	κ > .60 （>.80 幾近完美）

κ 算法示例（另一例：兩位督導各判 100 份交班紀錄）

	B 判達標	B 判未達標	A 小計
A 判達標	**40 一致**	10	50
A 判未達標	10	**40 一致**	50
B 小計	50	50	100

再測信度 ICC
MS 受試者間 13.33
MS 誤差 1.08
(13.33−1.08)÷(13.33+1.08)
= 12.25÷14.41 ≈ .85

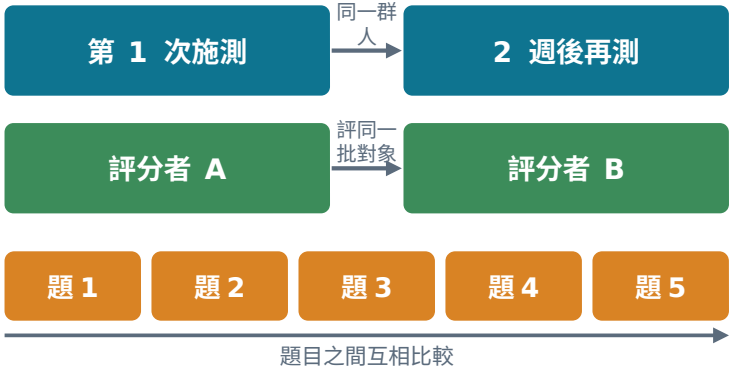
內部一致性 α
k = 10 題；題目變異和 3.8
總分變異 18
10/9 × (1 − 3.8/18)
= 1.11 × .789 ≈ .88

評分者間 Cohen's κ
Po = (40+40)÷100 = .80
Pe = .5×.5 + .5×.5 = .50
(.80−.50)÷(1−.50)
= .30÷.50 = .60

教學重點 三型回答不同問題（跨時間／跨題項／跨評分者）；量表研究最常報告 Cronbach's α，觀察法必報 inter-rater。

三種信度：各檢驗一種「一致」

承上 三種信度的數字 → **本頁** 用圖再看一次：各自檢驗哪一種『一致』



重測信度 Test-retest：跨「時間」穩不穩

評分者間信度 Inter-rater：跨「評分者」一不一致（κ）

內部一致性 Internal consistency：題目之間一不一致（α）

教學重點 選哪一種取決於你的威脅：怕狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→ α 。

三個信度係數怎麼算?

承上 三種係數的名字 → **本頁** r、α、κ 各自怎麼算、直覺是什麼

r · 再測信度

做法：同一群人隔一段時間（如 2 週）再測一次。

算法：兩次分數的 Pearson 相關係數 r。

直覺：兩次是否『同起同落』。

例： 10 人重測， r = .85

進階： r 看不出「第二次全體都偏高」， ICC 會扣分，故改報 ICC。

α · 內部一致性

做法：一次施測，看各題是否測同一件事。

算法： $\alpha = (k/(k-1)) \times (1 - \Sigma\sigma^2 \text{題} \div \sigma^2 \text{總})$

直覺：題目越一致， α 越高。

例： 5 題， α = .88

κ · 評分者間

做法：兩位評分者評同一批對象。

算法： $\kappa = (Po - Pe) \div (1 - Pe)$

直覺：扣掉『運氣一致』後的真實一致。例：見下方

教學重點 κ 為什麼要扣運氣：兩位主管各把 50 位員工分成『高壓力／否』。都判高 20、都判否 20 → 實際一致 Po=(20+20)/50=0.80； Pe 為「兩人各自判高的比例相乘＋各自判否的比例相乘」（本例兩人皆 25/50 判高）→ Pe=0.5×0.5+0.5×0.5=0.50。故 κ=(0.80−0.50)/(1−0.50)=0.60 （Landis–Koch： .41–.60 中等，未達 > .60 門檻； .61–.80 高度、 >.80 幾近完美）。

動手算： Cronbach's α 逐步計算

承上 α 的公式 → **本頁** 動手算一次： 5 人 × 3 題，算到 α

受試者	題 1	題 2	題 3	總分
P1	4	5	4	13
P2	2	3	2	7
P3	5	4	5	14
P4	3	3	4	10
P5	1	2	2	5
變異數 σ^2	2.00	1.04	1.44	11.76

步驟

① 每題的變異數： $\sigma^2_1=2.00$ 、 $\sigma^2_2=1.04$ 、 $\sigma^2_3=1.44$

② 加總題項變異數： $\Sigma\sigma^2$ 題 $= 4.48$

③ 總分的變異數： σ^2 總 $= 11.76$

④ 代入公式 (k=3):

$\alpha = (3/2)(1 - 4.48/11.76) = 0.93$

教學重點 讀懂： α=0.93 遠高於 .70 → 這 3 題內部一致性很好，像在測同一個構念。直覺：題項彼此越相關， $\Sigma\sigma^2$ 題 相對 σ^2 總 越小、（1− 比值）越大 → α 越高。（此處變異數除以 n；軟體除以 n−1 時各變異數同比例放大、比值不變， α 仍為 0.93 。）

ICC 怎麼選、怎麼讀：四個問題決定模型

承上 α 會算了；再測與評分者間常用 ICC → **本頁** ICC 有好幾種，回答四個問題就選得出來

Q1 每個對象都由『同一組』評分者（或時間點）測量嗎?
否 → 單向 ICC(1)　　是 → 看 Q2

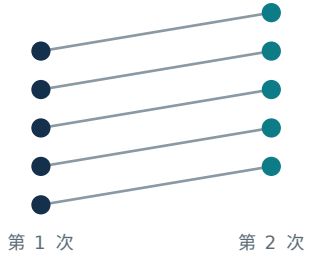
Q2 評分者是隨機抽來、想推論到其他評分者嗎?
是 → 雙向隨機 ICC(2)　　只在乎這幾位 → 雙向混合 ICC(3)

Q3 要分數本身『一樣』，還是排序『一致』就好?
再測、評分者間多要『絕對一致』；只比排序用『一致性』

Q4 實際使用時，是單次測量還是幾次取平均?
單次 → 單一測量（,1） 取平均 → 平均測量（,k）

常用答案： 再測信度 → ICC(2,1)、絕對一致（2.2A 再測即此）

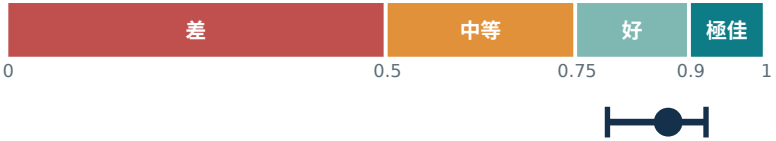
為什麼不用 r？ 5 人再測、第二次全部多 1 分



Pearson r	1.00
ICC 一致性	1.00
ICC 絕對一致	.83

整體偏高只有絕對一致抓得到

怎麼讀（Koo & Li, 2016；以 95% CI 判斷）



2.2A 再測 ICC = .87 ［.79, .92］→ 落在『好』到『極佳』

教學重點 報 ICC 一定寫清楚模型（單向／雙向隨機／雙向混合）、類型（絕對一致／一致性）與單一或平均，例如『ICC(2,1)、絕對一致，95% CI』；只寫『ICC = .85』別人無從判斷。

為什麼信度會影響統計顯著性?

承上 會算信度了 → **本頁** 為什麼要在乎：信度會影響你的 p 值

信度高

- 測量誤差低
- 統計檢定力（power）高
- 較易偵測顯著差異
- p 值較小
- 例：真實相關 .40、兩量表信度 .9 → 看到約 .36

信度低

- 測量誤差大
- 效果被雜訊稀釋
- 檢定力下降
- p 值較大（可能藏住真實關係）
- 例：同樣真實相關 .40、信度只有 .6 → 只看到約 .24（下一張）

顯著水準 α（如 0.05；與 Cronbach's α 不同）是事前設定的門檻，不因信度改變；但信度低時應增加樣本數或改良工具來補償。

信度低 → 效果被低估 → 檢定力下降

承上 信度低 → p 變大 → **本頁** 用圖看『衰減』：信度越低，看到的效果越小

低信度的連鎖後果

信度低

↓

測量誤差大

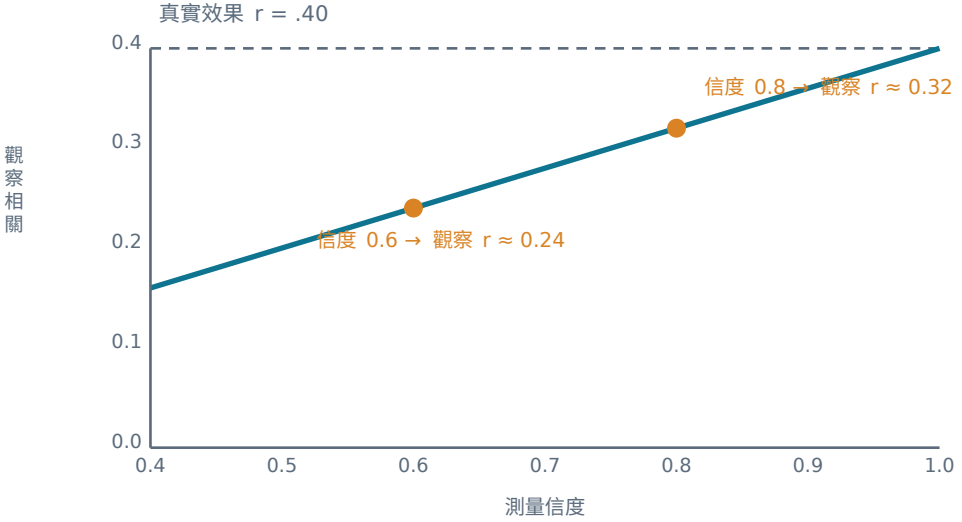
↓

觀察到的效果被稀釋

↓

檢定力下降．需更大樣本

衰減 Attenuation：信度越低，效果越被低估



教學重點 提高信度（多題、多次測量取平均）等於免費提升檢定力——比事後加樣本便宜得多。（圖示假設 X 、 Y 兩變項信度相同）

隨堂 60 秒：信度怎麼選、怎麼算

先自己作答，再看解答 · 預估 1 分鐘

① 案例 Q 的「交班紀錄完整性是否達標」由兩位觀察員各自判定。要檢驗這項測量的一致性，該算哪一個係數?

② 為什麼這裡不能用 Pearson r？請用一句話說明。

③ 若兩位觀察員的一致率 Po = 0.80、運氣一致 Pe = 0.50，κ 是多少？屬於哪一級?

參考解答

① Cohen's κ：兩位觀察員判定二元／類別結果，要看的是評分者間一致性

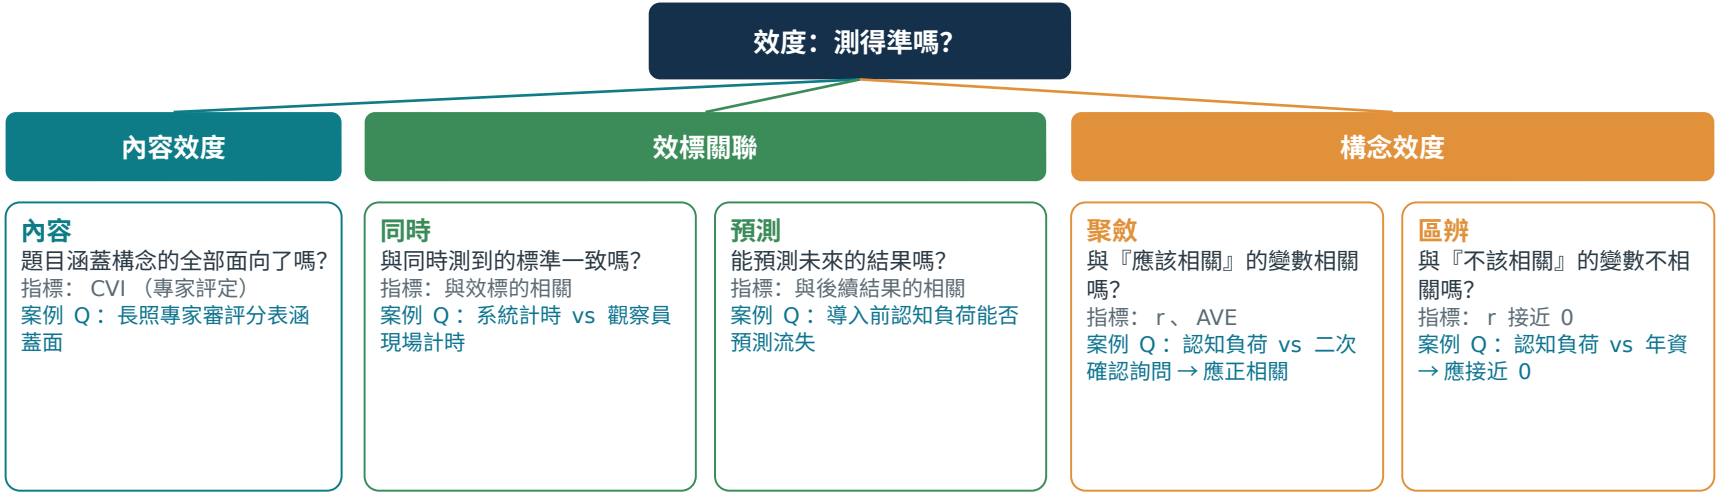
② 「是否達標」是類別（名義）變數；Pearson r 只適用連續（等距／等比）變數

③ κ = (Po−Pe)÷(1−Pe) = (0.80−0.50)÷(1−0.50) = 0.30÷0.50 = **0.60** → 中等一致（Landis–Koch .41–.60）

講評重點　選係數看的是「變數型態」與「威脅來源」，不是看手邊有什麼數字。

效度的全景：三大類、五種常見檢驗

承上 信度講完（穩不穩） → **本頁** 換效度（準不準）：三大類、五種檢驗的全景

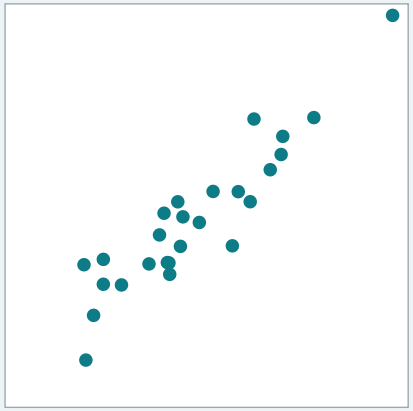


教學重點 效度不是單一數字，而是一組證據；同一份工具用在不同目的上，需要的效度證據不同（AERA／APA／NCME《Standards》（2014）以「效度證據來源」統稱）。信度是效度的必要非充分條件——見第 7 張靶心圖。

效度的兩種：聚斂與區辨

承上 效度全景 → **本頁** 最常用的構念效度：聚斂與區辨，用體適能舉例

聚斂效度 Convergent



與『應該相關』的變數確實相關

例：體適能 vs 跑步速度 → 正相關

r ≈ .6–.8 ✓

散布點為示意

區辨效度 Discriminant



與『不該相關』的變數不相關

例：體適能 vs 身高 → 接近 0

r ≈ 0 ✓

散布點為示意

好的測量：該相關的相關、不該相關的不相關——兩者一起看才完整。

效度實例：用相關矩陣看聚斂與區辨

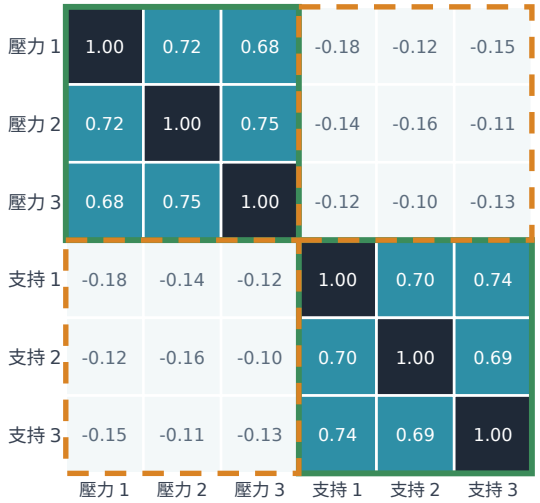
承上 聚斂與區辨的概念 → **本頁** 實例：新工作壓力量表與四個變數的相關

與哪個變數比	預期	觀察 r	判讀
職業倦怠	應正相關（聚斂）	.62	聚斂效度✓
睡眠品質	應負相關（聚斂）	−.48	聚斂效度✓
每週工時	弱正相關（合理）	.30	合理
身高	不該相關（區辨）	.04	區辨效度✓

教學重點 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算測到『壓力』而非別的東西。

聚斂與區辨：用相關矩陣看

承上 看了四個相關 → **本頁** 換成相關矩陣：同構念要高、跨構念要低



怎麼讀這張相關矩陣

綠框：同一構念的題目

應該「高」（此例 .68–.75）→ 聚斂效度成立

橘框：不同構念之間

應該「低」（此例 –.10~–.18）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事，要合併、重新定義，或改題。

相關係數矩陣（Correlation Matrix）來檢驗問卷或量表的「聚斂效度（Convergent Validity）」與「區辨效度（Discriminant Validity）
核心原則為：**「同構念要高、跨構念要低」**

具體問卷題目設計
構念 A：工作壓力（測量個人感受到的工作負荷與緊繃感）
壓力 1：「我經常覺得交辦的工作量過大，難以在時間內完成。」
壓力 2：「面對繁重的工作任務，我常感到焦慮或緊繃。」
壓力 3：「下班回到家後，我常常覺得身心俱疲、無法好好放鬆。」

構念 B：主管 / 同事支持（測量在職場能獲得的人際資源與實質幫助）
支持 1：「當我在工作上遇到難題時，主管會提供具體指引與協助。」
支持 2：「同事之間會互相補位、分擔突發的工作負荷。」
支持 3：「在單位裡，我能感受到團隊成員的關心與心理支持。」

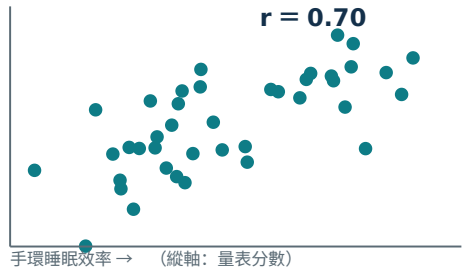
教學重點 跨構念相關若逼近同構念相關，先回頭看題目問法是不是太像——改題比事後在討論章辯解容易得多。

效標關聯與已知族群：另外三種效度證據

承上 聚斂與區辨看相關矩陣 → **本頁** 再補三種常用做法：同時、預測、已知族群

① 同時效度

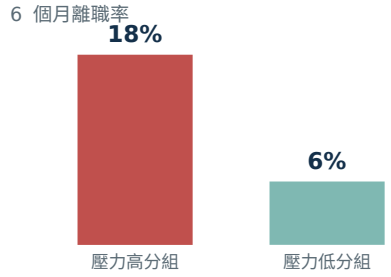
新的 3 題睡眠量表 vs 同一週手環測的睡眠效率



效標＝當下公認較準的測量

② 預測效度

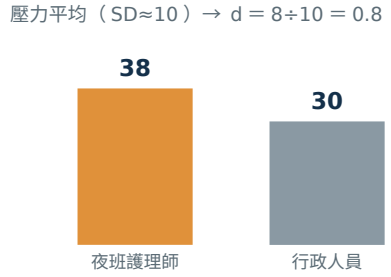
到職時的壓力分數，能否預測 6 個月內離職



效標＝未來才發生的結果

③ 已知族群效度

理論上壓力該較高的夜班護理師 vs 行政人員



比兩群平均差多少（效應量）

先問效標準不準：效標本身有誤差，相關就會被低估

效標是二分類（有無疾病）時：看敏感度、特異度與 ROC （9.2）

三個例子的數字皆為示意（散布點為模擬，r 由這些點算出）。

教學重點 效度證據越多元越可信：聚斂／區辨看『跟誰相關』，效標關聯看『跟標準對不對得上』，已知族群看『該分得開的人分不分得開』——預期都要在收資料前寫好。

四種測量方法總覽

承上 工具要信、要效 → **本頁** 接著選『用什麼方法測』：四種測量方法總覽

自陳法 Self-report

直接問當事人（訪談、問卷、調查）——最常用，但可能有社會期許偏誤。

例： PSS 知覺壓力量表

表現測量 Performance

以任務測能力（IQ、體能、反應時間）——難造假，但易受狀態干擾。

例： 6 分鐘步行距離

觀察行為 Observed behavior

觀察人們「實際怎麼做」（購買選擇、臉部表情）——外部效度高，但難設置。

例：觀察員計時交班時間（案例 Q）

生理測量 Physical

心率、皮膚電導（流汗）、荷爾蒙（皮質醇）、腦活動——難造假，但需設備、難解讀。

例：穿戴裝置測心率

沒有最好的方法，只有「最適合這個研究情境」的方法。

自陳法 Self-report：開放式 vs 封閉式

承上 最常用的是自陳法 → **本頁** 自陳法的兩種題型：開放式 vs 封閉式

開放式（偏質性）	封閉式（偏量化）
「最近工作上，什麼事最讓你覺得有壓力？為什麼？」	「我常覺得工作量超過我能負荷。」 1 非常不同意～5 非常同意
↓	↓
文字 → 編碼成主題（3.1）	**數字 → 統計（評定量表＝數值；勾選題＝類別）**
優 不引導、能發現沒想到的答案 **缺** 難統計、費時	**優** 易統計、可比較 **缺** 受選項侷限

避免誘導 ✗「是不是因為主管太嚴格？」→✓「你覺得壓力從哪裡來？」；敏感題易有社會期許偏誤，潛在構念用多個題項較穩。

常見自陳偏誤與對策

承上 封閉式題目易統計 → **本頁** 但自陳有四種常見偏誤，各有對策

偏誤	症狀	對策
社會期許 Social desirability	敏感題給美化的答案	匿名作答、中立措辭、間接問法
默許傾向 Acquiescence	不管內容都傾向『同意』	加入反向題、平衡正反向題
集中趨勢 Central tendency	什麼都選中間值	調整量尺點數、必要時強制選擇
月暈效應 Halo	一個印象影響所有題	打散題序、清楚定義各構面

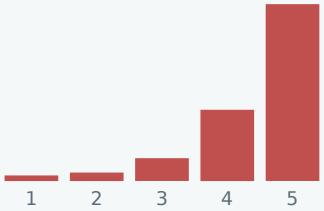
教學重點 測潛在構念時『用多個題項』最穩；反向題與注意力檢查題能同時抓默許與敷衍作答。

Response Biases · Examples

常見自陳偏誤 · 各舉一例

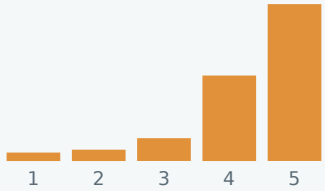
承上 四種偏誤與對策 → **本頁** 放進真實情境，各舉一例

社會期許



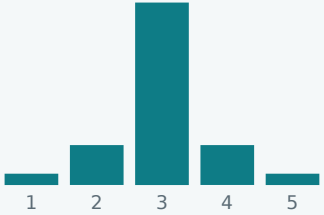
敏感題答得太漂亮：問『會不會對病人不耐煩？』→ 多答『從不』

默許傾向



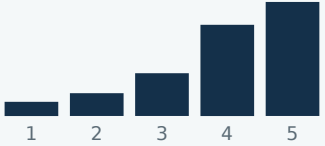
不看內容都勾同意，連反向題也同意 → 前後矛盾

集中趨勢



什麼都選『普通』→ 分數擠在中間、拉不開差異

月暈效應



覺得主管『人很好』，所有面向都評高分

教學重點 對策速記：社會期許 → 匿名／間接問法；默許 → 加反向題；集中趨勢 → 偶數點量尺或強制選擇；月暈 → 打散題序、清楚定義各面向。（問卷寫作詳見 4.3 問卷設計實務）

表現、行為、生理測量：優缺點對照

承上 自陳法的優缺點 → **本頁** 另外三種方法：表現、行為、生理，優缺點對照

表現 Performance	觀察行為 Observed	生理 Physical
例 IQ、體能、反應時間	**例** 購買選擇、臉部表情	**例** 心率、皮膚電導、皮質醇
✓ **優點** 難造假	✓ **優點** 外部效度高（看實際行為）	✓ **優點** 難造假
✗ **缺點** 易受狀態干擾（如沒睡好）	✗ **缺點** 常較難設置	✗ **缺點** 需設備、有時難解讀

表現測量常需在「不受干擾、條件相似」下進行，結果才可比較；自陳法的優缺見第 24–27 張。

如何選擇測量方法

承上 四種方法各有優缺 → **本頁** 怎麼選：回到信度與效度兩把尺

永遠先問兩把尺：這個方法『穩不穩』（信度）、『準不準』（效度）？

自陳法	**擔心** 擔心社會期許而失真	**對策** 改換問法，或換另一種方法
反應時間	**擔心** 每次波動很大	**對策** 多測幾次、取平均
心率	**擔心** 可能是興奮，也可能只是喝了咖啡	**對策** 控制情境，或併用其他方法

每種方法都可能是好選擇，取決於研究情境；若都不理想，就同時用多種方法交叉比對

測量的類型：數值 vs 類別

承上 方法選好了 → **本頁** 測出來是數值還是類別？這決定信度指標與統計

數值變量 Numerical



- 有大小、可測差距（壓力分數、睡眠時數）
- 靈敏度高，能捕捉細微變化
- **信度： ICC 或相關係數**

類別變量 Categorical

無失眠	輕度	中度	重度

- 以類別區分（有無失眠、性別、國籍）
- 名目無大小；次序（輕／中／重）有先後、無等距 → 可用加權 κ
- **信度： Cohen's κ 或百分比一致度，不可用相關係數**

例：兩位觀察員判定『交班紀錄是否達標』→ 先驗 κ

四種測量尺度：決定你能用哪些統計

承上 數值 vs 類別 → **本頁** 再細分成四種尺度：決定能不能算平均、能用哪些檢定

名目
可分類

案例 Q
職類、機構（A／B）、班別
集中量數 眾數
典型檢定 卡方

次序
＋可排序

案例 Q
認知負荷量表單題（1–7）
集中量數 中位數
典型檢定 無母數（Wilcoxon）

等距（準）
＋間距相等

案例 Q
認知負荷加總分（19–48）、完整性分數
集中量數 平均數、SD
典型檢定 t 檢定、ANOVA

比率
＋絕對零點

案例 Q
準備時間（2.0–36.4 分）、詢問次數、住民數
集中量數 平均數
典型檢定 t 檢定、相關、迴歸

越往右，能做的計算越多；判斷順序：可分類 → 可排序 → 間距相等 → 有絕對零點。單題 Likert 是次序，多題加總後才近似等距。

隨堂 60 秒：判斷測量尺度

先自己作答，再看解答 · 預估 1 分鐘

① 下列四個案例 Q 變數各屬哪一種測量尺度？ 職類／認知負荷單題（1–7）／認知負荷加總分／交班準備時間（分）

② 其中哪些可以算平均數？哪些只能看眾數或中位數？

③ 「準備時間 20 分鐘是 10 分鐘的兩倍」這句話成立嗎？為什麼？

參考解答（先自己想，再對照）

① 職類＝名目；認知負荷單題＝次序；認知負荷加總分＝等距（近似）；準備時間＝比率。
② 可算平均：加總分、準備時間。單題看中位數（或眾數）；職類只能看眾數。
③ 成立。時間有絕對零點（0 分鐘＝完全沒花時間），比率尺度才能說『兩倍』；溫度 20°C 就不是 10°C 的兩倍。

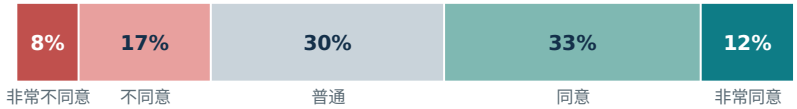
講評重點 尺度決定集中量數與檢定；判斷順序是「可分類 → 可排序 → 間距相等 → 有絕對零點」。

Likert 量表可以算平均嗎？單題 vs 加總

承上 尺度決定能算什麼 → **本頁** 最常見的爭議：Likert 題目是次序還是等距

單一題（Likert item）＝次序

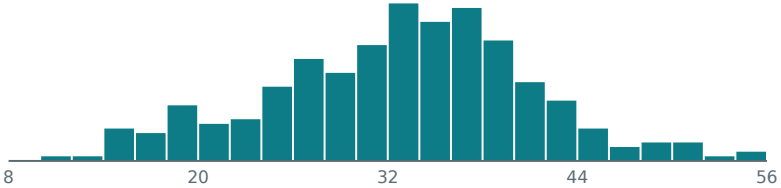
「我常覺得工作量超過我能負荷」各選項百分比



- 1→2 的距離不一定等於 4→5
- 報各選項百分比、中位數；圖用堆疊長條
- 比較組別用無母數（如 Mann–Whitney）

多題加總（Likert scale）≈ 等距

8 題、每題 1–7 分加總（8–56 分）的分佈



- 分數多、近連續 → 可報平均 ±SD、用 t／ANOVA （Norman, 2010）
- 前提：先確認這幾題測同一構念（α、因素分析）

加總當等距的四條件

≥ 4–5 題測同一構念	每題 ≥ 5 點、每點有文字	加總分佈不極端偏斜	結論用無母數再驗一次

案例 Q： load_1–load_8 單題＝次序， load_total （8–56）當等距使用，方法章須交代理由（2.3 第 46 張）。百分比與分佈為示意。

教學重點 單題是次序、多題加總近等距；不必選邊站，但方法章要寫清楚你怎麼處理、為什麼，並用圖呈現單題的作答分佈。

測不準怎麼辦？調整研究問題

承上 尺度與方法都有了 → **本頁** 如果概念就是測不準？換指標，或調整研究問題

難直接測的概念
犯罪行為
真實態度
是否按時吃藥

策略一：找可靠的替代指標
改測可觀察的行為或紀錄
例：按時吃藥：自陳常被高估 → 改用藥盒開啟紀錄或回診剩藥計數

策略二：微調研究問題
把問題改成測得到的版本
例：「你是否有犯罪行為」→ 改測『與犯罪相關的可觀察行為』或官方紀錄

留意 自陳式測量容易有社會期許偏誤；能用客觀紀錄就用，或兩者交叉比對。

問卷設計的具體做法

承上 前面所有原則 → **本頁** 串成問卷設計的四個具體步驟

① 題項與概念對應

為每個構念（construct）建立清楚定義，據此設計題項。例：服務品質可依 SERVQUAL 五構面設計。

② 專家效度檢核

邀專家審查題項是否涵蓋構念內容範圍；以 CVI（內容效度指數）評估各題與構念的相關性。

③ 預試與修正

小樣本預試，檢查題目是否模糊或誘導；以項目分析刪除區分度低的題項。

④ 構念效度檢驗

以探索性因素分析（EFA）或驗證性因素分析（CFA）確認題項結構符合理論預期。

用現成量表：找、評、授權、翻譯、重驗

承上 自編問卷的四個步驟 → **本頁** 多數研究其實用現成量表：五步把關

① 找

PubMed／華藝、 COSMIN 資料庫、 PROMIS；優先找已有中文版的

② 評

族群、情境、構面對得上嗎？原始信效度證據夠嗎（COSMIN，第 57 張）

③ 授權

寫信取得使用與翻譯同意；部分量表收費；未經同意不改題

④ 翻譯調適

沒有中文版時，照下方 Beaton 五階段

⑤ 重驗

在你的樣本至少報 α／ω、 CFA 結構；必要時再測

④ 翻譯與跨文化調適： Beaton 等（2000）五階段

1. **兩位獨立前譯** — 一位懂概念、一位不懂，各翻一版
2. **綜合成一版** — 兩位譯者對照討論，記錄分歧
3. **兩位回譯** — 不知原文的人翻回英文，比對原意
4. **專家委員會** — 審語意、慣用語、經驗、概念四種等值
5. **前測 30-40 人** — 邊答邊說（認知訪談），再修字

✗ **常見錯誤：** 自己翻一翻就用；改了題目卻沿用原作者的信效度；刪題不交代；網路上抓來的版本沒問授權

健康量表可查 COSMIN 資料庫與 PROMIS；量表授權條件以原作者或發行單位公告為準。

教學重點 現成量表不是拿來就用：要確認適合你的族群、取得授權、依標準流程翻譯，並在你的樣本重新驗證；改過題目，就不能沿用原作者的信效度數字。

SUMMARY · Measurement

本單元重點回顧

- **【目標①】先把抽象概念變成「操作型定義」——找到一個可測且合理的即可。**
- 【目標③】【目標④】信度＝穩定一致（再測、內部一致性、評分者間）；效度＝內容＋效標關聯（同時／預測）＋構念（聚斂／區辨）。
- 【目標③】多題項／多次測量取平均，是提高信度最實用的訣竅。
- 四種測量方法：自陳、表現、觀察行為、生理——各有優缺，依情境選、必要時併用。
- 【目標③】信度低會稀釋效果、降低檢定力、放大 p 值，可能藏住真實關係。
- 問卷設計四步：概念對應 → 專家效度 → 預試修正 → 構念效度。
- 【目標②】測量尺度（名目／次序／等距／比率）是 2.4 選圖、2.5 選檢定的共同判準。
- 【目標③】觀察分數＝真分數＋系統誤差＋隨機誤差；報 ICC 要寫清楚模型、類型與單一／平均。
- Likert 單題是次序、多題加總近等距；用現成量表要授權、依標準流程翻譯，並在你的樣本重驗。

下一站　2.3 資料蒐集：測量工具定下來了，接著決定跟誰收、收多少、怎麼避開偏誤。

S

延伸

量表發展與驗證

Scale Development & Validation

把前面的『信度・效度』升級成一套完整的量表製作流程：
從產生題項、內容效度，到 EFA 探索因素、 CFA 驗證結構。

為什麼需要『量表發展』這一節?

承上 前半講信度、效度的觀念 → **本頁** 延伸：為什麼要學一整套『量表發展』流程

隨便湊題目的下場

- 題目測到的不是你想測的概念（效度差）
- 不同題目各測各的、內部不一致（信度差）
- 幾個構面混在一起、分不開（維度不清）
- 審稿人一句『量表未經驗證』就退稿

→ 資料再多也是雜訊

這一節給你的能力

- 用系統流程把抽象概念變成可信量表
- EFA：找出題目背後有幾個構面
- CFA：驗證你的構面結構站不站得住
- 用 AVE/CR、適配度指標客觀評估

→ 依 COSMIN 報告，讓量表可被引用

重點 量表發展＝把「信度＝一致、效度＝測得準」做出來並證明給別人看的工程；健康科技尤其常需自製量表。

與 4.3 的分工 題目怎麼寫、量尺怎麼設計見 4.3 問卷設計實務；本節專講「寫完之後」的統計驗證。

量表發展的生命週期：六個階段

承上 知道為什麼要做 → **本頁** 全流程六個階段，一條龍走完

1. **界定建構＋維度** 講清楚概念定義與理論上有幾個構面 (dimension)
2. **產生題項 Item pool** 依定義＋文獻＋專家，寫出比需要更多的候選題
3. **內容效度 CVI** 專家評每題相關性，算 I-CVI / S-CVI 篩題
4. **前測＋項目分析** 小樣本試測，看題目鑑別度、刪爛題
5. **EFA 探索因素** 用一半樣本找出實際的構面結構
6. **CFA ＋信效度＋報告** 另一半樣本驗證，算 AVE/CR 、依 COSMIN 報告

重點 關鍵紀律： EFA 與 CFA 要用『不同的樣本』（或把資料切兩半）。用同一批資料先探索再驗證，等於自己出題自己改考卷——結構一定過，但沒有意義。本節實例：自製『數位健康識能量表 DHLS 』（教學用虛構數據）。（次頁把這六個階段展開為八個關卡）

量表發展八關卡：一張圖看完

承上 六個階段 → **本頁** 細拆成八個關卡；任何一關不過就回頭



任何一關不過 → 回頭修題再走一次

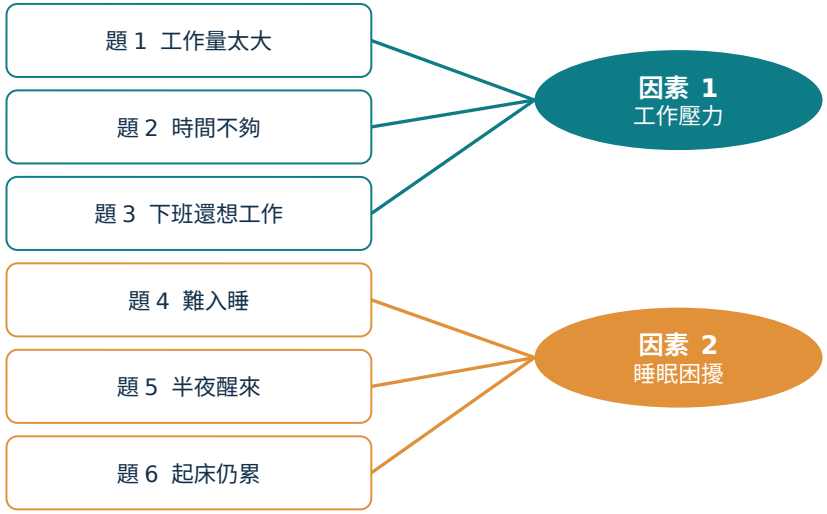
⑥ EFA 與 ⑦ CFA 必須用「不同樣本」——用同一批資料先探索再驗證，等於自己驗證自己。

健康測量工具的品質報告可對照 COSMIN 標準。

教學重點 切樣本前先確認兩半的年資與職類分佈相近；否則 CFA 不通過可能只是抽樣造成，不是結構有問題。

先修 · 因素分析在做什麼？（白話）

承上 關卡⑥⑦要用因素分析 → **本頁** 先修：因素分析在做什麼（白話）



彼此高度相關的題，歸成同一個因素（示意）

三個關鍵名詞（白話）

因素負荷 一題和某因素的相關（−1～1）；＞.5 表示這題『忠於』該因素

抽幾個因素 看特徵值、陡坡圖、平行分析（第 49 張）

KMO／Bartlett 資料『適不適合』做因素分析的體檢（第 48 張）

一句話：EFA 就是『讓資料告訴你，這堆題背後有幾個構面、每題屬於哪一個』

重點 一句話：EFA（探索性因素分析）就是『讓資料告訴你——這一堆題背後其實有幾個構面、每題屬於哪一個』。把它想成『幫題目分組』；後面的 KMO、負荷、因素數，都是為了把這件事做得可靠。

先修 · 驗證與信效度指標（白話速查）

承上 因素分析的直覺 → **本頁** 先修：後面會出現的指標縮寫，各回答一個問題

名詞	白話：它在問什麼	好的門檻
CVI （內容效度）	專家覺得這題『切不切題』的比例	I-CVI ≥ .78 、 S-CVI ≥ .90
題總相關	這一題和量表總分有沒有關係	≥ .30
CFA 適配度 (CFI/RMSEA…)	你畫的構面圖和真實資料合不合	CFI/TLI ≥ .95 ； RMSEA/SRMR ≤ .06/.08
AVE	一個構面的題目『共同解釋的變異』夠不夠	≥ .50
CR ／ Cronbach α ／ ω	內部一致性（同構面的題夠不夠一致）	≥ .70

重點 看懂速查：每個指標都對應一個問句——切題嗎 (CVI) 、這題有用嗎（題總相關）、結構對嗎 (CFA) 、構面實在嗎 (AVE) 、夠一致嗎 (CR/α/ω) 。之後本節總覽表，就是把這些門檻收在一起。

產生題項＋內容效度 CVI：先讓專家把關

承上 先修完畢 → **本頁** 關卡②③：寫題項的原則＋用專家評分算內容效度 CVI

產生題項的原則

- 一題一概念，避免雙重內涵 (double-barreled)
- 語意清楚、避免引導與否定套否定
- 涵蓋建構的每個面向（內容代表性）
- 寧可多寫（如每構面 8–10 題），後面再刪
- 量尺一致（如 Likert 1–5）

內容效度指標 CVI

專家小組（常 5–10 人）逐題評『相關性』1–4 分

I-CVI ＝某題評 3–4 分的專家比例

建議 I-CVI ≥ 0.78 保留（6 位以上專家；3–5 位須 1.00）

S-CVI/Ave ＝全量表平均，建議 ≥ 0.90

→ 據此刪修題目，並記錄過程

重點 CVI 是『量化的專家共識』：它把『這題到底測不測得到概念』交給領域專家評分，而不是研究者自己說了算。健康量表尤其重要——臨床專家能抓出病人真正在意、你卻漏掉的面向。

動手算：內容效度 CVI 逐步計算

承上 CVI 的規則 → **本頁** 動手算：6 位專家評 4 題，算 I-CVI 與 S-CVI

題目	評 3–4 分的專家數 (N=6)	I-CVI	判斷
Q1	6	1.00	保留
Q2	5	0.83	保留
Q3	6	1.00	保留
Q4	4	0.67	< 0.78 → 修 / 刪

重點 步驟：① I-CVI = 該題評『相關（3–4 分）』的專家數 ÷ 總專家數 (6)。② S-CVI/Ave = 各題 I-CVI 平均 =(1.00+0.83+1.00+0.67)÷4 = 0.875。判讀：I-CVI 應 ≥ 0.78（6 位以上專家）→ Q4 只有 0.67，須修改或刪除；整體 0.875 略低於 0.90 → 修好 Q4 再重評即達標。

前測與項目分析：淘汰『沒有鑑別力』的題

承上 專家把關過 → **本頁** 關卡④⑤：前測＋項目分析，刪掉沒有鑑別力的題

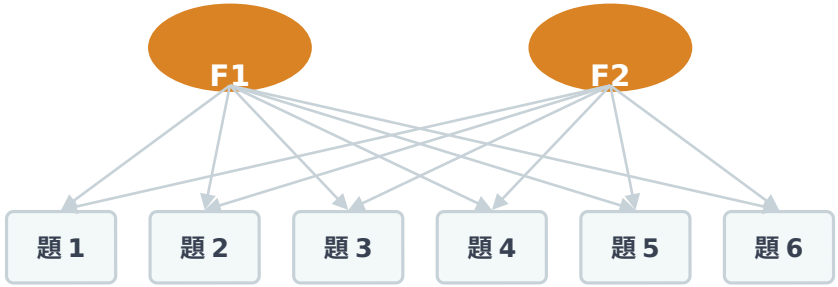
檢查	看什麼	判準（參考）
題總相關	該題與量表總分的相關	r < 0.3 → 考慮刪除
刪題後 α	刪掉這題， Cronbach α 會不會反而升高	升高 → 這題可能是雜訊
決斷值 critical ratio	高分組 vs 低分組在該題差異（t 檢定）	不顯著 → 鑑別力差
分佈 / 天花板	是否幾乎所有人都選同一格	嚴重偏斜 → 資訊量低

重點 直覺：一個好題目應該讓『概念高的人』和『概念低的人』答得不一樣。如果人人都答一樣、或它跟總分沒關係，這題就沒在測東西——先在前測用項目分析刪掉，別把爛題帶進 EFA 。

EFA vs CFA： 先探索、後驗證

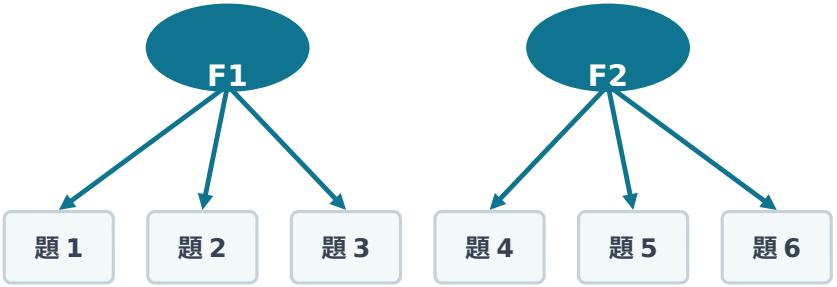
承上 題目刪乾淨了 → **本頁** 關卡⑥⑦的分工： EFA 先探索、 CFA 後驗證

EFA 探索性：不預設哪題屬哪因素



所有題目對所有因素都有負荷 → 由資料告訴你結構
用途：量表初期，還不確定有幾個構面

CFA 驗證性：事先指定結構再檢驗



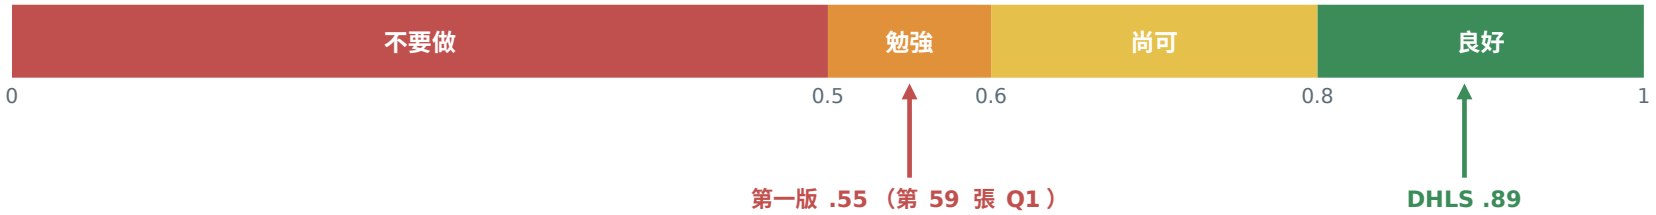
事先規定 1–3 屬 F1 、 4–6 屬 F2 → 檢驗這個假設合不合
用途：用「新樣本」驗證 EFA 找到的結構

教學重點 EFA 用途在量表開發早期、發現構面，結果是因素數與負荷矩陣； CFA 用於已有理論結構、拿新樣本驗證。量表初期不確定幾個構面 → EFA ； 順序不能反。

EFA 步驟①：先確認資料『適不適合』做因素分析

承上 要跑 EFA 了 → **本頁** EFA 第一步：資料適不適合做因素分析（KMO、Bartlett）

KMO 取樣適切性：0–1，越高越適合



Bartlett 球形檢定

$p < .05$ 才通過：題目間有共同相關可萃取
不顯著 → 沒有結構可找，別硬做

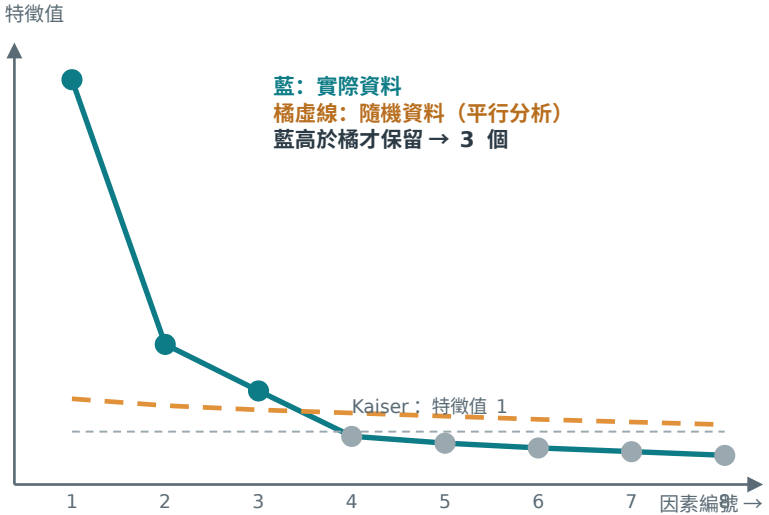
樣本量

常建議每題 5–10 人、且 ≥ 200
第一版 45 人跑 26 題（每題不到 2 人）→ KMO 才會偏低

重點 直覺：因素分析是『從很多題的共同變異裡，萃取出背後的少數構面』。如果題目之間根本沒共同變異（低 KMO、Bartlett 不顯著），就沒有『共同的東西』可萃取——硬做只會得到一堆無意義的因素。

EFA 步驟②：到底該抽『幾個』因素?

承上 資料適合 → **本頁** EFA 第二步：該抽幾個因素



前 4 個特徵值取自附錄第 91 張；第 5 個起為示意

方法	規則	評價
特徵值 > 1	保留 > 1 的因素	常高估，別單用
陡坡圖	看『手肘』前	主觀，需搭配
平行分析	高於隨機資料才留	目前最推薦
可解釋性	每個因素能命名	理論與統計並重

重點 別只信『特徵值 >1』：這條 Kaiser 規則簡單但常抽出太多因素。實務上以『平行分析』為主、陡坡圖與可解釋性為輔，三者交叉判斷。因素數不是純統計題——最終要能對每個因素講出一個有意義的構面名字。

EFA 步驟③：轉軸與負荷量判讀

承上 因素數決定了 → **本頁** EFA 第三步：轉軸，讀負荷量決定每題歸誰

轉軸前：糊在一起

	因素 1	因素 2
題 1	0.62	0.45
題 2	0.58	0.50
題 3	0.66	0.41
題 4	0.55	-0.48
題 5	0.60	-0.44
題 6	0.52	-0.50

轉軸後：一題一個因素

	因素 1	因素 2
題 1	0.78	0.08
題 2	0.75	0.12
題 3	0.79	0.05
題 4	0.06	0.74
題 5	0.10	0.76
題 6	0.04	0.71

深綠 ≥ .60、淺綠 .40–.59、粉紅 .30–.39（交叉負荷警訊）；數值為示意。轉軸不改變適配，只改變『好不好讀』

怎麼判讀

轉軸 正交（Varimax）假設因素不相關；斜交（Promax／Oblimin）允許相關 → 健康構面常相關，多用斜交

保留 主負荷 ≥ .40（嚴格 .50）

刪題 兩因素都 > .30–.40（交叉負荷），或共同性 < .20

流程 一次刪一題、重跑，直到結構乾淨

重點 判讀口訣：好題目『只忠於一個因素』——在自己構面上高載入 (>0.5)、在別的構面低載入 (<0.3)。腳踏兩條船的交叉負荷題會讓構面糊在一起，通常刪掉。刪題是正常且必要的，記得記錄每次決定。

EFA 實例：數位健康識能量表（DHLS）

承上 EFA 三步驟 → **本頁** 實例：DHLS 24 題跑出三個構面

因素（命名）	高載入題（示例）	載入量範圍
F1 取得資訊 Access	我能找到可信的健康網站 /App	0.72 – 0.84
F2 理解資訊 Understand	我看得懂檢驗報告與衛教內容	0.68 – 0.81
F3 應用決策 Apply	我能用查到的資訊做健康決定	0.70 – 0.79
（已刪）交叉負荷題 ×3	同時載入 F1 與 F3	刪除

重點 解讀：24 題經 EFA（斜交轉軸）後，浮現三個因素、共解釋約 62% 變異，各題乾淨載入到單一構面；刪掉 3 題交叉負荷題後剩 21 題。這三個構面（取得／理解／應用）符合健康識能理論——統計與理論對得上，才算好結構。

CFA：把 EFA 找到的結構，拿到新樣本『驗證』

承上 EFA 找到三構面 → **本頁** 關卡⑦：拿新樣本用 CFA 驗證這個結構

CFA 在做什麼

事先畫好模型： F1 、 F2 、 F3 各含哪些題
用『另一半樣本』檢定模型與資料的適配
每題只允許載入自己的構面（不像 EFA ）
輸出：適配度指標＋標準化負荷＋ AVE/CR
模型不好 → 依理論修正（勿盲目改）

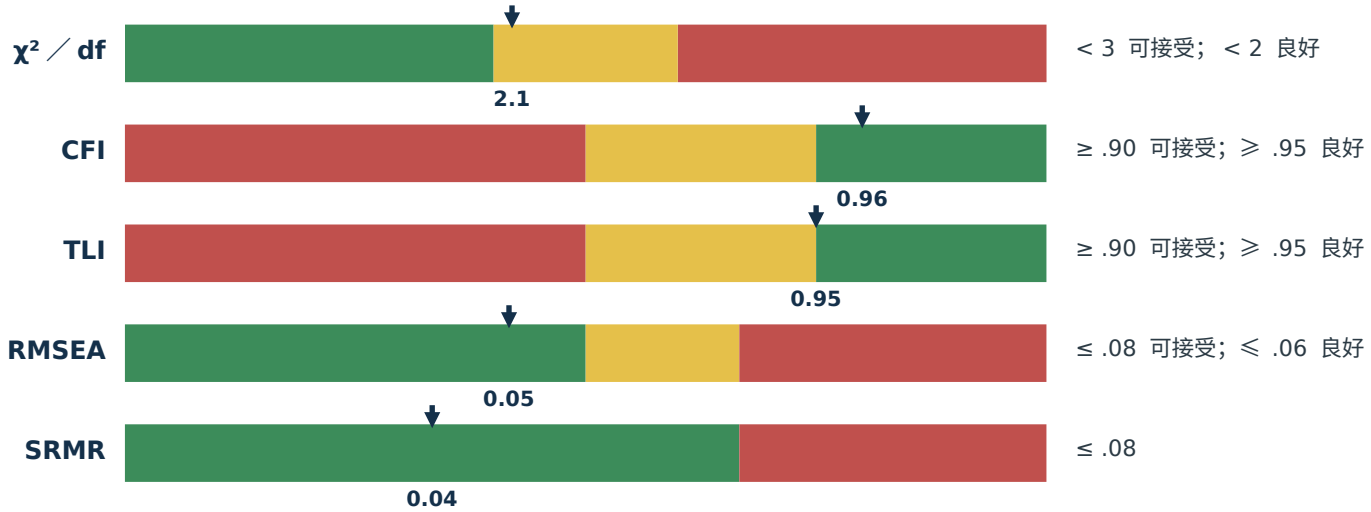
為什麼要換樣本

同一批資料先探索再驗證＝作弊（必過）
CFA 需獨立樣本（或先切一半留給 CFA ）
跨樣本仍站得住 → 結構才可信
健康量表常再做跨族群 / 跨語言恆等性
→ 這是可發表量表的基本要求

重點 EFA 與 CFA 的分工： EFA 像『田野探勘』畫出草圖， CFA 像『工程驗收』檢查這張圖在新地基上蓋不蓋得起來。只有草圖沒驗收，量表不算完成；用同一塊地既探勘又驗收，驗收一定過但毫無保證。

CFA 適配度指標：模型和資料合不合？

承上 CFA 跑完 → **本頁** 看一組適配度指標：模型和資料合不合



綠＝良好、黃＝可接受、紅＝不佳；箭頭為 DHLS 實例： χ²/df 2.1 、 CFI .96 、 TLI .95 、 RMSEA .05 、 SRMR .04 → 適配良好

重點 報告慣例： CFI/TLI 、 RMSEA 、 SRMR 都要報、一起判讀（Hu & Bentler, 1999），別只挑漂亮的講。 DHLS 實例： χ²/df=2.1 、 CFI=0.96 、 TLI=0.95 、 RMSEA=0.05 、 SRMR=0.04 → 模型適配良好，三構面結構獲驗證。

收斂與區辨效度：用 AVE、CR、√AVE 客觀判斷

承上 結構通過 → **本頁** 關卡⑧：構面內要抱團（收斂）、構面間要分開（區辨）

收斂效度 Convergent

同構面的題要『測到同一件事』

平均變異抽取 AVE ≥ 0.50

組合信度 CR ≥ 0.70

標準化因素負荷 ≥ 0.50 （佳 0.70）

→ DHLS：各構面 AVE 0.55–0.63 ✓

區辨效度 Discriminant

不同構面要『分得開』、不重疊

Fornell-Larcker：√AVE > 與其他構面的相關

HTMT < 0.85 （寬鬆 0.90）

→ 若兩構面相關過高，可能該合併

→ DHLS：√AVE 均大於構面間相關 ✓

重點 兩個效度一起看：收斂＝『同構面的題彼此夠像』（AVE 夠高）；區辨＝『不同構面夠不一樣』（√AVE 大於它與別人的相關）。前者確保構面『實』，後者確保構面『各自獨立』——健康量表若『理解』和『應用』分不開，就得考慮合併或重新界定。

動手算： AVE 與 CR 逐步計算

承上 AVE、CR 的門檻 → **本頁** 動手算： 4 題負荷算 AVE 與 CR

① 收斂效度 AVE

因素負荷 λ： .72、.81、.68、.77

AVE = Σλ² ÷ 題數

λ² = .52、.66、.46、.59； Σ = 2.23

AVE = 2.23 ÷ 4 = 0.56 (≥ .50 ✓)

→ 構面平均能解釋各題 56% 的變異

② 組合信度 CR

CR =(Σλ)² ÷ [(Σλ)² + Σ(1−λ²)]

Σλ = 2.98 →(Σλ)² = 8.88

Σ(1−λ²) = 1.77

CR = 8.88 ÷(8.88 + 1.77) = 0.83

(≥ .70 ✓)

重點 讀懂： AVE=0.56 → 這個構面平均能解釋各題 56% 的變異（收斂效度足夠）； CR=0.83 是用因素負荷加權的信度，比 Cronbach α 更貼近 CFA。兩者都過門檻 → 這個構面『實在且一致』。（√ AVE 再拿去和其他構面的相關比，即區辨效度。）

信度再進階： α 不是唯一，也不是萬能

承上 CR 也是一種信度 → **本頁** 信度再進階： α 、 CR 、 ω 怎麼選

指標	特點	建議
Cronbach's α	最常見；假設各題貢獻相等 (tau-equivalent)	≥ 0.70 ； 題數多時會虛高
組合信度 CR	用因素負荷加權，較貼近 CFA	≥ 0.70 ； SEM/CFA 常報這個
McDonald's ω	放寬 α 的等價假設，較穩健	≥ 0.70 ； 越來越被推薦

重點 別再只報 α： α 假設每題同等貢獻，題數一多就會『看起來很高』而誤導。在 CFA/SEM 脈絡下，組合信度 CR 與 McDonald's ω 更貼近真實內部一致性。報告時可同時附上，讓審稿人安心。 α 高也不代表單一維度——維度要靠因素分析判斷。

COSMIN：健康測量工具的『品質共識標準』

承上 八關都走完 → **本頁** COSMIN：怎麼把整套證據報告給別人看



用途 開發量表時逐項核對；選現成量表時評比品質；寫系統性回顧時評證據；投稿時證明驗證流程完整（附錄第 101 張有實例）

重點 為什麼健康領域特別看重 COSMIN：臨床與健康科技常需自製或改編量表（症狀、生活品質、數位識能），COSMIN 提供一致的語言與標準，讓不同量表的品質可被公平比較——這也是量表能被引用、被納入指引的關鍵。

本節總覽：一頁看完量表怎麼『做出來又證明給人看』

承上 所有關卡與指標 → **本頁** 本節總覽：一頁收齊流程與門檻

階段	關鍵動作	判準速查
內容效度	專家評分	I-CVI ≥ 0.78 、 S-CVI ≥ 0.90
項目分析	刪爛題	題總相關 ⩾ 0.3
EFA	找構面	KMO > 0.6 、負荷 ⩾ 0.4 、平行分析定因素數
CFA	驗結構	CFI/TLI ≥ .95 、 RMSEA/SRMR ≤ .06/.08
信效度	算指標	AVE ≥ .5 、 CR/ω ≥ .7 、√ AVE > 構面相關

重點 帶走一句話：量表發展＝『把抽象概念，用可重現、可驗證的流程，變成一把量得準、分得開、別人也能信的尺』。 EFA 找結構、 CFA 驗結構、 AVE/CR/ω 給證據、 COSMIN 定標準——這正是這一節加給你的能力。

小試身手：讀懂一份量表驗證結果

（參考答案見下一頁）

某團隊自製『長者用藥遵從 App 易用性量表』，報告如下，請判讀：

Q1 EFA： KMO=0.55 、 Bartlett p=0.21 。這份資料適合做因素分析嗎？為什麼？

Q2 他們用『特徵值 >1 』抽出 5 個因素，但有 2 個因素各只有 1 題、且無法命名。你會怎麼建議？

Q3 CFA 報告： CFI=0.91 、 RMSEA=0.11 、 SRMR=0.06 。模型適配可接受嗎？哪個指標有問題？

Q4 某構面 AVE=0.38 、 CR=0.82 。收斂效度 OK 嗎？該怎麼解讀與處理？

重點 提示： Q1 想 KMO/Bartlett 門檻； Q2 想 Kaiser 高估因素數＋可解釋性； Q3 想 RMSEA 超標； Q4 想 AVE<0.5 的判讀（ Fornell-Larcker 的但書）。

參考答案

判讀重點；四個錯誤如何逐關修正，見第 77–103 張附錄

題	參考要點
Q1	不適合。 KMO=0.55 偏低 (<0.6) 、 Bartlett p=0.21 不顯著，代表題目間缺乏足夠共同相關，抽不出有意義的共同因素。應先檢討題目或增樣本，別硬跑 EFA 。
Q2	『特徵值 >1 』常高估因素數。單題因素、無法命名＝不可解釋。建議改用平行分析＋陡坡圖重定因素數，刪除或合併那些單題 / 無法命名的因素，並兼顧理論可解釋性。
Q3	不理想。 CFI=0.91 未達 .95 ； 關鍵是 RMSEA=0.11 遠超 0.08 ，近似誤差過大、適配不佳。不能只挑 SRMR=0.06 好看的講，應依理論修正模型或重檢構面。
Q4	收斂效度不足： AVE=0.38<0.50 ，構面內題目共同解釋的變異偏低。雖 CR=0.82 高，仍應檢查並刪修低負荷題或重新界定構面（ Fornell-Larcker： CR>0.6 時可勉強接受但需說明）。

參考文獻與延伸閱讀

- Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159–174. → κ 分級（第 11–13 張）
- Koo, T. K., & Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. J Chiropractic Medicine, 15(2), 155–163. → ICC
- AERA, APA, & NCME. (2014). Standards for educational and psychological testing. AERA. → 效度證據來源（第 19 張）
- Polit, D. F., & Beck, C. T. (2006). The content validity index: Are you sure you know what's being reported? Research in Nursing & Health, 29(5), 489–497. → CVI
- Boateng, G. O., et al. (2018). Best practices for developing and validating scales for health, social, and behavioral research: A primer. Frontiers in Public Health, 6, 149. → 量表發展流程
- Hu, L., & Bentler, P. M. (1999). Cutoff criteria for fit indexes in covariance structure analysis. Structural Equation Modeling, 6(1), 1–55. → CFA 適配度
- Fornell, C., & Larcker, D. F. (1981). Evaluating structural equation models with unobservable variables and measurement error. J Marketing Research, 18(1), 39–50. → AVE／CR
- Henseler, J., Ringle, C. M., & Sarstedt, M. (2015). A new criterion for assessing discriminant validity in variance-based SEM. J Academy of Marketing Science, 43(1), 115–135. → HTMT
- McNeish, D. (2018). Thanks coefficient alpha, we'll take it from here. Psychological Methods, 23(3), 412–433. → α 與 ω
- Mokkink, L. B., et al. (2010). The COSMIN study reached international consensus on taxonomy, terminology, and definitions of measurement properties. J Clin Epidemiol, 63(7), 737–745. → COSMIN
- Shrout, P. E., & Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. Psychological Bulletin, 86(2), 420–428. → ICC 模型（第 15 張）
- Norman, G. (2010). Likert scales, levels of measurement and the "laws" of statistics. Advances in Health Sciences Education, 15(5), 625–632. → Likert 加總（第 33 張）
- Beaton, D. E., Bombardier, C., Guillemin, F., & Ferraz, M. B. (2000). Guidelines for the process of cross-cultural adaptation of self-report measures. Spine, 25(24), 3186–3191. → 量表翻譯（第 36 張）

A

作業

Take-home Assignment

Measure it right, or the design is wasted.

涵蓋單元 2：操作型定義、信度三型、效度（聚斂／區辨）、四種測量方法、問卷設計。

Part A 觀念題檢驗你「懂不懂」； Part B 實作題檢驗你「測不測得準」。參考解答在本節後段。

Assignment Brief

作業說明：目標、繳交與規則

作業目標

針對一個構念，產出一份『可信又有效』的測量方案（操作型定義＋量表＋信效度規劃）。

繳交方式

一份 PDF： Part A 文字作答 ＋ Part B 量表與信效度規劃，建議 3–5 頁。

建議時間

約 2–3 小時；先做 Part A 暖身，再進入 Part B 設計。

工具與誠信

可用 AI 協助發想與潤飾，但須附『AI 使用聲明』；引用需標註，禁止代寫與杜撰。

Part A ｜觀念題：熟悉變數測量（1/2）

A1 用一句話區分信度與效度；為什麼說『效度比信度更根本』？用靶心比喻說明其中一種組合。

A2 信度三種檢驗（再測／內部一致性／評分者間）各回答什麼問題？各舉一個檢驗情境。

A3 什麼是操作型定義？同一概念可有多個，選擇的準則是什麼？

A4 聚斂效度與區辨效度的差異為何？各需要什麼證據？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2–4 句即可，不必長篇。

Part A ｜觀念題：熟悉變數測量（2/2）

A5 四種測量方法（自陳／表現／觀察／生理）各寫一個優點與一個缺點；什麼情況該併用?

A6 為什麼信度低會降低統計檢定力、放大 p 值? 低信度時可以怎麼補償?

A7 自陳法常見偏誤至少三種，並各寫出一個對策。

A8 問卷設計四步驟是什麼? 每步用一句話說明『產出什麼』。

Part B ｜實作題：設計一份可信可效的測量（1/2）

指示：選一個構念（工作壓力／學習動機／服務品質，或你自己的變數），完成下列各題。

B1 寫出該構念的操作型定義；設計一份 5–8 題量表（附量尺），標明每題對應的子構面。

B2 規劃如何驗證信度：三型中至少兩型，寫出做法與可接受門檻。

B3 規劃如何驗證聚斂與區辨效度：列出『應相關』與『不該相關』的變數各至少一個，並預期相關方向／大小。

教學重點 量表題項必須對得回你的構念定義與子構面——這是內容效度的基礎。

Part B ｜實作題：設計一份可信可效的測量（2/2）

B4 指出你的測量可能的偏誤（社會期許等）與你的對策。

B5 說明你會用數值或類別測量、為什麼；若構念難測，你的替代指標或研究問題微調策略。

B6 附一段方法章『測量』小節（150 字內）＋ AI 使用聲明。

繳交格式 Part B 建議用『量表題目表＋信效度規劃表』呈現，一眼看得出每題測什麼、怎麼驗。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能用靶心／門檻說明
B1 操作化＋量表	15%	操作型定義清楚、題項對應子構面、附量尺
B2 信度規劃	15%	至少兩型、做法具體、門檻正確
B3 效度規劃	15%	聚斂與區辨都有、預期方向合理
B4–B6 偏誤＋方法＋誠信	15%	偏誤與對策對應、方法段可重做、附 AI 聲明

常見扣分 信效度混用、只報 α 就當作『效度良好』、題項與子構面對不上、忘了反向題與匿名。

案例應用：把三個結果變數變成可以測量的東西

案例 Q ｜ AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

① 本單元教了什麼

操作型定義、測量尺度，以及信度與效度各自需要什麼證據。

② 案例怎麼用

· 主要結果定義為：自取得前一班紀錄至開始口頭交班之分鐘數。
· 以第三方觀察計時，兩位觀察者校準 30 次交班， ICC = .91 。
· 紀錄完整性以 0 至 20 分評分表測量，兩位評分者獨立評分， ICC = .84 。
· 認知負荷屬潛在構念，須自編量表並驗證（題目撰寫見 4.3 ，統計驗證見本單元量表發展節），不可用單題自陳。
· 四個變數之測量尺度不同，直接決定單元 2.5 可用之檢定方法。

③ 產出什麼證據

變數操作型定義表（次頁），納入計畫書第 3.4 節「研究工具」。

④ 承接關係

上游：承自 2.1 之研究設計決策表 ｜ 下游：交棒 2.3 ，據此建立資料字典。

教學重點 操作型定義的檢驗標準只有一個：換一個人來測，會不會得到同一個數字。寫不到這個程度，就不是操作型定義，只是換句話說。

示範產物：變數操作型定義表

六個變數逐一交代定義、尺度、來源與品質證據；缺任一欄即為審查意見來源

變數	角色	操作型定義	尺度	資料來源與品質證據
交班準備時間	主要依變量	自取得前一班紀錄至開始口頭交班之分鐘數	比率	第三方觀察計時； ICC = .91 （設定值）
紀錄完整性	次要依變量	8 項必載事項之評分加總，滿分 20 分	等距	兩位評分者獨立評分； ICC = .84 （設定值）
二次確認詢問次數	探索性依變量	交班結束後 30 分鐘內接班者回頭詢問之次數	比率	現場計數
自評認知負荷	解釋變項	自編 8 題量表加總， 8 至 56 分	等距	α = .87 ； 重測 ICC = .78 （設定值）
導入與否	自變量	該次交班是否發生於該機構導入日之後	名目	系統上線紀錄
職類、年資	控制變項	護理師／資深照服員／單位主管；到職年數	名目／比率	人事資料

教學重點　「二次確認詢問次數」原本不在計畫中，是預試時觀察到才補測的（未列入預先註冊之分析，故屬探索性，見 7.2 ）——這一欄後來成了本研究最有價值的發現。測量計畫留一點餘裕，比全部鎖死更好。

附

附錄

量表發展全程實例

Worked Example: Building a Usability Scale Step by Step

以第 59 張的『長者用藥遵從 App 易用性量表』為例，從零走完八個關卡；
每一關都交代：要做什麼、實際怎麼做、得到什麼數字、下了什麼決定。
（教學用虛構數據，以固定亂數種子模擬產生，數字前後一致、可自行驗算。）

全程地圖：八個關卡、兩批樣本、題數 30 → 15

先看全貌；後面每一張的眉標都標出它在哪一關



①–④ 不跑統計：焦點團體 26 人
專家 6 位、認知訪談 10 人

⑤⑥ 樣本 A：260 人
項目分析＋ EFA

⑦⑧ 樣本 B：240 人
CFA ＋信效度（60 人再測）

任何一關不過 → 回頭修題再走一次

①–④ 不跑統計；⑤⑥ 只用樣本 A；⑦⑧ 只用樣本 B——EFA 與 CFA 用的是兩批不同的人。

題數 30 → 25 → 26 → 20 → 15；第 79 張先對照第 59 張的四個錯誤，各出在哪一關。

教學重點 題數一路刪減是正常的：30 題最後只留一半。每刪一題都要留下理由（數字＋題意），審查者最常問的就是『為什麼刪這題』。

第一版的四個錯誤：各出在哪一關？

第 59 張的報告，就是這個團隊的第一版——錯誤會一關傳一關

第 59 張	第一版做了什麼	錯在哪一關	正確做法（見第幾張）
Q1 KMO .55 Bartlett p = .21	前測只收 45 人，就拿 26 題直接跑 EFA（每題不到 2 人）	⑥ 的前提：樣本數	另收樣本 A 260 人 → KMO .91（第 86、90 張）
Q2 特徵值 > 1 抽出 5 個因素	只看 Kaiser 規則；其中 2 個因素各只有 1 題、無法命名	⑥ 決定因素數	改用平行分析 → 3 個因素（第 91 張）
Q3 CFI .91 RMSEA .11	把含單題因素的 5 因素模型直接拿去 CFA	⑦（被 ⑥ 的錯拖累）	3 因素模型＋新樣本 B → RMSEA .050（第 95 張）
Q4 AVE .38 CR .82	8 題全留，其中 3 題負荷量不到 .50	⑤ 項目分析被跳過	先淘汰弱題 → AVE .55–.65（第 88、89、96 張）

重點 四個錯其實是同一個病：急著跑統計、跳過前面的關卡。樣本不夠（Q1）→ 因素數抓錯（Q2）→ CFA 不合（Q3）；弱題沒先刪（Q4）→ AVE 被拉低。

關卡①：先確認『要自己編』，再把概念寫清楚

自編量表之前，要先證明現成的不夠用

第一步：先找現成量表

- 找到通用的系統易用性量表 SUS （10 題）
- 但 SUS 沒問長者最在意的兩件事：
  字看不看得清楚、提醒有沒有幫到吃藥
- 決定：自編新量表
- SUS 不丟：留到關卡⑧ 當比較對象，
  檢驗新量表的聚斂效度

第二步：寫出操作型定義

- 誰： 65 歲以上、每天吃慢性病藥的長者
- 在哪：在家，自己用手機 App
- 做什麼：三項核心任務——設定吃藥提醒、
  提醒響時確認服藥、查看服藥紀錄
- 測什麼：做這三件事時主觀感受到的
  『看得清楚、操作容易、提醒有用』程度

重點 定義要寫到『換一個人來讀，也知道測誰、在什麼情境、測什麼』。範圍越清楚，題目越好寫、專家越好評。

關卡①：三個構面從哪裡來？理論＋長者原話

焦點團體 3 場（長者 20 人）＋照顧者 1 場（6 人），逐字稿編碼後與理論對照

構面	定義	理論依據	焦點團體原話（例）
看得清楚	畫面上的字、顏色、圖示與藥品照片，長者能否看清、認得出來	ISO 9241-11 效能；老化帶來的視力退化	「字太小，都要叫孫子唸給我聽」
操作容易	設定與修改的步驟是否少、好記，按錯時能不能回頭	ISO 9241-11 效率；TAM 知覺易用性	「按錯一次，就不知道跑去哪裡了」
提醒有用	提醒是否真的幫助按時吃藥，並留下服藥紀錄	TAM 知覺有用性；用藥遵從文獻	「有響才記得吃，但要告訴我吃哪一顆」

重點　構面不是研究者想像出來的：理論說『應該有什麼』，長者原話說『實際在意什麼』，對得上才定案。這三個構面就是 EFA 要驗證的理論預期。

關卡②：每個構面寫 10 題，共 30 題題庫

目標最終 15 題；題庫至少寫到最終長度的 2 倍（Boateng 等，2018）

寫題原則	好題目（採用）	壞題目（避免）與原因
一題只問一件事	修改吃藥的時間很容易	App 好用又好看（兩件事，無從作答）
寫具體行為，不寫抽象評價	我一眼就能找到今天要吃的藥	App 的資訊架構清楚（術語、太抽象）
對準易用性，不測別的	吃完藥按「已服用」很方便	App 對我的健康有幫助（測到效益）
用長者自己的話	按錯的時候，我知道怎麼回到上一步	錯誤復原機制完善（長者看不懂）
時間框架一致	指導語統一：想想過去一週的使用經驗	各題時間不一（「最近」「平常」混用）

重點 量尺用 5 點（1 非常不同意～5 非常同意），每一點都印上文字、字級放大——長者的作答負擔優先（點數取捨見 4.3）。

關卡③：6 位專家兩輪評分，30 題 → 25 題

專家：老年醫學科醫師 1、社區藥師 2、老人護理 1、人因設計 1、資訊工程 1

題目（例）	評 3–4 分人數	I-CVI	處理
我一眼就能找到今天要吃的藥	6 ／ 6	1.00	保留
新增一種藥的步驟不多，我做得來	5 ／ 6	.83	保留（≥ .78）
提醒功能很好用	4 ／ 6	.67	太籠統 → 改寫為「提醒響起時，我知道要做什麼」 第二輪 6 ／ 6 → 保留
App 功能齊全	4 ／ 6	.67	改寫後第二輪仍 4 ／ 6 → 刪（功能多不等於好用）
App 下載很快	3 ／ 6	.50	刪（測到的是網路速度，不是 App 本身）
我喜歡這個 App 的設計風格	2 ／ 6	.33	刪（測到的是個人喜好）

重點 整體：第一輪 21 題直接過、5 題改寫、4 題刪除；第二輪只重評改寫的 5 題，4 題過、1 題刪——共留 25 題。

關卡③： I-CVI 與 S-CVI 怎麼算（本例）

每位專家逐題評 1–4 分： 1 不相關、 2 需大改、 3 小改即可、 4 非常相關

逐題： I-CVI

- 評 3 或 4 分＝「相關」
- I-CVI ＝評相關的人數 ÷ 專家數
- 6 位以上專家門檻 .78 （Lynn， 1986）
  → 至少 5 人評相關（5÷6 = .83）才過
- 本研究規則： 4 人（.67）改寫後重評；
  3 人以下（≤ .50）直接刪除

全量表： S-CVI/Ave

- 最後 25 題的 I-CVI：
  16 題為 1.00、 9 題為 .83 （5/6）
- S-CVI/Ave ＝各題 I-CVI 的平均
  ＝（16×1 + 9×5/6） ÷ 25
  ＝（16 + 7.5） ÷ 25 = .94
- 門檻 ≥ .90 （Polit 等， 2007）→ 通過✓

重點 與第 45 張同一套算法。 6 位以上專家用 .78；只有 3–5 位時每題都要全員同意（1.00）——專家越少，門檻越嚴。

關卡④：請 10 位長者邊想邊說，25 → 26 題

一對一：先作答，再追問「這題你是怎麼想的？」；刻意找 75 歲以上、戴老花眼鏡者

發現的問題	卡住人數	修正做法
「介面」這個詞看不懂	4 ／ 10	全部改成「畫面」
「推播通知」不知道是什麼	6 ／ 10	改成「手機跳出來的提醒訊息」
「字夠大、顏色也清楚」一題問兩件事	3 ／ 10	拆成「字夠大」與「顏色對比清楚」兩題 → 25 → 26 題
反向題「我常常不知道下一步要按哪裡」答反	3 ／ 10	改成正向：「我知道下一步要按哪裡」
中間選項「普通」被當成「不知道」	5 ／ 10	每一點都印文字；另設「沒用過這個功能」（不計分）

重點　本量表不用反向題：長者看到否定句易答反，誤差比默許傾向更大（與第 72 張一般建議不同，依族群調整並寫進研究限制）。

兩批不同的長者：樣本 A 探索、樣本 B 驗證

這一頁就是 Q1 的解方：樣本要夠大，而且 EFA 與 CFA 不能用同一批人

樣本 A （n = 260）→ 關卡⑤⑥

- 用途：項目分析＋ EFA
- 人數： 26 題 × 每題 10 人＝ 260
  （第 48 張：每題 5–10 人、且 ≥ 200）
- 來源： 3 個社區關懷據點
  ＋ 1 家醫院藥局

樣本 B （n = 240）→ 關卡⑦⑧

- 用途： CFA ＋信度＋效度
- 人數： CFA 常建議 ≥ 200，本例收 240
- 來源：另外 4 個據點、晚兩個月收案，
  與樣本 A 沒有重複的人
- 其中 60 人兩週後再填一次（再測；
  COSMIN： 50–99 人屬「足夠」）

重點 共同條件： 65 歲以上、每天吃慢性病藥、已用該 App 至少 2 週；排除中度以上認知障礙。兩批都由訪員唸題、長者作答。

關卡⑤：用四把尺檢查每一題（樣本 A）

規則：兩把以上不合格 → 刪除；只有一把不合格 → 標記「觀察」，交給 EFA 再判

尺	怎麼算	不合格的標準
① 校正題總相關	該題與「同構面其他題加總」的相關（不含自己）	< .30
② 刪題後 α	把這題拿掉，構面的 Cronbach's α 變成多少	比原本高（這題在拖後腿）
③ 決斷值（t 檢定）	總分前 27% 與後 27% 兩組，比較該題平均	差異不顯著（p ≥ .05）
④ 天花板／地板	選最高分（或最低分）那一格的人數比例	超過 50%

重點 ①② 看『這題跟同構面其他題是不是一夥的』，③ 看『能不能分出高低』，④ 看『是不是大家都答一樣』。原理見第 46 張。

關卡⑤結果：刪 6 題、標記 2 題，26 → 20 題

只列出有問題的 8 題（✗＝不合格）；其餘 18 題四把尺全部通過

題目	① 題總相關	② 刪題後 α（原 α）	③ 決斷值	④ 最高／最低格	不合格	決定
V7　App 的配色讓我看了舒服	.20 ✗	.864（.842）✗	顯著	—	2	刪
V9　畫面不會超出手機螢幕	.297 ✗	.848（.842）✗	顯著	5 分 87% ✗	3	刪
O8　我會自己更新 App 版本	.25 ✗	.843（.834）✗	顯著	1 分 58% ✗	3	刪
O9　我會打開這個 App	.21 ✗	.844（.834）✗	顯著	5 分 93% ✗	3	刪
R7　提醒的鈴聲好聽	.06 ✗	.837（.796）✗	p = .077 ✗	—	3	刪
R8　我會把 App 推薦給朋友	.20 ✗	.816（.796）✗	顯著	—	2	刪
V6　晚上光線暗也看得清楚	.37	.845（.842）✗	顯著	—	1	觀察
O7　不需家人幫忙就會用	.33	.843（.834）✗	顯著	—	1	觀察

重點　刪完 6 題，各構面 α 不降反升：看得清楚 .84 → .87、操作容易 .83 → .86、提醒有用 .80 → .87。

回頭看 Q4：為什麼 CR 有 .82，AVE 卻只有 .38？

第一版『操作容易』8 題全留（跳過項目分析）——拿它的負荷量實際算一次

第一版：8 題全留

λ：.82 .78 .74 .70 .52 .44 .40 .35

AVE = Σλ² ÷ 8 = 3.06 ÷ 8 = .38 ✗

Σλ = 4.75 → （Σλ）² = 22.56

Σ(1−λ²) = 8 − 3.06 = 4.94

CR = 22.56 ÷ （22.56 + 4.94）= .82 ✓

刪掉 λ < .50 的 3 題：剩 5 題

λ：.82 .78 .74 .70 .52

AVE = Σλ² ÷ 5 = 2.59 ÷ 5 = .52 ✓

Σλ = 3.56 → （Σλ）² = 12.67

Σ(1−λ²) = 5 − 2.59 = 2.41

CR = 12.67 ÷ （12.67 + 2.41）= .84 ✓

重點 CR 會隨題數變大，題一多就『看起來很一致』；AVE 是平均，弱題會把它拉下來。CR 高只能讓 AVE 偏低『勉強接受』（第 60 張），根本解法是刪弱題。

關卡⑥ -1： 這批資料適合做因素分析嗎?

方法：主軸因素法抽取＋ oblimin 斜交轉軸（三個構面預期彼此相關）

本例：樣本 A、 20 題

- KMO = .91 （> .80 良好）✓
- Bartlett： $\chi^2(190) = 2{,}796.2$， $p < .001$ ✓
- 每題人數： 260 ÷ 20 = 13 人✓

→ 可以做 EFA

對照第一版（Q1）： 45 人、 26 題

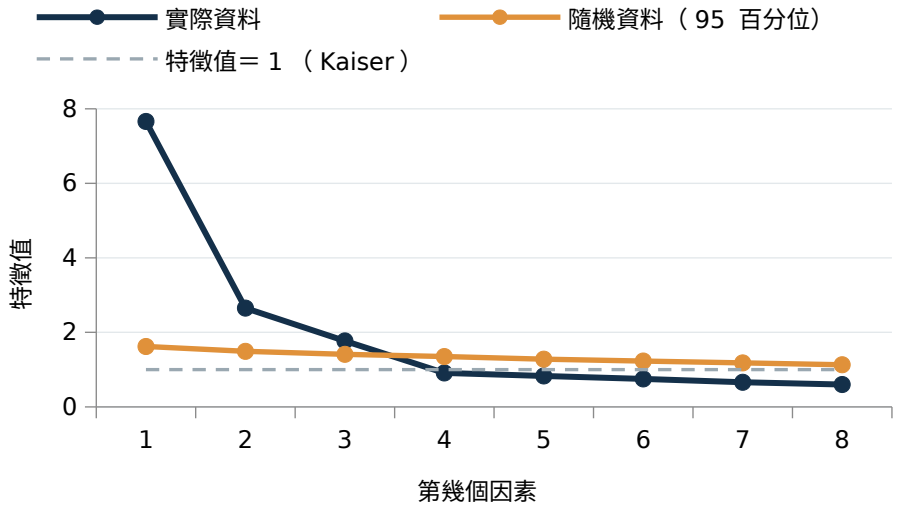
- 每題不到 2 人（45 ÷ 26 = 1.7）
- KMO = .55 、 Bartlett p = .21 ✗
- 人太少時相關係數充滿隨機雜訊，
  看不出題目間真正的共同變異

→ 該做的是多收人，不是硬跑

重點 Bartlett 的自由度＝題數 ×（題數－ 1） ÷ 2 = 20 × 19 ÷ 2 = 190。體檢通過只代表『可以做』，接著還要決定抽幾個因素。

關卡⑥ -2： 抽幾個因素？看平行分析

實際資料的特徵值（藍）高於隨機資料（橘， 500 次模擬的 95 百分位）才保留



讀圖三步

① 第 1–3 個： 7.66 、 2.65 、 1.77 都高於隨機的 1.62 、 1.49 、 1.41 → 保留

② 第 4 個： 0.91 低於隨機的 1.35 → 停

③ 陡坡圖的手肘也在第 3 個之後

結論： 3 個因素，和關卡① 的理論一致

為什麼第一版抽出 5 個？ （ Q2 ）

45 人、 26 題的『純隨機』資料，平均就有 11 個特徵值 > 1—— 人少時 Kaiser 規則必然高估。

重點 平行分析的邏輯：連亂數都做得出來的特徵值，不算真的因素。本例 Kaiser 也剛好給 3 個，是運氣——人少或題多時它常多抓好幾個。

關卡⑥ -3：第一輪負荷量，找出要刪的 5 題

20 題抽 3 個因素：15 題乾淨地只落在自己的構面，下列 5 題有問題（pattern 負荷量）

題目	看得清楚	操作容易	提醒有用	共同性 h^2	問題	決定
V6 晚上光線暗也看得清楚	**.44**	−.07	−.04	.17	共同性 < .20 （⑤已標記觀察）	刪
V8 小圖示的意思我看得懂	**.34**	**.33**	.09	.39	交叉負荷：兩個構面都約 .3	刪
O3 按鈕夠大，我點得到	**.50**	.29	.05	.52	寫給操作，卻落在看清： 同時問『看得到』與『點得到』	刪
O7 不需家人幫忙就會用	.11	**.35**	−.14	.14	主負荷 < .40、共同性 < .20	刪
R5 提醒畫面寫清楚吃哪顆藥	**.38**	.02	**.44**	.46	交叉負荷：看清 .38、提醒 .44	刪

重點 保留規則：主負荷 ≥ .40、次負荷 < .30、共同性 ≥ .20，且歸屬要符合題意。一次只刪一題、刪完重跑，再看下一題。

關卡⑥結果： 15 題、 3 個乾淨的構面

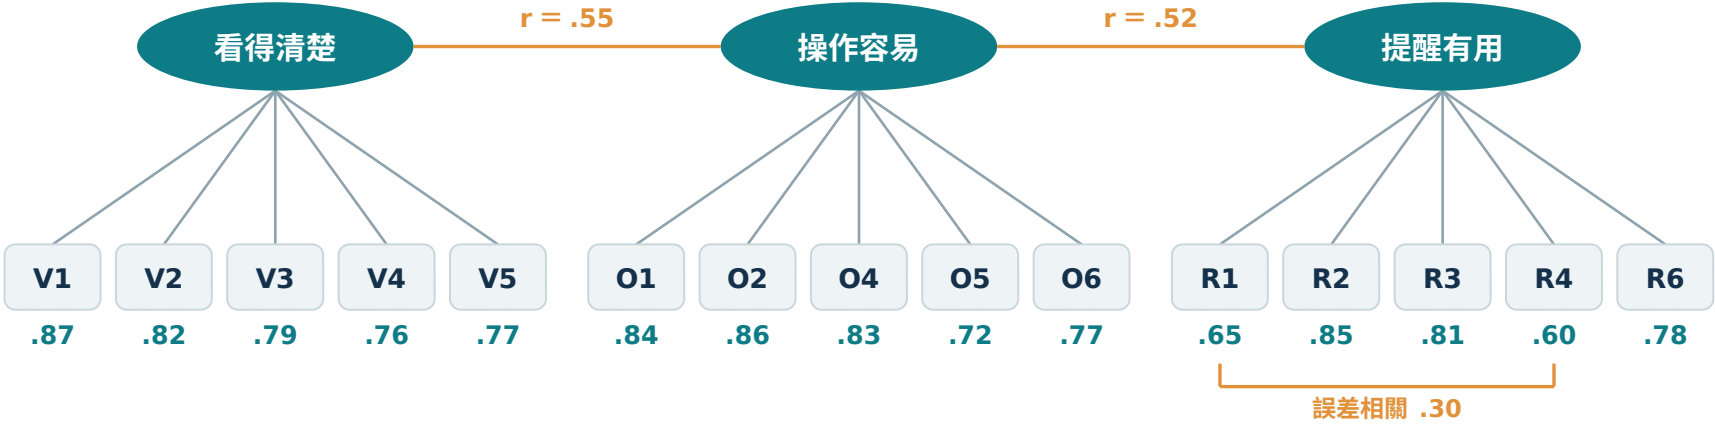
刪完重跑： KMO = .89 、 Bartlett $\chi^2(105) = 2{,}253.0$ ， $p < .001$ ；平行分析仍為 3 個因素

構面	保留的 5 題（題意）	主負荷量	最大交叉負荷
看得清楚	V1 字夠大、 V2 顏色對比、 V3 找到今天的藥、 V4 認得藥品照片、 V5 看懂服藥紀錄	.74–.84	.17
操作容易	O1 新增藥步驟少、 O2 知道下一步、 O4 按錯能回頭、 O5 用過就記得、 O6 改時間容易	.52–.86	.17
提醒有用	R1 依習慣設提醒、 R2 響了知道做什麼、 R3 比較不會忘、 R4 依作息調整、 R6 按已服用很方便	.68–.81	.16

重點 3 個因素共解釋 61.2% 的變異，因素間相關 .29–.50 （所以用斜交轉軸）。 EFA 找到的正是關卡① 的三個構面——對上了，才進 CFA 。

關卡⑦： CFA 模型——拿到樣本 B 驗證

事先規定每題只屬於一個構面（不像 EFA）；線旁數字為標準化負荷量 λ



看得清楚 與 提醒有用 的相關 r = .50 （兩者不相鄰，未畫線）。
圖中 15 題＝關卡⑥ 留下的題目；每題只畫一條線到自己的構面。

重點 估計法：最大概似法（ML），5 點題視為連續；分布嚴重偏斜時改用 WLSMV。 R1 與 R4 下方的括號是『誤差相關』，理由見下一張。

關卡⑦：適配度——初始模型 vs 修正一次

門檻同第 53 張（可接受／良好）；最右欄為第一版的 5 因素模型（Q3），作為對照

指標	門檻（可接受／良好）	初始模型	修正後（+ R1–R4 誤差相關）	第一版（Q3）
χ^2 ／ df	< 3 （嚴格 < 2）	196.8 ／ 87 = 2.26	136.9 ／ 86 = 1.59	—
CFI	≥ .90 ／≥ .95	.950	**.977**	.91
TLI	≥ .90 ／≥ .95	.940	**.972**	—
RMSEA ［90% CI］	≤ .08 ／≤ .06	.073 ［.059, .086］	**.050 ［.033, .065］**	.11 ✗
SRMR	≤ .08	.053	**.046**	.06

重點 修正指標最大的是 R1 、 R4： 兩題都在問『設定提醒時間』，誤差相關有題意依據才加（χ^2 降 59.8）；次大的 O5–O6 只降 14.9 且無題意理由，不加。

關卡⑧ -1： 信度與收斂效度（樣本 B）

AVE 與 CR 用頁面上四捨五入後的 λ 計算，可自行驗算； α 由原始資料算出

構面	標準化負荷量 λ	AVE（≥ .50）	CR（≥ .70）	α（≥ .70）	判讀
看得清楚	.87 .82 .79 .76 .77	.64	.90	.90	收斂✓ 信度✓
操作容易	.84 .86 .83 .72 .77	.65	.90	.90	收斂✓ 信度✓
提醒有用	.65 .85 .81 .60 .78	.55	.86	.87	收斂✓ 信度✓ R1、R4 較低：兩題共享誤差
全量表 15 題	—	—	—	.91	總分可用

重點 驗算『看得清楚』： $AVE = (.87^2 + .82^2 + .79^2 + .76^2 + .77^2) \div 5 = 3.22 \div 5 = .64$； $CR = 4.01^2 \div (4.01^2 + 1.78) = .90$。算法同第 55 張。

關卡⑧ -2： 區辨效度——三個構面分得開嗎?

Fornell–Larcker： 對角線 √ AVE 要大於同列、同欄的構面相關； HTMT 要 < .85

構面	看得清楚	操作容易	提醒有用	HTMT
看得清楚	**√AVE .80**			—
操作容易	.55	**√AVE .81**		與看得清楚 .54
提醒有用	.50	.52	**√AVE .74**	與看得清楚 .49、與操作容易 .51

重點 判讀： .80、 .81、 .74 都大於所在列與欄的相關（最大 .55）； HTMT 最大 .54，遠低於 .85。三個構面相關但不重疊。

關卡⑧ -3： 事先寫好的 4 個預測成立嗎?

構念效度的『假設檢驗』：預測寫在研究計畫裡，資料出來後才對答案（樣本 B ）

事先寫好的預測	為什麼這樣預期	結果	成立
H1　與 SUS 總分正相關， $r \geq .50$	兩者都在測易用性（聚斂）	$r = .70$	✓
H2　與三項任務完成時間負相關， $r \leq -.30$	越好用、做得越快（訪員現場計時）	$r = -.39$	✓
H3　與每天吃幾顆藥幾乎無關， $\lvert r \rvert < .20$	易用性不該隨藥量改變（區辨）	$r = -.02$	✓
H4　每天用智慧型手機者分數較高， $d \geq .50$	熟悉手機的人較容易上手 （已知群體： 111 人 vs 129 人）	M 3.59 vs 2.95 $t(238) = 7.22$ ， $p < .001$ ， $d = .93$	✓

重點　4 個預測全部成立（COSMIN 建議至少 75% 成立）。關鍵在『事先』：看了資料才編預測，一定全中也毫無意義。

關卡⑧ -4： 再測信度與測量誤差

樣本 B 中 60 人，隔 2 週（期間 App 未改版）再填一次

再測信度： ICC

- 模式： ICC(2,1)，絕對一致性
- ICC = .87， 95% CI ［.79, .92］
- 門檻 ⩾ .70 ✓ （同第 73 張）
- 兩次平均 3.27 → 3.31，幾乎沒變

測量誤差： SEM 與 SDC

- SEM = SD × √(1 − ICC)
  = 0.79 × √0.13 = 0.79 × 0.361 = 0.285
- 最小可偵測變化 SDC
  = 1.96 × √2 × SEM = 2.77 × 0.285 = 0.79
- 1–5 分量尺上，個人前後差 ⩾ 0.8 分
  才算真的改變（團體平均可偵測更小差異）

重點 ICC 高代表『整群人的排序穩定』； SEM ／ SDC 則說『個人分數有多少雜訊』： 看某位長者有沒有變好，差距要 ⩾ 0.8 分才算數。

成品：長者用藥遵從 App 易用性量表

指導語：請想想過去一週使用這個 App 的經驗，圈選最符合的答案（1 非常不同意～5 非常同意）

構面	題目	題目（續）
看得清楚	1 畫面上的字夠大，我看得清楚 2 畫面的顏色對比清楚，字不會和背景混在一起 3 我一眼就能找到今天要吃的藥	4 藥品的照片，讓我認得出是哪一顆藥 5 服藥紀錄的畫面，我看得懂自己有沒有漏吃
操作容易	6 新增一種藥的步驟不多，我做得來 7 我知道下一步要按哪裡 8 按錯的時候，我知道怎麼回到上一步	9 用過一兩次後，我就記得怎麼操作 10 修改吃藥的時間很容易
提醒有用	11 我可以把提醒設定在習慣吃藥的時間 12 提醒響起時，我知道要做什麼 13 有了提醒，我比較不會忘記吃藥	14 提醒的時間可以依我的作息調整 15 吃完藥按「已服用」很方便

重點 計分：各構面取 5 題平均（1–5 分），總分取 15 題平均，越高越好用；「沒用過這個功能」不計分，某構面缺 2 題以上則該構面不計分。

對照 COSMIN：做了什麼、還缺什麼

COSMIN 的測量性質逐項核對（第 57 張）；「待補」要寫進研究限制

測量性質	本例的證據	狀態
內容效度	焦點團體 26 人＋專家 6 位（S-CVI/Ave .94）＋認知訪談 10 人	✓
結構效度	EFA（樣本 A）→ CFA（樣本 B）：CFI .977、RMSEA .050	✓
內部一致性	α .87–.90、CR .86–.90	✓
信度（再測）	ICC .87（60 人，間隔 2 週）	✓
測量誤差	SEM 0.285、SDC 0.79 分	✓
假設檢驗	4 個事先預測全部成立	✓
跨文化／測量恆等性	未檢驗（例：65–74 歲與 75 歲以上是否為同一結構）	待補
效標效度	易用性沒有公認的黃金標準	不適用
反應性	需要 App 改版前後的追蹤資料	待補

重點　完成的量表不是『全部打勾』，而是『清楚交代做了哪些、還缺哪些』。缺的兩項是下一篇研究的題目，也是審查者一定會問的地方。

寫成論文方法段：一段話交代全流程

照關卡順序寫，每一步都附人數與數字——讀者照著做，要能做出同一份量表

【題項與內容效度】量表依 Boateng 等（2018）之流程發展。依文獻與焦點團體（長者 20 人、照顧者 6 人）界定三個構面並撰寫 30 題，經 6 位專家兩輪內容效度評定，保留 I-CVI ≥ .78 者 25 題（S-CVI/Ave = .94），再經 10 位長者認知訪談修訂為 26 題。

【項目分析與 EFA】樣本 A（n = 260）先進行項目分析，刪除 6 題；再以主軸因素法與 oblimin 斜交轉軸進行探索性因素分析，依平行分析保留 3 個因素，刪除 5 題後得 15 題（KMO = .89，解釋變異 61.2%）。

【CFA 與信效度】樣本 B（n = 240）以最大概似法進行驗證性因素分析，依題意加入一組誤差相關後，$\chi^2(86) = 136.9$、CFI = .977、TLI = .972、RMSEA = .050（90% CI [.033, .065]）、SRMR = .046；各構面 AVE .55–.65、CR .86–.90、Cronbach's α .87–.90；再測 ICC(2,1) = .87（n = 60，間隔 2 週）。

重點　寫法口訣：每一關寫『做了什麼＋多少人＋得到什麼數字＋刪幾題』。刪題理由放附錄表格（如第 88、92 張），正文只寫結果。

附錄參考文獻

- Brooke, J. (1996). SUS: A "quick and dirty" usability scale. In P. W. Jordan et al. (Eds.), Usability evaluation in industry (pp. 189–194). Taylor & Francis. → SUS （第 80、98 張）
- Davis, F. D. (1989). Perceived usefulness, perceived ease of use, and user acceptance of information technology. MIS Quarterly, 13(3), 319–340. → TAM （第 81 張）
- ISO. (2018). ISO 9241-11:2018 Ergonomics of human-system interaction — Usability: Definitions and concepts. ISO. → 易用性定義（第 81 張）
- Lynn, M. R. (1986). Determination and quantification of content validity. Nursing Research, 35(6), 382–385. → I-CVI 門檻（第 84 張）
- Polit, D. F., Beck, C. T., & Owen, S. V. (2007). Is the CVI an acceptable indicator of content validity? Appraisal and recommendations. Research in Nursing & Health, 30(4), 459–467. → S-CVI/Ave （第 84 張）
- Willis, G. B. (2005). Cognitive interviewing: A tool for improving questionnaire design. Sage. → 認知訪談（第 85 張）
- Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. Psychometrika, 30(2), 179–185. → 平行分析（第 91 張）
- Costello, A. B., & Osborne, J. W. (2005). Best practices in exploratory factor analysis. Practical Assessment, Research, and Evaluation, 10, Article 7. → EFA 刪題（第 92 張）
- Brown, T. A. (2015). Confirmatory factor analysis for applied research (2nd ed.). Guilford Press. → 誤差相關的修正原則（第 95 張）
- de Vet, H. C. W., Terwee, C. B., Mokkink, L. B., & Knol, D. L. (2011). Measurement in medicine: A practical guide. Cambridge University Press. → SEM ／SDC （第 99 張）
- Mokkink, L. B., et al. (2018). COSMIN Risk of Bias checklist for systematic reviews of patient-reported outcome measures. Quality of Life Research, 27(5), 1171–1179. → 再測樣本數（第 86 張）
- Prinsen, C. A. C., et al. (2018). COSMIN guideline for systematic reviews of patient-reported outcome measures. Quality of Life Research, 27(5), 1147–1157. → 假設檢驗 75% 準則（第 98 張）
- 其餘（Boateng et al., 2018； Hu & Bentler, 1999； Fornell & Larcker, 1981； Henseler et al., 2015）見第 61 張。