

量性研究方法 · 完整研究專案

單元 2

變數測量

Measuring Your Variables — Reliability & Validity

如果變數測不準，再好的設計也白費：操作型定義、信度三型、效度、四種測量方法與問卷設計實務

有效測量的兩大支柱



信度 Reliability

= 穩定一致性

測量結果是否「穩定、一致、可重複」。同一對象量兩次應得到相近結果。



效度 Validity

= 測得對不對

測量是否「真正反映」要測的概念。準不準，比穩不穩更根本。

本單元結束後，你能……

- 能為一個抽象概念寫出可操作、可測量的操作型定義。
- 能判別變數屬名目、次序、等距或比率尺度，並據以選擇統計方法。
- 能規劃信度驗證：從三型中選出適用者，並說明可接受門檻。
- 能規劃效度證據：說明內容、效標關聯與構念效度各需要什麼證據。
- 驗收方式 ① 對應作業 A3、B1；② 對應 B5；③ 對應 A2、B2；④ 對應 A4、B3。

從變數到測量：操作型定義

操作型定義（Operational Definition）＝為了這個研究的目的，把抽象概念變成「可實際測量」的具體做法。

抽象概念	可能的操作型定義
健康 Health	主觀評分、生理指標（如腫瘤大小）、體能表現
表現 Performance	速度、品質，或兩者兼具？
公司規模 Company size	營收、員工人數、顧客數
創業者 Entrepreneur	擁有事業（全職／兼職）、每週投入 ≥ 30 小時經營

同一個概念往往有多種操作型定義——選擇會直接影響你測到什麼。

操作型定義的原則：找到一個「行得通」的

- 別在這一步過度糾結——通常有很多操作型定義都可行
- 你只需要找到「一個行得通」的定義即可
- 「行得通」＝ ① 可以被測量 ② 對你關心的變數而言是合理的
- 把定義寫清楚、可重複——別人照著也能測出同一件事

提醒：操作型定義是「這份研究的測量約定」，不是「概念的唯一真理」——在方法章寫明你選了哪個、為什麼。

操作化實例：把「工作壓力」變成可測量

同一概念可有多種操作型定義——選一個可測且合理的即可


步驟	內容
概念定義	工作壓力 = 工作要求超過個人可負荷時的緊張感受
子構面	① 工作負荷 ② 時間壓力 ③ 情緒耗竭
操作型定義（選定）	以自陳量表測量：每構面 2-3 題、7 點量表
題項範例	「我常覺得工作量超過我能負荷。」（工作負荷）
替代做法	生理：唾液皮質醇；行為：加班時數——可交叉驗證

教學重點 別過度糾結『唯一真理』；把選定的定義寫清楚、可重複，並在方法章說明為何這樣測。

信效度四象限：靶心比喻


信度 = 集不集中；效度 = 有沒有打在靶心

信度高．效度高




彈著集中又在靶心

信度高．效度低




集中但系統性偏離（如體重計每次都多 3 公斤）
分散但平均在靶心（多測取平均可補救）

信度低．效度高



信度低．效度低



又散又偏

教學重點 信度是效度的必要非充分條件：不穩定的工具不可能有效；但很穩定也可能穩定地測錯東西。效度比信度更根本——『穩定地測錯』比隨機誤差更難發現，也更危險。註：兩種「效度」不同層次——靶心圖的「效度高」指無系統性偏誤（平均不偏），故「信度低．效度高」可以成立；心理計量意義的效度則會被低信度衰減（見衰減圖）。

信度的三種檢驗

再測信度

Test-retest

同一測量在不同時間點多次施測，結果是否一致。例：每次站上體重計都顯示同一數字。

內部一致性

Internal consistency

同一份工具的多個子題是否測到同一件事。例：數學題 1、3、4 得分一致。以 Cronbach's α 評估。

評分者間信度

Inter-observer

不同觀察者對同一對象是否得到相同結論。例：觀察者 1 與 2 都判定某人具攻擊性。

三種信度回答不同問題：跨時間、跨題項、跨觀察者是否一致。

提高信度的訣竅：多測幾次、取平均

核心訣竅：多次測量後取平均——隨機誤差會互相抵銷，測量結果更接近真值。

三種做法

- 多測幾次取平均：例如量體重量好幾次再平均，抵銷單次波動
- 多用幾個題項：問卷用數道題測同一構念，取平均（信度以內部一致性 α 評估）
- 改良工具與標準化施測程序：減少隨機波動（信度 $\uparrow$ ），也減少系統性偏差（效度 $\uparrow$ ）

信度三型實例：同一份「工作壓力量表」怎麼驗

信度類型	怎麼做	範例結果	可接受門檻
再測 Test-retest	同一群人隔 2 週再填一次，算 ICC 或 r	ICC = .85	ICC $\geq$.70
內部一致性	算量表題項的 Cronbach's α	α = .88	$\alpha \geq$.70
評分者間 Inter-rater	兩位主管各評同一批員工壓力行為	κ = .82	$\kappa >$.60 (>.80 幾近完美)

教學重點 三型回答不同問題（跨時間／跨題項／跨評分者）；量表研究最常報告 Cronbach's α ，觀察法必報 inter-rater。

三種信度：各檢驗一種「一致」

跨時間 / 跨評分者 / 題目之間



重測信度 **Test-retest**：跨「時間」穩不穩



評分者間信度 **Inter-rater**：跨「評分者」一不一致 (κ)



內部一致性 **Internal consistency**：題目之間一不一致 (α)

教學重點 選哪一種取決於你的威脅：怕狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→ α 。

三個信度係數怎麼算？

接上頁： r （再測）、 α （內部一致）、 κ （評分者間）各自的算法

r · 再測信度

做法：同一群人隔一段

時間（如 2 週）再測一次。

算法：兩次分數的 Pearson

相關係數 r 。

直覺：兩次是否『同起同落』。

例：10 人重測， $r = .85$

進階： r 看不出「第二次全體都偏高」，ICC 會扣分，故改報 ICC。

α · 內部一致性

做法：一次施測，看各題

是否測同一件事。

算法： $\alpha = (k / (k - 1)) \times$
 $(1 - \Sigma \sigma^2_{\text{題}} \div \sigma^2_{\text{總}})$

直覺：題目越一致， α 越高。

例：5 題， $\alpha = .88$

κ · 評分者間

做法：兩位評分者評同

一批對象。

算法： $\kappa = (Po - Pe) \div$
 $(1 - Pe)$

直覺：扣掉『運氣一致』

後的真實一致。例：見下方

教學重點 κ 為什麼要扣運氣：兩位主管各把 50 位員工分成『高壓力／否』。都判高 20、都判否 20 → 實際一致 $Po = (20 + 20) / 50 = 0.80$ ； Pe 為「兩人各自判高的比例相乘 + 各自判否的比例相乘」（本例兩人皆 25/50 判高）→ $Pe = 0.5 \times 0.5 + 0.5 \times 0.5 = 0.50$ 。故 $\kappa = (0.80 - 0.50) / (1 - 0.50) = 0.60$ （Landis-Koch：.41-.60 中等，未達 > .60 門檻；.61-.80 高度、>.80 幾近完美）。

動手算：Cronbach's α 逐步計算

5 位受試者、3 題的迷你量表，一步步算到 α

受試者	題 1	題 2	題 3	總分
P1	4	5	4	13
P2	2	3	2	7
P3	5	4	5	14
P4	3	3	4	10
P5	1	2	2	5
變異數 σ^2	2.00	1.04	1.44	11.76

步驟

- ① 每題的變異數： $\sigma^2_1=2.00$ 、 $\sigma^2_2=1.04$ 、 $\sigma^2_3=1.44$
- ② 加總題項變異數： $\Sigma\sigma^2_{\text{題}} = 4.48$
- ③ 總分的變異數： $\sigma^2_{\text{總}} = 11.76$
- ④ 代入公式 ($k=3$):
$$\alpha = (3/2)(1 - 4.48/11.76) = 0.93$$

教學重點 讀懂： $\alpha=0.93$ 遠高於 $.70 \rightarrow$ 這 3 題內部一致性很好，像在測同一個構念。直覺：題項彼此越相關， $\Sigma\sigma^2_{\text{題}}$ 相對 $\sigma^2_{\text{總}}$ 越小、 $(1 - \text{比值})$ 越大 $\rightarrow \alpha$ 越高。（此處變異數除以 n ；軟體除以 $n-1$ 時各變異數同比例放大、比值不變， α 仍為 0.93 。）

為什麼信度會影響統計顯著性？

信度高

- 測量誤差低
- 統計檢定力（power）高
- 較易偵測顯著差異
- p 值較小

信度低

- 測量誤差大
- 效果被雜訊稀釋
- 檢定力下降
- p 值較大（可能藏住真實關係）

顯著水準 α （如 0.05；與 Cronbach's α 不同）是事前設定的門檻，不因信度改變；但信度低時應增加樣本數或改良工具來補償。

信度 → 誤差 → 檢定力


信度低 → 效果被低估 → 檢定力下降

衰減 Attenuation 的連鎖後果

低信度的連鎖後果



衰減 Attenuation：信度越低，效果越被低估



教學重點 提高信度（多題、多次測量取平均）等於免費提升檢定力——比事後加樣本便宜得多。（圖示假設 X、Y 兩變項信度相同）

隨堂 60 秒：信度怎麼選、怎麼算

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 的「交班紀錄完整性是否達標」由兩位觀察員各自判定。要檢驗這項測量的一致性，該算哪一個係數？
- ② 為什麼這裡不能用 Pearson r ？請用一句話說明。
- ③ 若兩位觀察員的一致率 $P_o = 0.80$ 、運氣一致 $P_e = 0.50$ ， κ 是多少？屬於哪一級？

講評重點 選係數看的是「變數型態」與「威脅來源」，不是看手邊有什麼數字。

效度的全景：三大類、五種常見檢驗

效度類別	問的問題	常用指標	案例 Q 的做法
內容效度 Content	題目涵蓋構念的全部面向了嗎？	CVI（專家評定）	紀錄完整性評分表由長照專家審涵蓋面
效標關聯・同時	與同時測到的標準一致嗎？	與效標的相關	系統記錄的準備時間 vs 觀察員現場計時
效標關聯・預測	能預測未來的結果嗎？	與後續結果的相關	導入前認知負荷能否預測後續使用流失
構念效度・聚斂	與「應該相關」的變數相關嗎？	r、AVE	認知負荷 vs 二次確認詢問次數 → 應正相關
構念效度・區辨	與「不該相關」的變數不相關嗎？	r 接近 0	認知負荷 vs 年資 → 應接近 0

教學重點 效度不是單一數字，而是一組證據；同一份工具用在不同目的上，需要的效度證據不同（AERA / APA / NCME 《Standards》（2014）以「效度證據來源」統稱）。信度是效度的必要非充分條件——見第 7 張靶心圖。

效度的兩種：聚斂與區辨

聚斂效度 Convergent

測量與「應該相關」的變數確實相關。

- 例：體重計顯示數字，隨堆疊物品增加而增加 → 合理
- 體適能 vs 跑步速度 → 正相關 ✓

區辨效度 Discriminant

測量與「不該相關」的變數不相關。

- 例：體重計上的數字不應受「室溫」影響
- 體適能 vs 身高 → 接近 0、不顯著 ✓

好的測量：該相關的相關、不該相關的不相關——兩者一起看才完整。

效度實例：用相關矩陣看聚斂與區辨

新『工作壓力量表』——該相關的相關、不該相關的不相關

與哪個變數比	預期	觀察 r	判讀
職業倦怠	應正相關（聚斂）	.62	聚斂效度 ✓
睡眠品質	應負相關（聚斂）	-.48	聚斂效度 ✓
每週工時	弱正相關（合理）	.30	合理
身高	不該相關（區辨）	.04	區辨效度 ✓

教學重點 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算測到『壓力』而非別的東西。

聚斂與區辨：用相關矩陣看

同構念要高、跨構念要低

壓力 1	1.00	0.72	0.68	-0.18	-0.12	-0.15
壓力 2	0.72	1.00	0.75	-0.14	-0.16	-0.11
壓力 3	0.68	0.75	1.00	-0.12	-0.10	-0.13
支持 1	-0.18	-0.14	-0.12	1.00	0.70	0.74
支持 2	-0.12	-0.16	-0.10	0.70	1.00	0.69
支持 3	-0.15	-0.11	-0.13	0.74	0.69	1.00
壓力 1	壓力 2	壓力 3	支持 1	支持 2	支持 3	

怎麼讀這張相關矩陣

 綠框：同一構念的題目

應該「高」（此例 .68~.75）→ 聚斂效度成立

 橘框：不同構念之間

應該「低」（此例 -.10~-0.18）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事，要合併、重新定義，或改題。

教學重點 跨構念相關若逼近同構念相關，先回頭看題目問法是不是太像——改題比事後在討論章辯解容易得多。

四種測量方法總覽

自陳法 Self-report

直接問當事人（訪談、問卷、調查）——最常用，但可能有社會期許偏誤。

表現測量 Performance

以任務測能力（IQ、體能、反應時間）——難造假，但易受狀態干擾。

觀察行為 Observed behavior

觀察人們「實際怎麼做」（購買選擇、臉部表情）——外部效度高，但難設置。

生理測量 Physical

心率、皮膚電導（流汗）、荷爾蒙（皮質醇）、腦活動——難造假，但需設備、難解讀。

沒有最好的方法，只有「最適合這個研究情境」的方法。

自陳法 Self-report：開放式 vs 封閉式

開放式（偏質性）

- 不引導受訪者往任何方向回答
- 多用「你做了什麼？為什麼這樣做？」
- 避免「是不是因為 X？喜不喜歡 X？」這種誘導

封閉式（偏量化）

- 評定量表（5 = 非常同意… 1 = 非常不同意）→ 數值變量
- 勾選題（性別：男／女／其他）→ 類別變量
- 易統計，但受選項侷限

留意：社會期許偏誤 敏感題（是否欺騙伴侶、智商多高）易得美化答案；測量潛在構念時，用「多個題項」較穩。
尺度層級 單題 **Likert** 為次序尺度，多題加總後方近似等距——見下一節「四種測量尺度」。

常見自陳偏誤與對策

問卷測得準不準，一半看題目怎麼寫

偏誤	症狀	對策
社會期許 Social desirability	敏感題給美化的答案	匿名作答、中立措辭、間接問法
默許傾向 Acquiescence	不管內容都傾向『同意』	加入反向題、平衡正反向題
集中趨勢 Central tendency	什麼都選中間值	調整量尺點數、必要時強制選擇
月暈效應 Halo	一個印象影響所有題	打散題序、清楚定義各構面

教學重點 測潛在構念時『用多個題項』最穩；反向題與注意力檢查題能同時抓默許與敷衍作答。

常見自陳偏誤 · 各舉一例

把上頁四種偏誤，放進真實情境看

偏誤	具體範例
社會期許	問護理師『你會不會對病人不耐煩？』→即使會，也答『從不』以維持良好形象。
默許傾向	受訪者每題都勾『同意』，連反向題也勾同意→前後矛盾露餡。
集中趨勢	每題都選『普通／中立』，避免表態→分數擠在中間、拉不開差異。
月暈效應	覺得某主管『人很好』，就把他所有領導面向都評高分。

教學重點 對策速記：社會期許→匿名／間接問法；默許→加反向題；集中趨勢→偶數點量尺或強制選擇；月暈→打散題序、清楚定義各面向。（問卷寫作詳見 4.3 問卷設計實務）

表現、行為、生理測量：優缺點對照

方法	例子	優點	缺點
表現 Performance	IQ、體能、反應時間	難造假	易受狀態干擾（如沒睡好）
觀察行為 Observed	購買選擇、臉部表情	外部效度高（看實際行為）	常較難設置
生理 Physical	心率、皮膚電導、皮質醇	難造假	需設備、有時難解讀

表現測量常需在「不受干擾、條件相似」下進行，結果才可比較。

如何選擇測量方法

- 永遠先想「信度」與「效度」——這兩把尺決定方法好壞
- 例①：自陳法若因社會期許而失真 → 改換問法，或用不同方法測量
- 例②：反應時間波動大 → 多測幾次、取平均
- 例③：心率可能反映興奮，也可能只是喝了咖啡 → 若各法都有問題，就用多種方法交叉比對

每種測量方法都可能是好選擇——取決於研究情境；若都不理想，考慮同時使用多種方法。

測量的類型：數值 vs 類別

數值變量 Numerical

- 有大小、可測差距（例：壓力分數、睡眠時數）
- 靈敏度高，能捕捉細微變化
- 可用 ICC 或相關係數評估信度

類別變量 Categorical

- 以類別區分（例：有無失眠、性別、國籍）
- 名目類別無大小；次序類別（輕／中／重）有先後、無等距，可用加權 κ
- 信度改用一致性指標評估：Cohen's κ 或百分比一致度，不可用相關係數（例：兩位觀察員判定「交班紀錄完整性是否達標」，須先驗 κ ）

四種測量尺度：決定你能用哪些統計

尺度	可分類	可排序	間距相等	絕對零點	案例 Q 變數 (值域)	集中量數	典型檢定
名目 Nominal	✓	✗	✗	✗	職類、機構 (A / B)、班別	眾數	卡方
次序 Ordinal	✓	✓	✗	✗	認知負荷量表單題 (1-7)	中位數	無母數 (Wilcoxon)
等距 Interval (準)	✓	✓	✓	✗	認知負荷加總分 (19-48)、紀錄完整性分數 (6.9-20.0)	平均數、SD	t 檢定、ANOVA
比率 Ratio	✓	✓	✓	✓	交班準備時間 (2.0-36.4 分)、詢問次數 (0-7)、照顧住民數 (4-22)	平均數	t 檢定、相關、迴歸

單題 Likert 嚴格說是次序尺度；多題加總後方視為近似等距，才能用平均數與 t 檢定。凡「零」代表「完全沒有」的量，才是比率尺度。

隨堂 60 秒：判斷測量尺度

先自己作答，再看解答 · 預估 1 分鐘

- ① 下列四個案例 Q 變數各屬哪一種測量尺度？ 職類／認知負荷單題（1-7）／認知負荷加總分／交班準備時間（分）
- ② 其中哪些可以算平均數？哪些只能看眾數或中位數？
- ③ 「準備時間 20 分鐘是 10 分鐘的兩倍」這句話成立嗎？為什麼？

講評重點 尺度決定集中量數與檢定；判斷順序是「可分類 → 可排序 → 間距相等 → 有絕對零點」。

測不準怎麼辦？調整研究問題

- 有些概念難以直接、準確測量（例：犯罪行為、真實態度）
- 策略一：尋找可靠的替代指標 / 操作型定義
- 策略二：微調研究問題，使其可被測量
- 自陳式（self-report）測量要留意「社會期許偏誤」

例：直接問「你是否有犯罪行為」難以取得可靠答案 → 可改測「與犯罪相關的可觀察行為」或使用官方紀錄等替代指標。

問卷設計的具體做法

① 題項與概念對應

為每個構念（construct）建立清楚定義，據此設計題項。例：服務品質可依 SERVQUAL 五構面設計。

② 專家效度檢核

邀專家審查題項是否涵蓋構念內容範圍；以 CVI（內容效度指數）評估各題與構念的相關性。

③ 預試與修正

小樣本預試，檢查題目是否模糊或誘導；以項目分析刪除區分度低的題項。

④ 構念效度檢驗

以探索性因素分析（EFA）或驗證性因素分析（CFA）確認題項結構符合理論預期。

本單元重點回顧

- **【目標①】** 先把抽象概念變成「操作型定義」——找到一個可測且合理的即可。
- **【目標③】** **【目標④】** 信度＝穩定一致（再測、內部一致性、評分者間）；效度＝內容＋效標關聯（同時／預測）＋構念（聚斂／區辨）。
- **【目標③】** 多題項／多次測量取平均，是提高信度最實用的訣竅。
- 四種測量方法：自陳、表現、觀察行為、生理——各有優缺，依情境選、必要時併用。
- **【目標③】** 信度低會稀釋效果、降低檢定力、放大 p 值，可能藏住真實關係。
- 問卷設計四步：概念對應 → 專家效度 → 預試修正 → 構念效度。
- **【目標②】** 測量尺度（名目／次序／等距／比率）是 2.4 選圖、2.5 選檢定的共同判準。

下一站 2.3 資料蒐集：測量工具定下來了，接著決定跟誰收、收多少、怎麼避開偏誤。



延伸

量表發展與驗證

Scale Development & Validation

把前面的『信度・效度』升級成一套完整的量表製作流程：
從產生題項、內容效度，到 EFA 探索因素、CFA 驗證結構。

為什麼需要『量表發展』這一節？

好量表不是湊幾題問卷，而是一套可驗證的建構過程

隨便湊題目的下場

- 題目測到的不是你想測的概念（效度差）
 - 不同題目各測各的、內部不一致（信度差）
 - 幾個構面混在一起、分不開（維度不清）
 - 审稿人一句『量表未經驗證』就退稿
- 資料再多也是雜訊

這一節給你的能力

- 用系統流程把抽象概念變成可信量表
 - EFA：找出題目背後有幾個構面
 - CFA：驗證你的構面結構站不站得住
 - 用 AVE/CR、適配度指標客觀評估
- 依 COSMIN 報告，讓量表可被引用

重點 量表發展＝把「信度＝一致、效度＝測得準」做出來並證明給別人看的工程；健康科技尤其常需自製量表。
與 4.3 的分工 題目怎麼寫、量尺怎麼設計見 4.3 問卷設計實務；本節專講「寫完之後」的統計驗證。

量表發展的生命週期：六個階段

一條龍走完，才是一份『經驗證』的量表

- 1 界定建構＋維度** 講清楚概念定義與理論上有幾個構面 (dimension)
- 2 產生題項 Item pool** 依定義＋文獻＋專家，寫出比需要更多的候選題
- 3 內容效度 CVI** 專家評每題相關性，算 I-CVI / S-CVI 篩題
- 4 前測＋項目分析** 小樣本試測，看題目鑑別度、刪爛題
- 5 EFA 探索因素** 用一半樣本找出實際的構面結構
- 6 CFA＋信效度＋報告** 另一半樣本驗證，算 AVE/CR、依 COSMIN 報告

重點 關鍵紀律：EFA 與 CFA 要用『不同的樣本』（或把資料切兩半）。用同一批資料先探索再驗證，等於自己出題自己改考卷——結構一定過，但沒有意義。本節實例：自製『數位健康識能量表 DHLS』（教學用虛構數據）。（次頁把這六個階段展開為八個關卡）

量表發展八關卡：一張圖看完

從概念界定到信效度總結



任何一關不過 → 回頭修題再走一次

⑥ EFA 與 ⑦ CFA 必須用「不同樣本」——用同一批資料先探索再驗證，等於自己驗證自己。

健康測量工具的品質報告可對照 COSMIN 標準。

教學重點 切樣本前先確認兩半的年資與職類分佈相近；否則 CFA 不通過可能只是抽樣造成，不是結構有問題。

先修 · 因素分析在做什麼？（白話）

量表發展會用到的統計，先用白話＋小例子建立直覺

核心直覺

- 因素分析 = 看『哪些題彼此高度相關，像在測同一件事』。
- 把這些題歸成一個『因素／構面』（例如：焦慮、工作壓力）。
- 例：5 題若彼此相關都很高
→ 可能都在測『工作壓力』這一個構面。

三個關鍵名詞

- 因素負荷 loading：一題與某因素的相關（ $-1 \sim 1$ ）； > 0.5 = 這題『忠於』該因素。
- 特徵值／陡坡圖／平行分析：決定『抽幾個因素』的方法。
- KMO / Bartlett：資料『適不適合』做因素分析的體檢（ $KMO > 0.6$ 才值得做）。

重點 一句話：EFA（探索性因素分析）就是『讓資料告訴你——這一堆題背後其實有幾個構面、每題屬於哪一個』。把它想成『幫題目分組』；後面的 KMO、負荷、因素數，都是為了把這件事做得可靠。

先修 · 驗證與信效度指標（白話速查）

這些縮寫看起來嚇人，其實各回答一個簡單問題

名詞	白話：它在問什麼	好的門檻
CVI（內容效度）	專家覺得這題『切不切題』的比例	$I-CVI \geq .78$ 、 $S-CVI \geq .90$
題總相關	這一題和量表總分有沒有關係	$\geq .30$
CFA 適配度 (CFI/RMSEA...)	你畫的構面圖和真實資料合不合	$CFI/TLI \geq .95$ ； $RMSEA/SRMR \leq .06/.08$
AVE	一個構面的題目『共同解釋的變異』夠不夠	$\geq .50$
CR / Cronbach α / ω	內部一致性（同構面的題夠不夠一致）	$\geq .70$

重點 看懂速查：每個指標都對應一個問句——切題嗎 (CVI)、這題有用嗎（題總相關）、結構對嗎 (CFA)、構面實在嗎 (AVE)、夠一致嗎 (CR/ α / ω)。之後本節總覽表，就是把這些門檻收在一起。

產生題項＋內容效度 CVI：先讓專家把關

題目對不對題，先問懂的人

產生題項的原則

- 一題一概念，避免雙重內涵 (double-barreled)
- 語意清楚、避免引導與否定套否定
- 涵蓋建構的每個面向（內容代表性）
- 寧可多寫（如每構面 8-10 題），後面再刪
- 量尺一致（如 Likert 1-5）

內容效度指標 CVI

專家小組（常 5-10 人）逐題評『相關性』 1-4 分

$I-CVI$ = 某題評 3-4 分的專家比例

建議 $I-CVI \geq 0.78$ 保留（6 位以上專家；3-5 位須 1.00）

$S-CVI/Ave$ = 全量表平均，建議 ≥ 0.90

→ 據此刪修題目，並記錄過程

重點 CVI 是『量化的專家共識』：它把『這題到底測不測得到概念』交給領域專家評分，而不是研究者自己說了算。健康量表尤其重要——臨床專家能抓出病人真正在意、你卻漏掉的面向。

動手算：內容效度 CVI 逐步計算

6 位專家評 4 題的相關性，算 I-CVI 與 S-CVI

題目	評 3-4 分的專家數 (N=6)	I-CVI	判斷
Q1	6	1.00	保留
Q2	5	0.83	保留
Q3	6	1.00	保留
Q4	4	0.67	< 0.78 → 修 / 刪

重點 步驟：① $I-CVI = \text{該題評『相關（3-4分）』的專家數} \div \text{總專家數}(6)$ 。② $S-CVI/Ave = \text{各題 } I-CVI \text{ 平均}$
 $= (1.00 + 0.83 + 1.00 + 0.67) \div 4 = 0.875$ 。判讀：I-CVI 應 ≥ 0.78 （6 位以上專家）→ Q4 只有 0.67，須修改或刪除；整體
0.875 略低於 0.90 → 修好 Q4 再重評即達標。

前測與項目分析：淘汰『沒有鑑別力』的題

好題目要能把高分群和低分群分開


檢查	看什麼	判準（參考）
題總相關	該題與量表總分的相關	$r < 0.3 \rightarrow$ 考慮刪除
刪題後 α	刪掉這題，Cronbach α 會不會反而升高	升高 $\rightarrow$ 這題可能是雜訊
決斷值 critical ratio	高分組 vs 低分組在該題差異（t 檢定）	不顯著 $\rightarrow$ 鑑別力差
分佈 / 天花板	是否幾乎所有人都選同一格	嚴重偏斜 $\rightarrow$ 資訊量低

重點 直覺：一個好題目應該讓『概念高的人』和『概念低的人』答得不一樣。如果人人都答一樣、或它跟總分沒關係，這題就沒在測東西——先在前測用項目分析刪掉，別把爛題帶進 EFA。

EFA vs CFA：先探索、後驗證


一個讓資料說話，一個檢驗你的假設

EFA 探索性：不預設哪題屬哪因素



所有題目對所有因素都有負荷 → 由資料告訴你結構
用途：量表初期，還不確定有幾個構面

CFA 驗證性：事先指定結構再檢驗



事先規定 1-3 屬 F1、4-6 屬 F2 → 檢驗這個假設合不合
用途：用「新樣本」驗證 EFA 找到的結構

教學重點 EFA 用途在量表開發早期、發現構面，結果是因素數與負荷矩陣；CFA 用於已有理論結構、拿新樣本驗證。量表初期不確定幾個構面 → EFA；順序不能反。

EFA 步驟①：先確認資料『適不適合』做因素分析

題目之間要有足夠的相關，才值得抽因素

兩個把關指標

KMO 取樣適切性：0-1，越高越好

> 0.6 尚可、> 0.8 良好

Bartlett 球形檢定： $p < 0.05$ 才通過

(檢定相關矩陣是否 $\neq$ 單位矩陣)

樣本量：常建議每題 5-10 人、且 ≥ 200

為什麼要先做

若題目彼此幾乎不相關 → 抽不出共同因素

KMO 太低 (< 0.5) → 別硬做 EFA

Bartlett 不顯著 → 沒有結構可找

→ 先過這關，再談抽幾個因素

DHLS 實例：KMO=0.89、Bartlett $p < 0.001$ ✓

重點 直覺：因素分析是『從很多題的共同變異裡，萃取出背後的少數構面』。如果題目之間根本沒共同變異（低 KMO、Bartlett 不顯著），就沒有『共同的东西』可萃取——硬做只會得到一堆無意義的因素。

EFA 步驟②：到底該抽『幾個』因素？

這是 EFA 最關鍵、也最常做錯的一步

方法	規則	評價
特徵值 > 1 (Kaiser)	保留 eigenvalue > 1 的因素	最常見，但常『高估』因素數，別單用
陡坡圖 Scree plot	看曲線『手肘』轉折前的因素	主觀，需搭配其他方法
平行分析 Parallel	與隨機資料的特徵值比較	目前最推薦、較準確
可解釋性	抽出的因素能不能合理命名	理論與統計要並重

重點 別只信『特徵值 > 1』：這條 Kaiser 規則簡單但常抽出太多因素。實務上以『平行分析』為主、陡坡圖與可解釋性為輔，三者交叉判斷。因素數不是純統計題——最終要能對每個因素講出一個有意義的構面名字。

EFA 步驟③：轉軸與負荷量判讀

轉軸讓因素結構『看得懂』；負荷量告訴你題目歸誰

轉軸 Rotation

目的：讓每題盡量只在『一個』因素高載入

正交 (Varimax)：假設因素間不相關

斜交 (Promax/Oblimin)：允許因素相關

→ 社會 / 健康構面常相關，多用斜交

轉軸不改變適配，只改變『可讀性』

負荷量 Loading 判讀

負荷量 = 題目與因素的關聯（正交轉軸時即相關）

一般保留 $|\text{loading}| \geq 0.40$ （嚴格 0.50）

交叉負荷（兩因素都 $>0.3 \sim 0.4$ ）→ 考慮刪

共同性 communality 太低 (<0.2) → 該題弱

據此刪題、重跑，直到結構乾淨

重點 判讀口訣：好題目『只忠於一個因素』——在自己構面上高載入 (>0.5)、在別的構面低載入 (<0.3)。腳踏兩條船的交叉負荷題會讓構面糊在一起，通常刪掉。刪題是正常且必要的，記得記錄每次決定。

EFA 實例：數位健康識能量表（DHLS）

24 題跑 EFA，浮現三個乾淨的構面

因素（命名）	高載入題（示例）	載入量範圍
F1 取得資訊 Access	我能找到可信的健康網站 /App	0.72 - 0.84
F2 理解資訊 Understand	我看得懂檢驗報告與衛教內容	0.68 - 0.81
F3 應用決策 Apply	我能用查到的資訊做健康決定	0.70 - 0.79
（已刪）交叉負荷題 ×3	同時載入 F1 與 F3	刪除

重點 解讀：24 題經 EFA（斜交轉軸）後，浮現三個因素、共解釋約 62% 變異，各題乾淨載入到單一構面；刪掉 3 題交叉負荷題後剩 21 題。這三個構面（取得／理解／應用）符合健康識能理論——統計與理論對得上，才算好結構。

CFA：把 EFA 找到的結構，拿到新樣本『驗證』

從『資料告訴我』升級為『我假設，並檢定』

CFA 在做什麼

事先畫好模型：F1、F2、F3 各含哪些題

用『另一半樣本』檢定模型與資料的適配

每題只允許載入自己的構面（不像 EFA）

輸出：適配度指標＋標準化負荷＋AVE/CR

模型不好 → 依理論修正（勿盲目改）

為什麼要換樣本

同一批資料先探索再驗證＝作弊（必過）

CFA 需獨立樣本（或先切一半留給 CFA）

跨樣本仍站得住 → 結構才可信

健康量表常再做跨族群 / 跨語言恆等性

→ 這是可發表量表的基本要求

重點 EFA 與 CFA 的分工：EFA 像『田野探勘』畫出草圖，CFA 像『工程驗收』檢查這張圖在新地基上蓋不蓋得起來。只有草圖沒驗收，量表不算完成；用同一塊地既探勘又驗收，驗收一定過但毫無保證。

CFA 適配度指標：模型和資料合不合？

看一組指標，不要只看單一個

指標	門檻（可接受 / 良好）	說明
χ^2/df	< 3 （嚴格 < 2）	卡方受樣本數影響，看比值
CFI / TLI	≥ 0.90 / ≥ 0.95	比較適配指標，越接近 1 越好
RMSEA	≤ 0.08 / ≤ 0.06	近似誤差，越小越好（附 90% CI）
SRMR	≤ 0.08	標準化殘差均方根

重點 報告慣例：CFI/TLI、RMSEA、SRMR 都要報、一起判讀（Hu & Bentler, 1999），別只挑漂亮的講。DHLS 實例： $\chi^2/df=2.1$ 、CFI=0.96、TLI=0.95、RMSEA=0.05、SRMR=0.04 → 模型適配良好，三構面結構獲驗證。

收斂與區辨效度：用 AVE、CR、 $\sqrt{\text{AVE}}$ 客觀判斷

構面內要抱團、構面間要分得開

收斂效度 Convergent

同構面的題要『測到同一件事』

平均變異抽取 $\text{AVE} \geq 0.50$

組合信度 $\text{CR} \geq 0.70$

標準化因素負荷 ≥ 0.50 (佳 0.70)

→ DHLS：各構面 AVE 0.55-0.63 ✓

區辨效度 Discriminant

不同構面要『分得開』、不重疊

Fornell-Larcker： $\sqrt{\text{AVE}}$ > 與其他構面的相關

HTMT < 0.85 (寬鬆 0.90)

→ 若兩構面相關過高，可能該合併

→ DHLS： $\sqrt{\text{AVE}}$ 均大於構面間相關 ✓

重點 兩個效度一起看：收斂 = 『同構面的題彼此夠像』 (AVE 夠高)；區辨 = 『不同構面夠不一樣』 ($\sqrt{\text{AVE}}$ 大於它與別人的相關)。前者確保構面『實』，後者確保構面『各自獨立』——健康量表若『理解』和『應用』分不開，就得考慮合併或重新界定。

動手算： AVE 與 CR 逐步計算

從 4 題的因素負荷，算收斂效度 AVE 與組合信度 CR

① 收斂效度 AVE

因素負荷 λ : .72、.81、.68、.77

$AVE = \Sigma \lambda^2 \div \text{題數}$

$\lambda^2 = .52、.66、.46、.59$; $\Sigma = 2.23$

$AVE = 2.23 \div 4 = 0.56$ ($\geq .50$ ✓)

→ 構面平均能解釋各題 56% 的變異

② 組合信度 CR

$CR = (\Sigma \lambda)^2 \div [(\Sigma \lambda)^2 + \Sigma (1 - \lambda^2)]$

$\Sigma \lambda = 2.98 \rightarrow (\Sigma \lambda)^2 = 8.88$

$\Sigma (1 - \lambda^2) = 1.77$

$CR = 8.88 \div (8.88 + 1.77) = 0.83$

($\geq .70$ ✓)

重點 讀懂：AVE=0.56 → 這個構面平均能解釋各題 56% 的變異（收斂效度足夠）；CR=0.83 是用因素負荷加權的信度，比 Cronbach α 更貼近 CFA。兩者都過門檻 → 這個構面『實在且一致』。（ $\sqrt{AVE}$ 再拿去和其他構面的相關比，即區辨效度。）

信度再進階： α 不是唯一，也不是萬能

Cronbach α 、組合信度 CR、McDonald ω

指標	特點	建議
Cronbach's α	最常見；假設各題貢獻相等 (tau-equivalent)	≥ 0.70 ；題數多時會虛高
組合信度 CR	用因素負荷加權，較貼近 CFA	≥ 0.70 ；SEM/CFA 常報這個
McDonald's ω	放寬 α 的等價假設，較穩健	≥ 0.70 ；越來越被推薦

重點 別再只報 α ： α 假設每題同等貢獻，題數一多就會『看起來很高』而誤導。在 CFA/SEM 脈絡下，組合信度 CR 與 McDonald's ω 更貼近真實內部一致性。報告時可同時附上，讓審稿人安心。 α 高也不代表單一維度——維度要靠因素分析判斷。

COSMIN：健康測量工具的『品質共識標準』

做量表、選量表、評量表，都用得上

COSMIN 是什麼

健康測量工具的方法學共識標準

把測量性質分成三大類：

- 信度（內部一致性、信度、測量誤差）
- 效度（內容、結構、假設檢驗、跨文化、效標）
- 反應性（responsiveness 偵測變化）

你能拿它做什麼

- 開發量表：對照它逐項確認做齊了
 - 選現成量表：系統性評比工具品質
 - 寫系統性回顧：評測量性質的證據
 - 投稿：用它證明你的驗證流程完整
- 健康科技自製量表的黃金對照表

重點 為什麼健康領域特別看重 COSMIN：臨床與健康科技常需自製或改編量表（症狀、生活品質、數位識能），COSMIN 提供一致的語言與標準，讓不同量表的品質可被公平比較——這也是量表能被引用、被納入指引的關鍵。

本節總覽：一頁看完量表怎麼『做出來又證明給人看』

把流程與判準速查表收在一起

階段	關鍵動作	判準速查
內容效度	專家評分	$I-CVI \geq 0.78$ 、 $S-CVI \geq 0.90$
項目分析	刪爛題	題總相關 ≥ 0.3
EFA	找構面	$KMO > 0.6$ 、負荷 ≥ 0.4 、平行分析定因素數
CFA	驗結構	$CFI/TLI \geq .95$ 、 $RMSEA/SRMR \leq .06/.08$
信效度	算指標	$AVE \geq .5$ 、 $CR/\omega \geq .7$ 、 $\sqrt{AVE} >$ 構面相關

重點 帶走一句話：量表發展 = 『把抽象概念，用可重現、可驗證的流程，變成一把量得準、分得開、別人也能信的尺』。EFA 找結構、CFA 驗結構、AVE/CR/ ω 給證據、COSMIN 定標準——這正是這一節加給你的能力。

小試身手：讀懂一份量表驗證結果

(參考答案見下一頁)

某團隊自製『長者用藥遵從 App 易用性量表』，報告如下，請判讀：

- Q1 EFA：KMO=0.55、Bartlett $p=0.21$ 。這份資料適合做因素分析嗎？為什麼？
- Q2 他們用『特徵值 >1 』抽出 5 個因素，但有 2 個因素各只有 1 題、且無法命名。你會怎麼建議？
- Q3 CFA 報告：CFI=0.91、RMSEA=0.11、SRMR=0.06。模型適配可接受嗎？哪個指標有問題？
- Q4 某構面 AVE=0.38、CR=0.82。收斂效度 OK 嗎？該怎麼解讀與處理？

重點 提示：Q1 想 KMO/Bartlett 門檻；Q2 想 Kaiser 高估因素數+可解釋性；Q3 想 RMSEA 超標；Q4 想 AVE <0.5 的判讀（Fornell-Larcker 的但書）。

參考答案

判讀重點，實際作答請展開說明

題	參考要點
Q1	不適合。KMO=0.55 偏低 (<0.6)、Bartlett $p=0.21$ 不顯著，代表題目間缺乏足夠共同相關，抽不出有意義的共同因素。應先檢討題目或增樣本，別硬跑 EFA。
Q2	『特徵值 >1 』常高估因素數。單題因素、無法命名=不可解釋。建議改用平行分析+陡坡圖重定因素數，刪除或合併那些單題 / 無法命名的因素，並兼顧理論可解釋性。
Q3	不理想。CFI=0.91 未達 .95；關鍵是 RMSEA=0.11 遠超 0.08，近似誤差過大、適配不佳。不能只挑 SRMR=0.06 好看的講，應依理論修正模型或重檢構面。
Q4	收斂效度不足：AVE=0.38 <0.50 ，構面內題目共同解釋的變異偏低。雖 CR=0.82 高，仍應檢查並刪修低負荷題或重新界定構面（Fornell-Larcker：CR >0.6 時可勉強接受但需說明）。

參考文獻與延伸閱讀

- Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159-174. → κ 分級 (第 10-12 張)
- Koo, T. K., & Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. *J Chiropractic Medicine*, 15(2), 155-163. → ICC
- AERA, APA, & NCME. (2014). Standards for educational and psychological testing. AERA. → 效度證據來源 (第 17 張)
- Polit, D. F., & Beck, C. T. (2006). The content validity index: Are you sure you know what's being reported? *Research in Nursing & Health*, 29(5), 489-497. → CVI
- Boateng, G. O., et al. (2018). Best practices for developing and validating scales for health, social, and behavioral research: A primer. *Frontiers in Public Health*, 6, 149. → 量表發展流程
- Hu, L., & Bentler, P. M. (1999). Cutoff criteria for fit indexes in covariance structure analysis. *Structural Equation Modeling*, 6(1), 1-55. → CFA 適配度
- Fornell, C., & Larcker, D. F. (1981). Evaluating structural equation models with unobservable variables and measurement error. *J Marketing Research*, 18(1), 39-50. → AVE / CR
- Henseler, J., Ringle, C. M., & Sarstedt, M. (2015). A new criterion for assessing discriminant validity in variance-based SEM. *J Academy of Marketing Science*, 43(1), 115-135. → HTMT
- McNeish, D. (2018). Thanks coefficient alpha, we'll take it from here. *Psychological Methods*, 23(3), 412-433. → α 與 ω
- Mokkink, L. B., et al. (2010). The COSMIN study reached international consensus on taxonomy, terminology, and definitions of measurement properties. *J Clin Epidemiol*, 63(7), 737-745. → COSMIN



作業

Take-home Assignment

Measure it right, or the design is wasted.

涵蓋單元 2：操作型定義、信度三型、效度（聚斂／區辨）、四種測量方法、問卷設計。

Part A 觀念題檢驗你「懂不懂」； Part B 實作題檢驗你「測不測得準」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

針對一個構念，產出一份『可信又有效』的測量方案（操作型定義＋量表＋信效度規劃）。

繳交方式

一份 PDF：Part A 文字作答＋Part B 量表與信效度規劃，建議 3-5 頁。

建議時間

約 2-3 小時；先做 Part A 暖身，再進入 Part B 設計。

工具與誠信

可用 AI 協助發想與潤飾，但須附『AI 使用聲明』；引用需標註，禁止代寫與杜撰。

Part A | 觀念題：熟悉變數測量（1/2）

- A1** 用一句話區分信度與效度；為什麼說『效度比信度更根本』？用靶心比喻說明其中一種組合。
- A2** 信度三種檢驗（再測／內部一致性／評分者間）各回答什麼問題？各舉一個檢驗情境。
- A3** 什麼是操作型定義？同一概念可有多個，選擇的準則是什麼？
- A4** 聚斂效度與區辨效度的差異為何？各需要什麼證據？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2-4 句即可，不必長篇。

Part A | 觀念題：熟悉變數測量（2/2）

- A5** 四種測量方法（自陳／表現／觀察／生理）各寫一個優點與一個缺點；什麼情況該併用？
- A6** 為什麼信度低會降低統計檢定力、放大 p 值？低信度時可以怎麼補償？
- A7** 自陳法常見偏誤至少三種，並各寫出一個對策。
- A8** 問卷設計四步驟是什麼？每步用一句話說明『產出什麼』。

Part B | 實作題：設計一份可信可效的測量（1/2）

指示：選一個構念（工作壓力／學習動機／服務品質，或你自己的變數），完成下列各題。

- B1** 寫出該構念的操作型定義；設計一份 5-8 題量表（附量尺），標明每題對應的子構面。
- B2** 規劃如何驗證信度：三型中至少兩型，寫出做法與可接受門檻。
- B3** 規劃如何驗證聚斂與區辨效度：列出『應相關』與『不該相關』的變數各至少一個，並預期相關方向／大小。

教學重點 量表題項必須對得回你的構念定義與子構面——這是內容效度的基礎。

Part B | 實作題：設計一份可信可效的測量（2/2）

- B4** 指出你的測量可能的偏誤（社會期許等）與你的對策。
- B5** 說明你會用數值或類別測量、為什麼；若構念難測，你的替代指標或研究問題微調策略。
- B6** 附一段方法章『測量』小節（150 字內）+ AI 使用聲明。

繳交格式 Part B 建議用『量表題目表+信效度規劃表』呈現，一眼看得出每題測什麼、怎麼驗。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能用靶心／門檻說明
B1 操作化+量表	15%	操作型定義清楚、題項對應子構面、附量尺
B2 信度規劃	15%	至少兩型、做法具體、門檻正確
B3 效度規劃	15%	聚斂與區辨都有、預期方向合理
B4-B6 偏誤+方法+誠信	15%	偏誤與對策對應、方法段可重做、附 AI 聲明

常見扣分 信效度混用、只報 α 就當作『效度良好』、題項與子構面對不上、忘了反向題與匿名。

案例應用：把三個結果變數變成可以測量的東西

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

- ① 本單元教了什麼** 操作型定義、測量尺度，以及信度與效度各自需要什麼證據。
- ② 案例怎麼用**
 - 主要結果定義為：自取得前一班紀錄至開始口頭交班之分鐘數。
 - 以第三方觀察計時，兩位觀察者校準 30 次交班， $ICC = .91$ 。
 - 紀錄完整性以 0 至 20 分評分表測量，兩位評分者獨立評分， $ICC = .84$ 。
 - 認知負荷屬潛在構念，須自編量表並驗證（題目撰寫見 4.3，統計驗證見本單元量表發展節），不可用單題自陳。
四個變數→測量尺度不同，直接決定器二、三、五可用之檢定方法
- ③ 產出什麼證據** 變數操作型定義表（次頁），納入計畫書第 3.4 節「研究工具」。
- ④ 承接關係** 上游：承自 2.1 之研究設計決策表 | 下游：交棒 2.3，據此建立資料字典。

教學重點 操作型定義的檢驗標準只有一個：換一個人來測，會不會得到同一個數字。寫不到這個程度，就不是操作型定義，只是換句話說。

示範產物：變數操作型定義表

六個變數逐一交代定義、尺度、來源與品質證據；缺任一欄即為審查意見來源

變數	角色	操作型定義	尺度	資料來源與品質證據
交班準備時間	主要依變量	自取得前一班紀錄至開始口頭交班之分鐘數	比率	第三方觀察計時；ICC = .91（設定值）
紀錄完整性	次要依變量	8 項必載事項之評分加總，滿分 20 分	等距	兩位評分者獨立評分；ICC = .84（設定值）
二次確認詢問次數	探索性依變量	交班結束後 30 分鐘內接班者回頭詢問之次數	比率	現場計數
自評認知負荷	解釋變項	自編 8 題量表加總，8 至 56 分	等距	$\alpha = .87$ ；重測 ICC = .78（設定值）
導入與否	自變量	該次交班是否發生於該機構導入日之後	名目	系統上線紀錄
職類、年資	控制變項	護理師／資深照服員／單位主管；到職年數	名目／比率	人事資料

教學重點 「二次確認詢問次數」原本不在計畫中，是預試時觀察到才補測的（未列入預先註冊之分析，故屬探索性，見 7.2）——這一欄後來成了本研究最有價值的發現。測量計畫留一點餘裕，比全部鎖死更好。