量性研究方法 · 完整研究專案

單元 5

推論統計

Inferential Statistics — From Sample to Population

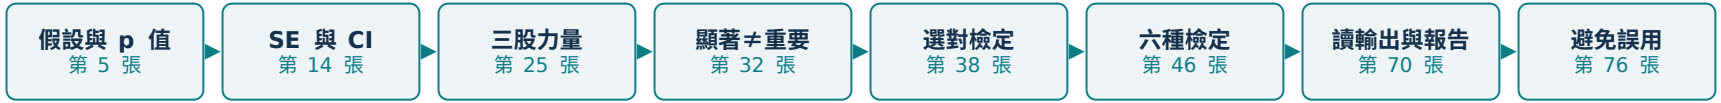
虛無假設與 p 值的邏輯、效應量／變異／樣本數三股力量、六種推論檢定（相關、t 檢定、ANOVA、RM ANOVA、邏輯斯、卡方）與 APA 報告，並避免 p 值誤用

Learning Objectives

本單元結束後，你能……

- 能寫出虛無與對立假設，並依自變量與依變量的型態選出適當檢定。
- 能正確陳述 p 值的定義，並指出至少三種常見誤用。
- 能計算並解讀 95% 信賴區間，說明它與顯著性判斷的關係。
- 能產出含統計量、自由度、精確 p 值、效應量與信賴區間的 APA 報告句。
- 驗收方式 ① 對應作業 A1、A5、B1；② 對應 A1、A8、B5；③ 對應 A3、B3；④ 對應 A5、B3、B6。

本單元怎麼走 推論的邏輯 → 估一個數 → 判斷有沒有差 → 選對檢定 → 算、報、避開誤用



A

推論的核心邏輯

From Sample to Population — The Logic

核心問題：能推論到更大的世界嗎?

承上 單元開場 → **本頁** 推論統計的核心問題：樣本看到的，能推到母體嗎?

- 兩個樣本不會完全相同，但共享某些特徵（如平均值）
- **我們要判斷：樣本中看到的關係，用「若 H_0 為真，出現這種資料的機率有多低」來評估**

虛無假設 H_0

假定「沒有效果／沒有差異／沒有關係」，例如兩組平均相等。差異僅來自隨機巧合。
例：新、舊教學法的平均成績相同。

對立假設 H_1

假定「存在效果／差異／關係」，例如兩組平均不相等。差異是系統性的。
例：新、舊教學法的平均成績不同。

為何「反駁 H_0」而非「證明 H_1」？

承上 要判斷能不能推論 → **本頁** 先假設『沒效果』（H_0），再看資料有多不像——為何反駁 H_0 而非證明 H_1

- **H_0 明確（$\mu_1 = \mu_2$）→ 可建立機率分佈；H_1 模糊（$\mu_1 \neq \mu_2$）→ 無法建唯一模型**
- **p 值 = 「當 H_0 為真時，觀察到這樣（或更極端）資料的機率」**
- p 值不是「H_1 為真的機率」，而是反駁 H_0 的證據強度
- 可證偽性（Popper）：科學假說不能被證明為真，只能被證明為假
- **若 $p < \alpha$（常用 0.05）→ 拒絕 H_0，結果具統計顯著性**

白話：假設檢定是『機率版的反證法』

數學反證法 假設命題為假 → 推出『不可能』的矛盾 → 命題必為真；結論 100% 確定。

假設檢定 假設 H_0（沒效果）為真 → 算出看到這種資料的機率 p → p 很小只代表『很不像』，不是『不可能』
→ 推翻 H_0，但結論永遠帶著 α（例如 5%）的誤判風險，所以不說『證明』。

為何不直接證 H_1 『有效』可以是差 1 分、2 分、10 分……沒有單一數字可算機率；『沒效』只有一種（差＝0），才算得出 p。

H₀ 與 H₁ 怎麼寫：六個生活例子

H₀ ＝沒差、沒關係（有一個確切數字，才算得出 p ）； H₁ ＝你真正想主張的有差、有關係

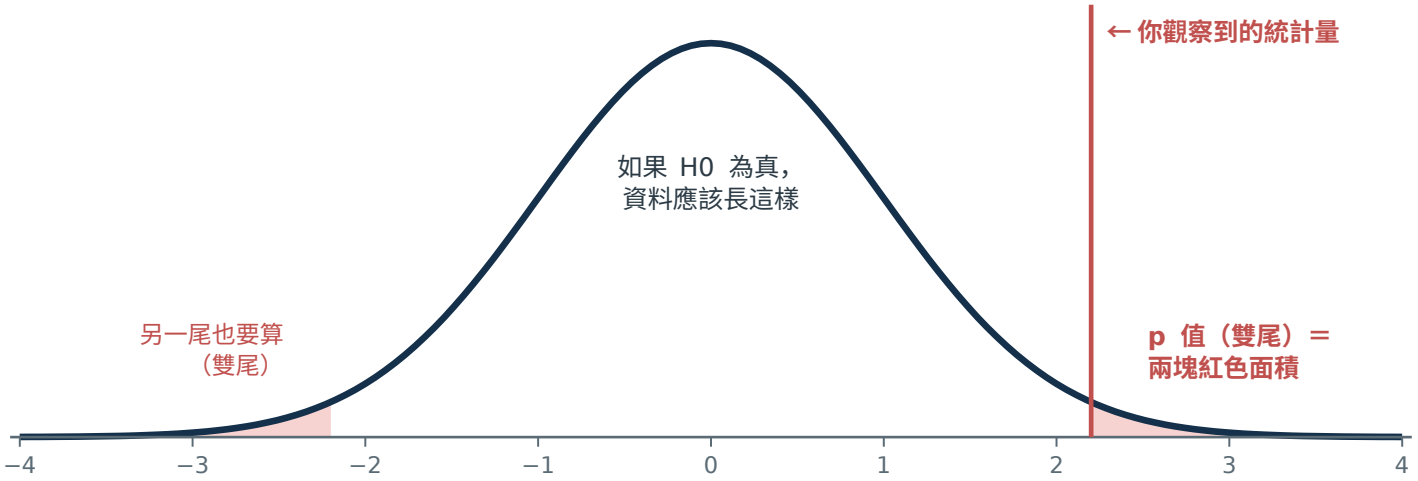
研究問題	H₀ 虛無假設（先假設沒效）	H₁ 對立假設（想證明的）	會用的檢定
新教學法能提高成績嗎?	新、舊教學法平均成績相同（μ 新＝ μ 舊）	平均成績不同（μ 新 ≠ μ 舊）	獨立樣本 t
減重課程前後體重有變嗎?	同一批人前後平均體重相同（平均差＝ 0 ）	前後平均體重不同（平均差 ≠ 0 ）	配對 t
三種運動處方降血壓一樣嗎?	三組平均下降都相同（ μA ＝ μB ＝ μC ）	至少有一組不同	單因子 ANOVA
性別和是否打流感疫苗有關嗎?	性別與接種無關（男女接種率相同）	有關（男女接種率不同）	卡方檢定
睡越久，隔天越專心嗎?	睡眠時數與專注力無關（母體相關 ρ ＝ 0 ）	有關（ ρ ≠ 0 ）	相關 r
年紀越大越少網購嗎?	年齡與是否網購無關（ OR ＝ 1 ）	有關（ OR ≠ 1 ）	邏輯斯迴歸

口訣　H₀ 一律寫『相等、＝ 0 、無關』； H₁ 寫『不同、≠ 0 、有關』。結論只說『拒絕 H₀ 』或『未能拒絕 H₀ 』——不說『接受 H₀ 』，也不說『證明 H₁ 』。

p 值在分佈上長什麼樣

承上 知道 H_0、H_1 怎麼寫 → **本頁** p 值在分佈上長什麼樣：H_0 為真時，結果有多極端

p 值＝在 H0（虛無假設）為真的前提下，看到『這麼極端或更極端』結果的機率



教學重點 p 值不是「H0 為真的機率」，而是「若 H0 為真，看到這麼極端結果的機率」——方向不能反。

p 值直覺：把假設檢定想成一場審判

承上 p 值的定義 → **本頁** 用審判比喻：無罪推定＝ H_0

法庭	假設檢定
無罪推定 先假設被告無罪	→ **H_0** 先假設『沒有效果』
證據 證據越不像無罪，越傾向定罪	→ **你的資料** 資料越不像『沒效果』該有的樣子，越傾向拒絕 H_0
證據有多罕見 若真無罪，會出現這麼不利的證據嗎?	→ **p 值** 若 H_0 為真，看到這麼極端資料的機率
判無罪 ≠ 清白 只是證據不足	→ **不顯著 ≠ 沒效果** 只是證據不足以拒絕 H_0

例 新教學法：若真的沒效，兩班差到 6 分的機率只有 0.8%（$p = .008$）→ 太不像巧合 → 推翻『沒效』

教學重點 $\alpha = .05$ 就像『定罪門檻』：若被告其實無罪，仍有 5% 機率被定罪（Type I）。門檻訂多嚴是價值取捨，非真理。

假設檢定的五個步驟

承上 懂了 p 值的邏輯 → **本頁** 把它變成固定的五個步驟

① 立假設	② 定 α	③ 算統計量	④ 求 p 值	⑤ 下決策
寫 H_0 ／ H_1 決定單／雙尾	願承擔的 偽陽性風險	依資料型態 選 t ／ F ／ χ^2 ／ r	H_0 為真時看到 這麼極端的機率	$p < \alpha$ → 拒絕 H_0 ＋報效應量與 CI

實例：新 vs 舊教學法（第 49 張）

H_0：兩班平均相同 雙尾	**$\alpha = .05$**	**$t(58) = 2.73$**	**$p = .008$**	**$.008 < .05$ → 拒絕 $d = 0.70$、CI [1.6, 10.4]**

教學重點 第 ⑤ 步不是終點——『拒絕 H_0』只說『有差異』，還要用效應量與 CI 說明『差多少、多確定』。

t / F / χ² / r 到底在算什麼?

第③步『算檢定統計量』——各在算什麼? IV ／ DV 要是文字還是數字? 組間、組內、混合各用哪一版?

統計量	在算什麼	IV 型態	DV 型態	組間（不同人分組比）	組內（同一批人重複測）	混合（分組 × 重複測）
t	平均差 ÷ 標準誤	類別・剛好 2 組 （文字：新法／舊法）	數值 （數字：成績）	獨立樣本 t 例：新 vs 舊教學法	配對 t 例：同一批人減重前、後	兩組各算『後−前』 再做獨立 t （F = t²）
F	組間變異 ÷ 組內變異	類別・2 組以上 （文字：A ／ B ／ C 法）	數值 （數字：血壓）	單因子 ANOVA 例：A、B、C 三種教學法	RM ANOVA 例：同一批人前、中、後測	混合 ANOVA 例：治療／控制 × 前／後
χ²	Σ(觀察−期望)²÷ 期望	類別 （文字：男／女）	類別 （文字：買／不買）	卡方獨立性檢定 例：性別 × 是否購買	McNemar （配對版 χ²） 例：同一批人介入前後有無運動	—（超出本單元，見 8.2）
r	兩個數值一起變動的程度（−1 ～ +1）	數值 （數字：睡眠時數）	數值 （數字：專注力）	不分組：同一群人身上各量兩個變數，看是否一起高、一起低		

文字還是數字? 類別＝用文字分組（男／女、A ／ B ／ C 組），就算登錄成 1、2 也還是類別；數值＝能加減、算平均的量（分數、血壓、時數）。
三種設計 組間＝不同的人分在不同組；組內＝同一批人測好幾次；混合＝既分組又重複測。數值 IV × 類別 DV 則用邏輯斯迴歸（第 64 張）。

重點 四者都是『訊號 ÷ 雜訊』家族：算出統計量後，再對照它的分佈查 p 值，判斷是否顯著。

推論要做兩件事

承上 五步驟要用到分佈 → **本頁** 推論其實要做兩件事：估一個數、判斷有沒有差

① 推論單變量統計

- 問：母體的平均值大概在哪裡?
- 由「樣本平均」估計「母體平均」
- 受兩股力量影響：變異、樣本數
- 例：抽 100 位護理師，平均壓力 21 分 → 全國護理師平均大約在哪?
- **答案是一個範圍：標準誤、 95% 信賴區間（第 14–23 張）**

② 推論變量間的關係

- 問：母體中各組平均是否真的不同?
- 由「樣本中的關係」推論「母體的關係」
- 受三股力量影響：效應量、變異、樣本數
- 例： App 組比等候組低 3.8 分 → 母體裡 App 真的有效，還是抽樣巧合?
- **答案是顯著與否： t 、 F 、 χ^2 、 r 與 p 值（第 25 張起）**

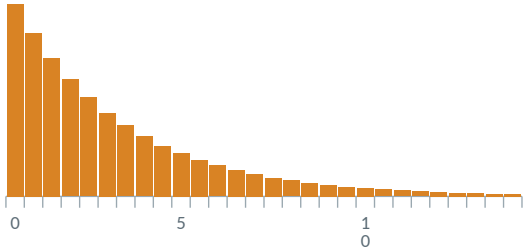
重點 ①是『估一個數』（答案是區間），②是『判斷有沒有差』（答案是顯著與否）。先打好①的地基，再進入②——②才是論文結果章的主角。

中央極限定理：為什麼可以用常態

承上 先做『估一個數』 → **本頁** 為什麼可以用常態分佈：中央極限定理

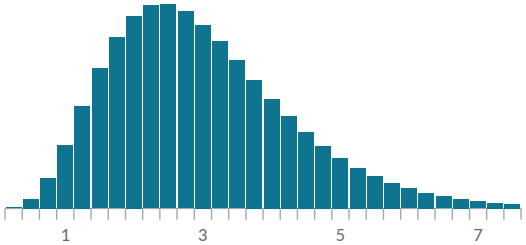
不管母體長什麼樣，樣本平均的分佈都會趨近常態，而且 n 越大越窄

母體（明顯右偏，平均 3）



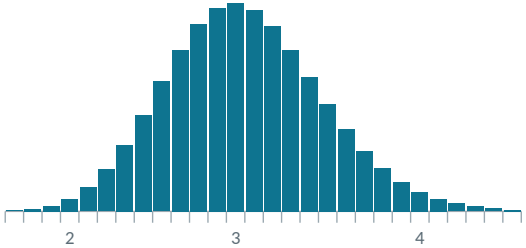
→

樣本平均的分佈（每次抽 n = 5）



→

樣本平均的分佈（每次抽 n = 50）



每根柱＝『個人』的值落在該區間的比例：多數人很低、少數人很高 → 明顯右偏。

每次隨機抽 5 人、算 1 個平均，重複上萬次，把這些『平均』畫成圖：已往中間集中，但仍有點歪。

改成每次抽 50 人：平均的分佈幾乎是對稱的鐘形，而且更窄（都擠在 3 附近）。

教學重點 這就是「用樣本推論母體」的理論基礎： n 越大，樣本平均的分佈越窄也越常態。

三個關鍵量：中英對照與白話

第 11 張『推論要做兩件事』提到的變異、樣本數、效應量，到底指什麼?

變異 Variation

定義 每個資料點離平均有多遠的整體程度，常用標準差 SD。
用意 代表『雜訊』：雜訊越大，越難看出真正的差異。
例 兩班平均都 75 分；A 班 SD = 3、B 班 SD = 15，B 班亂得多。

樣本數 Sample Size

定義 實際測量的觀察單位數（人、病人、事件），記為 N 或 n。
用意 決定估計多精確：SE = SD ÷ √N，人越多越穩。
例 同樣 SD = 10：N = 25 時 SE = 2；N = 100 時 SE = 1。

效應量 Effect Size

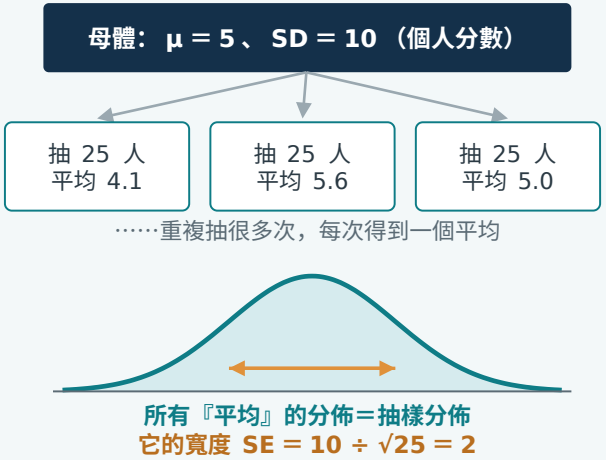
定義 差異或關聯的實際大小，不受樣本數影響；如 Cohen's d = 平均差 ÷ SD。
用意 回答『差多少、值不值得在意』；p 值只回答『像不像巧合』。
例 平均差 6 分、SD 8.5 → d = 0.70（中到大）。

重點 估平均只看變異＋樣本數；比較／關聯再加上效應量。三者合成一條式：$t \approx d \times \sqrt{(n \div 2)}$（d = 平均差 ÷SD，各組 n 人）。例 d = 0.70、各 30 人 → t ≈ 2.71（第 49 張實算 2.73）。

抽樣分佈與標準誤：推論的地基

承上 三個關鍵量 → **本頁** 推論的地基：抽樣分佈與標準誤

抽樣分佈 反覆抽樣、每次算一個樣本平均，這些『平均』排成的分佈（右圖）。
中央極限定理 N 夠大時抽樣分佈近似常態；母體不太偏時約 30 即可，極度偏斜需更多（第 12 張）。
標準誤 SE 抽樣分佈的寬度（標準差）＝ SD ÷ √N，量『樣本平均通常離母體平均多遠』。
SD vs SE SD 描述『個人』之間的差異；SE 描述『平均』之間的差異—— N 越大 SE 越小，SD 不變。
例 SD ＝ 10、每次抽 25 人：個人分數常在平均 ±20 內（約 2 SD），樣本平均只在 ±4 內（約 2 SE，SE ＝ 2）。

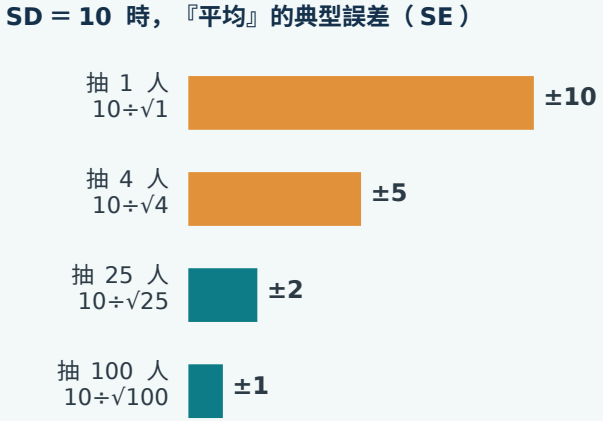


教學重點 所有推論（t、CI、p）都建立在抽樣分佈上：SE 越小，樣本平均越可信，越能偵測真實差異。

標準誤直覺：為什麼『平均』比『單一資料』可信

承上 SE 的定義 → **本頁** 直覺：為什麼『平均』比『單一資料』可信

單一測量會抖 量一次身高，可能因姿勢、儀器而差 1–2 公分。
取平均會穩 量很多次再平均，高估與低估互相抵消，越接近真值。
SE 就是在量這個 SE = SD ÷ √N： N 越大，『樣本平均』的抖動越小。
實感例子 SD = 10 的母體：只抽 1 人，估計常差約 10；抽 100 人取平均，常差只剩約 1（右圖）。
注意 人數變 4 倍，誤差才減半——所以 25 → 100 人很有感，100 → 400 人效益就小了（第 18 張）。



教學重點 『大樣本較可信』的直覺不是資料變乖了，而是『平均』這個估計本身變穩了——這正是所有推論的地基。

推論單變量：兩條規則

承上 SE = SD ÷ √N → **本頁** 推論單一變數的兩條規則：變異、樣本數

規則 1：變異越大，估計越飄

- 母體變異越大，樣本平均越容易偏離母體平均
- 最壞情況：抽到極端值，樣本平均偏很多
- 例：母體平均 = 5，若變異大，N=1 可能抽到 9
- 對照（每次都抽 25 人）：SD = 2 的母體，平均多在 4.2–5.8；SD = 10 的母體，平均可散到 1–9（下一張左圖）

規則 2：樣本越大，估計越穩

- 樣本數越大，樣本平均越接近母體平均
- N=1 → 很不穩；N=2、3… → 逐漸收斂
- 若 N 很大（如 100000），單點的影響幾乎消失
- 對照（母體 SD 都是 5）：每次抽 4 人，平均可散到 0–10；每次抽 100 人，平均多在 4–6（下一張右圖）

重點 兩條規則其實是同一條式子：SE = SD ÷ √N。SD 大 → SE 大（規則 1）；N 大 → SE 小（規則 2）。之後推論『關係』也一樣。

Two Rules · 示意圖

兩條規則，看圖就懂

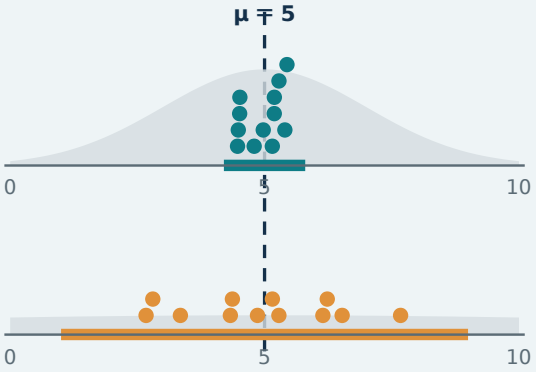
左圖只改母體 SD、右圖只改每次抽幾人 N；每個點＝抽一次樣本算出的平均（各抽 12 次）

規則 1：變異越大，估計越飄

固定每次抽 N = 25 人，只改母體 SD

SD = 2（小變異）
SE = 2÷√25 = 0.4
平均多在 4.2–5.8

SD = 10（大變異）
SE = 10÷√25 = 2
平均多在 1–9



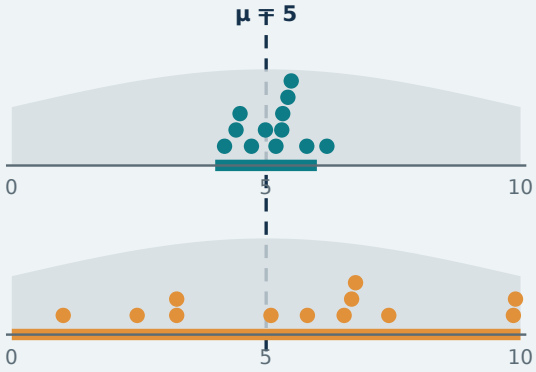
灰色山＝個人分數的分佈： SD 大，山就攤得很開

規則 2：樣本越大，估計越穩

固定母體 SD = 5，只改每次抽幾人 N

N = 100（大樣本）
SE = 5÷√100 = 0.5
平均多在 4–6

N = 4（小樣本）
SE = 5÷√4 = 2.5
平均多在 0–10



兩列的灰色山一樣（SD 沒變），差別只在每次抽幾人

重點 兩張圖點的散布都由 SE = SD÷√N 決定：左圖因 SD 變大而散開，右圖因 N 變小而散開。 SD 常受母體與測量限制； N 是研究者最能主動控制的旋鈕。

標準誤完整範例： N 如何讓估計變穩

母體標準差 SD = 10

樣本數 N	標準誤 SE = SD ÷ √N	95% 誤差範圍 ≈ ±1.96×SE
N = 25	10 ÷ √25 = 10 ÷ 5 = 2.0	±3.9
N = 100	10 ÷ √100 = 10 ÷ 10 = 1.0	±2.0
N = 400	10 ÷ √400 = 10 ÷ 20 = 0.5	±1.0

怎麼讀 SE ＝樣本平均每次抽樣會晃多少；誤差範圍 ±1.96×SE ＝ 95% 的樣本平均會落在母體平均的這個距離內。
看趨勢 N 從 25 → 100 （×4），SE 從 2.0 → 1.0 （減半）； N 再 ×4 到 400， SE 才再減半為 0.5—— 加人的效益越來越小。

教學重點 SE 隨 √ N 縮小——要把精度加倍（SE 減半），樣本數要變 4 倍。這就是『大樣本較穩』的數學根據。

那張表的第 2、3 欄是怎麼算出來的?

以母體 SD = 10、N = 100 這一列逐步拆解

第 2 欄　SE = SD ÷ √N

意思：平均值的估計誤差（標準誤）。
SD 是資料分散度，√N 讓大樣本更穩。

以 N=100:
SE = 10 ÷ √100 = 10 ÷ 10 = 1.0

N 變 4 倍 (400)→ √N 變 2 倍
→ SE 減半 (0.5)。

第 3 欄　95% 誤差範圍 ≈ ±1.96 × SE

意思：平均值上下大約這麼多，
就有 95% 的信心涵蓋母體平均。

以 N=100:
±1.96 × 1.0 ≈ ±2.0

1.96 來自常態分佈的『中間 95%』
（下一頁專門說明）。

重點　一句話：先用 SD 與 √N 算出『一個 SE』，再乘 1.96，得到『95% 的誤差範圍』。

信賴區間：不只給一個點，還給一個範圍

承上 SE 怎麼算 → **本頁** 把 SE 變成一個範圍：信賴區間

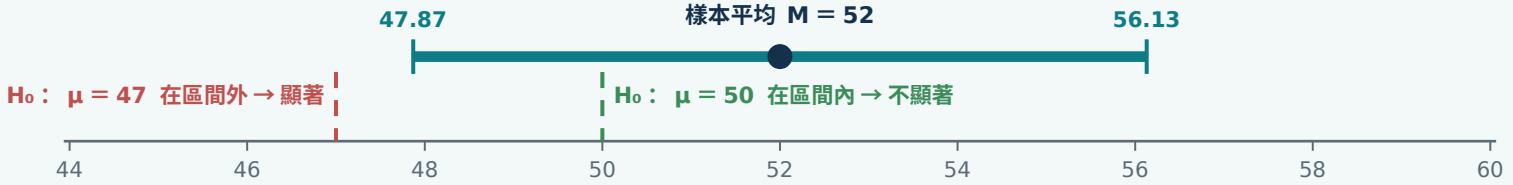
公式 95% CI ＝樣本平均 ± 臨界值 × SE。大樣本臨界值≈ 1.96 （為什麼是 1.96 見下一張）；小樣本、母體 σ 未知時改用 t 值（第 22 張）。

正確解讀 若用同樣方法重複抽樣很多次，約 95% 的區間會罩住真正的母體平均。

常見誤解 不是『母體平均有 95% 機率落在此區間』——母體平均是固定的，會變的是區間。

與檢定的關係 虛無值（如 H_0： μ ＝ 50 ）落在 95% CI 之內 ↔ 雙尾 p ≥ .05 不顯著；落在之外 ↔ p < .05 顯著。

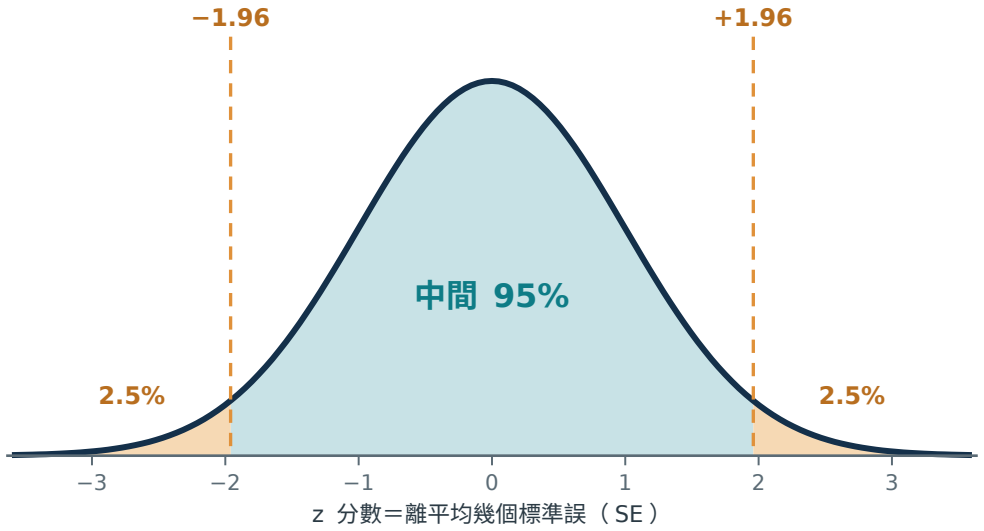
例（第 22 張） M ＝ 52 、 SE ＝ 2.0 、 N ＝ 25 → 95% CI [47.87, 56.13]： 母體平均很可能在 48 到 56 之間（下圖）。



教學重點 CI 比單一 p 值資訊更多：同時給你『效應方向、大小與精確度』——期刊越來越要求報 CI 。

1.96 是怎麼來的?

承上 CI 公式裡的 1.96 → **本頁** 1.96 是怎麼來的



怎麼讀這張圖

① 曲線下總面積＝ 100%，橫軸是離中心幾個 SE。
② 從中間往兩邊擴，圍到 95% 面積時停下——停的位置就是 ±1.96。
③ 所以樣本平均有 95% 機會落在 μ ± 1.96 SE 內；反過來，『樣本平均 ± 1.96 SE』就有 95% 機會罩住 μ＝95% CI。

信心水準	兩尾各切	臨界值 z
90%	5%	±1.645
95%	**2.5%**	**±1.96**
99%	0.5%	±2.58

重點 要涵蓋『中間 95%』，就要切掉兩尾各 2.5%—— 這兩個切點的 z 分數正好 ≈ ±1.96。要 99% 則用 ±2.58。

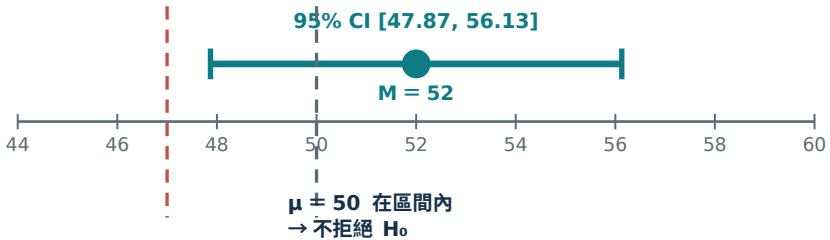
信賴區間完整範例＋判讀

樣本：M = 52 、 SD = 10 、 N = 25

1 **算 SE** 10 ÷ √25 ＝ 2.0

2 **算 95% CI** σ 未知 → 用 t(24) = 2.064 （非 1.96）： 52 ± 2.064 × 2.0 ＝ 52 ± 4.13

3 **解讀** 長期重複抽樣，約 95% 的區間會涵蓋母體平均（不是『μ 有 95% 機率在裡面』）



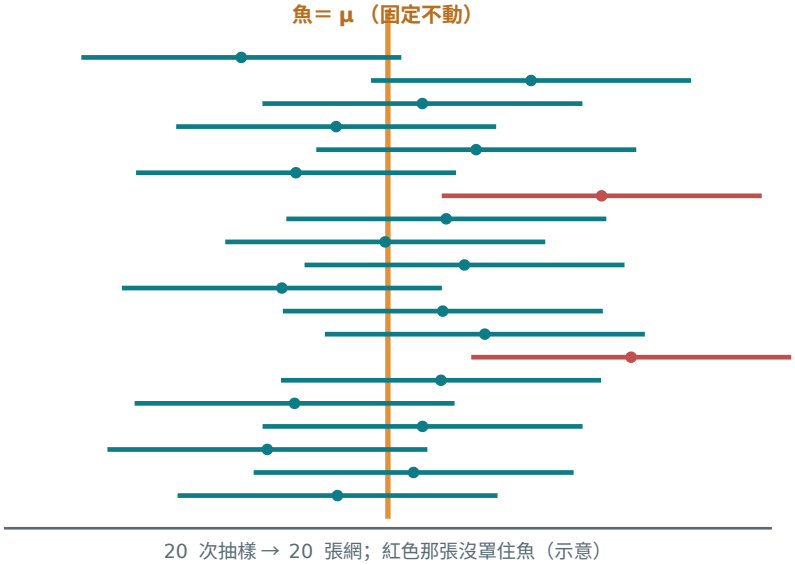
μ = 47 在區間外
→ 拒絕 H₀

CI 看兩件事：中心（估計多少）＋寬度（多不確定）； N 越大、 SD 越小 → 越窄

教學重點 CI 寬度＝不確定性： N 越大、變異越小，區間越窄、估計越精確。窄而明確的 CI 比『只報 p<.05 』更有說服力。

信賴區間直覺：撒網捕魚

承上 會算 CI → **本頁** 直覺：95% 指的是『網』，不是『魚』



20 次抽樣 → 20 張網；紅色那張沒罩住魚（示意）

魚是固定的
母體平均 μ 就在某個位置，不會動

網會動
每次抽樣＝撒一次網（一個 CI），位置隨樣本而變

95% 的意思
這樣撒 100 次網，約 95 次罩住魚；20 年約 19 次

常見誤解
不是『魚有 95% 機率在這張網裡』——魚固定、網才隨機

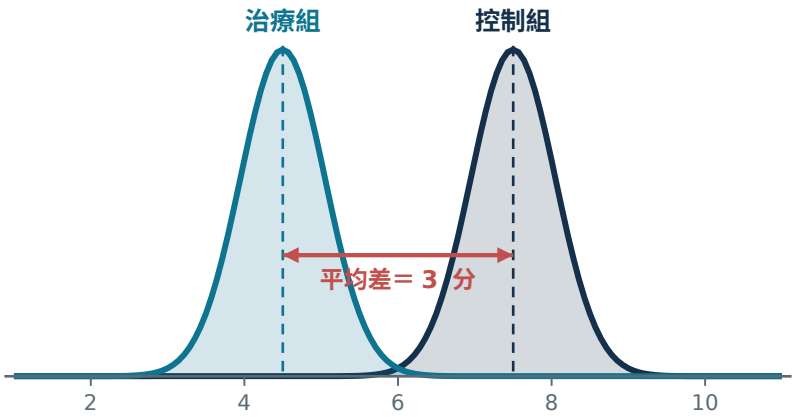
教學重點 所以看到一個 95% CI，別說『μ 有 95% 機率落在此區間』；而是『這個程序長期有 95% 的涵蓋率』。

Little vs. Lots of Variation

變異大小如何影響「能否推論」

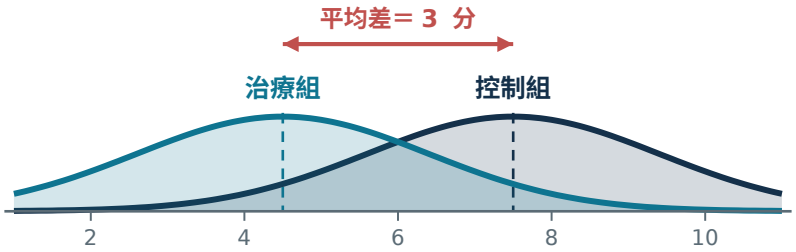
承上 『估一個數』講完 → **本頁** 第二件事『判斷有沒有差』：先看變異的影響

變異小 → 差異清楚、可推論



兩座山幾乎不重疊 → 差異看得清楚，容易顯著

變異大 → 差異被雜訊蓋住



兩座山大量重疊 → 差異被雜訊蓋住，難以顯著

重點 兩邊「平均差」一樣，但左邊變異小、兩座山不重疊 → 容易顯著；右邊變異大、兩座山重疊 → 難以顯著。

推論關係的三股力量

承上 變異會蓋住差異 → **本頁** 推論關係的三股力量：效應量、變異、樣本數

1

效應量 Effect Size

組間差異的實際大小；越大越易達顯著。

越大越好

2

變異性 Variation

資料的波動程度；越小結果越穩定。

越小越好

3

樣本量 N

越大檢定力（power）越強，越能偵測小效應。

越大越好

重點 三者共同決定 p 值：效應大、變異小、樣本大 → p 值小 → 越可能推論到母體。

三股力量，用一個比喻＋一組數字看懂

承上 三股力量 → **本頁** 一個比喻＋一組數字：為什麼它們決定 p

比喻 p 值像『訊號 vs 雜訊』：訊號＝效應量（差多大）；雜訊＝變異 ÷ 樣本（估得多不準）。訊號蓋過雜訊 → p 小。

同樣是『平均差 4 分』 若 SD=20、每組 n=10（雜訊大）→ t≈0.45，差被淹沒 → p≈.66 不顯著。

若 SD=5、每組 n=100（雜訊小）→ t≈5.7，同樣 4 分清楚浮現 → p<.001 顯著。

三個旋鈕 效應量↑、變異↓、樣本數↑，任一個都讓 p 變小；研究設計能主動控制的是後兩個。

算給你看 t＝平均差 ÷ SE，兩組各 n 人時 SE = SD × √(2÷n)；平均差都是 4 分

雜訊大：SD = 20、各 10 人
SE = 20 × √0.2 ≈ 8.94
t = 4 ÷ 8.94 ≈ 0.45 → p ≈ .66 不顯著

雜訊小：SD = 5、各 100 人
SE = 5 × √0.02 ≈ 0.71
t = 4 ÷ 0.71 ≈ 5.7 → p < .001 顯著

重點 所以『不顯著』不一定沒效果——可能是變異太大或樣本太小，把真效果蓋住了。

為什麼門檻是 0.05？

承上 p 怎麼來 → **本頁** 判斷顯著的門檻 α 為什麼是 .05

門檻（α）＝「把其實無效的結果，誤判為顯著」的可接受機率。

- α = 0.05 → 你接受「5% 誤判為顯著」的風險
- α = 0.01 → 更嚴格，誤判機率降到 1%（需要更強證據）
- **多數科學家認為 5% 的誤判風險「夠好」，因此以 0.05 為慣例門檻**
- 門檻不是真理，而是一個「群體共識的決策線」——不同領域可能不同
- 例：20 種其實無效的藥各做一次試驗（α = .05），平均約有 1 種會『顯著』——那 1 種就是偽陽性。
- 一次做很多檢定時（如上萬個基因），門檻要再調嚴，見第 77 張多重檢定。

單尾 vs 雙尾檢定：方向要不要事先決定

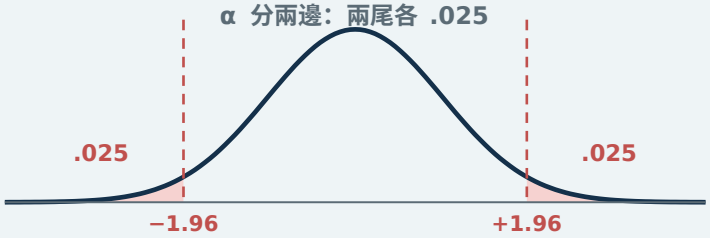
承上 門檻 .05 → **本頁** 這 5% 放一邊還是兩邊：單尾 vs 雙尾

雙尾檢定（預設）

H_1： $\mu_1 \neq \mu_2$（沒指定方向）。

α 分到兩尾（各 .025）。

適用：不確定方向、要偵測任一方向差異。

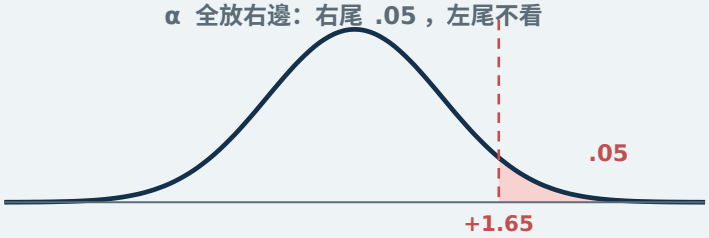


單尾檢定

H_1： $\mu_1 > \mu_2$（事先指定方向）。

α 全放一尾 → 同樣 α 下檢定力較高。

限制：只能在有強理論依據、且事先決定時使用。

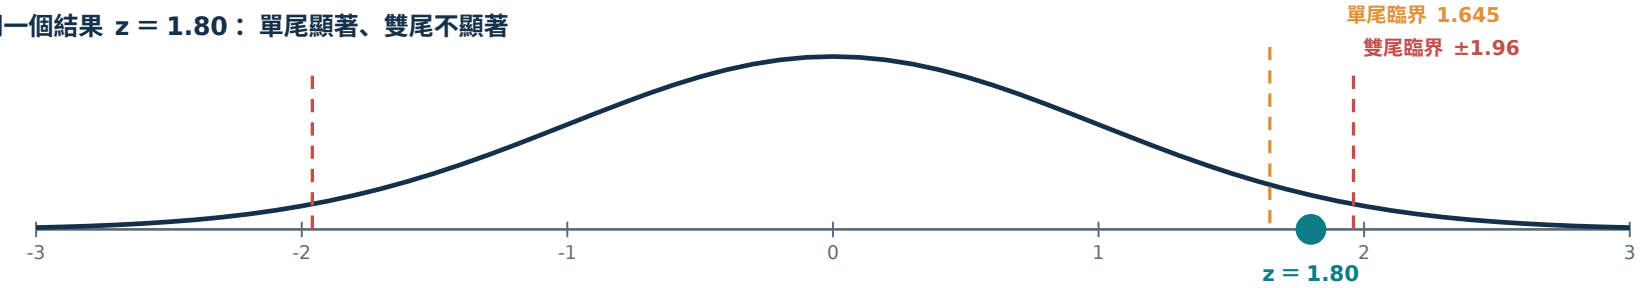


教學重點 單尾『看到資料才改成單尾』是作弊（會膨脹偽陽性）。除非事前有明確方向假設，否則用雙尾較保守、可信。

單尾 vs 雙尾：白話版與兩個例子（承前頁定義）

承上 單尾、雙尾的定義 → **本頁** 白話版與兩個例子

同一個結果 z = 1.80：單尾顯著、雙尾不顯著



雙尾（預設）：有沒有『不同』？
例：新藥 vs 安慰劑，H_1：藥效 ≠ 安慰劑
藥反而更差也抓得到
z = 1.80 → p = .072，不顯著

單尾：是不是『特別好』？
例：H_1：藥效 > 安慰劑，只看一個方向
藥若更差，你不會發現它有害
z = 1.80 → p = .036，顯著

重點 口訣：沒有事前的強方向假設 → 一律用雙尾。

兩種錯誤與檢定力：推論一定會冒的風險

這張表在 2.3 第 21 張出現過；這裡用它來讀懂：顯著、不顯著，各自可能錯在哪

真實 ＼ 你的判定	拒絕 H_0（宣稱有差異）	未拒絕 H_0（證據不足，非證明無差異）
H_0 為真（其實無差異）	✗ Type I （α，偽陽性）	✓ 正確（1−α）
H_0 為假（其實有差異）	✓ 檢定力 Power （1−β）	✗ Type II （β，偽陰性）

Type I 例 藥其實無效，你卻說有效 → 病人吃沒用的藥

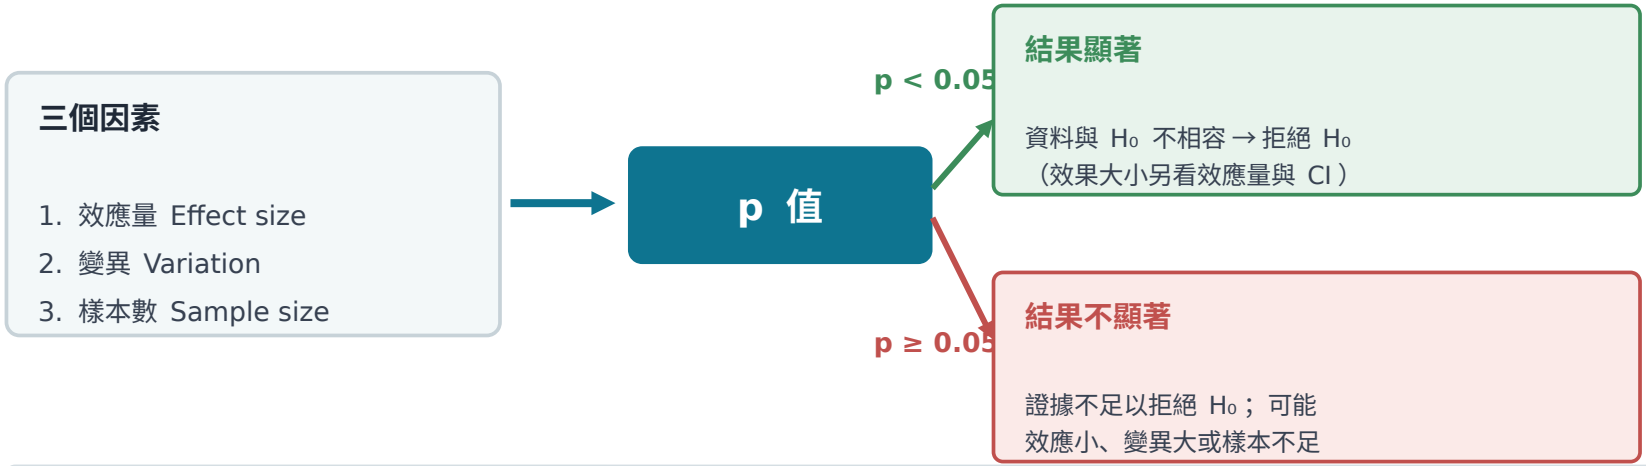
Type II 例 藥其實有效，你卻說沒差 → 好藥被放棄

怎麼用： ① 檢定前先定 α （第一列錯誤上限）② 規劃樣本數讓 Power ≥ .80 （2.6）③ 讀結果：顯著仍可能是 Type I，不顯著可能是 Type II → 看效應量與 CI

教學重點 α 管『偽陽性』、β 管『偽陰性』、Power = 1−β。要 α 更嚴（.01）就得付出更高 β，或加大樣本補回檢定力。

從三因素到 p 值的判斷流程

承上 p、門檻、兩種錯誤都講過 → **本頁** 從三因素一路到判斷顯著的流程



例（第 49 張） 新 vs 舊教學法：平均差 6 分、d = 0.70（效應量）；合併 SD 8.51（變異）；每組 30 人（樣本數）→ t(58) = 2.73，p = .008，顯著。

對照 同樣 6 分差距、同樣 SD，若每組只收 8 人：t 約 1.41、p 約 .18 → 不顯著。差的不是效果，是樣本數。

重點 效應量、變異性、樣本數共同決定 p 值：$p < .05$ → 資料與 H_0 不相容，拒絕 H_0；$p \geq .05$ → 證據不足以拒絕 H_0，不等於沒有效果。

統計顯著 ≠ 實務重要

承上 會判斷顯著了 → **本頁** 但顯著 ≠ 重要

p 只回答
『和 H_0 相不相容』，N 大時小差異也顯著

效應量回答
差多少、關聯多強（d、η^2、r、OR）

CI 回答
多確定；貼著 0 就算顯著也要謹慎

最後問
這個效果在你的領域值不值得在意?

效果	$p < .05$	$p \geq .05$
大	**顯著＋效果大** 研究 B： N = 40、d = 0.90 **值得在意**	**不顯著＋效果大** 復健 40 公尺、只收 8 人 **可能只是樣本太小**
小	**顯著＋效果小** 研究 A： N = 10,000、d = 0.05 **大樣本陷阱**	**不顯著＋效果小** 可能真的沒什麼

教學重點 結果一律『三件一起報』：檢定統計量＋精確 p 值＋效應量（與 CI）——只報 p 是不完整的。

顯著 ≠ 重要：兩個生活化例子

承上 顯著 ≠ 重要 → 本頁 兩個生活化例子

① 顯著但不重要

App 讓每日步數平均多 12 步，n = 50,000

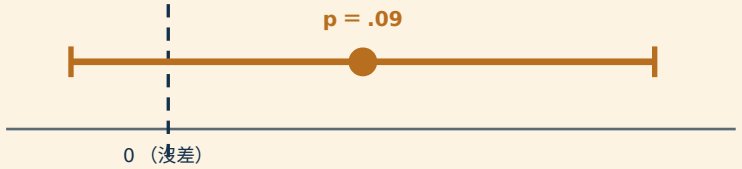


CI 很窄、離 0 不遠，但『12 步』對健康幾乎沒差

區間為示意

② 重要但未達顯著

新復健讓行走距離多 40 公尺，只收 8 人



CI 很寬、跨過 0：效果可能真實，只是樣本太小沒測出

區間為示意

重點 『有沒有差』(p) 與『差多少、值不值得』（效應量）是兩個不同問題，兩個都要回答。

效應量 vs p 值：兩個研究看懂差別

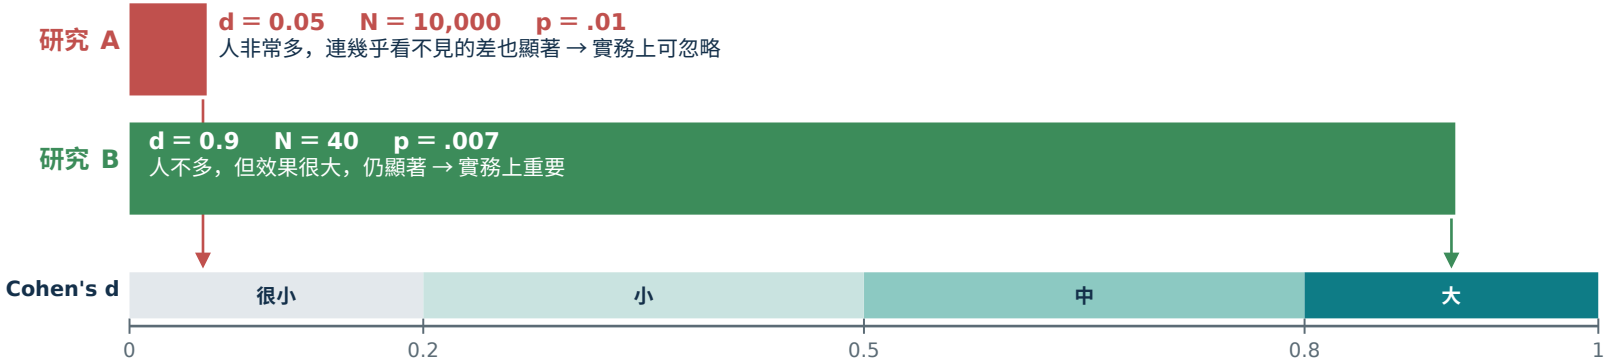
承上 生活例 → **本頁** 兩個研究並排：效應量 vs p 值

	研究 A	研究 B
樣本數 N	10,000	40
效應量 Cohen's d	0.05 （幾乎沒差）	0.90 （很大）
p 值	p = .01 （顯著）	p = .007 （顯著）
實務意義	幾乎沒用——大 N 讓微小差異也顯著	重要——效果大，小樣本仍達顯著

教學重點 只看 p 會把 A、B 當一樣；看效應量與 CI 才知道 A『顯著但沒意義』、B『顯著且重要』——這就是一定要報效應量的原因。

把上頁兩個研究讀成白話

承上 兩個研究的數字 → **本頁** 讀成白話



關鍵 **p 會被 N 放大；d 不會。** d 才是跨研究可比較的『效果大小』（0.2 小、0.5 中、0.8 大）

重點 只報 p、不報 d 與 CI，審稿人通常會要求補——因為讀者無法判斷 A 與 B 的差別。

各檢定的效應量一覽與基準

承上 一定要報效應量 → **本頁** 各檢定的效應量一覽與基準

檢定	效應量	小 / 中 / 大（粗略基準）
t 檢定	Cohen's d	0.2 / 0.5 / 0.8
ANOVA	η^2（或 partial η^2）	.01 / .06 / .14
相關 / 迴歸	r（r^2 為解釋變異）	.10 / .30 / .50
邏輯斯迴歸	勝算比 OR	≈1.68 / 3.47 / 6.71（Chen et al., 2010；基準率 1%）
卡方	Cramér's V	.10 / .30 / .50（df=1）



教學重點 效應量與『樣本數無關』，所以能跨研究比較、放進統合分析（meta-analysis）；p 值則會隨 N 變。

B

選對統計檢定

How to Apply Inferential Statistics

選擇統計檢定的決策表

承上 A 段：推論的邏輯 → 本頁 B 段：依 IV、DV 型態選對檢定

IV	DV	檢定方法
類別（2 組）	數值	t 檢定
類別（≥ 3 組，組間）	數值	單因子 ANOVA
類別（≥ 3 組，組內／混合）	數值	重複量數 ANOVA （RM ANOVA）
數值	數值	皮爾森相關 / 迴歸
數值	類別	邏輯斯迴歸
類別	類別	卡方檢定

先選檢定 → 考慮效應量、變異、樣本數 → 算出 p 值 → 判斷 H_1 或 H_0。（IV／DV 屬哪一種，看測量尺度——見 2.2）

檢定的基本假設：先檢查再解讀

承上 選好檢定 → **本頁** 跑之前先檢查它的假設

檢定	主要假設	違反時怎麼辦
t / ANOVA	常態性、變異數同質、獨立	Welch 校正；或改無母數
相關 / 迴歸	線性、常態、等分散 (homoscedasticity)	轉換變數；或用 Spearman
卡方	期望次數 <5 的格 ≤ 20% 且無 <1 、觀察獨立	合併類別；或 Fisher 精確檢定

教學重點 假設不是形式：變異數嚴重不同質或小樣本非常態時，硬跑 t/ANOVA 的 p 值不可信——先看圖與檢定（如 Levene ）。

假設違反了，實際怎麼處理?

承上 檢定的假設 → **本頁** 違反了怎麼辦：實例

	發現問題	改用
常態性	小樣本又嚴重偏態	→ 改無母數： Mann-Whitney （兩組）／ Kruskal-Wallis （多組）
變異數同質	兩組 SD 差很多（如 3 vs 12 ）	→ 用 Welch t ／ Welch ANOVA （不假設同質）
期望次數 < 5	卡方某格期望人數太少	→ 合併類別，或改 Fisher 精確檢定
怎麼先發現	先畫圖（直方圖／箱型圖）	→ 再跑 Levene （同質）、 Shapiro （常態）

重點 假設不是官僚手續：嚴重違反時 p 值會失真——先檢查、再解讀。

無母數替代：資料不符假設時的備案

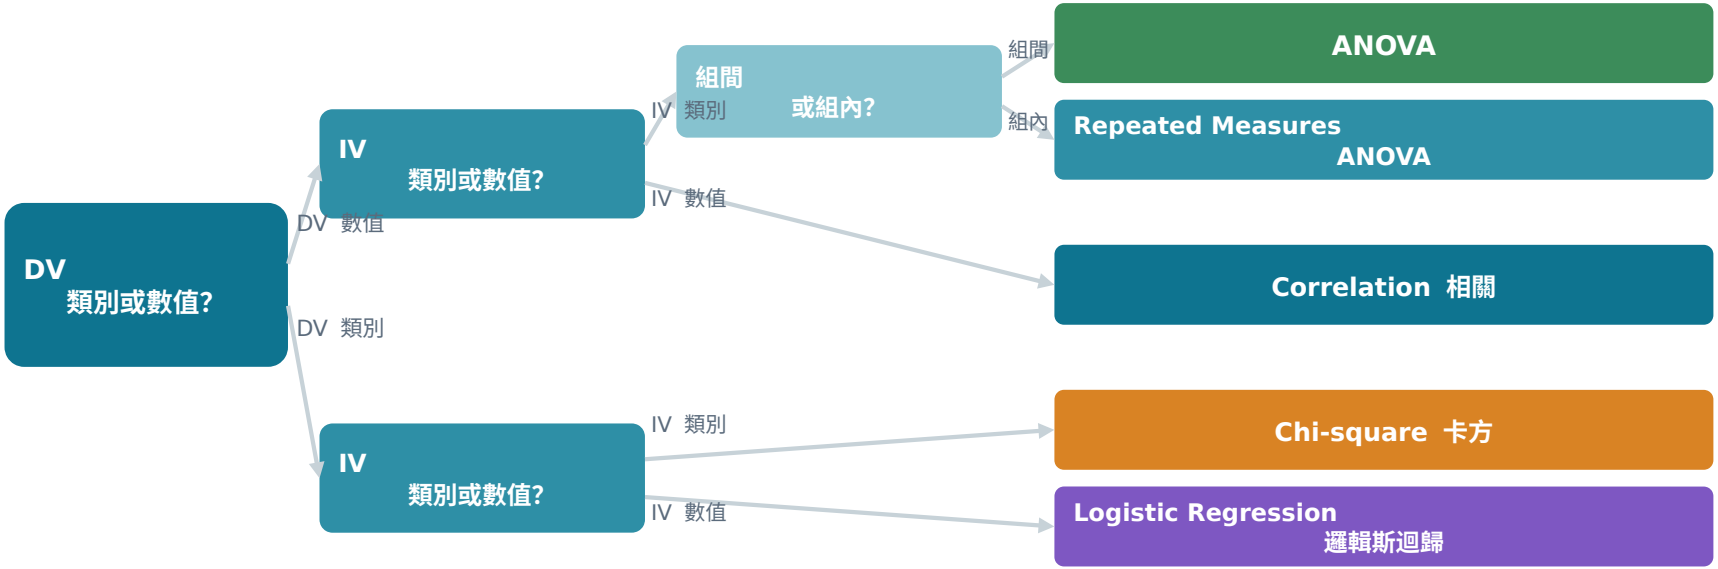
承上 違反假設 → **本頁** 無母數替代方案一覽

母數檢定	無母數替代	用於
獨立樣本 t	Mann–Whitney U	兩組、非常態或序位資料
配對 t	Wilcoxon signed-rank	前後、非常態
單因子 ANOVA	Kruskal–Wallis	≥3 組、非常態
Pearson r	Spearman ρ	序位或非線性單調關係

教學重點 無母數檢定用『排序』而非原始值，對離群值與偏態較穩健；代價是檢定力略低、且比較的是中位數 / 分佈位置。

統計檢定決策樹

承上 決策表與替代方案 → **本頁** 整理成一棵決策樹



重點　口訣：先定 DV 型態，再看 IV 型態與組數，一路往下即可決定：相關、t 檢定（2 組，即 ANOVA 的特例）、ANOVA、RM ANOVA、卡方或邏輯斯迴歸。

顯著代表什麼？取決於研究設計

承上 檢定選好了 → **本頁** 顯著能說到什麼程度？取決於研究設計

無混淆的實驗

- **H_1：治療「造成」了差異（只有一種因果解釋）**
- H_0：兩組母體無差異
- 顯著 → 可下「因果」結論

非實驗（無隨機化）

- **H_1：可能是治療影響疾病、疾病影響治療，或第三變項**
- H_0：兩組母體無差異
- 顯著 → 只能下「關聯」結論，不能斷定因果

重點 同樣是「$p < 0.05$」，實驗能談因果、非實驗只能談關聯——回想單元 1 的三種因果解釋。

實驗 vs 非實驗：白話與例子

承上 實驗 vs 非實驗 → **本頁** 白話與例子：差在有沒有隨機分派

實驗 Experiment

研究者『主動操弄』 IV，並『隨機分派』
受試者到各組。

例：把 60 位病人隨機分到
App 組／等候組。

→ 兩組事前條件平均相同，若有差，
可歸因於介入 → 可談因果。

非實驗 Non-experiment （觀察型）

研究者『只觀察、不操弄』，
分組是既存的。

例：比較『本來就有用 App』
vs 『沒用』的人的壓力。

→ 兩群人可能本來就不同（年齡 / 動機），
差異或來自第三變項 → 只能談關聯。

重點 同樣 $p<.05$，實驗能說『造成』，非實驗只能說『有關聯』——差別在研究設計，不在統計。

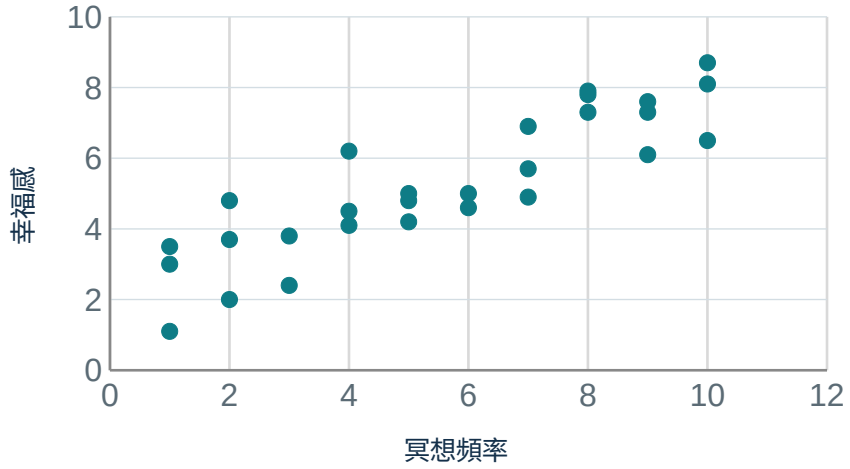
C

六種推論檢定

Six Inferential Tests

① 相關的推論（數值 IV × 數值 DV）

承上 B 段：選檢定 → 本頁 C 段：六種檢定逐一走過，先從相關開始



- **r = 0.88：強正相關（r 介於 −1 ~ 1）**
- 勾選 report significance 取得 p 值
- $p < 0.001$ → 顯著，可拒絕 H_0
- r(28)：括號內為自由度（= N−2）
- 資料：30 人每週冥想次數（IV）與幸福感分數（DV），圖上每一點＝一個人

APA 報告：r(28) = .88, p < .001

① 相關推論完整範例： r 顯著嗎?

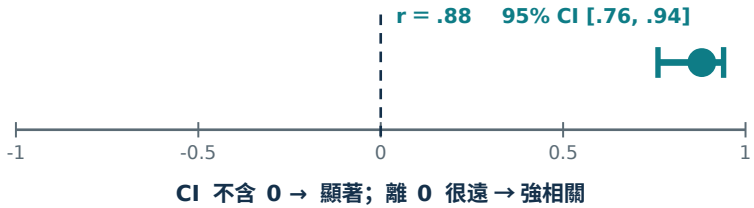
資料：同前頁，冥想頻率 vs 幸福感，r = .88 、 N = 30

1 **自由度** df = N − 2 = 28

2 **檢定統計量** t = r√df ÷ √(1−r²) = 4.66 ÷ .475 ≈ 9.8

3 **p 值** t(28) = 9.8 → p < .001 → 拒絕 H_0（母體相關 ≠ 0）

A **APA** r(28) = .88, p < .001, 95% CI [.76, .94]



CI 不含 0 → 顯著；離 0 很遠 → 強相關

r^2 = .77：幸福感的變異約 77% 與冥想頻率共變



仍是關聯、不是因果

教學重點 相關『顯著』只表示母體相關不為 0；仍是關聯非因果，且要看 r 的大小（效應量）而非只看 p。

② ③ 平均差異的推論： ANOVA / RM ANOVA

承上 相關講完 → **本頁** 類別 IV × 數值 DV：比較平均（t、ANOVA）

ANOVA （組間）

- 比較兩組（或多組）平均是否有差異
- 效應量： η^2 ／ partial η^2 （亦可報平均差）
- F(1, 58)： 括號內為自由度
- 例：治療組 vs 控制組（各 30 人）比後測疾病分數 → 不同的人分組比

RM ANOVA （組內）

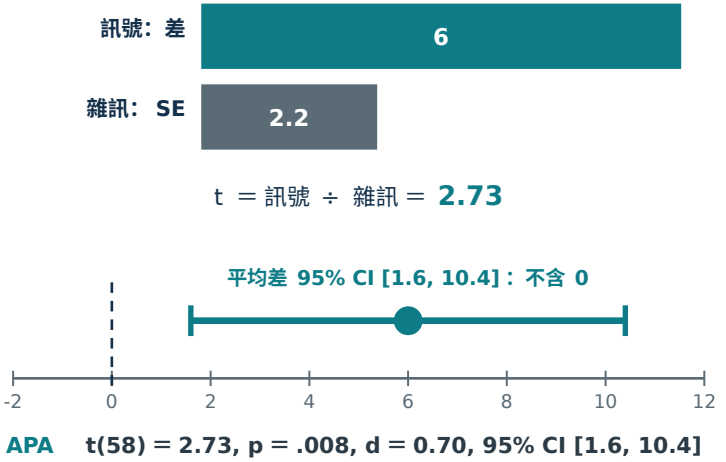
- 純組內設計無分組因子，比「治療前 vs 後」
- 同一群人重複測量 → 控制個體差異
- 所需樣本數比組間設計少
- 例：同一批病人比治療前 vs 後 → 每人跟自己比
- **兩者合在一起（分組 × 前後）＝混合設計，見第 59 張**

APA 報告： $F(1, 58) = 37.91, p < .001, \eta^2 = .40$ （後測 M：治療 4.63 vs 控制 7.65）

獨立樣本 t 檢定完整範例（兩組）

新教學法 M=78, SD=8, n=30　　vs　　傳統 M=72, SD=9, n=30

1. **假設**　H_0：兩組母體平均相等；H_1：不相等（雙尾）
2. **平均差**　78 − 72 ＝ 6 分
3. **合併 SD 與 SE**　pooled SD ≈ 8.51；SE ＝ 8.51 × √(1/30 + 1/30) ≈ 2.20
4. **t 與 df**　t ＝ 6 ÷ 2.20 ≈ 2.73；df ＝ 58 → p ≈ .008
5. **效應量**　d ＝ 6 ÷ 8.51 ≈ 0.70（中大）

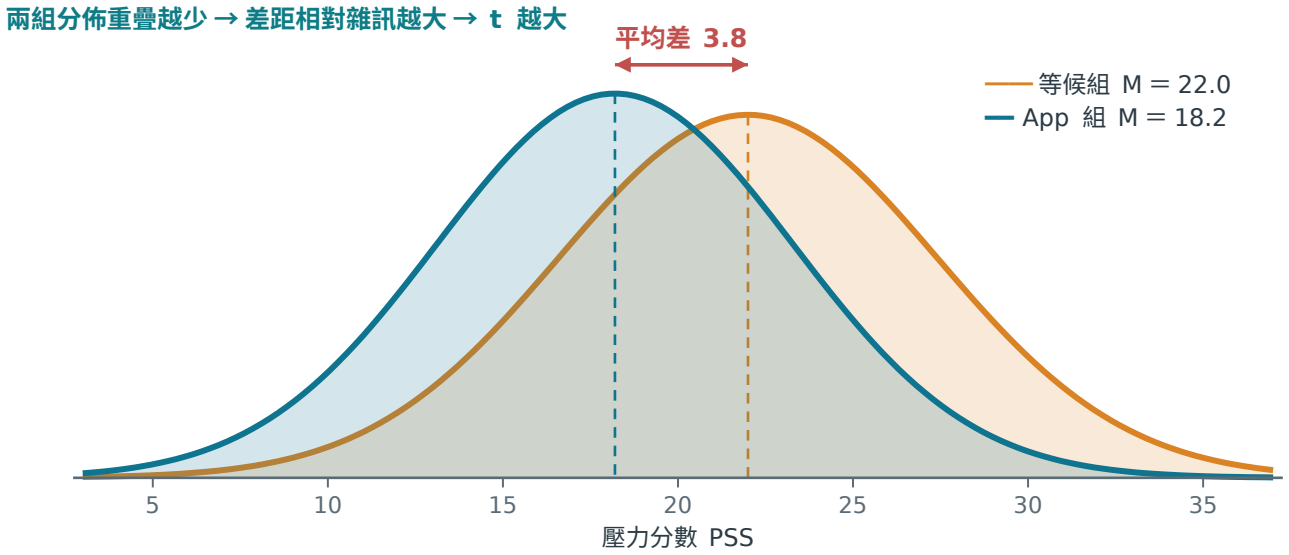


APA　**t(58) = 2.73, p = .008, d = 0.70, 95% CI [1.6, 10.4]**

教學重點　兩組比較用獨立 t；2 組時 $F = t^2$（ANOVA 與 t 一致）。務必同時報 d 與 CI，別只報 p。

獨立 t：兩組分佈與『差 ÷ 雜訊』

承上 獨立 t 的算法 → **本頁** 看圖：兩組分佈與『差 ÷ 雜訊』



重點 t = 平均差 ÷ 標準誤 (SE)。兩條鐘形曲線分越開、越瘦（變異小），重疊越少 → t 越大、越可能顯著。

配對樣本 t 檢定完整範例（同一批人前後）

減重前後（同 25 人）：平均差 $\bar{d}$ = 3 kg 、差的 SD = 4 、 n = 25

1 **假設** H_0：μ差 = 0；H_1：μ差 ≠ 0

2 **差的 SE** 4 ÷ √25 = 0.80

3 **t 與 df** t = 3 ÷ 0.80 = 3.75；df = 24 → p ≈ .001

4 **效應量** dz = 3 ÷ 4 = 0.75（中大）

A **APA** t(24) = 3.75, p = .001, dz = 0.75



t = 訊號 ÷ 雜訊 = **3.75**

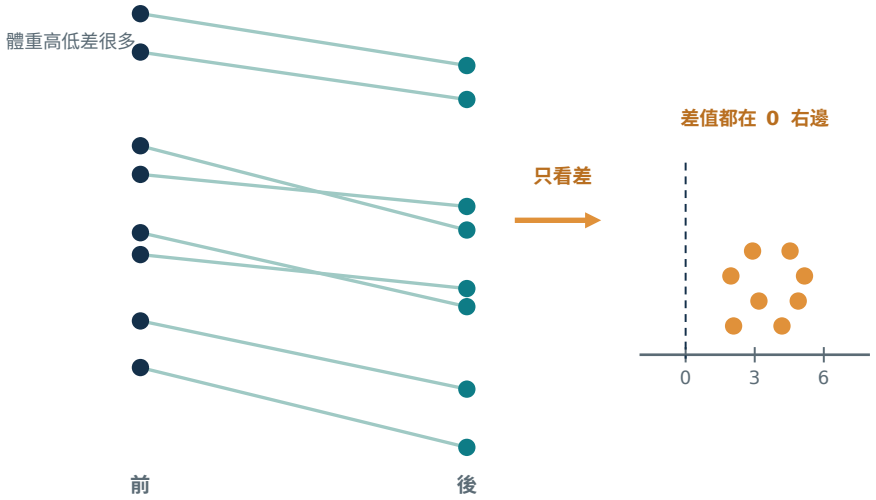
為什麼配對更有力?
每個人當自己的對照，消掉『本來就有胖有瘦』的個體差異 → 雜訊變小 → 同樣人數 t 更大（回想單元 1 的受試者內設計）

教學重點 配對 t 用『每個人的前後差』——去除個體差異，所以比獨立設計省樣本、檢定力高（回想單元 1 的受試者內）。

配對 t：為什麼用『每人前後差』？

承上 配對 t 的算法 → **本頁** 白話：為什麼用每人的前後差

同一個人量前、後兩次（示意）



關鍵動作
先把每人『後 − 前』算成差值，再檢定差的平均是否為 0

為何這樣做
消掉個體本來的高低差 → 雜訊變小 → 檢定力高、更省人

效應量
dz ＝平均差 ÷ 差的 SD （本例 3 ÷ 4 ＝ 0.75 ）

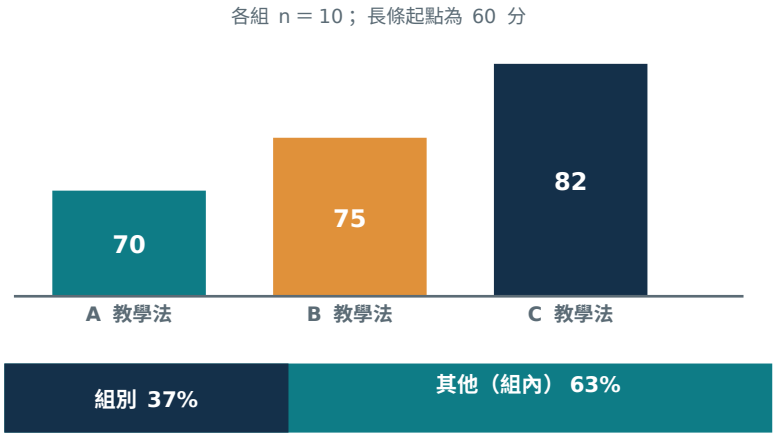
重點 判斷要不要用配對：問『這兩筆數字是不是同一受試者（或配對）產生的？』是 → 配對 t。

單因子 ANOVA 完整範例（≥ 3 組）

三種教學法（各 n=10 ）成績平均：A=70 、 B=75 、 C=82

1. **假設** H_0：三組母體平均都相等； H_1：至少一組不同
2. **F 的邏輯** 組間變異 ÷ 組內變異
3. **結果** $F(2, 27) = 8.00, p = .002$ → 拒絕 H_0
4. **效應量** η^2 = SS 組間 ÷ SS 總 ≈ .37 （大）

A. **APA** $F(2, 27) = 8.00, p = .002, \eta^2 = .37$

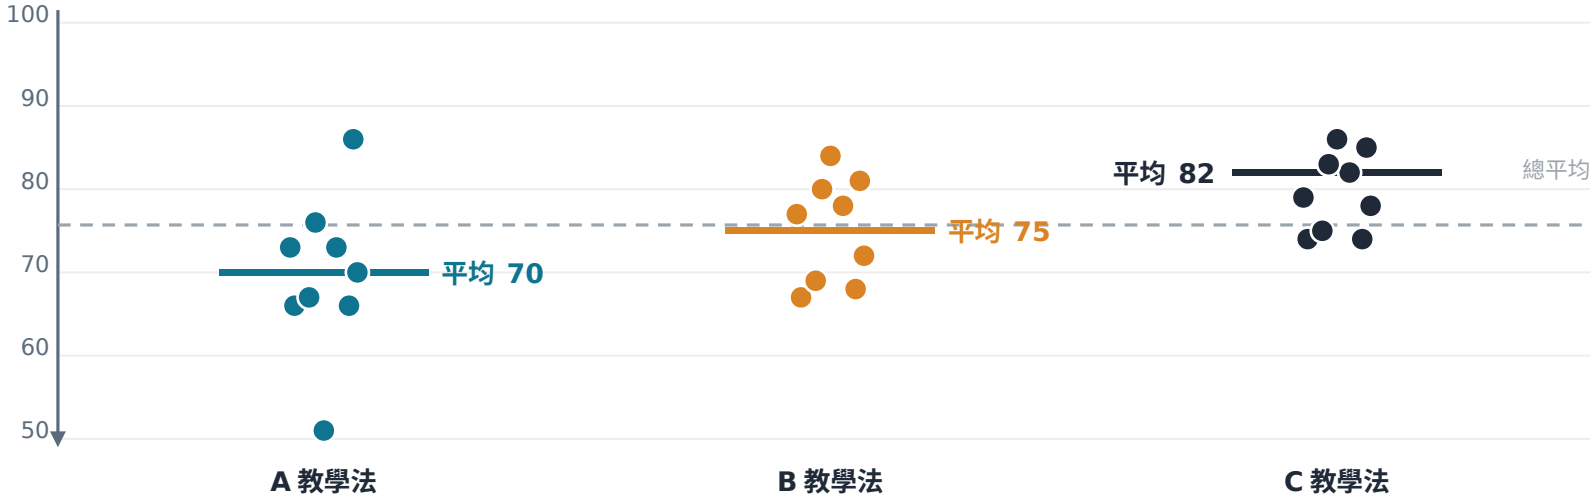


η^2：分數的變異有 37% 可用『哪一組』解釋；但還不知道是哪兩組不同 → 事後比較

教學重點 ANOVA 只說『至少有一組不同』，沒說『哪兩組不同』——要靠事後比較（下一頁）。

ANOVA：組間 vs 組內，看圖秒懂

承上 ANOVA 的算法 → 本頁 看圖：組間 vs 組內

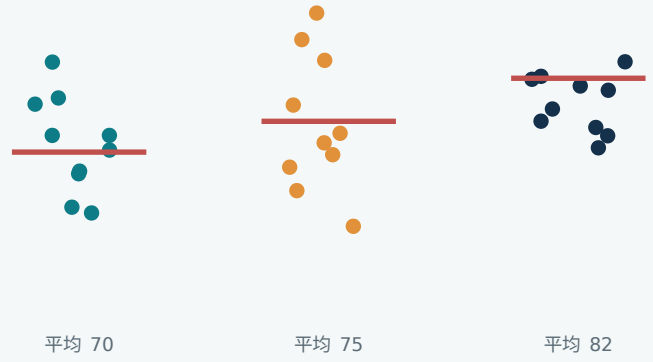


重點 粗橫線是各組平均、散點是組內個別值。F = 平均線分多開（組間） ÷ 點的散佈（組內）。

ANOVA 的 F 在比什麼?

承上 看過圖 → **本頁** 白話：F 在比什麼

組內每人上下飄很大



平均差被雜訊蓋住 → F 小

組內很集中



平均差一眼就看出 → F 大

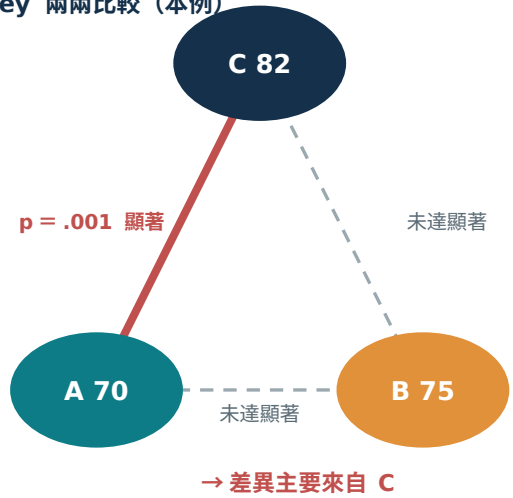
F ＝組間變異 ÷ 組內變異； F 大 → p 小 → 至少一組不一樣（點為示意，兩圖的組平均相同）

重點 ANOVA 只回答『有沒有人不一樣』；要知道『誰跟誰不一樣』，看下一頁的事後比較。

ANOVA 事後比較：到底哪幾組不同?

承上 F 顯著只說『有人不同』 → **本頁** 事後比較：到底哪幾組不同

Tukey 兩兩比較（本例）



為何需要?
ANOVA 顯著只說『有人不同』；要知道誰跟誰不同，得兩兩比較

為何不直接多跑幾次 t ?
3 組要比 3 次，偽陽性會累積（下一頁）；事後檢定會校正

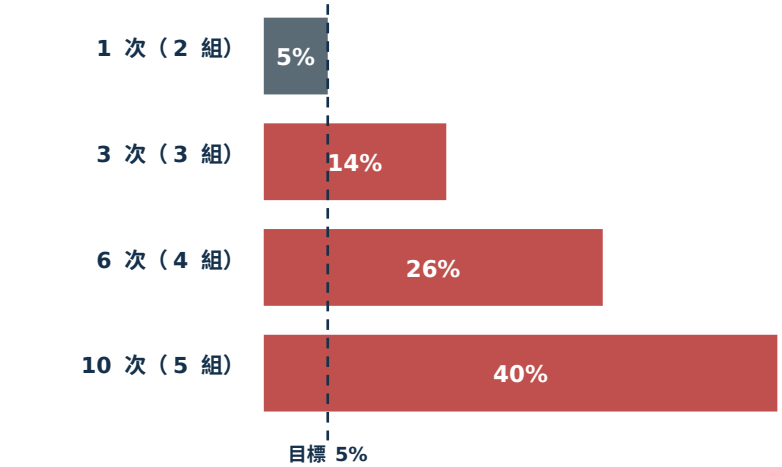
常用方法
Tukey HSD： 各組人數相近時最常用
Bonferroni： 最保守
Games-Howell： 變異數不同質

教學重點 先看 ANOVA 是否顯著（總體），再做事後比較（局部）；報告要同時給整體 F 與兩兩差異＋效應量。

事後比較：為何不能直接多跑幾次 t?

承上 事後比較的方法 → **本頁** 白話：為何不能直接多跑幾次 t

每次 α = .05，比越多次，『至少一次誤判』越可能



累積機率＝ 1 − 0.95^ 次數（假設各次獨立）

解法 事後檢定校正門檻，把整體偽陽性壓回 5%

怎麼選?

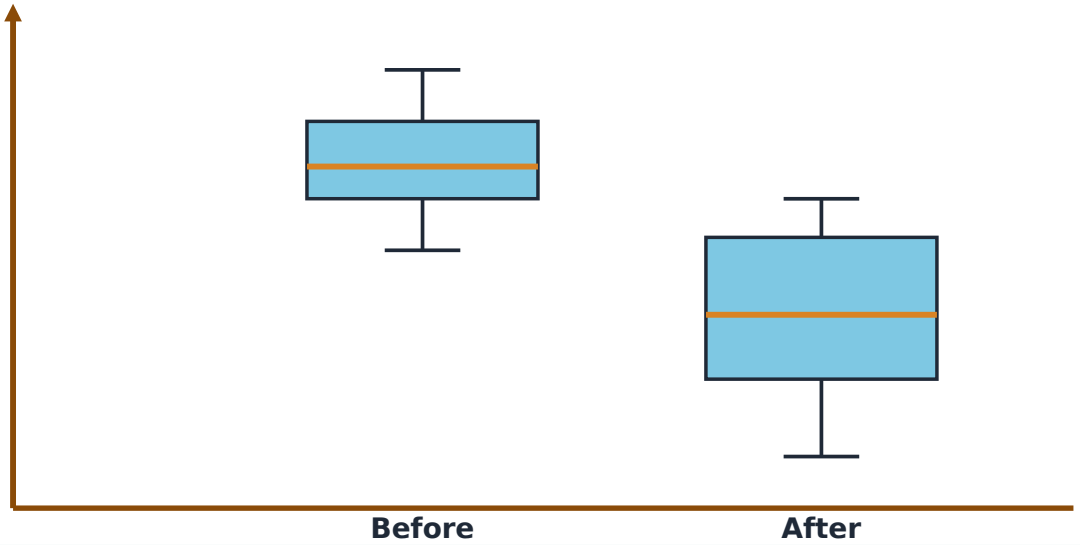
各組人數相近	→ Tukey HSD
要最保守	→ Bonferroni
變異數不同質	→ Games-Howell

重點 流程固定：先看整體 ANOVA 是否顯著，再做事後兩兩比較，並各自報效應量。

RM ANOVA （組內）：先看敘述結果，再寫假設

承上 組間比較講完 → **本頁** 組內：同一批人前後，先看敘述結果

疾病分數



H₀ 虛無假設

前後（母體）平均相等，
沒有差異。

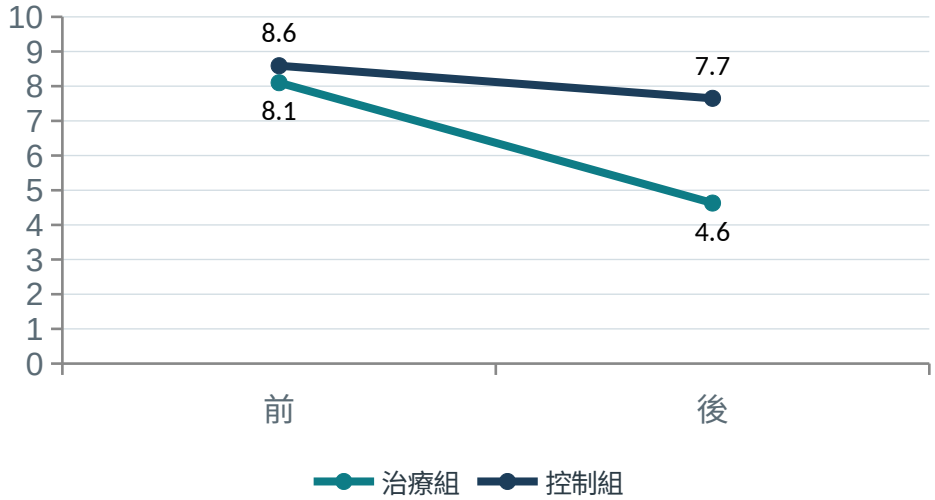
H₁ 對立假設

前後（母體）平均不相等，
有差異。

重點 H₀：前後（或兩組）母體平均相等； H₁：不相等。箱型圖：箱＝中間 50% 的人、中線＝中位數； After 整體往下移＝治療後分數降低，是否顯著要靠 RM ANOVA 判斷。

④ 混合設計的推論（RM ANOVA）

承上 組內前後 → **本頁** 再加控制組：混合設計看交互作用



- 問題：這個型態是巧合，還是能推論到母體?
- 控制組前後幾乎相同；治療組後測明顯下降
- **檢定「時間 × 組別」交互作用**
- **交互作用顯著 → 治療確有作用**

APA 報告：時間 × 組別 交互作用 $F(1, 58) = 10.20, p = .002$

④ 混合設計交互作用完整範例（RM ANOVA）

疾病分數：治療組 前 8.10→ 後 4.63 （降 3.47 ）；控制組 前 8.59→ 後 7.65 （降 0.94 ）

1. **問的是** 『時間 × 組別』交互作用：治療組變化量是否大於控制組
2. **為何看交互作用** 單看治療組下降可能是時間／安慰劑；要比兩組變化的差
3. **結果** $F(1, 58) = 10.20$, $p = .002$ → 治療確有作用
4. **效應量** partial $\eta^2 = 48.197 \div (48.197 + 274.103) = .15$ （大）

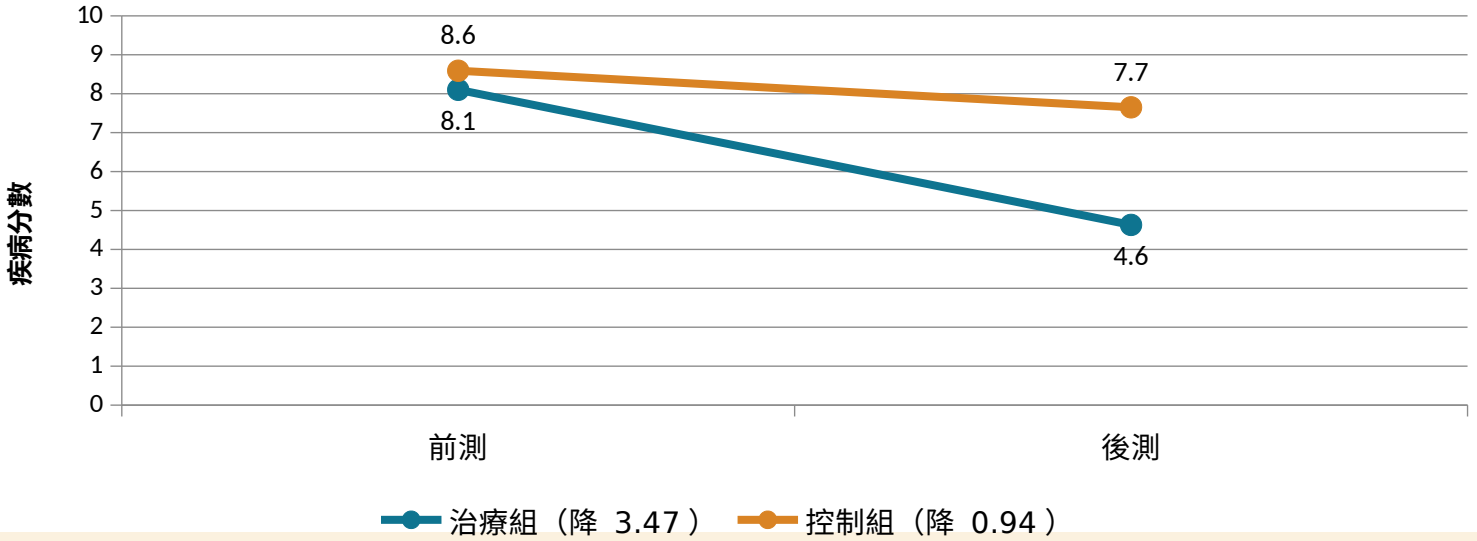


APA 時間 × 組別交互作用
$F(1, 58) = 10.20$, $p = .002$, partial $\eta^2 = .15$

教學重點 混合設計的關鍵永遠是『交互作用』，不是單一主效果；控制組若也下降，就要靠交互作用把治療效果分離出來。

交互作用：兩條線看治療效果

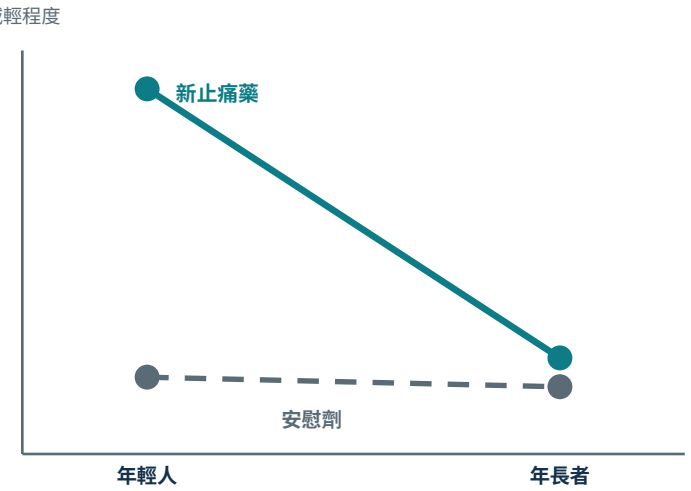
承上 交互作用的算法 → **本頁** 看圖：兩條線斜率不同



重點 治療組掉得多、控制組幾乎沒動 → 兩線不平行 ＝ 交互作用顯著 → 治療真的有效（已扣掉時間效應）。

交互作用白話：『看情況』就是交互作用

承上 看過圖 → **本頁** 白話：『看情況』就是交互作用



兩條線不平行＝交互作用（示意）

情境
新藥對年輕人很有效、對年長者幾乎無效

主效果會被平均掉
全體平均起來，藥效看起來只是普通

交互作用＝效果因人而異
年齡 × 用藥 顯著：藥效『看情況』

忽略它的代價
誤說『這藥普通』，錯過對特定族群很有用的藥

教學重點 混合設計的『時間 × 組別』就是同一回事：治療效果是否『因時間而不同』——看交互作用，不是看單一主效果。

用 JASP 執行重複量數 ANOVA

JASP 操作四步（選單以英文介面為準）；右表為輸出節錄，數字同第 60 張

① 資料寬格式
每人一列；前測、後測各一欄

▼

② 開分析
ANOVA → Repeated Measures ANOVA

▼

③ 放變數
前測、後測 → Repeated Measures Cells；組別 → Between Subject Factors

▼

④ 勾選輸出
Descriptive plots、 Estimates of effect size （$\eta^2 p$）

Within Subjects Effects （節錄）

效應	SS	df	MS	F	p	$\eta^2 p$
時間 × 組別	**48.197**	**1**	**48.197**	**10.20**	**.002**	**.15**
Residuals	274.103	58	4.726			

只看紅色那一列 『時間 × 組別』交互作用
$F(1, 58) = 10.20$， $p = .002 < .05$ → 顯著
＝治療組前後的變化，和控制組不一樣
Residuals 是誤差列，用來算 MS 與 F，不用解讀

重點 混合設計在 JASP 以 RM ANOVA 分析；重點看「時間 × 組別」交互作用是否顯著（$p < 0.05$）。

⑤ 邏輯斯迴歸（數值 IV × 類別 DV）

承上 DV 是數值的檢定講完 → **本頁** DV 變成類別：邏輯斯迴歸（數值 IV）

- **IV 數值（如年齡）、 DV 類別（如是否購買）**
- **檢驗：購買「機率」是否隨年齡而變化**
- $p < 0.05$ → 可推論：母體中購買機率確實隨年齡而變
- **勝算比（Odds Ratio, OR）量化關聯強度： OR 接近 1 → 效應小；離 1 越遠 → 越強**

APA 報告：$\exp(b) = 0.88, z = -3.67, p < .001$（購買機率隨年齡「顯著下降」）

⑤ 邏輯斯迴歸完整範例（數值 IV × 類別 DV）

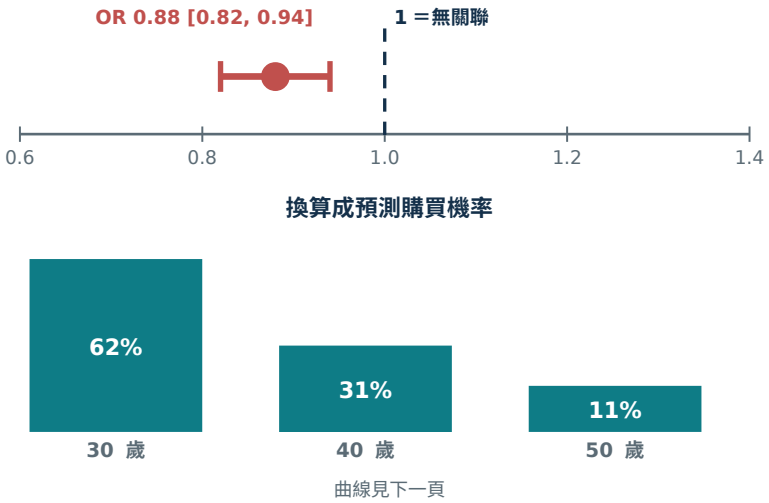
年齡（數值）預測是否購買（0/1）

1 **為何不用線性**　DV 是 0/1，用邏輯斯把『勝算的對數』對 IV 建模

2 **勝算比 OR**　exp(b) = 0.88：年齡每 +1 歲，購買勝算 ×0.88（約 −12%）

3 **方向與顯著**　OR < 1 → 負向；95% CI 不含 1 → 顯著

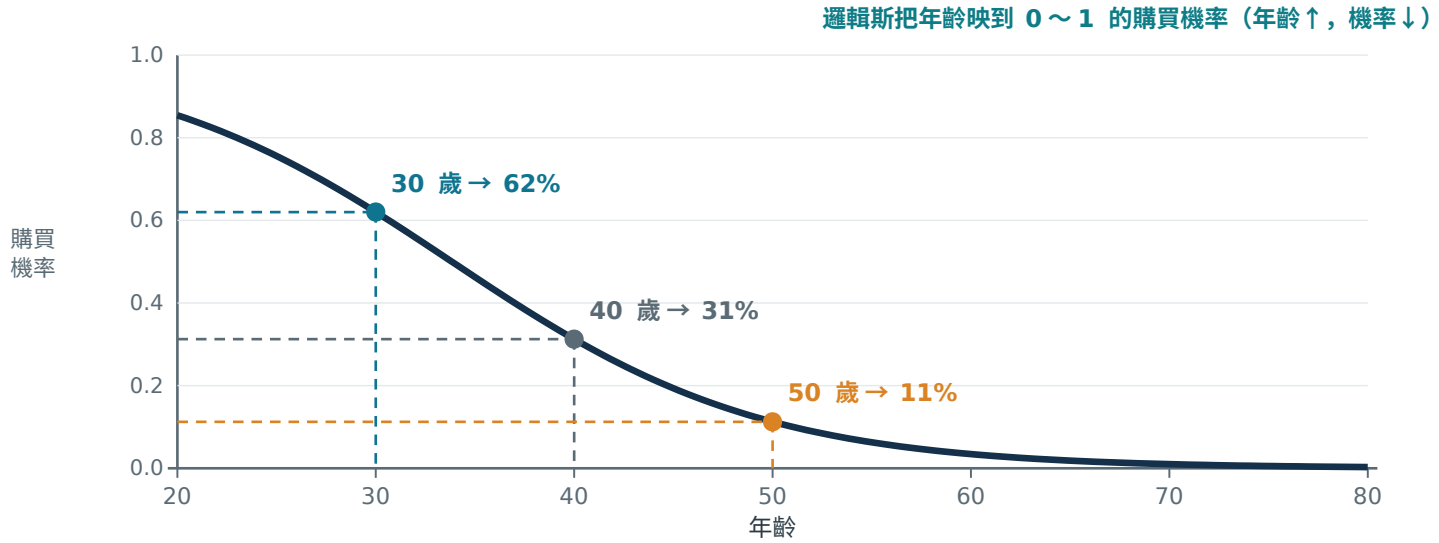
A **APA**　OR = 0.88, 95% CI [0.82, 0.94], z = −3.67, p < .001



教學重點　OR = 1 代表無關聯；離 1 越遠關聯越強。報 OR 一定要附 95% CI——CI 是否跨過 1，就是顯著與否。

邏輯斯：機率的 S 形曲線

承上 OR 的算法 → **本頁** 看圖：機率的 S 形曲線



重點 線性會跑出 0~1 之外；邏輯斯用 S 形把 IV 映到機率。年齡每增 1 歲勝算 ×0.88 （OR<1，負向）。

⑥ 卡方檢定（類別 IV × 類別 DV）

承上 數值 IV × 類別 DV → **本頁** 兩個都是類別：卡方檢定

- **檢驗兩個類別變量的關聯（如：性別 對 是否購買）**
- 以列聯表的次數與欄百分比為基礎
- **$p < 0.05$ → 兩變量有關聯**
- **$p > 0.05$ → 無法下結論有差異（可能真的無差異，或樣本太小）**

APA 報告（不顯著例，另一組小樣本資料）：$\chi^2(1) = 1.71, p = .19$（男 66% vs 女 50% 購買，差異不顯著）

非顯著 ≠ 證明沒差異；務必檢查樣本數是否足夠。

⑥ 卡方檢定完整範例（觀察 vs 期望）

性別 × 是否購買，N = 150：男 40/60、女 30/20

1. **期望次數** 若獨立：男·購買 = 100×70/150 = 46.7；女·購買 = 23.3
2. **卡方值** $\chi^2 = \Sigma(O-E)^2/E \approx 5.36$（四格加總，見右）
3. **df 與 p** df = (2−1)(2−1) = 1；$\chi^2(1) = 5.36 \rightarrow p = .021$
4. **效應量** Cramér's V = $\sqrt{(5.36 \div 150)} \approx .19$（小～中）

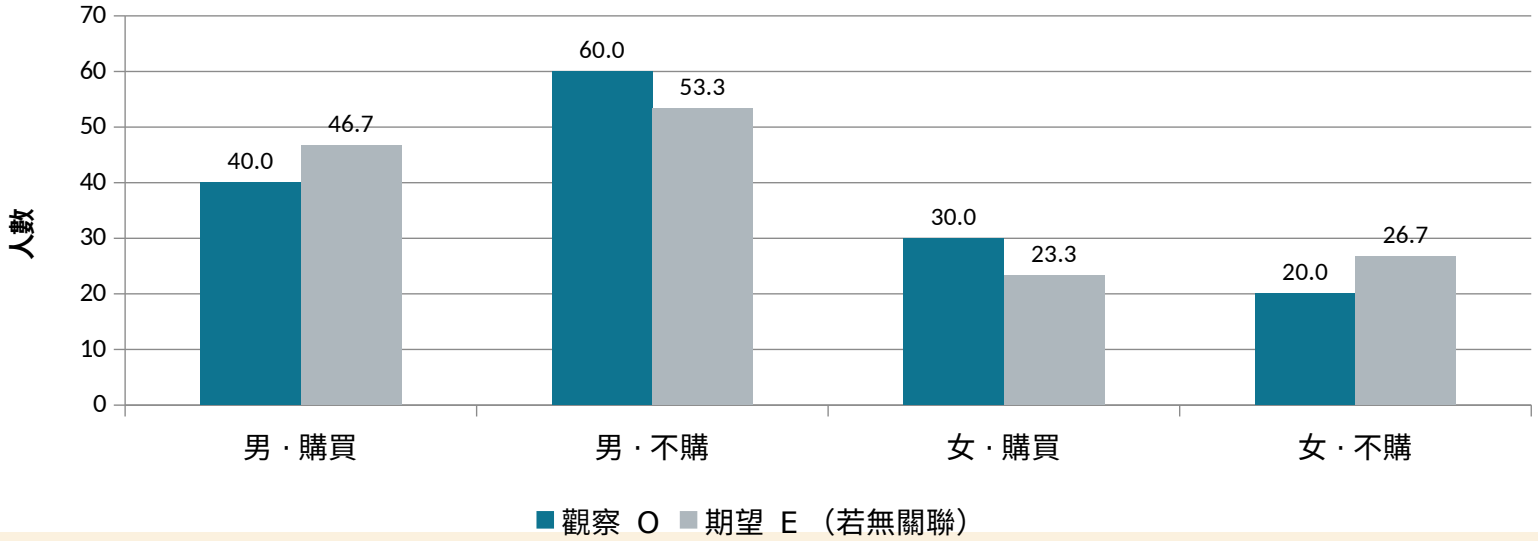
男·購買 O 40　E 46.7 **$(O-E)^2/E \approx 0.96$**	**女·購買** O 30　E 23.3 **$(O-E)^2/E \approx 1.93$**
男·未購 O 60　E 53.3 **$(O-E)^2/E \approx 0.84$**	**女·未購** O 20　E 26.7 **$(O-E)^2/E \approx 1.68$**

加總：**$0.95 + 1.90 + 0.83 + 1.67 \approx 5.36$**
女購買率 60% > 男 40%

教學重點 卡方比較『觀察 vs 獨立時的期望』；小樣本（期望 <5）用 Fisher 精確檢定。顯著只說有關聯，強度看 Cramér's V。

卡方：觀察 vs 期望，看圖秒懂

承上 卡方的算法 → 本頁 看圖：觀察 vs 期望



重點 $\chi^2 = \Sigma$ （觀察−期望）^{2} / 期望。藍柱（實際）與灰柱（若無關聯的期望）差越大 → χ^2 越大 → 越可能有關聯。

讀統計軟體輸出：擬真範例（獨立 t 檢定）

承上 六種檢定都會算了 → **本頁** 讀懂軟體輸出，翻成一句 APA

輸出欄位	數值	怎麼讀
t	2.73	檢定統計量
df	58	自由度（$n_1 + n_2 - 2$）
p (two-tailed)	.008	< .05 → 顯著
Mean Difference	6.00	兩組平均差（分）
Cohen's d	0.70	效應量（中大）
95% CI	[1.6, 10.4]	不含 0 → 顯著

翻成 APA t(58) = 2.73, p = .008, d = 0.70, 95% CI [1.6, 10.4]。讀表順序：先看 p（顯不顯著）→ 再看效應量與 CI（多大、多確定）→ 配上各組 M、SD 寫成句子。

完整案例：正念 App 能降低護理師壓力嗎？（1/2）

承上 會讀輸出 → **本頁** 完整案例：從研究問題走到選對檢定

① 研究問題與設計	② 假設	③ 選檢定	④ 檢查假設
隨機分派 60 位護理師：App 組 vs 等候組；4 週後測知覺壓力 PSS	H_0：兩組壓力平均相等；H_1：不相等（雖預期 App 較低，仍用雙尾）	IV＝組別（類別 2 組）、DV＝壓力分數（數值）→ 獨立樣本 t	各組近似常態、變異數同質（Levene $p = .42$）、觀察獨立 → 可用 t

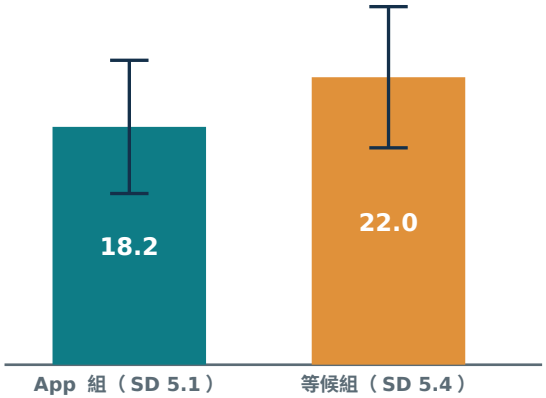
先把『問題 → 設計 → 假設 → 選檢定 → 假設檢查』定好，再碰數字（結果見下一頁）

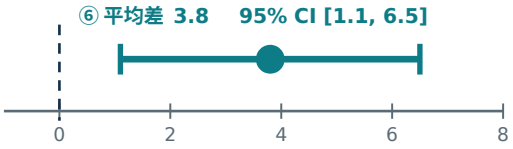
教學重點 先把『問題 → 設計 → 假設 → 選檢定 → 假設檢查』定好，再碰數字——這條線就是方法 / 結果章的骨架。

完整案例：正念 App （ 2/2 ）——結果、報告與討論

承上 問題、設計、檢定都定了 → **本頁** 結果、報告與討論

⑤ 結果： PSS 平均（誤差線＝ ±1 SD），各 30 人





t(58) = 2.80, p = .007
d = 0.72 （中大）

⑦ APA

App 組壓力（ M = 18.2, SD = 5.1 ）顯著低於等候組（ M = 22.0, SD = 5.4 ）， t(58) = 2.80, p = .007, d = 0.72, 95% CI [1.1, 6.5] 。

⑧ 討論：能談因果嗎?

✓ **有隨機分派 → 可談因果**

△ 單一樣本、需複製； PSS 為自陳，宜加客觀指標（如皮質醇）

教學重點 一個完整結果 = 顯著性（ p ）+ 效果大小（ d ／平均差）+ 精確度（ CI ）+ 設計能談到什麼（因果 vs 關聯）。

完整案例：把整條線讀成白話

承上 完整案例 → **本頁** 每個數字讀成白話

一句話 隨機分派 60 位護理師，用 App 4 週後壓力（PSS）顯著低於等候組

隨機分派
兩組事前相當 → 差異來自 App，能談因果

t(58) = 2.80
兩組差距是雜訊（SE）的 2.8 倍

p = .007
若 App 其實無效，只有 0.7% 機率看到這麼大的差

d = 0.72
中大效果

95% CI [1.1, 6.5]
與資料相容的平均差約 1.1 ～ 6.5 分；不含 0

重點 一個好結果 = 顯著 (p) ＋效果多大（d/ 平均差）＋多確定 (CI) ＋能談到什麼（因果 vs 關聯），四者缺一不可。

各檢定的 APA 報告格式總表

承上 案例的 APA → 本頁 各檢定的 APA 報告格式總表

檢定	統計量	APA 報告範例
相關 Correlation	r （df）	r(28) = .88, p < .001
ANOVA （組間）	F （df1, df2）	F(1, 58) = 37.91, p < .001
RM ANOVA （組內 / 混合）	F （df1, df2）	F(1, 58) = 10.20, p = .002 （交互作用）
邏輯斯迴歸 Logistic	exp(b) 、 z	exp(b) = 0.88, z = −3.67, p < .001
卡方 Chi-square	χ^2 （df）	$\chi^2(1) = 1.71$, p = .19

報告三要素：統計量＋自由度、精確 p 值、效應量／描述統計；t 檢定的格式見第 49 、 51 張。

D

避免 p 值誤用

Avoid Mistakes! How to Use p-values Correctly

錯誤一：把「不顯著」當成「證明沒差異」

承上 C 段：會算、會報 → 本頁 D 段避免誤用。錯誤一：把不顯著當成沒差異

$p > 0.05$ 時，你「不能」下結論說 H_0 為真——只能說「證據不足以拒絕 H_0」。

- **$p > 0.05$ 有兩種可能：**
- **① 母體中真的沒有差異（H_0 為真）**
- **② 其實有差異，但你的樣本數太小、沒偵測到**
- **所以「不顯著」無法區分這兩者——不要從 $p > 0.05$ 推出「沒有效果」**
- **要主張「沒有差異」，須改用等效性檢定（TOST，見 2.6）。**

錯誤二：多重檢定與 Bonferroni 校正

承上 錯誤一 → 本頁 錯誤二：做太多檢定

- **α = 0.05 代表「每一次檢定」約有 5% 誤判為顯著的機會**
- **若在同一批資料做 100 次檢定 → 約有 5 次「純靠運氣」達顯著（chance capitalization）**
- 不要「一直換題目做檢定，直到有一個顯著」

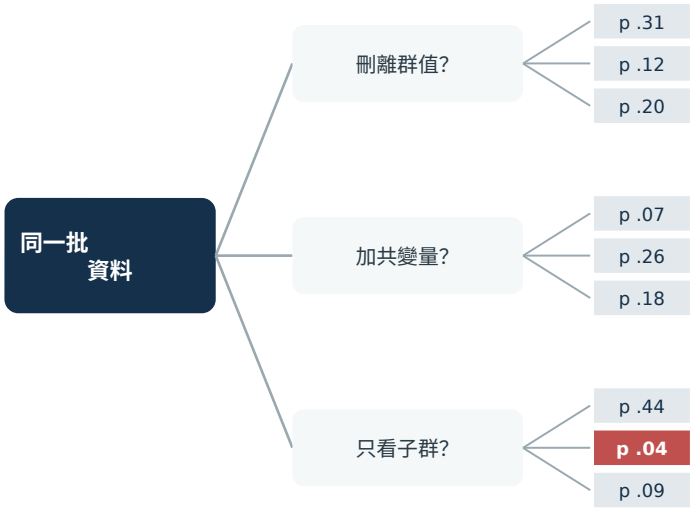
解法：Bonferroni 校正

把門檻除以檢定次數。例：做 2 個檢定 → 用 0.05 ÷ 2 = 0.025 當門檻；做 5 個 → 用 0.01。這樣控制「族系錯誤率（FWER）」，但偏保守；Holm 法同樣控制 FWER 且檢定力較高，大量探索性檢定可改控 FDR（Benjamini–Hochberg）。

原則：先想清楚要做幾個檢定；每份資料集只跑一組事先規劃好的檢定。

p-hacking 與研究者自由度

承上 多重檢定 → **本頁** 更隱蔽的版本：p-hacking



試的路越多，總有一條湊到 < .05 （p 值為示意）

研究者自由度
可選的分析很多：刪不刪離群值、加不加共變量、何時停止收案——都會影響 p

p-hacking
不斷嘗試不同分析／子群，直到 p < .05；等於偷偷做了很多檢定

HARKing
看到結果才回頭『假裝』當初就這樣假設

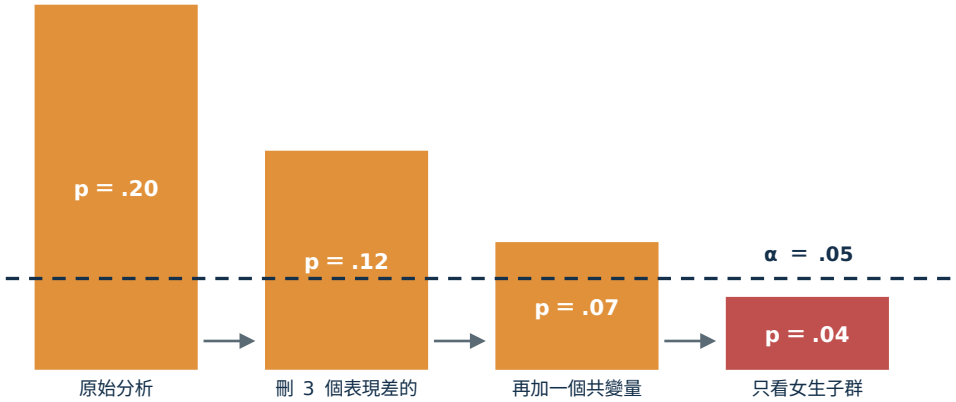
對策
預先註冊分析計畫；誠實區分驗證性與探索性分析

教學重點 先寫好分析計畫再看資料——探索性發現當『假設來源』沒問題，但要用新資料驗證，別在同一批資料裡當成定論。

p-hacking：一個具體的例子

承上 p-hacking 的定義 → **本頁** 一個具體的例子

研究者想證明新教材有效，一路『喬』分析



問題

試了很多種分析，總會有一種湊到 < .05；只報最後這個，『顯著』很可能是假的

對策

事前註冊分析計畫
把探索到的發現誠實標為『探索性』
再用新資料驗證

重點 同一批資料反覆嘗試到顯著 = p-hacking；它是可重現性危機的主因之一。

超越 p 值：用 CI 與效應量把話說完整

承上 避開兩種誤用 → **本頁** 正面做法：用 CI 與效應量把話說完整

一則完整結果＝五塊積木

t(58) = 2.73	p = .008	d = 0.70	95% CI [1.6, 10.4]
統計量＋ df	精確 p 值	效應量：差多少	精確度：多確定

p 不是
效果大小，也不是『假設為真的機率』；不能單獨當決策依據

一定要報效應量
d ／ η² ／ r ／ OR ／ V：差多少、關聯多強，可跨研究比較

一定要報 CI
同時給方向、大小與精確度，比顯著／不顯著二分更有資訊

別說『證明』
說『支持／不支持』；單一研究不定論，靠複製與統合分析

教學重點 現代結果報告 = 檢定統計量 + df + 精確 p + 效應量 + 95% CI；只給『p<.05』會被審稿人退。

超越 p 值：同一結果的兩種寫法（承前頁報告要件）

承上 報告要件 → **本頁** 同一結果的兩種寫法

只寫 p（不完整）

「兩組有顯著差異
（p < .05）。」

→ 讀者不知道
差多少、多確定，
也無法跨研究比較。

完整寫法（建議）

「App 組壓力顯著低於
等候組，平均差 3.8 分，
95% CI[1.1, 6.5],
Cohen's d=0.72,
t(58)=2.80, p=.007 。」

→ 方向、大小、精確度、
顯著性一次到位。

重點 現代期刊要求：檢定統計量＋ df ＋精確 p ＋效應量＋ 95% CI；別只丟一個『p<.05』。

結果章寫作檢查清單

承上 兩種寫法 → 本頁 結果章寫作檢查清單

☐ 統計量完整

統計量＋ df、精確 p （不只寫 p<.05 ）、效應量與 95% CI

☐ 先敘述、再推論

先報各組 M 、 SD 、 n ，再報檢定

☐ 假設有檢查

常態、變異數同質；違反時說明改用的方法

☐ 多重比較有校正

Bonferroni ／ Tukey ，或說明為事先規劃的少數檢定

☐ 顯著 ≠ 重要

用效應量與 CI 討論實質意義

☐ 驗證 vs 探索

誠實區分；不把『不顯著』寫成『證明沒差異』

教學重點 把這張清單當『送印前的最後檢查』——審稿人最常抓的就是漏效應量 /CI 、以及把不顯著當成沒差異。

本單元重點回顧

- **【目標②】推論統計判斷：在 H_0 為真的假定下，觀察到的資料有多不尋常。**
- 【目標②】我們反駁 H_0、而非證明 H_1；p 值是反駁 H_0 的證據強度，門檻 0.05 是共識決策線。
- 顯著性取決於三股力量：效應量（大）、變異（小）、樣本量（大）。
- 【目標①】【目標④】依 IV/DV 選檢定：相關、t 檢定、ANOVA、RM ANOVA、邏輯斯、卡方，並用 APA 格式報告。
- 顯著的意義看設計：實驗能談因果、非實驗只能談關聯。
- 【目標②】兩大誤用：不能把「不顯著」當沒差異；多重檢定要用 Bonferroni 校正。
- 【目標③】【目標④】95% CI 與效應量要與統計量、精確 p 值一起報——只報 p 是不完整的。

下一站　2.6 樣本數規劃：反過來問——要偵測到這樣的效果，事前需要多少人？

參考文獻與延伸閱讀

- Wasserstein, R. L., & Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. The American Statistician, 70(2), 129–133. → p 值六原則（第 80 張）
- Greenland, S., et al. (2016). Statistical tests, P values, confidence intervals, and power: A guide to misinterpretations. European Journal of Epidemiology, 31(4), 337–350. → p 值與 CI 的常見誤解
- Cumming, G. (2014). The new statistics: Why and how. Psychological Science, 25(1), 7–29. → 效應量與信賴區間
- Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). Lawrence Erlbaum. → 效應量基準（第 36 張）
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70. → 多重檢定（第 77 張）
- Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. JRSS B, 57(1), 289–300. → FDR
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology. Psychological Science, 22(11), 1359–1366. → p-hacking （第 78–79 張）
- Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. Social Psychological and Personality Science, 8(4), 355–362. → 主張「沒差異」
- American Psychological Association. (2020). Publication manual of the American Psychological Association (7th ed.). → APA 報告格式（第 74 張）

A

作業

Take-home Assignment

From p-value to a defensible conclusion.

涵蓋單元 5： H_0/H_1 與 p 值邏輯、三股力量、標準誤與信賴區間、六種檢定與效應量、 APA 報告、p 值誤用。

Part A 觀念題檢驗你「懂不懂」； Part B 實作題要你「選對檢定、算得出、報得對」。參考解答在本節後段。

Assignment Brief

作業說明：目標、繳交與規則

作業目標

能依資料選對推論檢定、算出並解讀結果，並用 APA 格式完整報告（含效應量與 CI）。

繳交方式

一份 PDF： Part A 文字作答 ＋ Part B 計算與 APA 報告，建議 3–5 頁。

建議時間

約 2–3 小時；可用 JASP 驗算，但需寫出檢定選擇與判讀。

工具與誠信

可用 AI／軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

Part A ｜觀念題：推論統計（1/2）

A1 H_0/H_1 是什麼？為何『反駁 H_0』而非『證明 H_1』？寫出 p 值的正確定義與兩個常見誤解。

A2 決定顯著的三股力量（效應量、變異、樣本數）如何影響 p？為何大樣本下微弱效應也會顯著？

A3 標準誤 SE 與標準差 SD 差在哪？95% 信賴區間怎麼算、怎麼解讀？CI 與假設檢定的關係為何？

A4 Type I / II 錯誤與 Power 各是什麼？把 α 設更嚴會付出什麼代價？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2–4 句即可。

Part A ｜觀念題：推論統計（2/2）

A5 依 IV/DV 選檢定：六種檢定各對應什麼資料型態？各寫一個 APA 報告範例。

A6 各檢定的效應量（d / η^2 / r / OR / Cramér's V）與基準是什麼？為何一定要報效應量與 CI？

A7 t / ANOVA 的基本假設有哪些？違反時的無母數替代分別是什麼？

A8 p 值兩大誤用（把不顯著當沒差異、多重檢定）與對策（Bonferroni、預先註冊）。

Part B ｜實作題：選檢定、算結果、報 APA （1/2）

情境： 比較『新教學法 vs 傳統教學』對考試成績的影響（兩組各 $n = 30$）。
新法 $M = 78, SD = 8$　　傳統 $M = 72, SD = 9$

B1 寫出 H_0 與 H_1；選擇適當的統計檢定並說明理由（依 IV/DV 型態）。

B2 算獨立樣本 t（可用公式）、df，判斷是否 $p < .05$，並算 Cohen's d、判讀效應大小。

B3 寫出這個結果的 APA 報告句（含統計量、df、精確 p、效應量與 95% CI）。

Part B ｜實作題：選檢定、算結果、報 APA （2/2）

B4 若改為『同一批學生前後測』，該用什麼檢定？效應量用什麼？與 B2 的設計差在哪（樣本效率、假設）？

B5 若研究者做了 8 個檢定才找到一個顯著，有什麼問題？你會怎麼處理（校正／預註冊）？並解釋『顯著 ≠ 重要』。

B6 寫一段結果章（含效應量與 95% CI 的完整報告）＋ AI 使用聲明。

繳交格式 Part B 要看得到『檢定選擇的理由』與『計算步驟』；報告句要符合 APA。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能說出關係（如 CI↔ 檢定、 Power=1−β ）
B1 選檢定	10%	H_0/H_1 正確、依 IV/DV 選對檢定並說理由
B2 計算	15%	t 、 df 、 d 計算正確、判讀效應大小
B3 APA 報告	10%	統計量＋ df ＋精確 p ＋效應量＋ CI 齊全
B4–B6 設計＋誠信	25%	配對設計與效應量正確、多重檢定處理、報告＋ AI 聲明

常見扣分 把不顯著當『沒差異』、只報 p 不報效應量 /CI 、相關講成因果、多重檢定不校正。

Reference URLs

資源連結 · 外部服務與官方網址

點按名稱或網址可直接開啟；工具更新快，功能與費用請以官方頁面為準。

資源 / 服務	官方網址 URL
JASP	jasp-stats.org/

案例應用：三個檢定，三種問題

案例 Q ｜ AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

① 本單元教了什麼

推論的邏輯，以及 t 檢定與卡方各自回答什麼樣的問題。

② 案例怎麼用

- 主要問題用配對 t：同一批人前後測，$t(33) = -6.30$、$p < .001$、$dz = -1.08$。
- 機構差異用獨立 t：A 對 B 後測 $t(60) = -3.85$、$p < .001$、$d = -0.98$。
- 類別關聯用卡方：職類 × 完整性達標 $\chi^2(1) = 0.47$、$p = .492$，未達顯著。
- 每個檢定先查前提：常態性、變異數同質、期望次數是否足夠。
- 報告一律附效應量與 95% 信賴區間，不只寫 p 值。

③ 產出什麼證據

APA 格式結果段三則（次頁），可直接移入論文第四章。

④ 承接關係

上游：承自 2.4 之 Table 1 樣本特徵表 ｜ 下游：交棒 2.6，回頭檢視檢定力是否足夠。

教學重點 三個檢定對應三種問題：同一群人前後比、兩群人互相比、兩個類別有沒有關聯。選錯的通常不是公式，而是沒想清楚要比的是什麼。

示範產物： APA 格式結果段三則

數值一律取自唯一數字表；此三段可原樣移入論文，毋須改寫

段落	示範文字
主要結果（配對 t）	導入後交班準備時間（M = 13.03, SD = 4.74）顯著短於導入前（M = 18.40, SD = 5.20）， t(33) = −6.30, p < .001, dz = −1.08, 95% CI [−7.10, −3.63]。
機構比較（獨立 t）	後測期間， A 機構之準備時間（M = 13.03, SD = 4.74）顯著短於同期未導入之 B 機構（M = 17.80, SD = 4.99）， t(60) = −3.85, p < .001, d = −0.98, 95% CI [−7.25, −2.29]。
類別關聯（卡方）	職類與紀錄完整性是否達標之間未達顯著關聯， $\chi^2(1) = 0.47$, p = .492, φ = .09。本結果不足以支持兩者無關聯之推論，詳見研究限制。

教學重點　第三段的寫法值得注意：不顯著不能寫成「兩者沒有差異」，只能寫「未達顯著關聯」。前者是對母體下結論，後者才是這份資料撐得住的說法。