

量性研究方法 · 完整研究專案

單元 5

推論統計

Inferential Statistics — From Sample to Population

虛無假設與 p 值的邏輯、效應量／變異／樣本數三股力量、六種推論檢定（相關、 t 檢定、ANOVA、RM ANOVA、邏輯斯、卡方）與 APA 報告，並避免 p 值誤用

本單元結束後，你能……

- 能寫出虛無與對立假設，並依自變量與依變量的型態選出適當檢定。
- 能正確陳述 p 值的定義，並指出至少三種常見誤用。
- 能計算並解讀 95% 信賴區間，說明它與顯著性判斷的關係。
- 能產出含統計量、自由度、精確 p 值、效應量與信賴區間的 APA 報告句。
- 驗收方式 ① 對應作業 A1、A5、B1；② 對應 A1、A8、B5；③ 對應 A3、B3；④ 對應 A5、B3、B6。

A

推論的核心邏輯

From Sample to Population — The Logic

核心問題：能推論到更大的世界嗎？

- 兩個樣本不會完全相同，但共享某些特徵（如平均值）
- 我們要判斷：樣本中看到的關係，用「若 H_0 為真，出現這種資料的機率有多低」來評估

虛無假設 H_0

假定「沒有效果／沒有差異／沒有關係」，例如兩組平均相等。差異僅來自隨機巧合。

例：新、舊教學法的平均成績相同。

對立假設 H_1

假定「存在效果／差異／關係」，例如兩組平均不相等。差異是系統性的。

例：新、舊教學法的平均成績不同。

為何「反駁 H_0 」而非「證明 H_1 」？

- H_0 明確 ($\mu_1 = \mu_2$) $\rightarrow$ 可建立機率分佈； H_1 模糊 ($\mu_1 \neq \mu_2$) $\rightarrow$ 無法建唯一模型
- p 值 = 「當 H_0 為真時，觀察到這樣（或更極端）資料的機率」
- p 值不是「 H_1 為真的機率」，而是反駁 H_0 的證據強度
- 可證偽性（Popper）：科學假說不能被證明為真，只能被證明為假
- 若 $p < \alpha$ （常用 0.05） $\rightarrow$ 拒絕 H_0 ，結果具統計顯著性

白話：假設檢定是『機率版的反證法』

數學反證法 假設命題為假 $\rightarrow$ 推出『不可能』的矛盾 $\rightarrow$ 命題必為真；結論 100% 確定。


假設檢定 假設 H_0 （沒效果）為真 $\rightarrow$ 算出看到這種資料的機率 $p \rightarrow p$ 很小只代表『很不像』，不是『不可能』
 $\rightarrow$ 推翻 H_0 ，但結論永遠帶著 α （例如 5%）的誤判風險，所以不說『證明』。

為何不直接證 H_1 『有效』可以是差 1 分、2 分、10 分……沒有單一數字可算機率；『沒效』只有一種（差 = 0），才算得出 p 。

p 值在分佈上長什麼樣

在 H_0 為真的前提下，有多極端

p 值 = 在 H_0 （虛無假設）為真的前提下，看到『這麼極端或更極端』結果的機率



教學重點 p 值不是「 H_0 為真的機率」，而是「若 H_0 為真，看到這麼極端結果的機率」——方向不能反。

p 值直覺：把假設檢定想成一場審判

為什麼我們『反駁 H_0 』而不是『證明 H_1 』

無罪推定 = H_0 法庭預設『被告無罪』（沒有效果），除非證據夠強才推翻。

證據 = 你的資料 資料越『不像無罪該有的樣子』，越傾向定罪（拒絕 H_0 ）。

p 值 = 若真的無罪、出現這麼不利證據的機率 p 很小 = 這種證據在『無罪』下很罕見 → 推翻無罪推定。

判『無罪』 ≠ 證明清白 不顯著只代表『證據不足』，不代表『證明沒效果』（無罪判決 ≠ 證明沒做）。

例 新教學法研究：先假設『沒效』。若真的沒效，兩班差到 6 分的機率只有 0.8% ($p = .008$) → 太不像巧合 → 推翻『沒效』。

教學重點 $\alpha = .05$ 就像『定罪門檻』：若被告其實無罪，仍有 5% 機率被定罪（Type I）。門檻訂多嚴是價值取捨，非真理。

假設檢定的五個步驟

每個推論檢定都照這條線走

① **立假設** 寫出 H_0 。（無效果）與 H_1 （有效果）；決定單尾或雙尾。

② **定顯著水準 α** 通常 .05——願承擔的偽陽性風險。

③ **算檢定統計量** 依資料型態選檢定，算出 $t / F / \chi^2 / r$ 等。

④ **求 p 值** 在 H_0 為真下，出現這樣（或更極端）結果的機率。

⑤ **下決策** $p < \alpha \rightarrow$ 拒絕 H_0 。（顯著）；並報告效應量與信賴區間。

實例 新 vs 舊教學法（第 48 張）：① H_0 兩班平均相同、雙尾 ② $\alpha = .05$ ③ $t(58) = 2.73$ ④ $p = .008$ ⑤ $.008 < .05 \rightarrow$ 拒絕 H_0 ，並報 $d = 0.70$ 、95% CI [1.6, 10.4]。

教學重點 第 ⑤ 步不是終點——『拒絕 H_0 』只說『有差異』，還要用效應量與 CI 說明『差多少、多確定』。

t / F / χ^2 / r 到底在算什麼？

第③步『算檢定統計量』——四個常見統計量的白話

t（用於 t 檢定）

兩組（或前後）的『平均差』÷『標準誤』。

= 差距是雜訊的幾倍；越大越可能顯著。

何時用 比較兩組或前後兩次的平均（例：新 vs 舊教學法的成績）

χ^2 卡方（用於卡方檢定）

$\sum (\text{觀察}-\text{期望})^2 \div \text{期望}$ 。

= 實際次數與『無關聯時的期望』差多少。

何時用 兩個類別變數有沒有關聯（例：性別 × 是否購買）

F（用於 ANOVA）

『組間變異』÷『組內變異』。

= 各組差異相對於組內雜訊；越大越可能不同。

何時用 比較三組以上的平均（例：A、B、C 三種教學法）

r 相關係數（相關 / 迴歸）

兩個數值變數的線性關聯，範圍 -1~+1。

0= 無關，±1= 完全線性；本身就是效應量。

何時用 兩個數值變數是否一起變動（例：讀書時數 × 成績）

重點 四者都是『訊號 ÷ 雜訊』家族：算出統計量後，再對照它的分佈查 p 值，判斷是否顯著。

推論要做兩件事

① 推論單變量統計

- 問：母體的平均值大概在哪裡？
- 由「樣本平均」估計「母體平均」
- 受兩股力量影響：變異、樣本數

② 推論變量間的關係

- 問：母體中各組平均是否真的不同？
- 由「樣本中的關係」推論「母體的關係」
- 受三股力量影響：效應量、變異、樣本數


重點 本單元先談「關係的推論」（各檢定），因為它正是論文結果章要回答的核心。

中央極限定理：為什麼可以用常態


母體再怎麼歪，樣本平均都會趨近常態

不管母體長什麼樣，樣本平均的分佈都會趨近常態，而且 n 越大越窄


母體（明顯右偏，平均 3）



樣本平均的分佈（每次抽 $n = 5$ ）



樣本平均的分佈（每次抽 $n = 50$ ）



教學重點 這就是「用樣本推論母體」的理論基礎： n 越大，樣本平均的分佈越窄也越常態。

三個關鍵量：中英對照與白話

上一頁的『變異、樣本數、效應量』到底指什麼？

變異 Variation

定義 每個資料點離平均有多遠的整體程度，常用標準差 SD。

用意 代表『雜訊』：雜訊越大，越難看出真正的差異。

例 兩班平均都 75 分；A 班 SD = 3、B 班 SD = 15，B 班亂得多。

樣本數 Sample Size

定義 實際測量的觀察單位數（人、病人、事件），記為 N 或 n。

用意 決定估計多精確： $SE = SD \div \sqrt{N}$ ，人越多越穩。

例 同樣 SD = 10：N = 25 時 SE = 2；N = 100 時 SE = 1。

效應量 Effect Size

定義 差異或關聯的實際大小，不受樣本數影響；如 Cohen's $d = \text{平均差} \div SD$ 。

用意 回答『差多少、值不值得在意』；p 值只回答『像不像巧合』。

例 平均差 6 分、SD 8.5 $\rightarrow d = 0.70$ （中到大）。

重點 推論『單變量』（估平均）只受變異＋樣本數影響；推論『關係』（比較 / 關聯）再加上效應量——共三股力量。

抽樣分佈與標準誤：推論的地基

樣本平均本身也會波動——標準誤就是在量這個波動

抽樣分佈 反覆抽樣、每次算一個樣本平均，這些平均值形成的分佈。

中央極限定理 CLT N 夠大時抽樣分佈近似常態；母體不太偏斜時約 30 即可，極度偏斜需更多。

標準誤 SE 抽樣分佈的標準差 = $SE = SD \div \sqrt{N}$ ；量『樣本平均離母體平均多遠』。

關鍵 SD 描述『個別資料』的分散； SE 描述『樣本平均』的分散—— N 越大 SE 越小。

例 $SD = 10$ 、每次抽 25 人：個別資料常在平均 ± 20 內跳動（約 2 SD ），樣本平均卻只在 ± 4 內跳動（約 2 SE ， $SE = 2$ ）。

教學重點 所有推論（ t 、 CI 、 p ）都建立在抽樣分佈上： SE 越小，樣本平均越可信，越能偵測真實差異。

標準誤直覺：為什麼『平均』比『單一資料』可信

同樣的資料，取平均就把雜訊抵消了

單一測量會抖 量一次身高，可能因姿勢、儀器而差 1-2 公分。

取平均會穩 量很多次再平均，高估與低估互相抵消，越接近真值。

SE 就是在量這個 $SE = SD \div \sqrt{N}$ ：N 越大，『樣本平均』的抖動越小。

實感例子 SD = 10 的母體：N = 1 時估計的典型誤差約 10；N = 100 時約 1（SE = 1）。

教學重點 『大樣本較可信』的直覺不是資料變乖了，而是『平均』這個估計本身變穩了——這正是所有推論的地基。

推論單變量：兩條規則

規則 1：變異越大，估計越飄

- 母體變異越大，樣本平均越容易偏離母體平均
- 最壞情況：抽到極端值，樣本平均偏很多
- 例：母體平均 = 5，若變異大， $N=1$ 可能抽到 9

規則 2：樣本越大，估計越穩

- 樣本數越大，樣本平均越接近母體平均
- $N=1 \rightarrow$ 很不穩； $N=2、3 \dots \rightarrow$ 逐漸收斂
- 若 N 很大（如 100000），單點的影響幾乎消失

重點 同一個道理之後會擴充到「關係的推論」——變異要小、樣本要大，結論才可靠。


兩條規則，看圖就懂

每個點＝抽一次樣本算出的『樣本平均』（各抽 12 次）；點越集中在母體平均 $\mu = 5$ ，估計越穩

規則 1：變異越大，估計越飄

小變異 (SD 小)

樣本平均都在
4.5–5.5



大變異 (SD 大)


樣本平均散到
2.5–7.5



規則 2：樣本越大，估計越穩

大樣本 $N = 100$

樣本平均都在
4.5–5.5



小樣本 $N = 5$

樣本平均散到
2.5–7.5



重點 變異（能否縮小）常受測量與母體限制；樣本數（能否加大）是研究者最能主動控制的旋鈕。

標準誤完整範例： N 如何讓估計變穩

母體標準差 $SD = 10$

樣本數 N	標準誤 $SE = SD \div \sqrt{N}$	95% 誤差範圍 $\approx \pm 1.96 \times SE$
N = 25	$10 \div \sqrt{25} = 10 \div 5 = 2.0$	± 3.9
N = 100	$10 \div \sqrt{100} = 10 \div 10 = 1.0$	± 2.0
N = 400	$10 \div \sqrt{400} = 10 \div 20 = 0.5$	± 1.0

怎麼讀 SE = 樣本平均每次抽樣會晃多少；誤差範圍 $\pm 1.96 \times SE = 95\%$ 的樣本平均會落在母體平均的這個距離內。
看趨勢 N 從 25 $\rightarrow$ 100 ($\times 4$)，SE 從 2.0 $\rightarrow$ 1.0 (減半)；N 再 $\times 4$ 到 400，SE 才再減半為 0.5—— 加人的效益越來越小。

教學重點 SE 隨 $\sqrt{N}$ 縮小——要把精度加倍 (SE 減半)，樣本數要變 4 倍。這就是『大樣本較穩』的數學根據。

那張表的第 2、3 欄是怎麼算出來的？

以母體 $SD = 10$ 、 $N = 100$ 這一系列逐步拆解

第 2 欄 $SE = SD \div \sqrt{N}$

意思：平均值的估計誤差（標準誤）。
 SD 是資料分散度， $\sqrt{N}$ 讓大樣本更穩。

以 $N=100$ ：

$$SE = 10 \div \sqrt{100} = 10 \div 10 = 1.0$$

N 變 4 倍 (400) $\rightarrow \sqrt{N}$ 變 2 倍
 $\rightarrow SE$ 減半 (0.5)。

第 3 欄 95% 誤差範圍 $\approx \pm 1.96 \times SE$

意思：平均值上下大約這麼多，
就有 95% 的信心涵蓋母體平均。

以 $N=100$ ：

$$\pm 1.96 \times 1.0 \approx \pm 2.0$$

1.96 來自常態分佈的『中間 95%』
(下一頁專門說明)。

重點 一句話：先用 SD 與 $\sqrt{N}$ 算出『一個 SE 』，再乘 1.96，得到『95% 的誤差範圍』。

信賴區間：不只給一個點，還給一個範圍

點估計（樣本平均） + 不確定性（SE） = 區間估計

公式 95% CI = 樣本平均 $\pm 1.96 \times SE$ （大樣本、常態近似）。

正確解讀 若重複抽樣很多次，約 95% 的這種區間會涵蓋『真正的母體平均』。

常見誤解 不是『母體平均有 95% 機率落在此區間』——母體平均是固定的，隨機的是區間。


與檢定的關係 若虛無值（如 0）落在 95% CI 之外 $\rightarrow$ 等同 $p < .05$ 顯著。

例 第 21 張：M = 52、SE = 2.0、N = 25 $\rightarrow$ 95% CI [47.87, 56.13]——母體平均很可能落在 48 到 56 之間。

教學重點 CI 比單一 p 值資訊更多：同時給你『效應方向、大小與精確度』——期刊越來越要求報 CI。

1.96 是怎麼來的？

標準常態分佈：中間 95%，兩尾各留 2.5%



重點 要涵蓋『中間 95%』，就要切掉兩尾各 2.5%——這兩個切點的 z 分數正好 $\approx \pm 1.96$ 。要 99% 則用 ± 2.58 。

信賴區間完整範例 + 判讀

樣本： $M = 52$ 、 $SD = 10$ 、 $N = 25$

① 算 SE $SE = 10 \div \sqrt{25} = 2.0$

② 算 95% CI 母體 σ 未知、以樣本 SD 估計 $\rightarrow$ 用 $t(24)=2.064$ (非 1.96) : $52 \pm 2.064 \times 2.0 = 52 \pm 4.13 = [47.87, 56.13]$

③ 解讀 以此程序長期重複抽樣，約 95% 的區間會涵蓋母體平均；不可說「母體平均有 95% 機率落在此區間」。

④ 對照假設檢定 若 $H_0: \mu = 50 \rightarrow 50$ 落在區間內 $\rightarrow$ 無法拒絕 H_0 (不顯著)；若 $H_0: \mu = 47 \rightarrow 47$ 在區間外 $\rightarrow$ 拒絕 (顯著)。

教學重點 CI 寬度 = 不確定性：N 越大、變異越小，區間越窄、估計越精確。窄而明確的 CI 比『只報 $p < .05$ 』更有說服力。

信賴區間直覺：撒網捕魚

95% 信心，指的是『網』而不是『魚』

魚（母體平均 μ ）是固定的 它在水裡某個位置，不會動。

每次抽樣＝撒一次網（一個 CI） 網的位置隨你抽到的樣本而變。

95% CI 的意思 用這種方式撒 100 次網，約 95 次會『罩住』那條魚。


常見誤解 不是『這條魚有 95% 機率在這張網裡』——魚固定、網才是隨機的。

例 每年抽一次樣、算一個 95% CI，連做 20 年：大約 19 年的網會罩住真正的平均，1 年落空——但你不知道是哪一年。

教學重點 所以看到一個 95% CI，別說『 μ 有 95% 機率落在此區間』；而是『這個程序長期有 95% 的涵蓋率』。


變異大小如何影響「能否推論」

變異小 → 差異清楚、可推論



兩座山幾乎不重疊 → 差異看得清楚，容易顯著

變異大 → 差異被雜訊蓋住



兩座山大量重疊 → 差異被雜訊蓋住，難以顯著

重點 兩邊「平均差」一樣，但左邊變異小、兩座山不重疊 → 容易顯著；右邊變異大、兩座山重疊 → 難以顯著。

推論關係的三股力量

1

效應量 Effect Size

組間差異的實際大小；越大越易達顯著。

越大越好

2

變異性 Variation

資料的波動程度；越小結果越穩定。

越小越好

3

樣本量 N

越大檢定力（power）越強，越能偵測小效應。

越大越好

重點 三者共同決定 p 值：效應大、變異小、樣本大 → p 值小 → 越可能推論到母體。

三股力量，用一個比喻＋一組數字看懂

為什麼『效應大、變異小、樣本大』會讓 p 變小？

比喻 p 值像『訊號 vs 雜訊』：訊號＝效應量（差多大）；雜訊＝變異 ÷ 樣本（估得多不準）。訊號蓋過雜訊 → p 小。

同樣是『平均差 4 分』 若 $SD=20$ 、每組 $n=10$ （雜訊大）→ $t \approx 0.45$ ，差被淹沒 → $p \approx .66$ 不顯著。

若 $SD=5$ 、每組 $n=100$ （雜訊小）→ $t \approx 5.7$ ，同樣 4 分清楚浮現 → $p < .001$ 顯著。

三個旋鈕 效應量 ↑、變異 ↓、樣本數 ↑，任一個都讓 p 變小；研究設計能主動控制的是後兩個。

重點 所以『不顯著』不一定沒效果——可能是變異太大或樣本太小，把真效果蓋住了。

為什麼門檻是 0.05 ？

門檻（ α ）＝「把其實無效的結果，誤判為顯著」的可接受機率。

- $\alpha = 0.05 \rightarrow$ 你接受「5% 誤判為顯著」的風險
- $\alpha = 0.01 \rightarrow$ 更嚴格，誤判機率降到 1%（需要更強證據）
- 多數科學家認為 5% 的誤判風險「夠好」，因此以 0.05 為慣例門檻
- 門檻不是真理，而是一個「群體共識的決策線」——不同領域可能不同


單尾 vs 雙尾檢定：方向要不要事先決定

雙尾檢定（預設）

$H_1: \mu_1 \neq \mu_2$ （沒指定方向）。

α 分到兩尾（各 .025）。

適用：不確定方向、要偵測任一方向差異。




單尾檢定

$H_1: \mu_1 > \mu_2$ （事先指定方向）。

α 全放一尾 → 同樣 α 下檢定力較高。

限制：只能在有強理論依據、且事先決定時使用。



教學重點 單尾『看到資料才改成單尾』是作弊（會膨脹偽陽性）。除非事前有明確方向假設，否則用雙尾較保守、可信。

單尾 vs 雙尾：白話版與兩個例子（承前頁定義）

方向要不要事先賭定？

白話 雙尾問『有沒有不同（變好或變差都算）』；單尾問『是不是特別好（只看一個方向）』。

例·雙尾 新藥 vs 安慰劑， H_1 ：藥效 $\neq$ 安慰劑。若新藥反而讓病情更差，雙尾也抓得到——這是新藥試驗與多數論文的做法。

例·單尾 H_1 ：藥效 $>$ 安慰劑，只問『有沒有比較好』。若藥其實更差，單尾只會判『不顯著』，你不會發現它有害。

同一結果 算出 $z = 1.80$ ：雙尾的臨界值是 $\pm 1.96 \rightarrow p = .072$ ，不顯著；單尾的臨界值是 $1.645 \rightarrow p = .036$ ，顯著。

所以 看到結果才改用單尾，等於把不顯著『變成』顯著——這就是為什麼要事先寫在計畫書，沒寫就用雙尾。

重點 口訣：沒有事前的強方向假設 $\rightarrow$ 一律用雙尾。

兩種錯誤與檢定力：推論一定會冒的風險

這張表在 2.3 第 21 張出現過；這裡用它來讀懂：顯著、不顯著，各自可能錯在哪

真實 \ 你的判定	拒絕 H_0 。（宣稱有差異）	未拒絕 H_0 。（證據不足，非證明無差異）
H_0 為真（其實無差異）	× Type I（ α ，偽陽性）	✓ 正確（ $1-\alpha$ ）
H_0 為假（其實有差異）	✓ 檢定力 Power（ $1-\beta$ ）	× Type II（ β ，偽陰性）


Type I 例 藥其實無效，你卻說有效 → 病人吃沒用的藥

Type II 例 藥其實有效，你卻說沒差 → 好藥被放棄

怎麼用：① 檢定前先定 α （第一列錯誤上限）② 規劃樣本數讓 Power $\geq .80$ （2.6）③ 讀結果：顯著仍可能是 Type I，不顯著可能是 Type II → 看效應量與 CI

教學重點 α 管『偽陽性』、 β 管『偽陰性』、Power = $1-\beta$ 。要 α 更嚴（.01）就得付出更高 β ，或加大樣本補回檢定力。

從三因素到 p 值的判斷流程



例 (第 48 張) 新 vs 舊教學法：平均差 6 分、 $d = 0.70$ (效應量)；合併 SD 8.51 (變異)；每組 30 人 (樣本數) → $t(58) = 2.73$ ， $p = .008$ ，顯著。

對照 同樣 6 分差距、同樣 SD，若每組只收 8 人： t 約 1.41、 p 約 .18 → 不顯著。差的不是效果，是樣本數。

重點 效應量、變異性、樣本數共同決定 p 值： $p < .05$ → 資料與 H_0 不相容，拒絕 H_0 ； $p \geq .05$ → 證據不足以拒絕 H_0 ，不等於沒有效果。

統計顯著 $\neq$ 實務重要

p 小不代表效果大

大樣本陷阱 N 很大時，微不足道的差異也會 $p < .05$ ——顯著只說『與 H_0 不相容』，沒說『很重要』。

效應量才談大小 d 、 η^2 、 r 、OR 這些才回答『差多少、關聯多強』。

信賴區間看精確度 窄 CI = 估計精確；若 CI 幾乎貼著 0，就算顯著也要謹慎。

實務門檻 要問：這個效果在你的領域『值不值得在意』？（臨床顯著性 vs 統計顯著性）

例 第 33 張研究 A： $N = 10,000$ 、 $d = 0.05$ （幾乎沒差）也能 $p = .01$ ——顯著，但實務上不值得在意。

教學重點 結果一律『三件一起報』：檢定統計量 + 精確 p 值 + 效應量（與 CI）——只報 p 是不完整的。

顯著 $\neq$ 重要：兩個生活化例子

p 過門檻，不代表值得在意

① **顯著但不重要** 某 App 讓每日步數平均多 12 步， $n=50000 \rightarrow p<.001$ 。統計顯著，但 12 步對健康幾乎沒差。

② **重要但未達顯著** 新復健讓行走距離多 40 公尺（很有意義），但只收 8 人、變異大 $\rightarrow p=.09$ 。效果可能真實，只是樣本太小沒測出來。

怎麼判斷 看效應量（差多少）+ 信賴區間（多確定），別只看 p 有沒有過 .05。

重點 『有沒有差』（p）與 『差多少、值不值得』（效應量）是兩個不同問題，兩個都要回答。

效應量 vs p 值：兩個研究看懂差別

同樣是『 $p < .05$ 』，意義可能天差地別

	研究 A	研究 B
樣本數 N	10,000	40
效應量 Cohen's d	0.05 （幾乎沒差）	0.90 （很大）
p 值	$p = .01$ （顯著）	$p = .007$ （顯著）
實務意義	幾乎沒用——大 N 讓微小差異也顯著	重要——效果大，小樣本仍達顯著

教學重點 只看 p 會把 A、B 當一樣；看效應量與 CI 才知道 A 『顯著但沒意義』、B 『顯著且重要』——這就是一定要報效應量的原因。

把上頁兩個研究讀成白話

同樣 $p < .05$ ，意義天差地別

研究 A $N=10000, d=0.05, p=.01 \rightarrow$ 因為人非常多，連幾乎看不見的差 ($d=0.05$) 也被判顯著。實務上可忽略。

研究 B $N=40, d=0.90, p=.007 \rightarrow$ 人不多，但效果很大 ($d=0.90$)，所以仍達顯著。實務上重要。

關鍵 p 會被 N 放大； d 不會。 d 才是跨研究可比較的『效果大小』。

Cohen's d 參考 0.2 小、0.5 中、0.8 大。

重點 只報 p 、不報 d 與 CI ，審稿人通常會要求補——因為讀者無法判斷 A 與 B 的差別。

各檢定的效應量一覽與基準

檢定	效應量	小 / 中 / 大 (粗略基準)
t 檢定	Cohen's d	0.2 / 0.5 / 0.8
ANOVA	η^2 (或 partial η^2)	.01 / .06 / .14
相關 / 迴歸	r (r^2 為解釋變異)	.10 / .30 / .50
邏輯斯迴歸	勝算比 OR	$\approx 1.68 / 3.47 / 6.71$ (Chen et al., 2010 ; 基準率 1%)
卡方	Cramér's V	.10 / .30 / .50 (df=1)

Cohen's d 尺規：效應量的實務意義



教學重點 效應量與『樣本數無關』，所以能跨研究比較、放進統合分析 (meta-analysis) ； p 值則會隨 N 變。

B

選對統計檢定

How to Apply Inferential Statistics

選擇統計檢定的決策表

IV	DV	檢定方法
類別（2 組）	數值	t 檢定
類別（ ≥ 3 組，組間）	數值	單因子 ANOVA
類別（ ≥ 3 組，組內／混合）	數值	重複量數 ANOVA（RM ANOVA）
數值	數值	皮爾森相關 / 迴歸
數值	類別	邏輯斯迴歸
類別	類別	卡方檢定

先選檢定 → 考慮效應量、變異、樣本數 → 算出 p 值 → 判斷 H_1 或 H_0 。（IV / DV 屬哪一種，看測量尺度——見 2.2）

檢定的基本假設：先檢查再解讀

檢定	主要假設	違反時怎麼辦
t / ANOVA	常態性、變異數同質、獨立	Welch 校正；或改無母數
相關 / 迴歸	線性、常態、等分散 (homoscedasticity)	轉換變數；或用 Spearman
卡方	期望次數 < 5 的格 $\leq 20\%$ 且無 < 1 、觀察獨立	合併類別；或 Fisher 精確檢定

教學重點 假設不是形式：變異數嚴重不同質或小樣本非常態時，硬跑 t/ANOVA 的 p 值不可信——先看圖與檢定（如 Levene）。

假設違反了，實際怎麼處理？

先檢查，再決定用原檢定或替代方案

常態性 小樣本又嚴重偏態 → 改無母數：Mann-Whitney（兩組）／Kruskal-Wallis（多組）。

變異數同質 兩組 SD 差很多（如 3 vs 12）→ 用 Welch t／Welch ANOVA（不假設同質）。

期望次數 < 5（卡方） 某格期望人數太少 → 合併類別，或改 Fisher 精確檢定。

怎麼先發現 先畫圖（直方圖 / 箱型圖），再跑 Levene（同質）、Shapiro（常態）。


重點 假設不是官僚手續：嚴重違反時 p 值會失真——先檢查、再解讀。

無母數替代：資料不符假設時的備案

母數檢定	無母數替代	用於
獨立樣本 t	Mann–Whitney U	兩組、非常態或序位資料
配對 t	Wilcoxon signed-rank	前後、非常態
單因子 ANOVA	Kruskal–Wallis	≥ 3 組、非常態
Pearson r	Spearman ρ	序位或非線性單調關係

教學重點 無母數檢定用『排序』而非原始值，對離群值與偏態較穩健；代價是檢定力略低、且比較的是中位數 / 分佈位置。

統計檢定決策樹



重點 口訣：先定 DV 型態，再看 IV 型態與組數，一路往下即可決定：相關、t 檢定（2 組，即 ANOVA 的特例）、ANOVA、RM ANOVA、卡方或邏輯斯迴歸。

顯著代表什麼？取決於研究設計

無混淆的實驗

- H_1 ：治療「造成」了差異（只有一種因果解釋）
- H_0 ：兩組母體無差異
- 顯著 → 可下「因果」結論

非實驗（無隨機化）

- H_1 ：可能是治療影響疾病、疾病影響治療，或第三變項
- H_0 ：兩組母體無差異
- 顯著 → 只能下「關聯」結論，不能斷定因果

重點 同樣是「 $p < 0.05$ 」，實驗能談因果、非實驗只能談關聯——回想單元 1 的三種因果解釋。

實驗 vs 非實驗：白話與例子

差別在有沒有『隨機分派』

實驗 Experiment

研究者『主動操弄』IV，並『隨機分派』受試者到各組。

例：把 60 位病人隨機分到 App 組／等候組。

→ 兩組事前條件平均相同，若有差，可歸因於介入 → 可談因果。

非實驗 Non-experiment（觀察型）

研究者『只觀察、不操弄』，分組是既存的。

例：比較『本來就有用 App』vs『沒用』的人的壓力。

→ 兩群人可能本來就不同（年齡 / 動機），差異或來自第三變項 → 只能談關聯。


重點 同樣 $p < .05$ ，實驗能說『造成』，非實驗只能說『有關聯』——差別在研究設計，不在統計。

C

六種推論檢定

Six Inferential Tests

① 相關的推論（數值 IV × 數值 DV）



- $r = 0.88$ ：強正相關（ r 介於 $-1 \sim 1$ ）
- 勾選 report significance 取得 p 值
- $p < 0.001 \rightarrow$ 顯著，可拒絕 H_0
- $r(28)$ ：括號內為自由度（ $= N-2$ ）

APA 報告： $r(28) = .88, p < .001$

① 相關推論完整範例： r 顯著嗎？

資料：讀書時數 vs 成績， $r = .88$ 、 $N = 30$

① 自由度 $df = N - 2 = 28$

② 檢定統計量 $t = r\sqrt{df} \div \sqrt{1-r^2} = .88 \times \sqrt{28} \div \sqrt{1-.774} \approx 4.66 \div .475 \approx 9.8$

③ p 值 $t(28) = 9.8 \rightarrow p < .001 \rightarrow$ 拒絕 H_0 。（母體相關 $\neq 0$ ）

④ 效應與精確度 $r^2 = .77$ （成績變異約 77% 與讀書時數共變）；95% CI 約 [.76, .94]

APA $r(28) = .88, p < .001, 95\% \text{ CI } [.76, .94]$

教學重點 相關『顯著』只表示母體相關不為 0；仍是關聯非因果，且要看 r 的大小（效應量）而非只看 p 。

② ③ 平均差異的推論： ANOVA / RM ANOVA

ANOVA (組間)

- 比較兩組（或多組）平均是否有差異
- 效應量： η^2 / partial η^2 （亦可報平均差）
- $F(1, 58)$ ：括號內為自由度

RM ANOVA (組內)

- 純組內設計無分組因子，比「治療前 vs 後」
- 同一群人重複測量 → 控制個體差異
- 所需樣本數比組間設計少

APA 報告： $F(1, 58) = 37.91, p < .001, \eta^2 = .40$ （後測 M：治療 4.63 vs 控制 7.65）

獨立樣本 t 檢定完整範例（兩組）

新教學法 $M=78, SD=8, n=30$ vs 傳統 $M=72, SD=9, n=30$

① 假設 H_0 ：兩組母體平均相等； H_1 ：不相等（雙尾）。

② 平均差 $78 - 72 = 6$ 分

③ 合併標準差與 SE $\text{pooled SD} = \sqrt{((8^2+9^2)/2)} \approx 8.51$ ； $SE = 8.51 \times \sqrt{(1/30+1/30)} \approx 2.20$

④ t 與 df $t = 6 \div 2.20 \approx 2.73$ ； $df = 30+30-2 = 58 \rightarrow p \approx .008$ 顯著

⑤ 效應量 Cohen's $d = 6 \div 8.51 \approx 0.70$ （中大效應）


APA $t(58) = 2.73, p = .008, d = 0.70, 95\% \text{ CI } [1.6, 10.4]$

教學重點 兩組比較用獨立 t；2 組時 $F = t^2$ （ANOVA 與 t 一致）。務必同時報 d 與 CI，別只報 p。

獨立 t：兩組分佈與『差 ÷ 雜訊』

兩組重疊越少，差距相對雜訊越大 → t 越大

兩組分佈重疊越少 → 差距相對雜訊越大 → t 越大



重點 $t = \text{平均差} \div \text{標準誤 (SE)}$ 。兩條鐘形曲線分越開、越瘦（變異小），重疊越少 → t 越大、越可能顯著。

配對樣本 t 檢定完整範例（同一批人前後）

減重前後（同 25 人）：平均差 $\bar{d} = 3 \text{ kg}$ 、差的 $SD = 4$ 、 $n = 25$

- ① 假設 H_0 ：前後母體平均相等（ $\mu_{\text{差}} = 0$ ）； H_1 ：不相等。
 - ② SE of 差 $SE = \text{差的 } SD \div \sqrt{n} = 4 \div \sqrt{25} = 0.80$
 - ③ t 與 df $t = 3 \div 0.80 = 3.75$ ； $df = n - 1 = 24 \rightarrow p \approx .001$ 顯著
 - ④ 效應量 $d_z = 3 \div 4 = 0.75$ （中大效應）
- APA $t(24) = 3.75, p = .001, d_z = 0.75$

教學重點 配對 t 用『每個人的前後差』——去除個體差異，所以比獨立設計省樣本、檢定力高（回想單元 1 的受試者內）。

配對 t：為什麼用『每人前後差』？

同一批人量兩次，不是兩群不同的人

資料長相 同一個人量前、後兩次（或自然配對：雙胞胎、左右手）。

關鍵動作 先把每個人的『後 - 前』算成一個差值，再檢定這些差的平均是否為 0。

為何這樣做 每個人當自己的對照，消掉『個體本來就有高有低』的差異（雜訊變小）→ 檢定力比獨立設計高、更省人。

效應量 $dz = \text{平均差} \div \text{差的 SD}$ （本例 $3 \div 4 = 0.75$ ）。

重點 判斷要不要用配對：問『這兩筆數字是不是同一受試者（或配對）產生的？』是 → 配對 t。

單因子 ANOVA 完整範例 (≥ 3 組)

三種教學法 (各 $n=10$) 成績平均: $A=70$ 、 $B=75$ 、 $C=82$

① 假設 H_0 : 三組母體平均都相等; H_1 : 至少一組不同。

② F 的邏輯 $F = \text{組間變異 (MS between)} \div \text{組內變異 (MS within)}$ —— 組間差異相對於雜訊有多大。

③ 結果 $F(2, 27) = 8.00, p = .002 \rightarrow$ 拒絕 H_0 。(各組不全相等)。


④ 效應量 $\eta^2 = \text{SS between} \div \text{SS total} \approx .37$ (大效應)。

APA $F(2, 27) = 8.00, p = .002, \eta^2 = .37$

教學重點 ANOVA 只說『至少有一組不同』，沒說『哪兩組不同』——要靠事後比較（下一頁）。

ANOVA：組間 vs 組內，看圖秒懂

平均線分越開、組內點越集中 → F 越大



重點 粗橫線是各組平均、散點是組內個別值。 $F = \text{平均線分多開 (組間)} \div \text{點的散佈 (組內)}$ 。

ANOVA 的 F 在比什麼？

組間差異 相對於 組內雜訊

F 的定義 $F = \text{組間變異} \div \text{組內變異} = \text{『各組平均差多開』}$ 相對於 『組內本來的雜訊』。

直覺 三組平均 70/75/82 差 12 分。若組內每人也上下飄 20 分 → 差被雜訊蓋住（F 小）；若組內很集中 → 差很明顯（F 大）。

結果 F 大 → p 小 → 拒絕 H_0 ：至少有一組不一樣（但還不知是哪兩組）。

效應量 $\eta^2 = \text{組間} \div \text{總變異} = \text{『組別』}$ 能解釋幾成分數變異（本例 .37）。

重點 ANOVA 只回答『有沒有人不一樣』；要知道『誰跟誰不一樣』，看下一頁的事後比較。

ANOVA 事後比較：到底哪幾組不同？

為何需要 ANOVA 顯著只代表『組間有差異』；要知道 A、B、C 誰跟誰不同，得再兩兩比較。

為何不直接多次 t 3 組要比 3 次、每次 $\alpha=.05 \rightarrow$ 累積偽陽性膨脹；事後檢定會『校正』這個問題。

常用方法 Tukey HSD（各組人數相近時最常用）、Bonferroni（保守）、Games-Howell（變異數不同質）。

範例判讀 Tukey：C 顯著高於 A（ $p=.001$ ），C vs B、B vs A 未達顯著 $\rightarrow$ 差異主要來自 C。

教學重點 先看 ANOVA 是否顯著（總體），再做事後比較（局部）；報告要同時給整體 F 與兩兩差異 + 效應量。

事後比較：為何不能直接多跑幾次 t?

多次比較會膨脹偽陽性

問題 3 組兩兩比要比 3 次，每次偽陽性 5% → 至少一次誤判的機率累積到約 14%；組數越多越嚴重。

解法 事後檢定 (Tukey / Bonferroni...) 會『校正』門檻，把整體偽陽性壓回 5%。


怎麼選 人數相近 → Tukey HSD；要最保守 → Bonferroni；變異數不同質 → Games-Howell。

讀法 (本例) Tukey 顯示 C 顯著高於 A；C-B、B-A 未達顯著 → 差異主要來自 C。

重點 流程固定：先看整體 ANOVA 是否顯著，再做事後兩兩比較，並各自報效應量。

ANOVA 的敘述結果與假設

Illness



Before

After

H_0 虛無假設


前後（母體）平均相等，
沒有差異。

H_1 對立假設

前後（母體）平均不相等，
有差異。

重點 H_0 ：前後（或兩組）母體平均相等； H_1 ：不相等。箱型圖先看差異，再用檢定判斷是否顯著。

④ 混合設計的推論 (RM ANOVA)



- 問題：這個型態是巧合，還是能推論到母體？
- 控制組前後幾乎相同；治療組後測明顯下降
- 檢定「時間 × 組別」交互作用
- 交互作用顯著 → 治療確有作用

APA 報告：時間 × 組別 交互作用 $F(1, 58) = 10.20, p = .002$

④ 混合設計交互作用完整範例（RM ANOVA）

疾病分數：治療組 前 8.10 → 後 4.63（降 3.47）；控制組 前 8.59 → 後 7.65（降 0.94）


- ① 問的是 『時間 × 組別』 交互作用——治療組的『變化量』是否大於控制組。
- ② 為何看交互作用 單看治療組下降可能是時間 / 安慰劑；要比『兩組變化的差異』（3.47 vs 0.94）。
- ③ 結果 $F(1, 58) = 10.20, p = .002 \rightarrow$ 交互作用顯著 $\rightarrow$ 治療確有作用。
- ④ 效應量 $\text{partial } \eta^2 = \text{SS 效果} \div (\text{SS 效果} + \text{SS 誤差}) = 48.197 \div (48.197 + 274.103) = .15$ （依 .01 / .06 / .14 基準屬大效應）。

APA 時間 × 組別交互作用 $F(1, 58) = 10.20, p = .002, \text{partial } \eta^2 = .15$

教學重點 混合設計的關鍵永遠是『交互作用』，不是單一主效果；控制組若也下降，就要靠交互作用把治療效果分離出來。

交互作用：兩條線看治療效果

兩條線斜率不同，就是交互作用



重點 治療組掉得多、控制組幾乎沒動 → 兩線不平行 = 交互作用顯著 → 治療真的有效（已扣掉時間效應）。

交互作用白話：『看情況』就是交互作用

主效果問『整體有沒有用』；交互作用問『對誰特別有用』

情境 新止痛藥對『年輕人』很有效、對『年長者』幾乎無效。

主效果可能被平均掉 把全體平均起來看，藥效可能只是中等，甚至看不太出來。

交互作用 = 效果『隨年齡而不同』 年齡 × 用藥 的交互作用顯著 = 效果因人而異。

為什麼重要 若忽略交互作用，會誤說『這藥普通』，其實它對特定族群很有用。

教學重點 混合設計的『時間 × 組別』就是同一回事：治療效果是否『因時間而不同』——看交互作用，不是看單一主效果。

用 JASP 執行重複量數 ANOVA

JASP 操作四步（選單以英文介面為準）；右表為輸出節錄，數字同第 59 張

① 資料寬格式

每人一列；前測、後測各一欄

② 開分析

ANOVA → Repeated Measures ANOVA

③ 放變數

前測、後測 → Repeated Measures Cells；組別 → Between Subject Factors

④ 勾選輸出

Descriptive plots、Estimates of effect size (η^2p)

Within Subjects Effects (節錄)

效應	SS	df	MS	F	p	η^2p
時間 × 組別	48.197	1	48.197	10.20	.002	.15
Residuals	274.103	58	4.726			

只看紅色那一列 『時間 × 組別』交互作用
 $F(1, 58) = 10.20$ ， $p = .002 < .05 \rightarrow$ 顯著
 = 治療組前後的變化，和控制組不一樣
 Residuals 是誤差列，用來算 MS 與 F，不用解讀

重點 混合設計在 JASP 以 RM ANOVA 分析；重點看「時間 × 組別」交互作用是否顯著 ($p < 0.05$)。

⑤ 邏輯斯迴歸（數值 IV × 類別 DV）

- IV 數值（如年齡）、DV 類別（如是否購買）
- 檢驗：購買「機率」是否隨年齡而變化
- $p < 0.05 \rightarrow$ 可推論：母體中購買機率確實隨年齡而變
- 勝算比（Odds Ratio, OR）量化關聯強度：OR 接近 1 $\rightarrow$ 效應小；離 1 越遠 $\rightarrow$ 越強

APA 報告： $\exp(b) = 0.88$, $z = -3.67$, $p < .001$ （購買機率隨年齡「顯著下降」）

⑤ 邏輯斯迴歸完整範例（數值 IV × 類別 DV）

年齡（數值）預測是否購買（0/1）


- ① **為何不用線性** DV 是 0/1 機率，用邏輯斯把『勝算的對數』對 IV 建模。
 - ② **勝算比 OR** $\exp(b) = 0.88 \rightarrow$ 年齡每增加 1 歲，購買的『勝算』變為 0.88 倍（下降約 12%）。
 - ③ **方向與顯著** $OR < 1 \rightarrow$ 負向；95% CI [0.82, 0.94] 不含 1 $\rightarrow$ 顯著。
 - ④ **換算機率** 把某年齡代入模型可得預測購買機率（如 30 歲 62% $\rightarrow$ 40 歲 31%；50 歲則降至約 11%，見下頁曲線）。
- APA** OR = 0.88, 95% CI [0.82, 0.94], $z = -3.67$, $p < .001$

教學重點 OR = 1 代表無關聯；離 1 越遠關聯越強。報 OR 一定要附 95% CI——CI 是否跨過 1，就是顯著與否。

邏輯斯：機率的 S 形曲線

把年齡映到 0~1 的購買機率

邏輯斯把年齡映到 0 ~ 1 的購買機率（年齡↑，機率↓）



重點 線性會跑出 0~1 之外；邏輯斯用 S 形把 IV 映到機率。年齡每增 1 歲勝算 $\times 0.88$ （OR<1，負向）。

⑥ 卡方檢定（類別 IV × 類別 DV）

- 檢驗兩個類別變量的關聯（如：性別 對 是否購買）
- 以列聯表的次數與欄百分比為基礎
- $p < 0.05 \rightarrow$ 兩變量有關聯
- $p > 0.05 \rightarrow$ 無法下結論有差異（可能真的無差異，或樣本太小）

APA 報告（不顯著例，另一組小樣本資料）： $\chi^2(1) = 1.71, p = .19$ （男 66% vs 女 50% 購買，差異不顯著）

非顯著 $\neq$ 證明沒差異；務必檢查樣本數是否足夠。

⑥ 卡方檢定完整範例（觀察 vs 期望）

性別 × 是否購買， $N = 150$ ：男 40/60、女 30/20

① **期望次數** 若獨立：男·購買 = $100 \times 70 / 150 = 46.7$ ；女·購買 = 23.3（其餘類推）。

② **卡方值** $\chi^2 = \sum (O-E)^2 / E = (6.67^2 / 46.7) + (6.67^2 / 23.3) + \dots \approx 5.36$

③ **df 與 p** $df = (2-1)(2-1) = 1$ ； $\chi^2(1) = 5.36 \rightarrow p = .021$ 顯著。


④ **效應量** Cramér's $V = \sqrt{(5.36 \div 150)} \approx .19$ （小～中關聯）。

APA $\chi^2(1, N = 150) = 5.36, p = .021, V = .19$ （女購買率 60% > 男 40%）

教學重點 卡方比較『觀察 vs 獨立時的期望』；小樣本（期望 < 5）用 Fisher 精確檢定。顯著只說有關聯，強度看 Cramér's V 。

卡方：觀察 vs 期望，看圖秒懂

實際次數與『無關聯期望』差多少



重點 $\chi^2 = \sum (\text{觀察} - \text{期望})^2 / \text{期望}$ 。藍柱（實際）與灰柱（若無關聯的期望）差越大 $\rightarrow \chi^2$ 越大 $\rightarrow$ 越可能有關聯。

讀統計軟體輸出：擬真範例（獨立 t 檢定）

把 JASP / SPSS 的表，翻成一句 APA 報告

輸出欄位	數值	怎麼讀
t	2.73	檢定統計量
df	58	自由度 ($n_1 + n_2 - 2$)
p (two-tailed)	.008	< .05 → 顯著
Mean Difference	6.00	兩組平均差 (分)
Cohen's d	0.70	效應量 (中大)
95% CI	[1.6, 10.4]	不含 0 → 顯著

翻成 APA $t(58) = 2.73, p = .008, d = 0.70, 95\% CI [1.6, 10.4]$ 。讀表順序：先看 p（顯不顯著）→ 再看效應量與 CI（多大、多確定）→ 配上各組 M、SD 寫成句子。

完整案例：正念 App 能降低護理師壓力嗎？（1/2）

從研究問題一路走到『選對檢定』

- ① **研究問題與設計** 隨機分派 60 位護理師：App 組 vs 等候組；4 週後測知覺壓力量表 PSS（數值）。
- ② **假設** H_0 ：兩組壓力平均相等； H_1 ：兩組不相等（雖預期 App 較低，仍採雙尾較保守）。
- ③ **選檢定** IV = 組別（類別 2 組）、DV = 壓力分數（數值）→ 獨立樣本 t 檢定。
- ④ **檢查假設** 各組近似常態、變異數同質（Levene $p = .42$ 未違反）、觀察獨立 → 可用 t。

教學重點 先把『問題 → 設計 → 假設 → 選檢定 → 假設檢查』定好，再碰數字——這條線就是方法 / 結果章的骨架。

完整案例：正念 App（2/2）——結果、報告與討論

- ⑤ **結果** App 組 $M = 18.2$, $SD = 5.1$ ；等候組 $M = 22.0$, $SD = 5.4$ ($n = 30$ 各) $\rightarrow t(58) = 2.80, p = .007$ 。
- ⑥ **效應量與 CI** Cohen's $d = 0.72$ (中大)；平均差 3.8 分，95% CI [1.1, 6.5] (不含 0)。
- ⑦ **APA 報告** 「App 組壓力 ($M = 18.2$, $SD = 5.1$) 顯著低於等候組 ($M = 22.0$, $SD = 5.4$)， $t(58) = 2.80, p = .007, d = 0.72, 95\% \text{ CI } [1.1, 6.5]$ 。」
- ⑧ **討論 (能談因果嗎?)** 有隨機分派 $\rightarrow$ 可談因果；但屬單一樣本、需複製；PSS 為自陳，宜再加客觀指標 (如皮質醇)。

教學重點 一個完整結果 = 顯著性 (p) + 效果大小 (d / 平均差) + 精確度 (CI) + 設計能談到什麼 (因果 vs 關聯)。

完整案例：把整條線讀成白話

每個數字在說什麼？

一句話結論 隨機分派 60 位護理師，用 App 4 週後壓力 (PSS) 顯著低於等候組。

為何可談因果 有隨機分派（實驗）→ 兩組事前相當 → 差異來自 App，而非兩群人本來就不同。

t(58)=2.80 兩組差距是雜訊 (SE) 的 2.8 倍。

p=.007 若 App 其實無效，只有 0.7% 機率看到這麼大或更大的差。

d=0.72 / 95% CI[1.1, 6.5] 中大效果；與資料相容的平均差約 1.1~6.5 分，區間不含 0（所以顯著）。

重點 一個好結果 = 顯著 (p) + 效果多大 (d/ 平均差) + 多確定 (CI) + 能談到什麼 (因果 vs 關聯)，四者缺一不可。

各檢定的 APA 報告格式總表

檢定	統計量	APA 報告範例
相關 Correlation	r (df)	$r(28) = .88, p < .001$
ANOVA (組間)	F ($df1, df2$)	$F(1, 58) = 37.91, p < .001$
RM ANOVA (組內 / 混合)	F ($df1, df2$)	$F(1, 58) = 10.20, p = .002$ (交互作用)
邏輯斯迴歸 Logistic	$\exp(b)$ 、 z	$\exp(b) = 0.88, z = -3.67, p < .001$
卡方 Chi-square	χ^2 (df)	$\chi^2(1) = 1.71, p = .19$

報告三要素：統計量＋自由度、精確 p 值、效應量／描述統計； t 檢定的格式見第 48、50 張。

D

避免 p 值誤用

Avoid Mistakes! How to Use p-values Correctly

錯誤一：把「不顯著」當成「證明沒差異」

$p > 0.05$ 時，你「不能」下結論說 H_0 為真——只能說「證據不足以拒絕 H_0 」。

- $p > 0.05$ 有兩種可能：
- ① 母體中真的沒有差異（ H_0 為真）
- ② 其實有差異，但你的樣本數太小、沒偵測到
- 所以「不顯著」無法區分這兩者——不要從 $p > 0.05$ 推出「沒有效果」
- 要主張「沒有差異」，須改用等效性檢定（TOST，見 2.6）。

錯誤二：多重檢定與 Bonferroni 校正

- $\alpha = 0.05$ 代表「每一次檢定」約有 5% 誤判為顯著的機會
- 若在同一批資料做 100 次檢定 → 約有 5 次「純靠運氣」達顯著 (chance capitalization)
- 不要「一直換題目做檢定，直到有一個顯著」

解法：Bonferroni 校正

把門檻除以檢定次數。例：做 2 個檢定 → 用 $0.05 \div 2 = 0.025$ 當門檻；做 5 個 → 用 0.01。這樣控制「族系錯誤率 (FWER)」，但偏保守；Holm 法同樣控制 FWER 且檢定力較高，大量探索性檢定可改控 FDR (Benjamini-Hochberg)。

原則：先想清楚要做幾個檢定；每份資料集只跑一組事先規劃好的檢定。

p-hacking 與研究者自由度

同一批資料『喬』到顯著，是可重複性危機的元凶

研究者自由度 可選的分析很多：刪不刪離群值、加不加共變量、何時停止收案——都會影響 p 。

p-hacking 不斷嘗試不同分析 / 子群，直到 $p < .05$ ；等於偷偷做了很多檢定。

HARKing 看到結果才回頭『假裝』當初就這樣假設（Hypothesizing After Results are Known）。

對策 預先註冊（pre-registration）分析計畫；區分『驗證性』與『探索性』分析並誠實標示。

教學重點 先寫好分析計畫再看資料——探索性發現當『假設來源』沒問題，但要用新資料驗證，別在同一批資料裡當成定論。

p-hacking：一個具體的例子

同一批資料『喬』到顯著

情境 研究者想證明新教材有效，但一開始 $p=.20$ 不顯著。

開始『喬』 刪掉 3 個表現差的樣本 $\rightarrow p=.12$ ；再加一個共變量 $\rightarrow p=.07$ ；只看女生子群 $\rightarrow p=.04$ ！於是只報這個。

問題 試了很多種分析，總會有一種湊到 $<.05$ （等於偷偷做了很多次檢定），這個『顯著』很可能是假的。

對策 事前註冊分析計畫；把『探索到的發現』誠實標為探索性，再用新資料驗證。

重點 同一批資料反覆嘗試到顯著 = p-hacking；它是可重現性危機的主因之一。

超越 p 值：用 CI 與效應量把話說完整

ASA 六原則（重點） p 值不是效果大小、也不是假設為真的機率；p 不能單獨作為決策依據。

一定要報效應量 $d/\eta^2/r/OR/V$ ——回答『差多少、關聯多強』，且可跨研究比較。

一定要報信賴區間 CI 同時給方向、大小與精確度；比『顯著 / 不顯著』的二分更有資訊。

別說『證明』 說『支持 / 不支持』；單一研究不定論，靠複製與統合分析。

教學重點 現代結果報告 = 檢定統計量 + df + 精確 p + 效應量 + 95% CI；只給『 $p < .05$ 』會被審稿人退。

超越 p 值：同一結果的兩種寫法（承前頁報告要件）

只報 p vs 報完整

只寫 p（不完整）

「兩組有顯著差異
($p < .05$)。」

→ 讀者不知道
差多少、多確定，
也無法跨研究比較。

完整寫法（建議）

「App 組壓力顯著低於
等候組，平均差 3.8 分，
95% CI[1.1, 6.5],
Cohen's $d=0.72$,
 $t(58)=2.80$, $p=.007$ 。」

→ 方向、大小、精確度、
顯著性一次到位。

重點 現代期刊要求：檢定統計量 + df + 精確 p + 效應量 + 95% CI；別只丟一個『 $p < .05$ 』。

結果章寫作檢查清單

- ☐ 每個檢定都報：統計量＋自由度、精確 p 值（不只寫 $p<.05$ ）、效應量與 95% CI
- ☐ 先報敘述統計（各組 M 、 SD 、 n ），再報推論檢定
- ☐ 檢定假設有檢查（常態、變異數同質）；違反時說明改用的方法
- ☐ 多重比較有校正（Bonferroni/Tukey），或說明為事先規劃的少數檢定
- ☐ 區分『統計顯著』與『實務重要』；用效應量與 CI 討論實質意義
- ☐ 區分驗證性與探索性分析；不把『不顯著』寫成『證明沒差異』

教學重點 把這張清單當『送印前的最後檢查』——審稿人最常抓的就是漏效應量 / CI、以及把不顯著當成沒差異。

本單元重點回顧

- 【目標②】推論統計判斷：在 H_0 為真的假定下，觀察到的資料有多不尋常。
- 【目標②】我們反駁 H_0 、而非證明 H_1 ； p 值是反駁 H_0 的證據強度，門檻 0.05 是共識決策線。
- 顯著性取決於三股力量：效應量（大）、變異（小）、樣本量（大）。
- 【目標①】【目標④】依 IV/DV 選檢定：相關、 t 檢定、ANOVA、RM ANOVA、邏輯斯、卡方，並用 APA 格式報告。
- 顯著的意義看設計：實驗能談因果、非實驗只能談關聯。
- 【目標②】兩大誤用：不能把「不顯著」當沒差異；多重檢定要用 Bonferroni 校正。
- 【目標③】【目標④】95% CI 與效應量要與統計量、精確 p 值一起報——只報 p 是不完整的。

下一站 2.6 樣本數規劃：反過來問——要偵測到這樣的效果，事前需要多少人？

參考文獻與延伸閱讀

- Wasserstein, R. L., & Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician*, 70(2), 129–133. → p 值六原則 (第 79 張)
- Greenland, S., et al. (2016). Statistical tests, P values, confidence intervals, and power: A guide to misinterpretations. *European Journal of Epidemiology*, 31(4), 337–350. → p 值與 CI 的常見誤解
- Cumming, G. (2014). The new statistics: Why and how. *Psychological Science*, 25(1), 7–29. → 效應量與信賴區間
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum. → 效應量基準 (第 35 張)
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70. → 多重檢定 (第 76 張)
- Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *JRSS B*, 57(1), 289–300. → FDR
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology. *Psychological Science*, 22(11), 1359–1366. → p-hacking (第 77–78 張)
- Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, 8(4), 355–362. → 主張「沒差異」
- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7th ed.). → APA 報告格式 (第 73 張)



作業

Take-home Assignment

From p-value to a defensible conclusion.

涵蓋單元 5： H_0/H_1 與 p 值邏輯、三股力量、標準誤與信賴區間、六種檢定與效應量、APA 報告、p 值誤用。

Part A 觀念題檢驗你「懂不懂」； Part B 實作題要你「選對檢定、算得出、報得對」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

能依資料選對推論檢定、算出並解讀結果，並用 APA 格式完整報告（含效應量與 CI）。

繳交方式

一份 PDF：Part A 文字作答 + Part B 計算與 APA 報告，建議 3–5 頁。

建議時間

約 2–3 小時；可用 JASP 驗算，但需寫出檢定選擇與判讀。

工具與誠信

可用 AI／軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

Part A | 觀念題：推論統計（1/2）

- A1** H_0/H_1 是什麼？為何『反駁 H_0 』而非『證明 H_1 』？寫出 p 值的正確定義與兩個常見誤解。
- A2** 決定顯著的三股力量（效應量、變異、樣本數）如何影響 p ？為何大樣本下微弱效應也會顯著？
- A3** 標準誤 SE 與標準差 SD 差在哪？95% 信賴區間怎麼算、怎麼解讀？CI 與假設檢定的關係為何？
- A4** Type I / II 錯誤與 Power 各是什麼？把 α 設更嚴會付出什麼代價？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2-4 句即可。

Part A | 觀念題：推論統計（2/2）

- A5** 依 IV/DV 選檢定：六種檢定各對應什麼資料型態？各寫一個 APA 報告範例。
- A6** 各檢定的效應量（ d / η^2 / r / OR / Cramér's V ）與基準是什麼？為何一定要報效應量與 CI？
- A7** t / ANOVA 的基本假設有哪些？違反時的無母數替代分別是什麼？
- A8** p 值兩大誤用（把不顯著當沒差異、多重檢定）與對策（Bonferroni、預先註冊）。

Part B | 實作題：選檢定、算結果、報 APA (1/2)

情境：比較『新教學法 vs 傳統教學』對考試成績的影響（兩組各 $n = 30$ ）。

新法 $M = 78, SD = 8$ 傳統 $M = 72, SD = 9$

- B1** 寫出 H_0 與 H_1 ；選擇適當的統計檢定並說明理由（依 IV/DV 型態）。
- B2** 算獨立樣本 t （可用公式）、 df ，判斷是否 $p < .05$ ，並算 Cohen's d 、判讀效應大小。
- B3** 寫出這個結果的 APA 報告句（含統計量、 df 、精確 p 、效應量與 95% CI）。

Part B | 實作題：選檢定、算結果、報 APA (2/2)

- B4** 若改為『同一批學生前後測』，該用什麼檢定？效應量用什麼？與 B2 的設計差在哪（樣本效率、假設）？
- B5** 若研究者做了 8 個檢定才找到一個顯著，有什麼問題？你會怎麼處理（校正／預註冊）？並解釋『顯著 ≠ 重要』。
- B6** 寫一段結果章（含效應量與 95% CI 的完整報告）+ AI 使用聲明。

繳交格式 Part B 要看得『檢定選擇的理由』與『計算步驟』；報告句要符合 APA。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能說出關係（如 $CI \leftrightarrow$ 檢定、 $Power=1-\beta$ ）
B1 選檢定	10%	H_0/H_1 正確、依 IV/DV 選對檢定並說理由
B2 計算	15%	t、df、d 計算正確、判讀效應大小
B3 APA 報告	10%	統計量 + df + 精確 p + 效應量 + CI 齊全
B4-B6 設計 + 誠信	25%	配對設計與效應量正確、多重檢定處理、報告 + AI 聲明

常見扣分 把不顯著當『沒差異』、只報 p 不報效應量 / CI、相關講成因果、多重檢定不校正。

資源連結 · 外部服務與官方網址

點按名稱或網址可直接開啟；工具更新快，功能與費用請以官方頁面為準。

資源 / 服務	官方網址 URL
JASP	jasp-stats.org/

案例應用：三個檢定，三種問題

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

① 本單元教了什麼

推論的邏輯，以及 t 檢定與卡方各自回答什麼樣的問題。

② 案例怎麼用

- 主要問題用配對 t：同一批人前後測， $t(33) = -6.30$ 、 $p < .001$ 、 $d_z = -1.08$ 。
- 機構差異用獨立 t：A 對 B 後測 $t(60) = -3.85$ 、 $p < .001$ 、 $d = -0.98$ 。
- 類別關聯用卡方：職類 × 完整性達標 $\chi^2(1) = 0.47$ 、 $p = .492$ ，未達顯著。
- 每個檢定先查前提：常態性、變異數同質、期望次數是否足夠。
- 報告一律附效應量與 95% 信賴區間，不只寫 p 值。

③ 產出什麼證據

APA 格式結果段三則（次頁），可直接移入論文第四章。

④ 承接關係

上游：承自 2.4 之 Table 1 樣本特徵表 | 下游：交棒 2.6，回頭檢視檢定力是否足夠。

教學重點 三個檢定對應三種問題：同一群人前後比、兩群人互相比、兩個類別有沒有關聯。選錯的通常不是公式，而是沒想清楚要比的是什麼。

示範產物： APA 格式結果段三則

數值一律取自唯一數字表；此三段可原樣移入論文，毋須改寫

段落	示範文字
主要結果（配對 t）	導入後交班準備時間（ $M = 13.03$, $SD = 4.74$ ）顯著短於導入前（ $M = 18.40$, $SD = 5.20$ ）， $t(33) = -6.30$, $p < .001$, $d_z = -1.08$, 95% CI [-7.10, -3.63]。
機構比較（獨立 t）	後測期間，A 機構之準備時間（ $M = 13.03$, $SD = 4.74$ ）顯著短於同期未導入之 B 機構（ $M = 17.80$, $SD = 4.99$ ）， $t(60) = -3.85$, $p < .001$, $d = -0.98$, 95% CI [-7.25, -2.29]。
類別關聯（卡方）	職類與紀錄完整性是否達標之間未達顯著關聯， $\chi^2(1) = 0.47$, $p = .492$, $\phi = .09$ 。本結果不足以支持兩者無關聯之推論，詳見研究限制。

教學重點 第三段的寫法值得注意：不顯著不能寫成「兩者沒有差異」，只能寫「未達顯著關聯」。前者是對母體下結論，後者才是這份資料撐得住的說法。