

量性研究方法 · 完整研究專案

單元 5

推論統計

Inferential Statistics — From Sample to Population

虛無假設與 p 值的邏輯、效應量／變異／樣本數三股力量、六種推論檢定（相關、 t 檢定、ANOVA、RM ANOVA、邏輯斯、卡方）與 APA 報告，並避免 p 值誤用

本單元結束後，你能……

- 能寫出虛無與對立假設，並依自變量與依變量的型態選出適當檢定。
- 能正確陳述 p 值的定義，並指出至少三種常見誤用。
- 能計算並解讀 95% 信賴區間，說明它與顯著性判斷的關係。
- 能產出含統計量、自由度、精確 p 值、效應量與信賴區間的 APA 報告句。
- 驗收方式 ① 對應作業 A1、A5、B1；② 對應 A1、A8、B5；③ 對應 A3、B3；④ 對應 A5、B3、B6。

A

推論的核心邏輯

From Sample to Population — The Logic

核心問題：能推論到更大的世界嗎？

- 兩個樣本不會完全相同，但共享某些特徵（如平均值）
- 我們要判斷：樣本中看到的關係，用「若 H_0 為真，出現這種資料的機率有多低」來評估

虛無假設 H_0

假定「沒有效果／沒有差異／沒有關係」，例如兩組平均相等。差異僅來自隨機巧合。

對立假設 H_1

假定「存在效果／差異／關係」，例如兩組平均不相等。差異是系統性的。


為何「反駁 H_0 」而非「證明 H_1 」？

- H_0 明確 ($\mu_1 = \mu_2$) → 可建立機率分佈； H_1 模糊 ($\mu_1 \neq \mu_2$) → 無法建唯一模型
- p 值 = 「當 H_0 為真時，觀察到這樣（或更極端）資料的機率」
- p 值不是「 H_1 為真的機率」，而是反駁 H_0 的證據強度
- 可證偽性（Popper）：科學假說不能被證明為真，只能被證明為假
- 若 $p < \alpha$ （常用 0.05）→ 拒絕 H_0 ，結果具統計顯著性

p 值在分佈上長什麼樣

在 H_0 為真的前提下，有多極端

p 值 = 在 H_0 (虛無假設)為真的前提下,看到「這麼極端或更極端」結果的機率



教學重點 p 值不是「 H_0 為真的機率」，而是「若 H_0 為真，看到這麼極端結果的機率」——方向不能反。

p 值直覺：把假設檢定想成一場審判

為什麼我們『反駁 H_0 』而不是『證明 H_1 』

無罪推定 = H_0 法庭預設『被告無罪』（沒有效果），除非證據夠強才推翻。

證據 = 你的資料 資料越『不像無罪該有的樣子』，越傾向定罪（拒絕 H_0 ）。

p 值 = 若真的無罪、出現這麼不利證據的機率 p 很小 = 這種證據在『無罪』下很罕見 → 推翻無罪推定。

判『無罪』 ≠ 證明清白 不顯著只代表『證據不足』，不代表『證明沒效果』（無罪判決 ≠ 證明沒做）。

教學重點 $\alpha = .05$ 就像『定罪門檻』：若被告其實無罪，仍有 5% 機率被定罪（Type I）。門檻訂多嚴是價值取捨，非真理。

假設檢定的五個步驟

每個推論檢定都照這條線走

- ① **立假設** 寫出 H_0 （無效果）與 H_1 （有效果）；決定單尾或雙尾。
- ② **定顯著水準 α** 通常 .05——願承擔的偽陽性風險。
- ③ **算檢定統計量** 依資料型態選檢定，算出 $t / F / \chi^2 / r$ 等。
- ④ **求 p 值** 在 H_0 為真下，出現這樣（或更極端）結果的機率。
- ⑤ **下決策** $p < \alpha \rightarrow$ 拒絕 H_0 （顯著）；並報告效應量與信賴區間。

教學重點 第⑤步不是終點——『拒絕 H_0 』只說『有差異』，還要用效應量與 CI 說明『差多少、多確定』。

t / F / χ^2 / r 到底在算什麼？

第③步『算檢定統計量』——四個常見統計量的白話

t（用於 t 檢定）

兩組（或前後）的『平均差』÷『標準誤』。

= 差距是雜訊的幾倍；越大越可能顯著。

F（用於 ANOVA）

『組間變異』÷『組內變異』。

= 各組差異相對於組內雜訊；越大越可能不同。

χ^2 卡方（用於卡方檢定）

$\sum (\text{觀察}-\text{期望})^2 \div \text{期望}$ 。

= 實際次數與『無關聯時的期望』差多少。

r 相關係數（相關 / 迴歸）

兩個數值變數的線性關聯，範圍 -1~+1。

0= 無關，±1= 完全線性；本身就是效應量。

重點 四者都是『訊號 ÷ 雜訊』家族：算出統計量後，再對照它的分佈查 p 值，判斷是否顯著。

推論要做兩件事

① 推論單變量統計

- 問：母體的平均值大概在哪裡？
- 由「樣本平均」估計「母體平均」
- 受兩股力量影響：變異、樣本數

② 推論變量間的關係

- 問：母體中各組平均是否真的不同？
- 由「樣本中的關係」推論「母體的關係」
- 受三股力量影響：效應量、變異、樣本數


重點 本單元先談「關係的推論」（各檢定），因為它正是論文結果章要回答的核心。

中央極限定理：為什麼可以用常態


母體再怎麼歪，樣本平均都會趨近常態

中央極限定理：不管母體長什麼樣，樣本平均的分佈會趨近常態，且 n 越大越窄


母體(明顯右偏)



樣本平均的分佈(每次抽 $n=5$)



樣本平均的分佈(每次抽 $n=50$)



教學重點 這就是「用樣本推論母體」的理論基礎： n 越大，樣本平均的分佈越窄也越常態。

三個關鍵量：中英對照與白話

上一頁的『變異、樣本數、效應量』到底指什麼？

變異 Variation

資料有多分散。

(標準差 SD / 變異數 σ^2)

越小 → 估計越穩、
越容易達顯著。

樣本數 Sample Size

抽了多少觀察值。

(N / n)

越大 → 估計越穩、
檢定力 power 越高。

效應量 Effect Size

效果或關係的實際大小。

($d / \eta^2 / r / OR$)

越大 → 越易顯著，
也越有實務意義。

重點 推論『單變量』（估平均）只受變異＋樣本數影響；推論『關係』（比較 / 關聯）再加上效應量——共三股力量。

抽樣分佈與標準誤：推論的地基

樣本平均本身也會波動——標準誤就是在量這個波動

抽樣分佈 反覆抽樣、每次算一個樣本平均，這些平均值形成的分佈。

中央極限定理 CLT N 夠大時抽樣分佈近似常態；母體不太偏斜時約 30 即可，極度偏斜需更多。

標準誤 SE 抽樣分佈的標準差 $= SE = SD \div \sqrt{N}$ ；量『樣本平均離母體平均多遠』。

關鍵 SD 描述『個別資料』的分散； SE 描述『樣本平均』的分散—— N 越大 SE 越小。

教學重點 所有推論（ t 、 CI 、 p ）都建立在抽樣分佈上： SE 越小，樣本平均越可信，越能偵測真實差異。

標準誤直覺：為什麼『平均』比『單一資料』可信

同樣的資料，取平均就把雜訊抵消了

單一測量會抖 量一次身高，可能因姿勢、儀器而差 1-2 公分。

取平均會穩 量很多次再平均，高估與低估互相抵消，越接近真值。

SE 就是在量這個 $SE = SD \div \sqrt{N}$ ：N 越大，『樣本平均』的抖動越小。

實感例子 SD = 10 的母體：N = 1 時估計的典型誤差約 10；N = 100 時約 1（SE = 1）。

教學重點 『大樣本較可信』的直覺不是資料變乖了，而是『平均』這個估計本身變穩了——這正是所有推論的地基。

推論單變量：兩條規則

規則 1：變異越大，估計越飄

- 母體變異越大，樣本平均越容易偏離母體平均
- 最壞情況：抽到極端值，樣本平均偏很多
- 例：母體平均 = 5，若變異大， $N=1$ 可能抽到 9


規則 2：樣本越大，估計越穩

- 樣本數越大，樣本平均越接近母體平均
- $N=1 \rightarrow$ 很不穩； $N=2、3 \dots \rightarrow$ 逐漸收斂
- 若 N 很大（如 100000），單點的影響幾乎消失

重點 同一個道理之後會擴充到「關係的推論」——變異要小、樣本要大，結論才可靠。

兩條規則，看圖就懂

左：變異越大越飄 右：樣本越大越穩



重點 變異（能否縮小）常受測量與母體限制；樣本數（能否加大）是研究者最能主動控制的旋鈕。

標準誤完整範例： N 如何讓估計變穩

母體標準差 $SD = 10$

樣本數 N	標準誤 $SE = SD \div \sqrt{N}$	95% 誤差範圍 $\approx \pm 1.96 \times SE$
N = 25	$10 \div \sqrt{25} = 10 \div 5 = 2.0$	± 3.9
N = 100	$10 \div \sqrt{100} = 10 \div 10 = 1.0$	± 2.0
N = 400	$10 \div \sqrt{400} = 10 \div 20 = 0.5$	± 1.0

教學重點 SE 隨 $\sqrt{N}$ 縮小——要把精度加倍（SE 減半），樣本數要變 4 倍。這就是『大樣本較穩』的數學根據。

那張表的第 2、3 欄是怎麼算出來的？

以母體 $SD = 10$ 、 $N = 100$ 這一系列逐步拆解

第 2 欄 $SE = SD \div \sqrt{N}$

意思：平均值的估計誤差（標準誤）。
 SD 是資料分散度， $\sqrt{N}$ 讓大樣本更穩。

以 $N=100$ ：

$$SE = 10 \div \sqrt{100} = 10 \div 10 = 1.0$$

N 變 4 倍 (400) $\rightarrow \sqrt{N}$ 變 2 倍
 $\rightarrow SE$ 減半 (0.5)。

第 3 欄 95% 誤差範圍 $\approx \pm 1.96 \times SE$

意思：平均值上下大約這麼多，
就有 95% 的信心涵蓋母體平均。

以 $N=100$ ：

$$\pm 1.96 \times 1.0 \approx \pm 2.0$$

1.96 來自常態分佈的『中間 95%』
(下一頁專門說明)。

重點 一句話：先用 SD 與 $\sqrt{N}$ 算出『一個 SE 』，再乘 1.96，得到『95% 的誤差範圍』。

信賴區間：不只給一個點，還給一個範圍

點估計（樣本平均） + 不確定性（SE） = 區間估計

公式 95% CI = 樣本平均 $\pm 1.96 \times SE$ （大樣本、常態近似）。

正確解讀 若重複抽樣很多次，約 95% 的這種區間會涵蓋『真正的母體平均』。


常見誤解 不是『母體平均有 95% 機率落在此區間』——母體平均是固定的，隨機的是區間。

與檢定的關係 若虛無值（如 0）落在 95% CI 之外 $\rightarrow$ 等同 $p < .05$ 顯著。

教學重點 CI 比單一 p 值資訊更多：同時給你『效應方向、大小與精確度』——期刊越來越要求報 CI。

1.96 是怎麼來的？

標準常態分佈：中間 95%，兩尾各留 2.5%



重點 要涵蓋『中間 95%』，就要切掉兩尾各 2.5%——這兩個切點的 z 分數正好 $\approx \pm 1.96$ 。要 99% 則用 ± 2.58 。

信賴區間完整範例 + 判讀

樣本： $M = 52$ 、 $SD = 10$ 、 $N = 25$

① 算 SE $SE = 10 \div \sqrt{25} = 2.0$

② 算 95% CI 母體 σ 未知、以樣本 SD 估計 $\rightarrow$ 用 $t(24)=2.064$ (非 1.96) : $52 \pm 2.064 \times 2.0 = 52 \pm 4.13 = [47.87, 56.13]$

③ 解讀 以此程序長期重複抽樣，約 95% 的區間會涵蓋母體平均；不可說「母體平均有 95% 機率落在此區間」。

④ 對照假設檢定 若 $H_0: \mu = 50 \rightarrow 50$ 落在區間內 $\rightarrow$ 無法拒絕 H_0 (不顯著)；若 $H_0: \mu = 47 \rightarrow 47$ 在區間外 $\rightarrow$ 拒絕 (顯著)。

教學重點 CI 寬度 = 不確定性：N 越大、變異越小，區間越窄、估計越精確。窄而明確的 CI 比『只報 $p < .05$ 』更有說服力。

信賴區間直覺：撒網捕魚

95% 信心，指的是『網』而不是『魚』

魚（母體平均 μ ）是固定的 它在水裡某個位置，不會動。

每次抽樣＝撒一次網（一個 CI） 網的位置隨你抽到的樣本而變。

95% CI 的意思 用這種方式撒 100 次網，約 95 次會『罩住』那條魚。

常見誤解 不是『這條魚有 95% 機率在這張網裡』——魚固定、網才是隨機的。

教學重點 所以看到一個 95% CI，別說『 μ 有 95% 機率落在此區間』；而是『這個程序長期有 95% 的涵蓋率』。

變異大小如何影響「能否推論」

變異小 → 差異清楚、可推論




控制組



治療組

變異大 → 差異被雜訊蓋住



控制組



治療組

重點 兩邊「平均差」一樣，但左邊變異小、盒子不重疊 → 容易顯著；右邊變異大、盒子重疊 → 難以顯著。

推論關係的三股力量

1

效應量 Effect Size

組間差異的實際大小；越大越易達顯著。

越大越好

2

變異性 Variation

資料的波動程度；越小結果越穩定。

越小越好

3

樣本量 N

越大檢定力（power）越強，越能偵測小效應。

越大越好

重點 三者共同決定 p 值：效應大、變異小、樣本大 → p 值小 → 越可能推論到母體。

三股力量，用一個比喻＋一組數字看懂

為什麼『效應大、變異小、樣本大』會讓 p 變小？

比喻 p 值像『訊號 vs 雜訊』：訊號＝效應量（差多大）；雜訊＝變異 ÷ 樣本（估得多不準）。訊號蓋過雜訊 → p 小。

同樣是『平均差 4 分』 若 $SD=20$ 、每組 $n=10$ （雜訊大）→ $t \approx 0.45$ ，差被淹沒 → $p \approx .66$ 不顯著。

若 $SD=5$ 、每組 $n=100$ （雜訊小）→ $t \approx 5.7$ ，同樣 4 分清楚浮現 → $p < .001$ 顯著。

三個旋鈕 效應量 ↑、變異 ↓、樣本數 ↑，任一個都讓 p 變小；研究設計能主動控制的是後兩個。

重點 所以『不顯著』不一定沒效果——可能是變異太大或樣本太小，把真效果蓋住了。

為什麼門檻是 0.05 ？

門檻（ α ）＝「把其實無效的結果，誤判為顯著」的可接受機率。

- $\alpha = 0.05 \rightarrow$ 你接受「5% 誤判為顯著」的風險
- $\alpha = 0.01 \rightarrow$ 更嚴格，誤判機率降到 1%（需要更強證據）
- 多數科學家認為 5% 的誤判風險「夠好」，因此以 0.05 為慣例門檻
- 門檻不是真理，而是一個「群體共識的決策線」——不同領域可能不同

單尾 vs 雙尾檢定：方向要不要事先決定

雙尾檢定（預設）

$H_1: \mu_1 \neq \mu_2$ （沒指定方向）。

α 分到兩尾（各 .025）。

適用：不確定方向、要偵測任一方向差異。

單尾檢定

$H_1: \mu_1 > \mu_2$ （事先指定方向）。

α 全放一尾 $\rightarrow$ 同樣 α 下檢定力較高。

限制：只能在有強理論依據、且事先決定時使用。

教學重點 單尾『看到資料才改成單尾』是作弊（會膨脹偽陽性）。除非事前有明確方向假設，否則用雙尾較保守、可信。

單尾 vs 雙尾：白話版與兩個例子（承前頁定義）

方向要不要事先賭定？

白話 雙尾問『有沒有不同（哪邊都算）』；單尾問『是不是特別高（只賭一個方向）』。

例・雙尾 新藥 vs 安慰劑， H_1 ：藥效 $\neq$ 安慰劑——不管更好或更差都要偵測（較保守，預設）。

例・單尾 H_1 ：藥效 $>$ 安慰劑——只有在有充分理論、且『事前』就決定方向時才可用。

為何預設雙尾 同 α 下單尾較易顯著；若看到資料才改單尾，等於偷偷放寬標準、灌水偽陽性。


重點 口訣：沒有事前的強方向假設 → 一律用雙尾。

兩種錯誤與檢定力：推論一定會冒的風險

真實 \ 你的判定	拒絕 H_0 （宣稱有差異）	未拒絕 H_0 （證據不足，非證明無差異）
H_0 為真（其實無差異）	✗ Type I（ α ，偽陽性）	✓ 正確（ $1-\alpha$ ）
H_0 為假（其實有差異）	✓ 檢定力 Power（ $1-\beta$ ）	✗ Type II（ β ，偽陰性）

教學重點 α 管『偽陽性』、 β 管『偽陰性』、Power = $1-\beta$ 。要 α 更嚴（.01）就得付出更高 β ，或加大樣本補回檢定力。

從三因素到 p 值的判斷流程



重點 效應量、變異性、樣本數共同決定 p 值： $p < .05 \rightarrow$ 資料與 H_0 不相容，拒絕 H_0 ； $p \geq .05 \rightarrow$ 證據不足以拒絕 H_0 ，不等於沒有效果。

統計顯著 $\neq$ 實務重要

p 小不代表效果大

大樣本陷阱 N 很大時，微不足道的差異也會 $p < .05$ ——顯著只說『與 H_0 不相容』，沒說『很重要』。

效應量才談大小 d 、 η^2 、 r 、OR 這些才回答『差多少、關聯多強』。

信賴區間看精確度 窄 CI = 估計精確；若 CI 幾乎貼著 0，就算顯著也要謹慎。

實務門檻 要問：這個效果在你的領域『值不值得在意』？（臨床顯著性 vs 統計顯著性）

教學重點 結果一律『三件一起報』：檢定統計量 + 精確 p 值 + 效應量（與 CI）——只報 p 是不完整的。

顯著 $\neq$ 重要：兩個生活化例子

p 過門檻，不代表值得在意

① **顯著但不重要** 某 App 讓每日步數平均多 12 步， $n=50000 \rightarrow p<.001$ 。統計顯著，但 12 步對健康幾乎沒差。

② **重要但未達顯著** 新復健讓行走距離多 40 公尺（很有意義），但只收 8 人、變異大 $\rightarrow p=.09$ 。效果可能真實，只是樣本太小沒測出來。

怎麼判斷 看效應量（差多少）+信賴區間（多確定），別只看 p 有沒有過 .05。

重點 『有沒有差』（p）與『差多少、值不值得』（效應量）是兩個不同問題，兩個都要回答。

效應量 vs p 值：兩個研究看懂差別

同樣是『 $p < .05$ 』，意義可能天差地別

	研究 A	研究 B
樣本數 N	10,000	40
效應量 Cohen's d	0.05 （幾乎沒差）	0.90 （很大）
p 值	$p = .01$ （顯著）	$p = .007$ （顯著）
實務意義	幾乎沒用——大 N 讓微小差異也顯著	重要——效果大，小樣本仍達顯著

教學重點 只看 p 會把 A、B 當一樣；看效應量與 CI 才知道 A 『顯著但沒意義』、B 『顯著且重要』——這就是一定要報效應量的原因。

把上頁兩個研究讀成白話

同樣 $p < .05$ ，意義天差地別

研究 A $N=10000$, $d=0.05$, $p=.01 \rightarrow$ 因為人非常多，連幾乎看不見的差 ($d=0.05$) 也被判顯著。實務上可忽略。

研究 B $N=40$, $d=0.90$, $p=.007 \rightarrow$ 人不多，但效果很大 ($d=0.90$)，所以仍達顯著。實務上重要。

關鍵 p 會被 N 放大； d 不會。 d 才是跨研究可比較的『效果大小』。

Cohen's d 參考 0.2 小、0.5 中、0.8 大。

重點 只報 p 、不報 d 與 CI ，審稿人通常會要求補——因為讀者無法判斷 A 與 B 的差別。

各檢定的效應量一覽與基準

檢定	效應量	小 / 中 / 大 (粗略基準)
t 檢定	Cohen's d	0.2 / 0.5 / 0.8
ANOVA	η^2 (或 partial η^2)	.01 / .06 / .14
相關 / 迴歸	r (r^2 為解釋變異)	.10 / .30 / .50
邏輯斯迴歸	勝算比 OR	$\approx 1.68 / 3.47 / 6.71$ (Chen et al., 2010 ; 基準率 1%)
卡方	Cramér's V	.10 / .30 / .50 (df=1)

Cohen's d 尺規: 效應量的實務意義



教學重點 效應量與『樣本數無關』，所以能跨研究比較、放進統合分析 (meta-analysis) ; p 值則會隨 N 變。

B

選對統計檢定

How to Apply Inferential Statistics

選擇統計檢定的決策表

IV	DV	檢定方法
類別 (2 組)	數值	t 檢定
類別 (≥ 3 組, 組間)	數值	單因子 ANOVA
類別 (≥ 3 組, 組內／混合)	數值	重複量數 ANOVA (RM ANOVA)
數值	數值	皮爾森相關 / 迴歸
數值	類別	邏輯斯迴歸
類別	類別	卡方檢定

先選檢定 → 考慮效應量、變異、樣本數 → 算出 p 值 → 判斷 H_1 或 H_0 。(IV / DV 屬哪一種, 看測量尺度——見 2.2)

檢定的基本假設：先檢查再解讀

檢定	主要假設	違反時怎麼辦
t / ANOVA	常態性、變異數同質、獨立	Welch 校正；或改無母數
相關 / 迴歸	線性、常態、等分散 (homoscedasticity)	轉換變數；或用 Spearman
卡方	期望次數 < 5 的格 $\leq 20\%$ 且無 < 1 、觀察獨立	合併類別；或 Fisher 精確檢定

教學重點 假設不是形式：變異數嚴重不同質或小樣本非常態時，硬跑 t/ANOVA 的 p 值不可信——先看圖與檢定（如 Levene）。

假設違反了，實際怎麼處理？

先檢查，再決定用原檢定或替代方案

常態性 小樣本又嚴重偏態 → 改無母數：Mann-Whitney（兩組）／Kruskal-Wallis（多組）。

變異數同質 兩組 SD 差很多（如 3 vs 12）→ 用 Welch t／Welch ANOVA（不假設同質）。

期望次數 < 5（卡方） 某格期望人數太少 → 合併類別，或改 Fisher 精確檢定。

怎麼先發現 先畫圖（直方圖 / 箱型圖），再跑 Levene（同質）、Shapiro（常態）。


重點 假設不是官僚手續：嚴重違反時 p 值會失真——先檢查、再解讀。

無母數替代：資料不符假設時的備案

母數檢定	無母數替代	用於
獨立樣本 t	Mann-Whitney U	兩組、非常態或序位資料
配對 t	Wilcoxon signed-rank	前後、非常態
單因子 ANOVA	Kruskal-Wallis	≥ 3 組、非常態
Pearson r	Spearman ρ	序位或非線性單調關係

教學重點 無母數檢定用『排序』而非原始值，對離群值與偏態較穩健；代價是檢定力略低、且比較的是中位數 / 分佈位置。

統計檢定決策樹



重點 口訣：先定 DV 型態，再看 IV 型態與組數，一路往下即可決定：相關、t 檢定（2 組，即 ANOVA 的特例）、ANOVA、RM ANOVA、卡方或邏輯斯迴歸。

顯著代表什麼？取決於研究設計

無混淆的實驗

- H_1 ：治療「造成」了差異（只有一種因果解釋）
- H_0 ：兩組母體無差異
- 顯著 → 可下「因果」結論

非實驗（無隨機化）

- H_1 ：可能是治療影響疾病、疾病影響治療，或第三變項
- H_0 ：兩組母體無差異
- 顯著 → 只能下「關聯」結論，不能斷定因果

重點 同樣是「 $p < 0.05$ 」，實驗能談因果、非實驗只能談關聯——回想單元 1 的三種因果解釋。

實驗 vs 非實驗：白話與例子

差別在有沒有『隨機分派』

實驗 Experiment

研究者『主動操弄』IV，並『隨機分派』受試者到各組。

例：把 60 位病人隨機分到 App 組／等候組。

→ 兩組事前條件平均相同，若有差，可歸因於介入 → 可談因果。

非實驗 Non-experiment（觀察型）

研究者『只觀察、不操弄』，分組是既存的。

例：比較『本來就有用 App』vs『沒用』的人的壓力。

→ 兩群人可能本來就不同（年齡 / 動機），差異或來自第三變項 → 只能談關聯。

重點 同樣 $p < .05$ ，實驗能說『造成』，非實驗只能說『有關聯』——差別在研究設計，不在統計。


C

六種推論檢定

Six Inferential Tests

Generalizing a Correlation

① 相關的推論（數值 IV × 數值 DV）



- **$r = 0.88$** ：強正相關（ r 介於 $-1 \sim 1$ ）
- 勾選 report significance 取得 p 值
- $p < 0.001 \rightarrow$ 顯著，可拒絕 H_0
- $r(28)$ ：括號內為自由度（ $= N - 2$ ）

APA 報告： $r(28) = .88, p < .001$

① 相關推論完整範例： r 顯著嗎？

資料：讀書時數 vs 成績， $r = .88$ 、 $N = 30$

① 自由度 $df = N - 2 = 28$

② 檢定統計量 $t = r\sqrt{df} \div \sqrt{(1-r^2)} = .88 \times \sqrt{28} \div \sqrt{(1-.774)} \approx 4.66 \div .475 \approx 9.8$

③ p 值 $t(28) = 9.8 \rightarrow p < .001 \rightarrow$ 拒絕 H_0 （母體相關 $\neq 0$ ）

④ 效應與精確度 $r^2 = .77$ （成績變異約 77% 與讀書時數共變）；95% CI 約 [.76, .94]

APA $r(28) = .88, p < .001, 95\% \text{ CI } [.76, .94]$

教學重點 相關『顯著』只表示母體相關不為 0；仍是關聯非因果，且要看 r 的大小（效應量）而非只看 p 。

② ③ 平均差異的推論： ANOVA / RM ANOVA

ANOVA（組間）

- 比較兩組（或多組）平均是否有差異
- 效應量： η^2 / partial η^2 （亦可報平均差）
- $F(1, 58)$ ：括號內為自由度

RM ANOVA（組內）

- 純組內設計無分組因子，比「治療前 vs 後」
- 同一群人重複測量 → 控制個體差異
- 所需樣本數比組間設計少

APA 報告： $F(1, 58) = 37.91, p < .001, \eta^2 = .40$ （後測 M：治療 4.63 vs 控制 7.65）

獨立樣本 t 檢定完整範例（兩組）

新教學法 $M=78, SD=8, n=30$ vs 傳統 $M=72, SD=9, n=30$

① **假設** H_0 ：兩組母體平均相等； H_1 ：不相等（雙尾）。

② **平均差** $78 - 72 = 6$ 分

③ **合併標準差與 SE** $\text{pooled SD} = \sqrt{((8^2+9^2)/2)} \approx 8.51$ ； $SE = 8.51 \times \sqrt{(1/30+1/30)} \approx 2.20$

④ **t 與 df** $t = 6 \div 2.20 \approx 2.73$ ； $df = 30+30-2 = 58 \rightarrow p \approx .008$ 顯著

⑤ **效應量** Cohen's $d = 6 \div 8.51 \approx 0.70$ （中大效應）


APA $t(58) = 2.73, p = .008, d = 0.70, 95\% CI [1.6, 10.4]$

教學重點 兩組比較用獨立 t；2 組時 $F = t^2$ （ANOVA 與 t 一致）。務必同時報 d 與 CI，別只報 p。

獨立 t：兩組分佈與『差 ÷ 雜訊』

兩組重疊越少，差距相對雜訊越大 → t 越大

兩組分佈重疊越少 → 差距相對雜訊越大 → t 越大



重點 $t = \text{平均差} \div \text{標準誤 (SE)}$ 。兩條鐘形曲線分越開、越瘦（變異小），重疊越少 → t 越大、越可能顯著。

配對樣本 t 檢定完整範例（同一批人前後）

減重前後（同 25 人）：平均差 $\bar{d} = 3 \text{ kg}$ 、差的 $SD = 4$ 、 $n = 25$

① **假設** H_0 ：前後母體平均相等（ $\mu \text{ 差} = 0$ ）； H_1 ：不相等。

② **SE of 差** $SE = \text{差的 } SD \div \sqrt{n} = 4 \div \sqrt{25} = 0.80$

③ **t 與 df** $t = 3 \div 0.80 = 3.75$ ； $df = n - 1 = 24 \rightarrow p \approx .001$ 顯著

④ **效應量** $d_z = 3 \div 4 = 0.75$ （中大效應）

APA $t(24) = 3.75, p = .001, d_z = 0.75$

教學重點 配對 t 用『每個人的前後差』——去除個體差異，所以比獨立設計省樣本、檢定力高（回想單元 1 的受試者內）。

配對 t：為什麼用『每人前後差』？

同一批人量兩次，不是兩群不同的人

資料長相 同一個人量前、後兩次（或自然配對：雙胞胎、左右手）。

關鍵動作 先把每個人的『後 - 前』算成一個差值，再檢定這些差的平均是否為 0。

為何這樣做 每個人當自己的對照，消掉『個體本來就有高有低』的差異（雜訊變小）→ 檢定力比獨立設計高、更省人。

效應量 $dz = \text{平均差} \div \text{差的 SD}$ （本例 $3 \div 4 = 0.75$ ）。

重點 判斷要不要用配對：問『這兩筆數字是不是同一受試者（或配對）產生的？』是 → 配對 t。

單因子 ANOVA 完整範例 (≥ 3 組)

三種教學法 (各 $n=10$) 成績平均: $A=70$ 、 $B=75$ 、 $C=82$

① 假設 H_0 : 三組母體平均都相等; H_1 : 至少一組不同。

② F 的邏輯 $F = \text{組間變異 (MS between)} \div \text{組內變異 (MS within)}$ ——組間差異相對於雜訊有多大。

③ 結果 $F(2, 27) = 8.00, p = .002 \rightarrow$ 拒絕 H_0 (各組不全相等)。


④ 效應量 $\eta^2 = SS \text{ between} \div SS \text{ total} \approx .37$ (大效應)。

APA $F(2, 27) = 8.00, p = .002, \eta^2 = .37$

教學重點 ANOVA 只說『至少有一組不同』，沒說『哪兩組不同』——要靠事後比較 (下一頁)。

ANOVA：組間 vs 組內，看圖秒懂

平均線分越開、組內點越集中 → F 越大



重點 粗橫線是各組平均、散點是組內個別值。 $F = \text{平均線分多開 (組間)} \div \text{點的散佈 (組內)}$ 。

ANOVA 的 F 在比什麼？

組間差異 相對於 組內雜訊

F 的定義 $F = \text{組間變異} \div \text{組內變異} = \text{『各組平均差多開』}$ 相對於 『組內本來的雜訊』。

直覺 三組平均 70/75/82 差 12 分。若組內每人也上下飄 20 分 → 差被雜訊蓋住（F 小）；若組內很集中 → 差很明顯（F 大）。

結果 F 大 → p 小 → 拒絕 H_0 ：至少有一組不一樣（但還不知是哪兩組）。

效應量 $\eta^2 = \text{組間} \div \text{總變異} = \text{『組別』}$ 能解釋幾成分數變異（本例 .37）。

重點 ANOVA 只回答『有沒有人不一樣』；要知道『誰跟誰不一樣』，看下一頁的事後比較。

ANOVA 事後比較：到底哪幾組不同？

為何需要 ANOVA 顯著只代表『組間有差異』；要知道 A、B、C 誰跟誰不同，得再兩兩比較。

為何不直接多次 t 3 組要比 3 次、每次 $\alpha=.05 \rightarrow$ 累積偽陽性膨脹；事後檢定會『校正』這個問題。

常用方法 Tukey HSD（各組人數相近時最常用）、Bonferroni（保守）、Games-Howell（變異數不同質）。

範例判讀 Tukey：C 顯著高於 A（ $p=.001$ ），C vs B、B vs A 未達顯著 $\rightarrow$ 差異主要來自 C。

教學重點 先看 ANOVA 是否顯著（總體），再做事後比較（局部）；報告要同時給整體 F 與兩兩差異 + 效應量。

事後比較：為何不能直接多跑幾次 t?

多次比較會膨脹偽陽性

問題 3 組兩兩比要比 3 次，每次偽陽性 5% → 至少一次誤判的機率累積到約 14%；組數越多越嚴重。

解法 事後檢定 (Tukey / Bonferroni...) 會『校正』門檻，把整體偽陽性壓回 5%。


怎麼選 人數相近 → Tukey HSD；要最保守 → Bonferroni；變異數不同質 → Games-Howell。

讀法 (本例) Tukey 顯示 C 顯著高於 A；C-B、B-A 未達顯著 → 差異主要來自 C。

重點 流程固定：先看整體 ANOVA 是否顯著，再做事後兩兩比較，並各自報效應量。

ANOVA 的敘述結果與假設

Illness



H₀ 虛無假設


前後（母體）平均相等，
沒有差異。

H₁ 對立假設

前後（母體）平均不相等，
有差異。

重點 H₀：前後（或兩組）母體平均相等； H₁：不相等。箱型圖先看差異，再用檢定判斷是否顯著。

④ 混合設計的推論（RM ANOVA）



- 問題：這個型態是巧合，還是能推論到母體？
- 控制組前後幾乎相同；治療組後測明顯下降
- 檢定「時間 × 組別」交互作用
- 交互作用顯著 → 治療確有作用

APA 報告：時間 × 組別 交互作用 $F(1, 58) = 10.20, p = .002$

④ 混合設計交互作用完整範例（RM ANOVA）


疾病分數：治療組 前 8.10 → 後 4.63（降 3.47）；控制組 前 8.59 → 後 7.65（降 0.94）

- ① 問的是 『時間 × 組別』交互作用——治療組的『變化量』是否大於控制組。
 - ② 為何看交互作用 單看治療組下降可能是時間 / 安慰劑；要比『兩組變化的差異』（3.47 vs 0.94）。
 - ③ 結果 $F(1, 58) = 10.20, p = .002 \rightarrow$ 交互作用顯著 $\rightarrow$ 治療確有作用。
 - ④ 效應量 $\text{partial } \eta^2 = \text{SS 效果} \div (\text{SS 效果} + \text{SS 誤差}) = 48.197 \div (48.197 + 274.103) = .15$ （依 .01 / .06 / .14 基準屬大效應）。
- APA 時間 × 組別交互作用 $F(1, 58) = 10.20, p = .002, \text{partial } \eta^2 = .15$

教學重點 混合設計的關鍵永遠是『交互作用』，不是單一主效果；控制組若也下降，就要靠交互作用把治療效果分離出來。

交互作用：兩條線看治療效果

兩條線斜率不同，就是交互作用



重點 治療組掉得多、控制組幾乎沒動 → 兩線不平行 = 交互作用顯著 → 治療真的有效（已扣掉時間效應）。

交互作用白話：『看情況』就是交互作用

主效果問『整體有沒有用』；交互作用問『對誰特別有用』

情境 新止痛藥對『年輕人』很有效、對『年長者』幾乎無效。

主效果可能被平均掉 把全體平均起來看，藥效可能只是中等，甚至看不太出來。

交互作用 = 效果『隨年齡而不同』 年齡 $\times$ 用藥 的交互作用顯著 = 效果因人而異。

為什麼重要 若忽略交互作用，會誤說『這藥普通』，其實它對特定族群很有用。

教學重點 混合設計的『時間 $\times$ 組別』就是同一回事：治療效果是否『因時間而不同』——看交互作用，不是看單一主效果。

用 JASP 執行重複量數 ANOVA

The screenshot shows the JASP software interface with the 'Repeated Measures ANOVA' window open. The left pane shows the setup for a Repeated Measures ANOVA with 'RM Factor 1' having levels 'before' and 'after'. The 'Repeated Measures Cells' table shows 'illness_before' and 'illness_after' for the 'before' level, and 'illness_after' for the 'after' level. The 'Between Subject Factors' table shows 'group'. The 'Display' section has 'Descriptive statistics' checked. The right pane shows the results for 'Repeated Measures ANOVA'.

Repeated Measures ANOVA

Within Subjects Effects

Cases	Sum of Squares	df	Mean Square	F	p
RM Factor 1	145.486	1	145.486	30.785	< .001
RM Factor 1 * group	48.197	1	48.197	10.198	0.002
Residuals	274.103	58	4.726		

Note. Type III Sum of Squares

Between Subjects Effects

Cases	Sum of Squares	df	Mean Square	F	p
group	92.559	1	92.559	26.556	< .001
Residuals	202.154	58	3.485		

Note. Type III Sum of Squares

Descriptives

Descriptives

RM Factor 1	group	N	Mean	SD	SE	Coefficient of variation
before	control	30	8.589	2.121	0.387	0.247
	treatment	30	8.100	2.166	0.395	0.267
after	control	30	7.654	1.927	0.352	0.252
	treatment	30	4.630	1.877	0.343	0.405

重點 混合設計在 JASP 以 RM ANOVA 分析；重點看「時間 × 組別」交互作用是否顯著（ $p < 0.05$ ）。

⑤ 邏輯斯迴歸（數值 IV × 類別 DV）

- IV 數值（如年齡）、DV 類別（如是否購買）
- 檢驗：購買「機率」是否隨年齡而變化
- $p < 0.05 \rightarrow$ 可推論：母體中購買機率確實隨年齡而變
- 勝算比（Odds Ratio, OR）量化關聯強度：OR 接近 1 $\rightarrow$ 效應小；離 1 越遠 $\rightarrow$ 越強

APA 報告： $\exp(b) = 0.88, z = -3.67, p < .001$ （購買機率隨年齡「顯著下降」）

⑤ 邏輯斯迴歸完整範例（數值 IV × 類別 DV）

年齡（數值）預測是否購買（0/1）

① 為何不用線性 DV 是 0/1 機率，用邏輯斯把『勝算的對數』對 IV 建模。

② 勝算比 OR $\exp(b) = 0.88 \rightarrow$ 年齡每增加 1 歲，購買的『勝算』變為 0.88 倍（下降約 12%）。

③ 方向與顯著 $OR < 1 \rightarrow$ 負向；95% CI [0.82, 0.94] 不含 1 $\rightarrow$ 顯著。


④ 換算機率 把某年齡代入模型可得預測購買機率（如 30 歲 62% $\rightarrow$ 40 歲 31%；50 歲則降至約 11%，見下頁曲線）。

APA $OR = 0.88, 95\% CI [0.82, 0.94], z = -3.67, p < .001$

教學重點 $OR = 1$ 代表無關聯；離 1 越遠關聯越強。報 OR 一定要附 95% CI——CI 是否跨過 1，就是顯著與否。

邏輯斯：機率的 S 形曲線

把年齡映到 0~1 的購買機率



重點 線性會跑出 0~1 之外；邏輯斯用 S 形把 IV 映到機率。年齡每增 1 歲勝算 $\times 0.88$ （OR <1 ，負向）。

⑥ 卡方檢定（類別 IV × 類別 DV）

- 檢驗兩個類別變量的關聯（如：性別 對 是否購買）
- 以列聯表的次數與欄百分比為基礎
- $p < 0.05 \rightarrow$ 兩變量有關聯
- $p > 0.05 \rightarrow$ 無法下結論有差異（可能真的無差異，或樣本太小）

APA 報告（不顯著例，另一組小樣本資料）： $\chi^2(1) = 1.71, p = .19$ （男 66% vs 女 50% 購買，差異不顯著）

非顯著 $\neq$ 證明沒差異；務必檢查樣本數是否足夠。

⑥ 卡方檢定完整範例（觀察 vs 期望）

性別 × 是否購買, $N = 150$: 男 40/60、女 30/20

① 期望次數 若獨立: 男·購買 = $100 \times 70 / 150 = 46.7$; 女·購買 = 23.3 (其餘類推)。

② 卡方值 $\chi^2 = \sum (O-E)^2 / E = (6.67^2 / 46.7) + (6.67^2 / 23.3) + \dots \approx 5.36$

③ df 與 p $df = (2-1)(2-1) = 1$; $\chi^2(1) = 5.36 \rightarrow p = .021$ 顯著。


④ 效應量 Cramér's $V = \sqrt{(5.36 \div 150)} \approx .19$ (小~中關聯)。

APA $\chi^2(1, N = 150) = 5.36, p = .021, V = .19$ (女購買率 60% > 男 40%)

教學重點 卡方比較『觀察 vs 獨立時的期望』; 小樣本 (期望 < 5) 用 Fisher 精確檢定。顯著只說有關聯, 強度看 Cramér's V 。

卡方：觀察 vs 期望，看圖秒懂

實際次數與『無關聯期望』差多少



重點 $\chi^2 = \sum (\text{觀察} - \text{期望})^2 / \text{期望}$ 。藍柱（實際）與灰柱（若無關聯的期望）差越大 → χ^2 越大 → 越可能有關聯。

讀統計軟體輸出：擬真範例（獨立 t 檢定）

把 JASP / SPSS 的表，翻成一句 APA 報告

輸出欄位	數值	怎麼讀
t	2.73	檢定統計量
df	58	自由度 ($n_1 + n_2 - 2$)
p (two-tailed)	.008	$< .05 \rightarrow$ 顯著
Mean Difference	6.00	兩組平均差 (分)
Cohen's d	0.70	效應量 (中大)
95% CI	[1.6, 10.4]	不含 0 $\rightarrow$ 顯著

翻成 APA $t(58) = 2.73, p = .008, d = 0.70, 95\% \text{ CI } [1.6, 10.4]$ 。讀表順序：先看 p（顯不顯著） $\rightarrow$ 再看效應量與 CI（多大、多確定） $\rightarrow$ 配上各組 M、SD 寫成句子。

完整案例：正念 App 能降低護理師壓力嗎？（1/2）

從研究問題一路走到『選對檢定』

- ① **研究問題與設計** 隨機分派 60 位護理師：App 組 vs 等候組；4 週後測知覺壓力量表 PSS（數值）。
- ② **假設** H_0 ：兩組壓力平均相等； H_1 ：兩組不相等（雖預期 App 較低，仍採雙尾較保守）。
- ③ **選檢定** IV = 組別（類別 2 組）、DV = 壓力分數（數值）→ 獨立樣本 t 檢定。
- ④ **檢查假設** 各組近似常態、變異數同質（Levene $p = .42$ 未違反）、觀察獨立 → 可用 t。

教學重點 先把『問題 → 設計 → 假設 → 選檢定 → 假設檢查』定好，再碰數字——這條線就是方法 / 結果章的骨架。

完整案例：正念 App（2/2）——結果、報告與討論

⑤ **結果** App 組 $M = 18.2$, $SD = 5.1$ ；等候組 $M = 22.0$, $SD = 5.4$ （ $n = 30$ 各） $\rightarrow t(58) = 2.80$, $p = .007$ 。

⑥ **效應量與 CI** Cohen's $d = 0.72$ （中大）；平均差 3.8 分，95% CI [1.1, 6.5]（不含 0）。

⑦ **APA 報告** 「App 組壓力（ $M = 18.2$, $SD = 5.1$ ）顯著低於等候組（ $M = 22.0$, $SD = 5.4$ ）， $t(58) = 2.80$, $p = .007$, $d = 0.72$, 95% CI [1.1, 6.5]。」

⑧ **討論（能談因果嗎？）** 有隨機分派 $\rightarrow$ 可談因果；但屬單一樣本、需複製；PSS 為自陳，宜再加客觀指標（如皮質醇）。

教學重點 一個完整結果 = 顯著性（ p ）+ 效果大小（ d / 平均差）+ 精確度（CI）+ 設計能談到什麼（因果 vs 關聯）。

完整案例：把整條線讀成白話

每個數字在說什麼？

一句話結論 隨機分派 60 位護理師，用 App 4 週後壓力 (PSS) 顯著低於等候組。

為何可談因果 有隨機分派（實驗）→ 兩組事前相當 → 差異來自 App，而非兩群人本來就不同。

t(58)=2.80 兩組差距是雜訊 (SE) 的 2.8 倍。

p=.007 若 App 其實無效，只有 0.7% 機率看到這麼大或更大的差。

d=0.72 / 95% CI[1.1, 6.5] 中大效果；與資料相容的平均差約 1.1~6.5 分，區間不含 0（所以顯著）。

重點 一個好結果 = 顯著 (p) + 效果多大 (d/ 平均差) + 多確定 (CI) + 能談到什麼 (因果 vs 關聯)，四者缺一不可。

各檢定的 APA 報告格式總表

檢定	統計量	APA 報告範例
相關 Correlation	r (df)	$r(28) = .88, p < .001$
ANOVA (組間)	F (df1, df2)	$F(1, 58) = 37.91, p < .001$
RM ANOVA (組內 / 混合)	F (df1, df2)	$F(1, 58) = 10.20, p = .002$ (交互作用)
邏輯斯迴歸 Logistic	$\exp(b)$ 、 z	$\exp(b) = 0.88, z = -3.67, p < .001$
卡方 Chi-square	χ^2 (df)	$\chi^2(1) = 1.71, p = .19$

報告三要素：統計量+自由度、精確 p 值、效應量／描述統計； t 檢定的格式見第 48、50 張。

D

避免 p 值誤用

Avoid Mistakes! How to Use p -values Correctly

錯誤一：把「不顯著」當成「證明沒差異」

$p > 0.05$ 時，你「不能」下結論說 H_0 為真——只能說「證據不足以拒絕 H_0 」。

- $p > 0.05$ 有兩種可能：
- ① 母體中真的沒有差異（ H_0 為真）
- ② 其實有差異，但你的樣本數太小、沒偵測到
- 所以「不顯著」無法區分這兩者——不要從 $p > 0.05$ 推出「沒有效果」
- 要主張「沒有差異」，須改用等效性檢定（TOST，見 2.6）。

錯誤二：多重檢定與 Bonferroni 校正

- $\alpha = 0.05$ 代表「每一次檢定」約有 5% 誤判為顯著的機會
- 若在同一批資料做 100 次檢定 → 約有 5 次「純靠運氣」達顯著（chance capitalization）
- 不要「一直換題目做檢定，直到有一個顯著」

解法：Bonferroni 校正

把門檻除以檢定次數。例：做 2 個檢定 → 用 $0.05 \div 2 = 0.025$ 當門檻；做 5 個 → 用 0.01。這樣控制「族系錯誤率（FWER）」，但偏保守；Holm 法同樣控制 FWER 且檢定力較高，大量探索性檢定可改控 FDR（Benjamini-Hochberg）。

原則：先想清楚要做幾個檢定；每份資料集只跑一組事先規劃好的檢定。

p-hacking 與研究者自由度

同一批資料『喬』到顯著，是可重複性危機的元凶

研究者自由度 可選的分析很多：刪不刪離群值、加不加共變量、何時停止收案——都會影響 p 。

p-hacking 不斷嘗試不同分析 / 子群，直到 $p < .05$ ；等於偷偷做了很多檢定。

HARKing 看到結果才回頭『假裝』當初就這樣假設（Hypothesizing After Results are Known）。

對策 預先註冊（pre-registration）分析計畫；區分『驗證性』與『探索性』分析並誠實標示。

教學重點 先寫好分析計畫再看資料——探索性發現當『假設來源』沒問題，但要用新資料驗證，別在同一批資料裡當成定論。

p-hacking：一個具體的例子

同一批資料『喬』到顯著

情境 研究者想證明新教材有效，但一開始 $p=.20$ 不顯著。

開始『喬』 刪掉 3 個表現差的樣本 $\rightarrow p=.12$ ；再加一個共變量 $\rightarrow p=.07$ ；只看女生子群 $\rightarrow p=.04$ ！於是只報這個。

問題 試了很多種分析，總會有一種湊到 $<.05$ （等於偷偷做了很多次檢定），這個『顯著』很可能是假的。

對策 事前註冊分析計畫；把『探索到的發現』誠實標為探索性，再用新資料驗證。

重點 同一批資料反覆嘗試到顯著 = p-hacking；它是可重現性危機的主因之一。

超越 p 值：用 CI 與效應量把話說完整

ASA 六原則（重點） p 值不是效果大小、也不是假設為真的機率；p 不能單獨作為決策依據。

一定要報效應量 $d/\eta^2/r/OR/V$ ——回答『差多少、關聯多強』，且可跨研究比較。

一定要報信賴區間 CI 同時給方向、大小與精確度；比『顯著 / 不顯著』的二分更有資訊。

別說『證明』 說『支持 / 不支持』；單一研究不定論，靠複製與統合分析。

教學重點 現代結果報告 = 檢定統計量 + df + 精確 p + 效應量 + 95% CI；只給『 $p < .05$ 』會被審稿人退。

超越 p 值：同一結果的兩種寫法（承前頁報告要件）

只報 p vs 報完整

只寫 p（不完整）

「兩組有顯著差異
（ $p < .05$ ）。」

→ 讀者不知道
差多少、多確定，
也無法跨研究比較。

完整寫法（建議）

「App 組壓力顯著低於
等候組，平均差 3.8 分，
95% CI[1.1, 6.5],
Cohen's $d=0.72$,
 $t(58)=2.80$, $p=.007$ 。」

→ 方向、大小、精確度、
顯著性一次到位。

重點 現代期刊要求：檢定統計量 + df + 精確 p + 效應量 + 95% CI；別只丟一個『 $p < .05$ 』。

結果章寫作檢查清單

- ☐ 每個檢定都報：統計量+自由度、精確 p 值（不只寫 $p<.05$ ）、效應量與 95% CI
- ☐ 先報敘述統計（各組 M 、 SD 、 n ），再報推論檢定
- ☐ 檢定假設有檢查（常態、變異數同質）；違反時說明改用的方法
- ☐ 多重比較有校正（Bonferroni/Tukey），或說明為事先規劃的少數檢定
- ☐ 區分『統計顯著』與『實務重要』；用效應量與 CI 討論實質意義
- ☐ 區分驗證性與探索性分析；不把『不顯著』寫成『證明沒差異』

教學重點 把這張清單當『送印前的最後檢查』——審稿人最常抓的就是漏效應量 / CI、以及把不顯著當成沒差異。

本單元重點回顧

- **【目標②】推論統計判斷：**在 H_0 為真的假定下，觀察到的資料有多不尋常。
- **【目標②】** 我們反駁 H_0 、而非證明 H_1 ； p 值是反駁 H_0 的證據強度，門檻 0.05 是共識決策線。
- 顯著性取決於三股力量：效應量（大）、變異（小）、樣本量（大）。
- **【目標①】 【目標④】** 依 IV/DV 選檢定：相關、 t 檢定、ANOVA、RM ANOVA、邏輯斯、卡方，並用 APA 格式報告。
- 顯著的意義看設計：實驗能談因果、非實驗只能談關聯。
- **【目標②】** 兩大誤用：不能把「不顯著」當沒差異；多重檢定要用 Bonferroni 校正。
- **【目標③】 【目標④】** 95% CI 與效應量要與統計量、精確 p 值一起報——只報 p 是不完整的。

下一站 **2.6 樣本數規劃：反過來問——要偵測到這樣的效果，事前需要多少人？**

參考文獻與延伸閱讀

- Wasserstein, R. L., & Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician*, 70(2), 129-133. → p 值六原則 (第 79 張)
- Greenland, S., et al. (2016). Statistical tests, P values, confidence intervals, and power: A guide to misinterpretations. *European Journal of Epidemiology*, 31(4), 337-350. → p 值與 CI 的常見誤解
- Cumming, G. (2014). The new statistics: Why and how. *Psychological Science*, 25(1), 7-29. → 效應量與信賴區間
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum. → 效應量基準 (第 35 張)
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65-70. → 多重檢定 (第 76 張)
- Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *JRSS B*, 57(1), 289-300. → FDR
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology. *Psychological Science*, 22(11), 1359-1366. → p-hacking (第 77-78 張)
- Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, 8(4), 355-362. → 主張「沒差異」
- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7th ed.). → APA 報告格式 (第 73 張)



作業

Take-home Assignment

From p-value to a defensible conclusion.

涵蓋單元 5： H_0/H_1 與 p 值邏輯、三股力量、標準誤與信賴區間、六種檢定與效應量、APA 報告、 p 值誤用。

Part A 觀念題檢驗你「懂不懂」； Part B 實作題要你「選對檢定、算得出、報得對」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

能依資料選對推論檢定、算出並解讀結果，並用 APA 格式完整報告（含效應量與 CI）。

繳交方式

一份 PDF：Part A 文字作答 + Part B 計算與 APA 報告，建議 3-5 頁。

建議時間

約 2-3 小時；可用 JASP 驗算，但需寫出檢定選擇與判讀。

工具與誠信

可用 AI／軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

Part A | 觀念題：推論統計（1/2）

- A1** H_0/H_1 是什麼？為何『反駁 H_0 』而非『證明 H_1 』？寫出 p 值的正確定義與兩個常見誤解。
- A2** 決定顯著的三股力量（效應量、變異、樣本數）如何影響 p ？為何大樣本下微弱效應也會顯著？
- A3** 標準誤 SE 與標準差 SD 差在哪？95% 信賴區間怎麼算、怎麼解讀？CI 與假設檢定的關係為何？
- A4** Type I / II 錯誤與 Power 各是什麼？把 α 設更嚴會付出什麼代價？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2-4 句即可。

Part A | 觀念題：推論統計（2/2）

- A5** 依 IV/DV 選檢定：六種檢定各對應什麼資料型態？各寫一個 APA 報告範例。
- A6** 各檢定的效應量（ d / η^2 / r / OR / Cramér's V ）與基準是什麼？為何一定要報效應量與 CI？
- A7** t / ANOVA 的基本假設有哪些？違反時的無母數替代分別是什麼？
- A8** p 值兩大誤用（把不顯著當沒差異、多重檢定）與對策（Bonferroni、預先註冊）。

Part B | 實作題：選檢定、算結果、報 APA (1/2)

情境：比較『新教學法 vs 傳統教學』對考試成績的影響（兩組各 $n = 30$ ）。

新法 $M = 78, SD = 8$ 傳統 $M = 72, SD = 9$

- B1** 寫出 H_0 與 H_1 ；選擇適當的統計檢定並說明理由（依 IV/DV 型態）。
- B2** 算獨立樣本 t （可用公式）、 df ，判斷是否 $p < .05$ ，並算 Cohen's d 、判讀效應大小。
- B3** 寫出這個結果的 APA 報告句（含統計量、 df 、精確 p 、效應量與 95% CI）。

Part B | 實作題：選檢定、算結果、報 APA (2/2)

- B4** 若改為『同一批學生前後測』，該用什麼檢定？效應量用什麼？與 B2 的設計差在哪（樣本效率、假設）？
- B5** 若研究者做了 8 個檢定才找到一個顯著，有什麼問題？你會怎麼處理（校正／預註冊）？並解釋『顯著 ≠ 重要』。
- B6** 寫一段結果章（含效應量與 95% CI 的完整報告）+ AI 使用聲明。

繳交格式 Part B 要看到『檢定選擇的理由』與『計算步驟』；報告句要符合 APA。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能說出關係（如 $CI \leftrightarrow$ 檢定、 $Power=1-\beta$ ）
B1 選檢定	10%	H_0/H_1 正確、依 IV/DV 選對檢定並說理由
B2 計算	15%	t、df、d 計算正確、判讀效應大小
B3 APA 報告	10%	統計量 + df + 精確 p + 效應量 + CI 齊全
B4-B6 設計+誠信	25%	配對設計與效應量正確、多重檢定處理、報告 + AI 聲明

常見扣分 把不顯著當『沒差異』、只報 p 不報效應量 / CI、相關講成因果、多重檢定不校正。

資源連結 · 外部服務與官方網址

點按名稱或網址可直接開啟；工具更新快，功能與費用請以官方頁面為準。

資源 / 服務	官方網址 URL
JASP	jasp-stats.org/

案例應用：三個檢定，三種問題

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

本單元教了什麼

推論的邏輯，以及 t 檢定與卡方各自回答什麼樣的問題。

②

案例怎麼用

- 主要問題用配對 t：同一批人前後測， $t(33) = -6.30$ 、 $p < .001$ 、 $d_z = -1.08$ 。
- 機構差異用獨立 t：A 對 B 後測 $t(60) = -3.85$ 、 $p < .001$ 、 $d = -0.98$ 。
- 類別關聯用卡方：職類 × 完整性達標 $\chi^2(1) = 0.47$ 、 $p = .492$ ，未達顯著。
- 每個檢定先查前提：常態性、變異數同質、期望次數是否足夠。
- 報告一律附效應量與 95% 信賴區間，不只寫 p 值。

③

產出什麼證據

APA 格式結果段三則（次頁），可直接移入論文第四章。

④

承接關係

上游：承自 2.4 之 Table 1 樣本特徵表 | 下游：交棒 2.6，回頭檢視檢定力是否足夠。

教學重點 三個檢定對應三種問題：同一群人前後比、兩群人互相比、兩個類別有沒有關聯。選錯的通常不是公式，而是沒想清楚要比的是什麼。

示範產物：APA 格式結果段三則

數值一律取自唯一數字表；此三段可原樣移入論文，毋須改寫

段落	示範文字
主要結果（配對 t ）	導入後交班準備時間（ $M = 13.03$, $SD = 4.74$ ）顯著短於導入前（ $M = 18.40$, $SD = 5.20$ ）， $t(33) = -6.30$, $p < .001$, $d_z = -1.08$, 95% CI $[-7.10, -3.63]$ 。
機構比較（獨立 t ）	後測期間，A 機構之準備時間（ $M = 13.03$, $SD = 4.74$ ）顯著短於同期未導入之 B 機構（ $M = 17.80$, $SD = 4.99$ ）， $t(60) = -3.85$, $p < .001$, $d = -0.98$, 95% CI $[-7.25, -2.29]$ 。
類別關聯（卡方）	職類與紀錄完整性是否達標之間未達顯著關聯， $\chi^2(1) = 0.47$, $p = .492$, $\phi = .09$ 。本結果不足以支持兩者無關聯之推論，詳見研究限制。

教學重點 第三段的寫法值得注意：不顯著不能寫成「兩者沒有差異」，只能寫「未達顯著關聯」。前者是對母體下結論，後者才是這份資料撐得住的說法。