

量性研究方法 · 完整研究專案

## 單元 6

# 樣本數規劃、執行與研究解讀

*Sample Size, Conducting & Interpreting Your Research*

型一／型二錯誤、各檢定的樣本數計算、最佳化檢定力、信效度檢測、執行研究與下結論，並附完整研究檢核清單

# 本單元結束後，你能……

- 能用 G\*Power 完成先驗樣本數估計，並換算為實際需招募的人數。
- 能區分先驗、事後與敏感度檢定力分析，並說明事後檢定力的侷限。
- 能列出研究執行的倫理要件與資料品質控制措施。
- 能用四步驟解讀研究發現，包含虛無結果與主張等價／非劣性的條件。
- 驗收方式 ① 對應作業 A3、B1；② 對應 A2；③ 對應 A6、B3；④ 對應 A7、A8、B4、B5。

A

# 把統計錯誤降到最低

*Minimize Statistical Errors & Choose Sample Size*

# 兩種錯誤：型一與型二

|       | H <sub>0</sub> 為真（無效果）   | H <sub>0</sub> 為假（有效果）  |
|-------|--------------------------|-------------------------|
| 判定顯著  | 型一錯誤 ( $\alpha$ )<br>偽陽性 | 正確<br>(檢定力 $1-\beta$ )  |
| 判定不顯著 | 正確                       | 型二錯誤 ( $\beta$ )<br>偽陰性 |

你無法同時把兩種錯誤都降到最低：降低型一（更嚴格）常會提高型二，反之亦然。

## 取捨：以新藥研發為例

### 嚴格控制型一（ $\alpha = 0.01$ ）

- 需極強證據才判定有效
- 不易讓無效藥上市（保障安全）
- 但可能錯失真正有效的好藥（型二↑）

### 放寬型一（ $\alpha = 0.20$ ）

- 只要有一點證據就傾向判定有效
- 不易錯過潛在好藥（型二↓）
- 但更多無效藥可能被錯誤接受（型一↑）

## 比喻：面試選才的兩種失誤

把「檢定」想成面試：門檻太鬆會錄取到不適任者（型一）；門檻太嚴會刷掉真正適任者（型二）。

### 門檻太鬆（高 $\alpha$ ）

- 容易「錄取到不適任者」＝偽陽性（型一↑）
- 少數真正適任者被錯過（偽陰性↓）
- 簡單問題 → 多錄取、也多誤收

### 門檻太嚴（低 $\alpha$ ）

- 不易「錄取到不適任者」（型一↓）
- 但容易「刷掉真正適任者」＝偽陰性（型二↑）
- 困難問題 → 少誤收、卻多漏才

## Two Types of Errors

# 統計檢定的兩種錯誤



### Key lessons

- Two types of errors can occur in statistical tests
- **False positives** (wrongly accepting  $H_1$ )
- **False negatives** (wrongly accepting  $H_0$ )
- Two forces control these two error rates
- **P value threshold** (primarily minimizes false positives)
- **Sample size** (primarily minimizes false negatives)

**重點**  $p$  值門檻主要控制偽陽性（型一）；樣本數主要控制偽陰性（型二）。兩者需權衡。（圖中「accepting  $H_0$ 」應讀作「未拒絕  $H_0$ 」）

Power  $\geq$  80% ，高風險研究再提高

## 如何決定樣本數

- 檢定力（power）：  $H_0$  為假時能正確拒絕它的機率
- 常規設 .80 ；臨床試驗等高風險或確認性研究提高至 .90-.95
- 偽陰性機率 =  $1 - \text{power}$  （80% power  $\rightarrow$  20% 偽陰性）
- 效應量：規劃時取「小」或「中」效應量較保守實際
- 研究設計的選擇，會大幅影響所需樣本數

# 檢定力：一個具體的例子

把 80% 與 95% 放進真實情境

**情境** 比較新舊衛教對血壓控制的效果，預期中效應  $d = 0.5$ 。

**設 power = 80%** 需每組約 64 人。意思：即使效果真的存在，仍有 20% 機率漏抓（得到不顯著）。

**設 power = 95%** 需每組約 105 人。漏抓機率降到 5%，但要多招募約 60% 的人。

**漏抓的代價** = 白做一場、還可能誤導『新衛教無效』；臨床等高風險研究值得用 90-95%。

**教學重點** power 是『效果存在時抓得到的機率』；80% 是底線，樣本充足或後果嚴重時再往上提。

# 三種檢定力分析：先驗、事後、敏感度

| 類型                     | 何時做         | 給定什麼 → 求什麼                          |
|------------------------|-------------|-------------------------------------|
| 先驗 <b>A priori</b>     | 收案『前』（正確做法） | 給 $\alpha$ 、Power、效應量 → 求所需 N       |
| 敏感度 <b>Sensitivity</b> | 樣本數已固定時     | 給 $\alpha$ 、Power、N → 求『能偵測的最小效應』   |
| 事後 <b>Post-hoc</b>     | 收案後（不建議）    | 給 $\alpha$ 、N、觀察效應 → 回算 Power（意義不大） |

**教學重點** 本頁為查閱用細表，課堂講授用次頁的三個情境。只有「先驗」能真正規劃樣本數；事後 **Power** 用觀察效應回算、與 **p** 值一體兩面，不能用來解釋不顯著——改用敏感度分析或信賴區間。

# 三種檢定力分析：各一個情境

先驗 / 敏感度 / 事後，分別長什麼樣

## 先驗 A priori (收案前 · 正確)

「要偵測  $d=0.5$ 、power .80  
→ G\*Power 算出每組 64 人」  
→ 拿去寫計畫、送 IRB。

## 敏感度 Sensitivity (N 已固定)

「醫院只能給 40 位病人  
→ 反推：只能偵測  $d \geq 0.9$  的大效應」  
→ 誠實說明能力上限。

## 事後 Post-hoc (收案後 · 不建議)

「收完 30 人、 $p=.20$ ，回算  $\text{power} \approx .25$ 」→ 這只是  $p$  值的重述，不能用來說『因為 power 低所以才不顯著』。要交代不顯著，改用敏感度分析或信賴區間。

**教學重點** 規劃樣本只能用『先驗』；樣本被綁死時用『敏感度』誠實交代；別用事後 power 替不顯著找藉口。

# 各檢定的效應量慣例

| 檢定      | 效應量指標      | 小              | 中              | 大              |
|---------|------------|----------------|----------------|----------------|
| t 檢定    | Cohen's d  | 0.2            | 0.5            | 0.8            |
| 相關 / 迴歸 | r          | 0.1            | 0.3            | 0.5            |
| ANOVA   | Cohen's f  | 0.10           | 0.25           | 0.40           |
| 邏輯斯迴歸   | Odds Ratio | $\approx 1.68$ | $\approx 3.47$ | $\approx 6.71$ |
| 卡方檢定    | w          | 0.1            | 0.3            | 0.5            |

*p* 值回答「有沒有效？」；效應量回答「效應有多大？」——兩者都要報告。

# 規劃樣本數，效應量從哪來？

樣本數計算最難的一步，就是先『猜』一個合理的效應量

- ① **文獻／統合分析** 找同主題研究或 meta-analysis 的平均效應量——最可靠的來源。
- ② **先導研究 pilot** 小規模先跑，估效應與變異；但 pilot 的  $d$  很不穩，別高估。
- ③ **最小有意義效應 SESOI** 問『多小的效果才值得在意』，用它當規劃基準（保守、實務導向）。
- ④ **Cohen 慣例（最後手段）** 沒資訊時用『中』效應，但要清楚這只是粗估。

**教學重點** 常見錯誤：用『pilot 算出的大效應』去規劃 →  $N$  太小、研究注定沒力。取『保守（偏小）』效應較安全。

# 效應量從哪來：四種來源各一例

規劃前先『猜』一個合理的效應量

- ① **文獻／統合分析** 查到同類正念介入對壓力的統合  $d \approx 0.45$  → 直接採用（最可靠）。
- ② **先導研究 pilot** 自己先跑 15 人估  $d=0.8$  → pilot 很不穩，別直接用，打折當參考。
- ③ **最小有意義效應 SESOI** 臨床上血壓至少要降 5 mmHg 才算有意義 → 換算成  $d$  當規劃基準。
- ④ **Cohen 慣例（最後手段）** 完全沒資訊 → 用『中效應』  $d=0.5$ ，但要註明只是粗估。

**教學重點** 寧可用『偏小／保守』的效應量規劃 →  $N$  抓大一點，免得研究注定沒力。


# 檢定力的四角關係： $\alpha$ 、Power、效應量、N

| 旋鈕            | 往哪調                        | 對 Power 的影響                                  | 備註                |
|---------------|----------------------------|----------------------------------------------|-------------------|
| 效應量           | 越大                         | Power $\uparrow$ (需 N $\downarrow$ )         | 多由現象決定，可用文獻估      |
| 樣本數 N         | 越多                         | Power $\uparrow$                             | 研究者最能控制的          |
| 顯著水準 $\alpha$ | 放寬 (.05 $\rightarrow$ .10) | Power $\uparrow$                             | 但偽陽性風險 $\uparrow$ |
| 雜訊／變異         | 降低                         | 有效效應 $\uparrow \rightarrow$ Power $\uparrow$ | 靠可靠測量、受試者內設計      |

**教學重點** 本頁為查閱用細表，課堂講授用次頁的四角關係圖。四者知道任三個就能算第四個；先驗 **power analysis** = 給定  $\alpha$ 、Power、效應量，反推所需 N。

# 檢定力四角關係：定三推一


$\alpha$ 、Power、效應量、N



四個量互相牽動：給定其中三個，第四個就被決定了。規劃樣本數=固定  $\alpha$ 、Power 與效應量，求 N。

**教學重點** 規劃樣本數就是固定  $\alpha$ 、Power 與效應量，反推 N；樣本已固定時則反推「能偵測多小的效應」。

## 設計如何影響所需樣本數



- 組間設計因個體差異大，需最多樣本
- 組內／混合設計大幅減少所需人數
- 示意（ $f = 0.10$ 、power .80、重複測量相關 .5）：組間 788 人，組內／混合約 200 人
- 降低需求的方法：強化操弄（放大效應）、提高測量信度、或改變研究設計

# 為什麼組內設計省這麼多人？

同一效應，組間 vs 組內差在哪

**讀圖** 同一效應量，組間（不同人）需要的  $N$  最多；組內 / 混合（同一批人）大幅下降。小效應 ( $d=0.2$ ) 下組間近 800 人。


**原因** 組間有『個體差異』（有人天生高、有人低），這是雜訊，要靠更多人才平均得掉。

**組內為何省** 每個人當自己的對照（比自己前後），個體差異被消掉 → 雜訊小 → 同效應用更少人就達 power。

**代價 / 限制** 組內有順序、練習、疲勞與遺留效應，需平衡次序 (counterbalance) 或洗滌期；且非所有 IV 都能組內。


**教學重點** 想省人先問：這個 IV 能不能讓同一個人都經歷？能 → 組內；不能（性別、疾病組）→ 只能組間，得靠加人或提高信度。

# G\*Power 樣本數計算：相關




- 檢定族：Correlation（雙尾）
- 效應量  $r$ ：中效應約 0.3
- $\alpha = 0.05$ 、Power = 0.95（本頁截圖示範值；常規請採 .80）
- $H_0$  下相關 = 0（母體無關聯）
- 輸出：所需總樣本數 **Total sample size**

# G\*Power 樣本數計算：ANOVA（組間）




- 效應量 Cohen's  $f$ ：小 0.10 / 中 0.25 / 大 0.40
- $\alpha = 0.05$ 、Power = 0.95（本頁截圖示範值；常規請採 .80）
- Number of groups：組數（如 2）
- 小效應（ $f = 0.10$ 、2 組）需求極大：power .80 約 788 人、.95 約 1,300 人
- → 改用較大效應量或改變設計

# G\*Power 樣本數計算：RM ANOVA（組內）



- 純組內設計： Number of groups = 1
- Number of measurements：如前後 = 2
- Corr among rep measures：難估時留預設
- 所需人數遠少於組間設計

# G\*Power 樣本數計算：邏輯斯迴歸



- 效應量以 Odds Ratio 表示
- OR 約 1.7 小、3.5 中、6.7 大（Chen et al., 2010）
- 設定基準事件機率（如 20% 購買）
- $\alpha = 0.05$ 、Power = 0.95（本頁截圖示範值；常規請採 .80）

## G\*Power 完整實例：常見檢定所需樣本數

$\alpha = .05$  ; 同時看 Power = .80 (最低) 與 .95 (理想) 的差別

| 檢定              | 中效應量        | Power .80     | Power .95      |
|-----------------|-------------|---------------|----------------|
| 獨立 t (兩組)       | $d = 0.5$   | 共 128 (每組 64) | 共 210 (每組 105) |
| 配對 t            | $d_z = 0.5$ | 34 人          | 54 人           |
| 單因子 ANOVA (3 組) | $f = 0.25$  | 共 159         | 共 252          |
| 相關              | $r = 0.30$  | 84            | 138            |
| 卡方 (2×2)        | $w = 0.30$  | 88            | 145            |

**教學重點** 把 Power 從 .80 拉到 .95，樣本數約要多 60%——『更保險』是有代價的。效應越小需求越爆炸（t 檢定  $d=0.2$  每組要 394 人）。

# 這張樣本數表怎麼讀？

## 一步步查給你看

**怎麼查** 先依 IV/DV 選『檢定』那一行，再看要的 power 欄。例：兩組比較中效應 → 獨立 t → power .80 → 共 128（每組 64）。

**為何 .95 欄都比較大** 要更保險（漏抓機率從 20% 降到 5%），就得多收約 60% 的人。

**效應越小，人越爆炸** 同樣獨立 t， $d=0.5$  每組 64； $d=0.2$  每組要 394。

**配對比獨立省很多** 配對 t 只要 34，獨立 t 要 128——因為配對去掉了個體差異。

**教學重點** 表是『中效應』的參考值；實際規劃要用你自己估的效應量在 G\*Power 重算，別直接套。

## 隨堂 60 秒：樣本數規劃

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 事前以  $d_z = 0.5$ 、 $\alpha = .05$  雙尾、 $\text{power} = .80$  規劃，算得 34 人。若把  $\text{power}$  提高到 .95，人數大約要增加多少？
- ② 既然 .95 更保險，為什麼常規仍取 .80？
- ③ 算出的 34 人就是要招募的人數嗎？還要再考慮什麼？

**講評重點** 檢定力是成本與風險的取捨；「算出的  $N$ 」永遠不等於「要招募的人數」。

## G\*Power 逐步操作實例（兩組平均比較）

- ① **Test family / test**    t tests → Means: Difference between two independent means。
- ② **Type of power analysis**    選 A priori （給效應量 /  $\alpha$  / Power，求所需樣本數）。
- ③ **輸入**    Tail(s) = Two；Effect size  $d = 0.5$ ； $\alpha = .05$ ；Power = .80；Allocation ratio = 1。
- ④ **讀輸出**    Total sample size = 128（每組 64）；Actual power  $\approx .80$ 。

**教學重點**    效應量不確定時，用 G\*Power 的『Determine =>』面板，從兩組平均與 SD 反推  $d$ ；或直接輸入你的 SESOI。

# 設計如何省樣本：組間 vs 組內（同一效應）

| 設計      | 效應量           | Power .80 所需 N |
|---------|---------------|----------------|
| 組間（兩組）  | $d = 0.5$ （中） | 共 128 人        |
| 組內／配對   | $d_z = 0.5$   | 34 人（同一批）      |
| 組間（小效應） | $d = 0.2$     | 共 788 人        |

同一效應下，設計決定人數（ $\alpha = .05$ 、Power .80）

組間  $d = 0.5$   128 人

組內／配對  $d_z = 0.5$   34 人

組間  $d = 0.2$ （小效應）  788 人

**教學重點** 組內設計用『每人當自己對照』去除個體差異 → 同效應下人數少一大截。小效應時組間需求近 800 人——改組內或提高測量信度最有效。

# 設計效率：同一效應，人數差在哪？

把三列數字讀成一句話

**對照三列** 組間中效應  $d=0.5 \rightarrow 128$  人；改組內  $d_z=0.5 \rightarrow$  只要 34 人（同一批）；組間但小效應  $d=0.2 \rightarrow$  暴增到 788 人。

**意思 1 · 設計比蠻力有效** 同樣的效應，組間改組內，人數少一大截 ( $128 \rightarrow 34$ )。

**意思 2 · 效應大小影響巨大** 效應從 0.5 掉到 0.2，需求從 128 飆到 788（約 6 倍）。

**實務順序** 先看能不能組內  $\rightarrow$  再想把效應做大（強操控）或雜訊做小（提高信度） $\rightarrow$  不得已才加樣本。

**教學重點** 省樣本的優先順序：改組內  $>$  提高測量信度 / 強操控  $>$  最後才是加大樣本。

## 把『算出的 N』變成『要招募的人數』

**流失率調整** 若需 128 且預估 20% 中途退出 → 招募  $128 \div (1-0.20) = 160$  人。

**不等組配置** 2:1 配置比 1:1 需要更多總人數——除非有理由，否則等組最省。

**共變量 ANCOVA** 納入與 DV 高相關的共變量（如前測），可降低誤差、減少所需 N（所需 N 約乘以  $1-r^2$ ）。

**叢集／分層** 叢集抽樣要乘『設計效應』把 N 放大；分層可提升效率。

**教學重點** 『算出的 N』是分析所需的最低有效樣本；真正要招募的，還要加上流失、篩選不合格與無效卷的緩衝。

# 從 N 到招募人數：一步步算給你看

算出的 N 不是要招募的人數

**起點** 分析需要的有效樣本  $N = 128$ （每組 64）。

① **加流失** 預估 20% 中途退出 → 招募  $128 \div (1 - 0.20) = 160$  人。

② **加篩選 / 無效卷** 再估 10% 不合格或問卷無效 →  $160 \div (1 - 0.10) \approx 178$  人。

**省人技巧** 納入前測當共變量 (ANCOVA)，與 DV 高相關（如  $r = .6$ ）可降低誤差 → 反而減少所需 N。

**教學重點** 『算出的 N』是分析要的最低有效樣本；真正要招募的  $= N \div (1 - \text{流失}) \div (1 - \text{無效})$ ，務必留緩衝。

# 完整樣本數規劃實例：從研究問題到招募人數

研究：正念 App 是否降低護理師壓力？（兩組比較）

- ① **檢定** 兩組平均比較 → 獨立樣本 t 檢定（雙尾）。
- ② **效應量** 查文獻，類似介入  $d \approx 0.5$ （中）；規劃取保守值  $d = 0.45$ 。
- ③  **$\alpha$  與 Power**  $\alpha = .05$ 、Power = .80。
- ④ **G\*Power**  $d = 0.45 \rightarrow$  每組 79（共 158）。
- ⑤ **流失緩衝** 預估 15% 退出  $\rightarrow 158 \div 0.85 \approx 186$ （每組 93）。
- ⑥ **結論** 規劃招募約 186 位護理師，才能在效果存在時有 80% 偵測力。

**教學重點** 先驗規劃要寫進研究計畫（收案前）——這是 IRB 與審查委員會檢查的重點，也避免做出一個『沒有檢定力』的研究。

B

# 如何最佳化統計檢定力

*How to Optimize Statistical Power*

# 檢定力不足會怎樣？如何提高 Power

## 檢定力不足 ( $<.80$ ) 的後果

- 真有效果卻測不出（偽陰性、高 Type II）
- 就算測到顯著，效果也常被高估、難複製
- 浪費資源與參與者

## 如何提高 Power

- 增加樣本數  $N$ （最直接）
- 降低雜訊：更可靠工具、標準化程序
- 用受試者內／配對設計（去個體差異）
- 增強操弄以放大效應
- （有依據時）單尾檢定或放寬  $\alpha$

**教學重點** 先驗（a priori）power 要在收案前做；事後（post-hoc）用觀察效應算 power 意義不大，別拿來『解釋不顯著』。

## 檢定力的三個槓桿

### 樣本數

#### 直接

唯一能「直接」控制的因素——  
加大樣本。

### 效應量

#### 間接

透過『強操控』間接放大：比較  
最極端的兩端。

### 變異性

#### 間接

透過提高『測量信度』間接降低  
雜訊。

強操控 = 把 IV 操弄到最強（大量治療 vs 完全無治療）；用類別 IV 比較兩極端。

# 三個槓桿：各用一個做法舉例

沒錢加人時，還有兩個間接槓桿

## 樣本數（直接）

若真實效應僅  $d = 0.42$ ，原每組 64 人 power 只有 .65  
→ 直接多招募到每組 90 人。

最直接，  
但最花錢、花時間。

## 效應量（強操控・間接）

比較『每天 60 分鐘運動』  
vs 『完全不運動』兩極端，  
而非 60 vs 45 分鐘。

→ 組間差變大、更易偵測。

## 變異（提高信度・間接）

單題自評 → 改 5 題量表  
( $\alpha = .85$ )，或多次測量取平均。

→ 雜訊變小，  
等於變相加大 power。

**教學重點** 沒錢加人時，先想能不能『強操控 IV』或『提高測量信度』——這兩招不加人也能提升檢定力。

## 檢測測量信度的三種方法

### 再測信度 Test-Retest

同一測量在兩個時間點的相關。例：兩次體重測量高度相關 → 信度佳。

### 內部一致性

同一問卷多題項是否測同一概念；用 Cronbach's  $\alpha$ 。 $\alpha \geq .70$  可接受、 $\geq .80$  佳（ $>.95$  恐題目重複）。


### 評分者間信度

多位觀察者評分的一致性；類別判定用 Cohen's  $\kappa$ ，連續分數用 ICC（相關看不出整體偏高或偏低）。

若某題項或某觀察者對信度無貢獻（如 Cronbach's  $\alpha$  因它下降）→ 可考慮刪除。

# 三種信度：各檢驗一種「一致」

跨時間 / 跨評分者 / 題目之間



選哪一種取決於你的威脅：怕受測者狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→ $\alpha$ 。

**教學重點** 信度不足會稀釋效果、拉低檢定力——提高信度等於免費提升 power，比事後加樣本便宜。

# 信度實例：Cronbach's $\alpha$ 與題目分析

## 5 題『工作壓力量表』的內部一致性

**公式概念**  $\alpha = (k/(k-1)) \times (1 - \Sigma \sigma^2_{\text{題}} / \sigma^2_{\text{總}})$ ， $k$  = 題數。題越多、題間相關越高  $\rightarrow \alpha$  越高。

**整體結果** 5 題  $\alpha = .82$ （良好；.70 可接受、.80 佳、>.95 可能題目重複）。

**題目分析** 看『校正後題總相關』：題 1、2、4、5 約 .55-.70；題 3 僅 .15。

**刪題判斷** 『 $\alpha$  if item deleted』：刪題 3 後  $\alpha$  升到 .87  $\rightarrow$  題 3 測的不是同一件事，考慮刪或改寫。

**教學重點**  $\alpha$  高不代表『單一維度』——題目太多也會推高  $\alpha$ 。要配合因素分析（EFA/CFA）確認結構。

## $\alpha$ 與題目分析：怎麼看、怎麼決定刪題

把上一頁的數字讀懂

**$\alpha = .82$  代表** 5 題大致測同一件事（工作壓力），內部一致性良好（.70 可接受 / .80 佳 / >.95 恐重複）。

**校正後題總相關** 每題與『其他題總分』的相關。題 1/2/4/5 約 .55-.70（好）；題 3 只有 .15（不合拍）。

**$\alpha$  if item deleted** 刪某題後的  $\alpha$ 。刪題 3  $\rightarrow \alpha$  從 .82 升到 .87  $\rightarrow$  題 3 在扯後腿。

**決策** 題 3 可能問到別的概念（或反向題沒反轉） $\rightarrow$  考慮刪除或改寫，再重新施測。

**教學重點**  $\alpha$  高只說『一致』，不保證『單一維度』；題目太多也會灌高  $\alpha$ ——要配合因素分析 (EFA/CFA) 確認結構。

## 檢測測量效度

### 聚斂效度 Convergent

- 與「應相關」的變數確實相關
- 體適能 vs 跑步速度 → 正相關 ✓
- 體適能 vs 安靜心跳 → 負相關 ✓

### 區辨效度 Discriminant

- 與「不該相關」的變數不相關
- 體適能 vs 身高 → 接近 0、不顯著 ✓
- 體適能 vs 襯衫數量 → 接近 0 ✓

## 效度實例：用相關矩陣看聚斂與區辨

新『工作壓力量表』——該相關的相關、不該相關的不相關

| 與哪個變數比 | 預期       | 觀察 $r$ | 判讀   |
|--------|----------|--------|------|
| 職業倦怠   | 應正相關（聚斂） | .62    | 聚斂 ✓ |
| 睡眠品質   | 應負相關（聚斂） | -.48   | 聚斂 ✓ |
| 每週工時   | 弱正相關（合理） | .30    | 合理   |
| 身高     | 不該相關（區辨） | .04    | 區辨 ✓ |

**教學重點** 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算真的測到『壓力』而非別的東西。

## 聚斂與區辨：用相關矩陣看

同構念要高、跨構念要低（與 2.2 第 20 張為同一範例矩陣，此處作回顧）

|      |       |       |       |       |       |       |
|------|-------|-------|-------|-------|-------|-------|
| 壓力 1 | 1.00  | 0.72  | 0.68  | -0.18 | -0.12 | -0.15 |
| 壓力 2 | 0.72  | 1.00  | 0.75  | -0.14 | -0.16 | -0.11 |
| 壓力 3 | 0.68  | 0.75  | 1.00  | -0.12 | -0.10 | -0.13 |
| 支持 1 | -0.18 | -0.14 | -0.12 | 1.00  | 0.70  | 0.74  |
| 支持 2 | -0.12 | -0.16 | -0.10 | 0.70  | 1.00  | 0.69  |
| 支持 3 | -0.15 | -0.11 | -0.13 | 0.74  | 0.69  | 1.00  |

壓力 1 壓力 2 壓力 3 支持 1 支持 2 支持 3

### 怎麼讀這張相關矩陣



綠框：同一構念的題目

應該「高」（此例 .68-.75）→ 聚斂效度成立



橘框：不同構念之間

應該「低」（此例 -.10~-.18）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事，  
要合併、重新定義，或改題。

**教學重點** 區辨效度不足會讓兩個構念互相稀釋，等同增加測量誤差——這正是「提高效率也能提高檢定力」的機制。

C

# 執行研究與解讀發現

*Conducting & Interpreting Your Research*

# 執行研究：如何取得參與者

- 在合適場域招募：醫學研究找醫院、商業研究找公司
- 大學生常用「便利樣本」——資源有限時的典型做法
- 篩選（screening）：確認受試者屬於目標母體
- 知情同意：事前告知風險與益處
- 留意「要求特徵」；測量基本人口變項（至少年齡、性別）
- 結束時做「debriefing」，讓受試者了解研究內容

# 專業執行（一）：招募、篩選與研究倫理

**場域與抽樣框** 到目標母體所在處招募（醫院 / 公司 / 校園）；記錄抽樣框與回收率。

**篩選 Screening** 用納入／排除條件確認受試者屬目標母體；記錄篩掉多少、為什麼。

**倫理審查 IRB** 收案前送機構審查（IRB/REC）；弱勢或高風險族群更嚴格。

**知情同意** 事前告知目的、風險、益處、可隨時退出，並取得書面同意。

**debriefing** 結束時說明研究內容（尤其有隱瞞設計時），並提供聯絡與資源。

**教學重點** 倫理不是形式：知情同意、資料保密、退出權、debriefing 都要寫進計畫；違反倫理取得的資料不能用。

## 專業執行（二）：讓資料可信的品質控制

**前註冊 Pre-registration** 收案前公開假設與分析計畫 → 區分驗證性 / 探索性、防 p-hacking。

**盲化 Blinding** 受試者 / 施測者不知分組（單盲 / 雙盲），降低期望與要求特徵。

**標準化程序** 統一指導語、環境與順序；用對抗平衡控制順序效應。

**資料監控** 邊收邊查：遺漏、離群、直線作答、注意力題；記錄流失與原因。

**教學重點** 『可重現』從執行就開始：把程序寫成可照做的手冊，別人（或未來的你）才能複製你的研究。

## 解讀發現的四大判準

### 無其他解釋

是否存在其他合理解釋？用控制變項或統計方法排除。

### 準確測量

結果是否準確反映研究目的？工具與資料是否可靠。

### 外部效度

結果能否推廣到其他情境？樣本與情境是否具代表性。

### 可重複性

結果能否複製？換樣本或換團隊重做是否一致。

# 解讀四判準：各配一個提問例子

用四個問句檢視你的結果

## ① 無其他解釋（內部效度）

「壓力下降，真的是 App 造成的嗎？  
會不會剛好碰上放暑假？」  
→ 用控制組 / 共變量排除。

## ③ 外部效度（可推廣）

「只在這 60 位護理師成立，  
還是能推到其他醫院 / 職業？」  
→ 看樣本與情境代表性。

## ② 準確測量（構念效度）

「我用的量表真的在測『壓力』嗎？」  
→ 檢查工具的效度證據  
與操作型定義。

## ④ 可重複性（一致）

「換一批人或換團隊重做，  
結果會一樣嗎？」  
→ 複製研究、多工具交叉驗證。

**教學重點** 四判準依序對應內部效度、測量、外部效度與可重複性；先確認『不是別的原因、測得準、重做也一致』，再談能不能推廣。

## A 4-Step Interpretation Framework

# 系統化解讀：四個步驟

**1 Step 1 統計結論** *Statistical conclusion*  $p < 0.05$  嗎？顯著 → 這個結果不太可能只是抽樣巧合。

**2 Step 2 測量** *Measurements* 測量有效度疑慮嗎？自陳是否與其他指標一致？

**3 Step 3 替代解釋** *Explanations* 是實驗嗎？實驗只留解釋 1；非實驗需考慮 2、3 與混淆。


**4 Step 4 外部效度** *External validity* 樣本隨機嗎？情境真實嗎？能推廣到母體嗎？

接下來用同一套四步驟，走過四個真實情境的解讀範例。

## A 4-Step Interpretation Framework

# 寫作版四步：統計 → 大小 → 設計 → 實務

上頁四步檢查效度威脅；本頁四步安排結果章與討論章的寫作順序



常見錯誤：只做第①步就下結論（「顯著，所以有效」）——那只回答了四分之一。

虛無結果也照這四步走：不顯著 → 看 CI 有多寬 → 看設計有無檢定力不足 → 再談實務。

寫作對應：①②寫在結果章，③④寫在討論章。

**教學重點** 常見錯誤是只做第①步就下結論；四步走完，結果章與討論章的骨架也就出來了。

# 四步驟解讀完整範例：一個真實情境

研究：線上輔導是否提升數學成績？（隨機分派兩組）

**結果** 輔導組  $M=76$  vs 對照組  $M=70$ ； $t(98)=2.9$ ,  $p=.005$ ,  $d=0.58$ , 95% CI [1.9, 10.1]。

- ① **統計結論（可靠嗎）**  $p<.05$ 、效應中等、CI 不含 0 → 不太可能只是抽樣巧合。
- ② **測量（測得準嗎）** 成績為標準化測驗（客觀）→ 效度佳；若為自評則需更謹慎。
- ③ **替代解釋** 有隨機分派 → 排除反向與第三變項，可談因果（留意實施差異等混淆）。
- ④ **外部效度（能推廣嗎）** 單一學校樣本 → 推廣需謹慎，宜複製到不同學校 / 年級。

**教學重點** 完整解讀＝先確認『可靠』（ $p$  + 效應 + CI），再問『測得準嗎、有無其他解釋、能推廣嗎』——四關都過才下強結論。

## 解讀範例①：實驗設計

### 研究設計與結果

組間實驗：把人「隨機」分到治療組與控制組。IV = 治療，DV = 憂鬱。

**結果** 治療組憂鬱顯著低於控制組（ $p < 0.05$ ）。

**結論：**治療有效，且在符合條件下可推論到母體。

### 四步驟解讀

**1 統計結論**  $p < 0.05 \rightarrow$  結果不太可能只是巧合。

**2 測量** 自陳憂鬱是否與臨床診斷等指標一致？

**3 解釋** 是實驗（已隨機化） $\rightarrow$  只有解釋 1：治療造成差異。留意控制組若未給安慰劑，期望效應可能混入。

**4 外部效度** 樣本隨機／分層？情境真實？ $\rightarrow$  可謹慎推廣。

## 解讀範例②：準實驗

### 研究設計與結果

準實驗混合設計（有介入，但未隨機分派誰接受治療）。前測、後測比較兩組。

**結果** 控制組前後幾乎相同；治療組後測較低。

**結論：**結果可靠，但「無法斷定因果」，只能談關聯。

### 四步驟解讀

**1 統計結論** 交互作用  $p < 0.05 \rightarrow$  不太可能只是巧合。

**2 測量** 憂鬱是自陳嗎？有無過去研究支持其效度？

**3 解釋** 未隨機化  $\rightarrow$  三種解釋都可能：治療 $\rightarrow$ 憂鬱、憂鬱 $\rightarrow$ 尋求治療（反向）、第三變項（自我照護）。

**4 外部效度** 樣本／情境是否具代表性？

## 解讀範例③：相關研究

### 研究設計與結果

非實驗：冥想頻率（數值 IV）與幸福感（數值 DV）。

**結果**  $r = 0.41$ ，中度正相關。

**結論：**有顯著關聯，但不能推論「冥想造成快樂」。

### 四步驟解讀

**1 統計結論**  $p < 0.05 \rightarrow$  相關不太可能只是巧合。

**2 測量** 幸福感為自陳，留意測量效度。

**3 解釋** 非實驗  $\rightarrow$  三種解釋：冥想 $\rightarrow$ 快樂、快樂 $\rightarrow$ 冥想、第三變項（自我照護動機）。

**4 外部效度** 受訪者在自家自行冥想，樣本是否代表一般人？

## 解讀範例④：虛無結果

### 研究設計與結果

組間實驗：治療組 vs 控制組 → 憂鬱。兩組差異很小。

**結果**  $p = 0.42$ （不顯著）。

**結論：**四關全過也只能說效果可能很小；要主張等價，須用 **TOST**（第 58 張）。

### 四步驟解讀

**1 統計結論** 不顯著 → 先別下「沒效果」的結論。

**2 測量** 測量與操控：信度效度夠嗎？IV 操弄夠強嗎？

**3 解釋**（本例先看樣本數）對「臨床上最小重要差異」是否達 .80 以上檢定力？

**4 外部效度** 樣本無偏？情境真實？

$p > 0.05$  時

## 如何解讀虛無結果（null result）

- 先排查方法學問題，再談結論：
  - 樣本數：對「臨床上最小重要差異（SESOI）」是否達 .80 以上檢定力？→ 若是，方可主張「未觀察到重要效果」
  - 測量與操弄：信度、效度足夠嗎？IV 操弄夠強嗎？
  - 外部效度：真隨機樣本？資料點獨立？情境真實？
- 以上全部為「是」，也只能說效果可能很小；要主張「沒有差異」須用等價檢定（第 58 張）

## 隨堂 60 秒：不顯著怎麼解讀

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 的紀錄完整性  $t(33)=1.26$ 、 $p = .215$ 。可以說「AI 工具對紀錄品質沒有影響」嗎？
- ② 若要主張「至少不比原本差」，事前必須先做什麼？
- ③ 該看哪一個數字來判斷這個主張成不成立？

**講評重點** 「不顯著」只是證據不足；要主張「不差」必須事前訂界限，並看信賴區間的下界。

# 解讀虛無結果進階：怎麼主張『沒有實務差異』

$p > .05$  不能證明沒差異——要主張『等價』得用等價檢定

**問題** 傳統檢定不顯著  $\neq$  沒差異（可能只是沒力）。『沒有證據』不等於『有證據證明沒有』。

**等價界限 SESOI** 先定『多小的差異算沒差』，例如  $\pm 5$  分。

**TOST 做法** 若差異的 90% CI 完全落在  $[-5, +5]$  內  $\rightarrow$  可主張『實務上等價』。


**範例** 觀察差異 1.2 分、90% CI  $[-2.1, 4.5] \subset [-5, 5] \rightarrow$  可主張兩法效果等價。

**教學重點** 想主張『沒差異 / 一樣好』，別只報  $p > .05$ ；用等價檢定（TOST），或看 CI 是否夠窄且落在可忽略範圍內。

## Equivalence Testing (TOST)

# 不顯著 $\neq$ 等價：要用等價檢定

CI 必須整段落落在等價界限內



**教學重點** 想主張「沒有實務差異」，必須事先訂好最小有意義差異，再看 CI 是否完全落在界限內。

## 統計顯著 vs 實務重要：用效應量與 CI 判讀

|       | 研究 A             | 研究 B            |
|-------|------------------|-----------------|
| 樣本數 N | 8,000            | 50              |
| 效應量 d | 0.06             | 0.85            |
| p 值   | p = .007 (顯著)    | p = .004 (顯著)   |
| 判讀    | 顯著但幾乎沒實務意義 (大 N) | 效果大、值得在意 (雖樣本小) |

**教學重點** 決策看『效應量 + CI + 實務門檻』，不是只看 p。大 N 會讓瑣碎差異顯著；小 N 的大效應也可能很重要。

# 顯著 $\times$ 效果大小：四種情況

p 與效應量 / CI 一起看

## 顯著 + 效果大

最理想：有效且值得推

## 顯著 + 效果小

大樣本才顯著；要問值不值得

## 不顯著 + CI 窄

較有把握「真的沒什麼效果」

## 不顯著 + CI 寬

資訊不足：可能只是樣本太小

**教學重點** 「不顯著」要先看 CI 寬窄：CI 很寬只代表資訊不足，不能說「證明沒效」。

# 事後補救：微調你的研究問題

研究做完才發現方法學限制時，不必推翻一切——改問「這份資料到底能回答什麼」。

- 問自己：這份資料「能」回答哪個問題（**which question CAN you answer**）？
- 問自己：從結果「能」得出什麼結論（**which conclusion CAN you draw**）？
- 例：原本想證明「自動」形成印象，若證據不足 → 改主張「自發」形成（較保守、仍有貢獻）
- 誠實揭露限制、用謹慎的語言陳述——縮小主張範圍，而非誇大或隱瞞

# 誠實寫限制與外部效度

**內部效度限制** 非隨機、混淆未控、測量誤差 → 說明可能的方向與影響。

**外部效度限制** 樣本（便利 / 單一場域）、情境（實驗室 vs 真實）、時間點 → 推廣範圍要保守。

**測量限制** 自陳偏誤、單一指標 → 建議未來加客觀或多元指標。

**語言要保守** 用『支持 / 傾向』而非『證明』；縮小主張範圍，而非隱瞞。

**教學重點** 誠實揭露限制不會扣分，反而顯示你懂方法學——審稿人最怕的是『過度宣稱』與『假裝沒有限制』。

# 完整研究實例（1/2）：規劃與執行

遠距工作是否提升員工幸福感？

- ① **問題與設計** 隨機分派員工：遠距組 vs 一般組；8 週後測幸福感 WHO-5（數值）。
- ② **樣本數規劃** 文獻  $d \approx 0.4$  → 每組約 100（共 200）；預估 15% 流失 → 招募約 236。
- ③ **測量** WHO-5（信度  $\alpha = .85$ 、效度佳）＋客觀出勤資料交叉驗證。
- ④ **執行** IRB 通過、知情同意、單盲評分、前註冊分析計畫、邊收邊清資料。

**教學重點** 好研究在『收案前』就把效應量、樣本數、測量工具、倫理與分析計畫都定好——這一頁就是計畫書骨架。

## 完整研究實例（2/2）：分析與解讀

- ⑤ **結果** 遠距組 WHO-5  $M=68$  vs 一般組  $M=62$  ;  $t(198)=3.1$ ,  $p=.002$ ,  $d=0.44$ , 95% CI [2.2, 9.8]。
- ⑥ **四步驟解讀** 統計結論：穩健；測量：有客觀資料佐證；解釋：隨機化→可談因果；外部：單一公司需複製。
- ⑦ **實務判讀**  $d = 0.44$  中等、CI 不含 0 → 有實務意義，但非萬靈丹。
- ⑧ **結論與限制** 支持遠距對幸福感有正向效果；限制：單一產業、以自陳為主、僅 8 週短期。

**教學重點** 一個完整研究的句點＝顯著性＋效應量＋CI＋設計能談到什麼＋誠實的限制——這就是結果與討論章。

# 完整研究檢核清單（一）

## 研究問題 & 設計

- 重要？新穎？合乎時機？
- 組間：是否隨機分派？
- 組內：是否隨機化／對抗平衡順序？
- 控制組是否含混淆變項？查清單！
- 無法隨機化 → 用準實驗（非對等控制組＋前後測）

## 測量 & 資料蒐集

- 測量可靠？標準化、多次平均
- 查過去研究：該工具信度如何？
- 測量有效？聚斂與區辨效度證據
- 自陳注意社會期許偏誤
- 蒐集盡量隨機獨立；N 由先驗檢定力分析決定並含流失緩衝（ $N \geq 30$  僅為經驗法則）

## 完整研究檢核清單（二）

### 資料準備 & 統計

- 格式：每列一人、每測量一欄
- 處理缺失值與離群值
- 敘述：對的圖（散布／箱型／列聯表）
- 推論：先驗  $\text{power} \geq .80$ （高風險研究提高至 .90-.95）
- 用對檢定？只做一個檢定？ $p < 0.05$ ？

### 執行 & 解讀

- 篩選、知情同意、debriefing
- 統計結論： $p < 0.05 \rightarrow$  不太可能是巧合
- 測量準確性：留意效度與信度
- 替代解釋：實驗設計？有混淆嗎？
- 外部效度：真隨機？情境真實？

# 結果與討論寫作檢查清單

- ☐ 先驗樣本數規劃有寫（效應量來源、 $\alpha$ 、Power、所需 N 與流失緩衝）
- ☐ 每個檢定報：統計量 + df + 精確 p + 效應量 + 95% CI
- ☐ 信度（ $\alpha$ ）與效度證據有交代；測量工具來源清楚
- ☐ 用四步驟解讀：可靠？測得準？有無其他解釋？能否推廣？
- ☐ 區分統計顯著與實務重要；虛無結果不寫成『證明沒差異』
- ☐ 誠實列限制與外部效度；用保守語言、附 AI 使用聲明

**教學重點** 把這張清單當『投稿前最後檢查』——最常被退稿的就是漏樣本數規劃、漏效應量 / CI，以及過度宣稱。

## 課程總結：你已經學會

- 提出一個吸引人且可行的研究問題
- 設計能將替代解釋降到最低的研究
- 在最大化信度與效度下進行測量
- 用適當技術與足夠樣本數蒐集資料
- 用免費易用的軟體（如 JASP）分析資料
- 從結果得出穩健的結論
- 【目標①】 – 【目標④】 四項目標的驗收，見帶回家作業 Part A 與 Part B。

下一站 2.7 實例演練：把 2.1-2.6 串成一條決策鏈，用五個範例完整走一遍。

## 參考文獻與延伸閱讀

- Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). Lawrence Erlbaum. → 效應量慣例 (第 12 張)
- Faul, F., Erdfelder, E., Lang, A.-G., & Buchner, A. (2007). G\*Power 3. Behavior Research Methods, 39(2), 175–191. → 樣本數計算 (第 19–26 張)
- Lakens, D. (2022). Sample size justification. Collabra: Psychology, 8(1), 33267. → 效應量從哪來、SESOI (第 13–14 張)
- Hoenig, J. M., & Heisey, D. M. (2001). The abuse of power: The pervasive fallacy of power calculations for data analysis. The American Statistician, 55(1), 19–24. → 事後 power 的謬誤 (第 10–11 張)
- Borm, G. F., Fransen, J., & Lemmens, W. A. J. G. (2007). A simple sample size formula for analysis of covariance in randomized clinical trials. J Clin Epidemiol, 60(12), 1234–1238. → ANCOVA 省樣本 (第 29 張)
- Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. Social Psychological and Personality Science, 8(4), 355–362. → TOST (第 58–59 張)
- Nosek, B. A., et al. (2018). The preregistration revolution. PNAS, 115(11), 2600–2606. → 前註冊 (第 46 張)



作業

# Take-home Assignment

*Plan it, run it, interpret it.*

涵蓋單元 6：型一 / 二錯誤與檢定力、樣本數規劃、信效度檢測、研究執行與倫理、四步驟解讀。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題要你「規劃得出、解讀得對」。參考解答在本節後段。

# 作業說明：目標、繳交與規則

### 作業目標

能規劃一個研究的樣本數與信效度檢測，並用四步驟解讀結果（含虛無結果）。

### 繳交方式

一份 PDF：Part A 文字作答 + Part B 規劃與解讀，建議 3-5 頁。

### 建議時間

約 2-3 小時；可用 G\*Power / JASP，但需寫出輸入與判讀。

### 工具與誠信

可用 AI / 軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

## Part A | 觀念題：規劃、執行與解讀（1/2）

- A1** 型一 / 型二錯誤與檢定力的關係為何？為何不能同時最小化兩者？ $\text{Power} \geq .80$  代表什麼？
- A2** 先驗／事後／敏感度三種 power analysis 的差別？為何『事後 power』意義不大？
- A3** 規劃樣本數要先估效應量——四種來源與各自風險？為何規劃時取『保守（偏小）』效應？
- A4** 為何組內設計比組間省樣本？還有哪些方法能降低所需  $N$ （共變量、提高信度…）？

**作答提示** 觀念題重『說得清楚＋舉得出例』；每題 2-4 句即可。

## Part A | 觀念題：規劃、執行與解讀（2/2）

- A5** 信度三型與 Cronbach's  $\alpha$  怎麼判讀？聚斂效度與區辨效度各需要什麼證據？
- A6** 研究執行的三項倫理要件（IRB、知情同意、debriefing）與兩項品質控制（前註冊、盲化）為何重要？
- A7** 解讀發現的四個步驟是什麼？各回答什麼問題？
- A8**  $p > .05$  該怎麼正確解讀？想主張『兩者沒有實務差異』要怎麼做？統計顯著 vs 實務重要差在哪？

## Part B | 實作題：規劃與解讀（1/2）

**情境：**研究『線上正念課程是否降低大學生焦慮』（隨機分派兩組比較）。

- B1** 選檢定並寫  $H_0/H_1$ ；文獻得  $d \approx 0.5$ ，設  $\alpha=.05$ 、Power=.80，估每組所需  $N$ ；再依 20% 流失算招募人數。
- B2** 你會用什麼工具測焦慮？如何檢驗其信度（ $\alpha$ ）與效度？各舉一個『應相關』與『不該相關』的變數。
- B3** 列出執行時的三項研究倫理要件與兩項資料品質控制措施。

**教學重點** 樣本數要在收案『前』規劃；測量要先確認信效度，資料才值得分析。

## Part B | 實作題：規劃與解讀（2/2）

- B4** 結果為  $t(158)=2.67$ ,  $p=.008$ ,  $d=0.42$ , 95% CI [1.2, 8.0]（隨機實驗）——用四步驟完整解讀。
- B5** 若另一結果  $p=.30$ （不顯著），你會怎麼解讀？在什麼條件下能主張『兩者等價』？
- B6** 寫一段結果與討論（含效應量、CI 與限制）+ AI 使用聲明。

**繳交格式** Part B 要看得『樣本數計算』與『四步驟解讀』；虛無結果別寫成『證明沒差異』。

## 評分重點與繳交 Rubric

| 項目                   | 配分  | 評分重點                                    |
|----------------------|-----|-----------------------------------------|
| <b>Part A 觀念</b>     | 40% | 定義正確、能舉例、能說出取捨（如錯誤取捨、事後 power）          |
| <b>B1 樣本數規劃</b>      | 15% | 選對檢定、N 計算正確、含流失緩衝                       |
| <b>B2 信效度</b>        | 15% | 測量工具 + $\alpha$ + 聚斂 / 區辨（各舉相關 / 不相關變數） |
| <b>B3 倫理 + 品質</b>    | 10% | 倫理要件與品質控制具體可行                           |
| <b>B4-B6 解讀 + 誠信</b> | 20% | 四步驟正確、虛無結果解讀恰當、報告 + AI 聲明               |

**常見扣分** 用事後 power 解釋不顯著、把  $p > .05$  當『沒差異』、樣本數沒含流失、報告缺效應量 / CI。

# 資源連結 · 外部服務與官方網址

點按名稱或網址可直接開啟；工具更新快，功能與費用請以官方頁面為準。

| 資源 / 服務 | 官方網址 URL                                                                         |
|---------|----------------------------------------------------------------------------------|
| JASP    | <a href="https://jasp-stats.org/">jasp-stats.org/</a>                            |
| G*Power | <a href="https://www.psychologie.hhu.de/en/forschung/gpower/">gpower.hhu.de/</a> |

# 案例應用：規劃時保守，結論才站得住

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

## 本單元教了什麼

型一與型二錯誤、檢定力，以及樣本數該怎麼算出來。

②

## 案例怎麼用

- 規劃階段保守假設  $d_z = 0.5$ ， $\alpha = .05$  雙尾、 $\text{power} = .80$ ，得  $n = 34$ 。
- 實際收案 A 機構 34 人恰達規劃值；B 機構 28 人為既有人力全數。
- 實得  $d_z = 1.08$ ，遠大於規劃值 0.5——保守的規劃假設讓樣本綽綽有餘。
- 若只收到 20 人，在  $d_z = 0.5$  之下檢定力僅 .565，過半機率得不到顯著。
- 職類  $\times$  完整性之卡方不顯著：效應  $w = .09$  極小，需 969 人才有 .80 檢定力——本研究無力回答，不能知道為何

③

## 產出什麼證據

事前檢定力分析報告與情境對照表（次頁），納入計畫書第 3.3 節。

④

## 承接關係

上游：承自 2.5 之 APA 格式結果段 | 下游：交棒 2.7，把七步驟完整走一遍。

**教學重點** 事前檢定力分析要用「你能接受的最小效果」，不是「你希望看到的效果」。假設 0.5 而實得 1.08 是好事；假設 1.0 而實得 0.4，研究就白做了。

# 示範產物：檢定力情境對照表

同一份資料在不同樣本數與效應量下的檢定力；未列說明不顯著結果為何不可解讀為無關聯

| 情境         | 效應量          | 樣本數 | 檢定力      | 判讀                  |
|------------|--------------|-----|----------|---------------------|
| 規劃假設       | $d_z = 0.50$ | 34  | .808     | 規劃基準；恰達 .80 之慣例門檻   |
| 實際結果       | $d_z = 1.08$ | 34  | $> .999$ | 以觀察效應回算，僅供對照        |
| 若只收到 20 人  | $d_z = 0.50$ | 20  | .565     | 過半機率得不到顯著，研究可能白做    |
| 若只收到 20 人  | $d_z = 1.08$ | 20  | .996     | 效果大時樣本可少，惟事前無從得知    |
| 職類 × 完整性   | $w = .09$    | 62  | .109     | 以觀察效應回算，僅供對照；重點看下一列 |
| 同上，若要達 .80 | $w = .09$    | 969 | .800     | 此效應量下所需樣本遠超本研究可及    |

**教學重點** 最後兩列是本單元最重要的一課：若真實效應小如  $w = .09$ ，要 969 人才有 .80 檢定力——62 人無力回答這個問題；這是對照，不是不顯著的『原因』。把「沒驗出來」寫成「沒有差異」，是論文最常見的過度宣稱。