

量性研究方法 · 完整研究專案

## 單元 6

# 樣本數規劃、執行與研究解讀

*Sample Size, Conducting & Interpreting Your Research*

型一 / 型二錯誤、各檢定的樣本數計算、最佳化檢定力、信效度檢測、執行研究與下結論，並附完整研究檢核清單

## 本單元結束後，你能.....

- 能用 G\*Power 完成先驗樣本數估計，並換算為實際需招募的人數。
- 能區分先驗、事後與敏感度檢定力分析，並說明事後檢定力的侷限。
- 能列出研究執行的倫理要件與資料品質控制措施。
- 能用四步驟解讀研究發現，包含虛無結果與主張等價 / 非劣性的條件。
- 驗收方式 ① 對應作業 A3、B1；② 對應 A2；③ 對應 A6、B3；④ 對應 A7、A8、B4、B5。

# 8

## 把統計錯誤降到最低

*Minimize Statistical Errors & Choose Sample Size*

## 兩種錯誤：型一與型二

|       | $H_0$ 為真 ( 無效果 )         | $H_0$ 為假 ( 有效果 )        |
|-------|--------------------------|-------------------------|
| 判定顯著  | 型一錯誤 ( $\alpha$ )<br>偽陽性 | 正確<br>( 檢定力 $1-\beta$ ) |
| 判定不顯著 | 正確                       | 型二錯誤 ( $\beta$ )<br>偽陰性 |

你無法同時把兩種錯誤都降到最低：降低型一（更嚴格）常會提高型二，反之亦然。

## 取捨：以新藥研發為例

### 嚴格控制型一 ( $\alpha = 0.01$ )

- 需極強證據才判定有效
- 不易讓無效藥上市 ( 保障安全 )
- 但可能錯失真正有效的好藥 ( 型二  $\uparrow$  )

### 放寬型一 ( $\alpha = 0.20$ )

- 只要有一點證據就傾向判定有效
- 不易錯過潛在好藥 ( 型二  $\downarrow$  )
- 但更多無效藥可能被錯誤接受 ( 型一  $\uparrow$  )

## 比喻：面試選才的兩種失誤

把「檢定」想成面試：門檻太鬆會錄取到不適任者（型一）；門檻太嚴會刷掉真正適任者（型二）。

### 門檻太鬆（高 $\alpha$ ）

- 容易「錄取到不適任者」= 偽陽性（型一↑）
- 少數真正適任者被錯過（偽陰性↓）
- 簡單問題 → 多錄取、也多誤收

### 門檻太嚴（低 $\alpha$ ）

- 不易「錄取到不適任者」（型一↓）
- 但容易「刷掉真正適任者」= 偽陰性（型二↑）
- 困難問題 → 少誤收、卻多漏才

# 統計檢定的兩種錯誤



## Key lessons

- Two types of errors can occur in statistical tests
- **False positives** (wrongly accepting  $H_1$ )
- **False negatives** (wrongly accepting  $H_0$ )
- Two forces control these two error rates
- **P value threshold** (primarily minimizes false positives)
- **Sample size** (primarily minimizes false negatives)

**重點**  $p$  值門檻主要控制偽陽性（型一）；樣本數主要控制偽陰性（型二）。兩者需權衡。

Power  $\geq$  80% , 高風險研究再提高

## 如何決定樣本數

- 檢定力 ( power ) :  $H_0$  為假時能正確拒絕它的機率
- 常規設 .80 ; 臨床試驗等高風險或確認性研究提高至 .90–.95
- 偽陰性機率 =  $1 - \text{power}$  ( 80% power  $\rightarrow$  20% 偽陰性 )
- 效應量 : 分析時採「小」或「中」效應量較保守實際
- 研究設計的選擇 , 會大幅影響所需樣本數

# 檢定力：一個具體的例子

把 80% 與 95% 放進真實情境

**情境** 比較新舊衛教對血壓控制的效果，預期中效應  $d = 0.5$ 。

**設 power = 80%** 需每組約 64 人。意思：即使效果真的存在，仍有 20% 機率漏抓（得到不顯著）。

**設 power = 95%** 需每組約 105 人。漏抓機率降到 5%，但要多招募約 60% 的人。

**漏抓的代價** = 白做一場、還可能誤導『新衛教無效』；臨床等高風險研究值得用 90–95%。

**教學重點** power 是『效果存在時抓得到的機率』；80% 是底線，樣本充足或後果嚴重時再往上提。

## 三種檢定力分析：先驗、事後、敏感度

| 類型              | 何時做            | 給定什麼 → 求什麼                             |
|-----------------|----------------|----------------------------------------|
| 先驗 A priori     | 收案『前』 ( 正確做法 ) | 給 $\alpha$ 、Power、效應量 → 求所需 N          |
| 敏感度 Sensitivity | 樣本數已固定時        | 給 $\alpha$ 、Power、N → 求『能偵測的最小效應』      |
| 事後 Post-hoc     | 收案後 ( 不建議 )    | 給 $\alpha$ 、N、觀察效應 → 回算 Power ( 意義不大 ) |

**教學重點** 本頁為查閱用細表，課堂講授用次頁的三個情境。只有「先驗」能真正規劃樣本數；事後 Power 用觀察效應回算、與 p 值一體兩面，不能用來解釋不顯著——改用敏感度分析或信賴區間。

# 三種檢定力分析：各一個情境

先驗 / 敏感度 / 事後，分別長什麼樣

## 先驗 A priori ( 收案前 · 正確 )

- 「要偵測  $d=0.5$ 、power .80
- G\*Power 算出每組 64 人」
- 拿去寫計畫、送 IRB。

## 敏感度 Sensitivity ( N 已固定 )

- 「醫院只能給 40 位病人
- 反推：只能偵測  $d \geq 0.9$  的大效應」
- 誠實說明能力上限。

## 事後 Post-hoc ( 收案後 · 不建議 )

「收完 30 人、 $p=.20$ ，回算 power=.35」→ 這只是  $p$  值的重述，不能用來說『因為 power 低所以才不顯著』。要交代不顯著，改用敏感度分析或信賴區間。

**教學重點** 規劃樣本只能用『先驗』；樣本被綁死時用『敏感度』誠實交代；別用事後 power 替不顯著找藉口。

# 各檢定的效應量慣例

| 檢定      | 效應量指標      | 小    | 中    | 大    |
|---------|------------|------|------|------|
| t 檢定    | Cohen's d  | 0.2  | 0.5  | 0.8  |
| 相關 / 迴歸 | r          | 0.1  | 0.3  | 0.5  |
| ANOVA   | Cohen's f  | 0.10 | 0.25 | 0.40 |
| 邏輯斯迴歸   | Odds Ratio | ≈1.5 | ≈2.5 | ≈4   |
| 卡方檢定    | w          | 0.1  | 0.3  | 0.5  |

*p* 值回答「有沒有效？」；效應量回答「效應有多大？」——兩者都要報告。

# 規劃樣本數，效應量從哪來？

樣本數計算最難的一步，就是先『猜』一個合理的效應量

- ① **文獻 / 統合分析** 找同主題研究或 meta-analysis 的平均效應量——最可靠的來源。
- ② **先導研究 pilot** 小規模先跑，估效應與變異；但 pilot 的 d 很不穩，別高估。
- ③ **最小有意義效應 SESOI** 問『多小的效果才值得在意』，用它當規劃基準（保守、實務導向）。
- ④ **Cohen 慣例（最後手段）** 沒資訊時用『中』效應，但要清楚這只是粗估。

**教學重點** 常見錯誤：用『pilot 算出的大效應』去規劃 → N 太小、研究注定沒力。取『保守（偏小）』效應較安全。

# 效應量從哪來：四種來源各一例

規劃前先『猜』一個合理的效應量

- ① 文獻 / 統合分析 查到同類正念介入對壓力的統合  $d \approx 0.45$  → 直接採用（最可靠）。
- ② 先導研究 pilot 自己先跑 15 人估  $d=0.8$  → pilot 很不穩，別直接用，打折當參考。
- ③ 最小有意義效應 SESOI 臨床上血壓至少要降 5 mmHg 才算有意義 → 換算成  $d$  當規劃基準。
- ④ Cohen 慣例（最後手段） 完全沒資訊 → 用『中效應』 $d=0.5$ ，但要註明只是粗估。

**教學重點** 寧可用『偏小/保守』的效應量規劃 →  $N$  抓大一點，免得研究注定沒力。


## 檢定力的四角關係： $\alpha$ 、Power、效應量、N

| 旋鈕            | 往哪調                          | 對 Power 的影響                                  | 備註                |
|---------------|------------------------------|----------------------------------------------|-------------------|
| 效應量           | 越大                           | Power $\uparrow$ ( 需 N $\downarrow$ )        | 多由現象決定，可用文獻估      |
| 樣本數 N         | 越多                           | Power $\uparrow$                             | 研究者最能控制的          |
| 顯著水準 $\alpha$ | 放寬 ( .05 $\rightarrow$ .10 ) | Power $\uparrow$                             | 但偽陽性風險 $\uparrow$ |
| 雜訊 / 變異       | 降低                           | 有效效應 $\uparrow \rightarrow$ Power $\uparrow$ | 靠可靠測量、受試者內設計      |

**教學重點** 本頁為查閱用細表，課堂講授用次頁的四角關係圖。四者知道任三個就能算第四個；先驗 power analysis = 給定  $\alpha$ 、Power、效應量，反推所需 N。

# 檢定力四角關係：定三推一


$\alpha$ 、Power、效應量、N



四個量互相牽動：給定其中三個，第四個就被決定了。規劃樣本數 = 固定  $\alpha$ 、Power 與效應量，求 N。

**教學重點** 規劃樣本數就是固定  $\alpha$ 、Power 與效應量，反推 N；樣本已固定時則反推「能偵測多小的效應」。

## 設計如何影響所需樣本數



- 組間設計因個體差異大，需最多樣本
- 組內 / 混合設計大幅減少所需人數
- 示意：小效應下組間需近 800 人
- 降低需求的方法：改用較大效應量、提高 power 上限、或改變研究設計

# 為什麼組內設計省這麼多人？

同一效應，組間 vs 組內差在哪

**讀圖** 同一效應量，組間（不同人）需要的 N 最多；組內/混合（同一批人）大幅下降。小效應( $d=0.2$ )下組間近 800 人。


**原因** 組間有『個體差異』（有人天生高、有人低），這是雜訊，要靠更多人才平均得掉。

**組內為何省** 每個人當自己的對照（比自己前後），個體差異被消掉 → 雜訊小 → 同效應用更少人就達 power。

**代價/限制** 組內有順序、練習、疲勞與遺留效應，需平衡次序(counterbalance)或洗滌期；且非所有 IV 都能組內。


**教學重點** 想省人先問：這個 IV 能不能讓同一個人都經歷？能 → 組內；不能（性別、疾病組）→ 只能組間，得靠加人或提高信度。

## G\*Power 樣本數計算：相關



- 檢定族：Correlation ( 雙尾 )
- 效應量  $r$ ：中效應約 0.3
- $\alpha = 0.05$ 、Power = 0.95 ( 本頁截圖示範值；常規請採 .80 )
- $H_0$  下相關 = 0 ( 母體無關聯 )
- 輸出：所需總樣本數 Total sample size

## G\*Power 樣本數計算：ANOVA (組間)



- 效應量 Cohen's  $f$  : 小 0.10 / 中 0.25 / 大 0.40
- $\alpha = 0.05$ 、Power = 0.95 ( 本頁截圖示範值；常規請採 .80 )
- Number of groups : 組數 ( 如 2 )
- 小效應下需求極大 ( 可能近 800 人 )
- → 改用較大效應量或改變設計

## G\*Power 樣本數計算：RM ANOVA (組內)

G\*Power 3.1.9.7

File Edit View Tests Calculator Help

Central and noncentral distributions Protocol of power analyses

Test family: F tests  
Statistical test: ANOVA: Repeated measures, within factors


Type of power analysis: A priori. Compute required sample size - given  $\alpha$ , power, and effect size

| Input Parameters        |                                     | Output Parameters |                                   |           |
|-------------------------|-------------------------------------|-------------------|-----------------------------------|-----------|
| Determine $\rightarrow$ | Effect size $f$                     | 0.1               | noncentrality parameter $\lambda$ | 7.960000  |
|                         | $\alpha$ err prob                   | 0.05              | Critical F                        | 3.8888529 |
|                         | Power ( $1 - \beta$ err prob)       | 0.8               | Numerator df                      | 1.0000000 |
|                         | Number of groups                    | 1                 | Denominator df                    | 198       |
|                         | Number of measurements              | 2                 | Total sample size                 | 199       |
|                         | Corr among rep measures             | 0.5               | Actual power                      | 0.8016910 |
|                         | Nonsphericity correction $\epsilon$ | 1                 |                                   |           |

Options X-Y plot for a range of values Calculate

- 純組內設計：Number of groups = 1
- Number of measurements：如前後 = 2
- Corr among rep measures：難估時留預設
- 所需人數遠少於組間設計

## G\*Power 樣本數計算：邏輯斯迴歸



- 效應量以 Odds Ratio 表示
- OR 接近 1 為小效應；約 2.5 為中效應
- 設定基準事件機率 ( 如 20% 購買 )
- $\alpha = 0.05$ 、Power = 0.95 ( 本頁截圖示範值；常規請採 .80 )

## G\*Power 完整實例：常見檢定所需樣本數

$\alpha = .05$  ; 同時看 Power = .80 ( 最低 ) 與 .95 ( 理想 ) 的差別

| 檢定                | 中效應量        | Power .80       | Power .95        |
|-------------------|-------------|-----------------|------------------|
| 獨立 t ( 兩組 )       | $d = 0.5$   | 共 128 ( 每組 64 ) | 共 210 ( 每組 105 ) |
| 配對 t              | $d_z = 0.5$ | 34 人            | 54 人             |
| 單因子 ANOVA ( 3 組 ) | $f = 0.25$  | 共 159           | 共 252            |
| 相關                | $r = 0.30$  | 84              | 138              |
| 卡方 ( 2×2 )        | $w = 0.30$  | 88              | 145              |

**教學重點** 把 Power 從 .80 拉到 .95，樣本數約要多 60%——『更保險』是有代價的。效應越小需求越爆炸 ( t 檢定  $d=0.2$  每組要 394 人 )。

# 這張樣本數表怎麼讀？

一步步查給你看

**怎麼查** 先依 IV/DV 選『檢定』那一行，再看要的 power 欄。例：兩組比較中效應 → 獨立 t → power .80 → 共 128 ( 每組 64 ) 。

**為何 .95 欄都比較大** 要更保險 ( 漏抓機率從 20% 降到 5% ) ，就得多收約 60% 的人。

**效應越小，人越爆炸** 同樣獨立 t,  $d=0.5$  每組 64;  $d=0.2$  每組要 394 。

**配對比獨立省很多** 配對 t 只要 34，獨立 t 要 128——因為配對去掉了個體差異。

**教學重點** 表是『中效應』的參考值；實際規劃要用你自己估的效應量在 G\*Power 重算，別直接套。

## 隨堂 60 秒：樣本數規劃

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 事前以  $d_z = 0.5$ 、 $\alpha = .05$  雙尾、 $\text{power} = .80$  規劃，算得 34 人。若把  $\text{power}$  提高到 .95，人數大約要增加多少？
- ② 既然 .95 更保險，為什麼常規仍取 .80？
- ③ 算出的 34 人就是要招募的人數嗎？還要再考慮什麼？

**講評重點** 檢定力是成本與風險的取捨；「算出的 N」永遠不等於「要招募的人數」。

## G\*Power 逐步操作實例（兩組平均比較）

- ① **Test family / test** t tests → Means: Difference between two independent means。
- ② **Type of power analysis** 選 A priori（給效應量/ $\alpha$ /Power，求所需樣本數）。
- ③ **輸入** Tail(s) = Two；Effect size d = 0.5； $\alpha$  = .05；Power = .80；Allocation ratio = 1。
- ④ **讀輸出** Total sample size = 128（每組 64）；Actual power  $\approx$  .80。

**教學重點** 效應量不確定時，用 G\*Power 的『Determine =>』面板，從兩組平均與 SD 反推 d；或直接輸入你的 SESOI。

## 設計如何省樣本：組間 vs 組內（同一效應）

| 設計      | 效應量           | Power .80 所需 N |
|---------|---------------|----------------|
| 組間（兩組）  | $d = 0.5$ （中） | 共 128 人        |
| 組內 / 配對 | $d_z = 0.5$   | 34 人（同一批）      |
| 組間（小效應） | $d = 0.2$     | 共 788 人        |

同一效應下，設計決定人數（ $\alpha=.05$ 、Power .80）

組間  $d = 0.5$   128 人

組內 / 配對  $d_z = 0.5$   34 人

組間  $d = 0.2$ （小效應）  788 人

**教學重點** 組內設計用『每人當自己對照』去除個體差異 → 同效應下人數少一大截。小效應時組間需求近 800 人——改組內或提高測量信度最有效。

## 設計效率：同一效應，人數差在哪？

把三列數字讀成一句話

**對照三列** 組間中效應  $d=0.5 \rightarrow 128$  人；改組內  $d_z=0.5 \rightarrow$  只要 34 人（同一批）；組間但小效應  $d=0.2 \rightarrow$  暴增到 788 人。

**意思 1 · 設計比蠻力有效** 同樣的效應，組間改組內，人數少一大截( $128 \rightarrow 34$ )。

**意思 2 · 效應大小影響巨大** 效應從 0.5 掉到 0.2，需求從 128 飆到 788（約 6 倍）。

**實務順序** 先看能不能組內  $\rightarrow$  再想把效應做大（強操控）或雜訊做小（提高信度） $\rightarrow$  不得已才加樣本。

**教學重點** 省樣本的優先順序：改組內  $>$  提高測量信度/強操控  $>$  最後才是加大樣本。

## 把『算出的 N』變成『要招募的人數』

**流失率調整** 若需 128 且預估 20% 中途退出 → 招募  $128 \div (1-0.20) = 160$  人。

**不等組配置** 2:1 配置比 1:1 需要更多總人數——除非有理由，否則等組最省。

**共變量 ANCOVA** 納入與 DV 高相關的共變量（如前測），可降低誤差、減少所需 N（所需 N 約乘以  $1-r^2$ ）。

**叢集 / 分層** 叢集抽樣要乘『設計效應』把 N 放大；分層可提升效率。

**教學重點** 『算出的 N』是分析所需的最低有效樣本；真正要招募的，還要加上流失、篩選不合格與無效卷的緩衝。

# 從 N 到招募人數：一步步算給你看

算出的 N 不是要招募的人數

**起點** 分析需要的有效樣本  $N = 128$  ( 每組 64 ) 。

① **加流失** 預估 20% 中途退出 → 招募  $128 \div (1-0.20) = 160$  人。

② **加篩選/無效卷** 再估 10% 不合格或問卷無效 →  $160 \div (1-0.10) \approx 178$  人。

**省人技巧** 納入前測當共變量(ANCOVA) · 與 DV 高相關 ( 如  $r=.6$  ) 可降低誤差 → 反而減少所需 N 。

**教學重點** 『算出的 N』是分析要的最低有效樣本；真正要招募的 =  $N \div (1-\text{流失}) \div (1-\text{無效})$ ，務必留緩衝。

# 完整樣本數規劃實例：從研究問題到招募人數

研究：正念 App 是否降低護理師壓力？（兩組比較）

- ① 檢定 兩組平均比較 → 獨立樣本 t 檢定（雙尾）。
- ② 效應量 查文獻，類似介入  $d \approx 0.5$ （中）；規劃取保守值  $d = 0.45$ 。
- ③  $\alpha$  與 Power  $\alpha = .05$ 、Power = .80。
- ④ G\*Power  $d = 0.45 \rightarrow$  每組 79（共 158）。
- ⑤ 流失緩衝 預估 15% 退出  $\rightarrow 158 \div 0.85 \approx 186$ （每組 93）。
- ⑥ 結論 規劃招募約 186 位護理師，才能在效果存在時有 80% 偵測力。

**教學重點** 先驗規劃要寫進研究計畫（收案前）——這是 IRB 與審查委員會檢查的重點，也避免做出一個『沒有檢定力』的研究。



# 如何最佳化統計檢定力

*How to Optimize Statistical Power*

# 檢定力不足會怎樣？如何提高 Power

## 檢定力不足 ( $<.80$ ) 的後果

- 真有效果卻測不出 ( 偽陰性、高 Type II )
- 就算測到顯著，效果也常被高估、難複製
- 浪費資源與參與者

## 如何提高 Power

- 增加樣本數  $N$  ( 最直接 )
- 降低雜訊：更可靠工具、標準化程序
- 用受試者內 / 配對設計 ( 去個體差異 )
- 增強操弄以放大效應
- ( 有依據時 ) 單尾檢定或放寬  $\alpha$

**教學重點** 先驗 ( a priori ) power 要在收案前做；事後 ( post-hoc ) 用觀察效應算 power 意義不大，別拿來『解釋不顯著』。

## 檢定力的三個槓桿

### 樣本數

#### 直接

唯一能「直接」控制的因素——  
加大樣本。

### 效應量

#### 間接

透過『強操控』間接放大：比較  
最極端的兩端。

### 變異性

#### 間接

透過提高『測量信度』間接降低  
雜訊。

強操控 = 把 IV 操弄到最強 ( 大量治療 vs 完全無治療 ) ；用類別 IV 比較兩極端。

## 三個槓桿：各用一個做法舉例

沒錢加人時，還有兩個間接槓桿

### 樣本數（直接）

若真實效應僅  $d = 0.42$ ，原每組 64 人 power 只有 .66

→ 直接多招募到每組 90 人。

最直接，  
但最花錢、花時間。

### 效應量（強操控·間接）

比較『每天 60 分鐘運動』  
vs 『完全不運動』兩極端，  
而非 60 vs 45 分鐘。

→ 組間差變大、更易偵測。

### 變異（提高信度·間接）

單題自評 → 改 5 題量表  
( $\alpha=.85$ )，或多次測量取平均。

→ 雜訊變小，  
等於變相加大 power。

**教學重點** 沒錢加人時，先想能不能『強操控 IV』或『提高測量信度』——這兩招不加人也能提升檢定力。

## 檢測測量信度的三種方法

### 再測信度 Test-Retest

同一測量在兩個時間點的相關。例：兩次體重測量高度相關 → 信度佳。

### 內部一致性

同一問卷多題項是否測同一概念；用 Cronbach's  $\alpha$ 。 $\alpha > 0.7$  良好、 $> 0.9$  很好。


### 評分者間信度

多位觀察者評分的一致性；類別判定用 Cohen's  $\kappa$ ，連續分數用 ICC 或相關。

若某題項或某觀察者對信度無貢獻（如 Cronbach's  $\alpha$  因它下降）→ 可考慮刪除。

## 三種信度：各檢驗一種「一致」

跨時間 / 跨評分者 / 題目之間



選哪一種取決於你的威脅：怕受測者狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→ $\alpha$ 。

**教學重點** 信度不足會稀釋效果、拉低檢定力——提高信度等於免費提升 power，比事後加樣本便宜。

# 信度實例：Cronbach's $\alpha$ 與題目分析

## 5 題『工作壓力量表』的内部一致性

**公式概念**  $\alpha = (k/(k-1)) \times (1 - \Sigma \sigma^2_{\text{題}} / \sigma^2_{\text{總}})$  ·  $k$  = 題數。題越多、題間相關越高  $\rightarrow \alpha$  越高。

**整體結果** 5 題  $\alpha = .82$  (良好；.70 可接受、.80 佳、>.95 可能題目重複)。

**題目分析** 看『校正後題總相關』：題 1、2、4、5 約 .55–.70；題 3 僅 .15。

**刪題判斷** 『 $\alpha$  if item deleted』：刪題 3 後  $\alpha$  升到 .87  $\rightarrow$  題 3 測的不是同一件事，考慮刪或改寫。

**教學重點**  $\alpha$  高不代表『單一維度』——題目太多也會推高  $\alpha$ 。要配合因素分析 (EFA/CFA) 確認結構。

## $\alpha$ 與題目分析：怎麼看、怎麼決定刪題

把上一頁的數字讀懂

**$\alpha = .82$  代表** 5 題大致測同一件事（工作壓力），內部一致性良好（.70 可接受/.80 佳/>.95 恐重複）。

**校正後題總相關** 每題與『其他題總分』的相關。題 1/2/4/5 約 .55-.70（好）；題 3 只有 .15（不合拍）。

**$\alpha$  if item deleted** 刪某題後的  $\alpha$ 。刪題 3  $\rightarrow \alpha$  從 .82 升到 .87  $\rightarrow$  題 3 在扯後腿。

**決策** 題 3 可能問到別的概念（或反向題沒反轉） $\rightarrow$  考慮刪除或改寫，再重新施測。

**教學重點**  $\alpha$  高只說『一致』，不保證『單一維度』；題目太多也會灌高  $\alpha$ ——要配合因素分析(EFA/CFA)確認結構。

## 檢測測量效度

### 聚斂效度 Convergent

- 與「應相關」的變數確實相關
- 體適能 vs 跑步速度 → 正相關 ✓
- 體適能 vs 運動心跳 → 負相關 ✓

### 區辨效度 Discriminant

- 與「不該相關」的變數不相關
- 體適能 vs 身高 → 接近 0、不顯著 ✓
- 體適能 vs 襯衫數量 → 接近 0 ✓

## 效度實例：用相關矩陣看聚斂與區辨

新『工作壓力量表』——該相關的相關、不該相關的不相關

| 與哪個變數比 | 預期       | 觀察 $r$ | 判讀   |
|--------|----------|--------|------|
| 職業倦怠   | 應正相關（聚斂） | .62    | 聚斂 ✓ |
| 睡眠品質   | 應負相關（聚斂） | -.48   | 聚斂 ✓ |
| 工作投入   | 弱相關（合理）  | .22    | 合理   |
| 身高     | 不該相關（區辨） | .05    | 區辨 ✓ |

**教學重點** 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算真的測到『壓力』而非別的東西。

## 聚斂與區辨：用相關矩陣看

同構念要高、跨構念要低（與 2.2 第 20 張為同一範例矩陣，此處作回顧）

|     |       |       |       |       |       |       |
|-----|-------|-------|-------|-------|-------|-------|
| 壓力1 | 1.00  | 0.72  | 0.68  | -0.18 | -0.12 | -0.15 |
| 壓力2 | 0.72  | 1.00  | 0.75  | -0.14 | -0.16 | -0.11 |
| 壓力3 | 0.68  | 0.75  | 1.00  | -0.12 | -0.10 | -0.13 |
| 支持1 | -0.18 | -0.14 | -0.12 | 1.00  | 0.70  | 0.74  |
| 支持2 | -0.12 | -0.16 | -0.10 | 0.70  | 1.00  | 0.69  |
| 支持3 | -0.15 | -0.11 | -0.13 | 0.74  | 0.69  | 1.00  |
|     | 壓力1   | 壓力2   | 壓力3   | 支持1   | 支持2   | 支持3   |

### 怎麼讀這張相關矩陣



綠框：同一構念的題目

應該「高」（此例 .68-.75）→ 聚斂效度成立



橘框：不同構念之間

應該「低」（此例  $-.10 \sim -.18$ ）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事，  
要合併、重新定義，或改題。

**教學重點** 區辨效度不足會讓兩個構念互相稀釋，等同增加測量誤差——這正是「提高效率也能提高檢定力」的機制。

9-10

# 執行研究與解讀發現

*Conducting & Interpreting Your Research*

## 執行研究：如何取得參與者

- 在合適場域招募：醫學研究找醫院、商業研究找公司
- 大學生常用「便利樣本」——資源有限時的典型做法
- 篩選 ( screening )：確認受試者屬於目標母體
- 知情同意：事前告知風險與益處
- 留意「要求特徵」；測量基本人口變項 ( 至少年齡、性別 )
- 結束時做「debriefing」，讓受試者了解研究內容

## 專業執行（一）：招募、篩選與研究倫理

**場域與抽樣框** 到目標母體所在處招募（醫院/公司/校園）；記錄抽樣框與回收率。

**篩選 Screening** 用納入 / 排除條件確認受試者屬目標母體；記錄篩掉多少、為什麼。

**倫理審查 IRB** 收案前送機構審查（IRB/REC）；弱勢或高風險族群更嚴格。

**知情同意** 事前告知目的、風險、益處、可隨時退出，並取得書面同意。

**debriefing** 結束時說明研究內容（尤其有隱瞞設計時），並提供聯絡與資源。

**教學重點** 倫理不是形式：知情同意、資料保密、退出權、debriefing 都要寫進計畫；違反倫理取得的資料不能用。

## 專業執行（二）：讓資料可信的品質控制

**前註冊 Pre-registration** 收案前公開假設與分析計畫 → 區分驗證性/探索性、防 p-hacking。

**盲化 Blinding** 受試者/施測者不知分組（單盲/雙盲），降低期望與要求特徵。

**標準化程序** 統一指導語、環境與順序；用對抗平衡控制順序效應。

**資料監控** 邊收邊查：遺漏、離群、直線作答、注意力題；記錄流失與原因。

**教學重點** 『可重現』從執行就開始：把程序寫成可照做的手冊，別人（或未來的你）才能複製你的研究。

## 解讀發現的四大判準

### 無其他解釋

是否存在其他合理解釋？用控制變項或統計方法排除。

### 準確測量

結果是否準確反映研究目的？工具與資料是否可靠。

### 外部效度

結果能否推廣到其他情境？樣本與情境是否具代表性。

### 信度

結果是否一致？可用重測或多種工具驗證。

# 解讀四判準：各配一個提問例子

用四個問句檢視你的結果

## ① 無其他解釋（內部效度）

「壓力下降，真的是 App 造成的嗎？  
會不會剛好碰上放暑假？」  
→ 用控制組/共變量排除。

## ② 準確測量（建構效度）

「我用的量表真的在測『壓力』嗎？」  
→ 檢查工具的效度證據  
與操作型定義。

## ③ 外部效度（可推廣）

「只在這 60 位護理師成立，  
還是能推到其他醫院/職業？」  
→ 看樣本與情境代表性。

## ④ 信度（一致）

「換時間或換工具再測，  
結果會一樣嗎？」  
→ 重測信度、多工具驗證。

**教學重點** 四判準對應四種效度/信度問題；先確認『不是別的原因、測得準、測得穩』，再談能不能推廣。

## 系統化解讀：四個步驟

1 Step 1 統計結論 *Statistical conclusion*  $p < 0.05$  嗎？顯著 → 這個結果不太可能只是抽樣巧合。

2 Step 2 測量 *Measurements* 測量有效度疑慮嗎？自陳是否與其他指標一致？


3 Step 3 替代解釋 *Explanations* 是實驗嗎？實驗只留解釋 1；非實驗需考慮 2、3 與混淆。

4 Step 4 外部效度 *External validity* 樣本隨機嗎？情境真實嗎？能推廣到母體嗎？

接下來用同一套四步驟，走過四個真實情境的解讀範例。

# 解讀結果的四個步驟

統計 → 大小 → 設計 → 實務



常見錯誤：只做第①步就下結論（「顯著，所以有效」）——那只回答了四分之一。

虛無結果也照這四步走：不顯著 → 看 CI 有多寬 → 看設計有無檢定力不足 → 再談實務。

寫作對應：①②寫在結果章，③④寫在討論章。

**教學重點** 常見錯誤是只做第①步就下結論；四步走完，結果章與討論章的骨架也就出來了。

## 四步驟解讀完整範例：一個真實情境

研究：線上輔導是否提升數學成績？（隨機分派兩組）

**結果** 輔導組  $M=76$  vs 對照組  $M=70$ ； $t(98)=2.9$ ,  $p=.005$ ,  $d=0.58$ , 95% CI [1.9, 10.1]。

- ① **信度（可靠嗎）**  $p<.05$ 、效應中等、CI 不含 0 → 結果穩健、非巧合。
- ② **測量（測得準嗎）** 成績為標準化測驗（客觀）→ 效度佳；若為自評則需更謹慎。
- ③ **替代解釋** 有隨機分派 → 排除反向與第三變項，可談因果（留意實施差異等混淆）。
- ④ **外部效度（能推廣嗎）** 單一學校樣本 → 推廣需謹慎，宜複製到不同學校/年級。

**教學重點** 完整解讀 = 先確認『可靠』（ $p$  + 效應 + CI），再問『測得準嗎、有無其他解釋、能推廣嗎』——四關都過才下強結論。

## 解讀範例①：實驗設計

### 研究設計與結果

組間實驗：把人「隨機」分到治療組與控制組。IV = 治療，DV = 憂鬱。

**結果** 治療組憂鬱顯著低於控制組 ( $p < 0.05$ )。

**結論**：治療有效，且在符合條件下可推論到母體。

### 四步驟解讀

**1 統計結論**  $p < 0.05 \rightarrow$  結果不太可能只是巧合。

**2 測量** 自陳憂鬱是否與臨床診斷等指標一致？

**3 解釋** 是實驗（已隨機化） $\rightarrow$  只有解釋 1：治療造成差異。留意注射 vs 安慰劑的混淆。

**4 外部效度** 樣本隨機 / 分層？情境真實？ $\rightarrow$  可謹慎推廣。

## 解讀範例②：準實驗

### 研究設計與結果

非實驗混合設計（未隨機分派誰接受治療）  
。前測、後測比較兩組。

**結果** 控制組前後幾乎相同；治療組後測較低。

**結論：**結果可靠，但「無法斷定因果」，只能談關聯。

### 四步驟解讀

**1 統計結論** 交互作用  $p < 0.05 \rightarrow$  不太可能只是巧合。

**2 測量** 憂鬱是自陳嗎？有無過去研究支持其效度？

**3 解釋** 非實驗  $\rightarrow$  三種解釋都可能：治療 $\rightarrow$ 憂鬱、憂鬱 $\rightarrow$ 尋求治療（反向）、第三變項（自我照護）。

**4 外部效度** 樣本 / 情境是否具代表性？

## 解讀範例③：相關研究

### 研究設計與結果

非實驗：冥想頻率（數值 IV）與幸福感（數值 DV）。

**結果**  $r = 0.41$ ，中度正相關。

**結論**：有顯著關聯，但不能推論「冥想造成快樂」。

### 四步驟解讀

**1 統計結論**  $p < 0.05 \rightarrow$  相關不太可能只是巧合。

**2 測量** 幸福感為自陳，留意測量效度。

**3 解釋** 非實驗  $\rightarrow$  三種解釋：冥想 $\rightarrow$ 快樂、快樂 $\rightarrow$ 冥想、第三變項（自我照護動機）。

**4 外部效度** 受訪者在自家自行冥想，樣本是否代表一般人？

## 解讀範例④：虛無結果

### 研究設計與結果

組間實驗：治療組 vs 控制組 → 憂鬱。兩組差異很小。

**結果**  $p = 0.42$  (不顯著)。

**結論**：四關全過才可「謹慎」建議  $H_0$  可能為真；否則證據不足。

### 四步驟解讀

**1 統計結論** 不顯著 → 先別下「沒效果」的結論。

**2 測量** 測量與操控：信度效度夠嗎？IV 操弄夠強嗎？

**3 解釋** (本例先看樣本數) 對「臨床上最小重要差異」是否達 .80 以上檢定力？

**4 外部效度** 樣本無偏？情境真實？

$p > 0.05$  時

## 如何解讀虛無結果 ( null result )

- 先排查方法學問題，再談結論：
  - 樣本數：對「臨床上最小重要差異 ( SESOI ) 」是否達 .80 以上檢定力？→ 若是，方可主張「未觀察到重要效果」
  - 測量與操弄：信度、效度足夠嗎？IV 操弄夠強嗎？
  - 外部效度：真隨機樣本？資料點獨立？情境真實？
- 只有當以上全部為「是」，才可謹慎地建議  $H_0$  可能為真

## 隨堂 60 秒：不顯著怎麼解讀

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 的紀錄完整性  $t(33)=1.26$ 、 $p = .215$ 。可以說「AI 工具對紀錄品質沒有影響」嗎？
- ② 若要主張「至少不比原本差」，事前必須先做什麼？
- ③ 該看哪一個數字來判斷這個主張成不成立？

講評重點 「不顯著」只是證據不足；要主張「不差」必須事前訂界限，並看信賴區間的下界。

## 解讀虛無結果進階：怎麼主張『沒有實務差異』

$p > .05$  不能證明沒差異——要主張『等價』得用等價檢定

**問題** 傳統檢定不顯著  $\neq$  沒差異（可能只是沒力）。『沒有證據』不等於『有證據證明沒有』。

**等價界限 SESOI** 先定『多小的差異算沒差』，例如  $\pm 5$  分。


**TOST 做法** 若差異的 90% CI 完全落在  $[-5, +5]$  內  $\rightarrow$  可主張『實務上等價』。

**範例** 觀察差異 1.2 分、90% CI  $[-2.1, 4.5] \subset [-5, 5] \rightarrow$  可主張兩法效果等價。

**教學重點** 想主張『沒差異/一樣好』，別只報  $p > .05$ ；用等價檢定（TOST），或看 CI 是否夠窄且落在可忽略範圍內。

# 不顯著 $\neq$ 等價：要用等價檢定

CI 必須整段落在等價界限內



**教學重點** 想主張「沒有實務差異」，必須事先訂好最小有意義差異，再看 CI 是否完全落在界限內。

## 統計顯著 vs 實務重要：用效應量與 CI 判讀

|       | 研究 A             | 研究 B            |
|-------|------------------|-----------------|
| 樣本數 N | 8,000            | 50              |
| 效應量 d | 0.06             | 0.85            |
| p 值   | p = .002 (顯著)    | p = .04 (顯著)    |
| 判讀    | 顯著但幾乎沒實務意義 (大 N) | 效果大、值得在意 (雖樣本小) |

**教學重點** 決策看『效應量 + CI + 實務門檻』，不是只看 p。大 N 會讓瑣碎差異顯著；小 N 的大效應也可能很重要。

## 顯著 $\times$ 效果大小：四種情況

p 與效應量/CI 一起看

### 顯著 + 效果大

最理想：有效且值得推

### 顯著 + 效果小

大樣本才顯著；要問值不值得

### 不顯著 + CI 窄

較有把握「真的沒什麼效果」

### 不顯著 + CI 寬

資訊不足：可能只是樣本太小

**教學重點** 「不顯著」要先看 CI 寬窄：CI 很寬只代表資訊不足，不能說「證明沒效」。

## 事後補救：微調你的研究問題

研究做完才發現方法學限制時，不必推翻一切——改問「這份資料到底能回答什麼」。

- 問自己：這份資料「能」回答哪個問題（which question CAN you answer）？
- 問自己：從結果「能」得出什麼結論（which conclusion CAN you draw）？
- 例：原本想證明「自動」形成印象，若證據不足 → 改主張「自發」形成（較保守、仍有貢獻）
- 誠實揭露限制、用謹慎的語言陳述——縮小主張範圍，而非誇大或隱瞞

## 誠實寫限制與外部效度

**內部效度限制** 非隨機、混淆未控、測量誤差 → 說明可能的方向與影響。

**外部效度限制** 樣本（便利/單一場域）、情境（實驗室 vs 真實）、時間點 → 推廣範圍要保守。

**測量限制** 自陳偏誤、單一指標 → 建議未來加客觀或多元指標。

**語言要保守** 用『支持/傾向』而非『證明』；縮小主張範圍，而非隱瞞。

**教學重點** 誠實揭露限制不會扣分，反而顯示你懂方法學——審稿人最怕的是『過度宣稱』與『假裝沒有限制』。

# 完整研究實例（1/2）：規劃與執行

遠距工作是否提升員工幸福感？

- ① **問題與設計** 隨機分派員工：遠距組 vs 一般組；8 週後測幸福感 WHO-5（數值）。
- ② **樣本數規劃** 文獻  $d \approx 0.4$  → 每組約 100（共 200）；預估 15% 流失 → 招募約 236。
- ③ **測量** WHO-5（信度  $\alpha = .85$ 、效度佳）+ 客觀出勤資料交叉驗證。
- ④ **執行** IRB 通過、知情同意、單盲評分、前註冊分析計畫、邊收邊清資料。

**教學重點** 好研究在『收案前』就把效應量、樣本數、測量工具、倫理與分析計畫都定好——這一頁就是計畫書骨架。

## 完整研究實例（2/2）：分析與解讀

- ⑤ **結果** 遠距組 WHO-5 M=68 vs 一般組 M=62 ;  $t(198)=3.1, p=.002, d=0.44, 95\% CI [2.2, 9.8]$  。
- ⑥ **四步驟解讀** 信度：穩健；測量：有客觀資料佐證；解釋：隨機化→可談因果；外部：單一公司需複製。
- ⑦ **實務判讀**  $d = 0.44$  中等、CI 不含 0 → 有實務意義，但非萬靈丹。
- ⑧ **結論與限制** 支持遠距對幸福感有正向效果；限制：單一產業、以自陳為主、僅 8 週短期。

**教學重點** 一個完整研究的句點 = 顯著性 + 效應量 + CI + 設計能談到什麼 + 誠實的限制——這就是結果與討論章。

# 完整研究檢核清單（一）

## 研究問題 & 設計

- 重要？新穎？合乎時機？
- 組間：是否隨機分派？
- 組內：是否隨機化 / 對抗平衡順序？
- 控制組是否含混淆變項？查清單！
- 無法隨機化 → 用非實驗混合設計

## 測量 & 資料蒐集

- 測量可靠？標準化、多次平均
- 查過去研究：該工具信度如何？
- 測量有效？聚斂與區辨效度證據
- 自陳注意社會期許偏誤
- 蒐集盡量隨機獨立；N 由先驗檢定力分析決定並含流失緩衝（ $N \geq 30$  僅為經驗法則）

## 完整研究檢核清單（二）

### 資料準備 & 統計

- 格式：每列一人、每測量一欄
- 處理缺失值與離群值
- 敘述：對的圖（散布 / 箱型 / 列聯表）
- 推論：先驗  $\text{power} \geq .80$ （高風險研究提高至 .90–.95）
- 用對檢定？只做一個檢定？ $p < 0.05$ ？

### 執行 & 解讀

- 篩選、知情同意、debriefing
- 信度： $p < 0.05 \rightarrow$  結果夠可靠
- 測量準確性：留意效度與信度
- 替代解釋：實驗設計？有混淆嗎？
- 外部效度：真隨機？情境真實？

## 結果與討論寫作檢查清單

- ☐ 先驗樣本數規劃有寫（效應量來源、 $\alpha$ 、Power、所需 N 與流失緩衝）
- ☐ 每個檢定報：統計量 + df + 精確 p + 效應量 + 95% CI
- ☐ 信度（ $\alpha$ ）與效度證據有交代；測量工具來源清楚
- ☐ 用四步驟解讀：可靠？測得準？有無其他解釋？能否推廣？
- ☐ 區分統計顯著與實務重要；虛無結果不寫成『證明沒差異』
- ☐ 誠實列限制與外部效度；用保守語言、附 AI 使用聲明

**教學重點** 把這張清單當『投稿前最後檢查』——最常被退稿的就是漏樣本數規劃、漏效應量/CI，以及過度宣稱。

## 課程總結：你已經學會

- 提出一個吸引人且可行的研究問題
- 設計能將替代解釋降到最低的研究
- 在最大化信度與效度下進行測量
- 用適當技術與足夠樣本數蒐集資料
- 用免費易用的軟體（如 JASP）分析資料
- 從結果得出穩健的結論
- 【目標①】－【目標④】四項目標的驗收，見帶回家作業 Part A 與 Part B。

下一站 2.7 實例演練：把 2.1–2.6 串成一條決策鏈，用五個範例完整走一遍。



作業

# Take-home Assignment

*Plan it, run it, interpret it.*

涵蓋單元 6：型一/二錯誤與檢定力、樣本數規劃、信效度檢測、研究執行與倫理、四步驟解讀。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題要你「規劃得出、解讀得對」。參考解答在本節後段。

# 作業說明：目標、繳交與規則

## 作業目標

能規劃一個研究的樣本數與信效度檢測，並用四步驟解讀結果（含虛無結果）。

## 繳交方式

一份 PDF：Part A 文字作答 + Part B 規劃與解讀，建議 3–5 頁。

## 建議時間

約 2–3 小時；可用 G\*Power / JASP，但需寫出輸入與判讀。

## 工具與誠信

可用 AI / 軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

## Part A | 觀念題：規劃、執行與解讀 ( 1/2 )

- A1 型一/型二錯誤與檢定力的關係為何？為何不能同時最小化兩者？Power  $\geq .80$  代表什麼？
- A2 先驗 / 事後 / 敏感度三種 power analysis 的差別？為何『事後 power』意義不大？
- A3 規劃樣本數要先估效應量——四種來源與各自風險？為何規劃時取『保守（偏小）』效應？
- A4 為何組內設計比組間省樣本？還有哪些方法能降低所需 N（共變量、提高信度...）？

**作答提示** 觀念題重『說得清楚 + 舉得出例』；每題 2–4 句即可。

## Part A | 觀念題：規劃、執行與解讀 ( 2/2 )

- A5 信度三型與 Cronbach's  $\alpha$  怎麼判讀？聚斂效度與區辨效度各需要什麼證據？
- A6 研究執行的三項倫理要件 ( IRB、知情同意、debriefing ) 與兩項品質控制 ( 前註冊、盲化 ) 為何重要？
- A7 解讀發現的四個步驟是什麼？各回答什麼問題？
- A8  $p > .05$  該怎麼正確解讀？想主張『兩者沒有實務差異』要怎麼做？統計顯著 vs 實務重要差在哪？

## Part B | 實作題：規劃與解讀 ( 1/2 )

**情境：**研究『線上正念課程是否降低大學生焦慮』（隨機分派兩組比較）。

- B1** 選檢定並寫  $H_0/H_1$ ；文獻得  $d \approx 0.5$ ，設  $\alpha=.05$ 、Power=.80，估每組所需  $N$ ；再依 20% 流失算招募人數。
- B2** 你會用什麼工具測焦慮？如何檢驗其信度（ $\alpha$ ）與效度？各舉一個『應相關』與『不該相關』的變數。
- B3** 列出執行時的三項研究倫理要件與兩項資料品質控制措施。

**教學重點** 樣本數要在收案『前』規劃；測量要先確認信效度，資料才值得分析。

## Part B | 實作題：規劃與解讀 ( 2/2 )

- B4** 結果為  $t(158)=2.6$ ,  $p=.011$ ,  $d=0.42$ , 95% CI [1.2, 8.0] ( 隨機實驗 ) ——用四步驟完整解讀。
- B5** 若另一結果  $p=.30$  ( 不顯著 ) , 你會怎麼解讀? 在什麼條件下能主張『兩者等價』?
- B6** 寫一段結果與討論 ( 含效應量、CI 與限制 ) + AI 使用聲明。

**繳交格式** Part B 要看得『樣本數計算』與『四步驟解讀』; 虛無結果別寫成『證明沒差異』。

## 評分重點與繳交 Rubric

| 項目            | 配分  | 評分重點                                |
|---------------|-----|-------------------------------------|
| Part A 觀念     | 40% | 定義正確、能舉例、能說出取捨（如錯誤取捨、事後 power）      |
| B1 樣本數規劃      | 15% | 選對檢定、N 計算正確、含流失緩衝                   |
| B2 信效度        | 15% | 測量工具 + $\alpha$ + 聚斂/區辨（各舉相關/不相關變數） |
| B3 倫理 + 品質    | 10% | 倫理要件與品質控制具體可行                       |
| B4–B6 解讀 + 誠信 | 20% | 四步驟正確、虛無結果解讀恰當、報告 + AI 聲明           |

**常見扣分** 用事後 power 解釋不顯著、把  $p > .05$  當『沒差異』、樣本數沒含流失、報告缺效應量/CI。

## 資源連結・外部服務與官方網址

點按名稱或網址可直接開啟；工具更新快，功能與費用請以官方頁面為準。

| 資源 / 服務 | 官方網址 URL                                              |
|---------|-------------------------------------------------------|
| JASP    | <a href="https://jasp-stats.org/">jasp-stats.org/</a> |
| G*Power | <a href="https://gpower.hhu.de/">gpower.hhu.de/</a>   |

# 案例應用：規劃時保守，結論才站得住

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

## 本單元教了什麼

型一與型二錯誤、檢定力，以及樣本數該怎麼算出來。

②

## 案例怎麼用

- 規劃階段保守假設  $d_z = 0.5$ ， $\alpha = .05$  雙尾、 $\text{power} = .80$ ，得  $n = 34$ 。
- 實際收案 A 機構 34 人恰達規劃值；B 機構 28 人為既有人力全數。
- 實得  $d_z = 1.08$ ，事後檢定力  $> .999$ ——當初的保守假設是對的。
- 若只收到 20 人，在  $d_z = 0.5$  之下檢定力僅 .565，過半機率得不到顯著。
- 職類  $\times$  完整性之卡方不顯著，係因檢定力僅 .109，非因兩者無關。

③

## 產出什麼證據

事前檢定力分析報告與情境對照表（次頁），納入計畫書第 3.3 節。

④

## 承接關係

上游：承自 2.5 之 APA 格式結果段 | 下游：交棒 2.7，把七步驟完整走一遍。

**教學重點** 事前檢定力分析要用「你能接受的最小效果」，不是「你希望看到的效果」。假設 0.5 而實得 1.08 是好事；假設 1.0 而實得 0.4，研究就白做了。

# 示範產物：檢定力情境對照表

同一份資料在不同樣本數與效應量下的檢定力；末列說明不顯著結果為何不可解讀為無關聯

| 情境         | 效應量          | 樣本數 | 檢定力    | 判讀                |
|------------|--------------|-----|--------|-------------------|
| 規劃假設       | $d_z = 0.50$ | 34  | .808   | 規劃基準；恰達 .80 之慣例門檻 |
| 實際結果       | $d_z = 1.08$ | 34  | > .999 | 規劃保守，主要結論穩健       |
| 若只收到 20 人  | $d_z = 0.50$ | 20  | .565   | 過半機率得不到顯著，研究可能白做  |
| 若只收到 20 人  | $d_z = 1.08$ | 20  | .996   | 效果大時樣本可少，惟事前無從得知  |
| 職類 × 完整性   | $w = .09$    | 62  | .109   | 檢定力極低；不顯著不可解讀為無關聯 |
| 同上，若要達 .80 | $w = .09$    | 969 | .800   | 此效應量下所需樣本遠超本研究可及  |

**教學重點** 最後兩列是本單元最重要的一課：卡方不顯著，是因為效應量小到需要 969 人才驗得出來。把「沒驗出來」寫成「沒有差異」，是論文最常見的過度宣稱。