

量性研究方法 · 完整研究專案

單元 6

樣本數規劃、執行與研究解讀

Sample Size, Conducting & Interpreting Your Research

型一／型二錯誤、各檢定的樣本數計算、最佳化檢定力、信效度檢測、執行研究與下結論，並附完整研究檢核清單

本單元結束後，你能……

- 能用 G*Power 完成先驗樣本數估計，並換算為實際需招募的人數。
- 能區分先驗、事後與敏感度檢定力分析，並說明事後檢定力的侷限。
- 能列出研究執行的倫理要件與資料品質控制措施。
- 能用四步驟解讀研究發現，包含虛無結果與主張等價／非劣性的條件。
- 驗收方式 ① 對應作業 A3、B1；② 對應 A2；③ 對應 A6、B3；④ 對應 A7、A8、B4、B5。

8

把統計錯誤降到最低

Minimize Statistical Errors & Choose Sample Size

兩種錯誤：型一與型二

	H ₀ 為真（無效果）	H ₀ 為假（有效果）
判定顯著	型一錯誤 (α) 偽陽性	正確 (檢定力 $1-\beta$)
判定不顯著	正確	型二錯誤 (β) 偽陰性

你無法同時把兩種錯誤都降到最低：降低型一（更嚴格）常會提高型二，反之亦然。

取捨：以新藥研發為例

嚴格控制型一（ $\alpha = 0.01$ ）

- 需極強證據才判定有效
- 不易讓無效藥上市（保障安全）
- 但可能錯失真正有效的好藥（型二↑）

放寬型一（ $\alpha = 0.20$ ）

- 只要有一點證據就傾向判定有效
- 不易錯過潛在好藥（型二↓）
- 但更多無效藥可能被錯誤接受（型一↑）

比喻：面試選才的兩種失誤

把「檢定」想成面試：門檻太鬆會錄取到不適任者（型一）；門檻太嚴會刷掉真正適任者（型二）。

門檻太鬆（高 α ）

- 容易「錄取到不適任者」＝偽陽性（型一↑）
- 少數真正適任者被錯過（偽陰性↓）
- 簡單問題 → 多錄取、也多誤收

門檻太嚴（低 α ）

- 不易「錄取到不適任者」（型一↓）
- 但容易「刷掉真正適任者」＝偽陰性（型二↑）
- 困難問題 → 少誤收、卻多漏才

Two Types of Errors

統計檢定的兩種錯誤



Key lessons

- Two types of errors can occur in statistical tests
- **False positives** (wrongly accepting H_1)
- **False negatives** (wrongly accepting H_0)
- Two forces control these two error rates
- **P value threshold** (primarily minimizes false positives)
- **Sample size** (primarily minimizes false negatives)

重點 p 值門檻主要控制偽陽性（型一）；樣本數主要控制偽陰性（型二）。兩者需權衡。

Power $\geq$ 80% ，高風險研究再提高

如何決定樣本數

- 檢定力（power）： H_0 為假時能正確拒絕它的機率
- 常規設 .80 ；臨床試驗等高風險或確認性研究提高至 .90-.95
- 偽陰性機率 = $1 - \text{power}$ （80% power $\rightarrow$ 20% 偽陰性）
- 效應量：規劃時取「小」或「中」效應量較保守實際
- 研究設計的選擇，會大幅影響所需樣本數

檢定力：一個具體的例子

把 80% 與 95% 放進真實情境

情境 比較新舊衛教對血壓控制的效果，預期中效應 $d = 0.5$ 。

設 power = 80% 需每組約 64 人。意思：即使效果真的存在，仍有 20% 機率漏抓（得到不顯著）。

設 power = 95% 需每組約 105 人。漏抓機率降到 5%，但要多招募約 60% 的人。

漏抓的代價 = 白做一場、還可能誤導『新衛教無效』；臨床等高風險研究值得用 90-95%。

教學重點 power 是『效果存在時抓得到的機率』；80% 是底線，樣本充足或後果嚴重時再往上提。

三種檢定力分析：先驗、事後、敏感度

類型	何時做	給定什麼 → 求什麼
先驗 A priori	收案『前』（正確做法）	給 α 、Power、效應量 → 求所需 N
敏感度 Sensitivity	樣本數已固定時	給 α 、Power、N → 求『能偵測的最小效應』
事後 Post-hoc	收案後（不建議）	給 α 、N、觀察效應 → 回算 Power（意義不大）

教學重點 本頁為查閱用細表，課堂講授用次頁的三個情境。只有「先驗」能真正規劃樣本數；事後 **Power** 用觀察效應回算、與 **p** 值一體兩面，不能用來解釋不顯著——改用敏感度分析或信賴區間。

三種檢定力分析：各一個情境

先驗 / 敏感度 / 事後，分別長什麼樣

先驗 A priori (收案前 · 正確)

「要偵測 $d=0.5$ 、power .80
→ G*Power 算出每組 64 人」
→ 拿去寫計畫、送 IRB。

敏感度 Sensitivity (N 已固定)

「醫院只能給 40 位病人
→ 反推：只能偵測 $d \geq 0.9$ 的大效應」
→ 誠實說明能力上限。

事後 Post-hoc (收案後 · 不建議)

「收完 30 人、 $p=.20$ ，回算 power $\approx .25$ 」→ 這只是 p 值的重述，不能用來說『因為 power 低所以才不顯著』。要交代不顯著，改用敏感度分析或信賴區間。

教學重點 規劃樣本只能用『先驗』；樣本被綁死時用『敏感度』誠實交代；別用事後 power 替不顯著找藉口。

各檢定的效應量慣例

檢定	效應量指標	小	中	大
t 檢定	Cohen's d	0.2	0.5	0.8
相關 / 迴歸	r	0.1	0.3	0.5
ANOVA	Cohen's f	0.10	0.25	0.40
邏輯斯迴歸	Odds Ratio	≈ 1.68	≈ 3.47	≈ 6.71
卡方檢定	w	0.1	0.3	0.5

p 值回答「有沒有效？」；效應量回答「效應有多大？」——兩者都要報告。

規劃樣本數，效應量從哪來？

樣本數計算最難的一步，就是先『猜』一個合理的效應量

- ① **文獻／統合分析** 找同主題研究或 meta-analysis 的平均效應量——最可靠的來源。
- ② **先導研究 pilot** 小規模先跑，估效應與變異；但 pilot 的 d 很不穩，別高估。
- ③ **最小有意義效應 SESOI** 問『多小的效果才值得在意』，用它當規劃基準（保守、實務導向）。
- ④ **Cohen 慣例（最後手段）** 沒資訊時用『中』效應，但要清楚這只是粗估。

教學重點 常見錯誤：用『pilot 算出的大效應』去規劃 → N 太小、研究注定沒力。取『保守（偏小）』效應較安全。

效應量從哪來：四種來源各一例

規劃前先『猜』一個合理的效應量

- ① **文獻／統合分析** 查到同類正念介入對壓力的統合 $d \approx 0.45$ → 直接採用（最可靠）。
- ② **先導研究 pilot** 自己先跑 15 人估 $d=0.8$ → pilot 很不穩，別直接用，打折當參考。
- ③ **最小有意義效應 SESOI** 臨床上血壓至少要降 5 mmHg 才算有意義 → 換算成 d 當規劃基準。
- ④ **Cohen 慣例（最後手段）** 完全沒資訊 → 用『中效應』 $d=0.5$ ，但要註明只是粗估。

教學重點 寧可用『偏小／保守』的效應量規劃 → N 抓大一點，免得研究注定沒力。


檢定力的四角關係： α 、Power、效應量、N

旋鈕	往哪調	對 Power 的影響	備註
效應量	越大	Power $\uparrow$ (需 N $\downarrow$)	多由現象決定，可用文獻估
樣本數 N	越多	Power $\uparrow$	研究者最能控制的
顯著水準 α	放寬 (.05 $\rightarrow$.10)	Power $\uparrow$	但偽陽性風險 $\uparrow$
雜訊／變異	降低	有效效應 $\uparrow \rightarrow$ Power $\uparrow$	靠可靠測量、受試者內設計

教學重點 本頁為查閱用細表，課堂講授用次頁的四角關係圖。四者知道任三個就能算第四個；先驗 **power analysis** = 給定 α 、Power、效應量，反推所需 N。

檢定力四角關係：定三推一


α 、Power、效應量、N



四個量互相牽動：給定其中三個，第四個就被決定了。規劃樣本數＝固定 α 、Power 與效應量，求 N。

教學重點 規劃樣本數就是固定 α 、Power 與效應量，反推 N；樣本已固定時則反推「能偵測多小的效應」。

設計如何影響所需樣本數



- 組間設計因個體差異大，需最多樣本
- 組內／混合設計大幅減少所需人數
- 示意：小效應下組間需近 800 人
- 降低需求的方法：強化操弄（放大效應）、提高測量信度、或改變研究設計

為什麼組內設計省這麼多人？

同一效應，組間 vs 組內差在哪

讀圖 同一效應量，組間（不同人）需要的 N 最多；組內 / 混合（同一批人）大幅下降。小效應 ($d=0.2$) 下組間近 800 人。


原因 組間有『個體差異』（有人天生高、有人低），這是雜訊，要靠更多人才平均得掉。

組內為何省 每個人當自己的對照（比自己前後），個體差異被消掉 → 雜訊小 → 同效應用更少人就達 power。

代價 / 限制 組內有順序、練習、疲勞與遺留效應，需平衡次序 (counterbalance) 或洗滌期；且非所有 IV 都能組內。


教學重點 想省人先問：這個 IV 能不能讓同一個人都經歷？能 → 組內；不能（性別、疾病組）→ 只能組間，得靠加人或提高信度。

G*Power 樣本數計算：相關




- 檢定族：Correlation（雙尾）
- 效應量 r ：中效應約 0.3
- $\alpha = 0.05$ 、Power = 0.95（本頁截圖示範值；常規請採 .80）
- H_0 下相關 = 0（母體無關聯）
- 輸出：所需總樣本數 **Total sample size**

G*Power 樣本數計算：ANOVA（組間）




- 效應量 Cohen's f ：小 0.10 / 中 0.25 / 大 0.40
- $\alpha = 0.05$ 、Power = 0.95（本頁截圖示範值；常規請採 .80）
- Number of groups：組數（如 2）
- 小效應（ $f = 0.10$ 、2 組）需求極大：power .80 約 788 人、.95 約 1,300 人
- → 改用較大效應量或改變設計

G*Power 樣本數計算：RM ANOVA（組內）



- 純組內設計： Number of groups = 1
- Number of measurements：如前後 = 2
- Corr among rep measures：難估時留預設
- 所需人數遠少於組間設計

G*Power 樣本數計算：邏輯斯迴歸



- 效應量以 Odds Ratio 表示
- OR 約 1.7 小、3.5 中、6.7 大（Chen et al., 2010）
- 設定基準事件機率（如 20% 購買）
- $\alpha = 0.05$ 、Power = 0.95（本頁截圖示範值；常規請採 .80）

G*Power 完整實例：常見檢定所需樣本數

$\alpha = .05$; 同時看 Power = .80 (最低) 與 .95 (理想) 的差別

檢定	中效應量	Power .80	Power .95
獨立 t (兩組)	$d = 0.5$	共 128 (每組 64)	共 210 (每組 105)
配對 t	$d_z = 0.5$	34 人	54 人
單因子 ANOVA (3 組)	$f = 0.25$	共 159	共 252
相關	$r = 0.30$	84	138
卡方 (2×2)	$w = 0.30$	88	145

教學重點 把 Power 從 .80 拉到 .95，樣本數約要多 60%——『更保險』是有代價的。效應越小需求越爆炸（t 檢定 $d=0.2$ 每組要 394 人）。

這張樣本數表怎麼讀？

一步步查給你看

怎麼查 先依 IV/DV 選『檢定』那一行，再看要的 power 欄。例：兩組比較中效應 → 獨立 t → power .80 → 共 128（每組 64）。

為何 .95 欄都比較大 要更保險（漏抓機率從 20% 降到 5%），就得多收約 60% 的人。

效應越小，人越爆炸 同樣獨立 t， $d=0.5$ 每組 64； $d=0.2$ 每組要 394。

配對比獨立省很多 配對 t 只要 34，獨立 t 要 128——因為配對去掉了個體差異。

教學重點 表是『中效應』的參考值；實際規劃要用你自己估的效應量在 G*Power 重算，別直接套。

隨堂 60 秒：樣本數規劃

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 事前以 $d_z = 0.5$ 、 $\alpha = .05$ 雙尾、 $\text{power} = .80$ 規劃，算得 34 人。若把 power 提高到 .95，人數大約要增加多少？
- ② 既然 .95 更保險，為什麼常規仍取 .80？
- ③ 算出的 34 人就是要招募的人數嗎？還要再考慮什麼？

講評重點 檢定力是成本與風險的取捨；「算出的 N」永遠不等於「要招募的人數」。

G*Power 逐步操作實例（兩組平均比較）

- ① **Test family / test** t tests → Means: Difference between two independent means。
- ② **Type of power analysis** 選 A priori （給效應量 / α / Power，求所需樣本數）。
- ③ **輸入** Tail(s) = Two；Effect size $d = 0.5$ ； $\alpha = .05$ ；Power = .80；Allocation ratio = 1。
- ④ **讀輸出** Total sample size = 128（每組 64）；Actual power $\approx .80$ 。

教學重點 效應量不確定時，用 G*Power 的『Determine =>』面板，從兩組平均與 SD 反推 d ；或直接輸入你的 SESOI。

設計如何省樣本：組間 vs 組內（同一效應）

設計	效應量	Power .80 所需 N
組間（兩組）	$d = 0.5$ （中）	共 128 人
組內／配對	$d_z = 0.5$	34 人（同一批）
組間（小效應）	$d = 0.2$	共 788 人

同一效應下，設計決定人數（ $\alpha = .05$ 、Power .80）

組間 $d = 0.5$  128 人

組內／配對 $d_z = 0.5$  34 人

組間 $d = 0.2$ （小效應）  788 人

教學重點 組內設計用『每人當自己對照』去除個體差異 → 同效應下人數少一大截。小效應時組間需求近 800 人——改組內或提高測量信度最有效。

設計效率：同一效應，人數差在哪？

把三列數字讀成一句話

對照三列 組間中效應 $d=0.5 \rightarrow 128$ 人；改組內 $d_z=0.5 \rightarrow$ 只要 34 人（同一批）；組間但小效應 $d=0.2 \rightarrow$ 暴增到 788 人。

意思 1 · 設計比蠻力有效 同樣的效應，組間改組內，人數少一大截 ($128 \rightarrow 34$)。

意思 2 · 效應大小影響巨大 效應從 0.5 掉到 0.2，需求從 128 飆到 788（約 6 倍）。

實務順序 先看能不能組內 $\rightarrow$ 再想把效應做大（強操控）或雜訊做小（提高信度） $\rightarrow$ 不得已才加樣本。

教學重點 省樣本的優先順序：改組內 $>$ 提高測量信度 / 強操控 $>$ 最後才是加大樣本。

把『算出的 N』變成『要招募的人數』

流失率調整 若需 128 且預估 20% 中途退出 → 招募 $128 \div (1-0.20) = 160$ 人。

不等組配置 2:1 配置比 1:1 需要更多總人數——除非有理由，否則等組最省。

共變量 ANCOVA 納入與 DV 高相關的共變量（如前測），可降低誤差、減少所需 N（所需 N 約乘以 $1-r^2$ ）。

叢集／分層 叢集抽樣要乘『設計效應』把 N 放大；分層可提升效率。

教學重點 『算出的 N』是分析所需的最低有效樣本；真正要招募的，還要加上流失、篩選不合格與無效卷的緩衝。

從 N 到招募人數：一步步算給你看

算出的 N 不是要招募的人數

起點 分析需要的有效樣本 $N = 128$ （每組 64）。

① **加流失** 預估 20% 中途退出 → 招募 $128 \div (1 - 0.20) = 160$ 人。

② **加篩選 / 無效卷** 再估 10% 不合格或問卷無效 → $160 \div (1 - 0.10) \approx 178$ 人。

省人技巧 納入前測當共變量 (ANCOVA)，與 DV 高相關（如 $r = .6$ ）可降低誤差 → 反而減少所需 N。

教學重點 『算出的 N』是分析要的最低有效樣本；真正要招募的 $= N \div (1 - \text{流失}) \div (1 - \text{無效})$ ，務必留緩衝。

完整樣本數規劃實例：從研究問題到招募人數

研究：正念 App 是否降低護理師壓力？（兩組比較）

- ① **檢定** 兩組平均比較 → 獨立樣本 t 檢定（雙尾）。
- ② **效應量** 查文獻，類似介入 $d \approx 0.5$ （中）；規劃取保守值 $d = 0.45$ 。
- ③ **α 與 Power** $\alpha = .05$ 、Power = .80。
- ④ **G*Power** $d = 0.45 \rightarrow$ 每組 79（共 158）。
- ⑤ **流失緩衝** 預估 15% 退出 $\rightarrow 158 \div 0.85 \approx 186$ （每組 93）。
- ⑥ **結論** 規劃招募約 186 位護理師，才能在效果存在時有 80% 偵測力。

教學重點 先驗規劃要寫進研究計畫（收案前）——這是 IRB 與審查委員會檢查的重點，也避免做出一個『沒有檢定力』的研究。



如何最佳化統計檢定力

How to Optimize Statistical Power

檢定力不足會怎樣？如何提高 Power

檢定力不足（ $<.80$ ）的後果

- 真有效果卻測不出（偽陰性、高 Type II）
- 就算測到顯著，效果也常被高估、難複製
- 浪費資源與參與者

如何提高 Power

- 增加樣本數 N （最直接）
- 降低雜訊：更可靠工具、標準化程序
- 用受試者內／配對設計（去個體差異）
- 增強操弄以放大效應
- （有依據時）單尾檢定或放寬 α

教學重點 先驗（a priori）power 要在收案前做；事後（post-hoc）用觀察效應算 power 意義不大，別拿來『解釋不顯著』。

檢定力的三個槓桿

樣本數

直接

唯一能「直接」控制的因素——
加大樣本。

效應量

間接

透過『強操控』間接放大：比較
最極端的兩端。

變異性

間接

透過提高『測量信度』間接降低
雜訊。

強操控 = 把 IV 操弄到最強（大量治療 vs 完全無治療）；用類別 IV 比較兩極端。

三個槓桿：各用一個做法舉例

沒錢加人時，還有兩個間接槓桿

樣本數（直接）

若真實效應僅 $d = 0.42$ ，原每組 64 人 power 只有 .66
→ 直接多招募到每組 90 人。

最直接，
但最花錢、花時間。

效應量（強操控・間接）

比較『每天 60 分鐘運動』
vs 『完全不運動』兩極端，
而非 60 vs 45 分鐘。

→ 組間差變大、更易偵測。

變異（提高信度・間接）

單題自評 → 改 5 題量表
($\alpha = .85$)，或多次測量取平均。

→ 雜訊變小，
等於變相加大 power。

教學重點 沒錢加人時，先想能不能『強操控 IV』或『提高測量信度』——這兩招不加人也能提升檢定力。

檢測測量信度的三種方法

再測信度 Test-Retest

同一測量在兩個時間點的相關。例：兩次體重測量高度相關 → 信度佳。

內部一致性

同一問卷多題項是否測同一概念；用 Cronbach's α 。 $\alpha > 0.7$ 良好、 > 0.9 很好。


評分者間信度

多位觀察者評分的一致性；類別判定用 Cohen's κ ，連續分數用 ICC（相關看不出整體偏高或偏低）。

若某題項或某觀察者對信度無貢獻（如 Cronbach's α 因它下降）→ 可考慮刪除。

三種信度：各檢驗一種「一致」

跨時間 / 跨評分者 / 題目之間



選哪一種取決於你的威脅：怕受測者狀態飄→重測；怕評分者主觀→評分者間；怕題目測到不同東西→α。

教學重點 信度不足會稀釋效果、拉低檢定力——提高信度等於免費提升 power，比事後加樣本便宜。

信度實例：Cronbach's α 與題目分析

5 題『工作壓力量表』的內部一致性

公式概念 $\alpha = (k/(k-1)) \times (1 - \Sigma \sigma^2_{\text{題}} / \sigma^2_{\text{總}})$ ， k = 題數。題越多、題間相關越高 $\rightarrow \alpha$ 越高。

整體結果 5 題 $\alpha = .82$ （良好；.70 可接受、.80 佳、>.95 可能題目重複）。

題目分析 看『校正後題總相關』：題 1、2、4、5 約 .55-.70；題 3 僅 .15。

刪題判斷 『 α if item deleted』：刪題 3 後 α 升到 .87 $\rightarrow$ 題 3 測的不是同一件事，考慮刪或改寫。

教學重點 α 高不代表『單一維度』——題目太多也會推高 α 。要配合因素分析（EFA/CFA）確認結構。

α 與題目分析：怎麼看、怎麼決定刪題

把上一頁的數字讀懂

$\alpha = .82$ 代表 5 題大致測同一件事（工作壓力），內部一致性良好（.70 可接受 / .80 佳 / >.95 恐重複）。

校正後題總相關 每題與『其他題總分』的相關。題 1/2/4/5 約 .55-.70（好）；題 3 只有 .15（不合拍）。

α if item deleted 刪某題後的 α 。刪題 3 $\rightarrow \alpha$ 從 .82 升到 .87 $\rightarrow$ 題 3 在扯後腿。

決策 題 3 可能問到別的概念（或反向題沒反轉） $\rightarrow$ 考慮刪除或改寫，再重新施測。

教學重點 α 高只說『一致』，不保證『單一維度』；題目太多也會灌高 α ——要配合因素分析 (EFA/CFA) 確認結構。

檢測測量效度

聚斂效度 Convergent

- 與「應相關」的變數確實相關
- 體適能 vs 跑步速度 → 正相關 ✓
- 體適能 vs 安靜心跳 → 負相關 ✓

區辨效度 Discriminant

- 與「不該相關」的變數不相關
- 體適能 vs 身高 → 接近 0、不顯著 ✓
- 體適能 vs 襯衫數量 → 接近 0 ✓

效度實例：用相關矩陣看聚斂與區辨

新『工作壓力量表』——該相關的相關、不該相關的不相關

與哪個變數比	預期	觀察 r	判讀
職業倦怠	應正相關（聚斂）	.62	聚斂 ✓
睡眠品質	應負相關（聚斂）	-.48	聚斂 ✓
工作投入	弱相關（合理）	.22	合理
身高	不該相關（區辨）	.05	區辨 ✓

教學重點 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算真的測到『壓力』而非別的東西。

聚斂與區辨：用相關矩陣看

同構念要高、跨構念要低（與 2.2 第 20 張為同一範例矩陣，此處作回顧）

壓力 1	1.00	0.72	0.68	-0.18	-0.12	-0.15
壓力 2	0.72	1.00	0.75	-0.14	-0.16	-0.11
壓力 3	0.68	0.75	1.00	-0.12	-0.10	-0.13
支持 1	-0.18	-0.14	-0.12	1.00	0.70	0.74
支持 2	-0.12	-0.16	-0.10	0.70	1.00	0.69
支持 3	-0.15	-0.11	-0.13	0.74	0.69	1.00

壓力 1 壓力 2 壓力 3 支持 1 支持 2 支持 3

怎麼讀這張相關矩陣



綠框：同一構念的題目

應該「高」（此例 .68-.75）→ 聚斂效度成立



橘框：不同構念之間

應該「低」（此例 -.10~-.18）→ 區辨效度成立

判準：同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事，
要合併、重新定義，或改題。

教學重點 區辨效度不足會讓兩個構念互相稀釋，等同增加測量誤差——這正是「提高效率也能提高檢定力」的機制。

9-
10

執行研究與解讀發現

Conducting & Interpreting Your Research

執行研究：如何取得參與者

- 在合適場域招募：醫學研究找醫院、商業研究找公司
- 大學生常用「便利樣本」——資源有限時的典型做法
- 篩選（screening）：確認受試者屬於目標母體
- 知情同意：事前告知風險與益處
- 留意「要求特徵」；測量基本人口變項（至少年齡、性別）
- 結束時做「debriefing」，讓受試者了解研究內容

專業執行（一）：招募、篩選與研究倫理

場域與抽樣框 到目標母體所在處招募（醫院 / 公司 / 校園）；記錄抽樣框與回收率。

篩選 Screening 用納入／排除條件確認受試者屬目標母體；記錄篩掉多少、為什麼。

倫理審查 IRB 收案前送機構審查（IRB/REC）；弱勢或高風險族群更嚴格。

知情同意 事前告知目的、風險、益處、可隨時退出，並取得書面同意。

debriefing 結束時說明研究內容（尤其有隱瞞設計時），並提供聯絡與資源。

教學重點 倫理不是形式：知情同意、資料保密、退出權、debriefing 都要寫進計畫；違反倫理取得的資料不能用。

專業執行（二）：讓資料可信的品質控制

前註冊 Pre-registration 收案前公開假設與分析計畫 → 區分驗證性 / 探索性、防 p-hacking。

盲化 Blinding 受試者 / 施測者不知分組（單盲 / 雙盲），降低期望與要求特徵。

標準化程序 統一指導語、環境與順序；用對抗平衡控制順序效應。

資料監控 邊收邊查：遺漏、離群、直線作答、注意力題；記錄流失與原因。

教學重點 『可重現』從執行就開始：把程序寫成可照做的手冊，別人（或未來的你）才能複製你的研究。

解讀發現的四大判準

無其他解釋

是否存在其他合理解釋？用控制變項或統計方法排除。

準確測量

結果是否準確反映研究目的？工具與資料是否可靠。

外部效度

結果能否推廣到其他情境？樣本與情境是否具代表性。

信度

結果是否一致？可用重測或多種工具驗證。

解讀四判準：各配一個提問例子

用四個問句檢視你的結果

① 無其他解釋（內部效度）

「壓力下降，真的是 App 造成的嗎？
會不會剛好碰上放暑假？」
→ 用控制組 / 共變量排除。

③ 外部效度（可推廣）

「只在這 60 位護理師成立，
還是能推到其他醫院 / 職業？」
→ 看樣本與情境代表性。

② 準確測量（構念效度）

「我用的量表真的在測『壓力』嗎？」
→ 檢查工具的效度證據
與操作型定義。

④ 信度（一致）

「換時間或換工具再測，
結果會一樣嗎？」
→ 重測信度、多工具驗證。

教學重點 四判準對應四種效度 / 信度問題；先確認『不是別的原因、測得準、測得穩』，再談能不能推廣。

A 4-Step Interpretation Framework

系統化解讀：四個步驟

1 Step 1 統計結論 *Statistical conclusion* $p < 0.05$ 嗎？顯著 → 這個結果不太可能只是抽樣巧合。

2 Step 2 測量 *Measurements* 測量有效度疑慮嗎？自陳是否與其他指標一致？

3 Step 3 替代解釋 *Explanations* 是實驗嗎？實驗只留解釋 1；非實驗需考慮 2、3 與混淆。


4 Step 4 外部效度 *External validity* 樣本隨機嗎？情境真實嗎？能推廣到母體嗎？

接下來用同一套四步驟，走過四個真實情境的解讀範例。

A 4-Step Interpretation Framework

寫作版四步：統計 → 大小 → 設計 → 實務

上頁四步檢查效度威脅；本頁四步安排結果章與討論章的寫作順序



常見錯誤：只做第①步就下結論（「顯著，所以有效」）——那只回答了四分之一。

虛無結果也照這四步走：不顯著 → 看 CI 有多寬 → 看設計有無檢定力不足 → 再談實務。

寫作對應：①②寫在結果章，③④寫在討論章。

教學重點 常見錯誤是只做第①步就下結論；四步走完，結果章與討論章的骨架也就出來了。

四步驟解讀完整範例：一個真實情境

研究：線上輔導是否提升數學成績？（隨機分派兩組）

結果 輔導組 $M=76$ vs 對照組 $M=70$ ； $t(98)=2.9$, $p=.005$, $d=0.58$, 95% CI [1.9, 10.1]。

- ① **統計結論（可靠嗎）** $p<.05$ 、效應中等、CI 不含 0 → 結果穩健、非巧合。
- ② **測量（測得準嗎）** 成績為標準化測驗（客觀）→ 效度佳；若為自評則需更謹慎。
- ③ **替代解釋** 有隨機分派 → 排除反向與第三變項，可談因果（留意實施差異等混淆）。
- ④ **外部效度（能推廣嗎）** 單一學校樣本 → 推廣需謹慎，宜複製到不同學校 / 年級。

教學重點 完整解讀＝先確認『可靠』（ p + 效應 + CI），再問『測得準嗎、有無其他解釋、能推廣嗎』——四關都過才下強結論。

解讀範例①：實驗設計

研究設計與結果

組間實驗：把人「隨機」分到治療組與控制組。IV = 治療，DV = 憂鬱。

結果 治療組憂鬱顯著低於控制組（ $p < 0.05$ ）。

結論：治療有效，且在符合條件下可推論到母體。

四步驟解讀

1 統計結論 $p < 0.05 \rightarrow$ 結果不太可能只是巧合。

2 測量 自陳憂鬱是否與臨床診斷等指標一致？

3 解釋 是實驗（已隨機化） $\rightarrow$ 只有解釋 1：治療造成差異。留意注射 vs 安慰劑的混淆。

4 外部效度 樣本隨機／分層？情境真實？ $\rightarrow$ 可謹慎推廣。

解讀範例②：準實驗

研究設計與結果

準實驗混合設計（有介入，但未隨機分派誰接受治療）。前測、後測比較兩組。

結果 控制組前後幾乎相同；治療組後測較低。

結論：結果可靠，但「無法斷定因果」，只能談關聯。

四步驟解讀

1 統計結論 交互作用 $p < 0.05 \rightarrow$ 不太可能只是巧合。

2 測量 憂鬱是自陳嗎？有無過去研究支持其效度？

3 解釋 未隨機化 $\rightarrow$ 三種解釋都可能：治療 $\rightarrow$ 憂鬱、憂鬱 $\rightarrow$ 尋求治療（反向）、第三變項（自我照護）。

4 外部效度 樣本／情境是否具代表性？

解讀範例③：相關研究

研究設計與結果

非實驗：冥想頻率（數值 IV）與幸福感（數值 DV）。

結果 $r = 0.41$ ，中度正相關。

結論：有顯著關聯，但不能推論「冥想造成快樂」。

四步驟解讀

1 統計結論 $p < 0.05 \rightarrow$ 相關不太可能只是巧合。

2 測量 幸福感為自陳，留意測量效度。

3 解釋 非實驗 $\rightarrow$ 三種解釋：冥想 $\rightarrow$ 快樂、快樂 $\rightarrow$ 冥想、第三變項（自我照護動機）。

4 外部效度 受訪者在自家自行冥想，樣本是否代表一般人？

解讀範例④：虛無結果

研究設計與結果

組間實驗：治療組 vs 控制組 → 憂鬱。兩組差異很小。

結果 $p = 0.42$ （不顯著）。

結論：四關全過也只能說效果可能很小；要主張等價，須用 **TOST**（第 58 張）。

四步驟解讀

- 1 統計結論** 不顯著 → 先別下「沒效果」的結論。
- 2 測量** 測量與操控：信度效度夠嗎？IV 操弄夠強嗎？
- 3 解釋**（本例先看樣本數）對「臨床上最小重要差異」是否達 .80 以上檢定力？
- 4 外部效度** 樣本無偏？情境真實？

$p > 0.05$ 時

如何解讀虛無結果（null result）

- 先排查方法學問題，再談結論：
 - 樣本數：對「臨床上最小重要差異（SESOI）」是否達 .80 以上檢定力？→ 若是，方可主張「未觀察到重要效果」
 - 測量與操弄：信度、效度足夠嗎？IV 操弄夠強嗎？
 - 外部效度：真隨機樣本？資料點獨立？情境真實？
- 以上全部為「是」，也只能說效果可能很小；要主張「沒有差異」須用等價檢定（第 58 張）

隨堂 60 秒：不顯著怎麼解讀

先自己作答，再看解答 · 預估 1 分鐘

- ① 案例 Q 的紀錄完整性 $t(33)=1.26$ 、 $p = .215$ 。可以說「AI 工具對紀錄品質沒有影響」嗎？
- ② 若要主張「至少不比原本差」，事前必須先做什麼？
- ③ 該看哪一個數字來判斷這個主張成不成立？

講評重點 「不顯著」只是證據不足；要主張「不差」必須事前訂界限，並看信賴區間的下界。

解讀虛無結果進階：怎麼主張『沒有實務差異』

$p > .05$ 不能證明沒差異——要主張『等價』得用等價檢定

問題 傳統檢定不顯著 $\neq$ 沒差異（可能只是沒力）。『沒有證據』不等於『有證據證明沒有』。

等價界限 SESOI 先定『多小的差異算沒差』，例如 ± 5 分。

TOST 做法 若差異的 90% CI 完全落在 $[-5, +5]$ 內 $\rightarrow$ 可主張『實務上等價』。


範例 觀察差異 1.2 分、90% CI $[-2.1, 4.5] \subset [-5, 5] \rightarrow$ 可主張兩法效果等價。

教學重點 想主張『沒差異 / 一樣好』，別只報 $p > .05$ ；用等價檢定（TOST），或看 CI 是否夠窄且落在可忽略範圍內。

Equivalence Testing (TOST)

不顯著 $\neq$ 等價：要用等價檢定

CI 必須整段落落在等價界限內



教學重點 想主張「沒有實務差異」，必須事先訂好最小有意義差異，再看 CI 是否完全落在界限內。

統計顯著 vs 實務重要：用效應量與 CI 判讀

	研究 A	研究 B
樣本數 N	8,000	50
效應量 d	0.06	0.85
p 值	p = .007 (顯著)	p = .004 (顯著)
判讀	顯著但幾乎沒實務意義 (大 N)	效果大、值得在意 (雖樣本小)

教學重點 決策看『效應量 + CI + 實務門檻』，不是只看 p。大 N 會讓瑣碎差異顯著；小 N 的大效應也可能很重要。

顯著 $\times$ 效果大小：四種情況

p 與效應量 / CI 一起看

顯著 + 效果大

最理想：有效且值得推

顯著 + 效果小

大樣本才顯著；要問值不值得

不顯著 + CI 窄

較有把握「真的沒什麼效果」

不顯著 + CI 寬

資訊不足：可能只是樣本太小

教學重點 「不顯著」要先看 CI 寬窄：CI 很寬只代表資訊不足，不能說「證明沒效」。

事後補救：微調你的研究問題

研究做完才發現方法學限制時，不必推翻一切——改問「這份資料到底能回答什麼」。

- 問自己：這份資料「能」回答哪個問題（**which question CAN you answer**）？
- 問自己：從結果「能」得出什麼結論（**which conclusion CAN you draw**）？
- 例：原本想證明「自動」形成印象，若證據不足 → 改主張「自發」形成（較保守、仍有貢獻）
- 誠實揭露限制、用謹慎的語言陳述——縮小主張範圍，而非誇大或隱瞞

誠實寫限制與外部效度

內部效度限制 非隨機、混淆未控、測量誤差 → 說明可能的方向與影響。

外部效度限制 樣本（便利 / 單一場域）、情境（實驗室 vs 真實）、時間點 → 推廣範圍要保守。

測量限制 自陳偏誤、單一指標 → 建議未來加客觀或多元指標。

語言要保守 用『支持 / 傾向』而非『證明』；縮小主張範圍，而非隱瞞。

教學重點 誠實揭露限制不會扣分，反而顯示你懂方法學——審稿人最怕的是『過度宣稱』與『假裝沒有限制』。

完整研究實例（1/2）：規劃與執行

遠距工作是否提升員工幸福感？

- ① **問題與設計** 隨機分派員工：遠距組 vs 一般組；8 週後測幸福感 WHO-5（數值）。
- ② **樣本數規劃** 文獻 $d \approx 0.4 \rightarrow$ 每組約 100（共 200）；預估 15% 流失 $\rightarrow$ 招募約 236。
- ③ **測量** WHO-5（信度 $\alpha = .85$ 、效度佳）+ 客觀出勤資料交叉驗證。
- ④ **執行** IRB 通過、知情同意、單盲評分、前註冊分析計畫、邊收邊清資料。

教學重點 好研究在『收案前』就把效應量、樣本數、測量工具、倫理與分析計畫都定好——這一頁就是計畫書骨架。

完整研究實例（2/2）：分析與解讀

- ⑤ **結果** 遠距組 WHO-5 $M=68$ vs 一般組 $M=62$; $t(198)=3.1$, $p=.002$, $d=0.44$, 95% CI [2.2, 9.8]。
- ⑥ **四步驟解讀** 統計結論：穩健；測量：有客觀資料佐證；解釋：隨機化→可談因果；外部：單一公司需複製。
- ⑦ **實務判讀** $d = 0.44$ 中等、CI 不含 0 → 有實務意義，但非萬靈丹。
- ⑧ **結論與限制** 支持遠距對幸福感有正向效果；限制：單一產業、以自陳為主、僅 8 週短期。

教學重點 一個完整研究的句點＝顯著性＋效應量＋CI＋設計能談到什麼＋誠實的限制——這就是結果與討論章。

完整研究檢核清單（一）

研究問題 & 設計

- 重要？新穎？合乎時機？
- 組間：是否隨機分派？
- 組內：是否隨機化／對抗平衡順序？
- 控制組是否含混淆變項？查清單！
- 無法隨機化 → 用準實驗（非對等控制組＋前後測）

測量 & 資料蒐集

- 測量可靠？標準化、多次平均
- 查過去研究：該工具信度如何？
- 測量有效？聚斂與區辨效度證據
- 自陳注意社會期許偏誤
- 蒐集盡量隨機獨立；N 由先驗檢定力分析決定並含流失緩衝（ $N \geq 30$ 僅為經驗法則）

完整研究檢核清單（二）

資料準備 & 統計

- 格式：每列一人、每測量一欄
- 處理缺失值與離群值
- 敘述：對的圖（散布／箱型／列聯表）
- 推論：先驗 $\text{power} \geq .80$ （高風險研究提高至 .90-.95）
- 用對檢定？只做一個檢定？ $p < 0.05$ ？

執行 & 解讀

- 篩選、知情同意、debriefing
- 統計結論： $p < 0.05 \rightarrow$ 不太可能是巧合
- 測量準確性：留意效度與信度
- 替代解釋：實驗設計？有混淆嗎？
- 外部效度：真隨機？情境真實？

結果與討論寫作檢查清單

- ☐ 先驗樣本數規劃有寫（效應量來源、 α 、Power、所需 N 與流失緩衝）
- ☐ 每個檢定報：統計量 + df + 精確 p + 效應量 + 95% CI
- ☐ 信度（ α ）與效度證據有交代；測量工具來源清楚
- ☐ 用四步驟解讀：可靠？測得準？有無其他解釋？能否推廣？
- ☐ 區分統計顯著與實務重要；虛無結果不寫成『證明沒差異』
- ☐ 誠實列限制與外部效度；用保守語言、附 AI 使用聲明

教學重點 把這張清單當『投稿前最後檢查』——最常被退稿的就是漏樣本數規劃、漏效應量 / CI，以及過度宣稱。

課程總結：你已經學會

- 提出一個吸引人且可行的研究問題
- 設計能將替代解釋降到最低的研究
- 在最大化信度與效度下進行測量
- 用適當技術與足夠樣本數蒐集資料
- 用免費易用的軟體（如 JASP）分析資料
- 從結果得出穩健的結論
- 【目標①】 – 【目標④】 四項目標的驗收，見帶回家作業 Part A 與 Part B。

下一站 2.7 實例演練：把 2.1-2.6 串成一條決策鏈，用五個範例完整走一遍。

參考文獻與延伸閱讀

- Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). Lawrence Erlbaum. → 效應量慣例 (第 12 張)
- Faul, F., Erdfelder, E., Lang, A.-G., & Buchner, A. (2007). G*Power 3. Behavior Research Methods, 39(2), 175–191. → 樣本數計算 (第 19–26 張)
- Lakens, D. (2022). Sample size justification. Collabra: Psychology, 8(1), 33267. → 效應量從哪來、SESOI (第 13–14 張)
- Hoenig, J. M., & Heisey, D. M. (2001). The abuse of power: The pervasive fallacy of power calculations for data analysis. The American Statistician, 55(1), 19–24. → 事後 power 的謬誤 (第 10–11 張)
- Borm, G. F., Fransen, J., & Lemmens, W. A. J. G. (2007). A simple sample size formula for analysis of covariance in randomized clinical trials. J Clin Epidemiol, 60(12), 1234–1238. → ANCOVA 省樣本 (第 29 張)
- Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. Social Psychological and Personality Science, 8(4), 355–362. → TOST (第 58–59 張)
- Nosek, B. A., et al. (2018). The preregistration revolution. PNAS, 115(11), 2600–2606. → 前註冊 (第 46 張)



作業

Take-home Assignment

Plan it, run it, interpret it.

涵蓋單元 6：型一 / 二錯誤與檢定力、樣本數規劃、信效度檢測、研究執行與倫理、四步驟解讀。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題要你「規劃得出、解讀得對」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

能規劃一個研究的樣本數與信效度檢測，並用四步驟解讀結果（含虛無結果）。

繳交方式

一份 PDF：Part A 文字作答 + Part B 規劃與解讀，建議 3-5 頁。

建議時間

約 2-3 小時；可用 G*Power / JASP，但需寫出輸入與判讀。

工具與誠信

可用 AI / 軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

Part A | 觀念題：規劃、執行與解讀（1/2）

- A1** 型一 / 型二錯誤與檢定力的關係為何？為何不能同時最小化兩者？ $\text{Power} \geq .80$ 代表什麼？
- A2** 先驗／事後／敏感度三種 power analysis 的差別？為何『事後 power』意義不大？
- A3** 規劃樣本數要先估效應量——四種來源與各自風險？為何規劃時取『保守（偏小）』效應？
- A4** 為何組內設計比組間省樣本？還有哪些方法能降低所需 N （共變量、提高信度…）？

作答提示 觀念題重『說得清楚＋舉得出例』；每題 2-4 句即可。

Part A | 觀念題：規劃、執行與解讀（2/2）

- A5** 信度三型與 Cronbach's α 怎麼判讀？聚斂效度與區辨效度各需要什麼證據？
- A6** 研究執行的三項倫理要件（IRB、知情同意、debriefing）與兩項品質控制（前註冊、盲化）為何重要？
- A7** 解讀發現的四個步驟是什麼？各回答什麼問題？
- A8** $p > .05$ 該怎麼正確解讀？想主張『兩者沒有實務差異』要怎麼做？統計顯著 vs 實務重要差在哪？

Part B | 實作題：規劃與解讀（1/2）

情境：研究『線上正念課程是否降低大學生焦慮』（隨機分派兩組比較）。

- B1** 選檢定並寫 H_0/H_1 ；文獻得 $d \approx 0.5$ ，設 $\alpha=.05$ 、Power=.80，估每組所需 N ；再依 20% 流失算招募人數。
- B2** 你會用什麼工具測焦慮？如何檢驗其信度（ α ）與效度？各舉一個『應相關』與『不該相關』的變數。
- B3** 列出執行時的三項研究倫理要件與兩項資料品質控制措施。

教學重點 樣本數要在收案『前』規劃；測量要先確認信效度，資料才值得分析。

Part B | 實作題：規劃與解讀（2/2）

- B4** 結果為 $t(158)=2.6$, $p=.011$, $d=0.42$, 95% CI [1.2, 8.0]（隨機實驗）——用四步驟完整解讀。
- B5** 若另一結果 $p=.30$ （不顯著），你會怎麼解讀？在什麼條件下能主張『兩者等價』？
- B6** 寫一段結果與討論（含效應量、CI 與限制）+ AI 使用聲明。

繳交格式 Part B 要看得『樣本數計算』與『四步驟解讀』；虛無結果別寫成『證明沒差異』。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能說出取捨（如錯誤取捨、事後 power）
B1 樣本數規劃	15%	選對檢定、N 計算正確、含流失緩衝
B2 信效度	15%	測量工具 + α + 聚斂 / 區辨（各舉相關 / 不相關變數）
B3 倫理 + 品質	10%	倫理要件與品質控制具體可行
B4-B6 解讀 + 誠信	20%	四步驟正確、虛無結果解讀恰當、報告 + AI 聲明

常見扣分 用事後 power 解釋不顯著、把 $p > .05$ 當『沒差異』、樣本數沒含流失、報告缺效應量 / CI。

資源連結 · 外部服務與官方網址

點按名稱或網址可直接開啟；工具更新快，功能與費用請以官方頁面為準。

資源 / 服務	官方網址 URL
JASP	jasp-stats.org/
G*Power	gpower.hhu.de/

案例應用：規劃時保守，結論才站得住

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

本單元教了什麼

型一與型二錯誤、檢定力，以及樣本數該怎麼算出來。

②

案例怎麼用

- 規劃階段保守假設 $d_z = 0.5$ ， $\alpha = .05$ 雙尾、 $\text{power} = .80$ ，得 $n = 34$ 。
- 實際收案 A 機構 34 人恰達規劃值；B 機構 28 人為既有人力全數。
- 實得 $d_z = 1.08$ ，遠大於規劃值 0.5——保守的規劃假設讓樣本綽綽有餘。
- 若只收到 20 人，在 $d_z = 0.5$ 之下檢定力僅 .565，過半機率得不到顯著。
- 職類 $\times$ 完整性之卡方不顯著：效應 $w = .09$ 極小，需 969 人才有 .80 檢定力——本研究無力回答，不知端在何處。

③

產出什麼證據

事前檢定力分析報告與情境對照表（次頁），納入計畫書第 3.3 節。

④

承接關係

上游：承自 2.5 之 APA 格式結果段 | 下游：交棒 2.7，把七步驟完整走一遍。

教學重點 事前檢定力分析要用「你能接受的最小效果」，不是「你希望看到的效果」。假設 0.5 而實得 1.08 是好事；假設 1.0 而實得 0.4，研究就白做了。

示範產物：檢定力情境對照表

同一份資料在不同樣本數與效應量下的檢定力；未列說明不顯著結果為何不可解讀為無關聯

情境	效應量	樣本數	檢定力	判讀
規劃假設	$d_z = 0.50$	34	.808	規劃基準；恰達 .80 之慣例門檻
實際結果	$d_z = 1.08$	34	$> .999$	以觀察效應回算，僅供對照
若只收到 20 人	$d_z = 0.50$	20	.565	過半機率得不到顯著，研究可能白做
若只收到 20 人	$d_z = 1.08$	20	.996	效果大時樣本可少，惟事前無從得知
職類 × 完整性	$w = .09$	62	.109	以觀察效應回算，僅供對照；重點看下一列
同上，若要達 .80	$w = .09$	969	.800	此效應量下所需樣本遠超本研究可及

教學重點 最後兩列是本單元最重要的一課：若真實效應小如 $w = .09$ ，要 969 人才有 .80 檢定力——62 人無力回答這個問題；這是對照，不是不顯著的『原因』。把「沒驗出來」寫成「沒有差異」，是論文最常見的過度宣稱。