

量性研究方法 · 完整研究專案

單元 6

樣本數規劃、執行與研究解讀

Sample Size, Conducting & Interpreting Your Research

型一 / 型二錯誤、各檢定的樣本數計算、最佳化檢定力、信效度檢測、執行研究與下結論，並附完整研究檢核清單

8

把統計錯誤降到最低

Minimize Statistical Errors & Choose Sample Size

兩種錯誤：型一與型二

	H_0 為真 (無效果)	H_0 為假 (有效果)
判定顯著	型一錯誤 (α) 偽陽性	正確 (檢定力 $1-\beta$)
判定不顯著	正確	型二錯誤 (β) 偽陰性

你無法同時把兩種錯誤都降到最低：降低型一（更嚴格）常會提高型二，反之亦然。

取捨：以新藥研發為例

嚴格控制型一 ($\alpha = 0.01$)

- 需極強證據才判定有效
- 不易讓無效藥上市 (保障安全)
- 但可能錯失真正有效的好藥 (型二 $\uparrow$)

放寬型一 ($\alpha = 0.20$)

- 只要有一點證據就傾向判定有效
- 不易錯過潛在好藥 (型二 $\downarrow$)
- 但更多無效藥可能被錯誤接受 (型一 $\uparrow$)

比喻：面試選才的兩種失誤

把「檢定」想成面試：門檻太鬆會錄取到不適任者（型一）；門檻太嚴會刷掉真正適任者（型二）。

門檻太鬆（高 α ）

- 容易「錄取到不適任者」= 偽陽性（型一↑）
- 少數真正適任者被錯過（偽陰性↓）
- 簡單問題 → 多錄取、也多誤收

門檻太嚴（低 α ）

- 不易「錄取到不適任者」（型一↓）
- 但容易「刷掉真正適任者」= 偽陰性（型二↑）
- 困難問題 → 少誤收、卻多漏才

統計檢定的兩種錯誤



Key lessons

- Two types of errors can occur in statistical tests
- **False positives** (wrongly accepting H_1)
- **False negatives** (wrongly accepting H_0)
- Two forces control these two error rates
- **P value threshold** (primarily minimizes false positives)
- **Sample size** (primarily minimizes false negatives)

重點 p 值門檻主要控制偽陽性（型一）；樣本數主要控制偽陰性（型二）。兩者需權衡。

Power $\geq$ 80% , 理想 95%

如何決定樣本數

- 檢定力 (power) : H_0 為假時能正確拒絕它的機率
- 永遠不要低於 80% ; 理想情況設 95%
- 偽陰性機率 = $1 - \text{power}$ (80% power $\rightarrow$ 20% 偽陰性)
- 效應量 : 分析時採「小」或「中」效應量較保守實際
- 研究設計的選擇 , 會大幅影響所需樣本數

檢定力:一個具體的例子

把 80% 與 95% 放進真實情境

情境 比較新舊衛教對血壓控制的效果,預期中效應 $d = 0.5$ 。

設 power = 80% 需每組約 64 人。意思:即使效果真的存在,仍有 20% 機率漏抓(得到不顯著)。

設 power = 95% 需每組約 105 人。漏抓機率降到 5%,但要多招募約 60% 的人。

漏抓的代價 = 白做一場、還可能誤導『新衛教無效』;臨床等高風險研究值得用 90–95%。

教學重點 power 是『效果存在時抓得到的機率』;80% 是底線,樣本充足或後果嚴重時再往上提。

三種檢定力分析：先驗、事後、敏感度

類型	何時做	給定什麼 → 求什麼
先驗 A priori	收案『前』（正確做法）	給 α 、Power、效應量 → 求所需 N
敏感度 Sensitivity	樣本數已固定時	給 α 、Power、N → 求『能偵測的最小效應』
事後 Post-hoc	收案後（不建議）	給 α 、N、觀察效應 → 回算 Power（意義不大）

教學重點 只有『先驗』能真正規劃樣本數；事後 Power 用觀察效應回算、和 p 值一體兩面，不能用來『解釋不顯著』——改用敏感度分析或信賴區間。

三種檢定力分析:各一個情境

先驗 / 敏感度 / 事後,分別長什麼樣

先驗 A priori (收案前 · 正確)

- 「要偵測 $d=0.5$ 、power .80
- G*Power 算出每組 64 人」
- 拿去寫計畫、送 IRB。

敏感度 Sensitivity (N 已固定)

- 「醫院只能給 40 位病人
- 反推:只能偵測 $d \geq 0.9$ 的大效應」
- 誠實說明能力上限。

事後 Post-hoc (收案後 · 不建議)

「收完 30 人、 $p=.20$,回算 power=.35」→ 這只是 p 值的重述,不能用來說『因為 power 低所以才不顯著』。要交代不顯著,改用敏感度分析或信賴區間。

教學重點 規劃樣本只能用『先驗』;樣本被綁死時用『敏感度』誠實交代;別用事後 power 替不顯著找藉口。

各檢定的效應量慣例

檢定	效應量指標	小	中	大
t 檢定	Cohen's d	0.2	0.5	0.8
相關 / 迴歸	r	0.1	0.3	0.5
ANOVA	Cohen's f	0.10	0.25	0.40
邏輯斯迴歸	Odds Ratio	≈ 1.5	≈ 2 (1.3中)	$\approx 3+$
卡方檢定	w	0.1	0.3	0.5

p 值回答「有沒有效？」；效應量回答「效應有多大？」——兩者都要報告。

規劃樣本數，效應量從哪來？

樣本數計算最難的一步，就是先『猜』一個合理的效應量

- ① **文獻 / 統合分析** 找同主題研究或 meta-analysis 的平均效應量——最可靠的來源。
- ② **先導研究 pilot** 小規模先跑，估效應與變異；但 pilot 的 d 很不穩，別高估。
- ③ **最小有意義效應 SESOI** 問『多小的效果才值得在意』，用它當規劃基準（保守、實務導向）。
- ④ **Cohen 慣例（最後手段）** 沒資訊時用『中』效應，但要清楚這只是粗估。

教學重點 常見錯誤：用『pilot 算出的大效應』去規劃 → N 太小、研究注定沒力。取『保守（偏小）』效應較安全。


效應量從哪來:四種來源各一例

規劃前先『猜』一個合理的效應量

- ① 文獻 / 統合分析 查到同類正念介入對壓力的統合 $d \approx 0.45$ → 直接採用(最可靠)。
- ② 先導研究 pilot 自己先跑 15 人估 $d=0.8$ → pilot 很不穩,別直接用,打折當參考。
- ③ 最小有意義效應 SESOI 臨床上血壓至少要降 5 mmHg 才算有意義 → 換算成 d 當規劃基準。
- ④ Cohen 慣例 (最後手段) 完全沒資訊 → 用『中效應』 $d=0.5$,但要註明只是粗估。

教學重點 寧可用『偏小/保守』的效應量規劃 → N 抓大一點,免得研究注定沒力。

設計如何影響所需樣本數



- 組間設計因個體差異大，需最多樣本
- 組內 / 混合設計大幅減少所需人數
- 示意：小效應下組間需近 800 人
- 降低需求的方法：改用較大效應量、提高 power 上限、或改變研究設計

為什麼組內設計省這麼多人？

同一效應,組間 vs 組內差在哪

讀圖 同一效應量,組間(不同人)需要的 N 最多;組內/混合(同一批人)大幅下降。小效應($d=0.2$)下組間近 800 人。


原因 組間有『個體差異』(有人天生高、有人低),這是雜訊,要靠更多人才平均得掉。

組內為何省 每個人當自己的對照(比自己前後),個體差異被消掉 → 雜訊小 → 同效應用更少人就達 power。

代價/限制 組內有順序、練習、疲勞與遺留效應,需平衡次序(counterbalance)或洗滌期;且非所有 IV 都能組內。


教學重點 想省人先問:這個 IV 能不能讓同一個人都經歷?能 → 組內;不能(性別、疾病組)→ 只能組間,得靠加人或提高信度。

G*Power 樣本數計算：相關



- 檢定族：Correlation (雙尾)
- 效應量 r ：中效應約 0.3
- $\alpha = 0.05$ 、Power = 0.95
- H_0 下相關 = 0 (母體無關聯)
- 輸出：所需總樣本數 Total sample size

G*Power 樣本數計算：ANOVA (組間)



- 效應量 Cohen's f : 小 0.10 / 中 0.25 / 大 0.40
- $\alpha = 0.05$ 、 Power = 0.95
- Number of groups : 組數 (如 2)
- 小效應下需求極大 (可能近 800 人)
- → 改用較大效應量或改變設計


G*Power 樣本數計算：RM ANOVA (組內)

The screenshot shows the G*Power 3.1.9.7 window. The 'Test family' is set to 'F tests' and the 'Statistical test' is 'ANOVA: Repeated measures, within factors'. The 'Type of power analysis' is 'A priori. Compute required sample size - given α , power, and effect size'. The 'Input Parameters' section includes: Effect size f (0.1), α err prob (0.05), Power (1- β err prob) (0.8), Number of groups (1), Number of measurements (2), Corr among rep measures (0.5), and Nonsphericity correction ϵ (1). The 'Output Parameters' section includes: Noncentrality parameter λ (7.960000), Critical F (3.8888529), Numerator df (1.0000000), Denominator df (198), Total sample size (199), and Actual power (0.8016910). At the bottom, there are buttons for 'Options', 'X-Y plot for a range of values', and 'Calculate'.

Input Parameters		Output Parameters		
Determine $\rightarrow$	Effect size f	0.1	Noncentrality parameter λ	7.960000
	α err prob	0.05	Critical F	3.8888529
	Power (1- β err prob)	0.8	Numerator df	1.0000000
	Number of groups	1	Denominator df	198
	Number of measurements	2	Total sample size	199
	Corr among rep measures	0.5	Actual power	0.8016910
	Nonsphericity correction ϵ	1		

- 純組內設計：Number of groups = 1
- Number of measurements：如前後 = 2
- Corr among rep measures：難估時留預設
- 所需人數遠少於組間設計

G*Power 樣本數計算：邏輯斯迴歸



- 效應量以 Odds Ratio 表示
- OR 接近 1 為小效應；1.3 約中效應
- 設定基準事件機率 (如 20% 購買)
- $\alpha = 0.05$ 、Power = 0.95

G*Power 完整實例：常見檢定所需樣本數

$\alpha = .05$; 同時看 Power = .80 (最低) 與 .95 (理想) 的差別

檢定	中效應量	Power .80	Power .95
獨立 t (兩組)	$d = 0.5$	共 128 (每組 64)	共 210 (每組 105)
配對 t	$d_z = 0.5$	34 人	54 人
單因子 ANOVA (3 組)	$f = 0.25$	共 159	共 252
相關	$r = 0.30$	84	138
卡方 (2×2)	$w = 0.30$	88	145

教學重點 把 Power 從 .80 拉到 .95，樣本數約要多 60%——『更保險』是有代價的。效應越小需求越爆炸 (t 檢定 $d=0.2$ 每組要 394 人)。

這張樣本數表怎麼讀？

一步步查給你看

怎麼查 先依 IV/DV 選『檢定』那一行,再看要的 power 欄。例:兩組比較中效應 → 獨立 t → power .80 → 共 128(每組 64)。

為何 .95 欄都比较大 要更保險(漏抓機率從 20% 降到 5%),就得多收約 60% 的人。

效應越小,人越爆炸 同樣獨立 t, $d=0.5$ 每組 64; $d=0.2$ 每組要 394。

配對比獨立省很多 配對 t 只要 34,獨立 t 要 128——因為配對去掉了個體差異。

教學重點 表是『中效應』的參考值;實際規劃要用你自己估的效應量在 G*Power 重算,別直接套。

G*Power 逐步操作實例（兩組平均比較）

- ① **Test family / test** t tests → Means: Difference between two independent means。
- ② **Type of power analysis** 選 A priori（給效應量/ α /Power，求所需樣本數）。
- ③ **輸入** Tail(s) = Two；Effect size $d = 0.5$ ； $\alpha = .05$ ；Power = .80；Allocation ratio = 1。
- ④ **讀輸出** Total sample size = 128（每組 64）；Actual power $\approx .80$ 。

教學重點 效應量不確定時，用 G*Power 的『Determine =>』面板，從兩組平均與 SD 反推 d ；或直接輸入你的 SESOI。

設計如何省樣本：組間 vs 組內（同一效應）

設計	效應量	Power .80 所需 N
組間（兩組）	$d = 0.5$ （中）	共 128 人
組內 / 配對	$d_z = 0.5$	34 人（同一批）
組間（小效應）	$d = 0.2$	共 788 人

教學重點 組內設計用『每人當自己對照』去除個體差異 → 同效應下人數少一大截。小效應時組間需求近 800 人——改組內或提高測量信度最有效。

設計效率:同一效應,人數差在哪?

把三列數字讀成一句話

對照三列 組間中效應 $d=0.5 \rightarrow 128$ 人;改組內 $d_z=0.5 \rightarrow$ 只要 34 人(同一批);組間但小效應 $d=0.2 \rightarrow$ 暴增到 788 人。

意思 1 · 設計比蠻力有效 同樣的效應,組間改組內,人數少一大截($128 \rightarrow 34$)。

意思 2 · 效應大小影響巨大 效應從 0.5 掉到 0.2,需求從 128 飆到 788(約 6 倍)。

實務順序 先看能不能組內 $\rightarrow$ 再想把效應做大(強操控)或雜訊做小(提高信度) $\rightarrow$ 不得已才加樣本。

教學重點 省樣本的優先順序:改組內 > 提高測量信度/強操控 > 最後才是加大樣本。

把『算出的 N』變成『要招募的人數』

流失率調整 若需 128 且預估 20% 中途退出 → 招募 $128 \div (1-0.20) = 160$ 人。

不等組配置 2:1 配置比 1:1 需要更多總人數——除非有理由，否則等組最省。

共變量 ANCOVA 納入與 DV 高相關的共變量（如前測），可降低誤差、減少所需 N（約省 $1-r^2$ ）。

叢集 / 分層 叢集抽樣要乘『設計效應』把 N 放大；分層可提升效率。

教學重點 『算出的 N』是分析所需的最低有效樣本；真正要招募的，還要加上流失、篩選不合格與無效卷的緩衝。

從 N 到招募人數:一步步算給你看

算出的 N 不是要招募的人數

起點 分析需要的有效樣本 $N = 128$ (每組 64)。

① **加流失** 預估 20% 中途退出 → 招募 $128 \div (1-0.20) = 160$ 人。

② **加篩選/無效卷** 再估 10% 不合格或問卷無效 → $160 \div (1-0.10) \approx 178$ 人。

省人技巧 納入前測當共變量(ANCOVA),與 DV 高相關(如 $r=.6$)可降低誤差 → 反而減少所需 N。

教學重點 『算出的 N』是分析要的最低有效樣本;真正要招募的 = $N \div (1-\text{流失}) \div (1-\text{無效})$,務必留緩衝。

完整樣本數規劃實例：從研究問題到招募人數

研究：正念 App 是否降低護理師壓力？（兩組比較）

- ① 檢定 兩組平均比較 → 獨立樣本 t 檢定（雙尾）。
- ② 效應量 查文獻・類似介入 $d \approx 0.5$ （中）；規劃取保守值 $d = 0.45$ 。
- ③ α 與 Power $\alpha = .05$ 、Power = .80。
- ④ G*Power $d = 0.45 \rightarrow$ 每組約 78（共 156）。
- ⑤ 流失緩衝 預估 15% 退出 $\rightarrow 156 \div 0.85 \approx 184$ （每組約 92）。
- ⑥ 結論 規劃招募約 184 位護理師，才能在效果存在時有 80% 偵測力。

教學重點 先驗規劃要寫進研究計畫（收案前）——這是 IRB 與審查委員會檢查的重點，也避免做出一個『沒有檢定力』的研究。



如何最佳化統計檢定力

How to Optimize Statistical Power

檢定力的三個槓桿

樣本數

直接

唯一能「直接」控制的因素——
加大樣本。

效應量

間接

透過『強操控』間接放大：比較
最極端的兩端。

變異性

間接

透過提高『測量信度』間接降低
雜訊。

強操控 = 把 IV 操弄到最強 (大量治療 vs 完全無治療) ；用類別 IV 比較兩極端。

三個槓桿:各用一個做法舉例

沒錢加人時,還有兩個間接槓桿

樣本數 (直接)

原每組 64 人 power 不足
→ 直接多招募到每組 90 人。

最直接,
但最花錢、花時間。

效應量 (強操控 · 間接)

比較『每天 60 分鐘運動』
vs 『完全不運動』兩極端,
而非 60 vs 45 分鐘。

→ 組間差變大、更易偵測。

變異 (提高信度 · 間接)

單題自評 → 改 5 題量表
($\alpha=.85$),或多次測量取平均。

→ 雜訊變小,
等於變相加大 power。

教學重點 沒錢加人時,先想能不能『強操控 IV』或『提高測量信度』——這兩招不加入也能提升檢定力。

檢測測量信度的三種方法

再測信度 Test-Retest

同一測量在兩個時間點的相關。例：兩次體重測量高度相關 → 信度佳。

內部一致性

同一問卷多題項是否測同一概念；用 Cronbach's α 。 $\alpha > 0.7$ 良好、 > 0.9 很好。

評分者間信度

多位觀察者評分的一致性；兩位算相關，多位算 Cronbach's α 。

若某題項或某觀察者對信度無貢獻（如 Cronbach's α 因它下降）→ 可考慮刪除。

三種信度:各檢驗一種「一致」

跨時間 / 跨版本 / 題目之間

三種信度,檢驗的是三種不同的「一致」



重測信度 Test-retest:跨「時間」穩不穩



複本信度 Parallel-form:跨「版本」一不一致



內部一致性 Internal consistency:題目之間一不一致 (α)

選哪一種取決於你的威脅:怕受測者狀態飄→重測;怕題目版本不同→複本;怕題目測到不同東西→ α 。

教學重點 信度不足會稀釋效果、拉低檢定力——提高信度等於免費提升 power,比事後加樣本便宜。

信度實例：Cronbach's α 與題目分析

5 題『工作壓力量表』的内部一致性

公式概念 $\alpha = (k/(k-1)) \times (1 - \Sigma \sigma^2_{\text{題}} / \sigma^2_{\text{總}})$ · k = 題數。題越多、題間相關越高 $\rightarrow \alpha$ 越高。

整體結果 5 題 $\alpha = .82$ (良好；.70 可接受、.80 佳、>.95 可能題目重複)。

題目分析 看『校正後題總相關』：題 1、2、4、5 約 .55-.70；題 3 僅 .15。

刪題判斷 『 α if item deleted』：刪題 3 後 α 升到 .87 $\rightarrow$ 題 3 測的不是同一件事，考慮刪或改寫。

教學重點 α 高不代表『單一維度』——題目太多也會推高 α 。要配合因素分析 (EFA/CFA) 確認結構。

α 與題目分析:怎麼看、怎麼決定刪題

把上一頁的數字讀懂

$\alpha = .82$ 代表 5 題大致測同一件事(工作壓力),內部一致性良好(.70 可接受/.80 佳/>.95 恐重複)。

校正後題總相關 每題與『其他題總分』的相關。題 1/2/4/5 約 .55-.70(好);題 3 只有 .15(不合拍)。

α if item deleted 刪某題後的 α 。刪題 3 $\rightarrow \alpha$ 從 .82 升到 .87 $\rightarrow$ 題 3 在扯後腿。

決策 題 3 可能問到別的概念(或反向題沒反轉) $\rightarrow$ 考慮刪除或改寫,再重新施測。

教學重點 α 高只說『一致』,不保證『單一維度』;題目太多也會灌高 α ——要配合因素分析(EFA/CFA)確認結構。

檢測測量效度

聚斂效度 Convergent

- 與「應相關」的變數確實相關
- 體適能 vs 跑步速度 → 正相關 ✓
- 體適能 vs 運動心跳 → 負相關 ✓

區辨效度 Discriminant

- 與「不該相關」的變數不相關
- 體適能 vs 身高 → 接近 0、不顯著 ✓
- 體適能 vs 襯衫數量 → 接近 0 ✓

效度實例：用相關矩陣看聚斂與區辨

新『工作壓力量表』——該相關的相關、不該相關的不相關

與哪個變數比	預期	觀察 r	判讀
職業倦怠	應正相關（聚斂）	.62	聚斂 ✓
睡眠品質	應負相關（聚斂）	-.48	聚斂 ✓
工作投入	弱相關（合理）	.22	合理
身高	不該相關（區辨）	.05	區辨 ✓

教學重點 聚斂與區辨要一起看：與倦怠高相關（該相關）、與身高近 0（不該相關），才算真的測到『壓力』而非別的東西。

聚斂與區辨:用相關矩陣看

同構念要高、跨構念要低

壓力1	1.00	0.72	0.68	-0.18	-0.12	-0.15
壓力2	0.72	1.00	0.75	-0.14	-0.16	-0.11
壓力3	0.68	0.75	1.00	-0.12	-0.10	-0.13
支持1	-0.18	-0.14	-0.12	1.00	0.70	0.74
支持2	-0.12	-0.16	-0.10	0.70	1.00	0.69
支持3	-0.15	-0.11	-0.13	0.74	0.69	1.00
壓力1	壓力2	壓力3	支持1	支持2	支持3	

怎麼讀這張相關矩陣

 綠框:同一構念的題目

應該「高」(此例 .68~.75) → 聚斂效度成立

 橘框:不同構念之間

應該「低」(此例 -.10~-.18) → 區辨效度成立

判準:同構念相關 明顯高於 跨構念相關。

若跨構念也很高 → 兩個構念可能其實是同一件事,
要合併、重新定義,或改題。

教學重點 若跨構念相關也很高,代表兩個構念可能其實是同一件事——要合併、重新定義或改題。

9-10

執行研究與解讀發現

Conducting & Interpreting Your Research

執行研究：如何取得參與者

- 在合適場域招募：醫學研究找醫院、商業研究找公司
- 大學生常用「便利樣本」——資源有限時的典型做法
- 篩選 (screening)：確認受試者屬於目標母體
- 知情同意：事前告知風險與益處
- 留意「要求特徵」；測量基本人口變項 (至少年齡、性別)
- 結束時做「debriefing」，讓受試者了解研究內容

專業執行（一）：招募、篩選與研究倫理

場域與抽樣框 到目標母體所在處招募（醫院/公司/校園）；記錄抽樣框與回收率。

篩選 Screening 用納入 / 排除條件確認受試者屬目標母體；記錄篩掉多少、為什麼。

倫理審查 IRB 收案前送機構審查（IRB/REC）；弱勢或高風險族群更嚴格。

知情同意 事前告知目的、風險、益處、可隨時退出，並取得書面同意。

debriefing 結束時說明研究內容（尤其有隱瞞設計時），並提供聯絡與資源。

教學重點 倫理不是形式：知情同意、資料保密、退出權、debriefing 都要寫進計畫；違反倫理取得的資料不能用。

專業執行（二）：讓資料可信的品質控制

前註冊 Pre-registration 收案前公開假設與分析計畫 → 區分驗證性/探索性、防 p-hacking。

盲化 Blinding 受試者/施測者不知分組（單盲/雙盲），降低期望與要求特徵。

標準化程序 統一指導語、環境與順序；用對抗平衡控制順序效應。

資料監控 邊收邊查：遺漏、離群、直線作答、注意力題；記錄流失與原因。

教學重點 『可重現』從執行就開始：把程序寫成可照做的手冊，別人（或未來的你）才能複製你的研究。

解讀發現的四大判準

無其他解釋

是否存在其他合理解釋？用控制變項或統計方法排除。

準確測量

結果是否準確反映研究目的？工具與資料是否可靠。

外部效度

結果能否推廣到其他情境？樣本與情境是否具代表性。

信度

結果是否一致？可用重測或多種工具驗證。

解讀四判準:各配一個提問例子

用四個問句檢視你的結果

① 無其他解釋 (內部效度)

「壓力下降,真的是 App 造成的嗎?
會不會剛好碰上放暑假?」
→ 用控制組/共變量排除。

② 準確測量 (建構效度)

「我用的量表真的在測『壓力』嗎?」
→ 檢查工具的效度證據
與操作型定義。

③ 外部效度 (可推廣)

「只在這 60 位護理師成立,
還是能推到其他醫院/職業?」
→ 看樣本與情境代表性。

④ 信度 (一致)

「換時間或換工具再測,
結果會一樣嗎?」
→ 重測信度、多工具驗證。

教學重點 四判準對應四種效度/信度問題;先確認『不是別的原因、測得準、測得穩』,再談能不能推廣。

系統化解讀：四個步驟

1 Step 1 信度 *Reliability* $p < 0.05$ 嗎？顯著 → 結果與測量「夠可靠」。

2 Step 2 測量 *Measurements* 測量有效度疑慮嗎？自陳是否與其他指標一致？

3 Step 3 替代解釋 *Explanations* 是實驗嗎？實驗只留解釋 1；非實驗需考慮 2、3 與混淆。

4 Step 4 外部效度 *External validity* 樣本隨機嗎？情境真實嗎？能推廣到母體嗎？

接下來用同一套四步驟，走過四個真實情境的解讀範例。

解讀結果的四個步驟

統計 → 大小 → 設計 → 實務

解讀結果的四個步驟——順序不能跳



常見錯誤:只做第①步就下結論(「顯著,所以有效」)——那只回答了四分之一。

虛無結果也照這四步走:不顯著 → 看 CI 有多寬 → 看設計有無檢定力不足 → 再談實務。

寫作對應:①②寫在結果章,③④寫在討論章。

教學重點 常見錯誤是只做第①步就下結論;四步走完,結果章與討論章的骨架也就出來了。

四步驟解讀完整範例：一個真實情境

研究：線上輔導是否提升數學成績？（隨機分派兩組）

結果 輔導組 $M=76$ vs 對照組 $M=70$ ； $t(98)=2.9$, $p=.005$, $d=0.58$, 95% CI [1.9, 10.1]。

① **信度（可靠嗎）** $p<.05$ 、效應中等、CI 不含 0 → 結果穩健、非巧合。

② **測量（測得準嗎）** 成績為標準化測驗（客觀）→ 效度佳；若為自評則需更謹慎。

③ **替代解釋** 有隨機分派 → 排除反向與第三變項，可談因果（留意實施差異等混淆）。

④ **外部效度（能推廣嗎）** 單一學校樣本 → 推廣需謹慎，宜複製到不同學校/年級。

教學重點 完整解讀 = 先確認『可靠』（ p + 效應 + CI），再問『測得準嗎、有無其他解釋、能推廣嗎』——四關都過才下強結論。

解讀範例①：實驗設計

研究設計與結果

組間實驗：把人「隨機」分到治療組與控制組。IV = 治療，DV = 憂鬱。

結果 治療組憂鬱顯著低於控制組 ($p < 0.05$)。

結論：治療有效，且在符合條件下可推論到母體。

四步驟解讀

1 信度 $p < 0.05 \rightarrow$ 結果與測量夠可靠。

2 測量 自陳憂鬱是否與臨床診斷等指標一致？

3 解釋 是實驗（已隨機化） $\rightarrow$ 只有解釋 1：治療造成差異。留意注射 vs 安慰劑的混淆。

4 外部效度 樣本隨機 / 分層？情境真實？ $\rightarrow$ 可謹慎推廣。

解讀範例②：準實驗

研究設計與結果

非實驗混合設計（未隨機分派誰接受治療）
。前測、後測比較兩組。

結果 控制組前後幾乎相同；治療組後測較低。

結論：結果可靠，但「無法斷定因果」，只能談關聯。

四步驟解讀

1 信度 交互作用 $p < 0.05 \rightarrow$ 結果夠可靠。

2 測量 憂鬱是自陳嗎？有無過去研究支持其效度？

3 解釋 非實驗 $\rightarrow$ 三種解釋都可能：治療 $\rightarrow$ 憂鬱、憂鬱 $\rightarrow$ 尋求治療（反向）、第三變項（自我照護）。

4 外部效度 樣本 / 情境是否具代表性？

解讀範例③：相關研究

研究設計與結果

非實驗：冥想頻率（數值 IV）與幸福感（數值 DV）。

結果 $r = 0.41$ ，強正相關。

結論：有顯著關聯，但不能推論「冥想造成快樂」。

四步驟解讀

1 信度 $p < 0.05 \rightarrow$ 相關可靠。

2 測量 幸福感為自陳，留意測量效度。

3 解釋 非實驗 $\rightarrow$ 三種解釋：冥想 $\rightarrow$ 快樂、快樂 $\rightarrow$ 冥想、第三變項（自我照護動機）。

4 外部效度 受訪者在自家自行冥想，樣本是否代表一般人？

解讀範例④：虛無結果

研究設計與結果

組間實驗：治療組 vs 控制組 → 憂鬱。兩組差異很小。

結果 $p = 0.42$ (不顯著)。

結論：四關全過才可「謹慎」建議 H_0 可能為真；否則證據不足。

四步驟解讀

1 信度 不顯著 → 先別下「沒效果」的結論。

2 測量 測量與操控：信度效度夠嗎？IV 操弄夠強嗎？

3 解釋 (本例先看樣本數) 對「小效應」是否達 95% power？

4 外部效度 樣本無偏？情境真實？

$p > 0.05$ 時

如何解讀虛無結果 (null result)

- 先排查方法學問題，再談結論：
 - 樣本數：對「小效應」是否達 95% power ? → 或許可主張效果不顯著
 - 測量與操弄：信度、效度足夠嗎？IV 操弄夠強嗎？
 - 外部效度：真隨機樣本？資料點獨立？情境真實？
- 只有當以上全部為「是」，才可謹慎地建議 H_0 可能為真

解讀虛無結果進階：怎麼主張『沒有實務差異』

$p > .05$ 不能證明沒差異——要主張『等價』得用等價檢定

問題 傳統檢定不顯著 $\neq$ 沒差異（可能只是沒力）。『沒有證據』不等於『有證據證明沒有』。

等價界限 SESOI 先定『多小的差異算沒差』，例如 ± 5 分。


TOST 做法 若差異的 90% CI 完全落在 $[-5, +5]$ 內 $\rightarrow$ 可主張『實務上等價』。

範例 觀察差異 1.2 分、90% CI $[-2.1, 4.5] \subset [-5, 5] \rightarrow$ 可主張兩法效果等價。

教學重點 想主張『沒差異/一樣好』，別只報 $p > .05$ ；用等價檢定（TOST），或看 CI 是否夠窄且落在可忽略範圍內。

不顯著 $\neq$ 等價:要用等價檢定

CI 必須整段落落在等價界限內



教學重點 想主張「沒有實務差異」,必須事先訂好最小有意義差異,再看 CI 是否完全落在界限內。

統計顯著 vs 實務重要：用效應量與 CI 判讀

	研究 A	研究 B
樣本數 N	8,000	50
效應量 d	0.06	0.85
p 值	p = .002 (顯著)	p = .04 (顯著)
判讀	顯著但幾乎沒實務意義 (大 N)	效果大、值得在意 (雖樣本小)

教學重點 決策看『效應量 + CI + 實務門檻』，不是只看 p。大 N 會讓瑣碎差異顯著；小 N 的大效應也可能很重要。

顯著 $\times$ 效果大小:四種情況

p 與效應量/CI 一起看

把 p 與效應量/CI 一起看,才分得出這四種情況

顯著 + 效果大

最理想:有效且值得推

顯著 + 效果小

大樣本才顯著;要問值不值得

不顯著 + CI 窄

較有把握「真的沒什麼效果」

不顯著 + CI 寬

資訊不足:可能只是樣本太小

教學重點 「不顯著」要先看 CI 寬窄:CI 很寬只代表資訊不足,不能說「證明沒效」。

事後補救：微調你的研究問題

研究做完才發現方法學限制時，不必推翻一切——改問「這份資料到底能回答什麼」。

- 問自己：這份資料「能」回答哪個問題（which question CAN you answer）？
- 問自己：從結果「能」得出什麼結論（which conclusion CAN you draw）？
- 例：原本想證明「自動」形成印象，若證據不足 → 改主張「自發」形成（較保守、仍有貢獻）
- 誠實揭露限制、用謹慎的語言陳述——縮小主張範圍，而非誇大或隱瞞

誠實寫限制與外部效度

內部效度限制 非隨機、混淆未控、測量誤差 → 說明可能的方向與影響。

外部效度限制 樣本（便利/單一場域）、情境（實驗室 vs 真實）、時間點 → 推廣範圍要保守。

測量限制 自陳偏誤、單一指標 → 建議未來加客觀或多元指標。

語言要保守 用『支持/傾向』而非『證明』；縮小主張範圍，而非隱瞞。

教學重點 誠實揭露限制不會扣分，反而顯示你懂方法學——審稿人最怕的是『過度宣稱』與『假裝沒有限制』。

完整研究實例（1/2）：規劃與執行

遠距工作是否提升員工幸福感？

- ① **問題與設計** 隨機分派員工：遠距組 vs 一般組；8 週後測幸福感 WHO-5（數值）。
- ② **樣本數規劃** 文獻 $d \approx 0.4$ → 每組約 100（共 200）；預估 15% 流失 → 招募約 236。
- ③ **測量** WHO-5（信度 $\alpha = .85$ 、效度佳）+ 客觀出勤資料交叉驗證。
- ④ **執行** IRB 通過、知情同意、單盲評分、前註冊分析計畫、邊收邊清資料。

教學重點 好研究在『收案前』就把效應量、樣本數、測量工具、倫理與分析計畫都定好——這一頁就是計畫書骨架。

完整研究實例（2/2）：分析與解讀

- ⑤ **結果** 遠距組 WHO-5 M=68 vs 一般組 M=62 ; $t(198)=3.1, p=.002, d=0.44, 95\% CI [2.2, 9.8]$ 。
- ⑥ **四步驟解讀** 信度：穩健；測量：有客觀資料佐證；解釋：隨機化→可談因果；外部：單一公司需複製。
- ⑦ **實務判讀** $d = 0.44$ 中等、CI 不含 0 → 有實務意義，但非萬靈丹。
- ⑧ **結論與限制** 支持遠距對幸福感有正向效果；限制：單一產業、以自陳為主、僅 8 週短期。

教學重點 一個完整研究的句點 = 顯著性 + 效應量 + CI + 設計能談到什麼 + 誠實的限制——這就是結果與討論章。

完整研究檢核清單（一）

研究問題 & 設計

- 重要？新穎？合乎時機？
- 組間：是否隨機分派？
- 組內：是否隨機化 / 對抗平衡順序？
- 控制組是否含混淆變項？查清單！
- 無法隨機化 → 用非實驗混合設計

測量 & 資料蒐集

- 測量可靠？標準化、多次平均
- 查過去研究：該工具信度如何？
- 測量有效？聚斂與區辨效度證據
- 自陳注意社會期許偏誤
- 蒐集盡量隨機獨立， $N \geq 30$

完整研究檢核清單（二）

資料準備 & 統計

- 格式：每列一人、每測量一欄
- 處理缺失值與離群值
- 敘述：對的圖（散布 / 箱型 / 列聯表）
- 推論： $\text{power} \geq 80\%$ （理想 95%）
- 用對檢定？只做一個檢定？ $p < 0.05$ ？

執行 & 解讀

- 篩選、知情同意、debriefing
- 信度： $p < 0.05 \rightarrow$ 結果夠可靠
- 測量準確性：留意效度與信度
- 替代解釋：實驗設計？有混淆嗎？
- 外部效度：真隨機？情境真實？

結果與討論寫作檢查清單

- ☐ 先驗樣本數規劃有寫（效應量來源、 α 、Power、所需 N 與流失緩衝）
- ☐ 每個檢定報：統計量 + df + 精確 p + 效應量 + 95% CI
- ☐ 信度（ α ）與效度證據有交代；測量工具來源清楚
- ☐ 用四步驟解讀：可靠？測得準？有無其他解釋？能否推廣？
- ☐ 區分統計顯著與實務重要；虛無結果不寫成『證明沒差異』
- ☐ 誠實列限制與外部效度；用保守語言、附 AI 使用聲明

教學重點 把這張清單當『投稿前最後檢查』——最常被退稿的就是漏樣本數規劃、漏效應量/CI，以及過度宣稱。

課程總結：你已經學會

- 提出一個吸引人且可行的研究問題
- 設計能將替代解釋降到最低的研究
- 在最大化信度與效度下進行測量
- 用適當技術與足夠樣本數蒐集資料
- 用免費易用的軟體（如 JASP）分析資料
- 從結果得出穩健的結論



作業

Take-home Assignment

Plan it, run it, interpret it.

涵蓋單元 6：型一/二錯誤與檢定力、樣本數規劃、信效度檢測、研究執行與倫理、四步驟解讀。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題要你「規劃得出、解讀得對」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

能規劃一個研究的樣本數與信效度檢測，並用四步驟解讀結果（含虛無結果）。

繳交方式

一份 PDF：Part A 文字作答 + Part B 規劃與解讀，建議 3–5 頁。

建議時間

約 2–3 小時；可用 G*Power / JASP，但需寫出輸入與判讀。

工具與誠信

可用 AI / 軟體協助，但須附『AI 使用聲明』；判讀與結論要自己寫。

Part A | 觀念題：規劃、執行與解讀 (1/2)

- A1 型一/型二錯誤與檢定力的關係為何？為何不能同時最小化兩者？Power $\geq .80$ 代表什麼？
- A2 先驗 / 事後 / 敏感度三種 power analysis 的差別？為何『事後 power』意義不大？
- A3 規劃樣本數要先估效應量——四種來源與各自風險？為何規劃時取『保守（偏小）』效應？
- A4 為何組內設計比組間省樣本？還有哪些方法能降低所需 N（共變量、提高信度...）？

作答提示 觀念題重『說得清楚 + 舉得出例』；每題 2–4 句即可。

Part A | 觀念題：規劃、執行與解讀 (2/2)

- A5 信度三型與 Cronbach's α 怎麼判讀？聚斂效度與區辨效度各需要什麼證據？
- A6 研究執行的三項倫理要件 (IRB、知情同意、debriefing) 與兩項品質控制 (前註冊、盲化) 為何重要？
- A7 解讀發現的四個步驟是什麼？各回答什麼問題？
- A8 $p > .05$ 該怎麼正確解讀？想主張『兩者沒有實務差異』要怎麼做？統計顯著 vs 實務重要差在哪？

Part B | 實作題：規劃與解讀 (1/2)

情境：研究『線上正念課程是否降低大學生焦慮』（隨機分派兩組比較）。

- B1** 選檢定並寫 H_0/H_1 ；文獻得 $d \approx 0.5$ ，設 $\alpha=.05$ 、Power=.80，估每組所需 N ；再依 20% 流失算招募人數。
- B2** 你會用什麼工具測焦慮？如何檢驗其信度（ α ）與效度？各舉一個『應相關』與『不該相關』的變數。
- B3** 列出執行時的三項研究倫理要件與兩項資料品質控制措施。

教學重點 樣本數要在收案『前』規劃；測量要先確認信效度，資料才值得分析。

Part B | 實作題：規劃與解讀 (2/2)

- B4 結果為 $t(158)=2.6$, $p=.011$, $d=0.42$, 95% CI [1.2, 8.0] (隨機實驗) ——用四步驟完整解讀。
- B5 若另一結果 $p=.30$ (不顯著) , 你會怎麼解讀? 在什麼條件下能主張『兩者等價』?
- B6 寫一段結果與討論 (含效應量、CI 與限制) + AI 使用聲明。

繳交格式 Part B 要看得『樣本數計算』與『四步驟解讀』; 虛無結果別寫成『證明沒差異』。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能說出取捨（如錯誤取捨、事後 power）
B1 樣本數規劃	15%	選對檢定、N 計算正確、含流失緩衝
B2 信效度	15%	測量工具 + α + 聚斂/區辨（各舉相關/不相關變數）
B3 倫理 + 品質	10%	倫理要件與品質控制具體可行
B4–B6 解讀 + 誠信	20%	四步驟正確、虛無結果解讀恰當、報告 + AI 聲明

常見扣分 用事後 power 解釋不顯著、把 $p > .05$ 當『沒差異』、樣本數沒含流失、報告缺效應量/CI。