

單元 8 · 進階量化分析與因果推論 · Research Methodology

因果推論

Causal Inference — 從『有關聯』走向『是不是因為它』：用觀察資料估計因果效應

涵蓋：潛在結果與反事實 · 因果圖 DAG · 傾向分數/IPTW · 工具變數 · 差異中差異 · 敏感度分析

實例：用電子病歷估計『某數位介入是否真的降低再住院』的因果效應

先修：8.1 迴歸 · 8.2 進階模型 · 銜接：9.3 標的試驗仿真 · 9.4 RCT · 建議學期：S1

課程地圖 Course Map

從『相關』一路走到『用觀察資料估計因果效應』

部分	主題	你會學到
Section 1	因果的語言	潛在結果、反事實、平均處理效果 ATE、干擾
Section 2	因果圖 DAG	干擾/中介/對撞、該調什麼、對撞偏誤
Section 3	觀察資料的因果方法	傾向分數/IPTW、工具變數、差異中差異、RDD、中斷時間序列
Section 4	假設、敏感度 + 實例	可交換性/正性/一致性、E-value、實例 + 作業

教學重點 一句話抓重點：8.1 的迴歸調整能估『調整後的關聯』，但關聯不等於因果。這一課給你一套『因果的語言與工具』——用潛在結果框架把因果問題講清楚、用 DAG 決定該調整什麼、用傾向分數/IV/DiD 等方法從觀察資料估計因果效應，並誠實面對它的假設。這是 9.3 標的試驗仿真、9.5 醫療 AI 因果解讀的方法根基。

為什麼需要因果推論？

決策需要『因果』，但我們常只有觀察資料

相關 $\neq$ 因果

- 冰淇淋銷量與溺水人數正相關
- 但不是冰淇淋造成溺水（共同原因：夏天）
- 用某 App 者較健康 → 是 App 有效，
還是『本來較自律的人才會用 App』？
- 干擾與自我選擇讓關聯不等於因果

但決策需要因果

- 『該不該推廣這個 App?』是因果問題
- 隨機試驗(9.4)是黃金標準，但常不可行
- 多數時候只有觀察資料（EHR、健保）
- 需要方法，從觀察資料逼近因果
- 這正是因果推論在做的事

教學重點 核心張力：政策與臨床決策要的是『因果』（做這件事會不會讓結果變好），但隨機試驗(9.4)常因倫理、成本、時效不可行，我們手上多半只有觀察資料。因果推論就是一套『在沒有隨機化的情況下，盡可能逼近因果效應』的框架與方法——它不能取代 RCT 的嚴謹，但能讓觀察資料的因果宣稱站得更穩。

1

SECTION 1

因果的語言

Potential Outcomes

對應：反事實·ATE·干擾

要談因果，先要有精確的語言。潛在結果框架把『因果效應』
定義成『同一個人，做與不做的結果差異』——雖然看不到兩者。

潛在結果與反事實：因果的精確定義

每個人都有『做』與『不做』兩個潛在結果

核心概念

- 每個人有兩個潛在結果：
 $Y(1)$ = 用 App 的結果、 $Y(0)$ = 沒用的結果
- 個人因果效應 = $Y(1) - Y(0)$
- 但你只觀察得到其中一個（他做了或沒做）
→ 另一個是『反事實』，永遠看不到

因果推論的根本難題

- 看不到同一個人的『反事實』
→ 無法直接算個人因果效應
- 退而求其次：估『平均處理效果 ATE』
= 全體 $Y(1)$ 平均 - $Y(0)$ 平均
→ 靠『可比的對照組』來估反事實

教學重點 因果的精確語言：一個人的因果效應是『他用 App 的結果』減『他沒用的結果』——但同一個人不可能同時做與不做，總有一個是看不到的『反事實』。這就是因果推論的根本難題。解法是找『可比的對照組』來代表那個看不到的反事實，估計『平均處理效果(ATE)』。整個因果推論，都是在想辦法讓對照組『真的可比』。

干擾：讓對照組『不可比』的元兇

隨機化為何是黃金標準

問題

- 觀察資料裡，用 App 者和沒用者本來就不同
(年齡、病情、動機...都不同)
- 兩組『不可比』，對照組估不準反事實
- 這些『同時影響用不用 App 與結果』的因子，就是干擾
- 直接比較 = 混入干擾的假效果

隨機化的魔力 (接 9.4)


- 隨機分組讓兩組『平均而言可比』
→ 連沒量到的干擾都平衡
- 對照組能正確代表反事實
- 這是 RCT 為何是黃金標準
- 觀察研究要用方法『模仿』這種可比性

教學重點 為什麼隨機化這麼珍貴：它讓介入組與對照組在基線上『平均可比』——連你想不到、沒量到的干擾也一起平衡。這樣對照組就能正確代表介入組『若沒介入會如何』(反事實)。觀察資料沒有這個奢侈，兩組本來就不同。因果推論的所有方法(Section 3)，本質上都是在『設法讓兩組變得可比』，以逼近隨機化的效果。

干擾：一張三角圖看懂

同時影響『介入』與『結果』的第三變項

干擾同時影響 X 與 Y → 不調整就會把「C 的效果」誤算成「X 的效果」



例：病情較重的人 (C) 比較會被給新藥 (X)，也比較容易惡化 (Y)

教學重點 干擾必須調整；判斷依據是因果知識與 DAG，不是看 p 值挑變數。

2

SECTION 2

因果圖 DAG

Causal Diagrams

對應：干擾/中介/對撞

DAG (有向無環圖) 用箭頭畫出變數間的因果關係。

它的最大用處：告訴你『該調整什麼、絕不能調什麼』。

DAG：用箭頭畫因果，決定該調什麼

三種角色，處理方式完全不同

角色	是什麼	要不要調整
干擾 Confounder	同時→暴露、→結果（共同原因）	要調整（否則假關聯）
中介 Mediator	暴露→它→結果（因果路徑上）	不要調（會抵消真實效果）
對撞 Collider	暴露→它←結果（共同結果）	絕不能調（調了製造假關聯）


教學重點 DAG 的核心價值：它讓『該調整哪些變數』從『把能想到的都丟進去』變成『有原則的判斷』。三種角色：①干擾（共同原因）要調——不調會有假關聯；②中介（在因果路徑上）不能調——調了會把真實效果抵掉；③對撞（共同結果）絕不能調——一調反而『製造』出假關聯。分辨這三者，是正確因果分析的前提，也是 8.1 迴歸調整最容易出錯的地方。

DAG：什麼該調、什麼千萬別調

干擾要調、中介不調、對撞絕對不能調


干擾 Confounder

→ 要調整




中介 Mediator

→ 不要調整



對撞 Collider

→ 千萬別調



教學重點 把 DAG 畫出來再決定共變量清單——這是計畫書與方法章應該附的一張圖。

對撞偏誤：為什麼多調一個變數反而製造偏誤

一個反直覺、卻常見的陷阱

對撞是什麼

- 對撞=兩個變數的『共同結果』
暴露 → 對撞 ← 結果
- 例：住院（對撞）受『疾病 A』與『疾病 B』
共同影響
- 在一般人群中 A、B 無關
- 但『只看住院病人』會讓 A、B 產生假關聯

為什麼危險


- 『控制/選在對撞上』會開啟假路徑
- 例：只研究住院者（選在對撞上）
→ 憑空冒出關聯（Berkson 偏誤，接 9.3）
- 所以不是『調越多變數越好』
- 要靠 DAG 判斷，別亂調

教學重點 最反直覺的一課：多調一個變數有時不是更嚴謹，而是製造偏誤。若你不小心『控制』或『選樣在對撞變數上』（如只研究住院病人），會讓原本無關的兩個因子憑空產生關聯（這就是 9.3 提過的 Berkson 偏誤）。這證明了『把所有變數丟進迴歸』是危險的——你需要 DAG 來判斷每個變數是干擾、中介還是對撞，再決定調不調。


對撞偏誤實例：選樣之後憑空出現的負相關

本來無關的兩件事，看起來相關了

全體：X 與 Y 本來無關 ($r \approx 0$)



只看 K 高的人 (調了對撞) → 出現假負相關



教學重點 常見情境：只分析住院病人、只看有回覆者——這類『選樣』本身就是在調對撞。

3

SECTION 3

觀察資料的因果方法

Methods for Observational Data

對應：傾向分數 · IV · DiD · ITS

有了框架與 DAG，這一部給你實際的工具——
從觀察資料中，設法讓兩組可比、逼近因果效應。

傾向分數：配對、分層與 IPTW 怎麼做

把多個干擾壓成一個分數 (接 9.3)

怎麼做

- 傾向分數 = 『在既有特徵下會接受介入』的機率
- 用邏輯迴歸(8.1)估這個機率
- 用法：配對、分層、或加權(IPTW)
- 讓介入組與對照組的『基線分布』趨近
- 模仿隨機化的可比性

IPTW 與檢查


- IPTW：用傾向分數的倒數加權，
建立一個『兩組可比』的擬似母體
- 務必檢查：配對/加權後，兩組基線特徵的
標準化差異 < 0.1 (平衡診斷)
- 限制：只能平衡『量到』的干擾
- 未量到的干擾仍在 (接敏感度分析)

教學重點 傾向分數是觀察性因果最常用的工具 (接 9.3)：把一堆干擾因子壓成一個『會被給予介入的機率』，再用配對或加權 (IPTW) 讓兩組的基線特徵分布趨近——模仿隨機化的可比性。做完一定要秀『平衡診斷』(加權後兩組基線標準化差異 < 0.1)，否則沒調好。但它的天花板和迴歸一樣：只能平衡『量到的』干擾，未量到的仍在，所以要搭配敏感度分析(Section 4)。

平衡診斷圖：用 SMD 證明兩組可比

配對或加權後，基線特徵應該要接近

傾向分數配對的目標：讓兩組基線特徵「看起來像隨機分派」



教學重點 報告 PS 分析一定要附平衡圖(SMD < 0.1)；沒有平衡證據，後面的效果估計就沒有說服力。

工具變數、差異中差異、斷點迴歸

當有『自然實驗』或『政策變動』時的利器


方法	核心想法	何時用 關鍵識別假設
工具變數 IV	找一個只透過暴露影響結果的『工具』	有好工具、疑有未量干擾時 假設：①相關性（Z 影響 X）②外生性（Z 與未量干擾無關）③排除限制（Z 只透過 X 影響 Y） 估到的是『順從者』的局部效果 LATE
差異中差異 DiD	比較『政策前後』介入組與對照組的變化差	有政策 / 制度變動、有對照組 假設：平行趨勢——若無介入，兩組的變化趨勢會一致 須以介入前多期資料檢視趨勢是否平行
斷點迴歸 RDD	在『門檻兩側』比較（如分數剛好過關與否）	分派依一個連續門檻決定 假設：連續性——門檻兩側除分派外無其他跳躍 估到的是『門檻附近』的效果，不宜外推

教學重點 這三種都是借『自然實驗』逼近隨機化，但每一種都靠一條無法迴避的識別假設：IV 要同時滿足相關性、外生性與排除限制，且估到的只是順從者的局部效果（LATE）；DiD 靠平行趨勢，必須用介入前的多期資料證明；RDD 靠連續性，且估計值只適用門檻附近。假設沒交代，估計值就沒有因果意義。


三種準實驗設計：DID、RDD、IV

沒有隨機分派時，借助『自然實驗』


差異中差異 DID



斷點迴歸 RDD



工具變數 IV




教學重點 三者各有關鍵假設：DID 要平行趨勢、RDD 要門檻附近可比、IV 要滿足排除限制。

中斷時間序列 ITS：只有一組序列時怎麼估

用『導入前後的趨勢斷點』估效果——沒有對照組也能做

分段迴歸估的三件事



關鍵假設與資料要求

- 假設：若無導入，導入前的趨勢會原樣延續（圖中虛線即此反事實）
- 導入前需足夠的時間點，慣例 8–12 個
- 須處理序列自相關與季節性
- 同期若有其他政策變動，就分不開
- 有可比對照組時，改用 DiD 更穩（前頁）

教學重點 ITS 與 DiD 的分工：只有一組序列但有很多期資料時用 ITS，有可比對照組時用 DiD。案例 Q 導入前只有 2 個月、前趨勢估不準，故 ITS 只列為敏感度分析——資料撐不起假設時，方法再對也不能用。

標的試驗仿真：把觀察分析當成『模仿 RCT』

整合前面所有工具的統整框架 (接 9.3)

核心精神

- 先想像『理想的 RCT 會怎麼設計』
 - 再用觀察資料一步步『模仿』它
 - 明確納入條件、治療策略、時間零點
 - 新使用者設計 + 傾向分數讓兩組可比
- 拆掉不死時間、盛行使用者等偏誤

為什麼有效

- 強迫你事先把因果問題的設計講清楚
 - 自動避開常見的觀察性偏誤
 - 整合 DAG (選干擾) + 傾向分數 (可比)
 - + 明確時間軸
- 當代觀察性因果的最佳實務 (接 9.3)

教學重點 標的試驗仿真 (接 9.3) 是把前面工具整合起來的統整框架：先想像『如果能做 RCT，會怎麼設計』(納入、治療策略、時間零點、結果)，再用觀察資料模仿。它強迫你把因果問題的設計事先講清楚，自然避開不死時間、盛行使用者等觀察性偏誤，並整合 DAG (決定調什麼) 與傾向分數 (讓兩組可比)。這是目前用 EHR/健保資料做因果最被推崇的做法。

4

SECTION 4

假設、敏感度與實例

Assumptions & a Worked Example

因果宣稱能不能信，取決於假設

所有觀察性因果方法都建立在『假設』上。

這一部教你三大假設、如何用敏感度分析誠實面對，並看一個實例。

三大因果假設：方法有效的前提

違反了，再漂亮的估計也不可信

假設	意思	現實
可交換性	在調整干擾後，兩組『可比』（無未量干擾）	最強、也最難保證的假設
正性 Positivity	每種人都有機會接受/不接受介入	某類人全都用/全不用 → 無法比較
一致性 Consistency	介入定義明確、你觀察到的即該處理	『使用 App』要定義清楚

教學重點 因果推論的『免責聲明』：所有從觀察資料估因果的方法，都靠三個假設。①可交換性（無未量干擾）——最關鍵也最無法驗證，你永遠不能證明『沒有沒量到的干擾』；②正性——每種人都可能接受或不接受介入（否則無從比較）；③一致性——介入要定義明確。這也是為什麼觀察性因果永遠比 RCT 弱一階——它的因果宣稱『條件於這些無法完全驗證的假設』。

敏感度分析：誠實面對『未量到的干擾』

不能證明沒有，但能問『要多強才會翻盤』

E-value 的想法

- 可交換性無法驗證 → 總有殘餘干擾疑慮
 - E-value：一個『未量到的干擾』要強到什麼程度，才能把你觀察到的效應解釋掉
 - E-value 越大 → 結論對未量干擾越穩健
- 把『我沒法排除干擾』量化

實務用法

- 報告點估計與 E-value
 - E-value 大 (需要很強的干擾才能翻盤)
→ 結論較可信
 - 搭配多種方法(PS、IV、DiD)交叉驗證
- 誠實勝於過度宣稱 (接 7.2)

教學重點 面對『你不能證明沒有未量干擾』這個死結，正確的態度不是假裝沒有，而是量化它。E-value 回答：『一個沒被你調整到的干擾因子，要跟暴露和結果都關聯到多強，才能把你看到的效應完全解釋掉？』——需要的干擾越強 (E-value 越大)，你的因果結論就越穩健。搭配多種方法交叉驗證，並誠實報告假設與敏感度，是觀察性因果研究的良心 (接 7.2)。

實例：用 EHR 估某數位介入的因果效應

把 Section 1–3 串起來

步驟	這個分析怎麼做	對應
設計	標的試驗仿真：新使用者、明確時間零點	Section 3
畫 DAG	辨識干擾（年齡/病情）、避開中介與對撞	Section 2
讓兩組可比	傾向分數 IPTW，查基線平衡 <0.1	Section 3
估效應	加權後比較，得因果效應估計 + CI	Section 1 ATE
敏感度	報 E-value、多方法交叉驗證	Section 4

教學重點 看整條路：①用標的試驗仿真把設計講清楚（避開時間相關偏誤）；②畫 DAG 辨識該調的干擾、避開中介與對撞；③用傾向分數 IPTW 讓兩組可比並查平衡；④估計因果效應(ATE)與信賴區間；⑤用 E-value 與多方法交叉驗證誠實面對殘餘干擾。這樣得到的是『在明確假設下的因果估計』——比單純迴歸調整強，但仍弱於 RCT(9.4)。

用 AI 的界線 + 本課總覽

方法會算，判斷『誰是干擾』靠你

用 AI：可以/不可以

- ✓ 請 AI 寫傾向分數/IPTW/DiD 的程式
- ✓ 請 AI 幫忙畫 DAG 草稿供你確認
- ✓ 請 AI 算 E-value、做平衡診斷
- X 讓 AI 『決定』哪些是干擾（需領域知識）
- X 把調整後關聯直接當因果宣稱

本課總覽

- 因果 = $Y(1) - Y(0)$ ；難題是看不到反事實
 - DAG 決定該調什麼（干擾）、別調什麼（中介/對撞）
 - 方法：傾向分數/IPTW、IV、DiD、標的試驗
 - 假設（可交換/正性/一致）+ E-value
- 誠實的因果，弱於 RCT 但強於裸關聯

教學重點 帶走一句話：因果推論不是『魔法把關聯變因果』，而是一套『在明確假設下，盡可能逼近因果』的紀律。核心是——用潛在結果講清楚問題、用 DAG 決定調整、用傾向分數/IV/DiD 讓兩組可比、並用敏感度分析誠實面對未量干擾。它是 9.3(RWE)、9.5（醫療 AI 因果解讀）的方法根基；但永遠記得，它的結論條件於無法完全驗證的假設。



作業

帶回家作業 Take-home Assignment

Reason About Causes

Part A 觀念題 · Part B 實作題 (附參考答案)

作業目標：能用潛在結果與 DAG 分析因果問題、選對方法，
並誠實評估假設與未量干擾。

作業說明與繳交

建議 2-3 頁；重點是因果思維，不是背名詞

形式與繳交

- 形式：一份因果分析規劃(PDF/Word)
- 篇幅：Part A 每題 3-5 句；Part B 完整規劃
- 可畫 DAG、平衡診斷示意
- 獨立完成；可用 AI 協助但需自行核對並揭露
- 繳交期限：兩週後上課前

評分重點

- 潛在結果/反事實理解 (20%)
- DAG：干擾/中介/對撞判斷 (25%)
- 方法選擇合理 (20%)
- 假設與敏感度 (E-value) (20%)
- 關聯 vs 因果的誠實 (15%)

情境 (Part B 共用)：你想用醫院 EHR 估計『一個遠距監測 App 是否降低心衰竭病人一年死亡』。

教學重點 寫作提醒：每個調整決定都要能對應到 DAG 上的角色 (干擾/中介/對撞)。老師看的是你能不能用因果框架思考、選對方法，並誠實說明『這條因果結論靠哪些假設』。

四題觀念題（每題 3–5 句）

用你的話講清楚

A1

用『潛在結果/反事實』說明為什麼『相關不等於因果』，以及隨機化為何是黃金標準。

A2

干擾、中介、對撞在 DAG 上各是什麼？各該不該調整？各舉一例。

A3

傾向分數(IPTW)在做什麼？它的最大限制是什麼？

A4

可交換性假設為何無法驗證？E-value 如何幫你誠實面對它？

教學重點 提示：A1 想反事實看不到、隨機化平衡未量干擾；A2 想共同原因/因果路徑/共同結果；A3 想讓兩組可比、只調量到的；A4 想無未量干擾不可證、E-value 量『要多強才翻盤』。

規劃一個 EHR 因果分析

遠距監測 App × 心衰竭一年死亡

針對此問題，請完成：

- B1 用潛在結果框架寫出你要估的因果效應是什麼。
- B2 畫（或文字描述）一個簡單 DAG：列出至少一個干擾、一個中介、一個對撞。
- B3 你會用什麼方法讓兩組可比？會做什麼檢查？
- B4 列出你的三個因果假設，並指出哪個最可能被違反。
- B5 你會怎麼誠實面對『未量到的干擾』？結論能說到多強？

教學重點 重點：B1 用 App vs 不用的一年死亡差(ATE);B2 干擾（疾病嚴重度）、中介（遵從/自我監測）、對撞（是否住院）;B3 傾向分數 IPTW + 平衡診斷、或標的試驗仿真；B4 可交換性最脆弱；B5 E-value + 多方法，只能說『在假設下的因果估計』。

想更深入可以看這些

經典教材與方法

主題	來源
因果框架	Hernán & Robins, Causal Inference: What If (免費線上)
DAG	Pearl, Causality; Pearl & Mackenzie, The Book of Why
方法	傾向分數(Austin 2011)、IPTW、工具變數、DiD、RDD
標的試驗仿真	Hernán & Robins (2016) Using Big Data to Emulate a Target Trial (接 9.3)
敏感度	E-value(VanderWeele & Ding, 2017)
健康應用	接 9.3 觀察性/RWE、9.4 RCT、9.5 醫療 AI 因果解讀

教學重點 這一課是單元 8 的核心橋樑：把 8.1/8.2 的『調整後關聯』提升為『有原則的因果估計』，並直接支撐 9.3 (標的試驗仿真、RWE)、9.4 (RCT 為因果黃金標準的理由)、9.5 (醫療 AI 的因果與偏誤)。下一課 8.4 教你用可重現的方式，把這些分析實際跑出來。



因果推論 · Causal Inference

從『有關聯』走向『是不是因為它』

潛在結果 · DAG 決定調什麼 · 傾向分數/IV/DiD · 敏感度 E-value

反事實 · 干擾/中介/對撞 · 標的試驗仿真 · 假設不可全驗 · 弱於 RCT 但強於裸關聯

案例應用：沒有隨機化，還能講因果嗎

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

本單元教了什麼

DAG、差異中之差異、中斷時間序列與傾向分數配對，以及多方法交叉驗證。

②

案例怎麼用

- 先畫 DAG：機構、職類組成、資訊化程度均為導入與結果之共同原因。
- DiD 估計 -4.76 分鐘 (95% CI $[-7.18, -2.35]$ 、 $p < .001$)，以人員叢集校正標準誤。
- 檢驗平行趨勢：導入前兩機構之時間趨勢差異 $b = -0.14$ 、 $p = .871$ ，假設可接受。
- 傾向分數配對 18 對 (caliper 0.20)，配對後組間差 -3.79 分鐘 ($p = .045$)。
- ITS 水準變化 -4.97 分鐘 ($p < .001$)；四法估計介於 -3.79 至 -5.37 ，方向一致。

③

產出什麼證據

DAG 一張與四法估計對照表 (次頁)，納入論文第四章第六節之敏感度分析。

④

承接關係

上游：承自 8.2 之 ICC 與 Kaplan-Meier 曲線 | 下游：交棒 8.4，把整套分析做成可一鍵重跑的專案。

教學重點 四種方法給出四個略有不同的數字，這不是問題，反而是證據：如果換一種假設就翻盤，結論本來就不該相信。

示範產物：四法估計對照與敏感度判讀

估計值由大到小排列；差異來源即為各方法所處理與未處理的偏誤

方法	估計值	所處理之偏誤	未處理者
單純前後測 (A 機構)	-5.37 分鐘	個人固定差異	同期政策變動、季節效應、學習曲線
中斷時間序列 (ITS)	-4.97 分鐘	個人固定差異 + 導入前既有趨勢	導入前僅 2 個月，前趨勢估不準
差異中之差異 (DiD)	-4.76 分鐘	個人固定差異 + 同期共同衝擊	兩機構趨勢若不同；平行趨勢須另行檢驗
傾向分數配對	-3.79 分鐘	可觀測之組間組成差異 (職類、年資、負荷)	未觀測之干擾 (如資訊化程度、主管支持度)
平行趨勢檢驗	$b = -0.14$ 、 $p = .871$	—	導入前趨勢無顯著差異，支持 DiD 之假設
結論	-3.79 至 -5.37 分鐘	—	四法方向一致；以事前指定的 DiD 為主要估計，其餘列為敏感度分析

教學重點 論文該報哪一個數字？應在看到結果之前就指定主要估計方法——本案例選 DiD，因為它針對本設計最主要的威脅（非隨機導入）——其餘全部列進敏感度分析。看完結果才挑最好看的那個報，是審查者最常抓到的問題。