

單元 8 · 進階量化分析與因果推論 · Research Methodology

因果推論

Causal Inference — 從『有關聯』走向『是不是因為它』:用觀察資料估計因果效應

涵蓋：潛在結果與反事實 · 因果圖 DAG · 傾向分數/IPTW · 工具變數 · 差異中差異 · 敏感度分析

實例：用電子病歷估計『某數位介入是否真的降低再住院』的因果效應

先修：8.1 迴歸 · 8.2 進階模型 · 銜接：9.3 標的試驗仿真 · 9.4 RCT · 建議學期：S1

課程地圖 Course Map

從『相關』一路走到『用觀察資料估計因果效應』

部分	主題	你會學到
Part 1	因果的語言	潛在結果、反事實、平均處理效果 ATE、干擾
Part 2	因果圖 DAG	干擾/中介/對撞、該調什麼、對撞偏誤
Part 3	觀察資料的因果方法	傾向分數/IPTW、工具變數、差異中差異、RDD
Part 4	假設、敏感度 + 實例	可交換性/正性/一致性、E-value、實例 + 作業

教學重點 一句話抓重點:8.1 的迴歸調整能估『調整後的關聯』,但關聯不等於因果。這一課給你一套『因果的語言與工具』——用潛在結果框架把因果問題講清楚、用 DAG 決定該調整什麼、用傾向分數/IV/DiD 等方法從觀察資料估計因果效應,並誠實面對它的假設。這是 9.3 標的試驗仿真、9.5 醫療 AI 因果解讀的方法根基。

為什麼需要因果推論?

決策需要『因果』,但我們常只有觀察資料

相關 $\neq$ 因果

- 冰淇淋銷量與溺水人數正相關
- 但不是冰淇淋造成溺水(共同原因:夏天)
- 用某 App 者較健康 → 是 App 有效,
還是『本來較自律的人才會用 App』?
- 干擾與自我選擇讓關聯不等於因果

但決策需要因果

- 『該不該推廣這個 App?』是因果問題
- 隨機試驗(9.4)是黃金標準,但常不可行
- 多數時候只有觀察資料(EHR、健保)
- 需要方法,從觀察資料逼近因果
- 這正是因果推論在做的事

教學重點 核心張力:政策與臨床決策要的是『因果』(做這件事會不會讓結果變好),但隨機試驗(9.4)常因倫理、成本、時效不可行,我們手上多半只有觀察資料。因果推論就是一套『在沒有隨機化的情況下,盡可能逼近因果效應』的框架與方法——它不能取代 RCT 的嚴謹,但能讓觀察資料的因果宣稱站得更穩。

1

PART 1

因果的語言

Potential Outcomes

對應：反事實・ATE・干擾

要談因果,先要有精確的語言。潛在結果框架把『因果效應』
定義成『同一個人,做與不做的結果差異』——雖然看不到兩者。

潛在結果與反事實:因果的精確定義

每個人都有『做』與『不做』兩個潛在結果

核心概念

- 每個人有兩個潛在結果:
 $Y(1)$ = 用 App 的結果、 $Y(0)$ = 沒用的結果
- 個人因果效應 = $Y(1) - Y(0)$
- 但你只觀察得到其中一個(他做了或沒做)
- 另一個是『反事實』,永遠看不到

因果推論的根本難題

- 看不到同一個人的『反事實』
- 無法直接算個人因果效應
- 退而求其次:估『平均處理效果 ATE』
= 全體 $Y(1)$ 平均 - $Y(0)$ 平均
- 靠『可比的對照組』來估反事實

教學重點 因果的精確語言:一個人的因果效應是『他用 App 的結果』減『他沒用的結果』——但同一個人不可能同時做與不做,總有一個是看不到的『反事實』。這就是因果推論的根本難題。解法是找『可比的對照組』來代表那個看不到的反事實,估計『平均處理效果(ATE)』。整個因果推論,都是在想辦法讓對照組『真的可比』。

干擾:讓對照組『不可比』的元兇

隨機化為何是黃金標準

問題

- 觀察資料裡,用 App 者和沒用者本來就不同
(年齡、病情、動機...都不同)
- 兩組『不可比』,對照組估不準反事實
- 這些『同時影響用不用 App 與結果』的
因子,就是干擾
- 直接比較 = 混入干擾的假效果

隨機化的魔力(接 9.4)


- 隨機分組讓兩組『平均而言可比』
→ 連沒量到的干擾都平衡
- 對照組能正確代表反事實
- 這是 RCT 為何是黃金標準
- 觀察研究要用方法『模仿』這種可比性

教學重點 為什麼隨機化這麼珍貴:它讓介入組與對照組在基線上『平均可比』——連你想不到、沒量到的干擾也一起平衡。這樣對照組就能正確代表介入組『若沒介入會如何』(反事實)。觀察資料沒有這個奢侈,兩組本來就不同。因果推論的所有方法(Part 3),本質上都是在『設法讓兩組變得可比』,以逼近隨機化的效果。

干擾:一張三角圖看懂

同時影響『介入』與『結果』的第三變項

干擾同時影響 X 與 Y → 不調整就會把「C 的效果」誤算成「X 的效果」



例：病情較重的人 (C) 比較會被給新藥 (X)，也比較容易惡化 (Y)

教學重點 干擾必須調整;判斷依據是因果知識與 DAG,不是看 p 值挑變數。

2

PART 2

因果圖 DAG

Causal Diagrams

對應：干擾/中介/對撞

DAG(有向無環圖)用箭頭畫出變數間的因果關係。

它的最大用處:告訴你『該調整什麼、絕不能調什麼』。

DAG:用箭頭畫因果,決定該調什麼

三種角色,處理方式完全不同

角色	是什麼	要不要調整
干擾 Confounder	同時→暴露、→結果(共同原因)	要調整(否則假關聯)
中介 Mediator	暴露→它→結果(因果路徑上)	不要調(會抵消真實效果)
對撞 Collider	暴露→它←結果(共同結果)	絕不能調(調了製造假關聯)


教學重點 DAG 的核心價值:它讓『該調整哪些變數』從『把能想到的都丟進去』變成『有原則的判斷』。三種角色:①干擾(共同原因)要調——不調會有假關聯;②中介(在因果路徑上)不能調——調了會把真實效果抵掉;③對撞(共同結果)絕不能調——一調反而『製造』出假關聯。分辨這三者,是正確因果分析的前提,也是 8.1 迴歸調整最容易出錯的地方。

DAG:什麼該調、什麼千萬別調

干擾要調、中介不調、對撞絕對不能調


干擾 Confounder

→ 要調整




中介 Mediator

→ 不要調整



對撞 Collider

→ 千萬別調



教學重點 把 DAG 畫出來再決定共變量清單——這是計畫書與方法章應該附的一張圖。

對撞偏誤：『調錯變數』反而製造假關聯

一個反直覺、卻常見的陷阱

對撞是什麼

· 對撞=兩個變數的『共同結果』

暴露 → 對撞 ← 結果

例:住院(對撞)受『疾病 A』與『疾病 B』

共同影響

· 在一般人群中 A、B 無關

→ 但『只看住院病人』會讓 A、B 產生假關聯

為什麼危險

· 『控制/選在對撞上』會開啟假路徑

例:只研究住院者(選在對撞上)

→ 憑空冒出關聯(Berkson 偏誤,接 9.3)

· 所以不是『調越多變數越好』


→ 要靠 DAG 判斷,別亂調

教學重點 最反直覺的一課:多調一個變數有時不是更嚴謹,而是製造偏誤。若你不小心『控制』或『選樣在對撞變數上』(如只研究住院病人),會讓原本無關的兩個因子憑空產生關聯(這就是 9.3 提過的 Berkson 偏誤)。這證明了『把所有變數丟進迴歸』是危險的——你需要 DAG 來判斷每個變數是干擾、中介還是對撞,再決定調不調。


對撞偏誤:調錯變數會製造假關聯

本來無關的兩件事,選樣後看起來相關

全體: X 與 Y 本來無關 ($r \approx 0$)



只看 K 高的人 (調了對撞) → 出現假負相關



教學重點 常見情境:只分析住院病人、只看有回覆者——這類『選樣』本身就是在調對撞。

3

PART 3

觀察資料的因果方法

Methods for Observational Data

對應：傾向分數 · IV · DiD

有了框架與 DAG,這一部給你實際的工具——
從觀察資料中,設法讓兩組可比、逼近因果效應。

傾向分數:讓兩組在基線上『可比』

把多個干擾壓成一個分數(接 9.3)

怎麼做

- 傾向分數 = 『在既有特徵下會接受介入』的機率
- 用邏輯迴歸(8.1)估這個機率
- 用法:配對、分層、或加權(IPTW)
- 讓介入組與對照組的『基線分布』趨近
- 模仿隨機化的可比性

IPTW 與檢查


- IPTW:用傾向分數的倒數加權,建立一個『兩組可比』的擬似母體
- 務必檢查:配對/加權後,兩組基線特徵的標準化差異 < 0.1 (平衡診斷)
- 限制:只能平衡『量到』的干擾
- 未量到的干擾仍在(接敏感度分析)

教學重點 傾向分數是觀察性因果最常用的工具(接 9.3):把一堆干擾因子壓成一個『會被給予介入的機率』,再用配對或加權(IPTW)讓兩組的基線特徵分布趨近——模仿隨機化的可比性。做完一定要秀『平衡診斷』(加權後兩組基線標準化差異 < 0.1),否則沒調好。但它的天花板和迴歸一樣:只能平衡『量到的』干擾,未量到的仍在,所以要搭配敏感度分析(Part 4)。

傾向分數:用平衡圖證明兩組可比

配對或加權後,基線特徵應該要接近

傾向分數配對的目標：讓兩組基線特徵「看起來像隨機分派」



教學重點 報告 PS 分析一定要附平衡圖(SMD < 0.1);沒有平衡證據,後面的效果估計就沒有說服力。

工具變數、差異中差異、斷點迴歸

當有『自然實驗』或『政策變動』時的利器


方法	核心想法	何時用
工具變數 IV	找一個只透過暴露影響結果的『工具』	有好的工具、疑有未量干擾時
差異中差異 DiD	比較『政策前後』介入組與對照組的變化差	有政策/制度變動、有對照組
斷點迴歸 RDD	在『門檻兩側』比較(如分數剛好過關與否)	分派依一個連續門檻決定

教學重點 這三種利用『自然實驗』:①工具變數(IV)找一個『只透過暴露影響結果』的變數(如政策、距離),能對付『未量到的干擾』,但好工具難找;②差異中差異(DiD)比較政策前後,介入組與對照組的『變化差異』,消掉不隨時間變的干擾;③斷點迴歸(RDD)利用『剛好過門檻與否』近似隨機。當你有政策變動、門檻分派或好的工具時,這些能提供比單純調整更強的因果證據。


三種準實驗設計:DID、RDD、IV

沒有隨機分派時,借助『自然實驗』


差異中差異 DID



斷點迴歸 RDD



工具變數 IV



教學重點 三者各有關鍵假設:DID 要平行趨勢、RDD 要門檻附近可比、IV 要滿足排除限制。

標的試驗仿真:把觀察分析當成『模仿 RCT』

整合前面所有工具的統整框架(接 9.3)

核心精神

- 先想像『理想的 RCT 會怎麼設計』
 - 再用觀察資料一步步『模仿』它
 - 明確納入條件、治療策略、時間零點
 - 新使用者設計 + 傾向分數讓兩組可比
- 拆掉不死時間、盛行使用者等偏誤

為什麼有效

- 強迫你事先把因果問題的設計講清楚
 - 自動避開常見的觀察性偏誤
 - 整合 DAG(選干擾) + 傾向分數(可比)
 - + 明確時間軸
- 當代觀察性因果的最佳實務(接 9.3)

教學重點 標的試驗仿真(接 9.3)是把前面工具整合起來的統整框架:先想像『如果能做 RCT,會怎麼設計』(納入、治療策略、時間零點、結果),再用觀察資料模仿。它強迫你把因果問題的設計事先講清楚,自然避開不死時間、盛行使用者等觀察性偏誤,並整合 DAG(決定調什麼)與傾向分數(讓兩組可比)。這是目前用 EHR/健保資料做因果最被推崇的做法。

4

PART 4

假設、敏感度與實例

Assumptions & a Worked Example

因果宣稱能不能信,取決於假設

所有觀察性因果方法都建立在『假設』上。

這一部教你三大假設、如何用敏感度分析誠實面對,並看一個實例。

三大因果假設:方法有效的前提

違反了,再漂亮的估計也不可信

假設	意思	現實
可交換性	在調整干擾後,兩組『可比』(無未量干擾)	最強、也最難保證的假設
正性 Positivity	每種人都有機會接受/不接受介入	某類人全都用/全不用 → 無法比較
一致性 Consistency	介入定義明確、你觀察到的即該處理	『使用 App』要定義清楚

教學重點 因果推論的『免責聲明』:所有從觀察資料估因果的方法,都靠三個假設。①可交換性(無未量干擾)——最關鍵也最無法驗證,你永遠不能證明『沒有沒量到的干擾』;②正性——每種人都可能接受或不接受介入(否則無從比較);③一致性——介入要定義明確。這也是為什麼觀察性因果永遠比 RCT 弱一階——它的因果宣稱『條件於這些無法完全驗證的假設』。

敏感度分析:誠實面對『未量到的干擾』

不能證明沒有,但能問『要多強才會翻盤』

E-value 的想法

- 可交換性無法驗證 → 總有殘餘干擾疑慮
 - E-value: 一個『未量到的干擾』要強到什麼程度,才能把你觀察到的效應解釋掉
 - E-value 越大 → 結論對未量干擾越穩健
- 把『我沒法排除干擾』量化

實務用法

- 報告點估計與 E-value
- E-value 大(需要很強的干擾才能翻盤)
→ 結論較可信
- 搭配多種方法(PS、IV、DiD)交叉驗證
→ 誠實勝於過度宣稱(接 7.2)

教學重點 面對『你不能證明沒有未量干擾』這個死結,正確的態度不是假裝沒有,而是量化它。E-value 回答:『一個沒被你調整到的干擾因子,要跟暴露和結果都關聯到多強,才能把你看到的效應完全解釋掉?』——需要的干擾越強(E-value 越大),你的因果結論就越穩健。搭配多種方法交叉驗證,並誠實報告假設與敏感度,是觀察性因果研究的良心(接 7.2)。

實例:用 EHR 估某數位介入的因果效應

把 Part 1–3 串起來

步驟	這個分析怎麼做	對應
設計	標的試驗仿真:新使用者、明確時間零點	Part 3
畫 DAG	辨識干擾(年齡/病情)、避開中介與對撞	Part 2
讓兩組可比	傾向分數 IPTW,查基線平衡 <0.1	Part 3
估效應	加權後比較,得因果效應估計 + CI	Part 1 ATE
敏感度	報 E-value、多方法交叉驗證	Part 4

教學重點 看整條路:①用標的試驗仿真把設計講清楚(避開時間相關偏誤);②畫 DAG 辨識該調的干擾、避開中介與對撞;③用傾向分數 IPTW 讓兩組可比並查平衡;④估計因果效應(ATE)與信賴區間;⑤用 E-value 與多方法交叉驗證誠實面對殘餘干擾。這樣得到的是『在明確假設下的因果估計』——比單純迴歸調整強,但仍弱於 RCT(9.4)。

用 AI 的界線 + 本課總覽

方法會算,判斷『誰是干擾』靠你

用 AI:可以/不可以

- ✓ 請 AI 寫傾向分數/IPTW/DiD 的程式
- ✓ 請 AI 幫忙畫 DAG 草稿供你確認
- ✓ 請 AI 算 E-value、做平衡診斷
- X 讓 AI 『決定』哪些是干擾(需領域知識)
- X 把調整後關聯直接當因果宣稱

本課總覽

- 因果= $Y(1)-Y(0)$;難題是看不到反事實
 - DAG 決定該調什麼(干擾)、別調什麼(中介/對撞)
 - 方法:傾向分數/IPTW、IV、DiD、標的試驗
 - 假設(可交換/正性/一致) + E-value
- 誠實的因果,弱於 RCT 但強於裸關聯

教學重點 帶走一句話:因果推論不是『魔法把關聯變因果』,而是一套『在明確假設下,盡可能逼近因果』的紀律。核心是——用潛在結果講清楚問題、用 DAG 決定調整、用傾向分數/IV/DiD 讓兩組可比、並用敏感度分析誠實面對未量干擾。它是 9.3(RWE)、9.5(醫療 AI 因果解讀)的方法根基;但永遠記得,它的結論條件於無法完全驗證的假設。



作業

帶回家作業 Take-home Assignment

Reason About Causes

Part A 觀念題 · Part B 實作題 (附參考答案)

作業目標:能用潛在結果與 DAG 分析因果問題、選對方法,
並誠實評估假設與未量干擾。

作業說明與繳交

建議 2-3 頁;重點是因果思維,不是背名詞

形式與繳交

- 形式:一份因果分析規劃(PDF/Word)
- 篇幅:Part A 每題 3-5 句;Part B 完整規劃
- 可畫 DAG、平衡診斷示意
- 獨立完成;可用 AI 協助但需自行核對並揭露
- 繳交期限:兩週後上課前

評分重點

- 潛在結果/反事實理解 (20%)
- DAG:干擾/中介/對撞判斷 (25%)
- 方法選擇合理 (20%)
- 假設與敏感度 (E-value) (20%)
- 關聯 vs 因果的誠實 (15%)

情境 (Part B 共用):你想用醫院 EHR 估計『一個遠距監測 App 是否降低心衰竭病人一年死亡』。

教學重點 寫作提醒:每個調整決定都要能對應到 DAG 上的角色(干擾/中介/對撞)。老師看的是你能不能用因果框架思考、選對方法,並誠實說明『這條因果結論靠哪些假設』。

四題觀念題（每題 3–5 句）

用你的話講清楚

A1

用『潛在結果/反事實』說明為什麼『相關不等於因果』,以及隨機化為何是黃金標準。

A2

干擾、中介、對撞在 DAG 上各是什麼?各該不該調整?各舉一例。

A3

傾向分數(IPTW)在做什麼?它的最大限制是什麼?

A4

可交換性假設為何無法驗證?E-value 如何幫你誠實面對它?

教學重點 提示:A1 想反事實看不到、隨機化平衡未量干擾;A2 想共同原因/因果路徑/共同結果;A3 想讓兩組可比、只調量到的;A4 想無未量干擾不可證、E-value 量『要多強才翻盤』。

規劃一個 EHR 因果分析

遠距監測 App × 心衰竭一年死亡

針對此問題,請完成:

- B1 用潛在結果框架寫出你要估的因果效應是什麼。
- B2 畫(或文字描述)一個簡單 DAG:列出至少一個干擾、一個中介、一個對撞。
- B3 你會用什麼方法讓兩組可比?會做什麼檢查?
- B4 列出你的三個因果假設,並指出哪個最可能被違反。
- B5 你會怎麼誠實面對『未量到的干擾』?結論能說到多強?

教學重點 重點:B1 用 App vs 不用的一年死亡差(ATE);B2 干擾(疾病嚴重度)、中介(遵從/自我監測)、對撞(是否住院);B3 傾向分數 IPTW + 平衡診斷、或標的試驗仿真;B4 可交換性最脆弱;B5 E-value + 多方法,只能說『在假設下的因果估計』。



解答

參考答案 Reference Answers

對答案,更要對『推理』

Part A 觀念 + Part B 規劃要點

先自己做完再看。

比對重點是因果思維與假設意識,不只是名詞。

觀念題參考答案

要點式,實際作答請展開成 3–5 句

題	參考要點
A1	因果效應是同一個人『做』與『不做』的結果差 $Y(1)-Y(0)$,但同一人不可能同時做與不做,總有一個是看不到的『反事實』。相關只看到觀察到的那一半,可能被干擾與自我選擇汙染。隨機化讓兩組『平均可比』(連未量干擾都平衡),使對照組能正確代表反事實,故為黃金標準。
A2	干擾=同時影響暴露與結果的共同原因(如年齡)→要調整;中介=在暴露→結果因果路徑上的中間變數(如自我監測)→不要調(會抵消真實效果);對撞=暴露與結果的共同結果(如住院)→絕不能調或選樣在其上(會製造假關聯,Berkson 偏誤)。
A3	傾向分數=『在既有特徵下會接受介入』的機率;用配對/分層/加權(IPTW)讓介入組與對照組的基線特徵分布趨近,模仿隨機化的可比性,做完要查平衡(標準化差異 <0.1)。最大限制:只能平衡『量到的』干擾,未量到的殘餘干擾仍在,故需敏感度分析。
A4	可交換性=『調整後無未量干擾、兩組可比』,但你永遠無法證明『沒有沒量到的干擾』,故不可驗證。E-value 把這個不確定量化:回答『一個未量干擾要跟暴露與結果都關聯到多強,才能把觀察到的效應完全解釋掉』;E-value 越大,結論對未量干擾越穩健。

規劃參考要點 (示例)

合理即可,重點是因果思維

B1–B3 效應、DAG、方法

B1 因果效應:心衰竭病人『使用 App』vs『不使用』的一年死亡風險差(ATE)。

B2 DAG 例:干擾=疾病嚴重度(EF/NYHA)、共病(→用不用 App、→死亡);中介=遵從/自我監測(App→行為→死亡,不可調);對撞=是否再住院(App 與病情的共同結果,不可調/選樣)。

B3 標的試驗仿真 + 傾向分數 IPTW 讓兩組可比;查加權後基線標準化差異 <0.1(平衡診斷)。

B4–B5 假設與誠實

B4 三假設:可交換性(無未量干擾)、正性(各種病人都有機會用/不用)、一致性(『使用 App』定義明確)。最可能被違反的是『可交換性』——病情嚴重度、社經、健康識能等常量不全。

B5 用 E-value 量『要多強的未量干擾才能翻盤』,並用多種方法(PS、IV 若有工具、DiD)交叉驗證;結論只能說『在上述假設下的因果估計』,不等於 RCT 等級的證據(接 9.4)。

教學重點 沒有唯一標準答案,但好規劃必須:用潛在結果講清楚要估什麼、用 DAG 正確分辨干擾/中介/對撞、用傾向分數或標的試驗仿真讓兩組可比並查平衡、明列三大假設並指出最脆弱者、用 E-value 與多方法誠實面對未量干擾。

想更深入可以看這些

經典教材與方法

主題	來源
因果框架	Hernán & Robins, Causal Inference: What If (免費線上)
DAG	Pearl, Causality; Pearl & Mackenzie, The Book of Why
方法	傾向分數(Austin 2011)、IPTW、工具變數、DiD、RDD
標的試驗仿真	Hernán & Robins (2016) Using Big Data to Emulate a Target Trial (接 9.3)
敏感度	E-value(VanderWeele & Ding, 2017)
健康應用	接 9.3 觀察性/RWE、9.4 RCT、9.5 醫療 AI 因果解讀

教學重點 這一課是單元 8 的核心橋樑:把 8.1/8.2 的『調整後關聯』提升為『有原則的因果估計』,並直接支撐 9.3(標的試驗仿真、RWE)、9.4(RCT 為因果黃金標準的理由)、9.5(醫療 AI 的因果與偏誤)。下一課 8.4 教你用可重現的方式,把這些分析實際跑出來。



因果推論 · Causal Inference

從『有關聯』走向『是不是因為它』

潛在結果 · DAG 決定調什麼 · 傾向分數/IV/DiD · 敏感度 E-value

反事實 · 干擾/中介/對撞 · 標的試驗仿真 · 假設不可全驗 · 弱於 RCT 但強於裸關聯