

單元 8 · 進階量化分析與因果推論 · Research Methodology

資料科學與可重現分析實務

Data Science & Reproducible Analysis — 把分析做成『別人一鍵重跑得出來』的流程

涵蓋：分析工作流程 · R/Python/筆記本 · 整潔資料與清理 · 視覺化 · 版本控制 · AI 輔助程式

實例：一份健康資料的『可重現分析』——從匯入、清理到結果,一鍵重跑

先修：8.1–8.3 · 銜接：7.2 開放科學 · 9.5 醫療 AI · 9.9 報告規範 · 建議學期：S1

課程地圖 Course Map

從『分析工作流程』一路走到『別人一鍵重跑』的可重現分析

部分	主題	你會學到
Part 1	分析工作流程與工具	匯入→整理→建模→溝通;R/Python/筆記本;點按 vs 寫程式
Part 2	整潔資料與清理	tidy data 原則、缺失/型態/重複、資料驗證
Part 3	資料視覺化	探索 vs 溝通、選對圖、誤導圖表
Part 4	可重現分析 + AI	版本控制、種子、環境、可用性聲明、AI 寫程式

教學重點 一句話抓重點:前面三課(8.1–8.3)教你『用什麼模型』;這一課教你『怎麼把分析實際、可靠、可重現地跑出來』。核心是把分析當成一條『可重跑的流程』(匯入→清理→視覺化→建模→溝通),用程式與版本控制記錄每一步——這樣別人(與半年後的你)才能一鍵重現你的結果。這直接呼應 7.2 開放科學與 9.5/9.9 的紀律。

為什麼分析要『可重現』？

很多論文的數字,連原作者半年後都跑不出來

不可重現的日常

- 手動點按分析、沒記步驟
 - 資料路徑寫死、手動改欄位
 - 套件版本更新→結果變了
 - 隨機過程沒固定種子→每次不同
- 換台電腦、過段時間就重現不了

可重現的好處

- 別人能驗證、能延伸你的分析(接 7.2)
 - 自己除錯、更新資料時省時省力
 - 投稿附程式/資料可用性聲明(接 9.9)
 - 是醫療 AI 開發的基本要求(接 9.5)
- 可信、可累積、也保護你自己

教學重點 定位:可重現分析是把 7.2『開放科學』落實到『你實際怎麼跑分析』的一課。最低門檻卻最常破功——很多研究的數字,換台電腦或過段時間就重現不出來,因為是手動操作、沒記步驟、套件更新了。解法是把整個分析寫成『可執行、可重跑的流程』。這不只利他(別人能驗證),也利己(自己除錯與更新超省事)。

1

PART 1

分析工作流程與工具

The Analysis Workflow

對應：R/Python/筆記本

資料分析不是按一個鈕,而是一條有步驟的流程。

先看整條流程與工具選擇,以及『為什麼寫程式勝過點按』。

資料分析的流程:六個步驟

每一步都可能出錯,也都該被記錄

- 1 **匯入 Import** 把資料讀進來(CSV、資料庫、API)
- 2 **整理 Tidy** 整成『每欄一變數、每列一觀測』(Part 2)
- 3 **轉換 Transform** 篩選、計算新變數、合併、聚合
- 4 **視覺化 Visualize** 畫圖探索與呈現(Part 3)
- 5 **建模 Model** 跑統計/機器學習(8.1–8.3、9.5)
- 6 **溝通 Communicate** 報告、圖表、可重現文件

教學重點 分析是一條流程,不是一個動作:匯入→整理→轉換→視覺化→建模→溝通(常在整理/轉換/視覺化間反覆迭代)。理解這條流程有兩個好處:①知道自己在哪一步、下一步做什麼;②每一步都用『程式』記錄下來,整條流程就能被重跑與檢驗。多數時間其實花在前面的『整理與清理』(Part 2),不是建模。

分析流程六步驟:一張圖

原始資料唯讀,一切轉換都靠程式碼



原始資料永遠唯讀：所有清理與轉換都用「程式碼」做，不要手改原檔

每一步都留下程式碼 → 別人（和三個月後的你）才能重跑出同樣結果

教學重點 手動點按改資料無法重現,把每一步寫成程式碼,才有『重跑』的可能。

工具選擇 + 為什麼『寫程式』勝過『點按』

R、Python、筆記本,以及可重現的關鍵

常見工具

- R / RStudio:統計與視覺化強、社群大
 - Python / pandas:通用、機器學習強(接 9.5)
 - Jupyter / R Markdown / Quarto:
把『程式 + 結果 + 文字』寫在一份文件
 - SPSS/Stata:好上手,但多為點按
- 依需求與所在領域選

點按 vs 寫程式

- 點按(手動選單):快,但沒有紀錄、難重現
 - 寫程式:每一步都被『腳本』記錄下來
- 可重跑、可版本控制、可分享
- 可執行筆記本:程式→結果自動連動
- 想可重現,就要『用腳本』而非手動

教學重點 為什麼可重現分析幾乎都用『寫程式』:手動點選單做分析,做完就沒有紀錄,別人(和你自己)無法重現每一步。把分析寫成腳本(R/Python),整個流程就被完整記錄、能一鍵重跑、能用版本控制追蹤。可執行筆記本(Jupyter/Quarto)更把『程式、結果、說明』寫在一起,是可重現報告的利器。點按工具適合快速探索,但正式分析建議用程式。

2

PART 2

整潔資料與清理

Tidy Data & Cleaning

對應：tidy data · 資料驗證

『80% 的分析時間花在清理資料』——這句話一點都不誇張。
先把資料整成『整潔』的結構,分析才順、才不出錯。

整潔資料 Tidy Data:分析友善的結構

Wickham 的三原則

三原則

- 每個『變數』自成一欄
- 每個『觀測』自成一列
- 每種『觀測單位』自成一張表

例:『每人每次測量』一列,

變數(時間、血糖、組別)各一欄

→ 幾乎所有分析工具都愛這種結構

雜亂 → 整潔

常見雜亂:

- 欄名其實是『值』(如把各月份當欄名)
- 一欄塞多個資訊(如『收縮/舒張壓』同格)
- 一張表混多種觀測單位

→ 用『長/寬轉換、拆欄、分表』整理

→ 整潔後,建模與畫圖都變簡單

教學重點 整潔資料(tidy data)是分析的地基:①每欄一個變數、②每列一個觀測、③每張表一種觀測單位。這聽起來理所當然,但真實資料常是雜亂的——欄名其實是數值(如 2020、2021 當欄名)、一格塞兩個資訊、多種單位混一張表。花時間整成整潔結構,後面所有分析(尤其縱貫資料 8.2、畫圖)都會順很多。整潔的資料,長得都很像;雜亂的資料,各有各的亂。

整潔資料 Tidy Data:凌亂 vs 整潔

每列一個觀察、每欄一個變數

凌亂：欄名裡藏著「變數值」（時間點）

姓名	2024前測	2024後測
王小明	52	44
李小華	61	50
陳大同	48	41

× 一列多筆觀察 × 難以分組分析

整潔 Tidy：每列一個觀察、每欄一個變數

姓名	時間點	分數
王小明	前測	52
王小明	後測	44
李小華	前測	61

○ 可直接分組、繪圖、跑混合模型

教學重點 花時間整理成 tidy 格式,後面的分組、繪圖與建模都會變簡單。

資料清理:分析前的必經之路

垃圾進、垃圾出(接 4.3 問卷)

問題	怎麼查/處理	注意
缺失值	看缺失比例與型態、決定處理策略	MCAR/MAR/MNAR;別亂補
資料型態	數字被當文字、日期格式亂	轉成正確型態
重複	找完全或關鍵欄重複	確認是真重複再刪
異常值	範圍檢查、邏輯檢查(如年齡 200)	分辨錯誤 vs 真極端(接 8.1)
一致性	單位、編碼、類別拼寫統一	建立資料字典

教學重點 清理是分析最耗時、卻最被低估的一步:缺失值、型態錯誤、重複、異常值、編碼不一致——每一項都可能悄悄毀掉你的結果。關鍵原則:①用『程式』做清理(而非手動改 Excel),這樣可重現、可追溯;②區分『資料錯誤』與『真實極端值』(別為了好看亂刪,接 8.1);③做『資料驗證』(範圍與邏輯檢查)並建立資料字典。清理做得好,分析才可信。

3

PART 3

資料視覺化

Data Visualization

對應：選對圖・誠實呈現

一張好圖勝過千言萬語,一張爛圖則誤導千人。

這一部教你選對圖、畫清楚、並避開誤導的陷阱。

視覺化的兩個目的 + 選對圖

探索給自己看,溝通給別人看

兩個目的

- 探索(給自己):快速看分布、關係、異常
 - 快就好,不必美
- 溝通(給別人):清楚傳達一個訊息
 - 要精心設計、去蕪存菁
 - 先想清楚『這張圖要回答什麼』

選對圖(依資料型態)

- 分布:直方圖、盒鬚圖
- 比較類別:長條圖
- 趨勢/時間:折線圖
- 關係:散布圖
- 部分佔比:堆疊長條(少用圓餅)
- 圖表型態要配合你要說的事

教學重點 畫圖前先問兩件事:①這是給『自己探索』還是『給別人溝通』?探索圖求快,溝通圖求精。②要說的是『分布、比較、趨勢、還是關係』?——分布用直方/盒鬚、比較用長條、趨勢用折線、關係用散布。選錯圖型,再美也傳達不了訊息。圓餅圖除非只有兩三類、且要強調佔比,否則少用(人眼比長度比角度準)。

誠實的圖表:別讓視覺騙人

同一份資料,畫法不同,印象天差地別

常見誤導手法

- 截斷 Y 軸 → 把小差異放大成巨大
 - 雙 Y 軸 → 硬湊出『相關』的假象
 - 比例失真的面積/3D 圖
 - 挑對自己有利的時間範圍
- 讓讀者得到錯誤印象

好圖的原則

- 座標軸誠實(數量圖多從 0 起)
 - 清楚標示軸、單位、來源
 - 去除干擾(chartjunk)、聚焦訊息
 - 考慮色盲友善與可近性(接 9.7)
- 讓資料自己說話,不誇大


教學重點 圖表倫理:同一份資料,截斷 Y 軸能把 1% 的差距畫成『暴增』、雙 Y 軸能無中生有一個『相關』。這些手法即使不改數字,也會讓讀者得到錯誤印象——這是視覺版的誤導(呼應 7.2 誠信)。好圖的原則:座標軸誠實(量值圖從 0 起)、清楚標示、去除無關裝飾、色盲友善(接 9.7)。目標是讓資料誠實地說話,而不是替你『演』出想要的結論。

誠實的圖表:Y 軸起點的陷阱


同一組資料,兩種完全不同的印象

同一組資料、兩種印象——Y 軸起點是最常見的「誠實問題」

截斷 Y 軸：看起來差很多



從 0 起算：其實差 2.2 分



教學重點 長條圖的 Y 軸原則上從 0 起算;若必須截斷,要明確標示並說明理由。

4

PART 4

可重現分析與 AI 輔助

Reproducible Pipelines & AI

對應：版本控制・種子・環境

把前面所有步驟,組成一條『別人一鍵重跑得出來』的流程。
並談如何用 AI 輔助寫程式——以及它的界線。

打造可重現的分析流程

五個習慣,讓分析『一鍵重跑』

習慣	做什麼	為什麼
用腳本	每一步用程式,而非手動點按	可重跑、可追溯
版本控制	用 Git 記錄每次改動	知道改了什麼、能還原
固定種子	set seed 固定隨機過程	結果每次一致
記錄環境	記套件版本或用容器	換電腦也跑得出來
結構與說明	清楚資料夾 + README + 可用性聲明	別人看得懂、接得上(接 9.9)

教學重點 可重現的五個習慣:①用腳本(不手動);②版本控制(Git,記錄每次改動);③固定亂數種子(結果一致);④記錄環境(套件版本/容器,換電腦也能跑);⑤清楚的資料夾結構 + README + 資料/程式可用性聲明(接 9.9)。理想境界:別人拿到你的資料與程式,執行一個指令,就重現你論文裡『所有』的圖表與數字。這也讓你更新資料、除錯時省下大量時間。

可重現的專案長什麼樣

資料夾結構 + 亂數種子 + 版本控制

專案資料夾/

data_raw/ ← 唯讀，永不修改

data_clean/ ← 由程式產生

code/ 01_clean → 02_analyze → 03_figures

output/ 圖表與報表 (可重跑覆蓋)

README 資料來源、環境、執行順序

固定亂數種子 `set.seed()`

記錄套件版本

版本控制 Git

可重現的定義：別人拿到你的資料夾，

照 README 重跑，能得到一模一樣的數字。

教學重點 檢驗標準:別人拿到你的資料夾,照 README 重跑,能得到一模一樣的數字。

用 AI 寫分析程式的『可以』與『不可以』

AI 是強大的程式助手,但結果要你負責

✓ 該做的

- 請 AI 幫你寫清理/分析/畫圖的程式
 - 請 AI 解釋錯誤訊息、除錯
 - 請 AI 加註解、重構、寫 README
 - 請 AI 依可重現原則檢查你的流程
- 用了 AI 撰寫要揭露(接 1.4/7.2)

✗ 不可以

- 照跑 AI 的程式不看它做了什麼
 - 不核對結果是否合理(AI 會出錯)
 - 讓 AI 用你不理解的方法就寫進論文
 - 把敏感健康資料貼給外部 AI(接 9.11)
- 理解與核對,永遠是你的責任

教學重點 AI 是目前最強的『程式助手』——寫清理與分析程式、除錯、加註解、寫 README,都能大幅加速。但兩條紅線:①你必須『看得懂並核對』AI 寫的程式與結果(AI 會產生看似合理卻錯誤的程式);②絕不能把『可識別的健康資料』貼給外部 AI(洩密,接 9.11)。用 AI 加速『打字與除錯』,但『這個分析對不對、結果合不合理』永遠由你負責。

實例與本課總覽

一份可重現分析長什麼樣

實例:可重現的健康資料分析

- 資料夾: data/ code/ output/ + README
 - 一個腳本: 讀原始資料→清理→整潔→
畫圖→跑迴歸(8.1)→輸出表與圖
 - 固定種子、記錄套件版本
 - 附『資料(去識別)/程式可用性聲明』
- 執行一個指令,重現所有結果

本課總覽

- 分析是流程: 匯入→整理→視覺化→建模→溝通
 - 整潔資料 + 用程式清理(80% 時間)
 - 選對圖、誠實呈現
 - 可重現五習慣 + AI 輔助(要揭露、要核對)
- 讓分析可信、可重跑、可累積

教學重點 帶走一句話: 一個好分析, 不只是『跑出正確的數字』, 而是『別人(和未來的你)能一鍵重跑、看懂、並延伸』。把分析當成一條可重現的流程——整潔資料、用程式清理、選對圖、誠實呈現、版本控制與環境記錄——你的研究就有了可信與可累積的基礎。這是單元 8 的收尾, 也把 7.2 開放科學真正落實到你的鍵盤上。



作業

帶回家作業 Take-home Assignment

Make It Reproducible

Part A 觀念題 · Part B 實作題 (附參考答案)

作業目標:能規劃並執行一條可重現的分析流程、整理與清理資料、
選對圖表,並用 AI 輔助程式而不失把關。

作業說明與繳交

建議 2-3 頁;重點是可重現與判斷

形式與繳交

- 形式:一份分析報告 + 可重跑的程式/筆記本
- 篇幅:Part A 每題 3-5 句;Part B 完整流程
- 附:資料夾結構與 README
- 獨立完成;可用 AI 協助但需自行核對並揭露
- 繳交期限:兩週後上課前

評分重點

- 整潔資料與清理正確 (25%)
- 選對圖表、誠實呈現 (20%)
- 可重現五習慣落實 (30%)
- AI 輔助的核對與揭露 (15%)
- 文件清楚、可被重跑 (10%)

情境 (Part B 共用):你拿到一份『健康 App 使用者』的雜亂資料(含缺失、格式不一),要做一份可重現分析。

教學重點 寫作提醒:每個步驟都要能被『重跑』。老師看的是你能不能把分析做成一條乾淨、有紀錄、別人能一鍵重現的流程,並在用 AI 時保持理解與把關。

四題觀念題（每題 3-5 句）

用你的話講清楚

A1

什麼是『整潔資料(tidy data)』?為什麼它讓後續分析變簡單?舉一個雜亂→整潔的例子。

A2

為什麼可重現分析要『用程式』而非『手動點按』?列出三個可重現習慣。

A3

舉一個『誤導圖表』的手法,並說明怎麼畫才誠實。

A4

用 AI 幫你寫分析程式時,有哪兩條紅線?為什麼?

教學重點 提示:A1 想每欄一變數/每列一觀測;A2 想腳本、Git、固定種子、環境;A3 想截斷 Y 軸、雙軸;A4 想核對結果、勿貼敏感資料給外部 AI。

做一份可重現的分析

雜亂健康 App 資料 → 乾淨結果

針對這份雜亂資料,請完成(用你熟悉的工具):

- B1 描述你的『資料夾結構』與 README 會怎麼安排。
- B2 列出你會做的『資料清理』步驟(缺失、型態、重複、異常、一致性)。
- B3 把資料整成『整潔』結構,說明你怎麼轉換。
- B4 選一張『溝通用』的圖,說明你選它的理由與如何畫得誠實。
- B5 列出讓這份分析『可重現』的三件事,並說明你如何用 AI 又保持把關。

教學重點 重點:B1 data/code/output + README + 可用性聲明;B2 對照五類清理 + 用程式;B3 每欄一變數、每列一觀測(長/寬轉換);B4 依資料型態選圖、軸誠實、色盲友善;B5 腳本 + Git + 固定種子 + 記錄環境,AI 寫的要看懂核對、勿貼敏感資料。



解答

參考答案 Reference Answers

對答案,更要對『推理』

Part A 觀念 + Part B 實作要點

先自己做完再看。

比對重點是可重現與資料處理的正確性,不只是名詞。

觀念題參考答案

要點式,實際作答請展開成 3–5 句

題	參考要點
A1	整潔資料=①每欄一個變數、②每列一個觀測、③每張表一種觀測單位。它讓幾乎所有分析與繪圖工具都能直接使用,減少反覆重整。例:把『2020、2021...各年當欄名』的寬表,轉成『年份』與『數值』兩欄的長表(每人每年一列),就從雜亂變整潔。
A2	手動點按做完就沒有紀錄,別人與自己都無法重現每一步;用程式(腳本)把每一步記錄下來,才能重跑、版本控制、分享。三個可重現習慣例:①用腳本不手動;②用 Git 版本控制;③固定亂數種子(或記錄套件版本/用容器)。
A3	誤導手法例:『截斷 Y 軸』把微小差異放大成巨大(或用雙 Y 軸硬湊相關)。誠實畫法:數量比較的長條/折線圖 Y 軸從 0 起、清楚標示軸與單位、不用比例失真的 3D 或面積、選對圖型,讓真實差距如實呈現(呼應 7.2 誠信)。
A4	兩條紅線:①你必須『看得懂並核對』AI 產生的程式與結果——AI 會產出看似合理卻錯誤的程式,照跑不查會出錯;②絕不能把『可識別的健康資料』貼給外部 AI(洩密風險,接 9.11)。AI 加速打字與除錯,但分析對不對、結果合不合理的你負責,且用了要揭露。

實作參考要點（示例）

合理即可,重點是可重現與把關

B1–B3 結構、清理、整潔

B1 資料夾:data/(raw 只讀)、code/、output/、
+ README(說明流程與如何重跑) + 資料/程式
可用性聲明(接 9.9)。

B2 清理:缺失(看比例與型態、決定策略)、型態
(數字/日期轉正確)、重複(關鍵欄去重)、異常
(範圍/邏輯檢查,分錯誤 vs 真極端)、一致性
(單位/編碼統一)——全用程式做。

B3 整潔:每欄一變數、每列一觀測;把寬表用
長/寬轉換、拆多資訊欄、分表整理。

B4–B5 視覺化與可重現

B4 依『要說的事』選圖(趨勢→折線、比較→長
條...);軸從 0 起、標清楚軸/單位/來源、去除
裝飾、色盲友善(接 9.7);說明為何選它。

B5 可重現三件事:①全程用腳本 + 固定種子;②
Git 版本控制;③記錄套件版本或用容器。用 AI:
請它寫/除錯程式但自己看懂並核對結果、不貼
可識別健康資料給外部 AI、並揭露使用。

教學重點 沒有唯一標準答案,但好分析必須:清楚的資料夾與 README、用程式做的完整清理、整潔的資料結構、選對且誠實的圖表、以及可重現的五個習慣;用 AI 要看懂核對、保護敏感資料並揭露。

想更深入可以看這些

經典資源與工具

主題	來源
資料科學	Wickham & Grolemund, R for Data Science;McKinney, Python for Data Analysis
整潔資料	Wickham (2014) Tidy Data(JSS)
視覺化	Wilke, Fundamentals of Data Visualization;Cairo, The Truthful Art
可重現	版本控制(Git)、可執行筆記本(Quarto/Jupyter)、容器(接 7.2)
報告	資料/程式可用性聲明(接 9.9);TRIPOD+AI(接 9.5)
AI 輔助	善用 AI 寫程式;但核對結果、保護資料、揭露(接 1.4/9.11)

教學重點 這一課是單元 8 的收尾,把 8.1–8.3 的方法用『可重現的方式』實際跑出來,並將 7.2 開放科學落實到鍵盤上。它直接支援 9.5(醫療 AI 的可重現開發)、9.9(資料/程式可用性)與整個研究的誠信。學會它,你的每一個分析都能被信任、被重跑、被延伸。



資料科學與可重現分析實務 · Data Science & Reproducible Analysis

把分析做成『別人一鍵重跑』的流程

整潔資料 · 用程式清理 · 選對圖 · 版本控制與種子 · AI 輔助但要把關

匯入 → 整理 → 視覺化 → 建模 → 溝通 · Tidy data · Git · Quarto · 可用性聲明