

健康資料來源與標準

Health Data Sources & Standards

資料從哪來、長什麼樣、怎麼對得起來——做健康科技研究的第一課。

來源盤點 → 互通性 → 術語編碼 (ICD/SNOMED/LOINC) → 交換與資料模型 (FHIR/OMOP) → 品質、隱私與研究應用。

本單元六個部分

沿『資料的生命週期』推進：從哪來 → 為何要標準 → 怎麼編碼交換 → 怎麼用於研究

部分	主題	關鍵字
Part 1	健康資料的來源 Sources	EHR、健保申報、登錄、穿戴、影像、基因體
Part 2	為何要標準與互通 Interoperability	資料孤島、四層級、語法 vs 語意
Part 3	術語與編碼 Terminologies	ICD、SNOMED CT、LOINC、RxNorm
Part 4	交換與資料模型 Exchange & CDM	HL7 v2/CDA、FHIR、OMOP CDM、DICOM
Part 5	品質、隱私與研究應用	資料品質、去識別化、FAIR、RWD→RWE
Part 6	AI 工具與使用界線	NLP 抽取、自動對應編碼、紅線

教學重點 | 一句話貫穿本單元：健康資料的價值，取決於它能不能被『找到、對得起來、且合法安全地再利用』——這正是『標準』要解決的事。

為什麼健康科技研究要先懂『資料與標準』？

再厲害的 AI 或統計，餵進去的資料若對不上、品質差，結論就不可信

資料是燃料 健康科技研究（AI 判讀、數位介入、RWE）成敗，八成取決於資料的可得性與品質。

醫療資料特別難 來源分散（各院各系統）、格式不一、含大量非結構化文字與影像、且高度敏感。

『對得起來』才有用 同一個『高血壓』在不同系統可能寫法各異——沒有共同編碼與標準，就無法整合與比較。

合法安全是前提 健康資料屬敏感個資；去識別化、治理與倫理審查是能不能用的門檻。

教學重點 | 本單元目標：讓你在開題時就能回答『我的資料從哪來、是什麼標準、品質如何、能不能合法取得與整合』。

1

PART 1

健康資料的來源 Sources of Health Data

先盤點：健康科技研究常用的資料，各有什麼特性

EHR、健保申報、疾病登錄與世代、穿戴與遠距監測、病人自陳、醫學影像、基因體。

每一種都有它的『強項與盲點』——選對資料，研究就成功一半。

健康資料全景：八大來源一次看懂

從『routine care 產生』到『為研究而收集』

來源	內容	典型用途
電子病歷 EHR/EMR	診斷、用藥、檢驗、病程、影像連結	臨床 AI、RWE、品質改善
健保申報 Claims	就診、處置、藥品、費用 (ICD 編碼)	流行病學、政策、成本分析
疾病登錄/世代 Registry	特定疾病或族群的結構化長期資料	預後、存活分析、追蹤
穿戴/遠距 Wearables/RPM	心率、步數、血糖、睡眠 (連續感測)	數位介入、行為、預警
病人自陳 PRO/PREM	症狀、生活品質、就醫體驗	以病人為中心的成效
醫學影像 Imaging	X 光、CT、MRI、病理 (DICOM)	影像 AI、電腦輔助判讀
基因體/組學 Omics	基因、蛋白質、代謝	精準醫療、生物標記

教學重點 | 選資料先問三件事：① 它原本為什麼被收集 (臨床/申報/研究) ② 涵蓋哪些變項與族群 ③ 品質與偏誤如何——來源決定了你能問什麼問題。

健康資料生態系：價值來自連結、治理與回饋

資料來源 × 參與者 × 共同基礎設施 × 使用情境，必須由治理護欄串接



教學重點 | 先問誰產生、誰使用、用什麼標準連結；再問是否可追溯、可共享、可公平使用。

健康資料從哪來?一條光譜

日常照護副產品 → 為研究刻意收集



越靠左，資料越便宜但越吵；越靠右，資料越乾淨但越貴——依研究問題選位置，不是越貴越好。

教學重點 | 選資料的原則:先問「我的研究問題需要多乾淨的變項」,而不是「哪個資料拿得到」。

資料的『形狀』：結構化 vs 非結構化

健康資料大量是非結構化的——這正是它難用、也是 AI 的機會

結構化 Structured

- 欄位固定、可直接統計
- 例：檢驗數值、ICD 診斷碼、生命徵象
- 易分析，但可能漏掉細節脈絡

半結構化 Semi-structured

- 有標籤但欄位彈性
- 例：FHIR/JSON、XML、含欄位的表單
- 機器可讀、又保留彈性

非結構化 Unstructured

- 自由文字、影像、波形、語音
- 例：病程紀錄、放射報告、心電圖
- 佔醫療資料約 80%，需 NLP/影像 AI

教學重點 | 多數臨床『真相』藏在非結構化文字裡（如病程與報告）；把它結構化（NLP 抽取 + 對應編碼）是健康科技研究的關鍵一步。

兩大主力：電子病歷 EHR vs 健保申報 Claims

最常用，但兩者的『視角』與偏誤完全不同

電子病歷 EHR (臨床視角)

- 內容：診斷、用藥、檢驗、影像、病程
- 優點：臨床細節豐富、時間解析度高
- 限制：只看得到『這家醫院』；跨院不連續
- 偏誤：有就醫才有資料 (healthy user 反向)

健保申報 Claims (給付視角)

- 內容：就診、處置、藥品、費用 (ICD 碼)
- 優點：涵蓋全人口、跨院連續、長期
- 限制：為『給付』而生，缺檢驗值與臨床細節
- 偏誤：編碼受給付規則影響 (up-coding)

教學重點 | 台灣情境：健保資料庫 (NHIRD) 涵蓋近全民、可長期追蹤，是流行病學金礦；但缺檢驗數值——常需與醫院 EHR 或登錄資料串接互補。

為研究而生：登錄、世代、穿戴與病人自陳

品質較高、變項明確，但收集成本也高

疾病登錄 Registry 為特定疾病系統性收集（如癌症登記）；變項標準化、追蹤完整，適合預後與存活分析。

世代資料庫 Cohort/Biobank 如台灣人體生物資料庫（Taiwan Biobank）：問卷 + 檢體 + 基因 + 長期追蹤，支援精準醫療。

穿戴與遠距監測 RPM 連續、被動、貼近真實生活的生理資料；但有配戴依從性、缺失與裝置差異問題。

病人自陳 PRO/PREM 症狀、生活品質（PRO）與就醫體驗（PREM）；以病人為中心，需驗證量表信效度（見單元 2）。

教學重點 | 『routine care 資料』（EHR/claims）便宜但雜；『為研究收集的資料』（registry/cohort/PRO）乾淨但貴——多數研究是兩者串接互補。

高維度資料：醫學影像與基因體

體積大、維度高、最需要專門標準與運算

醫學影像 Medical Imaging

- X 光、CT、MRI、超音波、病理切片
- 標準：DICOM (影像 + 中繼資料的通用格式)
- 研究：影像 AI、電腦輔助判讀 (CAD)
- 注意：像素外還有 metadata，須去識別化

基因體與組學 Omics

- 基因 (DNA)、轉錄、蛋白質、代謝
- 特性：超高維度 (數萬變項)、樣本相對少
- 研究：生物標記、精準醫療、風險預測
- 注意：可再識別風險高、倫理與同意嚴格

教學重點 | 高維度資料的共同挑戰：『變項遠多於樣本』 ($p \gg n$) —— 分析要防過度配適，並特別留意再識別與隱私風險。

真實世界資料 RWD → 真實世界證據 RWE

把『日常照護產生的資料』變成『可用於決策的證據』

RWD 是什麼 真實世界資料 = 日常產生的健康資料：EHR、claims、登錄、穿戴、PRO——不是為某個試驗特別收的。

RWE 是什麼 真實世界證據 = 分析 RWD 得到的臨床證據（如療效比較、安全監測、使用模式）。

為何重要 RCT 昂貴、族群窄；RWE 補足『真實情境、長期、罕見事件、特殊族群』的證據（FDA 已有 RWE 計畫）。

關鍵風險 RWD 非隨機 → 干擾與偏誤嚴重；需嚴謹設計（見單元 9 觀察性研究）與 STROBE/RECORD 報告。

教學重點 | RWD 很多、RWE 很難：資料再多，若設計不當（選擇偏誤、干擾、資料品質差），得到的只是『看似顯著的雜訊』。

2

PART 2

為何要標準與互通 Interoperability

資料能『對得起來』，價值才會出現

資料孤島問題、互通性的四個層級、以及『語法互通』與『語意互通』的差別。

沒有標準，串接就是一場永無止境的手工翻譯。

問題根源：資料孤島 Data Silos

每家醫院、每個系統，都用自己的方言記錄

同一件事、不同寫法 『心肌梗塞』在 A 院是自訂碼、B 院寫全名、C 院用縮寫 MI——機器不知道它們是同一件事。

系統各自為政 檢驗、影像、藥局、門診系統各自一套；連院內都難整合，跨院更難。

後果 無法整合分析、無法跨院追蹤病人、AI 換一家醫院就失準、重複檢查浪費資源。

解法方向 共同的『識別方式（編碼）+ 交換格式（訊息/API）+ 意義（術語）』——這就是互通性標準。

教學重點 | 互通性不是『能傳檔案』就好；是『傳過去對方看得懂、且意義一致』。這需要語法與語意兩層都對上。

互通性的四個層級 (HIMSS/ISO)

由淺到深：能傳 → 格式對 → 意義對 → 治理對

層級	意思	例
① 基礎 Foundational	能安全地傳送與接收資料	兩系統間建立連線、可收送
② 結構 Structural	資料格式與語法一致	HL7 v2 訊息、FHIR 資源的欄位結構
③ 語意 Semantic	資料的『意義』一致、可解讀	用 SNOMED/LOINC 讓『葡萄糖』兩邊同義
④ 組織 Organizational	治理、政策、法規、信任	資料使用協議、同意、隱私法遵

教學重點 | 最難的是第③與第④層：格式對上（結構）相對容易，但『意義一致』要靠共同術語，『能合法互信交換』要靠治理與法規。

互通性的四個層次:由淺到深

能傳 → 格式對 → 意義對 → 治理對

① 基礎 Foundational

能不能「傳過去」 · 有網路/介面可交換資料

② 結構 Structural

格式對不對 · 欄位結構一致,能被解析(如 HL7 訊息)

③ 語意 Semantic

意思對不對 · 雙方對「同一個碼」理解一致(靠術語標準)

④ 組織 Organizational

制度對不對 · 有治理、同意、法規與信任框架

常見誤解:以為「能匯出 CSV」就是互通了——那只到第②層。看得到欄位 ≠ 看得懂意思。

研究上最痛的通常是第③層:兩家醫院的「同一個檢驗」可能用不同代碼與單位。

教學重點 | 以為「能匯出 CSV」就是互通,其實只到第②層;研究上最痛的是第③層語意——同一個檢驗可能用不同代碼與單位。

語法互通 vs 語意互通

『看得到欄位』不等於『看得懂意思』

語法互通 Syntactic

- 格式/結構對得上，機器能解析
- 例：兩邊都用 FHIR JSON、欄位對應
- 達成：共同的訊息或 API 格式
- 但：欄位裡的『值』可能還是各寫各的

語意互通 Semantic

- 連『意義』都一致，可正確整合分析
- 例：檢驗項目都用 LOINC 碼、診斷用 SNOMED
- 達成：共同的『術語/編碼系統』
- 這才能跨院統計、訓練可移轉的 AI

教學重點 | 範例：兩系統都傳來『glucose = 110』。語法互通讓你讀到這個欄位；但要語意互通（同一個 LOINC 碼、同單位 mg/dL）才知道是同一項檢驗、能合併分析。

3

PART 3

術語與編碼標準 Terminologies & Code Systems

讓『同一件事』有同一個代碼

為什麼要編碼、主要編碼系統各管什麼 (ICD / SNOMED CT / LOINC / RxNorm) 。

以及最容易搞混的一題：ICD 與 SNOMED 到底差在哪？

為什麼要『編碼』？

把人類的文字，變成機器可讀、可統計、可交換的代碼

機器可讀 『糖尿病』有數十種寫法；給它一個唯一代碼，電腦才數得出來、找得到。

可統計與比較 編碼後才能算盛行率、跨院比較、做流行病學與 RWE。

可交換 不同系統交換資料時，代碼是共同語言（語意互通的基礎）。

可推理 好的術語（如 SNOMED）帶階層與關係，能『上捲』查詢（查『心臟病』涵蓋所有子類）。

教學重點 | 編碼 = 語意互通的地基。沒有共同編碼，再漂亮的 FHIR 格式也只是『整齊地各說各話』。

主要編碼系統對照：各管一塊

診斷、臨床概念、檢驗、藥品、處置、影像——分工不同

系統	管什麼	特性/用途
ICD-10/11	診斷分類 Diagnoses	統計與健保申報；分類、互斥類別
SNOMED CT	臨床概念 Clinical terms	最細緻、多階層、可組合；臨床紀錄
LOINC	檢驗與觀察 Labs/Observations	檢驗項目、生命徵象、文件類型識別碼
RxNorm / ATC	藥品 Medications	藥品標準命名 / 解剖治療分類
CPT / ICD-10-PCS	處置 Procedures	手術與處置編碼（給付常用）
DICOM	醫學影像 Imaging	影像儲存與交換的通用標準

教學重點 | 實務常見組合：診斷用 ICD（申報）+ SNOMED（臨床細節）、檢驗用 LOINC、用藥用 RxNorm、影像用 DICOM——一份完整病歷會同時用到好幾種。

最常搞混：ICD vs SNOMED CT

一個是『分類箱子』，一個是『樂高積木』

ICD (分類 Classification)

- 目的：統計與給付 / 申報
- 結構：互斥、窮盡的『類別』
- 粒度：較粗（一個碼涵蓋一群情況）
- 例：I21 急性心肌梗塞
- 像把病歷『歸檔到抽屜』

SNOMED CT (參考術語)

- 目的：在照護現場精準記錄臨床
- 結構：多階層、概念可『組合』
- 粒度：極細（數十萬概念、帶關係）
- 例：可精確到部位、時序、嚴重度
- 像用積木『拼出精確的臨床事實』

教學重點 | 實務：在點照護時用 SNOMED 記細節，再『對應 (map)』成 ICD 去申報與統計。兩者不是二選一，而是分工——但對應會損失細節，是資料品質的坑。

術語標準各管一塊:誰負責什麼

ICD / SNOMED / LOINC / ATC / DICOM

術語標準各管一塊:先看清楚「誰負責什麼」

把文字變成機器可讀、可統計、可交換的代碼

ICD-10 / ICD-11

診斷、死因

分類箱子:一個病一個碼,用於統計與給付

SNOMED CT

臨床概念

樂高積木:概念可組合,描述細緻臨床意義

LOINC

檢驗與測量

「這個檢驗是什麼」:名稱 + 單位 + 方法

ATC / RxNorm

藥品

藥物分類與成分

DICOM

醫學影像

影像格式 + 後設資料

跨碼對映(mapping)常常對不齊:ICD 的一個碼可能對應多個 SNOMED 概念,反之亦然——要記錄對映規則與版本。

跨碼對映常對不齊:ICD 一個碼可能對應多個 SNOMED 概念——要記錄對映規則與版本,並在方法章交代。

教學重點 | 跨碼對映常對不齊:ICD 一個碼可能對應多個 SNOMED 概念——要記錄對映規則與版本,並在方法章交代。

對應 Mapping 的難處 + 台灣情境

把一套碼翻成另一套，常常對不齊

一對多 / 多對一 一個 SNOMED 概念可能對到多個 ICD 碼，反之亦然——對應要靠對照表與規則。

版本變動 ICD-9→ICD-10→ICD-11、SNOMED 定期更新；跨版本研究要處理『碼的搬家』。

損失與偏誤 對應到較粗的分類會損失臨床細節；給付導向的編碼也可能失真。

台灣現況 健保自 2016 年起以 ICD-10-CM (診斷) / ICD-10-PCS (處置) 申報；研究用 NHIRD 需熟悉其編碼與版本。

教學重點 | 做跨系統或跨年研究，一定要交代『用了哪套編碼、哪個版本、如何對應』——這是方法透明性與可重現的一部分。

4

PART 4

交換與資料模型 Exchange & Data Models

資料怎麼『送出去』與『排整齊』

HL7 家族 (v2 → CDA → FHIR) 、FHIR 白話介紹與範例、以及研究用的通用資料模型 OMOP CDM。

編碼解決『意義』，這一部分解決『傳輸格式』與『分析結構』。

HL7 家族的演進：v2 → CDA → FHIR

從院內訊息，走到網路時代的 API

標準	是什麼	定位
HL7 v2	管線分隔的訊息 (1980s 至今)	院內系統整合主力 (掛號、醫囑、報告) ；老但仍普及
HL7 CDA	XML 臨床文件	出院摘要等『文件』交換
HL7 FHIR	以『資源』為單位的 RESTful API	現代標準；App/雲端/AI 首選 (下頁)

教學重點 | 別以為 v2 過時就沒人用——它仍是多數醫院院內整合的骨幹。FHIR 是『對外、對 App、對雲』的新一代標準，兩者常並存。

FHIR 白話介紹：健康資料的『樂高 + 網路 API』

把病歷拆成一塊塊標準『資源』，用網路方式存取

資源 Resources 把資料拆成模組化單位：Patient、Observation、Condition、MedicationRequest、Encounter...

RESTful API 用網路標準存取：GET /Patient/123 取病人、GET /Observation?patient=123 取檢驗。

格式 JSON 或 XML，人與機器都易讀；每個資源有唯一 id 與明確欄位。

為何當紅 美國 21st Century Cures Act 要求以 FHIR R4 開放資料；App、雲端、AI 都以它為介面。

教學重點 | FHIR R4 (v4.0.1) 是目前普遍實作與法規要求的版本；R5 已發布但 R4 仍是主流。學會讀 FHIR 資源，等於拿到現代健康資料的鑰匙。

FHIR:把病歷拆成標準「資源」

用 REST API 像取用網頁一樣取資料

FHIR:把病歷拆成一塊塊標準「資源」,用網路方式存取



研究上的用法:用 FHIR 直接把需要的欄位抓出來,而不是等資訊室做一次性報表。

教學重點 | 研究上的用法:用 FHIR 直接抓需要的欄位,而不是每次都等資訊室做一次性報表。

FHIR 範例判讀：一筆血糖檢驗長什麼樣

看得懂資源，就看得懂現代健康資料

```
{ "resourceType": "Observation",  
  "status": "final",  
  "code": { "coding": [{ "system": "http://loinc.org", "code": "2339-0", "display": "Glucose" }] },  
  "subject": { "reference": "Patient/123" },  
  "valueQuantity": { "value": 110, "unit": "mg/dL" } }
```

怎麼讀：這是一筆『Observation (觀察)』資源；用 LOINC 碼 2339-0 標明是『葡萄糖』；屬於 Patient/123；值 110 mg/dL。

關鍵：因為用了 LOINC (語意互通)，任何系統都知道這是同一項檢驗——這就是 FHIR + 標準術語的威力。

教學重點 | FHIR 只負責『格式與傳輸』；真正讓資料可比較的是裡面的『編碼 (LOINC/SNOMED)』——標準要一起用才有語意互通。

研究用的通用資料模型：OMOP CDM

把各院不同的資料，重排成同一張『研究用地圖』

為什麼需要 CDM 每家醫院資料結構不同；把它們 ETL 成同一個模型，才能用『同一套分析程式』跑多中心研究。

OMOP CDM (OHDSI) 最廣泛的觀察性研究通用資料模型：標準表 (person、condition_occurrence、drug_exposure、measurement...)。

標準詞彙 OMOP 的 Standardized Vocabulary 把 ICD/SNOMED/RxNorm 等對應到『標準概念』，達成語意一致。

威力 多國多中心用同一份程式跑同一分析 → 大規模 RWE 與可重現研究 (如藥物安全網絡研究)。

教學重點 | FHIR 擅長『即時交換單筆資料』，OMOP CDM 擅長『大規模分析研究』——近年常見『FHIR 取資料 → ETL 進 OMOP 分析』的組合。

共同資料模型:把各院資料重排成同一張地圖

多來源 → ETL → OMOP CDM



好處:同一套分析程式可以在多家機構跑 → 跨院研究、聯合分析、結果可比。

代價:ETL 很費工,且轉換過程一定有資訊損失——要記錄「哪些欄位對映不上、怎麼處理」。

常見用途:分散式研究網路(各院不外傳原始資料,只交換分析結果)。

教學重點 | 好處是同一套程式能在多家機構跑;代價是 ETL 費工且必有資訊損失——要記錄哪些欄位對映不上。

標準地圖：哪個標準管哪一層

一張表釐清 FHIR、ICD、LOINC、DICOM、OMOP 的分工

標準	主要負責	互通層級
ICD / SNOMED / LOINC / RxNorm	意義 (術語與編碼)	語意 Semantic
HL7 v2 / CDA / FHIR	格式與傳輸 (訊息/文件/API)	結構 Structural
DICOM	醫學影像的儲存與交換	結構 + 語意 (影像)
OMOP CDM	研究分析用的資料結構	結構 (分析) + 語意

教學重點 | 口訣：編碼系統管『意義』、HL7/FHIR 管『傳輸』、DICOM 管『影像』、OMOP 管『分析』——它們互補、常一起用，不是彼此取代。

資料到證據：標準化是中間的橋

可交換只是起點；品質、語意、方法與驗證共同決定資料能否形成證據



可交換只是起點；品質、語意、方法與驗證共同決定資料能否形成證據。

教學重點 | FHIR 解決交換，OMOP 支援共同分析；能否成為證據仍取決於品質、偏差與可重現性。

5

PART 5

品質、隱私與研究應用 Quality, Privacy & Use

資料要『可信、可合法用、可再利用』

資料品質怎麼評、如何去識別化與治理、FAIR 原則，以及用健康資料做研究的完整流程。

這一部分決定你的資料『能不能用、結論可不可信』。

健康資料品質怎麼評？（Kahn 架構）

資料再多，品質差就是雜訊——先評品質再分析

維度	看什麼	例（長照 AI）
符合性 Conformance	格式、型別、關係是否合規	日期格式、碼在合法值域內
完整性 Completeness	該有的欄位/紀錄有沒有缺	缺失率、某欄大量空白
合理性 Plausibility	值是否合理、可信	年齡 200、血壓 0、時間倒流
時效與一致 Timeliness/Consistency	是否即時、前後一致	跨系統同一值是否相符

教學重點 | 每個維度都可做兩種查核：對照『內部規則』（verification）與對照『外部真相/標準』（validation）。品質評估結果要寫進方法與限制。

資料品質四維度:先評再分析

完整性 / 一致性 / 合理性 / 時序性

完整性 Completeness	一致性 Consistency	合理性 Plausibility	時序性 Timeliness
該有的欄位/個案有多少缺漏	跨欄位、跨時間點是否互相矛盾	數值是否落在生理/邏輯合理範圍	記錄時間是否可信、有無延遲

先評估這四維度再進分析：品質差的資料，樣本再大也只是雜訊放大。

品質評估結果要寫進方法章，附上具體數字（如缺漏率、異常值比例），而不是只憑印象打折。

教學重點 | 資料再多,品質差就是雜訊;品質評估結果要寫進方法章,而不是只在自己心裡打折。

去識別化 De-identification：能不能用的門檻

健康資料是敏感個資——去識別化是合法再利用的關鍵

HIPAA 兩條路徑 (可參考)

- Safe Harbor：移除 18 類識別碼
(姓名、細於州的地理、細於年的日期、
病歷號、電話、email、身分證號...)
- Expert Determination：專家評估再識別風險極低

技術與台灣法遵

- k-匿名、l-多樣性：降低被指認風險
- 台灣：個資法 + 去識別化；敏感資料更嚴
- 研究通常需 IRB 核准與資料使用協議
- 注意：基因、罕病、細地理極易再識別

教學重點 | 『去識別化』不是刪個名字就好——結合多個準識別欄位 (生日 + 郵遞區號 + 性別) 仍可能指認到個人。去識別化程度要與再識別風險一起評估。

隱私強化技術與資料治理

讓資料『可用而不外流』的新做法

聯邦式學習 Federated Learning 把『模型送到資料端』訓練、只回傳參數——原始資料不出院，適合多院合作。

差分隱私 Differential Privacy 在統計輸出加入雜訊，保證單一個人的存在與否不可辨識。

安全運算/資料保險箱 Enclave 在受控環境中分析，研究者看不到原始明細、只能取結果。

合成資料 Synthetic Data 用模型生成『統計相似但非真人』的資料，供開發與教學（仍需驗證代表性）。

教學重點 | 趨勢是『資料不動、運算移動』：與其把敏感資料集中，不如讓分析在資料所在地進行——降低外洩風險，也更容易跨機構合作。

FAIR 原則：讓資料可被再利用

好的研究資料，應該 Findable / Accessible / Interoperable / Reusable

原則	意思	實務做法
Findable 可尋	有唯一識別碼與中繼資料	DOI、資料集描述、可被搜尋
Accessible 可取	有明確、受控的取用方式	申請流程、權限、DUA
Interoperable 可互通	用共同標準與詞彙	FHIR、SNOMED/LOINC、OMOP
Reusable 可再用	有清楚授權與來源紀錄	授權條款、provenance、品質說明

教學重點 | FAIR ≠ 完全開放：健康資料常是『可尋、可取（受控）』但不公開。重點是『有標準、有治理、可被合法再利用』，而非人人可下載。

用健康資料做研究：一條完整的路

從『拿到資料』到『可信結論』的六步

- ① **取得與治理** 定資料來源、送 IRB、簽資料使用協議、確認去識別化。
- ② **理解與探索** 看資料字典、抽樣檢視、評估品質 (Kahn 維度) 與偏誤。
- ③ **標準化/ETL** 對應編碼 (ICD/SNOMED/LOINC)、轉入通用模型 (如 OMOP)。
- ④ **設計與分析** 選對研究設計 (多為觀察性)、控制干擾、選對統計 (單元 3-6)。
- ⑤ **報告與透明** 用 STROBE/RECORD 報告；交代資料版本、編碼、清理與限制。
- ⑥ **倫理與再利用** 保護隱私、揭露 AI 使用、資料與程式盡量 FAIR。

教學重點 | 健康資料研究的成敗，往往不在『分析多花俏』，而在前段的『資料治理、品質與標準化』做得夠不夠扎實。

6

PART 6

AI 工具與使用界線 AI & Its Limits

AI 能加速健康資料工作，但不能取代把關

AI 在健康資料常見的三種加速：從文字抽結構、自動對應編碼、格式轉換。

以及處理敏感醫療資料時，絕不能跨越的紅線。

AI 怎麼幫健康資料工作？

把最花人力的『非結構化→結構化』自動化

可以 (輔助與加速)

- NLP 從病程/報告抽取結構化欄位
- 建議把診斷/檢驗自動對應到 ICD/LOINC
- 協助把資料轉成 FHIR 資源或 OMOP 格式
- 生成資料字典、品質檢查腳本草稿

紅線 (不可跨越)

- 把『未授權/未去識別化』的病歷貼給外部 AI
- 讓 AI 產出的編碼/數值不經人工核對就上線
- 用 AI 幻覺出的『文獻或數字』充當證據
- 跳過 IRB 與資料使用協議

教學重點 | 對敏感醫療資料，AI 的第一原則是『資料不外流、輸出必查證』：能用院內/去識別化資料就別上傳原始明細，AI 的每個對應與抽取都要人工抽查。

本單元重點回顧 Summary

一頁掌握健康資料與標準

來源決定問題 EHR/claims/登錄/穿戴/影像/基因各有強項與偏誤；先問『資料原本為何而收』。

標準解決互通 互通性有四層；語法對上還要語意對上（靠共同編碼）才有用。

編碼各管一塊 ICD 分類/申報、SNOMED 臨床細節、LOINC 檢驗、RxNorm 藥品、DICOM 影像。

FHIR + OMOP FHIR 管交換（RESTful 資源）、OMOP CDM 管大規模研究分析。

品質與隱私是門檻 用 Kahn 評品質、去識別化與治理保隱私、FAIR 促再利用、STROBE 報告。

AI 加速、人把關 AI 幫抽取與對應，但資料不外流、輸出必查證。

教學重點 | 一句話總結：健康資料的價值 = 可得性 × 品質 × 標準化 × 合法治理——四者缺一，再多資料也做不出可信的健康科技研究。



作業 · TAKE-HOME

帶回家作業 Take-home Assignment

Know your data before you analyse it.

用一個健康科技研究情境，走過『盤點來源 → 選對編碼 → 讀 FHIR → 評品質 → 顧隱私』。

Part A 觀念題檢驗你「懂不懂」；Part B 實作題要你「做得出」。參考解答在本節後段。

作業說明：目標、繳交與規則

作業目標

能為研究情境盤點資料來源、指定編碼與標準、評估品質並規劃隱私治理。

繳交方式

一份 PDF：Part A 文字作答 + Part B 表格/判讀，建議 3–5 頁。

建議時間

約 2–3 小時；可用 AI / 官方文件，但需寫出判斷。

工具與誠信

不上傳未授權病歷；AI 輸出須查證；附 AI 使用聲明。

Part A | 觀念題：健康資料與標準 (1/2)

- A1 健康資料八大來源舉三種，各說一個強項與一個限制/偏誤。
- A2 結構化 vs 非結構化資料差在哪？為何非結構化資料對健康科技研究特別重要？
- A3 互通性的四個層級是什麼？『語法互通』與『語意互通』差在哪？舉例說明。
- A4 ICD 與 SNOMED CT 的差別與各自用途？為何臨床上常需要在兩者間對應 (mapping) ？

教學重點 | 作答提示：觀念題重『說得清楚 + 舉得出例』，每題 2-4 句即可。

Part A | 觀念題：健康資料與標準 (2/2)

A5 LOINC、RxNorm、DICOM 各管什麼？各舉一個使用情境。

A6 FHIR 是什麼（資源 + API 各一句）？為何當紅？FHIR R4 的地位為何？

A7 OMOP CDM 解決什麼問題？它和 FHIR 的分工是什麼？

A8 去識別化的兩種思路（Safe Harbor / 專家判定）？為何『刪掉名字』還不夠？FAIR 四原則各一句。

Part B | 實作題：為研究情境規劃資料 (1/2)

情境：你要用某醫院 EHR + 健保申報資料，研究『某慢性病（如糖尿病）照護成效』。

B1 盤點：你會用哪些資料來源？各能提供什麼、缺什麼？如何互補（EHR vs claims）？

B2 為你的主要變項（診斷、檢驗、用藥）各指定合適的編碼系統，並說明理由。

B3 判讀下方 FHIR 片段：說出 resourceType、用的編碼系統、對象、值與其意義。

```
{ "resourceType": "Condition",  
  "code": { "coding": [ { "system": "http://snomed.info/sct", "code": "44054006", "display": "Diabetes mellitus type 2" } ] },  
  "subject": { "reference": "Patient/123", "recordedDate": "2026-03-01" } }
```

Part B | 實作題：品質、隱私與報告 (2/2)

- B4** 資料品質：用 Kahn 三維度（符合性 / 完整性 / 合理性）各舉一個你會做的檢查。
- B5** 隱私規劃：你會怎麼去識別化？列出至少三類要移除/處理的識別資訊，並說明治理（IRB / 資料使用協議）。
- B6** 附一段方法章『資料來源與標準』小節（150 字內）+ AI 使用聲明。

教學重點 | 繳交格式：Part B 要看到『來源盤點表、編碼對應、品質檢查與隱私規劃』；FHIR 判讀寫清楚每個欄位的意義。

評分重點與繳交 Rubric

項目	配分	評分重點
Part A 觀念	40%	定義正確、能舉例、能分辨 (如 ICD vs SNOMED、語法 vs 語意)
B1 來源盤點	15%	來源選擇合理、能說出互補與偏誤
B2 編碼指定	15%	診斷/檢驗/用藥對到正確系統並說理由
B3 FHIR 判讀	10%	正確讀出資源型別、編碼、對象與意義
B4–B6 品質 + 隱私 + 誠信	20%	品質檢查具體、去識別化 + 治理、方法段 + AI 聲明

教學重點 | 常見扣分：把 ICD 當臨床術語、只靠 FHIR 就宣稱『互通』(漏了編碼)、去識別化只刪名字、忽略資料偏誤與治理。

參考答案 · ANSWERS

參考解答 Reference Answers

Compare, don't copy.

示範解答採情境『糖尿病照護：某醫院 EHR + 健保申報』。

每題附『評分重點』與『常見錯誤』；你的情境不同，寫法可不同，但結構應一致。

Part A 參考答案 (1/2)

- A1** 例：EHR (臨床細節豐富 / 只限本院、有就醫才有)、claims (全人口長期 / 缺檢驗值、給付偏誤)、穿戴 (連續真實 / 依從性與缺失)。
- A2** 結構化 = 欄位固定可直接統計；非結構化 = 自由文字/影像/波形。非結構化佔約 80%，臨床『真相』常藏其中，需 NLP/影像 AI 抽取。
- A3** 四層：基礎 (能傳)、結構 (格式/語法)、語意 (意義/編碼)、組織 (治理/法規)。語法 = 格式對得上 (讀得到欄位)；語意 = 意義一致 (同一 LOINC 碼才知是同項檢驗)。
- A4** ICD = 診斷分類 (統計/申報、較粗、互斥)；SNOMED CT = 臨床參考術語 (極細、多階層可組合)。臨床用 SNOMED 記細節，再對應成 ICD 申報——對應會損失細節。

教學重點 | 評分重點：A3 四層齊全且能區分語法/語意；A4 講得出『分類 vs 參考術語』與『為何要對應』。

Part A 參考答案 (2/2)

A5 LOINC = 檢驗與觀察識別碼 (如葡萄糖) ; RxNorm = 藥品標準命名 (用藥) ; DICOM = 醫學影像儲存與交換 (CT/MRI) 。

A6 FHIR = 把資料拆成標準『資源』 (Patient/Observation...) , 以 RESTful API 存取。當紅因 Cures Act 要求以 FHIR R4 開放資料 ; R4 (v4.0.1) 為主流與法規版本。

A7 OMOP CDM = 把各院不同資料 ETL 成同一模型 + 標準詞彙 , 讓多中心用同一分析程式做 RWE 。 FHIR 管即時交換、OMOP 管大規模分析 , 常『FHIR 取資料→OMOP 分析』。

A8 Safe Harbor = 移除 18 類識別碼 ; 專家判定 = 評估再識別風險極低。刪名字不夠 , 因準識別欄位 (生日 + 郵遞區號 + 性別) 組合仍可指認。FAIR = 可尋/可取/可互通/可再用。

教學重點 | 常見錯誤 : 把 FHIR 當『資料庫』、以為 OMOP 取代 FHIR、以為去識別化 = 匿名 (其實仍有再識別風險) 。

Part B 參考答案 ①：來源盤點與編碼

項目	做法	理由
來源互補	EHR 取檢驗值/病程；claims 取長期跨院就診用藥	EHR 有細節無連續、claims 有連續無細節
診斷編碼	ICD-10-CM (申報) + SNOMED (臨床)	申報統計用 ICD、臨床細節用 SNOMED
檢驗編碼	LOINC (如 HbA1c 4548-4)	跨院統一辨識同一檢驗項目
用藥編碼	RxNorm / ATC	標準化藥品、可跨系統合併

教學重點 | 評分重點：能說出 EHR 與 claims 互補、三類變項對到正確編碼系統並給理由（不是硬背碼）。

Part B 參考答案 ②：FHIR 判讀與品質

B3 FHIR 判讀 resourceType = Condition (診斷) ; 編碼系統 = SNOMED CT (44054006) ; 對象 = Patient/123 ; 意義 = 第二型糖尿病 , 記錄於 2026-03-01 。

B4 符合性 檢查 ICD/檢驗碼是否在合法值域、日期格式與型別正確、外鍵 (病人) 存在。

B4 完整性 計算關鍵欄位 (HbA1c、用藥) 缺失率 ; 看是否某院/某時段大量空白。

B4 合理性 檢查離群與不合理值 (HbA1c 25%、年齡 200、診斷早於出生) ; 記錄清理規則。

教學重點 | 評分重點 : 正確讀出 FHIR 各欄位 ; 三個品質維度各舉『具體可執行』的檢查 , 而非空泛說『資料要乾淨』。

Part B 參考答案 ③：隱私、方法段與 AI 聲明

B5 去識別化 移除/處理：① 直接識別（姓名、病歷號、身分證）② 準識別（細於年的日期→只留年、細於州的地理→只留縣市）③ 聯絡（電話、email）。搭配 k-匿名評估再識別風險。

B5 治理 送 IRB 核准、簽資料使用協議（DUA）、於受控環境分析；跨院合作可考慮聯邦式學習『資料不出院』。

B6 方法段（示範） 「本研究資料來自某院 EHR（檢驗、病程）與健保申報（就診、用藥），診斷以 ICD-10-CM / SNOMED、檢驗以 LOINC、用藥以 RxNorm 編碼，並轉入 OMOP CDM。資料經去識別化並取得 IRB 核准。」

B6 AI 聲明 「以 NLP 協助從病程抽取結構化欄位、以 ChatGPT 檢查編碼對應；所有抽取與對應均經作者人工核對，未上傳未去識別化之原始病歷。」

教學重點 | 常見錯誤：去識別化只刪姓名（漏準識別欄位）、方法段沒交代編碼與版本、AI 聲明沒寫『資料不外流與查證』。

主要參考資料與延伸標準

權威原始出處 (規範與標準以官方最新版為準)

HL7 FHIR HL7 International. FHIR R4 (v4.0.1). hl7.org/fhir

SNOMED CT / LOINC SNOMED International ; Regenstrief Institute LOINC. snomed.org ; loinc.org

ICD WHO ICD-11 ; ICD-10-CM (台灣健保申報) . who.int/classifications

OMOP CDM OHDSI. The Book of OHDSI ; ohdsi.org (Common Data Model)

互通性 HIMSS Interoperability in Healthcare (四層級定義)

去識別化 / 隱私 HHS HIPAA De-identification Guidance ; 台灣個人資料保護法

資料品質 / FAIR Kahn et al. (2016) A harmonized data quality framework ; Wilkinson et al. (2016) FAIR Principles

RWE FDA Real-World Evidence Program ; STROBE / RECORD reporting guidelines

CLOSING

先讓資料對得起來，研究才站得住

健康資料的價值 = 可得性 × 品質 × 標準化 × 合法治理。

來源決定你能問什麼、標準讓資料對得起來、品質與隱私決定能不能用——

這四件事做好，AI 與統計才有意義。下一步：把你的論文資料，套進這條『來源→標準→品質→治理』的檢查線。