單元 9 · 健康科技研究方法　Health Technology Research Methods

流行病學與健康生統

Epidemiology & Health Biostatistics

從『多少人得病』到『這個檢測準不準』——含診斷準確度與 ROC 曲線。

敏感度 · 特異度 · PPV/NPV · 概似比 · ROC/AUC · STARD

先修：2.5 推論統計　·　對應報告規範：STARD 2015　·　建議學期：S2

本課地圖 Course Map

這堂課會帶你走過的六個部分

流病語言 → 效應測量 → 因果 → 診斷準確度 → ROC 與模型評估 → 綜合實作

部分	主題	你會學到
Part 1	疾病頻率 Frequency	盛行率 vs 發生率、發生密度、怎麼算、怎麼解讀
Part 2	關聯與效應 Association	2×2 表、 RR / OR / 風險差、 NNT，什麼設計配什麼指標
Part 3	偏誤・干擾・因果	選樣 / 資訊偏誤、干擾因子、控制方法、 Bradford Hill
Part 4	診斷準確度 Accuracy	敏感度 / 特異度、 PPV/NPV 、概似比，篩檢的陷阱
Part 5	ROC 與模型評估	ROC/AUC 、切點選擇、校準 vs 區辨、醫療 AI 指標、 STARD
Part 6	綜合實例 + 作業	穿戴式心律偵測 App：從資料到報告一次走完

教學重點 一句話抓重點：流病回答『疾病在人群怎麼分布、和什麼有關』；生統給你算的工具；診斷準確度與 ROC 則回答健康科技最常被問的——『你的檢測 / 模型到底準不準？』

導論 Why

為什麼健康科技研究一定要懂這一課

你做的 App、感測器、AI 模型，最後都要用這套語言被檢驗

沒有這課，你會…

- 把『很多人用』當成『疾病很常見』（混淆盛行率與發生率）
- 宣稱『準確率 95%』卻在罕見病上完全誤導人
- 把相關當因果，忽略干擾因子
- 投稿被審稿人以『未依 STARD 報告』退件

有了這課，你能…

- 正確描述疾病負擔與風險（RR/OR/ 風險差）
- 讀懂並計算敏感度、特異度、PPV、概似比
- 畫 ROC、選切點、評估 AI 模型的區辨與校準
- 依 STARD 完整報告一個診斷準確度研究

這一課是『2.5 推論統計』的健康應用延伸：把 p 值與信賴區間，放進『疾病、風險、檢測』的真實情境。

教學重點 健康科技的三大核心問題都在這課：① 這病有多常見？② 這因子有沒有關係？③ 這個檢測 / 模型可靠嗎？把這三題答好，你的研究就站得住腳。

1

PART 1

疾病在人群中有多少?

盛行率、發生率、發生密度

Part 1 | 疾病頻率 Disease Frequency

先學會『數對人』：分子是誰、分母是誰、時間怎麼算。
這是所有流病指標的地基——數錯了，後面全錯。

盛行率 vs 發生率：最常被搞混的一對

一個是『此刻有多少』，一個是『新增了多少』

盛行率 Prevalence

＝某時點『現有』病例 ÷ 全體人口

回答：現在有多少人帶著這個病?

像『拍一張快照』（橫斷面）

受發生率＋病程長短影響

例：全台糖尿病盛行率約 11%

→ 適合規劃醫療資源、需求評估

發生率 Incidence

＝某期間『新發生』病例 ÷ 有風險人口

回答：一段時間內多了多少新病人?

像『錄一段影片』（追蹤）

反映『得病的風險 / 速度』

例：每年每千人新增 3 例

→ 適合研究病因、風險因子、預防

關鍵直覺：盛行率 ≈ 發生率 × 平均病程。慢性病（病程長）盛行率會被『累積』撐高，即使新發生的人不多。

教學重點 健康科技常見錯誤：用 App 下載 / 使用人數推論『疾病很普遍』。使用者多 ≠ 盛行率高——那是自我選擇樣本，不是有代表性的人口分母。

盛行率 vs 發生率：浴缸模型

存量與流量，一張圖分清楚



水位（盛行率）取決於「流進來多快」與「流出去多快」——療效變好、存活變長，盛行率反而上升

教學重點　療效變好、病人活得久，盛行率反而上升——盛行率升高不等於疫情惡化；要判斷是哪一種，一定要回頭看發生率。

發生率的兩種算法：累積發生率 vs 發生密度

差別在分母——用『人數』還是『人時』

指標	分母	公式	何時用
累積發生率 Cumulative Incidence	期初有風險『人數』	新病例 ÷ 期初有風險人數	追蹤期固定、失訪少（如一年追蹤）
發生密度 / 率 Incidence Rate	累積『人時』 person-time	新病例 ÷ 總人時	追蹤期不一、有人中途退出 / 加入

為什麼要用『人時』？ 因為每個人被觀察的時間不一樣。追蹤 10 人各 1 年 = 10 人年；追蹤 20 人各半年也是 10 人年。用人時才公平。

教學重點 單位要說清楚：發生密度一定要帶時間，例如『每 1,000 人年 3 例』。只寫『3 例』或『3%』而不講分母與期間，讀者無法判讀。

動手算一次：一個社區的一年

同一份資料，三個指標算出來完全不同

情境設定

某社區 10,000 人，觀察 1 年：

- 1/1 當天已有 500 人患病（既有病例）
- 年初『有風險』人口 = 10,000 − 500 = 9,500
- 這一年新診斷出 200 例
- 假設新病例平均在年中發病（各貢獻半年）

計算結果

時點盛行率 = 500 ÷ 10,000 = 5.0%

累積發生率 = 200 ÷ 9,500 ≈ 2.1%（一年）

人時 ≈ 9,300×1 + 200×0.5 ≈ 9,400 人年

發生密度 ≈ 200 ÷ 9,400 ≈ 21.3 / 千人年

→ 盛行 (5%) 反映『累積存量』

→ 發生 (2.1%) 反映『這一年的新風險』

教學重點 看懂差異：盛行率高不代表最近很多人得病——可能是病人活得久、病程長而累積。要談『預防有沒有效』，看發生率才對。

2

PART 2

這個因子和疾病有沒有關係？有多強？

2×2 表、相對風險、勝算比、風險差、 NNT

Part 2 ｜關聯與效應 Measures of Association

把『暴露』與『疾病』擺進一張 2×2 表，
就能算出風險到底差多少、差幾倍。

一切從這張 2×2 表開始

記住四格的名字，後面每個指標都從這裡來

	有病 D+	沒病 D−	合計
有暴露 E+	a （真的暴露又生病）	b	a+b
無暴露 E−	c	d	c+d
合計	a+c	b+d	N

暴露 Exposure ＝你關心的因子（吸菸、久坐、用某 App 、帶某基因）；**疾病 Outcome** ＝你關心的結果（發病、住院、死亡）。

教學重點　提醒：a 、 b 、 c 、 d 是『人數』。所有效應指標（風險、勝算、 RR 、 OR ）都只是這四個數字的不同組合方式——不要背公式，理解它在算什麼。

2×2 表：每個效應指標從哪裡來

先認四格，再算 RR 、 OR 、 RD 、 NNT

從同一張表算出來的指標

風險 Risk ＝ a / (a+b)

RR ＝ [a/(a+b)] ÷ [c/(c+d)]

勝算 Odds ＝ a / b

OR ＝ (a/b) ÷ (c/d) ＝ ad/bc

RD ＝風險差； NNT ＝ 1/RD

		結果 Outcome：有	結果 Outcome：無
暴露 Exposure	有	a	b
	無	c	d

a 、 b 、 c 、 d 都是「人數」；先確認分母是誰，才知道這個指標能不能算

教學重點 算之前先問分母是誰：病例對照研究沒有真正的分母，所以只能算 OR 、不能算 RR 。

風險 vs 勝算：兩種『可能性』的講法

同一件事，分母不同

風險 Risk（機率）

＝發生數 ÷ 全部人

暴露組風險 = a ÷ (a+b)

範圍 0～1，就是日常說的『機率』

例：100 人中 20 人生病 → 風險 0.20

→ 直覺、好溝通

勝算 Odds

＝發生數 ÷ 未發生數

暴露組勝算 = a ÷ b

範圍 0～∞，是『發生：不發生』的比

例：20 生病：80 沒病 → 勝算 0.25

→ 病例對照研究、羅吉斯迴歸在用

兩者關係：疾病很罕見時，勝算 ≈ 風險（分母 a+b ≈ b）；疾病常見時，兩者差很大。這正是下一頁 OR 為何會高估 RR 的原因。

教學重點 一句話：風險的分母是『所有人』，勝算的分母是『沒發生的人』。搞清楚分母，就不會把 RR 和 OR 講反。

三個效應指標一次算： RR 、 OR 、風險差

用同一個世代研究資料

資料：久坐與代謝症候群

世代追蹤：久坐組 1,000 、非久坐組 1,000

久坐組： 200 人發病（風險 0.20 ）

非久坐組： 100 人發病（風險 0.10 ）

2×2： a=200 b=800 c=100 d=900

三個指標

相對風險 RR = 0.20 ÷ 0.10 = 2.0

→ 久坐者發病風險是 2 倍

風險差 RD = 0.20 − 0.10 = 0.10

→ 每多 100 名久坐者，多 10 人發病

勝算比 OR = (200/800)÷(100/900) = 2.25

→ 因疾病不罕見， OR(2.25) 高估 RR(2.0)

教學重點 RR 講『幾倍』（相對）， RD 講『多幾個』（絕對）——兩個都要看。相對風險再高，若絕對風險很小，實務衝擊可能有限；這是解讀健康科技成效時最常見的誤導點。

什麼設計配什麼指標？（很多人在這裡選錯）

分母能不能代表人口，決定你能算什麼

研究設計	能算風險?	主要指標	理由
世代 Cohort	能	RR 、 RD 、發生率	從暴露往前追，分母＝有風險人口
病例對照 Case-control	不能	OR	先挑病例與對照，發生率無法直接得出
橫斷面 Cross-sectional	盛行率	盛行勝算比 POR	同一時點量，因果先後不清
隨機試驗 RCT	能	RR 、 RD 、 NNT	隨機分組，可估因果效應

教學重點　實務規則：病例對照研究『只能』報 OR，不能報 RR—— 因為你人為決定了病例與對照的比例，分母不代表真實人口。搞錯這點，審稿人一眼看穿。

NNT：把效果翻譯成『要幫幾個人才少一個壞結果』

病人與決策者最聽得懂的數字

怎麼算

NNT = 1 ÷ 絕對風險差 (ARR)

介入把壞結果從 20% 降到 15%

ARR = 0.20 − 0.15 = 0.05

NNT = 1 ÷ 0.05 = 20

→ 每治療 20 人，可避免 1 例壞結果

為什麼重要

- NNT 小 = 效益高、CP 值高
- 把『相對降低 25%』變成可行動的數字
- NNH（傷害）同理，用來衡量副作用
- 成本效益、健保給付常用它
- 數位介入也適用：每用幾人省一次住院

教學重點 警惕『相對風險降低』的行銷話術：『風險減半！』聽起來很猛，但若是從 2% 降到 1%，NNT = 100——要 100 人用才少 1 例。務必同時看絕對數字。

3

PART 3

關聯是真的嗎？還是假象？

選樣偏誤、資訊偏誤、干擾因子、 Bradford Hill

Part 3 | 偏誤・干擾・因果

看到關聯先別急著下因果結論。

先問：會不會是偏誤、干擾、或反過來的因果?

看到關聯，先排除三種『假象』

真關聯之前，先過三關

① 偏誤 Bias

系統性誤差，方向固定
選樣偏誤：找錯人
資訊偏誤：量錯 / 記錯
→ 設計階段就要防

② 干擾 Confounding

第三個因子同時影響
暴露與結果
造成『假關聯』或遮蔽
→ 可事後統計調整

③ 機遇 Chance

純粹運氣造成的差異
用 p 值、信賴區間評估
樣本越大越不受影響
→ 2.5 推論統計處理

再加一問： 會不會是『反向因果』？ 例如『運動少的人比較胖』，也可能是『比較胖所以動得少』。橫斷面研究尤其要小心。

教學重點 順序很重要：先確認不是偏誤、干擾、機遇造成的，再談『可能有因果』。健康科技論文最常被打回票的，就是把『相關』直接當成『因為用了我的產品所以變好』。

從關聯到因果：要過三道關

偶然 → 偏誤 → 干擾



三關都過，再用 Bradford Hill 視角（時序、劑量反應、一致性…）強化因果論證——它是判斷輔助，不是打勾清單

教學重點 任何一關沒過，就只能說「有關聯」； Bradford Hill 是判斷輔助，不是打勾清單。

干擾因子長什麼樣？經典例子

咖啡、吸菸與心臟病

表面上的關聯

觀察到：喝咖啡的人心臟病較多

看似『咖啡 → 心臟病』

但…喝咖啡的人也比較常吸菸

而吸菸才是真正傷心臟的原因

→ 吸菸『干擾』了咖啡與心臟病的關係

干擾因子的三條件

① 與『暴露』有關（吸菸↔咖啡）

② 是『結果』的獨立風險因子（吸菸→心臟病）

③ 不在因果路徑上（不是咖啡造成吸菸）

三者都成立 → 它就是干擾因子

控制它之後，咖啡的關聯可能消失

教學重點　辨識干擾因子不是統計問題，是『領域知識』問題——你要先懂這個病，才知道誰可能是干擾因子。健康科技研究常忽略年齡、疾病嚴重度、社經地位這些強干擾因子。

怎麼對付干擾因子？設計期 vs 分析期

四種常用手段

階段	方法	做法	限制
設計期	隨機分配	RCT 隨機分組，讓干擾因子平均分布	成本高、非人人可行
設計期	限制 / 配對	只收特定族群，或病例對照配對	犧牲外推性、可配對數有限
分析期	分層分析	按干擾因子分層各自看關聯	層太多時樣本被切碎
分析期	多變量迴歸	把干擾因子一起放進模型調整	只能調整『量得到』的因子

教學重點　關鍵限制：統計調整只能處理『你有量到』的干擾因子。沒量到的（殘餘干擾）調不掉——這就是為什麼隨機化如此珍貴，它連你想不到的因子也一起平衡了。

從『關聯』到『因果』： Bradford Hill 準則

不是打勾清單，是輔助判斷的視角

① **強度**　關聯越強，越不可能只是干擾造成

② **一致性**　不同人群、不同研究都看到同樣關聯

③ **時序性**　暴露一定要在疾病『之前』（最關鍵、不可少）

④ **劑量反應**　暴露越多、風險越高（有梯度）

⑤ **生物合理性**　有可解釋的機制

⑥ **可逆性**　移除暴露後風險下降（實驗性證據最有力）

教學重點　別把它當『滿足幾條就算因果』的計分表。 Hill 本人強調這是幫助思考的視角；其中『時序性』是唯一近乎必要的條件——結果不可能發生在原因之前。

4

PART 4

你的檢測 / 模型到底準不準?

敏感度、特異度、 PPV/NPV 、概似比

Part 4 | 診斷準確度 Diagnostic Accuracy

健康科技被問最多的問題。

答錯一個指標，整個產品的價值判斷都會歪掉。

診斷的 2×2：檢測結果 vs 真實狀態

對照的是『黃金標準 gold standard』

	真的有病 D+	真的沒病 D−
檢測陽性 T+	TP 真陽性	FP 偽陽性（虛驚）
檢測陰性 T−	FN 偽陰性（漏掉）	TN 真陰性

兩種錯誤，代價不同：

- **偽陰性 FN（漏診）**：癌症沒驗出來 → 延誤治療，通常最不能忍。
- **偽陽性 FP（虛驚）**：沒病卻被判陽性 → 白受驚、多做侵入性檢查。

教學重點　設計檢測前先問：這個情境『漏掉』和『誤報』哪個代價高？篩檢工具通常要高敏感度（寧可虛驚不可漏診）；確診工具要高特異度（不冤枉好人）。

敏感度與特異度：檢測『本身』的能力

分母是『真實狀態』，不受盛行率影響

敏感度 Sensitivity

＝ TP ÷ (TP+FN)

『真的有病的人裡，抓出幾成』

高敏感度 → 漏診少

陰性時最有價值： SnNout

（Sn 高、結果 N → 可 rule out 排除）

例：敏感度 90% → 100 病人抓出 90

特異度 Specificity

＝ TN ÷ (TN+FP)

『真的沒病的人裡，正確排除幾成』

高特異度 → 誤報少

陽性時最有價值： SpPin

（Sp 高、結果 P → 可 rule in 確診）

例：特異度 90% → 100 健康者正確排除 90

教學重點 關鍵性質：敏感度與特異度是檢測的『固有能力』，不隨疾病多不多而變。所以廠商最愛報這兩個——但病人真正想知道的『我陽性到底有多可能真的有病』，要看下一頁的 PPV。

PPV / NPV： 病人真正在問的問題

分母是『檢測結果』，會隨盛行率大幅改變

陽性預測值 PPV

＝ TP ÷ (TP+FP)

『驗出陽性的人裡，真的有病的比例』

病人問：我陽性，到底多可能真的病了?

高度依賴盛行率!

盛行率低 → PPV 會很低（下一頁詳解）

陰性預測值 NPV

＝ TN ÷ (TN+FN)

『驗出陰性的人裡，真的沒病的比例』

病人問：我陰性，能多放心?

盛行率低時 NPV 通常很高

→ 篩檢陰性可安心，陽性需複檢

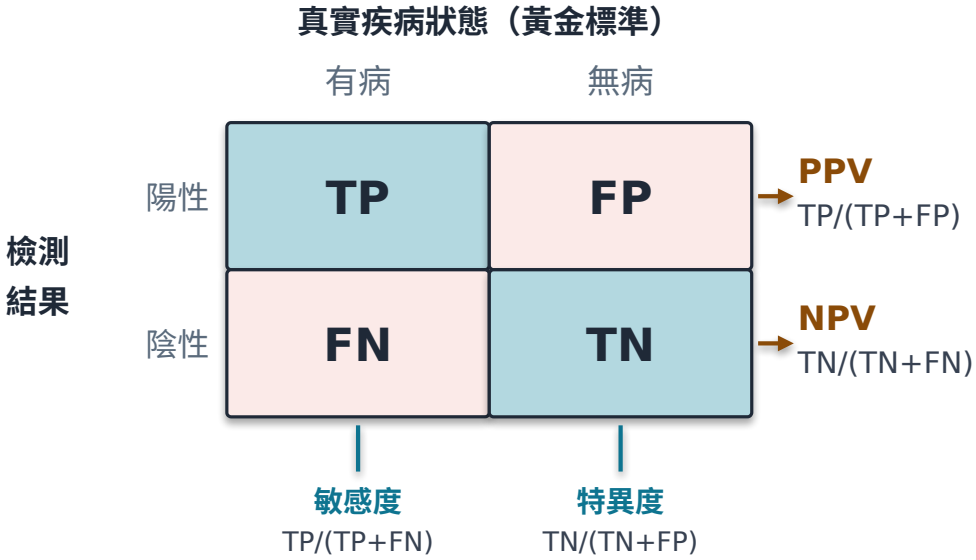
教學重點 最重要觀念：敏感度 / 特異度是『檢測的性質』， PPV/NPV 是『用在某個人群的結果』。同一個檢測，用在高風險門診 vs 全民篩檢， PPV 天差地別。

敏感度 / 特異度 vs PPV/NPV：方向不同

直行看真實狀態，橫列看檢測結果

直行↓＝以「真實狀態」為分母
→ 敏感度 / 特異度
（檢測的固有性質，不隨盛行率改變）

橫列→＝以「檢測結果」為分母
→ PPV/NPV
（會隨盛行率大幅改變）



教學重點　敏感度與特異度是檢測的固有性質； PPV/NPV 會隨盛行率大幅改變——換場域就要重算。

篩檢的陷阱：好檢測用在罕見病也會誤報一堆

同一個 90%/90% 檢測，兩種盛行率

盛行率	族群（N）	TP	FP	PPV	解讀
10%（高風險門診）	1,000	90	90	50.0%	陽性者一半真的有病
2%（全民篩檢）	10,000	180	980	15.5%	陽性者約 6.5 個才 1 個真病

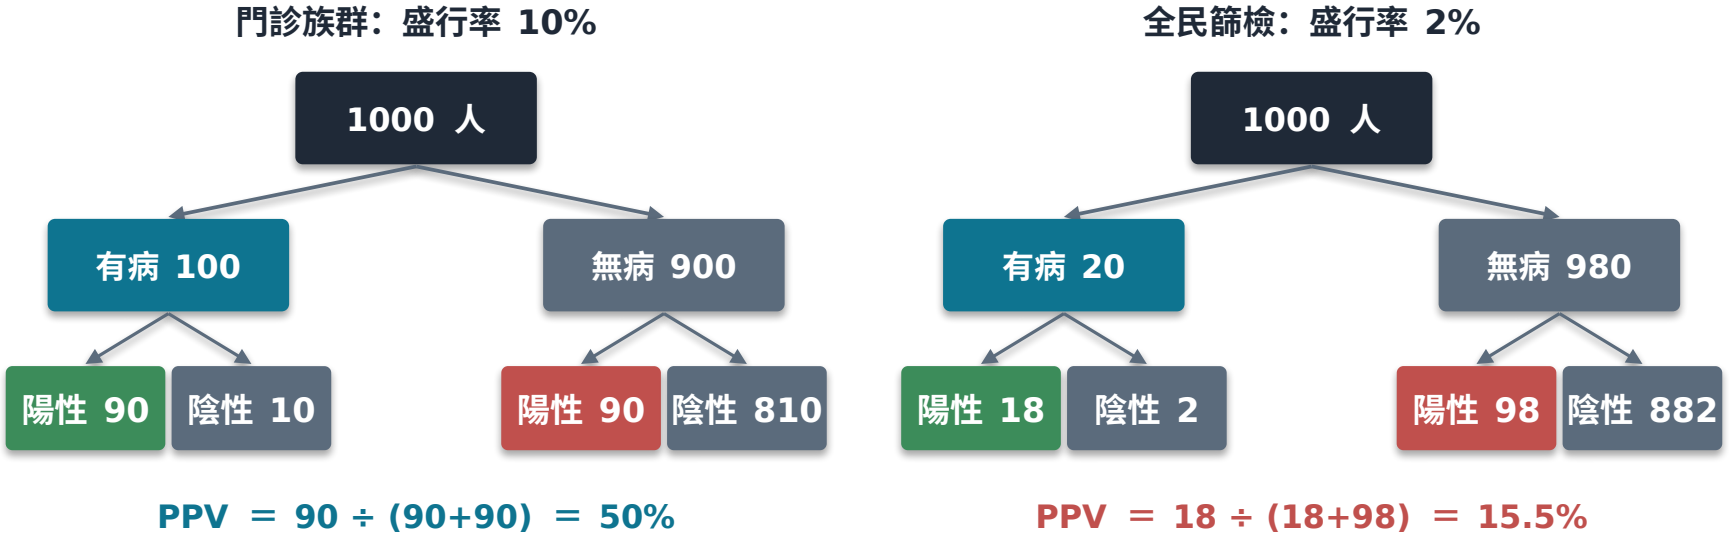
為什麼？盛行率 2% 時，沒病的人太多（9,800），就算只誤報 10%，也產生 980 個偽陽性，把 180 個真陽性淹沒了。

教學重點　這是健康科技最致命的誤區：拿高敏感度 / 特異度的穿戴式篩檢直接對全民推廣，會製造海量假警報——嚇到使用者、塞爆醫療系統。低盛行率情境務必先算 PPV。

同一支檢測、兩種盛行率：自然頻率樹

用 1,000 人把數字攤開來看

同一支檢測（敏感度 90%、特異度 90%），盛行率一變，陽性預測值天差地別



教學重點　低盛行率族群篩檢時，即使檢測很準，陽性者中大多數仍是偽陽性——這是篩檢政策的核心難題。

概似比 LR：一個數字同時濃縮敏感度與特異度

而且能直接更新『這個人』的患病機率

公式與計算

陽性概似比 LR+ = 敏感度 ÷ （1− 特異度）

= 0.90 ÷ 0.10 = 9.0

陰性概似比 LR− = （1− 敏感度） ÷ 特異度

= 0.10 ÷ 0.90 = 0.11

LR 不隨盛行率變（像敏感度 / 特異度）

怎麼解讀（經驗分級）

LR+ >10 或 LR− <0.1 → 強，足以改變決策

LR+ 5–10 / LR− 0.1–0.2 → 中等

LR+ 2–5 / LR− 0.2–0.5 → 微弱

LR ≈ 1 → 這個檢測沒提供資訊

本例 LR+ =9 （近強）， LR− =0.11 （近強）

教學重點 LR 的威力：後測勝算 = 前測勝算 × LR。它把『檢測結果』直接翻譯成『這個病人患病機率該往上或往下調多少』——這正是臨床決策與貝氏思維要的東西。

5

PART 5

連續分數要在哪裡切？模型好不好？

ROC/AUC 、切點選擇、校準、醫療 AI 指標、 STARD

Part 5 | ROC 與模型評估

敏感度 / 特異度是『某一個切點』的成績。

ROC 讓你一次看完『所有切點』的表現。

ROC 曲線是怎麼來的?

把每個可能的切點都畫成一個點

座標與畫法

模型 / 檢測輸出的是『連續分數』
每設一個切點，就得到一組敏感度 / 特異度
Y 軸：敏感度（真陽性率 TPR）
X 軸： 1− 特異度（偽陽性率 FPR）
把所有切點連起來 → ROC 曲線
左上角 (0,1) ＝完美：全抓到又不誤報

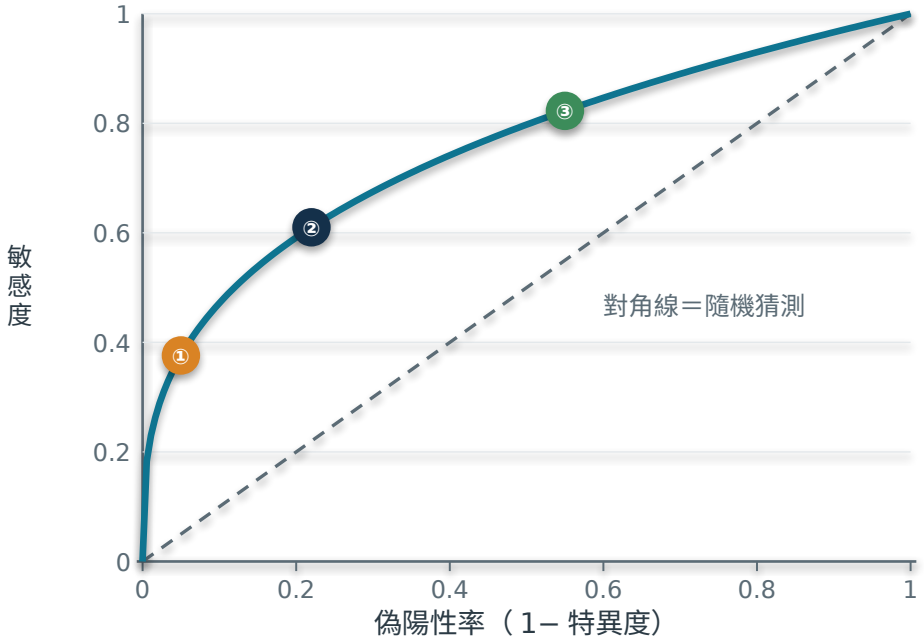
怎麼讀

曲線越往『左上角』貼 → 越好
對角線＝隨機猜（毫無區辨力）
切點往嚴格移：特異度↑、敏感度↓
切點往寬鬆移：敏感度↑、特異度↓
→ ROC 就是這個取捨的全景圖

教學重點 直覺： ROC 攤開了『敏感度 vs 特異度』永遠的拉鋸。你沒辦法同時把兩個都拉到 100%——ROC 幫你看清，在每個取捨點上各能拿到多少。

ROC 上的切點：要少漏診還是少誤報?

每一個點，都是一個切點決策



① 高特異度切點（門檻設高）
敏感度 0.38 、偽陽性率 0.05
少誤報、漏診多 → 適合確診

② 平衡切點（Youden 指數最大）
敏感度 0.61 、偽陽性率 0.22
J ＝敏感度＋特異度− 1 ＝ .39 ，兩種錯誤折衷

③ 高敏感度切點（門檻設低）
敏感度 0.82 、偽陽性率 0.55
少漏診、誤報多 → 適合篩檢

教學重點　沒有通用的「最佳切點」：篩檢重敏感度、確診重特異度，取決於漏診與誤報的代價。

AUC：把整條曲線濃縮成一個分數

曲線下面積 = 區辨能力 Discrimination

AUC 是什麼

= ROC 曲線下的面積（0.5 ～ 1.0）

機率解讀：隨機抽一個病人、一個健康者，

模型給『病人』更高分的機率

0.5 =亂猜； 1.0 =完美區辨

不受切點與盛行率影響 → 常用來比模型

經驗分級（Hosmer-Lemeshow）

0.5 = 沒有區辨力（等於擲硬幣）

0.7–0.8 = 可接受 Acceptable

0.8–0.9 = 優良 Excellent

≥ 0.9 = 卓越 Outstanding

但： AUC 高 ≠ 臨床有用（見校準頁）

教學重點 別被單一 AUC 沖昏頭：它只講『排序 / 區辨』能力，不講『預測的機率準不準（校準）』，也不管盛行率。醫療 AI 論文只報 AUC 而不報校準與 PPV，是常見的紅旗。

切點怎麼選？沒有『最佳』，只有『最適合情境』

四種常見策略

策略	怎麼選	適用情境
Youden 指數 J	選 J＝敏感度 + 特異度− 1 最大的點	想在敏感度與特異度間取平衡
固定高敏感度	先要求敏感度 ≥ 95%，再看特異度	篩檢：漏診代價高（如癌症初篩）
固定高特異度	先要求特異度 ≥ 95%，再看敏感度	確診：誤報代價高（如侵入性治療前）
成本 / 效益	納入 FP、 FN 的實際代價與盛行率	有明確成本資料時最理想

例： 三個候選切點 J 值分別為 0.65、 0.73、 0.65 → 選 J=0.73 那個做為平衡切點；但若是初篩，寧可挑敏感度最高的。

教學重點 切點是『價值判斷』不是『數學最佳解』。同一條 ROC，篩檢工具與確診工具會選在完全不同的位置。報告時務必說明切點怎麼定、為什麼。

區辨 vs 校準：兩件不一樣的『準』

一個好模型兩者都要

區辨 Discrimination

能不能『把病人和健康者分開排序』

指標： AUC / C-statistic

回答：高風險的人分數有沒有比較高?

AUC 0.9 但可能『機率數字』全都偏高

→ 排序對，數字不一定對

校準 Calibration

預測的『機率』和實際發生率合不合

看校準曲線 / Brier score

回答：模型說 30% 的那群，真的約 30% 發病嗎?

對『給病人看風險數字』極重要

→ 臨床決策與信任的關鍵

教學重點 舉例：一個模型 AUC=0.85 （區辨很好），卻把每個人的風險都算成 2 倍（校準很差）。拿它去跟病人說『你有 60% 機率』會嚴重誤導。健康科技模型一定要同時報這兩者。

醫療 AI 的指標：其實就是同一張表換名字

資料科學 vs 流病，術語對照

AI/ML 術語	流病術語	公式	注意
Recall 召回率	敏感度 Sensitivity	TP÷(TP+FN)	抓到多少真陽性
Precision 精確率	陽性預測值 PPV	TP÷(TP+FP)	隨盛行率變（會被不平衡資料坑）
Specificity	特異度	TN÷(TN+FP)	正確排除的比例
F1-score	（無對應）	精確率與召回率的調和平均	類別不平衡時比 accuracy 可靠
Accuracy 準確率	正確率	(TP+TN)÷N	罕見病時會極度誤導！

教學重點 最大陷阱是『Accuracy』：一個病盛行率 1% 的資料，模型全部猜『沒病』就有 99% 準確率——卻毫無用處。醫療 AI 一定要看召回率（敏感度）、精確率 (PPV) 與 AUC，別被 accuracy 騙。

報告規範：診斷準確度研究用 STARD 2015

30 項清單，讓你的研究可信、可重現

流程圖　附『病人流動圖』：多少人納入、多少人被排除、多少有黃金標準結果

參考標準　清楚說明『黃金標準』是什麼、怎麼判定、是否盲性判讀

納入方式　連續納入還是選樣？（選樣易高估準確度＝ spectrum bias ）

2×2 與指標　報 TP/FP/FN/TN 原始數字＋敏感度 / 特異度 /PPV/NPV 及其信賴區間

切點決定　切點是事先定的還是資料挑的？（事後挑會高估）

缺失與不確定　多少人缺結果、如何處理；避免只報最漂亮的子群

教學重點　為什麼要遵循 STARD：診斷準確度研究最容易被『選樣、事後挑切點、缺失資料』灌水。依 STARD 完整揭露，是讓審稿人與臨床端相信你數字的最低門檻。（ STARD 2015 共 30 項，見 equator-network.org ）

6

PART 6

一個穿戴式心律偵測 App，從資料到報告

把 Part 1–5 全部串起來

Part 6 ｜綜合實例 Worked Example

情境：某公司做了一款用 PPG 光學感測偵測『心房顫動 AF』的手環。
我們用一個驗證研究，走完整套流病與診斷準確度分析。

第一步：把研究講清楚（設計 + 黃金標準）

對應 STARD 的納入與參考標準

研究設計

- 地點：某醫學中心心臟科門診
- 對象：連續納入就診成人 1,000 人
- 指標檢測：手環 App 判讀是否 AF
- 黃金標準： 12 導程 ECG，兩位心臟科醫師盲性判讀（不知手環結果）
- AF 盛行率（此門診）＝ 10% → 100 人 AF

為什麼這樣設計

- 連續納入 → 避免選樣偏誤 (spectrum bias)
- 盲性判讀 → 避免資訊偏誤
- 門診族群盛行率高 → 適合先驗證能力
- 先固定切點（事先定，非事後挑）

→ 這些都是 STARD 要你交代的重點

教學重點 第一步不是算數字，是把『誰、在哪、跟什麼比、怎麼判讀』說清楚。這決定了你的準確度數字可不可信——設計有偏誤，後面算得再漂亮都沒用。

第二步：填 2×2，算核心指標

門診驗證結果（切點已固定）

	真 AF (ECG+)	真無 AF (ECG−)	合計
手環 陽性	90 (TP)	90 (FP)	180
手環 陰性	10 (FN)	810 (TN)	820
合計	100	900	1,000

敏感度 = 90/100 = **90%**　特異度 = 810/900 = **90%**

PPV = 90/180 = **50%**　NPV = 810/820 = **98.8%**　LR+ = 9.0、LR− = 0.11

教學重點　門診裡看起來不錯：漏診少（NPV 98.8%），陽性者有一半真的 AF（PPV 50%）。但這是『10% 盛行率』的門診——下一步看看推到全民會怎樣。

第三步：推到真實部署， PPV 會崩

同一支手環，全民篩檢 AF 盛行率只有 ~2%

情境	盛行率	真陽 TP	偽陽 FP	PPV	意義
門診驗證（N=1,000）	10%	90	90	50.0%	陽性者一半真 AF
全民篩檢（N=10,000）	2%	180	980	15.5%	陽性者近 6.5 個才 1 個真 AF

同一支手環、同樣 90%/90%， **PPV 從 50% 掉到 15.5%**—— 因為健康人變超多，偽陽性淹沒真陽性。

教學重點 這就是 Part 4 篩檢陷阱的真實版：手環對『心悸就醫者』很有用，直接對『全民』推廣卻會製造大量假警報。行銷可以說 90%/90%，但論文與說明書必須揭露部署情境的 PPV。

第四步：用 AI 輔助分析的『可以』與『不可以』

把 AI 當工具，判斷留給你

✓ 可以放心用 AI

- 請它列出 STARD 30 項、逐項自我檢查
- 讓它把 2×2 換算成各種指標並交叉驗算
- 請它生成 ROC/ 校準圖的繪圖程式碼
- 把方法段草稿請它潤飾成 STARD 用語
- 請它扮演審稿人挑你報告的漏洞

✗ 不要交給 AI 的

- 不要讓它『幫你決定切點』而不看情境成本
- 不要照抄它給的盛行率 /AUC 數字（會幻覺）
- 不要用它捏造或填補缺失的病人資料
- 不要只報它挑出來最漂亮的子群結果
- 不要略過臨床 / 領域判斷全信模型輸出

教學重點 原則： AI 加速『計算、檢查、寫作』，但『這個檢測能不能用、切點設在哪、對誰有害』是價值與臨床判斷，必須由你（和臨床合作者）負責。所有 AI 產出的數字都要回原始資料核對。

本課總覽：一頁看完你學到什麼

從人群到檢測，一條線串起來

疾病頻率 盛行率（存量） vs 發生率（新增）；發生密度用人時；別拿使用者數當盛行率

效應測量 2×2 → RR （幾倍） /RD （幾個） /OR；病例對照只能用 OR；同時看相對與絕對

因果 先排除偏誤 / 干擾 / 機遇；時序性最關鍵；相關≠因果

診斷準確度 敏感度 / 特異度是固有能力； PPV/NPV 隨盛行率變； LR 濃縮兩者

ROC/ 模型 AUC 看區辨、校準看機率準不準；切點是價值判斷；醫療 AI 別信 accuracy

報告 診斷準確度研究依 STARD 2015；揭露流程、切點、缺失，才可信

教學重點 帶走一句話：健康科技的價值，最終要用『這個檢測 / 模型對這群人，準到什麼程度、代價是什麼』來證明——而這正是這一課給你的語言與工具。

作業

把這一課用在一個新的檢測上

Part A 觀念題 · Part B 實作題（附參考答案）

帶回家作業 Take-home Assignment

作業目標：熟悉頻率 / 效應指標的計算與解讀，
並能完整分析一個診斷準確度研究、依 STARD 報告。

作業 Assignment

作業說明與繳交

建議 3–4 頁；重點是推理過程，不是背公式

形式與繳交

- 形式：一份報告（PDF 或 Word）
- 篇幅： Part A 每題 3–5 句； Part B 完整計算
- 可用試算表 /Python，附上計算過程
- 獨立完成；可用 AI 協助但需自行核對
- 繳交期限：兩週後上課前

評分重點

- 指標算對且單位 / 分母正確（30%）
- PPV 隨盛行率變化的解讀（20%）
- 切點選擇有結合情境說理（20%）
- STARD 關鍵項目有交代（20%）
- 表達清楚、可重現（10%）

情境（Part B 共用）： 你要驗證一款用血糖趨勢預測『低血糖事件』的 AI 手環，黃金標準為連續血糖監測 CGM。

教學重點 寫作提醒：每個數字都要標明分子、分母與情境。審稿人（和老師）看的是你有沒有理解『這個數字在回答什麼問題』，而不是有沒有背對公式。

四題觀念題（每題 3–5 句）

不用算，用你的話講清楚

A1 某 App 宣稱『使用者中 30% 有睡眠問題』，就推論『全國 30% 的人有睡眠問題』。這犯了什麼錯？用盛行率與樣本代表性說明。

A2 一則新聞：『每天喝含糖飲料，糖尿病風險增加 50%！』你會追問哪三件事，才能判斷這是不是誇大或有干擾？

A3 為什麼『敏感度 / 特異度』不隨盛行率變，但『PPV』會？用分母的角度解釋。

A4 一個醫療 AI 論文只報 accuracy = 98% 就宣稱成功。為什麼在罕見疾病上這可能毫無意義？該補報哪些指標？

教學重點 提示：A1 想『分母是誰』；A2 想 Bradford Hill 與干擾；A3 想固有能力 vs 人群結果；A4 想類別不平衡與 accuracy 陷阱。

作業 · Part B ｜實作題

低血糖預測手環：完整分析（附資料）

把 Part 1–5 全部用上

	真的低血糖（CGM+）	沒有低血糖（CGM−）
手環 陽性	160 (TP)	240 (FP)
手環 陰性	40 (FN)	1,560 (TN)

驗證族群共 2,000 人（住院高風險病人）。請完成：

B1　算敏感度、特異度、 PPV 、 NPV 、 LR+ 、 LR− （列出分子分母）。

B2　此族群低血糖盛行率是多少？若改用在盛行率 2% 的居家族群， PPV 大約變成多少？（自行設 N 計算）

B3　這支手環該走『高敏感度』還是『高特異度』的切點？結合低血糖漏診的後果說明。

B4　列出你會依 STARD 報告的 5 個關鍵項目，並各寫一句你會怎麼交代。

教學重點　B2 是本作業的靈魂：親手體會『同一支手環，換個族群 PPV 就崩』。這是你未來評估任何健康科技篩檢產品時，最該先問的一題。

延伸閱讀 References

想更深入可以看這些

經典教科書、報告規範與工具

流行病學 Gordis, Epidemiology； Rothman, Modern Epidemiology — 頻率、關聯、因果的標準教材

診斷準確度 Bossuyt et al., STARD 2015 （Radiology / BMJ）； Akobeng, 概似比與後測機率 (Acta Paediatr, 2007)

STARD 清單 EQUATOR Network： www.equator-network.org → STARD 2015 （30 項）與流程圖範本

模型評估 Hosmer & Lemeshow, Applied Logistic Regression （AUC 分級）； Steyerberg, Clinical Prediction Models （校準）

醫療 AI TRIPOD+AI （2024）與 PROBAST+AI — 預測模型的開發、驗證與偏誤評估規範

因果 Hill (1965), The Environment and Disease: Association or Causation? — Bradford Hill 準則原文

教學重點 下一步：本單元延伸『2.5 推論統計』，並銜接『9.3 觀察性研究＋ STROBE』與『9.5 醫療 AI 研究法＋ TRIPOD+AI』。報告規範全貌見 EQUATOR Network。

單元 9 · 健康科技研究方法

三個問題，一套語言

這病多常見？這因子有關係嗎？這檢測 / 模型準不準？
把這三題答好，你的健康科技研究就站得住腳。

敏感度 · 特異度 · PPV/NPV · 概似比 · ROC/AUC · 校準 · STARD

案例應用： AI 摘要漏掉重要事項，測得出來嗎

案例 Q ｜ AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①	**本單元教了什麼**	效應測量、干擾，以及診斷準確度的 2×2 表與 ROC 判讀。
②	**案例怎麼用**	· 自後測期抽 400 次交班（summary_audit.csv），由兩位護理師比對原紀錄判定是否遺漏。 · 遺漏率 12.2%；以 AI 自評信心 < 0.52 為警示閾值建 2×2 表。 · 敏感度 75.5%、特異度 70.1%， AUC = 0.817 （95% CI [0.742, 0.891]）。 · PPV 僅 26.1%—— 警示四次只有一次真的漏掉，這是低盛行率的必然結果。 · NPV 達 95.3%：不警示時大致可信，此為本工具較有價值的用法。
③	**產出什麼證據**	2×2 表與 ROC 判讀（次頁），納入論文第四章第七節。
④	**承接關係**	上游：承自 9.1 之資料元素對照表 ｜ 下游：交棒 9.3，若改用既有紀錄做回溯研究該怎麼設計。

教學重點 同一個 AUC = 0.82 的工具，在盛行率 12% 的場域 PPV 只有 26%。準確度指標與盛行率脫鉤，臨床意義就會被誤讀——這是健康科技評估最常見的陷阱。

Case Application · 示範產物

示範產物： 2×2 表與準確度指標

n = 400；閾值 AI 自評信心 < 0.52 判為警示；金標準為兩位護理師之獨立比對

	實際遺漏	實際未遺漏	指標
判為警示	37 （真陽性）	105 （偽陽性）	PPV = 26.1%： 警示四次約一次為真
未警示	12 （偽陰性）	246 （真陰性）	NPV = 95.3%： 不警示時大致可信
合計	49 （ 12.2% ）	351	盛行率 12.2%
準確度指標	敏感度 75.5%	特異度 70.1%	LR+ = 2.52 、 LR− = 0.35
整體判別力	AUC = 0.817	95% CI [0.742, 0.891]	屬優良（ 0.8–0.9 ）；惟須看分層結果（單元 9.5 ）

教學重點 12 個偽陰性是這張表最該被討論的一格：真的漏了、 AI 也沒警示。若此工具被當成安全網使用，這 12 次就是實際的病人風險，必須寫進限制與風險管理。