

流行病學與健康生統

Epidemiology & Health Biostatistics

從『多少人得病』到『這個檢測準不準』——含診斷準確度與 ROC 曲線。

敏感度 · 特異度 · PPV/NPV · 概似比 · ROC/AUC · STARD

這堂課會帶你走過的六個部分

流病語言 → 效應測量 → 因果 → 診斷準確度 → ROC 與模型評估 → 綜合實作

部分	主題	你會學到
Part 1	疾病頻率 Frequency	盛行率 vs 發生率、發生密度、怎麼算、怎麼解讀
Part 2	關聯與效應 Association	2×2 表、RR / OR / 風險差、NNT，什麼設計配什麼指標
Part 3	偏誤・干擾・因果	選樣/資訊偏誤、干擾因子、控制方法、Bradford Hill
Part 4	診斷準確度 Accuracy	敏感度/特異度、PPV/NPV、概似比，篩檢的陷阱
Part 5	ROC 與模型評估	ROC/AUC、切點選擇、校準 vs 區辨、醫療 AI 指標、STARD
Part 6	綜合實例 + 作業	穿戴式心律偵測 App：從資料到報告一次走完

教學重點 | 一句話抓重點：流病回答『疾病在人群怎麼分布、和什麼有關』；生統給你算的工具；診斷準確度與 ROC 則回答健康科技最常被問的——『你的檢測/模型到底準不準？』

為什麼健康科技研究一定要懂這一課

你做的 App、感測器、AI 模型，最後都要用這套語言被檢驗

沒有這課，你會...

- 把『很多人用』當成『疾病很常見』（混淆盛行率與發生率）
- 宣稱『準確率 95%』卻在罕見病上完全誤導人
- 把相關當因果，忽略干擾因子
- 投稿被審稿人以『未依 STARD 報告』退件

有了這課，你能...

- 正確描述疾病負擔與風險（RR/OR/風險差）
- 讀懂並計算敏感度、特異度、PPV、概似比
- 畫 ROC、選切點、評估 AI 模型的區辨與校準
- 依 STARD 完整報告一個診斷準確度研究

這一課是『2.5 推論統計』的健康應用延伸：把 p 值與信賴區間，放進『疾病、風險、檢測』的真實情境。

教學重點 | 健康科技的三大核心問題都在這課：① 這病有多常見？② 這因子有沒有關係？③ 這個檢測/模型可靠嗎？把這三題答好，你的研究就站得住腳。

1

Part 1 | 疾病頻率 Disease Frequency

疾病在人群中有多少？

盛行率、發生率、發生密度

先學會『數對人』：分子是誰、分母是誰、時間怎麼算。

這是所有流病指標的地基——數錯了，後面全錯。

盛行率 vs 發生率：最常被搞混的一對

一個是『此刻有多少』，一個是『新增了多少』

盛行率 Prevalence

= 某時點『現有』病例 ÷ 全體人口

回答：現在有多少人帶著這個病？

像『拍一張快照』（橫斷面）

受發生率 + 病程長短影響

例：全台糖尿病盛行率約 11%

→ 適合規劃醫療資源、需求評估

發生率 Incidence

= 某期間『新發生』病例 ÷ 有風險人口

回答：一段時間內多了多少新病人？

像『錄一段影片』（追蹤）

反映『得病的風險/速度』

例：每年每千人新增 3 例

→ 適合研究病因、風險因子、預防

關鍵直覺：盛行率 $\approx$ 發生率 $\times$ 平均病程。慢性病（病程長）盛行率會被『累積』撐高，即使新發生的人不多。

教學重點 | 健康科技常見錯誤：用 App 下載/使用人數推論『疾病很普遍』。使用者多 $\neq$ 盛行率高——那是自我選擇樣本，不是有代表性的人口分母。

盛行率 vs 發生率：浴缸模型

存量與流量，一張圖分清楚



水位（盛行率）取決於「流進來多快」與「流出去多快」——療效變好、存活變長，盛行率反而上升

教學重點 | 療效變好、病人活得久，盛行率反而上升——盛行率升高不等於疫情惡化；要判斷是哪一種，一定要回頭看發生率。

發生率的兩種算法：累積發生率 vs 發生密度

差別在分母——用『人數』還是『人時』

指標	分母	公式	何時用
累積發生率 Cumulative Incidence	期初有風險『人數』	新病例 ÷ 期初有風險人數	追蹤期固定、失訪少（如一年追蹤）
發生密度/率 Incidence Rate	累積『人時』 person-time	新病例 ÷ 總人時	追蹤期不一、有人中途退出/加入

為什麼要用『人時』？因為每個人被觀察的時間不一樣。追蹤 10 人各 1 年 = 10 人年；追蹤 20 人各半年也是 10 人年。用人時才公平。

教學重點 | 單位要說清楚：發生密度一定要帶時間，例如『每 1,000 人年 3 例』。只寫『3 例』或『3%』而不講分母與期間，讀者無法判讀。

動手算一次：一個社區的一年

同一份資料，三個指標算出來完全不同

情境設定

某社區 10,000 人，觀察 1 年：

- 1/1 當天已有 500 人患病（既有病例）
- 年初『有風險』人口 = $10,000 - 500 = 9,500$
- 這一年新診斷出 200 例
- 假設新病例平均在年中發病（各貢獻半年）

計算結果

時點盛行率 = $500 \div 10,000 = 5.0\%$

累積發生率 = $200 \div 9,500 \approx 2.1\%$ （一年）

人時 $\approx 9,300 \times 1 + 200 \times 0.5 \approx 9,400$ 人年

發生密度 $\approx 200 \div 9,400 \approx 21.3$ /千人年

→ 盛行(5%) 反映『累積存量』

→ 發生(2.1%) 反映『這一年的新風險』

教學重點 | 看懂差異：盛行率高不代表最近很多人得病——可能是病人活得久、病程長而累積。要談『預防有沒有效』，看發生率才對。

2

Part 2 | 關聯與效應 Measures of Association

這個因子和疾病有沒有關係？有多強？

2×2 表、相對風險、勝算比、風險差、NNT

把『暴露』與『疾病』擺進一張 2×2 表，
就能算出風險到底差多少、差幾倍。

一切從這張 2×2 表開始

記住四格的名字，後面每個指標都從這裡來

	有病 D+	沒病 D-	合計
有暴露 E+	a (真的暴露又生病)	b	a+b
無暴露 E-	c	d	c+d
合計	a+c	b+d	N

暴露 Exposure = 你關心的因子 (吸菸、久坐、用某 App、帶某基因) ; **疾病 Outcome** = 你關心的結果 (發病、住院、死亡) 。

教學重點 | 提醒：a、b、c、d 是『人數』。所有效應指標 (風險、勝算、RR、OR) 都只是這四個數字的不同組合方式——不要背公式，理解它在算什麼。

2×2 表：每個效應指標從哪裡來

先認四格，再算 RR、OR、RD、NNT

從同一張表算出來的指標

風險 Risk = $a / (a+b)$

RR = $[a/(a+b)] \div [c/(c+d)]$

勝算 Odds = a / b

OR = $(a/b) \div (c/d) = ad/bc$

RD = 風險差 ; NNT = $1/RD$

		結果 Outcome	
		有	無
暴露 Exposure	有	a	b
	無	c	d

a、b、c、d 都是「人數」；先確認分母是誰，才知道這個指標能不能算

教學重點 | 算之前先問分母是誰：病例對照研究沒有真正的分母，所以只能算 OR、不能算 RR。

風險 vs 勝算：兩種『可能性』的講法

同一件事，分母不同

風險 Risk (機率)

= 發生數 ÷ 全部人

暴露組風險 = $a \div (a+b)$

範圍 0 ~ 1，就是日常說的『機率』

例：100 人中 20 人生病 → 風險 0.20

→ 直覺、好溝通

勝算 Odds

= 發生數 ÷ 未發生數

暴露組勝算 = $a \div b$

範圍 0 ~ ∞ ，是『發生：不發生』的比

例：20 生病：80 沒病 → 勝算 0.25

→ 病例對照研究、羅吉斯迴歸在用

兩者關係：疾病很罕見時，勝算 $\approx$ 風險 (分母 $a+b \approx b$)；疾病常見時，兩者差很大。這正是下一頁 OR 為何會高估 RR 的原因。

教學重點 | 一句話：風險的分母是『所有人』，勝算的分母是『沒發生的人』。搞清楚分母，就不會把 RR 和 OR 講反。

三個效應指標一次算：RR、OR、風險差

用同一個世代研究資料

資料：久坐與代謝症候群

世代追蹤：久坐組 1,000、非久坐組 1,000

久坐組：200 人發病 (風險 0.20)

非久坐組：100 人發病 (風險 0.10)

2×2：a=200 b=800 c=100 d=900

三個指標

相對風險 $RR = 0.20 \div 0.10 = 2.0$

→ 久坐者發病風險是 2 倍

風險差 $RD = 0.20 - 0.10 = 0.10$

→ 每多 100 名久坐者，多 10 人發病

勝算比 $OR = (200/800) \div (100/900) = 2.25$

→ 因疾病不罕見，OR(2.25) 高估 RR(2.0)

教學重點 | RR 講『幾倍』(相對)，RD 講『多幾個』(絕對)——兩個都要看。相對風險再高，若絕對風險很小，實務衝擊可能有限；這是解讀健康科技成效時最常見的誤導點。

什麼設計配什麼指標？（很多人在這裡選錯）

分母能不能代表人口，決定你能算什麼

研究設計	能算風險？	主要指標	理由
世代 Cohort	能	RR、RD、發生率	從暴露往前追，分母 = 有風險人口
病例對照 Case-control	不能	OR	先挑病例與對照，發生率無法直接得出
橫斷面 Cross-sectional	盛行率	盛行勝算比 POR	同一時點量，因果先後不清
隨機試驗 RCT	能	RR、RD、NNT	隨機分組，可估因果效應

教學重點 | 實務規則：病例對照研究『只能』報 OR，不能報 RR——因為你人為決定了病例與對照的比例，分母不代表真實人口。搞錯這點，審稿人一眼看穿。

NNT：把效果翻譯成『要幫幾個人才少一個壞結果』

病人與決策者最聽得懂的數字

怎麼算

$NNT = 1 \div \text{絕對風險差(ARR)}$

介入把壞結果從 20% 降到 15%

$ARR = 0.20 - 0.15 = 0.05$

$NNT = 1 \div 0.05 = 20$

→ 每治療 20 人，可避免 1 例壞結果

為什麼重要

- NNT 小 = 效益高、CP 值高
- 把『相對降低 25%』變成可行動的數字
- NNH (傷害) 同理，用來衡量副作用
- 成本效益、健保給付常用它
- 數位介入也適用：每用幾人省一次住院

教學重點 | 警惕『相對風險降低』的行銷話術：『風險減半！』聽起來很猛，但若是從 2% 降到 1%， $NNT = 100$ ——要 100 人用才少 1 例。務必同時看絕對數字。

3

Part 3 | 偏誤・干擾・因果

關聯是真的嗎？還是假象？

選樣偏誤、資訊偏誤、干擾因子、*Bradford Hill*

看到關聯先別急著下因果結論。

先問：會不會是偏誤、干擾、或反過來的因果？

看到關聯，先排除三種『假象』

真關聯之前，先過三關

① 偏誤 Bias

系統性誤差・方向固定
選樣偏誤：找錯人
資訊偏誤：量錯/記錯
→ 設計階段就要防

② 干擾 Confounding

第三個因子同時影響
暴露與結果
造成『假關聯』或遮蔽
→ 可事後統計調整

③ 機遇 Chance

純粹運氣造成的差異
用 p 值、信賴區間評估
樣本越大越不受影響
→ 2.5 推論統計處理

再加一問：會不會是『反向因果』？例如『運動少的人比較胖』，也可能是『比較胖所以動得少』。橫斷面研究尤其要小心。

教學重點 | 順序很重要：先確認不是偏誤、干擾、機遇造成的，再談『可能有因果』。健康科技論文最常被打回票的，就是把『相關』直接當成『因為用了我的產品所以變好』。

從關聯到因果：要過三道關

偶然 → 偏誤 → 干擾



三關都過，再用 Bradford Hill 視角（時序、劑量反應、一致性...）強化因果論證——它是判斷輔助，不是打勾清單

教學重點 | 任何一關沒過，就只能說「有關聯」；Bradford Hill 是判斷輔助，不是打勾清單。

干擾因子長什麼樣？經典例子

咖啡、吸菸與心臟病

表面上的關聯

觀察到：喝咖啡的人心臟病較多

看似『咖啡 → 心臟病』

但...喝咖啡的人也比較常吸菸

而吸菸才是真正傷心臟的原因

→ 吸菸『干擾』了咖啡與心臟病的關係

干擾因子的三條件

① 與『暴露』有關（吸菸↔咖啡）

② 是『結果』的獨立風險因子（吸菸→心臟病）

③ 不在因果路徑上（不是咖啡造成吸菸）

三者都成立 → 它就是干擾因子

控制它之後，咖啡的關聯可能消失

教學重點 | 辨識干擾因子不是統計問題，是『領域知識』問題——你要先懂這個病，才知道誰可能是干擾因子。健康科技研究常忽略年齡、疾病嚴重度、社經地位這些強干擾因子。

怎麼對付干擾因子？設計期 vs 分析期

四種常用手段

階段	方法	做法	限制
設計期	隨機分配	RCT 隨機分組，讓干擾因子平均分布	成本高、非人人可行
設計期	限制/配對	只收特定族群，或病例對照配對	犧牲外推性、可配對數有限
分析期	分層分析	按干擾因子分層各自看關聯	層太多時樣本被切碎
分析期	多變量迴歸	把干擾因子一起放進模型調整	只能調整『量得到』的因子

教學重點 | 關鍵限制：統計調整只能處理『你有量到』的干擾因子。沒量到的（殘餘干擾）調不掉——這就是為什麼隨機化如此珍貴，它連你想不到的因子也一起平衡了。

從『關聯』到『因果』：Bradford Hill 準則

不是打勾清單，是輔助判斷的視角

- ① **強度** 關聯越強，越不可能只是干擾造成
- ② **一致性** 不同人群、不同研究都看到同樣關聯
- ③ **時序性** 暴露一定要在疾病『之前』（最關鍵、不可少）
- ④ **劑量反應** 暴露越多、風險越高（有梯度）
- ⑤ **生物合理性** 有可解釋的機制
- ⑥ **可逆性** 移除暴露後風險下降（實驗性證據最有力）

教學重點 | 別把它當『滿足幾條就算因果』的計分表。Hill 本人強調這是幫助思考的視角；其中『時序性』是唯一近乎必要的條件——結果不可能發生在原因之前。

4

Part 4 | 診斷準確度 Diagnostic Accuracy

你的檢測/模型到底準不準？

敏感度、特異度、PPV/NPV、概似比

健康科技被問最多的問題。

答錯一個指標，整個產品的價值判斷都會歪掉。

診斷的 2×2：檢測結果 vs 真實狀態

對照的是『黃金標準 gold standard』

	真的有病 D+	真的沒病 D-
檢測陽性 T+	TP 真陽性	FP 偽陽性 (虛驚)
檢測陰性 T-	FN 偽陰性 (漏掉)	TN 真陰性

兩種錯誤，代價不同：

- **偽陰性 FN (漏診)**：癌症沒驗出來 → 延誤治療，通常最不能忍。
- **偽陽性 FP (虛驚)**：沒病卻被判陽性 → 白受驚、多做侵入性檢查。

教學重點 | 設計檢測前先問：這個情境『漏掉』和『誤報』哪個代價高？篩檢工具通常要高敏感度（寧可虛驚不可漏診）；確診工具要高特異度（不冤枉好人）。

敏感度與特異度：檢測『本身』的能力

分母是『真實狀態』，不受盛行率影響

敏感度 Sensitivity

$$= TP \div (TP + FN)$$

『真的有病的人裡，抓出幾成』

高敏感度 → 漏診少

陰性時最有價值：SnNout

(Sn 高、結果 N → 可 rule out 排除)

例：敏感度 90% → 100 病人抓出 90

特異度 Specificity

$$= TN \div (TN + FP)$$

『真的沒病的人裡，正確排除幾成』

高特異度 → 誤報少

陽性時最有價值：SpPin

(Sp 高、結果 P → 可 rule in 確診)

例：特異度 90% → 100 健康者正確排除 90

教學重點 | 關鍵性質：敏感度與特異度是檢測的『固有能力』，不隨疾病多不多而變。所以廠商最愛報這兩個——但病人真正想知道的『我陽性到底有多可能真的有病』，要看下一頁的 PPV。

PPV / NPV : 病人真正在問的問題

分母是『檢測結果』，會隨盛行率大幅改變

陽性預測值 PPV

$$= TP \div (TP+FP)$$

『驗出陽性的人裡，真的有病的比例』

病人問：我陽性，到底多可能真的病了？

高度依賴盛行率！

盛行率低 → PPV 會很低（下一頁詳解）

陰性預測值 NPV

$$= TN \div (TN+FN)$$

『驗出陰性的人裡，真的沒病的比例』

病人問：我陰性，能多放心？

盛行率低時 NPV 通常很高

→ 篩檢陰性可安心，陽性需複檢

教學重點 | 最重要觀念：敏感度/特異度是『檢測的性質』，PPV/NPV 是『用在某個人群的結果』。同一個檢測，用在高風險門診 vs 全民篩檢，PPV 天差地別。

敏感度/特異度 vs PPV/NPV : 方向不同

直行看真實狀態，橫列看檢測結果

直行↓ = 以「真實狀態」為分母


→ 敏感度/特異度

(檢測的固有性質，不隨盛行率改變)

橫列→ = 以「檢測結果」為分母

→ PPV/NPV

(會隨盛行率大幅改變)



教學重點 | 敏感度與特異度是檢測的固有性質；PPV/NPV 會隨盛行率大幅改變——換場域就要重算。

篩檢的陷阱：好檢測用在罕見病也會誤報一堆

同一個 90%/90% 檢測，兩種盛行率

盛行率	族群 (N)	TP	FP	PPV	解讀
10% (高風險門診)	1,000	90	90	50.0%	陽性者一半真的有病
2% (全民篩檢)	10,000	180	980	15.5%	陽性者約 6.5 個才 1 個真病

為什麼？盛行率 2% 時，沒病的人太多 (9,800)，就算只誤報 10%，也產生 980 個偽陽性，把 180 個真陽性淹沒了。


教學重點 | 這是健康科技最致命的誤區：拿高敏感度/特異度的穿戴式篩檢直接對全民推廣，會製造海量假警報——嚇到使用者、塞爆醫療系統。低盛行率情境務必先算 PPV。

同一支檢測、兩種盛行率：自然頻率樹

用 1,000 人把數字攤開來看


同一支檢測（敏感度 90%、特異度 90%），盛行率一變，陽性預測值天差地別

門診族群：盛行率 10%



$$PPV = 90 \div (90 + 90) = 50\%$$

全民篩檢：盛行率 2%



$$PPV = 18 \div (18 + 98) = 15.5\%$$

教學重點 | 低盛行率族群篩檢時，即使檢測很準，陽性者中大多數仍是偽陽性——這是篩檢政策的核心難題。

概似比 LR：一個數字同時濃縮敏感度與特異度

而且能直接更新『這個人』的患病機率

公式與計算

陽性概似比 $LR+ = \text{敏感度} \div (1 - \text{特異度})$

$$= 0.90 \div 0.10 = 9.0$$

陰性概似比 $LR- = (1 - \text{敏感度}) \div \text{特異度}$

$$= 0.10 \div 0.90 = 0.11$$

LR 不隨盛行率變 (像敏感度/特異度)

怎麼解讀 (經驗分級)

$LR+ > 10$ 或 $LR- < 0.1 \rightarrow$ 強，足以改變決策

$LR+ 5-10$ / $LR- 0.1-0.2 \rightarrow$ 中等

$LR+ 2-5$ / $LR- 0.2-0.5 \rightarrow$ 微弱

$LR \approx 1 \rightarrow$ 這個檢測沒提供資訊

本例 $LR+ = 9$ (近強) · $LR- = 0.11$ (近強)

教學重點 | LR 的威力：後測勝算 = 前測勝算 $\times$ LR。它把『檢測結果』直接翻譯成『這個病人患病機率該往上或往下調多少』——這正是臨床決策與貝氏思維要的東西。

5

Part 5 | ROC 與模型評估

連續分數要在哪裡切？模型好不好？

ROC/AUC、切點選擇、校準、醫療 AI 指標、STARD

敏感度/特異度是『某一個切點』的成績。

ROC 讓你一次看完『所有切點』的表現。

ROC 曲線是怎麼來的？

把每個可能的切點都畫成一個點

座標與畫法

模型/檢測輸出的是『連續分數』

每設一個切點，就得到一組敏感度/特異度

Y 軸：敏感度（真陽性率 TPR）

X 軸：1-特異度（偽陽性率 FPR）

把所有切點連起來 → ROC 曲線

左上角(0,1) = 完美：全抓到又不誤報

怎麼讀

曲線越往『左上角』貼 → 越好

對角線 = 隨機猜（毫無區辨力）

切點往嚴格移：特異度 ↑、敏感度 ↓

切點往寬鬆移：敏感度 ↑、特異度 ↓


→ ROC 就是這個取舍的全景圖

教學重點 | 直覺：ROC 攤開了『敏感度 vs 特異度』永遠的拉鋸。你沒辦法同時把兩個都拉到 100%——ROC 幫你看清，在每個取舍點上各能拿到多少。

ROC 上的切點：要少漏診還是少誤報？

每一個點，都是一個切點決策

ROC 上每一個點＝一個切點;選哪個,取決於「漏診」與「誤報」誰的代價高



教學重點 | 沒有通用的「最佳切點」：篩檢重敏感度、確診重特異度，取決於漏診與誤報的代價。

AUC：把整條曲線濃縮成一個分數

曲線下面積 = 區辨能力 Discrimination

AUC 是什麼

= ROC 曲線下的面積 (0.5 ~ 1.0)

機率解讀：隨機抽一個病人、一個健康者，
模型給『病人』更高分的機率

0.5 = 亂猜；1.0 = 完美區辨

不受切點與盛行率影響 → 常用來比模型

經驗分級 (Hosmer–Lemeshow)

0.5 = 沒有區辨力 (等於擲硬幣)

0.7–0.8 = 可接受 Acceptable

0.8–0.9 = 優良 Excellent

≥ 0.9 = 卓越 Outstanding

但：AUC 高 ≠ 臨床有用 (見校準頁)

教學重點 | 別被單一 AUC 沖昏頭：它只講『排序/區辨』能力，不講『預測的機率準不準 (校準)』，也不管盛行率。醫療 AI 論文只報 AUC 而不報校準與 PPV，是常見的紅旗。

切點怎麼選？沒有『最佳』，只有『最適合情境』

四種常見策略

策略	怎麼選	適用情境
Youden 指數 J	選 $J = \text{敏感度} + \text{特異度} - 1$ 最大的點	想在敏感度與特異度間取平衡
固定高敏感度	先要求敏感度 $\geq 95\%$ ，再看特異度	篩檢：漏診代價高（如癌症初篩）
固定高特異度	先要求特異度 $\geq 95\%$ ，再看敏感度	確診：誤報代價高（如侵入性治療前）
例：三個候選切點 J 值分別為 0.65、0.73、0.65，選 J=0.73 那個做為平衡切點；但若是初篩，寧可挑敏感度最高的。 成本/效益	納入 FP、FN 的實際代價與盛行率	有明確成本資料時最理想

教學重點 | 切點是『價值判斷』不是『數學最佳解』。同一條 ROC，篩檢工具與確診工具會選在完全不同的位置。報告時務必說明切點怎麼定、為什麼。

區辨 vs 校準：兩件不一樣的『準』

一個好模型兩者都要

區辨 Discrimination

能不能『把病人和健康者分開排序』

指標：AUC / C-statistic

回答：高風險的人分數有沒有比較高？

AUC 0.9 但可能『機率數字』全都偏高

→ 排序對，數字不一定對

校準 Calibration

預測的『機率』和實際發生率合不合

看校準曲線 / Brier score

回答：模型說 30% 的那群，真的約 30% 發病嗎？

對『給病人看風險數字』極重要

→ 臨床決策與信任的關鍵

教學重點 | 舉例：一個模型 $AUC=0.85$ （區辨很好），卻把每個人的風險都算成 2 倍（校準很差）。拿它去跟病人說『你有 60% 機率』會嚴重誤導。健康科技模型一定要同時報這兩者。

醫療 AI 的指標：其實就是同一張表換名字

資料科學 vs 流病 · 術語對照

AI/ML 術語	流病術語	公式	注意
Recall 召回率	敏感度 Sensitivity	$TP \div (TP + FN)$	抓到多少真陽性
Precision 精確率	陽性預測值 PPV	$TP \div (TP + FP)$	隨盛行率變 (會被不平衡資料坑)
Specificity	特異度	$TN \div (TN + FP)$	正確排除的比例
F1-score	(無對應)	精確率與召回率的調和平均	類別不平衡時比 accuracy 可靠
Accuracy 準確率	正確率	$(TP + TN) \div N$	罕見病時會極度誤導！

教學重點 | 最大陷阱是『Accuracy』：一個病盛行率 1% 的資料，模型全部猜『沒病』就有 99% 準確率——卻毫無用處。醫療 AI 一定要看召回率 (敏感度)、精確率(PPV) 與 AUC，別被 accuracy 騙。

報告規範：診斷準確度研究用 STARD 2015

30 項清單，讓你的研究可信、可重現

流程圖 附『病人流動圖』：多少人納入、多少人被排除、多少有黃金標準結果

參考標準 清楚說明『黃金標準』是什麼、怎麼判定、是否盲性判讀

納入方式 連續納入還是選樣？（選樣易高估準確度 = spectrum bias）

2×2 與指標 報 TP/FP/FN/TN 原始數字 + 敏感度/特異度/PPV/NPV 及其信賴區間

切點決定 切點是事先定的還是資料挑的？（事後挑會高估）

缺失與不確定 多少人缺結果、如何處理；避免只報最漂亮的子群

教學重點 | 為什麼要遵循 STARD：診斷準確度研究最容易被『選樣、事後挑切點、缺失資料』灌水。依 STARD 完整揭露，是讓審稿人與臨床端相信你數字的最低門檻。（STARD 2015 共 30 項，見 equator-network.org）

6

Part 6 | 綜合實例 Worked Example

一個穿戴式心律偵測 App，從資料到報告

把 Part 1-5 全部串起來

情境：某公司做了一款用 PPG 光學感測偵測『心房顫動 AF』的手環。

我們用一個驗證研究，走完整套流病與診斷準確度分析。

第一步：把研究講清楚（設計 + 黃金標準）

對應 STARD 的納入與參考標準

研究設計

- 地點：某醫學中心心臟科門診
- 對象：連續納入就診成人 1,000 人
- 指標檢測：手環 App 判讀是否 AF
- 黃金標準：12 導程 ECG，兩位心臟科醫師盲性判讀（不知手環結果）
- AF 盛行率（此門診）= 10% → 100 人 AF

為什麼這樣設計

- 連續納入 → 避免選樣偏誤(spectrum bias)
 - 盲性判讀 → 避免資訊偏誤
 - 門診族群盛行率高 → 適合先驗證能力
 - 先固定切點（事先定，非事後挑）
- 這些都是 STARD 要你交代的重點

教學重點 | 第一步不是算數字，是把『誰、在哪、跟什麼比、怎麼判讀』說清楚。這決定了你的準確度數字可不可信——設計有偏誤，後面算得再漂亮都沒用。

第二步：填 2×2，算核心指標

門診驗證結果（切點已固定）

	真 AF (ECG+)	真無 AF (ECG-)	合計
手環 陽性	90 (TP)	90 (FP)	180
手環 陰性	10 (FN)	810 (TN)	820
合計	100	900	1,000

敏感度 = $90/100 = 90\%$ 特異度 = $810/900 = 90\%$

PPV = $90/180 = 50\%$ NPV = $810/820 = 98.8\%$ LR+ = 9.0、LR- = 0.11

教學重點 | 門診裡看起來不錯：漏診少（NPV 98.8%），陽性者有一半真的 AF（PPV 50%）。但這是『10% 盛行率』的門診——下一步看看推到全民會怎樣。

第三步：推到真實部署，PPV 會崩

同一支手環，全民篩檢 AF 盛行率只有 ~2%

情境	盛行率	真陽 TP	偽陽 FP	PPV	意義
門診驗證 (N=1,000)	10%	90	90	50.0%	陽性者一半真 AF
全民篩檢 (N=10,000)	2%	180	980	15.5%	陽性者近 6.5 個才 1 個真 AF

同一支手環、同樣 90%/90%，**PPV 從 50% 掉到 15.5%**——因為健康人變超多，偽陽性淹沒真陽性。

教學重點 | 這就是 Part 4 篩檢陷阱的真實版：手環對『心悸就醫者』很有用，直接對『全民』推廣卻會製造大量假警報。行銷可以說 90%/90%，但論文與說明書必須揭露部署情境的 PPV。

第四步：用 AI 輔助分析的『可以』與『不可以』

把 AI 當工具・判斷留給你

✓ 可以放心用 AI

- ・ 請它列出 STARD 30 項、逐項自我檢查
- ・ 讓它把 2×2 換算成各種指標並交叉驗算
- ・ 請它生成 ROC/校準圖的繪圖程式碼
- ・ 把方法段草稿請它潤飾成 STARD 用語
- ・ 請它扮演審稿人挑你報告的漏洞

✗ 不要交給 AI 的

- ・ 不要讓它『幫你決定切點』而不看情境成本
- ・ 不要照抄它給的盛行率/AUC 數字 (會幻覺)
- ・ 不要用它捏造或填補缺失的病人資料
- ・ 不要只報它挑出來最漂亮的子群結果
- ・ 不要略過臨床/領域判斷全信模型輸出

教學重點 | 原則：AI 加速『計算、檢查、寫作』，但『這個檢測能不能用、切點設在哪、對誰有害』是價值與臨床判斷，必須由你 (和臨床作者) 負責。所有 AI 產出的數字都要回原始資料核對。

本課總覽：一頁看完你學到什麼

從人群到檢測，一條線串起來

疾病頻率 盛行率（存量）vs 發生率（新增）；發生密度用人時；別拿使用者數當盛行率

效應測量 $2 \times 2 \rightarrow RR$ （幾倍）/ RD （幾個）/ OR ；病例對照只能用 OR ；同時看相對與絕對

因果 先排除偏誤/干擾/機遇；時序性最關鍵；相關 $\neq$ 因果

診斷準確度 敏感度/特異度是固有能力； PPV/NPV 隨盛行率變； LR 濃縮兩者

ROC/模型 AUC 看區辨、校準看機率準不準；切點是價值判斷；醫療 AI 別信 accuracy

報告 診斷準確度研究依 STARD 2015；揭露流程、切點、缺失，才可信

教學重點 | 帶走一句話：健康科技的價值，最終要用『這個檢測/模型對這群人，準到什麼程度、代價是什麼』來證明——而這正是這一課給你的語言與工具。



帶回家作業 Take-home Assignment

把這一課用在一個新的檢測上

Part A 觀念題 · Part B 實作題 (附參考答案)

作業目標：熟悉頻率/效應指標的計算與解讀，
並能完整分析一個診斷準確度研究、依 STARD 報告。

作業說明與繳交

建議 3–4 頁；重點是推理過程，不是背公式

形式與繳交

- 形式：一份報告 (PDF 或 Word)
- 篇幅：Part A 每題 3–5 句；Part B 完整計算
- 可用試算表/Python，附上計算過程
- 獨立完成；可用 AI 協助但需自行核對
- 繳交期限：兩週後上課前

評分重點

- 指標算對且單位/分母正確 (30%)
- PPV 隨盛行率變化的解讀 (20%)
- 切點選擇有結合情境說理 (20%)
- STARD 關鍵項目有交代 (20%)
- 表達清楚、可重現 (10%)

情境 (Part B 共用)：你要驗證一款用血糖趨勢預測『低血糖事件』的 AI 手環，黃金標準為連續血糖監測 CGM。

教學重點 | 寫作提醒：每個數字都要標明分子、分母與情境。審稿人 (和老師) 看的是你有沒有理解『這個數字在回答什麼問題』，而不是有沒有背對公式。

四題觀念題 (每題 3-5 句)

不用算，用你的話講清楚

- A1 某 App 宣稱『使用者中 30% 有睡眠問題』，就推論『全國 30% 的人有睡眠問題』。這犯了什麼錯？用盛行率與樣本代表性說明。
- A2 一則新聞：『每天喝含糖飲料，糖尿病風險增加 50%！』你會追問哪三件事，才能判斷這是不是誇大或有干擾？
- A3 為什麼『敏感度/特異度』不隨盛行率變，但『PPV』會？用分母的角度解釋。
- A4 一個醫療 AI 論文只報 accuracy = 98% 就宣稱成功。為什麼在罕見疾病上這可能毫無意義？該補報哪些指標？

教學重點 | 提示：A1 想『分母是誰』；A2 想 Bradford Hill 與干擾；A3 想固有能力 vs 人群結果；A4 想類別不平衡與 accuracy 陷阱。

低血糖預測手環：完整分析（附資料）

把 Part 1–5 全部用上

	真的低血糖 (CGM+)	沒有低血糖 (CGM-)
手環 陽性	160 (TP)	240 (FP)
手環 陰性	40 (FN)	1,560 (TN)

驗證族群共 2,000 人（住院高風險病人）。請完成：

- B1 算敏感度、特異度、PPV、NPV、LR+、LR-（列出分子分母）。
- B2 此族群低血糖盛行率是多少？若改用在盛行率 2% 的居家族群，PPV 大約變成多少？（自行設 N 計算）
- B3 這支手環該走『高敏感度』還是『高特異度』的切點？結合低血糖漏診的後果說明。
- B4 列出你會依 STARD 報告的 5 個關鍵項目，並各寫一句你會怎麼交代。

教學重點 | B2 是本作業的靈魂：親身體會『同一支手環，換個族群 PPV 就崩』。這是你未來評估任何健康科技篩檢產品時，最該先問的一題。

想更深入可以看這些

經典教科書、報告規範與工具

流行病學 Gordis, Epidemiology ; Rothman, Modern Epidemiology — 頻率、關聯、因果的標準教材

診斷準確度 Bossuyt et al., STARD 2015 (Radiology / BMJ) ; Akobeng, 概似比與後測機率(Acta Paediatr, 2007)

STARD 清單 EQUATOR Network : www.equator-network.org → STARD 2015 (30 項) 與流程圖範本

模型評估 Hosmer & Lemeshow, Applied Logistic Regression (AUC 分級) ; Steyerberg, Clinical Prediction Models (校準)

醫療 AI TRIPOD+AI (2024) 與 PROBAST+AI — 預測模型的開發、驗證與偏誤評估規範

因果 Hill (1965), The Environment and Disease: Association or Causation? — Bradford Hill 準則原文

教學重點 | 下一步：本單元延伸『2.5 推論統計』，並銜接『9.3 觀察性研究 + STROBE』與『9.5 醫療 AI 研究法 + TRIPOD+AI』。報告規範全貌見 EQUATOR Network。

三個問題，一套語言

這病多常見？這因子有關係嗎？這檢測/模型準不準？

把這三題答好，你的健康科技研究就站得住腳。

敏感度 · 特異度 · PPV/NPV · 概似比 · ROC/AUC · 校準 · STARD

案例應用：AI 摘要漏掉重要事項，測得出來嗎

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

本單元教了什麼

效應測量、干擾，以及診斷準確度的 2×2 表與 ROC 判讀。

②

案例怎麼用

- 自後測期抽 400 次交班 (summary_audit.csv)，由兩位護理師比對原紀錄判定是否遺漏。
- 遺漏率 12.2%；以 AI 自評信心 < 0.52 為警示閾值建 2×2 表。
- 敏感度 75.5%、特異度 70.1%、 $AUC = 0.817$ (95% CI [0.742, 0.891])。
- PPV 僅 26.1%——警示四次只有一次真的漏掉，這是低盛行率的必然結果。
- NPV 達 95.3%：不警示時大致可信，此為本工具較有價值的用法。

③

產出什麼證據

2×2 表與 ROC 判讀 (次頁)，納入論文第四章第七節。

④

承接關係

上游：承自 9.1 之資料元素對照表 | 下游：交棒 9.3，若改用既有紀錄做回溯研究該怎麼設計。

教學重點 同一個 $AUC = 0.82$ 的工具，在盛行率 12% 的場域 PPV 只有 26%。準確度指標與盛行率脫鉤，臨床意義就會被誤讀——這是健康科技評估最常見的陷阱。

示範產物：2×2 表與準確度指標

n = 400 ; 閾值 AI 自評信心 < 0.52 判為警示；金標準為兩位護理師之獨立比對

	實際遺漏	實際未遺漏	指標
判為警示	37 (真陽性)	105 (偽陽性)	PPV = 26.1% : 警示四次約一次為真
未警示	12 (偽陰性)	246 (真陰性)	NPV = 95.3% : 不警示時大致可信
合計	49 (12.2%)	351	盛行率 12.2%
準確度指標	敏感度 75.5%	特異度 70.1%	LR+ = 2.52、LR- = 0.35
整體判別力	AUC = 0.817	95% CI [0.742, 0.891]	中等偏佳；惟須看分層結果 (單元 9.5)

教學重點 12 個偽陰性是這張表最該被討論的一格：真的漏了、AI 也沒警示。若此工具被當成安全網使用，這 12 次就是實際的病人風險，必須寫進限制與風險管理。