單元 9 · 健康科技研究方法 · Research Methodology

醫療 AI／機器學習研究法

Medical AI / ML Research Methods — 開發、驗證、偏誤：做出真的能用的模型

涵蓋： ML 生命週期 · 資料洩漏 · 過度擬合 · 內外部驗證 · 校準 · 演算法偏誤與公平 · 漂移 · 可解釋性

實例：一個糖尿病視網膜病變篩檢模型，從開發到驗證、偏誤檢查與報告

先修： 2.5 推論統計 · 9.2 診斷準確度 · 對應： TRIPOD+AI / PROBAST+AI / CONSORT-AI · 建議學期： S2

本簡報五個部分 Five Parts

課程地圖 Course Map

從『為何醫療 AI 常翻車』一路走到『負責任地開發、驗證與報告』

部分	主題	你會學到
Part 1	地圖與陷阱	ML 基礎、生命週期、醫療 AI 為何特別難、複製危機
Part 2	開發 Development	資料品質、切分、過度擬合、資料洩漏、類別不平衡
Part 3	驗證 Validation	內部 vs 外部驗證、區辨 vs 校準、臨床效用
Part 4	偏誤與公平	演算法偏誤、公平性、 PROBAST+AI 、資料漂移、可解釋性
Part 5	報告與實例	TRIPOD+AI 等報告規範 · 視網膜篩檢模型全程實例

教學重點 一句話抓重點：醫療 AI 論文很多，但真正『能在別家醫院、別群病人身上一樣準』的很少。這一課教你分辨『看起來很準』與『真的可靠』——關鍵在嚴謹的開發、誠實的驗證、與對偏誤和公平的警覺。

Opening

為什麼要專門學『醫療 AI 研究法』？

模型準確率 99%？先別急著開心

論文寫的
準確率 99%
內部驗證、單一醫院

陷阱 1　資料洩漏
偷看到答案，分數被灌水
第 10A、12 張

陷阱 2　只做內部驗證
換一家醫院就失準
第 16、16A 張

陷阱 3　族群不公平
整體準，少數族群不準
第 20–21 張

陷阱 4　上線後退化
病人與流程變了，模型悄悄變差
第 23、23B 張

這一課給你的五個能力

- 揪出資料洩漏
- 要求外部驗證
- 區辨與校準都看
- 分族群檢查公平
- 用 TRIPOD+AI 報告

教學重點　醫療 AI 的價值不在訓練資料上多準，而在新病人、新醫院、每個族群身上都可靠。這要靠方法紀律，不只是演算法；本課延伸 2.5 推論統計與 9.2 診斷準確度。

1

PART 1

地圖與陷阱

The Landscape & Pitfalls

對應： ML 生命週期 · 複製危機

先建立共同語言： ML 在醫療怎麼用、一個模型從無到有要經過什麼，以及——為什麼醫療 AI 特別容易『翻車』。

醫療 AI 在做什麼？先分清楚任務型態

不同任務，評估方式與陷阱都不同

監督式－分類

本課主角

輸入 **眼底照片**

輸出 **需轉診／不需轉診**

怎麼評估
敏感度、特異度、 AUC 、校準

監督式－迴歸

輸入 **入院時資料**

輸出 **預測住院天數、風險分數**

怎麼評估
預測誤差、校準

非監督式

輸入 **病人特徵**

輸出 **自動分群、找異常**

怎麼評估
分群穩不穩、臨床有沒有意義

生成式 AI

另有風險

輸入 **病歷內容**

輸出 **摘要、報告草稿**

怎麼評估
正確性、遺漏、幻覺

教學重點 本課主角是『監督式的診斷／預後預測模型』：最常見、也最直接影響臨床決策（報告用 TRIPOD+AI ）。評估方式承接 9.2：敏感度、特異度、 PPV 、 AUC 與校準。生成式 AI 另有幻覺與洩密風險。

一個醫療 AI 模型的生命週期

每一關都有對應的陷阱與規範

① 定義問題	② 資料	③ 切分訓練	④ 驗證	⑤ 偏誤公平	⑥ 部署監測
常見陷阱 用途寫太模糊	常見陷阱 不具代表性、標註錯	常見陷阱 資料洩漏	常見陷阱 只做內部驗證	常見陷阱 少數族群失準	常見陷阱 漂移後沒人發現
第 06A 張	第 10 張	第 10A、12 張	第 16、16A 張	第 20–22 張	第 23、23B 張

①②③ 開發：Part 2

④⑤⑥ 最常被跳過：論文多停在 ③ 的內部分數

教學重點　訓練得好只是第一步。決定模型能不能用的，是後面三關：外部驗證、偏誤與公平檢查、部署後監測——也是最常被跳過的三關。每一關的陷阱，本課都有對應頁。

先把 AI 的臨床用途寫成可測試規格

疾病與族群、使用者、工作流時點、輸入輸出、行動門檻與失敗備援，都要在建模前固定。

建模前先完成 Intended use profile；否則資料、指標、門檻與研究設計都沒有共同目標

1 臨床問題／族群	2 預期使用者	3 時點與輸入	4 輸出與不確定性	5 行動與門檻	6 備援與結果
哪個疾病、哪類病人 排除誰?	醫師、技師、病人 需要什麼訓練?	在流程哪一步使用 當下真正拿得到什麼?	分數、分類、排序 如何呈現信心／限制?	誰依輸出做什麼 漏診／誤報代價?	拒絕、覆核、停用 預期利益與可能傷害

真正要估計的是「AI 輔助的照護路徑」相較目前照護，對決策、病人結果、傷害與工作負荷的影響；不是模型單獨的 AUC。

來源： DECIDE-AI 2022； FUTURE-AI international consensus guideline, BMJ 2025

一句「幫助診斷」太模糊。要把 intended use 寫到能決定資料來源、參考標準、錯誤代價、比較組與主要結果；並明確誰看輸出、如何行動、何時覆核或停用。這也把後續技術效能、早期臨床評估與試驗放在同一條證據鏈上。

醫療 AI 為什麼特別容易翻車?

四個讓它和一般 ML 不同的地方

錯誤代價高

漏掉一位敗血症病人，代價遠大於推薦錯一部電影；而且黃金標準本身也可能有錯。

各院資料不同

A 院用甲牌機器、 B 院用乙牌，影像亮度、流程與病人組成都不同；在 A 院訓練，到 B 院常失準。

偏誤與捷徑

模型可能學到『影像角落有某醫院標記＝重症』這種假線索，而不是病灶本身；或對某族群系統性不準。

會變動、受監管

疫情改變就醫族群、儀器更新，模型會慢慢退化；要上市還得符合醫材軟體（SaMD）法規（9.10）。

教學重點　醫療 AI 不是『把準確率衝高』的比賽，而是在高風險、各院不同、還會變動的真實環境裡持續可靠且公平。所以它需要一整套研究方法與報告規範，演算法只是其中一小塊。

複製危機：為何很多『突破』無法重現

三個反覆出現的元凶

有做外部驗證的研究有多少?



其餘 133 篇只在同一批資料裡切分驗證——換一家醫院，表現可能完全不同。

資料洩漏

發生什麼　測試資訊偷偷進了訓練
後果　效能被灌水，上線就崩
第 10A、12 張

缺外部驗證

發生什麼　只在同一批資料切分驗證
後果　換醫院、換族群就失準
第 16、16A 張

報告不透明

發生什麼　資料、方法、評估細節缺漏
後果　別人無法複製、無法評偏誤
第 25–25B 張

教學重點　一篇系統性回顧發現： 152 篇醫療 ML 研究只有 19 篇做過外部驗證（12.5%）。方法學界因此強調三件事：正確切分資料、做外部驗證、控制干擾；再加上偏誤檢查與透明報告。

2

PART 2

開發 Development

Building the Model Right

對應：資料切分 · 資料洩漏 · 過度擬合

模型好壞，很大程度決定在『資料與切分』，不是演算法。
這一部教你把開發做對——尤其是避開醫療 AI 頭號殺手：資料洩漏。

資料品質：垃圾進、垃圾出

再厲害的演算法也救不了爛資料

① 代表性：資料像誰，模型就只服務誰

族群	訓練資料幾乎都是 40–60 歲 → 用在 80 歲長者會失準
機型	只有甲牌眼底相機 → 換乙牌影像就不準
場域	只有醫學中心 → 用在社區診所，病人組成不同
盛行率	研究資料一半有病 → 真實篩檢只有 5%， PPV 大降（9.2）

② 標註品質：標籤是效能的天花板

誰標的?	1 位醫師 vs 3 位醫師共識
標得一致嗎?	兩位醫師意見不一致的比例
標籤有偏嗎?	過去某族群常被漏診 → 標籤就錯

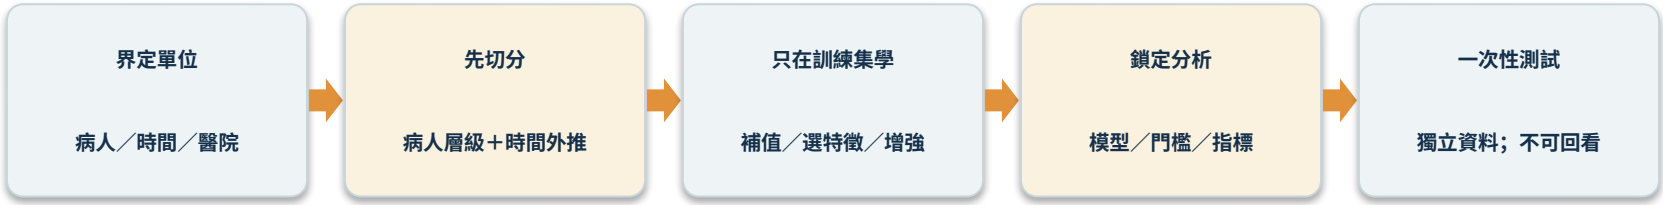
模型最多跟標籤一樣準；標籤錯，模型就學會錯

教學重點　兩大地基：資料要像你未來要服務的病人（族群、機型、場域、盛行率），標籤要可靠。模型不可能比它學的標籤更準；標籤若帶著歷史偏誤，模型會照單全收、甚至放大。

資料洩漏：看似高分，可能只是偷看答案

Leakage 不是小瑕疵，而是會把測試集變成訓練資料的設計錯誤。

資料切分之前做補值、特徵選擇、資料增強或門檻調整，等於讓測試資訊滲入訓練



若測試結果回頭改模型，測試集就變成訓練集

稽核：病人層級切分・時間外推・重複個案・未來資訊・前處理只 fit 訓練集

來源： Kapoor & Narayanan, Patterns 2023； TRIPOD+AI, BMJ 2024

資料洩漏會讓內部表現不合理地漂亮，卻在外部驗證消失。最穩妥的做法是先依病人、時間或場域切分，再在每個訓練折內完成所有前處理與調參；獨立測試只使用一次。

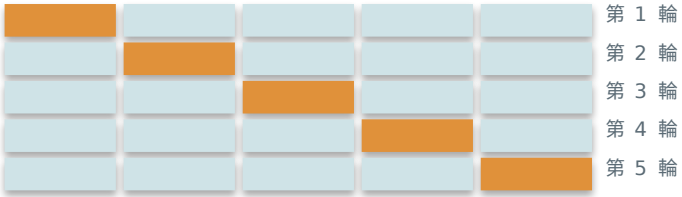
訓練 / 驗證 / 測試：三份資料，各司其職

測試集是『最後的考卷』，開發途中絕不能偷看

訓練 Training	驗證 Validation	測試 Test
課本練習題 讓模型學參數，可反覆用	**模擬考** 調參數、選模型，不算最終成績	**期末考** 最後只考一次，途中絕不偷看

比例只是示意（不是一律 70/15/15，見第 11A 張）；關鍵是測試資訊從未參與任何模型選擇

小資料：5 折交叉驗證（輪流當驗證）



以病人為單位切分

✗ 同一位病人的左眼在訓練、右眼在測試 → 模型認得這個人，分數虛高

✓ 同一位病人的所有影像只能在同一份資料裡

教學重點　測試集是『期末考』：所有決定做完之前都不能看，看了分數就偏樂觀。切分要以『病人』為單位，同一位病人的多張影像不能同時出現在訓練與測試。資料少時用交叉驗證，但仍要留獨立資料把關。

不是一律 70/15/15： 資料策略要配合目的與樣本量

開發、內部驗證與外部驗證回答不同問題；固定比例與單一樣本數規則常造成浪費或假精確。

固定 70/15/15 與「每參數 10 個事件」都只是粗略規則；小資料任意切分會浪費資訊並增加不穩定

模型開發 Development

- 依盛行率、候選參數／複雜度、預期表現與過度擬合風險規劃樣本量
- 臨床資料有限時，盡量用全部開發資料建模
- 以 bootstrap 或 nested cross-validation 做內部驗證與調參
- 切分單位要對齊病人、時間與場域，杜絕群聚洩漏

外部驗證 External validation

- 使用真正的新資料，第一次評估前不重新訓練
- 樣本量要讓校準、區辨與淨效益估計夠精確
- 確保足夠的事件與非事件，並能做重要族群分析
- 先驗證，再決定是否需要重新校準、更新或重建

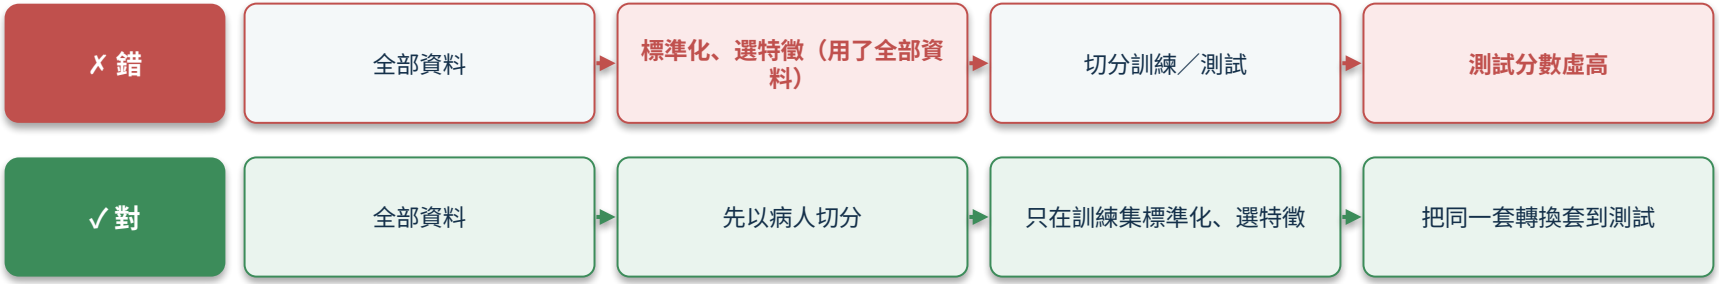
大型深度學習仍可保留獨立測試集；重點不是比例漂亮，而是測試資訊從未參與任何模型選擇。

來源： Riley et al., BMJ 2020； Riley et al., BMJ 2024； TRIPOD+AI 2024

臨床預測模型的樣本量需依盛行率、候選參數／模型複雜度、預期表現與過度擬合風險規劃。資料有限時，以全部開發資料建模並用 bootstrap ／ nested CV 校正樂觀偏誤，通常比隨機切掉一大塊更有效率；外部驗證則要以校準、區辨與淨效益的估計精度決定樣本。

資料洩漏：醫療 AI 的頭號殺手

訓練 / 測試看起來神準，一上線就崩



常見洩漏來源（例）

同病人跨集
左眼訓練、右眼測試

未來資訊
用『出院診斷』預測入院時風險

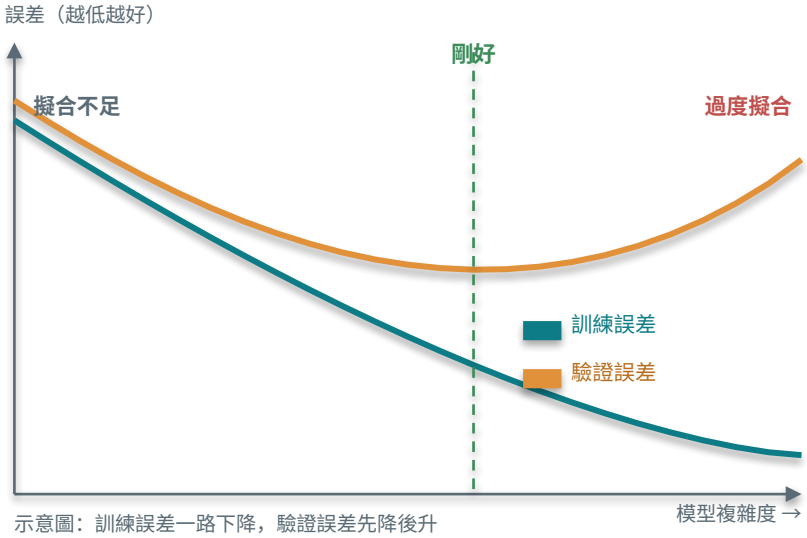
捷徑標記
影像上有某院的標籤或尺標

切分前選特徵
用全部資料挑出『最準』的變數

教學重點　黃金法則：任何用到資料的步驟（標準化、補值、選特徵）都要『先切分、只用訓練集』來做，再套用到測試集。洩漏讓論文準到不可思議，上線卻完全失效，因為它偷看了實際拿不到的資訊。

過度擬合 vs 擬合不足：記住題目 ≠ 學會

模型要學『規律』，不是『背答案』



示意圖：訓練誤差一路下降，驗證誤差先降後升

擬合不足（沒讀書）
徵兆　訓練、驗證都差
對策　用更強的模型、更多特徵

剛好（學會規律）
徵兆　兩者都好、落差小
對策　就停在這裡（早停）

過度擬合（背考古題）
徵兆　訓練很好、驗證差很多
對策　正則化、簡化、更多資料、交叉驗證

教學重點　過度擬合像把考古題答案背起來：題目一樣就滿分，換題就掛；擬合不足像根本沒讀書。看『訓練 vs 驗證』的落差最準：落差大＝過度擬合。目標是驗證誤差最低的那一點。

類別不平衡：罕見病的準確率陷阱

99% 準確率，可能一個病人都沒抓到

算給你看：1,000 人中只有 10 位病人（盛行率 1%） 教學示意數字

模型 A：全部猜『沒病』

	真的有病	真的沒病
判陽性	0	0
判陰性	10	990

accuracy 990 ÷ 1,000 = 99.0%
敏感度 0 ÷ 10 = 0%
→ 分數最高，卻一個病人都沒抓到

模型 B：認真學過的模型

	真的有病	真的沒病
判陽性	8	99
判陰性	2	891

accuracy (8 + 891) ÷ 1,000 = 89.9%
敏感度 8 ÷ 10 = 80%
PPV 8 ÷ 107 = 7.5%

怎麼處理

- 看對的指標：敏感度、 PPV 、 F1 、 AUC
- 重取樣：少數類多抽、多數類少抽
- 調類別權重或決策門檻
- 少數類樣本要夠、要有代表性

PPV 7.5% ＝約每 13 個陽性只有 1 個真的；當篩檢可接受，但要接確認檢查

教學重點 不平衡資料上 accuracy 會騙人：全猜『沒病』就有 99%。要看敏感度（有沒有抓到病人）、 PPV （陽性裡真的有病的比例）、 F1 、 AUC ，並依『漏診 vs 誤報』的代價調門檻——這就是 9.2 『切點是價值判斷』。

3

PART 3

驗證 Validation

Does It Actually Generalize?

對應：內外部驗證 · 區辨 vs 校準

模型在自己資料上準，不代表換個地方也準。
這一部教你用『外部驗證』與『校準』檢驗它是否真的能推廣。

內部 vs 外部驗證：換個地方還準嗎?

只做內部驗證，是複製危機的主因

偏樂觀 → 越接近真實使用

內部驗證

做法
同一批資料切分、交叉驗證
檢驗
同來源的新樣本

時間外部

做法
用較晚時期的資料（如 2023 年）
檢驗
時間變了還準嗎

地理外部

做法
用別家醫院、別國的資料
檢驗
換場域還準嗎（最關鍵）

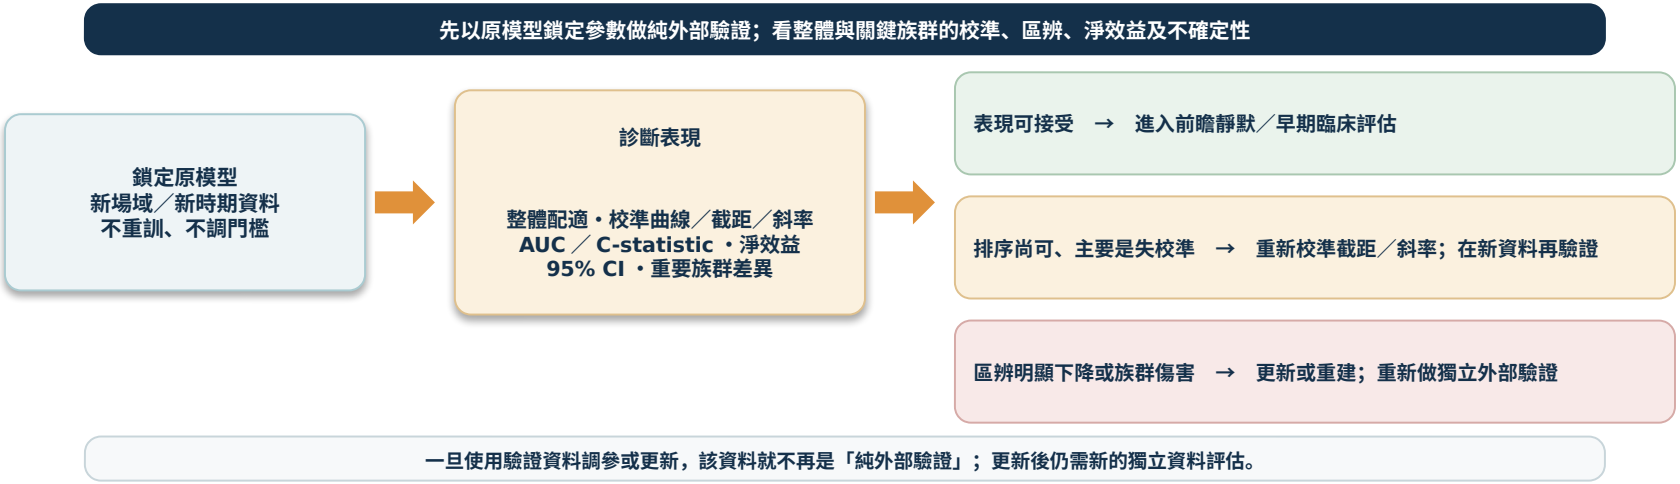
前瞻靜默

做法
上線但不影響決策，先觀察
檢驗
真實流程裡的表現

教學重點　外部驗證是黃金標準，尤其是別家醫院、別群病人；內部驗證幾乎總是偏樂觀。通過外部驗證，才有資格說『可能可以推廣』；上線前的靜默評估（先跑但不影響決策）是最後一道安全網。

外部驗證不是按一次 AUC：先診斷，再決定能否更新

先鎖定原模型在新資料誠實評估；表現不好時，區分失校準、區辨下降與族群傷害。



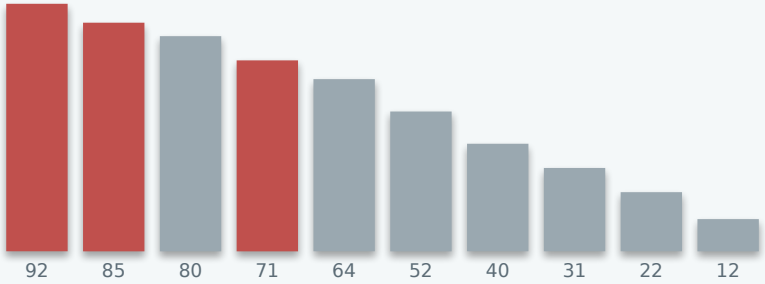
來源： Riley et al., BMJ 2024 external validation series ； TRIPOD+AI 2024

高品質外部驗證要檢查整體配適、校準、區辨、淨效益與關鍵族群，並報不確定性。若只是基準風險不同，可考慮重新校準；若區辨掉很多或特定族群受害，可能要更新或重建。重要的是：用驗證資料更新後，它就不再是原模型的純外部驗證，必須再找新的獨立資料。

區辨 vs 校準：兩種『準』，都要驗

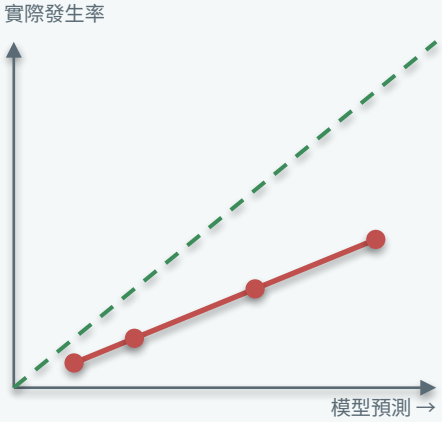
AUC 高，不代表機率數字可信

區辨：有病的人分數排在前面嗎?



紅＝真的有病：大多排在前面 → 排序對， AUC 高（示意）
指標： AUC ／ C-statistic

校準：說 60% 的那群，真的有 60% 嗎?



綠虛線＝完美校準
紅線＝高估一倍
模型說 60%，實際只有 30%
指標：校準曲線、截距、斜率、Brier score （示意）

教學重點　AUC （區辨）只講『排序對不對』，不講『機率數字準不準』（校準）。 AUC 0.85 的模型也可能把每個人的風險都算成兩倍；拿『你有 60% 機率』跟病人說就會嚴重誤導。兩者都要報，外部驗證時尤其要看校準。

臨床效用：準，然後呢?

模型要能改善『決策與結果』，才算真有用

淨效益怎麼算（門檻 10%；教學示意數字）

淨效益＝真陽性 ÷ N − 偽陽性 ÷ N × 門檻 ÷ (1 − 門檻)； N = 1,000、病人 100

用模型 TP 80、FP 200		0.080 − 0.200 × 0.111 = 0.058
全部都治療 TP 100、FP 900		0.100 − 0.900 × 0.111 = 0.000
都不治療 TP 0、FP 0		0

讀法： 用模型相當於每 1,000 人多抓 58 位真陽性、卻不增加不必要的處置

準了之後，要問的真問題

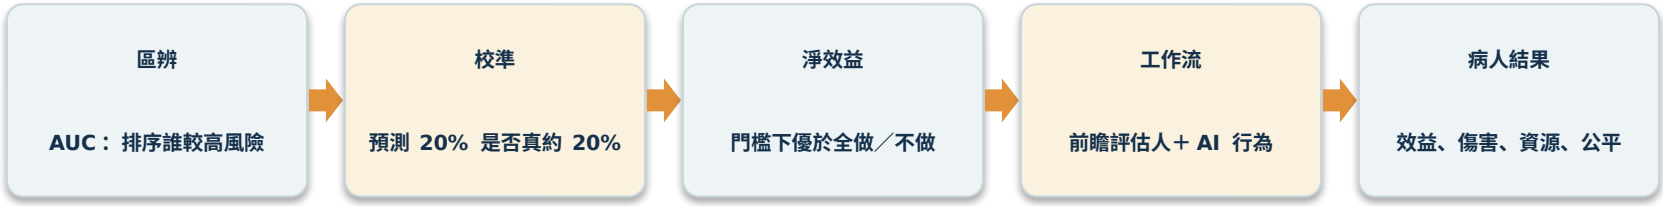
① 它改變了醫師的決策嗎?
② 改變後，病人結果更好嗎?
③ 在真實流程裡可行嗎（整合、時間）?
④ 對誰有幫助、對誰可能有害?
⑤ 會不會造成過度檢查、警報疲勞?
→ 最終用前瞻研究或 RCT 驗證（9.4）

教學重點 別停在 AUC：模型再準，若不能改善決策與病人結果，就只是漂亮的數字。決策曲線分析算『淨效益』；真正的臨床價值，最終要靠前瞻研究與隨機試驗（9.4，用 CONSORT-AI 報告）證明。

醫療 AI 的證據梯：從排名到病人結果

AUC 只回答「誰較高風險」；可信的臨床證據要再跨過四階。

每上一階，問題從模型表現走向臨床決策：機率可信、門檻有價值、工作流可用、病人真正受益



前一層失效，後面的臨床主張也站不住腳

最低證據組合：discrimination・calibration intercept／slope・decision curve・前瞻工作流・病人／系統結果

來源：BMJ 2024；Van Calster et al., BMC Med 2019；DECIDE-AI 2022

區辨（AUC）高不代表機率可信，校準好也不代表有淨效益。應依序驗證模型表現、決策效用、工作流與病人結果。

4

PART 4

偏誤與公平

Bias, Fairness & Drift

對應： PROBAST+AI · 資料漂移 · 可解釋性

準確的模型，也可能是不公平、會退化、看不懂的模型。
這一部教你檢查偏誤與公平、監測漂移、並理解可解釋性的限制。

演算法偏誤從哪來？不是只有『資料』

三個階段都可能植入偏誤

① 資料偏誤	② 標籤偏誤	③ 部署偏誤
訓練資料不具代表性 例：某族群樣本太少 → 對他們失準	**黃金標準本身帶偏** 例：拿『花費』當『需求』→ 低估弱勢者	**用在和開發不同的情境** 例：為醫學中心開發，套到社區診所

經典案例（Obermeyer 等，Science 2019）：一個廣泛使用的健康風險演算法

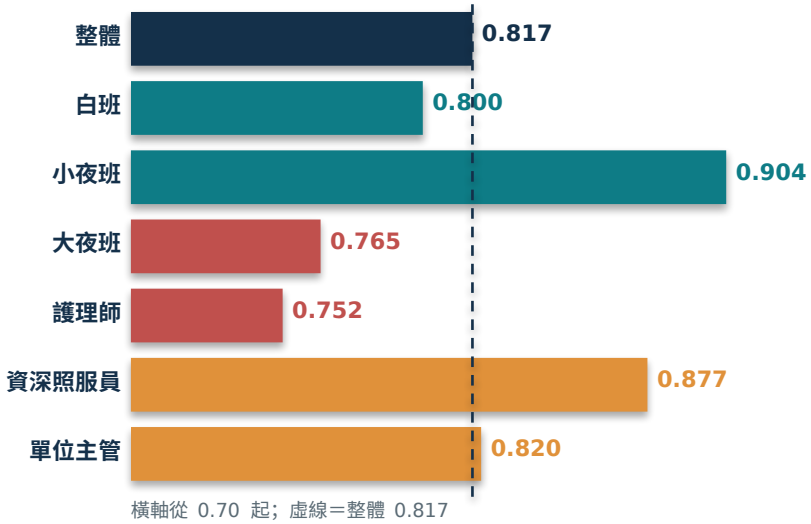
用『醫療花費』當『健康需求』的代理 → 弱勢族群就醫少，花費本來就低 → 模型系統性低估他們的需求 → 較少被轉介到加強照護計畫

教學重點　偏誤不一定來自惡意，常來自『看似合理的代理變數』。選標籤與特徵時要問：這個變數對每個族群的意義一樣嗎？會不會讓某些人被系統性低估？

公平性：整體很準，對每個族群也準嗎？

一定要『分組』檢查表現

案例 Q： AI 判別遺漏的 AUC，分組看（數字取自本單元第 39 張）



橫軸從 0.70 起；虛線＝整體 0.817

怎麼讀、怎麼做

大夜班 遺漏率最高（20.2%）， AUC 反而最低 0.765： 最需要的地方最不可靠

職類 護理師 0.752 vs 資深照服員 0.877，差 0.125 → 列為公平性議題

三步 ① 依族群拆開 ② 比敏感度、 PPV 、校準 ③ 找出對誰較差並說明

各組事件少、 CI 寬，差距要謹慎解讀

教學重點 核心動作：永遠『分組』評估。整體漂亮的數字可能靠多數群撐起，犧牲少數群。公平有多種定義、彼此會衝突，需要在設計階段就和臨床、倫理及受影響的人一起做取捨並說明。

PROBAST+AI： 系統性評估『偏誤風險』

開發者自查、審稿人評讀，都用得上

① 受試者與資料	② 預測變數	③ 結果（標籤）	④ 分析
要問 資料從哪來？像不像要用的族群？	**要問** 怎麼量？預測當下拿得到嗎？	**要問** 怎麼定義？標註者知道預測變數嗎？	**要問** 切分、樣本量、驗證、校準、過度擬合、洩漏

每個領域判一次

低偏誤風險　高偏誤風險　不清楚

只要一個領域判『高』，整體偏誤風險通常就判高

怎麼用

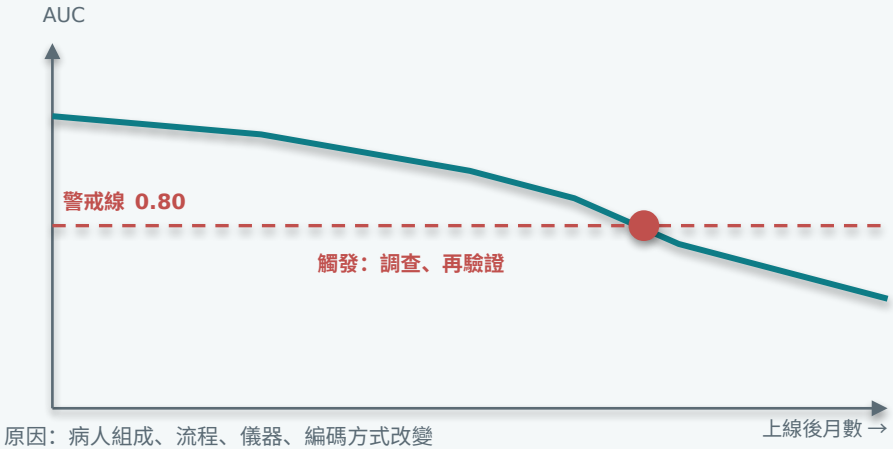
開發時逐項自我把關；評讀別人的研究時判偏誤風險；搭配 TRIPOD+AI（一個評偏誤、一個規範報告）

教學重點　分工： PROBAST+AI 評『這個模型研究的偏誤風險多高、適不適用』（給評讀者與開發者自查）； TRIPOD+AI 規範『報告要寫齊什麼』（給作者）。就像 5.2 的 AMSTAR 之於 PRISMA。

部署後：資料漂移與可解釋性

上線不是終點，模型會『退化』也需要『被理解』

資料漂移：效能會悄悄下降（示意）



原因：病人組成、流程、儀器、編碼方式改變

可解釋性（SHAP 、 LIME ）

說明『模型看了哪些特徵、哪些區域』

✓ **有用**　抓捷徑學習：發現模型看的是影像角落的醫院標記，而不是病灶

✓ **有用**　幫臨床人員理解，建立適度信任

✗ **限制**　解釋本身可能不忠實、被過度解讀；取代不了外部驗證

教學重點　兩個提醒：① 模型會隨資料漂移退化，部署後要持續監測、預先設好觸發門檻與再驗證計畫（第 23B 張）。② SHAP 、LIME 能幫忙抓假線索、建立信任，但解釋不等於正確，永遠取代不了外部驗證。

部署後監測：從漂移警訊到安全更新

上線不是終點；資料、表現、使用行為與傷害都可能隨時間改變。



來源：FDA GMLP 2021；FUTURE-AI, BMJ 2025；Finlayson et al., NEJM 2021

資料漂移不等於一定失效，但必須連結到表現、子群與臨床流程後果。監測計畫要在部署前寫好：量什麼、多久量、誰判讀、何時警報、何時降級或停用，以及更新後如何重新驗證。

評估的是「人＋ AI 工作系統」，不是模型單獨

使用者如何理解、依賴、覆核與覆寫 AI，會改變最終決策、傷害、工作負荷與公平。

部署時的研究單位是「人＋ AI ＋流程」；模型準確，不保證使用者會正確依賴、覆核或行動



來源：DECIDE-AI 2022；FUTURE-AI, BMJ 2025（fairness, universality, traceability, usability, robustness, explainability）

部署前後要比較 AI 單獨、臨床人員單獨與人機團隊；記錄接受、拒絕、覆寫與覆核的原因，也要看自信校準、警報疲勞、近失誤、時間與族群差異。好的介面要讓人看見限制與不確定性，並保留合理的拒絕、升級與停用路徑。

5

PART 5

報告與實例

Reporting & Worked Example

對應： TRIPOD+AI · 視網膜篩檢實例

最後：用對的報告規範讓你的模型可信、可複製，
並用一個完整實例把 Part 1–4 串起來。

報告規範地圖：哪種研究用哪一個

對應研究型態，選對規範

規範	用於	重點
TRIPOD+AI (2024)	開發 / 驗證『預測模型』（含 ML）	取代 TRIPOD 2015；透明報告開發與驗證
PROBAST+AI (2025)	評「預測模型」品質、偏誤風險與適用性	兩部分各四領域；開發 16 項、評估 18 項訊號問題
CONSORT-AI / SPIRIT-AI	AI 介入的『臨床試驗』報告 / 計畫	接 9.4：試驗層級的 AI 延伸
DECIDE-AI	AI 決策支援的『早期臨床評估』	17 AI 項＋ 10 通用項，重人因

教學重點　選規範看『研究做到哪一步』：開發 / 驗證一個預測模型→ TRIPOD+AI （報告）＋ PROBAST+AI （偏誤）；早期在臨床試用決策支援→ DECIDE-AI；做到隨機對照試驗→ CONSORT-AI （接 9.4）。全部可在 EQUATOR Network 查到。報告透明是讓別人能複製、能信任你模型的最低門檻。

先看研究問題與階段，再選 AI 報告規範

2025 年 STARD-AI 補上 AI 診斷準確度研究； PROBAST+AI 則是偏誤與適用性評讀工具。

同一個 AI 系統在不同研究階段，應搭配不同規範；報告清單不等於偏誤風險工具

預測模型開發／驗證	AI 診斷準確度	早期真實臨床使用	隨機試驗／計畫書
TRIPOD+AI **BMJ 2024**	**STARD-AI** **Nature Medicine 2025**	**DECIDE-AI** **Nature Medicine 2022**	**CONSORT-AI ／ SPIRIT-AI** **2020**
回歸或 ML 的診斷／預後預測模型	在 STARD 2015 上新增／修改 18 項	含人因、工作流、錯誤與安全	比較 AI 介入對照護與結果的影響

跨開發、更新與驗證的評讀工具： PROBAST+AI （BMJ 2025）→ 品質、偏誤風險與適用性；不是報告規範。

來源： TRIPOD+AI 2024； PROBAST+AI 2025； STARD-AI 2025； DECIDE-AI 2022； CONSORT-AI ／ SPIRIT-AI 2020

開發／驗證臨床預測模型用 TRIPOD+AI； AI 診斷準確度研究用 STARD-AI；進入早期真實工作流用 DECIDE-AI；比較對照護與結果的影響則用 CONSORT-AI ／ SPIRIT-AI。 PROBAST+AI 是跨模型開發、更新與驗證的品質、偏誤風險與適用性工具；正式名稱為 PROBAST+AI （非早期文獻常見的 PROBAST-AI ）。

可信任 AI 的四層證據：不能只勾報告清單

報告、偏誤評讀、生命週期工程與治理各回答不同問題。

透明報告讓人看見研究；偏誤工具判斷可信度；工程與治理讓系統在真實環境持續安全

透明報告	偏誤與適用性	生命週期工程	倫理與治理
TRIPOD+AI ／ STARD-AI DECIDE-AI ／ CONSORT-AI	PROBAST+AI BMJ 2025	FUTURE-AI ／ FDA GMLP 2021–2025	WHO AI for Health WHO 2021
研究做了什麼？是否可重現？	結果可信嗎？適用於此族群嗎？	如何開發、監測、更新與退場？	誰負責？如何確保公平、權利與問責

重要：報告完整 ≠ 低偏誤 ≠ 有臨床效益 ≠ 可安全部署；四層要一起對齊。

來源：TRIPOD+AI ／ STARD-AI ／ DECIDE-AI ／ CONSORT-AI； PROBAST+AI； FUTURE-AI； FDA GMLP； WHO 2021

一份寫得完整的研究仍可能高偏誤；一個低偏誤模型也可能沒有臨床淨效益。用報告規範檢查透明度、用 PROBAST+AI 評讀偏誤，再用 FUTURE-AI ／ GMLP 與 WHO 原則檢查部署與治理。

綜合實例：糖尿病視網膜病變篩檢模型

把開發→驗證→偏誤→報告一次走完

開發	內部驗證	外部驗證	偏誤／公平	報告
做了什麼 眼底照片分類『需轉診 vs 否』	**做了什麼** 交叉驗證看 AUC、敏感度	**做了什麼** 用別國、別機型資料再測	**做了什麼** 分膚色、機型看敏感度與校準	**做了什麼** TRIPOD+AI、PROBAST+AI 自查
關鍵把關 以病人切分；先切再前處理	**關鍵把關** 防洩漏；報 95% CI	**關鍵把關** AUC 通常會降；重查校準	**關鍵把關** 修正對深膚色影像的失準	**關鍵把關** 公開資料與程式可用性

五階段對應本課 Part 2–5；任何一階段省略，後面的結論都站不住腳

教學重點　負責任的醫療 AI 研究不會停在『內部 AUC 0.95』：它會在別國、別機型做外部驗證（效能通常會降，這才真實），分族群檢查公平，並依 TRIPOD+AI 報告、用 PROBAST+AI 自查。

做醫療 AI 的『可以』與『不可以』

方法紀律，比模型花俏更重要

	✓ 該做的	✗ 不要做的
切分	先切分再前處理，以病人為單位	先對全部資料前處理，再切分
驗證	做外部驗證，區辨與校準都報	只報訓練或內部的漂亮 AUC
指標	不平衡時看敏感度、 PPV 、 F1	只看 accuracy
公平	分族群檢查並報告限制	忽略少數族群的表現
部署	上線後監測漂移、規劃再驗證	上線就不管、不監測不更新

教學重點　醫療 AI 的可信度來自方法紀律，不是模型多新。守住這五條，你的研究就贏過文獻裡大半只報內部 AUC 的研究；若研究過程用了生成式 AI 輔助，也要揭露（1.3）。

本課總覽：一頁看完醫療 AI 研究法

從資料到部署，紀律貫穿全程

主題	關鍵心法	對應
陷阱	外部驗證少、洩漏多 → 複製危機	方法三要件
開發	先切再處理、防洩漏、看對指標	訓練 / 驗證 / 測試
驗證	外部驗證＋區辨與校準都要	接 9.2 ROC/ 校準
偏誤	分族群看公平、評偏誤風險	PROBAST+AI
報告	對症選規範、透明可複製	TRIPOD+AI 等

教學重點 帶走一句話：醫療 AI 的價值不在『訓練集上多神』，而在『對新病人、新場域、各族群都可靠、公平、可維護，且被透明報告』。演算法會一直進步，但這套研究方法的紀律——嚴謹開發、誠實驗證、警覺偏誤、透明報告——才是讓 AI 真正幫到病人的關鍵。

作業

Take-home Assignment

Critique & Design a Medical AI Study

Part A 觀念題 · Part B 實作題（附參考答案）

作業目標：能揪出資料洩漏與缺外部驗證、判讀區辨 vs 校準，並用 TRIPOD+AI ／公平性思維設計與評讀一個醫療 AI 研究。

作業 Assignment

作業說明與繳交

建議 3–4 頁；重點是判斷與設計，不是背名詞

形式與繳交

- 形式：一份評讀＋設計報告 (PDF/Word)
- 篇幅： Part A 每題 3–5 句； Part B 完整作答
- 可畫資料切分圖、分族群效能表
- 獨立完成；可用 AI 協助但需自行核對並揭露
- 繳交期限：兩週後上課前

評分重點

- 揪出資料洩漏 / 缺外部驗證（25%）
- 區辨 vs 校準判讀正確（20%）
- 不平衡與指標選擇（15%）
- 公平性 / 偏誤檢查設計（20%）
- 報告規範與監測意識（20%）

情境（Part B 共用）： 你要設計並評讀一個『從胸部 X 光偵測肺炎』的 AI 模型研究。

教學重點 寫作提醒：每個判斷都要說『為什麼、你會怎麼驗證 / 修正』。老師看的是你能不能把『先切再處理、外部驗證、區辨＋校準、分族群公平、透明報告』這套紀律，實際用在一個醫療 AI 研究上。

四題觀念題（每題 3–5 句）

用你的話講清楚

A1 一篇論文報告『內部驗證 AUC 0.98』就宣稱模型可臨床使用。你會質疑什麼？該補哪些驗證？

A2 什麼是『資料洩漏』？舉一個醫療影像的例子，並說明怎麼在切分與前處理上避免。

A3 一個模型 AUC=0.9 卻『校準很差』，會造成什麼問題？為什麼兩者都要報？

A4 為什麼整體準確率高，模型仍可能『不公平』？你會怎麼檢查？

教學重點 提示： A1 想外部驗證＋校準＋洩漏； A2 想同病人跨集、先切再處理； A3 想機率數字誤導、決策風險； A4 想分族群拆開看敏感度 /PPV/ 校準。

作業 · Part B ｜實作題

設計並評讀一個醫療 AI 研究

胸部 X 光 × 肺炎偵測

為『胸部 X 光偵測肺炎』的 AI 模型，請完成：

B1　描述你的資料切分策略（訓練 / 驗證 / 測試），並說明你如何防止資料洩漏。

B2　你會怎麼做『外部驗證』？要看哪些指標（至少含一個區辨、一個校準）？

B3　資料以『無肺炎』居多（不平衡）。你會看哪些指標、怎麼調門檻？為什麼不看 accuracy？

B4　你會怎麼檢查模型對不同族群 / 機型是否公平?

B5　列出你會依 TRIPOD+AI 交代的三個關鍵報告項目，並各寫一句。

教學重點　重點： B1 以病人為單位切分、先切再前處理； B2 別院 / 別機型資料＋ AUC 與校準曲線； B3 敏感度 /PPV/F1 ＋依代價調門檻； B4 分族群比效能與校準； B5 資料來源、切分 / 驗證方法、缺失與限制、程式 / 資料可用性。

想更深入可以看這些

權威規範與經典資源

主題	來源
預測模型報告	TRIPOD+AI （Collins et al., BMJ 2024；取代 TRIPOD 2015）
偏誤風險	PROBAST+AI （Moons et al., BMJ 2025；品質、偏誤風險與適用性）
AI 臨床試驗	CONSORT-AI / SPIRIT-AI （Nature Medicine 2020；接單元 9.4）
早期臨床評估	DECIDE-AI （Nature Medicine 2022； 17 AI 項+ 10 通用項）
方法 / 公平	Obermeyer et al. (Science 2019) 演算法偏誤經典；校準見 9.2
規範入口	EQUATOR Network； FDA/IMDRF 對 AI 醫材 (SaMD) 的指引

教學重點 下一步：本單元延伸『2.5 推論統計』與『9.2 診斷準確度』，並與『9.3 觀察性 /RWE』、『9.4 臨床試驗 (CONSORT-AI)』互相支援。若模型要進臨床試驗，用 CONSORT-AI；要上市為醫材，還需符合 SaMD 法規（見 9.10）。

醫療 AI／機器學習研究法 · Medical AI/ML Research Methods

準，不夠；要可靠、公平、可維護

先切再處理 · 外部驗證 · 區辨＋校準 · 分族群公平 · 透明報告 · 部署監測

資料洩漏 · TRIPOD+AI · PROBAST+AI · CONSORT-AI · 資料漂移

案例應用：這個 AI 工具本身驗證過了嗎

案例 Q ｜ AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

① 本單元教了什麼

醫療 AI 的驗證層次、外部驗證、族群公平性與 TRIPOD+AI 報告。

② 案例怎麼用

- 整體 AUC = 0.817，惟整體數字會掩蓋族群差異，必須分層檢視。
- 分機構外部驗證： A 機構 0.823 、 B 機構 0.810 ，跨場域表現一致。
- 分班別：大夜班 0.765 、小夜班 0.904—— 大夜班遺漏率最高而判別力最差。
- 分職類：護理師 0.752 、資深照服員 0.877 ，差距 0.125 須列為公平性議題。
- 本研究僅評估既有工具，未參與開發；此界線須在論文中明確聲明。

③ 產出什麼證據

分層驗證表與 TRIPOD+AI 自評（次頁），納入論文第四章第七節。

④ 承接關係

上游：承自 9.4 之試驗設計摘要與 CONSORT 流程圖 ｜ 下游：交棒 9.6 ，把工具放回介入設計的框架裡看。

教學重點 大夜班是遺漏率最高（ 20.2% ）而 AI 判別力最差（ AUC 0.765 ）的族群——風險最高的地方，工具反而最不可靠。只看整體 AUC 永遠看不到這件事。

示範產物：分層驗證與公平性檢視

整體 AUC = 0.817；下表為分層結果，差距超過 0.10 者須於論文中討論

分層	n	遺漏率	AUC	判讀
整體	400	12.2%	0.817	屬優良（0.8–0.9）； 95% CI [0.742, 0.891]
A 機構	217	11.1%	0.823	與整體一致
B 機構	183	13.7%	0.810	跨場域表現穩定，支持外部效度
白班	147	8.8%	0.800	與整體相近
小夜班	149	10.1%	0.904	表現最佳
大夜班	104	20.2%	0.765	風險最高而判別力最差——最須關注之族群
護理師	168	11.9%	0.752	與資深照服員差 0.125，屬潛在公平性議題；各層事件少、 CI 寬
資深照服員	162	13.0%	0.877	表現最佳之職類
單位主管	70	11.4%	0.820	與整體一致

教學重點 這張表也回答了單元 9.4 的問題：若要做群集隨機試驗，大夜班應列為預先指定的次群體分析，而不是等看到結果才回頭挖。