

單元 9 · 健康科技研究方法 · Research Methodology

醫療 AI / 機器學習研究法

Medical AI / ML Research Methods — 開發、驗證、偏誤：做出真的能用的模型

涵蓋：ML 生命週期 · 資料洩漏 · 過度擬合 · 內外部驗證 · 校準 · 演算法偏誤與公平 · 漂移 · 可解釋性

實例：一個糖尿病視網膜病變篩檢模型，從開發到驗證、偏誤檢查與報告

先修：2.5 推論統計 · 9.2 診斷準確度 · 對應：TRIPOD+AI / PROBAST+AI / CONSORT-AI · 建議學期：S2

課程地圖 Course Map

從『為何醫療 AI 常翻車』一路走到『負責任地開發、驗證與報告』

部分	主題	你會學到
Part 1	地圖與陷阱	ML 基礎、生命週期、醫療 AI 為何特別難、複製危機
Part 2	開發 Development	資料品質、切分、過度擬合、資料洩漏、類別不平衡
Part 3	驗證 Validation	內部 vs 外部驗證、區辨 vs 校準、臨床效用
Part 4	偏誤與公平	演算法偏誤、公平性、PROBAST+AI、資料漂移、可解釋性
Part 5	報告與實例	TRIPOD+AI 等報告規範、視網膜篩檢模型全程實例

教學重點 一句話抓重點：醫療 AI 論文很多，但真正『能在別家醫院、別群病人身上一樣準』的很少。這一課教你分辨『看起來很準』與『真的可靠』——關鍵在嚴謹的開發、誠實的驗證、與對偏誤和公平的警覺。

為什麼要專門學『醫療 AI 研究法』？

模型準確率 99%？先別急著開心

醫療 AI 的複製危機

- 多數模型只做『內部驗證』，換家醫院就失準
 - 資料洩漏讓效能被灌水（看起來神準）
 - 在多數族群準、在少數族群失效（公平問題）
 - 部署後資料漂移，模型悄悄退化
- 很多『突破』無法複製、甚至有害

這一課給你的能力

- 看穿被灌水的效能（揪出資料洩漏）
 - 要求並判讀『外部驗證』與『校準』
 - 檢查模型對不同族群是否公平
 - 用 TRIPOD+AI / PROBAST+AI 開發與評讀
- 做出、也看得懂『真的能用』的模型

教學重點 定位：這一課把『2.5 推論統計』與『9.2 診斷準確度（ROC/校準）』延伸到機器學習。核心訊息貫穿全課——醫療 AI 的價值不在『訓練集上多準』，而在『對新病人、新場域、各族群都可靠、公平、可維護』。這需要方法學的紀律，不只是演算法。

1

PART 1

地圖與陷阱

The Landscape & Pitfalls

對應：ML 生命週期·複製危機

先建立共同語言：ML 在醫療怎麼用、一個模型從無到有要經過什麼，
以及——為什麼醫療 AI 特別容易『翻車』。

醫療 AI 在做什麼？先分清楚任務型態

不同任務，評估方式與陷阱都不同

型態	在做什麼	醫療例子
監督式-分類	把個案分到類別	影像判讀有無病變、是否惡性
監督式-迴歸	預測連續數值	預測住院天數、風險分數
非監督式	找資料結構、分群	病人分型、異常偵測
生成式 AI	生成文字/影像	病歷摘要、報告草稿 (另有風險)

教學重點 本課聚焦『監督式的診斷/預後預測模型』——這是醫療 AI 最主流、也最直接影響臨床決策的類型 (對應 TRIPOD+AI) 。它們的評估承接 9.2：敏感度/特異度、PPV、AUC、校準。生成式 AI (如病歷摘要) 有另一套風險 (幻覺、洩密)，本課未會提醒。

一個醫療 AI 模型的生命週期

每一關都有對應的陷阱與規範


- 1 **定義問題與結果** 臨床用途、預測什麼、黃金標準怎麼定
- 2 **資料蒐集與整理** 代表性、標註品質、去識別 (呼應 9.1)
- 3 **切分與訓練** 訓練/驗證/測試分開，防資料洩漏
- 4 **驗證** 內部 + 『外部』驗證：區辨與校準都看
- 5 **偏誤與公平檢查** 跨族群表現、風險評估(PROBAST+AI)
- 6 **部署與監測** 上線後監控漂移、依規範報告(TRIPOD+AI)

教學重點 整條線的重點：模型『訓練得好』只是第一步。真正決定它能不能用的，是後面的『外部驗證、偏誤/公平檢查、部署後監測』——這也是最常被跳過的三關。本課 Part 2 講開發、Part 3 講驗證、Part 4 講偏誤、Part 5 講報告。

先把 AI 的臨床用途寫成可測試規格

疾病與族群、使用者、工作流時點、輸入輸出、行動門檻與失敗備援，都要在建模前固定。

建模前先完成 Intended use profile；否則資料、指標、門檻與研究設計都沒有共同目標



真正要估計的是「AI 輔助的照護路徑」相較目前照護，對決策、病人結果、傷害與工作負荷的影響；不是模型單獨的 AUC。

來源：DECIDE-AI 2022；FUTURE-AI international consensus guideline, BMJ 2025

一句「幫助診斷」太模糊。要把 intended use 寫到能決定資料來源、參考標準、錯誤代價、比較組與主要結果；並明確誰看輸出、如何行動、何時覆核或停用。這也把後續技術效能、早期臨床評估與試驗放在同一條證據鏈上。

醫療 AI 為什麼特別容易翻車？

四個讓它和一般 ML 不同的地方

高風險與異質

- 錯誤代價高：漏診、誤診傷害病人
 - 資料異質：不同醫院機器、流程、人口
 - 在 A 院訓練，到 B 院常失準
 - 標註本身可能有錯（黃金標準不完美）
- 不能只看一家資料的漂亮數字

偏誤與變動

- 資料偏誤 → 對某些族群系統性失準
 - 捷徑學習：學到假線索（如某院的標記）
 - 資料漂移：人口/流程變了，模型退化
 - 受法規監管（如 SaMD 醫材級軟體）
- 需要持續驗證與監測

教學重點 一句話：醫療 AI 不是『把準確率衝高』的比賽，而是『在高風險、異質、會變動的真實環境中，持續可靠且公平』的工程。這就是為什麼它需要一整套研究方法與報告規範——演算法只是其中一小塊。

複製危機：為何很多『突破』無法重現

三個反覆出現的元凶

元凶	發生什麼	後果
資料洩漏 Leakage	測試資訊偷偷進了訓練	效能被灌水，實際用就崩
缺乏外部驗證	只在同一批資料切分驗證	換家醫院/人口就失準
報告不透明	資料、方法、評估細節缺漏	無法複製、無法評偏誤

教學重點 殘酷數字：系統性回顧顯示僅 12.5% 的醫療 ML 研究做過『外部驗證』（152 篇中 19 篇），多數也未控制干擾。方法學界因此提出『方法三要件』——正確切分資料、外部驗證、控制干擾。本課接下來就圍繞這三件事，加上偏誤與報告，把模型做到『真的能用』。

2

PART 2

開發 Development

Building the Model Right

對應：資料切分・資料洩漏・過度擬合

模型好壞，八成決定在『資料與切分』，不是演算法。

這一部教你把開發做對——尤其是避開醫療 AI 頭號殺手：資料洩漏。

資料品質：垃圾進、垃圾出

再厲害的演算法也救不了爛資料

代表性 Representativeness

- 訓練資料要涵蓋你要服務的族群
 - 單一醫院/單一機型 → 學到偏門線索
 - 少數族群樣本太少 → 對他們失準
 - 盛行率要接近真實情境 (呼應 9.2 PPV)
- 資料像誰，模型就只服務誰

標註品質 Ground truth

- 黃金標準怎麼定？誰標的、可靠嗎
 - 標註不一致 → 模型學到雜訊
 - 標籤本身有偏 (如過去診斷就偏誤)
→ 模型會『學會並放大』這個偏誤
- 標註品質是效能的天花板

教學重點 兩大地基：① 資料要能『代表』你未來要服務的病人 (族群、機型、場域、盛行率) ；② 標籤 (黃金標準) 要可靠——模型再強也不可能比它學的標籤更準。標籤若帶有歷史偏誤 (如某族群過去被系統性誤診) ，模型會照單全收甚至放大。

資料洩漏：看似高分，可能只是偷看答案

Leakage 不是小瑕疵，而是會把測試集變成訓練資料的設計錯誤。

資料切分之前做補值、特徵選擇、資料增強或門檻調整，等於讓測試資訊滲入訓練



來源：Kapoor & Narayanan, Patterns 2023；TRIPOD+AI, BMJ 2024

資料洩漏會讓內部表現不合理地漂亮，卻在外部驗證消失。最穩妥的做法是先依病人、時間或場域切分，再在每個訓練折內完成所有前處理與調參；獨立測試只使用一次。

訓練/驗證/測試：三份資料，各司其職

測試集是『最後的考卷』，開發途中絕不能偷看

資料集	用途	鐵律
訓練 Training	讓模型學參數	可反覆使用
驗證 Validation	調超參數、選模型	據此調整，不算最終成績
測試 Test	最終、無偏的效能評估	只用一次、途中絕不偷看
交叉驗證 CV	小資料時輪流當驗證	仍需獨立測試集把關

教學重點 鐵律：測試集是『最後的考卷』——在你決定所有東西之前都不能碰它，碰了效能評估就失真（樂觀偏誤）。切分還要注意『同一病人的多張影像不可橫跨訓練/測試』，否則就是資料洩漏（下一頁）。小資料用交叉驗證，但仍要留一份獨立測試/外部資料把關。

不是一律 70/15/15：資料策略要配合目的與樣本量

開發、內部驗證與外部驗證回答不同問題；固定比例與單一樣本數規則常造成浪費或假精確。

固定 70/15/15 與「每參數 10 個事件」都只是粗略規則；小資料任意切分會浪費資訊並增加不穩定

模型開發 Development

- 依盛行率、候選參數 / 複雜度、預期表現與過度擬合風險規劃樣本量
- 臨床資料有限時，盡量用全部開發資料建模
- 以 bootstrap 或 nested cross-validation 做內部驗證與調參
- 切分單位要對齊病人、時間與場域，杜絕群聚洩漏

外部驗證 External validation

- 使用真正的新資料，第一次評估前不重新訓練
- 樣本量要讓校準、區辨與淨效益估計夠精確
- 確保足夠的事件與非事件，並能做重要族群分析
- 先驗證，再決定是否需要重新校準、更新或重建

大型深度學習仍可保留獨立測試集；重點不是比例漂亮，而是測試資訊從未參與任何模型選擇。

來源：Riley et al., BMJ 2020；Riley et al., BMJ 2024；TRIPOD+AI 2024

臨床預測模型的樣本量需依盛行率、候選參數 / 模型複雜度、預期表現與過度擬合風險規劃。資料有限時，以全部開發資料建模並用 bootstrap / nested CV 校正樂觀偏誤，通常比隨機切掉一大塊更有效率；外部驗證則要以校準、區辨與淨效益的估計精度決定樣本。

資料洩漏：醫療 AI 的頭號殺手

訓練/測試看起來神準，一上線就崩

常見洩漏來源

- 測試資訊滲入訓練（如先標準化再切分）
- 同病人影像橫跨訓練與測試
- 用了『未來』或『結果之後』才有的變數
- 以醫院/機器標記當捷徑（非病理特徵）
- 特徵選擇在切分前用了全部資料

怎麼防

- 先切分，再做任何前處理/特徵工程
 - 以『病人』為單位切分，不以影像
 - 只用『預測當下』真的拿得到的變數
 - 檢查模型是否靠假線索（可解釋性輔助）
- 外部驗證會讓洩漏現形

教學重點 為什麼致命：資料洩漏讓模型在論文裡『準到不可思議』，卻在真實部署時完全失效——因為它偷看了實際上拿不到的資訊。這是醫療 AI 效能被灌水的頭號原因。黃金法則：任何用到資料的步驟（標準化、特徵選擇）都要『在切分之後、只用訓練集』來做。

過度擬合 vs 擬合不足：記住題目 ≠ 學會

模型要學『規律』，不是『背答案』

過度擬合 Overfitting

模型把訓練資料『背起來』（含雜訊）

訓練集超準、新資料就崩

徵兆：訓練 vs 驗證效能差很大

對策：正則化、簡化模型、更多資料、

早停(early stopping)、交叉驗證

擬合不足 Underfitting

模型太簡單，連規律都沒學到

訓練與驗證都不好

徵兆：兩邊效能都低

對策：更強模型、更多特徵、

訓練久一點

→ 目標：在兩者間取得平衡

教學重點 直覺比喻：過度擬合像『把考古題答案背起來』——遇到一模一樣的題滿分，換個題型就掛。擬合不足像『根本沒讀書』——什麼題都不會。好模型要學到『可推廣的規律』。看『訓練 vs 驗證』的落差是最好的診斷：落差大 = 過度擬合。

類別不平衡：罕見病的準確率陷阱

99% 準確率，可能一個病人都沒抓到

問題

罕見結果（如某癌症）佔比極低

模型全猜『沒病』就有 99% accuracy

→ 卻毫無用處（全部漏診）

呼應 9.2：罕見病別看 accuracy

對策

- 看對的指標：召回率（敏感度）、PPV、AUC、F1
 - 重取樣（過採樣少數/欠採樣多數）
 - 調整類別權重或決策門檻
 - 確保少數類樣本『夠且有代表性』
- 別讓多數類淹沒真正重要的少數

教學重點 承接 9.2 的 accuracy 陷阱：在不平衡資料上，accuracy 會嚴重誤導。要看召回率（敏感度，有沒有抓到真陽性）、精確率（PPV）、F1 與 AUC，並依臨床情境（漏診 vs 誤報代價）調整決策門檻——這正是 9.2 教的『切點是價值判斷』在 AI 上的應用。

3

PART 3

驗證 Validation

Does It Actually Generalize?

對應：內外部驗證・區辨 vs 校準

模型在自己資料上準，不代表換個地方也準。

這一部教你用『外部驗證』與『校準』檢驗它是否真的能推廣。

內部 vs 外部驗證：換個地方還準嗎？

只做內部驗證，是複製危機的主因


類型	做法	檢驗什麼
內部驗證	同一資料切分/交叉驗證	對『同來源』新樣本的表現（較樂觀）
時間外部	用『較晚時期』資料驗證	對時間變化是否穩健
地理外部	用『別家醫院/國家』資料驗證	跨場域是否可推廣（最關鍵）
前瞻/靜默	上線但不影響決策，先觀察	真實流程中的實際表現

教學重點 黃金標準是『外部驗證』——尤其在別家醫院、別群病人身上測。內部驗證（同一批資料切分）幾乎總是偏樂觀。一個模型只有通過外部驗證，才有資格說『可能可以推廣』。上線前的『靜默評估』（先跑但不影響決策）是部署前最後一道安全網。

外部驗證不是按一次 AUC：先診斷，再決定能否更新

先鎖定原模型在新資料誠實評估；表現不好時，區分失校準、區辨下降與族群傷害。

先以原模型鎖定參數做純外部驗證；看整體與關鍵族群的校準、區辨、淨效益及不確定性



一旦使用驗證資料調參或更新，該資料就不再是「純外部驗證」；更新後仍需新的獨立資料評估。

來源：Riley et al., BMJ 2024 external validation series；TRIPOD+AI 2024

高品質外部驗證要檢查整體配適、校準、區辨、淨效益與關鍵族群，並報不確定性。若只是基準風險不同，可考慮重新校準；若區辨掉很多或特定族群受害，可能要更新或重建。重要的是：用驗證資料更新後，它就不再是原模型的純外部驗證，必須再找新的獨立資料。

區辨 vs 校準：兩種『準』，都要驗

AUC 高，不代表機率數字可信

區辨 Discrimination

能不能把有病/沒病的人分開排序

指標：AUC / C-statistic

回答：高風險者分數有沒有較高

AUC 高但『機率數字』可能全都偏

→ 排序對，數字未必對

校準 Calibration

預測的『機率』與實際發生率合不合

看校準曲線 / Brier score

回答：模型說 30% 的那群，真的約 30%？

對『拿風險數字給醫師/病人』極重要

→ 很多醫療 AI 只報 AUC，漏了校準

教學重點 承接 9.2：AUC (區辨) 只講『排序能力』，不講『機率準不準 (校準)』。一個 AUC 0.85 的模型可能把每個人的風險都算成兩倍——拿去跟病人說『你有 60% 機率』會嚴重誤導。醫療 AI 一定要『兩者都報』，外部驗證時尤其要看校準有沒有垮掉。

臨床效用：準，然後呢？

模型要能改善『決策與結果』，才算真有用

超越準確度

- 決策曲線分析(DCA)：淨效益
 - 在不同決策門檻下，用它比不用好嗎
 - 考慮漏診 vs 誤報的實際代價
 - 會不會造成過度檢查/警報疲勞
- 準確 ≠ 對病人有好處

要問的真問題

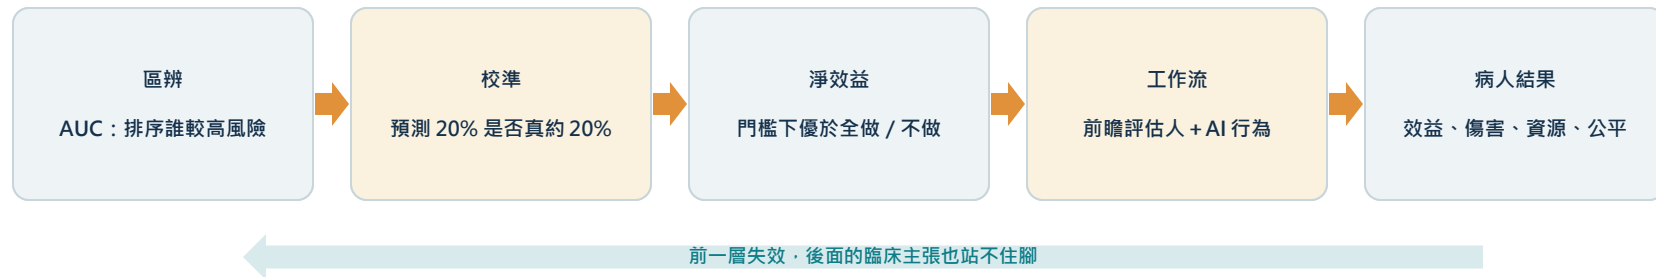
- 它改變了醫師的決策嗎
 - 改變後，病人結果更好嗎
 - 在真實流程中可行嗎 (整合、時間)
 - 對誰有幫助、對誰可能有害
- 最終要用『臨床試驗』驗證 (接 9.4)

教學重點 別停在 AUC：一個模型再準，若不能改善醫師決策與病人結果，就只是漂亮的數字。決策曲線分析評估『淨效益』；而真正的臨床價值，最終要靠前瞻研究、甚至隨機對照試驗 (如 9.4，並用 CONSORT-AI 報告) 來證明——這是從『模型很準』到『真的有用』的最後一哩。

醫療 AI 的證據梯：從排名到病人結果

AUC 只回答「誰較高風險」；可信的臨床證據要再跨過四階。

每上一階，問題從模型表現走向臨床決策：機率可信、門檻有價值、工作流可用、病人真正受益



最低證據組合：discrimination · calibration intercept / slope · decision curve · 前瞻工作流 · 病人 / 系統結果

來源：BMJ 2024；Van Calster et al, BMC Med 2019；DECIDE-AI 2022

區辨 (AUC) 高不代表機率可信，校準好也不代表有淨效益。應依序驗證模型表現、決策效用、工作流與病人結果。

4

PART 4

偏誤與公平

Bias, Fairness & Drift

對應：PROBAST+AI · 資料漂移 · 可解釋性

準確的模型，也可能是不公平、會退化、看不懂の模型。

這一部教你檢查偏誤與公平、監測漂移、並理解可解釋性的限制。

演算法偏誤從哪來？不是只有『資料』

三個階段都可能植入偏誤

來源	發生什麼	例子
資料偏誤	訓練資料不具代表性	某族群樣本太少 → 對他們失準
標籤偏誤	黃金標準本身帶偏	以『過去的花費』當健康需求代理 → 歧視
部署偏誤	用在與開發不同的情境	為 A 情境開發，套到 B 情境失準/有害

教學重點 經典案例：某廣泛使用的健康風險演算法，用『醫療花費』當『健康需求』的代理變數——但弱勢族群就醫花費本來就較低，導致模型系統性低估他們的需求。偏誤不一定來自惡意，常來自『看似合理的代理變數』。選標籤與特徵時要問：這會不會對某些人不公平？

公平性：整體很準，對每個族群也準嗎？

一定要『分組』檢查表現

怎麼檢查

- 把效能『分族群』拆開看(性別、年齡、種族、社經、膚色...)
 - 比較各組的敏感度、PPV、校準
 - 找出對誰系統性較差
- 整體 AUC 高，可能藏著對少數群的失準

公平的難處

- 公平有多種定義，彼此可能衝突
 - 不能全部同時滿足（要做價值取舍）
 - 修正一處可能犧牲另一處
 - 需與臨床、倫理、受影響社群討論
- 公平是社會技術問題，不只是技術

教學重點 核心動作：永遠『分組』評估——把敏感度、PPV、校準按族群拆開看。整體漂亮的數字，可能是靠多數群撐起、犧牲少數群。公平性沒有單一技術解（不同公平定義會互斥），需要在設計階段就納入受影響族群與倫理考量，明確做出並說明價值取舍。

PROBAST+AI：系統性評估『偏誤風險』

開發者自查、審稿人評讀，都用得上

四大評估領域

- 受試者/資料：來源與代表性
- 預測變數：如何量測與處理
- 結果（標籤）：如何定義、是否獨立
- 分析：切分、樣本量、驗證、校準、過度擬合與洩漏的風險

怎麼用

- 開發時逐項自我把關
 - 評讀他人模型研究的偏誤風險
 - 搭配 TRIPOD+AI（報告）一起用
（一個評偏誤、一個規範報告）
- 健康 AI 預測模型的品質對照表

教學重點 分工：PROBAST+AI 評『這個模型研究偏誤風險有多高』（給評讀者/開發者自查）；TRIPOD+AI 規範『報告要寫齊哪些』（給作者）。兩者互補——就像 5.2 的 AMSTAR 之於 PRISMA。用 PROBAST+AI 逐項檢查資料、變數、標籤、分析四大領域，能提早抓出洩漏、缺外部驗證等致命問題。

部署後：資料漂移與可解釋性

上線不是終點，模型會『退化』也需要『被理解』

資料漂移 Drift

人口、流程、儀器、疾病型態會變

→ 模型效能隨時間悄悄下降

對策：持續監測效能與輸入分佈

設定觸發條件，定期再驗證/再訓練

→ 部署後要有『維護計畫』

可解釋性 XAI

SHAP、LIME 等解釋『模型看了什麼』

幫助：抓捷徑學習、建立臨床信任

但：解釋本身可能不忠實、被過度解讀

不能取代『嚴謹的外部驗證』

→ 輔助工具，不是免死金牌

教學重點 兩個提醒：① 模型會隨『資料漂移』退化——部署後必須持續監測並規劃再訓練，不能上線就不管。② 可解釋性 (SHAP/LIME) 有助於抓假線索與建立信任，但解釋不等於正確，也可能誤導；它是輔助，永遠取代不了紮實的外部驗證與臨床評估。

部署後監測：從漂移警訊到安全更新

上線不是終點；資料、表現、使用行為與傷害都可能隨時間改變。

預先定義監測頻率、警戒線、責任人與停用 / 回退機制，才能把漂移轉成可處理的安全訊號



來源：FDA GMLP 2021；FUTURE-AI, BMJ 2025；Finlayson et al., NEJM 2021

資料漂移不等於一定失效，但必須連結到表現、子群與臨床流程後果。監測計畫要在部署前寫好：量什麼、多久量、誰判讀、何時警報、何時降級或停用，以及更新後如何重新驗證。

評估的是「人 + AI 工作系統」，不是模型單獨

使用者如何理解、依賴、覆核與覆寫 AI，會改變最終決策、傷害、工作負荷與公平。

部署時的研究單位是「人 + AI + 流程」；模型準確，不保證使用者會正確依賴、覆核或行動



來源：DECIDE-AI 2022；FUTURE-AI, BMJ 2025 (fairness, universality, traceability, usability, robustness, explainability)

部署前後要比較 AI 單獨、臨床人員單獨與人機團隊；記錄接受、拒絕、覆寫與覆核的原因，也要看自信校準、警報疲勞、近失誤、時間與族群差異。好的介面要讓人看見限制與不確定性，並保留合理的拒絕、升級與停用路徑。

5

PART 5

報告與實例

Reporting & Worked Example

對應：TRIPOD+AI·視網膜篩檢實例

最後：用對的報告規範讓你的模型可信、可複製，
並用一個完整實例把 Part 1–4 串起來。

報告規範地圖：哪種研究用哪一個

對應研究型態，選對規範

規範	用於	重點
TRIPOD+AI (2024)	開發/驗證『預測模型』（含 ML）	取代 TRIPOD 2015；透明報告開發與驗證
PROBAST+AI (2025)	評「預測模型」品質、偏誤風險與適用性	兩部分各四領域；開發 16 項、評估 18 項訊號問題
CONSORT-AI / SPIRIT-AI	AI 介入的『臨床試驗』報告/計畫	接 9.4：試驗層級的 AI 延伸
DECIDE-AI	AI 決策支援的『早期臨床評估』	17 AI 項 + 10 通用項，重入因

教學重點 選規範看『研究做到哪一步』：開發/驗證一個預測模型→TRIPOD+AI（報告）+ PROBAST+AI（偏誤）；早期在臨床試用決策支援→DECIDE-AI；做到隨機對照試驗→CONSORT-AI（接 9.4）。全部可在 EQUATOR Network 查到。報告透明是讓別人能複製、能信任你模型的最低門檻。

先看研究問題與階段，再選 AI 報告規範

2025 年 STARD-AI 補上 AI 診斷準確度研究；PROBAST+AI 則是偏誤與適用性評讀工具。

同一個 AI 系統在不同研究階段，應搭配不同規範；報告清單不等於偏誤風險工具

預測模型開發 / 驗證

TRIPOD+AI
BMJ 2024

回歸或 ML 的診斷 / 預後預測模型

AI 診斷準確度

STARD-AI
Nature Medicine 2025

在 STARD 2015 上新增 / 修改 18 項

早期真實臨床使用

DECIDE-AI
Nature Medicine 2022

含人因、工作流、錯誤與安全

隨機試驗 / 計畫書

CONSORT-AI / SPIRIT-AI
2020

比較 AI 介入對照護與結果的影響

跨開發、更新與驗證的評讀工具：PROBAST+AI (BMJ 2025) → 品質、偏誤風險與適用性；不是報告規範。

來源：TRIPOD+AI 2024；PROBAST+AI 2025；STARD-AI 2025；DECIDE-AI 2022；CONSORT-AI / SPIRIT-AI 2020

開發 / 驗證臨床預測模型用 TRIPOD+AI；AI 診斷準確度研究用 STARD-AI；進入早期真實工作流用 DECIDE-AI；比較對照護與結果的影響則用 CONSORT-AI / SPIRIT-AI。PROBAST+AI 是跨模型開發、更新與驗證的品質、偏誤風險與適用性工具；正式名稱為 PROBAST+AI (非早期文獻常見的 PROBAST-AI)。

可信任 AI 的四層證據：不能只勾報告清單

報告、偏誤評讀、生命週期工程與治理各回答不同問題。

透明報告讓人看見研究；偏誤工具判斷可信度；工程與治理讓系統在真實環境持續安全

透明報告

TRIPOD+AI / STARD-AI
DECIDE-AI / CONSORT-AI

研究做了什麼？是否可重現？

偏誤與適用性

PROBAST+AI
BMJ 2025

結果可信嗎？適用於此族群嗎？

生命週期工程

FUTURE-AI / FDA GMLP
2021–2025

如何開發、監測、更新與退場？

倫理與治理

WHO AI for Health
WHO 2021

誰負責？如何確保公平、權利與問責

重要：報告完整 ≠ 低偏誤 ≠ 有臨床效益 ≠ 可安全部署；四層要一起對齊。

來源：TRIPOD+AI / STARD-AI / DECIDE-AI / CONSORT-AI；PROBAST+AI；FUTURE-AI；FDA GMLP；WHO 2021

一份寫得完整的研究仍可能高偏誤；一個低偏誤模型也可能沒有臨床淨效益。用報告規範檢查透明度、用 PROBAST+AI 評讀偏誤，再用 FUTURE-AI / GMLP 與 WHO 原則檢查部署與治理。

綜合實例：糖尿病視網膜病變篩檢模型

把開發→驗證→偏誤→報告一次走完

階段	做了什麼	關鍵把關
開發	眼底照片分類『需轉診 vs 否』	以病人為單位切分、先切再前處理
內部驗證	交叉驗證看 AUC/敏感度	防洩漏、報效應與 CI
外部驗證	用別國、別機型資料再測	AUC 略降、重新檢查校準
偏誤/公平	分膚色/機型看敏感度與校準	修正對深膚色影像的失準
報告	依 TRIPOD+AI、PROBAST+AI 自查	公開資料/程式可用性

教學重點 看整體：一個負責任的醫療 AI 研究，不會停在『內部 AUC 0.95』——它會在別國別機型做外部驗證（效能通常會降，這才真實）、分族群檢查公平（如不同膚色的眼底照片）、並依 TRIPOD+AI 透明報告、用 PROBAST+AI 自查偏誤。這才是從『看起來準』到『真的能用又公平』。

做醫療 AI 的『可以』與『不可以』

方法紀律，比模型花俏更重要

✓ 該做的

- 先切分再前處理、以病人為單位
- 做『外部』驗證，區辨與校準都報
- 分族群檢查公平、報告限制
- 依 TRIPOD+AI 報告、PROBAST+AI 自查
- 部署後監測漂移、規劃再驗證

✗ 不要做的

- 只報訓練/內部的漂亮 AUC
- 只看 accuracy (不平衡時誤導)
- 讓資料洩漏灌水效能
- 忽略少數族群的表現
- 上線就不管、不監測不更新

教學重點 核心原則：醫療 AI 的可信度來自『方法紀律』而非模型多新。守住——先切分再處理、外部驗證、區辨 + 校準、分族群公平、透明報告、部署監測——你的模型就贏過文獻裡大半只報內部 AUC 的研究。若研究本身也用了生成式 AI 輔助，記得揭露（接 1.3）。

本課總覽：一頁看完醫療 AI 研究法

從資料到部署，紀律貫穿全程

主題	關鍵心法	對應
陷阱	外部驗證少、洩漏多 → 複製危機	方法三要件
開發	先切再處理、防洩漏、看對指標	訓練/驗證/測試
驗證	外部驗證 + 區辨與校準都要	接 9.2 ROC/校準
偏誤	分族群看公平、評偏誤風險	PROBAST+AI
報告	對症選規範、透明可複製	TRIPOD+AI 等

教學重點 帶走一句話：醫療 AI 的價值不在『訓練集上多神』，而在『對新病人、新場域、各族群都可靠、公平、可維護，且被透明報告』。演算法會一直進步，但這套研究方法的紀律——嚴謹開發、誠實驗證、警覺偏誤、透明報告——才是讓 AI 真正幫到病人的關鍵。



作業

Take-home Assignment

Critique & Design a Medical AI Study

Part A 觀念題 · Part B 實作題 (附參考答案)

作業目標：能揪出資料洩漏與缺外部驗證、判讀區辨 vs 校準，
並用 TRIPOD+AI / 公平性思維設計與評讀一個醫療 AI 研究。

作業說明與繳交

建議 3–4 頁；重點是判斷與設計，不是背名詞

形式與繳交

- 形式：一份評讀 + 設計報告(PDF/Word)
- 篇幅：Part A 每題 3–5 句；Part B 完整作答
- 可畫資料切分圖、分族群效能表
- 獨立完成；可用 AI 協助但需自行核對並揭露
- 繳交期限：兩週後上課前

評分重點

- 揪出資料洩漏/缺外部驗證 (25%)
- 區辨 vs 校準判讀正確 (20%)
- 不平衡與指標選擇 (15%)
- 公平性/偏誤檢查設計 (20%)
- 報告規範與監測意識 (20%)

情境 (Part B 共用)：你要設計並評讀一個『從胸部 X 光偵測肺炎』的 AI 模型研究。

教學重點 寫作提醒：每個判斷都要說『為什麼、你會怎麼驗證/修正』。老師看的是你能不能把『先切再處理、外部驗證、區辨 + 校準、分族群公平、透明報告』這套紀律，實際用在一個醫療 AI 研究上。

四題觀念題（每題 3–5 句）

用你的話講清楚

A1

一篇論文報告『內部驗證 AUC 0.98』就宣稱模型可臨床使用。你會質疑什麼？該補哪些驗證？

A2

什麼是『資料洩漏』？舉一個醫療影像的例子，並說明怎麼在切分與前處理上避免。

A3

一個模型 AUC=0.9 卻『校準很差』，會造成什麼問題？為什麼兩者都要報？

A4

為什麼整體準確率高，模型仍可能『不公平』？你會怎麼檢查？

教學重點 提示：A1 想外部驗證 + 校準 + 洩漏；A2 想同病人跨集、先切再處理；A3 想機率數字誤導、決策風險；A4 想分族群拆開看敏感度/PPV/校準。

設計並評讀一個醫療 AI 研究

胸部 X 光 × 肺炎偵測

為『胸部 X 光偵測肺炎』的 AI 模型，請完成：

- B1 描述你的資料切分策略（訓練/驗證/測試），並說明你如何防止資料洩漏。
- B2 你會怎麼做『外部驗證』？要看哪些指標（至少含一個區辨、一個校準）？
- B3 資料以『無肺炎』居多（不平衡）。你會看哪些指標、怎麼調門檻？為什麼不看 accuracy？
- B4 你會怎麼檢查模型對不同族群/機型是否公平？
- B5 列出你會依 TRIPOD+AI 交代的三個關鍵報告項目，並各寫一句。

教學重點 重點：B1 以病人為單位切分、先切再前處理；B2 別院/別機型資料 + AUC 與校準曲線；B3 敏感度/PPV/F1 + 依代價調門檻；B4 分族群比效能與校準；B5 資料來源、切分/驗證方法、缺失與限制、程式/資料可用性。

想更深入可以看這些

權威規範與經典資源

主題	來源
預測模型報告	TRIPOD+AI (Collins et al., BMJ 2024 ; 取代 TRIPOD 2015)
偏誤風險	PROBAST+AI (Moons et al., BMJ 2025 ; 品質、偏誤風險與適用性)
AI 臨床試驗	CONSORT-AI / SPIRIT-AI (Nature Medicine 2020 ; 接單元 9.4)
早期臨床評估	DECIDE-AI (Nature Medicine 2022 ; 17 AI 項 + 10 通用項)
方法/公平	Obermeyer et al. (Science 2019) 演算法偏誤經典 ; 校準見 9.2

教學重點 下一步：本單元延伸『2.5 推論統計』與『9.2 診斷準確度』，並與『9.3 觀察性/RWE』、『9.4 臨床試驗(CONSORT-AI)』互相支援。若模型要進臨床試驗，用 CONSORT-AI；要上市為醫材，還需符合 SaMD 法規（見 9.10）。



醫療 AI / 機器學習研究法 · Medical AI/ML Research Methods

準，不夠；要可靠、公平、可維護

先切再處理 · 外部驗證 · 區辨 + 校準 · 分族群公平 · 透明報告 · 部署監測

資料洩漏 · *TRIPOD+AI* · *PROBAST+AI* · *CONSORT-AI* · 資料漂移

案例應用：這個 AI 工具本身驗證過了嗎

案例 Q | AI 照護紀錄摘要工具對長照機構交班效率與紀錄品質之影響

①

本單元教了什麼

醫療 AI 的驗證層次、外部驗證、族群公平性與 TRIPOD+AI 報告。

②

案例怎麼用

- 整體 AUC = 0.817，惟整體數字會掩蓋族群差異，必須分層檢視。
- 分機構外部驗證：A 機構 0.823、B 機構 0.810，跨場域表現一致。
- 分班別：大夜班 0.765、小夜班 0.904——大夜班遺漏率最高而判別力最差。
- 分職類：護理師 0.752、資深照服員 0.877，差距 0.125 須列為公平性議題。
- 本研究僅評估既有工具，未參與開發；此界線須在論文中明確聲明。

③

產出什麼證據

分層驗證表與 TRIPOD+AI 自評（次頁），納入論文第四章第七節。

④

承接關係

上游：承自 9.4 之試驗設計摘要與 CONSORT 流程圖 | 下游：交棒 9.6，把工具放回介入設計的框架裡看。

教學重點 大夜班是遺漏率最高（20.2%）而 AI 判別力最差（AUC 0.765）的族群——風險最高的地方，工具反而最不可靠。只看整體 AUC 永遠看不到這件事。

示範產物：分層驗證與公平性檢視

整體 AUC = 0.817；下表為分層結果，差距超過 0.10 者須於論文中討論

分層	n	遺漏率	AUC	判讀
整體	400	12.2%	0.817	中等偏佳；95% CI [0.742, 0.891]
A 機構	217	11.1%	0.823	與整體一致
B 機構	183	13.7%	0.810	跨場域表現穩定，支持外部效度
白班	147	8.8%	0.800	與整體相近
小夜班	149	10.1%	0.904	表現最佳
大夜班	104	20.2%	0.765	風險最高而判別力最差——最須關注之族群
護理師	168	11.9%	0.752	與資深照服員相差 0.125，屬公平性議題
資深照服員	162	13.0%	0.877	表現最佳之職類
單位主管	70	11.4%	0.820	與整體一致

教學重點 這張表也回答了單元 9.4 的問題：若要做群集隨機試驗，大夜班應列為預先指定的次群體分析，而不是等看到結果才回頭挖。