智慧醫療與科技發展　Smart Healthcare & Technology Development

05

醫療 AI 方法論與模型生命週期

Medical AI Methods & Model Lifecycle

第 5 週 單元二：醫療 AI 技術與臨床應用
模型怎麼來、準不準、能不能用在我們醫院

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

開場 Opening

廠商說：「我們的再入院預測 AI，AUROC 0.85」

北城區域醫院（虛構）正在評估採購；你是評估小組成員

廠商簡報（ReAdmit-X，虛構產品）	評估小組該追問的
「以 50 萬筆住院資料訓練」	是哪裡、哪些年份、哪些病人的資料?
「AUROC 高達 0.85」	在誰的資料上算的? 是哪一層驗證?
「準確率 88%」	再入院率是多少? 只看準確率會誤導嗎?
「可提早找出高風險病人」	預測 30%，真的有 30% 會再住院嗎?
「降低再入院」	要標記多少人? 人力負擔得起? 有介入嗎?

下課前要能逐一回答右欄五個問題，這就是醫療 AI 的識讀能力。

開場 Opening

為什麼醫院在意再入院

再入院是品質指標，也是成本問題，更是常見的醫療 AI 題目

約 80%

受評美國醫院被扣款（FY2027）

0.684

LACE 指數的 C 統計量（2010）

2 次

王伯伯過去一年住院

機器學習號稱比傳統評分更準：在哪裡、對誰更準？

0.684 與 0.85 在不同資料上計算，不能直接比較。

本週要學的，就是判斷「更準」這句話能不能信。

學習目標 Learning Objectives

本週結束時，你能做到什麼

四個可檢核的學習目標

C1	說明 AI 、機器學習、深度學習、基礎模型的關係。
C3	辨識過度擬合、資料洩漏與捷徑學習等陷阱。
C3	計算敏感度、特異度、 PPV 、 NPV ，說明盛行率的影響。
C3	區分 AUROC 與校準度，依人力與介入成本選擇閾值。

課堂產物：一份 ReAdmit-X 採購建議與追問清單。

本週地圖 This Week

本週的五個問題

從「AI 是什麼」走到「這個 AI 能不能用在我們醫院」

名詞地圖	AI、機器學習、深度學習、基礎模型怎麼區分?
機器怎麼學	模型如何從資料學習? 會在哪裡學錯?
生命週期	模型上線後為什麼會變不準? 誰要負責?
評估指標	用本院資料驗證：準不準、標記多少人?
採購決策	ReAdmit-X 該不該買? 要追問什麼?

W2 看 AI 怎麼演進；本週看模型怎麼被造出來、怎麼被檢驗。

01

PART 1

AI 名詞地圖 The AI Landscape

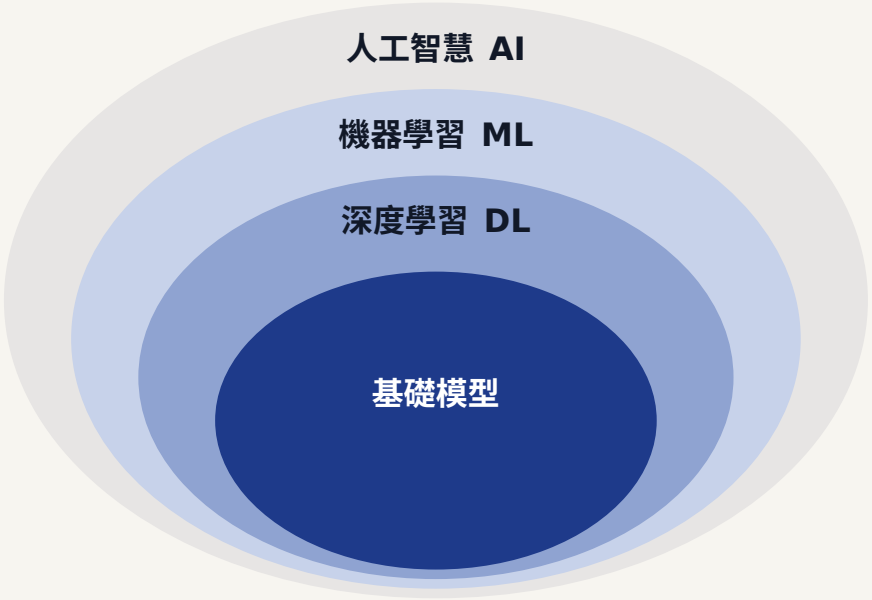
先把名詞的包含關係弄清楚

固定分數與學習模型、三種學習方式、任務類型、深度學習、基礎模型

Part 1 | 包含關係

AI、機器學習、深度學習、基礎模型

是包含與重疊的關係，不是一代取代一代



層次	醫療例子
AI （含規則）	用藥交互作用警示
機器學習	再入院風險預測
深度學習	胸部 X 光、心電圖判讀
基礎模型	病歷摘要、衛教生成（W6）
生成式 AI	與基礎模型大幅重疊，但不等同

新方法不會淘汰舊方法：規則式警示、迴歸與傳統機器學習至今仍是臨床主力。

Part 1 | 部署形式

固定分數表，或直接使用學習出的模型

以再入院風險為例；兩者的分數都從資料推導而來

面向	固定分數表： LACE 指數	直接部署的機器學習模型
輸入	住院天數、急性入院、共病、急診次數	數十到數百個變項
權重	由迴歸模型從資料推導，再簡化成整數給分	從歷史資料學出權重與交互作用
輸出	總分 0–19；常以 10 分以上為高風險	每位病人的再入院機率
優點	透明、好懂、好執行	通常鑑別力較好
限制	鑑別力有限	較難解釋；換醫院可能失準，需驗證

差別在部署形式，不在「人寫還是機器學」；複雜模型不一定比較好，資料少、需要透明時，分數表常更實用。

機器學習的三種學習方式

差別在於資料有沒有「標準答案」

學習方式	白話比喻	需要的資料	醫療例子
監督式	有答案的考古題	特徵＋標籤	預測 30 天再入院； X 光有無肺炎
非監督式	沒有答案，自己分組	只有特徵	把心衰竭病人分成亞型
強化式	嘗試錯誤、獲得獎勵	環境＋獎勵規則	加護病房給藥策略（多在研究）

另有自監督學習：從大量未標註資料自己出題自己學，是基礎模型的關鍵技術。

臨床最常見的是監督式學習，所以標籤品質決定模型的上限。

Part 1 | 任務類型

模型在做什麼：四種常見任務

先看任務，才知道用什麼指標評估

任務	回答什麼問題	常用評估
分類 Classification	會不會再入院？是不是肺炎？	AUROC 、敏感度、 PPV
迴歸 Regression	住院幾天？血糖多少？	誤差（例如 MAE ）
分群 Clustering	病人可分成幾種亞型？	臨床可解釋性
生成 Generation	寫摘要、回答問題	正確性、幻覺（ W6 ）

再入院預測是分類任務，但輸出的是機率，所以要同時看鑑別力與校準度。

深度學習：讓機器自己找出特徵

多層神經網路，擅長影像、聲音、波形與文字



強項　影像（X 光、眼底、病理）與波形（心電圖）；不必人工設計特徵。

代價　常需大量資料（標註需求視方法而定）、運算成本高、較難解釋判斷理由。

表格型資料（如再入院預測）用傳統機器學習常就足夠；影像與波形才是深度學習的主場。

基礎模型：先大量預訓練，再用於多種任務

延伸閱讀： Bommasani 等（2021）；醫療版稱通用醫療 AI （Moor 等，2023）

預訓練

海量文字、影像

自監督學習

學到通用能力



基礎模型

一個模型

- 病歷摘要
- 衛教生成
- 影像報告草稿
- 臨床問答

從一個任務一個模型，走向一個模型多種任務（W6 深入）。

02

PART 2

機器怎麼學 How Machines Learn

沒有魔法：從有答案的歷史資料中找規律

特徵與標籤、資料切分、過度擬合、資料洩漏與捷徑學習

一筆出院紀錄，如何變成機器能學的資料

特徵是輸入；標籤是要預測的答案

病人	年齡	住院天數	半年急診	共病指數	心衰竭	30 天內再入院
王伯伯	72	9	2	4	是	是
病人 B	58	3	0	1	否	否
病人 C	81	6	1	3	是	否
… 共 2,000 筆						

特徵 Features （來自 W3 的 FHIR 資源）

標籤 Label

標籤要先定義清楚：含不含計畫性住院？他院住院算不算？

Part 2 | 資料切分

訓練、驗證、測試：不能用考古題出期末考

資料要分開使用，才能公平評估模型



訓練集	驗證集	測試集
讓模型學習規律	調參數、挑模型	只考一次

比喻　訓練＝做練習題；驗證＝模擬考；測試＝正式大考。

常見錯誤　反覆看測試結果再改模型，等於偷看考題。

內部切分只能證明在同一家醫院有效；換醫院要靠外部驗證。

依病人、依時間、依醫院：回答不同的問題

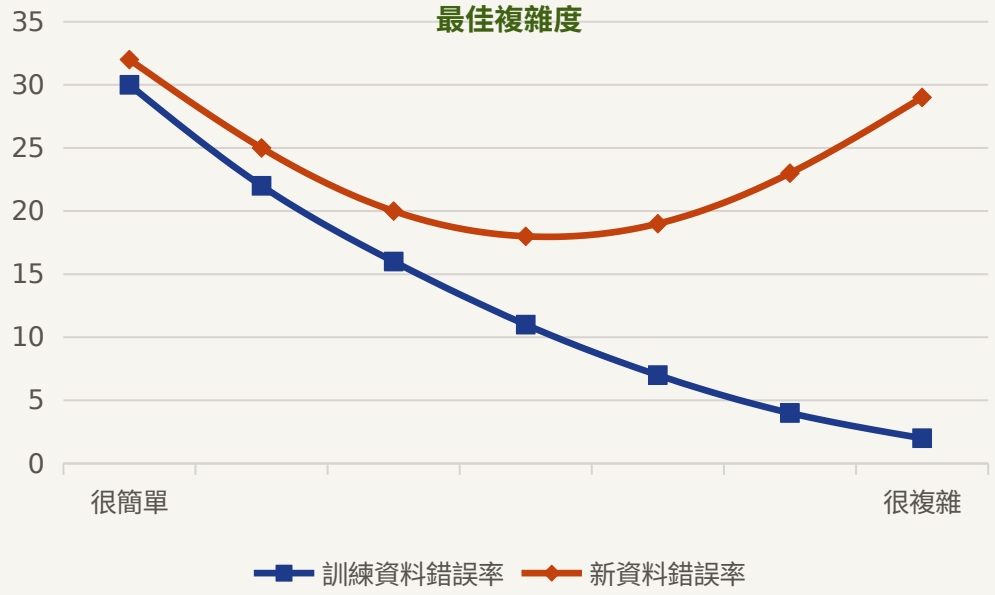
切分方式要對應「模型將來怎麼用」

切分方式	防的是什麼	回答的問題	要注意
依住院隨機	—	同一批資料內的表現	同一病人多次住院可能跨組，高估表現
依病人	同一人同時在訓練與測試	對沒看過的病人表現如何	仍是同一時期、同一家醫院
依時間	用未來資料訓練	部署到之後的病人表現如何	同一病人可能跨期，要另查重疊
依醫院（外部）	只適用開發醫院	換場域還能用嗎	病人組成、流程、編碼都不同

病人切分與時間切分處理不同的泛化問題，不能互相取代；依部署情境設計，並檢查交疊。

過度擬合：背熟考古題，遇到新題就不會

模型越複雜，訓練表現越好，新資料卻未必



怎麼避免

- 資料量要足夠
- 限制模型複雜度（正規化）
- 用驗證集挑模型
- 在沒看過的資料上測試

看到「訓練準確率 99%」先追問：沒看過的資料上是多少？

模型很準，但學錯了東西

兩個國際經典案例

面向	肺炎死亡風險（Caruana 2015）	胸部 X 光肺炎（Zech 2018）
模型學到	有氣喘 → 死亡風險較低	影像來自哪家醫院
真相	氣喘病人會直接送加護病房，照護更積極	各院肺炎盛行率不同，成了捷徑
後果	若據此讓氣喘病人回家，後果嚴重	換一家醫院，表現下降
教訓	把治療效果誤當成病人特性	高分不代表學到臨床特徵

兩例都不是「偷看答案」，而是學到照護流程與資料來源；高分不等於學到病人的病情。

看時間軸，不看變數名稱

例：再入院模型可不可以用「出院時已安排居家護理」？

時點	預測的時間點之前，這個資訊已經存在嗎?
先後	它是在結果發生之後才記錄的嗎?
標籤	它是結果定義的一部分嗎?
上線	實際使用時，同一時點拿得到嗎?
價值	就算不洩漏，是否只是重現團隊判斷？比既有照護多了什麼?

預測時點在出院時：居家護理已排定就可以用；但模型可能只是學到「團隊已經覺得他高風險」。

03

PART 3

模型生命週期與 MLOps Lifecycle & MLOps

模型不是買來就結束，而是要持續照顧

七個階段、驗證層級、資料集偏移、 MLOps 、 GMLP

醫療 AI 模型的生命週期

每一階段都有臨床人員必須參與的決策



階段	臨床人員要回答的問題
問題定義	預測出來之後，誰要做什麼？沒有行動的預測沒有價值。
資料與特徵	資料代表我們的病人嗎？標籤怎麼定義？有沒有洩漏？
驗證	在本院資料上準不準？各族群是否一樣準？
部署與監測	放在哪個畫面、誰看？上線後表現有沒有下滑？

最常被跳過的是第一步：只問能不能預測，沒問預測之後要做什麼。

驗證的五個層級：越往上，證據越強

從自己考自己，到證明改善病人結果

多數醫療 AI 研究停在前兩層； W12 用 TRIPOD+AI 、 DECIDE-AI 檢核。



廠商的 0.85 是哪一層？若只是內部驗證，對北城的證據力有限。

上線後為什麼會變不準

Finlayson 等（2021）：臨床人員應認識的資料集偏移

偏移類型	發生了什麼	再入院模型的例子
病人組成改變	病人特性分布不同	從醫學中心移到區域醫院，病人更老、共病更多
盛行率改變	結果發生比例不同	推出出院後追蹤計畫，再入院率下降
關係改變	特徵與結果的關係變了	新藥上市，心衰竭與再入院的關聯減弱
流程與編碼改變	資料產生方式改變	換 HIS 、 ICD 編碼規則或檢驗儀器

世界變了，模型不會自己知道： COVID-19 期間許多模型同時失準。

MLOps： 模型上線後的持續照顧

Machine Learning Operations： 借用軟體工程的維運觀念

監測表現	定期檢查 AUROC 、校準度、警示數量與各族群表現。
偵測偏移	比較輸入資料分布與訓練時是否不同。
更新模型	依預先定義的程序重新校準或重新訓練。
版本紀錄	每個版本可追溯，出事可回溯。

誰負責監測、多久一次、變不準時誰決定更新，都要寫進採購合約。

GMLP：優良機器學習規範十大原則

延伸閱讀：美國 FDA、加拿大衛生部、英國 MHRA （2021）

1. 跨領域專業參與整個生命週期
2. 良好的軟體工程與資安實務
3. 資料能代表目標病人族群
4. 訓練與測試資料彼此獨立
5. 參考標準採最佳可得方法
6. 模型設計符合資料與預期用途
7. 重視「人＋ AI」團隊整體表現
8. 在臨床相關情境下測試
9. 提供使用者清楚必要的資訊
10. 上線後持續監測與管理再訓練

第 3、4、10 條就是本週重點：資料代表性、測試獨立、上線監測。

04

PART 4

評估指標：用本院資料驗證 Evaluation Metrics

同一個模型，換一個指標，結論可能完全不同

混淆矩陣、四個指標、盛行率、 AUROC 、校準、重新校準、閾值

Part 4 | 本地驗證

北城區域醫院怎麼驗證 ReAdmit-X

虛構情境；合成資料，供課堂判讀

醫院	450 床區域醫院（W3 演練過）， EMRAM 約第 4 階。
人力	專責個管師 1 名，每月可額外追蹤約 25 人。
資料	院內近一年 2,000 次出院（去識別化）。
做法	以 ReAdmit-X 產生風險分數，與實際 30 天再入院比對。
要算的	混淆矩陣、 AUROC 、校準度、不同閾值的工作量。

這就是本地外部驗證：不靠廠商的數字，用自己醫院的資料驗證一次。

混淆矩陣：模型的四種結果

依風險排序，前 562 人（28%）標為高風險

	實際：再入院	實際：未再入院
預測：高風險	真陽性 TP 190 預測高風險，真的再入院	偽陽性 FP 372 預測高風險，其實沒有
預測：低風險	偽陰性 FN 134 預測低風險，卻再入院	真陰性 TN 1,304 預測低風險，也沒有

代價不同

- FN：漏掉王伯伯，可能再住院
- FP：個管師白打電話

實際再入院率 16.2%： 2,000 人中 324 人再入院；後面指標都從這四格算出。

Part 4 | 四個指標

敏感度、特異度、 PPV 、 NPV ： 各回答一個問題

以同一張混淆矩陣計算

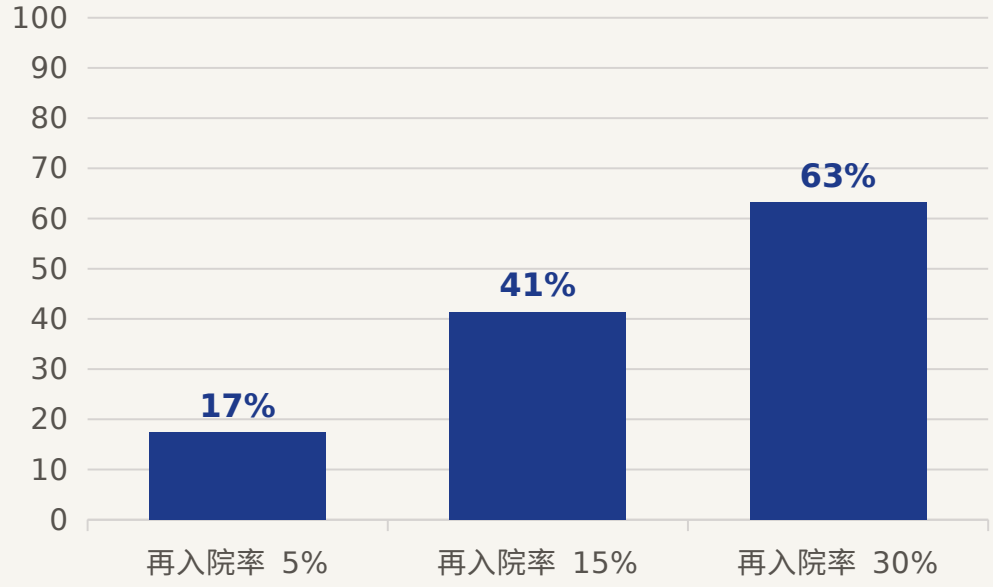
指標	回答的問題	計算	本例
敏感度	真的再入院的人，抓到幾成?	TP ÷ （TP + FN）	59%
特異度	沒再入院的人，正確排除幾成?	TN ÷ （TN + FP）	78%
陽性預測值 PPV	被標高風險的人，真的再入院幾成?	TP ÷ （TP + FP）	34%
陰性預測值 NPV	被標低風險的人，真的沒事幾成?	TN ÷ （TN + FN）	91%

準確率陷阱： 一律預測「不會再入院」，準確率就有 84% ，卻一個也沒抓到。

臨床人員最該看 PPV ： 被警示的人裡，有多少真的需要處理。

同一個模型，在不同醫院的 PPV 天差地遠

假設敏感度、特異度都是 80%，只改變再入院率



5% 被警示者只有約 17% 真的再入院

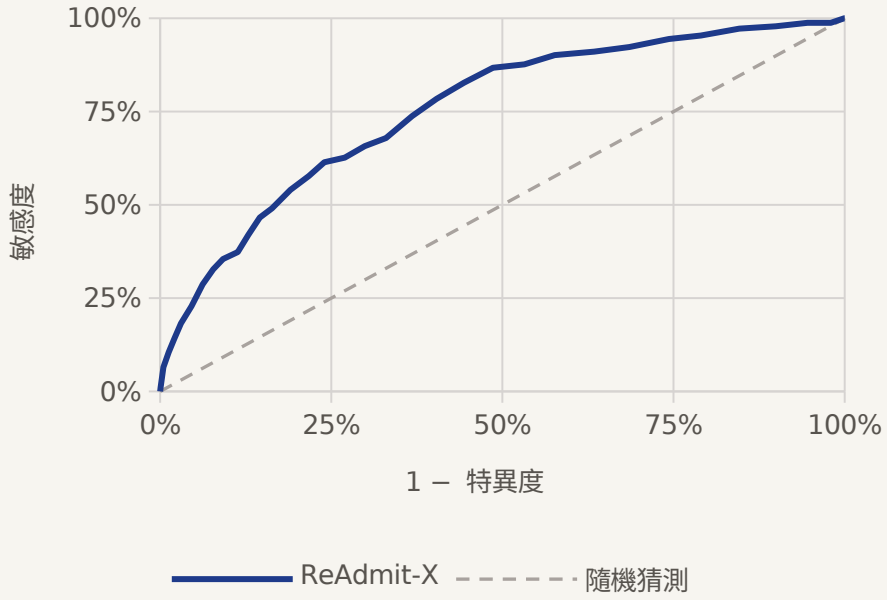
30% 上升到約 63%

解讀 低盛行率時，警示多半是虛驚

沒有盛行率，「準確率 88%」無法判斷臨床負擔；要換算成本院盛行率。

AUROC：模型分辨高低風險的能力

ReAdmit-X 在北城合成資料上： AUROC = 0.76



白話解釋

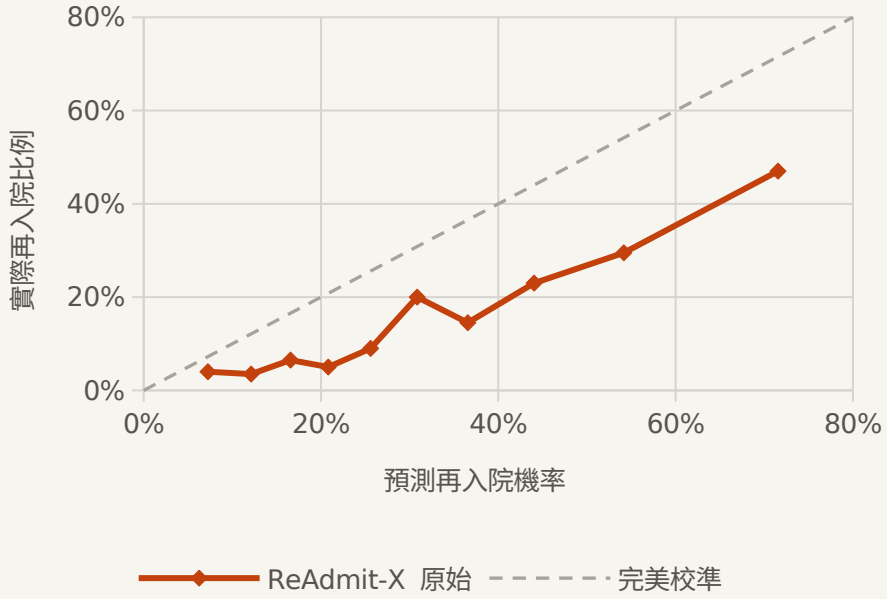
隨機抽一位再入院者與一位未再入院者，模型給前者較高分的機率約 76%。

0.76 夠不夠？要一起看
和誰比： LACE 在本院同一份資料的 AUROC、醫師判斷
本院事件率與校準度
閾值下的 PPV 與每月警示量
錯過與誤報的代價、可用人力

AUROC 沒有通用的「及格線」；它只看排序，不看機率準不準，也不看處理得了幾個警示。

校準度：模型說 30%，真的有 30% 嗎

Van Calster 等（2019）稱之為預測分析的阿基里斯腱



線上	預測準確
線下	高估風險
最高組	預測 72%，實際 47%
全院	平均預測 32%，實際 16%

ReAdmit-X 系統性高估約一倍：可能在再入院率較高的醫院開發。

鑑別力與校準度：兩種不同的「準」

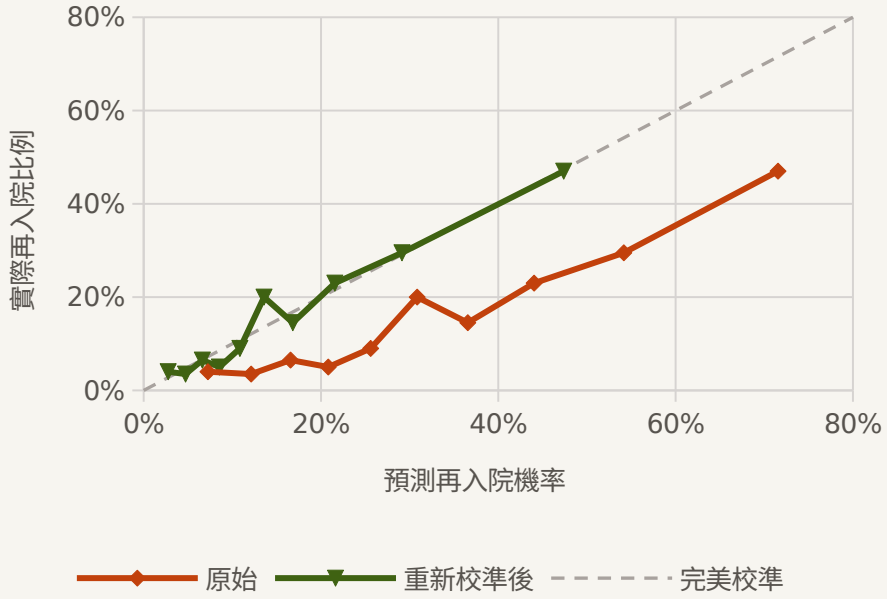
一個管排序，一個管機率；臨床決策兩個都需要

面向	鑑別力 Discrimination	校準度 Calibration
問題	能不能把高低風險分開?	機率數字可不可信?
指標	AUROC （C 統計量）	校準圖、校準斜率與截距
比喻	考試排名對不對	分數本身準不準
用途	決定先照顧誰	跟病人說明風險、估算資源
能否修正	不足時難以補救	可用本院資料重新校準

好消息：校準度可以用醫院自己的資料修正；鑑別力不足就難救了。

用本院資料重新校準

鑑別力不變，風險數字回到可信範圍



排序 保留不變（AUROC 不變）

調整 依本院資料修正截距與斜率

結果 平均預測 32% → 16%

合約 寫明多久重新校準一次

重新校準是國際建議做法，但要在獨立資料上確認，並定期監測。

閾值怎麼選：其實是在選工作量

重新校準後，在 2,000 次出院中改變高風險閾值

高風險閾值	被標記人數	占出院	抓到再入院者（敏感度）	PPV
≥ 10%	1,171	59%	284 ／ 324 （88%）	24%
≥ 20%	562	28%	190 ／ 324 （59%）	34%
≥ 30%	277	14%	118 ／ 324 （36%）	43%

取捨： 10% 幾乎都抓到，但要追蹤 1,171 人； 30% 工作量小，卻漏掉 206 位再入院者。

閾值是臨床與管理決策：依人力與介入成本，由醫療團隊共同決定。

決策曲線分析：模型有沒有用

延伸閱讀： Vickers 與 Elkin （2006）

比較策略	全部介入、全部不介入、依模型介入，三者比較。
淨效益	把抓到的好處，扣掉誤報的代價。
閾值區間	在臨床合理的閾值範圍內，模型是否都勝出。

AUROC 說模型好不好，決策曲線說模型有沒有用。

05

PART 5

採購決策： ReAdmit-X Simulated Case

把本週所學，用在一個真實會發生的決策

廠商宣稱與本院驗證、評估建議、追問清單

擬真個案 Simulated Case

廠商宣稱與本院驗證結果

同一個模型，換了醫院，數字就變了

項目	廠商宣稱	北城本院驗證	判讀
AUROC	0.85	0.76	鑑別力下降；能否用要看工作量與校準
再入院率	未揭露	16.2%	盛行率不同， PPV 會不同
平均預測風險	未揭露	32%	系統性高估約一倍
驗證層級	未揭露（推測為內部驗證）	本地外部驗證	本院結果才是決策依據

看清楚掉多少、為什麼掉、還能不能用。

擬真個案 Simulated Case

評估小組的建議：有條件採用

把本週概念串成一份可執行的建議

先試行	心衰竭等高風險科別試行 6 個月；下列人數為全院估計，科別內要重算。
定閾值	依每年約 300 人的量能，選 30%（每年約 277 人，PPV 約 43%）。
配介入	被標記者出院 7 天內電話追蹤並安排回診。
建監測	每季檢查 AUROC、校準度與各族群表現。
寫合約	揭露開發資料、驗證報告、更新程序與責任。

閾值是從人力倒推，不是從統計最佳點決定：這是臨床人員的專業價值。

擬真個案 Simulated Case

帶得走的工具：向 AI 廠商追問的十個問題

可直接用於採購評選與 W15 導入評估

1. 訓練資料來自哪些醫院、年份、病人？
2. 標籤（結果）怎麼定義？
3. 驗證停在哪一層？有外部驗證嗎？
4. AUROC 之外，有校準度嗎？
5. 各年齡、性別、族群表現一樣嗎？
6. 用了哪些特徵？有無洩漏疑慮？
7. 建議閾值與預估工作量？
8. 上線後誰監測？多久一次？
9. 模型更新的程序與通知方式？
10. 是否屬醫療器材？取得哪些許可？

回到開場：這十個問題，就是面對「AUROC 0.85」時應有的反應。

課堂討論 In-class Discussion

小組演練：你會買 ReAdmit-X 嗎

討論 15 分鐘；選 2 組各分享 3 分鐘

1 指標	廠商說「準確率 88%」「AUROC 0.85 屬優良」，為什麼都不足以決定採購?
2 盛行率	用盛行率頁的假設模型（敏感度、特異度各 80%），再入院率由 15% 降到 5%， PPV 怎麼變? 對個管師有何影響?
3 校準	AUROC 0.76 但高估一倍，能直接拿風險數字跟病人說明嗎?
4 閾值	個管師增加到 3 名，閾值往哪調? 代價是什麼?

每組繳一張表：建議（買／不買／有條件）、理由、閾值、監測與合約要求。

Summary

本週帶走的三個問題

用同一套方法，判讀下一個醫療 AI 模型

怎麼來	訓練資料代表誰？標籤怎麼定義？有沒有洩漏或捷徑？
準不準	在本院資料上，鑑別力與校準度各如何？盛行率是多少？
能不能用	閾值對應多少工作量？誰接手、做什麼、誰監測？

帶走一個問題：模型標記了王伯伯，誰會接到通知？他們會做什麼？

名詞小辭典 Glossary

本週名詞小辭典

延伸閱讀：相關名詞的白話意義與使用界線

名詞	白話解釋
資料洩漏 Data Leakage	特徵中混入了答案或預測當下拿不到的資訊
外部驗證 External Validation	在開發以外的機構或族群資料上測試
資料集偏移 Dataset Shift	上線後資料分布與訓練時不同，導致失準
陽性預測值 PPV	被判為陽性者中，真正陽性的比例；受盛行率影響
AUROC	區分有無結果的能力； 0.5 等同亂猜，沒有通用及格線
校準度 Calibration	預測機率與實際發生比例是否一致

英文名詞方便查找國際文獻；使用時注意定義。

下週預告 Next Week

下週：生成式 AI 與大型語言模型的臨床應用

W6 第二次課堂實作：門診對話 → SOAP 病歷

運作原理	大型語言模型如何運作：從基礎模型到臨床應用。
國際實證	環境式臨床記錄（Ambient AI Scribe）。
風險控管	檢索增強生成（RAG）與幻覺。
實作二	查核教師提供的固定 SOAP 草稿，再做一次受控比較。
課前準備	攜帶筆電；複習 W4 提示詞五要素；回想一次門診對話。

本週學會檢驗預測模型；下週學會檢驗生成內容。

核心參考資料

完整連結見講者備註；案例數據為教學合成資料

van Walraven （2010）	LACE 指數， CMAJ
Caruana； Zech	治療混淆與捷徑學習案例（2015； 2018）
Finlayson （2021）	The clinician and dataset shift in AI， NEJM
Van Calster （2019）	Calibration: the Achilles heel， BMC Medicine
Vickers （2006）	Decision curve analysis， Med Decis Making
FDA 等（2021）	Good Machine Learning Practice 十大原則

ReAdmit-X 與北城區域醫院為虛構；數據為固定種子合成資料，可重現。

CLOSING

模型不會自己說謊，但數字會被誤讀

看懂 AUROC、校準度與閾值，
就能在採購桌上替病人與同仁問出關鍵問題。