智慧醫療與科技發展　Smart Healthcare & Technology Development

05

醫療 AI 方法論與模型生命週期

Medical AI Methods & Model Lifecycle

第 5 週｜單元二：醫療 AI 技術與臨床應用
AI 名詞地圖 → 機器怎麼學 → 生命週期與 MLOps → 評估指標 → 擬真案例：再入院預測模型

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

本週地圖 This Week

本週五個部分

從「AI 是什麼」走到「這個 AI 能不能用在我們醫院」

01

AI 名詞地圖

AI Landscape

AI、機器學習、深度學習、基礎模型

02

機器怎麼學

How Machines Learn

特徵與標籤、資料切分、過度擬合、資料洩漏

03

生命週期

Lifecycle & MLOps

從問題定義到上線監測；驗證層級； GMLP

04

評估指標

Metrics

混淆矩陣、 AUROC、校準度、閾值與工作量

05

擬真案例

Simulated Case

判讀一個再入院預測模型，決定買不買

教學重點｜科技發展主軸： W2 看 AI 怎麼演進；本週拆開 AI 的「引擎蓋」，看它怎麼被造出來、怎麼被檢驗。

學習目標 Learning Objectives

本週結束時，你能夠……

每一項目標都對應課程三項核心能力；期中、期末個案分析即依此命題

1	說明 AI 、機器學習、深度學習、基礎模型的關係與三種學習方式	C1 趨勢洞察
2	辨識過度擬合、資料洩漏與捷徑學習等常見陷阱	C3 實證評估
3	計算並解讀敏感度、特異度、 PPV 、 NPV ，說明盛行率的影響	C3 實證評估
4	區分 AUROC 與校準度，並依人力與介入成本選擇閾值	C3 實證評估

對應評量｜期中 Q3 （本地驗證判讀， 25 分）

課程脈絡 Where we are

承上

W4 會用 AI 做工具

本週

拆開 AI 的引擎蓋：模型怎麼來、準不準

啟下

W6 生成式 AI：從「算」到「寫」

教學重點｜下課前要能回答開場的五個追問——這就是醫療 AI 採購桌上最需要的「識讀能力」。

開場 Opening

廠商說：「我們的再入院預測 AI，AUROC 0.85」

北城區域醫院（虛構）正在評估是否採購——你是評估小組成員，該追問什麼？

廠商簡報（ReAdmit-X，虛構產品）

「以 50 萬筆住院資料訓練」

「AUROC 高達 0.85」

「準確率 88%」

「可提早找出高風險病人，降低再入院」

評估小組該問的

- 50 萬筆是哪裡、哪些病人的資料？
- 0.85 是在誰的資料上算出來的？
  - 準確率 88%—— 再入院率是多少？
  - 預測 30% 風險，真的有 30% 會再住院嗎？
  - 要抓出多少人？護理人力負擔得起嗎？

教學重點｜本週結束時，你應該能逐一回答右邊五個問題——這就是醫療 AI 的「識讀能力」。

開場 Opening

為什麼醫院在意再入院?

再入院同時是品質指標、成本問題，也是最常見的醫療 AI 應用題目之一

80%

美國被罰款的醫院比例

CMS 再入院減少計畫（HRRP） FY2027： 2,334 家醫院被扣款，最高扣 3%

0.684

LACE 指數的 C 統計量

van Walraven 等（2010, CMAJ）：傳統規則式評分的代表

2 次

王伯伯過去一年住院

多重共病、獨居、多重用藥：典型高風險病人

問題：傳統評分（如 LACE）簡單透明，但鑑別力有限；機器學習號稱更準——但「更準」要在哪裡、用什麼指標、對誰而言？這正是本週要學的判讀方法。

資料來源： Healthcare Dive （2026） CMS HRRP FY2027 penalties； van Walraven C, et al. （2010） CMAJ 182(6):551–557 。

教學重點｜AUROC 0.684 vs 0.85—— 數字看起來差很多，但兩者是在不同資料上算的，不能直接比較。

01

PART 1

AI 名詞地圖 The AI Landscape

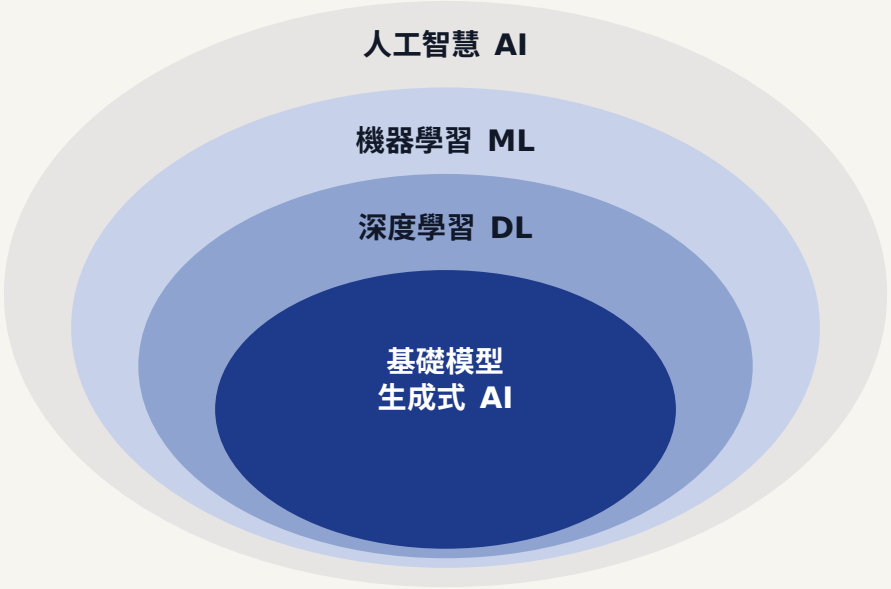
先把名詞的「包含關係」弄清楚

AI ⊃ 機器學習 ⊃ 深度學習；基礎模型與生成式 AI
規則式 vs 學習式；三種學習方式；任務類型

Part 1 | 包含關係

AI、機器學習、深度學習、基礎模型：一層包一層

最常見的誤會：以為 AI 都是 ChatGPT



層次	醫療例子
AI （含規則）	用藥交互作用警示
機器學習	再入院風險預測
深度學習	胸部 X 光判讀、心電圖分析
基礎模型	病歷摘要、衛教生成（W6）

教學重點｜本週主角是中間兩層：機器學習與深度學習——目前 FDA 核准的 AI 醫材絕大多數屬於這兩層。

兩種做法：人寫規則，或讓機器從資料學規則

以再入院風險為例

規則式：LACE 指數

- **L** 住院天數 Length of stay
- **A** 急性入院 Acuity
- **C** 共病指數 Comorbidity
- **E** 半年內急診次數 ED visits
- 各項給分相加，≥ 10 分為高風險
- ✓ 透明好懂　× 鑑別力有限

學習式：機器學習模型

- 輸入數十到數百個變項
- 從歷史資料自動找出權重與交互作用
- 輸出每位病人的再入院機率
- ✓ 通常較準　× 較難解釋、需要驗證
- × 換一家醫院可能就不準

資料來源：LACE 指數：van Walraven C, et al.（2010）CMAJ。總分 0–19 分。

教學重點｜不是「學習式一定比較好」：在資料少、需要透明的情境，簡單規則常常更實用。

Part 1 | 三種學習方式

機器學習的三種學習方式

差別在於：資料有沒有「標準答案」

學習方式	白話比喻	需要什麼資料	醫療例子
監督式 Supervised	有答案的考古題練習	特徵＋標籤（答案）	預測 30 天再入院；判讀 X 光有無肺炎
非監督式 Unsupervised	沒有答案，自己分組	只有特徵	把心衰竭病人分成不同亞型
強化式 Reinforcement	嘗試錯誤、獲得獎勵	環境＋獎勵規則	加護病房給藥策略研究（多在研究階段）

另有「自監督學習」：從大量未標註資料自己出題自己學——基礎模型的關鍵技術。

教學重點｜臨床上最常見的是監督式學習——所以「標籤」的品質，直接決定模型的上限。

Part 1 | 任務類型

模型在做什麼？四種常見任務

先看任務，才知道該用什麼指標評估

01

分類

Classification

會不會再入院？是不是肺炎？
→ AUROC 、敏感度

02

迴歸

Regression

住院幾天？血糖多少？
→ 誤差（ MAE ）

03

分群

Clustering

病人可分成幾種亞型？
→ 臨床可解釋性

04

生成

Generation

寫摘要、回答問題
→ 正確性、幻覺率（ W6 ）

教學重點 | 再入院預測是「分類」任務，但輸出的是機率——所以本週要同時看鑑別力與校準度。

Part 1 | 深度學習

深度學習：讓機器自己找出特徵

多層神經網路，特別擅長影像、聲音、波形與文字



強項

- 影像： X 光、眼底、病理切片
- 波形：心電圖、腦波
- 不必人工設計特徵

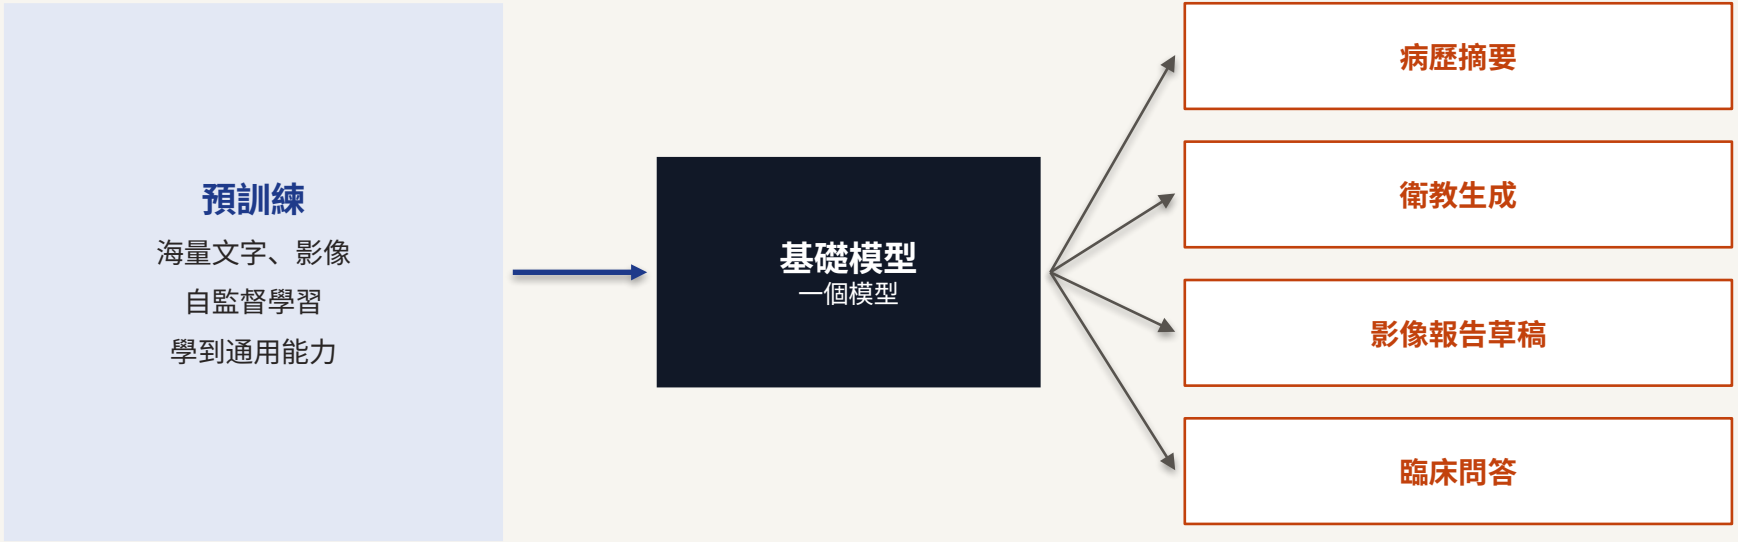
代價

- 需要大量標註資料
- 運算成本高
- 難以解釋「為什麼這樣判斷」

教學重點｜表格型資料（如再入院預測）用傳統機器學習常就足夠；影像與波形才是深度學習的主場。

基礎模型：先大量預訓練，再調整成各種任務

Foundation Model （Bommasani 等，2021）；醫療版稱為通用醫療 AI （Moor 等，2023）



教學重點｜從「一個任務一個模型」到「一個模型多種任務」——這是 2020 年代 AI 最大的典範轉移（W6 深入）。

02

PART 2

機器怎麼學 How Machines Learn

沒有魔法：從有答案的歷史資料中找規律

特徵與標籤：王伯伯的一筆出院紀錄
訓練、驗證、測試；過度擬合；資料洩漏與捷徑學習

Part 2 | 特徵與標籤

一筆出院紀錄，如何變成機器能學的資料

特徵（Features）是輸入；標籤（Label）是要預測的答案

病人	年齡	住院天數	半年急診次數	共病指數	心衰竭	→	30 天內再入院（標籤）
王伯伯	72	9	2	4	是	→	是
病人 B	58	3	0	1	否	→	否
病人 C	81	6	1	3	是	→	否
… 共 2,000 筆							

特徵 Features（來自 W3 的 FHIR 資源）

標籤 Label

教學重點｜標籤看似簡單，其實要定義清楚：「再入院」含不含計畫性住院？他院住院算不算？——定義不同，模型就不同。

Part 2 | 資料切分

訓練、驗證、測試：不能用考古題來出期末考

資料要分開使用，才能公平評估模型



訓練集 Training

讓模型學習規律

驗證集 Validation

調整參數、挑模型

測試集 Test

最後一次、只考一次

比喻

- 訓練＝做練習題；驗證＝模擬考；測試＝正式大考

常見錯誤

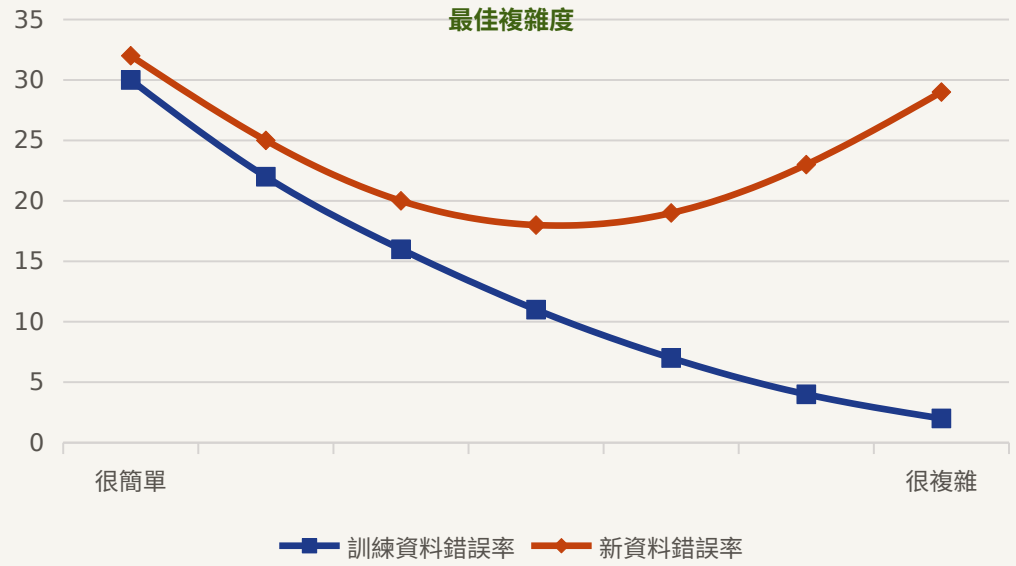
- 反覆看測試結果再改模型＝偷看考題

教學重點｜內部切分只能證明「在同一家醫院有效」——換到別家醫院，要靠外部驗證（Part 3）。

Part 2 | 過度擬合

過度擬合：把考古題背得滾瓜爛熟，遇到新題目就不會

模型越複雜，訓練表現越好，但新資料上的表現未必跟著變好



示意圖：曲線為概念說明，非特定研究數據。

怎麼避免

- 資料量要足夠
- 限制模型複雜度（正規化）
- 用驗證集挑模型
- 一定要在沒看過的資料上測試

教學重點｜看到「訓練準確率 99%」不要高興太早——要問：在沒看過的資料上是多少？

模型很準，但學錯了東西：兩個國際經典案例

Data leakage 與 Shortcut learning—— 看起來很準，其實不能用

氣喘病人肺炎死亡率「較低」？

- Caruana 等（2015）：模型學到「有氣喘→風險較低」
  - 真相：氣喘病人會直接送加護病房，照護更積極
  - 模型把「治療效果」誤當成「病人特性」
  - 若據此讓氣喘病人回家，後果嚴重

X 光模型認得的是「醫院」

- Zech 等（2018, PLOS Med）：肺炎模型跨院表現下降
  - 模型能辨識影像來自哪家醫院
  - 不同醫院的肺炎盛行率不同，成了捷徑
  - 換一家醫院，捷徑消失，表現就掉

教學重點｜再入院模型也會：若特徵含「出院時已安排居家護理」，可能洩漏醫療團隊對風險的判斷——要逐一檢視特徵來源。

03

PART 3

模型生命週期與 MLOps Lifecycle & MLOps

模型不是買來就結束，而是要「養」

七個階段：從問題定義到上線監測
驗證的層級；資料集偏移； GMLP 十大原則與 PCCP

醫療 AI 模型的生命週期：七個階段

每一階段都有臨床人員必須參與的決策



階段	臨床人員要回答的問題
問題定義	預測出來之後，誰要做什麼？沒有後續行動的預測沒有價值
資料與特徵	資料是否代表我們的病人？標籤怎麼定義？有沒有洩漏？
驗證	在我們醫院的資料上準不準？各族群是否一樣準？
部署與監測	放在哪個畫面、誰看？上線後表現有沒有下滑？

教學重點｜最常被跳過的是第一步：只問「能不能預測」，沒問「預測之後要做什麼」。

Part 3 | 驗證層級

驗證的五個層級：越往上，證據越強

從「自己考自己」到「真實臨床效益」

多數醫療 AI 研究停在前兩階—— W12 會用 TRIPOD+AI 、 DECIDE-AI 檢核



教學重點 | 廠商的 0.85 是哪一層？若只是內部驗證，對北城區域醫院而言，證據力相當有限。

Part 3 | 資料集偏移

上線後為什麼會變不準？資料集偏移

Finlayson 等（2021, NEJM）：臨床人員應認識的資料集偏移

偏移類型	發生了什麼	再入院模型的例子
病人組成改變	病人特性分布不同	從醫學中心移到區域醫院，病人更老、共病更多
盛行率改變	結果發生的比例不同	推出出院後追蹤計畫，再入院率下降
關係改變	特徵與結果的關係變了	新藥上市，心衰竭與再入院的關聯減弱
流程與編碼改變	資料產生方式改變	換 HIS 系統、ICD 編碼規則或檢驗儀器

教學重點｜COVID-19 期間許多預測模型同時失準——世界變了，模型不會自己知道。

Part 3 | MLOps

MLOps： 模型上線後的持續照顧

Machine Learning Operations—— 借用軟體工程的維運觀念

01

監測表現

Monitor

每月檢查 AUROC 、校準度、警示數量

02

偵測偏移

Detect Drift

比較輸入資料分布與訓練時是否不同

03

重新校準或訓練

Update

依預先定義的程序更新模型

04

版本與紀錄

Version & Audit

每個版本可追溯，出事可回溯

教學重點｜醫院要問廠商：誰負責監測？多久一次？變不準時誰決定更新？——這些要寫進採購合約。

Part 3 ｜國際原則

優良機器學習規範 GMLP：十大指導原則

美國 FDA、加拿大衛生部、英國 MHRA 於 2021 年共同發布

1. 跨領域專業參與整個產品生命週期
2. 良好的軟體工程與資安實務
3. 臨床資料能代表目標病人族群
4. 訓練資料與測試資料彼此獨立
5. 參考標準採用最佳可得方法
6. 模型設計符合資料與預期用途
7. 重視「人＋ AI」團隊的整體表現
8. 在臨床相關情境下測試效能
9. 提供使用者清楚、必要的資訊
10. 上線後持續監測並管理再訓練風險

資料來源：FDA, Health Canada, MHRA（2021）Good Machine Learning Practice for Medical Device Development: Guiding Principles.

教學重點｜第 3、4、10 條就是本週重點：資料代表性、測試獨立、上線監測——也連結 W2 的 PCCP 預定變更計畫。

04

PART 4

評估指標 Evaluation Metrics

同一個模型，換一個指標，結論可能完全不同

混淆矩陣：敏感度、特異度、 PPV 、 NPV ；盛行率的影響
AUROC （鑑別力）與校準度；閾值決定工作量

混淆矩陣：模型的四種結果

北城區域醫院 2,000 次出院（合成資料）；以預測風險 ≥ 20% 為「高風險」（採本院重新校準後的風險值，見 Part 5）

	實際：再入院	實際：未再入院
預測：高風險	**真陽性 TP** **190** 預測高風險，真的再入院	**偽陽性 FP** **372** 預測高風險，其實沒有
預測：低風險	**偽陰性 FN** **134** 預測低風險，卻再入院	**真陰性 TN** **1,304** 預測低風險，也沒有

成本不同

- FN：漏掉王伯伯，可能再住院
- FP：個管師白打電話
  - 兩種錯誤的代價不對等

教學重點｜實際再入院率 16.2%： 2,000 人中有 324 人再入院——後面所有指標都從這四格算出來。

Part 4 | 四個指標

敏感度、特異度、 PPV 、 NPV： 各回答一個問題

以同一張混淆矩陣（閾值 20%）計算

指標	回答的問題	計算	本例
敏感度 Sensitivity	真的會再入院的人，抓到幾成?	TP ÷ （TP + FN）	59%
特異度 Specificity	不會再入院的人，正確排除幾成?	TN ÷ （TN + FP）	78%
陽性預測值 PPV	被標為高風險的人，真的再入院幾成?	TP ÷ （TP + FP）	34%
陰性預測值 NPV	被標為低風險的人，真的沒事幾成?	TN ÷ （TN + FN）	91%

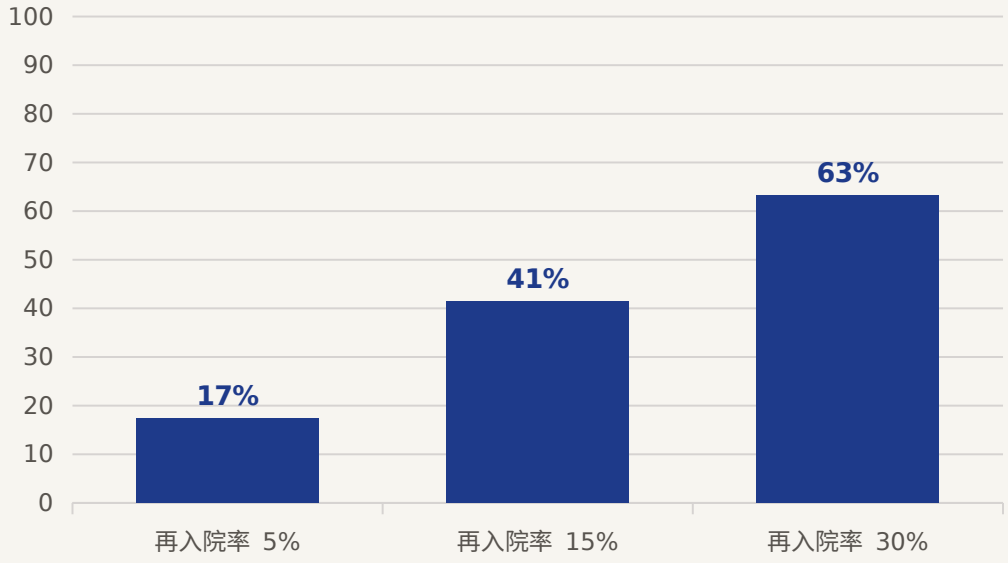
準確率陷阱： 若模型一律預測「不會再入院」，準確率就有 84%—— 卻一個高風險病人都沒抓到。

教學重點 | 臨床人員最該看 PPV： 它決定「被警示的人裡，有多少是真的需要處理」，也就是警示疲勞的程度。

Part 4 | 盛行率的影響

同一個模型，在不同醫院的 PPV 天差地遠

假設敏感度與特異度都是 80%，只改變再入院率（盛行率）



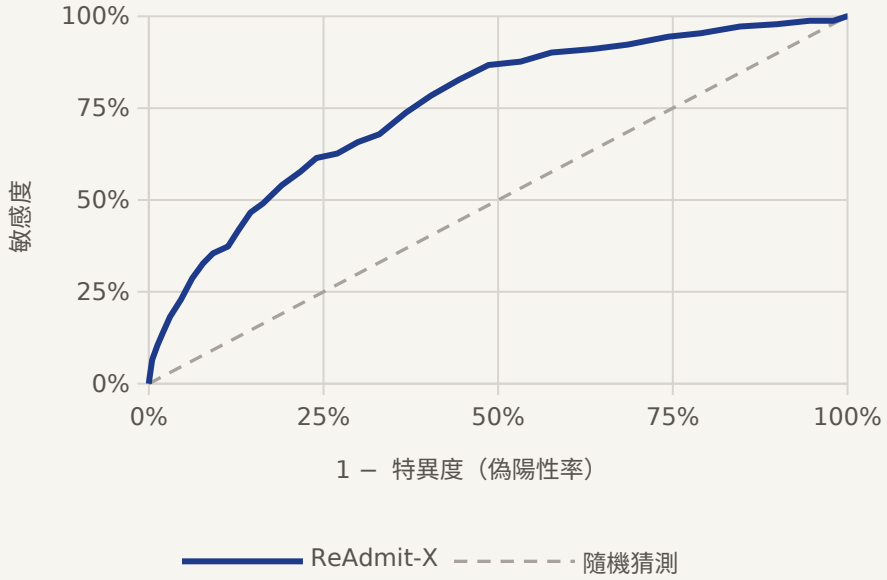
怎麼解讀

- 再入院率 5%：被警示者只有約 17% 真的再入院
- 再入院率 30%：上升到約 63%
- 低盛行率情境，警示多半是「虛驚」
- 廠商的數字要換算成「我們醫院」的盛行率

教學重點｜這就是為什麼「準確率 88%」毫無意義——沒有盛行率，就無法判斷臨床上會帶來多少負擔。

ROC 曲線與 AUROC：模型「分辨高低風險」的能力

ReAdmit-X 在北城區域醫院合成資料上的表現： AUROC = 0.76



白話解釋 AUROC

- 隨機抽一位再入院者與一位未再入院者，模型給前者較高分的機率約 76%

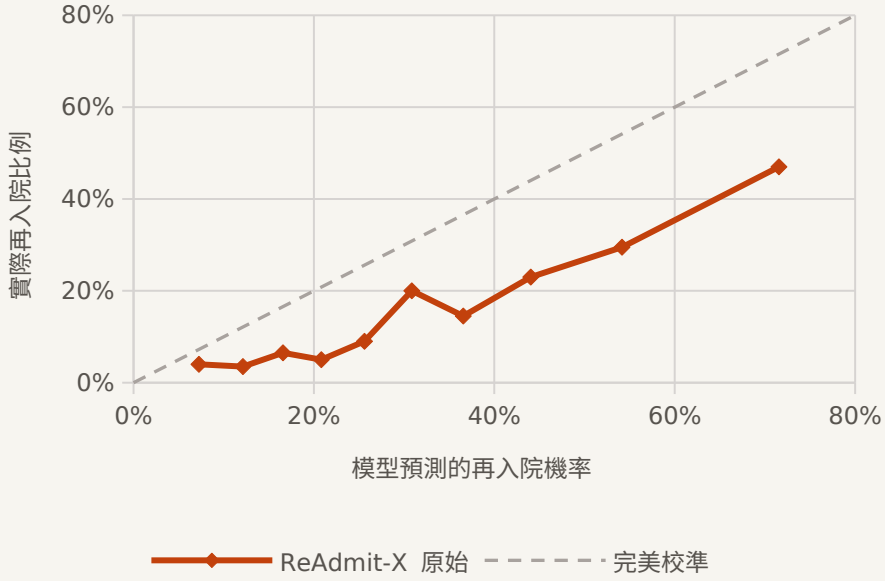
AUROC	常見解讀
0.5	等同亂猜
0.7–0.8	可接受
0.8–0.9	優良

資料來源：解讀區間參考 Hosmer & Lemeshow, Applied Logistic Regression；曲線依本課程合成資料計算。

教學重點｜AUROC 只看「排序對不對」，不看「機率準不準」—— 0.85 的模型，給出的風險數字仍可能完全失真。

校準度：模型說 30%，真的有 30% 會再入院嗎?

Van Calster 等（2019）稱校準度為「預測分析的阿基里斯腱」



怎麼讀這張圖

- 點在虛線上＝預測準確
- 點在虛線下＝高估風險
- 最高風險組：預測 72%，實際 47%
- 全院平均預測 32%，實際只有 16%

資料來源：依本課程合成資料，按預測值十分位分組計算。 Van Calster B, et al. （2019） BMC Medicine 17:230 。

教學重點 | ReAdmit-X 系統性高估約一倍：它可能在「再入院率較高的醫院」開發，搬到北城就失準。

Part 4 | 兩種能力

鑑別力與校準度：兩種不同的「準」

一個管排序，一個管機率；臨床決策兩個都需要

鑑別力 Discrimination

- 問題：能不能把高低風險分開?
- 指標： AUROC （C 統計量）
- 比喻：考試排名對不對
- 用途：決定「先照顧誰」

校準度 Calibration

- 問題：機率數字可不可信?
- 指標：校準圖、校準斜率與截距
- 比喻：分數本身準不準
- 用途：跟病人說明風險、估算資源需求

教學重點｜好消息：校準度可以用醫院自己的資料「重新校準」修正；鑑別力不足就難救了。

Part 4 ｜閾值與工作量

閾值怎麼選？其實是在選「工作量」

重新校準後的 ReAdmit-X，在 2,000 次出院中改變高風險閾值

高風險閾值	被標記人數	占出院比例	抓到的再入院者（敏感度）	標記者中真的再入院（PPV）
≥ 10%	1,171	59%	284 ／ 324 （88%）	24%
≥ 20%	562	28%	190 ／ 324 （59%）	34%
≥ 30%	277	14%	118 ／ 324 （36%）	43%

取捨：閾值 10% 幾乎抓到所有人，但要追蹤 1,171 人；閾值 30% 工作量小，卻漏掉 206 位再入院者。
決策依據：個管師人力能負擔多少人？介入措施的成本與效益？

教學重點｜閾值不是統計問題，而是臨床與管理決策——應由醫療團隊依人力與介入成本共同決定。

Part 4 | 進階

更進一步：決策曲線分析（Decision Curve Analysis）

Vickers 與 Elkin （2006）：模型「用了」比「不用」或「全部介入」更好嗎?

01

比較三種策略

Strategies

全部病人都介入、全部都不介入、依模型介入

02

淨效益

Net Benefit

把「抓到的好處」扣掉「誤報的代價」

03

看閾值區間

Threshold Range

在臨床合理的閾值範圍內，模型是否都勝出

教學重點 | AUROC 告訴你模型「好不好」，決策曲線告訴你模型「有沒有用」—— TRIPOD+AI 鼓勵報告臨床效用。

05

PART 5

擬真案例： ReAdmit-X 採購評估 Simulated Case

把本週所學，用在一個真實會發生的決策

廠商宣稱 vs 本院驗證；重新校準
評估小組的建議與追問清單

擬真個案 Simulated Case

案例設定：北城區域醫院評估 ReAdmit-X

虛構情境；資料為合成，供課堂判讀練習

背景

- 北城區域醫院， 450 床（ W3 已出現）
- EMRAM 約第 4 階，正在補資料整合
- 個管師 1 名專責，每月可額外追蹤約 25 人
- 目標：降低 30 天再入院

評估方式

- 取院內近一年 2,000 次出院（去識別化）
- 由資訊室以 ReAdmit-X 產生風險分數
- 與實際 30 天再入院結果比對
- 計算 AUROC 、校準度與不同閾值的工作量

教學重點｜這就是「本地外部驗證」：不靠廠商的數字，用自己醫院的資料驗證一次——成本不高，價值極大。

擬真個案 Simulated Case

驗證結果：廠商宣稱 vs 本院資料

同一個模型，換了醫院，數字就變了

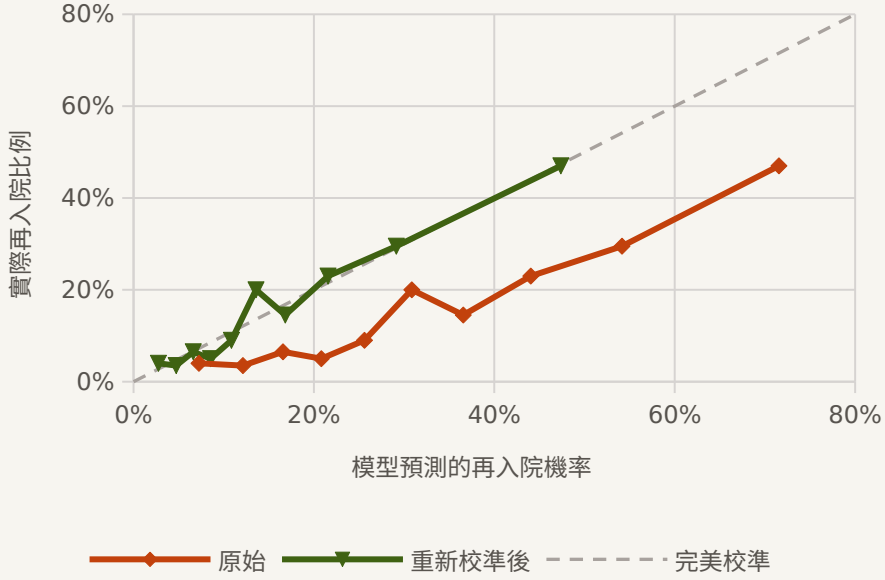
項目	廠商宣稱（開發醫院）	北城區域醫院（本院驗證）	判讀
AUROC	0.85	0.76	鑑別力下降，但仍在可接受範圍
再入院率	未揭露	16.2%	盛行率不同，PPV 會不同
平均預測風險	未揭露	32%	系統性高估約一倍
驗證層級	內部驗證	外部（本地）驗證	本院結果才是決策依據

教學重點｜AUROC 從 0.85 掉到 0.76 是很常見的外部驗證結果——重點是看清楚掉多少、為什麼掉、還能不能用。

擬真個案 Simulated Case

對策：用本院資料重新校準

鑑別力不變，但風險數字回到可信的範圍



重新校準做了什麼

- 保留模型的排序（AUROC 不變）
- 依本院資料調整截距與斜率
- 平均預測從 32% 回到 16%
- 要寫進合約：多久重新校準一次

資料來源：依本課程合成資料，以邏輯式重新校準（logistic recalibration）計算。

教學重點｜重新校準不是作弊，而是國際建議做法——但要在獨立資料上確認，並建立定期監測。

擬真個案 Simulated Case

評估小組的建議：有條件採用

把本週所有概念串成一份可執行的建議

1	**先試行**	選心衰竭等高風險科別試行 6 個月，不全院上線
2	**定閾值**	依個管師每月約 25 人（每年約 300 人）的量能，選閾值 30%（每年約 277 人，PPV 約 43%）
3	**配介入**	被標記者：出院 7 天內電話追蹤＋回診安排，否則預測沒有意義
4	**建監測**	每季檢查 AUROC、校準度與各族群表現；偏移時重新校準
5	**寫合約**	要求廠商揭露開發資料、驗證報告、更新程序與責任歸屬

教學重點｜注意第 2 點：閾值是從「人力」倒推，不是從「統計最佳點」決定——這就是臨床人員的專業價值。

擬真個案 Simulated Case

帶得走的工具：向 AI 廠商追問的十個問題

可直接用於採購評選與 W15 導入評估

1. 訓練資料來自哪些醫院、哪些年份、哪些病人？
2. 標籤（結果）怎麼定義？
3. 驗證停在哪一層？有外部驗證嗎？
4. AUROC 之外，有沒有校準度？
5. 各年齡、性別、族群的表現一樣嗎？
6. 使用了哪些特徵？有無資料洩漏疑慮？
7. 建議的閾值與預估工作量？
8. 上線後誰監測？多久一次？
9. 模型更新的程序與通知方式？
10. 是否屬醫療器材？取得哪些許可？

教學重點｜回到開場：這十個問題，就是你面對「AUROC 0.85」時應有的反應。

名詞小辭典 Glossary

本週名詞小辭典

中英對照，方便閱讀國際文獻

名詞	英文	白話解釋
特徵／標籤	Feature / Label	模型的輸入資料／要預測的答案
過度擬合	Overfitting	對訓練資料過度記憶，對新資料表現差
資料洩漏	Data Leakage	特徵中混入了「答案」或未來資訊
外部驗證	External Validation	在開發以外的機構或族群資料上測試
資料集偏移	Dataset Shift	上線後資料分布與訓練時不同，導致失準
陽性預測值	Positive Predictive Value, PPV	被判為陽性者中，真正陽性的比例
ROC 曲線下面積	AUROC / C-statistic	模型區分有無結果的能力， 0.5 為亂猜
校準度	Calibration	預測機率與實際發生比例是否一致

Summary

本週重點回顧

一頁掌握醫療 AI 方法論與模型生命週期

主題	一句話重點
名詞地圖	AI ⊃ 機器學習 ⊃ 深度學習 ⊃ 基礎模型；臨床最常見的是監督式學習
機器怎麼學	特徵＋標籤；訓練、驗證、測試分開；小心過度擬合與資料洩漏
生命週期	問題 → 資料 → 特徵 → 訓練 → 驗證 → 部署 → 監測； GMLP 十原則
驗證與偏移	內部 → 時間 → 外部 → 前瞻 → RCT ；上線後會因資料集偏移失準
指標	準確率會騙人；看敏感度、 PPV （受盛行率影響）
AUROC vs 校準	AUROC 管排序，校準管機率；校準可在本院重新調整
閾值	閾值決定工作量，應依人力與介入成本由團隊決定

教學重點｜帶走一個問題：如果這個模型標記了王伯伯，誰會接到通知？他們會做什麼？

課堂討論 In-class Discussion

課堂討論：你會買 ReAdmit-X 嗎?

分組 15 分鐘，以評估小組身分回答

- **Q1** **指標：**廠商說「準確率 88%」，為什麼這個數字幾乎沒有參考價值?
- **Q2** **盛行率：**若改到再入院率只有 5% 的醫院使用， PPV 會怎麼變？對個管師有何影響?
- **Q3** **校準：** AUROC 0.76 但高估一倍，可以直接拿風險數字跟病人說明嗎？要先做什麼?
- **Q4** **閾值：**若專責個管師增加到 3 名，你會調整閾值嗎？往哪個方向？代價是什麼?

教學重點｜沒有「標準答案」的採購決定，但有「標準的追問方式」——這正是本週要建立的能力。

下週預告 Next Week

W6 ★　生成式 AI 與大型語言模型的臨床應用

第二次課堂實作：門診對話 → SOAP 病歷

- 大型語言模型如何運作：從基礎模型到臨床應用
- 環境式臨床記錄（Ambient AI Scribe）的國際實證
- 檢索增強生成（RAG）與幻覺風險控管
- 實作二：做一個「門診對話 → SOAP 病歷」原型並查核錯誤

課前準備

- 攜帶筆電
- 複習 W4 的 Vibe Coding 提示詞五要素
- 回想一次門診看診的對話流程

教學重點｜本週學會「檢驗預測模型」；下週要學會「檢驗生成內容」——兩者都是醫療 AI 的核心素養。

參考資料 References

主要參考資料

數據以原始出處最新版為準（查證日期： 2026 年 10 月）

van Walraven C, et al. (2010). Derivation and validation of an index to predict early death or unplanned readmission (LACE). CMAJ, 182(6), 551–557.

Caruana R, et al. (2015). Intelligible models for healthcare: predicting pneumonia risk and hospital 30-day readmission. KDD '15.

Zech JR, et al. (2018). Variable generalization performance of a deep learning model to detect pneumonia. PLOS Medicine, 15(11), e1002683.

Finlayson SG, et al. (2021). The clinician and dataset shift in artificial intelligence. NEJM, 385(3), 283–286.

Van Calster B, et al. (2019). Calibration: the Achilles heel of predictive analytics. BMC Medicine, 17, 230.

Vickers AJ, Elkin EB. (2006). Decision curve analysis. Medical Decision Making, 26(6), 565–574.

FDA, Health Canada, MHRA. (2021). Good Machine Learning Practice for Medical Device Development: Guiding Principles.

Bommasani R, et al. (2021). On the opportunities and risks of foundation models. arXiv:2108.07258； Moor M, et al. (2023). Nature, 616, 259–265.

Hosmer DW, Lemeshow S, Sturdivant RX. (2013). Applied Logistic Regression (3rd ed.). Wiley.

Healthcare Dive （2026） . CMS HRRP penalties FY2027.

本週案例 ReAdmit-X、北城區域醫院及所有數據為教學用合成資料（固定亂數種子，可重現）。

CLOSING

模型不會自己說謊，但數字會被誤讀

看懂 AUROC、校準度與閾值，你就能在 AI 採購桌上，替病人與同仁問出關鍵問題。