智慧醫療與科技發展　Smart Healthcare & Technology Development

06

生成式 AI 與大型語言模型的臨床應用

Generative AI & Large Language Models in Clinical Care

第 6 週 ★ 課堂實作週
讓 AI 執筆，讓人負責：會用，更要會查核

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

開場 Opening

王伯伯回診的 15 分鐘：醫師的眼睛常停在螢幕上

生成式 AI 最先改變的，不是診斷，而是「寫字」這件事

6–10 份

住院醫師每天病程紀錄

0.5–2 小時

一份完整入院紀錄

40–50%

北榮預估減少撰寫時間

如果 AI 能代筆：醫師看著病人，AI 產生草稿，醫師審閱簽名

但 AI 若聽錯或多寫，誰發現？誰負責？

本週要回答： AI 代筆能省多少？會錯在哪？怎麼設計才能放心用？

學習目標 Learning Objectives

本週結束時，你能做到什麼

四個可檢核的學習目標

C1	說明 LLM 文字接龍原理，以及 Token 、上下文視窗、溫度的影響。
C3	依實證判斷 AI 代筆與訊息回覆的效益與限制。
C2	比較提示工程、 RAG 、微調的適用情境。
C2 · C3	依原文逐句查核固定草稿，並做一次受控比較。

課堂產物：固定草稿查核表、受控比較紀錄、溯源呈現與 AI 使用紀錄。

本週地圖 This Week

本週的五個問題

前半段建立判斷力，後半段動手做出可以被查核的原型

LLM 原理	它怎麼寫出文字？為什麼會寫錯？
應用與實證	醫院用在哪？真的省時間嗎？
RAG	怎麼讓 AI 依院內文件回答，並附出處？
幻覺與風控	會錯在哪？要設幾道防線？
實作二	查核固定草稿，再做受控比較：判斷 AI 寫得對不對。

講授約 20 分鐘（Part 1–4 重點頁）→ 課內驗證練習約 80 分鐘（Part 5）。

01

PART 1

LLM 怎麼運作 How Large Language Models Work

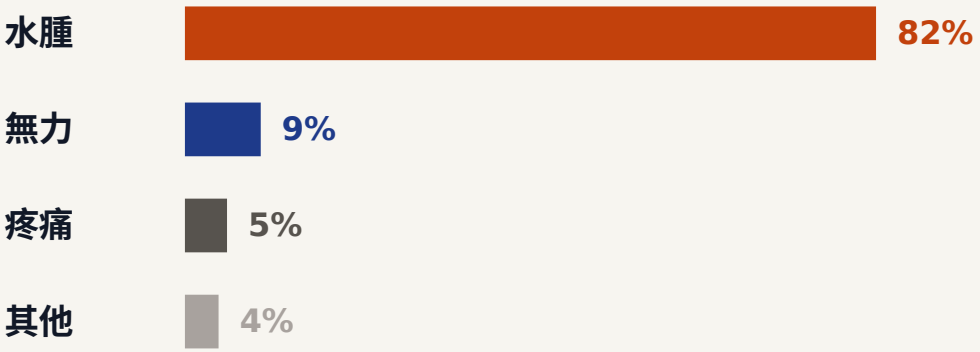
不懂原理，就看不懂它為什麼會犯錯

文字接龍、三個旋鈕、生成式與預測式、提示工程

LLM 的本質：超大型文字接龍

依前文預測最可能的下一個 Token，再接著往下寫

王伯伯近三天體重增加兩公斤，伴隨下肢 ____



機率為教學示意

不是查資料庫

依語言規律生成最順的句子

所以很會寫

文法流暢、語氣專業

也所以會錯

聽起來合理，不等於事實正確

LLM 優化的是「像真的」，不是「是真的」：查核永遠不能省。

Token 、上下文視窗、溫度：影響輸出的三個旋鈕

用一位實習醫師來比喻

概念	白話意思	臨床使用的提醒
Token	模型處理文字的單位；計費與長度都以它計	中文換算依模型而異；長病歷注意截斷
上下文視窗	一次能讀進的內容量，像能翻閱的病歷頁數	內容太長會漏讀；重要資訊放前面或分段
溫度	回答的隨機程度	病歷用低溫求一致；衛教標語可稍高

臨床文書：低溫度、明確格式、只依提供的內容作答。

生成式 AI 與預測式 AI：一個寫、一個算

延伸閱讀： W5 的再入院模型是預測式；本週的 SOAP 生成是生成式

比較	預測式 AI （W5）	生成式 AI （W6）
輸出	一個分數或類別	一段新內容（文字、圖、程式）
評估	AUROC、校準度等固定指標	正確性、完整性、安全性；常需人工評閱
典型錯誤	預測不準、族群偏誤	幻覺、遺漏、歸屬錯誤
監管	多以醫療器材軟體審查	文書用途多不屬醫材；臨床建議可能屬醫材
導入重點	模型驗證與監測	使用規範、人工審閱、稽核紀錄

同一家醫院可能同時用兩種 AI，驗證、法規與治理方式都不同。

好提示的五要素

實作二的基本功；依據與限制最關鍵

角色	「你是心臟內科門診的病歷文書助理」
任務	「把以下門診對話整理成 SOAP 病歷草稿」
依據	「只能使用對話中出現的資訊，每句標註行號」
格式	「分 S、O、A、P 四段」
限制	「沒提到的寫『未提及』，不可推測或補寫」

依據與限制兩項，直接決定幻覺的多寡。

Part 1 | 提示對照

同一個需求，兩種寫法

差別不在字數，而在有沒有把醫療規則寫進去

面向	模糊提示：「幫我把這段對話寫成病歷」	結構化提示（五要素）
格式	每次不同，難以比較	固定四段，輸出穩定
多寫風險	可能自行補上「理學檢查正常」	沒提到的寫「未提及」
說話者	家屬的話可能記成病人自述	家屬說的標「家屬代述」
可追溯	無法知道每句來源	每句有行號，醫師可逐句核對

實作二會用同一段對話比較兩種提示，親眼看到「多一行限制」的差別。

02

PART 2

臨床應用與實證 Applications & Evidence

從代筆、回訊息，到編碼與知識查詢

WHO 五大用途、六類應用、環境式記錄、實證研究、台灣導入

WHO 歸納大型多模態模型的五大醫療用途

延伸閱讀： WHO 2024 年 1 月指引，提出 40 多項建議

用途	例子	風險
診斷與臨床照護	回答病人書面提問	高
病人自主使用	查詢症狀與治療資訊	高
行政文書	記錄與摘要就診內容	相對低（本週重點）
醫護教育訓練	模擬病人對話練習	中
研究與藥物開發	找出候選化合物	依用途而定

越靠近診斷與病人自主使用，風險越高、驗證要求越嚴格。

Part 2 | 應用地圖

生成式 AI 在醫院的六類應用

延伸閱讀：依使用者與直接影響病人的程度排列

應用	使用者	例子	風險
環境式臨床記錄	醫師、護理師	門診對話生成 SOAP 草稿	中：須審閱
病歷摘要	醫師	入院、出院、轉診摘要	中：可能遺漏病史
病人訊息回覆	醫護 → 病人	入口網站留言回覆草稿	中高：直達病人
衛教內容生成	衛教師 → 病人	依病人程度改寫衛教單	中：須專業審定
疾病分類編碼	病歷管理師	由病歷預測 ICD-10 代碼	低中：影響申報
院內知識查詢	全院同仁	以 RAG 查 SOP、藥品仿單	低中：須附出處

多數醫院從低中風險、內部使用開始，累積信任後才擴大到直接面對病人。

Ambient AI Scribe 怎麼運作

醫師專心看診， AI 在背景聽並產生病歷草稿



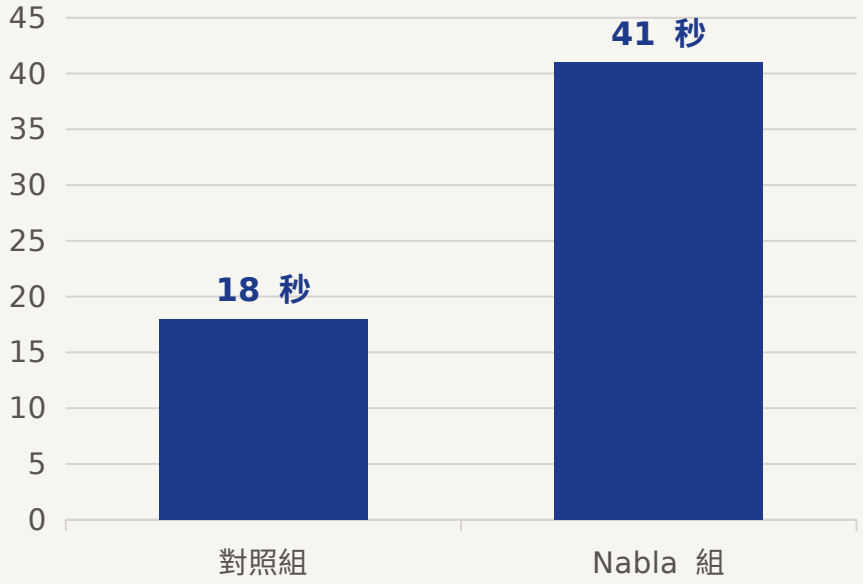
同意	告知病人並取得同意；說明錄音保存與刪除方式。
轉錄	台語、口音、多人對話都會影響正確率。
審閱	醫師是最後一道防線，也是法律上的負責人。
記錄	保留 AI 版本與修改紀錄，供稽核。

風險集中在轉錄與審閱：轉錄錯了後面全錯；沒看就簽，錯誤就成了正式病歷。

Part 2 | 實證

隨機對照試驗： AI 代筆省多少時間

UCLA Health： 238 位醫師、 14 個專科、約 72,000 次門診（NEJM AI, 2025）



省時 Nabla 相對對照組約 9.5%； DAX 未達統計顯著

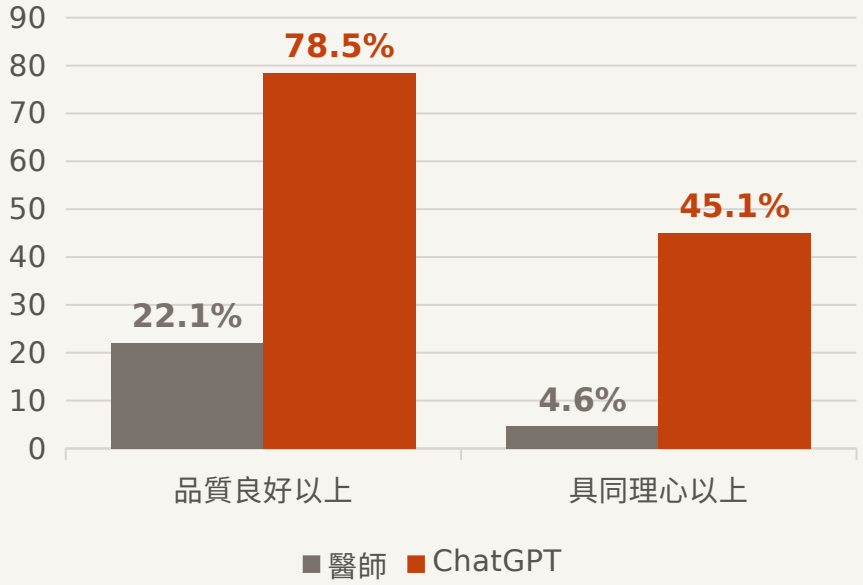
倦怠 兩個 AI 組約改善 7%

錯誤 偶有臨床上重要的不正確； 1 件輕微病安事件

比宣傳低調：省時有，但不大；倦怠改善溫和。

AI 回覆病人提問：更有同理心，卻不一定省時

延伸閱讀：兩個常被引用的研究，結論要放在一起看



Ayers 等 2023

195 則網路論壇提問；比較對象是醫師在論壇的簡短回覆。

Garcia 等 2024

162 位臨床人員使用回覆草稿：倦怠與負荷下降，但未節省時間。

寫得更暖不代表更對；審閱草稿也要時間，效益要在真實流程量測。

Part 2 | 台灣

台灣醫院的生成式 AI 導入

延伸閱讀：共同點：模型部署在院內、醫師最後審閱、從文書開始

醫院	應用	做法	公開資訊
臺大醫院	ICD-10 編碼預測	開源 LLM 以院內資料微調	全碼 86.67%、主診斷 82%（實測）
臺北榮總	智慧病歷助手	地端模型產生入院、病程、出院摘要草稿	2025-10 導入四大科；預估減 40–50%
高雄醫學大學	KMU Genie 平台	開源模型微調＋ RAG	護理紀錄撰寫時間縮短（院方說明）

分清數字性質：準確率是實測，預估減少時間是期待。

Part 2 | 實證整理

宣傳與實證：成效常和「省一半時間」不同

依本週引用資料整理

來源	常見期待	實際觀察	啟示
UCLA 隨機試驗	大幅節省時間	省時有限、倦怠溫和改善	用自己的流程驗證
Stanford 試辦	加快回覆	未省時，但減輕負擔	先定義成效指標
台灣醫院	減少文書時間	多為預估或院方說明	需要更多實測與公開數據

導入前先問：證據從哪來？成功的定義是什麼？

03

PART 3

RAG 檢索增強生成 Retrieval-Augmented Generation

讓 AI 從憑記憶作答，變成翻書作答

閉卷與開書、 RAG 步驟、提示、 RAG 與微調的比較

Part 3 | 白話比喻

RAG： 把閉卷考試改成開書考試

LLM 的知識有截止日，也不認識你們醫院的 SOP

面向	閉卷：一般 LLM	開書： RAG
知識來源	訓練時背下來的知識	先到指定文件庫找資料
院內新規範	不知道最新版照護流程	依找到的段落作答
不會時	傾向編一個像樣的答案	可要求找不到時回答「文件中沒有」
出處	沒有，無法查核	附上文件與頁碼

RAG 不保證零錯誤，但讓錯誤可以被追查。

RAG 的步驟

以護理師詢問「心衰竭出院衛教要包含哪些項目？」為例

1 提問	護理師輸入問題。
2 檢索	在院內文件庫找出最相關的 3 至 5 段。
3 組合	把段落與問題交給 LLM，只能依這些段落作答。
4 生成	回答並標註「出自《心衰竭照護指引》第 4 頁」。
5 維護	指引改版就更新文件庫，不必重新訓練模型。

RAG 的品質很大程度取決於文件庫：過期、矛盾的文件會被自信地引用。

Part 3 ｜方法比較

提示、 RAG 、微調：讓 AI 更懂醫院的三種方法

延伸閱讀：實務順序：先提示 → 再 RAG → 必要時才微調

方法	比喻	適合	成本	例子
提示工程	給實習醫師工作說明	格式、語氣、規則	最低	本週實作二
RAG	讓實習醫師帶院內手冊	院內知識、常改版內容	中	高醫 KMU Genie
微調	讓實習醫師接受專科訓練	特定任務、特定用語	高	臺大 ICD 編碼

問題出在不知道，用 RAG ； 出在不會做，才考慮微調。

04

PART 4

幻覺與風險控管 Hallucination & Safety

AI 會錯，而且錯得很有自信

五種錯誤、幻覺率實測、 Whisper 事件、五道防線、隱私

Part 4 | 錯誤類型

AI 生成病歷的五種常見錯誤

以王伯伯的門診為例；實作二要找的就是這些

錯誤類型	定義	王伯伯的例子
捏造	寫出對話中沒有的內容	沒做聽診，卻寫「兩側肺部有囉音」
遺漏	漏掉重要資訊	漏寫「睡覺要墊兩個枕頭」
歸屬錯誤	把甲說的記成乙說的	女兒說「他偷吃鹹的」，記成病人自述
否定錯誤	把「沒有」寫成「有」	「沒有胸痛」寫成「主訴胸痛」
過度推論	把討論中的選項寫成決定	「考慮調藥」寫成「已調高利尿劑」

五種錯誤都讀起來很通順：只看文筆抓不到，必須逐句回到原始對話。

臨床摘要的幻覺有多常見

Asgari 等（2025）：臨床醫師逐句標註約 1.3 萬句摘要與近 5 萬句逐字稿

1.47%

幻覺率（191 / 12,999 句）

3.45%

遺漏率（1,712 / 49,590 句）

44%

幻覺屬重大（84 / 191）

重大幻覺最多出現在計畫（P），約 21%

一份摘要約 20–30 句：平均每 2–4 份就可能有一句幻覺。

審閱時把最多注意力放在 P：藥物、劑量、檢查與回診安排。

Part 4 ｜事故案例

Whisper 語音轉錄： AI 會聽到沒人說過的話

美聯社 2024 年 10 月調查報導

約 8 / 10

一位研究者檢視的轉錄出現幻覺

187 處

逾 13,000 段清晰音檔中的幻覺

近 40%

幻覺被評為有害或令人擔憂

例：捏造不存在的藥物「hyperactivated antibiotics」

部分醫療產品刪除原始錄音，錯誤無法回頭比對。

原始資料是查核的依據：為了資料安全刪除錄音，錯誤就永遠無法被發現。

五道防線：讓生成式 AI 可以安全上線

瑞士起司模型：每一層都有洞，疊起來才擋得住

① 提示限制

只依原始資料；未提及寫「未提及」

② 依據與出處

RAG 或逐句標註行號

③ 結構化輸出

固定欄位，方便比對

④ 自動檢核

程式檢查數字、藥名、否定詞

⑤ 人工審閱

醫師逐句確認，簽名負責

＋ **稽核紀錄：**保留原始錄音或逐字稿、 AI 版本、醫師修改處，出事時才查得到哪一層失守。

第 ⑤ 道最貴也最容易鬆懈： AI 越準，人越容易沒看就簽（自動化偏誤）。

病人資料能不能丟進 ChatGPT

取決於部署方式、合約與是否去識別化

部署方式	資料去向	適合情境	注意事項
免費公用版	送到廠商雲端，可能用於訓練	不得輸入任何病人資料	最常見的違規來源
企業版／醫療雲	依合約不用於訓練	去識別化資料、行政文書	審查合約與資料駐留
院內地端部署	不離開醫院網路	含個資的病歷生成	需算力與維運人力

底線：未經機構核准，不把可識別的病人資料貼進任何公用 AI 工具。

05

PART 5

★ 實作二：門診對話 → SOAP 病歷 Hands-on Lab 2

80 分鐘：先查核固定草稿，再做受控比較

擬真對話、固定草稿、查核表、提示範本、受控比較、溯源呈現、 AI 使用紀錄

實作二： 80 分鐘的課內驗證練習

產出：固定材料查核表、受控比較紀錄、溯源呈現、 AI 使用紀錄



A 固定查核	全班查核同一份教師預製草稿：逐句判定，找出遺漏。
B 受控比較	同一段對話、同一工具，只換提示，兩份輸出都保留。
溯源呈現	網頁原型或標註文件擇一，能把每句對回行號。
討論	小組比對判定；有依據的異議可以提出。

評分看判定對不對、有沒有依據；沒找到錯誤不扣分，把正確句判成錯誤會扣分。

實作二｜擬真資料（合成）

擬真門診對話：王伯伯心臟內科回診

教學虛構；醫＝醫師、王＝王伯伯、女＝女兒

01 醫：王伯伯，這兩週還好嗎？

02 王：還可以啦，就是晚上比較喘。

03 女：醫師，他這三天體重多了快兩公斤，腳也比較腫。

04 醫：晚上睡覺要墊幾個枕頭？

05 王：兩個，不然躺平會喘。

06 醫：有胸痛嗎？

07 王：沒有，胸口不會痛。

08 女：他上禮拜喝喜酒，還偷吃很多鹹的。

09 醫：Furosemide 有每天吃嗎？

10 王：有啦……有時候忘記。

11 醫：血壓 148/92，體重 74.5 公斤。

12 醫：我先抽血看腎功能和 NT-proBNP，

13 醫：利尿劑可能要調整，看報告再決定。

14 醫：兩週後回診，三天內體重多兩公斤就要先回來。

這段對話刻意埋了幾個陷阱：先別看答案，看看 AI 會不會掉進去。

SOAP 病歷四段：每段該放什麼

Weed （1968）提出的問題導向病歷格式

段落	放什麼	這次要特別注意
S 主觀	病人與家屬的陳述	誰說的？家屬代述要標明
O 客觀	量測與檢查結果	沒做的檢查不能寫
A 評估	醫師的判斷	醫師有說嗎？沒說就寫「未提及」
P 計畫	檢查、治療、追蹤	「考慮」與「已執行」要分清

最容易出錯的是 A： AI 常自己幫醫師下診斷，但對話中醫師其實沒說。

固定材料：教師預先產生的 SOAP 草稿

全班查核同一份草稿；有對有錯，也可能漏寫

#	段	AI 草稿句子
1	S	病人自述夜間較喘［02］
2	S	病人自述三天內體重增加近 2 公斤、下肢較腫［03］
3	S	需墊兩個枕頭，躺平會喘［05］
4	S	主訴胸痛［06–07］
5	S	家屬代述上週喝喜酒後吃得較鹹［08］
6	S	規則服用 Furosemide ［10］
7	O	血壓 148/92 mmHg、體重 74.5 kg ［11］

#	段	AI 草稿句子
8	O	心跳每分鐘 88 次［11］
9	O	雙下肢凹陷性水腫 2+
10	O	肺部聽診：未提及
11	A	急性心衰竭惡化
12	P	抽血：腎功能、NT-proBNP ［12］
13	P	已調高 Furosemide 劑量［13］
14	P	一週後回診［14］

逐句回到原始對話判定；也要檢查原文有、草稿沒寫的重要資訊。

步驟一：逐句判定固定草稿

14 句都要判定；判錯正確句子會扣分

#	判定	依據行號	錯誤類型	改正為	嚴重度
1	正確／錯誤／無法確認		捏造／歸屬／否定／過度推論		重大／輕微
2					
…					
遺漏	原文有、草稿沒寫：		遺漏		

嚴重度：照著錯誤內容執行，是否可能改變診斷、用藥或回診安排？是＝重大。數字、時間與原文不符歸為捏造。

評分看判定是否正確、依據是否清楚，不看找到幾個錯誤。

步驟二：用這份提示產生 SOAP

可直接複製；四條規則是防幻覺的關鍵，請勿刪除

```
你是心臟內科門診的病歷文書助理。
任務：把下方門診對話整理成 SOAP 病歷草稿（繁體中文）。
規則：
1. 只能使用對話中出現的資訊，每句後面用［行號］標註來源，例如［03］。
2. 對話中沒有的內容一律寫「未提及」，不可推測、不可補寫正常值。
3. 區分說話者：家屬說的要寫「家屬代述」。
4. 醫師「考慮中」的計畫要寫「待決定」，不可寫成已執行。
輸出：S、O、A、P 四段，最後列出「需醫師確認的項目」。
對話：〈貼上 01–14 行〉
```

對照組：同一段對話只輸入「幫我寫成病歷」；兩份原始輸出全文都保留。

受控比較：一次只改一件事

比較的是提示的差別，不是哪個模型比較強

固定	同一段對話 01–14 、同一工具、同一天執行。
只改	提示：模糊提示 vs 範本提示。
記錄	兩份原始輸出全文、提示全文、執行日期與工具名稱。
比較	用同一張查核表，看否定、說話者、未提及、待決定各處理得如何。
限制	一次比較只代表本次小樣本觀察，不代表模型已通過驗證。

多跑幾次就全部保留，不挑最好的一次代表整體；沒有工具時用教師提供的成對輸出。

步驟三：讓每句都對得回原文（擇一）

網頁原型或標註文件都可以；網頁只是展示，不是串接臨床系統

```
請幫我做一個單一 HTML 檔的網頁：
1. 左邊是大文字框，可貼上有行號的門診對話。
2. 按「顯示 SOAP」後，右邊顯示 S、O、A、P
   四個區塊（用我提供的範例結果即可）。
3. 每句後面的［行號］可點擊，
   點了就把左邊對應那一行標成黃色。
4. 沒有［行號］的句子用紅底標示。
5. 繁體中文、大字體。
```

點行號	快速溯源
紅底	可能的幻覺
替代	標註文件：句子旁寫行號
延伸	串接 API 自動生成，不計分

網頁用預先產生的結果，屬展示原型；做不出網頁，用標註文件呈現同樣算分。

AI 使用紀錄：讓別人能重做一次

延續 W1 課程規範；工具、輸入、輸出與人工修訂都要留下

項目	要寫什麼	範例
工具與模型	工具名稱；介面有顯示才寫模型名稱	Claude （介面顯示的模型名稱）
日期與提示	執行日期、兩份提示全文	附件一：模糊提示；附件二：範本
輸入與輸出	輸入的對話、每次原始輸出全文	附件三、四：兩份原始輸出
人工修訂	改了什麼、依據哪一行	第 13 句依［13］改為「待決定」
未提供的設定	照實寫「介面未提供」	溫度：介面未提供

不知道的設定照實寫「介面未提供」；自行編造版本或參數，比沒寫更糟。

實作二評分規準

占學期成績 10%；重點在判斷力，不在程式技巧或工具

構面	比重	優秀表現
查核正確與理由	40%	固定草稿判定正確、引用行號；找出遺漏；類型與嚴重度合理
受控比較設計	20%	同輸入、只換提示；能說明差異來自哪一條規則
比較證據與紀錄	20%	兩份原始輸出、提示、日期、工具齊全；不挑最好的一次
溯源呈現	10%	網頁或標註文件能逐句對回行號；標明展示原型
個人說明	10%	能口頭解釋自己的一個判定或比較結果

沒找到錯誤不扣分，判錯正確句子會扣分；不看網頁美觀，也不看是否用付費工具。

Summary

本週帶走的三個問題

用同一套方法，評估下一個生成式 AI 工具

依據在哪	AI 寫的每一句，能回到原始資料或文件嗎?
錯在哪裡	捏造、遺漏、歸屬、否定、過度推論，最常在 P？
誰來把關	五道防線設了哪幾道？審閱的人會不會沒看就簽?

帶走一個問題：你的醫院明天導入 AI 代筆，你會先設哪一道防線?

名詞小辭典 Glossary

本週名詞小辭典

延伸閱讀：相關名詞的白話意義與使用界線

名詞	白話解釋
大型語言模型 LLM	以大量文字訓練、能生成文字的 AI 模型
上下文視窗	模型一次能處理的內容長度上限
環境式臨床記錄	在背景聆聽看診對話並產生病歷草稿
檢索增強生成 RAG	先檢索指定文件，再依文件內容生成回答
幻覺 Hallucination	生成看似合理、實際錯誤或無根據的內容
自動化偏誤	過度信任自動化系統而疏於查核

英文名詞方便查找國際文獻；使用時注意定義。

下週預告 Next Week

下週： AI Agent 與臨床流程自動化

從「幫你寫」到「幫你做」

三種形態	聊天機器人、副駕駛、代理人：差在哪?
架構	Agent 的元件；單一 Agent 與多代理人。
人機協作	哪些事 AI 可以自己做、哪些一定要人核准?
擬真案例	王伯伯出院準備的多代理人流程。
課前準備	想一個單位裡最繁瑣、最常出錯的跨部門流程。

下週沒有實作，但會用你帶來的流程做分組演練。

參考資料 References

核心參考資料

完整連結見講者備註

WHO （2024）	Guidance on large multi-modal models
Asgari 等（2025）	臨床摘要的安全與幻覺率框架， npj Digit Med
UCLA （2025）	AI scribes 隨機對照試驗， NEJM AI
Ayers； Garcia	病人訊息回覆研究（2023； 2024）
Lewis 等（2020）	Retrieval-augmented generation， NeurIPS
台灣案例	iThome 臺大（2024）、北榮（2025）； CIO Taiwan 高醫（2026）

數字要分清實測、預估與院方說明。

CLOSING

讓 AI 執筆，讓人負責

生成式 AI 把醫師從鍵盤前解放出來；
能找出錯誤的人，才是醫療 AI 時代真正稀缺的專業。