智慧醫療與科技發展　Smart Healthcare & Technology Development

06

# 生成式 AI 與大型語言模型的臨床應用

## Generative AI & Large Language Models in Clinical Care

第 6 週 ★ 課堂實作週
讓 AI 執筆，讓人負責：會用，更要會查核

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

開場 Opening

# 王伯伯回診的 15 分鐘：醫師的眼睛常停在螢幕上

生成式 AI 最先改變的，不是診斷，而是「寫字」這件事

**6–10 份**

住院醫師每天病程紀錄

**0.5–2 小時**

一份完整入院紀錄

**40–50%**

北榮預估減少撰寫時間

## 如果 AI 能代筆：醫師看著病人，AI 產生草稿，醫師審閱簽名

但 AI 若聽錯或多寫，誰發現？誰負責？

本週要回答： AI 代筆能省多少？會錯在哪？怎麼設計才能放心用？

學習目標 Learning Objectives

# 本週結束時，你能做到什麼

四個可檢核的學習目標

| | |
|---|---|
| **C1** | 說明 LLM 文字接龍原理，以及 Token 、上下文視窗、溫度的影響。 |
| **C3** | 依實證判斷 AI 代筆與訊息回覆的效益與限制。 |
| **C2** | 比較提示工程、 RAG 、微調的適用情境。 |
| **C2 · C3** | 依原文逐句查核固定草稿，並做一次受控比較。 |

課堂產物：固定草稿查核表、受控比較紀錄、溯源呈現與 AI 使用紀錄。

本週地圖 This Week

# 本週的五個問題

前半段建立判斷力，後半段動手做出可以被查核的原型

| | |
|---|---|
| **LLM 原理** | 它怎麼寫出文字？為什麼會寫錯？ |
| **應用與實證** | 醫院用在哪？真的省時間嗎？ |
| **RAG** | 怎麼讓 AI 依院內文件回答，並附出處？ |
| **幻覺與風控** | 會錯在哪？要設幾道防線？ |
| **實作二** | 查核固定草稿，再做受控比較：判斷 AI 寫得對不對。 |

講授約 20 分鐘（Part 1–4 重點頁）→ 課內驗證練習約 80 分鐘（Part 5）。

# 01

PART 1

## LLM 怎麼運作 How Large Language Models Work

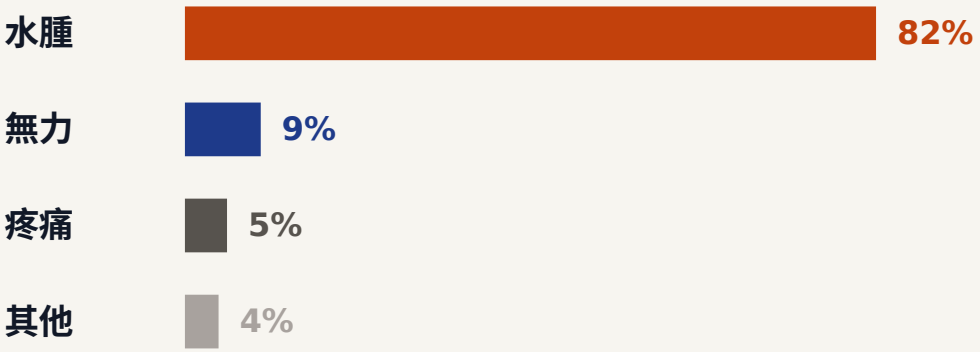
不懂原理，就看不懂它為什麼會犯錯

文字接龍、三個旋鈕、生成式與預測式、提示工程

# LLM 的本質：超大型文字接龍

依前文預測最可能的下一個 Token，再接著往下寫

王伯伯近三天體重增加兩公斤，伴隨下肢 ____




機率為教學示意

### 不是查資料庫

依語言規律生成最順的句子

### 所以很會寫

文法流暢、語氣專業

### 也所以會錯

聽起來合理，不等於事實正確

LLM 優化的是「像真的」，不是「是真的」：查核永遠不能省。

# Token 、上下文視窗、溫度：影響輸出的三個旋鈕

用一位實習醫師來比喻

| 概念 | 白話意思 | 臨床使用的提醒 |
| --- | --- | --- |
| **Token** | 模型處理文字的單位；計費與長度都以它計 | 中文換算依模型而異；長病歷注意截斷 |
| **上下文視窗** | 一次能讀進的內容量，像能翻閱的病歷頁數 | 內容太長會漏讀；重要資訊放前面或分段 |
| **溫度** | 回答的隨機程度 | 病歷用低溫求一致；衛教標語可稍高 |

臨床文書：低溫度、明確格式、只依提供的內容作答。

# 生成式 AI 與預測式 AI：一個寫、一個算

延伸閱讀： W5 的再入院模型是預測式；本週的 SOAP 生成是生成式

| 比較 | 預測式 AI （W5） | 生成式 AI （W6） |
|---|---|---|
| **輸出** | 一個分數或類別 | 一段新內容（文字、圖、程式） |
| **評估** | AUROC、校準度等固定指標 | 正確性、完整性、安全性；常需人工評閱 |
| **典型錯誤** | 預測不準、族群偏誤 | 幻覺、遺漏、歸屬錯誤 |
| **監管** | 多以醫療器材軟體審查 | 文書用途多不屬醫材；臨床建議可能屬醫材 |
| **導入重點** | 模型驗證與監測 | 使用規範、人工審閱、稽核紀錄 |

同一家醫院可能同時用兩種 AI，驗證、法規與治理方式都不同。

# 好提示的五要素

實作二的基本功；依據與限制最關鍵

| | |
|---|---|
| **角色** | 「你是心臟內科門診的病歷文書助理」 |
| **任務** | 「把以下門診對話整理成 SOAP 病歷草稿」 |
| **依據** | 「只能使用對話中出現的資訊，每句標註行號」 |
| **格式** | 「分 S、O、A、P 四段」 |
| **限制** | 「沒提到的寫『未提及』，不可推測或補寫」 |

依據與限制兩項，直接決定幻覺的多寡。

Part 1 | 提示對照

# 同一個需求，兩種寫法

差別不在字數，而在有沒有把醫療規則寫進去

| 面向 | 模糊提示：「幫我把這段對話寫成病歷」 | 結構化提示（五要素） |
| --- | --- | --- |
| **格式** | 每次不同，難以比較 | 固定四段，輸出穩定 |
| **多寫風險** | 可能自行補上「理學檢查正常」 | 沒提到的寫「未提及」 |
| **說話者** | 家屬的話可能記成病人自述 | 家屬說的標「家屬代述」 |
| **可追溯** | 無法知道每句來源 | 每句有行號，醫師可逐句核對 |

實作二會用同一段對話比較兩種提示，親眼看到「多一行限制」的差別。

02

PART 2

# 臨床應用與實證 Applications & Evidence

從代筆、回訊息，到編碼與知識查詢

WHO 五大用途、六類應用、環境式記錄、實證研究、台灣導入

# WHO 歸納大型多模態模型的五大醫療用途

延伸閱讀： WHO 2024 年 1 月指引，提出 40 多項建議

| 用途 | 例子 | 風險 |
| --- | --- | --- |
| **診斷與臨床照護** | 回答病人書面提問 | 高 |
| **病人自主使用** | 查詢症狀與治療資訊 | 高 |
| **行政文書** | 記錄與摘要就診內容 | 相對低（本週重點） |
| **醫護教育訓練** | 模擬病人對話練習 | 中 |
| **研究與藥物開發** | 找出候選化合物 | 依用途而定 |

越靠近診斷與病人自主使用，風險越高、驗證要求越嚴格。

Part 2 | 應用地圖

# 生成式 AI 在醫院的六類應用

延伸閱讀：依使用者與直接影響病人的程度排列

| 應用 | 使用者 | 例子 | 風險 |
| --- | --- | --- | --- |
| **環境式臨床記錄** | 醫師、護理師 | 門診對話生成 SOAP 草稿 | 中：須審閱 |
| **病歷摘要** | 醫師 | 入院、出院、轉診摘要 | 中：可能遺漏病史 |
| **病人訊息回覆** | 醫護 → 病人 | 入口網站留言回覆草稿 | 中高：直達病人 |
| **衛教內容生成** | 衛教師 → 病人 | 依病人程度改寫衛教單 | 中：須專業審定 |
| **疾病分類編碼** | 病歷管理師 | 由病歷預測 ICD-10 代碼 | 低中：影響申報 |
| **院內知識查詢** | 全院同仁 | 以 RAG 查 SOP、藥品仿單 | 低中：須附出處 |

多數醫院從低中風險、內部使用開始，累積信任後才擴大到直接面對病人。

# Ambient AI Scribe 怎麼運作

醫師專心看診， AI 在背景聽並產生病歷草稿



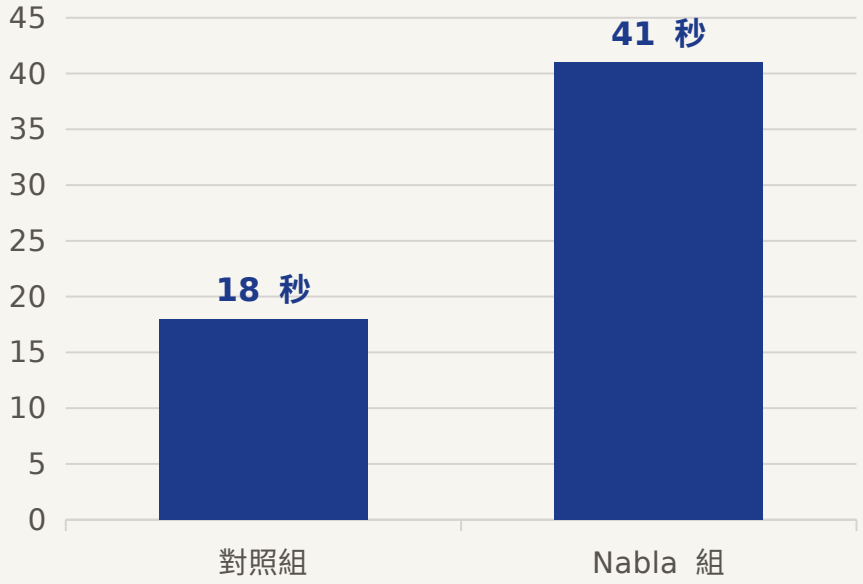

| | |
|---|---|
| **同意** | 告知病人並取得同意；說明錄音保存與刪除方式。 |
| **轉錄** | 台語、口音、多人對話都會影響正確率。 |
| **審閱** | 醫師是最後一道防線，也是法律上的負責人。 |
| **記錄** | 保留 AI 版本與修改紀錄，供稽核。 |

風險集中在轉錄與審閱：轉錄錯了後面全錯；沒看就簽，錯誤就成了正式病歷。

Part 2 | 實證

# 隨機對照試驗： AI 代筆省多少時間

UCLA Health： 238 位醫師、 14 個專科、約 72,000 次門診（NEJM AI, 2025）




**省時** Nabla 相對對照組約 9.5%； DAX 未達統計顯著

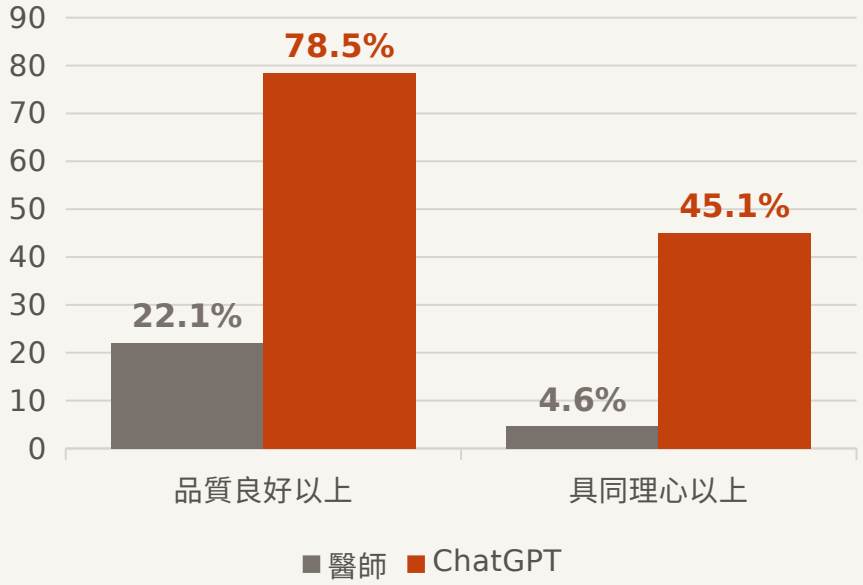
**倦怠** 兩個 AI 組約改善 7%

**錯誤** 偶有臨床上重要的不正確； 1 件輕微病安事件

比宣傳低調：省時有，但不大；倦怠改善溫和。

# AI 回覆病人提問：更有同理心，卻不一定省時

延伸閱讀：兩個常被引用的研究，結論要放在一起看




## Ayers 等 2023

195 則網路論壇提問；比較對象是醫師在論壇的簡短回覆。

## Garcia 等 2024

162 位臨床人員使用回覆草稿：倦怠與負荷下降，但未節省時間。

寫得更暖不代表更對；審閱草稿也要時間，效益要在真實流程量測。

Part 2 | 台灣

# 台灣醫院的生成式 AI 導入

延伸閱讀：共同點：模型部署在院內、醫師最後審閱、從文書開始

| 醫院 | 應用 | 做法 | 公開資訊 |
| --- | --- | --- | --- |
| **臺大醫院** | ICD-10 編碼預測 | 開源 LLM 以院內資料微調 | 全碼 86.67%、主診斷 82%（實測） |
| **臺北榮總** | 智慧病歷助手 | 地端模型產生入院、病程、出院摘要草稿 | 2025-10 導入四大科；預估減 40–50% |
| **高雄醫學大學** | KMU Genie 平台 | 開源模型微調＋ RAG | 護理紀錄撰寫時間縮短（院方說明） |

分清數字性質：準確率是實測，預估減少時間是期待。

Part 2 | 實證整理

# 宣傳與實證：成效常和「省一半時間」不同

依本週引用資料整理

| 來源 | 常見期待 | 實際觀察 | 啟示 |
| --- | --- | --- | --- |
| **UCLA 隨機試驗** | 大幅節省時間 | 省時有限、倦怠溫和改善 | 用自己的流程驗證 |
| **Stanford 試辦** | 加快回覆 | 未省時，但減輕負擔 | 先定義成效指標 |
| **台灣醫院** | 減少文書時間 | 多為預估或院方說明 | 需要更多實測與公開數據 |

導入前先問：證據從哪來？成功的定義是什麼？

Part 2 ｜原文評讀

# 用證據表讀 UCLA 試驗：能支持什麼、不能支持什麼

與 W12 MASAI 證據表同一套欄位；課前讀原文摘要與結果表，課堂 5 分鐘對答

| 欄位 | UCLA AI 代筆試驗（NEJM AI 2025） |
|---|---|
| **研究問題** | AI 代筆能否減少醫師寫病歷的時間與倦怠? |
| **設計與比較** | 以醫師為單位隨機分三組： Nabla 、 DAX 、一般書寫； 238 位、 14 科 |
| **效果與不確定性** | Nabla 每份少約 41 秒（對照少 18 秒），差異顯著； DAX 未達顯著 |
| **偏誤與限制** | 單一醫學中心、約 2 個月；倦怠改善小；偶有臨床上重要的錯誤 |
| **適用性（台灣）** | 語言、口音、台語與門診量都不同，需在地測試 |
| **下一步驗證** | 本院試辦：記錄書寫時間、修改率、錯誤與病人拒絕率 |

「省時 9.5% 」是相對對照組多省的比例，每份約多省 23 秒；不能寫成「省一半時間」。

# 03

PART 3

## RAG 檢索增強生成 Retrieval-Augmented Generation

讓 AI 從憑記憶作答，變成翻書作答

閉卷與開書、 RAG 步驟、提示、 RAG 與微調的比較

Part 3 | 白話比喻

# RAG： 把閉卷考試改成開書考試

LLM 的知識有截止日，也不認識你們醫院的 SOP

| 面向 | 閉卷：一般 LLM | 開書： RAG |
| --- | --- | --- |
| **知識來源** | 訓練時背下來的知識 | 先到指定文件庫找資料 |
| **院內新規範** | 不知道最新版照護流程 | 依找到的段落作答 |
| **不會時** | 傾向編一個像樣的答案 | 可要求找不到時回答「文件中沒有」 |
| **出處** | 沒有，無法查核 | 附上文件與頁碼 |

RAG 不保證零錯誤，但讓錯誤可以被追查。

# RAG 的步驟

以護理師詢問「心衰竭出院衛教要包含哪些項目？」為例

| | |
|---|---|
| **1 提問** | 護理師輸入問題。 |
| **2 檢索** | 在院內文件庫找出最相關的 3 至 5 段。 |
| **3 組合** | 把段落與問題交給 LLM，只能依這些段落作答。 |
| **4 生成** | 回答並標註「出自《心衰竭照護指引》第 4 頁」。 |
| **5 維護** | 指引改版就更新文件庫，不必重新訓練模型。 |

RAG 的品質很大程度取決於文件庫：過期、矛盾的文件會被自信地引用。

# 提示、 RAG 、微調：讓 AI 更懂醫院的三種方法

延伸閱讀：實務順序：先提示 → 再 RAG → 必要時才微調

| 方法 | 比喻 | 適合 | 成本 | 例子 |
|---|---|---|---|---|
| **提示工程** | 給實習醫師工作說明 | 格式、語氣、規則 | 最低 | 本週實作二 |
| **RAG** | 讓實習醫師帶院內手冊 | 院內知識、常改版內容 | 中 | 高醫 KMU Genie |
| **微調** | 讓實習醫師接受專科訓練 | 特定任務、特定用語 | 高 | 臺大 ICD 編碼 |

問題出在不知道，用 RAG ； 出在不會做，才考慮微調。

04

PART 4

# 幻覺與風險控管 Hallucination & Safety

## AI 會錯，而且錯得很有自信

五種錯誤、幻覺率實測、 Whisper 事件、五道防線、隱私

Part 4 | 錯誤類型

# AI 生成病歷的五種常見錯誤

以王伯伯的門診為例；實作二要找的就是這些

| 錯誤類型 | 定義 | 王伯伯的例子 |
| --- | --- | --- |
| **捏造** | 寫出對話中沒有的內容 | 沒做聽診，卻寫「兩側肺部有囉音」 |
| **遺漏** | 漏掉重要資訊 | 漏寫「睡覺要墊兩個枕頭」 |
| **歸屬錯誤** | 把甲說的記成乙說的 | 女兒說「他偷吃鹹的」，記成病人自述 |
| **否定錯誤** | 把「沒有」寫成「有」 | 「沒有胸痛」寫成「主訴胸痛」 |
| **過度推論** | 把討論中的選項寫成決定 | 「考慮調藥」寫成「已調高利尿劑」 |

五種錯誤都讀起來很通順：只看文筆抓不到，必須逐句回到原始對話。

# 臨床摘要的幻覺有多常見

Asgari 等（2025）：臨床醫師逐句標註約 1.3 萬句摘要與近 5 萬句逐字稿

**1.47%**

**幻覺率（191 / 12,999 句）**

**3.45%**

**遺漏率（1,712 / 49,590 句）**

**44%**

**幻覺屬重大（84 / 191）**

## 重大幻覺最多出現在計畫（P），約 21%

一份摘要約 20–30 句：平均每 2–4 份就可能有一句幻覺。

審閱時把最多注意力放在 P：藥物、劑量、檢查與回診安排。

# Whisper 語音轉錄： AI 會聽到沒人說過的話

美聯社 2024 年 10 月調查報導

**約 8 / 10**

一位研究者檢視的轉錄出現幻覺

**187 處**

逾 13,000 段清晰音檔中的幻覺

**近 40%**

幻覺被評為有害或令人擔憂

## 例：捏造不存在的藥物「hyperactivated antibiotics」

部分醫療產品刪除原始錄音，錯誤無法回頭比對。

原始資料是查核的依據：為了資料安全刪除錄音，錯誤就永遠無法被發現。

# 五道防線：讓生成式 AI 可以安全上線

瑞士起司模型：每一層都有洞，疊起來才擋得住

### ① 提示限制

只依原始資料；未提及寫「未提及」

### ② 依據與出處

RAG 或逐句標註行號

### ③ 結構化輸出

固定欄位，方便比對

### ④ 自動檢核

程式檢查數字、藥名、否定詞

### ⑤ 人工審閱

醫師逐句確認，簽名負責

＋ **稽核紀錄：**保留原始錄音或逐字稿、 AI 版本、醫師修改處，出事時才查得到哪一層失守。

第 ⑤ 道最貴也最容易鬆懈： AI 越準，人越容易沒看就簽（自動化偏誤）。

# 病人資料能不能丟進 ChatGPT

取決於部署方式、合約與是否去識別化

| 部署方式 | 資料去向 | 適合情境 | 注意事項 |
| --- | --- | --- | --- |
| **免費公用版** | 送到廠商雲端，可能用於訓練 | 不得輸入任何病人資料 | 最常見的違規來源 |
| **企業版／醫療雲** | 依合約不用於訓練 | 去識別化資料、行政文書 | 審查合約與資料駐留 |
| **院內地端部署** | 不離開醫院網路 | 含個資的病歷生成 | 需算力與維運人力 |

底線：未經機構核准，不把可識別的病人資料貼進任何公用 AI 工具。

05

PART 5

# ★ 實作二：門診對話 → SOAP 病歷 Hands-on Lab 2

80 分鐘：先查核固定草稿，再做受控比較

擬真對話、固定草稿、查核表、提示範本、受控比較、溯源呈現、 AI 使用紀錄

# 實作二： 80 分鐘的課內驗證練習

產出：固定材料查核表、受控比較紀錄、溯源呈現、 AI 使用紀錄




| | |
|---|---|
| **A 固定查核** | 全班查核同一份教師預製草稿：逐句判定，找出遺漏。 |
| **B 受控比較** | 同一段對話、同一工具，只換提示，兩份輸出都保留。 |
| **溯源呈現** | 網頁原型或標註文件擇一，能把每句對回行號。 |
| **討論** | 小組比對判定；有依據的異議可以提出。 |

評分看判定對不對、有沒有依據；沒找到錯誤不扣分，把正確句判成錯誤會扣分。

# 擬真門診對話：王伯伯心臟內科回診

教學虛構；醫＝醫師、王＝王伯伯、女＝女兒

01 醫：王伯伯，這兩週還好嗎？

02 王：還可以啦，就是晚上比較喘。

03 女：醫師，他這三天體重多了快兩公斤，腳也比較腫。

04 醫：晚上睡覺要墊幾個枕頭？

05 王：兩個，不然躺平會喘。

06 醫：有胸痛嗎？

07 王：沒有，胸口不會痛。

08 女：他上禮拜喝喜酒，還偷吃很多鹹的。

09 醫：Furosemide 有每天吃嗎？

10 王：有啦……有時候忘記。

11 醫：血壓 148/92，體重 74.5 公斤。

12 醫：我先抽血看腎功能和 NT-proBNP，

13 醫：利尿劑可能要調整，看報告再決定。

14 醫：兩週後回診，三天內體重多兩公斤就要先回來。

這段對話刻意埋了幾個陷阱：先別看答案，看看 AI 會不會掉進去。

# SOAP 病歷四段：每段該放什麼

Weed （1968）提出的問題導向病歷格式

| 段落 | 放什麼 | 這次要特別注意 |
| --- | --- | --- |
| **S 主觀** | 病人與家屬的陳述 | 誰說的？家屬代述要標明 |
| **O 客觀** | 量測與檢查結果 | 沒做的檢查不能寫 |
| **A 評估** | 醫師的判斷 | 醫師有說嗎？沒說就寫「未提及」 |
| **P 計畫** | 檢查、治療、追蹤 | 「考慮」與「已執行」要分清 |

最容易出錯的是 A： AI 常自己幫醫師下診斷，但對話中醫師其實沒說。

# 固定材料：教師預先產生的 SOAP 草稿

全班查核同一份草稿；有對有錯，也可能漏寫

| # | 段 | AI 草稿句子 |
|---|---|---|
| 1 | S | 病人自述夜間較喘［02］ |
| 2 | S | 病人自述三天內體重增加近 2 公斤、下肢較腫［03］ |
| 3 | S | 需墊兩個枕頭，躺平會喘［05］ |
| 4 | S | 主訴胸痛［06–07］ |
| 5 | S | 家屬代述上週喝喜酒後吃得較鹹［08］ |
| 6 | S | 規則服用 Furosemide ［10］ |
| 7 | O | 血壓 148/92 mmHg、體重 74.5 kg ［11］ |

| # | 段 | AI 草稿句子 |
|---|---|---|
| 8 | O | 心跳每分鐘 88 次［11］ |
| 9 | O | 雙下肢凹陷性水腫 2+ |
| 10 | O | 肺部聽診：未提及 |
| 11 | A | 急性心衰竭惡化 |
| 12 | P | 抽血：腎功能、NT-proBNP ［12］ |
| 13 | P | 已調高 Furosemide 劑量［13］ |
| 14 | P | 一週後回診［14］ |

逐句回到原始對話判定；也要檢查原文有、草稿沒寫的重要資訊。

# 步驟一：逐句判定固定草稿

14 句都要判定；判錯正確句子會扣分

| # | 判定 | 依據行號 | 錯誤類型 | 改正為 | 嚴重度 |
|---|---|---|---|---|---|
| **1** | 正確／錯誤／無法確認 | | 捏造／歸屬／否定／過度推論 | | 重大／輕微 |
| **2** | | | | | |
| **…** | | | | | |
| **遺漏** | 原文有、草稿沒寫： | | 遺漏 | | |

嚴重度：照著錯誤內容執行，是否可能改變診斷、用藥或回診安排？是＝重大。數字、時間與原文不符歸為捏造。

評分看判定是否正確、依據是否清楚，不看找到幾個錯誤。

# 步驟二：用這份提示產生 SOAP

可直接複製；四條規則是防幻覺的關鍵，請勿刪除

```
你是心臟內科門診的病歷文書助理。
任務：把下方門診對話整理成 SOAP 病歷草稿（繁體中文）。
規則：
1. 只能使用對話中出現的資訊，每句後面用［行號］標註來源，例如［03］。
2. 對話中沒有的內容一律寫「未提及」，不可推測、不可補寫正常值。
3. 區分說話者：家屬說的要寫「家屬代述」。
4. 醫師「考慮中」的計畫要寫「待決定」，不可寫成已執行。
輸出：S、O、A、P 四段，最後列出「需醫師確認的項目」。
對話：〈貼上 01–14 行〉
```

對照組：同一段對話只輸入「幫我寫成病歷」；兩份原始輸出全文都保留。

# 受控比較：一次只改一件事

比較的是提示的差別，不是哪個模型比較強

| | |
|---|---|
| **固定** | 同一段對話 01–14 、同一工具、同一天執行。 |
| **只改** | 提示：模糊提示 vs 範本提示。 |
| **記錄** | 兩份原始輸出全文、提示全文、執行日期與工具名稱。 |
| **比較** | 用同一張查核表，看否定、說話者、未提及、待決定各處理得如何。 |
| **限制** | 一次比較只代表本次小樣本觀察，不代表模型已通過驗證。 |

多跑幾次就全部保留，不挑最好的一次代表整體；沒有工具時用教師提供的成對輸出。

# 步驟三：讓每句都對得回原文（擇一）

網頁原型或標註文件都可以；網頁只是展示，不是串接臨床系統

```
請幫我做一個單一 HTML 檔的網頁：
1. 左邊是大文字框，可貼上有行號的門診對話。
2. 按「顯示 SOAP」後，右邊顯示 S、O、A、P
   四個區塊（用我提供的範例結果即可）。
3. 每句後面的［行號］可點擊，
   點了就把左邊對應那一行標成黃色。
4. 沒有［行號］的句子用紅底標示。
5. 繁體中文、大字體。
```

| | |
|---|---|
| **點行號** | 快速溯源 |
| **紅底** | 可能的幻覺 |
| **替代** | 標註文件：句子旁寫行號 |
| **延伸** | 串接 API 自動生成，不計分 |

網頁用預先產生的結果，屬展示原型；做不出網頁，用標註文件呈現同樣算分。

# AI 使用紀錄：讓別人能重做一次

延續 W1 課程規範；工具、輸入、輸出與人工修訂都要留下

| 項目 | 要寫什麼 | 範例 |
| --- | --- | --- |
| **工具與模型** | 工具名稱；介面有顯示才寫模型名稱 | Claude （介面顯示的模型名稱） |
| **日期與提示** | 執行日期、兩份提示全文 | 附件一：模糊提示；附件二：範本 |
| **輸入與輸出** | 輸入的對話、每次原始輸出全文 | 附件三、四：兩份原始輸出 |
| **人工修訂** | 改了什麼、依據哪一行 | 第 13 句依［13］改為「待決定」 |
| **未提供的設定** | 照實寫「介面未提供」 | 溫度：介面未提供 |

不知道的設定照實寫「介面未提供」；自行編造版本或參數，比沒寫更糟。

# 實作二評分規準

占學期成績 10%；重點在判斷力，不在程式技巧或工具

| 構面 | 比重 | 優秀表現 |
| --- | --- | --- |
| **查核正確與理由** | 40% | 固定草稿判定正確、引用行號；找出遺漏；類型與嚴重度合理 |
| **受控比較設計** | 20% | 同輸入、只換提示；能說明差異來自哪一條規則 |
| **比較證據與紀錄** | 20% | 兩份原始輸出、提示、日期、工具齊全；不挑最好的一次 |
| **溯源呈現** | 10% | 網頁或標註文件能逐句對回行號；標明展示原型 |
| **個人說明** | 10% | 能口頭解釋自己的一個判定或比較結果 |

沒找到錯誤不扣分，判錯正確句子會扣分；不看網頁美觀，也不看是否用付費工具。

Summary

# 本週帶走的三個問題

用同一套方法，評估下一個生成式 AI 工具

| | |
|---|---|
| **依據在哪** | AI 寫的每一句，能回到原始資料或文件嗎? |
| **錯在哪裡** | 捏造、遺漏、歸屬、否定、過度推論，最常在 P？ |
| **誰來把關** | 五道防線設了哪幾道？審閱的人會不會沒看就簽? |

帶走一個問題：你的醫院明天導入 AI 代筆，你會先設哪一道防線?

名詞小辭典 Glossary

# 本週名詞小辭典

延伸閱讀：相關名詞的白話意義與使用界線

| 名詞 | 白話解釋 |
| --- | --- |
| **大型語言模型 LLM** | 以大量文字訓練、能生成文字的 AI 模型 |
| **上下文視窗** | 模型一次能處理的內容長度上限 |
| **環境式臨床記錄** | 在背景聆聽看診對話並產生病歷草稿 |
| **檢索增強生成 RAG** | 先檢索指定文件，再依文件內容生成回答 |
| **幻覺 Hallucination** | 生成看似合理、實際錯誤或無根據的內容 |
| **自動化偏誤** | 過度信任自動化系統而疏於查核 |

英文名詞方便查找國際文獻；使用時注意定義。

下週預告 Next Week

# 下週： AI Agent 與臨床流程自動化

從「幫你寫」到「幫你做」

| | |
|---|---|
| **三種形態** | 聊天機器人、副駕駛、代理人：差在哪？ |
| **架構** | Agent 的元件；單一 Agent 與多代理人。 |
| **人機協作** | 哪些事 AI 可以自己做、哪些一定要人核准？ |
| **擬真案例** | 王伯伯出院準備的多代理人流程。 |
| **課前準備** | 想一個單位裡最繁瑣、最常出錯的跨部門流程。 |

下週沒有實作，但會用你帶來的流程做分組演練。

參考資料 References

# 核心參考資料

完整連結見講者備註

| | |
|---|---|
| **WHO （2024）** | Guidance on large multi-modal models |
| **Asgari 等（2025）** | 臨床摘要的安全與幻覺率框架， npj Digit Med |
| **UCLA （2025）** | AI scribes 隨機對照試驗， NEJM AI |
| **Ayers； Garcia** | 病人訊息回覆研究（2023； 2024） |
| **Lewis 等（2020）** | Retrieval-augmented generation， NeurIPS |
| **台灣案例** | iThome 臺大（2024）、北榮（2025）； CIO Taiwan 高醫（2026） |

數字要分清實測、預估與院方說明。

CLOSING

# 讓 AI 執筆，讓人負責

生成式 AI 把醫師從鍵盤前解放出來；
能找出錯誤的人，才是醫療 AI 時代真正稀缺的專業。