智慧醫療與科技發展　Smart Healthcare & Technology Development

06

生成式 AI 與大型語言模型的臨床應用

Generative AI & Large Language Models in Clinical Care

第 6 週｜★ 實作週　Hands-on Week （講授約 40 分鐘＋課堂實作約 70 分鐘）
LLM 怎麼運作 → 臨床應用全景 → RAG → 幻覺與風險控管 → 國際案例 → 實作二：門診對話 → SOAP 病歷

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

本週地圖 This Week

本週六個部分

前半段建立判斷力，後半段動手做出一個可以「被查核」的病歷生成原型

01

LLM 怎麼運作

How LLMs Work

文字接龍、 Token 、提示工程

02

臨床應用全景

Applications

環境式記錄、訊息回覆、台灣案例

03

RAG

Retrieval

開書考試：讓 AI 引用院內知識

04

幻覺與風控

Hallucination

錯誤類型、實測數據、五道防線

05

國際案例

Global Cases

UCLA 試驗、Whisper 、 Stanford

06

★ 實作二

Hands-on

門診對話→ SOAP 病歷＋查核

教學重點｜本週的核心能力不是「會用 AI 寫病歷」，而是「能找出 AI 寫錯的地方」。

學習目標 Learning Objectives

本週結束時，你能夠……

每一項目標都對應課程三項核心能力；期中、期末個案分析即依此命題

1	說明 LLM 「文字接龍」原理，以及 Token 、上下文視窗、溫度的影響	C1 趨勢洞察
2	依實證判斷 AI 代筆與訊息回覆的真實效益與限制	C3 實證評估
3	比較提示工程、 RAG 、微調的適用情境	C2 技術應用
4	分類五種生成錯誤，設計防線並完成一份病歷查核	C2 技術應用 C3 實證評估

對應評量｜★ 實作二（學期成績 10%）；期中 Q4

課程脈絡 Where we are

承上

W5 預測式 AI：輸出一個分數

本週

生成式 AI：輸出一段內容，要學會查核

啟下

W7 AI Agent：從「幫你寫」到「幫你做」

教學重點｜本週核心能力不是「會用 AI 寫病歷」，而是「能找出 AI 寫錯的地方」。

開場 Opening

王伯伯回診的 15 分鐘：醫師的眼睛常停在螢幕上

生成式 AI 最先改變的，不是診斷，而是「寫字」這件事

醫師的文書負擔（台灣實例）

- 住院醫師每天平均寫 6 至 10 份病程紀錄
- 一份完整入院紀錄約需 30 分鐘至 2 小時
- 門診邊問診、邊打字，眼睛離開病人
- 下班後補寫病歷，是倦怠主因之一

如果 AI 能代筆……

- 醫師專心看著王伯伯與女兒說話
- AI 聽完對話，自動產生 SOAP 草稿
- 醫師花 1 分鐘審閱、修改、簽名
- 但：AI 若「聽錯」或「多寫」，誰負責?

資料來源：臺北榮總智慧病歷助手導入報導（iThome，2025-12）。

教學重點｜本週要回答：AI 代筆能省多少時間？會錯在哪裡？怎麼設計才能放心用？

01

PART 1

LLM 怎麼運作 How Large Language Models Work

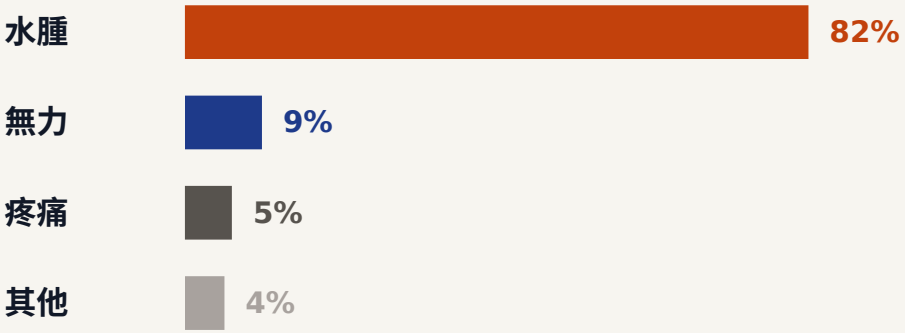
不懂原理，就看不懂它為什麼會犯錯

文字接龍：預測下一個字； Token 、上下文視窗、溫度
生成式 AI vs 預測式 AI ；提示工程五要素

LLM 的本質：超大型「文字接龍」

根據前文，一次預測「最可能的下一個字詞（Token）」，再接著往下寫

王伯伯近三天體重增加兩公斤，伴隨下肢 ____



機率為教學示意

- **它不是查資料庫：**而是依「語言規律」生成最順的句子
- **所以很會寫：**文法流暢、語氣專業
- **也所以會錯：**「聽起來合理」不等於「事實正確」——這就是幻覺的根源

教學重點｜記住一句話： LLM 優化的是「像真的」，不是「是真的」——查核永遠不能省。

Part 1 | 三個關鍵概念

Token 、上下文視窗、溫度：三個影響輸出的旋鈕

用「一位實習醫師」來比喻

01

Token 字詞單位

Token

模型處理文字的最小單位；中文約 1 字 1 至 2 個 Token。計費與長度限制都以它計算。

02

上下文視窗

Context Window

一次能「讀進腦中」的內容量。像實習醫師一次能翻閱的病歷頁數——超過就會忘了前面。

03

溫度

Temperature

回答的隨機程度。寫病歷要低溫（穩定一致）；寫衛教標語可稍高（多些創意）。

教學重點 | 臨床文書建議：低溫度＋明確格式＋只依提供內容作答——讓「文字接龍」盡量不亂接。

Part 1 ｜與 W5 的差別

生成式 AI vs 預測式 AI：一個「寫」、一個「算」

W5 的再入院風險模型是預測式；本週的 SOAP 生成是生成式

比較	預測式 AI （W5）	生成式 AI （W6）
輸出	一個分數或類別（例：再入院風險 0.72）	一段新內容（文字、圖、程式碼）
評估方式	AUROC、校準度等固定指標	正確性、完整性、安全性——常需人工評閱
典型錯誤	預測不準、族群偏誤	幻覺、遺漏、歸屬錯誤、語氣不當
監管現況	多為醫療器材軟體（SaMD）審查	文書用途多不屬醫材；臨床建議用途則可能屬醫材
醫院導入重點	模型驗證與監測	使用規範、人工審閱、稽核紀錄

教學重點｜同一家醫院可能同時用兩種 AI—— 但驗證方法、法規與治理方式完全不同，不能混為一談。

好提示的五要素：角色、任務、依據、格式、限制

Prompt 寫得好，錯誤可以少一大半——這是實作二的基本功

角色 Role	「你是一位心臟內科門診醫師的文書助理」
任務 Task	「把以下門診對話整理成 SOAP 病歷」
依據 Source	「只能使用對話中出現的資訊」
格式 Format	「分 S、O、A、P 四段，每句標註對話行號」
限制 Limits	「未提及的項目寫「未提及」，不可推測或補寫」

教學重點｜紅色兩項（依據、限制）是醫療情境最關鍵的——它們直接決定幻覺的多寡。

Part 1 | 提示對照

同一個需求，兩種寫法

差別不在字數，而在有沒有把「醫療規則」寫進去

× 模糊的提示

```
幫我把這段對話寫成病歷。
```

- 格式每次不同
- 可能自行補上「理學檢查正常」
- 無法追溯每句話的來源

✓ 結構化的提示

```
角色：心臟內科門診文書助理
任務：整理成 SOAP 病歷
依據：僅限對話內容，標註行號
限制：未提及寫「未提及」；不得推測
```

- 輸出穩定、可比較
- 缺漏一目了然
- 醫師可逐句核對來源

教學重點｜實作二會直接使用右邊這種結構——你會親眼看到「加一行限制」帶來的差別。

02

PART 2

臨床應用全景 Clinical Applications

從代筆、回訊息，到編碼與教學

WHO 歸納的五大用途；環境式臨床記錄（Ambient AI Scribe）
病人訊息回覆的實證；台灣醫院的生成式 AI 導入

WHO 歸納大型多模態模型（LMM）的五大醫療用途

WHO《健康 AI 倫理與治理：大型多模態模型指引》（2024 年 1 月），提出 40 多項建議

1	2	3	4	5
診斷與臨床照護	病人自主使用	行政文書	醫護教育訓練	研究與藥物開發
例：回答病人書面提問	例：查詢症狀與治療資訊	例：記錄與摘要就診內容	例：模擬病人對話練習	例：找出候選化合物

本週聚焦第 3 項「行政文書」：風險相對低、效益立即可見，是全球醫院導入生成式 AI 的第一站。

資料來源：WHO（2024-01-18）Ethics and governance of AI for health: Guidance on large multi-modal models.

教學重點｜用途越靠近「診斷與病人自主使用」，風險越高、需要的驗證越嚴格（呼應 W2 應用光譜）。

Part 2 | 應用地圖

生成式 AI 在醫院的六類應用

依「誰使用」與「直接影響病人的程度」排列

應用	使用者	例子	風險
環境式臨床記錄	醫師、護理師	門診對話自動生成 SOAP 草稿	中：草稿須審閱
病歷摘要	醫師	入院摘要、出院摘要、轉診摘要	中：遺漏關鍵病史
病人訊息回覆	醫護→病人	入口網站留言的回覆草稿	中高：直接到病人手上
衛教內容生成	衛教師→病人	依病人程度改寫衛教單張	中：須專業審定
疾病分類編碼	病歷管理師	由病歷預測 ICD-10 代碼	低中：影響申報
院內知識查詢	全院同仁	以 RAG 查詢 SOP、藥品仿單	低中：須附出處

教學重點｜多數醫院從「低中風險、內部使用」開始，累積信任後才擴大到直接面對病人的應用。

Ambient AI Scribe 怎麼運作?

醫師只要專心看診， AI 在背景「聽」並產生病歷草稿



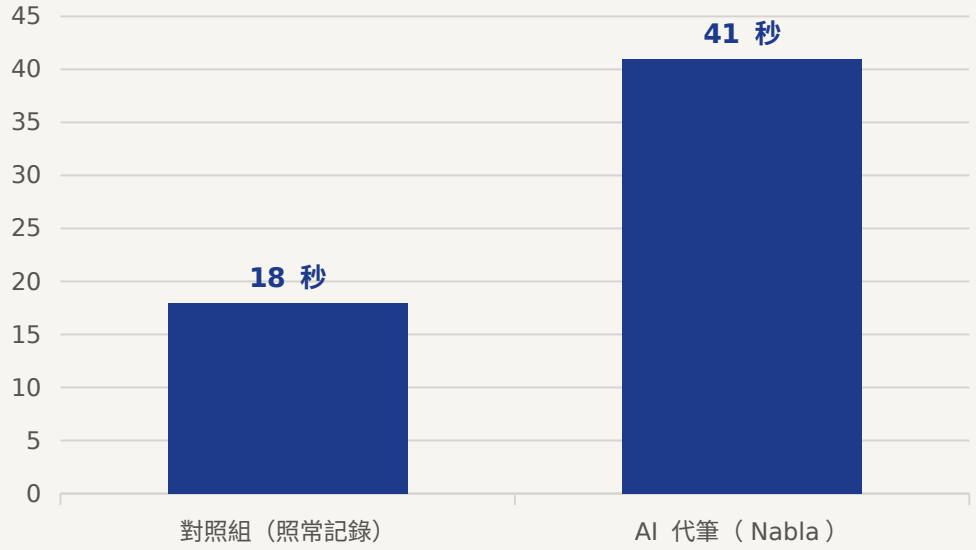
同意	轉錄	結構化	審閱	記錄
告知病人並取得同意；說明錄音保存與刪除方式	台語、口音、多人對話都會影響正確率	依科別範本產生 SOAP；標註資訊來源	醫師是最後一道防線，也是法律上的負責人	保留 AI 版本與修改紀錄供稽核

教學重點｜風險集中在 ② 與 ④：轉錄錯了，後面全錯；醫師若「看都沒看就簽」， AI 錯誤就成了正式病歷。

Part 2 | 實證

隨機對照試驗： AI 代筆到底省多少時間?

UCLA Health， 238 位醫師、 14 個專科、約 72,000 次門診（NEJM AI， 2025）



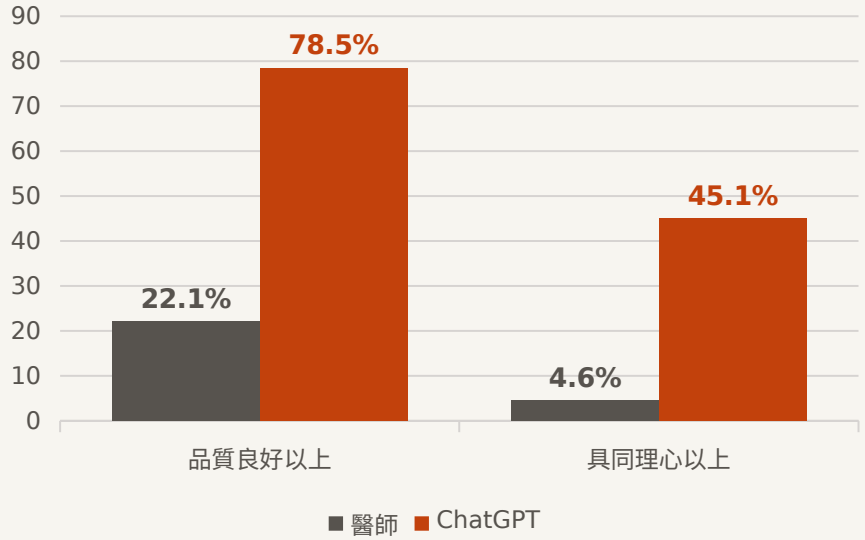
- **省時：** Nabla 組每份病歷比對照組多省約 9.5%；DAX 組差異未達統計顯著
- **倦怠：**兩個 AI 組的倦怠分數都改善約 7%
- **錯誤：**醫師回報偶有臨床上重要的不正確，多為遺漏或人稱代名詞錯誤； 1 件輕微病安事件

資料來源： UCLA Health 新聞稿（2025-11-26）； NEJM AI （2025）隨機對照試驗。

教學重點｜比宣傳低調得多：省時「有，但不大」，倦怠改善「溫和」——真正的價值在醫師的專注與感受。

AI 回覆病人提問：更有同理心，卻不一定更省時

兩個常被引用的研究，結論要放在一起看



Ayers 等（JAMA IM， 2023）

195 則網路論壇提問；評審 79% 偏好 ChatGPT 的回答。但比較對象是醫師在論壇上的簡短回覆。

Stanford （JAMA Netw Open， 2024）

162 位臨床人員使用 AI 回覆草稿：倦怠與認知負荷下降，但客觀數據顯示並未節省時間。

教學重點｜啟示： AI 寫得「更暖」不代表「更對」；而審閱草稿本身也要時間——效益要用真實流程量測。

Part 2 | 台灣

台灣醫院的生成式 AI 導入：三種路線

共同點：模型部署在院內、醫師最後審閱、從文書開始

醫院	應用	做法	公開成效
臺大醫院	ICD-10 編碼預測	以開源 LLM 微調	全碼準確率 86.67%、主診斷 82%（2024）
臺北榮總	智慧病歷助手	地端模型；產生入院、病程、出院病摘草稿；附出處	2025-10 導入四大科；預估減少 40–50% 撰寫時間
高雄醫學大學	KMU Genie 平台	開源模型微調＋ RAG；五大虛擬助理	對話查詢數十萬次；護理紀錄撰寫時間縮短

資料來源：iThome（2024-07、2025-12）；CIO Taiwan（2026-04）。北榮 40–50% 為院方預估值。

教學重點｜注意數字的性質：「準確率」是實測，「預估減少時間」是期待——引用時要分清楚。

03

PART 3

RAG 檢索增強生成 Retrieval-Augmented Generation

讓 AI 從「憑記憶作答」變成「翻書作答」

為什麼需要 RAG； RAG 的四個步驟
提示、 RAG 、微調：三種讓 AI 更懂醫院的方法

Part 3 | 白話比喻

RAG：把閉卷考試改成開書考試

LLM 的知識有截止日，也不認識你們醫院的 SOP

閉卷（一般 LLM）

- 只能靠訓練時「背下來」的知識
- 不知道院內最新版的心衰竭照護流程
- 不會時傾向「編一個像樣的答案」
- 答案沒有出處，無法查核

開書（RAG）

- 先到指定的文件庫「找資料」
- 再根據找到的段落作答
- 找不到就說「文件中沒有」
- 每個答案附上出處頁碼

教學重點｜RAG 不保證零錯誤，但它讓錯誤「可以被追查」——這是醫療場域最需要的特性。

RAG 的四個步驟

以護理師詢問「心衰竭病人出院衛教要包含哪些項目？」為例

1	**提問**	護理師輸入問題
2	**檢索 Retrieve**	系統在院內文件庫中找出最相關的 3 至 5 段（照護指引、衛教單張）
3	**組合 Augment**	把找到的段落與問題一起交給 LLM，並要求只能依這些段落作答
4	**生成 Generate**	產生回答，並標註「出自《心衰竭照護指引》第 4 頁」
5	**維護 Maintain**	指引改版時更新文件庫——答案就會跟著更新，不必重新訓練模型

教學重點｜RAG 的品質，七成取決於「文件庫」：過期、矛盾、沒人維護的文件，會讓 AI 自信地引用錯誤內容。

Part 3 | 方法比較

提示、 RAG 、微調：讓 AI 更懂醫院的三種方法

多數醫院的實務順序：先提示 → 再 RAG → 必要時才微調

方法	比喻	適合	成本	台灣例子
提示工程 Prompting	給實習醫師一張工作說明	格式、語氣、規則	最低	本週實作二
檢索增強 RAG	讓實習醫師帶著院內手冊	院內知識、常改版的內容	中	高醫 KMU Genie
微調 Fine-tuning	讓實習醫師接受專科訓練	特定任務、特定用語	高	臺大 ICD 編碼

教學重點｜選擇原則：問題出在「不知道」用 RAG；出在「不會做」才考慮微調——微調無法解決知識過期的問題。

04

PART 4

幻覺與風險控管 Hallucination & Safety

AI 會錯，而且錯得很有自信

五種常見錯誤；臨床摘要的幻覺率實測
五道防線；隱私與資料保護； AI 使用聲明

Part 4 | 錯誤類型

AI 生成病歷的五種常見錯誤

以王伯伯的門診為例——實作二要找的就是這些

錯誤類型	定義	王伯伯的例子
捏造 Fabrication	寫出對話中沒有的內容	對話沒做聽診，病歷卻寫「兩側肺部有囉音」
遺漏 Omission	漏掉重要資訊	漏寫「夜間需墊兩個枕頭才能睡」
歸屬錯誤 Attribution	把甲說的話記成乙說的	女兒說「他偷吃鹹的」，記成病人自述
否定錯誤 Negation	把「沒有」寫成「有」	「沒有胸痛」被寫成「主訴胸痛」
過度推論 Over-inference	把討論中的選項寫成決定	醫師說「考慮調藥」，病歷寫成「已調高利尿劑」

教學重點｜這五種錯誤都「讀起來很通順」——所以只看文筆無法發現，必須逐句回到原始對話核對。

Part 4 | 實測數據

臨床摘要的幻覺有多常見?

Asgari 等（npj Digital Medicine， 2025） CREOLA 框架：臨床醫師逐句標註約 1.3 萬句病歷與近 5 萬句逐字稿

1.47%

幻覺率

191 / 12,999 句病歷

3.45%

遺漏率

1,712 / 49,590 句逐字稿

44%

幻覺屬「重大」

可能影響診斷或處置

計畫 Plan

幻覺最集中的段落

約兩成的重大幻覺出現在 P

怎麼解讀： 1.47% 看似很低，但一份病歷約 20 至 30 句——平均每 2 至 4 份病歷就可能出現一句幻覺；而且最容易錯在「計畫」，也就是最影響病人的地方。

教學重點 | 審閱病歷時，請把最多注意力放在 P （計畫）：藥物、劑量、檢查與回診安排。

Part 4 | 風險控管

五道防線：讓生成式 AI 可以安全上線

瑞士起司模型——每一層都有洞，疊起來才擋得住

① 提示限制

只依原始資料；未提及寫「未提及」

② 依據與出處

RAG 或逐句標註來源行號

③ 結構化輸出

固定欄位，方便比對與自動檢查

④ 自動檢核

第二個程式檢查數字、藥名、否定詞

⑤ 人工審閱

醫師逐句確認，簽名負責

＋ **稽核紀錄：**保留原始錄音或逐字稿、 AI 版本、醫師修改處——出事時才查得到是哪一層失守。

教學重點｜第 ⑤ 道防線最貴也最容易鬆懈： AI 越準，人越容易「看都不看就簽」——這叫自動化偏誤。

Part 4 | 隱私與資料

病人資料能不能丟進 ChatGPT？

答案取決於：部署在哪裡、合約怎麼寫、資料有沒有去識別化

部署方式	資料去向	適合情境	注意事項
免費公用版	送到廠商雲端，可能用於訓練	不得輸入任何病人資料	最常見的違規來源
企業版／醫療雲	依合約不用於訓練	去識別化資料、行政文書	審查合約、資料駐留地點
院內地端部署	不離開醫院網路	含個資的病歷生成	需算力與維運人力

台灣醫院導入生成式 AI 多選擇地端部署（如臺北榮總、高醫）；本課程實作一律使用合成資料。

教學重點｜一條底線：未經機構核准，不把可識別的病人資料貼進任何公用 AI 工具。

AI 使用聲明：本課程每次實作都要附上

透明揭露，是負責任使用生成式 AI 的第一步

項目	要寫什麼	範例
使用工具	工具名稱與版本	Claude （2026 年 10 月版）
使用方式	用 AI 做了哪些事	生成 SOAP 草稿、撰寫網頁程式碼
查核過程	如何驗證 AI 輸出	逐句對照逐字稿，修正 3 處錯誤
人工貢獻	哪些是自己的判斷	錯誤分類與改善建議為本人撰寫

教學重點｜AI 使用聲明不是自首書，而是專業紀錄——未來在醫院使用 AI，也需要同樣的紀錄習慣。

05

PART 5

國際案例 Global Case Studies

實證、事故與「意料之外」的結果

美國 UCLA： AI 代筆隨機對照試驗
Whisper 語音轉錄幻覺事件； Stanford 病人訊息 AI 草稿

國際案例｜美國・實證

UCLA Health：用隨機對照試驗檢驗 AI 代筆

2024 年 11 月至 2025 年 1 月，比較兩款商用產品與照常記錄

背景 Context

- AI 代筆產品快速擴散，但多為廠商自評
  - 醫院需要獨立、可比較的證據來做採購決策

做法 Approach

- 238 位醫師隨機分到 Microsoft DAX、Nabla 或對照組
  - 量測病歷撰寫時間、倦怠、認知負荷與錯誤
  - 結果發表於 NEJM AI（2025）

成果 Results

約 72,000

次門診納入分析

約 9.5%

Nabla 組多節省的撰寫時間

約 7%

AI 組倦怠分數改善

資料來源：UCLA Health 新聞稿（2025-11-26）；NEJM AI（2025）。

教學重點｜啟示｜醫院採購 AI 也可以做 RCT—— 用自己的資料、自己的流程驗證，勝過任何廠商簡報。

國際案例｜全球・事故

Whisper 語音轉錄：AI 會「聽到」沒人說過的話

美聯社（AP）2024 年 10 月調查報導

背景 Context

- OpenAI 的開源語音轉錄模型 Whisper 被廣泛整合到各種產品
  - 包括醫療對話轉錄工具

做法 Approach

- 研究者發現轉錄中出現憑空捏造的句子
- 例：捏造不存在的藥物「hyperactivated antibiotics」
- 部分醫療產品刪除原始錄音，無法回頭比對

成果 Results

約 8 / 10

一位研究者檢視的轉錄中出現幻覺

187 處

逾 13,000 段清晰音檔中的幻覺

約 40%

幻覺被評為有害或令人擔憂

資料來源：Associated Press（2024-10-26）報導；Koenecke 等研究。

教學重點｜啟示｜原始資料（錄音）是查核的依據——為了「資料安全」刪除錄音，反而讓錯誤永遠無法被發現。

國際案例｜美國・意料之外

Stanford： AI 回覆草稿減輕倦怠，卻沒有省時間

Stanford Health Care， 2023 年 7 至 8 月，五週試辦

背景 Context

- 病人入口網站留言量大增，成為醫師下班後的負擔
- 電子病歷廠商推出 LLM 自動擬稿功能

做法 Approach

- 為初級照護與腸胃科醫師的病人留言自動產生回覆草稿
- 醫師可採用、修改或捨棄
- 比較使用前後的問卷與系統紀錄

成果 Results

162 位

參與的臨床人員（醫師、進階執業人員、護理師等）

倦怠 ↓

工作耗竭與認知負荷下降

時間 ≈

客觀數據顯示未節省時間

資料來源： Stanford Medicine News （2024-03-20）； JAMA Network Open （2024）。

教學重點｜啟示｜ AI 的價值不一定是「省時間」，也可能是「減輕心理負擔」——成效指標要事先定清楚。

國際案例｜比較

三個案例的共同教訓

生成式 AI 的成效，常和宣傳中的「省一半時間」不一樣

案例	預期	實際	教訓
UCLA 隨機試驗	大幅節省時間	省時有限、倦怠溫和改善	用 RCT 驗證，不只看廠商數據
Whisper 轉錄	準確轉錄對話	憑空捏造句子	保留原始資料，才能查核
Stanford 訊息草稿	加快回覆	未省時，但減輕負擔	先定義成效指標
台灣醫院	減少文書時間	多為預估或滿意度	需要更多實測與公開數據

教學重點｜導入生成式 AI 的三個問題：證據從哪來？錯了查得到嗎？成功的定義是什麼？

06

PART 6

★ 實作二：門診對話→ SOAP 病歷 Hands-on Lab 2

70 分鐘：做一個「可以被查核」的病歷生成原型

擬真門診對話（合成資料）；提示範本與 Vibe Coding 指令
錯誤查核表；評分規準； AI 使用聲明

實作二： 70 分鐘完成三件事

產出：一個可運作的網頁原型＋一份錯誤查核表＋ AI 使用聲明



暖身

讀完擬真對話；先手寫你認為的 SOAP 重點

生成

用提示範本請 AI 產生 SOAP，並比較「模糊提示」的結果

網頁

用 Vibe Coding 做出：左邊貼對話、右邊出 SOAP、標出來源行號

查核

用查核表逐句核對，找出至少 3 處錯誤

繳交

截圖＋查核表＋ AI 使用聲明

教學重點｜評分重點不在網頁漂不漂亮，而在你找出的錯誤是否正確、分類是否到位。

實作二｜擬真資料（合成）

擬真門診對話：王伯伯心臟內科回診

對話為教學虛構；醫＝醫師、王＝王伯伯、女＝女兒

01 醫：王伯伯，這兩週還好嗎?

02 王：還可以啦，就是晚上比較喘。

03 女：醫師，他這三天體重多了快兩公斤，腳也比較腫。

04 醫：晚上睡覺要墊幾個枕頭?

05 王：兩個，不然躺平會喘。

06 醫：有胸痛嗎?

07 王：沒有，胸口不會痛。

08 女：他上禮拜喝喜酒，還偷吃很多鹹的。

09 醫： Furosemide 有每天吃嗎?

10 王：有啦……有時候忘記。

11 醫：血壓 148/92 ，體重 74.5 公斤。

12 醫：我先抽血看腎功能和 NT-proBNP ，

13 醫：利尿劑可能要調整，看報告再決定。

14 醫：兩週後回診，體重一天多一公斤就要先回來。

教學重點｜這段對話刻意埋了幾個「陷阱」——先別看答案，看看 AI 會不會掉進去。

SOAP 病歷四段：每段該放什麼？

以王伯伯的對話為例（參考答案方向）

S 主觀 Subjective	**病人與家屬的陳述**	夜間喘、端坐呼吸（兩個枕頭）；女兒述三天增加近 2 公斤、下肢較腫；否認胸痛
O 客觀 Objective	**量測與檢查結果**	血壓 148/92 mmHg 、體重 74.5 kg （本次未記錄理學檢查）
A 評估 Assessment	**醫師的判斷**	對話中醫師未明說——應寫「未提及」或由醫師補寫
P 計畫 Plan	**檢查、治療、追蹤**	抽血：腎功能、 NT-proBNP ；利尿劑「待報告後決定」；兩週回診；體重一天增加 1 公斤以上提早回診

教學重點｜最容易出錯的是 A： AI 常會「自己幫醫師下診斷」——但對話中醫師其實沒有說。

實作二｜提示範本

步驟一：用這份提示產生 SOAP

可直接複製使用；橘色四條規則是防幻覺的關鍵，請勿刪除

```
你是心臟內科門診的病歷文書助理。
任務：把下方門診對話整理成 SOAP 病歷草稿（繁體中文）。
規則：
1. 只能使用對話中出現的資訊，每一句後面用［行號］標註來源，例如［03］。
2. 對話中沒有的內容一律寫「未提及」，不可推測、不可補寫正常值。
3. 區分說話者：家屬說的要寫「家屬代述」。
4. 醫師「考慮中」的計畫要寫「待決定」，不可寫成已執行。
輸出：S、O、A、P 四段，最後列出「需醫師確認的項目」。
對話：〈貼上 01–14 行〉
```

教學重點｜比較練習：先用「幫我寫成病歷」跑一次，再用這份範本跑一次——把兩份結果並排截圖。

步驟二：用一段話請 AI 做出網頁原型

不需要會寫程式——把需求說清楚就好

```
請幫我做一個單一 HTML 檔的網頁：
1. 左邊是大文字框，可貼上有行號的門診對話。
2. 按「產生 SOAP」後，右邊顯示 S、O、A、P
   四個區塊（先用我提供的範例結果即可）。
3. 每句後面的［行號］做成可點擊，
   點了就把左邊對應那一行標成黃色。
4. 沒有［行號］的句子用紅底標示。
5. 介面使用繁體中文，字體大、適合長者閱讀。
```

為什麼這樣設計

- 點行號＝快速溯源
- 紅底＝可能的幻覺
- 這就是「第 ② 道防線」的介面化
- 進階：串接 AI API 自動生成

教學重點｜好的醫療 AI 介面，會讓「查核」比「盲簽」更容易——這是設計，不只是技術。

實作二｜查核表

步驟三：錯誤查核表（逐句核對）

至少找出 3 處，並寫出改正方式

#	AI 寫的句子	對照行號	錯誤類型	改正為	嚴重度
1			捏造／遺漏／歸屬／否定／過度推論		重大／輕微
2					
3					
4					

嚴重度判斷：若照著錯誤內容執行，是否可能改變診斷、用藥或回診安排？是＝重大。

教學重點｜查核表本身就是一份「AI 品質報告」的雛形——醫院導入 AI 時，也是用類似的表格做驗證。

實作二評分規準（占學期成績 10%）

重點在判斷力，不在程式技巧

構面	比重	優秀表現
提示設計	20%	包含依據與限制規則；能說明兩種提示結果的差異
原型完成度	20%	網頁可運作；行號可溯源；無出處句子有標示
錯誤查核	40%	找出 3 處以上真實錯誤；分類正確；嚴重度判斷合理
AI 使用聲明	20%	工具、用法、查核過程與人工貢獻寫得具體

教學重點｜完成不了網頁也沒關係：查核表做得好，一樣可以拿到大部分分數。

名詞小辭典 Glossary

本週名詞小辭典

中英對照，方便閱讀國際文獻

名詞	英文	白話解釋
大型語言模型	Large Language Model, LLM	以大量文字訓練、能生成文字的 AI 模型
字詞單位	Token	模型處理文字的最小單位，也是計費單位
上下文視窗	Context Window	模型一次能處理的內容長度上限
環境式臨床記錄	Ambient AI Scribe	在背景聆聽看診對話並產生病歷草稿
檢索增強生成	RAG	先檢索指定文件，再依文件內容生成回答
微調	Fine-tuning	用特定資料再訓練模型，使其擅長特定任務
幻覺	Hallucination	生成看似合理、實際錯誤或無根據的內容
自動化偏誤	Automation Bias	過度信任自動化系統而疏於查核

Summary

本週重點回顧

一頁掌握生成式 AI 的臨床應用

主題	一句話重點
原理	LLM 是超大型文字接龍：優化「像真的」，不是「是真的」
提示	角色、任務、依據、格式、限制——依據與限制最關鍵
應用	從文書開始：環境式記錄、摘要、訊息回覆、編碼、知識查詢
實證	省時有限、倦怠改善溫和；同理心高不代表正確
RAG	開書考試：答案可追溯，品質取決於文件庫
風控	五道防線＋稽核紀錄；審閱重點放在計畫（P）

教學重點｜帶走一個問題：如果你的醫院明天導入 AI 代筆，你會先設哪一道防線?

下週預告 Next Week

W7　AI Agent 與臨床流程自動化

從「幫你寫」到「幫你做」

- 聊天機器人、副駕駛、代理人：三者差在哪?
- Agent 的四個元件；單一 Agent 與多代理人架構
- 人機協作：哪些事 AI 可以自己做、哪些一定要人核准?
- 擬真案例：王伯伯出院準備的多代理人流程

課前準備

- 回想你的單位裡，最繁瑣、最常出錯的一個跨部門流程
- 列出它經過哪些人、哪些系統

教學重點｜下週沒有實作，但會用你帶來的流程做分組演練。

參考資料 References

主要參考資料

數據以原始文獻為準（查證日期： 2026 年 10 月）

World Health Organization (2024). Ethics and governance of artificial intelligence for health: Guidance on large multi-modal models.

Asgari E, et al. (2025). A framework to assess clinical safety and hallucination rates of LLMs for medical text summarisation. npj Digital Medicine.

UCLA Health (2025-11-26). UCLA study finds AI scribes may reduce documentation time and improve physician well-being； NEJM AI (2025).

Ayers JW, et al. (2023). Comparing physician and AI chatbot responses to patient questions posted to a public social media forum. JAMA Internal Medicine.

Garcia P, Ma SP, et al. (2024). AI-generated draft replies integrated into health records and physicians' electronic communication. JAMA Network Open.

Lewis P, et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS.

Weed LL (1968). Medical records that guide and teach. NEJM. （SOAP 格式起源）

Parasuraman R, Manzey DH (2010). Complacency and bias in human use of automation. Human Factors.

參考資料 References

國際與台灣案例出處

本週案例之原始來源；數據以原始文獻為準

Associated Press (2024-10-26). Researchers say an AI-powered transcription tool used in hospitals invents things no one ever said.

Stanford Medicine News (2024-03-20). AI-drafted replies to patient messages.

iThome （2024-07-15）臺大醫院生成式 AI 應用： ICD-10 編碼預測。

iThome （2025-12-04）臺北榮總智慧病歷助手導入。

CIO Taiwan （2026-04）高雄醫學大學 KMU Genie 生成式 AI 平台專訪。

CLOSING

讓 AI 執筆，讓人負責

生成式 AI 把醫師從鍵盤前解放出來；而能找出錯誤的人，才是醫療 AI 時代真正稀缺的專業。