智慧醫療與科技發展　Smart Healthcare & Technology Development

生成式 AI 與大型語言模型的臨床應用

06

Generative AI & Large Language Models in Clinical Care

第 6 週 ★ 課堂實作週
讓 AI 執筆，讓人負責：會用，更要會查核

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

開場 Opening

王伯伯回診的 15 分鐘：醫師的眼睛常停在螢幕上

生成式 AI 最先改變的，不是診斷，而是「寫字」這件事

6–10 份

住院醫師每天病程紀錄

0.5–2 小時

一份完整入院紀錄

40–50%

北榮預估減少撰寫時間

如果 AI 能代筆：醫師看著病人， AI 產生草稿，醫師審閱簽名

但 AI 若聽錯或多寫，誰發現？誰負責？

本週要回答： AI 代筆能省多少？會錯在哪？怎麼設計才能放心用？

學習目標 Learning Objectives

本週結束時，你能做到什麼

四個可檢核的學習目標

C1	說明 LLM 文字接龍原理，以及 Token 、上下文視窗、溫度的影響。
C3	依實證判斷 AI 代筆與訊息回覆的效益與限制。
C2	比較提示工程、 RAG 、微調的適用情境。
C2 • C3	依原文逐句查核固定草稿，並做一次受控比較。

課堂產物：固定草稿查核表、受控比較紀錄、溯源呈現與 AI 使用紀錄。

本週地圖 This Week

本週的五個問題

前半段建立判斷力，後半段動手做出可以被查核的原型

PART 1　LLM 原理
怎麼寫出文字？為什麼會寫錯？

→

PART 2　應用與實證
醫院用在哪？真的省時間嗎？

→

PART 3　RAG
怎麼依院內文件回答並附出處？

→

PART 4　幻覺與風控
會錯在哪？要設幾道防線？

→

PART 5　實作二
查核固定草稿，再做受控比較

講授約 20 分鐘：建立判斷力

驗證練習 80 分鐘

講授約 20 分鐘（Part 1–4 重點頁）→ 課內驗證練習約 80 分鐘（Part 5）。

01

PART 1

LLM 怎麼運作 How Large Language Models Work

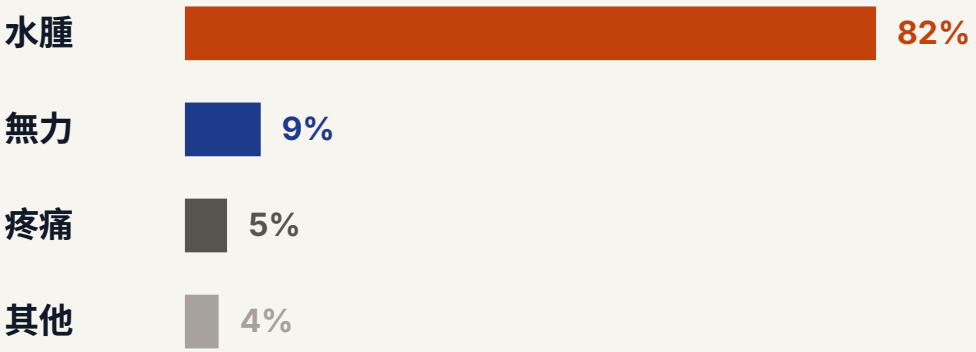
不懂原理，就看不懂它為什麼會犯錯

文字接龍、三個旋鈕、生成式與預測式、提示工程

LLM 的本質：超大型文字接龍

依前文預測最可能的下一個 Token，再接著往下寫

王伯伯近三天體重增加兩公斤，伴隨下肢 ____



機率為教學示意

不是查資料庫

依語言規律生成最順的句子

所以很會寫

文法流暢、語氣專業

也所以會錯

聽起來合理，不等於事實正確

LLM 優化的是「像真的」，不是「是真的」：查核永遠不能省。

Token 、上下文視窗、溫度：影響輸出的三個旋鈕

用一位實習醫師來比喻

Token

王伯 | 伯體 | 重增 | 加

切分方式為示意

白話

模型處理文字的單位；計費與長度都以它計

臨床提醒

中文換算依模型而異；長病歷注意截斷

上下文視窗



讀得到 | 讀不到

白話

一次能讀進的內容量，像能翻閱的病歷頁數

臨床提醒

太長會漏讀；重要資訊放前面或分段

溫度



低：病歷　　高：發想

白話

回答的隨機程度

臨床提醒

病歷用低溫求一致；衛教標語可稍高

臨床文書：低溫度、明確格式、只依提供的內容作答。

生成式 AI 與預測式 AI：一個寫、一個算

延伸閱讀： W5 的再入院模型是預測式；本週的 SOAP 生成是生成式



AUROC 、校準度等固定指標	評估	正確性、完整性、安全性；常需人工評閱
預測不準、族群偏誤	典型錯誤	幻覺、遺漏、歸屬錯誤
多以醫療器材軟體審查	監管	文書用途多不屬醫材；臨床建議可能屬醫材
模型驗證與監測	導入重點	使用規範、人工審閱、稽核紀錄

同一家醫院可能同時用兩種 AI，驗證、法規與治理方式都不同。

好提示的五要素

實作二的基本功；依據與限制最關鍵

角色	「你是心臟內科門診的病歷文書助理」
任務	「把以下門診對話整理成 SOAP 病歷草稿」
依據	「只能使用對話中出現的資訊，每句標註行號」
格式	「分 S、O、A、P 四段」
限制	「沒提到的寫『未提及』，不可推測或補寫」

依據與限制兩項，直接決定幻覺的多寡。

Part 1 | 提示對照

同一個需求，兩種寫法

差別不在字數，而在有沒有把醫療規則寫進去

模糊提示：「幫我把這段對話寫成病歷」	結構化提示（五要素）
× 格式每次不同，難以比較	✓ 固定 S、O、A、P 四段
× 自行補上「理學檢查正常」	✓ 沒提到的寫「未提及」
× 家屬的話記成病人自述	✓ 家屬說的標「家屬代述」
× 看不出每句來源	✓ 每句有［行號］可逐句核對

實作二會用同一段對話比較兩種提示，親眼看到「多一行限制」的差別。

02

PART 2

臨床應用與實證 Applications & Evidence

從代筆、回訊息，到編碼與知識查詢

WHO 五大用途、六類應用、環境式記錄、實證研究、台灣導入

WHO 歸納大型多模態模型的五大醫療用途

延伸閱讀： WHO 2024 年 1 月指引，提出 40 多項建議

風險較低 → 越靠近診斷與病人自主使用，風險越高、驗證越嚴

行政文書
記錄與摘要就診內容
風險：相對低（本週重點）

研究與藥物開發
找出候選化合物
風險：依用途而定

醫護教育訓練
模擬病人對話練習
風險：中

病人自主使用
查詢症狀與治療資訊
風險：高

診斷與臨床照護
回答病人書面提問
風險：高

越靠近診斷與病人自主使用，風險越高、驗證要求越嚴格。

生成式 AI 在醫院的六類應用

延伸閱讀：依使用者與直接影響病人的程度排列

低中：內部使用	中：須專業審閱	中高：直達病人
疾病分類編碼 病歷管理師；影響申報	**環境式臨床記錄** 門診對話 → SOAP 草稿	**病人訊息回覆** 入口網站留言回覆草稿
院內知識查詢 全院； RAG 查 SOP ，須附出處	**病歷摘要** 可能遺漏病史	
	衛教內容生成 衛教師審定後給病人	

多數醫院從左邊開始，累積信任後才往右擴大

多數醫院從低中風險、內部使用開始，累積信任後才擴大到直接面對病人。

Ambient AI Scribe 怎麼運作

醫師專心看診， AI 在背景聽並產生病歷草稿

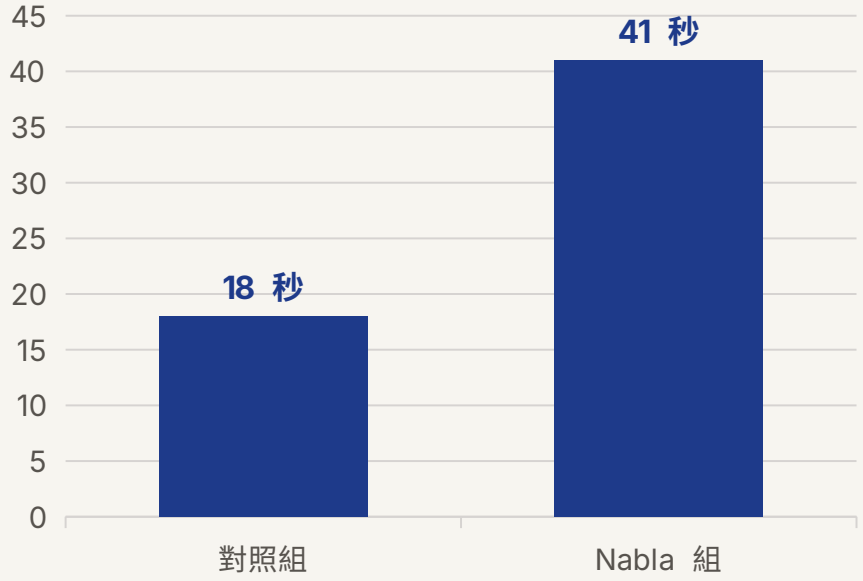


同意	告知病人並取得同意；說明錄音保存與刪除方式。
轉錄	台語、口音、多人對話都會影響正確率。
審閱	醫師是最後一道防線，也是法律上的負責人。
記錄	保留 AI 版本與修改紀錄，供稽核。

風險集中在轉錄與審閱：轉錄錯了後面全錯；沒看就簽，錯誤就成了正式病歷。

隨機對照試驗： AI 代筆省多少時間

UCLA Health： 238 位醫師、 14 個專科、約 72,000 次門診（NEJM AI, 2025）



省時 Nabla 相對對照組約 9.5%； DAX 未達統計顯著

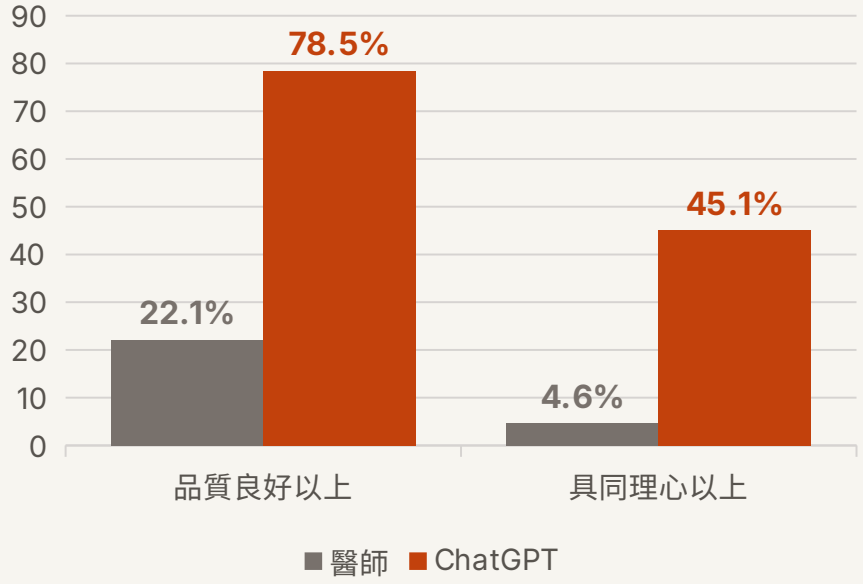
倦怠 兩個 AI 組約改善 7%

錯誤 偶有臨床上重要的不正確； 1 件輕微病安事件

比宣傳低調：省時有，但不大；倦怠改善溫和。

AI 回覆病人提問：更有同理心，卻不一定省時

延伸閱讀：兩個常被引用的研究，結論要放在一起看



Ayers 等 2023

195 則網路論壇提問；比較對象是醫師在論壇的簡短回覆。

Garcia 等 2024

162 位臨床人員使用回覆草稿：倦怠與負荷下降，但未節省時間。

寫得更暖不代表更對；審閱草稿也要時間，效益要在真實流程量測。

Part 2 | 台灣

台灣醫院的生成式 AI 導入

延伸閱讀：共同點：模型部署在院內、醫師最後審閱、從文書開始

臺大醫院	臺北榮總	高雄醫學大學
ICD-10 編碼預測 開源 LLM 以院內資料微調	**智慧病歷助手** 地端模型產生入院、病程、出院摘要草稿； 2025-10 導入四大科	**KMU Genie 平台** 開源模型微調＋ RAG
全碼 86.67%、主診斷 82%	**預估減少 40–50% 撰寫時間**	**護理紀錄撰寫時間縮短**
數字性質：實測	**數字性質：預估**	**數字性質：院方說明**

分清數字性質：準確率是實測，預估減少時間是期待。

Part 2 | 實證整理

宣傳與實證：成效常和「省一半時間」不同

依本週引用資料整理

來源	常見期待	實際觀察	啟示
UCLA 隨機試驗	大幅節省時間	省時有限、倦怠溫和改善	用自己的流程驗證
Stanford 試辦	加快回覆	未省時，但減輕負擔	先定義成效指標
台灣醫院	減少文書時間	多為預估或院方說明	需要更多實測與公開數據

導入前先問：證據從哪來？成功的定義是什麼？

Part 2 | 國際實證

環境式 AI 記錄的早期評估：減輕倦怠，財務效益未明

Peterson Health Technology Institute （2025-03）： 8 家醫療體系、 10 家廠商的導入資料

✓ **倦怠與認知負擔　證據較一致：下降**
例： Mass General Brigham 6 週試辦，自評倦怠相對下降 40% （n = 223）

△ **下班後寫病歷時間　結果不一**
有些體系下降，有些看不出差異

× **財務投資報酬　目前未見明顯回報**
看診量多未增加；帳務改善只在部分體系

i **草稿保留率　醫師保留約 80% 草稿內容**
Yale New Haven Health 數據；其餘仍需修改

成效要分開量：負擔、時間、財務、品質；只看一項會高估或低估。

Part 2 ｜原文評讀

用證據表讀 UCLA 試驗：能支持什麼、不能支持什麼

與 W12 MASAI 證據表同一套欄位；課前讀原文摘要與結果表，課堂 5 分鐘對答

欄位	UCLA AI 代筆試驗（NEJM AI 2025）
研究問題	AI 代筆能否減少醫師寫病歷的時間與倦怠?
設計與比較	以醫師為單位隨機分三組： Nabla 、 DAX 、一般書寫； 238 位、 14 科
效果與不確定性	Nabla 每份少約 41 秒（對照少 18 秒），差異顯著； DAX 未達顯著
偏誤與限制	單一醫學中心、 2024/11–2025/1 約 2–3 個月；倦怠改善小；偶有臨床上重要的錯誤
適用性（台灣）	語言、口音、台語與門診量都不同，需在地測試
下一步驗證	本院試辦：記錄書寫時間、修改率、錯誤與病人拒絕率

「省時 9.5% 」是相對對照組多省的比例，每份約多省 23 秒；不能寫成「省一半時間」。

03

PART 3

RAG 檢索增強生成 Retrieval-Augmented Generation

讓 AI 從憑記憶作答，變成翻書作答

閉卷與開書、 RAG 步驟、提示、 RAG 與微調的比較

Part 3 ｜白話比喻

RAG： 把閉卷考試改成開書考試

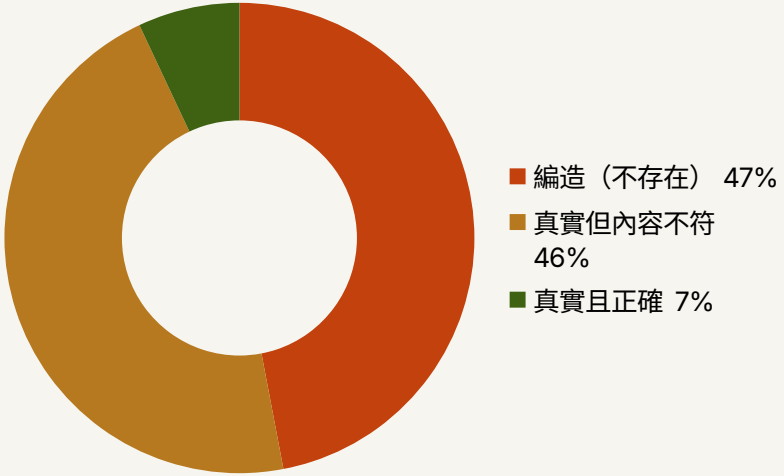
LLM 的知識有截止日，也不認識你們醫院的 SOP

閉卷：一般 LLM	開書： RAG
記憶 → 訓練時背下的知識（有截止日、不認識院內 SOP ）	文件庫 → 先到指定文件庫找段落（院內最新版照護流程）
不會時傾向編一個像樣的答案	找不到時可要求回答「文件中沒有」
出處：沒有，無法查核	出處：《心衰竭照護指引》第 4 頁

RAG 不保證零錯誤，但讓錯誤可以被追查。

沒有出處的 AI，連參考文獻都會編

Bhattacharyya 等（Cureus 2023）： ChatGPT-3.5 撰寫 30 篇醫學短文、產生 115 筆參考文獻



九成三有問題
47% 編造＋ 46% 內容不符；只有 7% 真實且正確

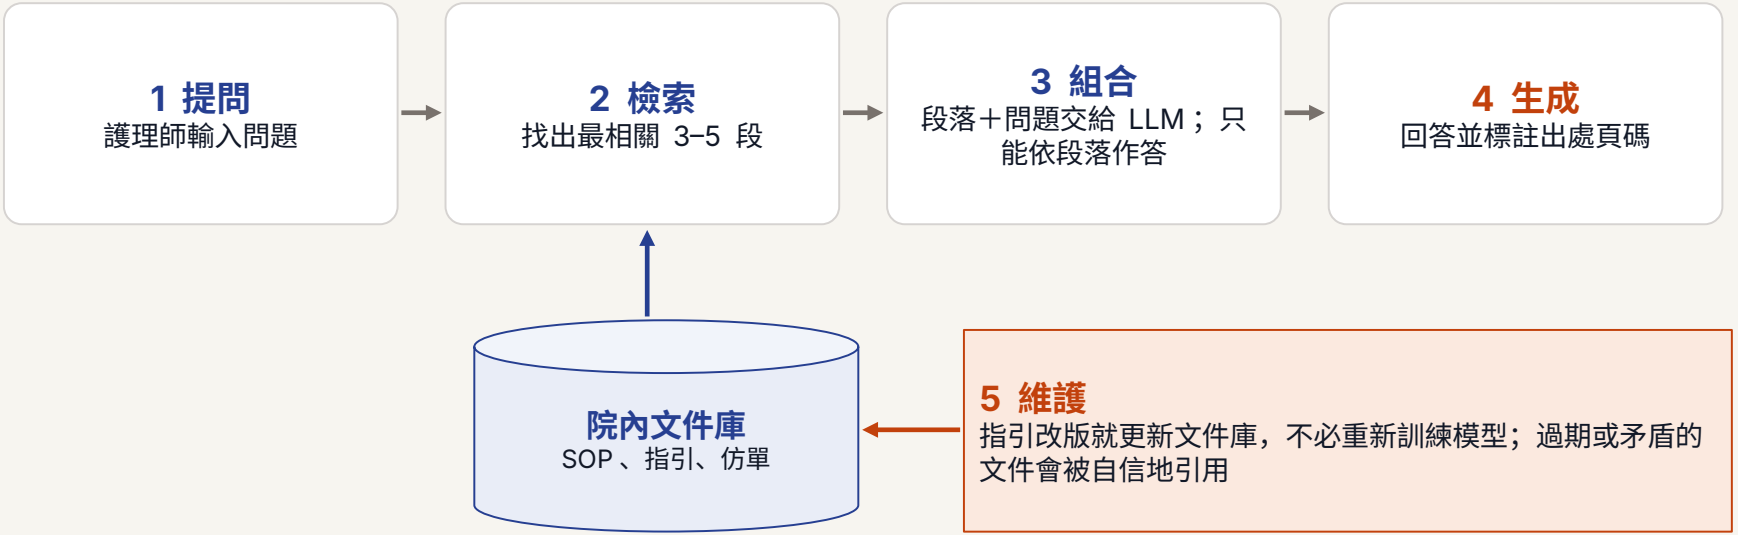
為什麼
模型生成「像文獻的格式」，不是去資料庫查

限制
2023 年舊版模型；新模型與 RAG 會改善，但仍要核對

能附出處還不夠，出處本身也要點開核對：這正是 RAG 與溯源介面的價值。

RAG 的步驟

以護理師詢問「心衰竭出院衛教要包含哪些項目？」為例



例：「心衰竭出院衛教要包含哪些項目？」

RAG 的品質很大程度取決於文件庫：過期、矛盾的文件會被自信地引用。

提示、 RAG 、微調：讓 AI 更懂醫院的三種方法

延伸閱讀：實務順序：先提示 → 再 RAG → 必要時才微調

成本與門檻：由低到高

提示工程

給實習醫師工作說明
適合：格式、語氣、規則
成本：最低　例：本週實作二

RAG

讓實習醫師帶院內手冊
適合：院內知識、常改版內容
成本：中　例：高醫 KMU Genie

微調

讓實習醫師接受專科訓練
適合：特定任務、特定用語
成本：高　例：臺大 ICD 編碼

問題出在不知道，用 RAG ；出在不會做，才考慮微調。

04

PART 4

幻覺與風險控管 Hallucination & Safety

AI 會錯，而且錯得很有自信

五種錯誤、幻覺率實測、 Whisper 事件、五道防線、隱私

AI 生成病歷的五種常見錯誤

以王伯伯的門診為例；實作二要找的就是這些

	原始對話		AI 草稿寫成
捏造	沒有做聽診	→	兩側肺部有囉音
遺漏	睡覺要墊兩個枕頭	→	（沒寫）
歸屬錯誤	女兒說「他偷吃鹹的」	→	病人自述吃得較鹹
否定錯誤	「沒有胸痛」	→	主訴胸痛
過度推論	「考慮調藥，看報告再決定」	→	已調高利尿劑

五種錯誤都讀起來很通順：只看文筆抓不到，必須逐句回到原始對話。

臨床摘要的幻覺有多常見

Asgari 等（2025）：臨床醫師逐句標註約 1.3 萬句摘要與近 5 萬句逐字稿

1.47%

幻覺率（191 / 12,999 句）

3.45%

遺漏率（1,712 / 49,590 句）

44%

幻覺屬重大（84 / 191）

重大幻覺最多出現在計畫（P），約 21%

一份摘要約 20–30 句：平均每 2–4 份就可能有一句幻覺。

審閱時把最多注意力放在 P：藥物、劑量、檢查與回診安排。

Whisper 語音轉錄： AI 會聽到沒人說過的話

美聯社 2024 年 10 月調查報導

約 8 / 10

一位研究者檢視的轉錄出現幻覺

187 處

逾 13,000 段清晰音檔中的幻覺

近 40%

幻覺被評為有害或令人擔憂

例：捏造不存在的藥物「hyperactivated antibiotics」

部分醫療產品刪除原始錄音，錯誤無法回頭比對。

原始資料是查核的依據：為了資料安全刪除錄音，錯誤就永遠無法被發現。

五道防線：讓生成式 AI 可以安全上線

瑞士起司模型：每一層都有洞，疊起來才擋得住

① 提示限制

只依原始資料；未提及寫「未提及」

② 依據與出處

RAG 或逐句標註行號

③ 結構化輸出

固定欄位，方便比對

④ 自動檢核

程式檢查數字、藥名、否定詞

⑤ 人工審閱

醫師逐句確認，簽名負責

＋ **稽核紀錄：**保留原始錄音或逐字稿、 AI 版本、醫師修改處，出事時才查得到哪一層失守。

第 ⑤ 道最貴也最容易鬆懈： AI 越準，人越容易沒看就簽（自動化偏誤）。

聊天機器人說錯話，機構要負責

Moffatt v. Air Canada （加拿大 BC 民事仲裁庭， 2024-02-14 ）

1. **聊天機器人說**
   親人過世可先買票， 90 天內再申請喪親優惠
2. **實際政策**
   旅程結束後不能再申請
3. **航空公司主張**
   機器人是「獨立法律實體」，自己負責
4. **仲裁結果**
   駁回；公司要為網站上所有資訊負責，判賠約 650 加幣與利息、規費

回到醫院

衛教機器人答錯回診規則，誰負責?

回覆草稿沒看就送出，誰負責?

對策：第 ⑤ 道人工審閱＋稽核紀錄

對外的 AI 回答就是機構的回答：醫院的衛教機器人、回覆草稿也一樣。

病人資料能不能丟進 ChatGPT

取決於部署方式、合約與是否去識別化

醫院資料 →

免費公用版

紅

資料去向
送到廠商雲端，可能用於訓練

適合
不得輸入任何病人資料

注意
最常見的違規來源

企業版／醫療雲

黃

資料去向
依合約不用於訓練

適合
去識別化資料、行政文書

注意
審查合約與資料駐留

院內地端部署

綠

資料去向
不離開醫院網路

適合
含個資的病歷生成

注意
需算力與維運人力

底線：未經機構核准，不把可識別的病人資料貼進任何公用 AI 工具。

05

PART 5

★ 實作二：門診對話 → SOAP 病歷 Hands-on Lab 2

80 分鐘：先查核固定草稿，再做受控比較

擬真對話、固定草稿、查核表、提示範本、受控比較、溯源呈現、 AI 使用紀錄

實作二： 80 分鐘的課內驗證練習

產出：固定材料查核表、受控比較紀錄、溯源呈現、 AI 使用紀錄



A 固定查核	全班查核同一份教師預製草稿：逐句判定，找出遺漏。
B 受控比較	同一段對話、同一工具，只換提示，兩份輸出都保留。
溯源呈現	網頁原型或標註文件擇一，能把每句對回行號。
討論	小組比對判定；有依據的異議可以提出。

評分看判定對不對、有沒有依據；沒找到錯誤不扣分，把正確句判成錯誤會扣分。

實作二｜擬真資料（合成）

擬真門診對話：王伯伯心臟內科回診

教學虛構；醫＝醫師、王＝王伯伯、女＝女兒

01 醫：王伯伯，這兩週還好嗎？

02 王：還可以啦，就是晚上比較喘。

03 女：醫師，他這三天體重多了快兩公斤，腳也比較腫。

04 醫：晚上睡覺要墊幾個枕頭？

05 王：兩個，不然躺平會喘。

06 醫：有胸痛嗎？

07 王：沒有，胸口不會痛。

08 女：他上禮拜喝喜酒，還偷吃很多鹹的。

09 醫：Furosemide 有每天吃嗎？

10 王：有啦……有時候忘記。

11 醫：血壓 148/92，體重 74.5 公斤。

12 醫：我先抽血看腎功能和 NT-proBNP，

13 醫：利尿劑可能要調整，看報告再決定。

14 醫：兩週後回診，三天內體重多超過兩公斤就要先回來。

這段對話刻意埋了幾個陷阱：先別看答案，看看 AI 會不會掉進去。

SOAP 病歷四段：每段該放什麼

Weed （1968）提出的問題導向病歷格式

S 主觀

放什麼
病人與家屬的陳述
這次特別注意
誰說的？家屬代述要標明

O 客觀

放什麼
量測與檢查結果
這次特別注意
沒做的檢查不能寫

A 評估

放什麼
醫師的判斷
這次特別注意
醫師有說嗎？沒說就寫「未提及」

P 計畫

放什麼
檢查、治療、追蹤
這次特別注意
「考慮」與「已執行」要分清

最容易出錯的是 A： AI 常自己幫醫師下診斷，但對話中醫師其實沒說。

固定材料：教師預先產生的 SOAP 草稿

全班查核同一份草稿；有對有錯，也可能漏寫

#	段	AI 草稿句子
1	S	病人自述夜間較喘［02］
2	S	病人自述三天內體重增加近 2 公斤、下肢較腫［03］
3	S	需墊兩個枕頭，躺平會喘［05］
4	S	主訴胸痛［06–07］
5	S	家屬代述上週喝喜酒後吃得較鹹［08］
6	S	規則服用 Furosemide ［10］
7	O	血壓 148/92 mmHg、體重 74.5 kg ［11］

#	段	AI 草稿句子
8	O	心跳每分鐘 88 次［11］
9	O	雙下肢凹陷性水腫 2+
10	O	肺部聽診：未提及
11	A	急性心衰竭惡化
12	P	抽血：腎功能、 NT-proBNP ［12］
13	P	已調高 Furosemide 劑量［13］
14	P	一週後回診［14］

逐句回到原始對話判定；也要檢查原文有、草稿沒寫的重要資訊。

步驟一：逐句判定固定草稿

14 句都要判定；判錯正確句子會扣分

#	判定	依據行號	錯誤類型	改正為	嚴重度
1	正確／錯誤／無法確認		捏造／歸屬／否定／過度推論		重大／輕微
2					
…					
遺漏	原文有、草稿沒寫：		遺漏		

嚴重度：照著錯誤內容執行，是否可能改變診斷、用藥或回診安排？是＝重大。數字、時間與原文不符歸為捏造。

評分看判定是否正確、依據是否清楚，不看找到幾個錯誤。

步驟二：用這份提示產生 SOAP

可直接複製；四條規則是防幻覺的關鍵，請勿刪除

```
你是心臟內科門診的病歷文書助理。
任務：把下方門診對話整理成 SOAP 病歷草稿（繁體中文）。
規則：
1. 只能使用對話中出現的資訊，每句後面用［行號］標註來源，例如［03］。
2. 對話中沒有的內容一律寫「未提及」，不可推測、不可補寫正常值。
3. 區分說話者：家屬說的要寫「家屬代述」。
4. 醫師「考慮中」的計畫要寫「待決定」，不可寫成已執行。
輸出：S、O、A、P 四段，最後列出「需醫師確認的項目」。
對話：〈貼上 01–14 行〉
```

對照組：同一段對話只輸入「幫我寫成病歷」；兩份原始輸出全文都保留。

受控比較：一次只改一件事

比較的是提示的差別，不是哪個模型比較強

固定	同一段對話 01–14 、同一工具、同一天執行。
只改	提示：模糊提示 vs 範本提示。
記錄	兩份原始輸出全文、提示全文、執行日期與工具名稱。
比較	用同一張查核表，看否定、說話者、未提及、待決定各處理得如何。
限制	一次比較只代表本次小樣本觀察，不代表模型已通過驗證。

多跑幾次就全部保留，不挑最好的一次代表整體；沒有工具時用教師提供的成對輸出。

步驟三：讓每句都對得回原文（擇一）

網頁原型或標註文件都可以；網頁只是展示，不是串接臨床系統

```
請幫我做一個單一 HTML 檔的網頁：
1. 左邊是大文字框，可貼上有行號的門診對話。
2. 按「顯示 SOAP」後，右邊顯示 S、O、A、P
   四個區塊（貼上 B 部分範本提示的輸出即可）。
3. 每句後面的［行號］可點擊，
   點了就把左邊對應那一行標成黃色。
4. 沒有［行號］的句子用紅底標示。
5. 繁體中文、大字體。
```

點行號	快速溯源
紅底	可能的幻覺
替代	標註文件：句子旁寫行號
延伸	串接 API 自動生成，不計分

網頁用預先產生的結果，屬展示原型；做不出網頁，用標註文件呈現同樣算分。

AI 使用紀錄：讓別人能重做一次

延續 W1 課程規範；工具、輸入、輸出與人工修訂都要留下

項目	要寫什麼	範例
工具與模型	工具名稱；介面有顯示才寫模型名稱	Claude （介面顯示的模型名稱）
日期與提示	執行日期、兩份提示全文	附件一：模糊提示；附件二：範本
輸入與輸出	輸入的對話、每次原始輸出全文	附件三、四：兩份原始輸出
人工修訂	改了什麼、依據哪一行	第 13 句依［13］改為「待決定」
未提供的設定	照實寫「介面未提供」	溫度：介面未提供

不知道的設定照實寫「介面未提供」；自行編造版本或參數，比沒寫更糟。

實作二評分規準

占學期成績 10%；重點在判斷力，不在程式技巧或工具

構面	比重	優秀表現
查核正確與理由	40%	固定草稿判定正確、引用行號；找出遺漏；類型與嚴重度合理
受控比較設計	20%	同輸入、只換提示；能說明差異來自哪一條規則
比較證據與紀錄	20%	兩份原始輸出、提示、日期、工具齊全；不挑最好的一次
溯源呈現	10%	網頁或標註文件能逐句對回行號；標明展示原型
個人說明	10%	能口頭解釋自己的一個判定或比較結果

沒找到錯誤不扣分，判錯正確句子會扣分；不看網頁美觀，也不看是否用付費工具。

案例研討 Case Study ｜美國

Tessa 聊天機器人：廠商加上生成式 AI 之後

美國飲食疾患協會（NEDA）； NPR 2023-06-08 報導

研發	華盛頓大學團隊以 NEDA 經費開發；原為規則式，只用有限的預寫回應
2022	營運廠商 Cass 「系統升級」，加入生成式 AI 功能； NEDA 表示未被告知
2023-03	NEDA 宣布轉向 AI 輔助， Tessa 作為全自動資源；同期關閉運作逾 20 年的人工熱線
2023-05-30	使用者公開截圖： Tessa 給出減重建議； NEDA 不到 24 小時下架

決策點 Decision Point

你是機構負責人：規則式版本有研究支持，升級成生成式後，還能沿用那份證據嗎？

先獨立想 1 分鐘，寫下你的選擇與理由，再看下一頁。

同一個名字、同一個介面，底層從規則式換成生成式，風險型態就完全不同。

結果：問題出在變更管理，不只出在模型

美國飲食疾患協會（NEDA）； NPR 2023-06-08 報導

逾 20 年
同期被關閉的人工熱線

< 24 小時
收到截圖到下架

1 次升級
從規則式變生成式，證據不再適用

原本做對的

- 原版本邊界明確：只用專家預寫內容
- 有研究團隊參與設計
- 發現問題後快速下架

出問題的地方

- 廠商變更未經機構審核
- 以 AI 取代人工熱線，服務定位混淆
- 高風險族群上線前缺少紅隊測試

生成式 AI 的風險，也在「誰可以改、改了要不要重審」；變更管理是防線的一部分。

案例研討｜課堂討論

討論：把本週的框架用在這個案例

三題擇一深入；先寫判斷，再寫證據與限制

Q1 **Tessa 改成生成式後，本週五種錯誤類型中最可能出現哪幾種？**
連結本週：錯誤類型

Q2 **用五道防線檢視：哪一道本來可以攔下這次事件？**
連結本週：五道防線

Q3 **醫院導入 AI 衛教機器人，合約要寫進哪些「變更須通知與重審」條款？**
連結本週：誰負責

課堂進行約 15 分鐘
① 個人閱讀與作答　3 分鐘
② 小組討論，選一題深入　8 分鐘
③ 兩組分享、教師回饋　4 分鐘

出處
NPR 2023-06-08 （06-09 更新）
完整連結見講者備註

沒有標準答案：好答案會說清楚判斷、依據的證據，以及還缺什麼。

Summary

本週帶走的三個問題

用同一套方法，評估下一個生成式 AI 工具

依據在哪	AI 寫的每一句，能回到原始資料或文件嗎?
錯在哪裡	捏造、遺漏、歸屬、否定、過度推論，最常在 P？
誰來把關	五道防線設了哪幾道？審閱的人會不會沒看就簽?

帶走一個問題：你的醫院明天導入 AI 代筆，你會先設哪一道防線?

名詞小辭典 Glossary

本週名詞小辭典

延伸閱讀：相關名詞的白話意義與使用界線

名詞	白話解釋
大型語言模型 LLM	以大量文字訓練、能生成文字的 AI 模型
上下文視窗	模型一次能處理的內容長度上限
環境式臨床記錄	在背景聆聽看診對話並產生病歷草稿
檢索增強生成 RAG	先檢索指定文件，再依文件內容生成回答
幻覺 Hallucination	生成看似合理、實際錯誤或無根據的內容
自動化偏誤	過度信任自動化系統而疏於查核

英文名詞方便查找國際文獻；使用時注意定義。

下週預告 Next Week

下週： AI Agent 與臨床流程自動化

從「幫你寫」到「幫你做」

三種形態	聊天機器人、副駕駛、代理人：差在哪?
架構	Agent 的元件；單一 Agent 與多代理人。
人機協作	哪些事 AI 可以自己做、哪些一定要人核准?
擬真案例	王伯伯出院準備的多代理人流程。
課前準備	想一個單位裡最繁瑣、最常出錯的跨部門流程。

下週沒有實作，但會用你帶來的流程做分組演練。

延伸學習：生成式 AI 的課程與指引

課後自學用，不列入評量；練習時只用合成或公開資料

DeepLearning.AI × Coursera
Generative AI for Everyone
吳恩達的入門課；不需程式
對應 Part 1

Microsoft
Generative AI for Beginners
GitHub 開放課程，含 RAG 單元
對應 Part 3

Anthropic ／ OpenAI
官方提示工程指南
角色、範例、格式與限制的寫法
對應提示五要素

WHO （2024）
大型多模態模型倫理與治理指引
五大用途與 40 多項建議
對應 Part 2

Asgari 等（2025）
臨床摘要安全與幻覺評估框架
npj Digital Medicine；逐句標註方法
對應 Part 4

PHTI （2025）
AI 環境式記錄早期評估報告
八家醫療體系、十家廠商的導入資料
對應實證頁

先學原理與風險，再練提示；任何練習都不要貼真實病人資料。

參考資料 References

核心參考資料

完整連結見講者備註

WHO （2024）	Guidance on large multi-modal models
Asgari 等（2025）	臨床摘要的安全與幻覺率框架， npj Digit Med
UCLA （2025）	AI scribes 隨機對照試驗， NEJM AI
Ayers； Garcia	病人訊息回覆研究（2023； 2024）
Lewis 等（2020）	Retrieval-augmented generation， NeurIPS
台灣案例	iThome 臺大（2024）、北榮（2025）； CIO Taiwan 高醫（2026）

數字要分清實測、預估與院方說明。

CLOSING

讓 AI 執筆，讓人負責

生成式 AI 把醫師從鍵盤前解放出來；
能找出錯誤的人，才是醫療 AI 時代真正稀缺的專業。