智慧醫療與科技發展　Smart Healthcare & Technology Development

臨床決策支援與預警系統

08

Clinical Decision Support & Early Warning Systems

第 8 週｜醫療 AI 技術與臨床應用　Unit 2
CDS 是什麼 → 早期預警 → 警示疲勞 → 資料集偏移 → 人機協作 → Epic 敗血症模型案例

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

本週地圖 This Week

本週六個部分

從「給建議」到「發警示」，再到「為什麼會失準」與「人怎麼和 AI 一起決策」

01

CDS 是什麼

CDS Basics

定義、五個對、形式與法規

02

早期預警

Early Warning

NEWS2 、 AI 預警、應變系統

03

警示疲勞

Alert Fatigue

數據、惡性循環、PPV

04

資料集偏移

Dataset Shift

三種偏移、本地驗證、監測

05

人機協作

Human–AI

自動化偏誤、協作模式、介面

06

案例與演練

Cases

Epic 敗血症模型、TREWS 、 Kaiser

W5 學了「模型準不準」，本週要問的是：模型上線後，「照護有沒有變好」。

學習目標 Learning Objectives

本週結束時，你能做到什麼

四個可檢核的學習目標

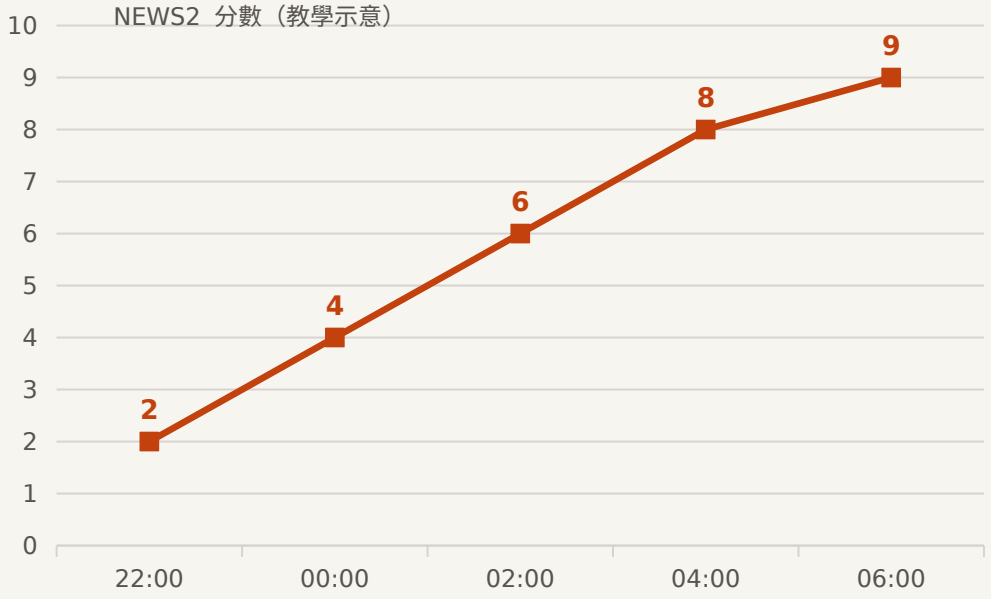
C2	以 CDS 「五個對」檢視一則臨床警示。
C2	計算 NEWS2 ，說明預警是一套「偵測—應變」系統。
C3	以 PPV 與 NNE 估算警示負擔，提出降低警示疲勞的設計。
C3	辨識資料集偏移，規劃本地驗證、靜默測試與上線監測。

課堂產物：閾值選擇與工作量估算，以及試辦、停用與升級處理條件。

開場 Opening

王伯伯住院第 3 天，凌晨的生命徵象慢慢變差

所有數據都在系統裡——為什麼直到早上 6 點才啟動快速應變小組?



02:00 的現場

- 呼吸 24 次／分、 SpO_2 93%
- 心跳 108 、收縮壓 102
- **NEWS2 = 6，已達「緊急評估」**
- 夜班護理師照顧 12 床
- 當晚全病房已響過 37 次警示

問題不在「沒有資料」，而在「訊號被淹沒」——這就是臨床決策支援要解決的事。

01

PART 1

臨床決策支援是什麼 Clinical Decision Support

把對的知識，在對的時間送到對的人手上

定義與 CDS 五個對；CDS 的常見形式
規則型 vs 機器學習型；美國 FDA 2026 年 CDS 指引

Part 1 | 定義

臨床決策支援（CDS）的定義與「五個對」

Osheroff 等（2007）：在適當時機，提供經過篩選、與個人相關的知識，以改善健康與照護

01

對的資訊

Right information

有實證、可行動，例如「建議抽血培養」

02

對的人

Right person

醫師、護理師、藥師或病人本人

03

對的格式

Right format

警示、醫囑套組、儀表板

04

對的管道

Right channel

EHR 畫面、手機、中央監測站

05

對的時機

Right time

在決策當下，不早也不晚

五個對少一個，CDS 就容易變成噪音——例如對的資訊，在錯的時機跳給錯的人。

CDS 不只有「跳出警示」：六種常見形式

警示最常見，但往往不是最有效的形式

打斷程度 ◀ 高 打斷式 | 嵌入流程 | 被動顯示 | 需要時查 低 ▶

警示與提醒 Alerts
條件成立時主動通知

王伯伯：腎功能變差 → 提醒調整劑量

醫囑套組 Order sets
把最佳實務預先組好

王伯伯：心衰竭入院標準醫囑一鍵開立

文件範本 Templates
引導完整記錄

王伯伯：出院準備評估表必填欄位

風險分數 Risk scores
計算並顯示風險

王伯伯： NEWS2 、再入院風險分數

儀表板 Dashboards
一次看全病房狀態

王伯伯：護理站依惡化風險排序各床

資訊按鈕 Infobuttons
需要時才查

王伯伯：點藥名即顯示腎功能調整建議

設計原則：能用「預設選項」或「儀表板」解決的，就不要用「打斷式警示」。

規則型 vs 機器學習型 CDS

知識從哪裡來，決定了透明度與維護方式（呼應 W2 的 AI 方法比較）

規則型 Knowledge-based

- 知識來源：專家寫的「若…則…」規則
- 例：腎絲球過濾率 < 30 → 提醒停用 Metformin
- 優點：透明、可解釋、易稽核
- 限制：規則越寫越多、彼此衝突
- 維護：指引更新就要改規則

機器學習型 Non-knowledge-based

- 知識來源：從歷史資料學出規律
- 例：以數十項變數預測 12 小時內惡化
- 優點：能抓到人寫不出的複雜模式
- 限制：可能是黑箱、會隨環境失準
- 維護：要持續監測與再訓練

兩者常混合使用： AI 算風險，規則決定「分數多少、通知誰、做什麼」。

哪些 CDS 不算醫療器材？美國 FDA 的四個條件

FDA《臨床決策支援軟體指引》2026 年 1 月 6 日修訂版，取代 2022 年版

關卡 ①	關卡 ②	關卡 ③	關卡 ④
不分析影像、訊號或波形 不直接讀影像或心電圖波形	**顯示、分析或列印醫療資訊** 處理的是病歷等資訊	**對專業人員提供建議** 對象是專業人員，不是病人	**專業人員能獨立檢視依據** 醫師看得懂「為什麼」

四關全過
非醫療器材 CDS

任一關不過
走醫療器材路徑

NEWS2 計算器 輸入與計分規則都看得到 → 多半可過關卡④

即時 AI 惡化預警 時間緊迫、依據不透明 → 多半卡在關卡④

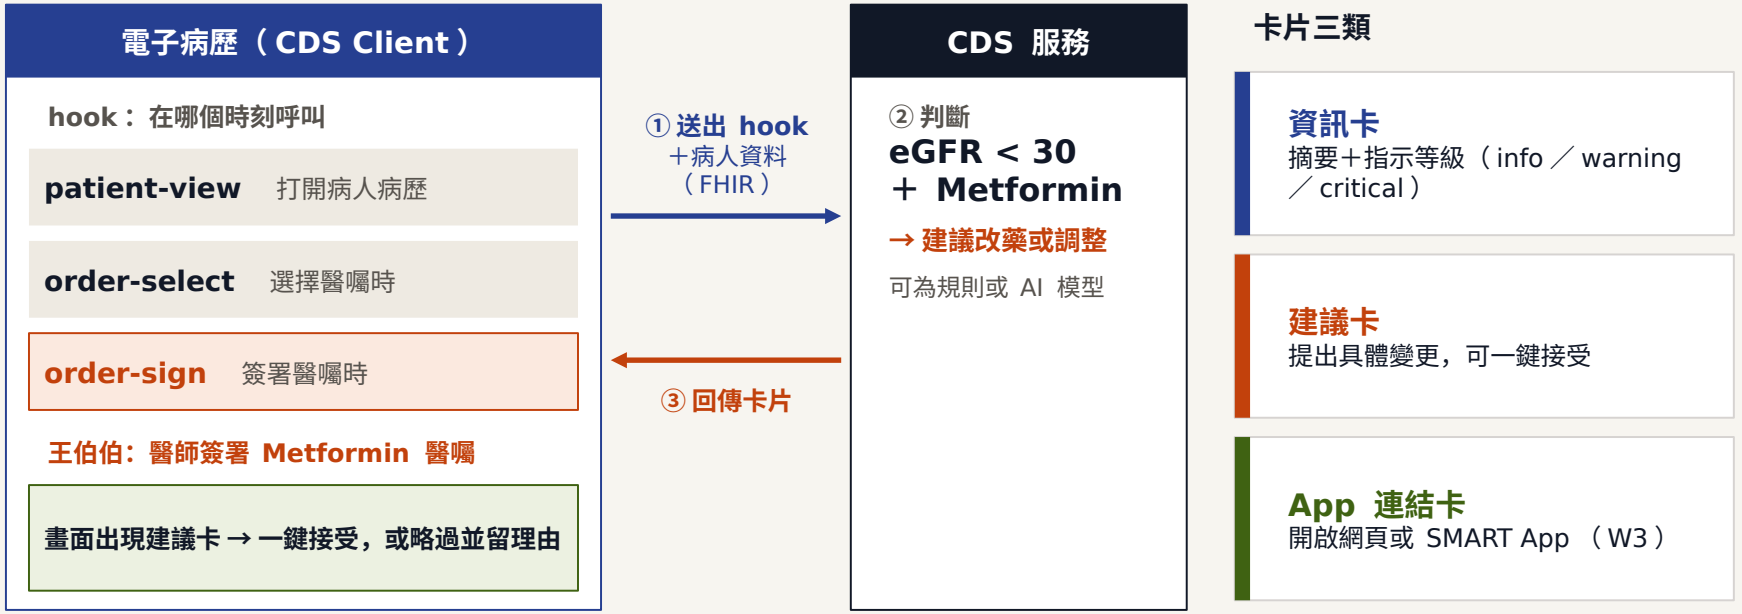
2026 修訂
單一建議也可適用；時間緊迫改在④判斷

美國 FDA 2026-01-06 修訂版；條件文字為重點摘譯

即時惡化預警多半難以滿足條件④——這類產品通常要走醫療器材路徑（W13 詳談台灣 TFDA）。

CDS 怎麼嵌進電子病歷？ HL7 CDS Hooks

病歷系統在特定時刻呼叫 CDS 服務，服務回傳「卡片」顯示在畫面上（版本 2.0.1，以 FHIR R4 為基礎）



hook 決定「時機」、卡片決定「格式」——五個對裡的兩個，在標準裡就能設計。

02

PART 2

早期預警系統 Early Warning Systems

在病人惡化之前，讓團隊提早看到

NEWS2：最常用的評分式預警； AI 預警與評分式的差別
預警是一套應變系統： Kaiser AAM 與 Johns Hopkins TREWS

NEWS2：英國國家早期預警分數

英國皇家內科醫師學會（RCP） 2017 年發布；六項生理參數＋是否給氧，共七項給分

參數	3	2	1	0	1	2	3
呼吸（次／分）	≤8		9–11	12–20		21–24	≥25
SpO_2（%）量表 1	≤91	92–93	94–95	≥96			
給氧		給氧		室內空氣			
收縮壓（mmHg）	≤90	91–100	101–110	111–219			≥220
心跳（次／分）	≤40		41–50	51–90	91–110	111–130	≥131
意識				清醒			新發混亂等
體溫（°C）	≤35.0		35.1–36.0	36.1–38.0	38.1–39.0	≥39.1	

總分 0–4 低｜5–6 中：緊急評估｜≥ 7 高：緊急應變 ｜ 王伯伯 02:00： 2 + 2 + 1 + 1 = 6 分

評分式預警 vs AI 預警

AI 預警把檢驗、用藥、趨勢一起納入，但也帶來新的問題

評分式 NEWS2 ／ MEWS

呼吸 | SpO_2 | 給氧 | 血壓

心跳 | 意識 | 體溫

→ 加總 0–20 分

7 項・人工可算

AI 預警 Kaiser AAM ／ TREWS

生命徵象 | 檢驗 | 診斷 | 用藥

趨勢 | 護理紀錄 | …數十至上百項

→ 模型 風險 %

自動擷取・每小時或即時

護理師測量時	更新頻率	每小時或即時自動計算
人工可算、一目了然	透明度	需額外說明主要影響因子
敏感度有限	效能	鑑別度通常較高，但需本地驗證
漏抓緩慢惡化	主要風險	資料集偏移、警報過多、黑箱

AI 預警「算得更準」只是第一步；它比評分式更依賴資料品質（W3）與本地驗證。

預警是一套「應變系統」，不只是一個模型

快速應變系統（Rapid Response System）：偵測端 + 應變端



偵測端 Afferent limb

- 模型或分數算出高風險
- 篩掉重複與已處理病人
- 依角色送到對的人

應變端 Efferent limb

- 床邊評估與處置
- 快速應變小組（RRT）到場
- 必要時轉加護病房

回饋 Feedback

- 記錄是否真惡化
- 定期檢討閾值
- 資料回流再訓練

模型再準，若沒有人接手（應變端），結果就和沒有預警一樣——評估時要看整套系統。

國際案例｜美國・成功

Kaiser Permanente AAM：用遠端護理師過濾警示

Advance Alert Monitor，北加州 21 家醫院；Escobar 等，NEJM（2020）

背景 Context

- 住院中未預期轉加護病房的病人，死亡率偏高
- 床邊團隊已承受大量警示

做法 Approach

- 每小時掃描 EHR，預測 12 小時內惡化風險
- 先由院外專責護理師審核每一則警示
- 確認後才通知快速應變小組與主治醫師

成果 Results

21 家

2016–2019 年分階段導入

15.8% vs 20.4%

警示後 30 天死亡率（導入組 vs 對照組）

約 16%

調整後死亡率相對下降

成功關鍵在「先過濾、再通知」：院外護理師把關，床邊團隊只接到值得處理的警示。

國際案例｜美國・成功

TREWS： 前瞻性多院驗證的敗血症預警

Johns Hopkins 開發； Adams 等， Nature Medicine （2022）

背景 Context

- 敗血症每延遲一小時治療，死亡風險上升
- 既有敗血症警示多被批評不準

做法 Approach

- 整合進 EHR ，顯示主要影響因子供醫師判斷
- 醫師須回應警示：確認或排除
- 5 家醫院前瞻性部署並追蹤結果

成果 Results

590,736 人

5 家醫院受監測病人

3.3 個百分點

3 小時內確認警示者，調整後死亡率絕對下降

18.7%

調整後死亡率相對下降

前瞻性、多院、看病人結果——這是醫療 AI 最該有、卻最少見的證據等級（W12 詳談）。

國際案例｜美國・成功

COMPOSER：警示先給護理師，不確定就不叫

UC San Diego 兩個急診； Boussina 等， npj Digital Medicine （2024）；前後比較準實驗設計

深度學習模型
每小時更新
預測 4 小時內敗血症

→

資料不像訓練資料?
標為「無法判定」
不硬給分數

→

護理師開病歷時
跳出警示
顯示風險與主要因子

→

護理師三選一
未懷疑感染／已在處置
／立即通知醫師

−1.9 個百分點
院內敗血症死亡率（相對 − 17%）

+5.0 個百分點
敗血症 bundle 遵從率（相對 +10%）

約 235 則／月
兩院合計警示量；約 55% 通知醫師

6,217 位成人敗血症病人（2021-01 至 2023-04）；非隨機試驗，同期其他改善也可能有貢獻

成功的設計同時做到三件事：先分流（護理師）、可行動（三選一）、不確定就不叫。

03

PART 3

警示疲勞 Alert Fatigue

警示越多，越沒有人看

警示疲勞的數據與惡性循環
降低警示疲勞的設計策略； PPV 與「每抓到一位要看幾則警示」

Part 3 | 數據

警示疲勞有多嚴重？三組數字

臨床人員每天被大量「狼來了」包圍

72–99%

生理監視器警報為假警報或無須處置

Sendelbach & Funk （2013）文獻回顧

49–96%

用藥安全警示被醫師略過的比例

van der Sijs 等（2006）系統性回顧

+ 43%

COVID-19 初期，24 家美國醫院每日敗血症警示量

同期住院人數反而減少 35%（Wong 等，2021）

最後一組數字最值得深思：病人變少、警示變多——模型遇到從未見過的病（COVID），就開始亂叫。

警示疲勞的惡性循環

每一步都很合理，合起來卻讓病人更不安全



打破循環的關鍵在第四步：事件發生後，先問「能否改流程」，而不是直接再加一條警示。

降低警示疲勞的六種做法

目標不是「零警示」，而是讓每一則警示都值得處理

① 源頭：少發

調整閾值 依本地資料選閾值
例： NEWS2≥5 → AI 分數前 5%

定期汰除 追蹤略過率，淘汰無效警示
例：略過率 >90% 列入檢討

② 傳遞：分流

分級警示 依嚴重度用不同管道
例：高風險打電話、中風險上儀表板

合併與抑制 短時間內不重複通知
例：已啟動評估 6 小時內不再跳

中央過濾 專責人員先審核
例： Kaiser 遠端護理師、遠距加護中心

③ 接收：好處理

可行動 附建議動作與一鍵醫囑
例：「建議抽血培養」＋直接開立

監測兩個指標
略過率
每抓到一位要看幾則警示（NNE）

可用「略過率」與「每抓到一位要看幾則警示」持續監測——兩者都是 CDS 治理委員會該看的指標。

國際案例｜美國・警示治理

Vanderbilt Clickbusters：把「定期汰除」變成全院活動

McCoy 等，JAMIA （2022）；醫師、護理師、藥師自願參加，2020 年兩輪各 3 個月

選一則警示 → 看臨床邏輯 → 看略過率 → 訪談使用者 → 決定去留 → 測試上線並評估

10 步驟流程（此處合併為 6 段示意）

檢視 84 則 BPA （約占規則型警示 20%）的結果



看什麼
邏輯是否過時、對象是否正確、略過率多高

怎麼改
縮小對象、改時機、改成非打斷式或加一鍵動作

打斷式警示

−15%

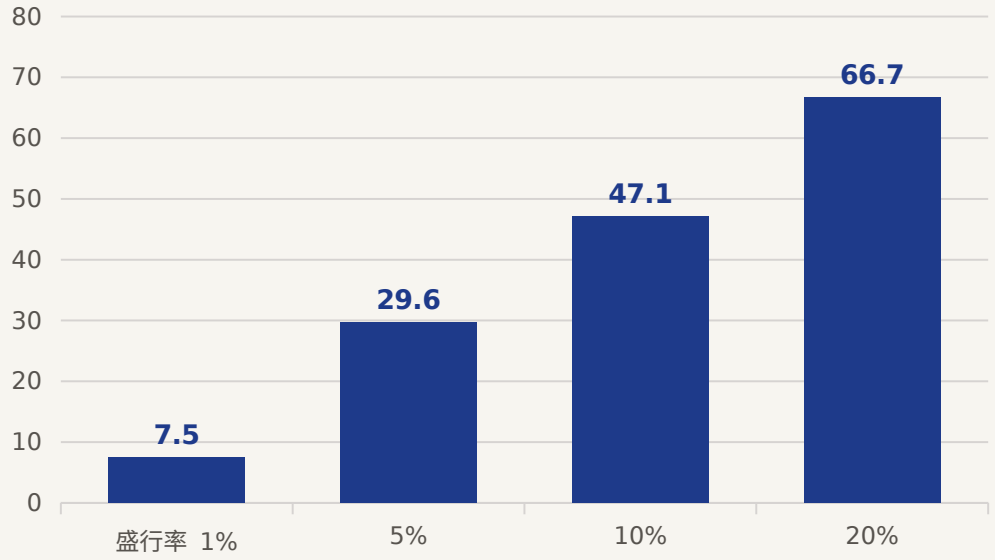
每週少 71,227 則

依 VUMC 新聞稿；計畫 2020-04 啟動

一半以上的警示是「修改」而非「刪除」——多數問題出在對象與時機，不是內容。

同一個模型，盛行率越低，假警示越多

陽性預測值（PPV）＝警示中真正有事的比例；以敏感度 80%、特異度 90% 試算



白話換算

- 盛行率 1% 時 PPV 7.5% ≈ 每 13 則警示才有 1 位真的有事
- 每抓到 1 位要看的警示數（NNE）＝ 1 ÷ PPV
- 一般病房惡化事件少， PPV 天生偏低
- 所以只看 AUROC 不夠，要看「閾值下的警示量」

同一模型搬到盛行率較低的醫院， PPV 自然下降——這不是模型壞掉，而是要重新選閾值。

04

PART 4

資料集偏移 Dataset Shift

在 A 醫院準的模型，到 B 醫院為什麼不準?

三種偏移來源（Finlayson 等，2021）
外部驗證、本地驗證與上線後監測

資料集偏移：訓練時的世界 ≠ 使用時的世界

Finlayson 等（NEJM, 2021）：臨床人員應該知道的三類來源

01

技術改變

Technology

換檢驗儀器或試劑、 EHR 改版、生命徵象改由設備自動上傳——數值分布跟著變

02

族群與場域改變

Population & Setting

從醫學中心搬到區域醫院、從美國搬到台灣、病人更老更多共病

03

行為與實務改變

Behavior & Practice

新指引、新疾病（COVID）、醫師因為警示而提早處置，改變了資料本身

第三類最隱微：模型上線後改變了醫師行為，資料就不再是模型當初學習的樣子。

Part 4 | 統計角度

從統計看偏移：三種型態

名稱不必背，重點是能對應到臨床情境



最後一列常被忽略：兩家醫院對「敗血症」的定義不同，比對出來的準確度就不能直接比較。

Part 4 | 驗證層次

上線前：從內部驗證到本地驗證

證據越往右，越接近「在我們醫院會不會準」

內部驗證 → 時間驗證 → 外部驗證 → 本地靜默測試

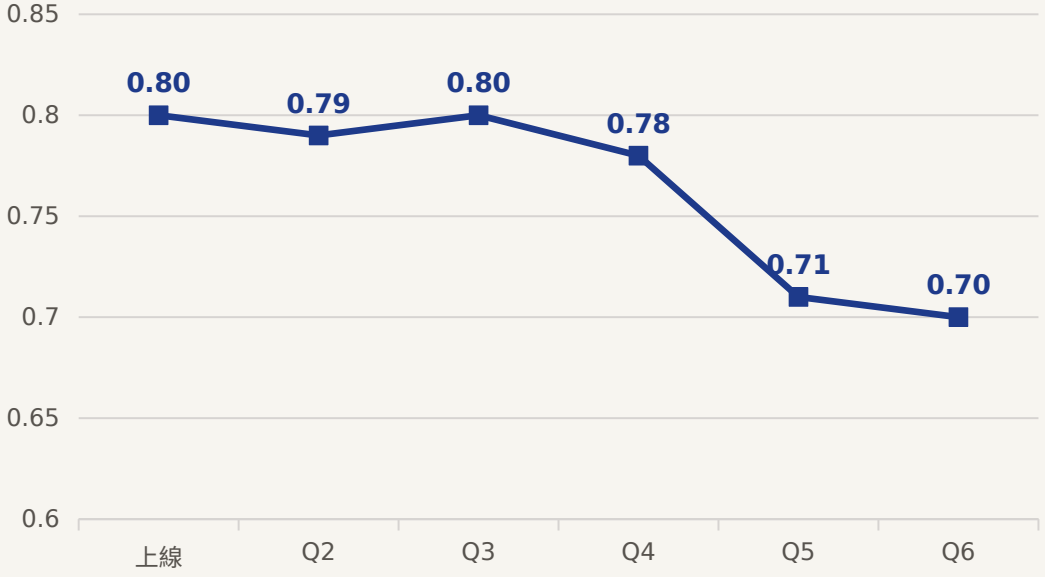
本地驗證檢核清單

1	**鑑別度**	AUROC 是否接近廠商宣稱？（W5）
2	**校準度**	預測 10% 的人，實際是否約 10% 發生？
3	**閾值下表現**	敏感度、 PPV 、每日警示量、 NNE
4	**次族群**	高齡、不同病房、不同性別是否一致？

「靜默測試」（silent mode）：模型在背景跑、不發警示，先累積本地證據再決定是否上線。

上線後監測：模型會悄悄變差

某醫院 AI 預警模型逐季 AUROC（教學示意）



Q5 發生什麼事?

- 檢驗科更換乳酸檢測儀器
- 同季導入新的護理生命徵象設備
- 觸發預設警戒線（AUROC < 0.75）
- 啟動檢討：重新校準或暫停

上線前就要寫好「監測指標、警戒線、誰負責、何時停用」——這是 AI 治理委員會的工作（W15）。

Part 4 | 導入四階段

離線測試 → 靜默測試 → 有限試辦 → 持續監測

每一階段回答不同問題；進下一階段與退回的條件，都要事先寫好（教學示例）

離線測試	靜默測試	有限試辦	持續監測
本院歷史資料上準不準 看： AUROC 、校準、閾值下 PPV	**即時資料下準嗎、警示多少** 看：每日警示數、 PPV 、資料延遲	**人會用嗎、處置有變嗎** 看：回應時間、處置率、覆寫率	**長期還有效嗎** 看：上列指標＋病人結果、次族群
✔ **進下一階段** 達預設表現	✔ **進下一階段** 警示量在人力範圍內	✔ **進下一階段** 回應達標、無新增傷害	**持續循環** 定期回報治理委員會
✖ **停止或退回** 校準偏差且無法重新校準	✖ **停止或退回** 資料延遲或缺漏過多	✖ **停止或退回** 警示造成延誤或過度處置	✖ **停止或退回** 觸發 W15 治理表停用條件

模型準只是第一關：警示量、回應時間、可行介入與病人結果，要一關一關確認。

05

PART 5

人機協作決策 Human–AI Collaborative Decisions

AI 給建議，人做決定——但人會被 AI 影響

自動化偏誤與演算法厭惡；四種協作模式
好的介面設計；責任歸屬

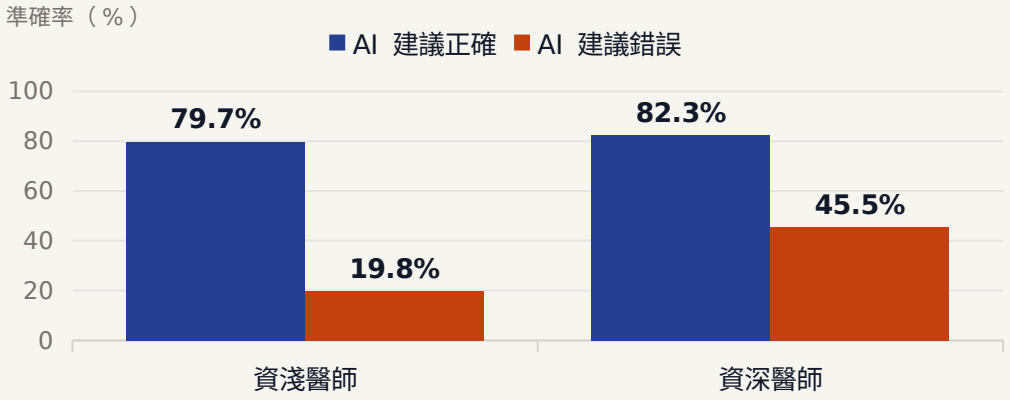
人和 AI 一起決策時的兩種偏誤

太信任和太不信任，都會讓人機協作失效

自動化偏誤 Automation bias
過度相信 AI，連錯的建議也照單全收

目標：適度信任

演算法厭惡 Algorithm aversion
看過 AI 錯一次，連正確的警示也忽略



實證：Dratsch 等，Radiology 2023
27 位放射科醫師判讀乳房攝影；AI 建議的正確與否由研究者控制

資淺：約 80% → 約 20%
資深：82.3% → 45.5%

資深者也會被影響——防偏誤要靠介面與流程，不能只靠經驗。

對策不是叫人「不要信 AI」，而是設計讓人能檢查 AI 依據、並在流程中保留獨立判斷的環節。

Part 5 | 協作模式

人機協作的四種模式

模式要依風險與 AI 成熟度選擇，不是越自動越好

人主導、較慢 → AI 主導、較快、較難攔錯

1 AI 先篩（分流）

AI 排序，人優先處理高風險者

例子

惡化風險儀表板

風險：低分者被忽略

2 第二意見

人先判斷，再看 AI 建議

例子

影像判讀第二讀者

風險：自動化偏誤

3 人審核後執行

AI 提出建議，人確認才生效

例子

TREWS 須醫師確認

風險：確認流於形式

4 AI 自主

AI 直接產生結果或行動

例子

IDx-DR 自主判讀（W2）

風險：錯誤無人攔截

human-in-the-loop 要寫清楚：哪一步、誰、看到什麼資訊、多久內處理、可否推翻、推翻怎麼記錄。

好的預警畫面長什麼樣子?

以王伯伯為例的示意畫面（虛構）

7B-12　王○○　72 歲　惡化風險：高

風險 18%（4 小時前 6%）↑

主要因子：呼吸 24 次／分、 SpO_2 93%、近 8 小時尿量減少

建議：床邊評估、抽血驗乳酸、通知值班醫師

模型：本院驗證 AUROC 0.78 ｜最近校正 2026/08

確認並處置　**已評估，暫不處置（需填理由）**

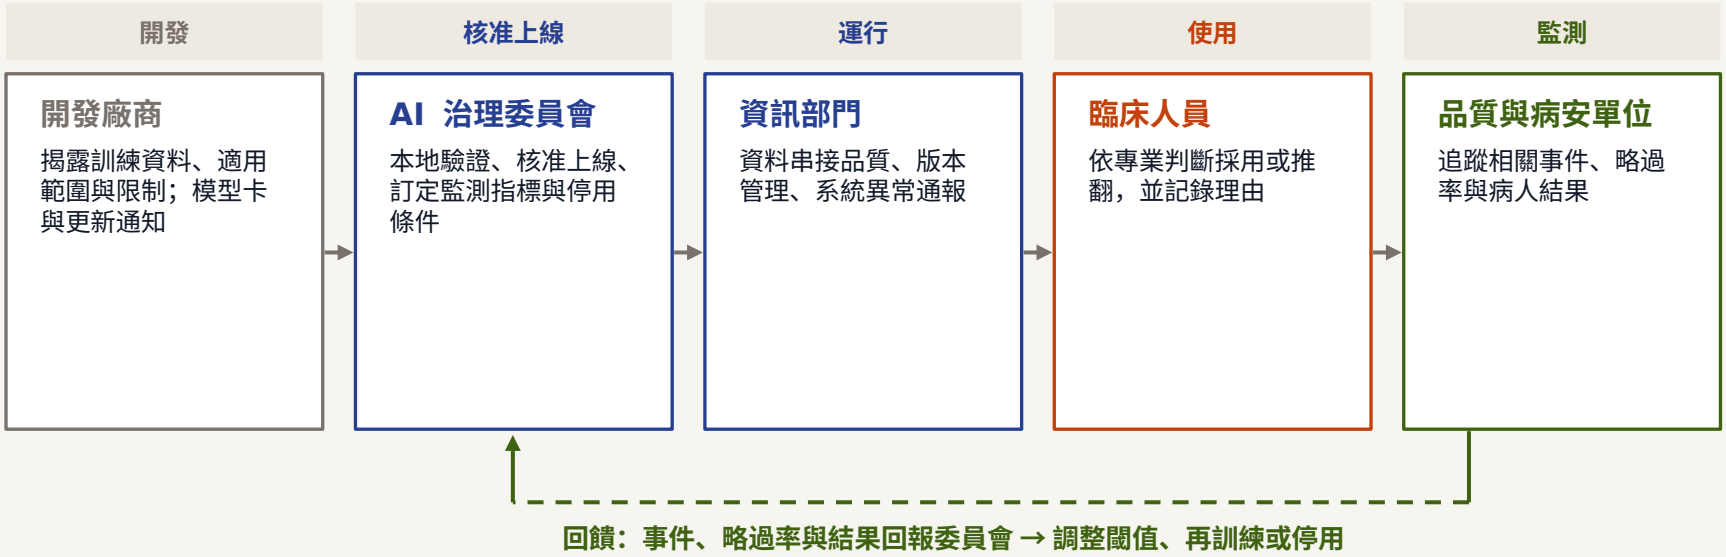
- **顯示趨勢：**不只當下分數
- **說明因子：**讓人能檢查依據（FDA 條件④）
- **附建議動作：**可行動
- **可推翻並留理由：**資料回流改善模型
- **揭露模型資訊：**驗證與校正日期

「暫不處置需填理由」不是為了刁難，而是讓每次推翻都成為改善模型與流程的資料。

Part 5 | 責任歸屬

AI 建議錯了，誰負責?

目前多數制度下，最終臨床決定仍由醫療人員負責——所以治理要分工清楚



責任不能只壓在第一線：若醫院沒做本地驗證就上線，制度上已先失職（W13 責任、 W15 治理延伸）。

06

PART 6

國際案例與擬真演練 Case Analysis & Simulation

Epic 敗血症模型：一個被廣泛使用、卻在外部驗證失準的模型

Epic Sepsis Model 外部驗證結果與原因分析
三個預警系統對照；為北城區域醫院選閾值

國際案例｜美國・教訓

Epic 敗血症模型：外部驗證的落差

Wong 等，JAMA Internal Medicine （2021），密西根大學醫學中心

背景 Context

- Epic 是美國最大 EHR 廠商，模型隨系統提供
- 已在數百家醫院使用，但少有獨立驗證

做法 Approach

- 回溯分析 2018–2019 年約 2.8 萬名成人、 3.8 萬次住院
- 以廠商建議閾值（分數 ≥ 6）評估
- 敗血症發生於 7% 的住院

成果 Results

0.63

住院層級 AUROC （廠商報告約 0.76–0.83）

67%

敗血症病人未被模型標記

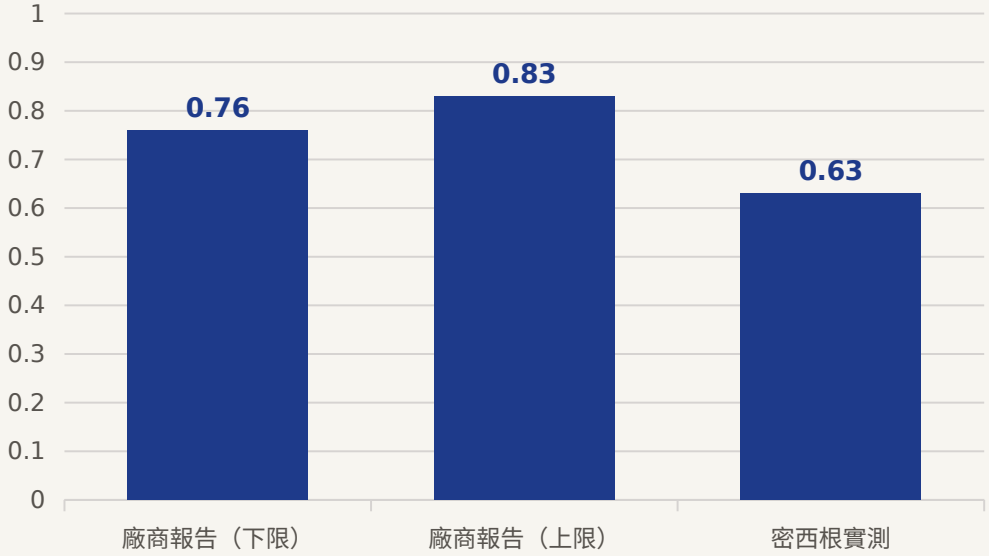
18%

全部住院病人觸發警示，警報負擔沉重

廣泛使用不等於經過驗證——任何預測模型上線前，都需要在本院資料上獨立驗證。

宣稱 vs 實測：同一個模型，兩種成績

AUROC 比較；0.5 等於擲硬幣



- **實測敏感度：**約 33%
- **實測 PPV：**約 12%，每 8 則警示約 1 則為真
- **臨床價值：**模型及時標記、而醫師尚未處置者，僅占敗血症病人 7%
- **後續：** Epic 於 2022 年推出需本地訓練的新版模型

注意比較基礎：評估時點、敗血症定義、閾值都不同——這正是下一頁原因分析的重點。

擬真演練 Simulation

演練： Epic 敗血症模型為什麼失準?

用本週五個面向做原因分析——分組 15 分鐘，每組負責一個面向

標籤定義

訓練用申報碼定義敗血症；驗證用臨床準則

特徵與洩漏

部分輸入（如已開抗生素）反映醫師早已懷疑

族群與實務

密西根病人組成、檢驗與記錄習慣不同

閾值與部署

未依本地盛行率調閾值，警示量過大

透明度

專有模型，醫院難以檢視與改良

共同教訓：模型的準確度不是產品的固定屬性，而是「模型 × 資料 × 場域 × 流程」的結果。

三個預警系統：成功與失敗的分水嶺

● 明顯具備　◐ 部分具備　○ 不足（教學判讀，依研究發表當時）

	本地驗證	工作流設計	警示過濾	可解釋性	前瞻成效評估
Kaiser AAM	●	●	●	◐	●
Johns Hopkins TREWS	●	●	◐	●	●
Epic 敗血症模型（2021 研究）	○	◐	○	○	○

觀察：成功的兩個系統，都把力氣花在「模型以外」：誰看警示、怎麼回應、如何評估病人結果。

採購 AI 預警時，請廠商回答的不只是 AUROC，而是這五欄各自怎麼做到。

擬真演練 Simulation

演練：北城區域醫院該選哪個閾值?

450 床，每日約 60 人次入院；惡化事件率 4%；以每 1,000 次住院試算（教學示意）

閾值	敏感度	特異度	抓到	漏掉	警示總數	PPV	每日警示	NNE
低（分數 ≥ 5）	80%	75%	32	8	272	11.8%	約 16 則	8.5
高（分數 ≥ 8）	50%	93%	20	20	87	23.0%	約 5 則	4.4

假設每次住院最多觸發一次警示；每日警示＝警示總數 × 60 ÷ 1,000。

- 討論 1：夜班 1 人顧 12 床，哪個閾值較可行?
- 討論 2：選低閾值，可搭配哪些設計降低警示疲勞?
- 討論 3：每 1,000 次住院多漏掉的 12 位，用什麼補位?



選定閾值後再寫三件事：試辦條件、停用條件、升級處理（誰接、多久內、接不到怎麼辦）。

擬真個案 Simulated Case

回到王伯伯：如果重新設計那一晚

把本週五個概念放回同一條流程

1	**02:00 偵測**	AI 預警依本地驗證閾值觸發，顯示趨勢與主要因子
2	**02:05 過濾**	中央監測護理師確認非重複、非已處理，升級為高優先
3	**02:10 通知**	以電話直接通知值班護理師與醫師，而非只跳 EHR 視窗
4	**02:30 處置**	床邊評估、驗乳酸、調整利尿劑；醫師記錄採用理由
5	**事後 回饋**	標記事件結果，納入每季模型監測與閾值檢討

比開場早了將近 4 小時——改變結果的不只是模型，而是「模型＋過濾＋通知＋應變＋回饋」整條鏈。

名詞小辭典 Glossary

本週名詞小辭典

中英對照，方便閱讀國際文獻

名詞	英文	白話解釋
臨床決策支援	Clinical Decision Support, CDS	在決策當下提供篩選過、與病人相關的知識或建議
早期預警分數	Early Warning Score, EWS	以生命徵象加總評估惡化風險，如 NEWS2
快速應變系統	Rapid Response System	偵測惡化並由專責團隊到場處置的機制
警示疲勞	Alert Fatigue	警示過多導致減敏感、忽略真警示
陽性預測值	Positive Predictive Value, PPV	被警示的人中，真正會發生事件的比例
資料集偏移	Dataset Shift	使用環境的資料與訓練資料分布不同
校準度	Calibration	預測機率與實際發生率是否一致
自動化偏誤	Automation Bias	過度依賴自動化系統的建議

Summary

本週重點回顧

一頁掌握臨床決策支援與預警系統

主題	一句話重點
CDS	五個對：資訊、人、格式、管道、時機；警示只是六種形式之一
法規	FDA 2026 年指引四條件；即時預警多半仍屬醫療器材
早期預警	NEWS2 透明簡單； AI 預警較準但更依賴資料與驗證
系統觀	偵測 → 過濾 → 通知 → 應變 → 回饋，缺一環就失效
警示疲勞	盛行率低則 PPV 低；看閾值下的警示量與 NNE
資料集偏移	技術、族群場域、行為改變；上線前本地驗證、上線後持續監測
人機協作	防自動化偏誤：顯示依據、可推翻、留理由

帶走一個問題：你的醫院若要買 AI 預警，第一個要請廠商拿出的證據是什麼?

課堂討論：你單位的警示，有多少是噪音？

分組 15 分鐘，每組 3 分鐘分享

- **Q1　盤點：**你的單位最常出現的三種警示是什麼？大約多少比例會被直接略過？
- **Q2　五個對：**挑一種常被略過的警示，它違反了五個對中的哪一個？怎麼改？
- **Q3　偏移：**若你的醫院要導入他院開發的預警模型，最可能發生哪一種資料集偏移？
- **Q4　協作：**預警被推翻時，你會希望系統記錄什麼？誰該定期看這些紀錄？

Q1 的「略過率」不必精確，憑經驗估計即可——重點是意識到警示也需要被管理。

延伸學習 Further Learning

延伸學習： CDS 與預警的標準、工具與案例

課後自學用，不列入評量；期末個案可引用

HL7
CDS Hooks 規格
CDS 怎麼嵌入電子病歷；卡片範例
對應 CDS Hooks 頁

AHRQ
CDS Connect
可分享的 CDS 規則與實作工具庫
對應 Part 1

英國 RCP
NEWS2 報告與圖表
官方計分表與臨床回應建議
對應 Part 2

美國 FDA
CDS Software Guidance
2026 修訂版全文
對應法規頁

Vanderbilt （JAMIA 2022）
Clickbusters
全院警示汰除的流程與成效
對應 Part 3

UC San Diego （npj 2024）
COMPOSER
護理師端敗血症預警的設計細節
對應 Part 2 案例

想改善單位的警示，先從 Clickbusters 的 10 步驟和「略過率」開始。

下週預告 Next Week

W9　期中評量：個案分析

課堂內完成；範圍為單元一、二（W1–W8）

- 形式：個人作答，閱讀一份擬真醫院個案後回答 5 題
- 範圍：價值框架、國際趨勢、資料互通、使用者設計、 AI 方法論、生成式 AI 、 AI Agent 、臨床決策支援
- 核心能力： C1 趨勢洞察、 C2 技術應用、 C3 實證評估
- 比重：學期成績 20%

考前準備

- 複習 W1–W8 講義的「重點回顧」頁
- 練習計算敏感度、 PPV 、 NNE
- 可攜帶紙本講義與計算機
- 期中評量不可使用生成式 AI 與網路

期中不考背誦，考的是「把框架用在一個新情境」——本週的閾值演練就是很好的練習。

主要參考資料

法規與數據以官方最新公告為準（查證日期： 2026 年 10 月）

Osheroff JA, et al. (2007). A roadmap for national action on clinical decision support. JAMIA, 14(2), 141–145.

U.S. FDA (2026-01-06). Clinical Decision Support Software: Guidance for Industry and FDA Staff （取代 2022 年版） .

Royal College of Physicians (2017). National Early Warning Score (NEWS) 2.

Sendelbach S, Funk M. (2013). Alarm fatigue: a patient safety concern. AACN Advanced Critical Care, 24(4), 378–386.

van der Sijs H, et al. (2006). Overriding of drug safety alerts in CPOE. JAMIA, 13(2), 138–147.

Finlayson SG, et al. (2021). The clinician and dataset shift in artificial intelligence. NEJM, 385(3), 283–286.

Dratsch T, et al. (2023). Automation bias in mammography: the impact of AI BI-RADS suggestions on reader performance. Radiology, 307(4).

Wong A, et al. (2021). Quantification of sepsis model alerts in 24 US hospitals before and during the COVID-19 pandemic. JAMA Network Open, 4(11).

Covington & Burling (2026-01). 5 key takeaways from FDA's revised CDS software guidance.

HL7 (2022). CDS Hooks, version 2.0.1 (STU 2). https://cds-hooks.hl7.org/

參考資料 References

國際案例出處

本週案例之原始來源；數據以原始文獻為準

Wong A, et al. (2021). External validation of a widely implemented proprietary sepsis prediction model in hospitalized patients. JAMA Internal Medicine, 181(8), 1065–1070.

Escobar GJ, et al. (2020). Automated identification of adults at risk for in-hospital clinical deterioration. NEJM, 383, 1951–1960.

Kaiser Permanente (2020-11-11). Real-time alerts associated with lower mortality （新聞稿）.

Adams R, et al. (2022). Prospective, multi-site study of patient outcomes after implementation of the TREWS machine learning-based early warning system for sepsis. Nature Medicine, 28, 1455–1460.

University of Michigan IHPI (2021). Study of 24 U.S. hospitals shows onset of COVID-19 led to spike in sepsis alerts.

Boussina A, et al. (2024). Impact of a deep learning sepsis prediction model on quality of care and survival. npj Digital Medicine, 7, 14.

McCoy AB, et al. (2022). Clinician collaboration to improve clinical decision support: the Clickbusters initiative. JAMIA, 29(6), 1050–1059.

CLOSING

好的預警，是讓對的人及時看見

模型決定「看不看得到」，系統決定「來不來得及」。