智慧醫療與科技發展　Smart Healthcare & Technology Development

醫療 AI 實證評估

Evidence Appraisal of Medical AI

12

第 12 週｜評估、治理與落地　Unit 4
證據落差 → 研究設計與 DiD → 評讀工具 → 指標 → 偏誤與公平 → 證據表與演練

謝楠楨 講座教授 ・ 2026 ・ 雙語版（English terms ＋ 中文講解）

本週地圖 This Week

本週六個部分

從「看懂證據」到「挑出漏洞」，練習用評估工具審視一篇研究

01

證據落差

Evidence Gap

宣稱很多、前瞻證據很少

02

評估階段

Evaluation Stages

證據階梯、差異中的差異

03

報告指引

Reporting Guidelines

TRIPOD+AI 等指引家族

04

指標與效益

Metrics & Utility

鑑別、校準、臨床效益

05

偏誤與公平

Bias & Fairness

偏誤來源、公平性指標

06

案例與演練

Cases

MASAI 證據表、 SepsiNet 檢核

W5 學「模型怎麼做」、 W8 學「上線會怎樣」，本週學「怎麼判斷別人說的是不是真的」。

學習目標 Learning Objectives

本週結束時，你能做到什麼

四個可檢核的學習目標

C3	判斷一項證據在證據階梯第幾層、能支持什麼結論。
C3	用差異中的差異估算導入效果，並說明它的前提。
C3	用證據表評讀原始研究，區分點估計、區間與非劣性。
C3	以 PROBAST+AI 評讀偏誤，依預測時點判斷資料洩漏。

課堂產物：差異中的差異練習、 MASAI 證據表、 SepsiNet-TW 評讀表。

開場 Opening

北城區域醫院院長收到一份廠商簡報

「我們的敗血症 AI 準確率 95%，論文已發表，優於醫師判斷。」——要不要買?

SepsiNet-TW 產品簡報（虛構）

- 準確率 95.2%、AUROC 0.94
- 訓練資料：5 萬多次住院
- 「在 100 個案例中優於 3 位醫師」
- 已發表於國際期刊
- 建議全院導入

院長該問的問題

- 資料從哪來？和我們醫院像嗎?
- 「敗血症」是怎麼定義的?
- 95% 是在哪一群人身上算的?
- 有沒有在別家醫院驗證過?
- 用了之後，病人結果有變好嗎?

本週最後的演練，就是拆解這份研究——先記住你的直覺判斷，下課前再對照。

01

PART 1

醫療 AI 的證據落差 The Evidence Gap

宣稱很多，前瞻證據很少

上市醫材與發表論文的證據等級
隨機對照試驗的現況與限制

醫療 AI 的證據有多薄？三組數字

準確度研究很多，「用了之後病人有沒有變好」的研究很少

126 ／ 130

FDA 核准 AI 醫材僅有回溯性評估

Wu 等（Nature Medicine, 2021）分析 2015–2020 年核准品項

2 項

已發表的深度學習隨機試驗

Nagendran 等（BMJ, 2020）；另 8 項進行中；81 項非隨機研究多屬高偏誤風險

86 項

2018–2023 年 AI 臨床隨機試驗

Han 等（Lancet Digital Health, 2024）；63% 為單一中心

AI 醫材已超過千項，但多數上市證據停在「回溯資料上算得準」，而非「臨床用了有效」。

FDA 授權 ≠ 有臨床驗證： 521 項 AI 醫材的分析

延伸閱讀： Chouffani El Fassi 等， Nature Medicine 2024



約 43%

有驗證者的研究設計（件數）



類別依原論文定義，是否互斥請見原文

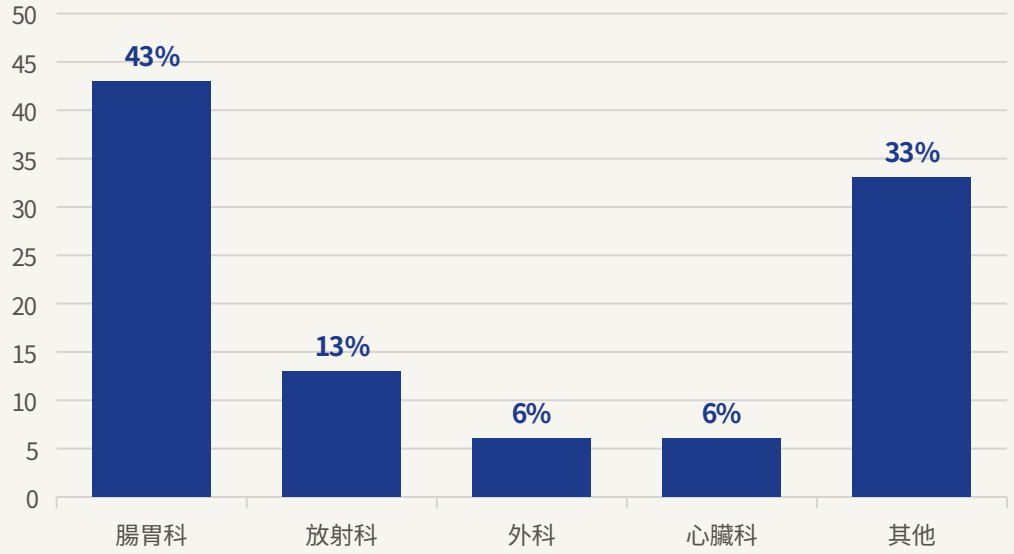
和前一頁一起看

2021： 130 項中 126 項只有回溯
2024： 521 項中近半連公開驗證都沒有
隨機試驗仍是少數

採購時不要只看「已取得許可」，要追問：用什麼資料、在誰身上、用什麼設計驗證過？

AI 隨機試驗集中在少數科別

延伸閱讀： Han 等（2024）納入 86 項 AI 隨機試驗（2018–2023），依科別分布



怎麼解讀

- 腸胃科 37 項，多為大腸鏡息肉偵測
- 81% 主要結果為正向——可能有發表偏誤
- 主要結果多為「偵出率」，少有死亡、住院等病人結果
- 63% 單一中心；美國 31%、中國 30%

「有 RCT」不等於「證據充分」：還要看結果指標是什麼、在哪裡做、能不能推論到我們的病人。

「算得準」到「病人變好」之間，還隔了四個環節

模型效能只是因果鏈的第一環



技術效能	流程整合	人的行為	臨床行動	病人結果
AUROC 、敏感度	警示有沒有送到對的人（W8）	信任、警示疲勞、自動化偏誤	有沒有對應的有效處置	死亡、住院、生活品質

例： Epic 敗血症模型（W8）在第一環就失準；即使模型準，若後面的環節沒做好，病人結果也不會改變。

評估醫療 AI 要問到最右邊：它改變了誰的什麼行為？最後病人有沒有受益？

02

PART 2

評估階段與研究設計 Evaluation Stages & Study Design

像新藥一樣， AI 也要分階段累積證據

醫療 AI 證據階梯：從內部驗證到上市後監測
無法隨機時：差異中的差異（ DiD ）

醫療 AI 的證據階梯

越往上，越接近「在真實世界對病人有益」；成本與時間也越高



W8 的 Epic 敗血症模型停在第 1 層就上市；TREWS 做到第 3 層（前瞻多院部署、看病人結果），尚無 RCT—— 差別就在證據階梯。

每一層要回答的問題與研究設計

評讀時先判斷：這篇研究在哪一層？它能支持什麼樣的結論？

每層：要回答的問題 → 常見設計 → 可以下的結論

第 1 層　內部驗證

在開發資料上準不準？

回溯世代、資料切分、交叉驗證

「有潛力」

第 2 層　外部驗證

換醫院、換時間還準嗎？

多中心回溯、時間驗證

「可推論到類似場域」

第 3 層　早期臨床評估

實際使用安全嗎？人怎麼用？

前瞻觀察、靜默測試、可用性研究

「可以進一步試驗」

第 4 層　隨機對照試驗

用了之後病人結果更好嗎？

個人或群集隨機、階梯式

「具臨床效益」

第 5 層　上市後監測

長期是否仍安全有效？

真實世界資料、登錄系統

「持續有效」或需修正

最常見的過度推論：拿第 1 層的研究，下第 4 層的結論（「建議全面導入」）。

實驗室超過 90%，到了泰國診所呢？ Google 視網膜 AI

Beede 等， CHI 2020； 泰國 11 家診所實地觀察與訪談（以人為中心的評估）

實驗室（第 1–2 層）	泰國診所（第 3 層）
準確度 > 90% 「達到專科醫師水準」	**> 1/5 影像被拒絕** 品質不符模型門檻，常因光線不足

網路
連線慢，雲端判讀延遲

轉介
被拒絕者要改天到另一家診所看專科

流程
護理師工作量與排程被打亂

數字依 MIT Technology Review （2020-04-27）報導；原論文為質性研究

第 1、 2 層看不到的問題——光線、網路、轉介路程——只有走進診所的第 3 層評估才會發現。

AI 隨機試驗的三種常見設計

AI 介入常是「整個流程」，所以設計比藥物試驗更多元

01

個人隨機

Individual RCT

每位病人隨機分組；例： MASAI 乳房攝影、大腸鏡 AI 。需防止醫師在兩組間「學習外溢」

02

群集隨機

Cluster RCT

以醫師、病房或醫院為單位隨機；適合警示類 AI 。例：台灣 AI-ECG 試驗以醫師為單位

03

階梯式設計

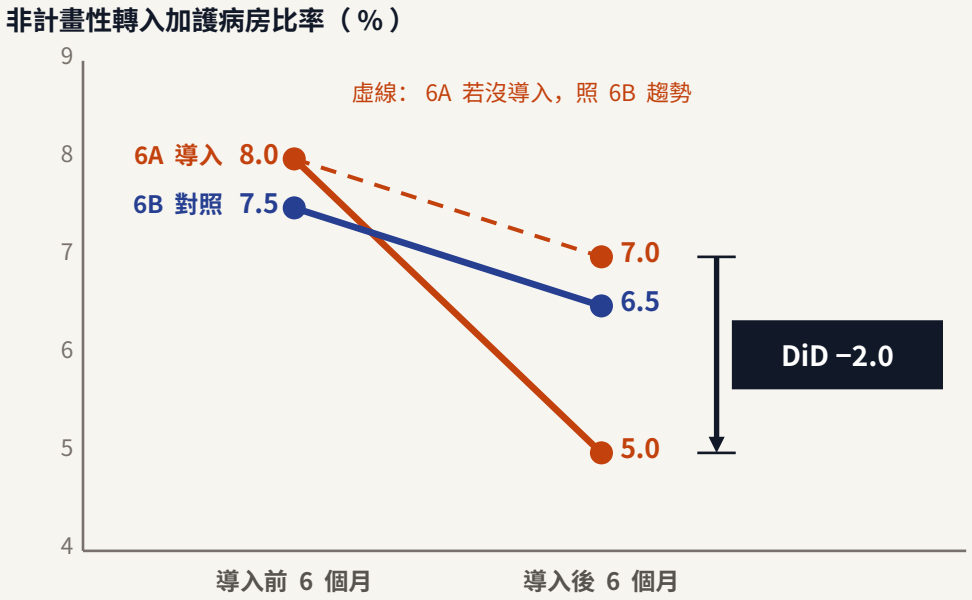
Stepped-wedge

各單位依序導入，最後全部使用；適合「一定要導入」但想評估效益的情境

選設計要考慮「污染」：同一位醫師同時照顧兩組病人，看過 AI 警示後，對另一組也會更警覺。

差異中的差異：扣掉兩組共同的變化

Difference-in-differences （DiD）；北城區域醫院 6A 病房導入預警系統（教學擬真）



怎麼算

- 只看 6A 前後：下降 3.0 個百分點
- 6B 沒導入也降 1.0：屬於兩組共同的變化
- DiD ＝（5.0−8.0）−（6.5−7.5）＝ −2.0
- 只看前後，會把效果高估 1.0 個百分點

DiD 估的是「多出來的變化」；先寫清楚是「後減前」還是「下降幅度」，正負號才不會讀錯。

算得出來，不等於因果已證實

DiD 的估計要成立，下面五件事都要檢查

平行趨勢	沒導入時，兩組原本會同方向、同幅度變化；只有前後兩點無法檢查，要多個導入前時點。
同期介入	導入期間若有其他措施只在一組實施，差值會混入它的效果。
選擇偏差	挑配合度高的病房先導入，或排除特定病人，比較就不公平。
回歸平均	因為前期特別差才導入，後期本來就容易回落。
不確定性	樣本小時，差值可能只是隨機波動；應報信賴區間。

結論寫法：在前提成立下，估計約減少 2 個百分點；仍需更多時點或隨機設計確認。

Part 2 ｜課堂練習

練習： AI 衛教提醒導入後，達標率多了多少?

北城區域醫院糖尿病門診（教學擬真）；個人 5 分鐘，寫出算式與限制

HbA1c 達標率	導入前一年	導入後一年
A 診（導入）	40% （n = 300）	52% （n = 310）
B 診（未導入）	42% （n = 280）	48% （n = 290）

- A 診醫師自願參加
- 導入後第 6 個月起，A 診另由個管師加強電話追蹤

請回答

- (1) 只看 A 診前後，提高幾個百分點?
- (2) 以 B 診為對照， DiD 估計是多少?
- (3) 寫出兩個可能讓估計偏離的原因

期末考同樣的能力：算出差值，並說明它還不能證明什麼。

03

PART 3

報告指引與評讀工具 Reporting Guidelines & Appraisal Tools

不是用來背的清單，而是「該問哪些問題」的提示

AI 報告指引家族： TRIPOD+AI 、 STARD-AI 、 DECIDE-AI 、 CONSORT-AI 等
偏誤風險評讀： PROBAST+AI

醫療 AI 報告指引家族：依研究類型選用

都可在 EQUATOR Network 查到；論文投稿與審查時常被要求附上檢核表

開發／驗證	診斷準確度	早期臨床	隨機試驗
TRIPOD+AI BMJ 2024； 27 項	**STARD-AI** Nat Med 2025	**DECIDE-AI** Nat Med ／ BMJ 2022； 人機互動	**SPIRIT-AI** 試驗計畫書（2020）
TRIPOD-LLM Nat Med 2025； LLM	**CLAIM** 影像 AI； 2024 更新		**CONSORT-AI** 試驗報告（2020）

作者用：寫得完不完整（報告指引）

讀者用： PROBAST+AI （BMJ 2025） 評讀偏誤風險與適用性——跨所有預測模型研究都適用

報告指引看「寫得完不完整」， PROBAST+AI 看「偏誤風險」；兩者都不能證明臨床有效。

TRIPOD+AI： 預測模型研究最該寫清楚的事

Collins 等（BMJ, 2024）； 27 項主清單，另有摘要清單——以下為評讀時最關鍵的八項

資料來源
哪些醫院、期間、納入與排除

沒寫：無法判斷是否像我們的病人

結果定義
用什麼標準、什麼時間點判定

沒寫：不同定義的準確度無法比較

預測因子
變數在預測時點是否已可取得

沒寫：可能偷看答案（資料洩漏）

樣本與缺值
樣本數、事件數、缺值處理

沒寫：排除缺值可能造成選擇偏誤

模型與切分
演算法、訓練／測試怎麼切

沒寫：同一病人跨組會高估效能

效能評估
鑑別、校準、臨床效益、區間

沒寫：只報準確率會誤導

公平性　新
各次族群的效能

沒寫：看不出對誰比較不準

開放科學　新
程式碼、模型、資料可否取得

沒寫：無法重現或獨立驗證

TRIPOD+AI 特別新增「公平性」與「開放科學」——這是 AI 研究與傳統統計模型最大的差異。

走進臨床之後： DECIDE-AI 與 CONSORT-AI

延伸閱讀：從「模型準不準」轉到「人和 AI 一起用時發生什麼事」

DECIDE-AI （早期臨床評估）

- 17 項 AI 特定＋ 10 項通用項目
- 使用者是誰、受過什麼訓練
- AI 建議被採納或推翻的比例
- 使用者學習曲線與工作流變化
- 安全事件與錯誤分析

CONSORT-AI （隨機試驗報告）

- 在 CONSORT 上新增 14 項 AI 項目
- AI 版本與是否在試驗中更新
- 輸入資料的取得與品質處理
- AI 輸出如何呈現給使用者
- 錯誤案例的分析方式

兩者共同重點：寫清楚「人機互動」——同一個 AI，介面與流程不同，效果就可能不同。

PROBAST+AI： 讀者用的偏誤風險評讀

Moons 等（ BMJ, 2025 ）；分「模型開發」與「模型評估」兩部分，各依四個面向判定

01

研究對象與資料

Participants & data

資料來源是否適當？納入排除是否造成偏誤？

02

預測因子

Predictors

定義與測量是否一致？預測時點是否可取得？

03

結果

Outcome

定義是否客觀？是否受預測因子影響？

04

分析

Analysis

樣本數、缺值、過度擬合、校準與驗證是否適當？

判定：每個面向評為低／高／不清楚偏誤風險，並另評「適用性」——研究再嚴謹，若對象不像我們的病人，仍不適用。

PROBAST+AI 新增「品質」與「公平性」相關問題；本週演練會用它的四個面向拆解 SepsiNet-TW 。

04

PART 4

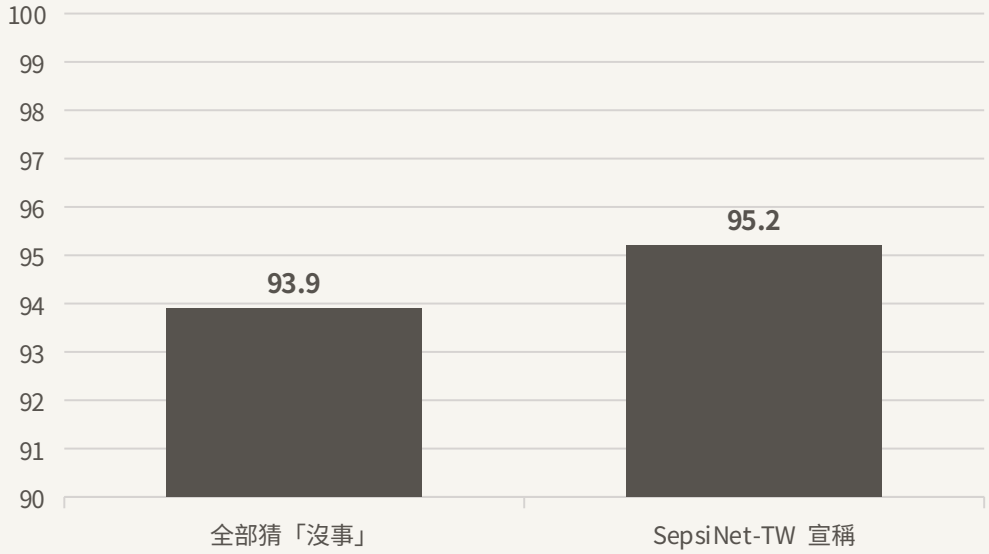
指標與臨床效益 Metrics & Clinical Utility

準確率會騙人：選對指標，才看得到真相

準確率陷阱、鑑別度與校準度
決策曲線分析：模型到底有沒有用

準確率 95%，可能什麼都沒預測到

當事件率只有 6% 時，「全部猜沒事」就有 94% 準確率



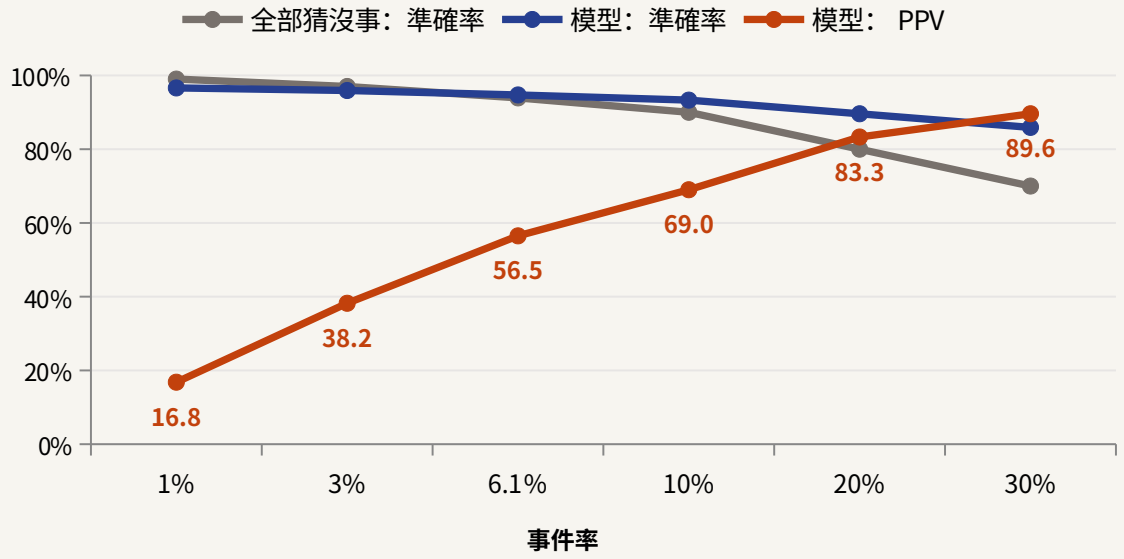
該要求的指標

- **鑑別度：** AUROC，事件少時加看 AUPRC
- **校準度：** 預測機率是否接近實際發生率
- **閾值表現：** 敏感度、 PPV 、每日警示量（W8）
- **臨床效益：** 淨效益、病人結果

看到「準確率」就要先問事件率；不平衡資料只報準確率，幾乎可以視為警訊。

事件率越低，準確率越沒有意義

同一個模型（敏感度 60%、特異度 97%，教學假設）放在不同事件率下



99% vs 96.6%
事件率 1%： 全部猜沒事 vs 模型準確率

93.9% vs 94.7%
事件率 6.1%： 只差不到 1 個百分點

16.8% → 89.6%
PPV： 事件率 1% → 30%

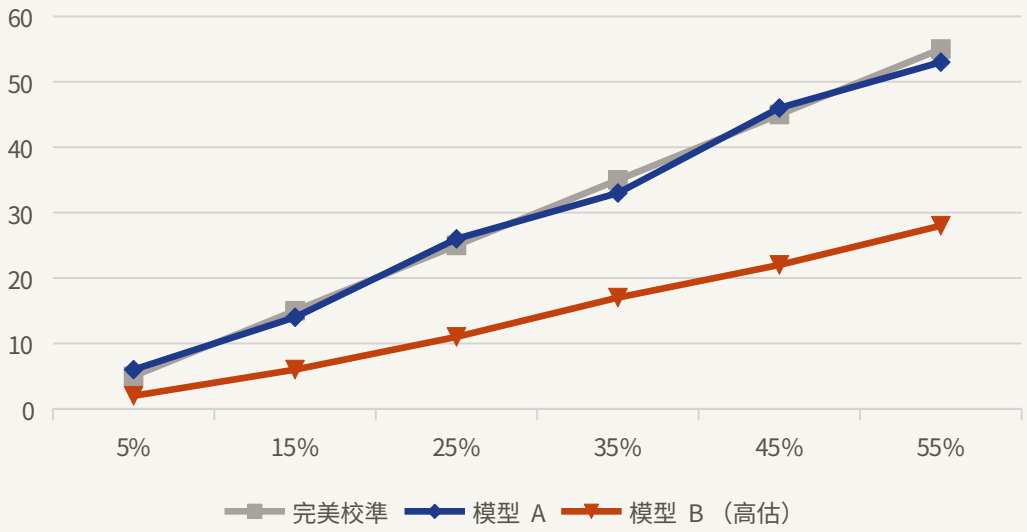
事件率 1% 時，模型準確率反而低於「全部猜沒事」——而 PPV 只剩一成多。

Part 4 ｜校準度

鑑別度好，不代表機率可信：校準度

兩個 AUROC 相同的模型，預測機率可能差很多（教學示意）

橫軸：預測機率｜縱軸：實際發生率（%）



為什麼重要

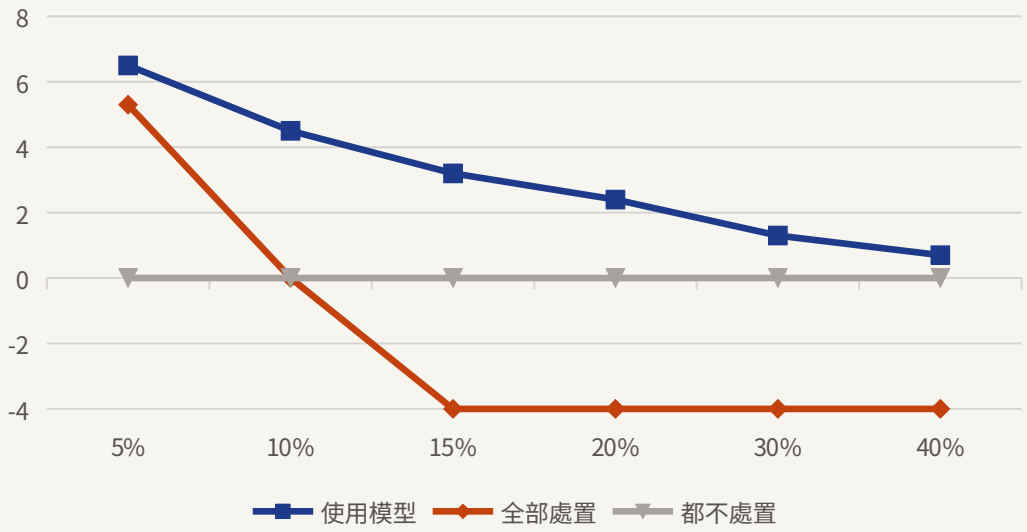
- 模型 B 說「45% 會惡化」，實際只有 22%
- 醫師若依機率決定處置，會過度治療
- 換醫院後最常壞掉的就是校準（W8）
- 可重新校準，不一定要重新訓練

風險分數要拿來「跟病人說明」或「決定處置」時，校準度往往比 AUROC 更重要。

決策曲線分析：用模型，比「全部處置」或「都不處置」更好嗎？

淨效益＝真陽性比例－偽陽性比例 ×（閾值勝算）；事件率 10%、AUROC 約 0.80 試算

橫軸：處置閾值機率｜縱軸：淨效益（每 100 人；低於－4 截斷顯示）



怎麼讀

- 曲線越高越好
- 藍線高於紅線與灰線的區間，才是模型「有用」的範圍
- 閾值代表臨床取捨：多願意為抓到 1 位而多處置幾位
- Vickers & Elkin （2006）提出

決策曲線把「準不準」翻譯成「值不值得用」——這是從統計走向臨床決策的橋梁。

05

PART 5

偏誤與公平性 Bias & Fairness

AI 會學到資料裡的不公平，還會把它放大

偏誤從哪裡來： AI 生命週期的六個來源
公平性指標與兩難；次族群分析

偏誤沿著 AI 生命週期進入模型

依 Suresh & Guttag （2021）架構整理，附醫療例子

資料生成

歷史偏誤
現實本來就不平等
例：弱勢就醫少，病況被低估

代表性偏誤
訓練資料缺某些族群
例：以歐美白人為主的皮膚影像

測量偏誤
代理指標或儀器不一致
例：以費用代表需求；血氧機

建模

彙整偏誤
一個模型套用差異大的族群
例：成人模型直接用在高齡衰弱長者

評估與部署

評估偏誤
測試資料不能代表使用族群
例：只在醫學中心驗證就賣給區域醫院

部署偏誤
使用方式與設計目的不同
例：篩檢工具被拿來決定是否收治

偏誤不只是「資料不平衡」：從問題定義、標籤選擇到部署方式，每一步都可能放進偏誤。

以「醫療費用」預測「健康需求」的演算法

Obermeyer 等， Science （2019）；美國廣泛使用的照護管理演算法

背景 Context

- 醫院用演算法挑選需要額外照護管理的病人
- 模型以「未來醫療費用」作為預測目標

做法 Approach

- 研究者比較同一風險分數下，黑人與白人病人的實際病況
- 發現同分的黑人病人，慢性病數量明顯較多
- 原因：黑人病人取得醫療較少，費用低≠較健康

成果 Results

17.7%

原演算法：被自動納入額外照護者中的黑人比例

46.5%

改以健康指標為目標後，黑人比例

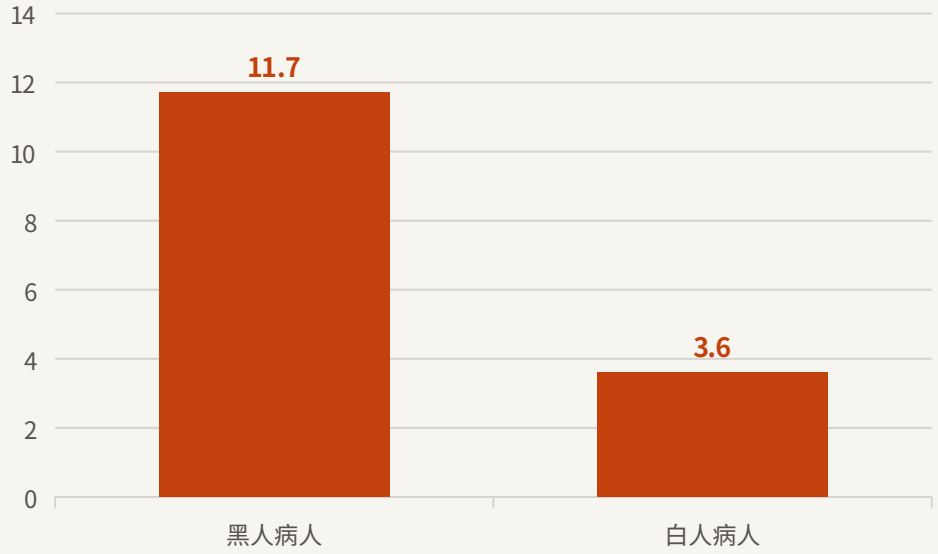
標籤選擇

偏誤不是來自種族變數，而是來自預測目標

最危險的偏誤藏在「標籤」裡：預測目標選錯，模型越準，不公平越嚴重。

儀器本身也可能有偏誤：脈搏血氧機

Sjoding 等（NEJM, 2020）：血氧機讀數 92–96% 時，動脈血實際 < 88% 的比例



對 AI 的意義

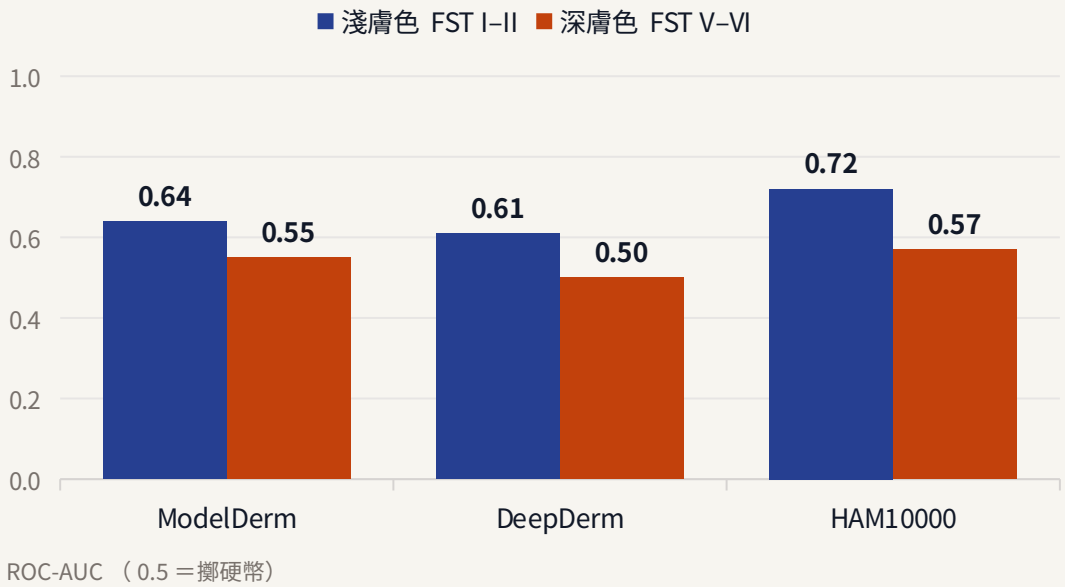
- 血氧值是許多預警模型（如 NEWS2）的輸入
- 輸入有系統性誤差，模型就會對某群人低估風險
- 這類偏誤在模型內部「看不到」
- 需回到資料來源與儀器端檢查

台灣也要問：深膚色移工、高齡末梢循環差的病人，血氧與其他感測讀數是否同樣可靠？

國際案例｜美國・代表性偏誤

皮膚科 AI 換成多元膚色影像，準確度掉三到四成

Daneshjou 等， Science Advances 2022； DDI 資料集： 390 位病人、 440 張經病理確認的影像



ROC-AUC （0.5 ＝擲硬幣）

原始報告 → DDI
ROC-AUC 約 0.88–0.94 → 0.53–0.65
下降 29–40%

深膚色更差
三個模型都是 V–VI 低於 I–II

偏誤類型
代表性偏誤＋評估偏誤

原始論文的高分，來自缺少深膚色的訓練與測試資料——評讀時要問「在誰身上驗證過」。

「公平」有不同定義，在特定條件下無法同時滿足

以「AI 篩出高風險者，給予額外照護」為例

01

群體一致

Demographic parity

各群被篩為高風險的比例相同

02

機會均等

Equal opportunity

真正會惡化的人中，各群被抓到的比例（敏感度）相同

03

校準一致

Calibration within groups

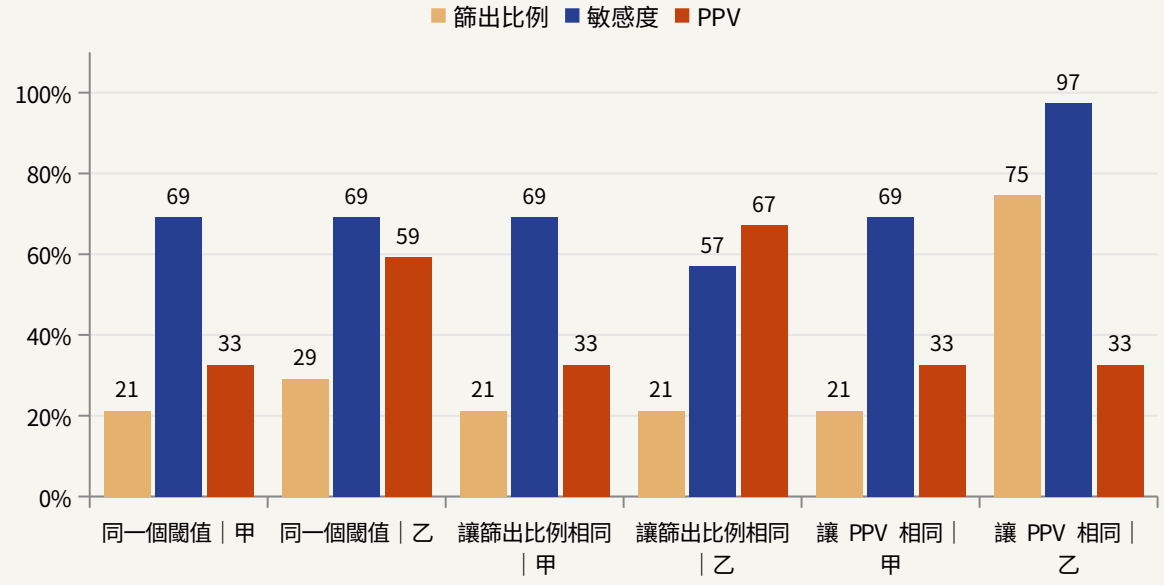
同樣預測 20% 的人，各群實際發生率都約 20%

定理有前提：各群事件率不同、預測又不完美時，「各群內校準」與「正例、負例的平均分數在各群相等」無法同時成立（Kleinberg 等 2016）； PPV 相等與偽陽性率、偽陰性率皆相等也無法並存（Chouldechova 2017）。

先定義要保障哪一群、避免哪種錯誤、分配哪項資源，再選公平定義並說明取捨。

同一個模型，兩群事件率不同：三種閾值設定

甲群事件率 10%、乙群 25%；模型對兩群一樣準（等變異雙常態， d = 1.5 ，教學假設）



哪些指標一致?

同一個閾值

一致：敏感度

讓篩出比例相同

一致：篩出比例

讓 PPV 相同

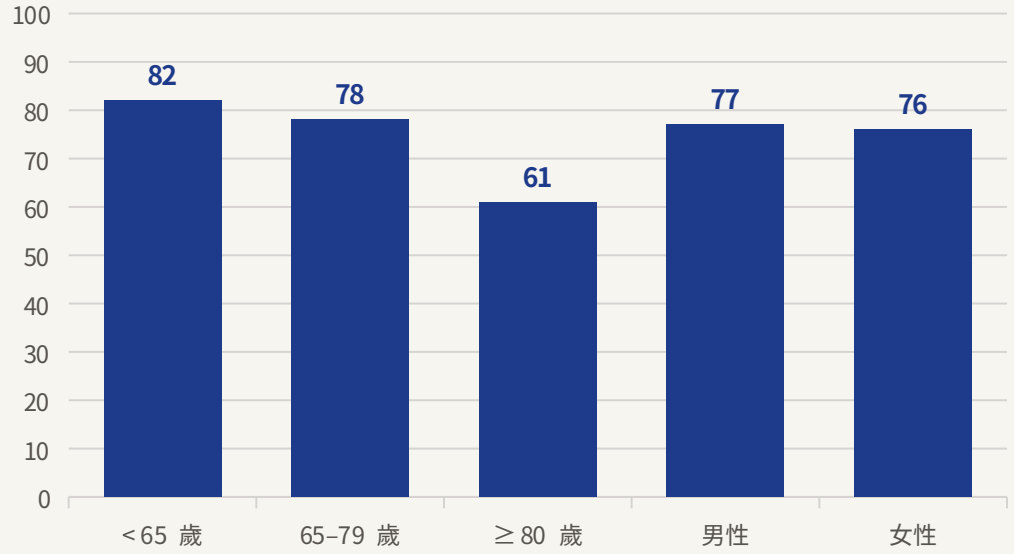
一致： PPV

事件率不同時，無法全部一致。

讓敏感度一致， PPV 就不同；讓 PPV 一致，乙群被篩出四分之三——先決定要保障什麼。

整體準確，不代表對每一群都準

北城區域醫院 AI 預警模型的次族群敏感度（教學示意）



觀察與行動

- 整體敏感度約 76%，看起來可接受
- ≥ 80 歲只有 61%—— 最需要的人最常被漏掉
- 可能原因：高齡者基礎生命徵象不同、訓練樣本少
- 對策：分群閾值、補充資料、加上人工評估

評讀研究時，沒有次族群分析就要追問；採購時，要求廠商提供「我們病人組成」下的次族群效能。

06

PART 6

國際與台灣案例、擬真演練 Cases & Simulation

好的證據長什麼樣子？再用工具拆解一篇有問題的研究

台灣： AI-ECG 警示的實用型隨機試驗；瑞典： MASAI 偵出與間隔癌結果
原始研究證據表；擬真演練：以 PROBAST+AI 檢核 SepsiNet-TW

台灣案例｜成功

AI 心電圖警示：降低住院病人死亡率的隨機試驗

國防醫學院／三軍總醫院團隊； Lin 等， Nature Medicine （2024）

背景 Context

- 住院病人的心電圖量大，高風險變化不易即時被注意
- AI-ECG 能否不只「準」，還能救命?

做法 Approach

- 實用型隨機試驗： 39 位醫師隨機分組
- AI 判定高風險時，即時通知主治醫師
- 主要結果： 90 天全死因死亡率

成果 Results

15,965 人

納入的住院病人

3.6% vs 4.3%

90 天死亡率（警示組 vs 對照組）， HR 0.83

HR 0.69

預先設定之高風險心電圖次族群的全死因死亡

證據等級做到第 4 層：以醫師為單位隨機、看病人結果——台灣團隊示範了醫療 AI 該有的證據樣貌。

國際案例｜瑞典

MASAI：間隔癌結果支持非劣性，不等於已證實減少

Hernström 等（Lancet Digit Health 2025）； Gommers 等（The Lancet 2026）；兩個分析階段分開讀

背景 Context

- 只看「偵出更多」可能是過度診斷
- 關鍵：兩次篩檢之間冒出的間隔癌有沒有變多?

做法 Approach

- 105,934 名婦女隨機分派（分析 105,915 名）： AI 輔助 vs 標準雙人判讀
- 2025 分析：癌症偵出率與判讀工作量
- 2026 分析：間隔癌率，預設非劣性界值 20%

成果 Results

6.4 vs 5.0

每千人癌症偵出（2025 分析，約 +29%）

1.55 vs 1.76

每千人間隔癌；比值 0.88 （95% CI 0.65–1.18）

−44%

判讀工作量（2025 分析）

0.88 是點估計，區間跨過 1： 支持「不比雙人判讀差」，不能說已證實減少 12%。

用證據表讀 MASAI：能支持什麼、不能支持什麼

決策用證據表：每一格都要能回到原文的方法或表格

欄位	MASAI 的內容
研究問題	AI 輔助判讀取代雙人判讀，間隔癌是否不會變多?
設計與比較	個人隨機試驗；對照為瑞典標準雙人判讀
效果與不確定性	間隔癌比值 0.88 （ 0.65–1.18 ），非劣性成立；偵出率較高
偏誤與限制	單一國家、單一 AI 產品；未看死亡率；過度診斷仍待追蹤
適用性（台灣）	篩檢年齡、間隔與判讀制度不同，需逐項比對
下一步驗證	在地試辦，監測偵出、召回、間隔癌與判讀工作量

評讀不是填完表格就好：每一格都要說明，這個證據支持哪一種決策。

四個案例放在證據階梯上

● 明顯具備　◐ 部分具備　○ 不足（教學判讀，依研究發表當時）

	外部／多中心	前瞻或隨機	病人結果指標	次族群分析	流程設計
台灣 AI-ECG 警示	◐	●	●	●	●
瑞典 MASAI 乳房攝影	◐	●	◐	◐	●
美國照護管理演算法	○	○	○	●	◐
Epic 敗血症模型（W8）	○	○	○	○	◐

觀察： AI-ECG 以死亡率、 MASAI 以間隔癌為主要結果；照護管理演算法的問題，是獨立研究者做次族群分析後才發現。

獨立驗證很重要：這正是醫療 AI 三大中心中「AI 取證驗證中心」要扮演的角色（W2）。

擬真演練 Simulation

演練： SepsiNet-TW 研究摘要（虛構）

先獨立閱讀 5 分鐘，圈出你覺得可疑的地方

目的　建立深度學習模型，預測住院病人 6 小時內發生敗血症。

方法　回溯某醫學中心 2018–2023 年 52,310 次成人住院。敗血症以出院 ICD-10 申報碼定義（事件率 6.1%）。排除缺值超過 30% 的住院（18%）。以 112 項變數建模，含生命徵象、檢驗、「血液培養醫囑」與「抗生素開立」（未說明是否限於預測時點前）。所有住院紀錄隨機切分為訓練 80%、測試 20%。

結果　測試集準確率 95.2%、AUROC 0.94。另選 100 個案例，請 3 位住院醫師僅依生命徵象判斷，模型準確率高於醫師（95% vs 81%）。

結論　SepsiNet-TW 優於醫師判斷，建議全面導入臨床。

提示：這份摘要至少藏了 8 個問題，分布在 PROBAST+AI 的四個面向與「結論」本身。

擬真演練 Simulation

演練：用 PROBAST+AI 四面向檢核

分組 15 分鐘：每組找出問題、判定偏誤風險，並寫出「應該怎麼做」

面向	你找到的問題	偏誤風險	應該怎麼做
研究對象與資料		低／高／不清楚	
預測因子			
結果			
分析			
結論與適用性			

每組最後用一句話回答開場的問題：北城區域醫院該不該買？如果要買，先要求廠商補什麼證據？

課堂討論 In-class Discussion

課後延伸：你單位正在用的 AI ，證據在第幾層？

課後分組討論；下週開場每組 1 分鐘分享，不占本週 100 分鐘

- **Q1　盤點：**你的單位用過或聽過哪一個 AI 工具？它的證據大約在證據階梯第幾層？
- **Q2　指標：**廠商或論文報告的是哪些指標？缺了哪一個最讓你擔心？
- **Q3　公平：**若這個 AI 決定誰得到額外照護，你最想保障哪一群？避免漏掉，還是避免誤納？
- **Q4　行動：**如果要你主持本地驗證，你會選哪兩個指標當「通過標準」？

Q1 答「不知道」也是答案——代表醫院導入 AI 時，證據資訊沒有傳到第一線。

實務應用 Practice

把評讀變成採購問題：向廠商要的七份證據

醫院評估 AI 產品時，可直接放進需求說明書或評選須知

1	**適用範圍**	預期用途、適用族群、禁忌情境與已知限制
2	**資料來源**	訓練與驗證資料的醫院、期間、族群組成
3	**外部驗證**	至少一家非開發醫院的驗證結果，含信賴區間
4	**完整指標**	鑑別度、校準度、閾值下的敏感度、 PPV 與警示量
5	**次族群效能**	依年齡、性別、科別等分組結果
6	**本地驗證計畫**	上線前靜默測試的方法與通過標準
7	**上市後監測**	監測指標、警戒線、更新與通報機制

這七份證據，就是本週所學的「實務版」—— W13 會再補上法規與模型卡的要求。

延伸學習：評讀醫療 AI 的工具箱

課後自學用，不列入評量；期末評讀可直接使用

EQUATOR Network
報告指引總入口
TRIPOD+AI 、 CONSORT-AI 等全收錄
對應 Part 3

BMJ 2024
TRIPOD+AI
27 項主清單與摘要清單
對應 Part 3

BMJ 2025
PROBAST+AI
讀者用偏誤風險評讀
對應演練

美國 FDA
AI-Enabled Medical Devices 清單
已授權 AI 醫材與摘要
對應 Part 1

JAMA 2014
Dimick & Ryan： DiD
一頁讀懂差異中的差異
對應 Part 2

Nature Med 2024
Chouffani El Fassi 等
授權 ≠ 有臨床驗證
對應 Part 1

評讀三步：先定位證據層級，再用檢核表找漏洞，最後問「適不適用我們的病人」。

名詞小辭典 Glossary

本週名詞小辭典

中英對照，方便閱讀國際文獻

名詞	英文	白話解釋
差異中的差異	Difference-in-differences	導入組前後變化減去對照組前後變化，估計多出來的效果
非劣性	Non-inferiority	在預設界值內不比對照差；不等於比較好
偏誤風險	Risk of Bias	研究設計或分析使結果偏離真實的可能性
資料洩漏	Data Leakage	訓練時用到預測時點無法取得或與答案相關的資訊
校準度	Calibration	預測機率與實際發生率是否一致
決策曲線分析	Decision Curve Analysis	以淨效益評估模型在不同閾值下的臨床價值
間隔癌	Interval Cancer	兩次篩檢之間發現的癌症，常用來評估篩檢成效
演算法公平性	Algorithmic Fairness	模型對不同族群的表現與影響是否公平

案例研討 Case Study ｜美國

乳房攝影 CAD：已核准、有給付、廣泛使用，卻沒提升準確度

Lehman 等， JAMA Intern Med 2015； Breast Cancer Surveillance Consortium

- **1998** — FDA 核准乳房攝影電腦輔助偵測（CAD）
- **2002** — Medicare 開始給付，每次約 7 美元
- **2012** — 83% 的數位篩檢乳房攝影搭配 CAD 判讀
- **2015** — 逾 62.5 萬次攝影、 271 位放射科醫師：有無 CAD ，準確度皆無改善

決策點 Decision Point

你是給付單位：上市與給付十多年後才出現負面證據，現在該怎麼做？

先獨立想 1 分鐘，寫下你的選擇與理由，再看下一頁。

這是「上一代醫療 AI」的完整故事：核准、給付、普及，最後才被真實世界資料檢驗。

結果：花了錢、用得很普遍，但沒有更準

Lehman 等， JAMA Intern Med 2015； Breast Cancer Surveillance Consortium

約 4 億美元 / 年
美國 CAD 相關支出（作者估計，可能低估）

271 位
放射科醫師（107 位兩種方式都判讀過）

0 項
準確度指標獲得改善

這份研究的強項

- 真實世界大型登錄資料，跨 66 個機構
- 同一位醫師用與不用 CAD 可比較
- 看的是臨床篩檢結果，而非實驗室效能

制度上的缺口

- 早期證據多為讀片研究，非真實篩檢
- 給付後缺少定期再評估
- CAD 多找到 DCIS，未證實改善預後

上市許可與給付都不等於臨床價值；證據要隨真實使用持續更新。

討論：把本週的框架用在這個案例

三題擇一深入；先寫判斷，再寫證據與限制

Q1 **CAD 在證據階梯上，1998 年和 2015 年各在哪一層？**
連結本週：證據階梯

Q2 **現在的 AI 乳房攝影（如 MASAI），要怎麼避免重演 CAD 的歷史？**
連結本週：上市後監測

Q3 **觀察性研究得出「沒效」，要排除哪些偏誤才可信？**
連結本週：偏誤評讀

課堂進行約 15 分鐘
① 個人閱讀與作答　3 分鐘
② 小組討論，選一題深入　8 分鐘
③ 兩組分享、教師回饋　4 分鐘

出處
Lehman CD 等， JAMA Intern Med 2015； Kaiser Permanente Washington 新聞稿 2015-09-28
完整連結見講者備註

沒有標準答案：好答案會說清楚判斷、依據的證據，以及還缺什麼。

Summary

本週重點回顧

一頁掌握醫療 AI 實證評估

主題	一句話重點
證據落差	多數 AI 醫材只有回溯證據；準≠有效，中間還有流程、行為、處置
證據階梯	內部 → 外部 → 早期臨床 → RCT → 上市後；結論不可越級
差異中的差異	兩組前後變化相減；前提是平行趨勢，算出來不等於因果已證實
報告與評讀	報告指引看完整性， PROBAST+AI 看偏誤；都不能證明臨床有效
指標與結論	事件少時別看準確率；非劣性不等於優越，點估計要看區間
公平性	偏誤常藏在標籤與測量；先定義保障誰，再選公平定義；做次族群分析

帶走一個問題：下次看到「準確率 9X%」，你會先問哪三個問題?

下週預告 Next Week

W13　醫療 AI 法規、倫理與資料治理

證據說「它有用」之後，下一關是「它合法嗎？可以安全地用嗎？」

- SaMD：什麼樣的 AI 軟體算醫療器材?
- 台灣 TFDA、美國 FDA PCCP、歐盟 AI 法案的監管重點
- 可解釋性、模型卡與透明度
- 個資法、健保資料與去識別化；聯邦學習
- 擬真演練：判定三個 AI 產品是否屬於醫療器材

課前準備

- 找一個你用過的健康相關 App 或 AI 工具
- 想一想：它算不算醫療器材？為什麼？

本週的「七份證據」清單，下週會加上法規與透明度要求，變成完整的 AI 採購檢核表。

主要參考資料

數據以原始文獻為準（查證日期： 2026 年 10 月）

Collins GS, et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. BMJ, 385, e078378.

Moons KGM, et al. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or AI methods. BMJ.

Sounderajah V, et al. (2025). The STARD-AI reporting guideline for diagnostic accuracy studies using artificial intelligence. Nature Medicine.

Gallifant J, et al. (2025). The TRIPOD-LLM reporting guideline for studies using large language models. Nature Medicine.

Vasey B, et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by AI: DECIDE-AI. Nature Medicine; BMJ.

Liu X, et al. (2020). Reporting guidelines for clinical trial reports for interventions involving AI: the CONSORT-AI extension. Nature Medicine; BMJ; Lancet Digital Health.

Vickers AJ, Elkin EB. (2006). Decision curve analysis: a novel method for evaluating prediction models. Medical Decision Making, 26(6), 565–574.

Suresh H, Guttag J. (2021). A framework for understanding sources of harm throughout the machine learning life cycle. EAAMO '21.

Kleinberg J, et al. (2016). Inherent trade-offs in the fair determination of risk scores. arXiv:1609.05807； Chouldechova A. (2017). Big Data, 5(2), 153–163.

Dimick JB, Ryan AM. (2014). Methods for evaluating changes in health care policy: the difference-in-differences approach. JAMA, 312(22), 2401–2402.

Chouffani El Fassi S, et al. (2024). Not all AI health tools with regulatory authorization are clinically validated. Nature Medicine.

Beede E, et al. (2020). A human-centered evaluation of a deep learning system deployed in clinics for the detection of diabetic retinopathy. CHI 2020.

Daneshjou R, et al. (2022). Disparities in dermatology AI performance on a diverse, curated clinical image set. Science Advances. （arXiv:2111.08006）

參考資料 References

證據與案例出處

本週案例之原始來源；數據以原始文獻為準

Wu E, et al. (2021). How medical AI devices are evaluated: limitations and recommendations from an analysis of FDA approvals. Nature Medicine, 27, 582–584.

Nagendran M, et al. (2020). Artificial intelligence versus clinicians: systematic review of design, reporting standards, and claims of deep learning studies. BMJ, 368, m689.

Han R, et al. (2024). Randomised controlled trials evaluating artificial intelligence in clinical practice: a scoping review. Lancet Digital Health, 6(5), e367–e373.

Lin CS, et al. (2024). AI-enabled electrocardiography alert intervention and all-cause mortality: a pragmatic randomized clinical trial. Nature Medicine.

Hernström V, et al. (2025). Screening performance and characteristics of breast cancer detected in the MASAI trial. Lancet Digital Health, 7(3), e175–e183.

Gommers J, et al. (2026). Interval cancer, sensitivity, and specificity comparing AI-supported mammography screening with standard double reading in the MASAI study. The Lancet.

Obermeyer Z, et al. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366, 447–453.

Sjoding MW, et al. (2020). Racial bias in pulse oximetry measurement. NEJM, 383, 2477–2478.

Wong A, et al. (2021). External validation of a widely implemented proprietary sepsis prediction model. JAMA Internal Medicine, 181(8), 1065–1070.

CLOSING

準確，是證據的起點，不是終點

會問「在誰身上、跟什麼比、最後病人有沒有變好」的人，才是醫療 AI 時代最需要的把關者。