智慧醫療與科技發展　Smart Healthcare & Technology Development

醫療 AI 實證評估

Evidence Appraisal of Medical AI

12

第 12 週｜評估、治理與落地　Unit 4
證據落差 → 評估階段 → 報告指引 → 指標與效益 → 偏誤與公平性 → 研究檢核演練

謝楠楨 講座教授 · 2026 · 雙語版（English terms ＋ 中文講解）

本週地圖 This Week

本週六個部分

從「看懂證據」到「挑出漏洞」，練習用評估工具審視一篇研究

01

證據落差

Evidence Gap

宣稱很多、前瞻證據很少

02

評估階段

Evaluation Stages

從回溯驗證到隨機試驗

03

報告指引

Reporting Guidelines

TRIPOD+AI 等指引家族

04

指標與效益

Metrics & Utility

鑑別、校準、臨床效益

05

偏誤與公平

Bias & Fairness

偏誤來源、公平性指標

06

案例與演練

Cases

台灣 AI-ECG 、MASAI 、研究檢核

教學重點｜W5 學「模型怎麼做」、 W8 學「上線會怎樣」，本週學「怎麼判斷別人說的是不是真的」。

學習目標 Learning Objectives

本週結束時，你能夠……

每一項目標都對應課程三項核心能力；期中、期末個案分析即依此命題

1	把一項 AI 證據放上五層證據階梯，判斷能下什麼結論	C3 實證評估
2	依研究類型選用 TRIPOD+AI 、 DECIDE-AI 等報告指引	C3 實證評估
3	以 PROBAST+AI 四面向評讀一篇研究的偏誤風險	C3 實證評估
4	解讀校準度、決策曲線與次族群公平性	C3 實證評估

對應評量｜期末 Q2 （證據與偏誤）

課程脈絡 Where we are

承上

W11 多為自報成效

本週

怎麼判斷別人說的是不是真的

啟下

W13 法規、倫理與資料治理

教學重點｜W5 學「模型怎麼做」、 W8 學「上線會怎樣」，本週學「怎麼判斷證據」。

開場 Opening

北城區域醫院院長收到一份廠商簡報

「我們的敗血症 AI 準確率 95%，論文已發表，優於醫師判斷。」——要不要買?

SepsiNet-TW 產品簡報（虛構）

- 準確率 95.2%、AUROC 0.94
- 訓練資料：5 萬多次住院
- 「在 100 個案例中優於 3 位醫師」
- 已發表於國際期刊
- 建議全院導入

院長該問的問題

- 資料從哪來？和我們醫院像嗎?
- 「敗血症」是怎麼定義的?
- 95% 是在哪一群人身上算的?
- 有沒有在別家醫院驗證過?
- 用了之後，病人結果有變好嗎?

教學重點｜本週最後的演練，就是拆解這份研究——先記住你的直覺判斷，下課前再對照。

01

PART 1

醫療 AI 的證據落差 The Evidence Gap

宣稱很多，前瞻證據很少

上市醫材與發表論文的證據等級
隨機對照試驗的現況與限制

Part 1 ｜三組數字

醫療 AI 的證據有多薄？三組數字

準確度研究很多，「用了之後病人有沒有變好」的研究很少

126 ／ 130

FDA 核准 AI 醫材僅有回溯性評估

Wu 等（Nature Medicine, 2021）分析 2015–2020 年核准品項

2 項

深度學習影像研究中的隨機對照試驗

Nagendran 等（BMJ, 2020）；另 81 項非隨機研究多屬高偏誤風險

86 項

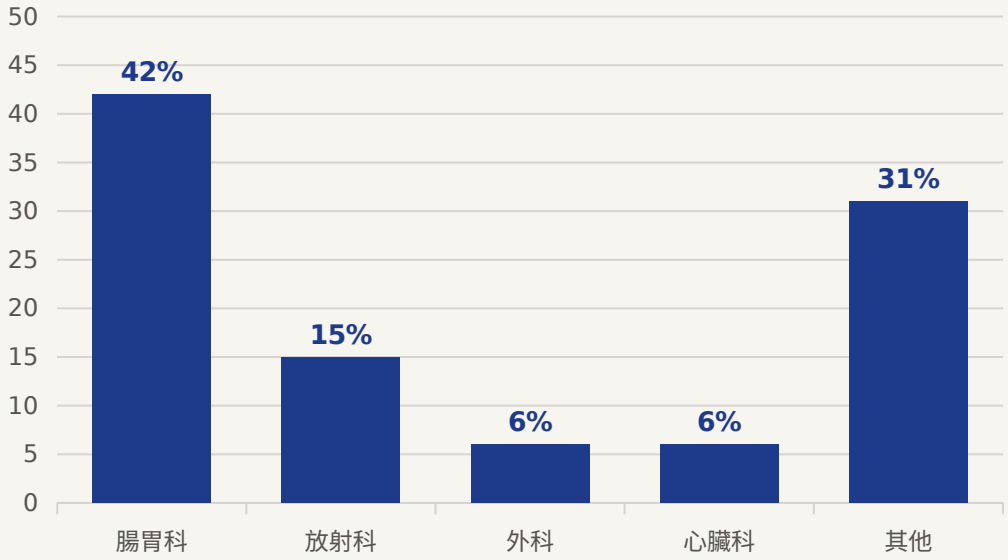
2018–2023 年 AI 臨床隨機試驗

Han 等（Lancet Digital Health, 2024）；約六成為單一中心

教學重點｜AI 醫材已超過千項，但多數上市證據停在「回溯資料上算得準」，而非「臨床用了有效」。

AI 隨機試驗集中在少數科別

Han 等（2024）納入之 AI 臨床隨機試驗，依科別分布（約略比例）



怎麼解讀

- 腸胃科以大腸鏡息肉偵測為主
- 約八成試驗主要結果為正向——但可能有發表偏誤
- 主要結果多為「偵出率」，少有死亡、住院等病人結果
- 多數只在單一國家進行

教學重點｜「有 RCT」不等於「證據充分」：還要看結果指標是什麼、在哪裡做、能不能推論到我們的病人。

Part 1 | 關鍵觀念

「算得準」到「病人變好」之間，還隔了四道關

模型效能只是因果鏈的第一環



技術效能	流程整合	人的行為	臨床行動	病人結果
AUROC、敏感度	警示有沒有送到對的人（W8）	信任、警報疲勞、自動化偏誤	有沒有對應的有效處置	死亡、住院、生活品質

例： Epic 敗血症模型（W8）在第一關就失準；即使模型準，若後四關沒做好，病人結果也不會改變。

教學重點｜評估醫療 AI 要問到最右邊：它改變了誰的什麼行為？最後病人有沒有受益？

02

PART 2

評估階段與研究設計 Evaluation Stages & Study Design

像新藥一樣， AI 也要分階段累積證據

醫療 AI 證據階梯：從內部驗證到上市後監測
各階段該用什麼研究設計、回答什麼問題

Part 2 | 證據階梯

醫療 AI 的證據階梯

越往上，越接近「在真實世界對病人有益」；成本與時間也越高



教學重點 | W8 的 Epic 敗血症模型停在第 1 層就上市；TREWS 做到第 3–5 層——差別就在證據階梯。

每一層要回答的問題與研究設計

評讀時先判斷：這篇研究在哪一層？它能支持什麼樣的結論？

層級	要回答的問題	常見設計	可以下的結論
內部驗證	在開發資料上準不準?	回溯世代、資料切分、交叉驗證	「有潛力」
外部驗證	換醫院、換時間還準嗎?	多中心回溯、時間驗證	「可推論到類似場域」
早期臨床評估	實際使用安全嗎？人怎麼用?	前瞻觀察、靜默測試、可用性研究	「可以進一步試驗」
隨機對照試驗	用了之後病人結果更好嗎?	個人或群集隨機、階梯式設計	「具臨床效益」
上市後監測	長期是否仍安全有效?	真實世界資料、登錄系統	「持續有效」或需修正

教學重點｜最常見的過度推論：拿第 1 層的研究，下第 4 層的結論（「建議全面導入」）。

Part 2 | 試驗設計

AI 隨機試驗的三種常見設計

AI 介入常是「整個流程」，所以設計比藥物試驗更多元

01

個人隨機

Individual RCT

每位病人隨機分組；例： MASAI 乳房攝影、大腸鏡 AI。需防止醫師在兩組間「學習外溢」

02

群集隨機

Cluster RCT

以醫師、病房或醫院為單位隨機；適合警示類 AI。例：台灣 AI-ECG 試驗以醫師為單位

03

階梯式設計

Stepped-wedge

各單位依序導入，最後全部使用；適合「一定要導入」但想評估效益的情境

教學重點｜選設計要考慮「污染」：同一位醫師同時照顧兩組病人，看過 AI 警示後，對另一組也會更警覺。

03

PART 3

報告指引與評讀工具 Reporting Guidelines & Appraisal Tools

不是用來背的清單，而是「該問哪些問題」的提示

AI 報告指引家族： TRIPOD+AI 、 STARD-AI 、 DECIDE-AI 、 CONSORT-AI 等
偏誤風險評讀： PROBAST+AI

Part 3 | 指引地圖

醫療 AI 報告指引家族：依研究類型選用

都可在 EQUATOR Network 查到；論文投稿與審查時常被要求附上檢核表

研究類型	報告指引	發表	重點
預測模型開發／驗證	TRIPOD+AI	BMJ 2024	27 項；取代 2015 年 TRIPOD
大型語言模型研究	TRIPOD-LLM	Nature Medicine 2025	LLM 特有項目，如提示與版本
診斷準確度研究	STARD-AI	Nature Medicine 2025	參考標準、資料集特性
醫學影像 AI	CLAIM	Radiology: AI 2020 ／ 2024 更新	影像資料、標註、切分
早期臨床評估	DECIDE-AI	Nature Medicine ／ BMJ 2022	人機互動、安全、使用者學習
隨機試驗計畫書／報告	SPIRIT-AI ／ CONSORT-AI	2020 （三刊同步）	AI 版本、輸入、錯誤分析
偏誤風險評讀（讀者用）	PROBAST+AI	BMJ 2025	評讀研究品質與適用性

教學重點｜記一個原則：報告指引是給「作者」寫清楚； PROBAST+AI 是給「讀者」判斷可不可信。

TRIPOD+AI：預測模型研究最該寫清楚的事

Collins 等（BMJ, 2024）； 27 項主清單，另有摘要清單——以下為評讀時最關鍵的八項

面向	要寫清楚什麼	沒寫會怎樣
資料來源	哪些醫院、期間、納入與排除條件	無法判斷是否像我們的病人
結果定義	「敗血症」用什麼標準、在什麼時間點判定	不同定義的準確度無法比較
預測因子	使用哪些變數、在預測時點是否已可取得	可能「偷看答案」（資料洩漏）
樣本與缺值	樣本數、事件數、缺值如何處理	排除缺值可能造成選擇偏誤
模型與切分	演算法、超參數、訓練／測試如何切分	同一病人跨組會高估效能
效能評估	鑑別度、校準度、臨床效益、信賴區間	只報準確率會誤導
公平性	各次族群的效能	看不出對誰比較不準
開放科學	程式碼、模型、資料可否取得	無法重現或獨立驗證

教學重點｜TRIPOD+AI 特別新增「公平性」與「開放科學」——這是 AI 研究與傳統統計模型最大的差異。

Part 3 | 臨床評估指引

走進臨床之後： DECIDE-AI 與 CONSORT-AI

從「模型準不準」轉到「人和 AI 一起用時發生什麼事」

DECIDE-AI （早期臨床評估）

- 17 項 AI 特定＋ 10 項通用項目
  - 使用者是誰、受過什麼訓練
- AI 建議被採納或推翻的比例
  - 使用者學習曲線與工作流變化
  - 安全事件與錯誤分析

CONSORT-AI （隨機試驗報告）

- 在 CONSORT 上新增 14 項 AI 項目
- AI 版本與是否在試驗中更新
  - 輸入資料的取得與品質處理
- AI 輸出如何呈現給使用者
  - 錯誤案例的分析方式

教學重點｜兩者共同重點：寫清楚「人機互動」——同一個 AI，介面與流程不同，效果就可能不同。

Part 3 ｜評讀工具

PROBAST+AI： 讀者用的偏誤風險評讀

Moons 等（BMJ, 2025）；分「模型開發」與「模型評估」兩部分，各依四個面向判定

01

研究對象與資料

Participants & data

資料來源是否適當？納入排除是否造成偏誤？

02

預測因子

Predictors

定義與測量是否一致？預測時點是否可取得？

03

結果

Outcome

定義是否客觀？是否受預測因子影響？

04

分析

Analysis

樣本數、缺值、過度擬合、校準與驗證是否適當？

判定：每個面向評為低／高／不清楚偏誤風險，並另評「適用性」——研究再嚴謹，若對象不像我們的病人，仍不適用。

教學重點｜PROBAST+AI 新增「品質」與「公平性」相關問題；本週演練會用它的四個面向拆解 SepsiNet-TW 。

04

PART 4

指標與臨床效益 Metrics & Clinical Utility

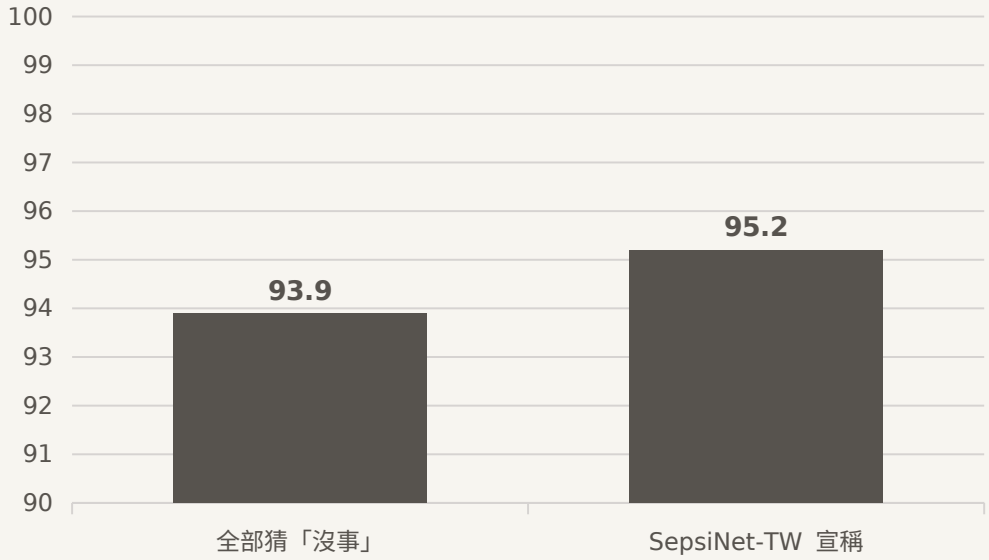
準確率會騙人：選對指標，才看得到真相

準確率陷阱、鑑別度與校準度
決策曲線分析：模型到底有沒有用

Part 4 | 準確率陷阱

準確率 95%，可能什麼都沒預測到

當事件率只有 6% 時，「全部猜沒事」就有 94% 準確率



該要求的指標

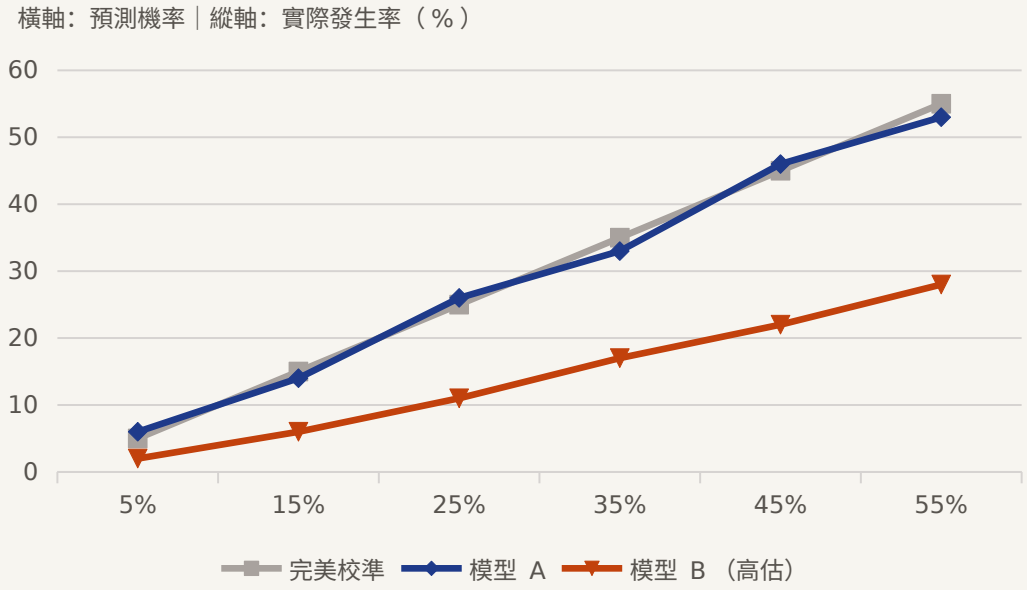
- **鑑別度：** AUROC，事件少時加看 AUPRC
- **校準度：** 預測機率是否接近實際發生率
- **閾值表現：** 敏感度、 PPV 、每日警示量（W8）
- **臨床效益：** 淨效益、病人結果

教學重點｜看到「準確率」就要先問事件率；不平衡資料只報準確率，幾乎可以視為警訊。

Part 4 ｜校準度

鑑別度好，不代表機率可信：校準度

兩個 AUROC 相同的模型，預測機率可能差很多（教學示意）



為什麼重要

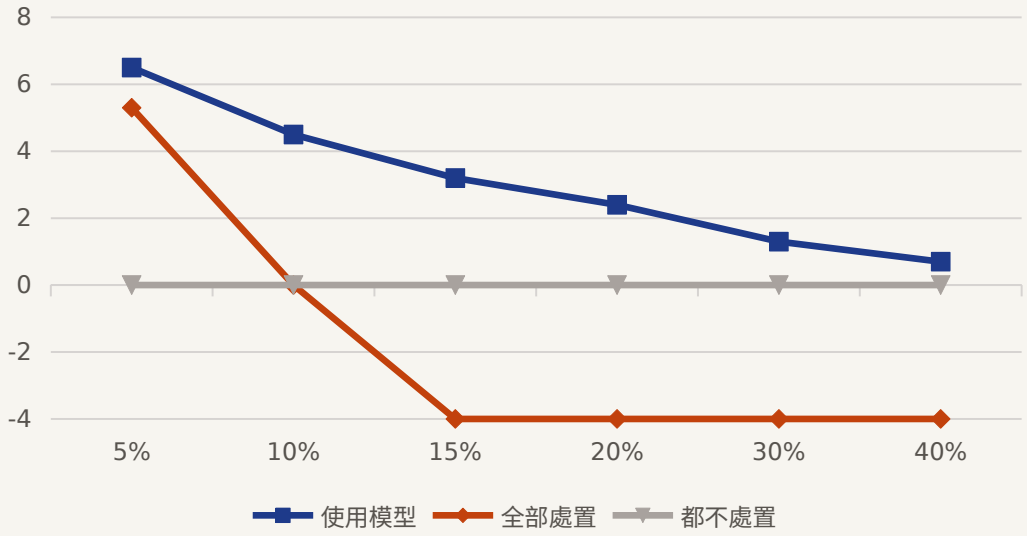
- 模型 B 說「45% 會惡化」，實際只有 22%
- 醫師若依機率決定處置，會過度治療
- 換醫院後最常壞掉的就是校準（W8）
- 可重新校準，不一定要重新訓練

教學重點｜風險分數要拿來「跟病人說明」或「決定處置」時，校準度往往比 AUROC 更重要。

決策曲線分析：用模型，比「全部處置」或「都不處置」更好嗎?

淨效益＝真陽性比例－偽陽性比例 ×（閾值勝算）；事件率 10%、AUROC 約 0.80 試算

橫軸：處置閾值機率｜縱軸：淨效益（每 100 人；低於－4 截斷顯示）



怎麼讀

- 曲線越高越好
- 藍線高於紅線與灰線的區間，才是模型「有用」的範圍
- 閾值代表臨床取捨：多願意為抓到 1 位而多處置幾位
- Vickers & Elkin （2006）提出

教學重點｜決策曲線把「準不準」翻譯成「值不值得用」——這是從統計走向臨床決策的橋梁。

05

PART 5

偏誤與公平性 Bias & Fairness

AI 會學到資料裡的不公平，還會把它放大

偏誤從哪裡來： AI 生命週期的六個來源
公平性指標與兩難；次族群分析

Part 5 | 偏誤來源

偏誤沿著 AI 生命週期進入模型

依 Suresh & Guttag （2021）架構整理，附醫療例子

來源	說明	醫療例子
歷史偏誤	現實世界本來就不平等	弱勢族群就醫少，紀錄中的病況被低估
代表性偏誤	訓練資料缺少某些族群	以歐美白人為主的皮膚病影像
測量偏誤	代理指標或儀器對各群不一致	以醫療費用代表健康需求；血氧機
彙整偏誤	一個模型套用在差異很大的族群	成人模型直接用在高齡衰弱長者
評估偏誤	測試資料不能代表使用族群	只在醫學中心驗證，就賣給區域醫院
部署偏誤	使用方式與設計目的不同	篩檢工具被拿來決定是否收治

教學重點｜偏誤不只是「資料不平衡」：從問題定義、標籤選擇到部署方式，每一步都可能放進偏誤。

國際案例｜美國・教訓

以「醫療費用」預測「健康需求」的演算法

Obermeyer 等， Science （2019）；美國廣泛使用的照護管理演算法

背景 Context

- 醫院用演算法挑選需要額外照護管理的病人
- 模型以「未來醫療費用」作為預測目標

做法 Approach

- 研究者比較同一風險分數下，黑人與白人病人的實際病況
- 發現同分的黑人病人，慢性病數量明顯較多
- 原因：黑人病人取得醫療較少，費用低≠較健康

成果 Results

17.7%

原演算法：被自動納入額外照護者中的黑人比例

46.5%

改以健康指標為目標後，黑人比例

標籤選擇

偏誤不是來自種族變數，而是來自預測目標

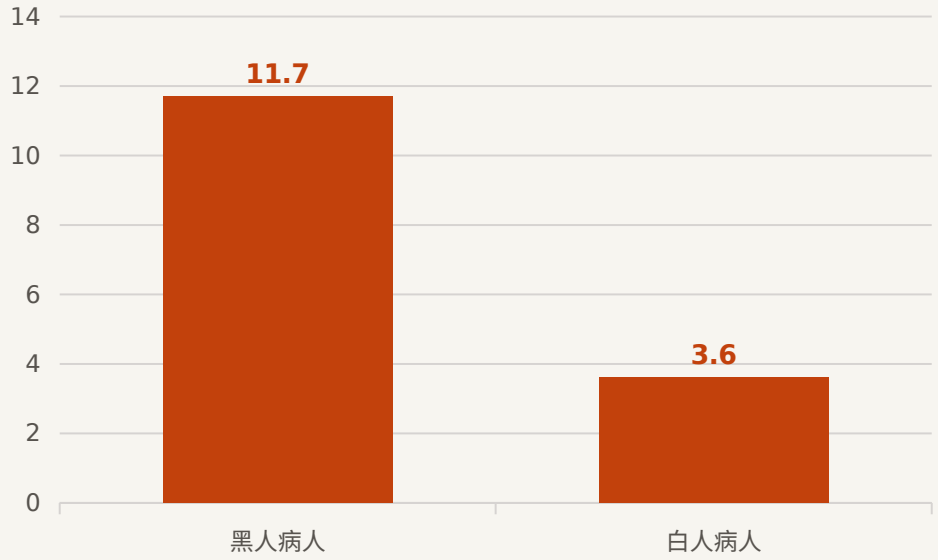
資料來源： Obermeyer Z, et al. Science 2019;366(6464):447–453 。

教學重點｜啟示｜最危險的偏誤藏在「標籤」裡：預測目標選錯，模型越準，不公平越嚴重。

Part 5 | 測量偏誤

儀器本身也可能有偏誤：脈搏血氧機

Sjoding 等（NEJM, 2020）：血氧機讀數 92–96% 時，動脈血實際 < 88% 的比例



對 AI 的意義

- 血氧值是許多預警模型（如 NEWS2）的輸入
- 輸入有系統性誤差，模型就會對某群人低估風險
- 這類偏誤在模型內部「看不到」
- 需回到資料來源與儀器端檢查

教學重點｜台灣也要問：深膚色移工、高齡末梢循環差的病人，血氧與其他感測讀數是否同樣可靠？

「公平」有不同定義，而且常常無法同時成立

以「AI 篩出高風險者，給予額外照護」為例

01

群體一致

Demographic parity

各群被篩為高風險的比例相同

02

機會均等

Equal opportunity

真正會惡化的人中，各群被抓到的比例（敏感度）相同

03

校準一致

Calibration within groups

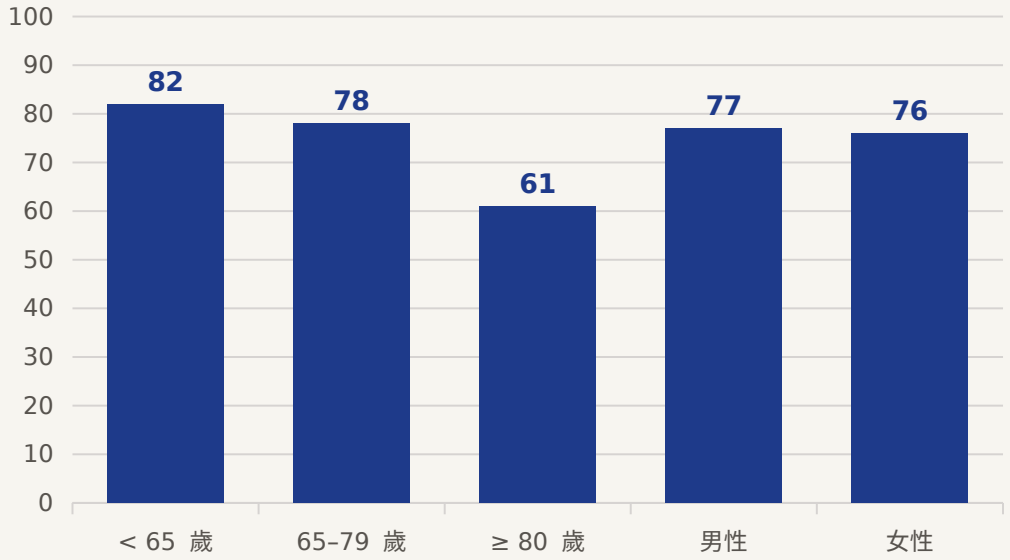
同樣預測 20% 的人，各群實際發生率都約 20%

不可能定理：當各群的事件率不同時，除非模型完美，否則「機會均等」與「校準一致」無法同時滿足（Kleinberg 等 2016；Chouldechova 2017）。

教學重點｜所以公平性是「選擇」：要由臨床、倫理與病人代表共同決定，在這個用途下哪一種公平最重要。

整體準確，不代表對每一群都準

北城區域醫院 AI 預警模型的次族群敏感度（教學示意）



觀察與行動

- 整體敏感度約 76%，看起來可接受
- ≥ 80 歲只有 61%—— 最需要的人最常被漏掉
- 可能原因：高齡者基礎生命徵象不同、訓練樣本少
- 對策：分群閾值、補充資料、加上人工評估

教學重點｜評讀研究時，沒有次族群分析就要追問；採購時，要求廠商提供「我們病人組成」下的次族群效能。

06

PART 6

國際與台灣案例、擬真演練 Cases & Simulation

好的證據長什麼樣子？再用工具拆解一篇有問題的研究

台灣： AI-ECG 警示的實用型隨機試驗；瑞典： MASAI 最終結果
擬真演練：以 PROBAST+AI 與 TRIPOD+AI 檢核 SepsiNet-TW

台灣案例｜成功

AI 心電圖警示：降低住院病人死亡率的隨機試驗

國防醫學院／三軍總醫院團隊； Lin 等， Nature Medicine （2024）

背景 Context

- 住院病人的心電圖量大，高風險變化不易即時被注意
- AI-ECG 能否不只「準」，還能救命?

做法 Approach

- 實用型隨機試驗： 39 位醫師隨機分組
- AI 判定高風險時，即時通知主治醫師
- 主要結果： 90 天全死因死亡率

成果 Results

15,965 人

納入的住院病人

3.6% vs 4.3%

90 天死亡率（警示組 vs 對照組）， HR 0.83

HR 0.69

預先設定之高風險心電圖次族群的全死因死亡

資料來源： Lin CS, et al. Nature Medicine 2024； DOI: 10.1038/s41591-024-02961-4； HCPLive （2024-05）。

教學重點｜啟示｜證據等級做到第 4 層：以醫師為單位隨機、看病人結果——台灣團隊示範了醫療 AI 該有的證據樣貌。

國際案例｜瑞典・成功

MASAI 最終結果： AI 篩檢減少「間隔癌」

Lund University； The Lancet （2026 年 1 月）； W2 介紹過期中結果

背景 Context

- 只看「偵出更多」可能是過度診斷
- 真正關鍵：兩次篩檢之間冒出的間隔癌有沒有減少?

做法 Approach

- 約 10.6 萬名婦女隨機分派： AI 輔助 vs 標準雙人判讀
- 所有受試者完成兩年追蹤（2025 年 12 月）
- 主要結果改為間隔癌發生率

成果 Results

+29%

癌症偵出數（AI 組較多）

−12%

間隔癌（93 → 82 例）

−44%

放射科醫師判讀工作量

資料來源： Lund University 新聞稿（2026-01-30）； The Lancet, DOI: 10.1016/S0140-6736(25)02464-X 。

教學重點｜啟示｜從「偵出率」走到「間隔癌」，是從替代指標走向病人結果——這正是證據階梯往上爬的樣子。

案例｜比較

四個案例放在證據階梯上

● 明顯具備　◐ 部分具備　○ 不足（教學判讀，依研究發表當時）

	外部／多中心	前瞻或隨機	病人結果指標	次族群分析	流程設計
台灣 AI-ECG 警示	◐	●	●	●	●
瑞典 MASAI 乳房攝影	◐	●	●	◐	●
美國照護管理演算法	●	○	○	●	◐
Epic 敗血症模型（W8）	○	○	○	○	◐

觀察：成功案例都把「病人結果」當主要指標；照護管理演算法的問題，則是在被獨立研究者做次族群分析後才被發現。

教學重點｜獨立驗證很重要：這正是醫療 AI 三大中心中「AI 取證驗證中心」要扮演的角色（W2）。

擬真演練 Simulation

演練： SepsiNet-TW 研究摘要（虛構）

先獨立閱讀 5 分鐘，圈出你覺得可疑的地方

目的　建立深度學習模型，預測住院病人 6 小時內發生敗血症。

方法　回溯某醫學中心 2018–2023 年 52,310 次成人住院。敗血症以出院 ICD-10 申報碼定義（事件率 6.1%）。排除缺值超過 30% 的住院（18%）。以 112 項變數建模，含生命徵象、檢驗、「血液培養醫囑」與「抗生素開立」。所有住院紀錄隨機切分為訓練 80%、測試 20%。

結果　測試集準確率 95.2%、AUROC 0.94。另選 100 個案例，請 3 位住院醫師僅依生命徵象判斷，模型準確率高於醫師（95% vs 81%）。

結論　SepsiNet-TW 優於醫師判斷，建議全面導入臨床。

教學重點｜提示：這份摘要至少藏了 8 個問題，分布在 PROBAST+AI 的四個面向與「結論」本身。

擬真演練 Simulation

演練：用 PROBAST+AI 四面向檢核

分組 15 分鐘：每組找出問題、判定偏誤風險，並寫出「應該怎麼做」

面向	你找到的問題	偏誤風險	應該怎麼做
研究對象與資料		低／高／不清楚	
預測因子			
結果			
分析			
結論與適用性			

教學重點｜每組最後用一句話回答開場的問題：北城區域醫院該不該買？如果要買，先要求廠商補什麼證據？

實務應用 Practice

把評讀變成採購問題：向廠商要的七份證據

醫院評估 AI 產品時，可直接放進需求說明書或評選須知

1	**適用範圍**	預期用途、適用族群、禁忌情境與已知限制
2	**資料來源**	訓練與驗證資料的醫院、期間、族群組成
3	**外部驗證**	至少一家非開發醫院的驗證結果，含信賴區間
4	**完整指標**	鑑別度、校準度、閾值下的敏感度、 PPV 與警示量
5	**次族群效能**	依年齡、性別、科別等分組結果
6	**本地驗證計畫**	上線前靜默測試的方法與通過標準
7	**上市後監測**	監測指標、警戒線、更新與通報機制

教學重點｜這七份證據，就是本週所學的「實務版」—— W13 會再補上法規與模型卡的要求。

名詞小辭典 Glossary

本週名詞小辭典

中英對照，方便閱讀國際文獻

名詞	英文	白話解釋
外部驗證	External Validation	在非開發資料（他院或他時段）上檢驗模型效能
報告指引	Reporting Guideline	規範研究應完整報告哪些內容的檢核表
偏誤風險	Risk of Bias	研究設計或分析使結果偏離真實的可能性
資料洩漏	Data Leakage	訓練時用到預測時點無法取得或與答案相關的資訊
校準度	Calibration	預測機率與實際發生率是否一致
決策曲線分析	Decision Curve Analysis	以淨效益評估模型在不同閾值下的臨床價值
間隔癌	Interval Cancer	兩次篩檢之間發現的癌症，常用來評估篩檢成效
演算法公平性	Algorithmic Fairness	模型對不同族群的表現與影響是否公平

Summary

本週重點回顧

一頁掌握醫療 AI 實證評估

主題	一句話重點
證據落差	多數 AI 醫材只有回溯證據；準≠有效，中間還有流程、行為、處置
證據階梯	內部 → 外部 → 早期臨床 → RCT → 上市後；結論不可越級
報告指引	依研究類型選 TRIPOD+AI 、 STARD-AI 、 DECIDE-AI 、 CONSORT-AI 等
評讀工具	PROBAST+AI 四面向：對象資料、預測因子、結果、分析
指標	事件少時別看準確率；要看校準度與決策曲線
公平性	偏誤常藏在標籤與測量；公平定義需取捨；一定要做次族群分析

教學重點｜帶走一個問題：下次看到「準確率 9X%」，你會先問哪三個問題?

課堂討論 In-class Discussion

課堂討論：你單位正在用的 AI，證據在第幾層？

分組 15 分鐘，每組 3 分鐘分享

- **Q1　盤點：**你的單位用過或聽過哪一個 AI 工具？它的證據大約在證據階梯第幾層？
- **Q2　指標：**廠商或論文報告的是哪些指標？缺了哪一個最讓你擔心？
- **Q3　公平：**你照顧的病人中，哪一群最可能被這個 AI「看不準」？為什麼？
- **Q4　行動：**如果要你主持本地驗證，你會選哪兩個指標當「通過標準」？

教學重點｜Q1 答「不知道」也是答案——代表醫院導入 AI 時，證據資訊沒有傳到第一線。

下週預告 Next Week

W13　醫療 AI 法規、倫理與資料治理

證據說「它有用」之後，下一關是「它合法嗎？可以安全地用嗎？」

- SaMD：什麼樣的 AI 軟體算醫療器材?
- 台灣 TFDA、美國 FDA PCCP、歐盟 AI 法案的監管重點
- 可解釋性、模型卡與透明度
- 個資法、健保資料與去識別化；聯邦學習
- 擬真演練：判定三個 AI 產品是否屬於醫療器材

課前準備

- 找一個你用過的健康相關 App 或 AI 工具
- 想一想：它算不算醫療器材？為什麼?

教學重點｜本週的「七份證據」清單，下週會加上法規與透明度要求，變成完整的 AI 採購檢核表。

參考資料 References

主要參考資料

數據以原始文獻為準（查證日期： 2026 年 10 月）

Collins GS, et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. BMJ, 385, e078378.

Moons KGM, et al. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or AI methods. BMJ.

Sounderajah V, et al. (2025). The STARD-AI reporting guideline for diagnostic accuracy studies using artificial intelligence. Nature Medicine.

Gallifant J, et al. (2025). The TRIPOD-LLM reporting guideline for studies using large language models. Nature Medicine.

Vasey B, et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by AI: DECIDE-AI. Nature Medicine; BMJ.

Liu X, et al. (2020). Reporting guidelines for clinical trial reports for interventions involving AI: the CONSORT-AI extension. Nature Medicine; BMJ; Lancet Digital Health.

Vickers AJ, Elkin EB. (2006). Decision curve analysis: a novel method for evaluating prediction models. Medical Decision Making, 26(6), 565–574.

Suresh H, Guttag J. (2021). A framework for understanding sources of harm throughout the machine learning life cycle. EAAMO '21.

Kleinberg J, et al. (2016). Inherent trade-offs in the fair determination of risk scores. arXiv:1609.05807； Chouldechova A. (2017). Big Data, 5(2).

參考資料 References

證據與案例出處

本週案例之原始來源；數據以原始文獻為準

Wu E, et al. (2021). How medical AI devices are evaluated: limitations and recommendations from an analysis of FDA approvals. Nature Medicine, 27, 582–584.

Nagendran M, et al. (2020). Artificial intelligence versus clinicians: systematic review of design, reporting standards, and claims of deep learning studies. BMJ, 368, m689.

Han R, et al. (2024). Randomised controlled trials evaluating artificial intelligence in clinical practice: a scoping review. Lancet Digital Health, 6(5), e367–e373.

Lin CS, et al. (2024). AI-enabled electrocardiography alert intervention and all-cause mortality: a pragmatic randomized clinical trial. Nature Medicine.

Lund University (2026-01-30). AI support in breast cancer screening leads to fewer missed cancer cases； The Lancet (2026).

Obermeyer Z, et al. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366, 447–453.

Sjoding MW, et al. (2020). Racial bias in pulse oximetry measurement. NEJM, 383, 2477–2478.

Wong A, et al. (2021). External validation of a widely implemented proprietary sepsis prediction model. JAMA Internal Medicine, 181(8), 1065–1070.

CLOSING

準確，是證據的起點，不是終點

會問「在誰身上、跟什麼比、最後病人有沒有變好」的人，才是醫療 AI 時代最需要的把關者。